


Hierarchiniai tiesiniai modeliai (HLM)

Hierarchical Linear Modeling
(Mixed Models)

Kas tas HLM?


- **Matematiškai HLM yra tiesinės regresijos apibendrinimas atvejui, kai koeficientai prie regresorių savo ruožtu yra atsitiktiniai dydžiai, kuriems irgi galima sudaryti regresinius modelius.**
- **Praktikoje HLM reiškia, kad modeliuodami atsižvelgiame į hierarchinę duomenų struktūrą.**

Hierarchinė struktūra




3

Hierarchinė struktūra



4

Hierarchinė struktūra



5


Hierarchinė struktūra

- sirgimo covid-19 eigos priklausomybė nuo ligonio sveikatos būklės, amžiaus ir antsvorio (I lygmuo) ir nuo gydytojo (II lygmuo).
- kriminologas tiria jaunimo polinkio į nusikalstamumą priklausomybę nuo respondento šeimos socialinių ir ekonominių parametrų (I lygmuo), gyvenamojo rajono kriminogeniškumo (II lygmuo) ir nuo miesto didumo (III lygmuo).

6

Hierarchinė struktūra

- Pirmasis lygmuo yra žemiausias.
- Elementai apibrėžiami kiekviename lygmenyje.



7

Bandymai išsisukti

- Deagregavimas: ignoruojame, kad informacija kartojasi (mokytojas moko kelis mokinius) ir apsimetame, kad tai mokinio charakteristika.
- Pasekmė: kintamųjų standartinės paklaidos tampa mažesnėmis, nei turėtų būti -> pasikliautiniai intervalai tampa nepagrįstai trumpais -> nulinė hipotezė atmetama rečiau, nei derėtų (ir norėtųsi).

8

Bandymai išsisukti

- Agregavimas: suvidurkiname I lygmens charakteristikas (mokinių) ir pereiname prie II lygmens modeliavimo.
- Pasekmė – nepanaudojame daug informacijos, o ir modeliuojame ne visada tai, ką norime.
- Kartais modeliai net išsikraipo.


9

Nesėkmingo agregavimo pavyzdys

- Tarkime, kad tirta dviejų klasių mokinių matematinio testo klaidų skaičiaus priklausomybė nuo testo trukmės. Jeigu kiekvienos klasės duomenys tiriama atskirai, tai gaunama natūrali priklausomybė – kuo ilgiau daromas testas, tuo mažiau klaidų.
- Kita vertus, jeigu imami klasių vidurkiai, tai juos jungianti tiesė rodo priešingą priklausomybę.

10

Nesėkmingo agregavimo pavyzdys



Bendra HLM idėja

- Pirmas lygmuo (primena regresiją)

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + e.$$

- Antras lygmuo (primena daug regresijų)

$$\beta_0 = \gamma_{00} + \gamma_{01} W_1 + u_0,$$

$$\beta_1 = \gamma_{10} + \gamma_{11} W_1 + u_1,$$

$$\beta_2 = \gamma_{20} + \gamma_{21} W_1 + \gamma_{22} W_2 + u_2,$$

$$\beta_3 = \gamma_{30} + \gamma_{32} W_2 + u_3.$$

12

Tipiška HLM sudarymo eiga

- Iš pradžių visada sudaromas besąlyginis (nulinis) modelis.
- Sudaromas sudėtingesnis modelis.
- Modeliai lyginami, aiškinamasi, kuris geresnis.
- tęsiame tol, kol gauname įmanomai gerą modelį
- arba išvadą, kad tokio modelio nėra.

13

Pastabos

- Stebinių turi būti pakankamai daug kiekviename lygmenyje. Negalima sudarinėti HLM, kai mokyklos tik dvi.
- Dauguma kintamųjų – normalūs.
- Modeliuosime mokinio matematikos pasiekimus (MAT), atsižvelgdami į mokinio (I lygmuo) ir mokyklos (II lygmuo) charakteristikas.

14

1 žingsnis: besąlyginis HLM

- Besąlyginis (nulinis) modelis svarbus tuo, kad su juo lyginami kiti hierarchiniai modeliai.
- Besąlyginio modelio analizė padeda atsakyti į klausimą, ar apskritai galima kalbėti apie hierarchinių modelių tinkamumą.

15

Besąlyginis HLM modelis

Vadovausimės tokia logika:

- mokinio rezultatų ir visos mokyklos vidurkio skirtumas atspindi tai, kas būdinga tik tam mokiniui – jo gabumus, namų aplinką, repetitoriaus patirtį ir pan. :

Mokinio rezultatas = mokyklos vidurkis + individualūs skirtumai nuo vidurkio.

- Analogiškai aprašome mokyklos lygmenį:

Mokyklos rezultatas = visų mokyklų vidurkis + šios mokyklos įtaka.

16

Besąlyginio HLM modelio idėja

- Mokinio lygmuo:

$$\text{MAT} = \beta_0 + e$$

- Mokyklos lygmuo:

$$\beta_0 = \gamma_{00} + u_0$$

- **Jungtinis modelis:**

$$\text{MAT} = \gamma_{00} + u_0 + e$$

17

MODELIO IDĖJA

2 lygmuo



1 lygmuo

$$\boxed{\text{MAT}} = f(\beta_0)$$

18

Jungtinis besąlyginis modelis

$$\text{MAT} = \gamma_{00} + u_0 + e$$

- Parametras γ_{00} nusako visų mokyklų matematikos testo rezultatų vidurkį.
- Mokyklų skirtumus rodo kintamojo u_0 dispersija τ_{00} .
- Mokinių individualius skirtumus rodo kintamojo e dispersija σ^2 .
- Kuo dispersijos didesnės, tuo didesni ir atitinkami skirtumai.

19

Terminai

- γ_{00} – fiksuoto poveikio parametras,
- τ_{00} ir σ^2 – atsitiktinio poveikio parametrai.

20

Besąlyginio modelio tyrimas su R

Yra keletas tinkamų bibliotekų. Populiariausios nlme ir lme4. Naudosime lme4 išplėtotą variantą lmerTest.

```
> df<-STAT3HLM1  
> library(lmerTest)  
> fit0<-lmer(MAT~1+(1|IDKLA), df)  
> summary(fit0)
```

21

Besąlyginio modelio tyrimo rezultatai

Fixed effects:

	Estimate	Std. Error	df	t value	Pr(> t)
(Intercept)	503.112	7.782	45.308	64.65	<2e-16 ***

Parametro γ_{00} įvertis $\hat{\gamma}_{00} = 503,112$

Be to, patikrinama hipotezė

$$\begin{cases} H_0: \gamma_{00} = 0 \\ H_1: \gamma_{00} \neq 0 \end{cases}$$

Gauta, kad $\gamma_{00} \neq 0$ statistiškai reikšmingai.

22

Besąlyginio modelio tyrimo rezultatai

- Primename, kad γ_{00} – tai bendras visų mokyklų matematikos testo MAT vidurkis.
- Statistinės hipotezės išvada, kad jis nelygus nuliui, nėra itin vertinga (niekas ir nesitikėjo, kad visi bus beraščiai).
- Įvertis $\hat{\gamma}_{00} = 503.112$ – daug svarbesnis.

23

Besąlyginio modelio tyrimo rezultatai

Random effects:

Groups	Name	Variance	Std.Dev.
IDKLA	(Intercept)	2387	48.86
Residual		4832	69.51

Gauti dispersijų įverčiai yra dideli:

$$\hat{\tau}_{00} = 2387$$

ir

$$\hat{\sigma}^2 = 4832$$

24

Tarpklasinė koreliacija

- Antrojo lygmens liekanos dispersija τ_{00}
- Pirmojo lygmens liekanos dispersija σ^2
- Skaičiuojame, naudodami jų įverčius (todėl kepurėlės).

$$ICC = \frac{\hat{\tau}_{00}}{\hat{\tau}_{00} + \hat{\sigma}^2}$$

25

Tarpklasinė koreliacija

- **ICC** (*Intraclass correlation coefficient*), parodo, kaip stipriai skiriasi grupių (mokyklų) rezultatai, palyginti su rezultatais grupėse.

$$ICC = \frac{\hat{\tau}_{00}}{\hat{\tau}_{00} + \hat{\sigma}^2}$$

- Kuo **ICC** didesnis, tuo labiau tikėtina, kad reikia atsižvelgti į hierarchinę duomenų struktūrą.

26

Pavyzdys

- Tegul

$$\hat{\tau}_{00} = 2387$$

$$\hat{\sigma}^2 = 4832$$

Tada

$$ICC = \frac{2387}{2387 + 4832} = 0,330\dots$$

Interpretuojama taip: apie 33 procentus mokinio rezultatų priklauso nuo mokyklos.

27

ICC su R

- Arba tiesiog

```
> ICC<-2387/(2387+4832)
```

```
> ICC
```

```
[1] 0.3306552
```

- Arba

```
> library(performance)
```

```
> icc(fit0)
```

```
# Intraclass Correlation Coefficient
```

```
Adjusted ICC: 0.331
```

28

Išvada

- Ir ICC, ir atsitiktinių parametru įverčiai rodo, kad reikia sudaryti sudėtingesnį modelį.
- Įtraukdami naujus I ir II lygmenų kintamuosius, siekiame sumažinti įverčių

$$\hat{\tau}_{00} = 2387$$

$$\hat{\sigma}^2 = 4832$$

didumus (jie parodo tuos mokinių ir mokyklų skirtumus, kurių nepaaiškina modelis).

29

Įvairūs modeliai

- Kintamieji

$CSES_{ij}$ – mokyklos vidurkiu centruotas i -ojo mokinio
socioekonominis statusas j -ojoje mokykloje;
 $MSES_j$ – j -osios mokyklos soc ek statuso vidurkis
 VK_j – mokyklos tipas (0 – Vilniaus, 1 – kaimo)
 MAT_{ij} – matematikos testo rezultatai.

30


1. Pastovaus posvyrio modelis

- Tarkime, kad kiekvieno mokinio matematikos testo rezultatai MAT priklauso tik nuo $CSES$ ir priklausomybė visose mokyklose tokia pat, tačiau gali skirtis papildomas mokyklos indėlis.
- $CSES$ yra normalus kintamasis.
- Visos liekamosios paklaidos normalios su lygiomis dispersijomis atitinkamuose lygmenyse.

31

1. Pastovaus posvyrio modelis

- Grafiškai



32

1. Pastovaus posvyrio modelis

- Pirmas lygmuo

$$MAT = \beta_0 + \beta_1 CSES + e$$

- Antras lygmuo

$$\beta_0 = \gamma_{00} + u_0$$

$$\beta_1 = \gamma_{10}$$

- Priklausomybė nuo *CSES* visose mokyklose vienoda (nes β_1 visur tas pats)

33

1. Pastovaus posvyrio modelis

- Jungtinė lygtis:

$$MAT = [\gamma_{00} + \gamma_{10} CSES] + [u_0 + e]$$

- Įvertinę modelį, gausime γ_{00} , γ_{10} ir τ_{00} (u_0 dispersijos) bei σ^2 (e dispersijos) įverčius.
- Jungtinę lygtį galima naudoti prognozėms.

34

2. Modelis su antrojo lygmens intervaliniu kintamuoju


Manome, kad:

- mokinio matematikos testo rezultatas priklauso nuo jo socialinio ir ekonominio statuso (CSES);
- mokykos įtaka visiems mokiniams vienoda;
- mokyklos įtakos stiprumą lemia jos mokinių socialinio ir ekonominio statuso vidurkis (MSES).

35

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Grafiškai modelis atrodo taip:



36

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Reikalavimai kintamiesiems:

- Priklausomas kintamasis (**MAT**) būtinai turi būti intervalinis.
- Kiti kintamieji yra intervaliniai arba kategoriniai (pseudokintamieji).
- Šiame pavyzdyje visi kiti kintamieji (**CSES** ir **MSES**) yra intervaliniai.
- Paklaidos (liekanos) – normaliai pasiskirsčiusios ir nepriklausomos.

37

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Pasižiūrime, kurio lygmens kintamųjų turime:

- pirmojo (mokinio) lygmens kintamasis yra **CSES**.
- antrojo (mokyklos) lygmens kintamasis yra **MSES**.

38

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Mokinio lygmens lygtis gana akivaizdi:

$$\text{MAT} = \beta_0 + \beta_1 \text{CSES} + e.$$

Čia e žymi atsitiktinę paklaidą, kuri yra normaliai pasiskirsčiusi su nuliniu vidurkiu ir nežinoma dispersija σ^2 . Ši dispersija atspindi mokinių skirtumus, atsiradusius ne dėl mokyklų įtakos.

39

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Antrojo lygmens kintamieji į modelį įtraukiami, tariant, kad atitinkami β koeficientai yra atsitiktiniai.

Laikomasi tokio principo:

- Kintamieji, kurie **veikia visus mokinius vienodai**, įtraukiami į lygtį, aprašančią laisvą narį β_0 .
- Kintamieji, kurie **turi sąveiką su CSES**, įtraukiami į lygtį, aprašančią koeficientą β_1 .

40

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Taigi antrojo lygmens lygtys yra tokios:

$$\beta_0 = \gamma_{00} + \gamma_{01} \text{MSES} + u_0,$$

$$\beta_1 = \gamma_{10} + u_1.$$

Čia γ_{ij} — nežinomos konstantos.

Paklaidos u_0, u_1 turi dispersijas τ_{00}, τ_{11} ir gali koreliuoti (kovariacija τ_{01}).

41

2. Modelis su antrojo lygmens intervaliniu kintamuoju

- Primename, kad dispersijos

$$\tau_{00}, \tau_{11}$$

atspindi rezultatų skirtumus, atsirandančius dėl mokyklų įtakos.

- Tačiau tik tuos skirtumus, kurių nepaaiškina pasirinktasis modelis.
- Kuo šios dispersijos mažesnės, tuo modelis geriau tinka duomenims.

42

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Galima sudaryti jungtinę lygtį

$$\text{MAT} = [\gamma_{00} + \gamma_{01}\text{MSES} + \gamma_{10}\text{CSES}] + [\mathbf{e} + \mathbf{u}_0 + \mathbf{u}_1\text{CSES}].$$

Matome, kad modelyje išsiskiria du komponentai:

- fiksuoto poveikio;
- atsitiktinio poveikio.

43

2. Modelis su antrojo lygmens intervaliniu kintamuoju

- Fiksuoto (pastovaus) poveikio parametrai yra

$$\gamma_{00}, \gamma_{01}, \gamma_{10}$$

- Atsitiktinio poveikio parametrai (liekanų e, u_0, u_1 dispersijos ir kovariacijos) yra

$$\tau_{00}, \tau_{11}, \tau_{01}, \sigma^2$$

44

2. Modelis su antrojo lygmens intervaliniu kintamuoju

- Kintamieji prie γ vadinami fiksuoto poveikio kintamaisiais, o kintamieji prie u – atsitiktinio poveikio kintamaisiais.
- Fiksuoto poveikio kintamieji: **CSES** ir **MSES**.
- Atsitiktinio – kintamasis **CSES**.

$$\text{MAT} = [\gamma_{00} + \gamma_{01}\text{MSES} + \gamma_{10}\text{CSES}] + [e + u_0 + u_1\text{CSES}]$$

45

2. R pavyzdys

```
> fit_2<-lmer(MAT~1+MSES+CSES+(1+CSES|IDKLA), df)
> summary(fit_2)
```

	Estimate	Std. Error	df	t value	Pr(> t)	
(Intercept)	189.442	38.096	40.429	4.973	1.26e-05	***
MSES	15.909	1.890	39.753	8.419	2.26e-10	***
CSES	7.832	1.086	445.585	7.211	2.40e-12	**

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

$$\hat{\gamma}_{00} = 189.442$$

$$\hat{\gamma}_{01} = 15.909$$

$$\hat{\gamma}_{10} = 7.832$$

46

2. R pavyzdys

```
> fit_2<-lmer(MAT~1+MSES+CSES+(1+CSES|IDKLA), df)
> summary(fit_2)
```

Fixed effects:

	Estimate	Std. Error	df	t value	Pr(> t)	
(Intercept)	189.442	38.096	40.429	4.973	1.26e-05	***
MSES	15.909	1.890	39.753	8.419	2.26e-10	***
CSES	7.832	1.086	445.585	7.211	2.40e-12	**

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Visi fiksuoto poveikio parametrai buvo statistiškai reikšmingi

47

2. R pavyzdys

Atsitiktinio poveikio parametrų įverčiai

Random effects:

Groups	Name	Variance	Std.Dev.	Corr
IDKLA	(Intercept)	635.1286	25.2018	
	CSES	0.3547	0.5956	-1.00
	Residual	4261.5377	65.2805	

$$\hat{\tau}_{00} = 635.1286$$

$$\hat{\tau}_{11} = 0.3547$$

$$\hat{\tau}_{01} = (-1.00) \cdot 25.2018 \cdot 0.5956 = -15.01..$$

$$\hat{\sigma}^2 = 4261.5377$$

48

2. Modelis su antrojo lygmens intervaliniu kintamuoju

- Antro lygmens lygtis β_1 pakankamai gerai aprašo mokyklos įtaką, nes liekanos dispersija
- $\hat{\tau}_{11} = 0,3547$ (maža)
- O β_0 antro lygmens lygtis dar ne itin gera, nes dispersija didelė $\hat{\tau}_{00} = 635.1286$

49

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Įsitikiname, kad respondentų skirtumus atspindinti dispersija nėra itin maža:

$$\hat{\sigma}^2 = 4261.5377$$

Vis dėlto, lyginant su besąlyginio modelio analogiška dispersija (4832), aišku, kad dispersija itin sumažėjo.

Galima ištirti, kuri dalis dispersijos dingo.

50

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Formulė:

$$\frac{\hat{\sigma}_{sena}^2 - \hat{\sigma}_{nauja}^2}{\hat{\sigma}_{sena}^2}$$

Gauname:

$$\frac{4832 - 4261.54}{4832} = 0,118...$$

Interpretuojame taip: lyginant su besąlyginiu modeliu, apie 12% sumažėjo modeliu nepaaiškintų mokinių rezultatų skirtumų. Gana nemenkas išlošis.

51

2. R pavyzdys. Akaike index

Akaike ir kitų indeksų sumažėjimas bent per 10 vienetų jau laikomas svarbiu.

- Galima tiesiog pasižiūrėti Akaike indeksus.

```
> library(AICcmodavg)
```

```
> AICc(fit0)
```

```
[1] 6416.01
```

Besąlyginis

```
> AICc(fit_2)
```

```
[1] 6126.23
```

Naujasis modelis

52

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Išvados:

- Nagrinėjamas modelis daug geriau tinka duomenims nei besąlyginis modelis.
- Testo rezultatai matuojami šimtais balų, todėl rezultatų paklaidos standartinis nuokrypis nėra labai didelis $\hat{\sigma} = 65,28...$
- Modelį galima laikyti pakankamai geru.
- Žinoma, tai nereiškia, kad nėra geriau duomenims tinkančių modelių.

53

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Norėdami prognozuoti, tiesiog įstatome fiksuotųjų parametų įverčius į jungtinę lygtį

$$\text{MAT} = \hat{\gamma}_{00} + \hat{\gamma}_{01}\text{MSES} + \hat{\gamma}_{10}\text{CSES}$$

Mūsų nagrinėjamu atveju

$$\widehat{\text{MAT}} = 189,44 + 15,9\text{MSES} + 7,83\text{CSES}$$

54

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Įstatę konkrečias kintamųjų CSES ir MSES reikšmes, gautume testo rezultato prognozę konkrečiam mokiniui.

Be to, ši regresinė lygtis leidžia įvertinti mokyklos įtaką. Iš tikro kiekvienas papildomas MSES balas padidina testo rezultatą 15,9 taško:

$$\widehat{MAT} = 189,44 + 15,9MSES + 7,83CSES$$

55

3. Modelis su kategoriniu kintamuoju

- Ištirsime modelį su antrojo lygmens kategoriniu kintamuoju **VK** (0-Vilnius, 1-kaimas), nurodančiu mokyklos priklausomybę Vilniaus miestui.
- Tirsime ankstesnį modelį, papildytą šiuo antrojo lygmens kintamuoju.
- Suformuluosime sąlygas tiksliau.

56

3 modelis. Grafiškai

2 lygmuo

$MSES$ VK

1 lygmuo

$$MAT = f(\beta_0, CSES)$$

β_1

57

3 modelis. Lygtys (idėja)

- Mokinio matematikos testo rezultatas priklauso nuo jo socialinio ir ekonominio statuso:

$$MAT = \beta_0 + \beta_1 CSES + e$$

- Mokyklos įtaka priklauso nuo mokyklos socialinio ir ekonominio statuso vidurkio bei mokyklos vietos:

$$\beta_0 = \gamma_{00} + \gamma_{01} MSES + \gamma_{12} VK + u_0$$

58

3 modelis. Charakteristikos

Vilniaus mokyklose socialinio ir ekonominio statuso reikšmė kitokia nei kitose mokyklose:

$$\beta_1 = \gamma_{10} + \gamma_{11}VK + u_1;$$

čia e turi dispersiją σ^2 ;

paklaidos u_0, u_1 turi dispersijas τ_{00}, τ_{11} ir gali koreliuoti (kovariacija τ_{01}).

59

3 modelis

- Jungtinė lygtis:

$$\begin{aligned} \text{MAT} = & \gamma_{00} + \gamma_{01}\text{MSES} + \gamma_{10}\text{CSES} \\ & + \gamma_{02}\text{VK} + \gamma_{12}\text{VK} \times \text{CSES} \\ & + [u_1\text{CSES} + u_0 + e]. \end{aligned}$$

- Fiksuotieji kintamieji: CSES, MSES, VK, VKx CSES .
- Atsitiktiniai kintamieji: CSES.
- CSES priklauso abiem grupėm.

60

3. R pavyzdys

```
> fit_3<-lmer(MAT~1+MSES+CSES+ VK+VK*CSES+(1+CSES|DKLA), df)
```

Fixed effects:					
	Estimate	Std. Error	df	t value	Pr(> t)
(Intercept)	48.628	55.897	37.793	0.870	0.38982
MSES	23.922	3.027	37.827	7.903	1.58e-09 ***
CSES	7.115	1.348	455.220	5.279	2.01e-07 ***
VK	-50.195	15.416	37.627	-3.256	0.00239 **
CSES:VK	2.111	2.259	414.600	0.934	0.35068

Ne visi fiksuotų efektų parametrai statistiškai reikšmingi (laisvam nariui nežiūrimė).

61

3 modelis. Parametrai.

Iššifravimas:

$$\begin{aligned} \text{MAT} = & \gamma_{00} + \gamma_{01}\text{MSES} + \gamma_{10}\text{CSES} \\ & + \gamma_{02}\text{VK} + \gamma_{12}\text{VK} \times \text{CSES} + \\ & \text{atsit.dalis} \end{aligned}$$

$$\begin{aligned} \hat{\gamma}_{00} &= 48.628 \\ \hat{\gamma}_{01} &= 23.922 \\ \hat{\gamma}_{10} &= 7.115 \\ \hat{\gamma}_{02} &= -50.195 \\ \hat{\gamma}_{12} &= 2.111 \end{aligned}$$

62

3 modelis. Akaikės indeksai.

- 10 vienetų pokytis jau yra svarbus.

```
> AICc(fit0)
```

```
[1] 6416.01
```

Besąlyginis

```
> AICc(fit_2)
```

```
[1] 6126.23
```

Senesnis modelis

```
> AICc(fit_3)
```

```
[1] 6109.18
```

Naujas modelis

63

3 modelis. Modelio įvertis.

Kaimui:

$$\widehat{MAT} = -1.57 + 23.9MSES + 9.22CSES$$

Vilniui:

$$\widehat{MAT} = 48.62 + 23.9MSES + 7.11CSES$$

64

3 modelis. Dispersijos

Random effects:

Groups	Name	Variance	Std.Dev.	Corr
IDKLA	(Intercept)	452.8191	21.2795	
	CSES	0.3291	0.5737	-1.00
	Residual	4263.9630	65.2990	

Pirmas lygmuo

$$\hat{\sigma}^2 = 4263.9630 \dots$$

65

3 modelis. Dispersijos

Random effects:

Groups	Name	Variance	Std.Dev.	Corr
IDKLA	(Intercept)	452.8191	21.2795	
	CSES	0.3291	0.5737	-1.00
	Residual	4263.9630	65.2990	

Antras lygmuo

$$\hat{\tau}_{00} = 452.8191$$

$$\hat{\tau}_{11} = 0.3291 \dots$$

$$\begin{aligned} \hat{\tau}_{11} &= \text{Corr}(u_0, u_1) \sqrt{\hat{\tau}_{00} \cdot \hat{\tau}_{11}} \\ &= -1 \cdot 21.28 \cdot 0.57 = -12.13 \dots \end{aligned}$$

66

3 modelis. Koreliacija

Ar reikia skaičiuoti dispersijas ir kovariacijas vietoje standartinių nuokrypių ir koreliacijos? Žinoma, kad **nereikia**. Standartiniai nuokrypiai turi tiek pat informacijos apie skirtumus tarp duomenų, kiek ir dispersijos.

Koreliacija leidžia „iš akies“ įvertinti priklausomybės stiprumą (-1 – labai stipri koreliacija, kelianti abejonių dėl modelio tinkamumo).

67

3 modelis. Preliminarios išvados.

- Modelis ne itin geras.
- Galbūt reikia išmesti VK^*CSES .
- Galbūt reikia išmesti γ_{00} .
- Dar reikėtų kintamųjų normalumą (ypač MAT) patikrinti.

68

PASTABOS

- Modelio tobulinimas vyksta, mažinant atsitiktinių poveikių dispersijas.
- Įtraukus naujus kintamuosius, tikimės, kad jos sumažės.
- Tačiau, kaip taisyklė, pridėjus antro lygmens kintamąjį, antro lygmens dispersijos mažėja, bet pirmo lygmens padidėja.
- Laimei, nedaug. Todėl to bijoti nereikia.

69

PASTABOS

- Paprastai parametrai vertinami apribotojo didžiausio tikėtumo (REML) metodu.
- Dar naudojamas didžiausio tikėtumo (ML) metodas.
- REML efektyvesnis už ML, kai kintamieji stipriai koreliuoja.
- ML dažniausiai duoda mažesnius kovariacijų-dispersijų įverčius (ir daro tyrėją laimingesniu).

70

PASTABOS

- Tarkime, vienas modelis yra kito modelio dalinis atvejis. Tada R yra galimybė palyginti tuos du modelius. Jeigu jie stat. reikšmingai nesiskiria, imamas paprastesnis.
- Tačiau tai galima daryti tik, kai parametrų įverčiai randami naudojant ML (didžiausio tikėtimumo) metodą (ir nlme biblioteką).

71

3. R

```
> model.0<-lme(MAT~1, data=df, random=~1|IDKLA)
> model.1<-lme(MAT~1+MSES+CSES, data=df, random=
~1+CSES|IDKLA)
> model.0m<-update(model.0, method='ML', data=df)
> model.1m<-update(model.1, method='ML', data=df)
> anova(model.0m, model.1m)
```

72

3. R

	Model	df	AIC	BIC	logLik	Test
model.0m	1	3	6217.89	6230.78	-3105.94	
model.1m	2	7	6136.23	6166.31	-3061.11	1 vs 2

L.Ratio p-value

2 89.66298 <.0001

Statistiškai reikšmingai geriau.

73


PRIELAUDŲ TIKRINIMAS

- Abiejų lygių liekamosios paklaidos turi būti normalios.
 - Tą galima patikrinti bent jau grafiškai.
 - Tarkime, kad sudarėme HLM duomenims
- ```
> model.1<-lme(MAT~1+MSES+CSES, data=data,
random= ~1+CSES|IDMOK)
```

74

## PRIELAUDŲ TIKRINIMAS


- Pažiūrime liekamųjų (e) paklaidų q-q grafiką:
- `> qqnorm(model.1,~resid(.))`
- Visai panašų į normalumą.



`qqnorm(model.1,~ranef(.))`

## PRIELAUDŲ TIKRINIMAS

- Galima pažiūrėti ir atsitiktinių kintamųjų, bei posvyrių q-q grafikus:
- `> qqnorm(model.1,~ranef(.))`



76

## Svarbi problema

Jei I lygmenyje įtrauktas labai stipriai su rezultatu koreliuojantis kintamasis, tai paaiškės, kad joks HLM modelis netinka.

Pavyzdžiui, įtraukus fizikos testo rezultatą FIZ

$$\text{MAT} = \beta_0 + \beta_1 \text{FIZ} + e,$$

paaiškės, kad geriau mokantys fiziką, geriau ir matematiką išmano. Ir kas iš to? Norint pagerinti matematikos žinias, reikia sustiprinti fizikos mokymą? Kažin, kažin.

77

## Svarbi problema

Modelį reikia sudaryti sąmoningai mąstant apie tyrimo tikslus, o ne pagal stipriausias koreliacijas.

Norime sužinoti, **kas daro įtaką** matematikos žinioms.

Pavyzdžiui:

- koks yra mokyklos vaidmuo (II lygmuo);
- koks yra socialinio ir ekonominio statuso vaidmuo (I lygmuo).

78

## METODINIAI PATARIMAI

Pradedama nuo besąlyginio modelio.

Nustatoma, kurie kintamieji yra pastovaus poveikio, o kurie – kintamojo. Tam atliekami tokie veiksmai:

- 1) Įvardijami pirmojo ir antrojo lygmens kintamieji.
- 2) Apibrėžiamos spėjamos priklausomybės.
- 3) Lygtimis užrašoma, kas nuo ko priklauso. Reikia nepamiršti antrojo lygmens lygtyse pridėti atsitiktinę paklaidą **u**. Pirmojo lygmens lygtyje pridedama **e**.
- 4) Antrojo lygmens lygtis įstatoma į pirmojo lygmens lygtį.
- 5) Jungtinėje lygtyje surenkami nariai prie **u** ir **e**.
- 6) Kintamieji be **u** yra pastovaus poveikio; kintamieji su **u** – atsitiktinio poveikio. Beje, tas pats kintamasis gali būti ir pastovaus ir atsitiktinio poveikio.

79

## METODINIAI PATARIMAI

- Modeliuoti liaujamasi, kai išsibaigia kintamieji ir idėjos.
- Pateikiamas geriausias modelis.
- Kartais geresni modeliai centruotiems kintamiesiems (kai atimame imties vidurkį).
- Visada galima pagalvoti apie duomenų transformacijas.

80



## Tikslios matematinės formuluotės

### Besąlyginis HLM modelis tiksliau

- Tarkime turime  $J$  mokyklų, t.y.  $j = 1, 2, \dots, J$ , o  $j$ -oje mokykloje yra  $n_j$  mokinių. Mokinio lygmuo:

$$MAT_{ij} = \beta_{0j} + e_{ij}, i = 1, \dots, n_j, j = 1, \dots, J.$$

- Mokyklos lygmuo:

$$\beta_{0j} = \gamma_{00} + u_{0j}, j = 1, 2, \dots, J.$$

## Besąlyginis HLM modelis tiksliau

- Prielaidos:

$$e_{ij} \sim N(0, \sigma^2) \text{ nepriklausomi, } i = 1, \dots, n_j, j = 1, \dots, J.$$

$$u_{0j} \sim N(0, \tau_{00}) \text{ nepriklausomi, } j = 1, \dots, J.$$

$e_{ij}$  ir  $u_{0j}$  nekoreliuoja

83

## Interpretacija

$\beta_{0j}$  yra  $j$ -osios mokyklos rezultatų vidurkis;

$e_{ij}$  i-jo mokinio rezultatų skirtumai nuo  $j$  mokyklos vidurkio;

$\sigma^2$  mokinių gabumų dispersija;

$\gamma_{00}$  bendrasis visų mokyklų mokinių rezultatų vidurkis

$\tau_{00}$  mokyklų skirtumų dispersija.

84

## Besąlyginis modelis

- Jungtinis modelis

$$Y_{ij} = \gamma_{00} + u_{0j} + e_{ij}$$

- Hipotezės

$$\begin{cases} H_0: \gamma_{00} = 0 \\ H_1: \gamma_{00} \neq 0 \end{cases}$$

$$\begin{cases} H_0: \tau_{00} = 0 \\ H_1: \tau_{00} > 0 \end{cases}$$

$$\begin{cases} H_0: \sigma^2 = 0 \\ H_1: \sigma^2 > 0 \end{cases}$$

85

## Besąlyginis modelis

$$Y_{ij} = \gamma_{00} + u_{0j} + e_{ij}$$

- $\tau_{00}$  atspindi antro lygmens (mokyklos) poveikį.
- $\sigma^2$  atspindi pirmo lygmens (mokinių) skirtumus, kurių nepaaiškina modelis.
- Įverčiai  $\hat{\tau}_{00}$  ir  $\hat{\sigma}^2$  gali būti labiau informatyvūs, nei jų statistinis reikšmingumas.

86

## Galimi įverčiai

$$Y_{ij} = \beta_{0j} + e_{ij},$$

$$\begin{array}{l} i = 1, \dots, n_j, \\ j = 1, \dots, J. \end{array}$$

- Jei norime įvertinti  $j$ 'tos mokyklos įtaką, tai tam galima naudoti

$$\bar{Y}_{\cdot j} = \frac{Y_{1j} + Y_{2j} + \dots + Y_{n_j, j}}{n_j}.$$

87

## Svertinis (Shrinkage) įvertis

$$\beta_{0j}^* = \lambda_j \bar{Y}_{\cdot j} + (1 - \lambda_j) \hat{\gamma}_{00}$$

$$\lambda_j = \frac{\hat{\tau}_{00}}{\hat{\tau}_{00} + \hat{\sigma}^2/n_j}$$

88

# Bendrasis modelis

- Pirmas lygmuo

$$Y_{ij} = \beta_{0j} + \beta_{1j}X_{1ij} + \beta_{2j}X_{2ij} + \dots$$

$$+ \beta_{Kj} X_{Kij} + e_{ij};$$

$$i = 1, 2, \dots, n_j, j = 1, 2, \dots, J.$$

89

## Bendrasis modelis

- Antras lygmuo

[illegible]

- (Čia, kai visi nuo visko priklauso. Dažnai W įtraukiame ne į visas lygtis).

90

## Jungtinis modelis

$$Y_{ij} = \gamma_{00} + \sum_{m=1}^S \gamma_{0m} W_{mj} + \sum_{k=1}^K \sum_{m=1}^S \gamma_{km} W_{mj} X_{kij} + \left[ u_{0j} + \sum_{k=1}^K X_{kij} u_{kj} + e_{ij} \right]$$

91

## Prielaidos liekanoms

- $e_{ij} \sim N(0, \sigma^2)$  ir yra nepriklausomos.
- $u_{kj} \sim N(0, \tau_{kk})$ .
- $\text{Cov}(u_{kj}, u_{mj}) = \tau_{km}$ .
- $u_{kj}$  ir  $u_{ml}$  nepriklausomos, kai  $j \neq l$ .
- $u_{ml}$  ir  $e_{ij}$  yra nepriklausomos.

92

## Fiksuoti ir atsitiktiniai parametrai

- Visi  $\gamma_{ij}$  yra fiksuotieji parametrai.
- Visi  $\tau_{kj}$  ir  $\sigma^2$  yra atsitiktiniai parametrai.

93

## Pastovaus ir atsitiktinio poveikio kintamieji

$$Y_{ij} = \gamma_{00} + \sum_{m=1}^S \gamma_{0m} W_{mj} + \sum_{k=1}^K \sum_{m=1}^S \gamma_{km} W_{mj} X_{kij} + \left[ u_{0j} + \sum_{k=1}^K X_{kij} u_{kj} + e_{ij} \right]$$

Diagrama, rodanti parametrų klasifikaciją:

- Redžiniai apvalkai aplink  $W_{mj}$  ir  $W_{mj} X_{kij}$  su rodyklėmis iš žodžio "pastovūs" (pastovūs).
- Blauzkinis apvalkai aplink  $X_{kij}$  su rodykle iš žodžio "atsitiktiniai" (atsitiktiniai).

94

## Example

P. Brandišauskas

Student Performance from a Socio-Economic Perspective

Master's Thesis, Vilnius 2022

## Aims

This study examines the relationship between the science test results and the socio-economic environment at student and school levels in Lithuania.



## (Why)

Lithuania started participating in PISA assessment in 2006. Lithuania's science literacy rate **is still below** the OECD average in all student testing periods from 2006 till 2018. Trend positive (but slow): Lithuania's average science literacy score was **488** in 2006, **491** in 2009 and **496** points in 2012.

## (Why)

Analysis of results from international surveys (e.g., TIMMS, PISA) in different countries shows that, regardless of the country, socio-economic and cultural exclusion is clearly linked to student achievement.....

Nonetheless, some students achieve high academic results despite their socio-economic disadvantages.....

## Method

Hierarchical linear modelling with multilevel sample weights, plausible values and the latest R software package are used to analyze the Programme for International Student Assessment 2015 data.

## Literature review

.... no agreement was reached on the conceptual meaning of socio-economic status or how to assess it...

... a composite measure that compiles the financial, social, cultural, and human capital resources accessible to students into a single score, is used in PISA ....

... usually, superior educational results are connected with higher student level SES...

## Literature review

In Lithuania, A. Zabulionis [32] conducted a study of PISA 2018 data of Lithuanian students achievement. According to the author, students' academic performance depends on two interrelated factors - **the student's SES** and the student's **school location**.

The achievement gap between urban and rural schools is widening....

## DATA

- 15-year-old students enrolled in schools in grades 7 and above.
- Schools were selected from a nationwide list with probabilities proportional to a size.
- Students within sampled schools were chosen with equal probabilities.
- If the number of students within the school was smaller than 42, all students were selected.

## DATA

- In TIMSS, PISA plausible values (PVs) are reported instead of students' actual scores.
- Plausible values can be described as random values drawn from the posterior distributions
- The main advantage of PVs is arguably better representation of investigated phenomena.
- Problem: there are 10 PV for each student.

## Regressors (students level)

- **Index of economic, social and cultural status**
- **Whole days of school missed** in the last two full weeks (1 – none, 2 – one or two times, 3 – three or four times, 4 – five or more times);
- **Environmental awareness** – how well student is aware of environmental matters;

## Regressors (students level)

- **Enjoyment of science**
- **Enjoyment of cooperation** - student's willingness to collaborate;
- **Use of ICT at school in general** – how often digital devices are used at school in general (for chatting, browsing, posting work online, doing schoolwork and etc.).

## Regressors (school level)

- **Description of the community** in which school is located – (1 – a village, ...5 – a large city with over 1 000 000 people);
- **Index proportion of all teachers** ISCED level 6
- **School Size**– total enrolment at school;
- **Estimated percentage of students with special needs**;
- **Estimated percentage of students from socio-economic disadvantaged homes.**

## Weights

- .. there are different student and school selection probabilities. To make sure that each participating student accurately represents the right number of students throughout the whole PISA sample, survey weights must be applied into the analysis.
- .... formulas, explanation,.....

## Assumptions

- Although different transformations of the variables (Z-Score and Log) were used in our investigation, the histograms did not closely resemble a normal distribution and
- Shapiro-Wilk test showed that the null hypothesis of normal distribution should be rejected.

## Modeling

- R does not have the package to perform HLM with all plausible values together with multilevel weights, therefore modelling with 1 PV and multilevel weights was conducted with WeMix package.
- For linear models a weighted version of the estimating equations in lme4 package was used.

## Equations

- ICC=0.1728

Student level:  $Y_{ij} = \beta_{0j} + \beta_{1j}ESC S_{ij} + \beta_{2j}ST062Q01TA_{ij} + \beta_{3j}ENV AWARE_{ij} + \beta_{4j}JOY SCIE_{ij} + \beta_{5j}COOPERATE_{ij} + \beta_{6j}USE SCH_{ij} + e_{ij};$

School level:  $\beta_{0j} = \gamma_{00} + \gamma_{01}SC001Q01TA_{1j} + \gamma_{02}PROAT6_{2j} + \gamma_{03}SCH SIZE_{3j} + \gamma_{04}SC048Q02NA_{4j} + \gamma_{05}SC048Q03NA_{5j} + u_{0j};;$

$$\beta_{1j} = \gamma_{10} + u_{1j};$$

$$\beta_{2j} = \gamma_{20} + u_{2j};$$

$$\beta_{3j} = \gamma_{30} + u_{3j};$$

$$\beta_{4j} = \gamma_{40} + u_{4j};$$

$$\beta_{5j} = \gamma_{50} + u_{5j};$$

$$\beta_{6j} = \gamma_{60} + u_{6j}.$$

## Results

| Effects & Statistics                                                             | Grade 9 model    | Grade 10 model    |
|----------------------------------------------------------------------------------|------------------|-------------------|
| Intercept                                                                        | 476.93*** (8.84) | 465.26*** (12.66) |
| Index of economic, social and cultural status (ESCS)                             | 14.21*** (1.57)  | 26.60*** (3.27)   |
| Whole days of school missed in the last two full weeks (ST062Q01TA)              | -15.72*** (1.79) | -20.64*** (4.00)  |
| Environmental awareness (ENVAWARE)                                               | 14.18*** (0.97)  | 11.16*** (2.39)   |
| Enjoyment of science (JOYSCIE)                                                   | 6.68*** (1.06)   | 6.15. (3.21)      |
| Enjoyment of cooperation (COOPERATE)                                             | 4.96*** (1.14)   | 6.02* (3.07)      |
| Use of ICT at school in general (USESCH)                                         | -13.32*** (1.16) | -6.81* (2.91)     |
| Description of the community in which school is located (SC001Q01TA)             | -4.03. (2.06)    | 9.78** (3.01)     |
| Index proportion of all teachers ISCED level 6 (PROAT6)                          | 6.82** (2.42)    | 7.91. (4.10)      |
| School Size (SCHSIZE)                                                            | 0.05*** (0.01)   | 0.03* (0.01)      |
| Est. percentage of students with special needs (SC048Q02NA)                      | 0.13 (0.26)      | 0.77 (0.48)       |
| Est. percentage of students from socio-economic disadvantaged homes (SC048Q03NA) | -0.39** (0.14)   | -0.19 (0.21)      |
| School level variance                                                            | 366.6            | 174.5             |
| Student level variance                                                           | 4665.7           | 4864.1            |
| CCV                                                                              | 18.35%           | 21.95%            |

## Results

- **...great impact of SES**, as 1 unit increase in the index increases scientific literacy score by 27.81 points.
- Another influential variable is **environmental awareness....**
- The variable describing the **settlement size where the school is located seems to be very impactful....**



## Conclusions

- The work is one of the first that investigates socio-economic background and academical performance relationship in Lithuanian educational system through data modelling...
- ... due to lack of normality, results should be viewed with a certain amount of caution but nevertheless might be used as basis for further research....