

Tikiuosi, kad išgudrėsit su laiku.
Tiktai išmokit viską redukuot
Ir tinkamai klasifikuot, drauguži.

Mefistofelis

(J.W.Goethe, „Faustas“, A.Churgino vertimas)

1

Klasterinė analizė

Cluster Analysis

2

Klasterinė analizė - objektus pagal panašumą suskirstome į grupes - klasterius.

Klasteris - panašių objektų grupė.

3

Skirtumai nuo diskriminantinės analizės:

- Kintamieji dažniausiai intervaliniai, bet yra klasterizacijų ir kitokiems x-ams.
- Kas sudarys grupes - nežinome.
- Kiek bus grupių - dažniausiai nežinome.
- Tuos pačius objektus galime skirtingai suklasterizuoti.
- Kuris metodas geresnis – subjektyvus sprendimas.

4

PAVYZDŽIAI

- pagal testų rezultatus grupuojame tiriamuosius;
- pagal sesijos rezultatus sugrupuojame II kurso edukometrus
- pagal socio-ekonominius parametrus norime suskirstyti valstybes į grupes;
- pagal nuobodumo laipsnį grupuojame pažįstamus.

5

Futbolo komandų klasterizavimo rezultato pavyzdys

- **I klasteris:** Ispanija, Prancūzija, Argentina, UK
- **II klasteris:** Kroatija, Belgija
- **III klasteris:** Olandija, Italija, Vokietija

6

Duomenys

- $(X_{11}, X_{21}, X_{31}, \dots, X_{k1}) , \dots ,$
 $(X_{1n}, X_{2n}, X_{3n}, \dots, X_{kn}) .$
- yra tik **kintamųjų X-ų** reikšmės!
- kintamieji X- intervaliniai,
ranginiai, kategoriniai.

7

Pastaba

- Kartais dar tariama, kad egzistuoja natūralūs klasteriai, kurie atsirado, kaip atsitiktinių dydžių reikšmės, tik juos reikia atpažinti.
- Tada pasipila tikimybiniai vertinimai ir metodai.
- **Apie juos šiandien nekalbėsime.**

8

Klasterizacijos rezultatus lemia:

- Dviejų **objektų** (respondentų) **panašumo** matas.
- Dviejų **klasterių panašumo** matas.
- Skirstymo į objektus metodas.


9

Objektų panašumo matai


- Euklido,
- Minkovskio,
- Manheteno,
- Julo,
- Mahalanobio,
- Žakardo (kategoriniams),
- Lenso ir Viljamso ir t.t. ir pan.

10

Panašumo matų pavyzdžiai



$$\begin{aligned} & ||\vec{X} - \vec{Y}|| \\ &= \sqrt{(X_1 - Y_1)^2 + (X_2 - Y_2)^2} \end{aligned}$$



$$\begin{aligned} & ||\vec{X} - \vec{Y}|| \\ &= |X_1 - Y_1| + |X_2 - Y_2| \end{aligned}$$

arba tiesiog koreliacija,...

11

Populiariausias panašumo matas

- Euklido atstumo kvadratas:

$$||\vec{X} - \vec{Y}||^2 = (X_1 - Y_1)^2 + \dots + (X_n - Y_n)^2$$

- Tinka - skaitiniams X-ams.
- Visi X atstumą įtakoja vienodai.
- Atitinka trumpiausio atstumo plokštumoje kvadratą.

12

Kitos problemos: Pavyzdys

- A : (30 tšk., 1000 kcal)
- B : (10 tšk., 600 kcal)
- A-B: (20, 400)

$$||A-B||^2 = 20^2 + 400^2 = 160400$$

- Viską nulemia antroji koordinatė.

13

Išeitis – pereiti prie z-reikšmių

- z-reikšmė:

$$z = \frac{x - \bar{x}}{s}$$

- Jeigu imtį pakeisime z-reikšmėmis, tai naujas imties vidurkis bus 0, o imties dispersija lygi 1.
- Ir kas iš to? (kodėl 1, o ne 10 – irgi gražus ir studentams net mielesnis skaičius).

14

Išeitis – pereiti prie z-reikšmių

- Esmė – kažkiek suvienodinti skales.
- Ir beje, galima imti tiesines z transformacijas.
- Pvz. $t=50+10z$, turės vidurkį 50, o dispersiją 100.
- Lygiai tiek pat informacijos, kaip ir z-reikšmėse.

Išeitis – pereiti prie z-reikšmių

- A : (30 tšk, 1000 kcal)
- B : (10 tšk, 600 kcal)
- vidurkiai (20 tšk, 800 kcal)
- dispersijos (200, 80000kg²)
- z-reikšmės:

- $\frac{30-20}{\sqrt{200}} = 0.707..$, $\frac{1000-800}{\sqrt{80000}} = 0.70..$ t.t.

Pavyzdys su z-reikšmėmis

- A_z : (0.70, 0.70)
- B_z : (-0.70, -0.70)
- $A_z - B_z$: (1.4, 1.4)

$$||A_z - B_z||^2 = 1.4^2 + 1.4^2 = 3.92$$

- Koordinačių svarba vienoda.

17

Problemos su X didumu

- Euklido metrika: didesnės X -o reikšmės - didesnė ir įtaka atstumams.
- lengva interpretuoti klasterius.
- I klasteriui būdinga (30tšk, 1000kcal)
- z-reikšmių taikymas: X_z -ų reikšmės vienodai svarbios
- **Nauja problema:** neaišku kas būdinga gautiems klasteriams
- pvz. (0.70; 0.70)

18

z-reikšmės su R

- Tiesiog, jei kintamieji skaitiniai, tai
- `> Az<- scale(A)`


19

K-vidurkių metodas

- Objektai suskirstomi į *k* pradinių klasterių
- Apskaičiuojami klasterių centrai.
- Objektas skiriamas į klasterį, prie kurio centro yra arčiausiai.
- Apskaičiuojami naujų klasterių centrai.
- Objektas skiriamas į klasterį, prie kurio centro yra arčiausiai.....
- (procesas tęsiamas tol, kol perskirstymų daugiau nėra).


20

Objektai skiriami į artimiausią klasterį




21

Suskaičiuojami klasterių centrai



22

Sudaromi nauji klasteriai



23

K-vidurkių metodo privalumai ir trūkumai

- Pakankamai efektyvus ir greitas.
- Netinka, jei duomenys kategoriniai (kaip skaičiuoti vidurkį?)
- Klasterių skaičius nustatomas iš anksto.
- Nurodydami klasterių skaičių, dirbtinai primetame duomenų struktūrą.

24

Klasterių skaičiaus parinkimas


- Yra keletas **rekomendacinių** metodų.
- Galutinai nusprendžia tyrėjas/ja.
- **Realiai visi metodai yra pakaitalas frazės „man taip atrodo“ , solidesnė frazė „kaip matome iš grafiko“.**
- Visi metodai turi tam tikrą logiką.

25


Elbow (alkūnės, lūžio) metodas

- Surandame kiekvienam klasteriui atstumų nuo klasterio centro sumą.
- Viską sudedame (suma žymima **wss**) ir pažymime grafike jos reikšmę.
- Didiname klasterių skaičių ir žiūrime, kada jau ta suma liaujasi greitai mažėti.

Elbow (alkūnēs, lūžio) metodos



wss didelis



wss mažesnis

Elbow (alkūnēs, linkio) metodos

```
> library(factoextra)
> library(cluster)
# pasilieiname tik skaitinius
kintamuosius
> W1short<-subset(W1,
select=c('populatn','lifeexpf','literacy'))
> W2short<-subset(W2,
select=c('pop','lf','lit'))
```

Elbow (alkūnės, linkio) metodas


#Braižome 10 klasterių wss reikšmes.

```
> fviz_nbclust(W1short, kmeans,  
method='wss')
```

```
> fviz_nbclust(W2short, kmeans,  
method='wss')
```

29

Grafikas nestandartizuotiems duomenims, 3 kintamieji



Silueto metodas

- Pamatuojame klasterio elementui x_i vidutinį atstumą iki kitų to klasterio taškų:

- $$a(i) = \frac{\sum_{m=1}^N d(x_i, x_m)}{N-1}$$

- Čia N klasterio elementų skaičius.

Silueto metodas

- Pamatuojame klasterio elementui x_i vidutinį atstumą iki kitų **kito** klasterio C_j taškų:

- $$d(x_i, C_j) = \frac{\sum_{m=1}^M d(x_i, y_m)}{M}$$

- Čia M klasterio C_j elementų skaičius.

Silueto metodas

- Surandame atstumą iki arčiausiai esančio klasterio:
- $b(i) = \min_j d(x_i, C_j)$
- Apibrėžiame 'silueta':
- $s(i) = \frac{b(i) - a(i)}{\max(b(i), a(i))}$
- (kai $N=1$, tai $s(i)=0$).

Silueto metodas

- $-1 \leq s(i) \leq 1$
- $s(i)$ arti 1 rodo gerą klasterizaciją.
- $s(i)$ arti -1 rodo blogą klasterizaciją.
- ($s(i) < 0$, jau negerai).
- Suskaičiavus vidutinį visų taškų $\bar{s}$ galima spręsti, kuri klasterizacija geresnė.

Silueto metodas


#Braižome 10 klasterių vidutinio silueto reikšmes.

```
> fviz_nbclust(W2short, kmeans,  
method='silhouette')
```


```
> fviz_nbclust(W2tik2, kmeans,  
method='silhouette')
```

35

Grafikas standartizuotiems duomenims, 3 kintamieji



Grafikas standartizuotiems duomenims, 2 kintamieji




Išvada

- Dar kartą įsitikinome, kad **aklai** tikėti formaliais rodikliais nėra gerai. Du klasteriai nepanašu, kad labai protinga (*ilgaamžiai ir raštingi* vs *trumpaamžius ir mažaraščius*).
- Kompiuteris žmogaus neatstos (bent jau tol, kol tas visai nenukvailės).


Dunn indeksas

- Kiekvienam klasteriui C_i surandame atstumą tarp labiausiai besiskiriančių elementų.
- $\Delta(C_i) = \max_{x_i, x_j \in C_i} d(x_i, x_j)$



Dunn indeksas

- Atstumas tarp klasterių, tai atstumas tarp arčiausiai esančių tų klasterių elementų
- $\delta(C_i, C_j) = \min_{x_i \in C_i, x_j \in C_j} d(x_i, x_j)$



Dunn indeksas

- Mažiausias atstumas tarp klasterių lyginamas su didžiausiu vidiniu atstumu.
- $DI(C) = \frac{\min \delta(C_i, C_j)}{\max \Delta(C_k)}$
- Čia minimumas ir maksimumas imami pagal visus klasterius.
- Didesnė $DI(C)$ reikšmė – geresnė klasterizacija.

Dunn indeksas

#Pavyzdys su 2 standartizuotais kintamaisiais faile W2tik2

```
> library(clValid)
```

```
> dunn_km=dunn(clusters=k2W2$cluster,Data=W2tik2)
```

```
> dunn_km
```

duoda reikšmę 0.1047623 (krykštauti iš džiaugsmo neišeina)

Dunn indeksas

- Jeigu reikia kitokio atstumo (pvz. Manheteno), tai tiesiog

```
> dist_dunn<-dist(W2tik2,method =  
'manhattan')  
> dunn_value<-  
dunn(distance=dist_dunn,  
clusters=k2W2$cluster)
```
- Beje, DI gausis 0.04203937

Kiti indeksai

- **CH** (Calinski-Harabasz) indeksas: F statistikos ANOVA analogas – vidutinis skirtumas tarp klasterių centrų lyginamas su vidutiniu skirtumu nuo bedro centro.
- Kuo didesnis, tuo klasterizacija geresnė.

Sveikas protas

- Objektų skaičius klasteriuose turi būti priimtinas.
- Jeigu visas valstybes pagal populiaciją sudalinsime į 3 klasterius: (I) Indija; (II) Kinija; (III) visos likusios; tai nebus labai informatyvu.
- Jei klasterių bus daugiau, nei 3, tai gal ir visai neblogai gausis.

Pavyzdys

- Įsitikinsime, kad ir perėjimas prie z-reikšmių nėra panacėja.
- Nagrinėsime failą World95n.
- (Importuotas iš senų SPSS failų su informacija apie kai kurias valstybes 95 metais)

Pavyzdys

- Duomenys atrodo taip:

> head(World95n)

```
country      populatn density urban religion lifeexpf lifeexpm literacy pop_incr
<chr>         <dbl>   <dbl> <dbl> <chr>         <dbl>   <dbl>   <dbl>   <dbl>
1 Afghanistan 20500    25    18 Muslim        44     45     29     2.8
2 Argentina   33900    12    86 Catholic      75     68     95     1.3
3 Armenia     3700   126    68 Orthodox     75     68     98     1.4
4 Australia   17800    2.3    85 Protstnt     80     74    100     1.38
5 Austria      8000    94    58 Catholic     79     73     99     0.2
6 Azerbaijan   7400    86    54 Muslim        75     67     98     1.4
```

47

Pavyzdys

Pasilikime kintamuosius:

- *country* – šalies pavadinimas,
- *populatn* – populiacija tūkstančiais,
- *lifeexpf* – vidutinė mot. gyv. trukmė
- *literacy* – raštingų žmonių procentas.

faile **W1**.

Pastaba: žemiau ir kitur yra tik galimas R taikymo variantas ir nebūtinai optimalus.

48

Pavyzdys

```
> W1 <- subset(World95n,  
select=c('country','populatn','literacy',  
'lifeexpf'))
```

```
> W1 <- na.omit(W1)
```


#pasižiūrimė priklausomybes
(problemos jau bus matyti)

```
> pairs(W1[,2:4])
```

#populiacija aiškiai turi išskirtis

49

Pavyzdys



50

Pavyzdys

```
> W1 <- na.omit(W1)
```

- Pasidarome W2 kopiją be country ir kopiją sunormuotą:

```
> W2 <- subset(W1, select=c(populatn,lit  
eracy, lifeexpf))  
> W3 <-scale(W2)
```

51

Pavyzdys

```
# k means su 3 klasteriais  
> klaW2 <- kmeans(W2,3,nstart=25)  
> klaW3 <- kmeans(W3, 3,nstart=25)  
# palyginame klasterių dydžius  
> klaW2$size  
96 2 9  
> klaW3$size  
2 28 77
```

Pastaba

Komandoje `kmeans` rekomenduojama pridėti `nstart=skč. didesnis už 1`;

- pvz.,

```
> klaW2 <- kmeans(W2,3,nstart=25)
```

- `nstart` nurodo pradinį centrų skaičių, ir

```
> klaW2 <- kmeans(W2,3)
```

gali baigtis ne visai gera klasterizacija (gali ir nesibaigti, bet kam rizikuoti).

Pavyzdys

Grafiškai


```
> library(factoextra)
```

```
> fviz_cluster(klaW2,data=W2,pointsize=3,  
ggtheme = theme_classic())
```

ir analogišką klaW3 grafiką


Pavyzdys

klaW2 (be standartizavimo)



Pavyzdys

k1W2 (su standartizavimu)



Moralas

- Jeigu yra labai išsiskiriančių objektų, o klasterių nedaug, tai standartizavimas gali ir nepadėti. (Šalia dramblio ir kiškis, ir musė atrodo labai maži).
- Be standartizavimo dominavo populiacija.
- Standartizavus kintamuosius, klasterizavimas tapo prasmingesnis.

Pavyzdys

palyginame centrus:

> klaW2\$centers

	<u>populatn</u>	<u>lifeexpf</u>	<u>literacy</u>
1	18104.2	70.41667	79.07292
2	1058400.0	64.00000	65.00000
3	148311.1	68.00000	73.44444

> klaW3\$centers

	<u>populatn</u>	<u>lifeexpf</u>	<u>literacy</u>
1	6.8240682	-0.5721490	-0.5828054
2	-0.1381363	-1.3903823	-1.4333986
3	-0.1270172	0.5204546	0.5363737

■ Ir kada aiškiau?

Pavyzdys

- Kaina, kuri mokama už geresnę klasterizaciją – interpretacijos problema.
- Prisimename:
 - ❖ Teigiama z-reikšmė: daugiau už vidurkį.
 - ❖ Jei duomenys normalūs, tai $z > 3$ yra labai (LABAI) didelė reikšmė.

Pavyzdys

- Vienas iš variantų pasilengvinti gyvenimą – pasinaudoti standartizuota klasterizacija, bet centrus suskaičiuoti tų klasterių pradiniais duomenimis.
 - `W1$kl<-klaW3$cluster`
 - `W1_klast_pirmas<-subset(W1su,kl==1)`
 - `summary(W1_klast_pirmas)`
- ir išsirenkame informaciją.

Pavyzdys

- Galima ir taip:

- `W1su<-W1`

- `W1su$kl<-klaW3$cluster`

- `aggregate(W1su[2:4],list(klaW3$cluster),mean)`

Tada iškart visi centrai.

Hierarchinis
klasterizavimas

Kas tai?

- Visi objektai po truputį jungiami, atsižvelgiant į jų artumą, kol lieka vienas didelis klasteris (agglomeration).
- Visi objektai po truputį skaidomi mažesniais klasteriais, kol vienam klasteriui lieka tik po objektą (divisive method).

63

Kas tai?

- Mes kalbėsime tik apie aglomeracinį klasterizavimą.
- Tada esminė tampa dendrograma, t.y. pažingsninio jungimo grafinis vaizdas.
- Į ją žiūrėdami, nusprendžiame kiek klasterių imti.


64

Hierarchinis klasterizavimas

- Kiekviename etape sujungiami du **artimiausi** objektai/klasteriai.
- Dendrogramoje jungtys braižomos proporcingai atstumams tarp objektų/klasterių.

65

Dendrograma



66

Hierarchinis klasterizavimas

Rezultatas priklauso nuo to, kaip:

- kaip matuosime atstumą tarp objektų.
- kaip matuosime atstumą tarp klasterių.

67

Atstumas tarp objektų

Čia analogiškai k-vidurkių metodei galima naudoti Euklido metriką, galima Manheteno metriką ir t.t.

Populiariausia yra Euklido metrika (t.y. kitas metrikas panaudojus, tenka aiškinti – kodėl)

68

Atstumas tarp klasterių

Populiariausi matavimo metodai:

- Vienetinės jungties (single linkage)
- Pilnosios jungties (complete linkage)
- Centrų (centroid linkage)
- Vidurkinės jungties (mean linkage)
- Wardo (Ward's method)


69

Vienetinės jungties atstumas

- Tarkime turime klasterius A, B .
- Surandame visus įmanomus atstumus $d(x_i, y_j)$, kur $x_i \in A; y_j \in B$.
- $d(A; B) = \min d(x_i; y_j)$.


70

Vienetinės jungties



71

Pilnosios jungties




72

Centrų atstumas

- Tarkime turime klasterius A, B .
- Surandame klasterio A centrą c_A , suvidurkinami visas koordinatas.
- Surandame klasterio B centrą c_B ,
- $d(A; B) = d(c_A; c_B)$.

73

Centrų



74

Vidurkinės jungties

- Surandame visus įmanomus atstumus $d(x_i, y_j)$ ir suvidurkiname.

$$d(A, B) = \frac{1}{N \cdot M} \sum_{i,j=1}^{N,M} d(x_i; y_j)$$

- Čia N, M yra klasterių A, B didumai.

75

Ward metodas

- Sujungia tuos klasterius, kurie mažiausiai padidina vidinę klasterių dispersiją.
- Naudoja Euklido atstumo kvadratą.
- Tegul c_{AB} žymi jungtinio klasterio centrą.

76

Ward atstumas

$$d(A, B) = \sum d_E^2(z_m; c_{AB}) \\ - \sum d_E^2(x_i; c_A) - \sum d_E^2(y_j; c_B)$$

Čia $d_E(\cdot; \cdot)$ yra Euklido atstumo kvadratas.

Sujungs klasterius, kuriems $d(A; B)$ mažiausias.

77

Kurį metodą rinktis?

- Tą, kuriuo gauta klasterizacija įtikinamiausiai atrodo (ir tuo pavyks įtikinti kitus).
- Jeigu įtikinėjimo įgūdžiai prasti, visada galima pasinaudoti jungimo (agglomerative) koeficientu.

78

Jungimo koeficientas

- Apibrėžimas gana miglotas: tai vidurkis normuotų dendrogramos jungčių (miglotas yra normavimas, net autorių L.Kaufman, P.J.Rousseeuw knygoje).
- Tačiau yra R pakete *cluster*.
- Tirsime W2tik2, t.y. standartizuotą info apie moterų gyv.trukmę (lf) ir raštingų piliečių procentą (lit).

79

Jungimo koeficientas

```
> v<-c('single','complete','average','ward')
> names(v)<-
c('single','complete','average','ward')
> ac<-
function(x){agnes(W2tik2,method=x)$ac}
> sapply(v,ac)
```

Jungimo koeficientas

single	complete	average	ward
0.8744079	0.9715437	0.9488266	0.9916664

- Geriausias tas metodas, kuriam AC didžiausias. Tačiau šiuo atveju, praktiškai visi metodai vienodai geri (ir AC itin didelis).

Jungimo koeficientas

- Problema su Ward metodu ta, kad praktiškai visuose R paketuose tai ne visai Ward metodas, nes imama Euklido atstumų, o ne jų kvadratų matrica. Tada reikia tiesiog imti
- `method= 'ward.D2'`
- Pavyzdžiui naudosime pilnosios jungties metodą.

Standartinė klasterizacija

#Susiskaičiuojame Euklido atstumus

```
> distW2tik2<-dist(W2tik2)
```

#Suklasterizuojame

```
➤ hc.pilnas<-hclust(distW2tik2,
  method='complete')
```


```
➤ W2tik2$country<-W1$country
```

#Pasižiūrime dendrogramą su šalių pavadinimais.

83

Pavyzdys

```
> plot(hc.pilnas, labels=W2tik$country,
      lwd=3)
```




Pavyzdys

- Gražumo ir aiškumo mažai. Reikia x-ašį patempti (tiesiog R-studio su pele ir 'zoom')
- Tada jau galima kažką perskaityti.

85

Pavyzdys



Standartinė klasterizacija


Galima ir Ward metodu (teisingu) klasterizuoti.

```
> hc.ward<-hclust(distW2tik2,  
method='ward.D2')  
> plot(hc.ward,labels=W2$country,lwd=3)
```

```
> hc.ward<-hclust(distW2tik2,  
method='ward.D2')  
> plot(hc.ward,labels=W2$country,lwd=3)
```

87

Standartinė klasterizacija



88


Standartinė klasterizacija

- Jeigu nenorime nagrinėti pavadinimų (tą galima vėliau ir ne iš dendrogramos), tai dailiname dendrogramą.

```
> plot(as.dendrogram(hc.pilnas),  
main='Pilna jungtis',lwd=4)
```

89

Standartinė klasterizacija



90

Standartinė klasterizacija

- Pabandome grafiškai pasižymėti 3 klasterius.

```
> par(lwd=4,mar=c(0,0,0,0))
```

```
> rect.hclust(hc.pilnas,k=3,border=2:4)
```

91


Standartinė klasterizacija



92

Standartinė klasterizacija

Su 4 klasteriais atrodo kiek logiškiau.



Standartinė klasterizacija

Išsaugome 4 klasterius.

```
> grup<-cutree(hc.pilnas, k=4)
```

Pažiūrime, kiek valstybių klasteriuose

```
> table(grup)
```

```
grup
 1  2  3  4
11 76 11  9
```

Standartinė klasterizacija

Prijungiame prie pradinio failo klasterių numerius.

```
> W1_su_hcl <- cbind(W1short, cluster=grup)
> head(W1_su_hcl)
```

	country	lifeexpf	literacy	cluster
1	Afghanistan	44	29	1
2	Argentina	75	95	2
3	Armenia	75	98	2
4	Australia	80	100	2
5	Austria	79	99	2
6	Azerbaijan	75	98	2

95

Standartinė klasterizacija

Jeigu smalsu, kokie centrai nestandartizuotiems duomenims

```
> aggregate(W1short[2:3], list(grup), mean)
```

	Group.1	lifeexpf	literacy
1	1	52.45455	30.18182
2	2	75.72368	91.17105
3	3	51.18182	55.18182
4	4	67.22222	57.11111

96

MANUEL EISNER

Crime, Problem Drinking, and Drug Use:
Patterns of Problem Behavior
in Cross-National Perspective

THE ANNALS OF THE AMERICAN ACADEMY
PSS, **580**, 2002, 201-225.

97


Ką tyrė

- 37 valstybes suskirstė pagal 4 būdingus probleminio elgesio pasireiškimus:
- smurtinius nusikaltimus, nuosavybės pažeidimus, alkoholio sukeltą agresiją, narkotikų vartojimą.
- naudojo išvestinius (kelių šaltinių z-reikšmių vidurkius) duomenis.

98

Tyrimų pagrindas:


CANNABIS CONSUMPTION WITHIN THE PAST YEAR, ACCORDING TO AGE



99

Tyrimų pagrindas:

ALCOHOL ABUSE, VARIOUS INDICATORS



100

Klasteriai

Cluster	Violent Crime	Property Crime	Drug Use	Alcohol Abuse	Countries
I: High, except violence	0	++	++	++	Australia, Canada, England and Wales, New Zealand, Scotland, United States
II: Alcohol use high	-	0	0	+	Austria, Belgium, Denmark, Finland, Germany, Ireland, Netherlands, Northern Ireland
III: Violence high	++	0	-	0	Bulgaria, Estonia, Latvia, Lithuania, Poland, Russian Republic, Ukraine
IV: Consistently average	-	0	0	0	Czech Republic, France, Hungary, Italy, Malta, Slovak Republic, Slovenia, Spain, Sweden
V: Consistently low	-	--	-	-	Cyprus, Croatia, Greece, Norway, Portugal, Switzerland

NOTE: Romania not included. ++ indicates that cluster mean > 1; + indicates that cluster mean =

101

Kitos išvados

- naudojo koreliacijas ir kt. metodus
- Anglo-Amerikos šalys: paauglystės problemos;
- Rytų Europa: didelis nusikalstamumas;
- Nusikalstamumas didesnis neturtingose šalyse su ryškia socialine nelygybe;
- Jaunimo narkotikų vartojimas ir alkoholio sukelti nusikaltimai būdingi urbanizuotose šalyse, turinčiose į poilsį orientuotose (leisure-time oriented) gyvenimo stilių.

102

Pastaba

- Būna ir dar labiau specializuotų tyrimų:

Hierarchical Cluster Analysis of
Cytokeratins and Stem Cell Expression
Profiles of Canine Cutaneous Epithelial
Tumors

*Mun Keong Kok, James K. Chambers,
Siew Mei Ong, Hiroyuki Nakayama , and
Kazuyuki Uchida*

Veterinary Pathology

2018, Vol. 55(6) 821-837