

Statistikas – tai žmogus, išsiskiriantis neįtikėtinais gabumais


- pateikti be galo daug įvairių skaičių,
- gautų remiantis miglotomis prielaidomis,
- grįstomis abejotinais įrodymais,
- naudojant nereprezentatyvią imtį,

siekiant vienintelio tikslo – susukti galvas ir taip jau nieko nebesuprantantiems žmonėms, kurie niekada nestudijavo statistikos.

1

Priežastiniai modeliai

- Modelis neturi būti pernelyg bendras.
- Modelis turi būti prasmingas.



2


Priežastinės analizės modeliai

- Sudaromi *spėjamiems* priežastiniams ryšiams tirti.
- Padės nustatyti, ar duomenys neprieštarauja spėjimui.
- Negarantuos, kad spėjimas teisingas.
- Tinkamesnis duomenims modelis nebūtinai yra geresnis, nes modelį dar reikia interpretuoti.

3

Priežastiniai modeliai

- Kaip visada dar reikia patikrinti prielaidas ir modelio tinkamumą.
- (Kartais tiks duomenims, kaip karvei balnas, ir tai reikės pamatyti.)



4

Kelių analizė

Path analysis

- Visi keliai veda į Romą!
- Visi keliai veda į komunizmą!
- Išvada: komunizmas yra Romoje.

5

KĄ DARO?

- Regresijos išplėtojimas, kai nepriklausomi kintamieji (x_i) savo ruožtu tampa priklausomais kintamaisiais kitose regresijos lygtyse.
- Bet ne tas pat, kas kelios atskirai sudarytos regresijos.

6

Bendroji tyrimo schema

1. Modelio specifikacija.
2. Modelio identifikacija.
3. Modelio įverčių skaičiavimas.
4. Modelio respecifikacija.

Aptarsime šiuos etapus smulkiau.

7


Modelio specifikacija

- Tyrėjas sudaro savo spėjamą modelį.
- Remiasi savo mokslais.
- Nebando sukišti į modelį kuo daugiau priklausomybių (o gal išeis).

8

Prielaidos

- Idealiu atveju visi kintamieji normalūs.
- Bet dažnai į tai dėmesio tyrėjai nekreipia (laimingi, jei kintamieji intervaliniai).



9

Prielaidos

- Kintamieji matuojami be paklaidų.
- Visos priklausomybės tiesinės.
- Duomenų bent 5 kartus daugiau, nei kintamųjų.
- Liekamosios paklaidos nekoreliuoja (kadangi PA tiriama, kaip SEM, tai ši prielaida ne itin aktuali).

10


Modelio diagramos elementai

-  stebimas kintamasis
-  latentinis kintamasis, liekana
-  priežastinis ryšys
-  koreliacija (kovariacija)

11

Modelio specifikacija

- Kintamieji, kurie paaiškinami kitais kintamaisiais (turi ateinančią rodyklę) vadinami endogeniniais.
- Kintamieji, kurie tokios rodyklės neturi – egzogeniniai.
- X1 egzogeninis, Y endogeninis.



12

Modelio specifikacija


- Jei manome (o dažniausiai manome), kad endogeninis kintamasis priklauso ne tik nuo modelio kintamųjų, tai nurodome, kad jis turi liekamąją paklaidą.
- Tos paklaidos dispersija irgi bus įvertinta.



13

Modelio specifikacija


- Galimos koreliacijos (kovariacijos) tarp egzogeninių kintamųjų.



14

Modelio specifikacija

- Galimos koreliacijos (kovariacijos) tarp endogeninių kintamųjų.




15

Standartinės PA prielaidos

- nėra ,kilpų‘ (kai grįžtama iš kur atėjom)
- neinama pirmyn, o po to atgal (bet galima eiti atgal, o po to pirmyn).
- Maksimum viena koreliacija keliui.


16

Idėjinė schema





17

Tikslesnė schema:



18



Kaip atrodytų lygtys:

$$EPaž = \beta_{11}Pož + \beta_{12}Prat + \beta_{13}Tik + e_1$$

$$Prat = \beta_{21}Pož + \beta_{22}Tik + e_2$$

Laisvųjų narių nėra (tariama, kad kintamieji centruoti).

21

Ką reikia įvertinti:

- Kelių koeficientus.
- Liekamųjų paklaidų dispersijas.
- Egzogeninių kintamųjų dispersijas.
- Kintamųjų kovariacijas (koreliacijas).

22

Ką reikia įvertinti:

Koeficientus $\beta_{11}, \beta_{12}, \beta_{13}, \beta_{21}, \beta_{22}$

ir liekamųjų paklaidų dispersijas

$Var e_1, Var e_2$

ir egzogeninių kintamųjų dispersijas

$Var Pož, Var Tik$

$$EPaž = \beta_{11}Pož + \beta_{12}Prat + \beta_{13}Tik + e_1$$

$$Prat = \beta_{21}Pož + \beta_{22}Tik + e_2$$

23

Koreliacijos

Koreliacija tarp kintamųjų randama kiekvienam keliui tarp kintamųjų suradus standartizuotų koeficientų sandaugas ir viską sudėjus.

Čia jau galioja visi reikalavimai (be kelių atgal) ir, jei yra koreliacijos, galima ir jomis jungti kintamuosius-bet ne daugiau 1 koreliacijos.

24


Koeficientai

Primena regresiją:

- (Paprasti) **koeficientai (ir kovariacijos)** – padeda sudaryti regresines lygtis (kartais prognozuoti).
- **Standartizuoti koeficientai (ir koreliacijos)** – padeda nustatyti, kurie kintamieji modelyje daro didesnę įtaką.


25

Galimi (standartizuoti) koeficientai:



26

Koreliacija tarp požiūrio ir pažymio



$$\text{cor (Pož.;Egz.paž)}=0.45+0.35\times0.67=0.6845$$

27

Kas naudojama vertinimui:

- Empirinių kovariacijų matrica.
- Pasekmė: modeliui sudaryti nebūtina turėti pradinis duomenis. Užtenka kovariacijų matricos ir stebinių skaičiaus.
- Jei yra k kintamųjų, tai modelis identifikuojamas, kai parametų ne daugiau $k(k+1)/2$.


28

Rekursyvus modelis

- Tokio modelio visi poveikiai vienos krypties (kartą iškeliaavęs į kintamąjį negrįši).
- Nerekursyvus modelis: bent du kintamieji veikia vienas kitą tiesiogiai ar netiesiogiai arba yra bent dvi koreliuojančios liekamosios paklaidos.


29

Rekursyvus modelis



30

Nerekursyvus modelis




31

Kintamojo poveikis

- Vieno kintamojo poveikį kitam kintamajam sudaro suma:
- tiesioginio poveikio (kelio tarp tų kintamųjų koeficientas).
- netiesioginio poveikio (kelių koeficientų sandauga).

32

Tik poveikis EPŽ =
 $-0.43 + 0.67 * (-0.36)$



33

Modelio tinkamumas

- Jeigu vertinamų charakteristikų tiek pat, kiek skirtingų kovariacijų, tai nelabai tą tinkamumą įvertinsi.
- Jeigu mažiau – tinka visos charakteristikos, kurios tiriamos ir SEM (pateiksime vėliau).

34

PASTABOS

- Dažniausiai Path Analysis modelyje visi kintamieji stebimi (nėra latentinių);
- Kintamieji – normalūs.
- Tikslas- nustatyti **priežastinius ryšius**.
- Net ir gera diagrama, dar negarantuoja, kad atsekėme šiuos ryšius.
- Nėra kaip palyginti, kuri iš dviejų kelio diagramų gresnė.

35

Patvirtinančioji Faktorinė analizė Confirmatory Factor Analysis

36

KĄ DARO?

- Panaši į tiriančiąją faktorinę analizę, tačiau:
- Čia **patys sudarome modelį**:
- Tarp latentinių faktorių gali būti koreliacija.

37

CFA idėja

- Kai žiloje senovėje (kai jūsų tėvai buvo maži) vaikai rašydavo
- Petras+Ona = KM,
- jie realiai kūrė CFA modelį.

IBRAHIM+LEILA+ SALIMA+ZAINAB+FATIMA+FA
PETRAS+ONA = ♡


☺ + ☺ = ♡



38

CFA idėja

- Stebimus kintamuosius sieja latentinio faktoriaus įtaka.



39


Reikalavimai

- Stebimi kintamieji – intervaliniai (idealiu atveju – normalūs).
- Nėra išskirčių.
- Duomenų pakankamai daug (stebinių bent 10 kartų daugiau, nei vertinamų parametrų).
- Faktorius bent du kintamuosius aiškina (geriau 3, ar 4).

40

Modelio specifikacija


- CFA atveju vienam iš kintamųjų tenka priskirti 1-inį regresijos koeficientą arba parinkti dispersiją lygią 1.



41

Pavyzdžiai

- Naujovės, Planavimas, Kontrolė, Savarankiškumas, Atsakomybė, komunikabilumas



42

Modelio tinkamumas

- Visi modelio tinkamumo vertinimai grindžiami imties kovariacijų matricos **S** panašumu į atkurtą kovariacijų matricą, kai atsižvelgiama į modelio priklausomybes.
- **Galima tinkamumą vertinti su chi kvadrato statistika** (gerai, kai $p > 0.05$).
- **Galima iš akies** (tik nereikia labai prisimerkti), žiūrint į specialius indeksus.

43

Modelio sudarymas

- Faktorių negali būti susijęs tik su vienu kintamuoju.
- Su dviem – ne itin gerai, bet iš bėdos tinka.
- Su trimis – keturiais, jau visai gerai.
- Daugiau, nei 6, jau atrodo pobaisiai ir nelabai informatyviai.

44

Modelio tinkamumas

- Vertinimai iš akies

Suderinamumo indeksas	Gera reikšmė	Priimtina reikšmė
<i>NC</i>	$NC \leq 2$	$NC \leq 3$
<i>RMSEA</i>	$RMSEA \leq 0,05$	$RMSEA \leq 0,08$
<i>SRMR</i>	$SRMR \leq 0,05$	$SRMR \leq 0,08$
<i>AGFI</i>	$AGFI \geq 0,95$	$AGFI \geq 0,90$
<i>IFI</i>	$IFI \geq 0,95$	$IFI \geq 0,90$
<i>TLI</i>	$TLI \geq 0,95$	$TLI \geq 0,90$
<i>CFI</i>	$CFI \geq 0,95$	$CFI \geq 0,90$

- Populiariausi NC ir RMSEA.

45

Modelio tinkamumas

- NC – Normed Chi-square
- RMSEA – Root Mean Square Error of approximation.
- SRMR – Root Mean Square Residual
- AGFI – Adjusted Goodness-of-fit Index
- IFI – incremental Fit Index
- TLI – Tucker-Lewis Index
- CFI – Comparative Fit Index

Imami 1-2 indeksai ir sprendžiama pagal juos.

46


Modelio tinkamumas

- Suderinamumo indeksai atspindi tik *vidutinį* modelio tinkamumą.
- Neparodo, ar reikalingi *visi* modelio keliai.
- Nepakankami, kad modelį laiktume geru.

47

Pastaba

- Papildomi kintamieji nebūtinai daro modelį geresniu.
- Akiniai su trimis stiklais (už paprastų akinių kainą) pagerina regėjimą, bet nebūtinai yra geresni.



48

Parametrų įverčiai

- Parametrų įverčius rasti pavyksta ne visada (nes tai iteracinis procesas).
- Parametrai skaičiuojami max tikėtimumo (ML) metodu
- arba apibendrintu mažiausių kvadratų (GLS) metodu
- arba asimptotiniu nepriklausomu nuo skirstinio (ADF) metodu (tik didelėms imtims).

49

Parametrų įverčiai

- Visada norime, kad parametrai (kelių koeficientai, dispersijos, koreliacijos) būtų statistiškai reikšmingi.
- Kartais (tokia jau čia matematika) gaunasi koreliacijos didesnės už 1, ar neigiamos dispersijos. Tai rodo, kad modelis blogas.

50

Parametrų įverčiai


Gaunami:

- Nestandartizuoti kelių koeficientai, liekanų dispersijų įverčiai, kovariacijų įverčiai. Tada kai kurie su latentiniais kintamaisiais susiję keliai yra vienetiniai.
- Standartizuoti kelių koeficientai, koreliacijų įverčiai – jie naudojami, norint išsiaiškinti, kurie modelio kintamieji svarbesni (labiau įtakoja kitus kintamuosius).

51

Parametrų įverčiai

- Dažniausiai galutinė schema turi standartizuotus koeficientus:



52

Modelių lyginimas

Lyginant modelius, atsižvelgiama į jų:

- bendrąjį tinkamumą duomenims,
- parametrų įverčius ir modelio logiškumą,
- Akaike's ar kito informacinio indekso reikšmę.

53

Struktūrinės lygtys

Structural Equation Modeling
(SEM)


54

KĄ DARO?

- SEM analizė tikrina ar tyrėjo sudarytas kintamųjų priklausomybės modelis suderintas su duomenimis.
- Gali būti ir latentinių (tiesiogiai nematuojamų) kintamųjų.
- Skirtingi mokslai kūrė skirtingus metodus (path analysis, CFA), o SEM juos apjungė.

55

SEM




56

SEM vs CFA

- SEM leidžiami priežastiniai ryšiai tarp latentinių faktorių.
- Visa kita, iš esmės sutampa su CFA vertinimu.

57

Struktūrinės lygtys



58

Bendros tiesios

- Norime sužinoti ar modelis apskritai suderintas su duomenimis.
- Siekiame įvertinti kiekvieno kintamojo poveikio stiprumą (svorį, regresinį koeficientą).
- Įvertiname kintamųjų priklausomybes.

59

Pradiniai duomenys

- Normalūs.
- Be išskirčių.
- Duomenų pakankamai daug (geru atveju 150-500 stebinių).
- Visos priklausomybės tiesinės.
- Nėra multikolinearumo problemos.
- Nedaug praleistų reikšmių.

60

Pradiniai duomenys

- Žinome matuojamų kintamųjų vidurkius, dispersijas ir koreliacijas arba (dažniau)
- **kintamųjų kovariacijų matricą** – t.y. visas įmanomas kovariacijas ir dispersijas.
- Kovariacija matuoja priklausomybių stiprumą, atsižvelgdama į kintamųjų didumą.
- Pačių kintamųjų reikšmės nėra būtinos.

61

Kaip tikrinamas modelis

- Atkuriamą kintamųjų kovariacijų matricą, atsižvelgiant į spėjamas kintamųjų priklausomybes.
- Lyginame šią matricą su tikrąja matricą.
- Jei mažai skiriasi (tuos skirtumus matuoja chi-kvadrato statistikos reikšmė) darome išvadą, kad duomenys spėjamam modeliui neprieštarauja.

62

Svarbi tiesa

- Gali būti keletas (ir net labai skirtingų) modelių, kurie bus vienodai gerai suderinti su duomenimis.
- SEM palengvins tiesos paieškas, bet nepakeis tyrėjo.
- Taigi, išvada teks daryti patiems ir įtikinti savo tiesa aplinkinius (kol kas užteks įtikinti mane).

63

Bendroji tyrimo schema


1. Modelio specifikacija.
2. Modelio identifikacija.
3. Modelio įverčių skaičiavimas.
4. Modelio respecifikacija.

Sutampa su Kelių Analize ir CFA.
Braižoma visiškai analogiškai.

64

MIMIC modelio pavyzdys


- Multiple Indicators and Multiple Causes
- Tai jau nebe klasikinis SEM.



65

Klasikinis modelis

- Latentiniai kintamieji neturi įeinančių stebimų kintamųjų.



66

Modelio tinkamumas

- Vertinimai iš akies

Suderinamumo indeksas	Gera reikšmė	Priimtina reikšmė
<i>NC</i>	$NC \leq 2$	$NC \leq 3$
<i>RMSEA</i>	$RMSEA \leq 0,05$	$RMSEA \leq 0,08$
<i>SRMR</i>	$SRMR \leq 0,05$	$SRMR \leq 0,08$
<i>AGFI</i>	$AGFI \geq 0,95$	$AGFI \geq 0,90$
<i>IFI</i>	$IFI \geq 0,95$	$IFI \geq 0,90$
<i>TLI</i>	$TLI \geq 0,95$	$TLI \geq 0,90$
<i>CFI</i>	$CFI \geq 0,95$	$CFI \geq 0,90$

- Populiariausi NC ir RMSEA.

67

Modelio tinkamumas

- Norime, kad parametrai (kelių koeficientai, koreliacijos, dispersijos) būtų statistiškai reikšmingi.
- Dažniausiai galutinė schema turi standartizuotus koeficientus.

68

Modelio respecifikavimas

- Sudarome naują modelį, kurį vėl tiriamo.
- Nėra griežtos taisyklės, kuris modelis geresnis. Visai nebūtinai tas, kurio parametrai geresni (pvz. chi-kvadratas mažesnis).
- Gali būti keli skirtingai interpretuojami modeliai tiems patiems duomenims.

69

PASTABOS

- SEM pakanka kovariacijų matricos (ir stebinių skaičiaus).
- Taigi gali tekti sudarinėti SEM duotai kovariacijų matricai.
- Šioje paskaitoje nebuvo parodyta, kaip daryti SEM (ir CFA, ir PA). Teks išsiaiškinti patiems.
- Rekomenduojamas R paketas lavaan.

70