

SEM ir Kelių analizė: Formulų ir diagramų konspektas

Skirta atsiskaitymui ant popieriaus (S1) pagal vadovėlį

Pagal prof. V. Čekanavičiaus „Statistika ir jos taikymai III“ ir paskaitų pavyzdžius

1 Pagrindinės sąvokos ir diagramų elementai

Atsiskaityme rankomis kintamieji beveik visada laikomi standartizuotais:

$$E[X] = 0, \quad \text{Var}(X) = 1 \implies \text{Cov}(X, Y) = \text{Cor}(X, Y) = r_{XY}$$

1.1 Kintamųjų tipai diagramoje

- **Egzogeninis** (X, ξ): nepriklausomas kintamasis. Į jį **neįeina** jokia **vienkryptė** rodyklė (iš jo rodyklės tik išeina).
 - *Savybė*: neturi liekamosios paklaidos e .
 - *Vertinama*: jo dispersija ir tarpusavio kovariacijos/koreliacijos su kitais egzogeniniais kintamaisiais.
- **Endogeninis** (Y, η): priklausomas kintamasis. Į jį **įeina bent viena vienkryptė** rodyklė $\rightarrow$.
 - *Savybė*: kiekvienas endogeninis kintamasis **privalo turėti liekamąją paklaidą** (e, δ, d).
 - *Vertinama*: įeinančių kelių koeficientai ir paklaidos dispersija $\text{Var}(e)$.
- **Stebimi kintamieji** (indikatoriai): žymimi **stačiakampiais**.
- **Latentiniai faktoriai**: žymimi **ovalais / elipsėmis**.
- **Liekamosios paklaidos**: žymimos **mažais apskritimais**.

1.2 Ryšių tipai kelių diagramose

- $X \xrightarrow{\beta} Y$: tiesioginė įtaka (kelio / regresijos svoris β).
- $X \xleftrightarrow{r} Y$: dvipusė lankinė rodyklė (koreliacija arba kovariacija). Priežastinis ryšys nenurodomas.
- $e \rightarrow Y$: liekamoji paklaida (kelio svoris fiksuojamas 1, o vertinama dispersija $\text{Var}(e)$).

1.3 Latentinių kintamųjų skalės fiksavimas

Latentiniai faktoriai neturi matavimo vienetų, todėl modeliui identifikuoti būtina fiksuoti skalę vienu iš 2 būdų:

1. **Žymimasis indikatorius** (*marker variable*): vieno indikatoriaus kelio svoris fiksuojamas $\lambda_1 = 1$.
2. **Standartizuotas faktorius**: fiksuojama paties latentinio faktoriaus dispersija $\text{Var}(\xi) = 1$.

2 Wright'o kelių sekimo taisyklės (*Tracing rules*)

Koreliacija tarp dviejų standartizuotų kintamųjų X ir Y lygi visų **leistinų jungiančių kelių** sandaugų sumai:

$$\text{Cor}(X, Y) = \sum_{\text{visi leistini keliai } p} \prod_{k \in p} w_k$$

4 Wright'o taisyklės leistinam keliui:

1. **Nėra kilpų**: kelias negali praeiti pro tą patį kintamąjį daugiau nei 1 kartą.
2. **Draudžiama** $\rightarrow \leftarrow$: negalima eiti rodykle pirmyn, o po to atgal! Tai susidūrimo taškas (*collider* / bendra pasekmė).
3. **Leidžiama** $\leftarrow \rightarrow$: galima eiti atgal, o po to pirmyn! Tai bendra priežastis (*common cause*).
4. **Ne daugiau 1 koreliacijos**: kelyje leidžiamas daugiausiai vienas dvipusis lankas $\leftrightarrow$.

3 Poveikių išskaidymas (*Effect decomposition*)

Vieno kintamojo X ryšys su kitu kintamuoju Y išskaidomas į dedamąsias:

- **Tiesioginis poveikis** (*Direct effect, DE*): kelio koeficientas tiesiogiai iš $X \rightarrow Y$.
- **Netiesioginis poveikis** (*Indirect effect, IE*): kelių per visus tarpinius kintamuosius koeficientų sandaugų suma ($X \rightarrow M_1 \rightarrow \dots \rightarrow Y$).
- **Bendrasis priežastinis poveikis** (*Total causal effect, TE*):

$$\text{TE} = \text{DE} + \text{IE}$$

- **Neanalizuojamas poveikis** (*Unanalyzed*): atsiranda dėl egzogeninių kintamųjų tarpusavio koreliacijos (kelyje yra dvipusis lankas $\leftrightarrow$).
- **Iškraipytas poveikis** (*Spurious / Distorted*): atsiranda dėl bendros trečio kintamojo priežasties ($\leftarrow Z \rightarrow$).

Bendra koreliacija $r_{XY} = \text{TE} + \text{Neanalizuojamas} + \text{Iškraipytas}$

4 Modelio identifikavimas ir laisvės laipsniai

4.1 Duomenų taškų skaičius (p^*)

- Kai žinoma **kovariacijų matrica** (k kintamųjų):

$$p^* = \frac{k(k+1)}{2} \quad (\text{apima } k \text{ dispersijų})$$

- Kai žinoma **koreliacijų matrica** (standartizuota):

$$p^* = \frac{k(k-1)}{2} \quad (\text{įstrižainėje vienetai})$$

4.2 Laisvės laipsniai (df)

Tarkime, kad modelyje laisvai vertinamų parametrų skaičius yra q :

$$df = p^* - q$$

- $df > 0$: **Perteklinis** (*Over-identified*). Modelį galima tikrinti χ^2 ir suderinamumo indeksais.
- $df = 0$: **Tiksliai identifikuojamas / pilnasis** (*Just-identified*). $\hat{\Sigma} = S$, $\chi^2 = 0$, tobulas sutapimas garantuotas matematiškai.
- $df < 0$: **Neidentifikuojamas** (*Under-identified*). Parametrų rasti neįmanoma (trūksta lygčių).

4.3 Identifikavimo taisyklės

1. **t-taisyklė** (būtina sąlyga): $q \leq p^*$.
2. **Rekursyvumo taisyklė**: jei modelio diagramoje nėra grįžtamųjų ciklų ir liekamosios paklaidos nekoreliuoja, modelis garantuotai identifikuojamas.
3. **CFA taisyklė**:
 - 1 faktoriaus modelis: reikia bent **3 indikatorius**.
 - ≥ 2 koreliuojančių faktorių: reikia bent **2 indikatorius** kiekvienam faktoriui.

5 Paklaidų dispersijos $\text{Var}(e)$ ir R^2 rankomis

Standartizuotam endogeniniam kintamajam Y :

$$\text{Var}(Y) = 1 = R_Y^2 + \text{Var}(e_Y) \implies \text{Var}(e_Y) = 1 - R_Y^2$$

Determinacijos koeficientas R_Y^2 :

$$R_Y^2 = \sum_j \beta_j \cdot \text{Cor}(X_j, Y)$$

Pvz., jei $Y = aX_1 + bX_2 + e_Y$:

$$R_Y^2 = a \cdot \text{Cor}(X_1, Y) + b \cdot \text{Cor}(X_2, Y)$$

$$\text{Var}(e_Y) = 1 - (a \cdot r_{1Y} + b \cdot r_{2Y})$$

6 Greitoji formulė 2x2 lygčių sistemoms (Egzamino formulė)

Kramerio formulė 2x2 sistemai: Kelių analizėje nuolat atsiranda sistema:

$$\begin{cases} \beta_1 + r\beta_2 = r_{1Y} \\ r\beta_1 + \beta_2 = r_{2Y} \end{cases}, \quad \text{kur } r = \text{Cor}(X_1, X_2)$$

Determinantas: $D = 1 - r^2$. Sprendiniai gaunami iš karto:


$$\beta_1 = \frac{r_{1Y} - r \cdot r_{2Y}}{1 - r^2}$$

$$\beta_2 = \frac{r_{2Y} - r \cdot r_{1Y}}{1 - r^2}$$

Sutaupo skaičiavimo laiką ir apsaugo nuo aritmetinių klaidų!

7 SEM matricinė struktūra (LISREL ir 3.3.9 pav.)

Šiame skyriuje pateikiama tiksli vadovėlio 3.3.9 pav. diagrama ir jos užrašymas LISREL matricomis pagal pavyzdį 3.3.4.



3.3.9 pav. Klasikinio SEM modelio diagrama (Čekanaavičius, p. 207).

7.1 LISREL lygčių sistema

Struktūrinis: $\eta = B\eta + \Gamma\xi + d$

Matavimas (Y): $Y = \Lambda_y\eta + e$

Matavimas (X): $X = \Lambda_x\xi + \delta$

7.2 Kaip iš diagramos užrašyti matricas:

1. **Stulpeliai** atitinka faktorius, iš kurių išeina rodyklė.
2. **Eilutės** atitinka kintamuosius, į kuriuos įeina rodyklė.
3. Jei rodyklės nėra $\rightarrow 0$; jei fiksuotas $\rightarrow 1$; jei laisvas $\rightarrow \lambda, \gamma, b$.

3.3.9 pav. atitinkančios matricos:

$$B = \begin{pmatrix} 0 & 0 \\ b_{21} & 0 \end{pmatrix}, \quad \Gamma = \begin{pmatrix} \gamma_{11} & \gamma_{12} \\ 0 & \gamma_{22} \end{pmatrix}$$

$$\Lambda_y = \begin{pmatrix} 1 & 0 \\ \lambda_{21}^y & 0 \\ 0 & 1 \\ 0 & \lambda_{42}^y \\ 0 & \lambda_{52}^y \end{pmatrix}, \quad \Lambda_x = \begin{pmatrix} 1 & 0 \\ \lambda_{21}^x & 0 \\ \lambda_{31}^x & 0 \\ 0 & 1 \\ 0 & \lambda_{52}^x \\ 0 & \lambda_{62}^x \end{pmatrix}$$

Paklaidų kovariacijų matricos:

- Θ_δ (6×6): įstrižainėje $D(\delta_i)$, o elementai (1, 2) ir (2, 1) yra $\text{Cov}(\delta_1, \delta_2)$ dėl lanko tarp $\delta_1 \leftrightarrow \delta_2$.
- Θ_e (5×5): įstrižainėje $D(e_i)$, o pozicijose (3, 4), (3, 5) yra $\text{Cov}(e_3, e_4)$ ir $\text{Cov}(e_3, e_5)$.
- $\Phi = \text{diag}(D\xi_1, D\xi_2)$, $\Psi = \text{diag}(Dd_1, Dd_2)$.

8 Mokinio savybių modeliai (3.3.7 pav.)

Vadovėlio 3.3.7 pav. nagrinėjami 3 Multitrait-Multimethod (MTMM) modelio variantai:

1. a) **MTMM modelis:**

- Viršuje 3 bruožų faktoriai: Patr, Gab, Lyd (su lankais $\leftrightarrow$).
- Apačioje 3 metodų faktoriai: Mok, Tėv, Klas (su lankais $\leftrightarrow$).
- Kiekvienas iš 9 indikatorių ($p_m, g_m, \dots, v_k$) turi **dvi įeinančias rodykles**: vieną iš savo bruožo ir vieną iš vertinimo metodo.

2. b) **CTCU modelis** (*Correlated Trait – Correlated Uniqueness*):

- Metodų faktoriai apačioje **pašalinami**.
- Vietoj jų įvedami **koreliuojančių liekamųjų paklaidų lankai** tarp to paties vertinimo būdo: $e_1 \leftrightarrow e_2 \leftrightarrow e_3$ (mokytojų), $e_4 \leftrightarrow e_5 \leftrightarrow e_6$ (tėvų), $e_7 \leftrightarrow e_8 \leftrightarrow e_9$ (klasės).


3. c) **CT modelis** (*Correlated Trait only*):

- Tik bruožų faktoriai viršuje, o liekamosios paklaidos tarpusavyje **nekoreliuoja**.

Egzaminio esmė: Jei CTCU tinka žymiai geriau nei CT modelis $\Rightarrow$ vertinimo metodas daro statistiškai reikšmingą įtaką matavimams!

9 1 Pavyzdys: Rasti ryšių reikšmes (Žalia lenta)

Sąlyga: Duota kelio diagrama tarp 4 kintamųjų A, B, C, D :



Duota koreliacijų matrica:

	A	B	C	D
A	1	0.50	0.60	0.20
B		1	0.70	0.25
C			1	0.30
D				1

Sprendimas žingsnis po žingsnio:

1 žingsnis: Randame α .

Tarp egzogeninių kintamųjų A ir B yra tik dvipusis lankas:

$$\alpha = \text{Cor}(A, B) = 0.50$$

2 žingsnis: Randame a ir b (kintamajam C).

Struktūrinė lygtis: $C = aA + bB + e_C$.

Pagal Wright'o taisykles:

$$\text{Cor}(A, C) = a + \alpha b = a + 0.5b = 0.60$$

$$\text{Cor}(B, C) = \alpha a + b = 0.5a + b = 0.70$$

Taikome greitąją 2x2 formulę ($r = 0.5$, $1 - r^2 = 0.75$):

$$a = \frac{0.60 - 0.5 \cdot 0.70}{0.75} = \frac{0.25}{0.75} = \frac{1}{3} \approx 0.333$$

$$b = \frac{0.70 - 0.5 \cdot 0.60}{0.75} = \frac{0.40}{0.75} = \frac{8}{15} \approx 0.533$$

3 žingsnis: Randame c ir d (kintamajam D).

Struktūrinė lygtis: $D = cC + dB + e_D$.

Užrašome D koreliacijas su B ir A :

$$\begin{aligned} \text{Cor}(B, D) &= c \cdot \text{Cor}(B, C) + d \cdot \text{Cor}(B, B) \\ &= 0.70c + 1.0d = 0.25 \end{aligned}$$

$$\begin{aligned} \text{Cor}(A, D) &= c \cdot \text{Cor}(A, C) + d \cdot \text{Cor}(A, B) \\ &= 0.60c + 0.50d = 0.20 \end{aligned}$$

Padauginame antrąją lygtį iš 2: $1.20c + d = 0.40$. Atimame pirmąją lygtį:

$$(1.20c + d) - (0.70c + d) = 0.40 - 0.25 \Rightarrow 0.50c = 0.15 \Rightarrow c = 0.30$$

Įstatome $c = 0.30$ į pirmąją lygtį:

$$d = 0.25 - 0.70(0.30) = 0.25 - 0.21 = 0.04$$

Galutiniai ryšių koeficientai:

$$\begin{aligned} \alpha &= 0.50, & a &= 1/3 \approx 0.333, \\ b &= 8/15 \approx 0.533, & c &= 0.30, & d &= 0.04 \end{aligned}$$


Liekamųjų paklaidų dispersijos:

$$\begin{aligned} \text{Var}(e_C) &= 1 - (a \cdot r_{AC} + b \cdot r_{BC}) \\ &= 1 - (0.20 + 0.3733) = 0.4267 \end{aligned}$$

$$\begin{aligned} \text{Var}(e_D) &= 1 - (c \cdot r_{CD} + d \cdot r_{BD}) \\ &= 1 - (0.09 + 0.01) = 0.90 \end{aligned}$$

10 2 Pavyzdys: Užrašyti visas koreliacijas (Baltas ekranas)

Sąlyga: Pradinis šakninis kintamasis * nukreipia rodykles į A, B, C :



Visų koreliacijų išvedimas pagal Wright'o taisykles:

10.1 1. Koreliacijos su šakniniu kintamuoju *

$$\text{Cor}(*, A) = \alpha, \quad \text{Cor}(*, B) = \beta, \quad \text{Cor}(*, C) = \gamma$$

$$\text{Cor}(*, D) = \alpha a + \beta b$$

$$\text{Cor}(*, E) = \beta c + \gamma d$$

10.2 2. Koreliacijos tarp pirmojo lygio (A, B, C)

Jungiasi per bendrą priežastį * ($\leftarrow * \rightarrow$):

$$\text{Cor}(A, B) = \alpha\beta, \quad \text{Cor}(A, C) = \alpha\gamma, \quad \text{Cor}(B, C) = \beta\gamma$$

10.3 3. Koreliacijos tarp lygmenų

Su kintamuoju D :

$$\begin{aligned}\text{Cor}(A, D) &= a + \text{Cor}(A, B)b = a + \alpha\beta b \\ \text{Cor}(B, D) &= b + \text{Cor}(A, B)a = b + \alpha\beta a \\ \text{Cor}(C, D) &= \text{Cor}(A, C)a + \text{Cor}(B, C)b \\ &= \alpha\gamma a + \beta\gamma b = \gamma(\alpha a + \beta b)\end{aligned}$$

Su kintamuoju E :

$$\begin{aligned}\text{Cor}(A, E) &= \text{Cor}(A, B)c + \text{Cor}(A, C)d \\ &= \alpha\beta c + \alpha\gamma d = \alpha(\beta c + \gamma d) \\ \text{Cor}(B, E) &= c + \text{Cor}(B, C)d = c + \beta\gamma d \\ \text{Cor}(C, E) &= d + \text{Cor}(B, C)c = d + \beta\gamma c\end{aligned}$$

10.4 4. Ryšys tarp galutinių kintamųjų D ir E

DĖSTYTOJO TAISYKLĖ TESTE (Poveikis vs. Koreliacija): Ką turėjo omenyje dėstytojas:

- D ir E yra galutiniai endogeniniai kintamieji. Į juos rodyklės tik įeina, iš jų rodyklės neišeina.
- Priežastinis poveikis:** tarp D ir E yra lygus 0 (iš D negalima nuvykti į E).
- Modelio lankas:** tarp D ir E dvipusio lanko nėra ($D \leftrightarrow E$), todėl jų liekanos e_D, e_E nekoreliuoja.
- Atsiskaityme rankomis:** dėstytojai dažnai traktuoja, kad galutiniai kintamieji **tarpusavyje nekoreliuojami / neturi ryšio** ($\text{Cor}(D, E) = 0$), nes iš D ar E „negalima grįžti atgal į modelį“.

Teorinis Wright'o atvejis (jei prašoma rasti kovariaciją per bendrą priežastį B):

Kadangi abu kintamieji priklauso nuo B ($D = bB + \dots, E = cB + \dots$), jie turi bendrą priežastį. Pagal taisyklę „galima eiti atgal, o po to pirmyn“ ($\leftarrow \rightarrow$):

- $D \xleftarrow{b} B \xrightarrow{c} E \implies bc$
- $D \xleftarrow{b} B \xleftarrow{*} \gamma \xrightarrow{d} C \xrightarrow{d} E \implies b\beta\gamma d$
- $D \xleftarrow{a} A \xleftarrow{\alpha} * \xrightarrow{\beta} B \xrightarrow{c} E \implies a\alpha\beta c$
- $D \xleftarrow{a} A \xleftarrow{\alpha} * \xrightarrow{\gamma} C \xrightarrow{d} E \implies a\alpha\gamma d$


Suma per bendrus protėvius:

$$\text{Cor}(D, E) = bc(1 - \beta^2) + \text{Cor}(*, D) \cdot \text{Cor}(*, E)$$

Egzamino patarimas: jeigu dėstytojas minėjo, kad iš D ar E grįžti negalima – rašykite: „Tarp D ir E ryšio/koreliacijos nėra ($\text{Cor}(D, E) = 0$), nes iš galutinių kintamųjų negrįžtama“. Jei reikalauja teorinės koreliacijos per B – nurodykite $bc + \dots$

11 3 Pavyzdys: Vadovėlio uždavinys (Čekanavičius, p. 167)

Sąlyga: Standartizuoti kintamieji X, Y, Z :



Duota koreliacijų matrica:

$$S = \begin{pmatrix} 1 & 0.40 & 0.60 \\ 0.40 & 1 & 0.20 \\ 0.60 & 0.20 & 1 \end{pmatrix}, \quad (r_{XY} = 0.4, r_{XZ} = 0.6, r_{YZ} = 0.2)$$

Sprendimas:

- Kintamajam Y : lygtis $Y = \beta_1 X + e_Y$.

$$\text{Cor}(X, Y) = \beta_1 \implies \beta_1 = 0.40$$

- Kintamajam Z : lygtis $Z = \beta_2 X + \beta_3 Y + e_Z$.

$$\text{Cor}(X, Z) = \beta_2 + \beta_3 \cdot r_{XY} = \beta_2 + 0.40\beta_3 = 0.60$$

$$\text{Cor}(Y, Z) = \beta_2 \cdot r_{XY} + \beta_3 = 0.40\beta_2 + \beta_3 = 0.20$$

Taikome greitąją 2x2 formulę ($r = 0.40, 1 - r^2 = 0.84$):

$$\beta_2 = \frac{0.60 - 0.40(0.20)}{0.84} = \frac{0.52}{0.84} = \frac{13}{21} \approx 0.619$$

$$\beta_3 = \frac{0.20 - 0.40(0.60)}{0.84} = \frac{-0.04}{0.84} = -\frac{1}{21} \approx -0.048$$

- Liekamųjų paklaidų dispersijos:

$$\text{Var}(e_Y) = 1 - \beta_1^2 = 1 - 0.40^2 = 0.84$$

$$\begin{aligned}\text{Var}(e_Z) &= 1 - (\beta_2 r_{XZ} + \beta_3 r_{YZ}) \\ &= 1 - (0.619 \cdot 0.60 - 0.048 \cdot 0.20) \\ &= 1 - 0.3619 = 0.6381\end{aligned}$$

- Poveikių kintamajam Z išskaidymas:

- $X \rightarrow Z$ tiesioginis: $\text{DE} = \beta_2 = 0.619$.
- $X \rightarrow Z$ netiesioginis per Y : $\text{IE} = \beta_1 \cdot \beta_3 = 0.40 \times (-0.048) = -0.019$.
- Bendrasis: $\text{TE} = 0.619 - 0.019 = 0.600 = r_{XZ}$!

12 Dažniausi kontroliniai klausimai ir gudrybės

- Kodėl kelias $A \rightarrow C \leftarrow B$ negalioja?** Nes rodyklės susiduria smaigaliais ($\rightarrow \leftarrow$). Tai yra „collider“ – informacija per jį neina.
- Kiek yra nepriklausomų koreliacijų?** k kintamiesiems yra $p^* = \frac{k(k-1)}{2}$ porinių koreliacijų. Pvz., $k = 4 \implies 6$; $k = 5 \implies 10$; $k = 6 \implies 15$.
- Heywood atvejis:** jei apskaičiuota liekanosios paklaidos dispersija gaunama neigiama ($\text{Var}(e) < 0$) arba koreliacija > 1 , modelis yra blogai specifikuotas arba duomenys netinkami.
- Kodėl χ^2 reikšmė priklauso nuo N ?** Kadangi $\chi^2 = (N - 1)F_{ML}$, esant dideliame N net mažiausi neatitiktimai tampa statistiškai reikšmingi ($p < 0.05$). Todėl vertinami RMSEA, CFI, TLI.