


Vydas Čekanavičius

Gediminas Murauskas

TAIKOMOJI REGRESINĖ ANALIZĖ

SOCIALINIULOSE TYRIMULOSE





Vydas Čekanavičius, Gediminas Murauskas

TAIKOMOJI REGRESINĖ ANALIZĖ SOCIALINIUOSE TYRIMUOSE

**Vilniaus universiteto leidykla
2014 m.**

Apsvarstė ir rekomendavo išleisti Vilniaus universiteto matematikos ir informatikos fakulteto taryba (2013 m. lapkričio 15 d.; protokolo išrašas Nr. 7)

Recenzavo:

prof. Marijus Radavičius (Vilniaus universitetas)

prof. Danutė Krapavickaitė (Vilniaus Gedimino technikos universitetas)

doc. Rimantas Eidukevičius (Vilniaus universitetas)

ISBN 978-609-459-300-0

© Vydas Čekanavičius, 2014

© Gediminas Murauskas, 2014

© Vilniaus universitetas, 2014

Turinys

Pratarmė	16
1. ĮVADAS	19
1.1. Kintamieji ir jų charakteristikos	19
1.1.1. Kintamųjų matavimo skalės.....	19
1.1.2. Svarbiausios kintamųjų skaitinės charakteristikos	21
1.1.3. Normalieji kintamieji	23
1.2. Statistinės išvados	25
1.2.1. Parametrų įverčiai ir jų pasikliautiniai intervalai.....	25
1.2.2. Statistinė hipotezė	26
1.2.3. Pastabos apie vartojamus terminus	28
2. TIESINĖ REGRESINĖ ANALIZĖ	29
2.1. Tiesinės regresijos modelis	29
2.1.1. Modelio lygtis	29
2.1.2. Prognozavimas	30
2.1.3. Reikalavimai duomenims ir modelio prielaidos	31
2.1.4. Modelio tinkamumas	33
2.1.5. Tiesinės regresinės analizės etapai	36
2.1.6. Modelio tobulinimas	37
2.1.7. Pastabos apie modelio taikymą.....	39
2.1.8. Standartiniai tiesinės regresijos modelio aprašymai	40
2.2. Tiesinė regresinė analizė su SPSS.....	41
2.2.1. Duomenys	41
2.2.2. Pirminio modelio tyrimas	42
2.2.3. Pirminio modelio tyrimo rezultatai	44
2.2.4. Šapiro–Vilko kriterijus SPSS.....	50
2.2.5. Modelio tobulinimas	51

2.2.6. Prognozės ir stebinių grafinis palyginimas	54
2.2.7. Rezultatų aprašymas	55
2.2.8. SPSS komandų sintaksė tiesinei regresinei analizei	56
2.2.9. Autokoreliacijos tyrimas	57
2.2.10. Multikolinearumo problema	58
2.2.11. Žingsninė regresija.....	59
2.3. Tiesinė regresinė analizė su STATA	63
2.3.1. Duomenys	63
2.3.2. Regresijos modelio lygtis.....	64
2.3.3. Regresijos prielaidų tikrinimas	66
2.3.4. Galutinis modelis	69
2.3.5. Prognozės ir stebinių grafinis palyginimas	71
2.3.6. Išvados	71
2.3.7. Autokoreliacija.....	72
2.3.8. Multikolinearumo problema	73
2.3.9. Žingsninė regresija.....	74
2.4. Tiesinė regresinė analizė su SAS	78
2.4.1. Duomenys	78
2.4.2. Regresijos modelio lygtis.....	80
2.4.3. Regresijos prielaidų tikrinimas	82
2.4.4. Galutinis modelis	88
2.4.5. Prognozės ir stebinių grafinis palyginimas	89
2.4.6. Išvados	90
2.4.7. Autokoreliacija.....	91
2.4.8. Multikolinearumo problema	91
2.4.9. Žingsninė regresija.....	94
2.4.10. SAS programos tiesinės regresijos procedūra	99

2.5. Tiesinė regresinė analizė su R.....	102
2.5.1. Duomenys	102
2.5.2. Regresijos modelio lygtis.....	103
2.5.3. Regresijos prielaidų tikrinimas	106
2.5.4. Galutinis modelis	112
2.5.5. Prognozės ir stebinių grafinis palyginimas	113
2.5.6. Išvados	114
2.5.7. Autokoreliacija.....	114
2.5.8. Multikolinearumo problema	115
2.5.9. Žingsninė regresija.....	117
2.5.10. R programos tiesinės regresijos komandos.....	120
Uždaviniai	123
3. TIESINĖS REGRESIJOS ALTERNATYVOS	127
3.1. Tiesinei regresijai netinkami duomenys	128
3.1.1. Heteroskedastiški ir ne visai normalūs duomenys	128
3.1.2. Duomenys su išskirtimis.....	131
3.1.3. Duomenų charakteristikų santrauka.....	133
3.2. Stabilizuotų liekamųjų paklaidų regresija	134
3.2.1. Modelio paskirtis	134
3.2.2. Liekamųjų paklaidų HC korekcijos su STATA.....	135
3.2.3. Liekamųjų paklaidų HC korekcijos su SAS	137
3.2.4. Liekamųjų paklaidų HC korekcijos su R.....	139
3.2.5. Savirankos regresija su STATA	142
3.2.6. Savirankos regresija su SPSS	144
3.2.7. Savirankos regresija su R.....	147
3.3. Atsparioji regresija	150
3.3.1. Modelio paskirtis	150

3.3.2. Atsparioji regresija su STATA	151
3.3.3. Atsparioji regresija su SAS.....	153
3.3.4. Atsparioji regresija su R	161
3.4. Medianos regresija.....	165
3.4.1. Modelio paskirtis	165
3.4.2. Medianos regresija su STATA	167
3.4.3. Medianos regresija su SAS	173
3.4.4. Medianos regresija su R.....	183
3.5. Netiesinė regresija.....	190
3.5.1. Modelio paskirtis	190
3.5.2. Netiesinė regresija su SPSS	192
3.5.3. Netiesinė regresija su STATA	196
3.5.4. Netiesinė regresija su SAS.....	198
3.5.5. Netiesinė regresija su R	204
Uždaviniai.....	207
4. DVINARĖ LOGISTINĖ REGRESINĖ ANALIZĖ.....	210
4.1. Dvinarės logistinės regresijos modelis.....	210
4.1.1. Modelio lygtis	210
4.1.2. Galimybių santykis	211
4.1.3. Prognozavimas.....	213
4.1.4. Reikalavimai duomenims	214
4.1.5. Modelio tinkamumas	215
4.1.6. Dvinarės logistinės regresinės analizės etapai	216
4.1.7. Modelio tobulinimas	217
4.1.8. Pastabos apie logistinės regresijos taikymą	218
4.1.9. Standartiniai regresijos modelių aprašymai	219
4.2. Dvinarė logistinė regresinė analizė su SPSS.....	219

4.2.1. Duomenys	219
4.2.2. SPSS parinktys pradiniam regresijos modeliui.....	221
4.2.3. Rezultatai	222
4.2.4. Modelio tobulinimas	228
4.2.5. Rezultatų aprašymas	232
4.2.6. SPSS komandų sintaksė.....	233
4.2.7. Regresorių sąveika.....	234
4.2.8. Viena dominuojanti priklausomo kintamojo reikšmė.....	235
4.2.9. Multikolinearumas	235
4.2.10. Žingsninė logistinė regresija	236
4.2.11. Apibendrintas tiesinis modelis su logit jungtimi	241
4.3. Dvinarė logistinė regresinė analizė su STATA.....	246
4.3.1. Duomenys	246
4.3.2. Modelio tyrimas	249
4.3.3. Atsparioji logistinė regresija	253
4.3.4. Reikšmių prognozavimas.....	254
4.3.5. Kategoriniai regresoriai	256
4.3.6. Multikolinearumas	257
4.3.7. Žingsninė logistinė regresija	259
4.4. Dvinarė logistinė regresinė analizė su SAS.....	260
4.4.1. Duomenys	260
4.4.2. Modelio tyrimas	263
4.4.3. Reikšmių prognozavimas.....	269
4.4.4. Kategoriniai regresoriai	270
4.4.5. Multikolinearumas	272
4.4.6. Žingsninė logistinė regresija	276
4.4.7. SAS programos logistinės regresijos procedūra	278

4.5. Dvinarė logistinė regresinė analizė su R.....	282
4.5.1. Duomenys	282
4.5.2. Modelio tyrimas	285
4.5.3. Atsparioji logistinė regresija	291
4.5.4. Reikšmių prognozavimas.....	292
4.5.5. Kategoriniai regresoriai	293
4.5.6. Multikolinearumas	295
4.5.7. Žingsninė logistinė regresija	298
Uždaviniai.....	304
5. DAUGIANARĖ LOGISTINĖ REGRESINĖ ANALIZĖ.....	307
5.1. Daugianarės logistinės regresijos modelis	307
5.1.1. Modelio lygtys	307
5.1.2. Prognozavimas.....	309
5.1.3. Galimybių santykiai	309
5.1.4. Duomenys	310
5.1.5. Modelio tinkamumas	311
5.1.6. Daugianarės logistinės regresinės analizės etapai	313
5.1.7. Modelio tobulinimas	314
5.1.8. Pastabos apie daugianarės regresijos taikymą	315
5.1.9. Standartiniai daugianarės logistinės regresijos modelių aprašymai	315
5.2. Daugianarė logistinė regresinė analizė su SPSS.....	316
5.2.1. Duomenys	316
5.2.2. SPSS parinktys daugianarei logistinei regresijai	317
5.2.3. Rezultatai	319
5.2.4. Prognozavimas.....	323
5.2.5. Rezultatų aprašymas	324
5.2.6. SPSS komandų sintaksė daugianarei logistinei regresinei analizei	325

5.2.7. Kitos kontrolinės kategorijos pasirinkimas.....	326
5.2.8. Kintamųjų sąveikos įtraukimas.....	327
5.2.9. Žingsninė daugianarė logistinė regresija	328
5.3. Daugianarė logistinė regresinė analizė su STATA	330
5.3.1. Duomenys	330
5.3.2. STATA parinktys.....	331
5.3.3. Prognozavimas.....	333
5.3.4. Klasifikacinė lentelė	333
5.3.5. Kategorinis kintamasis.....	334
5.4. Daugianarė logistinė regresinė analizė su SAS	335
5.4.1. Duomenys	335
5.4.2. Analizė	337
5.4.3. Prognozavimas.....	339
5.4.4. Klasifikacinė lentelė	340
5.4.5. Kategorinis kintamasis.....	342
5.4.6. SAS programos logistinės regresijos procedūra	344
5.5. Daugianarė logistinė regresinė analizė su R.....	348
5.5.1. Duomenys	348
5.5.2. Analizė	349
5.5.3. Prognozavimas.....	351
5.5.4. Klasifikacinė lentelė	351
5.5.5. Kategorinis kintamasis.....	352
5.5.6. R programos daugianarės logistinės regresijos komandos	354
Uždaviniai.....	356
6. RANGINĖ LOGISTINĖ REGRESINĖ ANALIZĖ	357
6.1. Ranginės logistinės regresijos modelis	357
6.1.1. Modelio lygtys	357

6.1.2. Galimybės ir jų santykis	359
6.1.3. Prognozavimas.....	360
6.1.4. Duomenys	361
6.1.5. Modelio tinkamumas	362
6.1.6. Modelio tyrimas ir tobulinimas.....	363
6.1.7. Pastabos apie ranginės regresijos taikymą.....	364
6.1.8. Standartiniai ranginės logistinės regresijos modelių aprašymai	364
6.2. Ranginė logistinė regresinė analizė su SPSS	365
6.2.1. Duomenys	365
6.2.2. SPSS parinktys ranginei logistinei regresijai.....	367
6.2.3. Rezultatai	368
6.2.4. Klasifikacinė lentelė	371
6.2.5. Rezultatų aprašymas	372
6.2.6. SPSS komandų sintaksė ranginei logistinei regresinei analizei.....	373
6.2.7. Ranginė logistinė regresija su kintamųjų sąveika.....	374
6.2.8. Ranginė regresija su kitomis jungties funkcijomis	375
6.3. Ranginė logistinė regresinė analizė su STATA	376
6.3.1. Duomenys	376
6.3.2. Modelio analizė.....	376
6.3.3. Prognozavimas.....	380
6.3.4. Klasifikacinė lentelė	382
6.4. Ranginė logistinė regresinė analizė su SAS	383
6.4.1. Duomenys	383
6.4.2. Modelio analizė.....	383
6.4.3. Klasifikacinė lentelė	387
6.4.4. Prognozavimas.....	389
6.4.5. Rezultatų aprašymas	390

6.4.6. SAS programos logistinės regresijos procedūra	390
6.5. Ranginė logistinė regresinė analizė su R.....	393
6.5.1. Duomenys	393
6.5.2. Modelio analizė.....	394
6.5.3. Prognozavimas.....	396
6.5.4. Klasifikacinė lentelė	397
6.5.5. R programos ranginės logistinės regresijos komandos.....	398
Uždaviniai	400
7. PUASONO REGRESINĖ ANALIZĖ	401
7.1. Puasono regresijos modelis	401
7.1.1. Modelio lygtis ir jos taikymas prognozuojant	401
7.1.2. Dažnio modelis	402
7.1.3. Duomenys	404
7.1.4. Modelio tinkamumas	404
7.1.5. Puasono regresinės analizės etapai	405
7.1.6. Modelio tobulinimas	406
7.1.7. Pastabos apie Puasono regresijos taikymą.....	407
7.1.8. Standartiniai Puasono regresijos modelio aprašymai	408
7.2. Puasono regresinė analizė su SPSS	408
7.2.1. Duomenys	408
7.2.2. Preliminari analizė	409
7.2.3. SPSS parinktys Puasono regresijos modeliui	412
7.2.4. Rezultatai	414
7.2.5. SPSS komandų sintaksė Puasono regresinei analizei	417
7.2.6. Kategorinis regresorius	418
7.2.7. Puasono regresinė analizė dažniui	419
7.3. Puasono regresinė analizė su STATA	419

7.3.1. Duomenys	419
7.3.2. Puasono modelio taikymas	421
7.3.3. Prognozavimas.....	423
7.3.4. Kategorinis regresorius	424
7.4. Puasono regresinė analizė su SAS	425
7.4.1. Duomenys	425
7.4.2. Puasono modelio taikymas	426
7.4.3. Prognozavimas.....	430
7.4.4. Kategorinis regresorius	430
7.4.5. SAS programos Puasono regresijos procedūra	432
7.5. Puasono regresinė analizė su R.....	436
7.5.1. Duomenys	436
7.5.2. Puasono modelio taikymas	438
7.5.3. Prognozavimas.....	440
7.5.4. Kategorinis regresorius	441
7.5.5. R programos Puasono regresijos komandos	442
Uždaviniai.....	444
8. NEIGIAMA BINOMINĖ REGRESIJA	445
8.1. Neigiamos binominės regresijos modelis	445
8.1.1. Modelio lygtis ir jos taikymas prognozuojant	445
8.1.2. Duomenys	446
8.1.3. Modelio tinkamumas	447
8.1.4. Neigiamos binominės regresinės analizės etapai.....	447
8.1.5. Modelio tobulinimas	448
8.1.6. Pastabos apie modelio taikymą.....	448
8.1.7. Standartiniai neigiamos binominės regresijos modelio aprašymai.....	449
8.2. Neigiama binominė regresinė analizė su SPSS.....	450

8.2.1. Duomenys	450
8.2.2. SPSS parinktys neigiamos binominės regresijos modeliui.....	451
8.2.3. Rezultatų aptarimas.....	452
8.2.4. Modelio tobulinimas	455
8.2.5. Rezultatų aprašymas	457
8.2.6. SPSS komandų sintaksė.....	457
8.2.7. Neigiama binominė regresinė analizė dažniui	458
8.2.8. Neigiamos binominės regresinės analizės standartinė opcija SPSS	458
8.3. Neigiama binominė regresinė analizė su STATA	459
8.3.1. Duomenys	459
8.3.2. Modelio parametrų analizė	460
8.4. Neigiama binominė regresinė analizė su SAS	463
8.4.1. Duomenys	463
8.4.2. Modelio parametrų analizė	464
8.4.3. Prognozavimas.....	466
8.4.4. SAS programos neigiamos binominės regresijos procedūra	469
8.5. Neigiama binominė regresinė analizė su R.....	472
8.5.1. Duomenys	472
8.5.2. Modelio parametrų analizė	473
8.5.3. Prognozavimas.....	476
8.5.4. R programos neigiamos binominės regresijos komandos.....	477
Uždaviniai.....	478
9. MODIFIKUOTI SKAIČIUOJAMIEJI MODELIAI	480
9.1. Perteklinių nulių Puasono regresijos modelis	480
9.1.1. Modelio paskirtis	480
9.1.2. Perteklinių nulių Puasono regresija su STATA	482
9.1.3. Perteklinių nulių Puasono regresija su SAS	484

9.1.4. Perteklinių nulių Puasono regresija su R	490
9.2. Perteklinių nulių neigiama binominė regresija	494
9.2.1. Modelio paskirtis	494
9.2.2. Perteklinių nulių neigiama binominė regresija su STATA.....	495
9.2.3. Perteklinių nulių neigiama binominė regresija su SAS	496
9.2.4. Perteklinių nulių neigiama binominė regresija su R.....	500
9.3. Skačiuojamų regresijos modelių palyginimas su STATA.....	502
9.4. Benulė Puasono regresija	506
9.4.1. Modelio paskirtis	506
9.4.2. Benulė Puasono regresija su STATA	507
9.4.3. Benulė Puasono regresija su SAS.....	508
9.4.4. Benulė Puasono regresija su R.....	518
Uždaviniai.....	524
10. PROBIT REGRESIJA.....	525
10.1. Probit regresijos modelis	525
10.1.1. Modelio lygtis	525
10.1.2. Reikalavimai duomenims	526
10.1.3. Modelio tinkamumas	527
10.1.4. Bendrosios <i>probit</i> regresinės analizės etapai	527
10.1.5. Modelio tobulinimas	528
10.1.6. Dozavimo modelis	529
10.1.7. Standartiniai <i>probit</i> regresijos modelių aprašymai	530
10.2. Probit regresinė analizė su SPSS.....	530
10.2.1. Duomenys	530
10.2.2. SPSS parinktys pradiniam regresijos modeliui.....	532
10.2.3. Rezultatai	534
10.2.4. Prognozavimas.....	537

10.2.5. Dozavimo modelio tyrimas.....	538
10.2.6. SPSS komandų sintaksė.....	542
10.3. <i>Probit</i> regresinė analizė su STATA	542
10.3.1. Duomenys	542
10.3.2. Modelio tyrimas	543
10.3.3. Reikšmių prognozavimas.....	546
10.4. <i>Probit</i> regresinė analizė su SAS	546
10.4.1. Duomenys	546
10.4.2. Modelio tyrimas	547
10.4.3. Reikšmių prognozavimas.....	551
10.5. <i>Probit</i> regresinė analizė su R.....	553
10.5.1. Duomenys	553
10.5.2. Modelio tyrimas	553
10.5.3. Reikšmių prognozavimas.....	557
10.5.4. R programos <i>probit</i> regresijos komanda.....	557
Uždaviniai.....	558
Literatūra	560

Pratarmė

Įsivaizduokime – nusipirko žmogus naują televizorių ir nori pareguliuoti spalvas ir garsą, o vietoje pultelio gauna atsuktuvą ir elektroninę televizoriaus schemą. Skaityk, analizuok ir daryk! O jei neišmanai fizikos, tai ir nagų nekišk! Vargu ar toks pirkėjas būtų laimingas. O štai dauguma statistikos vadovėlių yra kaip ta elektroninė schema – viskas juose matematiškai tikslu ir teisinga, bet spręsti praktines problemas nelabai padeda¹. Kokių klausimų dažniausiai kyla atliekant statistinę analizę? Tikrai ne apie įverčių gavimo metodo subtilybes ar Gauso–Markovo teoremos įrodymą. Dažniausias klausimas – ar šįkart gavau tinkamą modelį, ar (ir vėl) kažkokią nesąmonę? Išmintingos vadovėlinės tiesos – dviejų deviacijų skirtumas turi asimptotinę chi kvadrato skirstinį ir pan. – labiau ugdo priešišką statistikai nei padeda jį atsakyti.

Šio el. vadovėlio tikslas – padėti įgyti tinkamų **praktinių** regresinio modeliavimo ir analizės įgūdžių. Vadovėlių², kuriuose išdėstyta regresijos modelių teorija, šis el. vadovėlis tikrai nepakeis, bet uždavinius spręsti pagelbės. Sąmoningai vietoje tikslų ir gražių (bet bauginančių) matematinių formulų ir apibrėžimų pateikiami itin supaprastinti pagrindinių teorinių idėjų atpasakojimai.

El. vadovėlis yra skiriamas šiems regresijos modeliams ir jų apibendrinimams:

- **Tiesinė regresija.** Tiriama vieno intervalinio kintamojo priklausomybė nuo vieno ar kelių, nebūtinai intervalinių, kintamųjų. Priklausomybė užrašoma tiesiniu modeliu. Pavyzdžiui, tiriamė, kaip veikia kraujospūdis per dieną surūkytų cigarečių skaičius ir kūno masės indeksas.
- **Stabilizuotų liekamųjų paklaidų regresija.** Tiesinės regresijos alternatyva, kai liekamosios paklaidos nėra vienodai išsibarsčiusios (duomenys heteroskedastiški).
- **Atsparioji regresija.** Tiesinės regresijos alternatyva, kai yra labai išsiskiriančių stebinių (išskirčių).
- **Medianos regresija.** Tiesinės regresijos alternatyva. Modeliuojama intervalinio kintamojo medianos priklausomybė nuo vieno ar kelių, nebūtinai intervalinių, kintamųjų. Intervaliniai kintamieji nebūtinai normaliai pasiskirstę.
- **Netiesinė regresija.** Įvairios tiesinės regresijos alternatyvos, kai kintamųjų priklausomybės nėra tiesinės.

¹ Paprastai vadovėliuose aprašoma, kaip išspręsti uždavinius be programų („rankomis“). Regresijos modeliavimas „rankomis“ yra skirtas žmonėms, kurie ne tik patys myli darbą, bet ir darbas juos.

² Pavyzdžiui, vadovėlio V. Čekanavičius, G. Murauskas. Statistika ir jos taikymai II. TEV, 2002 (2004, 2008).

- **Dvinarė logistinė regresija.** Modeliuojama dvireikšmio kintamojo (priklausomo kintamojo) priklausomybė nuo vieno arba kelių kintamųjų (regresorių). Pavyzdžiui, tiriama, kokį poveikį politiko apsisprendimui kandidatuoti turi jo turtinė padėtis ir „politinis stažas“. Dvinarė logistinė regresija padeda įvertinti tikimybę susirgti diabetu, atsižvelgiant į kūno masės indeksą ir paveldimumo veiksnius.
- **Daugianarė logistinė regresija.** Tai dvinarės logistinės regresijos apibendrinimas, kai priklausomas kategorinis kintamasis gali įgyti daugiau nei dvi reikšmes. Pavyzdžiui, bandoma išsiaiškinti, kas turi įtakos, už kurią politinę partiją balsuos rinkėjas.
- **Ranginė logistinė regresija.** Modelis analogiškas daugianarei logistinei regresijai, tik priklausomas kintamasis yra ranginis. Pavyzdžiui, bandoma nustatyti, kaip požiūris į baigtas studijas (labai palankus – palankus – nepalankus) priklauso nuo gaunamo atlyginimo.
- **Puasono regresija.** Modeliuojama retų įvykių skaičiaus arba įvykių dažnio priklausomybė nuo vieno arba kelių kitų kintamųjų (regresorių). Prielaida – priklausomas kintamasis turi Puasono skirstinį. Pavyzdžiui, tiriama, ar vaikų skaičius šeimoje priklauso nuo tėvų išsilavinimo ir jų brolių / seserų skaičiaus.
- **Neigiama binominė regresija.** Modeliuojama įvykių skaičiaus arba įvykių dažnio priklausomybė nuo vieno arba kelių kitų kintamųjų (regresorių). Alternatyva Puasono regresijai (prielaida, kad priklausomas kintamasis turi neigiamą binominį skirstinį).
- **Perteklinių nulių modeliai.** Puasono regresijos modifikacijos, kai daug priklausomo kintamojo reikšmių yra nuliai. Pavyzdžiui, modeliuojamas respondento pavaldinių skaičius (pripažinkime, kad daugelis iš mūsų pavaldinių neturime ☺).
- **Probit regresija.** Dvireikšmės logistinės regresijos alternatyva. Klasikinis *probit* regresijos taikymas – dozavimo modelis. Pavyzdžiui, bandoma nustatyti, kiek reikia pesticidų, kad būtų išnaikinta 90 % kenkėjų.

Savo pobūdžiu šis el. vadovėlis yra „Gaminame patys. Receptai žaliems“. Skaitytojui apie statistiką pakanka turėti tik labai bendrą (ir miglotą) supratimą. Vis dėlto tikėtis, kad nieko apie statistiką nežinojau (tik girdėjau, kad žmonės ją taiko, rašydami disertacijas ir straipsnius), o štai dabar paskaitinėsiu knygelę ir tapsiu regresijos ekspertu, – nevertėtų. (Pavartysiu anatomijos vadovėlį ir – tik žybt – sėkmingai išpjausiu kaimynui apendiksą.) Ekspertu tampama praktikuojantis. Šis el. vadovėlis padės įgyti *pradinių* modeliavimo įgūdžių. Siekiama, kad tie įgūdžiai iš tikrųjų būtų praktiniai. Kaip atlikti analizę SPSS, STATA, SAS ir R programomis, aprašyta detalai. Sąmoningai vengta patarimų „pasidaryk pats“.



Pavyzdžiams tirti naudotos IBM SPSS 19, STATA 10 (su SPost priedu)³, SAS 9.3 ir R 3.0.1 programos. Dažniausiai naujesnėse programų versijose yra funkcinių papildymų, bet išsaugoma tiek vartotojo grafinė sąsaja, tiek galimybė vykdyti ankstesnėms versijoms pritaikytas programėles. Todėl neturėtų kilti kliūčių, tiriant regresijos modelius naujesnėmis programų versijomis. Analizei ir uždaviniams naudoti ESS4⁴ ir LiDA⁵ duomenų bazės duomenys. Į pavyzdžiuose gautus rezultatus nereikia žiūrėti kaip į labai rimtus mokslinius tyrimus. Nebandėme aiškinti, *kodėl* atsirado viena ar kita kintamųjų priklausomybė ir ar yra priežastinis ryšys. Tai būtų tyrėjų duona. O mūsų tikslas – kitas. Siekiame išmokyti tas priklausomybes *pastebėti*, kitaip tariant, išmokti statistinės tyrimo technikos. Maždaug – kaip taisyklingai kalti vinis, nenusimušant pirštų ir neišdaužant žiūrovų. O ką kalti – kėdę, stalą, kėdę prie stalo, – skaitytojo reikalas (kartais ir problema).

Regresijos modelių yra įvairiausių. Modelio parinkimas priklauso ir nuo duomenų prigimties. Šiame el. vadovėlyje nėra laikinių duomenų regresijos modelių. Be to, reiktų prisiminti, kad regresinė analizė – esamų priklausomybių tyrimas, todėl nereikia turėti iliuzijų, kad bet kokiems duomenims pavyks sudaryti tinkamą regresijos modelį. Net labai stengiantis nepavyks regresijos modeliu susieti Lietuvos BVP su kapibarų skaičiumi Argentinoje. Yra duomenų, kuriems jokie regresijos modeliai netinka.

Šio el. vadovėlio pagrindą sudaro pirmojo autoriaus parašytas projekto „Lietuvos HSM duomenų archyvo LiDA plėtra“ (SFMIS Nr. VP1-3.1-ŠMM-02-V-02-001) metodologinis paketas „Taikomoji regresinė analizė socialiniuose tyrimuose“, Kaunas, 2011. Tą pabrėžiant, antraštiniame lape pridėti atitinkami logotipai. Norime nuoširdžiai padėkoti prof. A. Krupavičiui, kuris buvo metodologinio paketo iniciatorius. Be jo nebūtų ir šio el. vadovėlio. Už pastabas, padėjusias pagerinti šį el. vadovėlį, nuoširdžiai dėkojame R. Rauleckui, M. Radavičiui, R. Eidukevičiui, D. Krapavickaitei.

Pabaigoje – labai svarbi žinia:

Tikrinant visas hipotezes, reikšmingumo lygmuo 0,05.

O ką tai reiškia, paaiškinta įvade.

³ Šį priedą, skirtą poregresinei analizei, primygtinai rekomenduoja patys STATA kūrėjai. SPost autoriai yra Scott Long ir Jeremy Freese iš Indianos universiteto, žr. http://www.indiana.edu/~jslsoc/web_spost/sp_install.htm

⁴ European Social Survey, <http://www.europeansocialsurvey.org/>

⁵ Lietuvos HSM duomenų archyvas (LiDA), <http://www.lidata.eu/>

1. ĮVADAS

Įvade labai trumpai priminsime pagrindines statistikos sąvokas, vartojamas kituose skyriuose.

Statistinės analizės (regresinė analizė viena iš jos dalių) tikslas – ištyrus dalį respondentų (imtį), padaryti išvadą apie visą populiaciją. Pavyzdžiui, tvirtindami, kad kraujospūdis priklauso nuo kūno masės indekso, šią išvadą padarome ištyrę ne visus (o kas tie visi?) gyventojus, o pasirinktos populiacijos (miesto, šalies ir kt.) dalį.

1.1. Kintamieji ir jų charakteristikos

1.1.1. Kintamųjų matavimo skalės

Norint, jog statistinis modelis tiktų duomenims, reikia, kad būtų tenkinami tam tikri formalūs reikalavimai. Aprašydami modelius, pabrėžiame juose naudojamų kintamųjų matavimo skales. Visų pirma kas apskritai yra tas kintamasis statistiniame tyrime? Požymis, kurį pasirinkę matavimo instrumentą matuojame, vadinamas kintamuoju. Pavyzdžiui, apklausų vykdytoji tai atsakymas į klausimyno klausimą.

Pagal matavimo skales visi kintamieji skirstytini į

- | |
|--|
| <ul style="list-style-type: none">a) nominaliuosius,b) ranginius,c) intervalinius⁶. |
|--|

Beje, šis šis skirstymas galioja ir duomenims. Pavyzdžiui, jei turime ranginį kintamąjį, tai jo reikšmių aibė (stebinių aibė) – ranginiai duomenys⁷.

Jeigu atsakant į klausimą galima rinktis tik iš kelių **lygiaverčių** galimybių, tai atitinkamas kintamasis yra *nominalusis*. Pavyzdžiui, tokie kintamieji yra rasė, tikyba, plaukų spalva. Jeigu kategorijos yra tik dvi (vyras – moteris, sutinku – nesutinku), sakysime, kad kintamasis yra *dvireikšmis* arba *dichotominis*. Jeigu atsakymai yra skaitiniai ir galima pasakyti, kiek kartų viena reikšmė didesnė už kitą, bei apskaičiuoti reikšmių vidurkį, tai tiriame *intervalinį* kintamąjį. Pavyzdžiui, ūgis, svoris, reakcijos laikas, kraujospūdis yra intervaliniai kintamieji. Dažniausiai

⁶ Griežtai kalbant, yra atskiros intervalų ir santykių skalės, bet abiejų skalių kintamiesiems taikomi tie patys statistiniai metodai. Todėl šiame vadovėlyje ir vienu, ir kitu atveju sakysime, kad tiriame intervalinį kintamąjį.

⁷ Reikėtų skirti sąvokas „kintamojo reikšmė (stebinys)“ ir „stebinys“ apskritai. Toliau knygoje stebinys – kintamųjų reikšmių rinkinys konkrečiam objektui. Pavyzdžiui, sociologiniame tyrime tai respondento atsakymų rinkinys.

socialinių tyrimų klausimynuose vartojami Likerto skalės kintamieji, kai atsakymą liepiama pasirinkti iš kelių variantų: 1 (labai nepritariu), ..., 5 (labai pritariu) ar pan. Tokie kintamieji vadinami *ranginiais*. Negalima pasakyti, kiek daug skiriasi rangai, bet galima konstatuoti, kuris didesnis. Pavyzdžiui, negalima pasakyti, kiek kartų atsakymas „labai pritariu“ didesnis už „labai nepritariu“ (neteigsime, kad „labai pritariu“ rodo 5 kartus didesnę pritarimą vien todėl, jog toks atsakymo kodas). Vis dėlto nesuklysime konstatavę, kad pasirinktas atsakymo kodas 4 rodo didesnę pritarimą nei kodas 2. Beje, labai dažnai *nominalieji* ir *ranginiai* kintamieji yra vadinami *kategoriniais*.

Praktinėje statistikoje atsiranda papildomų niuansų. Kai kurie ranginiai kintamieji konstruojami, siekiant padaryti juos kuo panašesnius į intervalinius kintamuosius. Taria, kad tokiems ranginiams kintamiesiems (atsargiai) galima taikyti intervalinės (santykinės) skalės operacijas.

Jeigu skirtingų ranginio kintamojo reikšmių yra gana daug, o jo vidurkis prasmingas, tai dažniausiai jis traktuojamas kaip intervalinis kintamasis.

Pavyzdžiui, egzamino pažymys iš tikrųjų yra *ranginis* kintamasis, nes negalima pasakyti, kad studentas, gavęs dešimtuką, žino *tiksliai* dukart daugiau už gavusį penketuką ir *tiksliai* trisdešimčia procentų daugiau už gavusį septintuką. Vis dėlto visuose tyrimuose egzamino pažymys traktuojamas kaip intervalinis kintamasis.

Nėra visuotinai sutarta, ką reiškia „skirtingų kintamojo reikšmių yra gana daug“. Socialiniuose tyrimuose dažnai tariama, kad tam pakanka septynių rangų Likerto skalės. Iš didelės bėdos kartais kaip intervalinius tenka naudoti ir penkiarangius kintamuosius. Jeigu ranginis kintamasis gali įgyti mažai reikšmių, jo analizei taikomi tokie patys metodai kaip ir tiriant nominaliuosius kintamuosius.

Jeigu kintamasis yra ranginis, bet turi mažai skirtingų atsakymo variantų (mažiau kaip 5), dažniausiai lieka jį tirti kaip nominalųjį kintamąjį.

Pavyzdžiui, kintamasis *savijauta*, įgyjantis tik tris reikšmes (1 – nors nusišauk, 2 – nebloga, 3 – skraidau) visuose statistiniuose modeliuose traktuotinas kaip nominalusis kintamasis.


1.1.2. Svarbiausios kintamųjų skaitinės charakteristikos

Statistiniuose tyrimuose naudojamos tiriamus kintamuosius apibūdinančios skaitinės charakteristikos. Aptarsime penkias tokias charakteristikas: vidurkį, dispersiją (ir jos ekvivalentą – standartinį nuokrypį), koreliaciją ir medianą.


Vidurkis yra vidutinė kintamojo reikšmė. Toks maždaug komunistinis pasidalijimo principas – kas būtų, jeigu visi savo turimus matavimus (pinigus, pragyventus metus, egzamino pažymius) sumestų į bendrą katilą ir draugiškai pasidalytų po lygiai. Formaliai – visų stebinių suma, padalyta iš stebinių skaičiaus. Vidurkis – populiariausia skaitinė charakteristika statistikoje. Vis dėlto, kai duomenys turi labai išsiskiriančių reikšmių, jis nėra itin informatyvus. Jeigu B. Geitsas savo gyvenamąją vietą deklaruos Adutiškį, kiekvieno adutiškio vidutinis turtas viršys milijoną dolerių, nors realiai jie nepraturtės.

Dispersija – statistikoje naudojama skaitinė kintamojo reikšmių išsibarstymo charakteristika. Didelė dispersija reiškia, kad reikšmės labai skiriasi. Dispersija aktuali, kai norima iš imties spręsti apie visą populiaciją. Natūralu, kad patikimoms išvadoms apie populiacijas, kurių respondentai labai skiriasi, reikia didesnės imties. Jeigu išmatavę dešimties vyrų ūgį radome ir 1,5 m, ir 2,5 m, ir 1,79 m ir dar kitokių pačių įvairiausių ūgių, tai tikrai padaryta išvada apie vidutinį to regiono vyrų ūgį bus mažiau patikima nei tuo atveju, kai visi respondentai yra 1,60 m. Todėl, darant statistines išvadas, į dispersiją atsižvelgiama. Dažnai vietoje dispersijos naudojamas *standartinis nuokrypis*. Standartinis nuokrypis – tai kvadratinė šaknis, ištraukta iš dispersijos. Pagal informatyvumą abu rodikliai lygiaverčiai. Tradiciškai aprašomojoje statistikoje pateikiami standartiniai nuokrypiai, o statistinėse išvadose labiau naudojama dispersija.

Koreliacija (tiesinės koreliacijos koeficientas) yra kintamųjų tiesinės priklausomybės matas. Jis, kaip ir vidurkis ar dispersija, turi savo teorinį atitikmenį tikimybių teorijoje. Statistikoje koreliacija naudojama, kai reikia išmatuoti dviejų *intervalinių* kintamųjų tiesinę priklausomybę. Koreliacijos koeficientas nematuoja netiesinės priklausomybės.



Tiesinė priklausomybė



Netiesinė priklausomybė

Koreliacijos koeficientas gali įgyti reikšmes nuo -1 iki 1. Kuo koreliacijos koeficientas absoliučiu didumu didesnis (toliau nuo nulio), tuo priklausomybė stipresnė. Pažymėkime imties duomenims apskaičiuotą koreliaciją raide r . Sprendžiant apie koreliacijos stiprumą „iš akies“, dažniausiai laikomasi tokio vertinimo:


- $|r| < 0,3$ labai silpna koreliacija
- $0,3 \leq |r| < 0,5$ silpna koreliacija
- $0,5 \leq |r| < 0,7$ vidutinė koreliacija
- $0,7 \leq |r| < 0,9$ stipri koreliacija
- $0,9 \leq |r| \leq 1$ labai stipri koreliacija

Koreliacijos koeficiento ženklas taip pat informatyvus. Jeigu X ir Y koreliacija teigiama, didesnės X reikšmės atitinka didesnės Y reikšmės. Jeigu neigiama – didesnės X reikšmės atitinka mažesnės Y reikšmės. Pavyzdžiui, jeigu didėjant darbo stažui atlyginimas taip pat didės, tai darbo stažo ir atlyginimo koreliacija bus teigiama. Galima visiškai skirtingos prigimties kintamųjų koreliacija: laiko ir pažymių, amžiaus ir atlyginimo, IQ ir TV žiūrėjimo ir pan.


Koreliacija nepaaiškina priežastingumo

Koreliacija atsako į klausimą – ar yra tiesinis kintamųjų ryšys, bet nepaaiškina, *kodėl* tas ryšys atsirado. Priežastingumui paaiškinti reikia remtis giliomis tiriamo dalyko žiniomis ir vaizduote. Stipri chemijos ir fizikos pažymių koreliacija rodo, kad mokiniai, geriau mokantys chemiją, geriau ir išmoksta fiziką. Bet tai nereiškia, jog fiziką išmoksta *todėl*, kad geriau moka chemiją.

Tarkime, kad įvertinome išlaidų duonkepių reklamai ir gautų pajamų koreliaciją. Gavome $r = 0,999$. Koreliacija teigiama ir labai stipri. Daugiau išleidžiama pinigų reklamai – didesnės ir pajamos. Atrodytų, reklama labai naudinga duonkepių pardavėjams. Vis dėlto tokia išvada gali būti net labai klaidinga! Iš tikrųjų, didėjant išlaidoms reklamai, didės ir gaunamos *pajamos*, bet tai nereiškia, kad didės ir *pelnas* = *pajamos* – *išlaidos*. Jeigu išleidome daugiau nei uždirbome, patirsime nuostolių. Pažvelkime į du galimus priklausomybės grafikus.



a) Valio! Pelnas didėja



b) Vaje! Pelnas mažėja


Abiejuose grafikuose išlaidų reklamai (x ašis) ir gautų pajamų (y ašis) priklausomybę pavaizdavome ištisine tiese, nes koreliacija beveik 1. Matome, kad a) atveju kiekvienas reklamai papildomai išleistas litas duos keliolika litų papildomų pajamų ir pelnas didės. O iš b) grafiko matyti, kad kiekvienas reklamai papildomai išleistas litas duos tik kelis centus papildomų pajamų ir pelnas mažės (išleidžiame daugiau nei uždirbame). Dar kartą reikia pabrėžti, kad abiem atvejais koreliacija yra tokia pati – stipri ir teigiama. Šis pavyzdys rodo, kad tyrimuose vien koreliacijos gali ir nepakakti. Aptartu atveju visus reikiamus atsakymus (įskaitant ir tai, kiek padidės pajamos, padidėjus išlaidoms reklamai vienu litu) padėtų gauti tiesinės regresijos modelis.

Mediana – vidurinė pagal didumą iš visų galimų kiekybinio kintamojo reikšmių. Jeigu visas reikšmes išrikiuosime nuo mažiausios iki didžiausios, tai mediana bus tos eilutės viduryje esanti reikšmė (kai imtis lyginė – dviejų vidurinių reikšmių vidurkis). Mediana nėra nei tokia informatyvi, nei turi tokias geras matematines savybes kaip vidurkis. Statistiniuose tyrimuose ji naudojama tada, kai duomenyse gali būti išskirčių. Mediana nepasikeis, jeigu vienas stebinis staiga taps milžiniškas. Jeigu turtingiausią Adutiškio gyventoją pakeisime B. Geitsu, tai adutiškiečių turto mediana nepasikeis. Jeigu jau galima kalbėti apie vidurinę pagal didumą reikšmę, tai galima ir apie dešimtąją pagal didumą ir pan. Atitinkamos charakteristikos vadinamos *kvantiliais*.


1.1.3. Normalieji kintamieji

Visoje statistikoje dažnai aptinkamas terminas – normalusis kintamasis. Rašydami, kad vienas ar kitas kintamasis yra normalusis, teigiame, kad jo **visų** reikšmių skirstinys yra normalusis (kintamasis pasiskirstęs pagal Gauso dėsnį). Tai yra prielaida (prisiminkime, kad analizuojame imties duomenis!). Tikslus **teorinio** normaliojo kintamojo elgesys aprašomas gana įmantria formule, kurios čia nepateiksime. Jo įgyjamos reikšmės labiau sukoncentruotos apie vidurkį. Tokio kintamojo stebinių histograma (grupuotų duomenų dažnių grafikas) primena varpą. Jeigu normaliojo kintamojo dispersija didelė, tai tas varpas priplotas iš viršaus, jeigu maža – suplotas iš

šonų. Pateikiame dvi kompiuteriu generuotas normaliųjų kintamųjų histogramas: a) kai vidurkis yra 1, o dispersija yra 2; b) kai vidurkis yra 1, o dispersija yra 0,5. Ištinės linijos rodo, kokie grafikai turėtų būti teoriškai.



Histogramos lyginimas su atitinkama normaliaja kreive nėra patogus būdas normalumui tikrinti. Tiriamo kintamojo normalumui nustatyti dažniau naudojami P–P⁸ ir Q–Q⁹ grafikai. P–P grafikas – tai tiriamo kintamojo dažnių pasiskirstymo funkcijos $F(x)$ ir normaliojo skirstinio funkcijos $\Phi(x)$ reikšmių porų $(F(x), \Phi(x))$ grafikas. Q–Q grafikas – tiriamo kintamojo ir normaliojo kintamojo kvantilių reikšmių porų grafikas. Abudu grafikai „iš akies“ vertinami analogiškai: kuo taškai arčiau tiesės, tuo tiriamas kintamasis normalesnis.



Daugelis klasikinių statistinių išvadų yra gauta esant prielaidai, kad nagrinėjami normalieji kintamieji. O realiuose tyrimuose kintamieji retai kada tokie būna (geriausiu atveju – beveik normalieji). Faktiškai statistikos taikymai primena situaciją su suknele, pasiūta manekenei.

⁸ Angl. *P–P plot*.

⁹ Angl. *Q–Q plot*.

Manekenei (ideali figūra; ūgis 190 cm) tinka kaip nulieta. O kai suknelę bandoma užtempti paprastai pirkėjai (kartais 30 cm žemesnei, kartais 30 kg sunkesnei), rezultatai būna įvairūs. Kartais labai geri, kartais pakenčiami, kartais nepakenčiami. Taip ir su statistikos taikymais. Jeigu duomenys beveik normalūs – viskas beveik puiku. Jeigu visiškai nenormalūs – visiška tragedija. Jeigu normalumas modeliams labai svarbus, tai jį reikėtų įvertinti bent „iš akies“.



1.2. Statistinės išvados

Įvado pradžioje rašėme, kad visų statistinių išvadų tikslas – ištyrus dalį respondentų (imtį), padaryti išvadą apie visą populiaciją. Akivaizdu, kad, darant tokius apibendrinimus, galima ir suklysti. Statistikos taikymas neapsaugo nuo klaidų, bet užtikrina, kad jų bus daroma nedažnai.

1.2.1. Parametrų įverčiai ir jų pasikliautiniai intervalai

Regresinė analizė – sudaryto statistinio kintamųjų priklausomybių modelio tyrimas. Dažniausiai informacijos apie modelio parametrus (visokius jame esančius daugiklius, naudojamų kintamųjų vidurkius, dispersijas ir kt.) neturima. Norint juos įvertinti, naudojamos imties duomenimis. Taip gautos apytikslės nežinomų parametrų reikšmės vadinamos parametrų įverčiais (beje, įverčių skaičiavimų formulės yra vadinamos įvertiniais). Yra įvairių parametrų įverčių radimo metodų. Visi jie sudėtingi ir skambiai vadinami – didžiausio tikėtinumo¹⁰ metodas, mažiausiųjų kvadratų¹¹ metodas ir pan. Parametrų įverčių radimą patikėsime statistinėms programoms.

Ir populiacijai, ir imčiai aprašyti vartojami tie patys terminai – vidurkis, dispersija, mediana. Kalbėdami apie kintamųjų charakteristikas, turime omenyje populiaciją. Pavyzdžiui, vidutinis lietuvių per metus perskaitytų knygų skaičius – populiacijos charakteristika (parametras). Atitinkama imties charakteristikos reikšmė yra to parametro įvertis. Pavyzdžiui, apklaustųjų 100 lietuvių vidutinis per metus perskaitytų knygų skaičius. Formaliai reikėtų rašyti – *populiacijos*

¹⁰ Angl. *maximum likelihood*.

¹¹ Angl. *ordinal least square*.

vidurkis, *imties* vidurkis ir pan. Dažnai apsiribojama terminu „vidurkis”, nes iš konteksto lengva suvokti, apie koki kalbama vidurkį.

Kartais norima tikslesnės informacijos apie parametą – jo galimų reikšmių intervalo. Informatyviau išgirsti, kad „šešėlinių“ pajamų vidurkis yra tarp 300 ir 500 litų per mėnesį, o ne vien kad jis apytiksliai yra 400 litų. Tokią patikslintą informaciją suteikia parametro pasikliautinis intervalas. Kadangi, stebint imtį, suteikti šimtaprocentės garantijos apie parametro reikšmę neišsina (imties atsitiktinumas gali pakišti koją), tai praktikoje naudojami 95 % pasikliautiniai intervalai. Tie 95 % reiškia, kad intervalo sudarymo *taisyklė* yra gera – 95 % jos taikymų baigiasi tuo, kad tikrieji parametrai patenka į sudarytus intervalus. Ar konkrečiai imčiai sudarytame intervale bus spėjamas parametras, nežinome, bet intervalų konstravimo metodas apskritai yra neblogas. Čia panašiai kaip skiriant vaistą pacientui pasakyti: 95 % ligonių jis padėjo. Ar konkrečiam ligoniui padės, neaišku, bet apskritai vaistas geras.

1.2.2. Statistinė hipotezė

Kartais užtenka nedidelės imties, kad būtų galima padaryti išvadą apie visą populiaciją. Pavyzdžiui, virėjas paragauja sriubos ir nusprendžia – trūksta druskos. Visi šia išvada noriai patiki ir niekas nereikalauja išsėbėti viso katilo. Kartais neįtikina net nemaža imtis. TV žvaigždė paskelbia – visi vyrai tokie! (Ir paaiškina kokie...) Nesinori patikėti, kad taip jau ir visi. Gal vertėtų palaukti, kol tas vyrų tyrimas bus pratęstas. Atkreipsime dėmesį, kad darant bet kokią išvadą apie populiaciją pagal jos dalį (imtį), visada lieka galimybė apsirikti (sriuboje gali būti nugrimzdęs dar neištirpęs druskos gabalas, kitas vyras bus ne toks). Todėl teks susitaikyti su neišvengiama tiesa – jokia statistinė išvada nėra šimtaprocentė. Blieka pasistengti, kad klaidingos išvados tikimybė būtų nedidelė. Bendrais bruožais visas dvipuses parametrines statistines hipotezes galima įsivaizduoti kaip du teiginius:

H_0 : parametras (parametrų skirtumas) yra lygus nuliui, H_1 : parametras (parametrų skirtumas) nelygus nuliui.
--

Dažniausiai tyrėjo tikslas – patvirtinti H_1 , todėl vadinamuoju **reikšmingumo lygmeniu** iš anksto nusistatoma, koks turėtų būti tokio sprendimo patikimumas. Tiksliau kalbant, reikšmingumo lygmuo – teorinis, iš anksto nusistatytas leistinų *apsirikimų* procentas, priimant H_1 . Visuotinai

naudojamas 0,05 reikšmingumo lygmuo. Jeigu skelbsime, kad kažkokie parametrai skiriasi, tai klaidų bus ne daugiau kaip 5 % (garantuosime sprendimo teisingumą bent 95 %).

Reikšmingumo lygmuo – iš anksto pasirenkamas leistinų neteisingų sprendimų procentas (teorinis dydis, rodantis, kas įvyktų, vykdant daugkartinius kartotinius analogiškus tyrimus). Praktiniuose skaičiavimuose atsižvelgiama į *p reikšmes*. Tarkime, kad parametrų skirtumą parodo didelė kriterijaus statistikos reikšmė. Taikydami statistinį kriterijų konkrečioms duomenims, gavome kažkokią statistikos reikšmę. Reikia nuspręsti, ar ji pakankamai didelė, kad būtų galima tikėti parametrų skirtumu. *P* reikšmė yra tikimybė, kad atliekant naują pakartotinį analogišką tyrimą, tariant, kad parametrai nesiskiria, būtų gauta didesnė statistikos reikšmė. Kitaip tariant, *p* reikšmė parodo, kiek tikėtina suklysti darant išvadą, kad parametrai skiriasi (atmetant nulinę hipotezę). Skamba panašiai kaip ir reikšmingumo lygmuo. Esminis skirtumas tas, kad reikšmingumo lygmuo – teorinis iš anksto nusistatytas nekintamas etalonas, o *p* reikšmė – tai, ką pavyko gauti konkrečiu atveju. Ji kiekvienai imčiai vis kita. Sprendimas priimamas *p* reikšmę lyginant su etalonu – reikšmingumo lygmeniu. Jeigu *p* reikšmė mažesnė už 0,05, nulinė hipotezė atmetama. Tada daroma išvada apie kažkokius statistiškai reikšmingus skirtumus (kokius, priklauso nuo tikrinamos hipotezės).

Jeigu $p < 0,05$, H_1 priimame.

Jeigu $p \geq 0,05$, H_1 atmetame.

Dažniausiai *p* reikšmės mažėja, imčiai didėjant. Tai visai logiška – kuo daugiau duomenų, tuo patikimesnės išvados. Kita vertus, tai reiškia, kad nederą pasitikėti vien *p* reikšmėmis. Labai didelėms imtims galima gauti visiškai tyrimui neįdomius, bet statistiškai reikšmingus skirtumus. Pavyzdžiui, nustatyti, kad statistiškai reikšmingai varanopsai miega visa minute ilgiau nei varanopsės (atitinkamai – septynias valandas trisdešimt tris minutes ir septynias valandas trisdešimt dvi minutes). Ir, matyt, būtent tą minutę sapnuoja vyriškai šovinistinius sapnus.



Populiariausia šio konspekto frazė susijusi su statistinėmis hipotezėmis – parametras statistiškai reikšmingas. Išvertus į šnekamąją kalbą, tai reiškia, kad labai tikėtina (95 % garantija), jog jis nelygus nuliui. Norisi pabrėžti, kad frazė – parametras nėra statistiškai reikšmingas – dar

nereiškia spėjimo, jog jis nulis. Tiesiog negalime duoti 95 % garantijos, kad nelygus nuliui (nors galbūt galime duoti 90 % garantiją). Mes reiklūs sau, ir mažesnė nei 95 % garantija mūsų netenkina.

Parametras statistiškai reikšmingas = yra bent 95 % garantija, kad jis nelygus 0.

Parametras statistiškai nereikšmingas = garantija, kad nelygus 0, yra mažesnė už 95 % .

Visos imties duomenų funkcijos vadinamos statistikomis (kaip ir pati disciplina, tokia jau nemaloni sutaptis). Jos turi pačius įvairiausius pavadinimus. Pavyzdžiui, chi kvadrato statistika, Voldo statistika, Fišerio statistika. Dažnai modelio gerą tikimą duomenims parodo tai, kad atitinkama statistika yra statistiškai reikšminga (daug skiriasi nuo nulio). Tuo atveju atitinkama p reikšmė yra mažesnė už pasirinktąjį reikšmingumo lygmenį 0,05. Šis faktas būtinai paminimas, aprašant išvadas.

1.2.3. Pastabos apie vartojamus terminus

Šiek tiek pastabų apie el. vdovėlyje vartojamus statistikos terminus. Tokie terminai, kaip antai *regresija*, *p reikšmė*, *pasikliautinis intervalas*, *heteroskedastiškumas* – yra tradiciniai ir plačiai vartojami. Kiti – *kaupiamoji žingsninė regresija*, *atsparioji regresija*, *betos pokyčio statistika* *DFBeta* – kur kas mažiau paplitę. Nesiimame teigti, kad jie labiausiai vykę ir vieninteliai teisingi. Tikimės, kad prireikus skaitytojas sugebės juos aprašymuose pakeisti į tuos, kurie nusistovės lietuviškoje terminijoje. Beje, terminas *regresiniai* (regresijos) modeliai yra istorinis ir neturi jokios neigiamos prasmės.

Mums nereikia regresinio Lietuvos modelio!
Mums reikia progresinio modelio!




2. TIESINĖ REGRESINĖ ANALIZĖ

Tipinės situacijos, kai gali būti taikoma regresinė analizė, yra šios:

- Tiriame nusikaltimų skaičiaus priklausomybę nuo gyventojų tankumo ir regiono urbanizuotumo masto.
- Aiškinamės, ar, atsižvelgdami į šalies ekonomikos būklę, partijos lyderio charizmatiškumą ir partijos priklausymą opozicijai, galime prognozuoti, kokį procentą rinkėjų balsų gaus konkreti partija per Seimo rinkimus.
- Nagrinėjame, ar per egzaminą surinktų balų skaičius priklauso nuo socialinio statuso.

Visais atvejais manome, kad intervalinis kintamasis priklauso nuo vieno ar kelių kitų kintamųjų. Modelio schema:



Kintamasis Y vadinamas *priklausomu* kintamuoju, kintamieji X , Z , W vadinami *aiškinamaisiais* kintamaisiais arba *regresoriais*¹². Visos spėjamos priklausomybės yra tiesinės.

2.1. Tiesinės regresijos modelis

2.1.1. Modelio lygtis

Matematinis formalus regresijos modelio užrašas yra toks:

$$Y = C + b_1 X + b_2 Z + b_3 W + e.$$

Čia e žymi liekamąją paklaidą, t. y. viską, nuo ko dar gali priklausyti Y . Nei konstanta C , nei koeficientai b_1 , b_2 , b_3 nei liekamoji paklaida nėra žinomi. Įverčiai $\hat{C}$, $\hat{b}_1$, $\hat{b}_2$, $\hat{b}_3$ gaunami panaudojus imties duomenis. Gaunama regresijos lygtis apytikslei Y reikšmei:

$$\hat{Y} = \hat{C} + \hat{b}_1 X + \hat{b}_2 Z + \hat{b}_3 W.$$

Ši lygtis naudojama kokybinei ir kiekybinei kintamųjų priklausomybių analizei.

Kokias išvadas galima padaryti iš šios lygties, jei ji tinkama (žr. 2.1.4 „Modelio tinkamumas“).

Koeficientų ženklai nurodo, ar regresoriams didėjant $\hat{Y}$ didės, ar mažės.

¹² Paprastumo dėlei šio skyrelio aprašymuose naudojame tris regresorius.

Jeigu $\hat{b}_1 > 0$, tai X didėjant, $\hat{Y}$ didėja.

Jeigu $\hat{b}_1 < 0$, tai X didėjant, $\hat{Y}$ mažėja.

Ką tas didėjimas / mažėjimas reiškia, priklauso nuo kintamųjų prasmės ir kodavimo. Beje, jeigu koeficientų $\hat{b}_i$ ženklai yra ne tokie kaip tikėjomės sudarydami modelį, labai tikėtina, kad susidūrėme su kintamųjų multikolinearumu. Ši problema aptariama kituose skyreliuose.

Koeficientas $\hat{b}_1$ parodo, kiek pasikeis $\hat{Y}$ reikšmė, vienu vienetu padidėjus X ir fiksuojant visų kitų regresorių reikšmes.

Pavyzdys. Tarkime, kad gavome tokį regresijos modelį

$$\text{Egzamino balas} = 70 + 1,1 \times h \text{ su repetitoriumi} - 2 \times h \text{ socialiniame tinklalapyje}.$$

Daugiklis 1,1 prie regresoriaus h su repetitoriumi rodo, kad kiekviena papildomai su repetitoriumi praleista valanda padidina tikėtiną egzamino rezultatą vidutiniškai 1,1 balo. Analogiškai kiekviena valanda, sugaišta skaitinėjan socialinį tinklalapį / rašinėjan į jį, sumažina egzamino rezultatus vidutiniškai 2 balais.

Be modelio koeficientų, dažnai skaičiuojami *standartizuotieji beta koeficientai*. Jie atsiranda regresijos modelį taikant regresorių standartizuotoms z reikšmėms. Faktiškai tai reiškia, kad suvienodiname regresorių matavimo skales, ir nebesvarbu, kad vieną kintamąjį matuojame tonomis, o kitą centimetrais. Šie koeficientai reikalingi, norint palyginti regresorių santykinę įtaką priklausomam kintamajam.

Kuo absoliučiu didumu standartizuotasis beta koeficientas didesnis, tuo atitinkamo regresorius įtaka modelyje didesnė.

Pavyzdžiui, jeigu regresoriaus X standartizuotasis beta koeficientas yra -0,8, tai jis modelyje daug įtakingesnis nei regresorius Z , kurio standartizuotasis beta koeficientas yra 0,3. Beta koeficientas neinterpretuojamas, jeigu modelyje yra tik vienas regresorius.

2.1.2. Prognozavimas

Prognozuojant pasirinktos konkrečios regresorių reikšmės tiesiog įstatomos į gautąją regresijos lygtį:

$$\hat{Y} = \hat{C} + \hat{b}_1 X + \hat{b}_2 Z + \hat{b}_3 W.$$

Pavyzdys. Tarkime, kad, atlikę regresinę analizę, gavome tokį modelį

$$\hat{Y} = 7 - 1,3X + 2Z + 3W.$$

Kokią Y reikšmę prognozuosime, kai $X = 10$, $Z = 0$, $W = 1$? Prognozuosime $Y = 7 - 13 + 0 + 3 = -3$.

Vis dėlto reikia nepamiršti, kad prognozės daromos tik toms X , Z , W reikšmėms, kurios nedaug skiriasi nuo turimų imties reikšmių. Neturėtume pasitikėti regresijos modeliu, prognozuodami automobilio stabdymo kelią esant 300 km/val. greičiui, jei turime tik „įprastų“ bandymų rezultatus.

2.1.3. Reikalavimai duomenims ir modelio prielaidos

Visi duomenys turi būti skaitiniai. Nominaliųjų kintamųjų reikšmės koduojamos skaičiais. Be to:


- Priklausomas kintamasis Y ir visi regresoriai (išskyrus dvireikšmius) yra intervaliniai. Liekamosios paklaidos yra normaliai pasiskirsčiusios. Klasikiniame modelyje tai ekvivalentu reikalavimui, kad Y būtų normalusis kintamasis.
- Klasikiniame modelyje tariama, kad regresoriai matuojami be paklaidų ir yra neatsitiktiniai. Šis reikalavimas dažniausiai nėra logiškas, todėl visuotinai įprasta regresorius taip pat laikyti atsitiktiniais dydžiais. Regresoriai tuo geriau tinka modeliui, kuo jie panašesni į normaliuosius atsitiktinius dydžius. Faktiškai tai reikalavimas, kad visų kintamųjų histogramos būtų „varpo formos“. Dažnai, siekiant didesnio kintamųjų panašumo į normaliuosius, kintamieji transformuojami. Pavyzdžiui, ekonominiuose regresijos modeliuose itin dažnai naudojama logaritminė transformacija, t. y. surandami kintamųjų logaritmai, ir regresijos modelis sudaromas šiems logaritmams. Pradinis modelis $Darbo\ užmokestis = C + b_1BVP + e$ gali būti keičiamas modeliu $\log(Darbo\ užmokestis) = C + b_1\log(BVP) + e$. Regresorių normalumo nereikia suabsoliutinti. Regresijos modeliai priimtini (gali būti naudingi) ir regresoriams šiek tiek skiriantis nuo normaliųjų kintamųjų.
- Kartais į modelį įtraukiami ir kategoriniai kintamieji, vadinami *pseudokintamieji*. Visi jie turi būti perkoduoti taip, kad įgytų tik dvi reikšmes – 0 ir 1. Pavyzdžiui, galima į modelį įtraukti pseudokintamąjį lytis (1 – vyr., 0 – mot.). Bendrojoje regresijos modelio lygtyje įstatę vietoje lyties reikšmę 1, gausime regresijos modelio lygtį vyrams. Įstatę 0, gausime regresijos modelio lygtį moterims. Pseudokintamieji naudojami tada, kai manome, kad modeliai skiriasi tik laisvuju nariu. Turint pakankamai daug stebinių, racionaliau vyrams ir moterims sudaryti atskirus regresijos modelius. Jeigu kategorinis kintamasis įgyja tris reikšmes (pvz., lietuviai, latviai, estai), tai įvedami du pseudokintamieji – P_1 ir P_2 (lietuviams

$P_1 = 0, P_2 = 0$, latviams $P_1 = 0, P_2 = 1$, o estams $P_1 = 1, P_2 = 0$). Kodavimo sistema tokia: vieną kategoriją atitinka visi nuliai, kiekvieną kitą kategoriją atitinka *vienas* vienetas ir likę nuliai. Paprastai regresijos modeliai, kai visi regresoriai yra pseudokintamieji, nenagrinėjami.

- d) Skirtingų stebinių liekamosios paklaidos e neturi koreliuoti. Tai reiškia, kad stebiniai nesusiję. Dažniausiai tai labai natūralus reikalavimas¹³ – nemanome, kad Petro IQ priklauso nuo Jono IQ, arba kad pirmojo respondento ištikimybė Europos Sąjungai kažkaip paveikia kitų respondentų požiūrį.
- e) Regresoriai neturi būti stipriai koreliuoti. Priešingu atveju iškyla vadinamoji multikolinearumo problema. Tada modelis tampa nestabilus, t. y. keli papildomi stebiniai gali radikaliai pakeisti vertinamų koeficientų $\hat{C}, \hat{b}_1, \hat{b}_2, \hat{b}_3$ reikšmes. Sudarius regresijos modelį 100 stebinių, natūralu tikėtis, kad vienas papildomas stebinys radikaliai modelio nepakeis. Kita problema, kuri gali kilti dėl regresorių multikolinearumo, yra nelogiški jų ryšiai modelyje. Visada reikia pasitikrinti, ar modelio priklausomybės atitinka teorines priklausomybes (tam reikia gerai išmanyti tiriamąją sritį). Dažniausiai norima, kad modelio koeficientas prie regresoriaus X turėtų tą patį ženklą kaip ir X ir Y koreliacija. Pavyzdžiui, kai X ir Y koreliacija yra teigiama (t. y. X didėjant, didėja ir Y), tikimės, kad tą rodys ir regresijos modelis. Kai svarbiausias modelio tikslas – prognozavimas, kai kurie statistikai siūlo ignoruoti nedidelį multikolinearumą.
- f) Duomenyse neturi būti išskirčių. Išskirtis – tokia Y, X, Z arba W reikšmė, kuri labai skiriasi nuo kitų stebinių. Modelis, sudarytas duomenims su išskirtimis nėra patikimas.
- g) Duomenys turi būti homoskedastiški. Reikalaujama, kad liekamosios paklaidos dispersija nepriklausytų nuo regresorių reikšmių. Jeigu taip nėra, tariama, kad kilo *heteroskedastiškumo* problema. Beveik heteroskedastiškumas pasireiškia tuo, kad esant vienoms regresorių reikšmėms priklausomas kintamasis Y įgyja labai skirtingas reikšmes, o kitoms – ne. Nubraižykime Y priklausomybės nuo kiekvieno regresoriaus grafikus¹⁴ ir pažiūrėkime, ar gauti Y reikšmių išsibarstymo „debesėliai“ yra daugmaž vienodo storio visoms X reikšmėms. Jeigu taip, – duomenys homoskedastiški (*a*) pav.). Jeigu ne, – heteroskedastiški (*b*) pav.). Modelis, sudarytas labai heteroskedastiškiems duomenims, nėra patikimas.

¹³ Laikiniai duomenys, kuriems liekamosios paklaidos dažnai koreliuoja, šiame el. vadovėlyje nenagrinėjami.

¹⁴ Angl. *scatter plot*.



2.1.4. Modelio tinkamumas

Net jei duomenys tinkami regresinei analizei, tai nereiškia, kad pavyks sudaryti tinkamą modelį. Regresijos modelio tinkamumą rodo tokie rodikliai:

- a) *Determinacijos koeficientas (R kvadratas)*. Tai svarbiausia tiesinės regresijos modelio tikimo duomenims charakteristika, kuri privaloma visuose aprašymuose. Determinacijos koeficientas – modeliujamų ir stebimų priklausomo kintamojo reikšmių skirtumų matas. Labai apytikslė R^2 interpretacija, padedanti geriau suvokti jo prasmę, yra tokia – kiek procentų Y elgesio paaiškina kintamųjų X , Z , W elgesys. Determinacijos koeficientas įgyja reikšmes iš intervalo $[0, 1]$. Kuo koeficiento reikšmė didesnė, tuo modelis geriau tinka duomenims. Blogai, kai $R^2 < 0,20$. Apskritai nėra ko labai džiaugtis ir tada, kai $R^2 = 0,25$ (modelis tinka tik iš bėdos). O štai, jei $R^2 = 0,89$, tai modelis gana tiksliai aprašo duomenis. Tiesa, didelė R^2 reikšmė dar neužtikrina, kad visi regresoriai jame būtini, o modelis yra prasmingas.
- b) *Koreguotas determinacijos koeficientas*¹⁵. Tai determinacijos koeficiento alternatyva, kai modelyje yra daug regresorių ir mažai stebinių. Jeigu respondentų yra bent 7 kartus daugiau nei regresorių, jokių koreguotų determinacijos koeficientų nereikia, nes visiškai pakanka standartinio R^2 . Pavyzdžiui, jeigu turime 30 respondentų duomenis, o modelyje jų IQ modeliujame pagal socialinį statusą, tėvo IQ, motinos IQ, brolių ir seserų IQ, mokytojų IQ vidurkį, respondento amžių ir perskaitytų per metus knygų skaičių, tai tikrai reikia koreguoto R^2 . Apsiribojus tėvų IQ, užteks įprasto determinacijos koeficiento. Paprastai rezultatų aprašyme pateikiamas tik vienas (koreguotas arba paprastas) determinacijos koeficientas.
- c) *ANOVA p reikšmė*. Ji parodo, ar modelyje yra su priklausomu kintamuoju susijusių regresorių. Jeigu p reikšmė didesnė už 0,05, tai regresijos modelio tinkamumas labai abejotinas (faktiškai gauname, kad Y nepriklauso nuo X , Z ir W). Jeigu p reikšmė mažesnė už 0,05, gavome patvirtinimą, kad modelis nėra beviltingas (o gal ir visai geras – reikia tirti toliau). Dažniausiai apie ANOVA p reikšmę regresijos modelio aprašyme neužsimenama.

¹⁵ Angl. *adjusted R square*.

Jeigu regresijos modelis pristatomas kaip duomenims tinkamas, tai visi ir taip supranta, kad ši reikšmė buvo maža.

- d) *T (Stjudento) kriterijai atskiriems regresoriams*. Padeda nuspręsti, ar atitinkamas regresorius šalintinas iš modelio. Jeigu atitinkamo kriterijaus p reikšmė $< 0,05$, tariama, kad *regresorius yra statistiškai reikšmingas* ir dažniausiai (jei nėra multikolinearumo) jis modelyje paliekamas. Jeigu p reikšmė $\geq 0,05$, tai regresorius (tiksliau daugiklis prie regresoriaus)¹⁶ yra statistiškai nereikšmingas ir modelyje regresorius paliekamas tik ypatingais atvejais (žr. 2.1.6 skyrelį). Dažniausiai modelio konstanta C paliekama net ir tada, kai ji statistiškai nereikšminga.

Ar tenkinamos regresijos modelio prielaidos parodo:

- 1) *Dispersijos mažėjimo daugiklis (VIF)*¹⁷. Parodo, ar regresoriai stipriai koreliuoja (yra multikolinearumo problema). VIF skaičiuojamas kiekvienam regresoriui. Multikolinearumas yra, kai $VIF > 4$. Vietoje VIF galima naudoti juo išsireiškiamą rodiklį – toleranciją. Kintamojo *tolerancija* $= 1/VIF$. Blogai, kai *tolerancija* $< 0,25$.
- 2) *DFBeta (betos pokyčio)*¹⁸ statistika. Parodo, ar duomenyse yra išskirčių. Jeigu pašalinus vieną stebinį, modelio koeficientai (daugikliai prie regresorių) labai pasikeičia, tai galima įtarti, kad pašalintasis stebinys yra išskirtis. DFBetos įvertina kiekvieno koeficiento pokytį, pašalinus stebinį. Kiekvienam stebiniui DFBetų yra tiek, kiek ir modelio koeficientų. Stebinys yra išskirtis, jeigu jam bent viena DFBeta > 1 . Beje, yra ir konservatyvesnė nuomonė, teigianti, kad stebinys gali būti išskirtimi, jeigu $DFBeta > 2/\sqrt{n}$. Čia n yra stebinių skaičius duomenyse.
- 3) *Kuko matas*. Parodo, ar duomenyse yra išskirčių. Alternatyva DFBetai. Kitaip nei DFBetos vertina ne kiekvieno koeficiento pokytį, pašalinus stebinį, o bendrą (suminį) visų modelio koeficientų pokytį. Skaičiuojamas kiekvienam regresorių stebiniui. Kai Kuko matas > 1 – atitinkamas stebinys yra išskirtis. Itin griežti (jų negausu) statistikai mano, kad turime išskirtį, kai Kuko matas viršija $4/n$. Čia n – stebinių skaičius duomenyse.
- 4) *Durbino–Vatsono (Durbin–Watson) statistika*. Norime nustatyti, ar skirtingų stebinių liekamosios paklaidos koreliuoja (yra autokoreliacija). Tai reiškia, kad vieno respondento atsakymai daro įtaką kito respondento atsakymams. Durbino–Vatsono statistika tiriama *tik tada*, kai toks įtarimas kyla (pvz., respondentai, atsakydami žiūrėjo kaimynui per petį; biržos

¹⁶ Toliau paprastumo dėlei rašysime, kad regresorius yra statistiškai nereikšmingas.

¹⁷ Angl. *variance inflation factor*.

¹⁸ Angl. *difference in beta*.


indeksai matuoti kelias dienas iš eilės ar pan.). Visais kitais atvejais šios statistikos nereikia. Durbino–Vatsono statistika skaičiuojama tik tada, kai duomenys yra laikiniai, t. y. stebime kintamuosius, bėgant laikui, bet norime taikyti paprastą tiesinę regresiją, o ne sudėtingą laiko eilučių modelį. Socialiniuose tyrimuose tokios situacijos retos ir Durbino–Vatsono statistikos taikymas juose yra egzotika. Jeigu Durbino–Vatsono statistikos reikšmė yra tarp 1,5 ir 2,5, dažniausiai tariama, kad autokoreliacijos nėra.

- 5) *Standartizuotosios liekamosios paklaidos*¹⁹ naudojamos patikrinti, ar Y normaliai pasiskirstęs. Dažniausiai tiriama histograma, kuri lyginama su normaliąja kreive (turi nedaug skirtis) ir standartizuotojų liekamųjų paklaidų ir standartinio normaliojo atsitiktinio dydžio santykinų procentinių dažnių P–P grafikas. Kuo šiame grafike taškai yra arčiau nubrėžtos tiesės (idealiu atveju visi taškai *priklauso* tiesei), tuo duomenys normalesni.
- 6) *Šapiro–Vilko (Shapiro–Wilk) kriterijaus p reikšmė $\geq 0,05$* rodo, kad standartizuotosios paklaidos yra normalios. Reikia nepamiršti, kad didelėms imtims šis kriterijus gali nepagrįstai atmesti normalumo hipotezę. Didelėms imtims grafikai (žr. ankstesnį punktą) informatyvesni.
- 7) *Liekamųjų paklaidų grafikai kiekvienam regresoriui (dar vadinami daliniais įtakos grafikais)* parodo, kurie regresoriai modelyje reikalingesni. Grafike *neatidedamos* kintamųjų reikšmės. Iš tikrųjų vienoje ašyje atidedamos liekamosios paklaidos, gautos iš regresijos modelio be tikrinamojo regresoriaus, o kitoje ašyje – liekamosios paklaidos iš regresijos modelio, kai tikrinamasis regresorius modeliuojamas pagal likusius regresorius. Regresijos tiesės, suderintos su grafiko taškais, posvyris rodo pilnojo regresijos modelio koeficiento įvertį prie tikrinamo regresoriaus. Mums svarbi tik grafiko *forma*. Šį grafiką būtų galima interpretuoti taip – kuo regresijos tiesė ir x ašis „panašesnės“ į lygiagrečias tieses, tuo mažesnė tiriamo regresoriaus įtaka²⁰. Daliniai įtakos grafikai leidžia „iš akies“ įvertinti, kokius regresorius verta įtraukti į modelį.
- 8) *Standartizuotųjų prognozuojamų reikšmių*²¹ – *liekamųjų paklaidų* grafikas, kai y ašyje atidedamos standartizuotosios liekamosios paklaidos, naudojamos homoskedastiškumui tikrinti. Gerai, kai grafiko taškai išsibarstę tolygiai ir primena vienodo pločio juostelę. Blogai, kai grafiko taškų išsibartymas rodo kažkokį kitą reguliarumą. Toliau pateiktos kelios galimos „blogos“ situacijos.

¹⁹ Angl. *standardized residuals*.

²⁰ Jei regresijos tiesė grafike neatidedama, žiūrime, ar grafikas primena siaurą vienodo pločio taškų juostelę ir kaip ji išsidėsčiusi x ašies atžvilgiu.

²¹ Angl. *standardized predicted values*.



9) *Breušo–Pagano* (*Breusch–Pagan*) kriterijaus p reikšmė $\geq 0,05$ rodo, kad homoskedastiškumo prielaida patenkinta²². Reikia nepamiršti, kad didelėms imtims šis kriterijus gali nepagrįstai atmesti homoskedastiškumo prielaidą. Didelėms imtims grafikai (žr. ankstesnį punktą) informatyvesni.

Apibendrinami galime nusakyti, kokie turi būti tinkamo regresijos modelio rodikliai.

Tinkamo regresijos modelio:

- $R^2 \geq 0,20$.
- ANOVA $p < 0,05$.
- Visų t kriterijų $p < 0,05$.
- Visi $VIF \leq 4$ (nėra multikolinearumo problemos).
- Visos Kuko mato (arba $DFBets$) reikšmės ≤ 1 .
- Koeficientų ženklai atitinka koreliacijas.
- Sprendžiant iš histogramos ir P–P grafiko, liekamosios paklaidos normalios.
- Šapiro–Vilko kriterijaus $p \geq 0,05$ (liekanos normalios).
- Sprendžiant iš liekamųjų paklaidų grafiko, nėra heteroskedastiškumo problemos, o Breušo–Pagano kriterijaus $p \geq 0,05$.

2.1.5. Tiesinės regresinės analizės etapai

Regresinė analizė susideda iš preliminarus kintamųjų tinkamumo tyrimo ir modelio tinkamumo duomenims tikrinimo. Išsamios analizės etapai:

²² SPSS šio kriterijaus (kol kas) nėra.

- 1) Patikriname, ar liekamosios paklaidos yra normalios. Pageidautina, kad būtų normalūs ir visi regresoriai (išskyrus dvireikšmius).
- 2) Nustatome, ar priklausomas kintamasis Y koreliuoja su regresoriais. Jeigu regresoriai silpnai koreliuoja su Y , tai jų įtraukimas į modelį yra labai abejotinas. Galima nusibraižyti Y priklausomybės nuo kiekvieno regresoriaus grafikus. Jie turi rodyti tikėtiną tiesinę priklausomybę.
- 3) Sudarome regresijos modelį ir pažiūrime, kokio didumo yra R^2 (arba, jeigu reikia, koreguotas R^2). Jeigu $R^2 < 0,20$, modelis nelabai tinkamas.
- 4) Patikriname, ar ANOVA p reikšmė $< 0,05$. Jeigu ne – modelis netinkamas.
- 5) Patikriname, ar visi regresoriai statistiškai reikšmingi (visos t kriterijaus p reikšmės $< 0,05$). Jeigu ne – modelis taisytinas.
- 6) Patikriname, ar nėra multikolinearumo, t. y., ar visi $VIF \leq 4$ ir ar modelio koeficientai b_j yra logiški (dažniausiai tai reiškia, kad jie yra to paties ženklo kaip ir atitinkamos 2) punkte rastos koreliacijos).
- 7) Patikriname, ar nėra išskirčių.
- 8) Iš standartizuotų liekamųjų paklaidų sprendžiamo, ar tenkinamos modelio normalumo ir homoskedastiškumo prielaidos ir ar visi regresoriai modelyje reikalingi.
- 9) Jeigu yra daugiau nei vienas regresorius, pagal standartizuotuosius beta koeficientus įvertiname regresorių įtaką modelyje.
- 10) Jeigu visi rodikliai tinkami, modelį aprašome. Jeigu ne – tobuliname.

2.1.6. Modelio tobulinimas

Beveik visada modelio tobulinimas reiškia regresorių šalinimą arba jų transformaciją.

Pašalinus bent vieną regresorių, keičiasi visos modelio charakteristikos: R^2 , p reikšmės, VIF, Kuko mato reikšmės.


Modelis tobulinamas, jeigu yra problemų:

- $R^2 < 0,20$. Regresorių šalinimas šiuo atveju nelabai padeda. Juos prasmingiau keisti kitais regresoriais. Yra statistikų, manančių, kad ir mažiems R^2 (0,15–0,19) dar galima modelio neatmesti. Ypač jeigu modelio ryšiai puikiai atitinka ekonominę (ar kitokią) logiką.

- *Yra statistiškai nereikšmingas regresorius* (t kriterijaus p reikšmė didesnė už 0,05). Regresorius pašalinamas iš modelio ir regresinė analizė pakartojama be jo. Viskas gerai, jeigu R^2 daug nesumažėjo (ką reiškia daug, sprendžia tyrėjas). Pristatydami galutinį modelį, tada rašysime, kad modelyje liko tik statistiškai reikšmingi regresoriai. Jeigu R^2 labai sumažėjo (pvz., nuo 0,35 iki 0,20), kintamąjį iš modelį grąžiname, o aprašyme konstatuojame, kad „regresorius buvo statistiškai nereikšmingas. Vis dėlto jis paliktas modelyje, nes be jo labai sumažėja determinacijos koeficientas“.
- *Yra multikolinearumo problema* ($VIF > 4$ arba modelis neteisingai rodo Y ir regresoriaus priklausomybę). Tada arba šaliname regresorių ir tikriname R^2 sumažėjimą, arba kelis stipriai koreliuojančius regresorius keičiame jų vidurkiu. Žinoma, keičiame tik tada, jeigu toks vidurkis prasmingas. Pavyzdžiui, jeigu modeliuosime mokinio valstybinio egzamino pažymį atsižvelgdami į keturių ekspertų nuomonę, tai multikolinearumo neišvengsime (nebus taip, kad tas mokinys vienam ekspertui atrodys Einšteino reinkarnacija, o kitam – alternatyviai protingas). Tada logiškiau sudaryti modelį, atsižvelgiant į visų keturių ekspertų nuomonių vidurkį, o ne į kažkurio vieno eksperto nuomonę.
- *Duomenyse yra išskirčių* (didelių Kuko mato arba DFBeta reikšmių). Gali būti, kad duomenyse tiesiog pasitaikė duomenų įvedimo klaida arba sugebėjome praleistos reikšmės kodą (pvz., atvejį, kai kintamojo vaikų skaičius reikšmė 99 tereiškia, kad respondentui vienuoliui klausimas netaikytinas, o ne tai, kad pasitaikė tėvas rekordininkas) traktuoti kaip eilinį stebinį. Šiaip jau išskirties šalinti vien todėl, kad ji netinka regresijos modeliui, negalima. Rekomenduojama, radus išskirtį, pakartoti regresinę analizę be jos. Jeigu gavome labai panašų modelį, išskirtis nėra kenksminga ir dėl jos nėra ko sukti galvos. Kitu atveju išėtimi gali tapti atsparioji regresija (žr. atitinkamą skyrelį).
- *Duomenys heteroskedastiški*. Tuo atveju patariama taikyti stabilizuotų liekamųjų paklaidų regresiją (žr. 3.2 skyrelį). Dažnai duomenys transformuojami, pavyzdžiui, visos kintamųjų reikšmės logaritmuojamos. Dar dažniau (ypač socialiniuose tyrimuose) duomenų heteroskedastiškumas paprasčiausiai ignoruojamas. Nors modelio parametrų įverčiai gana atsparūs prielaidų pažeidimams, tačiau reikėtų žinoti, kad tada statistinės išvados (hipotezių tikrinimo rezultatai) yra gana abejotinos.
- *Yra autokoreliacija*. Jeigu buvo galima įtarti, kad stebiniai susiję, o Durbino–Vatsono statistikos reikšmė artima 0 arba 4, turime autokoreliuotus stebinius. Tada regresijos modelis netinka ir reikia taikyti sudėtingesnius laiko eilučių metodus, kurių čia neaptarsime.

2.1.7. Pastabos apie modelio taikymą

- Tiesinės regresijos modelyje gali būti ir vienas regresorius. Terminas *daugianarė* tiesinė regresija vartotinas tik tada, kai regresorių yra bent du. Visada pakanka užrašo „*tiesinė regresija*“, nes prireikus skaitytojas suskaičiuos, kiek modelyje yra tų regresorių.
- T kriterijai dar vadinami Stjudento kriterijais. Tiesiog toks trumpinys.
- Įprasta modelyje palikti visus statistiškai reikšmingus regresorius. Vis dėlto pasitaiko (žr. 2.2.5 skyrelį), kai net statistiškai reikšmingas regresorius modelyje nereikalingas.
- Kai turime vieną priklausomą kintamąjį ir vieną regresorių, rašyti, kad nėra multikolinearumo (VIF), nereikia, nes, išskyrus priklausomą kintamąjį, tas vienišas regresorius neturi daugiau su kuo koreliuoti. Sakinys „buvo vienas regresorius ir multikolinearumo problemos nėra ($VIF = 1$)“, žinoma, yra teisingas, bet yra analogiškas sakiniui „Visi tyrime dalyvavę vyrai nebuvo nėsti“.
- Kai turime vieną priklausomą kintamąjį ir vieną regresorių, rašyti apie standartizuotąjį beta koeficientą nereikia. Juk nebeturime su kuo to vienišo regresoriaus lyginti.
- Šiame el. vadovėlyje išsamiai aptariame tik tiesioginę tiesinę regresiją, kai visus modelio tobulinimus atlieka tyrėjas. Tyrimuose dar taikoma žingsninė²³ regresija, kai modelyje automatiškai paliekami patys statistiškai reikšmingiausi iš pradinių regresorių. Kaip ją atlikti parodysime atitinkame skyrelyje. Vis dėlto manome, kad regresijos modelius reikia sudaryti sąmoningai, o ne formaliai. Tyrėjas turi nusimanyti, ką tiria. Dažnai ekonominė logika (sociologijos, psichologijos, biologijos, medicinos ir kt. teorija) lemia, kuriuos regresorius modelyje palikti. Tarkime, formaliai modeliuodami sistolinį kraujospūdį pagal diastolinį kraujospūdį ir kūno masės indeksą, galime gauti statistiškai patikimą modelį be kūno masės indekso. Tokio modelio vertė labai abejotina, nes tik konstatuojame faktą – žmonės, kurių diastolinis kraujospūdis padidėjęs, turi padidėjusį ir sistolinį kraujospūdį. Na ir kas iš to? Turbūt neimsime teigti, kad sistolinio kraujospūdžio padidėjimą lemia diastolinis kraujospūdis. Šiuo atveju kur kas įdomesnis modelis, kai nustatoma sistolinio kraujospūdžio priklausomybė nuo kūno masės indekso.



²³ Angl. *stepwise*.

- Reikia nepamiršti, kad darydami prognozes prognozuojame priklausomo kintamojo vidutinę reikšmę fiksuotoms regresorių reikšmėms. Prognozuodami, kad studentas, kurio IQ = 100, išlaikys statistiką labai gerai (gaus 9), iš tikrųjų darome prognozę, kad visų respondentų, kurių IQ = 100, statistikos pažymių vidurkis bus 9. Vis geriau negu nieko. Nereikia tikėti stebuklinga regresijos prognozių galia ir neteks skaudžiai nusivilti.
- Kartais spėjame, kad modelyje Y tiesiškai priklauso nuo kintamųjų sandaugų. Tuo atveju sakoma, kad spėjame esant kintamųjų sąveiką (interakciją). Tada reikia sukurti naujus kintamuosius regresorius, kuriems jau taikoma įprastinė tiesinė regresinė analizė. Pavyzdžiui, norint patikrinti modelio $Y = C + b_1XZ + e$ tinkamumą, pakanka atlikti kintamųjų transformaciją $V = XZ$, o paskui nagrinėti modelį $Y = C + b_1V + e$.
- Nereikia taikyti Durbino–Watsono statistikos, jeigu nėra pagrindo įtarti stebinių priklausomumo. Pasakymas, kad, apklausus po vieną respondentą iš 30 skirtingų rajonų, Durbino–Watsono statistika rodo duomenų tikimą regresijai, akivaizdžiai rodo tyrėjo liguistą nepasitikėjimą respondentais – „O gal jie, atsakydami į klausimus, bendravo“. Matyt, telepatiškai.

2.1.8. Standartiniai tiesinės regresijos modelio aprašymai

Svarbiausia visų regresijos modelių aprašymo taisyklė yra tokia: visada pateikiamas determinacijos koeficientas, beveik visada – modelio lygtis, gana dažnai – informacija, kad buvo tenkinamos normalumo ir homoskedastiškumo prielaidos. Apie išskirtis ir multikolinearumą rašoma tik tada, jeigu šių problemų kilo. Maždaug taip: buvo tokių ir tokių problemų, jas išsprendėme taip ir taip. Visada aprašomas *galutinis* modelis. Skaitytojai neįdomu, kiek daug sunkaus triūso įdėjo tyrėjas tobulindamas savo pradinį modelį. Visus domina to tobulinimo rezultatas. Pateiksime keletą galimų aprašymo fragmentų.

- *Sudarėme regresijos modelį, rodantį Y priklausomybę nuo X . Gautas $R^2 = 0,87$. Modelis $Y = 7,34 + 2,1X$.*
- *Sudarėme regresijos modelį, rodantį Y priklausomybę nuo X, W, Z . Modelyje buvo palikti tik statistiškai reikšmingi regresoriai W ir Z . Determinacijos koeficientas $R^2 = 0,66$. Galutinis regresijos modelis $Y = -2 + 3W + 3Z$. Daug didesnę įtaką Y turi regresorius W (jo standartizuotoji beta koeficiento reikšmė 0,68) nei Z (jo standartizuotoji beta koeficiento reikšmė 0,39).*

- Sudarėme regresijos modelį, rodantį Y priklausomybę nuo X , W , Z . Iš modelio buvo pašalintas statistiškai nereikšmingas regresorius X . Nors regresorius Z ir buvo statistiškai nereikšmingas ($p = 0,059$), jį pašalinus iš modelio labai sumažėja determinacijos koeficiento reikšmė. Todėl jį modelyje palikome...
- Dėl regresorių W ir Z multikolinearumo ($VIF > 4$) modelyje šiuos regresorius keitėme jų vidurkiu...
- Modelyje buvo išskirtis, kurią pašalinus, regresijos modelis beveik nepasikeitė...

2.2. Tiesinė regresinė analizė su SPSS


2.2.1. Duomenys

Kaip atlikti daugianarę tiesinę regresinę analizę, parodysime tirdami 2008 metų Europos Sąjungos socialinio tyrimo (European Social Survey) Estijos duomenis faile ESS4EE. Tirsime 20–40 metų vyrus. Tyrime naudosime tokius kintamuosius:

- *stfgov* (kiek respondentas yra patenkintas savo šalies vyriausybe), *stfdem* (kiek respondentas patenkintas demokratijos būseną šalyje);
- *trstprl* (pasitikėjimas šalies parlamentu), *trstlgl* (pasitikėjimas teisine sistema), *trstplt* (pasitikėjimas politikais), *trstprt* (pasitikėjimas partijomis), *trstun* (pasitikėjimas Jungtinėmis Tautomis);
- *happy* (laimingumas).

Kintamieji *stfgov* ir *stfdem* matuojami 11 balų skale nuo 0 (labai nepatenkintas) iki 10 (labai patenkintas). Kintamieji *trstprl*, *trstlgl*, *trstplt*, *trstprt*, *trstun* matuojami 10 balų skale nuo 0 (labai nepasitikiu) iki 9 (labai pasitikiu). Kintamasis *happy* matuojamas 10 balų skale nuo 0 (labai nelaimingas) iki 9 (labai laimingas).

Modeliuosime kintamųjų *stfgov* ir *stfdem* vidurkį (pavadinkime jį *satisfaction*). Šis kintamasis rodo respondentų pasitikėjimą politiniu šalies klimatu. Manome, kad *satisfaction* gali priklausyti nuo likusiųjų kintamųjų. Kitaip tariant, manome, kad pasitikėjimas įvairiomis šalies institucijomis turi įtakos ir pasitikėjimui politiniu klimatu. Spėjamo modelio schema atrodo taip:




Norime nustatyti, ar duomenys neprieštarauja spėjiamam modeliui, ar visi regresoriai modelyje reikalingi ir kurie iš jų svarbesni. Matematinis regresijos modelio užrašas yra toks:

$$satisfaction = C + b1 \ trstprl + b2 \ trstlgl + b3 \ trstplt + b4 \ trstprt + b5 \ trstun + b6 \ happy + e.$$

Reikiamus respondentus atsirinksime, atsižvelgę į *agea* (amžių) ir *gndr* (lytį, 1 – vyr.).


Su komanda **Compute** sukuriame naują kintamąjį *satisfaction*, kuris yra kintamųjų *stfgov* ir *stfdem* vidurkis.




Su komanda **Select Cases** atrenkame reikiamus respondentus. Tai daroma taip: meniu **Select Cases** pažymime **If condition is satisfied** ir spaudžiame klavišą **If**. Naujajame meniu suformuluojame sąlygą $agea \geq 20 \ \& \ agea \leq 40 \ \& \ gndr = 1$. Tada spaudžiame **Continue** ir **OK**.

2.2.2. Pirminio modelio tyrimas


Atsidarome langelį **Analyze** ir renkamės **Regression** → **Linear**:




Į laukelį **Dependent** įkeliamas kintamasis *satisfaction*. Kintamieji *trstprl*, *trstlgl*, *trstplt*, *trstprt*, *trstun*, *happy* sukeliami į laukelį **Independent(s)**. Paskui spaudžiame **Statistics**.



Atsidariusiame lange pažymime **Descriptives** ir **Collinearity diagnostics**. Visos kitos pagal nutylėjimą pažymėtos parinktys (**Estimates**, **Model fit**) paliekame ramybėje.



Spaudžiame **Continue**, grįžtame į ankstesnį langą ir renkamės **Save**. Pažymime **Cook's** ir **DfBeta(s)** ir **Standardized**.



Spaudžiame **Continue**, grįžtame į ankstesnį langą ir renkamės **Plots**. Atsidariusiame lange pažymime laukus **Histogram**, **Normal probability plot** ir **Produce all partial plots**. Į laukelį **X** įkeliame ZPRED, o į laukelį **Y** – ZRESID. Spaudžiame **Continue** ir **OK**.



2.2.3. Pirminio modelio tyrimo rezultatai

Rezultatų išsklotinė prasideda nuo lentelėje **Descriptive Statistics** pateikiamos informacijos apie visų modelio kintamųjų vidurkius ir standartinius nuokrypius. Matome, kad imtyje buvo 212 respondentų. Prisiminę kintamųjų kodus, galime konstatuoti, kad respondentai nelabai pasitiki visomis institucijomis, išskyrus Jungtines Tautas.

Descriptive Statistics			
	Mean	Std. Deviation	N
satisfaction	4.1439	2.22849	212
trstprl	3.93	2.322	212
trstlgl	5.19	2.542	212
trstplt	3.31	1.980	212
trstprt	3.36	1.926	212
trstun	5.44	2.237	212
happy	6.71	1.890	212

Tiesinės regresijos modelyje visi intervaliniai regresoriai turi koreliuoti su priklausomu modeliuojamu kintamuoju. Kita vertus, regresoriai neturėtų stipriai koreliuoti. Koreliacijų lentelė **Correlations** rodo, kad visi regresoriai su kintamuoju *satisfaction* koreliuoja statistiškai reikšmingai, o koreliacijos vidutinio stiprumo. Be to, visos koreliacijos yra teigiamos. Koreliacijų ženklai svarbūs, nes dažniausiai nurodo, kokios turi būti priklausomybės pačiame regresijos modelyje. Tiriamu atveju tiesioginės priklausomybės yra visai logiškos, todėl ir visi regresijos modelio koeficientai turi būti teigiami. Vis dėlto matome, kad regresoriai stipriai koreliuoja vieni su kitais. Todėl galima tikėtis, kad gali kilti multikolinearumo problema (regresoriai pradės vienas kitam trukdyti).

		Correlations						
		satisfaction	trstprl	trstlgl	trstplt	trstprt	trstun	happy
Pearson Correlation	satisfaction	1.000	.688	.623	.640	.624	.432	.421
	trstprl	.688	1.000	.648	.782	.746	.362	.288
	trstlgl	.623	.648	1.000	.544	.579	.402	.330
	trstplt	.640	.782	.544	1.000	.842	.446	.232
	trstprt	.624	.746	.579	.842	1.000	.453	.270
	trstun	.432	.362	.402	.446	.453	1.000	.189
	happy	.421	.288	.330	.232	.270	.189	1.000
Sig. (1-tailed)	satisfaction	.	.000	.000	.000	.000	.000	.000
	trstprl	.000	.	.000	.000	.000	.000	.000
	trstlgl	.000	.000	.	.000	.000	.000	.000
	trstplt	.000	.000	.000	.	.000	.000	.000
	trstprt	.000	.000	.000	.000	.	.000	.000
	trstun	.000	.000	.000	.000	.000	.	.003
	happy	.000	.000	.000	.000	.000	.003	.

Lentelėje **Model Summary** randame determinacijos koeficientą $R^2 = 0,596$. Primename, kad modelis nelabai tinkamas, jeigu $R^2 < 0,20$. Darome išvadą, kad determinacijos koeficientas pakankamai didelis, ir atmesti tiesinės regresijos modelio kaip netinkamo dar negalima. Koreguotasis R^2 šiam modeliui neaktualus, nes respondentų yra keliasdešimt kartų daugiau nei regresorių.

Model Summary ^b				
Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	.772 ^a	.596	.584	1.43749

ANOVA kriterijaus p reikšmė yra mažesnė už 0,05 (mažesnė net už 0,01). Todėl darome išvadą, kad modelyje yra bent vienas regresorius, nuo kurio priklauso *satisfaction*.

ANOVA ^b						
Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	624.254	6	104.042	50.350	.000 ^a
	Residual	423.608	205	2.066		
	Total	1047.862	211			

a. Predictors: (Constant), happy, trstun, trstprl, trstlgl, trstprt, trstplt

b. Dependent Variable: satisfaction

Lentelėje **Coefficients** pateikiama pagrindinė informacija apie modelio koeficientus.

Coefficients ^a								
		Unstandardized		Standardized			Collinearity	
		Coefficients		Coefficients			Statistics	
Model		B	Std. Error	Beta	t	Sig.	Tolerance	VIF
1	(Constant)	-.856	.407		-2.103	.037		
	trstprl	.286	.077	.298	3.705	.000	.305	3.278
	trstlgl	.183	.054	.208	3.383	.001	.520	1.923
	trstplt	.190	.104	.169	1.832	.068	.232	4.319
	trstprt	.040	.101	.034	.390	.697	.257	3.891
	trstun	.113	.051	.113	2.199	.029	.747	1.338
	happy	.231	.056	.196	4.137	.000	.875	1.142

a. Dependent Variable: satisfaction

Patys koeficientų įverčiai yra stulpelyje **Unstandardized Coefficients B**. Visų pirma išsiaiškinsime, kaip užrašyti regresijos lygtį, kurią galima naudoti prognozėms. Koeficientus reikia padauginti iš šalia parašytų regresorių ir sudėti. Konstanta pridedama tokia, koks yra jos įvertis. Gauname tokią regresijos lygtį:

$$satisfaction = -0,856 + 0,286trstprl + 0,183trstlgl + 0,190trstplt + 0,040trstprt + 0,113trstun + 0,231happy.$$

Visų koeficientų ženklai teigiami: kaip ir turėjo būti, sprendžiant iš koreliacijų. Norėdami suprasti, kuris regresorius modelyje įtakingesnis, pasižiūrime į **Standardized Coefficients Beta**. Matome, kad mažiausiai įtakingas regresorius modelyje *trstprt*, nes jo standartizuotasis beta koeficientas 0,034. Stulpelyje **t** pareikiamos Stjudento kriterijaus reikšmės, o stulpelyje **Sig.** – Stjudento kriterijaus *p* reikšmės kiekvienam koeficientui. Jeigu $p < 0,05$, tariame, kad atitinkamas regresorius statistiškai reikšmingas. Matome, kad regresoriai *trstprl*, *trstlgl*, *trstun* ir *happy* yra statistiškai reikšmingi, o regresoriai *trstplt* ir *trstun* statistiškai nereikšmingi. **Todėl modelį reikės tobulinti.** Vis dėlto parodysime, kur pateikiama likusi modelio informacija. Stulpelyje **VIF** surašyti dispersijos mažėjimo daugikliai. Kadangi regresoriui *trstplt* gauta, kad $VIF > 4$, darome išvadą, kad modelyje yra multikolinearumo problema. Ši išvada tik patvirtina įtarimus, kurių kilo peržiūrėjus pradines regresorių koreliacijas. Gavome dar vieną patvirtinimą, kad modelį reikia tobulinti.

Ar yra išskirčių, nustatome pažiūrėję į Kuko matus ir DFBetas kiekvienam stebiniui. Informaciją apie Kuko matą galima rasti lentelėje **Residual Statistics**. Priešpaskutinėje eilutėje yra informacijos, kad Kuko mato *maksimumas* yra 0,091. Taigi visos Kuko mato reikšmės neviršija vieneto – išskirčių nėra. Šis būdas vartotinas, jeigu DFBetų netiriame.

Residuals Statistics					
	Minimum	Maximum	Mean	Std. Deviation	N
Predicted Value	-.3928	9.1071	4.1439	1.72004	212
--- --	---	---	---	---	---
Cook's Distance	.000	.091	.006	.011	212
Centered Leverage Value	.002	.122	.028	.021	212

Kiekvienam respondentui Kuko mato ir DFBeta reikšmės atsirado duomenyse: įvykdžius komandą, automatiškai buvo sukurti nauji stulpeliai COO_1 ir DFB0_1 – DFB6_1 (nes buvo konstanta ir penki kintamieji).



COO_1	DFB0_1	DFB1_1	DFB2_1	DFB3_1	DFB4_1	DFB5_1	DFB6_1
.01525	.06058	-.00825	-.00082	-.00410	.02005	-.01089	-.00479
.02551	.06139	-.00940	-.00813	.00992	.01697	-.00380	-.00831

Galima tiesiog peržiūrėti visas eilutes, ieškant reikšmių, viršijančių vienetą. Vis dėlto tai nelabai patogu, nes eilučių daug. Alternatyviai galima panaudoti komandą **Analyze → Descriptive**


Statistics → **Descriptives**. Sukeliame kintamuosius DFB0_1 – DFB6_1 į **Variable(s)**. Pasirenkame **Options** ir paliekame pažymėtą tik parinktį **Maximum**. Renkamės **Continue** ir **OK**. Matome, kad visi maksimumai buvo mažesni už vienetą. Todėl darome išvadą, kad duomenys neturėjo išskirčių.

Descriptive Statistics		
	N	Maximum
COO_1 Cook's Distance	212	.09110
DFB0_1 DFBETA Intercept	212	.16573
DFB1_1 DFBETA happy	212	.01580
DFB2_1 DFBETA trstlgl	212	.01754
DFB3_1 DFBETA trstplt	212	.05593
DFB4_1 DFBETA trstprt	212	.04814
DFB5_1 DFBETA trstpri	212	.02556
DFB6_1 DFBETA trstun	212	.01556
Valid N (listwise)	212	


Informacija apie modelio standartizuotųjų liekamųjų paklaidų normalumą pateikiama dviejuose grafikuose. Histogramos grafike dar nubraižyta ir normalioji kreivė, t. y. tai, į ką turėtų būti panaši histograma, jeigu liekamosios paklaidos būtų normalios. Matome, kad histograma nedaug skiriasi nuo normaliosios kreivės. Šalia pateikiamas P–P grafikas. Kuo taškai arčiau nubrėžtos tiesės (idealiu atveju visi taškai yra *ant* tiesės), tuo duomenys normalesni. Antrasis grafikas taip pat rodo, kad standartizuotųjų liekamųjų paklaidų normalumo reikalavimas tenkinamas.



Ar duomenys nėra heteroskedastiški, sprendžiame žiūrėdami į grafiką **Scatterplot**. Nors grafiko kraštuose ir mažiau taškų, negalima įžiūrėti kažkokio standartizuotųjų liekamųjų paklaidų reguliarumo, o grafikas primena tolygaus storio debesėlį. Tėra keletas nuo bendro debesėlio nutolusių taškų. Darome išvadą, kad duomenys pakankamai homoskedastiški.




Papildoma informacija yra liekamųjų paklaidų grafikuose kiekvienam regresoriui **Partial Regression Plot**. Regresorius tuo geriau tinka modeliui, kuo grafike taškų išsibarstymo „debesėlis“ labiau primena juostelę, nelygiagrečią x ašiai. Dėl didelės regresorių koreliacijos šie grafikai nėra patikimi, todėl pateikiame tik vieną pavyzdį. Ką nors nuspręsti apie kintamojo *trstprl* tikimą modeliui iš pateikto grafiko yra sunku.




Galutinė pirminio modelio tyrimo išvada: nors determinacijos koeficientas ir pakankamai didelis, modelyje yra statistiškai nereikšmingų ir multikolinearių regresorių, todėl modelis netinkamas. Jį reikia tobulinti.

2.2.4. Šapiro–Vilko kriterijus SPSS

Jau žinome, kad modelį reikės tobulinti, ir vizualiai įsitikinome, jog normalumo prielaida nėra aiškiai pažeista. Vis dėlto susipažinsime, kaip patikrinti liekamųjų paklaidų normalumą Šapiro–Vilko kriterijumi. Renkamės **Analyze** → **Descriptives** → **Explore**. Į laukelį **Dependent List** įkeliamės *ZRE_1*. Šis standartizuotųjų liekamųjų paklaidų kintamasis buvo sukurtas vykdant regresiją (atitinkamą parinktį pasirinkome, kai buvome lange **Save**).



Spaudžiame **Plots**. Pažymime **Normality plots with tests**. Spaudžiame **Continue** ir **OK**.



Rezultatų išklotinėje randame **Test of Normality**. Matome, kad Šapiro–Vilko kriterijaus $p = 0,234 > 0,05$. Darome išvadą, kad pagal Šapiro–Vilko kriterijų normalumo prielaidos atmesti negalime.

Tests of Normality						
	Kolmogorov-Smirnov ^a			Shapiro-Wilk		
	Statistic	df	Sig.	Statistic	df	Sig.
ZRE_1 Standardized Residual	.036	212	.200 [*]	.991	212	.234

a. Lilliefors Significance Correction


*. This is a lower bound of the true significance.

Greta dar pateikti Kolmogorovo–Smirnovo kriterijaus rezultatai (nulinė hipotezė – kintamasis normalus). Kadangi $p = 0,20 > 0,05$, šie rezultatai taip pat neprieštarauja normalumo prielaidai.

Reikia nepamiršti, kad visi statistiniai kriterijai jautrūs stebinių skaičiui. Kai imtyje stebinių labai daug, normalumo prielaida gali būti atmesta net kai stebinių skirstinys nedaug skiriasi nuo normalaus. Todėl tikėti šiais kriterijais reikia atsargiai. Laimei, tiesinė regresija yra pakankamai atspari nedideliems prielaidų pažeidimams (plačiau žr. 3 skyrių). Todėl, tikrinant regresijos prielaidas, nereikėtų nusiristi iki paranojos. Jei labai priekabiaj tikrinsime visus reikalavimus duomenims, – liksime be nieko.

2.2.5. Modelio tobulinimas

Dažniausiai (bet ne visada) modelio tobulinimas reiškia, kad bus šalinami statistiškai nereikšmingi regresoriai. Tiriamo pavyzdžio regresoriai tarpusavyje dar ir pakankamai stipriai koreliavo (buvo multikolinearumas). Todėl paprasčiausiai pakeisime kintamuosius *trstprl*, *trstlgl*, *trstplt*, *trstprt*, *trstun* jų vidurkiu, kurį pavadinsime *trust_all*. Šį kintamąjį sukuriame naudodami **Transform** → **Compute** :



Paskui tikriname regresijos modelio $satisfaction = C + b_1 trust_all + b_2 happy + e$ tinkamumą. Peržiūrėję rezultatų išklotinę įsitikiname, kad determinacijos koeficientas beveik nepasikeitė: $R^2 = 0,590$, ANOVA p reikšmė $< 0,01$, išskirčių nėra (visiems stebiniams Kuko matas < 1). Koeficientų lentelė atrodo taip:


Coefficients ^a								
		Unstandardized		Standardized			Collinearity Statistics	
		Coefficients		Coefficients			Tolerance	VIF
Model		B	Std. Error	Beta	t	Sig.		
1	(Constant)	-.847	.359		-2.358	.019		
	trust_all	.824	.052	.689	15.841	.000	.911	1.098
	happy	.226	.052	.191	4.385	.000	.911	1.098

a. Dependent Variable: satisfaction


Matome, kad abudu regresoriai yra statistiškai reikšmingi, o multikolinearumo problemos nėra. Be to, iš standartizuotųjų beta koeficientų matyti, kad *trust_all* yra daug įtakingesnis modelio regresorius nei *happy*. Regresijos lygtis:

$$\text{satisfaction} = -0,847 + 0,824 \text{ trust_all} + 0,226 \text{ happy}.$$

Standartizuotųjų liekamųjų paklaidų grafikai rodo, kad normalumo ir heteroskedastiškumo prielaidos patenktos:



Liekamųjų paklaidų grafikuose matyti aiški tiesinė priklausomybė kintamajam *trust_all*. O kintamajam *happy* tokios priklausomybės nematyti.



Todėl dėl visa ko patikriname regresijos modelį be kintamojo *happy*. Naujojo modelio determinacijos koeficientas $R^2 = 0,558$.

Model Summary^b

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	.747 ^a	.558	.556	1.49917

Nors regresorius *happy* ir buvo statistiškai reikšmingas, jį pašalinus iš modelio determinacijos koeficiento reikšmė sumažėjo tik per 0,032.

Visos kitos charakteristikos – ANOVA *p* reikšmė, Kuko matas, liekamųjų paklaidų grafikai (jų nepateikiame) – rodo, kad šis modelis yra tinkamas, todėl jį ir laikysime galutiniu modeliu. Beje, į VIF nežiūrime (vis tiek jis lygus 1), nes liko tik vienas regresorius.

Coefficients^a


Model		Unstandardized Coefficients		Standardized Coefficients	t	Sig.	Collinearity Statistics	
		B	Std. Error	Beta			Tolerance	VIF
1	(Constant)	.379	.232		1.628	.105		
	trust_all	.894	.051	.747	17.409	.000	1.000	1.000

Pati tiesinės regresijos lygtis atrodo taip:


$$satisfaction = 0,379 + 0,894trust_all.$$

2.2.6. Prognozės ir stebinių grafinis palyginimas


Galima grafiškai palyginti stebėtas *satisfaction* reikšmes su reikšmėmis, gautomis prognozei pritaikius prieš tai aprašytąjį regresijos modelį. Visų pirma reikia išsaugoti prognozuojamas *satisfaction* reikšmes. Tam pakanka regresijos **Save** lange pažymėti **Predicted Values Unstandardized**.




Duomenyse atsiras naujas stulpelis *PRE_1*. Prognozuojamų ir stebimų reikšmių grafikas gaunamas pasirinkus **Graphs** → **Legacy Dialogs** → **Line**. Pažymime **Multiple** ir **Values of Individual Cases**. Spaudžiame **Define**.



Perkeliame *satisfaction* ir *PRE_1* į langelį **Lines Represent**. Spaudžiame **OK**.



Gautasis grafikas (kiek pareidagavus, kad būtų geriau matomas) atrodo taip:



Idealiu atveju, kai prognozė tiksli, abi linijos turi sutapti. Matome, kad tokių sutapčių yra gana daug. Apskritai kalbant, tas modelis prognozuoja visai pakenčiamai. Vis dėlto grafikas palieka labai daug erdvės subjektyvumui. Kitam tyrėjui gali atrodyti, kad pagal grafiką modelio tikimas ne itin geras. Be to, kai stebinių labai daug, yra sunku grafike ką nors įžiūrėti. Tokie grafikai beveik visada pridedami, kai tiriami laikiniai duomenys (pvz., BVP kitimas ketvirčiais). Socialiniuose tyrimuose panašūs grafikai braižomi retai. Čia jau – kaip tyrėjo širdis geidžia.

2.2.7. Rezultatų aprašymas

Visų pirma trumpai reziumuojame ką gavome. Tikėjomės, kad pasitikėjimas įvairiomis šalies institucijomis bus susijęs su požiūriu į šalies politinę sistemą. Tą ir pavyko parodyti. Tiesa, tirdami pradinį modelį, susidūrėme su statistinėmis problemomis (multikolinearumu, statistiniu regresorių nereikšmingumu). Šias problemas įveikėme, regresorius pakeitę jų vidurkiu.

Aprašydami rezultatus nurodome, ką tyrėme, kokius kintamuosius naudojome ir kaip juos perkodavome. Tada kompaktiškai surašome visa tai, ką išsamiai aptarėme ankstesniuose skyreliuose. Dažnai pridedame vieną kitą grafiką. Pateikiame vieną iš daugybės galimų tokio aprašymo variantų.

Tyrėme modelį $satisfaction = C + b1trstpr + b2 trstlgl + b3 trstplt + b4 trstprr + b5 trstun + b6 happy + e$. Regresoriai $trstprl$, $trstlgl$, $trstplt$, $trstprr$, $trstun$ rodo pasitikėjimą šalies parlamentu, teisine sistema, politikais, partijomis ir Jungtinėmis Tautomis, regresorius $happy$ – respondento laimingumo laipsnį. Pradinis modelio tyrimas parodė, kad yra multikolinearumo problema (keletui regresorių $VIF > 4$). Todėl regresorius $trstprl$, $trstlgl$, $trstplt$, $trstprr$, $trstun$ modelyje pakeitėme jų

vidurkiu *trust_all*. Nors naujojo modelio R^2 buvo pakankamai didelis, o abudu regresoriai buvo statistiškai reikšmingi, tačiau standartizuotieji beta koeficientai ir liekamųjų paklaidų grafikai rodė, kad regresoriaus *happy* įtaka priklausomam kintamajam *satisfaction* nėra stipri. Todėl regresorių *happy* iš modelio pašalinome. Determinacijos koeficiento reikšmė pašalinus regresorių *happy* sumažėjo tik per 0,032. Galutinė tiesinės regresijos lygtis atrodo taip:

$$\text{satisfaction} = 0,379 + 0,894\text{trust_all}.$$

Modelio $R^2 = 0,558$. Liekamųjų paklaidų grafikai rodo, kad modelio normalumo ir heteroskedastiškumo prielaidos tenkinamos.

2.2.8. SPSS komandų sintaksė tiesinei regresinei analizei

Surašysime, kaip atrodo SPSS komandos nagrinėjamam pradiniam tiesinės regresijos modeliui. Jas galima rašyti sintaksės lange ir įvykdyti pasirenkant **Run**.

Duomenų atranka:

```
USE ALL.  
COMPUTE filter_$=(agea >= 20 & agea <= 40 & gndr = 1).  
VARIABLE LABELS filter_$ 'agea >= 20 & agea <= 40 & gndr = 1 (FILTER)'.  
VALUE LABELS filter_$ 0 'Not Selected' 1 'Selected'.  
FORMATS filter_$ (f1.0).  
FILTER BY filter_$.  
EXECUTE.
```


Tiesinės regresijos modelio analizė:

```
REGRESSION  
  /DESCRIPTIVES MEAN STDDEV CORR SIG N  
  /MISSING LISTWISE  
  /STATISTICS COEFF OUTS R ANOVA COLLIN TOL  
  /CRITERIA=PIN(.05) POUT(.10) /NOORIGIN /DEPENDENT satisfaction  
  /METHOD=ENTER trstprl trstlgl trstplt trstprr trstun happy  
  /PARTIALPLOT ALL /SCATTERPLOT=(*ZRESID ,*ZPRED)
```

```
/RESIDUALS HISTOGRAM(ZRESID) NORMPROB(ZRESID)  
/SAVE COOK.
```

2.2.9. Autokoreliacijos tyrimas

Ar yra autokoreliacija reikia tirti tik esant logiškam paaiškinimui, kodėl vieno respondento atsakymas gali priklausyti nuo kito respondento atsakymo. Mūsų nagrinėtam pavyzdžiui toks spėjimas būtų visiškai nelogiškas. Nepanašu, kad antro respondento požiūris į politines institucijas priklauso nuo pirmo respondento požiūrio. Vis dėlto parodysime kaip Durbino–Watsono kriterijus taikomas, naudojant SPSS programą. Pasirinkę **Analyze** → **Regression** → **Linear** → **Statistics**, pažymime **Durbin-Watson**.



Tarp rezultatų suradę lentelę **Model Summary**, joje rasime ir Durbino–Watsono statistikos reikšmę. Toliau patekiame šios statistikos reikšmę galutiniam, prieš tai nagrinėto pavyzdžio modeliui. Matome, kad statistikos reikšmė 2,043 beveik nesiskiria nuo dviejų, t. y. iš tikrųjų vieno respondento atsakymai nesusiję su kito respondento atsakymais.

Model Summary ^b					
Model	R	R Square	Adjusted R Square	Std. Error of the Estimate	Durbin-Watson
1	.747 ^a	.558	.556	1.49917	2.043

a. Predictors: (Constant), trust_all

b. Dependent Variable: satisfaction

Primename, kad autokoreliacijos nėra, jeigu Durbino–Watsono statistika nedaug skiriasi nuo 2 (nedaug – reiškia, kad statistikos reikšmė pakliuvo į intervalą [1,5; 2,5].) Autokoreliaciją reikia tirti, kai turime laikinius stebinius. Pavyzdžiui, ketvirtinius BVP augimo duomenis.

2.2.10. Multikolinearumo problema

Primename, kad labai koreliuojantys (multikolinearūs) regresoriai gali sukelti problemų. Modelis tampa nestabilus, t. y. keli nauji stebiniai gali radikaliai pakeisti parametrų įverčius. Be to, gali atsirasti neteisingų priklausomybių. Pateiksime vieną kiek dirbtinį pavyzdį, parodantį, kaip multikolinearumas gali iškreipti tikrąsias kintamųjų priklausomybes. Sudarysime tiesinės regresijos modelį $trstlgl = C + b1 \ trstprr + b2 \ trust_all + e$. Koreliacija tarp $trstlgl$ ir $trstprr$ yra 0,659, t. y. priklausomybė tiesioginė – kuo vieno kintamojo reikšmė didesnė, tuo didesnė ir kito kintamojo reikšmė. Kitaip sakant, tie respondentai, kurie labiau pasitiki parlamentu, labiau linkę pasitikėti ir teisine sistema. Į modelį įtraukėme ir stipriai su abiem kintamaisiais koreliuojantį (visai natūralu, nes abudu kintamieji buvo naudoti jį sudarant) kintamąjį $trust_all$. Koreliacija tarp $trust_all$ ir $trstprr$ yra labai stipri ir lygi 0,877.

Gauto modelio $R^2 = 0,66$, ANOVA p reikšmė $< 0,05$. Pažvelkime į lentelę **Coefficients**. Pagal Stjudento kriterijų abudu regresoriai statistiškai reikšmingi ($p = 0,007$ ir $p = 0,000$). Taip pat matome, kad yra multikolinearumo problema (abudu $VIF > 4$). Kas įvyktų, jeigu į multikolinearumą nekreiptume dėmesio? Atsižvelgę į lentelėje pateiktus koeficientų įverčius, gautume tokią regresijos lygtį:

$$trstlgl = 0,33 - 0,23trstprr + 1,372 \ trust_all.$$

Coefficients ^a							
Model	Unstandardized Coefficients		Standardized Coefficients	t	Sig.	Collinearity Statistics	
	B	Std. Error	Beta			Tolerance	VIF
1.(Constant)	.330	.247		1.335	.183		
trstprr	-.230	.085	-.214	-2.708	.007	.231	4.338
trust_all	1.372	.109	.995	12.598	.000	.231	4.338

a. Dependent Variable: trstlgl


Neigiamas koeficiento prie $trstprr$ ženklas reiškia, kad $trstprr$ didėjant, $trstlgl$ mažėja. Kitaip tariant, kuo labiau respondentas pasitiki parlamentu, tuo mažiau pasitiki teisine sistema. Ši išvada prieštarauja pirmiau aptartai kintamųjų priklausomybei ir jų koreliacijos ženklui. Taigi nekreipdami dėmesio į stiprią regresorių koreliaciją, galime padaryti labai klaidingas išvadas.

2.2.11. Žingsninė regresija

Parodysime, kaip atliekama žingsninė (pažingsninė, keliaetapė) regresija, nagrinėdami ESS4 Lietuvos duomenis. Tiriame visus 20–30 metų respondentus. Norime išsiaiškinti, nuo ko priklauso pasitikėjimas Seimu. Tirsime modelį

$$trstprl = C + b1\ stfeco + b2\ stflife + b3\ stfgov + b4\ stfdem + b5\ stfedu + b6\ stfhlth + e.$$

Čia *trstprl* yra pasitikėjimas parlamentu, *stfeco*, *stflife*, *stfgov*, *stfdem*, *stfedu*, *stfhlth* atitinkamai – pasitenkinimas ekonomika, gyvenimu apskritai, vyriausybe, demokratijos padėtimi, švietimo būkle, sveikatos apsauga. Visi kintamieji intervaliniai (0–9 arba 10), didesnė reikšmė rodo palankesnę požiūrį. Norima sužinoti, kuri sritis daro didesnę įtaką parlamento autoritetui. Panaudosime žingsninę regresiją. Žingsniuoti galima ir į priekį, ir atgal (akumuliuojant, kaupiant regresorius arba juos eliminuojant, šalinant). Todėl ir atitinkamų regresijų yra ne viena. Išbandysime vieną tokį modelį. Visos SPSS parinktys yra tokios pačios kaip ir tikrinant pirminio modelio tinkamumą. Vienintelis skirtumas – pagrindiniame meniu pasirenkame **Method Stepwise**.



Pasirinkome tokį žingsninės regresijos metodą, kai regresoriai po vieną įtraukiami į modelį po vieną. Rezultatų išklotinėje dalis skirta aprašomajai statistikai liko tokia pati kaip ir tiesioginės tiesinės regresijos atveju. Lentelėje **Model Summary** pateikti penkių modelių determinacijos koeficientai. Po lentele nurodyta, kokie regresoriai naudojami modeliuose. Matome, kad

galutiniame modelyje yra visi regresoriai, išskyrus *trsp*. Vis dėlto R^2 reikšmės kito nedaug. Neturime svarių priežasčių teigti, kad penktasis modelis yra iš esmės geresnis už ketvirtąjį.

Model Summary

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	.603 ^a	.364	.362	1.519
2	.623 ^b	.388	.384	1.494
3	.630 ^c	.396	.390	1.486
4	.638 ^d	.407	.398	1.475

Lentelėje **ANOVA** yra visų penkių regresijos modelių ANOVA p reikšmės. Jos visos yra mažesnės už 0,05 . Todėl šis rodiklis nerodo, kad kuris nors modelis geresnis nei kiti.

ANOVA^e

Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	391.441	1	391.441	169.545	.000 ^a
	Residual	683.395	296	2.309		
	Total	1074.836	297			
2	Regression	416.716	2	208.358	93.396	.000 ^b
	Residual	658.120	295	2.231		
	Total	1074.836	297			
3	Regression	425.964	3	141.988	64.334	.000 ^c
	Residual	648.871	294	2.207		
	Total	1074.836	297			
4	Regression	436.987	4	109.247	50.183	.000 ^d
	Residual	637.848	293	2.177		
	Total	1074.836	297			

Lentelėje **Coefficients** yra informacijos apie visų regresijos modelių koeficientų reikšmes, VIF ir beta koeficientus.

Coefficients ^a							
Model	Unstandardized Coefficients		Standardized Coefficients	t	Sig.	Collinearity Statistics	
	B	Std. Error	Beta			Tolerance	VIF
1 (Constant)	.768	.131		5.884	.000		
stfgov	.594	.046	.603	13.021	.000	1.000	1.000
2 (Constant)	.535	.146		3.674	.000		
stfgov	.464	.059	.472	7.846	.000	.575	1.740
stfdem	.153	.045	.202	3.366	.001	.575	1.740
3 (Constant)	.884	.224		3.953	.000		
stfgov	.472	.059	.480	8.006	.000	.572	1.748
stfdem	.177	.047	.234	3.791	.000	.538	1.859
stflife	-.082	.040	-.100	-2.047	.042	.858	1.165
4 (Constant)	.704	.236		2.985	.003		
stfgov	.437	.061	.445	7.228	.000	.535	1.868
stfdem	.168	.047	.222	3.608	.000	.534	1.873
stflife	-.094	.040	-.116	-2.356	.019	.841	1.189
stfhlth	.094	.042	.113	2.250	.025	.797	1.255

Matome, kad modelis vis buvo pildomas, pridedant po naują regresorių (keturi žingsniai). Į galutinį modelį nepakliuvo *stfedu* ir *stfeco*. Determinacijos koeficientas $R^2 = 0,4066$. Užrašykime gautąją regresijos lygtį:

$$trstprl = 0,70 + 0,44 \text{ stfgov} + 0,17 \text{ stfdem} - 0,09 \text{ stflife} + 0,09 \text{ stfhlth}.$$

Tūlas politikas tokį rezultatą (neteisingai) gali interpretuoti taip: norint, kad jauno amžiaus rinkėjai labiau gerbtų parlamentą, reikia rūpinantis sveikatos apsauga, puoselėti demokratiją ir prižiūrėti, kad gerai dirbtų vyriausybė (koeficientai prie šių regresorių yra teigiami). Be to, nėra ko labai stengtis, kad žmonės jaustųsi laimingi (koeficientas prie *stflife* neigiamas). Na o ekonomikos ir švietimo būklė požiūriui į parlamentą neturi įtakos (regresoriai buvo statistiškai nereikšmingi).


Visų regresorių $VIF < 4$. Taigi, formaliai žiūrint, jokio kintamųjų multikolinearumo nėra. Įsitikinsime, kad modelis nėra patikimas. Pažiūrėkime kintamųjų koreliacijas su *trstprl*:

Correlations		
		trstprl Trust in country's parliament
stfeco	Pearson Correlation	.526**
	Sig. (2-tailed)	.000
	N	323
stflife	Pearson Correlation	.105
	Sig. (2-tailed)	.059
	N	323
stfgov	Pearson Correlation	.611**
	Sig. (2-tailed)	.000
	N	321
stfdem	Pearson Correlation	.512**
	Sig. (2-tailed)	.000
	N	317
stfedu	Pearson Correlation	.264**
	Sig. (2-tailed)	.000
	N	306
stfhlth	Pearson Correlation	.330**
	Sig. (2-tailed)	.000
	N	314

** . Correlation is significant at the 0.01 level (2-tailed).

Matome, kad *trstprl* su visais kintamaisiais koreliuoja *teigiamai*, tačiau koreliacija su *stflife* yra silpna ir statistiškai nereikšminga (jei reikšmingumo lygmuo 0,05) . Be to, atsiminkime, kad regresijos koeficiento įverčio reikšmė artima nuliui, o ir *p* reikšmė tikrinant jo reikšmingumą nėra maža. Taigi regresijos modelyje ženklas prie *stflife* nėra įtikinamas (kaip ir politiko išvada, kad geriau, kai respondentai nelaimingi).

Įdomu, kad, parinkus kitą reikšmingumo slenkstį ($p = 0,02$), modelis lieka su dviem regresoriais ir yra visai tinkamas: $R^2 = 0,3877$ (o buvo $R^2 = 0,407$).



Kokią išvadą galima padaryti iš pateiktų pavyzdžių? Kad ir kokią regresiją pasirinktume, gautą modelį reikia vertinti kritiškai – būtina pažiūrėti koreliacijas ir pamąstyti apie modelio suderinamumą su sveiku protu (su žinoma teorija, ankstesniais tyrimais ir pan.)

Atlikus žingsninę regresiją, būtina patikrinti modelio logiškumą.
Neapsiriboti formaliais statistikos rodikliais.

2.3. Tiesinė regresinė analizė su STATA

2.3.1. Duomenys

Kitaip nei naudojant SPSS programą, dirbant su STATA, komandas paprasčiau surašyti patiems nei naudotis meniu. Tirsime tuos pačius duomenis kaip ir SPSS atveju, tik pasinaudosime sukurtais kintamaisiais. Tiriame 2008 metų Europos Sąjungos socialinio tyrimo (*European Social Survey*) Estijos duomenis ESS4EE. Mus domins, kaip pasitenkinimas šalies politiniu klimatu susijęs su pasitikėjimu politinėmis institucijomis ir bendroju žmogaus laimingumu. Tirsime 20–40 metų vyrus. Tyrime naudosime tokius kintamuosius:

- *satisfaction* (pasitenkinimas šalies politiniu klimatu),
- *trust_all* (pasitikėjimas politinėmis institucijomis),
- *happy* (laimingumas).

Kintamasis *satisfaction* sukurtas paėmus kintamųjų *stfgov* (kiek respondentas patenkintas savo šalies vyriausybe) ir *stfdem* (kiek respondentas patenkintas demokratijos būseną šalyje) vidurkį. Jis įgyja reikšmes nuo 0 (itin nepatenkintas) iki 10 (labai patenkintas). Kintamasis *trust_all* sukurtas, suskaičiavus kintamųjų *trstprl* (pasitikėjimas šalies parlamentu), *trstlgl* (pasitikėjimas teisine sistema), *trstplt* (pasitikėjimas politikais), *trstprt* (pasitikėjimas partijomis), *trstun* (pasitikėjimas Jungtinėmis Tautomis) vidurkį ir įgyja reikšmes nuo 0 (itin nepasitiki) iki 9 (itin pasitiki). Kintamasis *happy* matuojamas 10 balų skale nuo 0 (itin nelaimingas) iki 9 (itin laimingas).

Reikiamus respondentus atsirinksime, atsižvelgę į *agea* (amžių) ir *gndr* (lytį, 1 – vyr., 2 – mot.). SPSS *.sav formato failas buvo išsaugotas STATA *.dta formatu. Atidarę failą STATA programa, atsirenkame reikiamus respondentus:

```
keep if agea >= 20 & agea <= 40 & gndr == 1 & happy < 11 & satisfaction < 11
```

Reikia turėti omenyje, kad neatsakyti klausimai dažnai užkoduojami didelėmis skaitinėmis reikšmėmis. Norint, kad jos nebūtų naudojamos, reikėtų jas tiesiog pašalinti iš tyrimo. Būtent todėl STATA komandoje ir atsirado paskutinės sąlygos (STATA tuščią vietą traktuoja kaip begalybę).

Tiesinė regresija turi prasmę tik tada, kai intervaliniai regresoriai pakankamai stipriai koreliuoja su priklausomu kintamuoju ir pakankamai silpnai tarpusavyje. Patikriname kintamųjų koreliacijas komanda

```
pwcorr satisfaction trust_all happy, sig
```

Gauta koreliacijų lentelė rodo stiprią teigiamą *satisfaction* ir *trust_all* koreliaciją ($r = 0,7461$) ir vidutinę teigiamą *satisfaction* ir *happy* koreliaciją ($r = 0,3967$). Patys regresoriai *happy* ir *trust_all* koreliuoja silpnai ($r = 0,2988$). Multikolinearumo problema neturėtų iškilti. Visos koreliacijos yra statistiškai reikšmingos (visos p reikšmės lygios $0,000 < 0,05$).

	satisf~n	trust_~l	happy
satisfaction	1.0000		
trust_all	0.7461 0.0000	1.0000	
happy	0.3947 0.0000	0.2988 0.0000	1.0000

2.3.2. Regresijos modelio lygtis

Dabar patikrinsime regresijos modelį $satisfaction = C + b1trust_al + b2happy + e$. Įvykdome komandą

```
regress satisfaction happy trust_all, beta
```

Gauname pagrindinę informaciją apie modelį. Determinacijos koeficientas $R^2 = 0,5898$ yra pakankamai didelis.

Source	SS	df	MS	Number of obs = 241	
Model	716.420078	2	358.210039	F(2, 238) =	171.13
Residual	498.181582	238	2.09319992	Prob > F =	0.0000
				R-squared =	0.5898
				Adj R-squared =	0.5864
Total	1214.60166	240	5.06084025	Root MSE =	1.4468

satisfaction	Coef.	Std. Err.	t	P> t	Beta
happy	.2260815	.0515548	4.39	0.000	.1907632
trust_all	.8241485	.0520248	15.84	0.000	.6891185
_cons	-.8467996	.3590563	-2.36	0.019	.

Užrašykime regresijos lygtį:


$$satisfaction = -0,847 + 0,824 \text{ trust_all} + 0,226 \text{ happy}$$

ANOVA p reikšmė yra eilutėje **Prob > F**. Ji mažesnė už 0,05. Taigi modelyje yra statistiškai reikšmingų kintamųjų. Iš lentelės matyti, kad abudu regresoriai yra statistiškai reikšmingi, nes jiems t kriterijaus p reikšmės (jos yra stulpelyje **P>|t|**) mažesnės už 0,05.

Norėdami nustatyti, kuris regresorius modelyje yra įtakingesnis, pažiūrime į standartizuotuosius beta koeficientus. Regresorius *trust_all* (jo beta koeficientas lygus 0,689) yra daug įtakingesnis nei *happy* (beta lygus 0,191). Papildomai nubraižysime dalinius liekamųjų paklaidų grafikus abiem regresoriams. Tai galima atlikti viena komanda apps. Vis dėlto aiškesnis vaizdas yra, kai grafikus braižome kiekvienam regresoriui atskirai. Paeiliui įvykdome dvi komandas:

```
avplot trust_all
avplot happy
```

Gautuosiuose daliniuose liekamųjų paklaidų grafikuose matyti aiški tiesinė priklausomybė kintamajam *trust_all*. O kintamajam *happy* tokios akivaizdžios priklausomybės nematyti.



Taigi pagrindinės modelio charakteristikos rodo gerą modelio tikimą duomenims. Vis dėlto kintamojo *happy* reikalingumas modelyje yra abejotinas.

2.3.3. Regresijos prielaidų tikrinimas

Dar reikia patikrinti modelio prielaidas, t. y. ar:

- liekamosios paklaidos homoskedastiškos,
- liekamosios paklaidos normalios,
- nėra išskirčių,
- regresoriai nėra multikolinearūs.



Norėdami patikrinti, ar tenkinama homoskedastiškumo prielaida, nubraižome liekamųjų paklaidų ir prognozuojamųjų *satisfaction* reikšmių išsibarstymo grafiką. Tai galima padaryti tiesiog įvykdžius komandą:

```
rvfplot
```

Alternatyviai galima nubraižyti standartizuotųjų liekamųjų paklaidų ir prognozuojamųjų *satisfaction* reikšmių išsibarstymo grafiką. Tai galima padaryti paeiliui įvykdžius tris komandas

```
predict a
predict r1, rstandard
scatter a r1
```

Gautieji grafikai skiriasi nedaug ir rodo, kad duomenys nėra labai heteroskedastiški, liekanos išsibarsčiusios daugmaž tolygiai (grafikas primena juostelę).



Galima įtarti, kad homoskedastiškumo prielaida tenkinama. Patikrinsime, ar duomenys tam statistiškai reikšmingai neprieštaruoja, taikydami Breušo–Pagano kriterijų. Nulinė šio kriterijaus hipotezė teigia, kad homoskedastiškumo prielaida galioja. Homoskedastiškiems duomenims p reikšmė turi būti **ne mažesnė** už 0,05. Įvykdome komandą

```
estat hett
```

Gautoji chi kvadrato statistikos reikšmė yra 2,19, o $p = 0,1391 \geq 0,05$. Darome išvadą, kad duomenys statistiškai reikšmingai neprieštaruoja homoskedastiškumo prielaidai.

Breusch-Pagan / Cook-Weisberg test for heteroskedasticity

Ho: Constant variance

Variables: fitted values of satisfaction

chi2(1) = 2.19

Prob > chi2 = 0.1391


Norime atkreipti dėmesį, kad p reikšmės gali būti mažos ir dėl imties didumo. Todėl visada reikia atsižvelgti ir į chi kvadrato statistikos reikšmę (homoskedastiškiems duomenims ji maža) ir į liekamųjų paklaidų grafikus.

Tikrindami liekamųjų paklaidų normalumą, visų pirma nubraižysime standartizuotųjų liekamųjų paklaidų histogramą (ji turėtų būti panaši į normaliąją kreivę) ir P–P grafiką (grafiko taškai turi nedaug skirtis nuo tiesės). Standartizuotųjų liekamųjų paklaidų kintamąjį $r1$ sukūrėme komanda `predict r1, rstandard`. Paeiliui įvykdome dvi komandas:

```
histogram r1, frequency normal
```



```
pnorm r1
```



Matome, kad ir histograma, ir kvantilių grafikas rodo liekamųjų paklaidų normalumą. Dabar patikrinsime paklaidų normalumą Šapiro–Vilko kriterijumi. Nulinė hipotezė teigia, kad paklaidos normalios. Normalumo prielaida nepatenkinta, jeigu $p < 0,05$. Įvykdome komandą

```
swilk r1
```

variable	Shapiro-wilk w test for normal data				
	Obs	W	V	Z	Prob>z
r1	241	0.99257	1.305	0.617	0.26847

Įsitikiname, kad $p = 0,268 > 0,05$. Todėl galima teigti, kad sprendžiant iš Šapiro–Vilko kriterijaus, liekamosios paklaidos turi normalųjį skirstinį. Kaip ir tikrinant homogeniškumą, reikia nepamiršti, kad p reikšmės gali būti mažos ir dėl imties didumo. Todėl visada reikia atsižvelgti ir į grafikus, nes didelėms imtims jie informatyvesni.

Patikrinsime, ar duomenyse nebuvo išskirčių. Atsižvelgsime į regresorių DFBetas reikšmes ir į Kuko matą. Sukuriame DFBeta kiekvienam regresoriui (nauji kintamieji turės vardus Dftrust_all ir Dfhappy) ir pasižiūrime jų maksimalias reikšmes:

```
dfbeta trust_all happy
summarize Dftrust_all DFhappy
```

Variable	Obs	Mean	Std. Dev.	Min	Max
DFtrust_all	241	-.0000299	.060555	-.2955649	.2377913
DFhappy	241	-2.38e-06	.0634298	-.3248331	.2693256

Išskirtimi laikomas tas duomuo, kuriam $DFBeta > 1$. Kadangi maksimalios $DFBeta$ reikšmės mažesnės už vienetą, tokių duomenų imtyje nėra.

Kuko mato reikšmes kiekvienam respondentui sukuriame (pavadiname naująjį stulpelį *Coo*) ir pažiūrime maksimalią reikšmę analogiškai:

```
predict Coo , cooks
summarize Coo
```

Variable	Obs	Mean	Std. Dev.	Min	Max
Coo	241	.0039244	.0066371	7.96e-08	.0515792

Įsitikiname, kad ir Kuko mato maksimali reikšmė neviršija vieneto. Darome išvadą, kad duomenyse išskirčių nėra.

Galimą kintamųjų multikolinearumą patikrinsime suradę dispersijos mažėjimo daugiklius VIF. Įvykdome komandą

```
estat vif
```

Multikolinearumo problema kyla, jeigu $VIF > 4$. Abiem regresoriams $VIF < 1$. Todėl darome išvadą, kad kintamųjų multikolinearumo nėra.

variable	VIF	1/VIF
happy	1.10	0.910707
trust_all	1.10	0.910707
Mean VIF	1.10	

2.3.4. Galutinis modelis

Ankstesniuose skyreliuose įsitikinome, kad regresijos modelis gerai aprašo duomenis. Vis dėlto nedidelė *happy* ir *satisfaction* koreliacija, maža beta koeficiento reikšmė regresoriui *happy* ir netiesinis liekanų išsibastymo grafikas kelia abejonių šio regresoriaus reikalingumu. Todėl patikriname regresijos modelį be jo.

```
regress satisfaction trust_all, beta
```

Matome, kad naujojo modelio $R^2 = 0,5567$ nuo ankstesniojo $R^2 = 0,5898$ skiriasi tik per 0,0331, t. y. determinacijos koeficientas sumažėjo labai nedaug.

Source	SS	df	MS	Number of obs = 241	
Model	676.16673	1	676.16673	F(1, 239) =	300.14
Residual	538.43493	239	2.25286581	Prob > F =	0.0000
				R-squared =	0.5567
				Adj R-squared =	0.5548
Total	1214.60166	240	5.06084025	Root MSE =	1.501

satisfaction	Coef.	Std. Err.	t	P> t	Beta
trust_all	.8923218	.0515065	17.32	0.000	.7461222
_cons	.38224	.2328408	1.64	0.102	.

Darome išvadą, kad regresorių *happy* galima iš modelio pašalinti, *nepaisant to, kad jis buvo statistiškai reikšmingas*. Užrašykime gautą regresijos lygtį:

$$satisfaction = 0,382 + 0,892 \text{ trust_all}.$$

Naujajame modelyje liko tik vienas regresorius, todėl nebereikia tikrinti multikolinearumo, nebereikia aprašinėti standartizuotosios beta reikšmės, o ANOVA ir t kriterijaus *p* reikšmės sutaps. Dar reikėtų ištirti, ar tenkinamos regresijos prielaidos, t. y. įvykdyti komandas

```
avplot trust_all
rvfplot
predict r2, rstandard
estat hottest
histogram r2, frequency
normal pnorm r2
```

```
swilk r2
dfbeta trust_all
summarize DFtrust_all
predict Coo1, cooks
summarize Coo1
```

Nebepateiksime gautų rezultatų, tik konstatuosime, kad visos regresijos modelio prielaidos buvo tenkinamos.


2.3.5. Prognozės ir stebinių grafinis palyginimas

Sukuriame prognozuojamų *satisfaction* reikšmių stulpelį duomenyse (pavadiname jį *PRED*) įvykdydami komandą:

```
predict PRED
```

Braižydami grafiką, pasinaudosime duomenyse esančiu respondento identifikaciniu numeriu *idno*. Įvykdome:

```
graph twoway line satisfaction PRED idno
```



Kuo labiau sutampa linijos, tuo modelio prognozė tikslesnė. Matome, kad modelis gana geras.

2.3.6. Išvados

Regresijos aprašymas iš esmės nesiskiria nuo pateikto 2.2.5 skyrelio pabaigoje. Tik jį reikia papildyti informacija apie Breušo–Pagano ir Šapiro–Vilko kriterijus. Visas aprašymas turėtų apimti naujam modeliui pakartotą visą tyrimą. Lakoniškas aprašymas gali skambėti kad ir taip:

Tyrėme modelį $satisfaction = C + b1trust_al + b2happy + e$. Nors R^2 buvo pakankamai didelis, o abudu regresoriai statistiškai reikšmingi, tačiau standartizuotieji beta koeficientai ir

liekamųjų paklaidų grafikai rodė, kad regresoriaus *happy* įtaka priklausomam kintamajam *satisfaction* nėra stipri. Todėl regresorių *happy* iš modelio pašalinome. Determinacijos koeficiento reikšmė po regresoriaus *happy* pašalinimo sumažėjo tik per 0,03. Gautoji tiesinės regresijos lygtis atrodo taip: $satisfaction = 0,382 + 0,892 \text{ trust_all}$. Modelio $R^2 = 0,558$.

Visi duomenims keliami reikalavimai buvo tenkinami. Šapiro–Vilko kriterijus parodė, kad liekamųjų paklaidų normalumo prielaida tenkinama. Pritaikę Breušo–Pagano kriterijų įsitikinome, kad galioja ir homoskedastiškumo prielaida. DFBetų ir Kuko mato reikšmės leidžia teigti, kad duomenys neturėjo išskirčių.

2.3.7. Autokoreliacija

Tirtiesiems pavyzdžiams tai visiškai neaktualus klausimas, nes nebuvo jokio įtarimo, kad duomenyse gretimų respondentų atsakymai kažkaip susiję. Vis dėlto parodysime, kaip su STATA apskaičiuoti Durbino–Vatsono statistiką. Tam reikia turėti vadinamąjį laiko kintamąjį (dažnai tai metai, kada buvo atliktas matavimas, galimi ir niuansai, jeigu duomenys ketvirtiniai). Kadangi tokio kintamojo tiriamame faile nėra, dirbtinai apsiribojame pirmaisiais šimtu respondentų ($\text{keep if idno} < = 100$) ir pavadiname kintamąjį *idno* laiko kintamuoju:

```
tsset idno
```

Atlikę regresiją (`reg satisfaction trust_all`), įvykdome komandą

```
dwstat
```

Gautoji Durbino–Vatsono statistikos reikšmė (1,7496) yra pakankamai arti 2, todėl manome, kad autokoreliuotumo nėra. Primename, kad autokoreliuotumas mažai tikėtinas, jeigu Durbino–Vatsono statistika yra tarp 1,5 ir 2,5.

```
Number of gaps in sample: 4
```

```
Durbin-watson d-statistic( 2, 96) = 1.749634
```

Beje, **Number of gaps in sample** rodo, kad ne visos eilutės buvo panaudotos regresijoje (ne visoms turėjome duomenų ir apie *satisfaction*, ir apie *trust_all*).

2.3.8. Multikolinearumo problema

Pateiksime vieną kiek dirbtinį pavyzdį, parodantį, kaip multikolinearumas gali iškreipti tikrąsias kintamųjų priklausomybes. Sudarysime tiesinės regresijos modelį, regresuodami požiūrį į vyriausybę (*stfgov*) pagal požiūrį į parlamentą (*trstprl*) ir politikus (*trstplt*). Visiems kintamiesiems didesnė reikšmė rodo didesnę pasitikėjimą. Tiriame tuos pačius 20–40 metų Estijos vyrus kaip ir ankstesniuose skyreliuose. Sąlyginis regresijos modelis: $stfgov = f(trstprl, trstplt)$. Įvykdome:

```
keep if agea >= 20 & agea <= 40 & gndr == 1 & trstlgl < 11 & trstprl < 11
& trust_all < 11 reg trstlgl trstprl trust_all
```

Source	SS	df	MS	Number of obs = 238	
Model	1061.57205	2	530.786024	F(2, 235) =	230.31
Residual	541.587616	235	2.30462815	Prob > F =	0.0000
				R-squared =	0.6622
Total	1603.15966	237	6.76438677	Adj R-squared =	0.6593
				Root MSE =	1.5181

trstlgl	Coef.	Std. Err.	t	P> t	Beta
trstprl	-.2295373	.0847529	-2.71	0.007	-.2138819
trust_all	1.371896	.1089021	12.60	0.000	.9948559
_cons	.3296577	.2468893	1.34	0.183	.

Gautojo modelio $R^2 = 0,66$, ANOVA p reikšmė $< 0,05$. Pažvelkime į lentelę **Coefficients**. Pagal Stjudento kriterijų abudu regresoriai statistiškai reikšmingi ($p = 0,007$ ir $p = 0,000$). Atsižvelgę į lentelėje pateiktus koeficientų įverčius, gautume tokį modelį:

$$trstlgl = 0,33 - 0,23trspri + 1,372 trust_all.$$

Neigiamas koeficiento prie *trstprl* ženklas reiškia, kad *trstprl* didėjant, *trstlgl* mažėja. Kitaip tariant, kuo labiau respondentas pasitiki parlamentu, tuo mažiau pasitiki teisine sistema. Ši išvada prieštarauja pirmiau aptartai kintamųjų priklausomybei ir jų koreliacijos ženklui.

Atrodytų, kad modelis visai gerai tinka: determinacijos koeficientas $R^2 = 0,44$, ANOVA p reikšmė $= 0,000$; abudu regresoriai statistiškai reikšmingi (atitinkamos t kriterijaus p reikšmės yra 0,031 ir 0,000). Patikriname multikolinearumą:

estat vif

Variable	VIF	1/VIF
trstprl	4.34	0.230501
trust_all	4.34	0.230501
Mean VIF	4.34	

Matome, kad yra multikolinearumo problema (abudu VIF > 4). Taigi, nekreipdami dėmesio į didelias regresorių koreliacijas, galime padaryti klaidingas išvadas.

2.3.9. Žingsninė regresija

Parodysime, kaip atliekama žingsninė (pažingsninė, keliaetapė) regresija, nagrinėdami ESS4 Lietuvos duomenis. Tiriame visus 20–30 metų respondentus. Norime išsiaiškinti, nuo ko priklauso pasitikėjimas Seimu. Tirsime modelį

$$trstprl = C + b1\ stfeco + b2\ stflife + b3\ stfgov + b4\ stfdem + b5\ stfedu + b6\ stfhlth + e.$$

Čia *trstprl* yra pasitikėjimas parlamentu, *stfeco*, *stflife*, *stfgov*, *stfdem*, *stfedu*, *stfhlth* atitinkamai – pasitenkinimas ekonomika, gyvenimu apskritai, vyriausybe, demokratijos padėtimi, švietimo būkle, sveikatos apsauga. Visi kintamieji intervaliniai (0–9 arba 10), didesnė reikšmė rodo palankesnę požiūrį. Norima sužinoti, kuri sritis daro didesnę įtaką parlamento autoritetui. Panaudosime žingsninę regresiją. Žingsniuoti galima ir į priekį, ir atgal (akumuliuojant, kaupiant regresorius arba juos eliminuojant, šalinant). Todėl ir atitinkamų regresijų yra ne viena. Išbandysime du tokių regresijų modelius.

Duomenis *dta* formatu išsaugojome naudodami SPSS programą. Todėl, norėdami išvengti neteisingo praleistų reikšmių traktavimo, paliekame tik reikiamus respondentus:

```
keep if agea >= 20 & agea <= 30 & stfeco < 11 & trstprl < 11 & stflife < 11 &
stfgov < 11 & stfdem < 11 & stfedu < 11 & stfhlth < 11
```

Tyrimą pradėsime nuo regresijos, kai „žingsniuojama pirmyn ir tik pirmyn“, t. y. kai į modelį įtraukiami vis nauji statistiškai reikšmingi regresoriai (akumuliuojamoji, kaupiamoji regresija²⁴). Procesas baigiamas, kai neįtraukti lieka tik statistiškai nereikšmingi regresoriai. Įvykdome komandą:

```
sw reg trstprl stflife stfeco stfgov stfdem stfedu stfhlth, pe(0.05) beta
```

²⁴ Angl. *forward stepwise regression*.

Parinktis $pe(0.05)$ reiškia, kad į modelį bus įtraukti tik tie regresoriai, kuriems t kriterijaus p reikšmė mažesnė už 0,05.

. sw reg trstprl stflife stfeco stfgov stfdem stfedu stfhlth, pe(0.05) beta					
begin with empty model					
p =	0.0000	<	0.0500	adding	stfgov
p =	0.0009	<	0.0500	adding	stfdem
p =	0.0415	<	0.0500	adding	stflife
p =	0.0252	<	0.0500	adding	stfhlth

Source	SS	df	MS		
Model	436.987469	4	109.246867	Number of obs =	298
Residual	637.848101	293	2.17695598	F(4, 293) =	50.18
Total	1074.83557	297	3.61897498	Prob > F =	0.0000
				R-squared =	0.4066
				Adj R-squared =	0.3985
				Root MSE =	1.4755

trstprl	Coef.	Std. Err.	t	P> t	Beta
stfgov	.4374456	.0605192	7.23	0.000	.444568
stfdem	.1679884	.0465637	3.61	0.000	.2221915
stflife	-.0944838	.0400954	-2.36	0.019	-.1156208
stfhlth	.093558	.0415772	2.25	0.025	.1134544
_cons	.7043779	.2359976	2.98	0.003	.

Matome, kad modelis vis buvo pildomas, pridėdant naują regresorių. Į galutinį modelį nepakliuvo *stfedu* ir *stfeco*. Determinacijos koeficientas $R^2 = 0,41$. Užrašykime gautąją regresijos lygtį:

$$trstprl = 0,70 + 0,44 stfgov + 0,17 stfdem - 0,09 stflife + 0,09 stfhlth.$$

Tūlas politikas tokį rezultatą (neteisingai) gali interpretuoti taip: norint, kad jauno amžiaus rinkėjai labiau gerbtų parlamentą, reikia rūpintis sveikatos apsauga, puoselėti demokratiją ir prižiūrėti, kad gerai dirbtų vyriausybė (koeficientai prie šių regresorių yra teigiami). Be to, nėra ko labai stengtis, kad žmonės jaustųsi laimingi (koeficientas prie *stflife* neigiamas). Na o ekonomikos ir švietimo būklė požiūriui į parlamentą neturi įtakos (kintamieji buvo statistiškai nereikšmingi). Prie šios interpretacijos dar grįšime, o dabar tiems patiems duomenims pritaikykime kitą modelį.

Pasirinksime regresiją, kai „žingsniuojama atgal ir tik atgal“, t. y. kai pradėdama nuo modelio su visais regresoriais, laipsniškai po vieną vis šalinant statistiškai nereikšmingus iš jų (eliminuojamoji, šalinamoji regresija²⁵). Procesas baigiamas, kai modelyje lieka tik statistiškai reikšmingi regresoriai. Įvykdome:

```
sw reg trstprl stflife stfeco stfgov stfdem stfedu stfhlth, pr(0.05) beta
```

²⁵ Angl. *backward stepwise regression*.

Parinktis $pr(0.05)$ reiškia, kad iš modelio bus šalinami tie regresoriai, kuriems t kriterijaus p reikšmė ne mažesnė už 0,05.

```
. sw reg trstprl stflife stfeco stfgov stfdem stfedu stfhlth, pr(0.05) beta
begin with full model
p = 0.3668 >= 0.0500 removing stfeco
p = 0.1597 >= 0.0500 removing stfedu
```

Source	SS	df	MS	Number of obs = 298	
Model	436.987469	4	109.246867	F(4, 293) =	50.18
Residual	637.848101	293	2.17695598	Prob > F =	0.0000
				R-squared =	0.4066
				Adj R-squared =	0.3985
Total	1074.83557	297	3.61897498	Root MSE =	1.4755

trstprl	Coef.	Std. Err.	t	P> t	Beta
stflife	-.0944838	.0400954	-2.36	0.019	-.1156208
stfhlth	.093558	.0415772	2.25	0.025	.1134544
stfgov	.4374456	.0605192	7.23	0.000	.444568
stfdem	.1679884	.0465637	3.61	0.000	.2221915
_cons	.7043779	.2359976	2.98	0.003	.

Matome, kad modelis buvo vis siaurinamas šalinant regresorius. Gautasis modelis niekuo nesiskiria nuo ankstesnio (taip būna ne visada). Ramybės dėlei patikriname multikolinearumą. Įvykdome:

```
estat vif
```

Variable	VIF	1/VIF
stfdem	1.87	0.533968
stfgov	1.87	0.535419
stfhlth	1.26	0.796739
stflife	1.19	0.841321
Mean VIF	1.55	

Visų regresorių $VIF < 4$. Formaliai žiūrint, jokio kintamųjų multikolinearumo nėra.

Dabar įsitikinsime, kad modelis nėra teisingas. Pažiūrėkime kintamųjų koreliacijas. Įvykdome

```
pwcorr trstprl stflife stfeco stfgov stfdem stfedu stfhlth, sig
```

	trstprl	stflife	stfeco	stfgov	stfdem	stfedu	stfhlth
trstprl	1.0000						
stflife	0.1254 0.0305	1.0000					
stfeco	0.5148 0.0000	0.3677 0.0000	1.0000				
stfgov	0.6035 0.0000	0.2887 0.0000	0.7702 0.0000	1.0000			
stfdem	0.5098 0.0000	0.3715 0.0000	0.6197 0.0000	0.6522 0.0000	1.0000		
stfedu	0.2644 0.0000	0.3139 0.0000	0.3586 0.0000	0.3942 0.0000	0.4416 0.0000	1.0000	
stfhlth	0.3481 0.0000	0.2651 0.0000	0.4331 0.0000	0.4176 0.0000	0.3583 0.0000	0.6456 0.0000	1.0000

Matome, kad *trstprl* su visais kintamaisiais koreliuoja *teigiamai*, tačiau koreliacija su *stflife* yra silpna ir statistiškai nereikšminga (jei reikšmingumo lygmuo 0,05). Be to, atsiminkime, kad regresijos koeficiento įverčio reikšmė artima nuliui, o ir *p* reikšmė tikrinant jo reikšmingumą nėra maža. Taigi regresijos modelyje ženklas prie *stflife* nėra įtikinamas (ir politiko išvada, kad geriau, kai respondentai nelaimingi). Įdomu, kad eliminuojamojoje regresijoje parinkus kitą reikšmingumo slenkstį ($p=0,02$) jis lieka su dviem regresoriais ir visai tinkamas: $R^2 = 0,3877$ (o buvo $R^2 = 0,407$).

sw reg trstprl stflife stfeco stfgov stfdem stfedu stfhlth, pr(0.02) beta

Source	SS	df	MS	Number of obs = 298		
Model	416.715533	2	208.357766	F(2, 295) = 93.40		
Residual	658.120038	295	2.23091538	Prob > F = 0.0000		
Total	1074.83557	297	3.61897498	R-squared = 0.3877		
				Adj R-squared = 0.3836		
				Root MSE = 1.4936		

trstprl	Coef.	Std. Err.	t	P> t	Beta
stfgov	.4639935	.0591364	7.85	0.000	.4715481
stfdem	.1529409	.0454382	3.37	0.001	.2022889
_cons	.535498	.1457544	3.67	0.000	.

Dabar pažiūrime, kaip atrodo modelis, kai *trstprl* regresuojame pagal *stfeco*
reg trstprl stfeco.

. reg trstprl stfeco						
Source	SS	df	MS			
Model	284.900997	1	284.900997	Number of obs = 298		
Residual	789.934573	296	2.66869788	F(1, 296) = 106.76		
				Prob > F = 0.0000		
				R-squared = 0.2651		
				Adj R-squared = 0.2626		
				Root MSE = 1.6336		
Total	1074.83557	297	3.61897498			
trstprl	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
stfeco	.5110578	.0494621	10.33	0.000	.4137158	.6083998
_cons	.889902	.1448872	6.14	0.000	.6047625	1.175042

Nors šis modelis ir blogiau tinka nei ankstesnieji, bet visai jo atmesti negalima. Jeigu politikas būtų pradėjęs tyrimą nuo šio modelio, tai darytų išvadą, kad pasitikėjimas parlamentu didėja, kai gerėja ekonominė situacija.

Kokią išvadą galima padaryti iš pateiktų pavyzdžių? Kad ir kokią regresiją pasirinktume, gautą modelį reikia įvertinti kritiškai, būtina pažiūrėti koreliacijas ir pamąstyti apie modelio suderinamumą su sveiku protu (žinoma teorija, ankstesniais tyrimais ir pan.)

Atlikus žingsninę regresiją, būtina patikrinti modelio logiškumą.
Neapsiriboti formaliais statistikos rodikliais.

2.4. Tiesinė regresinė analizė su SAS

2.4.1. Duomenys

Tirsime tuos pačius duomenis kaip ir SPSS bei STATA atveju. Tiriamo 2008 metų Europos Sąjungos socialinio tyrimo (*European Social Survey*) Estijos duomenis ESS4EE. Mus domins, kaip pasitenkinimas politiniu šalies klimatu susijęs su pasitikėjimu politinėmis institucijomis ir bendruoju žmogaus laimingumu. Tirsime 20–40 metų vyrus. Tyrime naudosime tokius kintamuosius:

- *satisfaction* (pasitenkinimas šalies politiniu klimatu),
- *trust_all* (pasitikėjimas politinėmis institucijomis),
- *happy* (laimingumas).

Kintamasis *satisfaction* sukurtas paėmus kintamųjų *stfgov* (kiek respondentas patenkintas savo šalies vyriausybe) ir *stfdem* (kiek respondentas patenkintas demokratijos būseną šalyje) vidurkį. Jis įgyja reikšmes nuo 0 (itin nepatenkintas) iki 10 (labai patenkintas). Kintamasis

trust_all sukurtas, suskaičiavus kintamųjų *trstprl* (pasitikėjimas šalies parlamentu), *trstlgl* (pasitikėjimas teisine sistema), *trstplt* (pasitikėjimas politikais), *trstprt* (pasitikėjimas partijomis), *trstun* (pasitikėjimas Jungtinėmis Tautomis) vidurkį ir įgyja reikšmes nuo 0 (itin nepasitiki) iki 9 (itin pasitiki). Kintamasis *happy* matuojamas 10 balų skale nuo 0 (itin nelaimingas) iki 9 (itin laimingas).

Reikiamus respondentus atsirinksime, atsižvelgę į *agea* (amžių) ir *gndr* (lytį, 1 – vyr., 2 – mot.). Pradiniai duomenys saugomi SAS duomenų bibliotekoje **rgr**. Toliau pateiksime SAS komandų seką (scenarijų), kaip parengti duomenis regresinei analizei:

```
OPTIONS nofmterr;  
data Esta;  
set rgr.ESS4EE_s;  
keep idno agea gndr happy trust_all satisfaction;  
if 20 <= agea <=40 and gndr=1 and happy<11 and satisfaction <11 ;  
run;
```

Tiesinė regresija turi prasmę tik tada, kai intervaliniai regresoriai pakankamai stipriai koreliuoja su priklausomu kintamuoju, ir pakankamai silpnai tarpusavyje. Patikriname kintamųjų koreliacijas įvykdę procedūrą:

```
proc corr data=Esta;  
var satisfaction happy trust_all;  
run;
```

Gauta koreliacijų lentelė rodo stiprią teigiamą *satisfaction* ir *trust_all* koreliaciją ($r = 0,74704$) ir vidutinę teigiamą *satisfaction* ir *happy* koreliaciją ($r = 0,39469$). Patys regresoriai *happy* ir *trust_all* koreliuoja silpnai ($r = 0,28808$). Multikolinearumo problema neturėtų iškilti. Visos koreliacijos yra statistiškai reikšmingos (visos p reikšmės $< 0,0001$).

Pearson Correlation Coefficients Prob > r under H0: Rho=0 Number of Observations			
	satisfaction	happy	trust_all
satisfaction satisfaction	1.00000 243	0.39469 <.0001 242	0.74704 <.0001 242
happy How happy are you	0.39469 <.0001 242	1.00000 245	0.28808 <.0001 242
trust_all trust_all	0.74704 <.0001 242	0.28808 <.0001 242	1.00000 243

2.4.2. Regresijos modelio lygtis

Analizuosime tokį regresijos modelį $satisfaction = C + b_1trust_al + b_2happy + e$. SAS universali ir lanksti programa. Regresinę analizę galima atlikti naudojant įvairias procedūras. Čia aprašysime tik procedūros *reg* taikymą. Pateiksime scenarijų, kurį įvykdę gauname ir modelio aprašymą, ir diagnostiką (sakinyje *model* nurodomos parinktys *stb*, *partial*, *spec*, *vif*), tačiau rezultatus aprašysime nuosekliai. Įvykdome:

```
proc reg data=Esta;
model satisfaction = happy trust_all / stb partial spec vif;
run;
```

Pirmiausia rezultatų išklotinėje pateikiama pagrindinė informacija apie modelį. Determinacijos koeficientas (**R-Square**) $R^2 = 0,5898$ yra pakankamai didelis.

Analysis of Variance					
Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	2	716.42008	358.21004	171.13	<.0001
Error	238	498.18158	2.09320		
Corrected Total	240	1214.60166			

Root MSE	1.44679	R-Square	0.5898
Dependent Mean	4.05187	Adj R-Sq	0.5864
Coeff Var	35.70674		

Parameter Estimates								
Variable	Label	DF	Parameter Estimate	Standard Error	t Value	Pr > t	Standardized Estimate	Variance Inflation
Intercept	Intercept	1	-0.84680	0.35906	-2.36	0.0192	0	0
happy	How happy are you	1	0.22608	0.05155	4.39	<.0001	0.19076	1.09805
trust_all	trust_all	1	0.82415	0.05202	15.84	<.0001	0.68912	1.09805


Užrašykime regresijos lygtį:

$$satisfaction = -0,847 + 0,824 \text{ trust_all} + 0,226 \text{ happy}$$

ANOVA p reikšmė yra pirmos lentelės paskutiniame stulpelyje **Pr > F**. Ji mažesnė už 0,05. Taigi modelyje yra statistškai reikšmingų regresorių. Iš **Parameter Estimates** lentelės matyti, kad abudu regresoriai yra statistškai reikšmingi, nes jiems t kriterijaus p reikšmės (jos yra stulpelyje **Pr>|t|**) mažesnės už 0,05.

Norėdami nustatyti, kuris kintamasis modelyje yra *įtakingesnis*, turime pasižiūrėti į koeficientų lentelės **Standardized Estimate** stulpelį.

Regresorius *trust_all* (jo beta koeficientas 0,689) yra daug įtakingesnis nei *happy* (beta 0,191). Papildomai peržiūrėkime liekamųjų paklaidų grafikus kiekvienam regresoriui. Gautuose grafikuose matyti aiški tiesinė priklausomybė ir didesnis regresijos tiesės posvyrio kampas regresoriui *trust_all*. O regresoriui *happy* tokios akivaizdžios priklausomybės nematyti (apie tokių grafikų interpretavimą žr. 2.1.4 sk.).



Taigi pagrindinės modelio charakteristikos rodo gerą jo tinkamumą duomenims. Vis dėlto regresoriaus *happy* reikalingumas modelyje yra abejotinas.


2.4.3. Regresijos prielaidų tikrinimas

Dar reikia patikrinti modelio prielaidas, t. y. ar:


- liekamosios paklaidos homoskedastiškos,
- liekamosios paklaidos normalios,
- nėra išskirčių,
- regresoriai nėra multikolinearūs.

Norėdami patikrinti, ar tenkinamos modelio prielaidos, pažiūrėkime į diagnostikos grafikus (jie spausdinami, įvykdžius pirmiau pateiktą procedūrą). Kelis svarbius grafikus ir papildomų kriterijų rezultatus aptarsime vėliau.

Fit Diagnostics for satisfaction



Residual by Regressors for satisfaction



Homoskedastiškos liekamosios paklaidos turėtų būti išsibarsčiusios tolygiai palei x ašį (grafikai turėtų priminti juostelę). Šiuo atveju tai nėra akivaizdu (1 ir 2 grafikai). Taigi reikia papildomai – „ne iš akies“ patikrinti homoskedastiškumo prielaidą.

Patikrinsime, ar paklaidos homoskedastiškos, pažiūrėję Vaito (White) kriterijaus, kuris yra modifikuotas Breušo–Pagano kriterijus, rezultatus lentelėje **Test of First and Second Moment Specification**. Nulinė šio kriterijaus hipotezė teigia, kad homoskedastiškumo prielaida galioja. Homoskedastiškiems duomenims p reikšmė turi būti **ne mažesnė** už 0,05.


Test of First and Second Moment Specification		
DF	Chi-Square	Pr > ChiSq
5	9.96	0.0764

Gautoji chi kvadrato statistikos reikšmė yra 9,96, o $p = 0,0764 \geq 0,05$. Darome išvadą, kad duomenys statistškai reikšmingai neprieštarauja homoskedastiškumo prielaidai.

Norime atkreipti dėmesį, kad p reikšmės gali būti mažos vien dėl imties didumo. Todėl visada reikia atsižvelgti ir į chi kvadrato statistikos reikšmę (homoskedastiškiems duomenims ji maža) ir į liekamųjų paklaidų grafikus.

Tikrindami liekamųjų paklaidų normalumą, nubraižysime liekamųjų paklaidų histogramą (ji turėtų būti panaši į normaliąją kreivę) ir kvantilių Q–Q grafiką (grafiko taškai turi nedaug skirtis nuo tiesės) bei patikrinsime paklaidų normalumą Šapiro–Vilko kriterijumi. Nulinė hipotezė teigia, kad paklaidos normalios. Normalumo prielaida nepatenkinta, jeigu $p < 0,05$. Įvykdome:

```
proc reg data=Esta;
    model satisfaction = happy trust_all /noprint;
    output out=res r=r;
run; quit;
proc univariate data=res normal;
    var r;
    qqplot /normal (mu=est sigma=est) ;
    histogram/ kernel;
run;
```




Matome, kad ir histograma, ir kvantilių grafikas rodo liekamųjų paklaidų normalumą (nors Q–Q grafiko taškai galuose truputį nutolę nuo tiesės).


Tests for Normality				
Test	Statistic		p Value	
Shapiro-Wilk	W	0.992489	Pr < W	0.2601
Kolmogorov-Smirnov	D	0.038196	Pr > D	>0.1500
Cramer-von Mises	W-Sq	0.042479	Pr > W-Sq	>0.2500
Anderson-Darling	A-Sq	0.307658	Pr > A-Sq	>0.2500

Sprendžiant iš Šapiro–Vilko kriterijaus rezultatų (lentelė **Tests for Normality**), liekamosios paklaidos turi normalųjį skirstinį ($p = 0,2601 > 0,05$). Beje, tą patį patvirtina ir kitų kriterijų rezultatai. Kaip ir tikrinant homogeniškumą, reikia nepamiršti, kad p reikšmės gali būti mažos vien dėl imties didumo. Todėl visada reikia atsižvelgti ir į grafikus.

Patikrinsime, ar duomenyse nebuvo išskirčių. Atsižvelgsime į regresorių DFBetų reikšmes ir į Kuko matą.

```
proc reg data=Esta
  plots(label)=(CooksD RStudentByLeverage DFFITS DFBETAS);
  model satisfaction = happy trust_all;
run;
```





Įsitikiname, kad tiek $DFBet_u$, tiek Kuko mato reikšmės neviršija vieneto. Darome išvadą, kad duomenyse išskirčių nėra.

Galimas kintamųjų multikolinearumas tikrinamas atsižvelgiant į dispersijos mažėjimo daugiklius VIF. Jie yra **Parameter Estimates** lentelės (ji įdėta pakartotinai) paskutiniame stulpelyje (gaunamas **model** sakinyje nurodžius parinktį **vif**).

Multikolinearumo problema kyla, jeigu yra $VIF > 4$. Abiem regresoriams $VIF = 1,09805$. Todėl darome išvadą, kad kintamųjų multikolinearumo nėra.

Parameter Estimates								
Variable	Label	DF	Parameter Estimate	Standard Error	t Value	Pr > t	Standardized Estimate	Variance Inflation
Intercept	Intercept	1	-0.84680	0.35906	-2.36	0.0192	0	0
happy	How happy are you	1	0.22608	0.05155	4.39	<.0001	0.19076	1.09805
trust_all	trust_all	1	0.82415	0.05202	15.84	<.0001	0.68912	1.09805

2.4.4. Galutinis modelis

Ankstesniuose skyreliuose įsitikinome, kad regresijos modelis gerai aprašo duomenis. Vis dėlto nedidelė *happy* ir *satisfaction* koreliacija, maža beta koeficiento reikšmė kintamajam *happy* ir netiesinis liekanų išsibastymo grafikas kelia abejonių šio regresoriaus reikalingumu. Todėl patikriname regresijos modelį be jo.

```
proc reg data=Esta;
    model satisfaction = trust_all;
run;
```

Matome, kad naujojo modelio $R^2 = 0,5581$ nuo ankstesniojo $R^2 = 0,5898$ skiriasi tik per 0,0317, t. y. determinacijos koeficientas sumažėjo labai nedaug.

Analysis of Variance					
Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	1	681.16839	681.16839	303.08	<.0001
Error	240	539.40185	2.24751		
Corrected Total	241	1220.57025			

Root MSE	1.49917	R-Square	0.5581
Dependent Mean	4.06198	Adj R-Sq	0.5562
Coeff Var	36.90731		

Parameter Estimates						
Variable	Label	DF	Parameter Estimate	Standard Error	t Value	Pr > t
Intercept	Intercept	1	0.37854	0.23250	1.63	0.1048
trust_all	trust_all	1	0.89421	0.05136	17.41	<.0001

Darome išvadą, kad regresorių *happy* iš modelio galima pašalinti. *Nepaisant to, kad jis buvo statistiškai reikšmingas*. Užrašykime gautąją regresijos lygtį:

$$satisfaction = 0,379 + 0,894 \text{ trust_all}.$$

Naujajame modelyje liko tik vienas regresorius, todėl nebereikia tikrinti multikolinearumo, nebereikia aprašinėti standartizuotosios beta reikšmės, o ANOVA ir t testo p reikšmės sutaps. Dar reikėtų ištirti, ar tenkinamos regresijos prielaidos, t. y. įvykdyti:

```
proc reg data=Esta;
model satisfaction = trust_all /noprint;
output out=res r=r;
run; quit;

proc univariate data=res normal; var r;
qqplot /normal (mu=est sigma=est) ;
histogram/ kernel;
run;
```

```
proc reg data=Esta
plots(label)=(CooksD
RStudentByLeverage DFFITS DFBETAS);
model satisfaction = happy trust_all;
run;
```


Nebepateiksime gautųjų rezultatų, tik konstatuosime, kad visos regresijos modelio prielaidos buvo tenkinamos.

2.4.5. Prognozės ir stebinių grafinis palyginimas

Galima grafiškai palyginti stebėtas *satisfaction* reikšmes su reikšmėmis, gautomis prognozei pritaikius pirmiau aprašytąjį regresijos modelį. Braižydami grafiką pasinaudosime duomenyse esančiu respondento identifikaciniu numeriu *idno*. Įvykdome:

```
proc reg data=Esta;
model satisfaction = happy trust_all /noprint;
output out=new p=pred;
run;quit;
data nauj;
set new;
id=_N_;
if _N_ le 20;
run;

proc gplot data=nauj;
symbol i=spline v=circle h=2 pointlabel=("#idno");
plot satisfaction*id pred*id / overlay;
run;
```



Reikia pažymėti, kad grafike pateikta tik 20 reikšmių porų. Kai stebinių labai daug, ką nors įžiūrėti grafike yra sunku. Kuo labiau sutampa linijos, tuo modelio prognozės tikslesnės. Tokie grafikai beveik visada pridedami, kai tiriami laikiniai duomenys (pvz., BVP kitimas ketvirčiais) ir jų nėra daug. Socialiniuose tyrimuose panašūs grafikai braižomi retai.

2.4.6. Išvados

Regresijos aprašymas iš esmės nesiskiria nuo pateiktojo 2.4.5 skyrelio pabaigoje. Lakoniškas aprašymas gali skambėti, kad ir taip:

Tyrėme modelį $satisfaction = C + b_1 trust_all + b_2 happy + e$. Nors R^2 buvo pakankamai didelis, o abudu regresoriai statistiškai reikšmingi, tačiau standartizuotieji beta koeficientai ir liekamųjų paklaidų grafikai rodė, kad regresoriaus $happy$ įtaka kintamajam $satisfaction$ nėra stipri. Todėl regresorių $happy$ iš modelio pašalinome. Determinacijos koeficiento reikšmė pašalinus regresorių $happy$ sumažėjo tik per 0,03. Gautoji tiesinės regresijos lygtis atrodo taip: $satisfaction = 0,382 + 0,892 trust_all$. Modelio $R^2 = 0,558$.

Visi duomenims keliami reikalavimai buvo tenkinami. Šapiro–Vilko kriterijus parodė, kad liekamųjų paklaidų normalumo prielaida tenkinama. Pritaikę White kriterijų (modifikuotą Breušo–Pagano kriterijų) įsitikinome, kad galioja ir homoskedastiškumo prielaida. DFBetų ir Kuko mato reikšmės leidžia teigti, kad duomenyse nebuvo išskirčių.

2.4.7. Autokoreliacija

Tirtiesiems pavyzdžiams tai visiškai neaktualus klausimas, nes nebuvo jokio įtarimo, kad duomenyse gretimų respondentų atsakymai kažkaip susiję (t. y. duomenys NĖRA laikiniai). Vis dėlto parodysimė, kaip su SAS apskaičiuoti Durbino–Vatsono statistiką (galutiniam praėjusio skyrelio modeliui):

```
proc reg data=Esta;
    model satisfaction = trust_all /dwProb;
run;
```

Gautoji Durbino–Vatsono statistikos reikšmė (2,043) yra pakankamai arti 2, todėl manome, kad autokoreliuotumo nėra. Primename, kad autokoreliuotumas mažai tikėtinas, jeigu Durbino–Vatsono statistika yra tarp 1,5 ir 2,5.

Durbin-Watson D	2.043
Pr < DW	0.6312
Pr > DW	0.3688
Number of Observations	242
1st Order Autocorrelation	-0.024

Note: Pr<DW is the p-value for testing positive autocorrelation, and Pr>DW is the p-value for testing negative autocorrelation.

2.4.8. Multikolinearumo problema

Primename, kad labai koreliuojantys (multikolinearūs) regresoriai gali sukelti problemų. Modelis tampa nestabilus, gali atsirasti neteisingų priklausomybių. Pateiksime vieną kiek dirbtinį pavyzdį, parodantį, kaip multikolinearumas gali iškreipti tikrąsias kintamųjų priklausomybes. Analizuosime tiesinės regresijos modelį $trstlgl = C + b1 \ trstpr + b2 \ trust_all + e$. Įvykdome


```

OPTIONS nofmterr;
data Dse;
data Esta;
keep trstlgl trstprl trust_all;
set rgr.ESS4EE_s;
if 20 <= agea <=40 and gndr=1 and trstlgl <11 AND trstprl < 11 AND trust_all < 11
AND (trstlgl ne .) AND trstprl ne . and trust_all ne .;
run;
proc reg data= Esta;
model trstlgl=trstprl trust_all / vif;
run;
proc corr data=Esta;
var trstlgl trstprl trust_all;
run;

```

Koreliacija tarp *trstlgl* ir *trstprl* yra 0,659, t. y. priklausomybė tiesioginė – kuo vieno kintamojo reikšmė didesnė, tuo didesnė ir kito kintamojo reikšmė. Kitaip sakant, tie respondentai, kurie labiau pasitiki parlamentu, yra labiau linkę pasitikėti ir teisine sistema. Į modelį įtraukėme ir stipriai su abiem kintamaisiais koreliuojantį (visai natūralu, nes abudu kintamieji buvo naudoti jį sudarant) kintamąjį *trust_all*. Koreliacija tarp *trust_all* ir *trstprl* yra labai stipri ir lygi 0,877.

Gautojo modelio $R^2 = 0,66$, ANOVA p reikšmė $< 0,05$. Pagal Stjudento kriterijų abudu kintamieji statistiškai reikšmingi ($p = 0,005$ ir $p = 0,000$). Taip pat matome, kad yra multikolinearumo problema (abudu $VIF > 4$). Kas įvyktų, jeigu į multikolinearumą nekreiptume dėmesio? Atsižvelgę į rezultatų išklotinėje pateiktus koeficientų įverčius, gautume tokią regresijos lygtį:

$$trstlgl = 0,33 - 0,24 trstprl + 1,38 trust_all.$$

Neigiamas koeficiento prie *trstprl* ženklas reiškia, kad *trstprl* didėjant, *trstlgl* mažėja. Kitaip tariant, kuo labiau respondentas pasitiki parlamentu, tuo mažiau pasitiki teisine sistema. Ši išvada prieštarauja pirmiau aptartai kintamųjų priklausomybei ir jų koreliacijos ženklui. Taigi nekreipdami dėmesio į stiprias regresorių koreliacijas, galime padaryti labai klaidingas išvadas.

Number of Observations Read	238
Number of Observations Used	238

Analysis of Variance					
Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	2	1061.57205	530.78602	230.31	<.0001
Error	235	541.58762	2.30463		
Corrected Total	237	1603.15966			

Root MSE	1.51810	R-Square	0.6622
Dependent Mean	5.10924	Adj R-Sq	0.6593
Coeff Var	29.71282		

Parameter Estimates							
Variable	Label	DF	Parameter Estimate	Standard Error	t Value	Pr > t	Variance Inflation
Intercept	Intercept	1	0.32966	0.24689	1.34	0.1831	0
trstprl	Trust in country's parliament	1	-0.22954	0.08475	-2.71	0.0073	4.33837
trust_all	trust_all	1	1.37190	0.10890	12.60	<.0001	4.33837

Simple Statistics							
Variable	N	Mean	Std Dev	Sum	Minimum	Maximum	Label
trstlgl	238	5.10924	2.60084	1216	0	10.00000	Trust in the legal system
trstprl	238	3.84034	2.42345	914.00000	0	10.00000	Trust in country's parliament
trust_all	238	4.12647	1.88605	982.10000	0	9.20000	trust_all

Pearson Correlation Coefficients, N = 238 Prob > r under H0: Rho=0			
	trstlgl	trstprl	trust_all
trstlgl Trust in the legal system	1.00000	0.65882 <.0001	0.80724 <.0001
trstprl Trust in country's parliament	0.65882 <.0001	1.00000	0.87721 <.0001
trust_all trust_all	0.80724 <.0001	0.87721 <.0001	1.00000

2.4.9. Žingsninė regresija

Parodysime, kaip atliekama žingsninė (pažingsninė, keliaetapė) regresija, nagrinėdami ESS4 Lietuvos duomenis. Tiriame visus 20–30 metų respondentus. Norime išsiaiškinti, nuo ko priklauso pasitikėjimas Seimu. Tirsime modelį

$$trstpri = C + b1 stfeco + b2 stflife + b3 stfgov + b4 stfdem + b5 stfedu + b6 stfhlth + e.$$

Čia *trstpri* yra pasitikėjimas parlamentu, *stfeco*, *stflife*, *stfgov*, *stfdem*, *stfedu*, *stfhlth* atitinkamai – pasitenkinimas ekonomika, gyvenimu apskritai, vyriausybe, demokratijos padėtimi, švietimo būkle, sveikatos apsauga. Visi kintamieji intervaliniai (0–9 arba 10), didesnė reikšmė rodo palankesnę poziciją. Norima sužinoti, kuri sritis daro didesnę įtaką parlamento autoritetui. Panaudosime žingsninę regresiją. Žingsniuoti galima ir į priekį, ir atgal (akumuliuojant, kaupiant kintamuosius arba juos eliminuojant). Todėl ir atitinkamų regresijų yra ne viena. Išbandysime du tokių regresijų modelius.

Duomenis įkeliame iš SAS **rgr** bibliotekos. Todėl, norėdami išvengti neteisingo praleistų reikšmių traktavimo, paliekame tik atsakiusių į visus parinktus klausimus respondentų duomenis:

```
data Lta;
set rgr.ESS4LT1_s;
if agea >= 20 AND agea <= 30 AND stfeco < 11 AND trstpri < 11 AND stflife < 11 AND
stfgov < 11 AND stfdem < 11 AND stfedu < 11 AND stfhlth < 11 ;
run;
```

Žingsninei regresijai naudosime SAS **stepwise** procedūrą. Tyrimą pradėsime nuo regresijos, kai „žingsniuojama pirmyn ir tik pirmyn“, t. y. kai į modelį įtraukiami vis nauji statistiškai reikšmingi regresoriai (akumuliuojamoji, kaupiamoji regresija). Procesas baigiamas, kai neįtraukti lieka tik statistiškai nereikšmingi regresoriai. Įvykdome:

```
proc stepwise;
model trstpri = stflife stfeco stfgov stfdem stfedu stfhlth / selection=forward
slentry=0.05;
run;;
```

Parinktis *slentry* = 0,05 reiškia, kad į modelį bus įtraukti tik tie regresoriai, kuriems *t* kriterijaus *p* reikšmė mažesnė už 0,05.

Forward Selection: Step 4

Variable	Parameter Estimate	Standard Error	Type II SS	F Value	Pr > F
Intercept	0.70438	0.23600	19.39304	8.91	0.0031
stflife	-0.09448	0.04010	12.08860	5.55	0.0191
stfgov	0.43745	0.06052	113.73964	52.25	<.0001
stfdem	0.16799	0.04656	28.33429	13.02	0.0004
stfhlth	0.09356	0.04158	11.02302	5.06	0.0252

Bounds on condition number: 1.8728, 24.737

No other variable met the 0.0500 significance level for entry into the model.

Summary of Forward Selection								
Step	Variable Entered	Label	Number Vars In	Partial R-Square	Model R-Square	C(p)	F Value	Pr > F
1	stfgov	How satisfied with the national government	1	0.3642	0.3642	20.7831	169.55	<.0001
2	stfdem	How satisfied with the way democracy works in country	2	0.0235	0.3877	11.1410	11.33	0.0009
3	stflife	How satisfied with life as a whole	3	0.0086	0.3963	8.8808	4.19	0.0415
4	stfhlth	State of health services in country nowadays	4	0.0103	0.4066	5.8034	5.06	0.0252

Matome, kad modelis vis buvo pildomas, pridėdant naują regresorių (keturi žingsniai). Į galutinį modelį nepakliuvo *stfedu* ir *stfeco*. Determinacijos koeficientas $R^2 = 0,4066$. Užrašykime gautąją regresijos lygtį:

$$trstprl = 0,70 + 0,44 \text{ stfgov} + 0,17 \text{ stfdem} - 0,09 \text{ stflife} + 0,09 \text{ stfhlth}.$$

Tūlas politikas tokį rezultatą (neteisingai) gali interpretuoti taip: norint, kad jauno amžiaus rinkėjai labiau gerbtų parlamentą, reikia rūpinantis sveikatos apsauga, puoselėti demokratiją ir prižiūrėti, kad gerai dirbtų vyriausybė (koeficientai prie šių regresorių yra teigiami). Be to, nėra ko labai stengtis, kad žmonės jaustųsi laimingi (koeficientas prie *stflife* neigiamas). Na o ekonomikos ir švietimo būklė neturi įtakos požiūriui į parlamentą (kintamieji buvo statistiškai nereikšmingi). Prie šios interpretacijos grįšime, o dabar tiems patiems duomenims pritaikysime kitą modelį.

Pasirinksime regresiją, kai „žingsniuojama atgal ir tik atgal“, t. y. kai pradėdama nuo modelio su visais regresoriais, laipsniškai po vieną vis šalinant statistiškai nereikšmingus iš jų (eliminuojamieji, šalinamieji regresija). Procesas baigiamas, kai modelyje lieka tik statistiškai reikšmingi regresoriai. Įvykdome procedūrą (papildomai nurodome parinktį *vif* multikolinearumui patikrinti):

```
proc stepwise;
    model trstprl = stflife stfeco stfgov stfdem stfedu stfhlth / selection=backward vif
    slstay=0.05;
run;
```

Parinktis slstay = 0,05 reiškia, kad iš modelio bus šalinami tie regresoriai, kuriems t kriterijaus p reikšmė ne mažesnė už 0,05.

Summary of Backward Elimination								
Step	Variable Removed	Label	Number Vars In	Partial R-Square	Model R-Square	C(p)	F Value	Pr > F
1	stfeco	How satisfied with present state of economy in country	5	0.0017	0.4106	5.8171	0.82	0.3668
2	stfedu	State of education in country nowadays	4	0.0040	0.4066	5.8034	1.99	0.1597

Parameter Estimates							
Variable	Label	DF	Parameter Estimate	Standard Error	t Value	Pr > t	Variance Inflation
Intercept	Intercept	1	0.70438	0.23600	2.98	0.0031	0
stflife	How satisfied with life as a whole	1	-0.09448	0.04010	-2.36	0.0191	1.18861
stfgov	How satisfied with the national government	1	0.43745	0.06052	7.23	<.0001	1.86770
stfdem	How satisfied with the way democracy works in country	1	0.16799	0.04656	3.61	0.0004	1.87277
stfhlth	State of health services in country nowadays	1	0.09356	0.04158	2.25	0.0252	1.25512

Matome, kad modelis vis buvo siaurinamas, šalinant regresorius (du žingsniai). Gautasis modelis niekuo nesiskiria nuo ankstesnio (taip būna ne visada). Visų regresorių VIF < 4. Taigi formaliai žiūrint, jokio kintamųjų multikolinearumo nėra.

Dabar įsitikinsime, kad modelis nėra patikimas. Pažiūrėkime kintamųjų koreliacijas. Įvykdome

```
Proc corr;
var trstprl stflife stfeco stfgov stfdem stfedu stfhlth;
run;
```

Pearson Correlation Coefficients Prob > r under H0: Rho=0 Number of Observations							
	trstprl	stflife	stfeco	stfgov	stfdem	stfedu	stfhlth
trstprl Trust in country's parliament	1.00000 324	0.10503 0.0594 323	0.52643 <.0001 323	0.61135 <.0001 321	0.51188 <.0001 317	0.26383 <.0001 306	0.33048 <.0001 314
stflife How satisfied with life as a whole	0.10503 0.0594 323	1.00000 324	0.34647 <.0001 324	0.26058 <.0001 322	0.35661 <.0001 318	0.31395 <.0001 307	0.27855 <.0001 315
stfeco How satisfied with present state of economy in country	0.52643 <.0001 323	0.34647 <.0001 324	1.00000 324	0.76705 <.0001 322	0.62172 <.0001 318	0.35546 <.0001 307	0.41486 <.0001 315
stfgov How satisfied with the national government	0.61135 <.0001 321	0.26058 <.0001 322	0.76705 <.0001 322	1.00000 322	0.63884 <.0001 317	0.39474 <.0001 305	0.40760 <.0001 313
stfdem How satisfied with the way democracy works in country	0.51188 <.0001 317	0.35661 <.0001 318	0.62172 <.0001 318	0.63884 <.0001 317	1.00000 318	0.44524 <.0001 302	0.35535 <.0001 309
stfedu State of education in country nowadays	0.26383 <.0001 306	0.31395 <.0001 307	0.35546 <.0001 307	0.39474 <.0001 305	0.44524 <.0001 302	1.00000 307	0.64751 <.0001 305
stfhlth State of health services in country nowadays	0.33048 <.0001 314	0.27855 <.0001 315	0.41486 <.0001 315	0.40760 <.0001 313	0.35535 <.0001 309	0.64751 <.0001 305	1.00000 315

Matome, kad *trstprl* su visais kintamaisiais koreliuoja *teigiamai*, tačiau koreliacija su *stflife* yra silpna ir statistiškai nereikšminga (jei reikšmingumo lygmuo 0,05). Be to, atsiminkime, kad regresijos koeficiento įverčio reikšmė artima nuliui, o ir *p* reikšmė tikrinant jo reikšmingumą nėra maža. Taigi regresijos modelyje ženklas prie *stflife* nėra įtikinamas (ir politiko išvada, kad geriau, kai respondentai nelaimingi). Įdomu, kad eliminuojamoje regresijoje parinkus kitą reikšmingumo slenkstį ($p = 0,02$) jis lieka su dviem regresoriais ir visai tinkamas: $R^2 = 0,3877$ (o buvo $R^2 = 0,407$).

```
proc stepwise;
```

```
    model trstprl = stflife stfeco stfgov stfdem stfedu stfhlth / selection=backward vif  
    slstay=0.02;
```

```
run;
```

Variable	Parameter Estimate	Standard Error	Type II SS	F Value	Pr > F
Intercept	0.53550	0.14575	30.11310	13.50	0.0003
stfgov	0.46399	0.05914	137.34007	61.56	<.0001
stfdem	0.15294	0.04544	25.27488	11.33	0.0009

Summary of Backward Elimination								
Step	Variable Removed	Label	Number Vars In	Partial R-Square	Model R-Square	C(p)	F Value	Pr > F
1	stfeco	How satisfied with present state of economy in country	5	0.0017	0.4106	5.8171	0.82	0.3668
2	stfedu	State of education in country nowadays	4	0.0040	0.4066	5.8034	1.99	0.1597
3	stfhlth	State of health services in country nowadays	3	0.0103	0.3963	8.8808	5.06	0.0252
4	stflife	How satisfied with life as a whole	2	0.0086	0.3877	11.1410	4.19	0.0415

Dabar pažiūrime, kaip atrodo modelis, kai *trstprl* regresuojame pagal *stfeco*:

```
proc reg;
  model trstprl = stfeco ;
run;
```

Number of Observations Read	325
Number of Observations Used	323
Number of Observations with Missing Values	2

Analysis of Variance					
Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	1	320.05699	320.05699	123.06	<.0001
Error	321	834.86561	2.60083		
Corrected Total	322	1154.92260			

Root MSE	1.61271	R-Square	0.2771
Dependent Mean	2.01548	Adj R-Sq	0.2749
Coeff Var	80.01609		

Parameter Estimates							
Variable	Label	DF	Parameter Estimate	Standard Error	t Value	Pr > t	Variance Inflation
Intercept	Intercept	1	0.87097	0.13673	6.37	<.0001	0
stfec0	How satisfied with present state of economy in country	1	0.52886	0.04767	11.09	<.0001	1.00000

Nors šis modelis ir blogiau tinka nei ankstesnieji, bet visai jo atmesti negalima. Jeigu politikas būtų pradėjęs tyrimą nuo šio modelio, tai darytų išvadą, kad pasitikėjimas parlamentu didėja, kai gerėja ekonominė situacija.

Kokią išvadą galimą padaryti iš pateiktųjų pavyzdžių? Kad ir kokią regresiją pasirinktume, gautą modelį reikia įvertinti kritiškai, būtina pažiūrėti koreliacijas ir pamąstyti apie modelio suderinamumą su sveiku protu (žinoma teorija, ankstesniais tyrimais ir pan.)

Atlikus žingsninę regresiją, būtina patikrinti modelio logiškumą.
Neapsiriboti formaliais statistikos rodikliais.

2.4.10. SAS programos tiesinės regresijos procedūra

Taikant SAS tiesinei regresinei analizei yra naudojama **proc reg** procedūra. Šios procedūros sintaksė atrodo taip:

```
PROC REG options;
  MODEL dependents=regressors / options;
  VAR variables;
  FREQ variable;
  WEIGHT variable;
  ID variable;
  OUTPUT OUT=SASdataset keyword=names...;
  PLOT yvariable*xvariable = symbol ...;
  RESTRICT linear_equation,...;
  TEST linear_equation,...;
  MTEST linear_equation,...;
  BY variables;
```


Sakinys **model** yra vienintelis būtinas **reg** procedūros sakiny. Šio parametro reikšmė – modelio pavidalas. Pavyzdžiui, užrašas **Y = X** reiškia, kad turi būti analizuojamas paprasčiausios tiesinės regresijos modelis $Y = C + b_1 X + e$. Beje, modeliuose laisvasis narys yra numatytoji parinktis.

SAS'e žingsninei regresinei analizei yra naudojama **proc stepwise** procedūra. Šios procedūros sintaksė atrodo taip:

```
PROC REG options;  
  MODEL dependents=regressors / options;  
  VAR variables;  
  FREQ variable;  
  WEIGHT variable;  
  ID variable;  
  OUTPUT OUT=SASdataset keyword=names...;  
  PLOT yvariable*xvariable = symbol ...;  
  RESTRICT linear_equation,...;  
  TEST linear_equation,...;  
  MTEST linear_equation,...;  
  
  BY variables;
```

Scenarijus :

```
data Esta;  
set regr.ESS4EE_s;  
keep idno agea gndr happy trust_all satisfaction;  
if 20 <= agea <=40 and gndr=1 and happy<11 and satisfaction <11 ;  
run;  
  
proc corr data=Esta;  
var satisfaction happy trust_all;  
run;
```

```

proc reg data=Esta;
model satisfaction = happy trust_all / stb partial spec vif;
run;
roc reg data=Esta;
    model satisfaction = happy trust_all / noprint;
    output out=res r=r;
run; quit;
proc univariate data=res normal;
    var r;
    qqplot /normal (mu=est sigma=est) ;
    histogram/ kernel;
run;
proc reg data=Esta
    plots(label)=(CooksD RStudentByLeverage DFFITS DFBETAS);
model satisfaction = happy trust_all;
run;
/*===== */
/* Žingsninė regresija */
/*===== */
data Lta;

set rgr.ESS4LT1_s;

if agea >= 20 AND agea <= 30 AND stfecu < 11 AND trstprl < 11AND stflife < 11 AND
stfgov < 11 AND stfdem < 11 AND stfedu < 11 AND stfhlth < 11 ;

run;

proc reg;

    model trstprl = stflife stfecu stfgov stfdem stfedu stfhlth / selection=forward
slentry=0.05;

run;;

proc reg;

    model trstprl = stflife stfecu stfgov stfdem stfedu stfhlth / selection=backward vif
slstay=0.05;

run;

Proc corr;
var trstprl stflife stfecu stfgov stfdem stfedu stfhlth;
run;

```

2.5. Tiesinė regresinė analizė su R

2.5.1. Duomenys

Tirsime tuos pačius duomenis kaip ir SPSS bei STATA atveju. Tiriamo 2008 metų Europos Sąjungos socialinio tyrimo (*European Social Survey*) Estijos duomenis ESS4EE. Mus domins, kaip pasitenkinimas šalies politiniu klimatu susijęs su pasitikėjimu politinėmis institucijomis ir bendruoju žmogaus laimingumu. Tirsime 20–40 metų vyrus. Tyrime naudosime tokius kintamuosius:

- *satisfaction* (pasitenkinimas šalies politiniu klimatu),
- *trust_all* (pasitikėjimas politinėmis institucijomis),
- *happy* (laimingumas).

Kintamasis *satisfaction* sukurtas paėmus kintamųjų *stfgov* (kiek respondentas yra patenkintas savo šalies vyriausybe) ir *stfdem* (kiek respondentas yra patenkintas demokratijos būseną šalyje) vidurkį. Jis įgyja reikšmes nuo 0 (itin nepatenkintas) iki 10 (labai patenkintas). Kintamasis *trust_all* sukurtas, suskaičiavus kintamųjų *trstprl* (pasitikėjimas šalies parlamentu), *trstlgl* (pasitikėjimas teisine sistema), *trstplt* (pasitikėjimas politikais), *trstprt* (pasitikėjimas partijomis), *trstun* (pasitikėjimas Jungtinėmis Tautomis) vidurkį ir įgyja reikšmes nuo 0 (itin nepasitiki) iki 9 (itin pasitiki). Kintamasis *happy* matuojamas 10 balų skale nuo 0 (itin nelaimingas) iki 9 (itin laimingas).

Reikiamus respondentus atsirinksime, atsižvelgę į *agea* (amžių) ir *gndr* (lytį, 1 – vyr., 2 – mot.). Pradiniai duomenys buvo išsaugoti .csv formatu. Toliau pateiksime R komandų seką (scenarijų) kaip paruošti duomenis regresinei analizei:

```
ddd=read.csv2("ESS4EE_s.csv",na.strings = "NA",stringsAsFactors=FALSE)
newdata <- subset(ddd,agea>= 20 & agea<= 40 & gndr == 1 & happy < 11 & satisfaction < 11,
select=c(happy,satisfaction,trust_all))

dta <- newdata[complete.cases(newdata), ]
```

Tiesinė regresija turi prasmę tik tada, kai intervaliniai regresoriai pakankamai stipriai koreliuoja su priklausomu kintamuoju, ir pakankamai silpnai tarpusavyje. Patikriname kintamųjų koreliacijas komanda

```
cor(dta)
```

Gauta koreliacijų lentelė rodo stiprią teigiamą *satisfaction* ir *trust_all* koreliaciją ($r = 0,7461$) ir vidutinę teigiamą *satisfaction* ir *happy* koreliaciją ($r = 0,3967$). Patys regresoriai *happy* ir *trust_all* koreliuoja silpnai ($r = 0,2988$). Multikolinearumo problema neturėtų iškilti. Visos koreliacijos yra statistiškai reikšmingos (visos p reikšmės lygios $0,000 < 0,05$).

	happy	satisfaction	trust_all
happy	1.0000000	0.3966850	0.2988191
satisfaction	0.3966850	1.0000000	0.7461222
trust_all	0.2988191	0.7461222	1.0000000

Deja, *cor* komanda apskaičiuoja tik koreliacijų reikšmes. Norėdami gauti ir p reikšmes, turime pasinaudoti *Hmisc* funkcijų biblioteka.

```
library(Hmisc)
rcorr(as.matrix(dta), type="pearson")
```

```

             happy satisfaction trust_all
happy         1.0          0.40       0.30
satisfaction  0.4          1.00       0.75
trust_all     0.3          0.75       1.00

n= 241

P
             happy satisfaction trust_all
happy         0              0
satisfaction  0              0
trust_all     0              0

```

2.5.2. Regresijos modelio lygtis

Analizuosime tokį regresijos modelį $satisfaction = C + b1*trust_all + b2*happy + e$. Įvykdome:

```
regr=lm(satisfaction~happy+trust_all)
summary(regr)
```

Gauname pagrindinę informaciją apie modelį. Determinacijos koeficientas $R^2 = 0,5898$ yra pakankamai didelis.

```

Call:
lm(formula = satisfaction ~ happy + trust_all, data = dta)

Residuals:
    Min       1Q   Median       3Q      Max
-3.8754 -0.9067 -0.0613  0.9487  5.2918

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  -0.84680    0.35906   -2.358   0.0192 *
happy         0.22608    0.05155    4.385 1.74e-05 ***
trust_all     0.82415    0.05202   15.841 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.447 on 238 degrees of freedom
Multiple R-squared:  0.5898,    Adjusted R-squared:  0.5864
F-statistic: 171.1 on 2 and 238 DF,  p-value: < 2.2e-16

```

Užrašykime regresijos lygtį:

$$satisfaction = -0,847 + 0,824 \text{ trust_all} + 0,226 \text{ happy}$$

ANOVA p reikšmė yra paskutinėje eilutėje (**p-value: <2.2e-16**). Ji mažesnė už 0,05 (užrašas 2.2e-16 yra užrašo 0.000000000000000022 santrumpa). Taigi modelyje yra statistiškai reikšmingų regresorių. Iš lentelės matyti, kad abudu regresoriai yra statistiškai reikšmingi, nes jiems t kriterijaus p reikšmės (jos yra stulpelyje **Pr(>|t|)**) mažesnės už 0,05.

Norėdami nustatyti, kuris regresorius modelyje yra įtakingesnis, turime apskaičiuoti standartizuotus beta koeficientus. Tam pasitelksim `QuantPsyc` funkcijų biblioteką.

```

library(QuantPsyc)
lm.beta(regr)

```

```


    happy trust_all
0.1907632 0.6891185

```

Regresorius *trust_all* (jo beta koeficientas lygus 0,689) yra daug įtakingesnis nei *happy* (beta lygus 0,191). Papildomai nubraižysime liekamųjų paklaidų grafikus abiem regresoriams. Paeiliui įvykdome komandas (naudojamės *car* funkcijų biblioteka):

```
library(car)
avPlots(regr)
```

Gautuosiuose grafikuose matyti aiški tiesinė priklausomybė ir didesnis regresijos tiesės posvyrio kampas regresoriui *trust_all*. O regresoriui *happy* tokios akivaizdžios priklausomybės nematyti (apie tokių grafikų interpretaciją žr. 2.1.4 sk.).



Taigi pagrindinės modelio charakteristikos rodo gerą modelio tinkamumą duomenims. Vis dėlto kintamojo *happy* reikalingumas modelyje yra abejotinas.

2.5.3. Regresijos prielaidų tikrinimas

Dar reikia patikrinti modelio prielaidas, t. y. ar:

- liekamosios paklaidos homoskedastiškos,
- liekamosios paklaidos normalios,
- nėra išskirčių,
- regresoriai nėra multikolinearūs.


Norėdami patikrinti, ar tenkinama homoskedastiškumo prielaida, nubraižome liekamųjų paklaidų ir prognozuojamų *satisfaction* reikšmių išsibarstymo grafiką. Alternatyviai galima nubraižyti standartizuotųjų liekamųjų paklaidų ir prognozuojamų *satisfaction* reikšmių išsibarstymo grafiką. Tai galima padaryti paeiliui įvykdžius tokias komandas:


```
plot(regr$fitted, regr$residuals)

regr.stdres = rstandard(regr)

plot(dta$satisfaction, regr$residuals, ylab="Standardized residuals", xlab="Satisfaction" )

abline(0,0)
```





Homoskedastiškos liekamosios paklaidos turėtų būti išsibarsčiusios tolygiai palei x ašį (grafikai turėtų priminti juostelę). Taigi reikia papildomai – „ne iš akies“ patikrinti homoskedastiškumo prielaidą.

Galima įtarti, kad homoskedastiškumo prielaida tenkinama. Patikrinsime, ar duomenys tam statistiškai reikšmingai neprieštaruoja, taikydami Breušo–Pagano kriterijų. Nulinė šio kriterijaus hipotezė teigia, kad homoskedastiškumo prielaida galioja. Homoskedastiškiems duomenims p reikšmė turi būti **ne mažesnė** už 0,05. Įvykdome komandas (naudojamės *lmtest* funkcijų biblioteka):

```
library(lmtest)
bptest(regr)
```

Gautoji chi kvadrato statistikos reikšmė yra 2,19, o $p = 0,1391 \geq 0,05$. Darome išvadą, kad duomenys statistiškai reikšmingai neprieštaruoja homoskedastiškumo prielaidai.

```
studentized Breusch-Pagan test


data:  regr
BP = 4.7017, df = 2, p-value = 0.09529
```



Norime atkreipti dėmesį, kad p reikšmės gali būti mažos ir dėl imties didumo. Todėl visada reikia atsižvelgti ir į chi kvadrato statistikos reikšmę (homoskedastiškų duomenų ji maža) ir į liekamųjų paklaidų grafikus.

Tikrindami liekamųjų paklaidų normalumą, visų pirma nubraižysime standartizuotųjų liekamųjų paklaidų histogramą (ji turėtų būti panaši į normaliąją kreivę) ir P–P grafiką (grafiko taškai turi nedaug skirtis nuo tiesės). Paeiliui įvykdome komandas:

```
x= rstandard(regr) #Standartizuotųjų liekamųjų paklaidų kintamasis
hist(x, freq=F,ylim=c(0,0.5))
#dx <- min(diff(H$breaks))
curve(dnorm(x), add=TRUE, col="blue")
probDist <- pnorm(x)
plot(ppoints(length(x)), sort(probDist), main = "PP Plot", xlab = "Observed Probability",
ylab = "Expected Probability")

abline(0,1)
```





Matome, kad ir histograma, ir kvantilių grafikas rodo liekamųjų paklaidų normalumą. Dabar patikrinsime paklaidų normalumą Šapiro–Vilko kriterijumi. Nulinė hipotezė teigia, kad paklaidos normalios. Normalumo prielaida netenkinama, jeigu $p < 0,05$. Įvykdome komandą

```
shapiro.test(regr$residuals)
```

Shapiro-Wilk normality test

```
data:  regr$residuals
W = 0.9925, p-value = 0.2601
```

Įsitikiname, kad $p = 0,2602 > 0,05$. Todėl galima teigti, kad sprendžiant iš Šapiro–Vilko kriterijaus, liekamosios paklaidos turi normalųjį skirstinį. Kaip ir tikrinant homoskedastiškumą, reikia nepamiršti, kad p reikšmės gali būti mažos vien dėl imties didumo. Todėl visada reikia atsižvelgti ir į grafikus, nes didelėms imtims jie informatyvesni.


Patikrinsime, ar duomenyse nebuvo išskirčių. Pritaikysime Bonferonio kriterijų (nulinė hipotezė – išskirčių nėra), apskaičiuosime Kuko matą ir išspausdinsime jo reikšmių grafiką.

```
outlierTest(regr)
cutoff <- 4/((nrow(dta)-length(regr$coefficients)-2))
plot(regr, which=4, cook.levels=cutoff)
```


```
influencePlot(regr, main="Influence Plot", sub="Circle size is proportional to Cook's Distance" )
```

	rstudent	unadjusted	p-value	Bonferonni	p
	624	3.769349	0.00020667	0.049807	

Nors formaliai gavome, kad išskirčių yra, vis dėlto p reikšmė nuo 0,05 skiriasi labai nedaug (mažiau nei per 0,0002). Todėl dar pasižiūrime grafikus ir Kuko mato reikšmę.



Pažiūrėję į grafiką įsitikiname, kad ir Kuko mato maksimali reikšmė neviršija vieneto.



Pažiūrėję į studentizuotų paklaidų²⁶ grafiką (dar vadinama įtakos grafiku) matome, kad vieno stebinio ši paklaida > 3 . Tai reiškia, kad šis stebinytis turi santykinai didelę įtaką regresinės analizės rezultatams.

Atsižvelgę į Bonferonio kriterijaus rezultatus (su pateiktu komentaru) ir į Kuko mato reikšmes darome išvadą, kad duomenyse išskirčių nėra.

Galimą regresorių multikolinearumą patikrinsime suradę dispersijos mažėjimo daugiklius VIF. Įvykdome komandą

```
vif(regr)
```

Multikolinearumo problema kyla, jeigu $VIF > 4$. Abiem regresoriams $VIF < 4$. Todėl darome išvadą, kad regresorių multikolinearumo nėra.

```
happy trust all
1.098048 1.098048
```

²⁶ Šiame el. vadovėlyje ši charakteristika nėra aptariama.

2.5.4. Galutinis modelis

Ankstesniuose skyreliuose įsitikinome, kad regresijos modelis labai gerai aprašo duomenis. Vis dėlto nedidelė *happy* ir *satisfaction* koreliacija, maža beta koeficiento reikšmė regresoriui *happy* ir netiesinis liekanų išsibastymo grafikas kelia abejonių šio regresoriaus reikalingumu. Todėl patikriname regresijos modelį be jo.

```
regr=lm(satisfaction~trust_all)
summary(regr)
```

Matome, kad naujojo modelio $R^2 = 0,5567$ nuo ankstesniojo $R^2 = 0,5898$ skiriasi tik per 0,0331, t. y. determinacijos koeficientas sumažėjo labai nedaug.

```
Call:
lm(formula = satisfaction ~ happy + trust_all, data = dta)

Residuals:
    Min       1Q   Median       3Q      Max
-3.8754 -0.9067 -0.0613  0.9487  5.2918

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  -0.84680    0.35906   -2.358   0.0192 *
happy         0.22608    0.05155    4.385 1.74e-05 ***
trust_all     0.82415    0.05202   15.841 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.447 on 238 degrees of freedom
Multiple R-squared:  0.5898,    Adjusted R-squared:  0.5864
F-statistic: 171.1 on 2 and 238 DF,  p-value: < 2.2e-16
```

Darome išvadą, kad regresorių *happy* galima iš modelio pašalinti, *nepaisant to, kad jis buvo statistiškai reikšmingas*. Užrašykime regresijos lygtį:

```
satisfaction = 0,382 + 0,892 trust_all.
```

Naujajame modelyje liko tik vienas regresorius, todėl nebereikia tikrinti multikolinearumo, nebereikia aprašinėti standartizuotosios beta reikšmės, o ANOVA ir t testo *p* reikšmės sutaps. Dar reikėtų ištirti, ar tenkinamos regresijos prielaidos (išskirčių nebeieškome), t. y. įvykdyti komandas

```
library(lmtest)
```


```
bptest(regr) # homoskedastiškumo tikrinimas  
shapiro.test(regr$residuals) # paklaidų normalumo tikrinimas
```

Nebepateiksime gautųjų rezultatų, tik konstatuosime, kad visos regresijos modelio prielaidos buvo tenkinamos.

2.5.5. Prognozės ir stebinių grafinis palyginimas

Galima grafiškai palyginti stebėtas *satisfaction* reikšmes su reikšmėmis, gautomis prognozei pritaikius pirmiau aprašytąjį regresijos modelį. Braižydami grafiką, pasinaudosime duomenyse esančiu respondento identifikaciniu numeriu *idno*. Įvykdome:

```
plot(regr$fit[1:10],type="b",col=2,ylim=c(0,10),lwd=2,ylab="satisfaction",xlab="idno",main  
="stebimos, prognozuojamos reikšmės",xaxt="n")  
  
lines(dta$satisfaction[1:10],type="b",lwd=2, col=4)  
  
axis(1,at=c(1:10),labels=dta$idno[1:10],las=2)  
  
legend(c(4.5,4.5), c(10,10), c("Prognozuojamos", "Stebimos"), col = c(2,4), pch=10)
```



Reikia pažymėti, kad grafike pateikta tik 10 reikšmių porų. Kai stebinių labai daug, ką nors grafike įžiūrėti yra sunku. Kuo labiau sutampa linijos, tuo modelio prognozės tikslesnės. Tokie grafikai beveik visada pridedami, kai tiriami laikiniai duomenys (pvz., BVP kitimas ketvirčiais), ir jų nėra daug. Socialiniuose tyrimuose panašūs grafikai braižomi retai.

2.5.6. Išvados

Regresijos aprašymas iš esmės nesiskiria nuo pateiktojo 2.5.5 skyrelio pabaigoje. Tik jį reikia papildyti informacija apie Breušo–Pagano ir Šapiro–Vilko kriterijus. Visas aprašymas turėtų apimti naujam modeliui pakartotą visą tyrimą. Lakoniškas aprašymas gali skambėti, kad ir taip:

Tyrėme modelį $satisfaction = C + b_1trust_all + b_2happy + e$. Nors R^2 buvo pakankamai didelis, o abudu regresoriai buvo statistškai reikšmingi, tačiau standartizuotieji beta koeficientai ir liekamųjų paklaidų grafikai rodė, kad regresoriaus happy įtaka priklausomam kintamajam satisfaction nėra stipri. Todėl regresorių happy iš modelio pašalinome. Determinacijos koeficiento reikšmė po regresoriaus happy pašalinimo sumažėjo tik per 0,03. Gautoji tiesinės regresijos lygtis atrodo taip: $satisfaction = 0,382 + 0,892 trust_all$. Modelio $R^2 = 0,558$.

Visi duomenims keliami reikalavimai buvo tenkinami. Šapiro–Vilko kriterijus parodė, kad liekamųjų paklaidų normalumo prielaida tenkinama. Pritaikę Breušo–Pagano kriterijų įsitikinome, kad galioja ir homoskedastiškumo prielaida. DFBetos ir Kuko mato reikšmės leidžia teigti, kad duomenyse nebuvo išskirčių.

2.5.7. Autokoreliacija

Tirtiesiems pavyzdžiams tai visiškai neaktualus klausimas, nes nebuvo jokio įtarimo, kad duomenyse gretimų respondentų atsakymai kažkaip susiję (t. y. duomenys NĖRA laikiniai). Vis dėlto parodysime kaip su R apskaičiuoti Durbino – Vatsono statistiką (galutiniam praėjusio skyrelio modeliui):

```
regr=lm(satisfaction~trust_all, data=dta)
durbinWatsonTest(regr)
```

Gautoji Durbino–Vatsono statistikos reikšmė (2,043) yra pakankamai arti 2, todėl manome, kad autokoreliuotumas nėra. Primename, kad autokoreliuotumas mažai tikėtinas, jeigu Durbino–Vatsono statistika yra tarp 1,5 ir 2,5.

```
lag Autocorrelation D-W Statistic p-value
1      -0.02347113      2.043161    0.734
Alternative hypothesis: rho != 0
```

2.5.8. Multikolinearumo problema

Primename, kad labai koreliuojantys (multikolinearūs) regresoriai gali sukelti problemų. Modelis tampa nestabilus, gali atsirasti neteisingų priklausomybių. Pateiksime vieną kiek dirbtinį pavyzdį, parodantį, kaip multikolinearumas gali iškreipti tikrąsias kintamųjų priklausomybes. Analizuosime tiesinės regresijos modelį $trstlgl = C + b_1 trstprl + b_2 trust_all + e$.

Ivykdome:

```
library(car)

newdata <- subset(ddd, agea >= 20 & agea <= 40 & gndr == 1 & happy < 11 & satisfaction
< 11 & trstlgl < 11 & trstprl < 11, select = c(trstlgl, trstprl, trust_all))

dta <- newdata[complete.cases(newdata), ]

cor(dta)

regr <- lm(trstlgl ~ trstprl + trust_all, data = dta)

summary(regr)

vif(regr)
```

```
          trstlgl  trstprl trust_all
trstlgl  1.0000000 0.6565534 0.8065599
trstprl  0.6565534 1.0000000 0.8778169
trust_all 0.8065599 0.8778169 1.0000000
```

Koreliacija tarp *trstlgl* ir *trstprl* yra 0,659, t. y. priklausomybė tiesioginė – kuo vieno kintamojo reikšmė didesnė, tuo didesnė ir kito kintamojo reikšmė. Kitaip sakant, tie respondentai, kurie labiau pasitiki parlamentu, yra labiau linkę pasitikėti ir teisine sistema. Į modelį įtraukėme ir stipriai su abiem kintamaisiais koreliuojantį (visai natūralu, nes abudu kintamieji buvo naudoti jį sudarant) kintamąjį *trust_all*. Koreliacija tarp *trust_all* ir *trstprl* yra labai stipri ir lygi 0,877.


```

Call:
lm(formula = trstlgl ~ trstprl + trust_all, data = dta)

Residuals:
    Min       1Q   Median       3Q      Max
-5.4767 -1.0296 -0.2412  0.7948  5.3216

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   0.32610     0.24682   1.321  0.18773
trstprl      -0.24158     0.08545  -2.827  0.00511 **
trust_all     1.38228     0.10929  12.648 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.518 on 234 degrees of freedom
Multiple R-squared:  0.6621,    Adjusted R-squared:  0.6592
F-statistic: 229.2 on 2 and 234 DF,  p-value: < 2.2e-16

```

Gautojo modelio $R^2 = 0,66$, ANOVA p reikšmė $< 0,05$. Pagal Stjudento kriterijų abudu kintamieji statistiškai reikšmingi ($p = 0,005$ ir $p = 0,000$).

trstprl	trust_all
4.358486	4.358486

Taip pat matome, kad yra multikolinearumo problema (abudu $VIF > 4$). Kas įvyktų, jeigu į multikolinearumą nekreiptume dėmesio? Atsižvelgę į rezultatų išsklotinėje pateiktus koeficientų įverčius, gautume tokią regresijos lygtį:

$$trstlgl = 0,33 - 0,24trspri + 1,38 trust_all.$$

Neigiamas koeficiento prie *trstprl* ženklas reiškia, kad *trstprl* didėjant, *trstlgl* mažėja. Kitaip tariant, kuo labiau respondentas pasitiki parlamentu, tuo mažiau pasitiki teisine sistema. Ši išvada prieštarauja pirmiau aptartai kintamųjų priklausomybei ir jų koreliacijos ženklui. Taigi nekreipdami dėmesio į stiprias regresorių koreliacijas, galime padaryti labai klaidingas išvadas.

2.5.9. Žingsninė regresija

Parodysime kaip atliekama žingsninė (pažingsninė, keliaetapė) regresija, nagrinėdami ESS4 Lietuvos duomenis. Tiriame visus 20–30 metų respondentus. Norime išsiaiškinti, nuo ko priklauso pasitikėjimas Seimu. Tirsime modelį

$$trstprl = C + b1 stfeco + b2 stflife + b3 stfgov + b4 stfdem + b5 stfedu + b6 stfhlth + e.$$

Čia *trstprl* yra pasitikėjimas parlamentu, *stfeco*, *stflife*, *stfgov*, *stfdem*, *stfedu*, *stfhlth* atitinkamai – pasitenkinimas ekonomika, gyvenimu apskritai, vyriausybe, demokratijos padėtimi, švietimo būkle, sveikatos apsauga. Visi kintamieji intervaliniai (0–9 arba 10), didesnė reikšmė rodo palankesnę požiūrį. Norima sužinoti, kuri sritis daro didesnę įtaką parlamento autoritetui. Panaudosime žingsninę regresiją. Žingsniuoti galima ir į priekį, ir atgal (akumuliuojant, kaupiant regresorius arba juos eliminuojant, šalinant). Todėl ir atitinkamų regresijų yra ne viena. Pasirinksime regresiją, kai „žingsniuojama atgal ir tik atgal“, t. y. kai pradedama nuo modelio su visais regresoriais, laipsniškai po vieną vis šalinant statistiškai nereikšmingus iš jų (eliminuojamoji, šalinamoji regresija). Procesas baigiamas, kai modelyje lieka tik statistiškai reikšmingi regresoriai.

Duomenis csv formatu išsaugojome, naudodami SPSS programą. Todėl, norėdami išvengti neteisingo praleistų reikšmių traktavimo, paliekame tik reikiamus respondentus:

```
dta=read.csv2("ESS4LT1_s.csv",na.strings = "NA",stringsAsFactors=FALSE)

newdata <- subset(dta,agea >= 20 & agea <= 30 & stfeco < 11 & trstprl < 11& stflife < 11
& stfgov < 11 & stfdem < 11 & stfedu < 11 & stfhlth <
11,select=c(trstprl,stflife,stfeco,stfgov,stfdem,stfedu,stfhlth))

ldta <- newdata[complete.cases(newdata), ]
```

R programai yra daug funkcijų bibliotekų, kuriomis naudojantis galima atlikti žingsninę regresinę analizę. Pasinaudosime biblioteka *rms*. Įvykdome:

```
library(rms)

fastbw(ols(trstprl ~ stflife+stfeco+stfgov+stfdem+stfedu+stfhlth, data=ldta) ,
rule="p",type="individual")
```

	Deleted	Chi-Sq	d.f.	P	Residual	d.f.	P	AIC	R2
stfeco	0.82	1	0.3660	0.82	1	0.3660	-1.18	0.411	
stfedu	1.99	1	0.1587	2.80	2	0.2462	-1.20	0.407	

Approximate Estimates after Deleting Factors

	Coef	S.E.	Wald Z	P
Intercept	0.70438	0.23567	2.989	2.801e-03
stflife	-0.09448	0.04004	-2.360	1.829e-02
stfgov	0.43745	0.06044	7.238	4.550e-13
stfdem	0.16799	0.04650	3.613	3.031e-04
stfhlth	0.09356	0.04152	2.253	2.424e-02

Factors in Final Model

[1] stflife stfgov stfdem stfhlth

Matome, kad modelis vis buvo siaurinamas, šalinant regresorius. Į galutinį modelį nepakliuvo *stfedu* ir *stfeco*. Determinacijos koeficientas $R^2 = 0,41$. Užrašykime gautąją regresijos lygtį:

$$trstprl = 0,70 + 0,44 \text{ stfgov} + 0,17 \text{ stfdem} - 0,09 \text{ stflife} + 0,09 \text{ stfhlth}.$$

Tūlas politikas tokį rezultatą (neteisingai) gali interpretuoti taip: norint, kad jauno amžiaus rinkėjai labiau gerbtų parlamentą, reikia rūpinantis sveikatos apsauga, puoselėti demokratiją ir prižiūrėti, kad gerai dirbtų vyriausybė (koeficientai prie šių regresorių yra teigiami). Be to, nėra ko labai stengtis, kad žmonės jaustųsi laimingi (koeficientas prie *stflife* neigiamas). Na o ekonomikos ir švietimo būklė požiūriui į parlamentą neturi įtakos (kintamieji buvo statistiškai nereikšmingi).

Dabar įsitikinsime, kad modelis nepatikimas. Pažiūrėkime kintamųjų koreliacijas. Įvykdome

```
library(Hmisc)
rcorr(as.matrix(ldta), type="pearson")
```

	trstprl	stflife	stfeco	stfgov	stfdem	stfedu	stfhlth
trstprl	1.00	0.13	0.51	0.60	0.51	0.26	0.35
stflife	0.13	1.00	0.37	0.29	0.37	0.31	0.27
stfeco	0.51	0.37	1.00	0.77	0.62	0.36	0.43
stfgov	0.60	0.29	0.77	1.00	0.65	0.39	0.42
stfdem	0.51	0.37	0.62	0.65	1.00	0.44	0.36
stfedu	0.26	0.31	0.36	0.39	0.44	1.00	0.65
stfhlth	0.35	0.27	0.43	0.42	0.36	0.65	1.00

n= 298

P		trstprl	stflife	stfeco	stfgov	stfdem	stfedu	stfhlth
trstprl			0.0305	0.0000	0.0000	0.0000	0.0000	0.0000
stflife	0.0305			0.0000	0.0000	0.0000	0.0000	0.0000
stfeco	0.0000	0.0000			0.0000	0.0000	0.0000	0.0000
stfgov	0.0000	0.0000	0.0000			0.0000	0.0000	0.0000
stfdem	0.0000	0.0000	0.0000	0.0000			0.0000	0.0000
stfedu	0.0000	0.0000	0.0000	0.0000	0.0000			0.0000
stfhlth	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000		

Matome, kad *trstprl* su visais kintamaisiais koreliuoja *teigiamai*, tačiau koreliacija su *stflife* yra silpna, o kriterijaus *p* reikšmė gana didelė ($p = 0,0305$). Koreliacija net statistiškai nereikšminga, jeigu reikšmingumo lygmuo 0,03. Be to, atsiminkime, kad regresijos koeficiento įverčio reikšmė artima nuliui, o ir *p* reikšmė tikrinant jo reikšmingumą nėra maža. Taigi regresijos modelyje ženklas prie *stflife* nėra įtikinamas (ir politiko išvada, kad geriau, kai respondentai nelaimingi). Įdomu, kad eliminuojančioje regresijoje parinkus kitą reikšmingumo slenkstį ($p = 0,02$) jis lieka su dviem regresoriais ir visai tinkamas: $R^2 = 0,388$ (o buvo $R^2 = 0,407$).

```
fastbw(ols(trstprl ~ stflife+stfeco+stfgov+stfdem+stfedu+stfhlth, data=ldta),
rule="p",sls=.02,type="individual")
```

Deleted	Chi-Sq	d.f.	P	Residual	d.f.	P	AIC	R2
stfeco	0.82	1	0.3660	0.82	1	0.3660	-1.18	0.411
stfedu	1.99	1	0.1587	2.80	2	0.2462	-1.20	0.407
stfhlth	5.08	1	0.0242	7.88	3	0.0485	1.88	0.396
stflife	4.26	1	0.0390	12.14	4	0.0163	4.14	0.388

Approximate Estimates after Deleting Factors

	Coef	S.E.	Wald Z	P
Intercept	0.5355	0.14378	3.724	1.958e-04
stfgov	0.4640	0.05834	7.954	1.776e-15
stfdem	0.1529	0.04482	3.412	6.448e-04

Factors in Final Model

```
[1] stfgov stfdem
```

Dabar pažiūrime kaip atrodo modelis vien su *trstprl* ir *stfeco*:

```
regr=lm(trstprl ~ stfeco, data=ldta)
summary(regr)
```

```
Call:
lm(formula = trstprl ~ stfeco, data = ldta)

Residuals:
    Min       1Q   Median       3Q      Max
-3.956 -0.912 -0.401  1.066  8.088

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.88990    0.14489   6.142 2.62e-09 ***
stfeco       0.51106    0.04946  10.332 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.634 on 296 degrees of freedom
Multiple R-squared:  0.2651,    Adjusted R-squared:  0.2626
F-statistic: 106.8 on 1 and 296 DF,  p-value: < 2.2e-16
```

Nors šis modelis ir blogiau tinka nei ankstesnieji, bet visai jo atmesti negalima. Jeigu politikas būtų pradėjęs tyrimą nuo šio modelio, tai darytų išvadą, kad pasitikėjimas parlamentu didėja, kai gerėja ekonominė situacija.

Kokią išvadą galimą padaryti iš pateiktųjų pavyzdžių? Kad ir kokią regresiją pasirinktume, gautą modelį reikia įvertinti kritiškai, būtina pažiūrėti koreliacijas ir pamąstyti apie modelio suderinamumą su sveiku protu (žinoma teorija, ankstesniais tyrimais ir pan.)

Atlikus žingsninę regresiją, būtina patikrinti modelio logiškumą.
Neapsiriboti formaliais statistikos rodikliais.

2.5.10. R programos tiesinės regresijos komandos

R programoje tiesinei regresinei analizei yra naudojama **lm** komanda. Šios komandos sintaksė atrodo taip:

```
lm(formula, data, subset, weights, na.action, method = "qr", model = TRUE, x = FALSE, y = FALSE, qr = TRUE, singular.ok = TRUE, contrasts = NULL, offset, ...)
```

formula yra vienintelis būtinas **lm** procedūros parametras. Šio parametro reikšmė – modelio pavidalas. Pavyzdžiui, užrašas $Y \sim X$ reiškia, kad turi būti analizuojamas paprasčiausios tiesinės regresijos modelis $Y = C + b_1 X + e$.

Beje, į modelius laisvasis narys yra įtraukiamas pagal nutylėjimą. Reikia pažymėti, kad regresijos modelio prielaidoms tikrinti reikia keleto papildomų funkcijų bibliotekų (pvz., *lmtest*, *nortest*). Jų įdiegimas žinančiam darbo su R programa pradmenis yra paprastas.

R programoje eliminuojamajai žingsninei regresinei analizei galima naudoti funkcijų bibliotekos *rms* komandą *fastbw*²⁷.

Scenarijus:

```
ddd=read.csv2("ESS4EE_s.csv",na.strings = "NA",stringsAsFactors=FALSE)
newdata <- subset(ddd,agea>= 20 & agea<= 40 & gndr == 1 & happy < 11 & satisfaction <
11,select=c(happy,satisfaction,trust_all))
dta <- newdata[complete.cases(newdata), ]

library(Hmisc)
rcorr(as.matrix(dta), type="pearson")

regr<-lm(satisfaction~happy+trust_all, data=dta)
summary(regr)
library(QuantPsyc)
lm.beta(regr)

library(car)
avPlots(regr)

plot(regr$fitted,regr$residuals)

regr.stdres <- rstandard(regr)

plot(dta$satisfaction,regr$residuals,ylab="Standardized residuals", xlab="Satisfaction" )
abline(0,0)

x<- rstandard(regr)
```

²⁷ Daugeliui analizės metodų R programa turi nemažai alternatyvių funkcijų bibliotekų. Norėtume paskatinti skaitytojus giliau pasidomėti programos galimybėmis.

```

hist(x, freq=F,ylim=c(0,0.5))
#dx <- min(diff(H$breaks))
curve(dnorm(x), add=TRUE, col="blue")
probDist <- pnorm(x)
plot(ppoints(length(x)), sort(probDist), main = "PP Plot", xlab = "Observed Probability",
ylab = "Expected Probability")

abline(0,1)

shapiro.test(regr$residuals)

outlierTest(regr)
cutoff <- 4/((nrow(dta)-length(regr$coefficients)-2))
plot(regr, which=4, cook.levels=cutoff)
influencePlot(regr, id.method="identify", main="Influence Plot", sub="Circle size is
proportional to Cook's Distance" )
vif(regr)

regr=lm(satisfaction~trust_all)
summary(regr)

library(lmtest)
bptest(regr) # homoskedastiškumo tikrinimas
shapiro.test(regr$residuals) # paklaidų normalumo tikrinimas

plot(regr$fit[1:10],type="b",col=2,ylim=c(0,10),lwd=2,ylab="satisfaction",xlab="idno",ma
in="stebimos, prognozuojamos reikšmės",xaxt="n")

lines(dta$satisfaction[1:10],type="b",lwd=2, col=4)

axis(1,at=c(1:10),labels=dta$idno[1:10],las=2)
legend(c(4.5,4.5), c(10,10), c("Prognozuojamos", "Stebimos"), col = c(2,4), pch=10)

regr<-lm(satisfaction~trust_all, data=dta)
durbinWatsonTest(regr)
# Multikolinearumo problema

library(car)

newdata <- subset(ddd,agea>= 20 & agea<= 40 & gndr == 1 & happy < 11 & satisfaction <
11 & trstlgl<11 & trstprl<11 ,select=c(trstlgl, trstprl,trust_all))

```

```

dta <- newdata[complete.cases(newdata), ]
cor(dta)

regr<-lm(trstlgl~ trstpri+trust_all, data=dta)
summary(regr)
vif(regr)

#####

#Žingsninė regresija

#####

dta<-read.csv2("ESS4LT1_s.csv",na.strings = "NA",stringsAsFactors=FALSE)

newdata <- subset(dta,agea >= 20 & agea <= 30 & stfeco < 11 & trstpri < 11& stflife <
11 & stfgov < 11 & stfdem < 11 & stfedu < 11 & stfhlth <
11,select=c(trstpri,stflife,stfeco,stfgov,stfdem,stfedu,stfhlth))

ldta <- newdata[complete.cases(newdata), ]

library(rms)
fastbw(ols(trstpri ~ stflife+stfeco+stfgov+stfdem+stfedu+stfhlth, data=ldta)
,rule="p",type="individual")

library(Hmisc)
rcorr(as.matrix(ldta), type="pearson") # type can be pearson or spearman
fastbw(ols(trstpri ~ stflife+stfeco+stfgov+stfdem+stfedu+stfhlth, data=ldta)
,rule="p",sls=.02,type="individual")

regr=lm(trstpri ~ stfeco, data=ldta)
summary(regr)

```

Uždaviniai

1. Failas **ZTLT**. Tyrimas: Lietuvos tolerancijos profiliai, 2003 m. Klausimų grupės:

- *r01_01 – r01_06* respondento požiūris (skalėje 1 – teigiamas, 2 – neutralus, 3 – neigiamas, 4 – sunku pasakyti) į juodaodžius, musulmonus, žydus, čigonus, migrantus, pabėgėlius).
- *r02_01 – r02_04* ranginėje skalėje įvertinta, koks procentas nurodytos grupės (kitos rasės, kitos tautybės, kitos religijos, kitos seksualinės orientacijos) gyventojų nekeltų Lietuvoje problemų.

- $r04_01 - r04_09$ Lietuvoje turėtų būti toleruojama (skalėje 1 – visiškai sutinku, 2 – sutinku, 3 – nesutinku, 4 – visiškai nesutinku) kitos tautybės, kitos rasės, kitos krikščioniškos konfesijos, nekrikščioniškos religijos, suteikiamas prieglobstis politiniams pabėgėliams, suteikiamas prieglobstis ekonominiais pabėgėliams, visi Lietuvos gyventojai turi turėti lygias galimybes įsidarbinti ir socialines garantijas).
- $r06_01 - r06_09$ ar galima pateisinti darbdavį, jeigu jis nepriima į darbą (skalėje 1 – niekada negalima, 2 – kartais galima, 3 – visada galima, 4 – sunku pasakyti) dėl to, kad kitos rasės, kito tikėjimo, neįgalus, vyras, moteris, kitos tautybės, homoseksualus, senas, jaunas.
- $s01$ – lytis.
- $s02$ – amžius.

Sukurti naujus kintamuosius:

- $a1 = r01_01 + \dots + r01_06$, tiems respondentams, kurie nepasirinko nė į vieną klausimą atsakymo 4. Kintamasis $a1$ rodo respondento požiūrį į svetimšalius. Kuo mažesnė $a1$ reikšmė, tuo požiūris tolerantiškesnis.
- $a2 = r02_01 + \dots + r02_04$. Kintamasis $a2$ rodo respondento pakantumą „kitokiems“. Kuo didesnė $a2$ reikšmė, tuo pakantumas didesnis.
- $a4 = r04_01 + \dots + r04_09$. Kintamasis $a4$ rodo respondento nuomonę apie valstybės kaip institucijos geidautiną tolerantiškumo laipsnį. Kuo mažesnė $a4$ reikšmė, tuo valstybė tolerantiškesnė.
- $a6 = r06_01 + \dots + r06_09$, tiems respondentams, kurie nepasirinko nė į vieną klausimą atsakymo 4. Kintamasis $a6$ rodo respondento darbo santykių tolerantiškumo nuostatas. Kuo mažesnė $a6$ reikšmė, tuo tolerantiškumas didesnis.

Reikia sudaryti regresijos modelį $a4 = f(a1, a2, a6, s02)$. Atsakyti į klausimus:

- 1) Ar visi kintamieji modelyje reikalingi?
- 2) Ar teisingi koeficientų ženklai?
- 3) Kurie kintamieji modelyje svarbesni?
- 4) Ar tenkinamos regresijos prielaidos?
- 5) Ar modelis vyrams panašus į modelį moterims? Ar daug skiriasi modeliai, sudaryti atskirai vyrams ir moterims, nuo modelio su pseudokintamuoju $s01$?
- 6) Kokius regresijos modelius gausime, taikydami žingsninę regresiją?

2. Failas ESS4LT1.sav. Socialinis Lietuvos respondentų tyrimas 2009 m. spalio – 2010 m. Reikia atlikti Lietuvos 20–40 metų vyrams tą patį tyrimą, kuris skyrelyje buvo atliktas su Estijos gyventojais. Primename, ką matuoja kintamieji:

- *stfgov* (kiek respondentas yra patenkintas savo šalies vyriausybe),
- *stfdem* (kiek respondentas yra patenkintas demokratijos būseną šalyje),
- *trstprl* (pasitikėjimas šalies parlamentu),
- *trstlgl* (pasitikėjimas teisine sistema),
- *trstplt* (pasitikėjimas politikais),
- *trstprt* (pasitikėjimas partijomis),
- *trstun* (pasitikėjimas Jungtinėmis Tautomis),
- *happy* (laimingumas).

Kintamieji *stfgov* ir *stfdem* matuojami 10 balų skale nuo 0 (itin nepatenkintas) iki 10 (itin patenkintas). Kintamieji *trstprl*, *trstlgl*, *trstplt*, *trstprt*, *trstun* matuojami 10 balų skale nuo 0 (itin nepasitikiu) iki 9 (itin pasitikiu). Kintamasis *happy* matuojamas 10 balų skale nuo 0 (itin nelaimingas) iki 9 (itin laimingas).

Modeliuosime kintamųjų *stfgov* ir *stfdem* vidurkį (pavadinkime jį *satisfaction*). Šis kintamasis rodo respondentų pasitikėjimą politiniu šalies klimatu. Manome, kad *satisfaction* gali priklausyti nuo kitų kintamųjų: $satisfaction = f(trstprl, trstlgl, trstplt, trstprt, trstun, happy)$.

Atsirinkti reikiamus respondentus, atsižvelgus į *agea* (amžių) ir *gndr* (lytį, 1 – vyr., 2 – mot.). Reikia:

- 1) Atlikti pradinę modelio analizę (kartu ištirti, ar tenkinamos tiesinės regresijos prielaidos).
- 2) Patikrinti, kaip atrodo modelis, kai kintamieji *trstlgl*, *trstplt*, *trstprt*, *trstun* keičiami jų reikšmių vidurkiu *trust_all*.
- 3) Ar naujajame modelyje reikalingas kintamasis *happy*?
- 4) Patikrinti, kokį modelį gausime taikydami žingsninę regresiją?
- 5) Ar toks modelis bus gautas, jeigu tirsime vyresnius nei 60 metų respondentus?

3. Failas LAMS: Universitetų absolventų integracija darbo rinkoje, 2009 m. lapkritis – 2010 m. sausis. Kintamieji:

- *K2* – aukštoji mokykla,
- *K10_1* – bakalauro studijų forma (1 – dieninės),
- *K11_1* – studijų vidurkio vertinimas (1 – dažniausiai vienas žemiausių kurse, ..., 5 –

dažniausiai vienas pirmiausių kurse),

- *K17* – bendrojo darbo stažo laikas,
- *K32* – vidutinės pajamos per mėnesį (rangais nuo 1 – iki 1000, ..., 9 – daugiau kaip 10 000)
- *K33_1* – pasiekiant dabartinę padėtį darbo rinkoje išsilavinimas (1 – visai nereikšmingas, ..., 5 – labai reikšmingas),
- *K33_2* – pasiekiant dabartinę padėtį darbo rinkoje studijų metu įgytos žinios (1 – visai nereikšmingos, ..., 5 – labai reikšmingos),
- *K33_3* – pasiekiant dabartinę padėtį darbo rinkoje darbo patirtis (1 – visai nereikšminga, ..., 5 – labai reikšminga),
- *K33_4* – pasiekiant dabartinę padėtį darbo rinkoje asmeninės savybės (1 – visai nereikšmingos, ..., 5 – labai reikšmingos),
- *K33_5* – pasiekiant dabartinę padėtį darbo rinkoje socialiniai ryšiai (1 – visai nereikšmingi, ..., 5 – labai reikšmingi),
- *K37_1* – pasitenkinimas esamu darbu (1 – labai nepatenkintas, ..., 5 – labai patenkintas).

Atsirinkus dienas bakalauro studijas baigusiuosius, taikant žingsninę regresiją modelį sąlygiškai galima užrašyti taip:

$$K37_1 = f(K11_1, K17, K32, K33_1, K33_2, K33_3, K33_4, K33_5),$$

ištirti: a) veterinarijos akademijos absolventams, b) LŽŪA absolventams.


Ar visos prielaidos patenkinamos? Ar galima taikyti tiesinės regresijos modelį?

Eliminuojantysis



tyrėjas

*Eliminuoja **moji***



regresija

*Eliminuoja **masis***




kintamasis

Kalbos paradoksai

3. TIESINĖS REGRESIJOS ALTERNATYVOS

Kai netenkinamos tiesinės regresijos prielaidos, analizės išvados yra nepatikimos. Tada visai tikėtinas toks inkvizitoriaus (opponento, dėstytojo) pokalbis su tardomuoju (doktorantu, studentu):



To *amen*²⁸ tardomasis visai netrokšta. Išvada: reikia kažkokio tiesinės regresijos pakaitalo. Šiame skyrelyje aptarsime statistinius modelius, kuriuos galima naudoti vietoje tiesinės regresijos. Dažniausiai, kai

- pažeista homoskedastiškumo prielaida – taikoma stabilizuotų liekamųjų paklaidų regresija,
- duomenys turi išskirčių – taikoma atsparioji regresija,
- pažeista normalumo prielaida – taikoma medianos regresija,
- kintamųjų priklausomybės netiesinės – taikoma netiesinė regresija.

Nereikia šio sąrašo laikyti neginčijamu ir vieninteliu teisingu²⁹. Visų pirma beveik niekada nebūna pažeista tik viena prielaida. Be to, išvardijome ne visus galimus tiesinės regresijos prielaidų pažeidimus. Ką daryti, kai yra regresorių multikolinearumas, aptarta ankstesniame skyriuje (reikia tiesiog pakeisti tiesinės regresijos kintamuosius). Be to, neužmirškime, kad tiesinės regresijos modeliai (ir regresinė analizė) nėra *visų* statistinių problemų sprendimo būdas.

Tiesinė regresija labai gerai ištirta, daugybė taikymų rodo praktinį jos naudingumą. Alternatyvūs modeliai nėra taip gerai išanalizuoti, jų tikimą duomenims patikrinti daug sunkiau. Todėl nereikia tokių regresijų laikyti panacėja nuo visų bėdų. Tai šiaudas (kartais gana storas), kurio stveriamasi, kai tiesinė regresija netinka. Čia panašiai kaip su aviečių arbata ir karštį malšinančiais vaistais. Nėra vaistų, tai bent arbatos išgersime. Gal ir padės.

Alternatyvų taikymo rezultatas yra toks: suradome parinkto modelio parametrų įverčius, kurie yra pagrįsti ir *galbūt* prasmingi. Daugybės visokių kriterijų taikyti jau neišeis, aprašymai sutrumpės radikalčiai, bet bent jausimės per daug nenusišnekėję. Tardomasis inkvizitoriui galės atsakyti: *Buvo nepatenkinta ...(įrašyti tinkamą)... tiesinės regresijos prielaida. Todėl parametrų įverčius apskaičiavome, taikydami ...(įrašyti tinkamą)... regresiją. Va, koks aš gudrus (neįrašyti).*

²⁸ Bakalauro, magistro darbui, disertacijai.

²⁹ Kaip ir šio el. vadovėlio.

Nereikia dėl menkiausio prielaidos pažeidimo atsisakyti tiesinės regresijos – jos analizės rezultatai dažniausiai atskleidžia galimas priklausomybes ir įtakos tendencijas. Tiesinė regresija gana atspari prielaidų pažeidimams, o rezultatų analizė – daug išsamesnė. Be to, visada galima išbandyti duomenų transformaciją. Galbūt, logaritnavus kintamuosius, visos išskirtys pradingės, o duomenys taps panašūs į normalius. Tiesinės regresijos alternatyvos reikia imtis tik tada, kai duomenų transformacijos nieko gero neduoda.

Idealiu atveju alternatyvios regresijos duos labai panašius (bet labiau pagrįstus) parametrų įverčius ir bus pateikiamos kaip pagrindinio tyrimo *priedas*.

3.1. Tiesinei regresijai netinkami duomenys

Šis skyrelis yra pagalbinis. Norėsime pademonstruoti regresijos alternatyvų veikimą konkretiems duomenims. Visų pirma metodus taikysime „geriems“, t. y. visas tiesinės regresijos prielaidas tenkinantiems, duomenims. Tam naudosime ankstesnio skyrelio medžiagą. Apibrėšime kitas, jau ne visai tiesinei regresijai tinkamas, duomenų aibes. Duomenims tirti taikysime STATA programą.

3.1.1. Heteroskedastiški ir ne visai normalūs duomenys

Tyrimui pasirinkime failo **LAMS** (Universitetų absolventų integracija darbo rinkoje, 2009 m. lapkritis – 2010 m. sausis) dalį. Tirsime ISM ir Veterinarijos akademijos studentus ($K2 = 15$ ir $K2 = 6$). Kiti kintamieji:

- $K32$ – vidutinės pajamos per mėnesį (rangais nuo 1 – iki 1000, ..., 9 – daugiau kaip 10 000)
- $K33_4$ – pasiekiant dabartinę padėtį darbo rinkoje asmeninės savybės (1 – visai nereikšmingos, ..., 5 – labai reikšmingos),
- $K37_1, \dots, K37_4$ – pasitenkinimas įvairiais darbo aspektais (1 – labai nepatenkintas, ..., 5 – labai patenkintas).

Sukuriame $K37suminis = K37_1 + K37_2 + K37_3 + K37_4$. Šis kintamasis rodo respondento pasitenkinimą darbu. Naudodami STATA programą, nepamirštame pašalinti reikšmes 99 (jomis SPSS duomenų faile buvo koduoti neatsakymai).

Nagrinėsime modelį $K37suminis = C + b_1 K32 + b_2 K33 + e$. Įvykdome

reg K37suminis K32 K33_4

Source	SS	df	MS	Number of obs = 124		
Model	280.445041	2	140.222521	F(2, 121) = 25.80		
Residual	657.579152	121	5.43453845	Prob > F = 0.0000		
				R-squared = 0.2990		
				Adj R-squared = 0.2874		
Total	938.024194	123	7.62621296	Root MSE = 2.3312		

k37suminis	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
k32	.8030617	.156602	5.13	0.000	.4930267	1.113097
k33_4	1.242025	.26922	4.61	0.000	.7090329	1.775017
_cons	7.412178	1.265357	5.86	0.000	4.907069	9.917286

Determinacijos koeficientas $R^2 = 0,299 > 0,20$, nors ir nėra labai didelis, bet pakankamas. ANOVA rodo gerą modelio tikimą ($p = 0,00\dots$). Pagal t kriterijų abudu regresoriai statistiškai reikšmingi. Tikrindami modelio prielaidas, paėiliui įvykdome komandas:

<pre> predict r1, rstandard swilk r1 estat hettest estat vif corr k32 k33_4 k37suminis </pre>	<pre> dfbeta k32 k33_4 summarize DFK32 DFK33_4 predict Cook , cooksd summarize Cook </pre>
---	--

Shapiro-wilk w test for normal data					
Variable	Obs	W	V	z	Prob>z
r1	124	0.98870	1.118	0.250	0.40141

Breusch-Pagan / Cook-Weisberg test for heteroskedasticity
Ho: Constant variance
Variables: fitted values of k37suminis

chi2(1) = 3.29
Prob > chi2 = 0.0697

Variable	VIF	1/VIF
k32	1.01	0.993862
k33_4	1.01	0.993862
Mean VIF	1.01	

	k32	k33_4	k37sum~s
k32	1.0000		
k33_4	0.0783	1.0000	
k37suminis	0.4191	0.3829	1.0000

```
. summarize DFK32 DFK33_4
```

variable	Obs	Mean	Std. Dev.	Min	Max
DFK32	124	-.0003293	.0938039	-.5807394	.2671409
DFK33_4	124	.0000477	.0869116	-.372424	.3053622

```
. summarize Cook
```

Variable	Obs	Mean	Std. Dev.	Min	Max
Cook	124	.0080659	.0153015	9.72e-07	.1276695



Formaliai žiūrint, visos tiesinės regresijos prielaidos patenktos: Šapiro–Vilko kriterijus neatmeta liekamųjų paklaidų normalumo ($p = 0,401$), Breušo–Pagano testas rodo, kad patenkinta liekanų homoskedastiškumo prielaida ($p = 0,0697$), nors p reikšmė nedaug didesnė už $0,05$. Multikolinearumo nėra – lygties ženklai atitinka koreliacijas, o abudu $VIF < 4$. Esminių išskirčių taip pat nėra – abiejų regresorių $DFBets < 1$, o Kuko matas < 1 .


Vis dėlto stebinių nebuvo labai daug ($n = 124$). Todėl Šapiro–Vilko ir Breušo–Pagano kriterijų p reikšmės galėjo būti nepagrįstai didelės.

Neatmestos nulinės hipotezės *nereiškia*, kad įrodėme liekamųjų paklaidų homoskedastiškumą ir normalumą.

Mums *nepavyko* įrodyti priešingai. Todėl braižome grafikus. Įvykdome komandas:

```
avplot K33_4
avplot K32
rvfplot
```







Visi grafikai primena „vėduoklės“ – tai tipinis heteroskedastiškumo požymis (homoskedastiškiems duomenims grafikai primena „juosteles“). Situaciją, kai tikrinant homoskedastiškumo prielaidą p reikšmė artė 0,05, o liekamųjų paklaidų grafikas primena „vėduoklę“, toliau vadinsim *nežymiu* heteroskedastiškumu. Kita vertus, nematyti, kad duomenys turėtų išskirčių.

Vizualiai patikrinsime normalumą. Įvykdome komandas:

```
histogram r1, frequency normal
pnorm r1
```




Matome, kad yra asimetriškumas, todėl, nors liekamųjų paklaidų normalumo prielaida nėra atmesta šią situaciją toliau įvardysime kaip *švelnų* normalumo sąlygos pažeidimą.

3.1.2. Duomenys su išskirtimiais

Tirdami tiesinės regresijos alternatyvas, nagrinėsime ne tik ankstesnio skyrelio pavyzdį, bet ir tą patį failą, papildytą nauja duomenų eilute su sąmoningai paliktomis klaidingomis išsiskiriančiomis

reikšmėmis: $K33_4 = 99$, $K37_suminis = 30$ ir neišsiskiriančia $K32 = 5$. Atlikę jiems analizę, analogišką aprašytajai ankstesniame skyrelyje, gauname



Brėžiniuose akivaizdžiai matyti $K33_4$ išskirtis ir duomenų nenormalumas. Tą rodo ir atsiradusi labai didelė Kuko mato reikšmė:

```
. predict Cook , cooks
. summarize Cook
```

variable	Obs	Mean	Std. Dev.	Min	Max
Cook	125	4.704767	52.54054	3.25e-07	587.4265

Be to, šiems duomenims Šapiro–Vilko kriterijus rodo, kad normalumo prielaida nepatenkinta statistiškai reikšmingai ($p = 0,029 < 0,050$).

Shapiro-wilk w test for normal data					
variable	Obs	w	V	z	Prob>z
r2	125	0.97664	2.327	1.896	0.02897

3.1.3. Duomenų charakteristikų santrauka

Pateiksime tiesinės regresijos pagrindinius rezultatus visoms trimis duomenų aibėms:

- 1) *A duomenimis* pavadiname Estijos duomenis, po visų jų transformacijų, aptartų 2.3 skyriuje. Šie duomenys tenkina visas tiesinės regresijos prielaidas, $R^2 = 0,557$. Regresijos lygtis su koeficientų įverčių 95 % pasikliautiniais intervalais ir *t* kriterijų *p* reikšmėmis atrodo taip:

$$\begin{array}{l} \text{satisfaction} = 0,382 + 0,892 \text{ trust_all.} \\ [-0,076; 0,841] \quad [0,791; 0,994] \\ (0,102) \quad (0,00) \end{array}$$

- 2) *B duomenys* – tai 3.1.1 skyrelyje aptarti duomenys. Jiems būdingas *nedidelis* heteroskedastiškumas ir *nedidelis* normalumo prielaidos pažeidimas. Išskirčių nėra. $R^2 = 0,299$. Regresijos lygtis su koeficientų įverčių 95 % pasikliautiniais intervalais ir *t* kriterijų *p* reikšmėmis atrodo taip:

$$\begin{array}{l} K37suminis = 7,41 + 0,80 K32 + 1,24 K33_4. \\ [4,907; 9,917]. \quad [0,493; 1,113] \quad [0,709; 1,775] \\ (0,00) \quad (0,00) \quad (0,00) \end{array}$$

- 3) *C duomenys* – tai 3.1.2 skyrelyje aptarti duomenys. Jiems būdingos išskirtys, statistiškai reikšmingas normalumo prielaidos pažeidimas ir *nedidelis* heteroskedastiškumas. $R^2 = 0,346$. Regresijos lygtis:

$$\begin{array}{l} K37suminis = 11,99 + 0,847 K32 + 0,147 K33_4. \\ [10,758; 13,221]. \quad [0,518; 1,175] \quad [0,096; 0,199] \\ (0,00) \quad (0,00) \quad (0,00) \end{array}$$

Palyginę B ir C duomenų modelius, matome, kad išskirtys radikaliai padidino konstantą ir pakeitė daugiklį prie *K33_4*.

3.2. Stabilizuotų liekamųjų paklaidų regresija

3.2.1. Modelio paskirtis

Stabilizuotų liekamųjų paklaidų regresija yra skirta atvejams, kai *nedaug* pažeista homoskedastiškumo prielaida. Tai ta pati tiesinė regresija, tik skaičiuojant įverčius, naudojamos specialiu liekamųjų paklaidų korekcijos algoritmu, užtikrinančiu skaičiavimų nejautrumą heteroskedastiškumui. Kadangi tokių algoritmų yra ne vienas, tai ir stabilizuotų liekamųjų paklaidų regresijų yra keletas. Visas jas vienija tai, kad pokyčiai vyksta tik vertinant standartines koeficientų paklaidas, atsižvelgiant į koreguotas liekamąsias paklaidas. Šių metodų pranašumas – tikslesni regresijos koeficientų pasikliautinieji intervalai, didesnė kriterijų, tikrinant koeficientų reikšmingumą, galia. Statistikoje nejautrios prielaidų pažeidimams procedūros vadinamos *robastiškomis* (*atspariosiomis*). Stabilizuotų liekamųjų paklaidų regresija – tai regresija, kai įverčiams taikomi robastiniai skaičiavimo metodai. Nevadiname šio modelio atspariąja (robastine) regresija, nes šį terminą vartosime, kai modelyje robastiškai bus vertinamos ne tik paklaidos (tiksliau paklaidų dispersijos), bet ir modelio koeficientai (žr. kitą skyrelį).

Stabilizuotų liekamųjų paklaidų regresijose:

- Modelio koeficientų įverčiai nesiskiria nuo gaunamų naudojant klasikinę tiesinę regresiją.
- Kitaip apskaičiuojami regresijos koeficientų pasikliautinieji intervalai.
- Kitaip įvertinamos standartinės koeficientų paklaidos – dėl to keičiasi t kriterijų rezultatai.

Dažniausiai liekamosios paklaidos stabilizuojamos atliekant duomenų matricos transformavimą. Tradiciškai tokios transformacijos vadinamos HC1, HC2 ir HC3 tipo korekcijomis. Kai kurie autoriai (Long ir Ervin), atlikę gausybę simuliacijų, teigia, kad nedidelėms imtims (iki 250 stebinių) geriausia naudoti HC3 korekciją. Didelėms imtims geriau tinka kitos korekcijos.

Nedidelėms imtims ($n \leq 250$) rekomenduojama taikyti HC3 korekciją.

Kitas populiarus būdas gauti stabilesnius liekamųjų paklaidų įverčius – naudoti saviranką³⁰. Savirankos idėją galima nusakyti taip: į imtį pažvelkime kaip į mini populiaciją. Daug kartų iš jos atrinkę imtis, turėtume gauti objektyvesnius paklaidų įverčius. Savirankos metodui reikia daug labai intensyvių skaičiavimų, nes procesas yra iteracinis. Liekamųjų paklaidų įverčiai lyginami po kiekvieno žingsnio. Jeigu jie nesistabilizuoja, atsakymo galime tiesiog negauti. Nuo visų tų milijoninių skaičiavimų gali ir kompiuteris „mirti“. Todėl regresiją su saviranka rekomenduotume taikyti tik nedidelėms imtims. Nereikia nustepti, kad, pritaikius tą pačią saviranką tiems patiems duomenims, gaunami truputį kitokie rezultatai. Juk tos naujosios imtys yra atsitiktinės. Mes tik nurodome jų skaičių (vadinamąjį kartotinių imčių skaičių).

Mažoms imtims galima taikyti regresiją su savirankos būdu įvertintomis liekamosioms paklaidoms.

3.2.2. Liekamųjų paklaidų HC korekcijos su STATA

IBM SPSS 19 programoje stabilizuotų liekamųjų paklaidų regresijos nėra. STATA 10 programoje HC1 ir HC3 tipo korekcijos gaunamos įvykdžius komandas

`reg priklausomas regresoriai, robust`

`reg priklausomas regresoriai, hc3`

Visų pirma patikriname, ar korekcijos pakeičia įverčius, kai tiesinės regresijos prielaidos tenkinamos. Pasirenkame A duomenis. Įvykdome

`reg satisfaction trust_all, robust`

satisfaction	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
trust_all	.8923218	.0471038	18.94	0.000	.7995301	.9851135
_cons	.38224	.2306284	1.66	0.099	-.072084	.836564

³⁰ Angl. *bootstrap*.

Minėta, kad patys koeficientų įverčiai nesiskiria. Pasikeičia koeficientų standartinės paklaidos³¹, todėl keičiasi ir t kriterijų reikšmės. Naujosios t testų *p* reikšmės (0,00 ir 0,099) labai nedaug skiriasi nuo buvusių (0,00 ir 0,102, žr. 3.1.3 skyrelį). Nedaug pasikeitė ir koeficientų pasikliautiniai intervalai. Pavyzdžiui, regresoriaus *trust_all* koeficiento 95 % pasikliautinis intervalas dabar yra [0,799; 0,985], o buvo [0,791; 0,994]. Taigi kaip ir reikėjo tikėtis, jeigu duomenys tenkina tiesinės regresijos prielaidas, tai ir korekcijos nelabai ką pakeičia (pagadina). Analogiškas išvadas padarytume, pritaikę modeliui analizę su HC3 pataisa.

Pritaikę HC3 pataisą B duomenims (t. y. heteroskedastiškiems duomenims), gauname

reg satisfaction trust_all, hc3						
k37suminis	Coef.	Robust HC3 Std. Err.	t	P> t	[95% Conf. Interval]	
k32	.8030617	.161637	4.97	0.000	.4830586	1.123065
k33_4	1.242025	.2577623	4.82	0.000	.7317163	1.752333
_cons	7.412178	1.258441	5.89	0.000	4.920762	9.903593

Palyginę su 3.1.3 skyreliu, įsitikiname, kad nei *p* reikšmės nei pasikliautiniai intervalai daug nepasikeitė. Taigi kai heteroskedastiškumas nebuvo labai didelis ir nebuvo išskirčių, tiesinė regresija pakankamai gerai tiko (korekcijos iš esmės nieko nepakeitė).

Pritaikę HC3 pataisą C duomenims (duomenims su išskirtimi), gauname

k37suminis	Coef.	Robust HC3 Std. Err.	t	P> t	[95% Conf. Interval]	
k32	.8470274	.1695127	5.00	0.000	.5114601	1.182595
k33_4	.1478968	1.094139	0.14	0.893	-2.01806	2.313854
_cons	11.99029	4.623618	2.59	0.011	2.837381	21.14321

Palyginę su 3.3.1 skyreliu, įsitikiname, kad regresorius *K33_4* tapo statistiškai nereikšmingas (*p* = 0,893). Labai padidėjo pasikliautinis konstantos intervalas: tapo [2,837; 21,143], o buvo [10,758; 13,221]. Nors išskirčių HC3 korekcija ir „nenukenksmino“, modelis į jas šiek tiek sureagavo.

Apibendrinsime empirines šio skyrelio išvadas. Stabilizuotų liekamųjų paklaidų regresija:

- taikytina, kai duomenys yra heteroskedastiški ir nėra didelių išskirčių;
- gali būti taikoma ir kai liekamosios paklaidos šiek tiek skiriasi nuo normaliųjų;

³¹ Angl. *standard error*.

- netinka, jeigu duomenys turi išskirčių. Nors į išskirtis ir reaguojama, bet modelis „neišgydomas“.

3.2.3. Liekamųjų paklaidų HC korekcijos su SAS

Visų pirma patikriname, ar korekcijos pakeičia įverčius, kai tiesinės regresijos prielaidos tenkinamos. Pasirenkame A duomenis. Įvykdome

```
proc reg data=Est_A;
model satisfaction=trust_all /acov;
ods output ACovEst = estcov;
ods output ParameterEstimates=pest;
run;
quit;
data temp_dm;
set estcov;
drop model dependent;
array a(2) intercept trust_all;
array b(2) std1-std2;
b(_n_) = sqrt((242/237)*a(_n_));
std = max(of std1-std2);
keep variable std;
run;
proc sql;
select pest.variable, estimate, stderr, tvalue, probt, std as robust_stderr,
estimate/robust_stderr as tvalue_rb,
(1 - probt(abs(estimate/robust_stderr), 241))*2 as probt_rb
from pest, temp_dm
where pest.variable=temp_dm.variable;
quit;
```

Variable	Parameter Estimate	Standard Error	t Value	Pr > t	robust_stderr	tvalue_rb	probt_rb
Intercept	0.37854	0.23250	1.63	0.1048	0.232002	1.631609	-0.89593
trust_all	0.89421	0.05136	17.41	<.0001	0.047297	18.90615	-1

Minėta, kad patys koeficientų įverčiai nesiskiria. Pasikeičia koeficientų standartinės paklaidos. Pavyzdžiui, regresoriaus *trust_all* koeficiento įverčio stabilizuotoji standartinė liekamoji paklaida yra 0,047 (stulpelis **robust_stderr**). Ji yra vos mažesnė nei apskaičiuotoji *klasikiniu* būdu (stulpelyje **Standard Error** reikšmė 0,051). Taigi kaip ir reikėjo tikėtis, jeigu duomenys tenkina tiesinės regresijos prielaidas, tai ir korekcijos nelabai ką pakeičia.

Pritaikę HC3 pataisą B duomenims (t. y. heteroskedastiškiems duomenims), gauname

Variable	Parameter Estimate	Standard Error	t Value	Pr > t	robust_stderr	tvalue_rb	probt_rb
Intercept	7.41218	1.26536	5.86	<.0001	1.226554	6.04309	-1
K32	0.80306	0.15660	5.13	<.0001	0.155812	5.154027	-1
K33_4	1.24202	0.26922	4.61	<.0001	0.252019	4.928297	-1

Palyginę **Standard Error** ir **robust_stderr** stulpelius, įsitikiname, kad įverčių standartinės paklaidos (ir pasikliautiniai intervalai) šiek tiek sumažėjo. Taigi kai heteroskedastiškumas nebuvo labai didelis ir nebuvo išskirčių, tiesinė regresija pakankamai gerai tiko (korekcijos iš esmės nieko nepakeitė).

Pritaikę HC3 pataisą C duomenims (duomenims su išskirtimi), gauname

Variable	Parameter Estimate	Standard Error	t Value	Pr > t	robust_stderr	tvalue_rb	probt_rb
Intercept	11.99029	0.62201	19.28	<.0001	0.638936	18.76604	-1
K32	0.84703	0.16595	5.10	<.0001	0.159863	5.298455	-1
K33_4	0.14790	0.02630	5.62	<.0001	0.010447	14.15619	-1

Palyginę **Standard Error** ir **robust_stderr** stulpelius, įsitikiname, kad regresorių koeficientų įverčių standartinės paklaidos (ir pasikliautiniai intervalai) šiek tiek sumažėjo.

Apibendrinsime empirines šio skyrelio išvadas. Stabilizuotų liekamųjų paklaidų regresija:

- taikytina, kai duomenys yra heteroskedastiški ir nėra didelių išskirčių;
- gali būti taikoma ir kai liekamosios paklaidos šiek tiek skiriasi nuo normaliųjų;
- netinka, jeigu duomenys turi išskirčių. Nors į išskirtis ir reaguojama, bet modelis „neišgydomas“.

3.2.4. Liekamųjų paklaidų HC korekcijos su R

Visų pirma patikriname, ar korekcijos pakeičia įverčius, kai tiesinės regresijos prielaidos tenkinamos (pritakysime HC1 ir HC3 korekcijas). Pasirenkame A duomenis. Analizei su korekcijomis pasinaudosime dviem funkcijų bibliotekomis *lmtest* ir *sandwich*. Įvykdome

```
library(lmtest)
library(sandwich)
regr<-lm(satisfaction~trust_all,data=dta)
coeftest(regr, vcov. = vcovHC(regr,type="HC1"))
Cov <- vcovHC(regr, type="HC1")
tt <-qt(c(0.025,0.975),summary(regr)$df[2])
se <- sqrt(diag(Cov))
ci <-coef(regr) + se %o% tt
colnames(ci) <-c("lower bd","upper bd")
ci
coeftest(regr, vcov. = vcovHC(regr,type="HC3"))
Cov <- vcovHC(regr, type="HC3")
tt <-qt(c(0.025,0.975),summary(regr)$df[2])
se <- sqrt(diag(Cov))
ci <-coef(regr) + se %o% tt
colnames(ci)=c("lower bd","upper bd")
ci
```



```
> coeftest(regr, vcov. = vcovHC(regr,type="HC1"))
```

t test of coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.382240	0.230628	1.6574	0.09875 .
trust_all	0.892322	0.047104	18.9437	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

	lower bd	upper bd
(Intercept)	-0.07208395	0.8365640
trust_all	0.79953015	0.9851135

```
> coeftest(regr, vcov. = vcovHC(regr,type="HC3"))
```

t test of coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.382240	0.232340	1.6452	0.1012
trust_all	0.892322	0.047514	18.7801	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

	lower bd	upper bd
(Intercept)	-0.07545608	0.8399361
trust_all	0.79872167	0.9859220

Minėta, kad patys koeficientų įverčiai nesiskiria. Pasikeičia koeficientų standartinės paklaidos, todėl keičiasi ir t kriterijų reikšmės. Naujosios t kriterijų *p* reikšmės (0,00 ir 0,099) labai nedaug skiriasi nuo buvusių (0,00 ir 0,102, žr. 3.1.3 skyrelį). Nedaug pasikeitė ir koeficientų pasikliautiniai intervalai. Pavyzdžiui, regresoriaus *trust_all* koeficiento 95 % pasikliautinis intervalas dabar yra [0,799; 0,985], o buvo [0,791; 0,994]. Taigi kaip ir reikėjo tikėtis, jeigu duomenys tenkina tiesinės regresijos prielaidas, tai ir korekcijos nelabai ką pakeičia (pagadina). Analogiškas padarytume išvadas, pritaikę modeliui analizę su HC3 pataisa.

Pritaikę HC3 pataisą B duomenims (t. y. heteroskedastiškiems duomenims), gauname

```

regr=lm(K37sum~K32+K33_4,data=dta)
coeftest(regr, vcov. = vcovHC(regr,type="HC3"))
Cov <- vcovHC(regr, type="HC3")
tt <- qt(c(0.025,0.975),summary(regr)$df[2])
se <- sqrt(diag(Cov))
ci <-coef(regr) + se %o% tt
colnames(ci)=c("lower bd","upper bd")
ci

```

```
> coeftest(regr, vcov. = vcovHC(regr,type="HC3"))
```

t test of coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	7.41218	1.25844	5.8900	3.553e-08	***
K32	0.80306	0.16164	4.9683	2.246e-06	***
K33_4	1.24202	0.25776	4.8185	4.240e-06	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

	lower bd	upper bd
(Intercept)	4.9207623	9.903593
K32	0.4830586	1.123065
K33_4	0.7317163	1.752333

Palyginę su 3.1.3 skyreliu įsitikiname, kad nei p reikšmės nei pasikliautiniai intervalai daug nepasikeitė. Taigi kai heteroskedastiškumas nebuvo labai didelis ir nebuvo išskirčių, tiesinė regresija pakankamai gerai tiko (korekcijos iš esmės nieko nepakeitė).

Pritaikę HC3 pataisą C duomenims (duomenims su išskirtimi), gauname

```
> coeftest(regr, vcov. = vcovHC(regr,type="HC3"))
```

t test of coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	11.99029	4.62362	2.5933	0.01067	*
K32	0.84703	0.16951	4.9968	1.97e-06	***
K33_4	0.14790	1.09414	0.1352	0.89270	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

	lower bd	upper bd
(Intercept)	2.8373807	21.143206
K32	0.5114601	1.182595
K33_4	-2.0180603	2.313854

Palyginę su 3.1.3 skyreliu įsitikiname, kad regresorius *K33_4* tapo statistiškai nereikšmingas ($p = 0,893$). Labai padidėjo pasikliautinis konstantos intervalas: [2,837; 21,143], o buvo [10,758; 13,221]. Nors išskirčių HC3 korekcija ir „nenukenksmino“, modelis į jas šiek tiek sureagavo.

Apibendrinsime empirines šio skyrelio išvadas. Stabilizuotų liekamųjų paklaidų regresija:

- taikytina, kai duomenys yra heteroskedastiški ir nėra didelių išskirčių;
- gali būti taikoma ir kai liekamosios paklaidos šiek tiek skiriasi nuo normaliųjų;
- netinka jeigu duomenys turi išskirčių. Nors į išskirtis ir reaguojama, bet modelis „neišgydomas“.

3.2.5. Savirankos regresija su STATA

Pritaikysime 1 000 kartotinių imčių saviranką. Primename, kad savirankoje imama daug *atsitiktinių* imčių, todėl tiems patiems duomenims pakartotinai pritaikius tą pačią savirankos komandą, rezultatai jau šiek tiek skirsis. Vis dėlto kai kartotinių imčių daug, rezultatų skirtumas yra nedidelis. Pirmiausia tirsime heteroskedastiškus B duomenis. Įvykdome


```
reg K37suminis K32 K33_4, vce(bootstrap, reps(1000))
```

K37suminis	Observed Coef.	Bootstrap Std. Err.	z	P> z	Normal-based [95% Conf. Interval]	
K32	.8030617	.1579608	5.08	0.000	.4934642	1.112659
K33_4	1.242025	.2735865	4.54	0.000	.7058052	1.778244
_cons	7.412178	1.340443	5.53	0.000	4.784957	10.0394


Palyginę su 3.1.3 skyreliu įsitikiname, kad visi pasikliautiniai intervalai beveik nepasikeitė. Pritaikę tą pačią saviranką C tipo duomenims su išskirtimis, gauname

3.2.6. Savirankos regresija su SPSS


Tirsime B duomenis. Renkamės **Analyze** → **Regression** → **Linear**. Perkeliame *K37suminis* į laukelį **Dependent**, regresorius *K32*, *K33_4* į laukelį **Independent(s)**.



Pasirenkame **Statistics** ir pažymime **Confidence intervals**, **Descriptives**.



Spaudžiame **Continue** ir **Bootstrap**. Pažymime **Perform bootstrapping**. Šiame meniu (**Number of samples**) galima nurodyti ir kitą replikacijų skaičių.



Spaudžiame **Continue** ir **OK**. Lentelėje **Descriptive Statistics** pateiktos *populiacijos kintamųjų* (o ne jų koeficientų regresijos modelyje) vidutinės reikšmės ir jų 95 % pasikliautinieji

intervalai. Turint vieną imtį, kintamojo vidurkiui pasikliautinį intervalą surasti neįmanoma. Tai kas pasikeitė? Taikant saviranką, imčių buvo 1000.

Descriptive Statistics						
		Statistic	Bootstrap ^a			
			Bias	Std. Error	95 % Confidence Interval	
					Lower	Upper
K37suminis	Mean	15.59	.01	.25	15.09	16.06
	Std. Deviation	2.762	-.012	.167	2.404	3.076
	N	124	0	0	124	124
K32 Asmeninės vidutinės pajamos per mėnesį	Mean	3.48	.00	.12	3.25	3.73
	Std. Deviation	1.346	-.013	.120	1.091	1.570
	N	124	0	0	124	124
K33_4 Asmeninių savybių įtaka pasiekiant esamą padėtį darbo rinkoje	Mean	4.33	.00	.07	4.19	4.47
	Std. Deviation	.783	-.008	.083	.618	.937
	N	124	0	0	124	124

a. Unless otherwise noted, bootstrap results are based on 1000 bootstrap samples

Kitoje lentelėje pateikiami kintamųjų koreliacijų įverčiai ir tų įverčių 95 % pasikliautiniai intervalai. Visos lentelės į šį el. vadovėlį nedėsiu, pateiksiu tik jos fragmentus kintamojo *K37suminis* ir regresoriaus *K32* koreliacijai.

Correlations				
Pearson Correlation		K37suminis	K37suminis	1.000
			K32	.419
Sig. (1-tailed)		K37suminis	K37suminis	.
			K32	.000
95 % Confidence Interval	Lower	K37suminis	K37suminis	1.000
			K32	.263
	Upper	K37suminis	K37suminis	1.000
			K32	.553

Tiesinės regresijos koeficientai ir jų pasikliautiniai intervalai yra lentelėje **Coefficients**.

Coefficients ^a							
Model	Unstandardized Coefficients		Standardized Coefficients	t	Sig.	95.0% Confidence Interval for B	
	B	Std. Error	Beta			Lower Bound	Upper Bound
1 (Constant)	7.412	1.265		5.858	.000	4.907	9.917
K32	.803	.157	.392	5.128	.000	.493	1.113
K33_4	1.242	.269	.352	4.613	.000	.709	1.775

a. Dependent Variable: K37suminis

Savirankos metodu įvertinti modelio koeficientų 95 % pasikliautiniai intervalai ir t kriterijų *p* reikšmės yra lentelėje **Bootstrap for Coefficients**. Matome, kad ir pasikliautiniai intervalai ir *p* reikšmės nedaug skiriasi nuo apskaičiuotų, naudojant tiesinę regresiją.

Bootstrap for Coefficients						
Model	B	Bootstrap ^a				
		Bias	Std. Error	Sig. (2-tailed)	95 % Confidence Interval	
					Lower	Upper
1 (Constant)	7.412	-.014	1.248	.001	5.067	9.811
K32	.803	.009	.157	.001	.495	1.117
K33_4	1.242	-.002	.259	.001	.710	1.721

a. Unless otherwise noted, bootstrap results are based on 1000 bootstrap samples

Skyrelio pabaigoje pateiksime šioias tokias rekomendacijas:

- Jeigu tiesinėje regresijoje susidūrėme su heteroskedastiškumu, bet stabilizuotų liekamųjų paklaidų regresija nustatė tuos pačius statistiškai reikšmingus regresorius ir labai panašius jų pasikliautinuosius intervalus, tai heteroskedastiškumas *neiškraipė* rezultatų. Aprašyme viską ir nurodome – ir heteroskedastiškumą paminime, ir stabilizuotų liekamųjų paklaidų regresiją ir jos rezultatus.
- Nėra labai svarbu, kokį taikyti stabilizavimo metodą. Dalis tyrėjų itin mėgsta saviranką. Kiti – nemėgsta.
- Jeigu pasikliautiniai intervalai, palyginti su tiesinės regresijos modeliu, labai pakito arba jeigu yra didelių išskirčių, vertėtų išbandyti atspariąją regresiją (žr. kitą skyrelį).

3.2.7. Savirankos regresija su R

Pritaikysime 1000 kartotinių imčių saviranką. Pinaudosime funkcijų biblioteka *boot*. Tirsime heteroskedastiškus B duomenis. Įvykdome

```
library(boot)

# function to obtain regression weights
bs <- function(formula, data, indices) {
  d <- data[indices,] # allows boot to select sample
  fit <- lm(formula, data=d)
  return(coef(fit))
}

# bootstrapping with 1000 replications
results <- boot(data=dta, statistic=bs, R=1000, formula=K37suminis~K32+K33_4)

# view results
Results

# get 95 % confidence intervals
boot.ci(results, type=c("norm","bca"), index=1) # intercept
boot.ci(results, type=c("norm","bca"), index=2) # k32
boot.ci(results, type=c("norm","bca"), index=3) # k33_4
```

ORDINARY NONPARAMETRIC BOOTSTRAP

Call:

```
boot(data = dta, statistic = bs, R = 1000, formula = K37suminis ~
  K32 + K33_4)
```

Bootstrap Statistics :

	original	bias	std. error
t1*	7.4121777	-0.0002377705	1.3154338
t2*	0.8030617	0.0045927536	0.1583999
t3*	1.2420248	-0.0049057668	0.2621712

BOOTSTRAP CONFIDENCE INTERVAL CALCULATIONS

Based on 1000 bootstrap replicates

CALL :

```
boot.ci(boot.out = results, type = c("norm", "bca"), index = 1)
```

Intervals :

Level	Normal	BCa
95%	(4.834, 9.991)	(4.934, 10.177)

Calculations and Intervals on Original Scale

Intervals :

Level	Normal	BCa
95%	(0.4880, 1.1089)	(0.5114, 1.1144)

Calculations and Intervals on Original Scale

Intervals :

Level	Normal	BCa
95%	(0.733, 1.761)	(0.706, 1.751)

Calculations and Intervals on Original Scale

Palyginę su 3.1.3 skyreliu, įsitikiname, kad visi pasikliautiniai intervalai beveik nepasikeitė. Pritaikome tą pačią saviranką C tipo duomenims su išskirtimis.

Palyginę su 3.1.3 skyreliu, galime padaryti tas pačias išvadas kaip ir modeliui su korekcija HC3: regresorius K33_4 tapo statistiškai nereikšmingas ($p = 0,793$). Kiek padidėjo pasikliautinis konstantos intervalas: [7,183; 16,797], o buvo [10,758; 13,221]. Taigi nors išskirčių saviranka ir „nenukenksmino“, į jas buvo sureaguota.

ORDINARY NONPARAMETRIC BOOTSTRAP

Call:

```
boot(data = dta, statistic = bs, R = 1000, formula = K37suminis ~  
K32 + K33_4)
```

Bootstrap Statistics :

	original	bias	std. error
t1*	11.9902934	-1.57116539	2.3273984
t2*	0.8470274	-0.01253457	0.1630486
t3*	0.1478968	0.37882076	0.5367325

Konstruojant pasikliautinius intervalus, pagal nutylėjimą taria, kad duomenys normalūs. Kadangi normalumo prielaida buvo pažeista, pažiūrime kaip pasikeičia pasikliautiniai intervalai, kai jie skaičiuojami atsižvelgus į savirankos rezultatus.

```

BOOTSTRAP CONFIDENCE INTERVAL CALCULATIONS
Based on 1000 bootstrap replicates

CALL :
boot.ci(boot.out = results, type = c("norm", "bca"), index = 1)

Intervals :
Level    Normal          BCa
95% ( 9.00, 18.12 ) ( 7.84, 14.01 )
Calculations and Intervals on Original Scale
Warning : BCa Intervals used Extreme Quantiles
Some BCa intervals may be unstable
Warning message:
In norm.inter(t, adj.alpha) : extreme order statistics used as endpoints
-----
Intervals :
Level    Normal          BCa
95% ( 0.5400, 1.1791 ) ( 0.5352, 1.2045 )
Calculations and Intervals on Original Scale
-----
Intervals :
Level    Normal          BCa
95% (-1.2829, 0.8211 ) ( 0.1331, 1.3887 )
Calculations and Intervals on Original Scale

```


Matome, kad išskirtys turėjo įtakos ir pasikliautiniams intervalams. Jeigu nuspręstume pateikti pasikliautinuosius intervalus, aprašymuose šiuo atveju reiktų remtis (BCa) pasikliautiniais intervalais.

Gavome tas pačias išvadas kaip ir ankstesniame skyrelyje: stabilizuotų liekamųjų paklaidų regresija su savirankos parinktimi tinka (bet nėra prasminga) A, tinka ir naudotina B duomenims, nėra naudinga ir netaikytina C duomenims.

3.3. Atsparioji regresija

3.3.1. Modelio paskirtis

Paprastam žmogui (ne statistikui) terminas *atsparioji regresija* primena Lietuvos ekonomikos būklę opozicijos kalbose – vyksta regresas ir sustabdyti jo niekaip neišeina. Susidūrusiam su statistika atrodo kaip tik priešingai – tai kažkokia regresijų regresija. Tvirta kaip tankas.



Atsparioji regresija (viduje)



Neatspariosios regresijos (viduje)

Iš tikrųjų situacija kiek kitokia. Visų pirma atsparioji (robustinė³²) regresija yra atspari tik išskirtims. Stebiniams suteikiami svoriai, į kuriuos atsižvelgiama skaičiuojant koeficientų įverčius. Jeigu vienas stebinyas labai išsiskiria iš kitų, tai jo svoris būna artimas nuliui. Kitaip tariant, išskirtys nedaro didelės įtakos koeficientų įverčiams.

Matematiškai žiūrint, viskas gražu. O idėjiškai? Gerai, jeigu tokia išskirtis buvo atsitiktinė, o jeigu – ne? Įsivaizduokime ekonomistą, sudariusį Lietuvos ekonomikos raidos modelį ir samprotaujantį: Viskas modelyje gerai, tik per 2008–2010 metų krizę rodikliai labai suprastėjo. Tai aš tų metų duomenis išmečiau.“ Visi didžiai piktintųsi tokiu ekonomistu ir aiškintų, kad jo modeliu tikėti negalima. O dabar, tarkime, kad ekonomistas pareiškia: „Modelyje buvo išskirčių. Todėl modeliuodami, taikėme atspariąją regresiją.“ Klausytojai žavėtųsi ekonomisto erudicija (specialistas!) . O modelis tai beveik tas pats.

Atsparioji regresija – optimistinis požiūris į duomenis. Ignoruokime išskirtis, ir gal jų gyvenime nepasitaikys. Kartais toks požiūris pasiteisina.

Įtikinti klausytojus sprendimo protingumu yra tyrėjo uždavinys. Jis turi tikėti, kad duomenų išskirtys yra grynas atsitiktinumas. Pavyzdžiui, tyrėjas turi informaciją apie modelius Estijos, Latvijos, Lenkijos duomenims ir yra tikras, kad analogiškas modelis (gal su kiek kitais koeficientų įverčiais) turi būti teisingas ir Lietuvai.

Atsparioji regresija „nukenksmina“ išskirtis duomenyse.

Tinka tik tada, kai išskirtys atsitiktinės – nežinome, kodėl jų atsirado.

Nėra jokios garantijos, kad taip gautas modelis tiksliau aprašo realius reiškinius.

³² Angl. *robust*.

Taikydami atspariąją regresiją, gausime ANOVA statistikos reikšmę ir jos p reikšmę, patikrinsime t kriterijumi koeficientų statistinį reikšmingumą, rasime koeficientų įverčius ir jų 95 % pasikliautuosius intervalus. Šie statistiniai rodikliai interpretuojami visiškai taip pat kaip ir tiesinėje regresijoje. Atsparioje regresijoje nėra determinacijos koeficiento R^2 analogo. Tai bene svarbiausia visuotinio jos išplitimo kliūtis. Kol kas atsparioji regresija nėra realizuota SPSS programoje.

3.3.2. Atsparioji regresija su STATA

Visų pirma įsitikinsime, kad duomenims be išskirčių atsparioji regresija duoda beveik tuos pačius koeficientų įverčius kaip ir tiesinė regresija. Tirsime A duomenis. Įvykdome

```
rreg satisfaction trust_all
```

Robust regression

Number of obs = 241
F(1, 239) = 303.38
Prob > F = 0.0000

satisfaction	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
trust_all	.9176449	.0526847	17.42	0.000	.8138592	1.021431
_cons	.2405901	.2381669	1.01	0.313	-.2285843	.7097646

Palyginę su 3.3.1 skyrelyje patektu tiesinės regresijos modeliu matome, kad regresoriaus *trust_all* koeficiento įvertis (0.917) nedaug skiriasi³³ nuo tiesinės regresijos įverčio (0,892). Nedaug keitėsi ir atitinkamas pasikliautinis intervalas. Konstantos įvertis skiriasi kiek daugiau, bet abiejuose modeliuose konstantos buvo statistiškai nereikšmingos. Taigi kaip ir reikia tikėtis, jeigu duomenys tinka tiesinei regresijai, tai atsparioji regresija nieko negadina.

Analogiškai ištyrę heteroskedastiškus B duomenis, taip pat gauname labai panašius įverčius kaip ir tiesinėje regresijoje. Matome, kad atsparioji regresija gerai susitvarko („pagydo“ modelį), kai yra *nedidelis* duomenų heteroskedastiškumas.

k37suminis	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
k32	.7990511	.1646414	4.85	0.000	.4731	1.125002
k33_4	1.263801	.2830408	4.47	0.000	.7034469	1.824155
_cons	7.352299	1.330316	5.53	0.000	4.718587	9.986012

³³ Žinoma, būtų smagu palyginti, ar šie koeficientai skiriasi statistiškai reikšmingai. Deja, atsparijai regresijai to padaryti negalima. O štai dviejų tiesinės regresijos modelių koeficientus palyginti galima, nors tai ir sukelia papildomų problemų, žr. <http://www.ats.ucla.edu/stat/stata/faq/compreg2.htm>

Dabar ištirsime C duomenis su didele išskirtimi. Sudarę atspariosios regresijos modelį, gauname

k37suminis	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
k32	.7990511	.1646414	4.85	0.000	.4731	1.125002
k33_4	1.263801	.2830408	4.47	0.000	.7034469	1.824155
_cons	7.352299	1.330316	5.53	0.000	4.718587	9.986012

Matome, kad dirbtinai įvestoji išskirtis buvo „nukenksmintą“ – modelio parametrų įverčiai liko tokie patys kaip ir B atveju. Taigi šiuo atveju atsparioji regresija tinka daug geriau nei klasikinė tiesinė regresija.

Kada taikoma atsparioji regresija, o kada stabilizuotų liekamųjų paklaidų regresija? Jeigu tik galime, tai taikome liekamųjų paklaidų regresiją (žr. ankstesnio skyrelio pabaigą), pavyzdžiui, B duomenims. Atsparioji regresija taikoma, jeigu:

- tiesinės regresijos modelyje nustatėme išskirtį (kažkuriam stebiniui Kuko matas buvo didelis);
- nesugalvojame, kodėl išskirtį būtų galima iš duomenų pašalinti;
- esame šventai įsitikinę, kad išskirtis duomenyse – grynas atsitiktinumas;
- priklausomo kintamojo stebiniai normalūs.

Tolesni veiksmai priklauso nuo to, ar gauto modelio koeficientų įverčiai panašūs į gautuosius tiesinės regresijos modelyje. Jeigu taip – lengviau atsipūtę, toliau nagrinėjame tiesinę regresiją, tik nurodome, kad išskirtis nebuvo labai „kenksminga“ ir atsparioji regresija parodė, kad modelis beveik nepasikeitė. Jeigu ne – pateikiame atspariosios regresijos modelio koeficientus ir apgailestaujame, kad nebeliko determinacijos koeficiento reikšmės ir apskritai bent kiek geresnio modelio tikimo įrodymo.

Jeigu duomenyse yra išskirčių, o mes nesame šventai įsitikinę jų atsitiktinumu, tai sudaryti jokio tinkamo regresijos modelio nepavyks. Yra duomenų, kuriems jokie regresijos modeliai netinka.

3.3.3. Atsparioji regresija su SAS

Visų pirma įsitikinsime, kad duomenims be išskirčių atsparioji regresija duoda beveik tuos pačius koeficientų įverčius kaip ir tiesinė regresija. Tirsime A duomenis. Įvykdome (naudojame standartinį M metodą):

```
proc robustreg data=est_a method=m (wf=huber) ;
    model satisfaction = trust_all;
run;
```

Summary Statistics						
Variable	Q1	Median	Q3	Mean	Standard Deviation	MAD
trust_all	2.8000	4.2000	5.6000	4.1192	1.8801	2.0756
satisfact	2.5000	4.0000	5.5000	4.0620	2.2505	2.2239

Parameter Estimates							
Parameter	DF	Estimate	Standard Error	95% Confidence Limits		Chi-Square	Pr > ChiSq
Intercept	1	0.2398	0.2359	-0.2225	0.7021	1.03	0.3093
trust_all	1	0.9185	0.0521	0.8164	1.0206	310.72	<.0001
Scale	1	1.5348					

Palyginę su 3.3.1 skyrelyje pateiktu tiesinės regresijos modeliu matome, kad regresoriaus *trust_all* koeficiento įvertis (0.919) nedaug skiriasi nuo tiesinės regresijos įverčio (0,892). Nedaug keitėsi ir atitinkamas pasikliautinasis intervalas. Konstantos įvertis skiriasi kiek daugiau, bet abiejuose modeliuose konstantos buvo statistiškai nereikšmingos (žr. **Parameter Estimates**). Taigi kaip ir reikia tikėtis, jeigu paprasčiausias tiesinės regresijos modelis tinka duomenims, tai ir atsparioji regresija nieko nepagadina.

Analogiškai ištyrę heteroskedastiškus B duomenis, taip pat gauname labai panašius įverčius kaip ir tiesinėje regresijoje. Matome, kad atsparioji regresija gerai susitvarko („pagydo“ modelį), kai yra *nedidelis* duomenų heteroskedastiškumas.

Summary Statistics						
Variable	Q1	Median	Q3	Mean	Standard Deviation	MAD
K32	3.0000	3.0000	4.0000	3.4839	1.3464	1.4826
K33_4	4.0000	4.0000	5.0000	4.3306	0.7832	1.4826
K37sumini	14.0000	16.0000	18.0000	15.5887	2.7616	2.9652

Parameter Estimates							
Parameter	DF	Estimate	Standard Error	95% Confidence Limits		Chi-Square	Pr > ChiSq
Intercept	1	7.3758	1.3518	4.7263	10.0253	29.77	<.0001
K32	1	0.7972	0.1673	0.4693	1.1251	22.71	<.0001
K33_4	1	1.2648	0.2876	0.7011	1.8285	19.34	<.0001
Scale	1	2.2193					

Dabar ištirsime C duomenis su didele išskirtimi. Sudarę atspariosios regresijos modelį, gauname

Summary Statistics						
Variable	Q1	Median	Q3	Mean	Standard Deviation	MAD
K32	3.0000	3.0000	4.0000	3.4960	1.3478	1.4826
K33_4	4.0000	4.0000	5.0000	5.0880	8.5033	1.4826
K37sumini	14.0000	16.0000	18.0000	15.7040	3.0375	2.9652

Parameter Estimates							
Parameter	DF	Estimate	Standard Error	95% Confidence Limits		Chi-Square	Pr > ChiSq
Intercept	1	12.0714	0.6497	10.7979	13.3448	345.18	<.0001
K32	1	0.8498	0.1733	0.5101	1.1896	24.03	<.0001
K33_4	1	0.1449	0.0275	0.0911	0.1988	27.83	<.0001
Scale	1	2.4452					

Diagnostics Summary		
Observation Type	Proportion	Cutoff
Outlier	0.0000	3.0000

Matome, kad dirbtinai įvestoji išskirtis „nenukenksminta“ – modelio parametrų įverčiai skirtingi nei B atveju. Kodėl? Taikomas atspariosios regresinės analizės metodas pagrįstas svorių priskyrimu stebiniams, atsižvelgiant į gautųjų liekamųjų paklaidų reikšmes. Šiuo atveju regresijos lygtis taip „sureagavo“ į mūsų naująjį stebinį: kadangi liekamoji paklaida maža, tai šio stebinio svoris liko 1! Kokias galima padaryti išvadas? Pritaikius atspariąją regresinę analizę, reikėtų patikrinti, kokie svoriai buvo priskirti. Tai leidžia subjektyviai įvertinti, ar skaičiavimo rezultatai priimtini. Sviurių skalė yra nuo 0 iki 1. Jei svoris mažas, vadinasi, stebinio įtaka skaičiuojant įverčius yra sąlygiškai maža, – t. y. stebinys traktuojamas kaip nebūdingas populiacijai. Kai svoris yra lygus 0 – stebinys nėra naudojamas skaičiuojant įverčius, t. y. jis pašalinamas iš regresinės analizės. Turėtume pasitikrinti, dėl kokių priežasčių tai buvo padaryta. Tam geriausia tiktų diagnostinės procedūros, aptartos 2.4 skyrelyje.

Patartina taikyti ne vieną, o keletą atspariosios regresinės analizės metodų. Tai leidžia geriau suprasti, kurie stebiniai yra netipiniai, ir pasirinkti „geriausią“ modelį.

Taigi šiuo atveju svorius išsispausdiname įvykdę (spausdiname 15 mažiausių):

```
hweights <- data.frame(resid = rr.huber$resid, weight = rr.huber$w)
hweights2 <- hweights[order(rr.huber$w), ]
hweights2[1:15, ]
```


Obs	K32	K33_4	K37_1	K37_2	K37_3	K37_4	K37suminis	wgt
1	4	4	5	5	5	5	20	0.83268
2	4	4	4	4	5	3	16	1.00000
3	2	4	4	4	4	4	16	1.00000
4	2	5	4	4	5	4	17	1.00000
5	2	5	4	3	2	2	11	0.94079
6	2	5	5	4	5	3	17	1.00000
7	1	5	5	4	4	3	16	1.00000
8	4	4	4	4	3	4	15	1.00000
9	3	4	3	3	4	3	13	1.00000
10	3	5	4	4	4	3	15	1.00000
123	5	5	5	5	5	3	18	1.00000
124	3	4	4	4	4	3	15	1.00000
125	5	99	.	.	.	.	30	1.00000

Mūsų „dirbtinio“ stebinio pateiktame sąrašė nėra.

Pritaikykime C duomenims vadinamąjį MM atspariosios regresijos metodą:

```
proc robustreg data=lams_c method=mm(inith=502 k0=1.8);
  model k37suminis = k32 k33_4;
  output out = t3 weight=wgt;
run;
proc print data=t3;
run;
```

Parameter Estimates							
Parameter	DF	Estimate	Standard Error	95% Confidence Limits		Chi-Square	Pr > ChiSq
Intercept	1	7.3078	1.3752	4.6125	10.0031	28.24	<.0001
K32	1	0.7993	0.1711	0.4641	1.1346	21.84	<.0001
K33_4	1	1.2756	0.2914	0.7045	1.8468	19.16	<.0001
Scale	0	2.4070					

Diagnostics Summary		
Observation Type	Proportion	Cutoff
Outlier	0.0080	3.0000

Obs	K32	K33_4	K37_1	K37_2	K37_3	K37_4	K37suminis	wgt
1	4	4	5	5	5	5	20	0.51642
2	4	4	4	4	5	3	16	0.99552
3	2	4	4	4	4	4	16	0.88772
4	2	5	4	4	5	4	17	0.91601
5	2	5	4	3	2	2	11	0.53617
6	2	5	5	4	5	3	17	0.91601
7	1	5	5	4	4	3	16	0.93420
123	5	5	5	5	5	3	18	0.99707
124	3	4	4	4	4	3	15	0.99893
125	5	99	.	.	.	.	30	0.00000

Stebiny nr.125 „nukenksmintas“, jo svoris 0. Suprantama, kad rezultatas tada toks pat kaip ir B duomenims.

Taigi šiuo atveju atsparioji regresija tinka daug geriau nei klasikinė tiesinė regresija.

Kada taikoma atsparioji regresija, o kada stabilizuotų liekamųjų paklaidų regresija? Jeigu tik galime, tai taikome liekamųjų paklaidų regresiją (žr. ankstesnio skyrelio pabaigą), pavyzdžiui, B duomenims. Atsparioji regresija taikoma, jeigu:

- tiesinės regresijos modelyje nustatėme išskirtį (kažkuriam stebiniui Kuko matas buvo didelis);
- nesugalvojame, kodėl išskirtį būtų galima pašalinti iš duomenų;
- esame įsitikinę, kad išskirtis duomenyse – grynas atsitiktinumas;
- priklausomo kintamojo stebiniai normalūs.

Tolesni veiksmai priklauso nuo to, ar gauto modelio koeficientų įverčiai panašūs į gautuosius tiesinės regresijos modelyje. Jeigu taip – lengviau atsipūtę, toliau nagrinėjame tiesinę regresiją, tik nurodome, kad išskirtis nebuvo labai „kenksminga“ ir atsparioji regresija parodė, jog modelis beveik nepasikeitė. Jeigu ne – pateikiame atspariosios regresijos modelio koeficientus ir apgailestaujame, kad nebeliko determinacijos koeficiento reikšmės ir apskritai bent kiek geresnio modelio tikimo įrodymo.

Jeigu duomenys turi išskirčių, o nesame įsitikinę jų atsitiktinumu, tiesiog jokio tinkamo regresijos modelio sudaryti nepavyks. Yra duomenų, kuriems jokie regresijos modeliai netinka.

SAS programos atspariosios regresijos procedūra yra *proc robustreg*. Šios procedūros sintaksė:

```
PROC ROBUSTREG <options> ;
BY variables ;
CLASS variables ;
EFFECT name=effect-type ( variables </options> ) ;
ID variables ;
MODEL response= <effects> </options> ;
OUTPUT <OUT=SAS-data-set> <options> ;
PERFORMANCE <options> ;
TEST effects ;
WEIGHT variable ;
```

```
OPTIONS nofmterr;
/* A duomenys */
data Est_A;
keep idno agea gndr happy trust_all satisfaction stfgov trstprl trstplt;
set rgr.ESS4EE_s;
if 20 <= agea <=40 and gndr=1 and happy<11 and satisfaction <11 ;
run;
/* regresijos santrauka A duomenims */
```

```

proc reg data=Est_a;
    model satisfaction = trust_all;
run;

/*                      */
/* B duomenys */
/*                      */

data lams_B;
set rgr.lams_s;
keep K32 K33_4 K37_1 K37_2 K37_3 K37_4 K37suminis;
K37suminis=K37_1+K37_2+K37_3+K37_4;
if (K2 eq 15 or K2 eq 6) and K32 ne . and K33_4 ne . and K37suminis ne .;
run;

/*====*/
/* regresijos santrauka B duomenims */
/*=====*/

proc reg data=lams_b;
    model k37suminis = k32 k33_4;
run;

/*=====*/
/* C duomenys */
data lams_C;
set lams_B end=eof;
output;
if eof then do;
    Call missing( of _all_ );

    K33_4=99;
    K37suminis= 30;
    K32 = 5;
output;
end ;

/* regresijos santrauka C duomenims */
/*====*/

```

```

proc reg data=lams_c;
    model k37suminis = k32 k33_4;
run;

run;

/*=====*/
/* Atsparioji (robastinė) regresija */
/*=====*/

proc robustreg data=est_a method=m (wf=huber) ;
    model satisfaction = trust_all;
    /* output out = t3 weight=wgt;*/
run;

proc robustreg data=lams_b method=m (wf=huber) ;
    model k37suminis = k32 k33_4;
    /* output out = t3 weight=wgt;*/
run;

proc robustreg data=lams_c method=m (wf=huber) ;
    model k37suminis = k32 k33_4;
    output out = tt weight=wgt;
run;

proc print data=tt;
run;

/* mm metodos */
proc robustreg data=lams_c method=mm /* (inith=502 k0=1.8) */;
    model k37suminis = k32 k33_4;
    output out = t3 weight=wgt;
run;

proc print data=t3;
run;

```

3.3.4. Atsparioji regresija su R

Visų pirma įsitikinsime, kad duomenims be išskirčių atsparioji regresija duoda beveik tuos pačius koeficientų įverčius kaip ir tiesinė regresija. Tirsime A duomenis. Įvykdome (naudojame standartinį M metodą):

```
library(MASS)

summary(rr.huber<-rlm(satisfaction~trust_all,data=dta))
```

Call: rlm(formula = satisfaction ~ trust_all, data = dta)
Residuals:

Min	1Q	Median	3Q	Max
-3.09271	-0.97746	-0.07696	1.04079	5.50679

Coefficients:

	Value	Std. Error	t value
(Intercept)	0.2445	0.2368	1.0322
trust_all	0.9162	0.0524	17.4893

Residual standard error: 1.543 on 239 degrees of freedom

Palyginę su 3.3.1 skyrelyje pateiktu tiesinės regresijos modeliu matome, kad regresoriaus *trust_all* koeficiento įvertis (0,916) nedaug skiriasi nuo tiesinės regresijos įverčio (0,892). Nedaug keitėsi ir atitinkamas pasikliautinis intervalas. Konstantos įvertis skiriasi kiek daugiau, bet abiejuose modeliuose konstantos buvo statistiškai nereikšmingos. Taigi kaip ir reikia tikėtis, jeigu paprasčiausias tiesinės regresijos modelis tinka duomenims, tai ir atsparioji regresija nieko nepagadina.

Analogiškai ištyrę heteroskedastiškus B duomenis, taip pat gauname labai panašius įverčius kaip ir tiesinėje regresijoje. Matome, kad atsparioji regresija gerai susitvarko („pagydo“ modelį), kai yra *nedidelis* duomenų heteroskedastiškumas.

```
Call: rlm(formula = K37suminis ~ K32 + K33_4, data = dta)
Residuals:
```

Min	1Q	Median	3Q	Max
-6.02925	-1.18914	-0.09124	1.50666	5.43835

Coefficients:

	Value	Std. Error	t value
(Intercept)	7.3757	1.3518	5.4563
K32	0.7972	0.1673	4.7652
K33_4	1.2648	0.2876	4.3976

Residual standard error: 2.219 on 121 degrees of freedom

Dabar ištirsime C duomenis su didele išskirtimi. Sudarę atspariosios regresijos modelį, gauname

```
Call: rlm(formula = K37suminis ~ K32 + K33_4, data = dta)
```

Residuals:

Min	1Q	Median	3Q	Max
-6.3508	-1.2006	-0.1954	1.6545	4.6545

Coefficients:

	Value	Std. Error	t value
(Intercept)	12.0714	0.6498	18.5782
K32	0.8498	0.1734	4.9022
K33_4	0.1449	0.0275	5.2749

Residual standard error: 2.445 on 122 degrees of freedom

Matome, kad dirbtinai įvesta išskirtis „nenukenksminta“ – modelio parametrų įverčiai skirtingi nei B atveju. Kodėl? Taikomas atspariosios regresinės analizės metodas pagrįstas svorių priskyrimu stebiniams atsižvelgiant į gautųjų liekamųjų paklaidų reikšmes. Šiuo atveju regresijos lygtis taip „sureagavo“ į mūsų naująjį stebinį – kadangi liekamoji paklaida buvo maža, tai šio stebinio svoris liko 1! Kokias išvadas galima padaryti? Pritaikius atspariąją regresinę analizę reikėtų patikrinti, kokie svoriai buvo priskirti. Tai leidžia subjektyviai įvertinti, ar skaičiavimo rezultatai priimtini. Svių skalė yra nuo 0 iki 1. Jei svoris mažas, tai reiškia, kad stebinio įtaka skaičiuojant įverčius yra sąlygiškai maža – stebinis traktuojamas kaip nebūdingas populiacijai. Kai svoris yra lygus 0 – stebinis nėra naudojamas skaičiuojant įverčius, jis pašalinamas iš regresinės analizės. Turėtume patikrinti, dėl kokių priežasčių tai buvo padaryta. Tam geriausiai tiktų diagnostika, aptarta 2.5 skyrelyje.

Patartina taikyti ne vieną, o keletą atspariosios regresinės analizės metodų, tai leidžia geriau suprasti, kurie stebiniai yra netipiniai, ir atitinkamai pasirinkti „geriausią“ modelį.

Taigi šiuo atveju svorius išsispausdiname įvykdę (spausdiname 15 mažiausių):

```
hweights <- data.frame(resid = rr.huber$resid, weight = rr.huber$w)
hweights2 <- hweights[order(rr.huber$w), ]
hweights2[1:15, ]
```

	resid	weight
1290	-6.350766	0.5178427
953	-5.905477	0.5568959
4025	-5.350766	0.6146219
3292	-5.205828	0.6317341
2844	-5.200591	0.6323742
3416	-5.050415	0.6511825
1569	-4.765777	0.6900711
2829	4.654471	0.7065614
4057	4.654471	0.7065614
3710	4.649234	0.7073623
4044	-4.610364	0.7133434
3489	4.354121	0.7553119
3491	-4.050415	0.8119546
47	3.949585	0.8326536
2631	3.944347	0.8337660

Mūsų „dirbtinio“ stebinio pateiktame sąrašo nėra. Pritaikykime C duomenims vadinamąjį MM atspariosios regresijos metodą:

```
summary(rr.huber<-
  rlm(K37suminis~K32+K33_4,method="MM",wt.method="case",data=dta))

hweights <- data.frame(resid = rr.huber$resid, weight = rr.huber$w)

hweights2 <- hweights[order(rr.huber$w), ]

hweights2[1:15, ]
```

Call: `rlm(formula = K37suminis ~ K32 + K33_4, data = dta, method = "MM", wt.method = "case")`

Residuals:

Min	1Q	Median	3Q	Max
-106.26509	-1.46259	-0.06408	1.53492	5.45936

Coefficients:

	Value	Std. Error	t value
(Intercept)	7.3570	0.6115	12.0314
K32	0.7995	0.1631	4.9006
K33_4	1.2617	0.0259	48.7938

Residual standard error: 2.299 on 122 degrees of freedom

	resid	weight
1	-106.265088	0.0000000
1290	-6.002859	0.4751303
2631	5.459364	0.5520226
4025	-5.002859	0.6149624
3710	4.997141	0.6156889
2844	-4.802360	0.6418297
3416	-4.601861	0.6681381
47	4.398139	0.6942153
953	-4.340138	0.7015397
398	-4.264582	0.7109665
2473	-4.264582	0.7109665
3424	4.197640	0.7191949
3138	-4.061589	0.7357194
2829	3.935917	0.7506702
4057	3.935917	0.7506702

Stebiny's nr.1 „nukenksmintas“, svoris 0. Suprantama, kad rezultatas toks pat kaip ir B duomenims.

Taigi šiuo atveju atsparioji regresija tinka daug geriau nei klasikinė tiesinė regresija.

Kada taikoma atsparioji regresija, o kada stabilizuotų liekamųjų paklaidų regresija? Jeigu tik galime, tai taikome liekamųjų paklaidų regresiją (žr. ankstesnio skyrelio pabaigą), pavyzdžiui, B duomenims. Atsparioji regresija taikoma, jeigu:

- tiesinės regresijos modelyje nustatėme išskirtį (kažkuriam stebiniui Kuko matas buvo didelis);
- nesugalvojame, kodėl išskirtį būtų galima pašalinti iš duomenų;
- esame įsitikinę, kad duomenų išskirtys – grynas atsitiktinumas;
- priklausomo kintamojo stebiniai normalūs.

Tolesni veiksmai priklauso nuo to, ar gauto modelio koeficientų įverčiai panašūs į gautuosius tiesinės regresijos modelyje. Jeigu taip – lengviau atsipūtę, toliau nagrinėjame tiesinę regresiją, tik nurodome, kad išskirtis nebuvo labai „kenksminga“ ir atsparioji regresija parodė, jog modelis beveik nepasikeitė. Jeigu ne – pateikiame atspariosios regresijos modelio koeficientus ir apgailestaujame, kad nebeliko determinacijos koeficiento reikšmės ir apskritai bent kiek geresnio modelio tikimo įrodymo.

Jeigu duomenys turi išskirčių ir nesame įsitikinę jų atsitiktinumu, tada jokio tinkamo regresijos modelio sudaryti nepavyks. Yra duomenų, kuriems jokie regresijos modeliai netinka.

R programoje atspariajai regresinei analizei yra naudojama *rlm* funkcija iš *MASS* funkcijų bibliotekos.

```
rlm(formula, data, weights, ..., subset, na.action, method = c("M", "MM",  
"model.frame"), wt.method = c("inv.var", "case"),  
model = TRUE, x.ret = TRUE, y.ret = FALSE, contrasts = NULL)
```

Būtinasis parametras **formula** – užrašome modelio išraišką.

Scenarijus:

```
library(MASS)  
summary(rr.huber<-rlm(satisfaction~trust_all,data=dta))  
  
hweights <- data.frame(resid = rr.huber$resid, weight = rr.huber$w)  
hweights2 <- hweights[order(rr.huber$w), ]  
hweights2[1:15, ]  
  
# MM metodo taikymas  
  
summary(rr.huber<-  
rlm(K37suminis~K32+K33_4,method="MM",wt.method="case",data=dta))  
  
hweights <- data.frame(resid = rr.huber$resid, weight = rr.huber$w)  
hweights2 <- hweights[order(rr.huber$w), ]  
hweights2[1:15, ]
```

3.4. Medianos regresija

3.4.1. Modelio paskirtis

Medianos regresijos idėja – modeliuoti ne priklausomo kintamojo *vidutinę* reikšmę parinktų regresorių atžvilgiu, o *medianos* reikšmę. Todėl nereikia tikėtis, kad parametrų įverčiai bus labai panašūs į gautuosius taikant tiesinę regresiją.

Priminsime, kad tiesinės regresijos modelis siejamas su priklausomo kintamojo reikšmių vidurkiu. Net ir prognozuojama *vidutinė* priklausomo kintamojo reikšmė. Tik tai ne visada pabrėžiama. Tarkime, kad regresijos modelį naudojame gydymo trukmės prognozei. Įstatę konkretaus ligonio tyrimų rezultatus į modelį, iš tikrųjų prognozuojame, kiek *vidutiniškai* laiko gyja

ligoniai, kurių yra tokie tyrimų rezultatai. Tokią interpretaciją (pvz., vidutiniškai gydymas trunka 3 savaites) ligonis be vargo supranta. Medianos regresijos interpretacija skambėtų taip: pusė visų ligonių gydėsi iki trijų savaičių. Medianos regresija gali būti taikoma, nors ir tenkinamos tiesinės regresijos prielaidos. Tiesiog tyrėjams nėra įdomios kintamųjų vidutinės reikšmės. Mus šiame el. vadovėlyje labiau domina kita situacija – kada ir kuo medianos regresija gali pagelbėti, kai tiesinės regresijos prielaidos netenkinamos.

Kada taikoma medianos regresija? Dažniausiai ji rekomenduojama, kai duomenys turi išskirčių ir / arba kai nepatenkinta normalumo prielaida. Heteroskedastiškumas jai neturi didelės įtakos.

Mediana nejautri išskirtims. Atrodytų, kad ir medianos regresija turėtų būti nejautri išskirtims. Vis dėlto taip bus tik tada, kai išskirtys nedidelės. Skaičiuojant regresijos koeficientų įverčius, atsižvelgiama į stebinių skirtumą nuo jų medianos (klasikinėje regresijoje – nuo vidurkio). Jeigu išskirtis labai skiriasi³⁴ ir nuo medianos, ir nuo vidurkio, tai matoma įverčiuose. Būtent tokį atvejį nagrinėjame toliau.

Medianos regresija naudotina, kai negalioja normalumo prielaida.

Gautieji modelio parametrų įverčiai nesutampa su gautais taikant tiesinę regresiją.

Interpretacija nesutampa su tiesinės regresijos interpretacija.

Jeigu duomenys turi didelių išskirčių, medianos regresija netinka.

Statistinių rodiklių medianos regresijoje yra labai nedaug. Pseudo R^2 tėra gana netikęs determinacijos koeficiento analogas. Visas tyrimas suvedamas į parametrų įverčius ir jų pasikliautinius intervalus. Norint standartinėms paklaidoms skaičiuoti galima pritaikyti saviranką.

Medianos regresija tėra atskiras (populiariausias) *kvantilių regresijos* atvejis. Pavyzdžiui, galima modeliuoti 10 % didžiausių priklausomo kintamojo reikšmių režio priklausomybes.

Kvantilių regresija dar vadinama mažiausio absoliutinio didumo³⁵, minimalaus absoliutaus nuokrypio³⁶ arba L1 – normos modeliu.

Kol kas medianos (kvantilių) regresija nėra realizuota SPSS programoje.

³⁴ Deja, nurodyti tikslią skaitinę išraišką, kurią viršijus išskirtis jau laikytina didele, neįmanoma. Lygiai kaip ir nurodyti tikslų žmogaus ūgį centimetrais, kurį viršijus jau jis laikytinas aukštu.

³⁵ Angl. trumpinys LAV.

³⁶ Angl. trumpinys MAD.

3.4.2. Medianos regresija su STATA

Visų pirma išbandysime, kaip medianos regresija pritaikoma duomenims, kurie tenkina tiesinės regresijos prielaidas. Jiems taikyti medianos regresiją tikrai galima. Tiriame A duomenis. Įvykdome:

```
qreg satisfaction trust_all
```

Median regression	Number of obs =	241
Raw sum of deviations 444.5 (about 4)	Pseudo R2 =	0.3557
Min sum of deviations 286.3718		

satisfaction	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
trust_all	.9615385	.0522533	18.40	0.000	.8586026	1.064474
_cons	2.95e-08	.2331381	0.00	1.000	-.459268	.459268

Palyginę su 3.3.1 skyrelyje pateiktu tiesinės regresijos modeliu matome, kad regresoriaus *trust_all* koeficiento įvertis (0,961) nedaug skiriasi nuo tiesinės regresijos įverčio (0,892). Nedaug keitėsi ir atitinkamas pasikliautinis intervalas. Konstantos įvertis skiriasi radikalai (2.95e-08, tai užrašas, kuris reiškia, kad 2,95 reikia padalyti iš 10^8 . Gausime beveik 0, todėl ir atitinkama *p* reikšmė lygi 1). Žodžiu, rekomendacija pašalinti iš modelio konstantą, šįkart labai primygtina. $Pseudo R^2 = 0,355 > 0,20$ vis dar rodo regresijos tikimą, nors ir sumažėjo gerokai (nuo 0,557).


Modelio tinkamumą verta patikrinti ir grafiškai. Sukuriame prognozuojamų *satisfaction* reikšmių³⁷ stulpelį duomenyse (pavadiname jį *PRED*) įvykdydami komandą:

```
predict PRED
```

Braižydami grafiką, pasinaudosime duomenyse esančiu respondento identifikaciniu numeriu *idno*. Įvykdome:


```
graph twoway line satisfaction PRED idno
```

³⁷ Beje, tai yra prognozuojamos *satisfaction* medianos reikšmės fiksuotų regresorių reikšmėms.



Prognozuojamų ir stebimų kintamojo *satisfaction* reikšmių grafikai skiriasi nedaug. Matome, kad ir medianos regresijos modelis gerai aprašo duomenų elgesį. Žinoma, galima ir kitaip pateikti duomenų tikimo grafiką³⁸. Pavyzdžiui, išdėliosime visas reikšmes pagal *satisfaction* augimą. Įvykdome komandas:

```
sort satisfaction
gen id = _n
graph twoway line satisfaction PRED id
```



Sumodeliuokime 75 % kvantilio elgesį. Apytikslė tokio modelio interpretacija skambėtų taip: „modelis, aprašantis respondentus, kurie pagal pasitenkinimą politika yra tarp ketvirtadalio labiausiai patenkintų“. Ši interpretacija yra tik apytiksle (bet lengviau suprantama) nei tikslesnis

³⁸ Beje, prognozuojamų ir stebimų reikšmių grafikai bendresnei kvantilių regresijai netinka.

pasakymas, kad modelis sudarytas respondentams, už kurios tiksliai 75 % respondentų yra mažiau patenkinti, o 25 % labiau patenkinti. Įvykdome

```
qreg satisfaction trust_all, q(0.75)
```

```
.75 Quantile regression
Raw sum of deviations   344.5 (about 5.5)
Min sum of deviations 232.6399
Number of obs =      241
Pseudo R2      =      0.3247
```

satisfaction	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
trust_all	.8928571	.0720372	12.39	0.000	.7509483	1.034766
_cons	1.392857	.3213599	4.33	0.000	.7597977	2.025917

Pasikeitė ne tik konstantos įvertis (daugiklis prie *trust_all* liko panašus į tiesinės regresijos modelio daugiklį), bet ir pseudo R^2 . Analogiškai galima apskaičiuoti ir kitų kvantilių regresijas. Pavyzdžiui, norime sumodeliuoti priklausomybę labiausiai patenkintiems politika respondentams. Tada ir interpretuosime, kad pasitenkinimas politika nuo *trust_all* respondentams, kurie yra tarp labiausiai politika patenkintųjų, priklauso štai taip: $satisfaction = 1,39 + 0,89 trust_all$.

Analogiškai galima sumodeliuoti priklausomybę 25 % labiausiai nepatenkintų politika respondentų. STATA yra numatyta galimybė pateikti kelių kvantilių regresijos modelius iškart. Įvykdome

```
sqreg satisfaction trust_all, q(0.25, 0.5, 0.75)
```

```
Simultaneous quantile regression
bootstrap(20) SEs
Number of obs =      241
.25 Pseudo R2 =      0.3695
.50 Pseudo R2 =      0.3557
.75 Pseudo R2 =      0.3247
```

satisfaction	Coef.	Bootstrap Std. Err.	t	P> t	[95% Conf. Interval]	
q25						
trust_all	.9375	.0769749	12.18	0.000	.785864	1.089136
_cons	-.875	.2759415	-3.17	0.002	-1.418588	-.3314119
q50						
trust_all	.9615385	.0490163	19.62	0.000	.8649793	1.058098
_cons	2.95e-08	.1892589	0.00	1.000	-.3728284	.3728285
q75						
trust_all	.8928571	.0776942	11.49	0.000	.7398042	1.04591
_cons	1.392857	.4082513	3.41	0.001	.5886269	2.197087

Liekamosios paklaidos, vykdant šią komandą, buvo vertinamos savirankos metodu. Matome, kad koeficientai prie *trust_all* daug nesiskiria, o jų pasikliautiniai intervalai labai persidengia. Tai leidžia įtarti, kad modeliuose reikšmingai skiriasi tik konstantos. Parodysime, kad 75 % ir 25 % kvantilių regresijų koeficientai prie *trust_all* statistiškai reikšmingai nesiskiria. Įvykdome:

```
test[q25]trust_all = [q75]trust_all
```

```
( 1) [q25]trust_all - [q75]trust_all = 0
```

```
F( 1, 239) = 0.17
Prob > F = 0.6817
```

Matome, kad $p = 0,68 > 0,05$. Analogiškai įsitikiname, kad statistiškai reikšmingai nesiskiria ir medianos regresijos modelio koeficientas prie *trust_all*. Konstantas palyginame, įvykdydami:

```
test[q25]_cons = [q75]_cons
```

```
( 1) [q25]_cons - [q75]_cons = 0
```

```
F( 1, 239) = 30.69
Prob > F = 0.0000
```

Matome, kad $p = 0,00 < 0,05$. Taigi modelių konstantos skiriasi statistiškai reikšmingai.

Tyrimo požiūriu šie rezultatai nėra labai įdomūs. Kur kas būtų įdomiau, jeigu būtų pavykę nustatyti, kad labiau politika patenkintiems *trust_all* įtaka yra silpnesnė nei politika nepatenkintiems. Taigi tirtiems duomenims 75 % arba 25 % kvantilių regresijų išskyrimas ir aprašymas nėra prasmingas.

Be modelio konkrečiam kvantiliui, galima sumodeliuoti ir pirmojo ir trečiojo kvartilių skirtumą (t. y. 0,75 ir 0,25 kvantilių skirtumą). Toks modelis gali turėti prasmę, jeigu norime išryškinti modelių skirtumus tarp palankiai ir nelabai palankiai vertinančių politinę padėtį. Įvykdome

```
iqreg satisfaction trust_all, q(0.25, 0.75)
```

```
.75-.25 Interquantile regression
bootstrap(20) SEs
```

```
Number of obs = 241
.75 Pseudo R2 = 0.3247
.25 Pseudo R2 = 0.3695
```

satisfaction	Coef.	Bootstrap Std. Err.	t	P> t	[95% Conf. Interval]	
trust_all	-.0446429	.0872086	-0.51	0.609	-.2164385	.1271528
_cons	2.267857	.418498	5.42	0.000	1.443441	3.092273

Labai politika patenkintų ir mažai patenkintų požiūrio į politiką skirtumas nuo *trust_all* priklauso štai taip: *Skirtumas satisfaction* = 2,27 – 0,044 *trust_all*.

Regresorius *trust_all* tapo statistiškai nereikšmingas. Tai dar kartą patvirtina jau anksčiau gautą išvadą, kad priklausomybė nuo *trust_all* tokia pati ir labiau politika patenkintų ir menčiau patenkintų respondentų. Kvartilių skirtumo regresiją nagrinėti reikia tik tada, jeigu manome, kad atotrūkis tarp požiūrių kinta. Šiuo atveju tai buvo neaktualu. Apskritai socialiniuose tyrimuose kvartilių skirtumo regresija naudojama retai.

Pritaikysime medianos regresiją B duomenims. Primename, kad netenkinamos homoskedastiškumo prielaidos. Įvykdome

qreg K37suminis K32 K33_4						
Median regression			Number of obs = 124			
Raw sum of deviations			271 (about 16)			
Min sum of deviations			226.5			
			Pseudo R2 = 0.1642			
K37suminis	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
K32	1	.2029565	4.93	0.000	.598194	1.401806
K33_4	1.5	.3295227	4.55	0.000	.8476229	2.152377
_cons	5.5	1.560052	3.53	0.001	2.411466	8.588534

Matome, kad koeficientų įverčiai gerokai skiriasi nuo tiesinės regresijos modelio (pvz., konstantos įvertis 5,5 daug mažesnis už 7,412 iš tiesinės regresijos).

Minėjome, kad medianos regresijoje taip pat galima taikyti savirankos parinktį. Galima įvykdyti 1000 replikacijų saviranką taip:

```
bsqreg K37suminis K32 K33_4, reps(1000)
```

Vis dėlto toks metodas pasikliautiniams intervalams skaičiuoti nėra labai geras. Nors standartinės paklaidos ir surandamos savirankos metodu, pasikliautiniai intervalai apskaičiuojami pagal formules, tinkamas *normaliesiems* duomenims. O pati medianos regresija skirta duomenims, kurie *nėra normalieji*. Todėl geriau ir pačius intervalus konstruoti, atsižvelgiant į saviranką. Įvykdome:

```
bootstrap "qreg K37suminis K32 K33_4" _b[K32] _b[K33_4] _b[_cons], reps(1000)
```


Nesunku suprasti, kad „_b[regresorius]“ nurodo, kuriam regresoriui bus konstruojamas pasikliautinis intervalas. Savirankos replikacijų skaičius nurodomas reps(...). Nereikia pasirinkti labai didelio skaičiaus, nes skaičiavimai truks daug laiko. Manoma, kad saviranka su 1000 replikacijų yra visiškai pakankama.

```
command:      qreg k37suminis k32 k33_4
statistics:   _bs_1      = _b[k32]
              _bs_2      = _b[k33_4]
              _bs_3      = _b[_cons]
```

Bootstrap statistics

Number of obs = 124
Replications = 1000

Variable	Reps	Observed	Bias	Std. Err.	[95% Conf. Interval]	
_bs_1	1000	1	-.0610312	.1993424	.6088221 .3333333	1.391178 1.2 (N) (P)
_bs_2	1000	1.5	-.1910651	.4267538	.6625633 .5	2.337437 2 (N) (P)
_bs_3	1000	5.5	.9099349	2.074094	1.429919 3 3	9.570081 10.6 (N) (P) (BC)

Note: N = normal
P = percentile
BC = bias-corrected

Gavome trimis būdais įvertintus koeficientų pasikliautinius intervalus. Didelių skirtumų tarp rezultatų vis dėlto nėra. Dažniausiai rekomenduojama cituoti (BC) metodu gautuosius pasikliautinius intervalus. BC³⁹ metodas pateikia įverčius, kai atsižvelgiama į galimą jų paslinktumą.

Reziumuodami galime konstatuoti, kad heteroskedastiškiems B duomenims medianos regresija yra tinkama tiesinės regresijos alternatyva. Primename, kad B duomenims galima naudoti ir stabilizuotų liekamųjų paklaidų regresiją. Kurį regresijos modelį pasirinkti, priklauso tik nuo tyrėjo. Įprasčiau taikyti tiesinę regresiją ir jos modifikacijas.

Skyrelio pabaigoje ištirsime, kaip medianos regresijos modelis tinka C duomenims:

Median regression

Raw sum of deviations 285 (about 16)

Min sum of deviations 238.9255

Number of obs = 125

Pseudo R2 = 0.1617

k37suminis	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
k32	1	.1948748	5.13	0.000	.6142258	1.385774
k33_4	.1382979	.0053317	25.94	0.000	.1277433	.1488524
_cons	11.30851	.7223108	15.66	0.000	9.878624	12.7384

³⁹ Angl. *bias corrected*.

Gauname, kad beveik visi koeficientai yra panašūs į tiesinės regresijos koeficientus, o ne į B duomenų medianos regresijos koeficientus. C duomenys nuo B duomenų skyrėsi ryškia išskirtimi. Medianos regresija jos „nenukenksmino“.

Medianos regresija nėra tinkama duomenims, kuriuose yra išskirčių.

Jeigu duomenys nėra normalieji ir turi išskirtis, pagrįsto ir tinkamo prognozuoti regresijos modelio sudaryti nepavyks.

3.4.3. Medianos regresija su SAS

Visų pirma išbandysime, kaip medianos regresija atrodo duomenims, kurie tenkina tiesinės regresijos prielaidas. Jiems taikyti medianos regresiją tikrai galima. Tiriame A duomenis. Įvykdome:

```
proc Quantreg data=Est_A;
model satisfaction=trust_all /quantile=.5 diagnostics;
test_trust: test trust_all / lr wald;
run;
```


Number of Observations Read	242
Number of Observations Used	242

Summary Statistics						
Variable	Q1	Median	Q3	Mean	Standard Deviation	MAD
trust_all	2.8000	4.2000	5.6000	4.1192	1.8801	2.0756
satisfaction	2.5000	4.0000	5.5000	4.0620	2.2505	2.2239

Parameter Estimates				
Parameter	DF	Estimate	95% Confidence Limits	
Intercept	1	0.0000	-0.3109	0.3973
trust_all	1	0.9615	0.7355	1.0438

Diagnostics		
Obs	Standardized Residual	Outlier
84	3.6472	*

Diagnostics Summary		
Observation Type	Proportion	Cutoff
Outlier	0.0041	3.0000



Test test_trust Results				
Test	Test Statistic	DF	Chi-Square	Pr > ChiSq
Wald	198.2871	1	198.29	<.0001
Likelihood Ratio	153.3561	1	153.36	<.0001

Rezultatų išsklotinėje pirmiausia pateikiama kintamųjų charakteristikų lentelė. Lentelėje **Parameter Estimates** pateikiami regresijos koeficientų įverčiai ir pasikliautiniai jų intervalai. Palyginę su 3.3.1 skyrelyje pateiktu tiesinės regresijos modeliu, matome, kad regresoriaus *trust_all* koeficiento įvertis (0,961) nedaug skiriasi nuo tiesinės regresijos įverčio (0,892). Nedaug keitėsi ir atitinkamas pasikliautinis intervalas. Lentelėje **Test test_trust Results** yra *trust_all* reikšmingumo tikrinimo rezultatai. Kadangi $p < 0,0001$ tiek Voldo, tiek Lr kriterijams – regresorius *trust_all* yra statistiškai reikšmingas. Konstantos įvertis skiriasi radikaliai (jis beveik lygus 0). Žodžiu, rekomendacija pašalinti iš modelio konstantą šikart labai primygtina. Lentelėse **Diagnostics** ir **Diagnostics Summary** pateikiama informacija apie stebinius, kurie labiausiai netinka modeliui – standartizuota liekana didesnė už 3^{40} . Yra viena „išskirtis“ ir tai sudaro $1/242 = 0,0041$ visos imties. Taigi mūsų teiginys, kad duomenys A neturi išimčių, nėra visai tikslus, bet ši išimtis nėra „įtakinga“.

Pseudo R^2 skaičiuojamas, todėl apie modelio tinkamumą sprendžiame žiūrėdami į koeficientų reikšmingumo testų rezultatus ir grafikus.

Rezultatų išsklotinėje taip pat pateikiamas kintamųjų ir *satisfaction* išsibarstymo grafikas kartu su regresijos tiese. Vizualiai matome, kad taškai nėra „koncentruotai“ išsidėstę tiesės atžvilgiu, todėl negalima tikėtis gero suderinamumo su tiesiniu modeliu. Dar galima grafiškai palyginti stebėtas *satisfaction* reikšmes su reikšmėmis, gautomis prognozei pritaikius pirmiau aprašytąjį regresijos modelį. Braižydami grafiką, pasinaudosime duomenyse esamu respondento identifikaciniu numeriu *idno*. Įvykdome

```
proc quantreg data=Est;
    model satisfaction = trust_all / quantile=.5;
    output out=new p=pred;
run;quit;
```


⁴⁰ Žinome, kad išskirtys nustatomos pagal DFBetas arba Kuko matą. Čia dar vienas būdas.

```

data nauj;
    set new;
    id=_N_;
    if _N_ le 30;
run;

proc gplot data=nauj;
    symbol i=spline v=circle h=2 pointlabel=("idno");
    plot satisfaction*id pred*id / overlay;
run;

```



Reikia pažymėti, kad grafike pateikta tik 30 reikšmių porų. Kai stebinių labai daug, ką nors įžiūrėti grafike yra sunku. Prognozuojamų ir tikrųjų kintamojo *satisfaction* reikšmių grafikai panašūs. Matome, kad ir medianos regresijos modelis neblogai aprašo duomenų elgesį.

Sumodeliuokime 75 % kvantilio elgesį. Apytikslė tokio modelio interpretacija skambėtų taip: „modelis, aprašantis pasitenkinimą politika ketvirtadalio labiausiai patenkintų“. Ši interpretacija yra tik apytikslė (bet lengviau suprantama) nei tikslesnis pasakymas, kad modelis sudarytas

respondentams, už kuriuos tiksliai 75 % respondentų yra mažiau patenkinti, o 25 % labiau patenkinti. Įvykdome

```
proc Quantreg data=Est_A;
model satisfaction=trust_all /quantile=.75;
test_trust: test trust_all / lr wald;
run;
```

Parameter Estimates				
Parameter	DF	Estimate	95% Confidence Limits	
Intercept	1	1.3929	0.6602	2.5785
trust_all	1	0.8929	0.7007	1.0603

Test test_trust Results				
Test	Test Statistic	DF	Chi-Square	Pr > ChiSq
Wald	185.9811	1	185.98	<.0001
Likelihood Ratio	122.3447	1	122.34	<.0001

Trumpumo dėlei rezultatų nekomentuojame. Analogiškai galima apskaičiuoti ir kitų kvantilių regresijas. Kada yra prasmė skaičiuoti 0,75 kvantilio regresiją? Pavyzdžiui, norime modeliuoti priklausomybę labiausiai patenkintų politika respondentų. Tada teigsime, kad pasitenkinimas politika nuo regresoriaus *trust_all* respondentams, kurie yra tarp labiausiai politika patenkintųjų, priklauso štai taip:

$$satisfaction = 1,39 + 0,89 \text{ trust_all}.$$

Kaip interpretuosime šį modelį. Tarkime *trust_all*=6, tada

$$satisfaction = 1,39 + 0,89*6 = 6,73.$$

Sakysime, kad tikėtina, jog ne mažiau ketvirtadalis respondentų, įvertinę *trust_all* šešetu, *satisfaction* įvertins 6,73 ir daugiau. Aišku, čia reiktų pažymėti, kad tokia interpretacija galima, jei modelis patikimas. Kadangi *satisfaction* yra sveikaskaitis dydis, tai turėtume pasakyti aptakiau:

„tikėtina, jog apie ketvirtadalį respondentų, įvertinę *trust_all* ketvertu, *satisfaction* įvertins 7 ir daugiau“.


Analogiškai galima sumodeliuoti priklausomybę 25 % labiausiai nepatenkintų politika respondentų. Atlikime trijų kvantilinių regresijų (0,25;0,5;0,75) analizę, pavaizduokime kintamųjų *trust_all* ir *satisfaction* išsibarstymo grafiką ir nubrėžkime regresijos lygtis.

Parameter Estimates				
Parameter	DF	Estimate	95% Confidence Limits	
Intercept	1	-0.8750	-1.6415	-0.1200
trust_all	1	0.9375	0.7387	1.0926

Parameter Estimates				
Parameter	DF	Estimate	95% Confidence Limits	
Intercept	1	0.0000	-0.3109	0.3973
trust_all	1	0.9615	0.7355	1.0438

Parameter Estimates				
Parameter	DF	Estimate	95% Confidence Limits	
Intercept	1	1.3929	0.6602	2.5785
trust_all	1	0.8929	0.7007	1.0603

Test test_trust Results					
Quantile	Test	Test Statistic	DF	Chi-Square	Pr > ChiSq
0.25	Wald	172.7449	1	172.74	<.0001
0.25	Likelihood Ratio	131.0713	1	131.07	<.0001
0.50	Wald	198.2871	1	198.29	<.0001
0.50	Likelihood Ratio	153.3561	1	153.36	<.0001
0.75	Wald	185.9811	1	185.98	<.0001
0.75	Likelihood Ratio	122.3447	1	122.34	<.0001



Parametrų įverčių ir jų reikšmingumo neaptarinėsimė. Ką galima pasakyti apie grafiką? Matome, kad tiesės yra lygiagrečios – regresijos lygtis skiriasi tik konstanta. Fiksuotoms *trust_all* reikšmėms galime pasakyti, kokia yra prognozuojama kintamojo *satisfaction* 25,50 ir 75 procentų kvantilio reikšmė. Pavyzdžiui, kai *trust_all* 4, tai pažiūrėję į grafiką, galime pasakyti, kad *satisfaction* prognozuojamas 25 kvantilis ~2, 50 ~3, 75 ~4, t. y. tikėtina, kad tarp respondentų, kurių *trust_all* balas lygus 4, 25 procentų *satisfaction* reikšmė ne didesnė kaip 2, 50 procentų ne didesnė kaip 3 ir 75 procentų ne didesnė kaip 4.

Pritaikysime medianos regresiją B duomenims. Primename, kad jie netenkina homoskedastiškumo prielaidos. Įvykdome

```
proc Quantreg data=lams_B;
model k37suminis = k32 k33_4 /quantile=.5 diagnostics;
test_koef: test k32 k33_4 /lr wald;
run;
```


Parameter Estimates				
Parameter	DF	Estimate	95% Confidence Limits	
Intercept	1	5.5000	0.0813	9.9971
K32	1	1.0000	0.2430	1.2029
K33_4	1	1.5000	-0.3307	2.1018

Test test_koef Results				
Test	Test Statistic	DF	Chi-Square	Pr > ChiSq
Wald	97.4748	2	97.47	<.0001
Likelihood Ratio	29.3099	2	29.31	<.0001

Matome, kad koeficientų įverčiai gerokai skiriasi nuo tiesinės regresijos modelio (pvz., konstantos įvertis 5,5 daug mažesnis už 7,412 iš tiesinės regresijos).

Reziumuodami galime konstatuoti, kad heteroskedastiškiems B duomenims medianos regresija yra tinkama tiesinės regresijos alternatyva. Primename, kad B duomenims galima naudoti ir stabilizuotų liekamųjų paklaidų regresiją. Kurį regresijos modelį pasirinkti, priklauso tik nuo tyrėjo. Labiau įprasta taikyti tiesinę regresiją ir jos modifikacijas.

Skyrelio pabaigoje ištirsime, kaip medianos regresijos modelis tinka C duomenims:

Įvykdome:

```
proc Quantreg data=lams_C;
model k37suminis = k32 k33_4 /quantile=.5 diagnostics;
test_koef: test k32 k33_4 /lr wald;
run;
```

Parameter Estimates				
Parameter	DF	Estimate	95% Confidence Limits	
Intercept	1	11.3085	11.0725	13.3861
K32	1	1.0000	0.4732	1.2083
K33_4	1	0.1383	-Infinity	Infinity

Gauname, kad beveik visi koeficientai yra panašūs į tiesinės regresijos koeficientus, o ne į B duomenų medianos regresijos koeficientus. C duomenys nuo B duomenų skyrėsi ryškia išskirtimi. Medianos regresija jos „nenukenksmino“.

Medianos regresija nėra tinkama duomenims, kurie turi didelių išskirčių.

Jeigu duomenys nėra normalūs ir turi dideles išskirtis, jokio gero regresijos modelio sudaryti nepavyks.

SAS programoje medianos regresinei analizei yra naudojama *proc quantreg* procedūra. Šios procedūros sintaksė atrodo taip:

```
PROC QUANTREG <options> ;  
BY variables ;CLASS variables ;  
EFFECT name = effect-type ( variables </ options> ) ;  
ID variables ;MODEL response = independents </ options> ;  
OUTPUT <OUT= SAS-data-set> <options> ;  
PERFORMANCE <options> ;  
TEST effects </ options> ;  
WEIGHT variable ;
```

Būtiną procedūros sakinį yra **model**. **Model** parametro reikšmė – modelio pavidalas.

Scenarijus :

```
/* A duomenys */  
proc Quantreg data=Est_A;  
model satisfaction=trust_all /quantile=.5 diagnostics;  
test_trust: test trust_all / lr wald;  
run;  
/* 0.75 */  
proc Quantreg data=Est_A;  
model satisfaction=trust_all /quantile=.75;  
test_trust: test trust_all / lr wald;
```

```

run;
/* kvantilių procesas */
proc Quantreg data=Est_A;
model satisfaction=trust_all /quantile= 0.25 to 0.75 by 0.25;
test_trust: test trust_all / lr wald;
run;
/* verta įdėti quantile= 0.05 to 0.95 by 0.05
      plot=quantplot; --- 19 kvantilių*/
/*=====*/
/* B duomenys */
/*===== */
proc Quantreg data=lams_B;
model k37suminis = k32 k33_4 /quantile=.5 diagnostics;
test_koef: test k32 k33_4 / lr wald;
run;
/* 0.75 */
proc Quantreg data=lams_B;
model k37suminis = k32 k33_4 /quantile=.75;
test_k32: test k32 / lr wald;
run;
/* kvantilių procesas */
proc Quantreg data=lams_B;
model k37suminis = k32 k33_4 /quantile= 0.25 to 0.75 by 0.25;
test_k32: test k32 / lr wald;
run;
/*=====*/
/* C duomenys */
proc Quantreg data=lams_C;
model k37suminis = k32 k33_4 /quantile=.5 diagnostics;
test_koef: test k32 k33_4 / lr wald;
run;

```

3.4.4. Medianos regresija su R

Visų pirma išbandysime, kaip medianos regresija atrodo duomenims, kurie tenkina tiesinės regresijos prielaidas. Jiems taikyti medianos regresiją tikrai galima. Tiriame A duomenis. Įvykdome:

```
library(quantreg)
q1 <- rq(satisfaction~trust_all,tau = 0.5,data=dta)
summary(q1)
q0 <- rq(satisfaction~1,tau = 0.5,data=dta)
rsquare<-1-q2$rho/q0$rho
rsquare
```

```
> summary(q1)

Call: rq(formula = satisfaction ~ trust_all, tau = 0.5, data = ldta)

tau: [1] 0.5

Coefficients:
      coefficients lower bd upper bd
(Intercept) 0.00000  -0.29447  0.44879
trust_all    0.96154    0.80233  1.04672
```

```
> rsquare
[1] 0.355744
```

Palyginę su 3.1.3 skyrelyje pateiktu tiesinės regresijos modeliu matome, kad regresoriaus *trust_all* koeficiento įvertis (0,961) nedaug skiriasi nuo tiesinės regresijos įverčio (0,892). Nedaug keitėsi ir atitinkamas pasikliautinis intervalas. Konstantos įvertis lygus 0. Žodžiu, rekomendacija pašalinti iš modelio konstantą šįkart labai primygtina. Pseudo $R^2 = 0,355$ yra priimtino didumo, nors gerokai mažesnis nei buvo (0,557), bet norime priminti, kad pseudo R^2 nėra patikimas medianos regresijos modelio matas (jo savybės nebeatitinka „tradicinio“ R^2 savybių, todėl ir pseudo).


Galima grafiškai palyginti stebėtas *satisfaction* reikšmes su reikšmėmis, gautomis prognozei pritaikius pirmiau aprašytąjį regresijos modelį. Braižydami grafiką, pasinaudosime duomenyse esančiu respondento identifikaciniu numeriu *idno*. Įvykdome:

```
plot(q1$fit[1:20],type="b",col=2,ylim=c(0,10),lwd=2,ylab="satisfaction",xlab="idno",
     main="stebimos, prognozuojamos reikšmės",xaxt="n")

lines(dta$satisfaction[1:20],type="b",lwd=2, col=4)

axis(1,at=c(1:20),labels=dta$idno[1:20],las=2)

legend(c(4.5,4.5), c(10,10), c("Prognozuojamos", "Stebimos"), col = c(2,4), pch=10)
```



Reikia pažymėti, kad grafike pateikta tik 20 reikšmių porų. Kai stebinių labai daug, ką nors įžiūrėti grafike yra sunku. Prognozuojamų ir tikrųjų kintamojo *satisfaction* reikšmių grafikai skiriasi nedaug. Matome, kad ir medianos regresijos modelis gerai aprašo duomenų elgesį.

Sumodeliuokime 75 % kvantilio elgesį. Apytikslė tokio modelio interpretacija skambėtų taip: „modelis, aprašantis respondentus, kurie pagal pasitenkinimą politika yra tarp ketvirtadalio labiausiai patenkintų“. Ši interpretacija yra tik apytikslė (bet lengviau suprantama) nei tikslesnis pasakymas, kad modelis sudarytas respondentams, už kuriuos tiksliai 75 % respondentų yra mažiau patenkinti, o 25 % labiau patenkinti. Įvykdome

```
q3 <- rq(satisfaction~trust_all,tau = 0.75,data=dta)
summary(q3)
```

Call: `rq(formula = satisfaction ~ trust_all, tau = 0.75, data = dta)`

tau: [1] 0.75

Coefficients:

	coefficients	lower bd	upper bd
(Intercept)	1.39286	0.84105	2.09672
trust_all	0.89286	0.78522	1.01877


Pasikeitė ne tik konstantos įvertis (daugiklis prie *trust_all* liko panašus į tiesinės regresijos modelio daugiklį), bet ir pseudo R^2 . Analogiškai galima ir kitų kvantilių regresijas. Kada yra prasmė skaičiuoti kvantilio regresiją? Kai norime iš visos respondentų grupės pasirinkti dalį, o duomenis panaudoti visus. Pavyzdžiui, sumodeliuoti priklausomybę labiausiai patenkintiems politika respondentams. Tada ir interpretuosime, kad pasitenkinimas politika nuo *trust_all* respondentams, kurie yra tarp labiausiai politika patenkintųjų, priklauso štai taip:

$$satisfaction = 1,39 + 0,89 trust_all.$$

Analogiškai galima sumodeliuoti priklausomybę 25 % labiausiai nepatenkintų politika respondentų. Pavaizduokime kintamųjų *trust_all* ir *satisfaction* išsibarstymo grafiką ir nubrėžkime trijų kvantilinių regresijų (0,25; 0,5; 0,75) regresijos lygtis.

Įvykdome

```
q2 <- rq(satisfaction~trust_all,tau = 0.5,data=dta)
summary(q2)
# 0.75 kvantilio regresija
q3 <- rq(satisfaction~trust_all,tau = 0.75,data=dta)
summary(q3)
q1 <- rq(satisfaction~trust_all,tau = 0.25,data=dta)
summary(q1)
# Bandydas palyginti
plot(dta$trust_all,dta$satisfaction,xlab="trust_all",ylab="satisfaction")
  abline(q1,col=2)
  abline(q2,col=3,lwd=2,lty=2)
  abline(q3,col=4,lwd=3,lty=3)
```



Ką galima pasakyti apie šį grafiką. Matome, kad tiesės yra lygiagrečios – regresijos lygtis skiriasi tik konstanta. Fiksuotoms *trust_all* reikšmėms galime pasakyti, kokia yra prognozuojama kintamojo *satisfaction* 25,50 ir 75 procentų kvantilio reikšmė. Pavyzdžiui, kai *trust_all* -4, tai, pažiūrėję į grafiką, galime pasakyti, kad *satisfaction* prognozuojamas 25 kvantilis ~2, 50 ~3, 75 ~4, t. y. tikėtina, kad respondentų, kurių *trust_all* balas lygus 4,25 procentų *satisfaction* reikšmė ne didesnė kaip 2, 50 procentų ne didesnė kaip 3 ir 75 procentai – ne didesnė kaip 4.

Liekamosios paklaidos, vykdant šią komandą, buvo vertinamos savirankos metodu. Matome, kad koeficientai prie *trust_all* daug nesiskiria, o jų pasikliautiniai intervalai labai persidengia. Tai leidžia įtarti, kad modeliuose reikšmingai skiriasi tik konstantos.

Tyrimo požiūriu šie rezultatai nėra labai įdomūs. Kur kas būtų įdomiau, nepavykus nustatyti, kad labiau politika patenkintiems *trust_all* įtaka yra silpnesnė nei politika nepatenkintiems. Taigi tirtiems duomenims išskirti 75 % arba 25 % kvantilių regresijas ir jas aprašyti nėra prasminga.

Pritaikysime medianos regresiją B duomenims. Primename, kad jiems netenkinama homoskedastiškumo prielaida. Įvykdome

```
q1 <- rq(K37suminis~K32+K33_4,tau = 0.5,data=dta)
summary(q1)
```

```
Call: rq(formula = K37suminis ~ K32 + K33_4, tau = 0.5, data = dta)

tau: [1] 0.5

Coefficients:
              coefficients      lower bd      upper bd
(Intercept) 5.500000e+00 2.388020e+00 1.797693e+308
K32          1.000000e+00 4.257100e-01 1.165610e+00
K33_4        1.500000e+00 6.011100e-01 3.039210e+00
Warning message:
In rq.fit.br(x, y, tau = tau, ci = TRUE, ...) : Solution may be nonunique
```

Matome, kad koeficientų įverčiai gerokai skiriasi nuo tiesinės regresijos modelio (pvz. konstantos įvertis 5,5 daug mažesnis už 7,412 iš tiesinės regresijos).

Reziumuodami galime konstatuoti, kad heteroskedastiškiems B duomenims medianos regresija yra tinkama tiesinės regresijos alternatyva. Primename, kad B duomenims galima naudoti ir stabilizuotų liekamųjų paklaidų regresiją. Kurį regresijos modelį pasirinkti, priklauso tik nuo tyrėjo. Įprasčiau taikyti tiesinę regresiją ir jos modifikacijas.

Skyrelio pabaigoje ištirsime, kaip medianos regresijos modelis tinka C duomenims:

```
Call: rq(formula = K37suminis ~ K32 + K33_4, tau = 0.5, data = dta)

tau: [1] 0.5

Coefficients:
              coefficients      lower bd      upper bd
(Intercept) 1.130851e+01 1.120741e+01 1.327734e+01
K32          1.000000e+00 5.972600e-01 1.139500e+00
K33_4        1.383000e-01 -1.797693e+308 1.797693e+308
Warning message:
In rq.fit.br(x, y, tau = tau, ci = TRUE, ...) : Solution may be nonunique
```

Gauname, kad beveik visi koeficientai yra panašūs į tiesinės regresijos koeficientus, o ne į B duomenų medianos regresijos koeficientus. C duomenys nuo B duomenų skyrėsi ryškia išskirtimi. Medianos regresija jos „nenukenksmino“.

Medianos regresija nėra tinkama duomenims, kurie turi didelių išskirčių.

Jeigu duomenys nėra normalieji ir turi didelių išskirčių, jokio gero regresijos modelio sudaryti nepavyks.

Scenarijus :

```
#
# Kvantilių regresija (A duomenys)
#
ddd<-read.csv2("ESS4EE_s.csv",na.strings = "NA",stringsAsFactors=FALSE)
library(quantreg)
mode(dta$satisfaction)="numeric"
mode(dta$trust_all)="numeric"
newdata <- subset(ddd,agea>= 20 & agea<= 40 & gndr == 1 & happy < 11 & satisfaction <
11,select=c(idno,satisfaction,trust_all))
dta <- newdata[complete.cases(newdata), ]
#
# Medianos regresija
#
q1 <- rq(satisfaction~trust_all,tau = 0.5,data=dta)
summary(q1)
q0 <- rq(satisfaction~1,tau = 0.5,data=dta)
rsquare<-1-q2$rho/q0$rho
rsquare
#
# Grafikas
#
plot(q1$fit[1:20],type="b",col=2,ylim=c(0,10),lwd=2,ylab="satisfaction",xlab="idno",main
="stebimos, prognozuojamos reikšmės",xaxt="n")
lines(dta$satisfaction[1:20],type="b",lwd=2, col=4)
axis(1,at=c(1:20),labels=dta$idno[1:20],las=2)
legend(c(4.5,4.5), c(10,10), c("Prognozuojamos", "Stebimos"), col = c(2,4), pch=10)
#
# 0.75 kvantilio regresija
#
q3 <- rq(satisfaction~trust_all,tau = 0.75,data=dta)
summary(q3)
#####
```

```

#
# Kvantiliu regresija (B duomenys)
#####
ddd<-read.csv2("LAMS_s.csv",na.strings = "NA",stringsAsFactors=FALSE)
ddd$K37suminis<-ddd$K37_1+ddd$K37_2+ddd$K37_3+ddd$K37_4;
newdata <- subset(ddd,(K2 == 15 | K2 == 6) & K32 <11 & K33_4 <11 & K37suminis < 99
,select=c(K2,K32,K33_4,K37suminis,K37_1,K37_2,K37_3,K37_4))
dta <- newdata[complete.cases(newdata), ]
q1 <- rq(K37suminis~K32+K33_4,tau = 0.5,data=dta)
summary(q1)
#
# Grafikas
#
plot(q1$fit[1:20],type="b",col=2,ylim=c(0,10),lwd=2,ylab="satisfaction",xlab="idno",main
="stebimos, prognozuojamos reikšmės",xaxt="n")
lines(dta$satisfaction[1:20],type="b",lwd=2, col=4)
axis(1,at=c(1:20),labels=dta$idno[1:20],las=2)
legend(c(4.5,4.5), c(10,10), c("Prognozuojamos", "Stebimos"), col = c(2,4), pch=10)
#
# 0.75 kvantilio regresija
#
q3 <- rq(K37suminis~K32+K33_4,tau = 0.75,data=dta)
summary(q3)
#####
#
# Kvantilių regresija (C duomenys)
#####
ddd<-read.csv2("LAMS_s.csv",na.strings = "NA",stringsAsFactors=FALSE)
ddd$K37suminis<-ddd$K37_1+ddd$K37_2+ddd$K37_3+ddd$K37_4;
newdata <- subset(ddd,(K2 == 15 | K2 == 6) & K32 <11 & K33_4 <11 & K37suminis < 99
,select=c(K32,K33_4,K37suminis))
dta <- newdata[complete.cases(newdata), ]
dta<-rbind(data.frame(K33_4=99, K37suminis= 30,K32 = 5), dta)
q1 <- rq(K37suminis~K32+K33_4,tau = 0.5,data=dta)

```

```

summary(q1)

#

# Grafikas

#

plot(q1$fit[1:20],type="b",col=2,ylim=c(0,10),lwd=2,ylab="satisfaction",xlab="idno",main
="stebimos, prognozuojamos reikšmės",xaxt="n")

lines(dta$satisfaction[1:20],type="b",lwd=2, col=4)

axis(1,at=c(1:20),labels=dta$idno[1:20],las=2)

legend(c(4.5,4.5), c(10,10), c("Prognozuojamos", "Stebimos"), col = c(2,4), pch=10)

#

# 0.75 kvantilio regresija

#

q3 <- rq(K37suminis~K32+K33_4,tau = 0.75,data=dta)

summary(q3)

```

3.5. Netiesinė regresija

3.5.1. Modelio paskirtis

Regresija vadinama tiesine būtent todėl, kad aprašo tik tiesines priklausomybes – regresoriai nekeliama laipsniu ir nedauginami tarpusavyje. Gyvenime ne visos kintamųjų (spėjamos) priklausomybės yra tiesinės. Štai tada ir taikoma netiesinė regresija. Vis dėlto netiesinėje regresijoje išvados daromos labai negriežtai (apie statistinį reikšmingumą ir visokius kriterijus faktiškai galima tik pasvajoti), todėl, jeigu tik galima, jos vengiama.

Kai kuriuos modelius tinkamomis kintamųjų transformacijomis galima paversti tiesiniais. Tada taikoma tiesinė regresija.

Pateiksime keletą pavyzdžių, kada tokios transformacijos įmanomos:

- a) Polinominė regresija: $Y = a + bX + cX^2 + dX^3$. Tada tiesiog sukuriame naujus kintamuosius $Z = X^2, W = X^3$ ir tiriamo modelį $Y = a + bX + cZ + dW$.
- b) Kobo–Daglo produkcijos funkcija $Q = AK^aL^b$. Čia K (kapitalas) ir L (darbo jėga) yra regresoriai, o a, b ir A (technologijos daugiklis) nežinomi parametrai, kuriuos reikia įvertinti. Kadangi Q, A, K ir L yra teigiami dydžiai, tai tiesinį modelį gauname

logaritmuodami abi lygybės puses: $\ln Q = \ln A + a \ln K + b \ln L$. Pažymėję $Y = \ln Q$, $C = \ln A$, $X = \ln K$, $Z = \ln L$, gauname tiesinės regresijos modelį $Y = C + aX + bZ$.

- c) Paprasčiausias Verhulst–Pearl populiacijos augimo modelis: $P(t) = P_0 e^{kt}$. Nežinomas modelio parametras – k . Logaritmuojame abi lygybės puses ir įvedame naujus pažymėjimus: $\ln P = \ln P_0 + kt$, $Y = \ln P - \ln P_0$. Gauname modelį $Y = k t$.

Ne visada tokios transformacijos įmanomos. Pateiksime keletą tipinių netiesinių modelių pavyzdžius iš SPSS 19 aprašo:

Pavadinimas	Išraiška
Asimptotinė regresija	$b1 + b2 * \exp(b3 * x)$
Asimptotinė regresija	$b1 - (b2 * (b3 ** x))$
Tankumo	$(b1 + b2 * x) ** (-1 / b3)$
Gauso	$b1 * (1 - b3 * \exp(-b2 * x ** 2))$
Gompertz	$b1 * \exp(-b2 * \exp(-b3 * x))$
Grąžų	$b1 + b2 * \exp(-b3 * x)$
Richards	$b1 / ((1 + b3 * \exp(-b2 * x)) ** (1 / b4))$
Veibulo	$b1 - b2 * \exp(-b3 * x ** b4)$
Verhulst	$b1 / (1 + b3 * \exp(-b2 * x))$
Derliaus tankio	$(b1 + b2 * x + b3 * x ** 2) ** (-1)$

Žinoma, galima susikurti ir visiškai naują nematytą modelį, pavyzdžiui, varanopsų augimo sąlygiškai inteligentiškoje aplinkoje modelį (VASIA).

Netiesinėje regresijoje modelio išraišką pasirenka tyrėjas.

Visos nežinomų parametų reikšmės vertinamos iteraciniu būdu – jas po truputį keičiant (tą daro programa) ir meldžiantis, kad pasisektų (tą daro tyrėjas). Pradinės nežinomų parametų

reikšmes turi (gali) pasirinkti tyrėjas. Nuo sėkmingo pasirinkimo labai priklauso galutinio modelio tinkamumas. Kaip žinoti, kokias rinktis reikšmes? Manoma, kad modeliotojas turi nujausti, kokie tie parametrai turi būti. Kitaip, ko tą modelį rinktis? Maždaug taip: pažiūrėjome į varanopsų svorio augimo kreivę ir matome – kaip iš akies luptas Gompertz modelis su parametrais $1, \sqrt{2}, \pi$. Nuo jų ir pradedame.

Dar viena nemaloni naujiena – visi įverčiai jautrūs išskirtims. Geriau, kai duomenys jų neturi.

Tikrinant, ar modelis tinka, pasižiūrima į R^2 reikšmę. Jeigu modelis būtų tiesinis, tai R^2 atitiktų determinacijos koeficientą. Dabar tai viso labo determinacijos koeficiento analogas. Gerai duomenims tinkantiems modeliams R^2 nedaug skiriasi nuo vieneto.

Jeigu parametrų koreliacijos didelės, tai *galbūt* modelyje yra per daug parametrų.

Visada rekomenduojama nusibraižyti stebimų ir prognozuojamų reikšmių grafikus ir vizualiai palyginti, ar jie labai skiriasi. Tiesa, jeigu duomenų pakankamai daug, toks grafikas primena kintamo dažnio srovę ir jame sunku ką nors įžiūrėti (bet atrodo įspūdingai).


3.5.2. Netiesinė regresija su SPSS

Pasirinksime tiesinėje regresijoje nagrinėtą respondentų pasitikėjimo politiniu šalies klimatu *satisfaction* priklausomybės nuo pasitikėjimo svarbiausiomis valstybės institucijomis *trust_all* tyrimą (A duomenys). Tirsime 35–40 metų Estijos vyrus ($agea \geq 35$ & $agea \leq 40$ & $gndr = 1$). Pasirenkame tokį modelį su trimis nežinomais parametrais a, b, c :


$$satisfaction = e^{a+b \cdot trust_all} + c \cdot trust_all + e.$$

Kodėl pasirinkome tokią modelio išraišką? Žinome, kad duomenims tinka tiesinė regresija. Pasirinkome modelį, kuris tik truputį bendresnis ir jame atsispindi mūsų tikėjimas, kad *satisfaction* labiau reaguoja į *trust_all* pokyčius. Jeigu $b = 0$, tai faktiškai gauname tiesinę regresiją. Šią informaciją išnaudojame, pasirinkdami pradinės reikšmės $a = 1, b = 0, c = 1$.


Renkamės **Analyze** → **Regression** → **Nonlinear**. Atsidariusiame lange kintamąjį *satisfaction* įkeliam į laukelį **Dependent**. Langelyje **Model Expression** įrašome modelio išraišką su visomis nežinomomis konstantomis: $\exp(a + b \cdot trust_all) + c \cdot trust_all$.



Paspaudę **Parameters** surašome nežinomus parametrus ir pradines jų reikšmes. Renkamės **Continue**.



Pasirenkame **Save**. Pažymime **Predicted values** ir **Residuals**. Renkamės **Continue**.



Jeigu norėtume apriboti galimas parametrų reikšmes (pvz., $c > 0$), tai būtų galima padaryti pasirinkus **Constraints**.

Rezultatų išsklotinė prasideda nuo iteracijų istorijos. Joje matyti, kaip vis kartojant skaičiavimus keitėsi parametrų reikšmės. Procesas nutraukiamas, kai parametrų reikšmės stabilizuojasi. Čia galima sulaukti informacijos apie netikusius parametrų pasirinkimus (neigiamo skaičiaus logaritmovimą ir pan.). Lentelėje **Parameter Estimates** pateikiami parametrų įverčiai.

Parameter Estimates

Parameter	Estimate	Std. Error	95 % Confidence Interval	
			Lower Bound	Upper Bound
a	.237	.538	-.837	1.311
b	.199	.030	.139	.260
c	.279	.392	-.504	1.063

Matome, kad $b = 0,199$ nors ir netoli nulio, bet yra statistiškai reikšmingas. Jeigu nuspręstume, kad modelis tinkamas, šiuos įverčius įstatytume į modelio išraišką. Kitoje lentelėje surašyti parametų koreliacijų įverčiai. Matome, kad c ir a stipriai koreliuoja. Nors modelis ir netiesinis, kintamieji gali vienas kitam „trukdyti“. Galbūt reikėtų ištirti modelį be vieno iš šių parametų.

Correlations of Parameter Estimates

	a	B	c
A	1.000	-.160	-.944
B	-.160	1.000	-.158
C	-.944	-.158	1.000

Kita lentelė **ANOVA** su ANOVA sietusi tiesiogiai, jeigu tirtume tiesinę priklausomybę. SPSS nepateikia jokių p reikšmių, nes netiesiniame modelyje nelabai šiuo kriterijumi galima tikėti, ypač nedidelėms imtims. Dažniausiai visus patenkina R^2 suradimas. Mūsų atveju $R^2 = 0,571$, pakankamai didelis.


ANOVA^a

Source	Sum of Squares	df	Mean Squares
Regression	1548.629	3	516.210
Residual	155.121	67	2.315
Uncorrected Total	1703.750	70	
Corrected Total	361.718	69	


Dependent variable: satisfaction

a. $R^2 = 1 - (\text{Residual Sum of Squares}) / (\text{Corrected Sum of Squares}) = .571$.


Vis dėlto aklaai pasitikėti *vieninteliu* R^2 negalima. Pabandysime vizualiai palyginti tikras *satisfaction* reikšmes su gautomis, naudojant modelį. Spaudžiame **Graphs** → **Legacy Dialogs** → **Line**. Pažymime **Multiple** ir **Values of individual cases**. Spaudžiame **Define**.



Atsidariusiame lange perkeliame *satisfaction* ir *PRED_* į laukelį **Lines Represent**.



Spaudžiame **OK**. Gauname tikrųjų ir prognozuotų reikšmių grafikus. Kuo geresnis prognozavimas, tuo labiau šie grafikai sutampa. Paredagavome grafiką taip, kad kreivės būtų skirtingo storio. Matome, kad modelis gana gerai tinka.




Labai norint įsitikinti liekamųjų paklaidų normalumu (tada labiau galima pasitikėti R^2), galima pritaikyti Šapiro–Vilko kriterijų. Jį aprašėme tiesinės regresijos skyriuje. Surinkę **Analyze** → **Descriptive Statistics** → **Explore** → **Plots**, pažymėję **Normality plots with tests**, į **Dependent List** įkeliamo *RESID* ir spaudžiame **OK**. Gautasis Šapiro–Vilko kriterijus rodo, kad liekamąsias

paklaidas galima laikyti normaliomis ($p = 0,792 > 0,05$). Tą patį leidžia teigti ir Q–Q grafikas (primename – kuo taškai arčiau tiesės, tuo liekamosios paklaidos normalesnės).

Tests of Normality						
	Kolmogorov-Smirnov ^a			Shapiro-Wilk		
	Statistic	df	Sig.	Statistic	df	Sig.
RESID Residuals	.055	70	.200*	.989	70	.792

a. Lilliefors Significance Correction

*. This is a lower bound of the true significance.



Gavome, kad siūlomas modelis tinka duomenims. Ar tai reiškia, kad jau galima užmiršti analogišką tiesinės regresijos modelį? Jokių būdu. Nerašyta taisyklė skelbia, jeigu yra keli daugmaž vienodai gerai tinkami modeliai, tai naudotinas *paprastesnis*. Reikėtų užmesti akį į tiesinės regresijos prognozių grafiką ir tik tada nuspręsti.

Jeigu yra keli vienodai tinkami modeliai, pranašesniu laikomas paprastesnis modelis.

3.5.3. Netiesinė regresija su STATA

Pasirinksim A duomenis ir pakartosime tyrimą, kurį aprašėme ankstesniame skyrelyje. Tirsime 35–40 metų Estijos vyrus (keep if agea >= 35 & agea <= 40 & gndr == 1). Viena iš keisčiausių

STATA kūrėjų užgaidų – praleistas reikšmės (tuščią langelį duomenyse) traktuoti kaip begalybę. Tas sukelia didžiulį nepatogumų skaičiuojant, jeigu duomenyse yra tokių „tuštumų“. Apsisaugome nuo keistųjų STATA kūrėjų fantazijų, pasirinkę galimas baigtines kintamųjų reikšmes: Įvykdome:

```
keep if satisfaction < 30 & trust_all < 30.
```

Tiriamas modelis:

$$satisfaction = e^{a+b \cdot trust_all} + c \cdot trust_all + e.$$

Siekiame įvertinti nežinomus parametrus a , b , c . Surenkame (visi parametrai **būtinai** rašomi riestiniuose skliaustuose: {a} ir pan.) ir įvykdome:

```
nl ( satisfaction = exp({a}+{b}* trust_all ) + {c}* trust_all), initial (a 1 b 0 c 1)
```

Source	SS	df	MS			
Model	1548.62869	3	516.209564	Number of obs =	70	
Residual	155.121307	67	2.31524339	R-squared =	0.9090	
				Adj R-squared =	0.9049	
				Root MSE =	1.521592	
Total	1703.75	70	24.3392857	Res. dev. =	254.3512	

satisfaction	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
/a	.2370719	.5379013	0.44	0.661	-.8365835	1.310727
/b	.1994025	.0304736	6.54	0.000	.1385769	.260228
/c	.2791581	.392484	0.71	0.479	-.5042433	1.06256


Matome, kad $R^2 = 0,909$, t. y. tiesiog fantastiškas, jeigu tai būtų tiesinė regresija. Beje, ir R^2 , ir kitos charakteristikos skiriasi nuo gautųjų SPSS programa. Taip yra todėl, kad vartojami skirtingi algoritmai. SPSS remiasi Levenberg–Marquardt formule, o STATA naudoja patį paprasčiausią mažiausiųjų kvadratų metodą, primenantį tiesinės regresijos modelį. Todėl SPSS rezultatai (nors ir ne tokie puikūs) yra patikimesni. STATA lentelę su parametų galutiniais įverčiais (jie beveik nesiskiria nuo gautųjų SPSS programa), jų pasikliautiniais intervalais ir p reikšmėmis galima naudoti tik kaip *rekomendacijas*. Pavyzdžiui, atsižvelgti, kad modelio koeficientas a buvo statistiškai nereikšmingas ($p = 0,661$), ir todėl prasminga patyrinėti modelį be koeficiento a .

Modelio gerumą visada verta patikrinti ir grafiškai. Sukuriame prognozuojamų *satisfaction* reikšmių stulpelį duomenyse (pavadiname jį *PRED*) įvykdydami komandą:

```
predict PRED
```

Braižydami grafiką, pasinaudosime duomenyse esančiu respondento identifikaciniu numeriu *idno*. Įvykdome:

```
graph twoway line satisfaction PRED idno
```



Matome, kad naujasis modelis tinka duomenims. Tačiau jis sudėtingesnis nei tiesinės regresijos modelis ir turi gerokai mažiau modelio tinkamumą aprašančių charakteristikų.

3.5.4. Netiesinė regresija su SAS

Pasirinksime A duomenis ir pakartosime tyrimą, kurį aprašėme ankstesniame skyrelyje. Tirsime 35–40 m Estijos vyrus (keep if agea >= 35 & agea <= 40 & gndr == 1). Pradiniai duomenys saugomi SAS duomenų bibliotekoje **rgr**. Įvykdome:

```
OPTIONS nofmterr;
data Esta;
keep gndr trust_all satisfaction;
set rgr.ESS4EE_s;
if 35 <= agea <= 40 and gndr=1 and satisfaction <30 and trust_all<30 and satisfaction ne .
and trust_all ne .;
run;
```

Tiriamas modelis:

$$satisfaction = e^{a+b \cdot trust_all} + c \cdot trust_all + e.$$

Siekiame įvertinti nežinomus parametrus a , b , c . Pasirenkame pradines parametrų reikšmes. Pavyzdžiui, $a = 1$ $b = 0,1$ $c = 1$ ir įvykdome⁴¹:

```
proc nlin data=esta;
model satisfaction=exp(a+b*trust_all)+c*trust_all;
parms a=1 b=0.1 c=1;
output out=rez p=pred;
ods output ANOVA=SSdata;
run;
data d1;
  set SSdata(where=(source="Error"));
  SS_1=SS;
run;
data d2;
  set SSdata(where=(source="Uncorrected Total"));
  SS_2=SS;
run;
data koef;
merge d1 d2;
r2=1-SS_1/SS_2;
run;
proc print data=koef;
var r2;
run;
```

Rezultatų išsklotinė prasideda nuo iteracijų istorijos⁴². Joje matyti, kaip vis kartojant skaičiavimus keitėsi parametrų reikšmės. Procesas nutraukiamas, kai jis stabilizuojasi. Čia galima sulaukti informacijos apie netikusius pradinių reikšmių pasirinkimus (neigiamo skaičiaus logaritmovimą ir pan.). Vadinasi, netiesinę regresiją vertėtų taikyti po tiesinės regresijos, nes tiesinės regresijos rezultatai „pasufleruoja“ pradines parametrų reikšmes. Toliau pateikiama **ANOVA** lentelė ir R^2 : **ANOVA** lentelės stulpelyje **Approx Pr>F** pateikiama apytikslė p reikšmė.

⁴¹ Programos tekstas yra ilgas, nes R^2 tenka skaičiuoti patiems.

⁴² Trumpumo dėlei jos čia nepateikiame.

Ji mažesnė už 0,05. Taigi *trust_all* yra statistiškai reikšmingas regresorius. R^2 kaip modelio tikimo matas netiesinėje regresijoje nėra plačiai naudojamas (ne veltui jis vadinamas pseudo R^2). SAS procedūros **nlin** rezultatų išklotinėje jis nėra pateikiamas. Jį pateikiame suskaičiuotą naudojantis ANOVA lentelės duomenimis. Matome, kad $R^2 = 0,907$, t.y. tiesiog fantastiškas, jeigu tai būtų tiesinė regresija. Beje, ir R^2 , ir kitos charakteristikos skiriasi nuo gautųjų SPSS programa (ten $R^2 = 0,571$). Taip įvyksta todėl, kad naudojamos skirtingos R^2 skaičiavimo formulės. SPSS rezultatai (nors ir ne tokie puikūs) yra patikimesni.

Source	DF	Sum of Squares	Mean Square	F Value	Approx Pr > F
Model	3	1548.6	516.2	222.96	<.0001
Error	67	155.1	2.3152		
Uncorrected Total	70	1703.8			

Obs	r2
1	0.90724

Toliau pateikiami parametų įverčiai ir pasikliautinieji jų intervalai (jie beveik nesiskiria nuo gautųjų SPSS ir STATA programomis). Jeigu nuspręstume, kad modelis tinkamas, šiuos įverčius įstatytume į modelio išraišką.

Parameter	Estimate	Approx Std Error	Approximate 95% Confidence Limits	
a	0.2371	0.5379	-0.8366	1.3107
b	0.1994	0.0305	0.1386	0.2602
c	0.2792	0.3925	-0.5042	1.0626

Matome, kad $b = 0,199$ nors ir netoli nulio, bet statistiškai reikšmingas (pasikliautinasis intervalas „neuždengia“ 0). Tiek a , tiek c parametų pasikliautiniai intervalai „uždengia“ 0. Taigi jie nėra statistiškai reikšmingi. Todėl prasminga patyrinėti modelį be koeficiento a (arba c).

Lentelėje **Approximate Correlation Matrix** surašyti parametų koreliacijų įverčiai. Matome, kad c ir a stipriai koreliuoja. Tai dar vienas požymis, kad galbūt reikėtų ištirti modelį be vieno iš šių parametų.


Approximate Correlation Matrix			
	a	b	c
a	1.0000000	-0.1604718	-0.9442245
b	-0.1604718	1.0000000	-0.1583812
c	-0.9442245	-0.1583812	1.0000000

Modelio tinkamumą visada verta patikrinti ir grafiškai. Įvykdome komandą:

```
data nauj;
set rez;
format pred 6.2;
id=_N_;
if _N_ le 30;
run;

proc gplot data=nauj;
symbol i=spline v=circle h=2 pointlabel=("idno");
plot satisfaction*id pred*id / overlay;
run;
```

Braižydami grafiką pasinaudojome duomenyse esančiu respondento identifikaciniu numeriu *idno* (pažymimas prie kiekvieno taško).



Matome, kad naujasis modelis tinka duomenims (pirmiesiems 30-čiai stebinių). Tačiau jis sudėtingesnis nei tiesinės regresijos modelis ir turi kur kas mažiau modelio tinkamumą aprašančių charakteristikų.

SAS'e netiesinei regresinei analizei yra naudojama **proc reg** procedūra. Šios procedūros sintaksė atrodo taip:

```
PROC NLIN <options> ;
  BOUNDS inequality <, ..., inequality> ;
  BY variables ; CONTROL variable <=values> <...variable <=values>> ;
  DER. parameter=expression ;
  DER. parameter.parameter=expression ; ID variables ;
  MODEL dependent=expression ;
  OUTPUT OUT=SAS-data-set keyword=names <...keyword=names> ;
  PARAMETERS <parameter-specification> <,..., parameter-specification>
  < / PDATA=SAS-data-set> ;
  RETAIN variable <=values> <...variable <=values>> ;
```

model ir *parameters* yra būtini *nlin* procedūros sakiniai. **Model** sakinyje aprašomas modelio pavidalas. **Parameters** sakinyje nurodome pradinės parametrų reikšmes.

Scenarijus :

```
OPTIONS nofmterr;
data Esta;
keep idno gndr trust_all satisfaction;
set rgr.ESS4EE_s;
if 35 <= agea <=40 and gndr=1 and satisfaction <30 and trust_all<30 and satisfaction ne .
and trust_all ne .;
run;
proc nlin data=esta;
model satisfaction=exp(a+b*trust_all)+c*trust_all;
parms a=1 b=0 c=1;
output out=rez p=pred;
ods output ANOVA=SSdata;
run;
data d1;
set SSdata(where=(source="Error"));
SS_1=SS;
run;
data d2;
set SSdata(where=(source="Uncorrected Total"));
SS_2=SS;
run;
data koef;
merge d1 d2;
r2=1-SS_1/SS_2;
run;
proc print data=koef;
var r2;
run;
```



```

data nauj;

    set rez;

    format pred 6.2;

    id=_N_;

    if _N_ le 30;

    run;

proc gplot data=nauj;

symbol i=spline v=circle h=2 pointlabel=("#idno");

plot satisfaction*id pred*id / overlay;

run;

```

3.5.5. Netiesinė regresija su R

Pasirinksime A duomenis ir pakartosime tyrimą, kurį aprašėme ankstesniame skyrelyje. Tirsime 35–40 m Estijos vyrus (keep if agea >= 35 & agea <= 40 & gndr == 1). Kadangi duomenis ruošiami įvairiais formatais ir kartais nenurodomi praleistų reikšmių kodai, analizei paliksime tik „teisingas“ nagrinėjamų kintamųjų reikšmes. Įvykdome:

```

dta<-read.csv2("ESS4EE_s.csv",na.strings = "NA",stringsAsFactors=FALSE)
mode(dta$satisfaction)="numeric"
mode(dta$trust_all)="numeric"
ldta<-subset(dta,satisfaction < 30 & trust_all < 30 & agea >= 35 & agea <= 40 & gndr ==
1,select=c(satisfaction,trust_all,gndr))

```

Tiriamas modelis:

$$satisfaction = e^{a+b \cdot trust_all} + c \cdot trust_all + e.$$

Siekiame įvertinti nežinomus parametrus a , b , c . Parenkame pradines a , b , c reikšmes. Žinodami, kad tiesinis modelis neblogai tinka duomenims, renkamės „panašų“ modelį, t. y. pirmiausia parenkame $a = 1, b = 0, c = 1$. Tada įvykdome:

```

nreg<-nls(satisfaction ~ exp(a+b*trust_all)+c*trust_all,start =
list(a=1,b=0.1,c=1),data=ldta)

```

```
summary(nreg)
rsquare<-1-(deviance(nreg)/sum((ldta$satisfaction-mean(ldta$satisfaction))^2))
rsquare
```

Formula: satisfaction ~ exp(a + b * trust_all) + c * trust_all

Parameters:

Estimate Std. Error t value Pr(> |t|)

a 0.23707 0.53790 0.441 0.661

b 0.19940 0.03047 6.543 9.85e-09 ***

c 0.27916 0.39248 0.711 0.479

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.522 on 67 degrees of freedom

Number of iterations to convergence: 4

Achieved convergence tolerance: 2.419e-06

```
> rsquare
[1] 0.5711539
>
```

Rezultatų išsklotinėje yra parametrų įverčiai ir jų p reikšmės (rezultatai beveik nesiskiria nuo gautųjų SPSS, STATA ir SAS programomis). Jeigu nuspręstume, kad modelis tinkamas, šiuos įverčius įstatytume į modelio išraišką. Matome, kad $b = 0,199$ nors ir netoli nulio, bet statistiškai reikšmingas (p reikšmė mažesnė už 0,05). Tiek a , tiek c parametrai nėra statistiškai reikšmingi. Todėl prasminga patyrinėti modelį be koeficiento a (arba c).


$R^2 = 0,571$ pakankamai didelis, tačiau šis matas nėra plačiai naudojamas, todėl modelio tinkamumą verta patikrinti ir grafiškai. Braižydami grafiką, pasinaudosime prognozuojamomis reikšmėmis ir duomenyse esančiu respondento identifikaciniu numeriu *idno*. Įvykdome:

```
plot(fitted(nreg)[1:30],type="b",col=2,ylim=c(0,10),lwd=2,ylab="satisfaction",xlab=
"idno",main="stebimos, prognozuojamos reikšmės",xaxt="n")

lines(ldta$satisfaction[1:30],type="b",lwd=2, col=4)
```

```
axis(1,at=c(1:30),labels=ldta$idno[1:30],las=2)
```

```
legend('topright', c("Prognozuojamos", "Stebimos"), col = c(2,4), pch=10)
```



Matome, kad naujasis modelis gana neblogai tinka duomenims (patikrinome 30-čiai pradinių reikšmių, kad grafikas būtų vaizdesnis). Tačiau jis sudėtingesnis nei tiesinės regresijos modelis ir turi kur kas mažiau modelio tinkamumą aprašančių charakteristikų.

Scenarijus:

```
dta<-read.csv2("ESS4EE_s.csv",na.strings = "NA",stringsAsFactors=FALSE)
```

```
mode(dta$satisfaction)="numeric"
```

```
mode(dta$trust_all)="numeric"
```

```
ldta<-subset(dta,satisfaction < 30 & trust_all < 30 & agea >= 35 & agea <= 40 & gndr ==  
1,select=c(satisfaction,trust_all,gndr,idno))
```

```
nreg<-nls(satisfaction~ exp(a+b*trust_all)+c*trust_all,start =
```

```

list(a=1,b=0.1,c=1),data=ldta)
summary(nreg)
rsquare<-1-(deviance(nreg)/sum((ldta$satisfaction-mean(ldta$satisfaction))^2))
rsquare
# Grafikas

plot(fitted(nreg)[1:30],type="b",col=2,ylim=c(0,10),lwd=2,ylab="satisfaction",xlab="idno",
     ,main="stebimos, prognozuojamos reikšmės",xaxt="n")
lines(ldta$satisfaction[1:30],type="b",lwd=2, col=4)
axis(1,at=c(1:30),labels=ldta$idno[1:30],las=2)
legend('topright', c("Prognozuojamos", "Stebimos"), col = c(2,4), pch=10)

```

Uždaviniai

1. Failas **ESS4LT1.sav**. Socialinis Lietuvos respondentų tyrimas 2009 m. spalio – 2010 m. Naudojant kintamuosius *agea* (amžius) ir *gndr* (lytis), atrinkti ne jaunesnės nei 65 metų moteris. Kintamieji

- *trstprl* (pasitikėjimas šalies parlamentu),
- *trstlgl* (pasitikėjimas teisine sistema),
- *trstplt* (pasitikėjimas politikais)

matuojami 10 balų skale nuo 0 (itin nepasitikiu) iki 9 (itin pasitikiu). Reikia:

- ištirti tiesinės regresijos modelį $trstprl = f(trstlgl, trstplt)$;
- kurios tiesinės regresijos prielaidos nepatenkintos;
- kokius modelius gautume, taikydami šio skyrelio tiesinės regresijos alternatyvas.

2. Pateiksime tyrimo „Darbo valandų skaičius ir atlyginimas, 2008 m. birželis“ (http://www.lidata.eu/data/quant/LiDA_SEB_0111_STUDY_01) truputį paredaguotą fragmentą. Pateiktame fragmente 42 lenkų tautybės respondentai atsakė į klausimą, kiek valandų per savaitę jie sutiktų dirbti, jeigu gautų 1 000 LT atlyginimą (*K1*) ir 2 000 LT atlyginimą (*K2*). Sudaryti regresiją,

nusakančią $K2$ priklausomybę nuo $K1$.

- a) Ar patenktos tiesinės regresijos prielaidos?
- a) Kuri tiesinės regresijos alternatyva geriausiai tinka duomenims?
- b) Kaip atrodo atsakymas į b), pašalinus iš duomenų išskirtį?

ID	$K1$	$K2$	ID	1	$K2$	ID	$K1$	$K2$
1	20	26	15	0	50	29	20	40
2	10	25	16	35	35	30	40	40
3	40	40	17	30	30	31	40	40
4	25	34	18	25	35	32	40	40
5	2	20	19	40	40	33	20	30
6	18	22	20	20	30	34	15	25
7	20	30	21	0	15	35	30	30
8	30	40	22	30	30	36	30	40
9	40	40	23	5	1	37	10	20
10	30	30	24	20	30	38	5	7
11	20	25	25	20	25	39	30	40
12	20	40	26	30	45	40	30	35
13	24	40	27	15	20	41	20	30
14	20	35	28	20	40	42	10	15

3. Norint paskatinti kaimo turizmo plėtrą, vienoje besivystančioje šalyje buvo pradėta supirkinėti vikriojo driežo uodegas. Lentelėje pateikta, kiek kasmet po naujojo potvarkio buvo supirkti tokių uodegų.

Metai	Kiekis
1	40
2	113
3	285
4	548


5	836
6	1333
7	2149
8	3233
9	3537
10	4349
11	4566
12	4771
13	4970
14	5025
15	5227

Ištirti supirkto uodegų kiekio priklausomybę nuo metų.

- Ar tinka tiesinė regresija?
- Ar tinka tiesinė regresija, panaudojus logaritminę *Kiekio* transformaciją?
- Patikrinti, ar tinka netiesinės regresijos modelis:

$$Kiekis = \frac{a}{b + e^{ct}},$$

Pradinės parametrų reikšmės $a = 1$, $b = 1$, $c = 0$.




Statistikų greitakalbė

4. DVINARĖ LOGISTINĖ REGRESINĖ ANALIZĖ

Tipinės situacijos, kai taikoma dvinarė logistinė regresinė analizė, yra šios:

- Norime įvertinti onkologinės ligos remisijos po operacijos tikimybę, atsižvelgdami į paciento lytį, amžių, išoperuoto auglio didumą ir kraujo parametrus.
- Tiriamo, kaip požiūris į narystę NATO (pritaria narystei – nepritaria) priklauso nuo respondento amžiaus, tautybės, partiškumo ir metinių pajamų.
- Norime atsakyti į klausimą, kaip kiekviena papildoma su repetitoriumi praleista valanda pakeičia tikimybių išlaikyti egzaminą / neišlaikyti egzamino santykį.

Modeliuojamas *dvireikšmis* kintamasis Y priklauso nuo X, Z, W . Modelio schema:



Kintamasis Y vadinamas *priklausomu kintamuoju*, kintamieji X, Z, W vadinami *regresoriais*. Y įgyjamos reikšmės yra **kodai 0 ir 1**. Ką šie kodai reiškia, priklauso nuo konkretaus tyrimo. Gali būti, kad 1 žymės, jog pacientas susirgo diabetu; o gali ir tai, kad respondentas yra vegetaras. Yra statistinių programų (pvz., SPSS, SAS), kurios automatiškai perkoduoja kiekvieną logistinėje analizėje naudojamą dvireikšmį priklausomą kintamąjį. Skaitiniam kintamajam nuliui keičiama mažesnė reikšmė, simboliniam kintamajam – pirmesnis pagal abėcėlę simbolis.

4.1. Dvinarės logistinės regresijos modelis

4.1.1. Modelio lygtis

Matematinis modelis sudaromas ne pačiam priklausomam kintamajam, o jo tikimybių santykio logaritmui (vadinamajai *logit funkcijai*):

$$\ln \frac{P(Y = 1)}{P(Y = 0)} = C + b_1 X + b_2 Z + b_3 W.$$

Ekvivalentus modelio užrašas yra

$$P(Y = 1) = \frac{e^z}{1 + e^z} = \frac{1}{1 + e^{-z}}, \quad P(Y = 0) = 1 - P(Y = 1).$$

Čia

$$z = C + b_1X + b_2Z + b_3W.$$

Koeficientų C , b_1 , b_2 , b_3 reikšmės nėra žinomos. Jų įverčiai $\hat{C}$, $\hat{b}_1$, $\hat{b}_2$, $\hat{b}_3$ gaunami panaudojus imties duomenis.

Kokybinei analizei pakanka atsižvelgti į koeficientų reikšmes. Jeigu koeficientas prie kažkurio regresoriaus teigiamas, tai, šiam regresoriui didėjant, tikimybė $P(Y = 1)$ (o kokią situaciją ta modelio lygybė $Y = 1$ atitinka, turime žinoti iš sąlygos) didėja. Jeigu koeficientas neigiamas, tai atitinkamam regresoriui didėjant, tikimybė $P(Y = 1)$ mažėja (didėja tikimybė, kad Y įgis 0).

Jeigu $b_1 > 0$, tai X didėjant, didėja ir tikimybė $P(Y = 1)$.

Jeigu $b_1 < 0$, tai X didėjant, didėja ir tikimybė $P(Y = 0)$.

Kadangi regresorių matavimo skalės gali labai skirtis, tai bendriausiu atveju negalima teigti, kad įtakingiausias yra tas regresorius, kurio koeficientas absoliučiu didumu didžiausias. Pavyzdžiui, toks lyginimas yra nekorektiškas, jeigu X – pragyventi metai, o Z – kūno masės indeksas. Koeficientų didumus galima lyginti, jeigu visi regresoriai matuojami ta pačia skale (pavyzdžiui, regresoriai yra skirtingų egzaminų pažymiai). Standartizuotųjų beta koeficientų analogų, leidžiančių palyginti regresorių įtaką, logistinėje regresijoje nėra. Šiek tiek pagelbsti galimybių santykiai.

4.1.2. Galimybių santykis

Būtų puiku pasakyti, kaip stipriai nuo regresorių priklauso tikimybė $P(Y = 1)$. Deja, tą galima padaryti tik konkrečioms regresorių reikšmėms, o norisi kažkokios apibendrintos charakteristikos. Tokia charakteristika yra galimybių santykis.

*Galimybė*⁴³ vadinamas tikimybių santykis $P(Y = 1) / P(Y = 0)$. Jis parodo, kiek kartų viena Y reikšmė labiau tikėtina už kitą. Informacijos atžvilgiu galimybė yra tolygi tikimybei. Jeigu pacientui tikimybė susirgti diabetu yra 0,75, tai tą pačią informaciją galima pasakyti taip: tikimybė susirgti diabetu yra tris kartus didesnė nei nesusirgti, t. y. galimybė lygi 3:1. Kaip ir tikimybę, galimybę

⁴³Angl. *odds*. Lietuviškas terminas *galimybė* nėra itin geras. Tiesiog, kai reikėjo, nieko geresnio nesumąstėme. Be to, niekas iš mūsų kolegų ir studentų nepasiūlė tinkamesnio termino, nors visų prašėme ir laukėme porą metų. Tai (vis dar) puiki proga įsiamžinti lietuviškoje terminijoje.

galima įvertinti tik konkrečioms duomenims. Pavyzdžiui, surasti, koks bus tikėtinas santykis $P(Y = 1) / P(Y = 0)$, kai $X = 2$, $W = 3$, o $Z = 9$.

*Galimybių santykis*⁴⁴ parodo, kaip pasikeis tikimybių santykis (galimybė), kai atitinkamas regresorius padidės vienetu, fiksuojant visų kitų regresorių reikšmes. Kai regresorius X padidėja vienetu, ankstesnis tikimybių santykis pasikeičia $e^{\hat{\beta}_1}$ kartų. Šis dydis ir vadinamas galimybių santykiu. Nesunku įsitikinti, kad galimybių santykis didesnis už vienetą tik tada, kai atitinkamas koeficientas b teigiamas.

Skaičius $e^{\hat{\beta}_1}$ yra galimybių santykis:

$$\left(\frac{P(Y = 1)}{P(Y = 0)} \right)_{\text{nauja}} = e^{\hat{\beta}_1} \left(\frac{P(Y = 1)}{P(Y = 0)} \right)_{\text{ankstesnė}}$$

Nauja galimybė – tikimybių santykis, kai regresoriaus X reikšmė padidėja vienetu.

Galima sakyti, kad didesnis už vienetą galimybių santykis rodo, *kiek kartų*, palyginti su ankstesne galimybe, tampa labiau tikėtina, kad $Y = 1$, o ne $Y = 0$. Jei galimybių santykis mažesnis už vienetą, jo *atvirkštinė* reikšmė rodo, *kiek kartų*, palyginti su ankstesne galimybe, tampa **mažiau** tikėtina, kad $Y = 1$, o ne $Y = 0$.

Pavyzdys. Tarkime, kad tirdami diabetą sukeliančius veiksnius (susirgs / nesusirgs) nustatėme, jog galimybių santykis regresoriaus X atžvilgiu (kiek savaitių pacientas laikėsi kietos dietos) yra 0,5. Tai reiškia, kad X padidėjus vienetu, tikimybių santykis $P(\text{susirgs}) / P(\text{nesusirgs})$ sumažėja perpus.

Galimybių santykis priklauso tik nuo modelio koeficientų, todėl tai ir yra ta regresoriaus svarbą parodanti kiekybinė charakteristika, kuri dažnai pateikiama logistinės regresijos išvadų aprašymuose. Statistinės programos dažniausiai kiekvienam regresoriui pateikia ne tik patį galimybių santykio įvertį, bet ir šio santykio 95 % pasikliautinąjį intervalą. Jeigu visų regresorių skalės vienodos, tai galimybių santykius galima taikyti regresorių įtakai nustatyti. Tada galima tarti, kad įtakingesnis tas regresorius, kurio pokytis *daugiau kartų pakeičia* galimybių santykį (padidina jį arba sumažina). Nesunku suvokti, kad regresorius, kurio pokytis galimybę patrigubina, yra svarbesnis už tą, kuris galimybių santykį padvigubina. Analogiškai išmąstome, kad įtakingesnis tas regresorius, kurio pokytis galimybę sumažina triskart (galimybių santykis 1/3) nei tas, kurio

⁴⁴ Angl. *odds ratio*.

pokytis galimybę sumažina dukart (galimybių santykis 1/2). Kai regresorių skalės visiškai skirtingos (pvz., vienas matuojamas tonomis, o kitas metrais), tai jokie galimybių santykiai nepadės nustatyti, kuris regresorius modelyje įtakingesnis.

4.1.3. Prognozavimas

Prognozė, kam bus lygi tikimybė $P(Y = 1)$, atliekama tik konkrečioms X , Z , W reikšmėms. Prognozę lengviausia atlikti dviem etapais. Pirmiausia į formulę

$$z = \hat{C} + \hat{b}_1 X + \hat{b}_2 Z + \hat{b}_3 W$$

įstatome tas konkrečias X , Z ir W reikšmes, kurioms reikia prognozės. Tada tikimybių įverčiai skaičiuojami pagal formules:

$$\hat{P}(Y = 1) = \frac{e^z}{1 + e^z}, \quad \hat{P}(Y = 0) = 1 - \hat{P}(Y = 1) = \frac{1}{1 + e^z}.$$

Čia $e = 2,7182818284590452353602874713527...$. Praktiniams skaičiavimams visiškai pakanka apytikslės reikšmės $e \approx 2,7183$.

Pavyzdys. Tarkime, kad atlikę logistinę regresiją gavome tokius koeficientų įverčius $\hat{C} = 2$, $\hat{b}_1 = -4$, $\hat{b}_2 = 3$, $\hat{b}_3 = 1$. Užrašome logit funkcijos modelį:

$$z = 2 - 4X + 3Z + W.$$

Tarkime, kad turime respondentą, kuriam $X = 0$, $Z = 8$, $W = 2$. Šiam respondentui norime įvertinti tikimybę $P(Y = 1)$. Pirmiausia įstatome X , Z ir W reikšmes į logit funkciją ir gauname $z = 2 + 0 + 24 + 2 = 28$. Tada pakeliame e gautuoju laipsniu:

$$e^{28} = 1446257064291,475.$$

Beliko apskaičiuoti tikimybės įvertį:

$$\hat{P}(Y = 1) = \frac{1446257064291,475}{1 + 1446257064291,475} = 0,99999 \dots$$

Taigi šiam respondentui labai tikėtina, kad $Y = 1$.

Kartais reikia tik nustatyti, kuriai iš dviejų kategorijų turėtų priklausyti respondentas. Pavyzdžiui, atsižvelgę į atsvorį ir dietą, prognozuojame, kad Pūkuotukas susirgs diabetu, o Paršelis nesusirgs. Toks *šiurkštus* priskyrimas vienai iš kategorijų ($Y = 1$ arba $Y = 0$) vadinamas *klasifikavimu*. Jis atliekamas taip: konkrečioms regresorių reikšmėms taip kaip pirmiau aprašyta, surandamas tikimybės $P(Y = 1)$ įvertis $\hat{P}(Y = 1)$. Prognozuojame labiau tikėtiną reikšmę. Jeigu $\hat{P}(Y = 1) > 0,5$, tai prognozuojame $Y = 1$. Jeigu $\hat{P}(Y = 1) < 0,5$, tai prognozuojame $Y = 0$. Jeigu

$\hat{P}(Y = 1) = 0,5$, tai rekomenduojama sprendimą priimti atsitiktinai, pavyzdžiui, metant monetą. Tiesą sakant, klasifikacijai tikimybių įverčiai nebūtinai. Pakanka surasti z . Primename, kad tikslus z pavadinimas yra *tikimybių santykio logit funkcija*.

Progozė, atsižvelgiant į tikimybių santykio logit funkcijos reikšmę z .

- Jeigu $z > 0$, tai prognozuojama, kad $Y = 1$.
- Jeigu $z < 0$, tai prognozuojama, kad $Y = 0$.
- Jeigu $z = 0$, tai rekomenduojama sprendimą priimti, metant monetą.

4.1.4. Reikalavimai duomenims

Duomenys turi tenkinti tokius reikalavimus:

- Priklausomas kintamasis Y yra dvireikšmis.* Formaliai kalbant, visi regresoriai gali būti arba intervaliniai, arba dvireikšmiai (įgyti reikšmes 0 arba 1). Vis dėlto kai modelyje daug kategorinių regresorių, korektiškiau kalbėti apie apibendrintąjį tiesinį modelį, o ne apie logistinę regresiją. Tada ir truputį kitokia analizė taikoma, žr. 4.2.11 skyrelį. Todėl geriausia, kai dauguma regresorių yra intervaliniai, o dvireikšmių regresorių nedaug.
- Duomenyse negali vyrauti viena iš Y reikšmių.* Dažniausiai reikalaujama, kad tarp stebimų Y reikšmių vienetų (nulių) būtų ne mažiau kaip penktadalis. Tokio reikalavimo logika paprasta – kad galėtume nustatyti, kas būdinga kiekvienai kategorijai, turime turėti informacijos apie abiejų kategorijų respondentus. Negalima išsiaiškinti, kas būdinga sergantiesiems diabetu, tiriant tik sveikus respondentus.
- Jeigu modelyje yra daug kategorinių regresorių, tai *kiekvienam tų kategorijų deriniui turi būti pakankamai daug stebinių*. Minimalus reikalavimas – bent 5 stebiniai. Jeigu atsižvelgiame į lytį ir žvairumą, tai negerai, jei imtyje nėra žvairų vyrų. Ir neužteks, kad ir vyrų yra ne mažiau kaip 20 %, ir žvairuojančių tiriamųjų yra ne mažiau kaip 20 %.
- Regresoriai neturi stipriai koreliuoti.* Dėl multikolinearumo gali atsirasti neteisingi kintamųjų ryšiai modelyje. Pavyzdžiui, gali būti taip, kad logistinės regresijos modelį papildžius naujais regresoriais, regresoriaus X daugiklis pakeis ženklą. Vis dėlto multikolinearumo problema dvinarėje logistinėje regresijoje tiriama retai.

4.1.5. Modelio tinkamumas

Modelio tikimą duomenims parodo tokie rodikliai:

- 1) *Klasifikacinė lentelė*. Tai bene svarbiausia modelio tikimo charakteristika. Jeigu jau sudarėme logistinės regresijos modelį duomenims, kuriems žinomos Y reikšmės, tai natūralu pasitikrinti, ar tinkamai klasifikuojama. Konkretiems stebiniams prognozuojama Y reikšmė ir žiūrima, ar spėjimas sutapo su tikrąja Y reikšme. Kuo daugiau sutapčių, tuo modelis geresnis. Kiekvienos kategorijos stebinių turi būti suklasifikuota daugiau, nei gautume atsitiktinai spėdami. Jeigu abiejų Y reikšmių imtyje yra panašus kiekis, tai tinkami modeliai kiekvienos iš Y kategorijų teisingai klasifikuos ne mažiau kaip po 50 procentų.
- 2) *Tikėtinumų santykio kriterijus*. Parodo, ar modelyje yra bent vienas reikalingas regresorius. Jeigu kriterijaus p reikšmė $\geq 0,05$, tai regresijos modelio tinkamumas labai abejotinas (gavome, kad visi regresoriai nereikalingi). Jeigu $p < 0,05$, gavome patvirtinimą, kad modelis nėra beviltiškas (o gal ir visai geras – reikia tirti toliau).
- 3) *Hosmerio–Lemešou kriterijus*. Šis kriterijus yra mažiau populiarus pirmiau minėto tikėtinumų santykio kriterijaus alternatyva. Modelis gerai tinka duomenims, kai Hosmerio–Lemešou kriterijaus p reikšmė $\geq 0,05$. Hosmerio–Lemešou kriterijų rekomenduojama taikyti tik nedidelėms imtims (iki 200 stebinių taikyti galima drąsiai, daugiau kaip 500 stebinių – jau labai atsargiai).
- 4) *Voldo kriterijai regresoriams*. Padeda nuspręsti, ar regresorius šalintinas iš modelio. Jeigu regresoriui Voldo kriterijaus p reikšmė $< 0,05$, tai sakome, kad *regresorius yra statistiškai reikšmingas* ir dažniausiai jį modelyje paliekame. Jeigu $p \geq 0,05$, tai regresorius yra statistiškai nereikšmingas ir modelyje jis paliekamas tik ypatingais atvejais (žr. kitą skyrelį). Dažniausiai modelio konstanta C paliekama net ir tada, kai ji statistiškai nereikšminga.
- 5) *Informaciniai indeksai* (pavyzdžiui, Akaikės informacinis kriterijus AIC). Gero modelio AIC yra daug mažesnis už AIC modelio be regresorių (tik su konstanta). Vis dėlto tai santykinis matas, todėl nėra paprasta pasakyti, kokia turi būti indekso reikšmė, kad pasirinktą modelį laikytume tinkamu.
- 6) *Determinacijos (pseudo) koeficientai*. Rodo bendrąjį modelio tikimą duomenims. Įgyja reikšmes iš intervalo $[0, 1]$. Kuo koeficiento reikšmė didesnė, tuo modelis geriau tinka duomenims. Ne itin gerai, kai R^2 yra labai mažas. Vis dėlto priešingai tiesinei regresijai logistinėje regresijoje R^2 vaidina tik pagalbinį vaidmenį. Jeigu R^2 yra mažas, bet pagal visus kitus rodiklius logistinė regresija tinka, tai vis tiek tariama, kad modelis tinkamas.

Determinacijos pseudokoefficientų yra net keli. Galima naudoti bet kurį. Tiesa, privalu nurodyti tikslų determinacijos koeficiento pavadinimą.

- 7) *Kuko matas*. Parodo, ar stebinių aibėje (duomenyse) yra išskirčių. Išskirčiai Kuko matas viršija 1. Skaičiuojamas kiekvienam stebiniui. Modelis su išskirtimis – nepatikimas.
- 8) *DFBetų statistika*. Tai Kuko mato alternatyva, padedanti surasti tas duomenų išskirtis, kurios daro įtaką koeficientų b įverčiams. Išskirčiai $DFBeta > 1$. $DFBeta$ statistika skaičiuojama kiekvienam regresoriui atskirai. Modelis su išskirtimis – nepatikimas.
- 9) *Prognozuotų tikimybių grafikas*. Tai tikrai nėra labai svarbus tikimo rodiklis (ir itin negražus). Vis dėlto kartais toks grafikas pridedamas. Jame matyti, ar teisingai klasifikuotų stebinių $Y = 1$ modelio tikimybės buvo didelės, o teisingai klasifikuotų stebinių $Y = 0$ tikimybės buvo mažos. Taip turi būti tinkamiems modeliams.

4.1.6. Dvinarės logistinės regresinės analizės etapai

Išsamios modelio analizės etapai:

- 1) Sudarome dvinarės logistinės regresijos modelį ir peržiūrime klasifikacinę lentelę. Tikriname, ar kiekvienai Y kategorijai teisingai klasifikuota bent 50 % atvejų. Geriau, kai šie procentai kur kas didesni.
- 2) Patikriname, ar tikėtinumų santykio kriterijaus p reikšmė $< 0,05$. Jeigu ne – modelis netinkamas. (Nedidelėms imtims alternatyviai galima patikrinti, ar Hosmerio–Lemšou kriterijaus p reikšmė $\geq 0,05$. Jeigu ne – modelis netinkamas.)
- 3) Patikriname, ar visi regresoriai statistiškai reikšmingi (visos Voldo kriterijaus p reikšmės $< 0,05$). Jeigu ne – modelis taisytinas. Konstantai p reikšmės nežiūrime.
- 4) Patikriname, ar duomenys neturi išskirčių (nėra stebinių, kuriems Kuko matas > 1). Alternatyviai galima patikrinti, ar nėra stebinių, kuriems $DFBeta > 1$.
- 5) Žiūrime, ar koeficientų ženklai atitinka spėjamą regresorių įtaką (neįtariame multikolinearumo).
- 6) Jeigu viskas gerai – modelį aprašome. Jeigu ne – tobuliname.

Gera duomenims tinkamo modelio:

- Tikėtinumų santykio kriterijaus $p < 0,05$.
- Visiems regresoriams Voldo kriterijaus $p < 0,05$.
- Koeficientų ženklai neatrodo nelogiški.

- Teisingai klasifikuojama ne mažiau kaip 50 % atvejų, kai $Y = 1$ ir kai $Y = 0$.
- Nedideliai imčiai Hosmerio–Lemeshow kriterijaus $p \geq 0,05$.
- Visų stebinių Kuko matai ≤ 1 ir visi $DFBeta \leq 1$.
- Pasirinktas determinacijos koeficientas $\geq 0,20$.

4.1.7. Modelio tobulinimas

Modelio tobulinimas reiškia regresorių šalinimą arba jų transformaciją. Transformacija (logaritmavimas ir pan.) padeda retai, bet pabandyti visada galima.

Pašalinus bent vieną regresorių, keičiasi visos modelio charakteristikos: visos p reikšmės, klasifikacinė lentelė, determinacijos koeficientai.

Modelis tobulinamas, jeigu yra problemų:

- Yra statistiškai nereikšmingas regresorius* (jam Voldo kriterijaus $p \geq 0,05$). Regresorius pašalinamas iš modelio ir logistinė regresinė analizė pakartojama be jo. Viskas gerai, jeigu klasifikacinėje lentelėje teisingai klasifikuotų atvejų sumažėjo nedaug (kartais teisingų klasifikavimų net padaugėja). Ką reiškia nedaug, sprendžia tyrėjas. Jeigu teisingai klasifikuotų atvejų sumažėja radikaliai, regresorių grąžiname į modelį. Aprašydami tada konstatuosime, kad „regresorius buvo statistiškai nereikšmingas. Vis dėlto jis paliktas modelyje, nes be jo labai sumažėja teisingų klasifikavimų procentas“.
- Multikolinearumo problema*. Multikolinearumas reiškia, kad modelyje yra stipriai koreliuotų regresorių, kurie iškreipia tikrąsias kintamųjų priklausomybes (modelyje atsiranda neįtikėtini koeficientų ženklai). Tada patikrinama, ar intervaliniai regresoriai stipriai koreliuoja. Jeigu taip – dalį regresorių pašaliname. Šalinami tie regresoriai, kurių standartinės paklaidos yra didžiausios.

Kai kurie autoriai pataria palikti tik tuos regresorius, kurių standartinės paklaidos neviršija 5.

Kartais (jeigu toks veiksmas prasmingas) stipriai koreliuojančius regresorius keičiame jų vidurkiu.

- c) *Yra išskirčių*. Jeigu visi $DFBeta \leq 1$, o daliai stebinių Kuko matai nedaug viršija 1 (arba atvirkščiai), tai modelis laikomas pakankamai geru. Žinoma, aprašymuose tada ir figūruoja tik DFBetos (Kuko matas). Apskritai nederėtų to 1 suabsoliutinti. Niekio blogo neįvyks, jeigu ir DFBetos, ir Kuko matas nedaug viršys 1. Kartais išskirtį galima pašalinti (pavyzdžiui, įtarus duomenų vedimo klaidą ar *gryną* atsitiktinumą). Kitais atvejais modelis yra netinkamas.
- d) *Pasirinktas determinacijos pseudokoeficientas $< 0,20$* . Galima pabandyti pasirinkti kitą koeficientą (pavyzdžiui, Nagelkerkės, o ne Kokso–Snelo). Logistinėje regresijoje determinacijos pseudokoeficientai tėra labai apytiksliai tiesinės regresijos R^2 analogai. Todėl jų vaidmuo nėra toks svarbus kaip tiesinėje regresijoje. Jeigu $R^2 = 0,15$, o visos kitos charakteristikos rodo gerą modelio tikimą, tariama, kad modelis yra tinkamas.

4.1.8. Pastabos apie logistinės regresijos taikymą

- Dažniausiai, taikant logistinę regresinę analizę, apsiribojama vienu – tikėtinumą santykio arba Hosmerio–Lemešou – kriterijumi. Hosmerio–Lemešou kriterijus taikytinas, kai imtis nedidelė, nes didelėms imtims p reikšmė gali būti maža vien dėl imties didumo.
- Aprašymuose dažnai nurodomas tik bendrasis teisingų klasifikavimų procentas. Tai nėra blogai. Tik reikia nepamiršti, kad modelis turi padėti „gerai atpažinti“ abi Y reikšmes. Antraip galima padaryti neteisingą išvadą. Pavyzdžiui, galima pamanyti, kad modelis latentiniam kairiarankiškumui nustatyti gerai tinka, nes bendras teisingų klasifikacijų procentas yra 60 %. Atidžiau pažvelgus, ims ir paaiškės, kad taikomas modelis 100 % atpažįsta dešiniarankius ir 0 % – kairiarankius, t. y. klasifikavimo taisyklė labai paprasta (ir kvaila) – nesvarbu, kokios ten tos kintamųjų reikšmės, sakysime, kad respondentas dešiniarankis. Tiesiog dešiniarankių imtyje buvo 60 %.
- Šiame el. vadovėlyje išsamiai aptariama tik tiesioginė dvinarė logistinė regresija, kai visus modelio tobulinimus atlieka tyrėjas. Tyrimuose dar taikomi keliaetapiai (žingsniniai) logistinės regresijos modeliai, kai modelyje automatiškai paliekami patys statistiškai reikšmingiausi iš pradinių kintamųjų.
- Priešingai nei tiesinėje regresijoje, jeigu daugiklis prie X yra $\hat{b}_1 = 3$, tai **negalima** sakyti, kad X padidėjus vienetu, Y padidės 3.
- Gali būti ir vienas regresorius.

- Gana dažna klaida išraišką $z = \hat{C} + \hat{b}_1X + \hat{b}_2Z + \hat{b}_3W$ pavadinti tikimybe. Todėl dar kartą primename: z nėra tikimybė, o tikimybių santykio logaritmas.
- Kai Y įgyja reikšmes 1 ir 2, jos modelyje **perkoduojamos**: reikšmė $Y = 1$ traktuojama kaip modelio 0, o $Y = 2$ traktuojama kaip modelio 1. Todėl, sudarę modelio vieneto tikimybės modelį, turime prisiminti, kad šis vienetas atitinka pradinį kodą $Y = 2$. Tai sukelia papildomų problemų interpretuojant rezultatus. Todėl labai primygtinai rekomenduojame skaitinį kintamąjį iš pat pradžių koduoti, suteikiant reikšmes 0 ir 1.

4.1.9. Standartiniai regresijos modelių aprašymai

Visada aprašomas galutinis, po visų tobulinimų gautasis, modelis. Privaloma aprašyti modelio tikėtinumų santykio kriterijaus chi kvadrato statistikos reikšmingumą ir aptarti regresorių statistinius reikšmingumus. Pateiksime keletą galimų aprašymų fragmentų.

- *Logistinės regresijos modelis tiko, tikėtinumų santykio kriterijaus $\chi^2 = 13,27$; $p < 0,01$. Visi regresoriai buvo statistiškai reikšmingi. Teisingai klasifikuota 78,3 % imties respondentų. Nagelgerkės determinacijos koeficientas 0,72. Regresoriui X galimybių santykio įvertis 1,3; (95 % pasikliautinis intervalas [0,99;1,61])...*
- *Iš modelio buvo pašalintas statistiškai nereikšmingas regresorius X . Galutinis modelis buvo statistiškai reikšmingas, $\chi^2 = 10,02$; $p = 0,023$. Taikant modelį imties duomenims, teisingai klasifikuoti 73 % diabetu sergantys pacientai ir 88 % sveiki respondentai. Kokso ir Snello determinacijos koeficientas $R^2 = 0,57$. Didėjant W , diabeto rizika padidėja. Didėjant Z , diabeto rizika sumažėja...*
- *Modelyje paliktas statistiškai nereikšmingas regresorius Z , nes jį pašalinus, labai sumažėja teisingai klasifikuotų atvejų procentas...*

4.2. Dvinarė logistinė regresinė analizė su SPSS

4.2.1. Duomenys


Kaip atlikti dvinarę logistinę regresinę analizę, parodysime, tirdami 2008 metų Europos Sąjungos socialinio tyrimo (*European Social Survey*) Estijos ir Portugalijos duomenis **ESS4EE** ir **ESS4PT**. Tirsime 20–30 metų vyrus. Tyrime naudosime tokius kintamuosius:

- *cntry* – šalies kodas (EE – Estija, PT – Portugalija),

- *stfedu* – respondento požiūris į savo šalies švietimo sistemos būklę (reikšmės nuo 0 – itin bloga, iki 10 – itin gera),
- *happy* – laimingumas (matuojamas 10 balų skale nuo 0 – itin nelaimingas, iki 10 – itin laimingas),
- *freehms* – gėjai ir lesbietės gali gyventi kaip nori (matuojamas skale nuo 1 – visiškai sutinku, iki 5 – visiškai nesutinku),
- *imsclbn* – nuo kada imigrantai gali visiškai naudotis šalies socialinėmis lengvatomis (matuojamas nominalia skale: 1 – iškart atvykę, 2 – po vienerių metų, neatsižvelgiant į tai, ar dirbo, 3 – po vienerių darbo ir mokesčių mokėjimo metų, 4 – tapę piliečiais, 5 – niekada negalės naudotis visomis lengvatomis).


Duomenų atrankai naudosime kintamuosius: *agea* – amžių ir *gndr* – lytį (1 – vyr., 2 – mot.),

Abu duomenų failus sujungsim į vieną. Atsidarome ESS4EE ir renkamės **Data → Merge Files → Add Cases** parinktį.




Atsidariusiame lange renkamės **Browse**, nurodome failą ESS4PT ir spaudžiame **Continue**. Atsidariusiame lange spaudžiame **OK**.

Su komanda **Select Cases** atrenkame reikiamus respondentus. Tai daroma taip: meniu **Select Cases** pažymime **If condition is satisfied** ir spaudžiame klavišą **If**. Naujajame meniu suformuluojame sąlygą $agea \geq 20 \ \& \ agea \leq 30 \ \& \ gndr = 1$.



Tada spaudžiame **Continue** ir **OK**.

Tirsime, ar 20–30 metų respondento laimingumo laipsnis ir požiūris į seksualines mažumas, švietimo sistemos būklę bei imigrantų socialines lengvatas gerai apibūdina, kurios šalies gyventojas jis yra. Grafiškai tiriamą modelį galima pavaizduoti taip:




Kitais žodžiais tariant, tikimės, kad parinktieji regresoriai gerai apibūdina respondento kilmės šalį. Sąlygiškai modelį galima užrašyti taip:

$$cntry = f(stfedu, happy, freehms, imscbln)^{45}.$$

Atlikome pradinę modelio specifikaciją. Dabar patikrinsime, ar parinktasis modelis tinka duomenims.


4.2.2. SPSS parinktys pradiniam regresijos modeliui

Atsidarome langelį **Analyze** ir renkamės **Regression** → **Binary Logistic**. Atsidariusiame meniu perkeliame kintamąjį *cntry* į laukelį **Dependent**. Kintamuosius *freehms*, *happy*, *imsclbn* ir *stfedu* įkeliamo į laukelį **Covariates**.



Regresorius *imsclbn* yra kategorinis. Tiesa, kategorijų yra pakankamai daug. Nebūtų labai didelė nuodėmė ir traktuoti šį regresorių kaip intervalinį kintamąjį. Vis dėlto norėdami parodyti logistinės regresijos taikymo niuansus, tarsime, kad *imsclbn* yra nominalus kintamasis. Todėl renkamės parinktį **Categorical** ir perkeliame *imsclbn* į dešinę lauką.


⁴⁵ Tikslī modelio išraiška pateikiama rezultatų aprašyme.



Options meniu pažymime **CI for exp(B)**. Kadangi nemanome, kad imtis bus labai didelė, tai pažymime ir **Hosmer-Lemeshow goodness-of-fit**. Šio kriterijaus galima ir nenaudoti, ypač jeigu imtis didelė. Be to, pažymime **Classification Plots**.



Grįžę į prieš tai buvusį meniu, pasirenkame parinktį **Save**. Pažymime **Cook's** ir **DfBeta(s)**. Šiame meniu galima pažymėti ir *Probabilities* arba *Group membership*. Tada duomenyse bus sukurtas naujas stulpelis su tikimybės $P(Y = 1)$ įverčiu kiekvienam respondentui. Pasirenkame **Continue** ir **OK**.



Pažymėjus *Standardized* arba *Studentized*, duomenyse atsirastų naujų stulpelių su normalizuotomis liekamosiomis paklaidomis. Jas galima naudoti, jei jau labai kiltų noras patikrinti liekamųjų paklaidų normalumą.

4.2.3. Rezultatai

Lentelėje **Dependent variable Encoding** pateikiama informacija, kad *cntry* = EE (t. y. šalis Estija) modelyje atitiks $Y = 0$, o *cntry* = PT (Portugalija) modelyje atitiks $Y = 1$.

Dependent Variable Encoding	
Original Value	Internal Value
EE Estonia	0
PT Portugal	1

Nurodėme, kad kintamasis *imsclbn* yra kategorinis. Kintamasis įgyja 5 reikšmes. Todėl modelyje jis keičiamas 4 pseudokintamaisiais *imsclbn(1)*, *imsclbn(1)*, *imsclbn(1)*, *imsclbn(1)*, galinčiais įgyti reikšmes 0 ir 1. Lentelėje **Categorical Variables Codings** pateikiama informacija, koks pseudokintamųjų reikšmių derinys atitiks įvairias kintamojo *imsclbn* kategorijas. Kai visi pseudokintamieji įgis nulines reikšmes, tai atitiks kintamojo *imsclbn* reikšmę 5. Kai *imsclbn(1) = 0*, *imsclbn(2) = 0*, *imsclbn(3) = 1*, *imsclbn(4) = 0*, tai atitiks kintamojo *imsclbn* reikšmę 3, ir t. t.

Categorical Variables Codings						
		Frequency	Parameter coding			
			(1)	(2)	(3)	(4)
imsclbn When should immigrants obtain rights to social benefits/services	1 Immediately on arrival	26	1.000	.000	.000	.000
	2 After a year, whether or not have worked	25	.000	1.000	.000	.000
	3 After worked and paid taxes at least a year	128	.000	.000	1.000	.000
	4 Once they have become a citizen	63	.000	.000	.000	1.000
	5 They should never get the same rights	6	.000	.000	.000	.000

Surandame **Block 0:Beginning block : Classification Table**. Tai **NĖRA** klasifikacinė lentelė, kuri rodo klasifikavimo tikslumą, naudojant logistinę regresiją.

SPSS pateikia **dvi** klasifikacines lenteles:

- Pirmoji skirta atsitiktinio spėjimo efektyvumui įvertinti.
- Antroji rodo modelio gerumą (būtent ji ir yra svarbiausia).

Pirmoje lentelėje yra informacijos apie klasifikavimo tikslumą, jeigu respondento šalį spėjame akiai. Imtyje yra 125 respondentai iš Estijos ir 123 respondentai iš Portugalijos. Jeigu visą laiką sakysime, kad respondentas iš Estijos, turėsime 50,4 % teisingų spėjimų. Logistinės regresijos modelis bus geras tik tada, jeigu modeliuojant atitinkamas teisingų prognozių procentas bus didesnis.

Classification Table^{a,b}

Classification Table					
Observed			Predicted		
			cntry Country		Percentage Correct
			EE Estonia	PT Portugal	
Step 0	cntry Country	EE Estonia	125	0	100.0
		PT Portugal	123	0	.0
Overall Percentage					50.4

Lentelėje **Classification Table** (tai antroji klasifikacinė lentelė, ji yra rezultatų išsklotinės pabaigoje) yra informacijos, kaip gerai pavyksta atpažinti respondento šalį, taikant logistinės regresijos modelį imties duomenims. Matome, kad teisingai buvo atpažinti 77,6 % Estijos respondentų ir 78,9 % Portugalijos respondentų. Bendrasis teisingai klasifikuotų atvejų procentas yra 78,2 %. Paaiškinsime, kaip šie procentai apskaičiuojami. Pirmojoje lentelės eilutėje yra pažymėta, kad iš 125 Estijos respondentų 97 buvo teisingai klasifikuoti kaip Estijos atstovai, o 28 respondentai klaidingai priskirti Portugalijai: 97 iš 125 ir sudaro 77,6 %. Prisiminę (žr. pirmiau), kad aklas spėjimas duotų tik 50,4 % teisingų Estijos respondentų klasifikavimą, darome išvadą, kad modelis tinkamas.

Classification Table^a

Classification Table					
Observed			Predicted		
			cntry Country		Percentage
			EE Estonia	PT Portugal	
Step 1	cntry Country	EE Estonia	97	28	77.6
		PT Portugal	26	97	78.9
	Overall Percentage				78.2

a. The cut value is .500

Tikėtinumų santykio statistika ir p reikšmė pateikiama lentelėje **Omnibus Tests of Model Coefficients**. Mes pasirinkome tiesioginę (ne žingsninę) regresiją, todėl visos trys eilutės lentelėje yra identiškos. Kadangi $p = 0,000... < 0,05$, tai modelis gerai aprašo duomenis. Nors dar neaišku, ar visi kintamieji modelyje reikalingi.

Omnibus Tests of Model Coefficients			
	Chi-square	df	Sig.
Step 1 Step	122.047	7	.000
Block	122.047	7	.000
Model	122.047	7	.000

Lentelėje **Model Summary** pateikiami du determinacijos pseudokoeficientai. Kokso ir Snello $R^2 = 0,389$, Nagelkerkės $R^2 = 0,518$. Abudu determinacijos koeficientai rodo neblogą modelio tikimą duomenims (abudu $R^2 > 0,20$).

Model Summary			
Step	-2 Log likelihood	Cox & Snell R Square	Nagelkerke R Square
1	221.738 ^a	.389	.518

Lentelėje **Hosmer and Lemeshow Test** yra Hosmerio–Lemešou kriterijaus statistika ir p reikšmė. Imtis buvo vidutinio didumo ($n = 248$), todėl į p atsižvelgsime. Gerai, kai $p > 0,05$. Kadangi $p = 0,665 > 0,05$, darome išvadą, kad modelio duomenims tinka.

Hosmer and Lemeshow Test			
Step	Chi-square	df	Sig.
1	5.846	8	.665

Lentelėje **Variables in the Equation** yra pačių koeficientų įverčių reikšmės, taip pat informacijos apie statistinį jų reikšmingumą ir galimybių santykius. Statistiškai reikšmingi tie regresoriai, kuriems stulpelyje **Sig.** pateiktos Voldo kriterijaus p reikšmės $< 0,05$. Matome, kad yra nemažai statistiškai nereikšmingų regresorių. Todėl darome išvadą, kad modelį reikia tobulinti. Modelio užrašą, galimybių santykius ir praktinį prognozavimą aptarsime nagrinėdami galutinį modelį.

Rezultatų išklotinė baigiama ganėtinai neišvaizdžiu prognozuotų tikimybių grafiku. Galimos tikimybės reikšmės (nuo 0 iki 1) atidėtos x ašyje. Mūsų modelyje $Y = 1$ ekvivalentu teiginiui, kad respondentas yra iš Portugalijos. Todėl jeigu $P(Y = 1) > 0,5$, prognozuojame, kad respondentas yra iš Portugalijos. Jeigu $P(Y=1) < 0,5$, prognozuojame, kad respondentas yra iš Estijos. Norint tą pabrėžti, x ašyje iki 0,5 prirašyta raidžių E, o nuo 0,5 – raidžių P. Kiekvienam respondentui įvertinama tikimybė, kad jis yra iš Portugalijos. Atitinkamoje vietoje virš x ašies atidedama raidė E, jeigu tai buvo Estijos atstovas, ir P – jeigu Portugalijos.


Variables in the Equation

	B	S.E.	Wald	df	Sig.	Exp(B)	95 % C.I. for EXP(B)	
							Lower	Upper
Step 1 ^a freehms	-.730	.160	20.938	1	.000	.482	.352	.659
happy	.314	.099	10.025	1	.002	1.369	1.127	1.663
stfedu	-.564	.092	37.329	1	.000	.569	.475	.682
imsclbn			15.751	4	.003			
imsclbn(1)	1.849	1.284	2.075	1	.150	6.354	.513	78.647
imsclbn(2)	-.039	1.197	.001	1	.974	.962	.092	10.046
imsclbn(3)	.195	1.123	.030	1	.862	1.215	.134	10.977
imsclbn(4)	-1.057	1.168	.819	1	.366	.347	.035	3.430
Constant	2.599	1.422	3.341	1	.068	13.445		

a. Variable(s) entered on step 1: freehms, happy, stfedu, imscbln.

Raidė E, atsidūrusi virš x ašies į kairę nuo 0,5, žymi teisingą esto klasifikavimą. Raidė E, atsidūrusi už 0,5, – jau yra Estijos atstovas, klaidingai priskirtas portugalams. Analogiškai yra su Portugalijos atstovais – gerai, kai P raidės yra į dešinę nuo 0,5, ir blogai – kai į kairę.

Observed Groups and Predicted Probabilities



Jeigu logistinės regresijos modelis gerai tinka duomenims, matysime daug E raidžių į kairę nuo 0,5 ir daug P raidžių – į dešinę nuo 0,5. Šiame grafike taip ir yra. Todėl darome išvadą, kad prognozuotų tikimybių grafikas taip pat rodo, kad logistinės regresijos modelis gerai tinka. Norint nustatyti, ar imtyje nėra išskirčių reikia patikrinti, ar duomenyse (ne rezultatų išsklotinėje) atsiradusio stulpelio *COO_1* ir visų DFBetų stulpelių reikšmės neviršija vieneto.

COO_1	DFB0_1	DFB1_1	DFB2_1	DFB3_1	DFB4_1	DFB5_1	DFB6_1	DFB7_1
.00038	-.00246	-.00044	.00129	-.00008	-.00101	-.00115	-.00646	-.00084
.01090	.07333	-.01453	-.00353	-.00201	.00052	-.01094	.00477	-.00229

Kuko mato reikšmė yra viena vienam respondentui (stebiniui). Joje atsispindi informacija apie visus to respondento duomenis (*cntr*, *freehms*, *happy*, *stfedu*, *imsclbn*). O DFBetų rodikliai skirti kiekvienam regresoriui ir konstantai atskirai: DFB0_1 – konstantai, DFB1_1 – *freehms*, DFB2_1 – *happy*, DFB3_1 – DFB6_1 skirti kintamiesiems *imsclbn*(1) – *imsclbn*(4). Nebūtina peržiūrėti visas stulpelio reikšmes. Naudojame komandą **Analyze** → **Descriptive Statistics** → **Descriptives**. Sukeliame visus kintamuosius į **Variable(s)**. Pasirenkame **Options** ir paliekame pažymėtą tik parinktį **Maximum**. Renkamės **Continue** ir **OK**.


Descriptive Statistics		
	N	Maximum
COO_1 Analog of Cook's influence statistics	248	.83938
DFB0_1 DFBETA for constant	248	1.03108
DFB1_1 DFBETA for freehms	248	.04821
DFB2_1 DFBETA for happy	248	.02601
DFB3_1 DFBETA for imscbln(1)	248	.77091
DFB4_1 DFBETA for imscbln(2)	248	.77503
DFB5_1 DFBETA for imscbln(3)	248	.77403
DFB6_1 DFBETA for imscbln(4)	248	.77786
DFB7_1 DFBETA for stfedu	248	.03491
Valid N (listwise)	248	

Matome, kad maksimali Kuko mato reikšmė $0,839 < 1$. Visos DFBetų reikšmės, išskyrus DFB0_1, neviršija vieneto. O ir $DFB0_1 = 1,03108$, t. y. reikšmė beveik lygi 1. Be to, reikšmė skirta konstantai, t. y. mažiausiai svarbiam iš visų koeficientų. Todėl darome išvadą, kad duomenys neturi išskirčių. Nors iš daugelio rodiklių buvo galima spręsti, kad modelis gerai tinka, buvo daug statistiškai nereikšmingų regresorių. Todėl darome išvadą, kad modelį reikia tobulinti.

4.2.4. Modelio tobulinimas

Standartinė procedūra, kai yra statistiškai nereikšmingų regresorių – dalį jų pašalinti iš modelio. Mūsų atveju taip daryti netinka, nes statistiškai nereikšmingi yra pseudokintamieji, aprašantys **vieną** kategorinį kintamąjį. Nebus logiška, jeigu iš tyrimo pašalinsime visus respondentus, išskyrus tuos, kurie griežtai pasisako prieš imigrantų teises. Reikėtų arba apskritai iš modelio pašalinti regresorių *imsclbn*, arba pakeisti jį kitu regresoriumi.

Pirmiausia patikrinsime, kiek respondentų rinkosi įvairias *imsclbn* reikšmes. Pasirinkę **Analyze → Descriptive Statistics → Frequencies**, gauname kintamojo *imsclbn* dažnių lentelę.




Įsitikiname, kad, atsakydami į šį klausimą, tik septyni respondentai pasirinko penketą.


imsclbn When should immigrants obtain rights to social benefits/services				
	Frequency	Percent	Valid Percent	Cumulative Percent
Valid 1 Immediately on arrival	27	9.7	10.4	10.4
2 After a year, whether or not have worked	27	9.7	10.4	20.8
3 After worked and paid taxes at least a year	131	47.3	50.4	71.2
4 Once they have become a citizen	68	24.5	26.2	97.3
5 They should never get the same rights	7	2.5	2.7	100.0
Total	260	93.9	100.0	
Missi 7 Refusal	3	1.1		
ng 8 Don't know	14	5.1		
Total	17	6.1		
Total	277	100.0		

Sumažinsime kintamojo *imsclbn* kategorijų skaičių. Sukursime naują kintamąjį *imsb3*, kuris įgis reikšmę 0, kai *imsclbn* = 1 arba 2. Kintamasis *imsb3* įgis reikšmę 1, kai *imsclbn* = 3, ir

imsb3 = 2, kai *imslbnc* = 4 arba 5. Pasirenkame **Transform** → **Recode into Different Variables** ir perkeliame *imslbn* į dešinį laukelį. Laukelyje **Name** užrašome *imsb3* ir spaudžiame **Change**.



Pasirenkame **Old and New Value**. Naudodami **Old value** – **New Value** – **Add** parinktis nurodome kaip turi atrodyti naujasis regresorius. Paskui spaudžiame **Continue** ir **OK**.



Norėdami paaiškinti naujo regresoriaus prasmę papildomai (**Variable View** – **Labels** – **Value Labels**) aprašome jį kaip požiūrį į socialines lengvatas imigrantams⁴⁶, o reikšmes pakomentuojame taip: 0 – teigiamas požiūris⁴⁷, 1 – labiau teigiamas nei neigiamas⁴⁸, 2 – neigiamas požiūris⁴⁹.

Tiriame naują modelį, kurį sąlygiškai galima užrašyti taip:

$$cntry = f(stfedu, happy, freehms, imsb3).$$

Tyrimą atliekame lygiai kaip ankstesnio modelio. Nepamirštame nurodyti, kad *imsb3* yra kategorinis kintamasis. Nepateiksime visų lentelių, tik surašysime jose gautus rezultatus:

⁴⁶ Angl. *attitude towards social benefits for immigrants*.

⁴⁷ Angl. *positive attitude*.

⁴⁸ Angl. *more positive than negative*.

⁴⁹ Angl. *negative attitude*.

- Priklausomo kintamojo modelio kodai liko nepakitę: *cntr* = EE (Estija), atitinka modelio priklausomo kintamojo reikšmę 0, o *cntr* = PT (Portugalija) atitinka modelio kintamojo reikšmę 1.
- Naujasis kategorinis regresorius *imsb3* pakeičiamas dviem pseudokintamaisiais *imsb3(1)* ir *imsb3(2)*, įgyjančiais tik dvi reikšmes: 0 ir 1. Pseudokintamųjų kodų derinių reikšmės pateiktos lentelėje **Categorical Variables Codings**:

Categorical Variables Codings				
		Frequency	Parameter coding	
			(1)	(2)
imsb3 Attitude towards social benefits for immigrants	.00 positive attitude	51	1.000	.000
	1.00 more positive than negative	128	.000	1.000
	2.00 negative attitude	69	.000	.000

Pavyzdžiui, *imsb3* = 1 atitiks derinys *imsb3(1)* = 0, *imsb3(2)* = 1, o *imsb3* = 2 atitiks derinys *imsb3(1)* = 0, *imsb3(2)* = 0.

- Pradinė klasifikacinė lentelė rodo, kad aklas spėjimas jog kiekvienas respondentas yra iš Estijos, duotų 50,4 % teisingų imties duomenų klasifikavimų.
- Tikėtinumų santykio kriterijaus ($\chi^2 = 115,195$) *p* reikšmė $p < 0,05$, o Hosmerio–Lemešou kriterijaus $\chi^2 = 13,132$, $p = 0,107 > 0,05$ rodo gerą modelio tikimą duomenims.
- Kokso ir Snello $R^2 = 0,372$, o Nagelkerkės $R^2 = 0,495$. Determinacijos koeficientai yra kiek mažesni nei tiriant pradinį modelį, bet reikšmės viršija 0,20.
- Patikrinę Kuko mato ir DFBetų reikšmes įsitikiname, kad visos jos neviršija vienetų. Darome išvadą, kad modelyje išskirčių nėra.
- Klasifikacinė lentelė rodo beveik tokį patį modelio tikimą kaip ir pradinis modelis. Bendrasis teisingai klasifikuotų imties respondentų procentas yra 77,4

Classification Table ^a					
Observed			Predicted		
			cntry Country		Percentage Correct
			EE Estonia	PT Portugal	
Step 1	cntry Country	EE Estonia	95	30	76.0
		PT Portugal	26	97	78.9
Overall Percentage					77.4

- Regresorių koeficientų įverčių lentelėje matome, kad visi kintamieji, išskyrus konstantą, statistiškai reikšmingi. Tik konstantai Voldo kriterijaus $p = 0,065 > 0,050$. Tradiciškai į konstantos statistinį reikšmingumą nekreipiame dėmesio. Juolab kad ir p reikšmė viršija 0,05 visai nedaug.

Variables in the Equation									
		B	S.E.	Wald	df	Sig.	Exp(B)	95 % C.I. for EXP(B)	
								Lower	Upper
Step 1 ^a	freehms	-.760	.158	23.117	1	.000	.468	.343	.637
	happy	.300	.099	9.258	1	.002	1.350	1.113	1.637
	stfedu	-.564	.091	38.819	1	.000	.569	.476	.679
	imsb3			11.371	2	.003			
	imsb3(1)	1.661	.508	10.688	1	.001	5.263	1.945	14.243
	imsb3(2)	1.137	.426	7.132	1	.008	3.117	1.353	7.178
	Constant	1.833	.992	3.415	1	.065	6.255		

a. Variable(s) entered on step 1: freehms, happy, stfedu, imsb3.

Įsitikinome, kad naujasis modelis gerai suderintas su duomenimis. Koeficientai B prie *freehms* ir *stfedu* yra neigiami, o koeficientas prie *happy* teigiamas⁵⁰. Primename, kad teigiamas koeficientas rodo, jog atitinkamam kintamajam didėjant, didėja ir $P(Y = 1)$ tikimybė. Ir atvirkščiai, jeigu koeficientas neigiamas, tai didėja $P(Y = 0)$ tikimybė. Todėl, didėjant *freehms* reikšmei didėja *cntry* = EE (modelio kodas 0) tikimybė. Taigi kuo respondentas priešiščiau nusistatęs seksualinių mažumų atžvilgiu (*freehms* didesnis), tuo labiau tikėtina, kad jis iš Estijos. Analogiškai darome išvadą, kad kuo respondentas palankiau vertina švietimo sistemą, tuo didesnė tikimybė, kad jis iš Estijos, o kuo laimingesnis, tuo labiau tikėtina, kad iš Portugalijos.

Stulpelyje **EXP(B)** pateikiamos galimybių santykių įverčių reikšmės, t. y. $e^{\hat{b}_i}$. Jau rezultatų išklotinės pradžioje buvo pažymėta, kad teigiamą požiūrį į socialines lengvatas *imsb3* = 1 atitinka kategorinių kintamųjų derinys *imsb3*(1) = 1, *imsb3*(2) = 0, o neigiamą *imsb3*(1) = 0, *imsb3*(2) = 0. Atitinkamas galimybių santykis pateiktas prie *imsb3*(1) = 1 ir yra 5,263. Todėl galime padaryti tokią išvadą: palankus požiūris į socialines lengvatas imigrantams, palyginti su nepalankiu, padidina tikimybių santykį

$$\frac{\hat{P}(cntry = PT)}{\hat{P}(cntry = EE)}$$

⁵⁰ Trumpumo dėlei čia ir toliau „koeficientai“, tai – „koeficientų įverčiai“.

5,263 karto. Tampa labiau tikėtina, kad respondentas buvo iš Portugalijos. Analogiškai labiau teigiamas nei neigiamas požiūris į socialines lengvatas ($imsb3(1) = 0$, $imsb3(2) = 1$) padidina tikimybių santykį 3,117 karto.

Analogiškai interpretuojami ir tolydžių kintamųjų galimybių santykiai. Pavyzdžiui, kiekvienas papildomas balas vertinant savo laimingumą (*happy*) padidina tikimybių santykį 1,35 karto. Tampa labiau tikėtina, kad respondentas iš Portugalijos. Kiekvienas papildomas balas vertinant švietimo būklę *stfedu*, pakeičia tikimybių santykį 0,569 karto (paprasciau kalbant, sumažina $1/0,569 = 1,76$ karto). Tada labiau tikėtina, kad respondentas iš Estijos.

Kadangi *happy* ir *stfedu* matavimo skalės daugmaž vienodos, labai supaprastindami situaciją galime tarti, kad *stfedu* modelyje įtakingesnis, nes jo pokytis galimybių santykį pakeičia dvigubai, o *happy* pokytis galimybių santykį pakeičia tik 1,35 karto.

Grafoje **95 % C.I. for EXP(B)** yra galimybių santykių 95 % pasikliautinių intervalų apatiniai (Lower) ir viršutiniai (Upper) rėžiai.

Pavyzdys. Pateiksime prognozavimo pavyzdį. Tarkime, kad respondentas labiau teigiamai nei neigiamai įvertino imigrantų galimybes naudotis socialinėmis lengvatomis ($imsb3 = 1$), savo laimingumo laipsnį įvertino 5 (*happy* = 5), požiūrį į seksualines mažumas 2 (*freehms* = 2), o šalies švietimo sistemą supeikė (*stfedu* = 4). Kokia tikimybė, kad tai respondentas iš Portugalijos? Visų pirma užrašome bendrąją logit funkcijos pavidalą naudodami koeficientų reikšmes iš lentelės **Variables in the Equation** stulpelio **B**:

$$z = -0,76 \text{ freehms} + 0,30 \text{ happy} - 0,564 \text{ stfedu} + 1,661 \text{ imsb3}(1) + 1,137 \text{ imsb3}(2) + 1,833.$$

Istatome į šią lygtį $imsb3(1) = 0$, $imsb3(2) = 1$ (nes būtent toks derinys atitinka $imsb3 = 1$, žr. prieš tai), $freehms = 2$, $happy = 5$, $stfedu = 4$, ir gauname $z = 2,95$. Tikimybė, kad atsakinėjo respondentas iš Portugalijos, skaičiuojama pagal formulę (primename, kad $e = 2,71828...$)

$$\hat{P}(cntry = PT) = \frac{e^z}{1 + e^z} = \frac{e^{2,95}}{1 + e^{2,95}} = 0,950 \dots$$

Taigi tikimybė, kad atsakinėjo respondentas iš Portugalijos, yra 0,95. Tikimybė, kad respondentas yra iš Estijos lygi 0,05.

4.2.5. Rezultatų aprašymas

Trumpai apibūdindami atliktą tyrimą galime konstatuoti, kad požiūris į seksualines mažumas, požiūris į imigrantus, požiūris į šalies švietimo sistemą ir bendrasis respondento laimingumas pakankamai tiksliai apibūdina respondento šalį. Belieka išsamiau aprašyti, kaip pasireiškia tas apibūdinimas.

Pirmiausia aprašome, ką tyrėme, kokius naudojome kintamuosius ir kaip juos perkodavome. Tada kompaktiškai surašome visa tai, ką išsamiai aptarėme ankstesniame skyrelyje. Pateikiame vieną iš daugybės galimų tokio aprašymo variantų.

Pritaikytas dvinarės logistinės regresijos modelis gerai tiko duomenims. Tikėtinumų santykio kriterijaus $\chi^2 = 115,195$; $p < 0,05$, Hosmerio–Lemešou kriterijaus statistikos reikšmė 13,132; o $p = 0,107 > 0,05$. Nagelkerkės $R^2 = 0,495$. Teisingai klasifikuojama 76 % Estijos respondentų ir 78,9 % Portugalijos respondentų. Voldo kriterijus rodo, kad visi regresoriai yra statistiškai reikšmingi. Gautas toks modelis

$$\ln \frac{\hat{P}(\text{cntry} = \text{PT})}{\hat{P}(\text{cntry} = \text{EE})} = -0,76 \text{ freehms} + 0,30 \text{ happy} - 0,564 \text{ stfedu} \\ + 1,661 \text{ imsb3}(1) + 1,137 \text{ imsb3}(2) + 1,833$$

*Čia $\text{imsb3}(1) = 1$, $\text{imsb3}(2) = 0$ atitinka $\text{imsb3} = 0$; $\text{imsb3}(1) = 0$, $\text{imsb3}(2) = 1$ atitinka $\text{imsb3} = 1$; $\text{imsb3}(1) = 0$, $\text{imsb3}(2) = 0$ atitinka $\text{imsb3} = 2$. Didesnės regresorių *freehms*, *stfedu* reikšmės didina tikimybę, kad respondentas yra iš Estijos, o didesnė *happy* reikšmė – kad respondentas esąs iš Portugalijos. Galimybių santykio įvertis regresoriui *freehms* yra 0,468 (95 % pasikliautinis intervalas [0,343; 0,637]), galimybių santykio įvertis regresoriui *happy* yra 1,35 ([1,113; 1,637]), o galimybių santykio įvertis regresoriui *stfedu* yra 0,569 ([0,476; 0,679]). Lyginant su nepalankia nuomone apie imigrantus ($\text{imsb3} = 2$), palanki nuomonė ($\text{imsb} = 0$) padidina galimybę Portugalijos naudai 5,263 karto (95 % galimybių santykio pasikliautinis intervalas [1,945; 14,243]). Lyginant su nepalankia nuomone apie imigrantus ($\text{imsb3} = 2$), labiau palanki nei nepalanki nuomonė ($\text{imsb} = 1$) padidina galimybę Portugalijos naudai 3,117 karto ([1,353; 7,178]).*

4.2.6. SPSS komandų sintaksė

Surašysime kaip atrodo SPSS komandos nagrinėtajam pradiniam logistinės regresijos modeliui. Jas galima vykdyti sintaksės lange, pasirenkant **Run**.


```
LOGISTIC REGRESSION VARIABLES cntry
/METHOD=ENTER freehms happy imsc1bn stfedu
/CONTRAST (imsc1bn)=Indicator
/SAVE=COOK
/PRINT=GOODFIT CI(95)
/CRITERIA=PIN(0.05) POUT(0.10) ITERATE(20) CUT(0.5).
```

4.2.7. Regresorių sąveika

Regresorių sąveika (interakcija) vadinama situacija, kai į modelį įtraukiama jų sandauga. Toks modelis reiškia, kad regresoriai gali veikti vienas kitą. Visos interpretacijos ir tyrimo etapai lieka nepakitę. Tereikia modelyje nurodyti norimą sąveiką. Tarkime, norime patikrinti modelį, kurį sąlygiškai užrašome taip:

$$cntry = f(stfedu, happy, freehms, happy*freehms).$$

Atsidarę **Logistic Regression** meniu po vieną perkeliame kintamuosius į **Covariates** langą, po to pažymime abudu kintamuosiu *happy* ir *freehms* ir spaudžiame **>a*b>**.



Pasirinkę kitas parinktis taip kaip ir pirmiau aptartuose pavyzdžiuose gauname, kad visi rodikliai, išskyrus koeficientų lentelę, rodo gerą modelio tikimą duomenims. O Voldo kriterijaus rezultatai parodė, kad *happy* ir *freehms* sąveika yra statistiškai nereikšminga.

Variables in the Equation						
	B	S.E.	Wald	df	Sig.	Exp(B)
Step 1 ^a						
freehms	-.847	.570	2.204	1	.138	.429
stfedu	-.537	.082	43.414	1	.000	.584
happy	.291	.216	1.824	1	.177	1.338
freehms by happy	.013	.077	.030	1	.863	1.013
Constant	2.746	1.663	2.725	1	.099	15.579

a. Variable(s) entered on step 1: freehms, stfedu, happy, freehms * happy .

Įdomu, kad statistiškai nereikšmingas tapo ir regresorius *happy*. Darome išvadą, kad modelyje regresorių sąveika buvo nereikalinga.

4.2.8. Viena dominuojanti priklausomo kintamojo reikšmė

Tarkime, kad norime pagal požiūrį į seksualines mažumas (*freehms*) atskirti kasdien besimeldžiančius Estijos 20–40 metų respondentus (*pray* = 1) nuo to paties amžiaus niekada nesimeldžiančiųjų (*pray* = 7). Pateikiame klasifikacinę lentelę. Matome, kad bendrasis 96,9 teisingų klasifikacijų procentas visai nereiškia gero klasifikavimo. Tiesiog imtyje buvo tik 5 kasdien besimeldžiantys Estijos gyventojai, kurių nė vienas nebuvo atpažintas. Buvo pažeistas reikalavimas, kad kiekviena priklausomo kintamojo reikšmė turi sudaryti bent penktadalį imties

Classification Table^a

Observed			Predicted		
			pray How often pray apart from at religious services		Percentage Correct
			1 Every day	7 Never	
Step 1	pray How often pray apart from at religious services	1 Every day	0	5	.0
		7 Never	0	158	100.0
Overall Percentage					96.9

4.2.9. Multikolinearumas

Pateiksime vieną pavyzdį, kai dvinarės logistinės regresijos modelyje pasireiškia multikolinearumas. Tirsime Estijos 20–40 metų vyrų požiūrį į Europarlamentą. Naudosime 2008 metų Europos Sąjungos socialinio tyrimo Estijos duomenis. Tyrime naudosime tokius kintamuosius: *trstprl* (pasitikėjimas šalies parlamentu), *trstlgl* (pasitikėjimas teisine sistema), *trstplc* (pasitikėjimas policija), *trstplt* (pasitikėjimas politikais), *trstprt* (pasitikėjimas partijomis), *trstun* (pasitikėjimas Jungtinėmis Tautomis, *trstep* (pasitikėjimas Europarlamentu).

Visi kintamieji matuojami 10 balų skale nuo 0 (itin nepasitikiu) iki 9 (itin pasitikiu). Kintamąjį *trstep* keičiame dvireikšmiu kintamuoju $zzzz = 0$, kai $trstep \leq 2$ ir $zzzz = 1$, kai $trstep \geq 8$. Taigi *zzzz* rodo požiūrio į Europarlamentą kraštutinumus. Sudarome kintamajam *zzzz* logistinės regresijos modelį, regresoriais imdami visus likusius kintamuosius. Visi rodikliai, išskyrus koeficientų lentelę, tiesiog *fantastiški*:

- Tikėtinumų santykio kriterijaus $p = 0,000$, Hosmerio–Lemešou kriterijaus $p = 1$, Nagelkerkės $R^2 = 1$.

- Kvalifikacinė lentelė rodo, kad modelis 100 % imties stebinių klasifikuoja teisingai. Beje, abiejų kategorijų stebinių skaičius buvo panašus (28 ir 19).

O iš koeficientų įverčių lentelės **Variables in the Equation** rezultatų matyti, kad visi regresoriai yra statistiškai nereikšmingi. Be to, visos Voldo statistikos standartinės paklaidos **S.E.** yra tiesiog didžiulės. Visuose pirmiau nagrinėtuose modeliuose jos retai kada viršydavo vieneta, o čia visos didesnės už 1900. Galiausiai neigiami koeficientų **B** ženklai taip pat kelia įtarimą. Išeitų, kad kuo labiau respondentas pasitiki savo šalies parlamentu, tuo mažesnė tikimybė, kad jis pasitiks Europarlamentu. Visi šie požymiai rodo, kad modelyje yra multikolinearumo problema. Darome išvadą, kad modelis netinkamas. **Nepaisant visų kitų gerų rodiklių.**

Variables in the Equation						
		B	S.E.	Wald	df	Sig.
Step 1 ^a	trstlgl	4.366	1917.425	.000	1	.998
	trstplc	12.254	2355.696	.000	1	.996
	trstplt	-2.964	4088.301	.000	1	.999
	trstprl	-4.368	2761.944	.000	1	.999
	trstprt	11.969	5018.000	.000	1	.998
	trstun	9.491	2069.086	.000	1	.996
	Constant	-182.445	20226.246	.000	1	.993
		Exp(B)				
		78.691				
		209789.593				
		.052				
		.013				
		157850.256				
		13245.274				
		.000				

a. Variable(s) entered on step 1: trstlgl, trstplc, trstplt, trstprl, trstprt, trstun.

Beje, sumodeliavus zzzz vien pagal *trstprl*, atitinkamo koeficiento ženklas tampa teigiamu. Taigi multikolinearus modelis iš tikrųjų iškrepė kintamųjų priklausomybes.

4.2.10. Žingsninė logistinė regresija


Pastabose minėjome, kad daugiausia dėmesio sutelksime į logistinės regresijos modelio tyrimą, kai regresorius šalina arba keičia tyrėjas. SPSS yra realizuota galimybė, kai iš pateiktų regresorių sudaromas geriausias modelis. Tai atliekama formaliai, atsižvelgus į statistinį jų reikšmingumą, bet ne į prasmę. Yra du principiniai žingsninės regresijos metodai. Kaupiamojoje žingsninėje regresijoje pradedama nuo trivialaus modelio, sudaryto iš konstantos. Šis modelis laipsniškai pildomas kitais regresoriais. Alternatyviai šalinamojoje žingsninėje regresijoje pradedama nuo modelio su visais regresoriais, tolydžio vis mažinant regresorių skaičių. Žinoma, tik principiniai metodų skirtumai. Iš tikrųjų dalis regresorių gali būti viename žingsnyje pašalinti, o kitame grąžinti.

SPSS yra realizuota keletas tokių algoritmų. Dažniausiai atsižvelgiama į didžiausio tikėtimumo funkcijos reikšmes. Pademonstruosime vieną iš tokių metodų.

Pasirinksime pradinį tirtą modelį, t. y. tirsime, ar skiriasi 20–30 metų vyrai iš Portugalijos nuo tokio paties amžiaus vyrų iš Estijos, jeigu atsižvelgsime į kintamųjų *stfedu*, *happy*, *freehms* ir *imsclbn* reikšmes. Sąlygiškai modelį galima užrašyti taip:

$$cntry = f(stfedu, happy, freehms, imsclbn).$$

Visas parinktis pasirenkame taip kaip aprašyta 3.2.2 skyrelyje. Vienintelis skirtumas tas, kad pagrindiniame meniu pasirenkame **Method: Forward LR**.



Pasirinkome metodą, kai pradinis modelis vis papildomas naujais regresoriais. Rezultatų išsklotinė prasideda jau matyta informacija apie kintamųjų kodus ir klasifikavimą, kai aklaai spėjama priklausomybė Estijai. Paskui pateikiama informacija apie pradinį modelį, kurį sudaro tik konstanta. Tai *a priori* blogas modelis, nes jis teigia, kad joks regresorius nepadės rasti skirtumų tarp portugalų ir estų. Iš tikrųjų įsitikiname, kad jis statistiškai nereikšmingas (Voldo kriterijaus statistikos $p = 0,899 > 0,05$).

Variables in the Equation						
	B	S.E.	Wald	df	Sig.	Exp(B)
Step 0 Constant	-.016	.127	.016	1	.899	.984

Lentelėje **Variables not in the Equation** išvardyti visi regresoriai, kartu pateikiant jų Roa statistikos (Voldo kriterijaus statistikos tam tikras analogas) reikšmes stulpelyje **Score** ir p reikšmes stulpelyje **Sig**. Visi regresoriai statistiškai reikšmingi ir juos galima bandyti įtraukti į modelį.

Variables not in the Equation					
			Score	df	Sig.
Step 0	Variables	Freehms	34.961	1	.000
		Happy	7.024	1	.008
		Stfedu	46.378	1	.000
		Imsclbn	39.756	4	.000
		imscIbn(1)	14.248	1	.000
		imscIbn(2)	.028	1	.866
		imscIbn(3)	7.143	1	.008
		imscIbn(4)	31.529	1	.000
Overall Statistics		99.531	7	.000	

Iš kitų lentelių matyti, kad regresoriai į modelį buvo įtraukiami keturiais etapais (keturi regresijos žingsniai). Po kiekvieno žingsnio svarbiausios modelio charakteristikos rodė, kad naujasis modelis gerai tinka duomenims. Tikėtinumų santykio statistikos p reikšmės $< 0,05$; Hosmerio– Lemešou kriterijaus p reikšmės $> 0,05$. Determinacijos pseudokoefficientų reikšmės vis didėjo.

Hosmer and Lemeshow Test			
Step	Chi-square	df	Sig.
1	4.313	6	.634
2	10.556	8	.228
3	4.928	8	.765
4	5.846	8	.665

Omnibus Tests of Model Coefficients				
		Chi-square	df	Sig.
Step 1	Step	50.185	1	.000
	Block	50.185	1	.000
	Model	50.185	1	.000
Step 2	Step	42.426	1	.000
	Block	92.611	2	.000
	Model	92.611	2	.000
Step 3	Step	18.644	4	.001
	Block	111.255	6	.000
	Model	111.255	6	.000
Step 4	Step	10.792	1	.001
	Block	122.047	7	.000
	Model	122.047	7	.000

Model Summary

Step	-2 Log likelihood	Cox & Snell R Square	Nagelkerke R Square
1	293.600 ^a	.183	.244
2	251.174 ^b	.312	.416
3	232.530 ^b	.361	.482
4	221.738 ^b	.389	.518

Jungtinė klasifikacinė lentelė rodo, kad naujų regresorių įtraukimas, pradedant antruoju žingsniu, klasifikavimą nelabai gerino.

Classification Table^a

Observed			Predicted		
			cntry Country		Percentage Correct
			EE Estonia	PT Portugal	
Step 1	cntry Country	EE Estonia	92	33	73.6
		PT Portugal	40	83	67.5
	Overall Percentage				70.6
Step 2	cntry Country	EE Estonia	98	27	78.4
		PT Portugal	30	93	75.6
	Overall Percentage				77.0
Step 3	cntry Country	EE Estonia	96	29	76.8
		PT Portugal	27	96	78.0
	Overall Percentage				77.4
Step 4	cntry Country	EE Estonia	97	28	77.6
		PT Portugal	26	97	78.9
	Overall Percentage				78.2

Galiausiai gauname visų žingsnių logistinės regresijos modelius. Matome, kad kiekvienas įtrauktas tolydus regresorius buvo statistiškai reikšmingas. Kadangi kategorinio kintamojo *imsclbn* kai kurie pseudokintamieji taip pat buvo statistiškai reikšmingi, ir jis modelyje buvo paliktas.

Rezultatų išklotinėje dar pateikiama lentelė **Model if Term Removed**, kuri rodo, kad visi regresoriai modelyje reikalingi (**Sig. of the Change** visiems regresoriams yra < 0,05).

Galutinis tokiu būdu gautas modelis sutampa su 4.2.2 skyrelyje nagrinėtuuoju modeliu, kurį sąlygiškai (tikslus užrašas užimtų daug vietos, nes reikėtų išvardyti visas *imsclbn* kategorijas) galima užrašyti taip: $cntry = f(\text{freehms}, \text{happy}, \text{stfedu}, \text{imsclbn})$.

Šiame modelyje liko statistiškai nereikšmingų pseudokintamųjų. Žinome, kad toks modelis nėra geras, nes duomenyse tiesiog nėra pakankamai daug visų *imsclbn* kategorijų reikšmių. Modelį patobulinome, transformuodami (perkoduodami) kintamąjį *imsclbn*. Žingsninė regresija čia negali pagelbėti.

Kita vertus, galime panaudoti žingsninę regresiją visų modelių analizei ir apsiriboti antruoju modeliu, kuris yra visai neblogas:

$$\ln \frac{\hat{P}(\text{cntry} = \text{PT})}{\hat{P}(\text{cntry} = \text{EE})} = 5,145 - 0,899 \text{ freehms} - 0,539 \text{ stfedu}.$$


Variables in the Equation								
		B	S.E.	Wald	df	Sig.	Exp(B)	95 % C.I. for EXP(B)
								Lower Upper
Step 1 ^a	stfedu	-.463	.074	39.518	1	.000	.630	.545 .727
	Constant	2.511	.431	33.974	1	.000	12.317	
Step 2 ^b	freehms	-.899	.155	33.588	1	.000	.407	.300 .551
	stfedu	-.539	.084	40.802	1	.000	.584	.495 .688
	Constant	5.145	.711	52.408	1	.000	171.531	
Step 3 ^c	freehms	-.781	.156	25.149	1	.000	.458	.338 .622
	stfedu	-.511	.087	34.832	1	.000	.600	.506 .711
	imsclbn			15.886	4	.003		
	imsclbn(1)	1.990	1.197	2.761	1	.097	7.312	.700 76.418
	imsclbn(2)	.260	1.116	.054	1	.816	1.296	.146 11.552
Step 4 ^d	imsclbn(3)	.511	1.037	.243	1	.622	1.667	.218 12.732
	imsclbn(4)	-.737	1.081	.465	1	.495	.479	.058 3.981
	Constant	4.378	1.233	12.608	1	.000	79.652	
	freehms	-.730	.160	20.938	1	.000	.482	.352 .659
	happy	.314	.099	10.025	1	.002	1.369	1.127 1.663
	stfedu	-.564	.092	37.329	1	.000	.569	.475 .682
	imsclbn			15.751	4	.003		
	imsclbn(1)	1.849	1.284	2.075	1	.150	6.354	.513 78.647
	imsclbn(2)	-.039	1.197	.001	1	.974	.962	.092 10.046
	imsclbn(3)	.195	1.123	.030	1	.862	1.215	.134 10.977
	imsclbn(4)	-1.057	1.168	.819	1	.366	.347	.035 3.430
	Constant	2.599	1.422	3.341	1	.068	13.445	

4.2.11. Apibendrintas tiesinis modelis su logit jungtimi


Formuluodami reikalavimus duomenims (žr. 4.1.4 skyrelį) minėjome, kad logistinės regresijos modelis naudojamas ir tada, kai dauguma regresorių kategoriniai. Tiesiog tokį modelį labiau įprasta vadinti apibendrintu tiesiniu modeliu su logit jungtimi, o jį aprašant, pateikti *deviacijos ir jos laisvės laipsnių santykį*. Kiekvieną logistinės regresijos modelį galima tirti kaip atskirą apibendrinto tiesinio modelio atvejį, tiesiog tai nėra patogu. Parodysime tai tirdami 4.2.4 skyrelio modelį (čia pateikiamas sąlyginis modelio užrašas):

$$cntry = f(stfedu, happy, freehms, imsb3).$$


Tirsime 20–30 metų vyrus (atrenkame $agea \geq 20$ & $agea \leq 30$ & $gndr = 1$). Pasirenkame **Analyze** → **Generalized Linear Models** → **Generalized Linear Models...**



Lange **Type of Model** pažymime **Binary logistic**.



Renkamės **Response**. Į langelį **Dependent Variable** įkeliamo *cntry*.



Renkamės **Predictors**. Į langelį **Factors** įkeliamo *imsb3*, o į langelį **Covariates** regresorius *freehms, happy, stfedu*.

Renkamės **Model**. Perkeliame visus regresorius į lauką **Model**.

Type of Model	Response	Predictors	Model	Estimation	Statistics	EM Means	Save	Export
Specify Model Effects								
Factors and Covariates:				Model:				
imsb3 freehms happy stfedu				imsb3 freehms happy stfedu				
Build Term(s)								
Type:								
Main effects								

Renkamės **Statistics**. Papildomai pažymime **Include exponential parameter estimates**.

Renkamės **Save** ir pažymime **Predicted category** ir **Cook's distance**. Spaudžiame **OK**.

Save	Item to Save	Variable Name
☐	Predicted value of mean of response	MeanPredicted
☐	Lower bound of confidence interval for mean of response	CIMeanPredicted
☐	Upper bound of confidence interval for mean of response	CIMeanPredicted
☒	Predicted category	PredictedValue
☐	Predicted value of linear predictor	XPredicted
☐	Estimated standard error of predicted value of linear predictor	XBStandardError
☒	Cook's distance	CooksDistance

Rezultatų išsklotinėje nesunkiai randame dalį tos informacijos, kurią jau aprašėme 4.2.4 skyrelyje. Pavyzdžiui, modelio parametrai (kategorinis kintamasis *imsb3* keičiamas pseudokintamaisiais), jų statistinis reikšmingumas, galimybių santykių įverčiai ir galimybių santykių pasikliautiniai intervalai surašyti lentelėje **Parameter Estimates**.

Parameter Estimates										
Parameter	B	Std. Error	95 % Wald Confidence Interval		Hypothesis Test			Exp(B)	95 % Wald Confidence Interval for Exp(B)	
			Lower	Upper	Wald Chi- Square	df	Sig.		Lower	Upper
(Intercept)	-1.833	.9922	-3.778	.111	3.415	1	.065	.160	.023	1.118
[imsb3=.00]	-1.661	.5080	-2.656	-.665	10.688	1	.001	.190	.070	.514
[imsb3=1.00]	-1.137	.4256	-1.971	-.303	7.132	1	.008	.321	.139	.739
[imsb3=2.00]	0 ^a	.	.	.	.	.	.	1	.	.
freehms	.760	.1581	.450	1.070	23.117	1	.000	2.139	1.569	2.916
happy	-.300	.0985	-.493	-.107	9.258	1	.002	.741	.611	.899
stfedu	.564	.0906	.387	.742	38.819	1	.000	1.759	1.472	2.100
(Scale)	1 ^b									

Tikėtinumų santykio statistikos ir p reikšmės (0,00) pateikiamos lentelėje **Omnibus Test**. Skyrelyje 4.2.4 buvo nurodyta, kad visos šios charakteristikos rodo gerą modelio tikimą.

Omnibus Test ^a		
Likelihood Ratio		
Chi-Square	df	Sig.
115.195	5	.000

Rezultatų išsklotinėje nėra determinacijos pseudokoefficientų (nedidelė bėda) ir klasifikacinės lentelės (rimtas trūkumas). Užtat lentelėje **Goodness of Fit** pateikiama deviacija. Ji parodo, kiek tiriamas modelis skiriasi nuo tiksliai visus duomenis aprašančio (bet labai sudėtingo ir todėl naudoti netinkamo) modelio. Dar reikia atsižvelgti į imties didumą ir regresorių skaičių, kuriuos nusako vadinamieji laisvės laipsniai⁵¹.

Gera duomenims tinkamo apibendrinto tiesinio modelio deviacijos ir laisvės laipsnių santykis turi būti artimas vienetui.

Deviacijos ir laisvės laipsnių santykį randame stulpelyje **Value/df**. Šis santykis yra 0,976. Tai patvirtina gerą modelio tikimą duomenims.

Goodness of Fit ^b			
	Value	df	Value/df
Deviance	180.584	185	.976
Scaled Deviance	180.584	185	
Pearson Chi-Square	191.020	185	1.033
Scaled Pearson Chi-Square	191.020	185	
Log Likelihood ^a	-100.038		
Akaike's Information Criterion (AIC)	212.076		
Finite Sample Corrected AIC (AICC)	212.424		
Bayesian Information Criterion (BIC)	233.156		
Consistent AIC (CAIC)	239.156		

⁵¹ Angl. *degrees of freedom, df*.


Rezultatų išklotinėje lentelėje **Tests of Model Effects** pateikiamos p reikšmės kiekvienam regresoriui. Įsitikiname, kad visi regresoriai yra statistiškai reikšmingi, taigi svarbūs modeliui.

Tests of Model Effects			
Source	Type III		
	Wald Chi-Square	df	Sig.
(Intercept)	9.067	1	.003
imsb3	11.371	2	.003
freehms	23.117	1	.000
happy	9.258	1	.002
stfedu	38.819	1	.000

Dependent Variable: Country

Model: (Intercept), imsb3, freehms, happy, stfedu

Parinkome tokias SPSS **Save** parinktis, kad atsirado du nauji duomenų stulpeliai: *CooksDistance* su Kuko mato reikšmėmis ir *PredictedValue* su prognozuojama respondento šalimi kiekvienam respondentui. Norėdami įsitikinti, kad duomenys neturi išskirčių, renkamės **Analyze** → **Descriptive Statistics** → **Descriptives**. Perkeliame *CooksDistance* į laukelį **Variable(s)** ir spaudžiame **OK**.




Matome, kad maksimali Kuko mato reikšmė neviršija 1, todėl darome išvadą, kad duomenys neturi išskirčių.


Descriptive Statistics					
	N	Minimum	Maximum	Mean	Std. Deviation
CooksDistance_4 Cook's Distance	248	.000	.050	.00439	.008036
Valid N (listwise)	248				

Gauti klasifikacinę lentelę yra kiek sunkiau, nes SPSS į prognozuojamas reikšmes įtraukia ir tuščius langelius, t. y. tuos 29 respondentus, kurių duomenys buvo nepilni ir modeliuojant nebuvo naudojami. Todėl duomenyse kairiame apatiniame kampe spaudžiame **Variable View**, kintamųjų

sąrašo apačioje randame **PredictedValue**, jam atidarome langelį **Missing Values** ir pažymime **Discrete missing values**. Su pele „kliktelime“ ant pirmo langelio ir spaudžiame tarpo klavišą (įvedame tučią lauką). Ekrane niekas nepasikeičia, tik pelės kursorius kiek atsitraukia nuo langelio krašto.



Spaudžiame OK. Grįžtame į duomenų langą Data View. Pasirenkame Analyze → Descriptive Statistics → Crosstabs. Į langelį Row(s) perkeliame kintamąjį *cntry*, į langelį Column(s) – kintamąjį *PredictedValue*.



Renkamės **Cells** ir pažymime **Row**. Spaudžiame **Continue** ir **OK**. Gauname klasifikacinę lentelę

cntry Country * PredictedValue Predicted Category Value Crosstabulation					
			PredictedValue Predicted		
			Category Value		
			EE Estonia	PT Portugal	Total
cntry Country	EE Estonia	Count	95	30	125
		% within cntry Country	76.0%	24.0%	100.0%
	PT Portugal	Count	26	97	123
		% within cntry Country	21.1%	78.9%	100.0%
Total		Count	121	127	248
		% within cntry Country	48.8%	51.2%	100.0%

Taikant modelį, teisingai klasifikuojama 76 % Estijos respondentų ir 78,9 % Portugalijos respondentų.

Skyrelio pabaigoje dar kartą pakartosime savo požiūrį, kad SPSS programa daryti logistinę regresiją, naudojantis apibendrintu tiesiniu modeliu su logit jungtimi, verta tik tada, kai yra daug kategorinių regresorių. Šiaip daug lengviau tyrimą atlikti su **Regression → Binary Logistic**.

4.3. Dvinarė logistinė regresinė analizė su STATA

4.3.1. Duomenys

Kaip atlikti dvinarę logistinę regresinę analizę parodysime, tirdami Europos Sąjungos socialinio tyrimo (*European Social Survey*) Lietuvos ir Portugalijos duomenis **ESS4LT1** ir **ESS4PT**. Tirsime 20–30 metų vyrus. Tyrime naudosime tokius kintamuosius:

- *cntry* – šalies kodas (LT – Lietuva, PT – Portugalija),
- *stfgov* – respondento požiūris į savo šalies vyriausybę (0 – itin bloga, ..., 9 – itin gera),
- *freehms* – gėjai ir lesbietės gali gyventi kaip nori (1 – visiškai sutinku, ..., 5 – visiškai nesutinku),
- *imsclbn* – kada imigrantai gali visiškai naudotis šalies socialinėmis lengvatomis (matuojamas nominalia skale: 1 – iškart atvykę, 2 – po vienerių metų, neatsižvelgiant į tai, ar dirbo, 3 – po vienerių darbo ir mokesčių mokėjimo metų, 4 – tapę piliečiais, 5 – niekada negalės naudotis visomis lengvatomis).

Duomenų atrankai naudosime kintamuosius: *agea* – amžių ir *gndr* – lytį (1 – vyr., 2 – mot.). Grafikams pravers respondento identifikacijos numeris *idno*.

Sujungę SPSS failus, išsaugome juos *dta* formatu. Atidarę failą STATA programa, visų pirma paliekame tik tuos kintamuosius, kurių reikės tyrime:

```
keep agea gndr cntry stfgov freehms imsc1bn idno
```

Paliksime tyrime reikiamo amžiaus ir lyties respondentus. Kad nekiltų problemų su neteisingai išsaugotais praleistų reikšmių kodais, dar įvesime apribojimus kitų kintamųjų reikšmėms:

```
keep if agea >=20 & agea <= 30 & gndr == 1 & stfgov <= 9 & freehms <=5 & imsc1bn <=5
```

Galima pasižiūrėti informaciją apie failo kintamuosius. Įvykdome

```
describe cntry stfgov freehms imsc1bn
```

```
. describe cntry stfgov freehms imsc1bn
```

variable name	storage type	display format	value label	variable label
cntry	str2	%2s		Country
stfgov	double	%10.0g	stfgov	How satisfied with the national government
freehms	double	%10.0g	freehms	Gays and lesbians free to live life as they wish
imsc1bn	double	%10.0g	imsc1bn	When should immigrants obtain rights to social benefits/services

```
tabulate cntry
```

Country	Freq.	Percent	Cum.
LT	161	56.69	56.69
PT	123	43.31	100.00
Total	284	100.00	

Matome, kad abiejų šalių atstovų yra maždaug po tiek pat. Kintamasis *imsc1bn* yra kategorinis.

Prieš įtraukiant kategorinį kintamąjį į logistinės regresijos modelį, reikia įsitikinti, kad kiekvienai jo kategorijai yra pakankamai daug stebinių.

Patikriname, kokias reikšmes įgyja *imsclbn*:

```
tabulate cntry imscbn
```

Country	when should immigrants obtain rights to social benefits/services					Total
	Immediate	After a y	After wor	Once they	They shou	
LT	10	9	58	75	9	161
PT	22	12	73	13	3	123
Total	32	21	131	88	12	284

Matome, kad Lietuvos imtyje mažai respondentų rinkosi 1, 2 ir 5. Todėl regresorių *imsclbn* keisime kategoriniu kintamuoju, įgyjančiu mažiau reikšmių. Sukursime du tokius kintamuosius: *imsb3* (*imsb3* = 0, kai *imsclbn* = 1 arba 2; *imsb3* = 1, kai *imsclbn* = 3; *imsb3* = 2, kai *imsclbn* = 4 arba 5) ir *imsb2* (*imsb2* = 0, kai *imsclbn* = 1, 2 arba 3; *imsb2* = 1, kai *imsclbn* = 4 arba 5):

```
recode imscbn (1 2 = 0) (3 = 1) (4 5 = 2), gen(imsb3)
recode imscbn (1/3 = 0) (4 5 = 1), gen(imsb2)
```

Mažesnės *imsb2*, *imsb3* reikšmės rodo palankesnę nuostatą imigrantų atžvilgiu. Įsitikiname, kad dabar yra pakankamai daug stebinių⁵² kiekvienai regresorių kategorijai. Įvykdome

```
tabulate cntry imsb2
```

country	RECODE of imscbn (when should immigrants obtain rights to social benefits/servi		Total
	0	1	
LT	77	84	161
PT	107	16	123
Total	184	100	284

```
tabulate cntry imsb3
```

⁵² Ką reiškia pakankamai daug, sprendžia tyrėjas. Mūsų nuomone, jeigu kažkokį atsakymą renkasi mažiau nei 10 % respondentų, vertėtų pamąstyti apie kintamojo perkodavimą, paliekant mažiau kategorijų.

country	RECODE of imsb2 (when should immigrants obtain rights to social benefits/servi			Total
	0	1	2	
LT	19	58	84	161
PT	34	73	16	123
Total	53	131	100	284

4.3.2. Modelio tyrimas

Logistinę regresiją STATA programa galima atlikti naudojant *logit* ir *logistic* komandas. Didelio skirtumo tarp šių komandų nėra, todėl apsiribosime komanda *logit*. Tirsime modelį, kurį sąlygiškai galima užrašyti taip: $cntry = f(stfgov, freehms, imsb2)$. Modelyje yra vienas dvireikšmis regresorius *imsb2* (reikšmės 0 ir 1). Jeigu *cntry* įgytų tik 0 arba 1, komanda atrodytų taip: *logit cntry freehms stfgov imsb2*. Nagrinėjamame pavyzdyje *cntry* yra simbolinis kintamasis. Jis bus automatiškai perkoduotas, jeigu tą nurodysime komandoje. Analogiškai pasielgsime su *imsb2*.

Įvykdome komandą:

xi: logit i.cntry freehms stfgov i.imsb2

i.cntry	_Icntry_1-2	(_Icntry_1 for cntry==LT omitted)				
i.imsb2	_Iimsb2_0-1	(naturally coded; _Iimsb2_0 omitted)				
Iteration 0:	log likelihood	=	-194.30391			
Iteration 1:	log likelihood	=	-139.71847			
Iteration 2:	log likelihood	=	-135.06235			
Iteration 3:	log likelihood	=	-134.8241			
Iteration 4:	log likelihood	=	-134.82313			
Logistic regression		Number of obs	=	284		
		LR chi2(3)	=	118.96		
		Prob > chi2	=	0.0000		
Log likelihood = -134.82313		Pseudo R2	=	0.3061		

_Icntry_2	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
freehms	-.81604	.151165	-5.40	0.000	-1.112318	-.5197622
stfgov	.3504268	.0753233	4.65	0.000	.2027959	.4980578
_Iimsb2_1	-1.708391	.3430608	-4.98	0.000	-2.380778	-1.036004
_cons	1.306911	.427897	3.05	0.002	.4682487	2.145574

Viršuje nurodoma, kad *cntry* buvo automatiškai pakeistas kintamuoju *_Icntry_2*, kuris įgyja reikšmes 1 (kai *cntry* = PT) ir 0 (kai *cntry* = LT). Kategorinis regresorius *imsb2* buvo pakeistas identišku jam regresoriumi *_Iimsb2*. Tikėtinumų santykio kriterijaus statistikos reikšmė (118,96) ir *p* reikšmė (0.00..) pateikiama lentelės dešinėje pusėje. Faktiškai tai informacija, kad su pasirinktais

regresoriais modelis gerai tinka duomenims, nors neaišku, ar visi regresoriai modelyje reikalingi. Kuo tikėtinumų santykio kriterijaus statistikos reikšmė didesnė, tuo labiau tikėtina, kad logistinės regresijos modelis tinka. Jis ypač informatyvus, kai turima labai daug duomenų.

Determinacijos pseudokoeficiento reikšmė nėra didelė (**Pseudo R² = 0.3061**), bet logistinei regresijai šis rodiklis yra nelabai svarbus. Juolab kad vis tiek viršija 0,20 – tradicinę determinacijos koeficientams taikomą tinkamumo ribą. STATA pateikia Makfadeno determinacijos pseudokoeficientą.

Užrašysime modelį, įstatydami koeficientų įverčius ($\exp\{x\}$, trumpas e^x žymėjimas).

$$\frac{\hat{P}(cntry = PT)}{\hat{P}(cntry = LT)} = \exp\{1,31 + 0,35 stfgov - 0,81 freehms - 1,71 imsb2\}.$$

Įsitikiname modelio logiškumu. Didėjant skliaustuose esančiam reiškiniui (tikimybių santykio logit funkcijai), didėja ir tikimybė, kad respondentas iš Portugalijos. Ir atvirkščiai, mažėjant skliaustuose esančiam reiškiniui, didėja tikimybė, kad respondentas iš Lietuvos. Koeficientas prie *freehms* ir yra neigiamas, o koeficientas prie *stfgov* teigiamas. Todėl, didėjant *freehms* reikšmei, didėja tikimybė, kad respondentas iš Lietuvos. Vadinasi, kuo respondentas priešiščiau nusistatęs seksualinių mažumų atžvilgiu (*freehms* didesnis), tuo tikėtiniau, kad jis iš Lietuvos. Analogiškai darome išvadą, kad kuo respondentas palankiau vertina vyriausybę, tuo didesnė tikimybė, kad jis iš Portugalijos. Koeficientas prie *imsb2* yra neigiamas. Kai įstatome vienetą (*imsb2* = 1 atitinka neigiamą požiūrį į imigrantus), visas reiškinys sumažėja ir padidėja tikimybė, kad respondentas iš Lietuvos.

Modelio regresorių galimybių santykių įverčiai gaunami įvykdžius komandą:

xi: logit i.cntry freehms stfgov i.imsb2, or						
Logistic regression			Number of obs	=	284	
			LR chi2(3)	=	118.96	
			Prob > chi2	=	0.0000	
Log likelihood = -134.82313			Pseudo R2	=	0.3061	
_Icntry_2	Odds Ratio	Std. Err.	z	P> z	[95% Conf. Interval]	
freehms	.4421792	.066842	-5.40	0.000	.328796	.594662
stfgov	1.419673	.1069345	4.65	0.000	1.224822	1.645522
_Iimsb2_1	.1811571	.0621479	-4.98	0.000	.0924786	.3548699

Regresoriaus *imsb2* galimybių santykio įvertis yra 0,181. Todėl galime padaryti tokią išvadą: nepalankus požiūris į socialines lengvatas imigrantams (*imsb2* = 1), palyginti su palankiu, padidina santykį

$$\frac{\hat{P}(\text{country} = \text{PT})}{\hat{P}(\text{country} = \text{LT})}$$

0,181 karto (paprastiau kalbant, sumažina 1/0,181 = 5,525 karto). Pirmiau minėta, kad labiau tampa tikėtina, jog respondentas buvo iš Lietuvos. Analogiškai interpretuojami galimybių santykiai ir tolydiems kintamiesiems. Pavyzdžiui, kiekvienas papildomas balas, palankiau vertinant vyriausybę (*stfgov*), padidina tikimybių santykį 1,42 karto. Tampa labiau tikėtina, kad respondentas iš Portugalijos. Kiekvienas papildomas balas neigiamiau vertinant seksualines mažumas *freehms*, padidina tikimybių santykį 0,44 karto (sumažina 1/0,44 = 2,27 karto). Tada labiau tikėtina, kad respondentas iš Lietuvos. Be pačių galimybių, santykių lentelėje pateikiami ir jų 95 % pasikliautinųjų intervalų apatiniai ir viršutiniai rėžiai. Matome, kad intervaliniams kintamiesiems rėžiai yra pakankamai maži.

Norėdami gauti klasifikacinę lentelę, įvykdome komandą:

Istat			
Logistic model for _Icntry_2			
Classified	True		Total
	D	~D	
+	89	33	122
-	34	128	162
Total	123	161	284
Classified + if predicted Pr(D) >= .5 True D defined as _Icntry_2 != 0			
Sensitivity	Pr(+ D)		72.36%
Specificity	Pr(- ~D)		79.50%
Positive predictive value	Pr(D +)		72.95%
Negative predictive value	Pr(~D -)		79.01%
False + rate for true ~D	Pr(+ ~D)		20.50%
False - rate for true D	Pr(- D)		27.64%
False + rate for classified +	Pr(~D +)		27.05%
False - rate for classified -	Pr(D -)		20.99%
Correctly classified			76.41%

D kategorija atitinka Portugaliją (*_Icntry_2* ≠ 0). Matome, kad iš 123 Portugalijos atstovų teisingai atpažinti 89. Tai sudaro 72,36 % teisingų klasifikavimų. Analogiškai nustatome, kad iš 161 Lietuvos atstovo teisingai klasifikuoti 128 (79,5 %). Bendrasis teisingų klasifikavimų procentas (89 + 128 iš 123 + 161) yra 76,41 %. Ankstesniame skyrelyje nustatyta, kad imtyje respondentai iš Portugalijos sudaro 43,31 % , o iš Lietuvos – 56,69 %. Būtent toks būtų ir prognozės tikslumas,

jeigu visą laiką kaip papūgos kartotume „PT” („LT”). Taigi taikant logistinę regresiją, klasifikavimas labai pagerėja. Vienas iš svarbiausių reikalavimų keliamų geriems logistinės regresijos modeliams, patenkintas.

Norėdami gauti informaciją apie Hosmerio–Lemešou kriterijų, įvykdome komandą:

```
lfit, group(10)
```

Logistic model for country, goodness-of-fit test

(Table collapsed on quantiles of estimated probabilities)

number of observations =	284
number of groups =	10
Hosmer-Lemeshow chi2(8) =	15.44
Prob > chi2 =	0.0512

Gera, kai Hosmerio–Lemešou kriterijaus $p \geq 0,05$. Šiuo atveju $p = 0,0512$. Šis rodiklis taip pat rodo priimtina modelio tikimą duomenims. Šiaip jau Hosmerio–Lemešou kriterijus yra pagalbinis ir taikomas tik nedidelėms imtims. Imtis $n = 284$ nėra itin maža, todėl buvo galima apsieiti ir be jo.


Išskirčių nustatymas STATA programa nėra labai gerai realizuotas ir taikomas retai (išskirtis turi būti labai „piktybinė“, kad logistinė regresija į ją reaguotų). Todėl toliau pateikiamas aprašymas skaitytinas tik kaip *labai neprimygtina rekomendacija*. Visa ankstesnė informacija rodo, kad *logistinės regresijos modelis duomenims gerai tinka*.

Vienas iš išskirčių nustatymo būdų – sukurti kintamuosius, kuriuose atsispindėtų liekamosios paklaidos, ir pažiūrėti, ar nėra labai išsiskiriančių reikšmių. Ištirsime standartizuotąsias paklaidas ir deviacijos paklaidas. Deviacija – rodiklis, naudojamas apibendrintuose tiesiniuose modeliuose (logistinė regresija – atskiras tokių modelių atvejis). Įvykdome komandas:

```
predict dev, deviance
predict rstandart, rstandard
```

Nusibraižome liekamųjų paklaidų grafikus:

```
scatter rstandart idno
scatter dev idno
```



Abudu grafikai nerodo kažkokių labai išsiskiriančių reikšmių. Vis dėlto, jeigu laikysime, kad standartinės paklaidos, viršijančios 3, rodo išskirtį (ši prielaida siejasi su regresorių normalumu, kuris logistinei regresijai nėra svarbus), keletą tokių taškų rasime. Kaip nustatyti kur jie? Galima tiesiog įvykdyti komandą:

```
list rstandart if rstandart> 3
```

	rstand~t
30.	3.050217
191.	3.942029
275.	3.050217
276.	3.050217

Šias išskirtis galima pašalinti ir pažiūrėti, ar labai keičiasi modelis. Alternatyva aptariama kitame skyrelyje.

4.3.3. Atsparioji logistinė regresija

Jeigu kilo abejonių dėl duomenyse esančių išskirčių, galima apskaičiuoti modelio koeficientų įverčius, naudojantis atspariąja (robastine) logistine regresija.

```
xi: logit i.cntry freehms stfgov i.imsb2, robust
```

```
. xi: logit i.cntry freehms stfgov i.imsb2, robust
i.cntry      _Icntry_1-2      (_Icntry_1 for cntry==LT omitted)
i.imsb2      _Iimsb2_0-1      (naturally coded; _Iimsb2_0 omitted)

Iteration 0:   log pseudolikelihood = -194.30391
Iteration 1:   log pseudolikelihood = -139.71847
Iteration 2:   log pseudolikelihood = -135.06235
Iteration 3:   log pseudolikelihood = -134.8241
Iteration 4:   log pseudolikelihood = -134.82313

Logistic regression                                Number of obs   =      284
                                                    wald chi2(3)    =      62.44
                                                    Prob > chi2     =      0.0000
Log pseudolikelihood = -134.82313                Pseudo R2      =      0.3061
```

_Icntry_2	Coef.	Robust Std. Err.	z	P> z	[95% Conf. Interval]	
freehms	-.81604	.16484	-4.95	0.000	-1.13912	-.4929596
stfgov	.3504268	.0761087	4.60	0.000	.2012565	.4995972
_Iimsb2_1	-1.708391	.3492739	-4.89	0.000	-2.392955	-1.023827
_cons	1.306911	.4261149	3.07	0.002	.4717415	2.142081

Gautoji modelio lygtis

$$\frac{\hat{P}(\text{country} = PT)}{\hat{P}(\text{country} = LT)} = \exp\{1,31 + 0,35 \text{ stfgov} - 0,81 \text{ freehms} - 1,71 \text{ imsb2}\}.$$

Matome, kad ji n  kiek nesiskiria nuo gautosios, naudojant klasikinę logistinę regresiją. Tai dar kartą patvirtina, kad pirmiau nagrin tas modelis gerai tinka duomenims.

Dar viena situacija, kai si uloma taikyti atspariąją logistinę regresiją, yra vadinamosios *klasterizuotos imtys*. Duomenys nat raliai grupuojasi pagal ka kokį po ymį, ir  tariame liekamųjų paklaidų priklausomumą grup se. Pavyzd iui, i laikys egzaminą studentas ar nei laikys, sprend iame tikrindami 7 grupių atstovus. Priklausymas tai pa iai grupei (darbin  atmosfera, tie patys d stytojai) daro tik tiną prielaidą, kad i  rezultatų tai bus matoma. Tada geriau taikyti atspariosios logistinės regresijos modelį⁵³.

4.3.4. Reik mių prognozavimas

Tarkime, kad norime prognozuoti respondento šalį,  inodami, kad jam(jai) *freehms* = 3, *stgov* = 5, *imsb2* = 0. Tą padaryti galima įvykd ius komandą:

adjust freehms = 3 stfgov = 5 _limsb2_1 = 0, pr

⁵³ Turint informaciją apie klasterių savybes, reik tų taikyti HLM.

Dependent variable: country Command: logit
Covariates set to value: freehms = 3, stfgov = 5, imsb2 = 0

All	pr
	.648152

Key: pr = Probability

Tikimybė, kad respondentas iš Portugalijos $P(\text{country} = 1) = P(\text{country} = \text{PT}) = 0,65$. Aišku, kad $P(\text{country} = \text{LT}) = 0,35$. Tikėtinau, kad iš Portugalijos.

Galima padaryti prognozes abiem *imsb2* atvejams:

adjust freehms = 3 stfgov = 5, by(_limsb2_1) pr

benefits/ servi	pr
0	.648152
1	.250215

Key: pr = Probability

Kai *imsb2* = 0, tikimybė $P(\text{country} = \text{PT}) = 0,65$ sutampa su anksčiau apskaičiuotąja. Kai *imsb2* = 1, tikimybė $P(\text{country} = \text{PT}) = 0,25$. Tikimybė sumažėja daugiau nei perpus ir tampa labiau tikėtina, kad respondentas iš Lietuvos. Vaizdžiai matome požiūrio į imigrantus vaidmenį. Priešiškesnė nuostata imigrantų atžvilgiu labai stipriai keičia tikėtiną respondento šalį.

Galima skaičiuoti ne pačias tikimybes, bet galimybes (tikimybių santykius). Įvykdome:

adjust freehms = 3 stfgov = 5 _limsb2_1 = 0, exp

Dependent variable: country Command: logit
Covariates set to value: freehms = 3, stfgov = 5, imsb2 = 0

All	exp(xb)
	1.84214

Key: exp(xb) = exp(xb)

Kadangi žinome, kad $P(\text{country} = \text{PT}) = 0,65$, $P(\text{country} = \text{LT}) = 0,35$, nesunku patikrinti

$$\frac{\hat{P}(\text{country} = \text{PT})}{\hat{P}(\text{country} = \text{LT})} = \frac{0,65}{0,35} = 1,8 \dots$$

4.3.5. Kategoriniai regresoriai

Dvireikšmio regresoriaus atvejį aptarėme ankstesniuose skyreliuose. Situacija sudėtingesnė, kai regresorius gali įgyti daugiau nei dvi kategorines reikšmes. Tada jį reikia pakeisti keletu dvireikšmių pseudokintamųjų. STATA programa tą galima padaryti automatiškai. Iširsime modelį, kai vietoje *imsb2* į modelį įtrauktas *imsb3*. Įvykdome komandą:

```
xi: logit i.cntry freehms stfgov i.imsb3
```

Opcija *i.imsb3* reiškia, kad bus sukurti du (vienu mažiau nei yra kategorijų) pseudokintamieji, įgyjantys reikšmes 0 ir 1. Be to, 1 atitiks atitinkamą *imsb3* reikšmę.

```
. xi: logit i.cntry freehms stfgov i.imsb3
i.cntry      _Icntry_1-2      (_Icntry_1 for cntry==LT omitted)
i.imsb3      _Iimsb3_0-2      (naturally coded; _Iimsb3_0 omitted)

Iteration 0:  log likelihood = -194.30391
Iteration 1:  log likelihood = -139.44295
Iteration 2:  log likelihood = -134.72543
Iteration 3:  log likelihood = -134.47972
Iteration 4:  log likelihood = -134.47869

Logistic regression                                Number of obs   =       284
                                                    LR chi2(4)      =     119.65
                                                    Prob > chi2     =     0.0000
Log likelihood = -134.47869                        Pseudo R2       =     0.3079
```

_Icntry_2	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
freehms	-.8117534	.1514513	-5.36	0.000	-1.108592	-.5149144
stfgov	.3533061	.0757091	4.67	0.000	.204919	.5016931
_Iimsb3_1	-.3309373	.4009415	-0.83	0.409	-1.116768	.4548937
_Iimsb3_2	-1.953385	.4556013	-4.29	0.000	-2.846347	-1.060423
_cons	1.532331	.5110018	3.00	0.003	.5307859	2.533876

Gavome statistiškai reikšmingai tinkamą modelį. Vis dėlto vienas iš naudotųjų pseudokintamųjų (atitinkantis *antrąją* regresoriaus *imsb3* reikšmę) yra statistiškai nereikšmingas. Pažvelkime į klasifikacinę lentelę (įvykdome *lstat*):

Logistic model for country

Classified	True		Total
	D	~D	
+	87	27	114
-	36	134	170
Total	123	161	284

Classified + if predicted $\Pr(D) \geq .5$
 True D defined as country != 0

Sensitivity	$\Pr(+ D)$	70.73%
Specificity	$\Pr(- \sim D)$	83.23%
Positive predictive value	$\Pr(D +)$	76.32%
Negative predictive value	$\Pr(\sim D -)$	78.82%
False + rate for true ~D	$\Pr(+ \sim D)$	16.77%
False - rate for true D	$\Pr(- D)$	29.27%
False + rate for classified +	$\Pr(\sim D +)$	23.68%
False - rate for classified -	$\Pr(D -)$	21.18%
Correctly classified		77.82%

Bendrasis teisingų klasifikavimų procentas (77,82 %) kiek didesnis nei modelyje su *imsb2* (76,41 %). Kita vertus, mažiau teisingai klasifikuoti Portugalijos atstovai (70,73 %, o buvo 72,36 %), ir kiek geriau Lietuvos respondentai (83,23 %, buvo 79,5 %). Galime daryti išvadą, kad apskritai šis modelis nėra geresnis už buvusįjį.

4.3.6. Multikolinearumas

Parodysime kaip gali kilti (ir likti nepastebėta) multikolinearumo problema, į modelį įtraukdami kintamojo *freehms* kvadratą. Paaiškinti tokį įtraukimą nesunku – manome, kad šis kintamasis toks svarbus, kad priklausomybė nuo jo ne tiesinė, o kvadratinė. Naująjį regresorių (pavadinsime jį *freesquare*) sukuriame komanda:

```
gen freesquare = freehms*freehms
```

Sudarome modelį su visais kintamaisiais:

```
xi: logit i.cntry freehms stfgov i.imsb2 freesquare
```

Logistic regression Number of obs = 284
 LR chi2(4) = 126.26
 Prob > chi2 = 0.0000
 Pseudo R2 = 0.3249
 Log likelihood = -131.1732

_Icntry_2	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
freehms	-2.612501	.7065961	-3.70	0.000	-3.997404	-1.227598
stfgov	.3687341	.0762968	4.83	0.000	.2191951	.5182732
_Iimsb2_1	-1.759636	.3542756	-4.97	0.000	-2.454004	-1.065269
freesquare	.3123296	.1161209	2.69	0.007	.0847368	.5399223
_cons	3.460992	.9527517	3.63	0.000	1.593633	5.328351

Matome, kad modelyje visi regresoriai statistškai reikšmingi, tikėtinumų santykio kriterijaus statistikos reikšmė yra didelė 126, o $p = 0,000...$ Vis dėlto modelyje yra akivaizdžiai neteisinga priklausomybė nuo *freesquare*: šio regresoriaus koeficientas yra teigiamas, priešingai nei *freehms*. Iškart susiduriame su interpretacijos problema. Multikolinearumą galima pastebėti, užmetus akį į kintamųjų koreliaciją:

corr freesquare freehms

. corr freesquare freehms
 (obs=284)

	freesq~e	freehms
freesquare	1.0000	
freehms	0.9791	1.0000

Koreliacija lygi 0,97, t. y. nepaprastai stipri. Įsitikinti, kad regresijos lygtyje atsirado neteisingas koeficiento ženklas, galima ir tiesiog atliekant logistinę *country* regresiją pagal vienintelį kintamąjį *freesquare*. Įvykdome

xi: logit i.cntry freesquare

Logistic regression Number of obs = 284
 LR chi2(1) = 52.98
 Prob > chi2 = 0.0000
 Pseudo R2 = 0.1363
 Log likelihood = -167.81396

_Icntry_2	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
freesquare	-.1487757	.0249306	-5.97	0.000	-.1976387	-.0999126
_cons	.8404502	.2056653	4.09	0.000	.4373536	1.243547

Matome, kad koeficiento prie *freesquare* ženklas, kaip ir tikėjomės, yra neigiamas. Beje, multikolinearumo problemą galima išspręsti iš modelio pašalinant ir *freehms*. Čia, kaip ir dažnai būna regresijoje, nėra vienintelio teisingo duomenims tinkamo modelio. Gali būti net keli statistikos požiūriu tinkami modeliai. Geresnis iš jų tas, kuris geriau rodo realią situaciją. O tą nuspręsti padeda ne statistika, o geras tiriamo dalyko išmanymas.

Praktiniuose logistinės regresijos taikymuose multikolinearumas tikrinamas tik tada, kai, tyrėjo nuomone, atsiranda netikėti koeficientų ženklai. Jeigu tyrėjas savo nuomonės neturi (o kitų nuomonių nežino), jis gali pažiūrėti, ar intervalinių regresorių koreliacijos nėra didelės. Jeigu tyrėjui neaišku, kokia koreliacija yra didelė (jis ir sriubos pasūdyti nesugeba, jeigu neranda instrukcijos, kiek gramų druskos dėti į litrą sriubos, ką jau kalbėti apie koreliaciją), jis gali sudaryti logistinės regresijos modelį su *vieninteliu* regresoriumi. Regresoriaus koeficiento ženklas (teigiamas / neigiamas) turėtų išlikti ir jungtiniame modelyje. Operaciją kartojame su antruoju regresoriumi. Tada su trečiuoju. Ir t. t.

4.3.7. Žingsninė logistinė regresija

Viskas, kas pasakyta apie žingsninės regresijos trūkumus, kalbant apie tiesinę regresiją, tinka ir logistinės regresijos atveju. Trumpai galima rešumuoti taip: jokios formalios statistinės procedūros neatstos gilaus dalyko išmanymo. Pasitikint vien statistiniais skaičiavimais, galima prikurti labai neteisingų interpretacijų.

Po tokios pesimistinės įžangos pažiūrėkime, kaip su STATA atlikti žingsninę logistinę regresiją. Kaip ir visada, galima žingsniuoti į priekį arba atgal. Tirsime modelį su *imsb3*. Kaupiamoji (akumuliuojamoji) žingsninė regresija atliekama komanda

```
xi: sw logit i.cntry freehms stfgov i.imsb3, pe(0.05)
```

Logistic regression

Number of obs = 284

LR chi2(3) = 118.96

Prob > chi2 = 0.0000

Log likelihood = -134.82313

Pseudo R2 = 0.3061

_Icntry_2	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
freehms	-.81604	.151165	-5.40	0.000	-1.112318	-.5197622
_Iimsb3_2	-1.708391	.3430608	-4.98	0.000	-2.380778	-1.036004
stfgov	.3504268	.0753233	4.65	0.000	.2027959	.4980578
_cons	1.306911	.427897	3.05	0.002	.4682487	2.145574

Matome, kad modelyje liko regresorius, kuris iš esmės sutampa su *imsb2*, t. y. netiesiogiai siūloma pereiti prie modelio su *imsb2*. O žiūrint formaliai, nieko gero negavome, nes neišeina į modelį įtraukti tik pusę kategorinio kintamojo (*_Iimsb3_1* modelyje nebeliko).

Šalinamoji (eliminuojamoji) žingsninė regresija atliekama komanda

xi: sw logit i.cntry freehms stfgov i.imsb3, pr(0.05)						
Logistic regression			Number of obs	=	284	
			LR chi2(3)	=	118.96	
			Prob > chi2	=	0.0000	
Log likelihood = -134.82313			Pseudo R2	=	0.3061	
_Icntry_2	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
freehms	-.81604	.151165	-5.40	0.000	-1.112318	-.5197622
stfgov	.3504268	.0753233	4.65	0.000	.2027959	.4980578
_Iimsb3_2	-1.708391	.3430608	-4.98	0.000	-2.380778	-1.036004
_cons	1.306911	.427897	3.05	0.002	.4682487	2.145574

Gavome tiksliai tą patį modelį kaip ir pirmu atveju (taip įvyksta ne visada).

4.4. Dvinarė logistinė regresinė analizė su SAS

4.4.1. Duomenys

Kaip atlikti dvinarę logistinę regresinę analizę parodysime tirdami Europos Sąjungos socialinio tyrimo (*European Social Survey*) Lietuvos ir Portugalijos duomenis **ESS4LT1** ir **ESS4PT**. Tirsime 20–30 metų vyrus. Tyrime naudosime tokius kintamuosius:

- *cntry* – šalies kodas (LT – Lietuva, PT – Portugalija),
- *stfgov* – respondento požiūris į savo šalies vyriausybę (0 – itin bloga, ..., 9 – itin gera),
- *freehms* – gėjai ir lesbietės gali gyventi kaip nori (1 – visiškai sutinku,..., 5 – visiškai nesutinku),
- *imsc1bn* – kada imigrantai gali visiškai naudotis šalies socialinėmis lengvatomis (matuojamas nominalia skale: 1 – iškart atvykę, 2 – po vienerių metų, neatsižvelgiant į tai, ar dirbo, 3 – po vienerių darbo ir mokesčių mokėjimo metų, 4 – tapę piliečiais, 5 – niekada negalės naudotis visomis lengvatomis).

Duomenų atrankai naudosime kintamuosius: *agea* – amžių ir *gndr* – lytį (1 – vyr., 2 – mot.). Grafikams pravers respondento identifikacijos numeris *idno*.

Pradiniai duomenys saugomi SAS duomenų bibliotekoje **rgr**. Toliau pateiksime SAS komandų seką (scenarijų), kaip paruošti duomenis regresinei analizei. Paliksime tyrime reikiamo

amžiaus ir lyties respondentus. Kad nekiltų problemų su neteisingai išsaugotais praleistų reikšmių kodais, dar įvesime apribojimus kitų kintamųjų reikšmėms. Visi kintamieji yra skaitiniai, o kintamasis *cntry* – simbolinis. Šį kintamąjį naudosime kaip priklausomą dvireikšmį kintamąjį ir SAS programoje jo perkoduoti nereikia. Įvykdome:

```

OPTIONS nofmterr;
data LtPt;
set rgr.ESS4LT_PT_s;
if (agea ge 20) AND (agea le 30) AND (gn dr = 1) AND (stfgov le 9) AND (stfgov ne .) AND
(freehms le 5) AND (freehms ne .) AND (imsclbn le 5) AND (imsclbn ne .);
run;
PROC FREQ data=LtPt;
tables cntry;
run

```

Country				
cntry	Frequency	Percent	Cumulative Frequency	Cumulative Percent
LT	161	56.69	161	56.69
PT	123	43.31	284	100.00

Proc freq naudojame gauti apklaustųjų pagal šalis dažnių lentelę (Ši lentelė bus naudinga, kai reikės tikrinti klasifikavimo gerumą.)

Kintamasis *imsclbn* yra kategorinis.

Prieš įtraukiant kategorinį kintamąjį į logistinės regresijos modelį, reikia įsitikinti, kad kiekvienai jo kategorijai yra pakankamai daug stebinių.

Patikriname, kokias reikšmes įgyja *imsclbn*:

```

PROC freq data=LtPt;
tables cntry*imsclbn;
run;

```

Frequency Percent Row Pct Col Pct	Table of cntry by imscblbn						
	cntry(Country)	imscblbn(When should immigrants obtain rights to social benefits/services)					
		1	2	3	4	5	Total
LT	10	9	58	75	9	161	
	3.52	3.17	20.42	26.41	3.17	56.69	
	6.21	5.59	36.02	46.58	5.59		
	31.25	42.86	44.27	85.23	75.00		
PT	22	12	73	13	3	123	
	7.75	4.23	25.70	4.58	1.06	43.31	
	17.89	9.76	59.35	10.57	2.44		
	68.75	57.14	55.73	14.77	25.00		
Total	32	21	131	88	12	284	
	11.27	7.39	46.13	30.99	4.23	100.00	

Matome, kad Lietuvos imtyje mažai respondentų rinkosi 1 – 2 ir 5. Todėl regresorių *imscblbn* keisime kategoriniu kintamuoju, įgyjančiu mažiau reikšmių. Sukursime du tokius kintamuosius: *imsb3* (*imsb3* = 0, kai *imscblbn* = 1 arba 2; *imsb3* = 1, kai *imscblbn* = 3; *imsb3* = 2, kai *imscblbn* = 4 arba 5) ir *imsb2* (*imsb2* = 0, kai *imscblbn* = 1, 2 arba 3; *imsb2* = 1, kai *imscblbn* = 4 arba 5):

```
data LtPtn;
set LtPt;
IF      (imscblbn LE 3) THEN imsb2=0;
ELSE IF (imscblbn GE 4) THEN imsb2=1;
IF      (imscblbn LE 2) THEN imsb3=0;
ELSE IF (imscblbn GE 4) THEN imsb3=2;
                        ELSE imsb3=1;

run;
```

Mažesnės *imsb2*, *imsb3* reikšmės rodo palankesnę nuostatą imigrantų atžvilgiu. Įsitikiname, kad yra pakankamai daug stebinių⁵⁴ kiekvienai regresorių kategorijai. Įvykdome

```
proc freq data=LtPtn;
tables cntry*imsb2 cntry*imsb3;
run;
```

⁵⁴ Ką reiškia pakankamai daug, sprendžia tyrėjas. Mūsų nuomone, jeigu kažkokį atsakymą renkasi mažiau nei 10 % respondentų, vertėtų pamąstyti apie kintamojo perkodavimą, paliekant mažiau kategorijų.

Frequency Percent Row Pct Col Pct	Table of entry by imsb2			
	entry(Country)	imsb2		
		0	1	Total
	LT	77 27.11 47.83 41.85	84 29.58 52.17 84.00	161 56.69
	PT	107 37.68 86.99 58.15	16 5.63 13.01 16.00	123 43.31
	Total	184 64.79	100 35.21	284 100.00

Frequency Percent Row Pct Col Pct	Table of entry by imsb3				
	entry(Country)	imsb3			
		0	1	2	Total
	LT	19 6.69 11.80 35.85	58 20.42 36.02 44.27	84 29.58 52.17 84.00	161 56.69
	PT	34 11.97 27.64 64.15	73 25.70 59.35 55.73	16 5.63 13.01 16.00	123 43.31
	Total	53 18.66	131 46.13	100 35.21	284 100.00

4.4.2. Modelio tyrimas

Logistinę regresiją SAS programa galima atlikti naudojant *proc logistic*. Tirsime modelį

$$\frac{\hat{P}(\text{country} = PT)}{\hat{P}(\text{country} = LT)} = \exp\{C + b1stfgov + b2 freehms + b3imsb2\}.$$

Modelyje yra vienas dvireikšmis regresorius *imsb2* (reikšmės 0 ir 1).

Išvykdome:

```
proc logistic data=LtPtn;
class imsb2(ref="0") / param=ref;
model cntry(event='PT')= freehms stfgov imsb2 / rsq;
run;
```

Class Level Information		
Class	Value	Design Variables
imsb2	0	0
	1	1

Model Fit Statistics		
Criterion	Intercept Only	Intercept and Covariates
AIC	390.608	277.646
SC	394.257	292.242
-2 Log L	388.608	269.646

R-Square	0.3422	Max-rescaled R-Square	0.4591
----------	--------	-----------------------	--------

Testing Global Null Hypothesis: BETA=0			
Test	Chi-Square	DF	Pr > ChiSq
Likelihood Ratio	118.9616	3	<.0001
Score	98.3472	3	<.0001
Wald	68.1760	3	<.0001

Analysis of Maximum Likelihood Estimates						
Parameter		DF	Estimate	Standard Error	Wald Chi-Square	Pr > ChiSq
Intercept		1	1.3069	0.4279	9.3281	0.0023
freehms		1	-0.8160	0.1512	29.1405	<.0001
stfgov		1	0.3504	0.0753	21.6429	<.0001
imsb2	1	1	-1.7084	0.3431	24.7981	<.0001

Lentelėje **Class Level Information** yra informacija, kaip modelyje perkoduojamas kategorinis regresorius⁵⁵.

Model Fit Statistics lentelėje pateikiami suderinamumo informaciniai kriterijai. Matome, kad pasirinkto modelio visi informaciniai indeksai yra mažesni nei modelio be regresorių (tik su konstanta). Pavyzdžiui, AIC yra 277,65 (be regresorių 390,61). Determinacijos pseudokoeficiento reikšmė skaičiuojama tik nurodžius parinktį *rsq*. Ji nėra didelė (**R-Square = 0.3422**), bet logistinei regresijai šis rodiklis įvairiomis programomis skaičiuojamas skirtingai, todėl vertinamas prieštaringai ir nėra „lemiamas“ vertinant modelio kokybę. Juolab kad vis tiek viršija 0,20 – tradicinę determinacijos koeficientams taikomą tinkamumo ribą.

Lentelės **Testing Global Null Hypothesis** ir **Analysis of Maximum Likelihood Estimates** yra numatytosios. Tikėtinumų santykio kriterijaus statistikos reikšmė (118,96) ir *p* reikšmė (0,000...) pateikiamos lentelės **Testing Global Null Hypothesis** viršuje, dešinėje pusėje. Faktiškai tai informacija, kad su pasirinktais regresoriais modelis tinka duomenims, nors neaišku, ar visi regresoriai modelyje reikalingi. Kuo tikėtinumų santykio kriterijaus statistikos reikšmė didesnė, tuo labiau tikėtina, kad logistinės regresijos modelis tinka. Ji ypač informatyvi, kai turima labai daug duomenų.

Užrašysime modelį, įstatydami koeficientų įverčius ($\exp\{x\}$, trumpas e^x žymėjimas).

$$\frac{\hat{P}(\text{country} = PT)}{\hat{P}(\text{country} = LT)} = \exp\{1,31 + 0,35 \text{ stfgov} - 0,82 \text{ freehms} - 1,71 \text{ imsb2}\}.$$

Įsitikiname modelio logiškumu. Didėjant skliaustuose esančiam reiškiniui (tikimybių santykio logit funkcijai), kartu didėja ir tikimybė, kad respondentas iš Portugalijos. Ir atvirkščiai, mažėjant skliaustuose esančiam reiškiniui, didėja tikimybė, kad respondentas iš Lietuvos. Koeficientas prie *freehms* ir yra neigiamas, o koeficientas prie *stfgov* teigiamas. Todėl, didėjant *freehms* reikšmei, didėja tikimybė, kad respondentas iš Lietuvos. Taigi kuo respondentas priešiščiau nusistatęs seksualinių mažumų atžvilgiu (*freehms* didesnis), tuo labiau tikėtina, kad jis iš Lietuvos. Analogiškai darome išvadą: kuo respondentas palankiau vertina vyriausybę, tuo didesnė tikimybė, kad jis iš Portugalijos. Koeficientas prie *imsb2* yra neigiamas. Kai įstatome vienetą (*imsb2* = 1 atitinka neigiamą požiūrį į imigrantus), visas reiškinys sumažėja ir padidėja tikimybė, kad respondentas iš Lietuvos.

⁵⁵ Sakinio *class* parinktyje *re* nurodome, nuo kurios reikšmės vykdome rekodavimą

Modelio regresorių galimybių santykiai matomi rezultatų išsklotinės lentelėje **Odds Ratio Estimates**:

Odds Ratio Estimates			
Effect	Point Estimate	95% Wald Confidence Limits	
freehms	0.442	0.329	0.595
stfgov	1.420	1.225	1.646
imsb2 1 vs 0	0.181	0.092	0.355

Kintamojo *imsb2* galimybių santykis yra 0,181. Todėl galima padaryti tokią išvadą: nepalankus požiūris į socialines lengvatas imigrantams (*imsb2* = 1), palyginti su palankiu, padidina santykį

$$\frac{\hat{P}(\text{country} = \text{PT})}{\hat{P}(\text{country} = \text{LT})}$$

0,181 karto (paprasciau sakant, sumažina $1/0,181 = 5,25$ karto). Minėta pirmiau, kad tampa labiau tikėtina, jog respondentas buvo iš Lietuvos. Analogiškai interpretuojami galimybių santykiai ir tolydiems kintamiesiems. Pavyzdžiui, kiekvienas papildomas balas, palankiau vertinant vyriausybę (*stfgov*), padidina tikimybių santykį 1,42 karto. Labiau tikėtina, kad respondentas iš Portugalijos. Kiekvienas papildomas balas, neigiamiau vertinant seksualines mažumas *freehms*, padidina tikimybių santykį 0,44 karto (t. y. sumažina $1/0,44 = 2,27$ karto). Tampa labiau tikėtina, kad respondentas iš Lietuvos. Be pačių galimybių santykių, lentelėje pateikiami ir jų 95 % pasikliautinųjų intervalų apatiniai ir viršutiniai rėžiai. Matome, kad intervaliniams kintamiesiems pasikliautinųjų intervalų ilgiai yra maži – gautieji galimybių santykių įverčiai patikimi.

Norint gauti klasifikavimo lentelę, *model* sakinyje reikia pridėti dvi parinktis *ctable* ir *pprob*, t. y. reikia įvykdyti:

```
proc logistic data=LtPtn;
class imsb2(ref="0") / param=ref;
model cntry(event='PT')= freehms stfgov imsb2 / ctable pprob=0.5;
run;
```

Classification Table									
Prob Level	Correct		Incorrect		Percentages				
	Event	Non-Event	Event	Non-Event	Correct	Sensitivity	Specificity	False POS	False NEG
0.500	89	128	33	34	76.4	72.4	79.5	27.0	21.0

Event kategorija atitinka Portugaliją (nurodėme procedūros sakinyje *model*). Matome, kad iš 123 Portugalijos atstovų teisingai atpažinti 89. Tai sudaro 72,4 % teisingų klasifikavimų. Analogiškai nustatome, kad iš 161 Lietuvos atstovo (**Non-Event**) teisingai klasifikuoti 128 (79,5 %). Bendrasis teisingų klasifikavimų procentas (89 + 128 iš 123 + 161) yra **Correct** stulpelyje 76,4 %. Ankstesniame skyrelyje nustatyta, kad respondentai iš Portugalijos sudaro 43,31 % imties, o iš Lietuvos – 56,69 %. Būtent toks būtų ir prognozės tikslumas, jeigu visą laiką kaip papūgos kartotume „PT“ („LT“). Taigi, taikant logistinę regresiją, klasifikavimas labai pagerėja. Vienas iš svarbiausių reikalavimų, keliamų geriems logistinės regresijos modeliams, patenkintas.

Norėdami gauti Hosmerio–Lemeshou suderinamumo kriterijaus rezultatus, *model* sakinyje nurodome parinktį *lackfit*:

```
proc logistic data=LtPtn;
class imsb2(ref="0") / param=ref;
model cntry(event='PT')= freehms stfgov imsb2 / lackfit;

run;
```

Hosmer and Lemeshow Goodness-of-Fit Test		
Chi-Square	DF	Pr > ChiSq
18.1665	8	0.0200

Gerai, kai Hosmerio–Lemeshou kriterijaus $p \geq 0,05$. Šiuo atveju $p = 0,02$. Šis rodiklis rodo nelabai gerą modelio tinkamumą duomenims. Vis dėlto Hosmerio–Lemeshou kriterijus yra pagalbinis ir taikomas tik nedidelėms imtims. Imtis $n = 284$ nėra itin maža, todėl buvo galima apsieiti ir be jo.

Išskirčių nustatymas (diagnostika) SAS programos *proc logistic* gerai realizuotas, bet išskirtis turi būti labai „piktybinė“, kad logistinė regresija į ją reaguotų. Todėl čia tik trumpai aprašysime, kaip atliekama diagnostika. Įvykdome:

```
proc logistic data=LtPtn;
class imsb2(ref="0") / param=ref;
model cntry(event='PT')= freehms stfgov imsb2 / influence iplots;


run;
```

Pateiksime rezultatų išklotinės fragmentą. Tiek lentelė, tiek grafikai rodo, kad pagal *DFBetų* reikšmes išskirčių nėra. Vis dėlto, jeigu laikysime, kad standartizuotos liekamosios paklaidos, viršijančios 3, rodo išskirtį (ši prielaida susijusi su regresorių normalumu, kuris logistinei regresijai nėra svarbus)⁵⁶, keletą tokių taškų rasime.

Regression Diagnostics										
Case Number	Covariates			Pearson Residual	Deviance Residual	Hat Matrix Diagonal	Intercept DfBeta	freehms DfBeta	stfgov DfBeta	imsb21 DfBeta
	Gays and lesbians free to live life as they wish	How satisfied with the national government	imsb2 1							
1	1.0000	5.0000	0	0.3258	0.4492	0.00987	0.0165	-0.0222	0.0194	-0.00965
2	3.0000	4.0000	0	0.8779	1.0690	0.0116	-0.0172	0.0360	0.0393	-0.0446
3	5.0000	0	0	4.0012	2.3807	0.0137	-0.1574	0.4010	-0.2369	-0.0784
4	3.0000	2.0000	0	1.2463	1.3692	0.0103	0.0102	0.0614	-0.0378	-0.0537
5	4.0000	6.0000	1.0000	2.1848	1.8726	0.0250	-0.2217	0.1739	0.1610	0.1894
6	2.0000	6.0000	0	0.4112	0.5590	0.0124	0.00351	-0.0128	0.0378	-0.0163

66	4.0000	4.0000	1.0000	3.1017	2.1738	0.0119	-0.1888	0.2045	0.0360	0.2175
81	5.0000	0	0	4.0012	2.3807	0.0137	-0.1574	0.4010	-0.2369	-0.0784

⁵⁶ Deviacija – rodiklis, taikomas apibendrintuose tiesiniuose modeliuose (logistinė regresija – atskiras tokių modelių atvejais).



Galima šiuos stebinius pašalinti ir pažiūrėti, ar labai keičiasi modelis.

4.4.3. Reikšmių prognozavimas

Tarkime, kad norime prognozuoti respondentų šalį, žinodami du atsakymus $freehms = 3$, $stgov = 5$, $imsb2 = 0$ ir $freehms = 3$, $stgov = 5$, $imsb2 = 1$. Tą padaryti galima taip:

```
data new;
set LtPtn end=eof;
output;
if eof then do;
Call missing( of _all_ );
freehms=3;stfgov=5;imsb2 = 0;
output;
freehms=3;stfgov=5;imsb2 = 1;
output;
```

```

end ;
run;
proc logistic data=new noprint;
class imsb2(ref="0") / param=ref;
model cntry(event='PT')= freehms stfgov imsb2;
output out=mmm predicted=pre;
run;
proc sql;
select distinct imsb2, pre from mmm where freehms=3 and stfgov = 5 and (imsb2 = 0
or imsb2=1) ;
run;

```

imsb2	Estimated Probability
0	0.64815
1	0.250219

Kai $imsb2 = 0$, $freehms = 3$ ir $stfgov = 5$, tada tikimybė $P(country = PT) = 0,65$. Aišku, kad $P(country = LT) = 0,35$. Tikėtiniau, kad pateikęs tokius atsakymus respondentas bus iš Portugalijos. Kai $imsb2 = 1$, $freehms = 3$ ir $stfgov = 5$, tada tikimybė $P(country = PT) = 0,25$. Tikimybė sumažėja daugiau nei perpus ir tampa labiau tikėtina, kad respondentas iš Lietuvos. Vaizdžiai matome požiūrio į imigrantus vaidmenį. Priešiškesnė nuostata imigrantų atžvilgiu labai stipriai keičia tikėtiną respondento šalį.

Galime apskaičiuoti galimybę (tikimybių santykį). Kadangi jau žinome, kad $P(country = PT) = 0,65$, $P(country = LT) = 0,35$, apskaičiuojame

$$\frac{\hat{P}(country = PT)}{\hat{P}(country = LT)} = \frac{0,65}{0,35} = 1,857.$$

4.4.4. Kategoriniai regresoriai

Dvireikšmio regresoriaus atvejį aptarėme ankstesniuose skyreliuose. Situacija sudėtingesnė, kai regresorius gali įgyti daugiau nei dvi kategorines reikšmes. Tada jį reikia pakeisti keletu dvireikšmių pseudokintamųjų. SAS programa tai atlieka automatiškai (tereikia kategorinį kintamąjį aprašyti *class* sakinyje). Ištirsime modelį, kai vietoje *imsb2* į modelį įtrauktas *imsb3*. Įvykdome:

```
proc logistic data=LtPtn;
class imsb3(ref="0") / param=ref;
model cntry(event='PT')= freehms stfgov imsb3 / rsq ctable pprob=0.5;
run;
```

Class Level Information			
Class	Value	Design Variables	
imsb3	0	0	0
	1	1	0
	2	0	1

Model Fit Statistics		
Criterion	Intercept Only	Intercept and Covariates
AIC	390.608	278.957
SC	394.257	297.202
-2 Log L	388.608	268.957

R-Square	0.3438	Max-rescaled R-Square	0.4612
----------	--------	-----------------------	--------

Testing Global Null Hypothesis: BETA=0			
Test	Chi-Square	DF	Pr > ChiSq
Likelihood Ratio	119.6504	4	<.0001
Score	98.8102	4	<.0001
Wald	68.0351	4	<.0001

Analysis of Maximum Likelihood Estimates						
Parameter		DF	Estimate	Standard Error	Wald Chi-Square	Pr > ChiSq
Intercept		1	1.5323	0.5110	8.9916	0.0027
freehms		1	-0.8117	0.1515	28.7261	<.0001
stfgov		1	0.3533	0.0757	21.7763	<.0001
imsb3	1	1	-0.3309	0.4009	0.6813	0.4092
imsb3	2	1	-1.9533	0.4556	18.3819	<.0001

Lentelėje **Class Level Information** yra pateikiama pseudokintamųjų schema. Modelio tinkamumo matai labai panašūs kaip nagrinėto anksčiau. Vis dėlto vienas iš naudotų pseudokintamųjų (atitinkantis *antrąją* regresoriaus *imsb3* reikšmę) yra statistiškai nereikšmingas. Pažvelkime į klasifikacinę lentelę:

Classification Table									
Prob Level	Correct		Incorrect		Percentages				
	Event	Non-Event	Event	Non-Event	Correct	Sensitivity	Specificity	False POS	False NEG
0.500	87	134	27	36	77.8	70.7	83.2	23.7	21.2

Bendras teisingų klasifikavimų procentas (77,8 %) kiek didesnis nei modelyje su *imsb2* (76,4 %). Kita vertus, mažiau teisingai klasifikuoti Portugalijos atstovai (70,7 %, o buvo 72,4 %), ir kiek geriau Lietuvos respondentai (83,2 %, buvo 79,5 %). Galime daryti išvadą, kad apskritai šis modelis nėra geresnis už buvusįjį.

4.4.5. Multikolinearumas

Parodysime, kaip gali kilti (ir likti nepastebėta) multikolinearumo problema, į modelį įtraukdami kintamojo *freehms* kvadratą. Paaiškinti tokį įtraukimą nesunku – manome, kad šis kintamasis toks svarbus, kad priklausomybė nuo jo ne tiesinė, o kvadratinė. Sukuriame naująjį regresorių (pavadinsime jį *freesquare*). Įvykdome:

```
data new;
set LtPtn;
freesquare=freehms*freehms;
run;
```

Sudarome modelį su visais kintamaisiais:

```
proc logistic data=new;
class imsb2(ref="0") / param=ref;
model cntry(event='PT')= freehms stfgov imsb2 freesquare / rsq;
run;
```

Model Fit Statistics		
Criterion	Intercept Only	Intercept and Covariates
AIC	390.608	272.346
SC	394.257	290.591
-2 Log L	388.608	262.346

R-Square	0.3589	Max-rescaled R-Square	0.4815
----------	--------	-----------------------	--------

Testing Global Null Hypothesis: BETA=0			
Test	Chi-Square	DF	Pr > ChiSq
Likelihood Ratio	126.2614	4	<.0001
Score	105.5527	4	<.0001
Wald	70.0072	4	<.0001

Analysis of Maximum Likelihood Estimates						
Parameter		DF	Estimate	Standard Error	Wald Chi-Square	Pr > ChiSq
Intercept		1	3.4609	0.9528	13.1954	0.0003
freehms		1	-2.6124	0.7066	13.6695	0.0002
stfgov		1	0.3687	0.0763	23.3558	<.0001
imsb2	1	1	-1.7596	0.3543	24.6686	<.0001
freesquare		1	0.3123	0.1161	7.2341	0.0072

Matome, kad tikėtinumų santykio kriterijaus statistika didelė 126, o $p = 0,000...$ Modelyje visi regresoriai statistiškai reikšmingi, Vis dėlto modelyje yra akivaizdžiai neteisinga priklausomybė nuo *freesquare*: šio regresoriaus koeficientas yra teigiamas, priešingai nei *freehms*. Iškart susiduriame su interpretacijos problema. Multikolinearumą galima pastebėti, užmetus akį į kintamųjų koreliaciją:

```
proc corr data=new;
var freehms freesquare;
run;
```

Pearson Correlation Coefficients, N = 284 Prob > r under H0: Rho=0		
	freehms	freesquare
freehms Gays and lesbians free to live life as they wish	1.00000	0.97906 <.0001
freesquare	0.97906 <.0001	1.00000

Koreliacija lygi 0,97, t. y. nepaprastai stipri. Įsitikinti, kad regresijos lygtyje atsirado neteisingas koeficiento ženklas, galima ir tiesiog atliekant logistinę *country* regresiją pagal vienintelį kintamąjį *freesquare*. Įvykdome

```
proc logistic data=new;
class imsb2(ref="0") / param=ref;
model cntry(event='PT')= freesquare / rsq;
run;
```

Model Fit Statistics		
Criterion	Intercept Only	Intercept and Covariates
AIC	390.608	339.628
SC	394.257	346.926
-2 Log L	388.608	335.628

R-Square	0.1702	Max-rescaled R-Square	0.2283
----------	--------	-----------------------	--------

Testing Global Null Hypothesis: BETA=0			
Test	Chi-Square	DF	Pr > ChiSq
Likelihood Ratio	52.9799	1	<.0001
Score	45.3727	1	<.0001
Wald	35.6120	1	<.0001

Analysis of Maximum Likelihood Estimates					
Parameter	DF	Estimate	Standard Error	Wald Chi-Square	Pr > ChiSq
Intercept	1	0.8404	0.2057	16.6994	<.0001
freesquare	1	-0.1488	0.0249	35.6120	<.0001

Matome, kad koeficiento prie *freesquare* ženklas, kaip ir tikėjomės, yra neigiamas. Beje, multikolinearumo problemą galima išspręsti iš modelio pašalinant ir *freehms*. Čia, kaip dažnai būna regresijoje, nėra vienintelio teisingo duomenims tinkamo modelio. Gali būti net keli statistikos požiūriu tinkami modeliai. Geresnis iš jų tas, kuris geriau rodo realią situaciją. Tą nuspręsti padeda ne statistika, o geras tiriamo dalyko išmanymas.

Praktiniuose logistinės regresijos taikymuose multikolinearumas tikrinamas tik tada, kai, tyrėjo nuomone, atsiranda netikėti koeficientų ženklai. Jeigu tyrėjas savo nuomonės neturi (o kitų nuomonių nežino), jis gali pažiūrėti, ar intervalinių regresorių koreliacijos nėra didelės. Jeigu tyrėjui neaišku, kokia koreliacija yra didelė (jis ir sriubos pasūdyti nesugeba, jeigu neranda instrukcijos, kiek gramų druskos dėti į litrą sriubos, ką jau kalbėti apie koreliaciją), jis gali sudaryti logistinės

regresijos modelį su *vieninteliu* regresoriumi. Regresoriaus koeficiento ženklas (teigiamas / neigiamas) turėtų išlikti ir jungtiniame modelyje. Operaciją kartojame su antruoju regresoriumi. Tada su trečiuoju. Ir t. t.

4.4.6. Žingsninė logistinė regresija

Viskas, kas pasakyta apie žingsninės regresijos trūkumus, kalbant apie tiesinę regresiją, tinka ir logistinės regresijos atveju. Trumpai galima režiūmuoti taip: jokios formalios statistinės procedūros neatstos gilaus dalyko išmanymo. Pasitikint vien statistiniais skaičiavimais, galima prikurti labai neteisingų interpretacijų.

Po tokios pesimistinės įžangos, pažiūrėkime, kaip su SAS atlikti žingsninę logistinę regresiją. Kaip ir visada, galima žingsniuoti į priekį arba atgal. Procedūros *logistic* sakinyje *MODEL* nurodome parinktį: *SELECTION=*Metodas (*STEPWISE*, *BACKWARD*, *FORWARD*, *SCORE*). Tirsime modelį su *imsb3*. Kaupiamoji (akumuliuojamoji) žingsninė regresija atliekama taip:

```
/* logistinė regresija, zingsnine, kaupiamoji FORWARD */
proc logistic data=LtPtn;
class imsb3(ref="0") / param=ref;
model cntry(event='PT')= freehms stfgov imsb3 / selection=forward slentry=0.05;
run;
```

Model Fit Statistics		
Criterion	Intercept Only	Intercept and Covariates
AIC	390.608	278.957
SC	394.257	297.202
-2 Log L	388.608	268.957

Summary of Forward Selection						
Step	Effect Entered	DF	Number In	Score Chi-Square	Pr > ChiSq	Variable Label
1	freehms	1	1	55.5723	<.0001	Gays and lesbians free to live life as they wish
2	imsb3	2	2	31.7786	<.0001	
3	stfgov	1	3	23.7843	<.0001	How satisfied with the national government

Analysis of Maximum Likelihood Estimates						
Parameter		DF	Estimate	Standard Error	Wald Chi-Square	Pr > ChiSq
Intercept		1	1.5323	0.5110	8.9916	0.0027
freehms		1	-0.8117	0.1515	28.7261	<.0001
stfgov		1	0.3533	0.0757	21.7763	<.0001
imsb3	1	1	-0.3309	0.4009	0.6813	0.4092
imsb3	2	1	-1.9533	0.4556	18.3819	<.0001

Šalinamoji (eliminuojamoji) žingsninė regresija atliekama taip:

```
/* logistinė regresija, žingsnine, kaupiamoji BACKWARD */
proc logistic data=LtPtn;
class imsb3(ref="0") / param=ref;
model cntry(event='Pt')= freehms stfgov imsb3 / selection=backward slstay=0.05;
run;
```

Step 0. The following effects were entered:

Intercept freehms stfgov imsb3

Note: No (additional) effects met the 0.05 significance level for removal from the model.

Analysis of Maximum Likelihood Estimates						
Parameter		DF	Estimate	Standard Error	Wald Chi-Square	Pr > ChiSq
Intercept		1	1.5323	0.5110	8.9916	0.0027
freehms		1	-0.8117	0.1515	28.7261	<.0001
stfgov		1	0.3533	0.0757	21.7763	<.0001
imsb3	1	1	-0.3309	0.4009	0.6813	0.4092
imsb3	2	1	-1.9533	0.4556	18.3819	<.0001

Nepateikiame modelių komentarų. Matome, kad tiek vienos, tiek kitos analizės rezultatas yra tokie pat modeliai. Tačiau reikėtų žinoti, kad daug kas priklauso nuo kintamųjų įtraukimo (šalinimo) į modelį kriterijų, o jų teisingas parinkimas yra statistikų įnirtingų ginčų objektas. Tad

norintiems taikyti žingsninę regresiją rekomenduotume paskaityti specialiai šiam klausimui skirtą literatūrą.

4.4.7. SAS programos logistinės regresijos procedūra

SAS programoje logistinei regresinei analizei yra naudojama **proc logistic** procedūra. Šios procedūros sintaksė atrodo taip:

```
PROC LOGISTIC <options> ;  
BY variables ;  
CLASS variable <(options)><variable <(options)>></ options> ;  
CONTRAST 'label' effect values<, effect values,></ options> ;  
EFFECT name = effect-type ( variables </ options> ) ;  
EFFECTPLOT <plot-type<(plot-definition-options)>></ options> ;  
ESTIMATE <'label'> estimate-specification </ options> ;  
EXACT <'label'><INTERCEPT><effects></ options> ;  
EXACTOPTIONS options ;FREQ variable ;  
LSMEANS <model-effects> </ options> ;LSMESTIMATE model-effect lsestimate-  
specification </ options> ;  
<label:> MODEL variable <(variable_options)>=<effects></ options> ;  
<label:> MODEL events/trials=<effects></ options> ;ODDSRATIO <'label'> variable </  
options> ;  
OUTPUT <OUT=SAS-data-set><keyword=name <keyword=name>></ option> ;  
ROC <'label'> <specification> </ options> ;  
ROCCONTRAST <'label'><contrast></ options> ;SCORE <options> ;  
SLICE model-effect </ options> ;STORE <OUT=>item-store-name </ LABEL='label'> ;  
STRATA effects </ options> ;<label:> TEST equation1 <,equation2,></ option> ;  
UNITS <independent1=list1 <independent2=list2 >></ option> ;  
WEIGHT variable </ option> ;
```

model yra būtinas **logistic** procedūros sakiny. Šiuo sakiniu aprašomas modelio pavidalas.

CLASS and EFFECT sakiniai (jei apibrėžti) turi būti prieš MODEL sakinį; CONTRAST, EXACT, ir ROC sakiniai (jei apibrėžti) turi būti po MODEL sakinio.

Scenarijus :

```
OPTIONS nofmterr;
data LtPt;
set rgr.ESS4LT_PT_s;
if (agea ge 20) AND (agea le 30) AND (gndr = 1) AND (stfgov le 9) AND (stfgov ne .)
AND (freehms le 5) AND (freehms ne .) AND (imsclbn le 5) AND (imsclbn ne .);
run;
proc freq data=LtPt;
tables cntry;
run;
proc freq data=LtPt;
tables cntry*imsclbn;
run;
data LtPtn;
set LtPt;
IF      (imsclbn LE 3) THEN imsb2=0;
ELSE IF (imsclbn GE 4) THEN imsb2=1;
IF      (imsclbn LE 2) THEN imsb3=0;
ELSE IF (imsclbn GE 4) THEN imsb3=2;
                        ELSE imsb3=1;

run;
proc freq data=LtPtn;
tables cntry*imsb2 cntry*imsb3;
run;
/* logistinė regresija, R2 */
proc logistic data=LtPtn;
class imsb2(ref="0") / param=ref;
model cntry(event='PT')= freehms stfgov imsb2 / rsq;
run;
/* lemesow */
proc logistic data=LtPtn;
class imsb2(ref="0") / param=ref;
```

```

model cntry(event='PT')= freehms stfgov imsb2 / lackfit;
run;
/* logistinė regresija, klasifikavimo lentelė */
proc logistic data=LtPtn;
class imsb2(ref="0") / param=ref;
model cntry(event='PT')= freehms stfgov imsb2 / ctable pprob=0.5;
run;
/* išskirtys */
proc logistic data=LtPtn;
class imsb2(ref="0") / param=ref;
model cntry(event='PT')= freehms stfgov imsb2 / influence iplots;
run;
/* multikolinearumas */
data new;
set LtPtn;
freesquare=freehms*freehms;
run;
proc logistic data=new;
class imsb2(ref="0") / param=ref;
model cntry(event='PT')= freehms stfgov imsb2 freesquare / rsq;
run;
proc corr data=new;
var freehms freesquare;
run;
/* Modelis -- vienas regresorius */
proc logistic data=new;
class imsb2(ref="0") / param=ref;
model cntry(event='PT')= freesquare / rsq;
run;
/* logistinė regresija su keletos reikšmiu kategoriniu kintamuju */
proc logistic data=LtPtn;
class imsb3(ref="0") / param=ref;
model cntry(event='PT')= freehms stfgov imsb3 / rsq ctable pprob=0.5;

```

```

run;

/* logistinė regresija, žingsnine, kaupiamoji FORWARD */
proc logistic data=LtPtn;
class imsb3(ref="0") / param=ref;
model cntry(event='PT')= freehms stfgov imsb3 / selection=forward slentry=0.3;
run;

/* logistinė regresija, žingsnine, kaupiamoji BACKWARD */
proc logistic data=LtPtn;
class imsb3(ref="0") / param=ref;
model cntry(event='PT')= freehms stfgov imsb3 / selection=backward slstay=0.05;
run;

/*=====*/

/* Prognozavimas */
data new;
set LtPtn end=eof;
output;
if eof then do;
Call missing( of _all_ );
freehms=3;stfgov=5;imsb2 = 0;
output;
end ;
run;

proc logistic data=new noprint;
class imsb2(ref="0") / param=ref;
model cntry(event='PT')= freehms stfgov imsb2;
output out=mmm predicted=pre;
run;

proc sql;
select distinct pre from mmm where freehms=3 and stfgov = 5 and imsb2 = 0;
run;

ods pdf close;

/* dviems įrašams */
data new;

```

```

set LtPtn end=eof;
output;
if eof then do;
Call missing( of _all_ );
freehms=3;stfgov=5;imsb2 = 0;
output;
freehms=3;stfgov=5;imsb2 = 1;
output;
end ;
run;

proc logistic data=new noprint;
class imsb2(ref="0") / param=ref;
model cntry(event='PT')= freehms stfgov imsb2;
output out=mmm predicted=pre;
run;

proc sql;
select distinct imsb2, pre from mmm where freehms=3 and stfgov = 5 and (imsb2 = 0
or imsb2=1) ;
run;

```

4.5. Dvinarė logistinė regresinė analizė su R

4.5.1. Duomenys

Kaip atlikti dvinarę logistinę regresinę analizę parodysime tirdami Europos Sąjungos socialinio tyrimo Lietuvos ir Portugalijos duomenis **ESS4LT1** ir **ESS4PT**. Tirsime 20–30 metų vyrus. Tyrime naudosime tokius kintamuosius:

- *cntry* – šalies kodas (LT – Lietuva, PT – Portugalija),
- *stfgov* – respondento požiūris į savo šalies vyriausybę (0 – itin bloga,..., 9 – itin gera),
- *freehms* – gėjai ir lesbietės gali gyventi kaip nori (1 – visiškai sutinku,..., 5 – visiškai nesutinku),

- *imsclbn* – kada imigrantai gali visiškai naudotis šalies socialinėmis lengvatomis (matuojamas nominalia skale: 1 – iškart po atvykimo, 2 – po vienerių metų, neatsižvelgiant į tai, ar dirbo, 3 – po vienerių darbo ir mokesčių mokėjimo metų, 4 – tapę piliečiais, 5 – niekada negalės naudotis visomis lengvatomis).

Duomenų atrankai naudosime kintamuosius: *agea* – amžių ir *gndr* – lytį (1 – vyr., 2 – mot.). Grafikams pravers respondento identifikacijos numeris *idno*.

Pirmiausia paruošime duomenis analizei. Tarkime, duomenų failas darbiname kataloge yra csv formatu. Paliksime tyrime reikiamo amžiaus ir lyties respondentus. Kad nekiltų problemų su neteisingai išsaugotais praleistų reikšmių kodais, dar įvesime apribojimus kitų kintamųjų reikšmėms. Visi kintamieji yra skaitiniai, o kintamasis *cntry* – simbolinis. Perkoduosime jį į skaitinį kintamąjį taip, kad jo reikšmės būtų 0 ir 1 (logistinėje regresijoje atsako kintamasis turi būti dvireikšmis ir jo reikšmės turi būti 0 ir 1):

Įvykdome tokias komandas (*table* komanda ir jos rezultatų išklotinė – perkodavimo teisingumui patikrinti):

```
dta<-read.csv2("ESS4LT_PT_s.csv",na.strings = "NA",stringsAsFactors=FALSE)
library(car)
catn1 <- factor(dta$cntry, labels=(1:length(levels(factor(dta$cntry))))))
dta$country <- recode(as.numeric(catn1),"1=0;2=1")
table(dta$country,dta$cntry)

ldta<-subset(dta,agea >=20 & agea <= 30 & gndr == 1 & stfgov <= 9 & freehms <=5 &
imsclbn <=5)
```

```
> table(dta$country,dta$cntry)
```

	LT	PT
0	2002	0
1	0	2367

Kintamasis *imsclbn* yra kategorinis.

Prieš įtraukiant kategorinį kintamąjį į logistinės regresijos modelį, reikia įsitikinti, kad kiekvienai jo kategorijai yra pakankamai daug stebinių.

Patikriname, kokias reikšmes įgyja *imsclbn*:

```
tb=addmargins(table(ldta$country,ldta$imsclbn))
rownames(tb)=c("Lt","Pt","Suma")
colnames(tb)=c("Iškart","Po metų","Pradėjus dirbti","Tapus piliečiu","Niekada","Suma")
tb
```

```
> tb
```

	Iškart	Po metų	Pradėjus dirbti	Tapus piliečiu	Niekada	Suma
Lt	10	9	58	75	9	161
Pt	22	12	73	13	3	123
Suma	32	21	131	88	12	284

```
>
```

Matome, kad Lietuvos imtyje mažai respondentų rinkosi 1 – 2 („iškart“, „po metų“) ir 5 („niekada“). Todėl regresorių *imsclbn* keisime kategoriniu kintamuoju, įgyjančiu mažiau reikšmių. Sukursime du tokius kintamuosius: *imsb3* (*imsb3* = 0, kai *imsclbn* = 1 arba 2; *imsb3* = 1, kai *imsclbn* = 3; *imsb3* = 2, kai *imsclbn* = 4 arba 5) ir *imsb2* (*imsb2* = 0, kai *imsclbn* = 1, 2 arba 3; *imsb2* = 1, kai *imsclbn* = 4 arba 5):

```
ldta$imsb3<-recode(ldta$imsclbn, "c(1,2) = 0; 3 = 1;c(4,5) = 2")
ldta$imsb2<-recode(ldta$imsclbn, "c(1,2,3) = 0; c(4,5) = 1")
```

Mažesnės *imsb2*, *imsb3* reikšmės rodo palankesnę nuostatą imigrantų atžvilgiu. Įsitikiname, kad dabar yra pakankamai daug stebinių⁵⁷ kiekvienai regresorių kategorijai. Įvykdome

```
tb1<-addmargins(table(ldta$country,ldta$imsb2))
rownames(tb1) <-c("Lt","Pt","Suma")
colnames(tb1) <-c("0","1","Suma")
tb1
tb2=addmargins(table(ldta$country,ldta$imsb3))
rownames(tb2) <-c("Lt","Pt","Suma")
colnames(tb2) <-c("0","1","2","Suma")
tb2
```

⁵⁷ Ką reiškia pakankamai daug, sprendžia tyrėjas. Mūsų nuomone, jeigu kažkokį atsakymą renkasi mažiau nei 10 % respondentų, vertėtų pamąstyti apie kintamojo perkodavimą, paliekant mažiau kategorijų.

> tb1				> tb2				
	0	1	Suma		0	1	2	Suma
Lt	77	84	161	Lt	19	58	84	161
Pt	107	16	123	Pt	34	73	16	123
Suma	184	100	284	Suma	53	131	100	284

4.5.2. Modelio tyrimas

Logistinę regresiją R programa galima atlikti naudojant *glm* komandą. Tirsime modelį

$$\frac{\hat{P}(\text{country} = PT)}{\hat{P}(\text{country} = LT)} = \exp\{C + b1stfgov + b2 freehms + b3imsb2\}.$$

Modelyje yra vienas dvireikšmis regresorius *imsb2* (reikšmės 0 ir 1). Įvykdome komandas:

```
mdl<-glm(country~freehms+stfgov+factor(imsb2),family=binomial(logit), data=ldta)
summary(mdl)
mdl.reduced <-glm(country~1, family=binomial,data=ldta)
anova(mdl.reduced,mdl, test="Chisq")
rkvadrat<-1-mdl$deviance/mdl$null.deviance
rkvadrat
```

Call:

```
glm(formula = country ~ freehms + stfgov + factor(imsb2), family = binomial(logit),
    data = ldta)
```

Deviance Residuals:

```
Min      1Q      Median      3Q      Max
-2.1651 -0.7653  -0.2460  0.7283  2.4108
```

Coefficients:

```
Estimate Std. Error z value Pr(>|z|)
(Intercept)  1.30691    0.42790   3.054   0.00226 **
freehms      -0.81604    0.15117  -5.398   6.73e-08 ***
stfgov        0.35043    0.07532   4.652   3.28e-06 ***
factor(imsb2)1 -1.70839    0.34306  -4.980   6.36e-07 ***
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

```
Null deviance: 388.61 on 283 degrees of freedom
Residual deviance: 269.65 on 280 degrees of freedom
AIC: 277.65
```

Number of Fisher Scoring iterations: 5

Analysis of Deviance Table

Model 1: country ~ 1

Model 2: country ~ freehms + stfgov + factor(imsb2)

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	283	388.61			
2	280	269.65	3	118.96	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
> rkvadrat  
[1] 0.3061224
```

Tikėtinumų santykis (118,96) ir p reikšmė (0,00...) pateikiami lentelės „**Analysis Deviance Table**“ antroje eilutėje. Faktiškai tai informacija, kad su pasirinktais regresoriais modelis gerai tinka duomenims, nors neaišku, ar visi kintamieji modelyje reikalingi. Kuo tikėtinumų santykio reikšmė didesnė, tuo labiau tikėtina, kad logistinės regresijos modelis tinka. Ji ypač informatyvi tada, kai turime labai daug duomenų. Tada net ir statistiškai reikšmingas tikėtinumų santykis kelia įtarimų dėl modelio gerumo.

Determinacijos pseudokoefficiento reikšmė nėra didelė (**rkvadrat** = **0.3061**), bet logistinei regresijai šis rodiklis įvairiomis programomis skaičiuojamas skirtingai, todėl vertinamas prieštaringai ir nėra „lemiamas“ vertinant modelio kokybę. Juolab kad vis tiek viršija 0,20 – tradicinę determinacijos koeficientams taikomą tinkamumo ribą.

Užrašysime modelį, įstatydami koeficientų įverčius ($\exp\{x\}$, trumpas e^x žymėjimas).

$$\frac{\hat{P}(\text{country} = PT)}{\hat{P}(\text{country} = LT)} = \exp\{1,31 + 0,35 \text{ stfgov} - 0,81 \text{ freehms} - 1,71 \text{ imsb2}\}.$$

Įsitikiname modelio logiškumu. Didėjant skliaustuose esančiam reiškiniui (tikimybių santykio logit funkcijai), kartu didėja ir tikimybė, kad respondentas iš Portugalijos. Ir atvirkščiai, mažėjant skliaustuose esančiam reiškiniui, didėja tikimybė, kad respondentas iš Lietuvos. Koeficientas prie *freehms* ir yra neigiamas, o koeficientas prie *stfgov* teigiamas. Todėl, didėjant *freehms* reikšmei, didėja tikimybė, kad respondentas iš Lietuvos. Taigi kuo respondentas priešiščiau nusistatęs seksualinių mažumų atžvilgiu (*freehms* didesnis), tuo tikėtiniau, kad jis iš Lietuvos. Analogiškai darome išvadą, kad kuo respondentas palankiau vertina vyriausybę, tuo didesnė tikimybė, kad jis iš Portugalijos. Koeficientas prie *imsb2* yra neigiamas. Kai įstatome vieneta (*imsb2* = 1 atitinka neigiamą požiūrį į imigrantus), visas reiškinys sumažėja ir padidėja tikimybė, kad respondentas iš Lietuvos.

Modelio regresorių galimybių santykiai (ir jų 95 % pasikliautiniai intervalai) gaunami įvykdžius komandas:

```
exp mdl$coefficients
exp(confint.default(mdl))
```

(Intercept)	freehms	stfgov	factor(imsb2)1
3.6947441	0.4421792	1.4196734	0.1811571

	2.5 %	97.5 %
(Intercept)	1.5971858	8.5469920
freehms	0.3287946	0.5946644
stfgov	1.2248205	1.6455248
factor(imsb2)1	0.0924781	0.3548719

Kintamojo *imsb2* galimybių santykis yra 0,181. Todėl galime padaryti tokią išvadą: nepalankus požiūris į socialines lengvatas imigrantams (*imsb2* = 1), palyginti su palankiu, pakeičia santykį

$$\frac{\hat{P}(\text{country} = \text{PT})}{\hat{P}(\text{country} = \text{LT})}$$

0,181 karto (paprasčiau sakant, sumažina $1/0,181 = 5,525$ karto). Kaip jau minėta, tampa labiau tikėtina, kad respondentas buvo iš Lietuvos. Analogiškai interpretuojami galimybių santykiai ir tolydiems kintamiesiems. Pavyzdžiui, kiekvienas papildomas balas, palankiau vertinant vyriausybę (*stfgov*), padidina tikimybių santykį 1,42 karto. Tampa labiau tikėtina, kad respondentas iš Portugalijos. Kiekvienas papildomas balas neigiamiau vertinant seksualines mažumas *freehms* pakeičia tikimybių santykį 0,44 karto (t. y. sumažina $1/0,44 = 2,27$ karto). Tampa labiau tikėtina, kad respondentas iš Lietuvos. Be pačių galimybių santykių, lentelėje pateikiami ir jų 95 % pasikliautinių intervalų apatiniai ir viršutiniai režiai. Matome, kad intervaliniams kintamiesiems pasikliautinių intervalų ilgiai yra maži – gautieji galimybių santykių įverčiai patikimi.

Norėdami gauti klasifikacinę lentelę, įvykdome komandas:

```
library(QuantPsyc)
ClassLog(mdl,Idta$country)
```

```

> ClassLog mdl, ldt, $country)
$rawtab
  resp
    0  1
FALSE 128 34
TRUE  33 89

$classtab
  resp
    0    1
FALSE 0.7950311 0.2764228
TRUE  0.2049689 0.7235772

$overall
[1] 0.7640845

$mcFadden
[1] 0.3061224

```

Klasifikavimo rezultatai yra pateikiami lentelėse **\$rawtab** ir **\$classtab**. Matome, kad iš 123 (34 + 89) Portugalijos atstovų teisingai atpažinti 89 (stulpelis **1**, eilutė **TRUE**). Tai sudaro 72,36 % teisingų klasifikavimų. Analogiškai nustatome, kad iš 161 (128 + 33) Lietuvos atstovo teisingai klasifikuoti 128 (79,5 %) (stulpelis **0**, eilutė **FALSE**). Bendrasis teisingų klasifikavimų procentas (89 + 128 iš 123 + 161) yra 76,41 % (**\$overall**). Ankstesniame skyrelyje buvo nustatyta, kad imtyje respondentai iš Portugalijos sudaro 43,31 % , o iš Lietuvos – 56,69 %. Būtent toks būtų ir prognozės tikslumas, jeigu visą laiką kaip papūgos kartotume „PT“ („LT“). Taigi, taikant logistinę regresiją, klasifikavimas labai pagerėja. Vienas iš svarbiausių reikalavimų, keliamų tinkamiems logistinės regresijos modeliams, patenkinamas.

Norėdami gauti Hosmerio–Lemešou suderinamumo kriterijaus rezultatus, įvykdome⁵⁸:

```

hosmerlem = function(y, yhat, g=10) {
  cutyhat = cut(yhat,
    breaks = quantile(yhat, probs=seq(0, 1, 1/g)), include.lowest=TRUE)
  obs = xtabs(cbind(1 - y, y) ~ cutyhat)
  expect = xtabs(cbind(1 - yhat, yhat) ~ cutyhat)
  chisq = sum((obs - expect)^2/expect)
  P = 1 - pchisq(chisq, g - 2)
  return(list(chisq=chisq,p.value=P)) }
hosmerlem(y=ldt$country, yhat=fitted(mdl))

```

⁵⁸ Pasinaudosime svetainėje <http://r.789695.n4.nabble.com/Hosmer-Lemeshow-goodness-of-fit-td3508127.html> pateikiamu funkcijos kodu.

```
$chisq
[1] 9.67522


$p.value
[1] 0.288565
```

Gera, kai Hosmerio–Lemešou kriterijaus $p \geq 0,05$. Šiuo atveju $p = 0,289$. Šis rodiklis taip pat rodo priimtina modelio tikimą duomenims. Šiaip jau Hosmerio–Lemešou kriterijus yra pagalbinis ir taikomas tik nedidelėms imtims. Imtis $n = 284$ nėra itin maža, todėl buvo galima apsieiti ir be jo.


Išskirčių nustatymas logistinėje regresijoje taikomas retai (išskirtis turi būti labai „piktybinė“, kad logistinė regresija į ją reaguotų). Toliau pateikiami diagnostikos grafikai, leidžiantys įvertinti, ar yra „įtartinių“ stebinių⁵⁹.

Įvykdome komandas:


```
par(mfrow=c(2,2))
plot mdl
```



⁵⁹ Deviacija – rodiklis, taikomas apibendrintuose tiesiniuose modeliuose (logistinė regresija – atskiras tokių modelių atvejis).



Grafikai nerodo kažkokių labai išsiskiriančių reikšmių. Vis dėlto jeigu laikysime, kad standartinės paklaidos, viršijančios 3, rodo išskirtį (ši prielaida susijusi su regresorių normalumu, kuris logistinei regresijai nėra svarbus), keletą tokių taškų rasime. Pažiūrėję į ketvirtąją išdidintą grafiką matome, kad yra keletas stebinių, kuriems standartizuota Pirsono paklaida >3 . Beje, Kuko mato reikšmės (raudona linija) mažos – jokių išskirčių „nerodo“.



Šias „išskirtis“ galima pašalinti ir pažiūrėti, ar labai keičiasi modelis. Alternatyva aptariama kitame skyrelyje.

4.5.3. Atsparioji logistinė regresija

Jeigu kilo abejonių dėl duomenyse esančių išskirčių, galima apskaičiuoti modelio koeficientų įverčius naudojantis atspariosios (robastinės) logistinės regresijos analize. Pasinaudosime *robustbase* funkcijų biblioteka. Įvykdome:

```
library(robustbase)
mdl_r<-glmrob(country~freehms+stfgov+factor(imsb2),family=binomial(logit), data=ldta)
summary(mdl_r)
```

Call: **glmrob(formula = country ~ freehms + stfgov + imsb2, family = binomial(logit), data = ldta)**

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	1.4234	0.4557	3.124	0.00179 **
freehms	-0.9130	0.1716	-5.319	1.04e-07 ***
stfgov	0.3640	0.0817	4.456	8.37e-06 ***
imsb2	-1.7699	0.3708	-4.773	1.81e-06 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Robustness weights w.r * w.x:

256 weights are ~ = 1. The remaining 28 ones are summarized as

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.2796	0.4453	0.6153	0.6125	0.7863	0.9529

Number of observations: 284

Fitted by method 'Mqle' (in 5 iterations)

(Dispersion parameter for binomial family taken to be 1)

No deviance values available

Algorithmic parameters:

```
acc tcc
0.0001 1.3450
maxit
50
test.acc
"coef"
```

Gautoji modelio lygtis

$$\frac{\hat{P}(\text{country} = PT)}{\hat{P}(\text{country} = LT)} = \exp\{1,42 + 0,36 \text{ stfgov} - 0,91 \text{ freehms} - 1,77 \text{ imsb2}\}.$$

Matome, kad rezultatai beveik nesiskiria nuo gautųjų taikant klasikinę logistinę regresiją. Tai dar kartą patvirtina, kad pirmiau nagrinėtas modelis gerai tinka duomenims.

Dar viena situacija, kai siūloma taikyti atspariąją logistinę regresiją, – vadinamosios *klasterizuotos imtys*. Duomenys natūraliai grupuojasi pagal kažkokį požymį ir įtariame liekamųjų paklaidų priklausomumą grupėse. Pavyzdžiui, studentas išlaikys egzaminą ar neišlaikys, sprendžiam tikrindami 7 grupių atstovus. Priklausymas tai pačiai grupei (darbinė atmosfera, tie patys dėstytojai) daro tikėtiną prielaidą, kad iš rezultatų tai bus matyti. Tada geriau taikyti atspariosios logistinės regresijos modelį⁶⁰.

4.5.4. Reikšmių prognozavimas

Tarkime, kad norime prognozuoti respondento šalį, žinodami, kad jam(jai) $freehms = 3$, $stgov = 5$, $imsb2 = 0$. Tą galima padaryti įvykdžius komandą:

```
predict mdl, data.frame(freehms = 3, stgov = 5, imsb2 = 0), type="response"
```

```
> predict mdl, data.frame(freehms = 3, stgov = 5, imsb2 = 0), type="response"
1
0.6481519
```

Tikimybė, kad respondentas iš Portugalijos $P(country = 1) = P(country = PT) = 0,65$. Aišku, kad $P(country = LT) = 0,35$. Labiau tikėtina, kad iš Portugalijos.

Galima padaryti prognozes abiem $imsb2$ atvejams:

```
predict mdl, data.frame(freehms = 3, stgov = 5, imsb2 = c(0,1)), type="response"
```

```
> predict mdl, data.frame(freehms = 3, stgov = 5, imsb2 = c(0,1)), type="response"
1      2
0.6481519 0.2502151
```

Kai $imsb2 = 0$, tikimybė $P(country = PT) = 0,65$ sutampa su pirmiau apskaičiuotąja. Kai $imsb2 = 1$, tikimybė $P(country = PT) = 0,25$. Tikimybė sumažėja daugiau kaip perpus ir tampa labiau tikėtina, kad respondentas iš Lietuvos. Vaizdžiai matome požiūrio į imigrantus vaidmenį. Priešiškesnė nuostata imigrantų atžvilgiu labai stipriai keičia tikėtiną respondento šalį.

Galima skaičiuoti ne pačias tikimybes, bet galimybes (tikimybių santykius). Įvykdome:

⁶⁰ Turint informaciją apie klasterių savybes, reikėtų taikyti HLM, žr. praturmę.

```
exp(predict(mdl, data.frame(freehms = 3,stfgov = 5,imsb2 = 0)))
```

```
> exp(predict(mdl, data.frame(freehms = 3,stfgov = 5,imsb2 = 0)))  
1  
1.842135
```

Kadangi žinome, kad $P(\text{country} = \text{PT}) = 0,65$, $P(\text{country} = \text{LT}) = 0,35$, nesunku patikrinti

$$\frac{\hat{P}(\text{country} = \text{PT})}{\hat{P}(\text{country} = \text{LT})} = \frac{0,65}{0,35} = 1,8 \dots$$

4.5.5. Kategoriniai regresoriai

Dvireikšmio regresoriaus atvejį aptarėme ankstesniuose skyreliuose. Situacija sudėtingesnė, kai regresorius gali įgyti daugiau nei dvi kategorines reikšmes. Tada jį reikia pakeisti keletu dvireikšmių pseudokintamųjų. R programa tą galima padaryti automatiškai (kategorinis kintamasis turi būti nurodytas kaip *factor* tipo). Ištirsime modelį, kai vietoje *imsb2* įtrauktas *imsb3*. Įvykdome komandas:

```
mdl_n<-glm(country~freehms+stfgov+factor(imsb3),family=binomial(logit), data=ldta)  
summary(mdl_n)  
mdl_n.reduced <-glm(country~1, family=binomial,data=ldta)  
anova(mdl_n.reduced,mdl_n, test="Chisq")
```

Vietoj *imsb3* sukuriame du (vienu mažiau nei yra kategorijų) pseudokintamieji, įgyjantys reikšmes 0 ir 1 (*factor(imsb3)1* ir *factor(imsb3)1*).

Call:
**glm(formula = country ~ freehms + stfgov + factor(imsb3), family = binomial(logit),
 data = ldta)**

Deviance Residuals:

Min	1Q	Median	3Q	Max
-2.1287	-0.7965	-0.2459	0.6807	2.4138

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	1.53233	0.51101	2.999	0.00271 **
freehms	-0.81175	0.15145	-5.360	8.33e-08 ***
stfgov	0.35331	0.07571	4.667	3.06e-06 ***
factor(imsb3)1	-0.33094	0.40094	-0.825	0.40915
factor(imsb3)2	-1.95339	0.45561	-4.287	1.81e-05 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 388.61 on 283 degrees of freedom
 Residual deviance: 268.96 on 279 degrees of freedom
 AIC: 278.96

Number of Fisher Scoring iterations: 5

Analysis of Deviance Table

Model 1: country ~ 1

Model 2: country ~ freehms + stfgov + imsb2 + factor(imsb3)

	Resid. Df	Resid. Dev	Df	Deviance	P(> Chi)
1	283	388.61			
2	279	268.96	4	119.65	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

>

Gavome tinkamą modelį. Vis dėlto vienas iš naudotų pseudokintamųjų (atitinkantis *antrąją* regresoriaus *imsb3* reikšmę) yra statistiškai nereikšmingas. Pažvelkime į klasifikacinę lentelę. Įvykdome:

```
library(QuantPsyc)
ClassLog mdl_n, ldt, $country)
```

```
$rawtab
  resp
    0  1
FALSE 134 36
TRUE  27 87

$classtab
  resp
    0    1
FALSE 0.8322981 0.2926829
TRUE  0.1677019 0.7073171

$overall
[1] 0.778169

$mcFadden
[1] 0.3078951
```

Bendrasis teisingų klasifikavimų procentas (77,82 %) kiek didesnis nei modelyje su *imsb2* (76,41 %). Kita vertus, mažiau teisingai klasifikuoti Portugalijos atstovai (70,73 %, o buvo 72,36 %) ir kiek geriau Lietuvos respondentai (83,23 %, buvo 79,5 %). Galime daryti išvadą, kad apskritai šis modelis nėra geresnis už buvusįjį.

4.5.6. Multikolinearumas

Parodysime, kaip gali kilti (ir likti nepastebėta) multikolinearumo problema, į modelį įtraukdami kintamojo *freehms* kvadratą. Paaiškinti tokį įtraukimą nesunku – manome, kad šis kintamasis toks svarbus, kad priklausomybė nuo jo ne tiesinė, o kvadratinė. Naująjį regresorių (pavadinsime jį *freesquare*) sukuriame komanda:

```
ldt$freeSquare<-ldt$freehms^2
```

Sudarome modelį su visais kintamaisiais:

```
mdl2<-glm(country~freehms+stfgov+imsb2+freesquare,family=binomial(logit), data=ldta)
summary(mdl2)
mdl2.reduced<-glm(country~1, family=binomial,data=ldta)
anova(mdl2.reduced,mdl2, test="Chisq")
```

Call:

```
glm(formula = country ~ freehms + stfgov + factor(imsb2) + freesquare,
     family = binomial(logit), data = ldta)
```

Deviance Residuals:

Min	1Q	Median	3Q	Max
-2.4710	-0.7359	-0.2658	0.6854	2.5925

Coefficients:

	Estimate	Std. Error	z	value	Pr(> z)
(Intercept)	3.4610	0.9528	3.633	0.000281	***
freehms	-2.6125	0.7066	-3.697	0.000218	***
stfgov	0.3687	0.0763	4.833	1.35e-06	***
factor(imsb2)1	-1.7596	0.3543	-4.967	6.81e-07	***
freesquare	0.3123	0.1161	2.690	0.007152	**

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 388.61 on 283 degrees of freedom
 Residual deviance: 262.35 on 279 degrees of freedom
 AIC: 272.35

Number of Fisher Scoring iterations: 5

Analysis of Deviance Table

Model 1: country ~ 1

Model 2: country ~ freehms + stfgov + factor(imsb2) + freesquare

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	283	388.61			
2	279	262.35	4	126.26	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Matome, kad modelyje visi kintamieji statistiškai reikšmingi, tikėtinumų santykis didelis (126,26; $p = 0,000...$). Vis dėlto modelyje yra akivaizdžiai neteisinga priklausomybė nuo

freesquare: šio regresoriaus koeficientas yra teigiamas, kitaip nei *freehms*. Iškart susiduriame su interpretacijos problema. Multikolinearumą galima pastebėti, užmetus akį į kintamųjų koreliaciją:

```
cor(ldta$freesquare,ldta$freehms)
> cor(ldta$freesquare,ldta$freehms)
[1] 0.9790606
```

Koreliacija yra 0,97, t. y. nepaprastai stipri. Įsitikinti, kad regresijos lygtyje atsirado neteisingas koeficiento ženklas, galima ir tiesiog atliekant logistinę *country* regresiją pagal vienintelį kintamąjį *freesquare*. Įvykdome

```
mdl3<-glm(country~freesquare,family=binomial(logit), data=ldta)
summary(mdl3)
mdl3.reduced<-glm(country~1, family=binomial,data=ldta)
anova(mdl3.reduced,mdl3, test="Chisq")
```

Call:
glm(formula = country ~ freesquare, family = binomial(logit), data = ldta)

Deviance Residuals:

Min	1Q	Median	3Q	Max
-1.4816	-0.9743	-0.3307	1.0752	2.4222

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	0.84045	0.20566	4.087	4.38e-05 ***
freesquare	-0.14878	0.02493	-5.968	2.40e-09 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 388.61 on 283 degrees of freedom
Residual deviance: 335.63 on 282 degrees of freedom
AIC: 339.63

Number of Fisher Scoring iterations: 4

Analysis of Deviance Table

Model 1: country ~ 1

Model 2: country ~ freesquare

	Resid.Df	Resid. Dev	Df	Deviance	P(> Chi)
1	283	388.61			
2	282	335.63	1	52.98	3.37e-13 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

>

Matome, kad koeficiento prie *freesquare* ženklas, kaip ir tikėjomės, yra neigiamas. Beje, multikolinearumo problemą galima išspręsti iš modelio pašalinant ir *freehms*. Čia, kaip dažnai būna regresijoje, nėra vienintelio teisingo duomenims tinkamo modelio. Gali būti net keli statistikos požiūriu tinkami modeliai. Geresnis iš jų tas, kuris geriau rodo realią situaciją. Tą nuspręsti padeda ne statistika, o geras tiriamo dalyko išmanymas.

Praktiniuose logistinės regresijos taikymuose multikolinearumas tikrinamas tik tada, kai, tyrėjo nuomone, atsiranda netikėti koeficientų ženklai. Jeigu tyrėjas savo nuomonės neturi (o kitų nuomonės nežino), jis gali pažiūrėti, ar intervalinių regresorių koreliacijos nėra didelės. Jeigu tyrėjui neaišku, kokia koreliacija yra didelė (jis ir sriubos pasūdyti nesugeba, jeigu neranda instrukcijos, kiek gramų druskos dėti į litrą sriubos, ką jau čia kalbėti koreliaciją), jis gali sudaryti logistinės regresijos modelį su *vieninteliu* regresoriumi. Regresoriaus koeficiento ženklas (teigiamas / neigiamas) turėtų išlikti ir jungtiniame modelyje. Operaciją kartojame su antruoju regresoriumi. Tada su trečiuoju. Ir t. t.

4.5.7. Žingsninė logistinė regresija

Viskas, kas pasakyta apie žingsninės regresijos trūkumus, kalbant apie tiesinę regresiją, tinka ir logistinės regresijos atveju. Trumpai galima rešumuoti taip: jokios formalios statistinės procedūros neatstos gilaus dalyko išmanymo. Pasitikint vien statistiniais skaičiavimais, galima prikurti labai neteisingų interpretacijų.

Po tokios pesimistinės įžangos pažiūrėkime, kaip su R atlikti žingsninę logistinę regresiją. Kaip ir visada galima žingsniuoti į priekį arba atgal. Tirsime modelį su *imsb3*.

Pasirinksime regresiją, kai „žingsniuojama atgal ir tik atgal“, t. y. kai pradedama nuo modelio su visais regresoriais, laipsniškai po vieną vis šalinant statistiškai nereikšmingus iš jų

(eliminuojamoji, šalinamoji regresija). Procesas baigiamas, kai modelyje lieka tik statistiškai reikšmingi regresoriai.

Šalinamoji (eliminuojanči, *backward*) žingsninė regresija atliekama taip:

```
mdl_n<-glm(country~freehms+stfgov+factor(imsb3),family=binomial(logit), data=ldta)
fml<-step(mdl_n,direction="backward",test="Chisq")
summary(fml)
```

Start: AIC=278.96

country ~ freehms + stfgov + factor(imsb3)

	Df	Deviance	AIC	LRT	Pr(>Chi)
<none>		268.96	278.96		
- stfgov	1	293.73	301.73	24.769	6.463e-07 ***
- factor(imsb3)	2	297.72	303.72	28.759	5.688e-07 ***
- freehms	1	304.91	312.91	35.955	2.019e-09 ***

Signif. codes: 0 '*' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1**

Matome, kad modelyje liko kintamasis, kuris iš esmės sutampa su *imsb2*, t. y. netiesiogiai siūloma pereiti prie modelio su *imsb2*. O žiūrint formaliai, nieko gero negavome, nes neišėina į modelį įtraukti tik pusę kategorinio kintamojo (*_Iimsb3_1* modelyje nebeliko).

```
> summary(fml)

Call:
glm(formula = country ~ freehms + stfgov + as.factor(imsb3),
     family = binomial(logit), data = ldta)

Deviance Residuals:
    Min       1Q   Median       3Q      Max
-2.1287 -0.7965 -0.2459  0.6807  2.4138

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept)   1.53233   0.51101   2.999  0.00271 **
freehms       -0.81175   0.15145  -5.360 8.33e-08 ***
stfgov         0.35331   0.07571   4.667 3.06e-06 ***
```



```

as.factor(imsb3)1 -0.33094  0.40094 -0.825  0.40915
as.factor(imsb3)2 -1.95339  0.45561 -4.287 1.81e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 388.61  on 283  degrees of freedom
Residual deviance: 268.96  on 279  degrees of freedom
AIC: 278.96

Number of Fisher Scoring iterations: 5

```

Iš pradinio modelio nebuvo pašalintas nė vienas regresorius.

R programos dvinarės logistinės regresijos komandos

R programoje dvinarei logistinei regresinei analizei yra naudojama **glm** komanda. Šios komandos sintaksė atrodo taip:

```
glm(formula, family, data, weights, subset, ...)
```

Būtinasis parametras **formula** – užrašome modelio išraišką.

Kaip matysime vėliau, **glm** naudojama ne tik dvinarės logistinės regresijos analizei. Kokia analizė bus atliekama, nulemia parametras *family*. Logistinės regresijos atveju jo reikšmė yra *binomial(logit)*, t. y. **family=binomial(logit)**.

Scenarijus:

```

dta<-read.csv2("ESS4LT_PT_s.csv",na.strings = "NA",stringsAsFactors=FALSE)
library(car)
catn1 <- factor(dta$cntry, labels=(1:length(levels(factor(dta$cntry))))))
dta$country <- recode(as.numeric(catn1),"1=0;2=1")

```

```

table(dta$country,dta$cntry)
ldta=subset(dta,agea >=20 & agea <= 30 & gndr == 1 & stfgov <= 9 & freehms <=5 &
imsclbn <=5)
# patikrinimas
tb=addmargins(table(ldta$country,ldta$imsclbn))
rownames(tb)=c("Lt","Pt","Suma")
colnames(tb)=c("Iškart","Po metų","Pradėjus dirbti","Tapus
piliečiu","Niekada","Suma")
tb
ldta$imsb3<-recode(ldta$imsclbn, "c(1,2) = 0; 3 = 1;c(4,5) = 2")
ldta$imsb2<-recode(ldta$imsclbn, "c(1,2,3) = 0; c(4,5) = 1")
tb1<-addmargins(table(ldta$country,ldta$imsb2))
rownames(tb1) <-c("Lt","Pt","Suma")
colnames(tb1) <-c("0","1","Suma")
tb1
tb2<-addmargins(table(ldta$country,ldta$imsb3))
rownames(tb2) <-c("Lt","Pt","Suma")
colnames(tb2) <-c("0","1","2","Suma")
tb2
mdl<-glm(country~freehms+stfgov+factor(imsb2),family=binomial(logit), data=ldta)
summary(mdl)
mdl.reduced <-glm(country~1, family=binomial,data=ldta)
anova(mdl.reduced,mdl, test="Chisq")
# pseudo r kvadratas
rkvadrat<-1-mdl$deviance/mdl$null.deviance
#galimybių santykiai
exp(mdl$coefficients) #arba exp(coef(mdl))
exp(confint.default(mdl))
# klasifikavimo lentelė
library(QuantPsyc)
ClassLog(mdl,ldta$country)
#

```

```

# Hosmerio–Lemešou suderinamumo kriterijus
#
mdl=glm(country~freehms+stfgov+factor(imsb2),family=binomial(logit), data=ldta)
hosmerlem = function(y, yhat, g=10) {
  cutyhat = cut(yhat,
    breaks = quantile(yhat, probs=seq(0, 1, 1/g)), include.lowest=TRUE)
  obs = xtabs(cbind(1 - y, y) ~ cutyhat)
  expect = xtabs(cbind(1 - yhat, yhat) ~ cutyhat)
  chisq = sum((obs - expect)^2/expect)
  P = 1 - pchisq(chisq, g - 2)
  return(list(chisq=chisq,p.value=P))
}
hosmerlem(y=ldta$country, yhat=fitted(mdl))
#
#liekanos
#
residuals(mdl,type="pearson")
residuals(mdl,type="deviance")
deviance(mdl)
#
# grafikai
#
par(mfrow=c(2,2))
plot(mdl)
#
# Prognozavimas
#
predict(mdl, data.frame(freehms = 3,stfgov = 5,imsb2 = 0), type="response")
predict(mdl, data.frame(freehms = 3,stfgov = 5,imsb2 = c(0,1)), type="response")
exp(predict(mdl, data.frame(freehms = 3,stfgov = 5,imsb2 = 0)))
#
#kategoriniai regresoriai
#

```

```

mdl_n<-glm(country~freehms+stfgov+factor(imsb3),family=binomial(logit), data=ldta)
summary(mdl_n)
mdl_n.reduced <-glm(country~1, family=binomial,data=ldta)
anova(mdl_n.reduced,mdl_n, test="Chisq")
# klasifikavimo lentelė
library(QuantPsyc)
ClassLog(mdl_n,ldta$country)
#
# Multikolinearumo problema
#
ldta$freesquare<-ldta$freehms^2
mdl2<-glm(country~freehms+stfgov+factor(imsb2)+freesquare,family=binomial(logit),
data=ldta)
summary(mdl2)
mdl2.reduced<-glm(country~1, family=binomial,data=ldta)
anova(mdl2.reduced,mdl2, test="Chisq")
cor(ldta$freesquare,ldta$freehms)
#
# atsparioji logistinė
library(robustbase)
mdl_r<-glmrob(country~freehms+stfgov+factor(imsb2),family=binomial(logit), data=ldta)
summary(mdl_r)
#
# žingsninė logistinė
#
mdl_n<-glm(country~freehms+stfgov+factor(imsb3),family=binomial(logit), data=ldta)
# pirmyn
fml<-step(mdl_n,direction="forward",test="Chisq")
summary(fml)
# pirmyn atgal
fml<-step(mdl_n,direction="both",test="Chisq")
summary(fml)

```

#atgal

step(md1,direction="backward",test="Chisq")

summary(fnl)

Uždaviniai

1. Failas **ESS4LT1.sav**. Socialinis Lietuvos respondentų tyrimas, 2009 m. spalio – 2010 m. ir analogiškas 2008 m. tyrimas Estijoje **ESS4EE.sav**. Kintamieji:

- *ageyo30* (amžiaus grupės, *ageyo30* = 1, jeigu iki 29 m.)
- *gndr* (lytis, 1 – vyr., 2 – mot.),
- *cntry* (šalis, LT – Lietuva, EE – Estija),
- *pray* (maldos nereliginių apeigų metu, 1 – kasdien, 2 – dažniau nei kartą per sav., 3 – kartą per sav., 4 – bent kartą per mėn., 5 – tik per didžiąsias šventes, 6 – dar rečiau, 7 – niekada),
- *freehms* (gėjai ir lesbietės gali gyventi kaip nori, 1 – visiškai sutinku, ... 5 – visiškai nesutinku),
- *happy* (laimingumas, 0 – ypač nelaimingas, 10 – ypač laimingas),
- *stfdem* (kiek respondentas yra patenkintas demokratijos padėtimi savo šalyje),
- *stfeco* (kiek respondentas yra patenkintas savo šalies ekonomine padėtimi),
- *stfedu* (kiek respondentas yra patenkintas savo šalies švietimo sistema),
- *stfgov* (kiek respondentas yra patenkintas savo šalies vyriausybe),
- *stfhlth* (kiek respondentas yra patenkintas savo šalies sveikatos apsauga),
- *stflife* (kiek respondentas yra patenkintas savo gyvenimu apskritai).

Kintamieji *stfdem*, *stfeco*, *stfgov*, *stfhlth*, *stflife* matuojami 10 balų skale nuo 0 (itin nepatenkintas) iki 10 (itin patenkintas).

Atrinkus moteris iki 29 metų, ištirti modelį:

$$cntry = f(pray, freehms, happy, stfdem, stfeco, stfgov, stflife).$$

Atsakyti į klausimus:

- 1) Ar tikėtinumų santykis statistiškai reikšmingas?
- 2) Ar visi pradinio modelio kintamieji statistiškai reikšmingi?
- 3) Ar yra multikolinearumo problema?
- 4) Ar pakankamas klasifikavimo tikslumas?

Modelį patobulinti, naudojantis žingsnine regresija.

2. Failas **ZTLT** . Tyrimas: Lietuvos tolerancijos profiliai, 2003 m. Klausimų grupės:

- $r02_01 - r02_04$ ranginėje skalėje įvertinta, koks procentas nurodytos grupės (kitos rasės, kitos tautybės, kitos religijos, kitos seksualinės orientacijos) gyventojų nekeltų Lietuvoje problemų.
- $r04_01 - r04_09$ Lietuvoje turėtų būti toleruojama (skalėje 1 – visiškai sutinku, 2 – sutinku, 3 – nesutinku, 4 – visiškai nesutinku) kitos tautybės, kitos rasės, kitos krikščioniškos konfesijos, nekrikščioniškos religijos, suteikiamas prieglobstis politiniams pabėgėliams, suteikiamas prieglobstis ekonominiais pabėgėliams, visi Lietuvos gyventojai turi turėti lygias galimybes įsidarbinti ir socialines garantijas).
- $s01$ – lytis,
- $s02$ – amžius,
- $r01_01$ respondento požiūris (skalėje 1 – teigiamas, 2 – neutralus, 3 – neigiamas, 4 – sunku pasakyti) į juodaodžius.
- $r01_02$ respondento požiūris (skalėje 1 – teigiamas, 2 – neutralus, 3 – neigiamas, 4 – sunku pasakyti) į musulmonus.

Sukurti naujus kintamuosius:

- 1) $a2 = r02_01 + \dots + r01_04$. Kintamasis $a2$ rodo respondento pakantumą „kitokiems“. Kuo didesnė $a2$ reikšmė, tuo pakantumas didesnis.
- 2) $a4 = r04_01 + \dots + r04_09$. Kintamasis $a4$ – respondento nuomonė apie valstybės tolerantiškumo laipsnį. Kuo mažesnė $a4$ reikšmė, tuo valstybė tolerantiškesnė.

Atsirinkti ne vyresnes nei 35 metų moteris, kurios turi savo nuomonę apie juodaodžius ir musulmonus ($r01_01$ ir $r01_02$ nelygūs 4). Įsitikinti, kad tarp šių moterų yra tik viena, kuri nepalankiai vertina juodaodžius. Pašalinti ją iš tolesnio tyrimo. Sukurti naują kintamąjį *juodas* ($juodas = 0$, kai $r01_01 = 1$ ir $juodas = 1$, kai $r01_01 = 2$).


Ištirti logistinės regresijos modelį $juodas = f(a2, a2, r01_02)$.

3. Failas **ZTLT1**. Vyrai ir moterys, 2006 m. spalio. Kintamieji

- $s1$ – lytis (1 – vyr., 2 – mot.),
- $s12$ – regionas ($s12 = 1$, jeigu Vilniaus; $s12 = 2$, jeigu Kauno, ...),
- $G6_1$ – dažniausiai ruošia maistą,
- $G6_2$ – dažniausiai plauna indus,
- $G6_3$ – dažniausiai perka maisto produktus,

- $G6_4$ – dažniausiai plauna grindis, šluosto dulkes, valo kilimus,
- $G6_5$ – dažniausiai taiso sugedusius buitinius prietaisus,
- $G6_6$ – dažniausiai apmoka sąskaitas,
- $G6_7$ – dažniausiai organizuoja laisvalaikį.

Visi kintamieji $G6_1$ – $G6_7$ matuojami skalėje: 1 – visada aš, 2 – dažniausiai aš, 3 – vieno-dai abudu sutuoktiniai / partneriai, 4 – dažniausiai sutuoktinis / partneris, 5 – visada sutuoktinis/ partneris, 6 – visada arba dažniausiai kitas kartu gyvenantis žmogus. Taigi kuo kintamieji $G6_1$ – $G6_7$ mažesni, tuo labiau problemą sprendžia pats respondentas. Atsirinkus Kauno regiono gyventojus, su žingsnine logistine regresija ištirti modelį $s_1 = f(G6_1, G6_2, G6_3, G6_4, G6_5, G6_6, G6_7)$. Ar gautasis modelis tinkamas? Kokius galima pasiūlyti alternatyvius modelius?




5. DAUGIANARĖ LOGISTINĖ REGRESINĖ ANALIZĖ

Tipinės situacijos, kai gali būti taikoma daugianarė logistinė regresinė analizė, yra šios:

- Norime įvertinti, kaip perkamo automobilio spalva priklauso nuo pirkėjo amžiaus, lyties ir išsilavinimo.
- Tiriame, kas apibūdina parlamentaro balsavimą (pritaria, nepritaria, susilaiko).
- Norime išsiaiškinti, kokią įtaką įmušti vienuolikos metrų baudinį svarbiose futbolo rungtynėse turi nervingumas, patirtis ir nuovargis.
- Tiriame, kaip vairavimo egzamino praktinės dalies (išlaiko iš karto, išlaiko antrą kartą laikydamas, pirmus du kartus laiko nesėkmingai) priklauso nuo vairuotojo amžiaus ir turėtų praktinių užsiėmimų skaičiaus. Viena iš tiriamų problemų yra tokia: kaip kiekviena papildoma su vairavimo instruktoriumi praleista valanda pakeičia tikimybių iškart išlaikyti egzaminą / neišlaikyti egzamino santykį.

Modelio schema:



Kintamasis Y vadinamas *priklausomu kintamuoju*, kintamieji X , Z , W – *regresoriais*. Akivaizdu, kad daugianarė logistinė regresija yra dvinarės logistinės regresijos apibendrinimas, kai priklausomas kintamasis įgyja daugiau nei dvi skirtingas reikšmes.

5.1. Daugianarės logistinės regresijos modelis

5.1.1. Modelio lygtys

Supaprastintai daugianarę logistinę regresiją galima įsivaizduoti taip: sumodeliuojame kiekvienos Y reikšmės įgijimo tikimybes. Jas ir nagrinėjame. Realiai lyginamos ne visos tikimybės tarpusavyje, o visos su viena – iš anksto pasirinktos Y reikšmės tikimybe. Todėl daugianarės logistinės regresinės analizės matematinis modelis aprašomas keliomis lygtimis. Pasirenkama viena vadinamoji kontrolinė Y kategorija (dažniausiai tai didžiausia Y reikšmė) ir sudaroma daug dvinarės logistinės regresijos dalinių modelių kitų Y kategorijų tikimybių ir kontrolinės kategorijos

tikimybės santykiams. Parodysime, kaip sudaromi modeliai, kai Y įgyja keturias reikšmes $Y = 1, 2, 3, 4$. Tegul kontrolinė kategorija atitinka reikšmę $Y = 4$. Sudarome tris matematinius modelius tikimybių santykiams.

$$\begin{aligned}\frac{P(Y = 1)}{P(Y = 4)} &= \exp\{C_1 + b_{11}X + b_{12}Z + b_{13}W\}, \\ \frac{P(Y = 2)}{P(Y = 4)} &= \exp\{C_2 + b_{21}X + b_{22}Z + b_{23}W\}, \\ \frac{P(Y = 3)}{P(Y = 4)} &= \exp\{C_3 + b_{31}X + b_{32}Z + b_{33}W\}.\end{aligned}$$

Koeficientai $C_1, b_{11}, b_{12}, b_{13}, C_2, b_{21}, b_{22}, b_{23}, C_3, b_{31}, b_{32}, b_{33}$ nėra žinomi. Jų įverčiai $\hat{C}_1, \hat{b}_{11}, \hat{b}_{12}, \hat{b}_{13} \dots$ gaunami, panaudojus imties duomenis. Teigiamas (neigiamas) koeficientas rodo, kad kintamajam didėjant priklausymo konkrečiai Y kategorijai tikimybė, *palyginus ją su kontrolinės kategorijos tikimybe*, padidėja (sumažėja). Žinoma, jeigu kitų kintamųjų reikšmės lieka fiksuotos.

Jeigu $b_{11} > 0$, X didėjant, tampa labiau tikėtina, kad $Y = 1$, o ne $Y = 4$.
Jeigu $b_{11} < 0$, X didėjant, tampa labiau tikėtina, kad $Y = 4$, o ne $Y = 1$.

Pavyzdžiui, jeigu $Y = 4$ žymi atvejį, kai pacientas sveikas, o $Y = 1$ – susirgimą tuberkulioze, $\hat{b}_{11} > 0$, rodo, kad X didėjant, tikimybė susirgti tuberkulioze, palyginti su tikimybe išlikti sveikam, padidėja. Su $Y = 4$ lyginame tik todėl, kad minėtame modelyje tai buvo kontrolinė kategorija. Jeigu kontrolinė kategorija būtų $Y = 3$, viską lygintume su $Y = 3$.

Aprašant regresijos modelį paprastai apsiribojama lyginimais su kontroline kategorija. Vis dėlto pažymėtina, kad pagal koeficientų reikšmes galima padaryti išvadą ir apie dviejų nekontrolinių kategorijų tikimybes. Tereikia atsižvelgti į atitinkamų koeficientų skirtumą. Fiksuokime visų kintamųjų, išskyrus X , reikšmes.

Jeigu $b_{11} - b_{21} > 0$, X didėjant, tampa labiau tikėtina, kad $Y = 1$, o ne $Y = 2$.
Jeigu $b_{11} - b_{21} < 0$, X didėjant, tampa labiau tikėtina, kad $Y = 2$, o ne $Y = 1$.

Analogiškai visiems regresoriams galima palyginti kitas Y kategorijas.

5.1.2. Prognozavimas

Tikimybių $P(Y = k)$ prognozės konkrečioms X, Z, W reikšmėms skaičiuojamos taip: tikimybių santykių logaritmams (kurie dar vadinami tikimybių santykių logit funkcijomis) z_1, z_2, z_3 pagal formules

$$z_1 = \hat{C}_1 + \hat{b}_{11}X + \hat{b}_{12}Z + \hat{b}_{13}W, \quad z_2 = \hat{C}_2 + \hat{b}_{21}X + \hat{b}_{22}Z + \hat{b}_{23}W, \\ z_3 = \hat{C}_3 + \hat{b}_{31}X + \hat{b}_{32}Z + \hat{b}_{33}W$$

surandame konkrečias jų reikšmes. Tam užtenka įstatyti tas X, Z ir W reikšmes, kurioms norime gauti prognozę. Tikimybės įverčiai skaičiuojami pagal formules:

$$\hat{P}(Y = 1) = \frac{e^{z_1}}{1 + e^{z_1} + e^{z_2} + e^{z_3}}, \quad \hat{P}(Y = 2) = \frac{e^{z_2}}{1 + e^{z_1} + e^{z_2} + e^{z_3}}, \\ \hat{P}(Y = 3) = \frac{e^{z_3}}{1 + e^{z_1} + e^{z_2} + e^{z_3}}, \quad \hat{P}(Y = 4) = \frac{1}{1 + e^{z_1} + e^{z_2} + e^{z_3}}.$$

Čia $e = 2,7183\dots$

Pavyzdys. Tarkime, kad, atlikę daugianarę logistinę regresiją, gavome tokius logit funkcijų įverčius

$$z_1 = 1 + 2X - Z + 3W, \quad z_2 = 2 + X + Z + 2W, \quad z_3 = 1 + X + Z + W.$$

Tarkime, kad $X = 0, Z = 1, W = 0$. Įstatome šias reikšmes ir gauname $z_1 = 0, z_2 = 3, z_3 = 2$. Nesunkiai surandame $e^0 = 1, e^3 = 20,1, e^2 = 7,39, e^0 + e^3 + e^2 = 29,49$. Todėl

$$\hat{P}(Y = 1) = \hat{P}(Y = 4) = \frac{1}{29,49} = 0,0339, \quad \hat{P}(Y = 2) = \frac{20,1}{29,49} = 0,68, \quad \hat{P}(Y = 3) = \frac{7,39}{29,49} = 0,25.$$

Taigi, kai $X = 0, Z = 1, W = 0$, labiausiai tikėtina, kad $Y = 2$.

Kartais reikalinga Y reikšmės prognozė. Pavyzdžiui, kokios spalvos automobilį pirks dvidešimtmetė pankė? Prognozė daroma taip: suskaičiuojamos visų galimų Y kategorijų tikėtinos tikimybės. Prognozuojame tą Y reikšmę, kurios įgijimo tikimybė didžiausia. Jeigu didžiausia tikimybė, kad pankė pirks raudoną automobilį, ir prognozuojame, kad ji pirks raudoną automobilį.

5.1.3. Galimybių santykiai

Apskaičiavus tikėtinas tikimybes, galima rasti jų santykius, kurie vadinami *galimybėmis*. Galimybė parodo, kiek kartų kintamasis Y labiau tikėtina įgis reikšmę j nei reikšmę m . Aišku, kad galimybių yra viena mažiau nei Y kategorijų.

Galimybių santykis parodo, kiek kartų pasikeis tikimybių santykis (galimybė), kai atitinkamas kintamasis padidės vienetu, fiksavus kitų kintamųjų reikšmes. Praktiškai galimybių santykiai

skaičiuojami tik lyginant su kontroline kategorija. Statistinės programos dažniausiai kiekvienam kintamajam pateikia ne tik patį galimybių santykio įvertį, bet ir šio santykio 95 % pasikliautinąjį intervalą.

Tarkime, kad kontrolinė kategorija yra $Y = 3$, ir tiriame $\hat{P}(Y = 1) / \hat{P}(Y = 3)$. Kai regresorius X padidėja vienetu, ankstesnis tikimybių santykis pasikeičia $e^{\hat{b}_{11}}$ karto.

Skaičius $e^{\hat{b}_{11}}$ yra galimybių santykis galimybei $\hat{P}(Y=1) / \hat{P}(Y=3)$.

$$\left(\frac{\hat{P}(Y = 1)}{\hat{P}(Y = 3)} \right)_{nauja} = e^{\hat{b}_{11}} \left(\frac{\hat{P}(Y = 1)}{\hat{P}(Y = 3)} \right)_{ankstesnė}$$

Šioje išraiškoje nauja galimybė – tai galimybė (tikimybių santykis), kai regresorius X padidėja vienetu.

Pavyzdys. Tarkime, kad tiriame respondentus, kurių abudu tėvai sirgo diabetu, Y žymi respondento sveikatos būseną: $Y = 1$ (pirmo tipo diabetas), $Y = 2$ (antro tipo diabetas), $Y = 3$ (sveikas). Tegul $Y = 3$ yra kontrolinė kategorija. Tarkime, kad vienas iš regresorių yra kūno masės indeksas. Jeigu galimybių santykis galimybei $\hat{P}(Y = 1) / \hat{P}(Y = 3)$ yra 1,2, tai reikš, kad kūno masės indekso padidėjimas padidina galimybę susirgti pirmos rūšies diabetu 1,2 karto. Analogiškai interpretuojamas galimybių santykis modeliui $\hat{P}(Y = 2) / \hat{P}(Y = 3)$.

Nors galimybių santykiai ir rodo regresorių svarbą, bendriausiu atveju jie neleidžia nustatyti, kurie regresoriai modelyje turi didžiausią įtaką. Daugianarėje logistinėje regresijoje tokių rodiklių (tiesinės regresijos standartizuotųjų beta koeficientų analogų) apskritai nėra. Jeigu regresoriai palyginami pagal savo reikšmes (nelyginame tonų su metais), tai gal ir galima kalbėti apie regresorių svarbą *daliniuose* modeliuose. Tada tiesiog reikia prisiminti dvinarės logistinės regresijos galimybių santykių interpretacijas (žr. 4.1.2 skyrelį).

5.1.4. Duomenys

Duomenys turi tenkinti tokius reikalavimus:

- Priklausomas kintamasis Y kategorinis, regresoriai – intervaliniai arba kategoriniai. Visi kategoriniai regresoriai keičiami dvireikšmių (0 ir 1) regresorių rinkiniu. SPSS, STATA, SAS, R programos tą daro automatiškai (nurodžius atitinkamas parinktis). Primename, kad ranginis kintamasis, kurio galimų skirtingų reikšmių (kategorijų) aibė yra maža (pvz.,

mažiau nei 5 reikšmės), taip pat traktuotinas kaip kategorinis. Jis taip pat keičiamas dvireikšmių regresorių rinkiniu.

- Intervaliniai regresoriai neturi stipriai koreliuoti.
- Duomenyse negali kažkurių Y reikšmių būti labai mažai. Reikia turėti pakankamai informacijos apie įvairių kategorijų respondentus. Tai kiek gi stebinių turi tekti kiekvienai Y kategorijai? Griežtos instrukcijos nėra. Idealiu atveju visų kategorijų stebinių yra po lygiai. Žiūrint į turimą imtį, tenka patiems apsispręsti, ar nuokrypiai nuo idealios imties struktūros yra maži. Jeigu Y turi 3–4 kategorijas, imtyje kiekvienos kategorijos stebiniai turėtų sudaryti bent 15–20 % visų stebinių. Jeigu Y turi 5–6 kategorijas, imtyje kiekvienos kategorijos stebiniai turėtų sudaryti bent 10–15 % visų stebinių. Šio el. vadovėlio autoriams neteko matyti, kad daugianarė logistinė regresija būtų taikoma, kai Y įgyja daugiau nei 6 skirtingas reikšmes.
- Jeigu modelyje yra kategorinių regresorių, reikalaujama, kad kiekvienam jų reikšmių deriniui būtų bent keli Y stebiniai. Pavyzdžiui, jeigu regresoriai X ir Z įgyja tik dvi reikšmes (0 ir 1), imtyje turi būti Y stebinių, kai $(X = 0, Z = 0)$, kai $(X = 0, Z = 1)$, kai $(X = 1, Z = 0)$, kai $(X = 1, Z = 1)$. Dažnai šis reikalavimas keičiamas švelnesniu – turi būti ne daugiau kaip 5 % kategorinių regresorių reikšmių derinių, kuriems neturima Y stebinių. Intervaliniams regresoriams tokio reikalavimo nekeliamo.

5.1.5. Modelio tinkamumas

Modelio tinkamumas nustatomas atsižvelgus į keletą rodiklių. Svarbiausi yra šie:

- a) *Klasifikacinė lentelė.* Tai viena iš svarbiausių modelio tinkamumo duomenims charakteristikų. Jeigu sudarėme logistinės regresijos modelį duomenims, kuriems žinomos Y reikšmės, natūralu pasitikrinti, ar klasifikavimas tinkamas. Konkretiems stebiniams prognozuojama Y reikšmė ir žiūrima, ar spėjimas sutapo su tikrąja Y reikšme. Kuo daugiau sutapčių, tuo modelis geresnis. Įprasta reikalauti, kad teisingai klasifikuojamų kiekvienos kategorijos stebinių procentas būtų ne mažesnis nei tos kategorijos procentas tarp Y reikšmių. Kodėl? Logika čia tokia: tarkime, visą laiką spėjame, kad $Y = 1$. Teisingų sprendimų bus toks procentas, kokį tarp visų Y reikšmių sudaro vienetai. Modelis turėtų užtikrinti neblogesnį klasifikavimą.

- b) *Tikėtinumų santykio kriterijus*. Parodo, ar modelyje yra bent vienas reikalingas (reikšmingas) regresorius. Jeigu p reikšmė didesnė už 0,05, regresijos modelio tinkamumas labai abejotinas.
- c) *Pirsono ir deviacijos chi kvadrato kriterijai*. Tai tikėtinumų santykio kriterijaus alternatyvos. Modelis tinka duomenims, kai Pirsono ir deviacijos chi kvadratų kriterijų $p \geq 0,05$. Kai modelyje yra intervalinių regresorių, Pirsono ir deviacijos chi kvadrato statistikos taikomos retai.
- d) *Regresorių tikėtinumų santykio kriterijai*. Padeda nuspręsti, ar regresorius šalintinas iš modelio. Jeigu p reikšmė $< 0,05$, sakome, kad *regresorius yra statistiškai reikšmingas*, ir dažniausiai jį modelyje paliekame. Jeigu p reikšmė $\geq 0,05$, regresorius yra statistiškai nereikšmingas ir modelyje jis paliekamas tik ypatingais atvejais (kai be to regresoriaus labai suprastėja teisingų klasifikavimų procentas).
- e) *Voldo kriterijai*. Pirmiau buvo parodyta, kad daugianarės logistinės regresijos matematinį modelį sudaro daug dalinių modelių, skirtų visoms Y kategorijoms, išskyrus kontrolinę kategoriją. Voldo kriterijus taikomas kiekvienam iš šių dalinių modelių (submodelių). Jis padeda nustatyti, kurie regresoriai statistiškai reikšmingi tuose daliniuose modeliuose (jiems $p < 0,05$). Pavyzdžiui, gali būti, kad modelyje, skirtame santykiui $P(Y = 1)/P(Y = 4)$, regresorius X bus statistiškai reikšmingas, o modelyje, skirtame santykiui $P(Y = 3)/P(Y = 4)$, regresorius X bus statistiškai nereikšmingas. Tai leis padaryti išvadą, kad regresorius X labiau skiria $Y = 1$ nuo $Y = 4$ nei $Y = 3$ nuo $Y = 4$. Manoma, kad Voldo kriterijus yra silpnesnis už tikėtinumų santykio kriterijų. Todėl, darant išvadas apie bendrąjį kintamųjų statistinį reikšmingumą, reikėtų remtis ankstesniu punktu.
- f) *Determinacijos (pseudo) koeficientai*⁶¹. Parodo bendrąjį modelio tikimą. Įgyja reikšmes iš intervalo $[0, 1]$. Kuo reikšmė didesnė, tuo modelis geriau tinka duomenims. Nelabai gerai, kai $R^2 < 0,20$. Daugianarėje logistinėje regresijoje nėra tikslaus tiesinės regresijos determinacijos koeficiento analogo. Vietoj jo vartojami determinacijos pseudokoeficientai, kurie tik pagalbiniai. Koeficientų yra net keli: Kokso–Snello, Nagelkerkės, Makfadeno. Kurį iš jų naudoti, pasirenka tyrėjas (pavyzdžiui, STATA naudoja Makfadeno). Aprašant rezultatus, privalu nurodyti tikslų determinacijos koeficiento pavadinimą.

⁶¹ Angl. *pseudo R square*.

5.1.6. Daugianarės logistinės regresinės analizės etapai

Išsami modelio analizė susideda iš tokių etapų:

- 1) Patikriname, ar modelio tikėtinumų santykio kriterijaus p reikšmė $< 0,05$. Jeigu $p \geq 0,05$, – modelis netinkamas.
- 2) Patikriname, ar visi regresoriai statistiškai reikšmingi (visos tikėtinumų santykių kriterijų p reikšmės $< 0,05$). Jeigu ne – modelis taisytinas.
- 3) Pažiūrėję į galimybių santykių įverčius, nustatome, kaip regresorių pokyčiai veikia konkrečios Y reikšmės įgijimo tikimybę, lyginant ją su kontrolinės kategorijos įgijimo tikimybe.
- 4) Peržiūrime, ar pakankamai daug teisingų klasifikavimų klasifikacinėje lentelėje. Jeigu nedaug – modelis netinkamas.
- 5) Papildomai galima ištirti, ar deviacijos kriterijaus p reikšmė $\geq 0,05$ (taip turi būti geruose modeliuose, kuriuose nedaug intervalinių regresorių). Su Voldo kriterijumi patikriname, ar daliniuose modeliuose visi regresoriai statistiškai reikšmingi, t. y. ar jų p reikšmės $< 0,05$. Konstantos statistinio reikšmingumo netiriame.
- 6) Jeigu viskas gerai – modelį aprašome. Jeigu ne – tobuliname.

Gera duomenims tinkamo modelio:

- Tikėtinumų santykio kriterijaus $p < 0,05$.
- Visiems regresoriams tikėtinumų santykių kriterijų $p < 0,05$.
- Daliniuose modeliuose daugumai regresorių Voldo kriterijų $p < 0,05$.
- Teisingai klasifikuojama kiekvienos kategorijos stebinių procentas ne mažesnis nei tos kategorijos procentas tarp Y reikšmių.
- Jeigu imtis nėra didelė ir visiems įmanomiems regresorių reikšmių deriniams yra pakankamai daug Y stebinių (nulinis dažnis turi ne daugiau kaip 5 % langelių), deviacijos ir Pirsono chi kvadrato kriterijų p reikšmės $\geq 0,05$.
- Visų stebinių Kuko matai ≤ 1 .
- Pasirinktas determinacijos koeficientas $\geq 0,20$.

5.1.7. Modelio tobulinimas

Modelio tobulinimas dažniausiai reiškia regresorių šalinimą arba jų transformavimą.


Pašalinus bent vieną regresorių, keičiasi visos modelio charakteristikos: determinacijos koeficientai, visos p reikšmės, klasifikacinė lentelė.

Reikia nepamiršti, kad ne visada pavyksta sudaryti duomenims tinkamą modelį. Yra duomenų, kuriems logistinė regresija (o dažnai ir jokia kita regresija) tiesiog netinka. Modelis tobulinamas, jeigu yra problemų:

- *Yra statistiškai nereikšmingas regresorius* (jo tikėtinumų santykio kriterijaus p reikšmė didesnė už 0,05). Tada šis regresorius pašalinamas iš modelio, ir logistinė regresinė analizė pakartojama be jo. Viskas gerai, jeigu klasifikacinėje lentelėje teisingai klasifikuotų atvejų sumažėjo nedaug. Pristatydami galutinį modelį, tada rašysime, kad modelyje liko tik statistiškai reikšmingi regresoriai. Jeigu teisingai klasifikuotų atvejų sumažėja radikaliai, regresorių į modelį grąžiname, o aprašyme konstatuojame, kad „regresorius buvo statistiškai nereikšmingas. Vis dėlto jis paliktas modelyje, nes be jo labai sumažėja teisingų klasifikavimų procentas“.
- *Yra multikolinearumo problema*. Faktiškai ši problema susideda iš dviejų dalių – priežasties nustatymo ir jos pašalinimo. Multikolinearumą įtarsime tik tada, jeigu modelyje atsirastų „keistas“ (mums visai nelauktas) regresoriaus koeficiento ženklas. Tada galima atskirai apskaičiuoti ir peržiūrėti intervalinių regresorių koreliacijas. Jeigu kažkurie regresoriai stipriai koreliuoja, derėtų modelyje palikti tik kelis iš jų arba juos pakeisti jų vidurkiu. Žinoma, tik tada, kai tas vidurkis yra prasmingas, t. y. nesudėjome metų su kilogramais. Galima sudaryti atskiras daugianares logistines regresijas kiekvienam regresoriui. Tada bent išsiaiškinsime, kokie turi būti modelio koeficientų ženklai. O paskui vis tiek pradėsime šalinti iš modelio regresorius arba sugalvojame, kuo juos pakeisti. Daugianarėje logistinėje regresijoje multikolinearumas tikrinamas labai retai.

5.1.8. Pastabos apie daugianarės regresijos taikymą

- Kontrolinė Y reikšmė dažniausiai yra ta, kuri tyrėjui atrodo svarbiausia.
- Aprašymuose dažnai apsiribojama bendruoju teisingų klasifikavimų procentu. Tai nėra blogai. Tik reikia nepamiršti, kad modelis turi *gerai atpažinti visas Y kategorijas*. Tyrėjas sprendžia, kurios kategorijos atpažinimas yra svarbiausias.
- Tyrimuose dar taikomos žingsninės logistinės regresijos modeliai, kai modelyje automatiškai paliekami patys statistiškai reikšmingiausi iš pradinių regresorių.
- Jeigu kitos charakteristikos geros, bet netikęs teisingai klasifikuotų atvejų procentas, modelis vis tiek nelaikomas geru.
- Gali būti ir vienas regresorius.
- Kartais šio skyrelio daugianarė logistinė regresija dar vadinama **nominaliąja daugianare logistine regresija**, skiriant ją nuo ranginės daugianarės logistinės regresijos.
- Pseudokintamieji aprašomi taip pat kaip ir tiesinėje regresijoje.
- Galima modelio tinkamumą įvertinti ir naudojant informacinius indeksus (kriterijus), pavyzdžiui, Akaikės informacinį kriterijų AIC. Gero modelio AIC yra daug mažesnis už AIC modelio be regresorių (tik su konstanta). Vis dėlto apsiriboti informaciniais indeksais nederėtų, nes *geresnis nei visai blogas* dar nereiškia *geras* (palyginti su žmogžudžiais–maniakais, kaltinamasis dar visai doras).



5.1.9. Standartiniai daugianarės logistinės regresijos modelių aprašymai

Visada aprašomas galutinis, po visų tobulinimų gautas modelis. Pateiksime keletą galimų aprašymų fragmentų.

- *Taikytas daugianarės logistinės regresijos modelis duomenims tiko. Modelio tikėtinumų santykio kriterijaus $\chi^2=23,27$; $p < 0,05$. Visi regresoriai buvo statistiškai reikšmingi.*

Teisingai klasifikuota 80,3 % imties respondentų. Nagelgerkės determinacijos koeficientas lygus 0.69.

- Iš modelio buvo pašalintas statistiškai nereikšmingas regresorius X . Galutinis modelis buvo statistiškai reikšmingas, $\chi^2 = 45,2$; $p < 0,01$. Taikant modelį imties duomenims, teisingai klasifikuoti 73 % pirmos rūšies diabetu sergantys pacientai, 65 % antros rūšies diabetu sergantys respondentai ir 80 % sveikų respondentų. Makfadeno determinacijos koeficientas $R^2 = 0,70$. Regresoriui W padidėjus vienetu, galimybių santykis susirgti pirmos rūšies diabetu padidėja 1,5 karto.
- Modelyje paliktas statistiškai nereikšmingas regresorius Z , nes jį pašalinus labai sumažėja teisingai klasifikuotų atvejų procentas...

5.2. Daugianarė logistinė regresinė analizė su SPSS

5.2.1. Duomenys

Kaip atlikti daugianarę logistinę regresinę analizę parodysime tirdami 2008 metų Europos Sąjungos socialinio tyrimo (*European Social Survey*) Čekijos, Izraelio ir Švedijos duomenis **ESS4CZ**, **ESS4IL**, **ESS4SE**. Tyrime naudosime tokius kintamuosius:

- *cntry* – šalies kodas (CZ – Čekija, IL – Izraelis, SE – Švedija),
- *stfedu* – respondento požiūris į savo šalies švietimo sistemos būklę (reikšmės nuo 0 – itin bloga, iki 10 – itin gera);
- *imscbln* – nuo kada imigrantai gali visiškai naudotis šalies socialinėmis lengvatomis (matuojamas nominalia skale: 1 – iškart po atvykimo, 2 – po vienerių metų, neatsižvelgiant į tai, ar dirbo, 3 – po vienerių darbo ir mokesčių mokėjimo metų, 4 – tapę piliečiais, 5 – niekada negalės naudotis visomis lengvatomis);
- *trstprl* – pasitikėjimas savo šalies parlamentu (matuojamas 10 balų skale nuo 0 – itin nepasitikiu, iki 9 – itin pasitikiu);
- *pray* – kaip dažnai meldžiamasi (matuojamas 7 balų skale nuo 1 – kasdien iki 7 – niekada),
- *hhmmb* – nuolat kartu gyvenančių namų ūkio narių skaičius.

Bandysime nustatyti, ar išvardinti kintamieji padeda apibūdinti respondento šalį. Tirsime 20–30 metų vyrus. Duomenų atrankai naudosime kintamuosius *agea* (amžius) ir *gnr* (lytis, 1 – vyr., 2 – mot.).

Visus duomenų failus sujungsime į vieną. Atsidarome ESS4CZ ir renkamės **Data → Merge Files → Add Cases**. Atsidariusiame lange renkamės **Browse**, nurodome failą ESS4IL ir spaudžiame **Continue**. Atsidariusiame lange spaudžiame **OK**. Viską pakartojame prijungdami failą ESS4SE.

Peržiūrėję kintamojo *imsclbn* įgyjamų reikšmių dažnius, įsitikiname, kad Čekijoje labai nedidelis procentas respondentų renka atsakymų reikšmes 1, 2 ir 5. Todėl kintamąjį *imsclbn*, keisime dvireikšmiu kintamuoju *imigrantbf* (*imigrantbf* = 0, kai *imsclbn* ≤ 3 ir *imigrantbf* = 1, kai *imsclbn* ≥ 4). Pasirenkame **Transform → Recode into Different Variables** ir perkeliame *imsclbn* į dešinį laukelį. Laukelyje **Name** užrašome *imigrantbf* ir spaudžiame **Change**. Pasirenkame **Old and New Value**. Naudodami **Old value – New Value – Add** parinktis nurodome, kaip turi atrodyti naujasis regresorius (1 to 3 → 0, 4 to 5 → 1). Paskui spaudžiame **Continue** ir **OK**. Norėdami paaiškinti naujo kintamojo prasmę, papildomai (**Variable View–Value Labels**) pridedame kintamojo reikšmių komentarus (0 – teigiamas požiūris, 1 – neigiamas požiūris).


Reikiamus respondentus atrenkame naudodami **Select Cases** (atrankos sąlyga: *agea* ≤ 30 & *agea* ≥ 20 & *gnr* = 1).

5.2.2. SPSS parinktys daugianarei logistinei regresijai

Tirsime modelį, kurį sąlygiškai galima užrašyti taip:


$$cntry = f(imigrantbf, pray, stfedu, trstprl, hhmmb)^{62}.$$

Atsidarome langelį **Analyze** ir renkamės **Regression → Multinomial Logistic**.




Atsidariusiame meniu perkeliame kintamąjį *cntry* į laukelį **Dependent**. Kintamuosius *pray*, *stfedu*, *trstprl*, *hhmmb* įkeliamo į laukelį **Covariates**. Kintamasis *imigrantbf* yra kategorinis, todėl jį keliame į **Factor(s)**.

⁶² Modelio tiksli išraiška pateikiama aprašant rezultatus



Pagal nutylėjimą SPSS programoje kontroline priklausomo kintamojo kategorija tampa ta, kurios kodas yra didžiausias. Kintamasis *cntry* simbolinis, surikiavus jo reikšmes pagal abėcėlę, kontroline valstybe taps Švedija. **Kontrolinė kategorija – ta kategorija, su kuria lyginsime visas likusias.** Ką pasirinkti kontroline kategorija, yra paties tyrėjo reikalas (kaip tą padaryti, žr. toliau). Kiekvieną valstybę lyginsime su Švedija ir tai atspindės išvadosė.

Spaudžiame klavišą **Statistics** ir papildomai pažymime **Goodness-of-fit** ir **Classification table**. Visas kitas pagal nutylėjimą pažymėtas parinktis paliekame ramybėje.



5.2.3. Rezultatai

Rezultatų išklotinė prasideda įspėjimu, kad 899 (65 %) langelių turi nulinius dažnius.

Warnings

There are 899 (65.0%) cells (i.e., dependent variable levels by subpopulations) with zero frequencies.

Nesigilinant į detales galima pasakyti, kad tai įspėjimas jog Pirsono ir deviacijos kriterijai **šiam modeliui netaikytini**. Tiesiog buvo sudaryti visų įmanomų regresorių reikšmių deriniai ir patikrinta, ar jiems yra pakankamai *cntry* reikšmių. Pirsono ir deviacijos kriterijai taikytini tik tada, kai nulinius dažnius turi mažai (pvz., ne daugiau kaip 5 %) regresorių reikšmių derinių. Kai modelyje yra bent keli intervaliniai regresoriai, tokia situacija yra reta. Taigi, spręsdami, ar modelis tinkamas duomenims, Pirsono ir deviacijos kriterijus ignoruosime. Beje, žemiau suradę lentelę **Goodness-of-Fit**, galime įsitikinti abiejų kriterijų neadekvačiu elgesiu: Pirsono kriterijaus *p* reikšmė lygi nuliui (modelis duomenims absoliučiai netinka), o deviacijos kriterijaus *p* reikšmė lygi vienetui (modelis duomenims absoliučiai tinka).

Goodness-of-Fit

	Chi-Square	df	Sig.
Pearson	1072.259	910	.000
Deviance	611.343	910	1.000

Lentelėje **Case Processing Summary** pateikiama informacija apie kategorinių kintamųjų reikšmes. Žinome, kad nė viena kategorija neturi labai stipriai dominuoti. Įsitikiname, kad taip ir yra: imtyje yra 158 Čekijos gyventojai, 221 izraelietis ir 142 Švedijos gyventojai. Iš tirtųjų respondentų palankią nuomonę apie socialines lengvatas imigrantams pareiškė apie pusę.

Case Processing Summary

		N	Marginal Percentage
cntry Country	CZ Czech Republic	158	30.3%
	IL Israel	221	42.4%
	SE Sweden	142	27.3%
imigrantbf Social benefits for immigrants	.00 positive attitude	283	54.3%
	1.00 negative attitude	238	45.7%
Valid		521	100.0%
Missing		71	
Total		592	
Subpopulation		461 ^a	

Lentelė **Case Processing Summary** dar naudojama sprendžiant apie klasifikavimo gerumą. Klasifikacinėje lentelėje teisingų klasifikavimų procentas turi būti ne mažesnis nei jų procentas imtyje (šie procentai yra lentelėje **Case Processing Summary** stulpelyje **Marginal Percentage**). Logika čia tokia: jeigu užsimerksime ir apie kiekvieną respondentą sakysime „švedas“, tai teisingai klasifikuosime 27,3 % respondentų. Tinkamas diaugianarės logitinės regresijos modelis turi duoti didesnę švedų atpažinimo procentą. Pačiame rezultatu išklotinės gale yra klasifikacinė lentelė:

Classification				
Observed	Predicted			
	CZ Czech Republic	IL Israel	SE Sweden	Percent Correct
CZ Czech Republic	111	23	24	70.3%
IL Israel	23	177	21	80.1%
SE Sweden	27	19	96	67.6%
Overall Percentage	30.9%	42.0%	27.1%	73.7%

Iš jos plaukia, kad, taikydami daugianarės logistinės regresijos modelį, teisingai atpažinome (klasifikavome) 70,3 % Čekijos gyventojų, 80,1 % izraeliečių ir 67,6 % Švedijos gyventojų. Taigi gavome vieną svarbiausių modelio tinkamumo patvirtinimo įrodymų. Trumpai aptarsime kitus lentelės **Classification** skaičius. Pirmoje eilutėje parašyta, kad iš visų imties Čekijos atstovų, modelis teisingai atpažino 111, klaidingai 23 Čekijos respondentus palaikė izraeliečiais, o 24 – Švedijos gyventojais. Analogiškai interpretuojamos likusios eilutės. Bendras teisingai klasifikuotų imties respondentų procentas 73,7.

Lentelėje **Pseudo R-Square** yra determinacijos pseudokoefficientai. Kaip ir dvinarėje logistinėje regresijoje, jie nėra svarbūs. Vis dėlto koeficientai turėtų būti nelabai maži. Pavyzdžiui, jie turėtų būti ne mažesni už 0,20 (ar bent nedaug mažesni). Paprastai modelio aprašyme cituojamas tik vienas determinacijos pseudokoefficientas (kuris – tyrėjo įgeidis). Pavyzdžiui, šiuo atveju galima konstatuoti, kad „gerą modelio tikimą duomenims rodo ir pakankamai didelis Nagelkerkės determinacijos pseudokoefficientas $R^2 = 0,65$ “.

Pseudo R-Square	
Cox and Snell	.575
Nagelkerke	.650
McFadden	.397

Modelio tikimo tikėtinumų santykio kriterijaus p reikšmė yra lentelės **Model Fitting Information Sig.** stulpelyje. Darome išvadą, kad modelis duomenims tinka (bent vienas regresorius modelyje reikalingas), nes $p = 0,000 < 0,05$.

Model Fitting Information				
	Model Fitting Criteria	Likelihood Ratio Tests		
Model	-2 Log Likelihood	Chi-Square	df	Sig.
Intercept Only	1090.376			
Final	644.039	446.337	10	.000

Kurie regresoriai modelyje reikalingi, sprendžiama iš lentelės **Likelihood Ratio Tests**. Joje yra tikėtinumų santykių kriterijų rezultatai regresoriams ir konstantai. Jeigu p reikšmė (jos visos yra stulpelyje **Sig.**) yra mažesnė už 0,05, sakysime, kad regresorius statistiškai reikšmingas. Toks regresorius dažniausiai modelyje paliekamas. Jeigu modelyje būtų statistiškai nereikšmingų regresorių, juos reikėtų pabandyti iš modelio pašalinti. Pašalinus bent vieną regresorių, visa analizė pradedama iš pradžių, nes keičiasi ir klasifikacinė lentelė, ir visos p reikšmės. Regresorių galima šalinti iš modelio, jeigu teisingų klasifikavimų procentas keičiasi nedaug. Mūsų nagrinėjamo pavyzdžio visi regresoriai yra statistiškai reikšmingi. Tai dar vienas įrodymas, kad modelis tinka.

Likelihood Ratio Tests				
	Model Fitting Criteria	Likelihood Ratio Tests		
Effect	-2 Log Likelihood of Reduced Model	Chi-Square	df	Sig.
Intercept	644.039	.000	0	.
pray	713.761	69.722	2	.000
stfedu	771.837	127.798	2	.000
trstprl	723.584	79.545	2	.000
hhmmb	706.825	62.786	2	.000
imigrantbf	663.956	19.917	2	.000

Lentelėje **Parameter Estimates** yra informacijos apie dalinius modelius (submodelius), kai kiekviena kategorija lyginama su kontroline.

Parameter Estimates									
cntry Country ^a		B	Std. Error	Wald	df	Sig.	Exp(B)	95 % Confidence Interval for Exp(B)	
								Lower Bound	Upper Bound
CZ Czech Republic	Intercept	.502	.977	.263	1	.608			
	pray	.011	.122	.008	1	.927	1.011	.796	1.284
	stfedu	.299	.069	18.908	1	.000	1.348	1.178	1.543
	trstprl	-.487	.062	61.777	1	.000	.614	.544	.694
	hhmmb	.216	.105	4.252	1	.039	1.241	1.011	1.524
	[imigrantbf=.00]	-1.212	.281	18.661	1	.000	.298	.172	.516
	[imigrantbf=1.00]	0 ^b	.	.	0	.	.	.	.
IL Israel	Intercept	5.077	.877	33.477	1	.000			
	pray	-.573	.108	28.098	1	.000	.564	.456	.697
	stfedu	-.379	.072	27.700	1	.000	.685	.595	.789
	trstprl	-.250	.065	14.987	1	.000	.779	.686	.884
	hhmmb	.704	.106	43.903	1	.000	2.023	1.642	2.491
	[imigrantbf=.00]	-.821	.306	7.226	1	.007	.440	.242	.801
	[imigrantbf=1.00]	0 ^b	.	.	0	.	.	.	.

a. The reference category is: SE Sweden.

b. This parameter is set to zero because it is redundant.

Viršutinė lentelės dalis yra skirta palyginti tikimybę, kad respondentas yra iš Čekijos, su tikimybe, kad jis – iš Švedijos. Visų pirma peržvelgę Voldo kriterijaus p reikšmės (konstantai p reikšmės nežiūrime), įsitikiname, kad regresorius *pray* yra statistiškai nereikšmingas. Darome išvadą, kad maldingumo laipsnis nėra reikšmingas faktorius, padedantis atskirti Čekijos gyventojus nuo Švedijos gyventojų. Ar reikia bandyti iš modelio šalinti regresorių *pray*? Nesunku pastebėti, kad šis regresorius yra statistiškai reikšmingas antrame modelyje, t. y. padeda atskirti izraelietį nuo Švedijos gyventojų. Todėl tikėtina, kad apskritai modelyje regresorius *pray* reikalingas. Visi kiti regresoriai statistiškai reikšmingi. Pasižiūrėję į stulpelį B ir prisiminę, kaip koduojamos šalys, užrašome pirmąjį dalinį logistinį modelį taip:

$$\frac{\hat{P}(cntry = CZ)}{\hat{P}(cntry = SE)} = e^{z_1}.$$

Čia $z_1 = 0,502 + 0,011pray + 0,299stfedu - 0,487trstprl + 0,216hhmmb$

$$+ \begin{cases} 0, & \text{jei } imigrantbf = 1, \\ -1,212, & \text{jei } imigrantbf = 0. \end{cases}$$

Koeficientų ženklai rodo, kad, didėjant *stfedu* ir *hhmb* reikšmėms (respondentui išreiškiant didesnę pasitikėjimą švietimo sistema ir gyvenant didesnėje šeimoje), didėja tikimybė, kad jis iš Čekijos, o ne iš Švedijos. Didėjant pasitikėjimui parlamentu (*trstprl*), tikimybė, kad respondentas iš Čekijos, o ne iš Švedijos, mažėja. Galiausiai dviguba koeficiento *imigrantbf* reikšmė rodo, kad respondentui pareiškus palankesnę nuomonę apie socialines lengvatas imigrantams (*imigrantbf* = 0), tikimybė, kad jis iš Čekijos, o ne iš Švedijos, mažėja. Šią informaciją galima patikslinti, pateikiant galimybių santykių įverčius (stulpelis **Exp(B)**) kartu su jų pasikliautiniais intervalais (stulpelis **95 % Confidence Interval for Exp(B)**). Pavyzdžiui, galimybių santykio įvertis regresoriui *stfedu* yra 1,348 (95 % pasikliautinis intervalas 1,178 – 1,543). Tai reiškia, kad regresoriui *stfedu* padidėjus vienetu, tikimybių santykis $\hat{P}(cntry = CZ) / \hat{P}(cntry = SE)$ padidės 1,348 karto:

$$\left(\frac{\hat{P}(cntry = CZ)}{\hat{P}(cntry = SE)} \right)_{\text{kai } stfedu \text{ padidėja vienetu}} = 1,348 \left(\frac{\hat{P}(cntry = CZ)}{\hat{P}(cntry = SE)} \right)_{senas}$$

Analogiškai interpretuojami visi likę galimybių santykiai.

Visiškai analogiškai ištiriamas antrasis lentelės **Parameter Estimates** modelis, skirtas Izraelio ir Švedijos lyginimui. Gauname

$$\frac{\hat{P}(cntry = IL)}{\hat{P}(cntry = SE)} = e^{z_2},$$

$$\begin{aligned} \text{Čia } z_2 = & 5,077 - 0,573pray - 0,379stfedu - 0,25trstprl + 0,704hhmb \\ & + \begin{cases} 0, & \text{jei } imigrantbf = 1, \\ -0,821, & \text{jei } imigrantbf = 0. \end{cases} \end{aligned}$$

Parametrų ženklai ir galimybių santykiai aptariami analogiškai Čekijos ir Švedijos modeliui.

5.2.4. Prognozavimas

Prognozės atliekamos tik esant poreikiui. Atitinkamos tikimybės skaičiuojamos pagal formules pateiktas ankstesniame skyrelyje. Pateiksime vieną pavyzdį. Tarkime, kad respondentas pasirinko tokius atsakymus: *pray* = 2, *stfedu* = 4, *trstprl* = 5, *hhmb* = 4, *imigrantbf* = 1. Įvertinsime tikimybes, kad jis iš Čekijos (Izraelio, Švedijos). Pirmiausia pagal pirmiau pateiktas formules surandame z_1 ir z_2 :

$$z_1 = 0,502 + 0,011 * 2 + 0,299 * 4 - 0,487 * 5 + 0,216 * 4 + 0 = 0,149,$$

$$z_2 = 5,077 - 0,573 * 2 - 0,379 * 4 - 0,25 * 5 + 0,704 * 4 + 0 = 3,981.$$

Tada apskaičiuojame (primename, kad $e = 2,71828...$)

$$e^{z_1} = 1,160 \dots, \quad e^{z_2} = 53,570, \quad e^{z_1} + e^{z_2} = 54,73.$$

Beliko įvertinti tikimybes:

$$\hat{P}(\text{cntry} = \text{SE}) = \frac{1}{1 + 54,73} = 0,01794 \dots, \quad \hat{P}(\text{cntry} = \text{CZ}) = \frac{1,16}{1 + 54,73} = 0,0208 \dots$$

$$\hat{P}(\text{cntry} = \text{IL}) = \frac{53,57}{1 + 54,73} = 0,9612..$$

Matome, kad labai didelė tikimybė, jog atsakinėjo izraelietis.

5.2.5. Rezultatų aprašymas

Tikėjomės, kad požiūris į šalies švietimo būseną, imigrantus, parlamentą ir pamaldumas gerai apibūdina respondento šalį. Šis spėjimas pasitvirtino. Pateikdami aprašymus, pirmiausia nurodome, ką tyrėme, kokius kintamuosius naudojome ir kaip juos perkodavome. Tada tiesiog kompaktiškai surašome visa tai, ką išsamiai aptarėme ankstesniame skyrelyje. Pateikiame vieną iš daugybės galimų tokio aprašymo variantų.

Taikėme daugianarę logistinę regresiją. Kontrolinė kategorija pasirinkome Švediją – visuotinės socialinės gerovės šalį. Modelis gerai tiko duomenims. Buvo teisingai klasifikuota 70,3 % Čekijos, 80,1 % Izraelio ir 67,6 % Švedijos gyventojų. Bendras teisingai klasifikuotų imties respondentų procentas 73,7%. Nagelkerkės determinacijos pseudokoeficientas $R^2 = 0,65$. Modelio tikėtinumų santykio kriterijaus statistika $\chi^2 = 446,337$, $p < 0,01$. Sprendžiant iš tikėtinumų santykių kriterijų, visi regresoriai yra statistiškai reikšmingi.

Pritaikius Voldo kriterijų, paaiškėjo, kad submodelyje, skirtame Izraelio ir Švedijos respondentų skirtumams, visi regresoriai (pray, stfedu, trsprl, hhmmb, imigrantbf) yra statistiškai reikšmingi. Tikimybių santykio logaritmo lygtis yra

$$\ln \frac{\hat{P}(\text{cntry} = \text{IL})}{\hat{P}(\text{cntry} = \text{SE})} = 5,077 - 0,573\text{pray} - 0,379\text{stfedu} - 0,25\text{trsprl} + 0,704\text{hhmmb}$$

$$+ \begin{cases} 0, & \text{jei imigrantbf} = 1 \\ -0,821, & \text{jei imigrantbf} = 0 \end{cases}$$

Matome, kad, mažėjant pamaldumui ir didėjant pasitikėjimui parlamentu bei švietimo sistema (didėjant pra, stfedu ir trsprl) ir esant teigiamam požiūriui į imigrantus, mažėja tikimybė, kad respondentas iš Izraelio, o ne iš Švedijos. O priklausymas didesnėms šeimoms (hhmmb) didina tikimybę, kad respondentas iš Izraelio, o ne iš Švedijos. Galimybių santykių įverčiai ir jų 95% pasikliautinieji intervalai yra tokie: kintamajam pray – 0,564 ([0,456; 0,697]), regresoriui stfedu – 0,685 ([0,595; 0,697]), regresoriui trsprl – 0,779 ([0,686; 0,884]), regresoriui hhmmb – 2,023 ([1,642; 2,491]). Lyginant su nepalankia nuomone apie imigrantus (imigrantbf = 1), palanki

nuomonė (imigrantbf = 0) sumažina galimybę, kad respondentas iš Izraelio, o ne iš Švedijos, 0,44 karto (95 % galimybių santykio pasikliautinis intervalas [0,242; 0,801]).

Pritaikius Voldo kriterijų, paaiškėjo, kad submodelyje, skirtame Čekijos ir Švedijos respondentų skirtumams, visi regresoriai, išskyrus pamaldumą (pray), yra statistiškai reikšmingi. Tikimybių santykio logaritmo lygtis yra

$$\ln \frac{\hat{P}(\text{cntry} = CZ)}{\hat{P}(\text{cntry} = SE)} = 0,502 + 0,011\text{pray} + 0,299\text{stfedu} - 0,487\text{trstprl} + 0,216\text{hhmmb} + \begin{cases} 0, & \text{jei imigrantbf} = 1, \\ -1,212, & \text{jei imigrantbf} = 0. \end{cases}$$

Matome, kad didėjant pasitikėjimui švietimo sistema ir gyvenant didesnėje šeimoje (didėjant hhmmb ir stfedu), didėja tikimybė, kad respondentas iš Čekijos, o ne iš Švedijos. O teigiamas požiūris į parlamentą ir į imigrantus tikimybė, kad respondentas iš Čekijos, o ne iš Švedijos, mažina. Galimybių santykių įverčiai ir jų 95 % pasikliautiniai intervalai yra tokie: regresoriui stfedu – 1,348 ([1,178; 1,543]), regresoriui trstprl – 0,614 ([0,544; 0,694]), regresoriui hhmmb – 1,241 ([1,011; 1,524]). Lyginant su nepalankia nuomone apie imigrantus (imigrantbf = 1), palanki nuomonė (imigrantbf = 0) sumažina galimybę, kad respondentas iš Čekijos, o ne iš Švedijos, 0,298 karto (95 % galimybių santykio pasikliautinis intervalas [0,172; 0,516]).

5.2.6. SPSS komandų sintaksė daugianarei logistinei regresinei analizei

Surašysime, kaip atrodo SPSS komandos nagrinėtajam daugianarės logistinės regresijos modeliui. Jas galima vykdyti sintaksės lange, pasirenkant **Run**.

Kintamojo *imigrantbf* kūrimas:

```
RECODE imsc1bn (1 thru 3=0) (4 thru 5=1) INTO imigrantbf.
EXECUTE.
```

Tinkamų respondentų atranka:

```
USE ALL.
COMPUTE filter_$=(agea >= 20 & agea <= 30 & gndr = 1).
VARIABLE LABELS filter_$ 'agea >= 20 & agea <= 30 & gndr = 1 (FILTER)'.
VALUE LABELS filter_$ 0 'Not Selected' 1 'Selected'.
```

FORMATS filter_\$ (f1.0).

FILTER BY filter_\$.

EXECUTE.

Daugianarė logistinė regresija:

```
NOMREG cntry (BASE=LAST ORDER=ASCENDING) WITH pray stfedu  
hhmmb trstprl
```

```
/CRITERIA CIN(95) DELTA(0) MXITER(100) MXSTEP(5)
```

```
CHKSEP(20) LCONVERGE(0) PCONVERGE(0.000001)
```

```
SINGULAR(0.00000001)
```

```
/MODEL
```

```
/STEPWISE=PIN(.05) POUT(0.1) MINEFFECT(0) RULE(SINGLE)
```

```
ENTRYMETHOD(LR) REMOVALMETHOD(LR)
```


```
/INTERCEPT=INCLUDE
```

```
/PRINT=CLASSTABLE FIT PARAMETER
```


```
SUMMARY LRT CPS STEP MFI.
```

5.2.7. Kitos kontrolinės kategorijos pasirinkimas

Jeigu norime lyginimams pasirinkti kitą priklausomo kintamojo kategoriją, reikia meniu **Multinomial Logistic Regression** paspausti klavišą **Reference Category**.



Atsidariusiame lange renkamės **Custom** ir langelyje **Value** nurodome norimą priklausomo kintamojo kodą. Pavyzdžiui, norėdami kitas valstybes lyginti su Izraeliu, rašome IL.




Beje, visų statistikų ir klasifikacinių lentelių reikšmės nepriklauso nuo kontrolinės kategorijos pasirinkimo. Keičiasi tik lentelė **Parameter Estimates**.

5.2.8. Kintamųjų sąveikos įtraukimas

Analogiškai dvinarei logistinei regresijai į modelį galima įtraukti ir regresorių sandaugas. Tada sakoma, kad modelyje buvo atsižvelgta į kintamųjų sąveiką. Tarkime, kad norime ištirti modelį, kurį sąlygiškai galime užrašyti taip:

$$cntry = f(imigrantbf, pray, stfedu, trstpri, hhmb, stfedu*trstpri).$$

Visos SPSS parinktys išlieka tokios pačios kaip ir pirminiame modelyje. Vienintelis skirtumas tas, kad pagrindiniame meniu pasirenkame **Model**. Atsidariusiame lange pažymime **Custom Stepwise** ir į langelį **Forced Entry Terms** sukeliame visus kintamuosius. Kintamųjų sandauga atsiras, kai kelsime *stfedu* ir *trstpri* kartu. Pasirenkame **Continue** ir **OK**.



Rezultatų išklotinėje matyti, kad regresorių sąveika statistiškai nereikšminga.

Likelihood Ratio Tests				
Effect	Model Fitting Criteria	Likelihood Ratio Tests		
	-2 Log Likelihood of Reduced Model	Chi-Square	df	Sig.
Intercept	641.201 ^a	.000	0	.
hhmmb	704.311	63.111	2	.000
imigrantbf	661.190	19.989	2	.000
pray	709.903	68.702	2	.000
stfedu	707.976	66.775	2	.000
trstprl	653.156	11.955	2	.003
stfedu * trstprl	644.039	2.838	2	.242

Beje, Voldo kriterijai abiem modeliams (su interakcija ir be interakcijos) tokie patys. Klasifikacinė lentelė taip pat nepagerėja. Darome išvadą, kad regresorių sąveika *stfedu*trstprl* modelyje nereikalinga.

5.2.9. Žingsninė daugianarė logistinė regresija


Kaip ir kituose regresijos modeliuose galima taikyti žingsninę (keliaetapę) regresiją ir leisti modelį tobulinti SPSS programai. Primename, kad tada modelis bus tobulinamas pagal formalius statistinius rodiklius. Gautas galutinis modelis bus statistiškai geriausias, bet nebūtinai geriausias tyrimo požiūriu. Yra keli žingsninės regresijos variantai – kai modelis vis pildomas naujais regresoriais arba kai jie iš modelio šalinami. Be to, žingsninę regresiją galima taikyti tik daliai regresorių, kuriais norime papildyti jau turimą modelį. Ją šiame skyrelyje ir aptarsime. Tarkime, kad į modelį (naudojame sąlyginį užrašą)

$$cntry = f(imigrantbf, pray, stfedu, hhmmb)$$

norime įtraukti kintamuosius

- *stfdem* (pasitenkinimas demokratijos lygiu šalyje),
- *stflife* (pasitenkinimas gyvenimu),
- *agea* (amžių).

Taikysime žingsninę regresiją. Visi meniu užpildomi kaip ir pirminio tyrimo atveju. Skirtumų atsiranda tik **Model** lange. Regresorius *imigrantbf*, *pray*, *stfedu*, *hhmml* perkeliame į lauką **Forced Entry Terms**. Šie regresoriai bus visuose modeliuose. Regresorius *stfdem*, *stflife*, *agea* perkeliame į langą **Stepwise Terms**. Šiais regresoriais modelis bus po truputį pildomas. Statistiškai nereikšmingi regresoriai į modelį nebus įtraukiami. Pasirenkame **Stepwise Method: Forward stepwise**.



Gautoje rezultatų išklotinėje atsirado lentelė **Step Summary**.

Step Summary						
Model	Action	Effect(s)	Model Fitting Criteria	Effect Selection Tests		
			-2 Log Likelihood	Chi-Square ^{a,b}	df	Sig.
Step 0 0	Entered	Intercept, imigrantbf, hhmb, pray, stfdeu	756.278	.		
Step 1 1	Entered	Stfdeu	708.037	48.241	2	.000
Step 2 2	Entered	Stflife	691.149	16.888	2	.000

Stepwise Method: Forward Stepwise

a. The chi-square for entry is based on the likelihood ratio test.

b. The chi-square for removal is based on the likelihood ratio test.

Lentelėje pažymėta, kad pradinis modelis su regresoriais *imigrantbf*, *pray*, *stfedu*, *hhmml* (Step 0) buvo pirmiausia papildytas regresoriumi *stfдем* (Step 1), o paskui – regresoriumi *stflife* (Step 2). Regresorius *agea* nepanaudotas. Tai reiškia, kad įtraukus *agea* į modelį, jis buvo statistiškai nereikšmingas. Galutinis sąlygiškai užrašytas modelis

$$cntry = f(imigrantbf, pray, stfedu, hhmml, stfдем, stflife).$$

Visos jo charakteristikos pateikiamos lentelėse, kurios nėra nesiskiria nuo aptartųjų skyrelyje 4.2.3. Beje, lange **Stepwise Terms** galima įrašyti ir regresorių sandaugas.

5.3. Daugianarė logistinė regresinė analizė su STATA

5.3.1. Duomenys

Failas **ZTLT**. Tyrimas: Lietuvos tolerancijos profiliai, 2003 m. Respondentai atsakė, koks jų požiūris (1 – teigiamas, 2 – neutralus, 3 – neigiamas, 4 – sunku pasakyti) į:

- *r01_01* – juodaodžius,
- *r01_02* – musulmonus,
- *r01_03* – žydus,
- *r01_04* – čigonus (romus),
- *r01_05* – migrantus,
- *r01_06* – pabėgėlius.

Norėsime ištirti, kaip požiūriui į romus turi įtakos požiūris į kitus nelietuvius. Visų pirma pasižiūrime, kiek kokių reikšmių šis kintamasis įgyja. Įvykdome komandą

tabulate r01_04			
grupes?	Freq.	Percent	Cum.
Teigiamas	147	14.08	14.08
Neutralus	402	38.51	52.59
Neigiamas	446	42.72	95.31
Sunku pasakyti	49	4.69	100.00
Total	1,044	100.00	

Matome, kad nuomonės neturėjo tik 4,69 % respondentų. Panaši situacija su atsakymais į kitus klausimus. Todėl iš tyrimo pašaliname visus respondentus, neturinčius nuomonės apie svetimtaučius:

```
keep if r01_01<=3 & r01_02 <=3 & r01_03 <=3 & r01_04 <=3 & r01_05 <=3 & r01_06 <=3
```

Sudėdami visus kintamuosius, išskyrus *r01_04*, sukuriame jungtinį kintamąjį *kiti*. Šis kintamasis rodo respondentų priešišumą visiems nelietuviams, išskyrus romus. Kuo didesnė kintamojo *kiti* reikšmė, tuo priešišumas yra didesnis:

```
gen kiti = r01_01+ r01_02 + r01_03+ r01_05+ r01_06
```

5.3.2. STATA parinktys

Tikrinsime modelį, kurį sąlygiškai galima užrašyti taip: $r01_04 = f(kiti)$. Kontrolinė kategorija pasirenkame reikšmę $r01_04 = 3$ (neigiamą požiūrį). Įvykdome

```
mlogit r01_04 kiti, base(3)
```

Multinomial logistic regression				Number of obs	=	863
				LR chi2(2)	=	478.10
				Prob > chi2	=	0.0000
Log likelihood = -640.75012				Pseudo R2	=	0.2717
r01_04	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
Teigiamas						
kiti	-1.28939	.0833927	-15.46	0.000	-1.452836	-1.125943
_cons	11.32658	.7826248	14.47	0.000	9.792668	12.8605
Neutralus						
kiti	-.4749833	.0498444	-9.53	0.000	-.5726766	-.37729
_cons	5.285512	.5570161	9.49	0.000	4.193781	6.377244
(r01_04==Neigiamas is the base outcome)						

Modelio tikimo tikėtinumų santykio kriterijaus p reikšmė yra, kai **Prob > chi2**. Darome išvadą, kad modelis duomenims tinka, nes $p = 0,000 < 0,05$. Pateiktasis (Makfadeno) determinacijos pseudokoefficientas nėra itin didelis $R^2 = 0,271$, bet jo vaidmuo nėra itin svarbus (ir jis vis tiek $> 0,20$). Voldo kriterijai ($P>|z|$) rodo, kad visuose submodeliuose regresoriai statistiškai reikšmingi. Užrašykime pirmąjį dalinį modelį:

$$\frac{\hat{P}(\text{Teigiamas})}{\hat{P}(\text{Neigiamas})} = e^{z_1}.$$

Čia $z_1 = 11,326 - 1,289kiti$.

Regresoriaus *kiti* koeficiento ženklas yra neigiamas. Todėl, didėjant *kiti* reikšmėms (respondentui išreiškiant didesnę priešišumą nelietuviams), didėja tikimybė, kad ir romų atžvilgiu jis nusistatęs neigiamai. Analogiškai galima sudaryti ir pakomentuoti antrąjį modelį:

$$\frac{\hat{P}(\text{Neutralus})}{\hat{P}(\text{Neigiamas})} = e^{z_2}.$$

Čia $z_2 = 5,285 - 0,7498\textit{kiti}$.

Norėdami gauti galimybių santykių įverčius, įvykdome:

mlogit r01_04 kiti, base(3) rrr

r01_04	RRR	Std. Err.	z	P> z	[95% Conf. Interval]	
Teigiamas kiti	.2754389	.0229696	-15.46	0.000	.2339059	.3243465
Neutralus kiti	.6218955	.030998	-9.53	0.000	.5640138	.6857172

(r01_04==Neigiamas is the base outcome)

Galimybių santykių įverčiai pateikti kartu su jų pasikliautiniais intervalais. Paimkime pirmąjį dalinį modelį. Galimybių santykio įvertis regresoriui *kiti* lygus 0,275 (95 % pasikliautinis intervalas 0,234 – 0,324). Tai reiškia, kad kintamajam *kiti* padidėjus vienetu, tikimybių santykis $P(\text{Teigiamas}) / P(\text{Neigiamas})$ padidės 0,275 karto (paprasčiau kalbant, sumažės $1/0,275 = 3,64$ karto:

$$\left(\frac{\hat{P}(\text{Teigiamas})}{\hat{P}(\text{Neigiamas})} \right)_{\text{kai } kiti \text{ padidėja vienetu}} = 0,275 \left(\frac{\hat{P}(\text{Teigiamas})}{\hat{P}(\text{Neigiamas})} \right)_{\text{senas}}$$

Analogiškai interpretuojamas ir antrojo galimybių santykio įvertis.

Norėdami pamatyti alternatyvius determinacijos koeficientus, Akaikės indeksą ir pan., įvykdome:

fitstat

Measures of Fit for mlogit of r01_04			
Log-Lik Intercept Only:	-879.802	Log-Lik Full Model:	-640.750
D(859):	1281.500	LR(2):	478.104
		Prob > LR:	0.000
McFadden's R2:	0.272	McFadden's Adj R2:	0.267
ML (Cox-Snell) R2:	0.425	Cragg-Uhler(Nagelkerke) R2:	0.489
Count R2:	0.673	Adj Count R2:	0.429
AIC:	1.494	AIC*n:	1289.500
BIC:	-4525.696	BIC':	-464.583
BIC used by Stata:	1308.542	AIC used by Stata:	1289.500

5.3.3. Prognozavimas

Prognozavimui patogiau naudoti `SPost` priedo komandą `prvalue`. Tarkime, kad norime padaryti `r01_04` prognozę respondentui, kurio `kiti = 10`. Įvykdome

```
prvalue, x(kiti=10)
```

Confidence intervals by delta method

		95% Conf. Interval	
Pr(y=Teigiamas x):	0.0715	[0.0485,	0.0946]
Pr(y=Neutralus x):	0.5857	[0.5426,	0.6288]
Pr(y=Neigiamas x):	0.3428	[0.3011,	0.3845]

kiti
x= 10

Jeigu regresorių būtų daugiau, nurodytume daugiau reikšmių.

5.3.4. Klasifikacinė lentelė

Tiesiogiai klasifikacinės lentelės gauti su STATA 10 negalima. Todėl ją sukursime, įdėję šiek tiek darbo. Visų pirma kiekvienam respondentui, taikydami logistinės regresijos modelį, sukuriame ir išsaugome visų kategorijų tikimybes:

```
predict pre1 pre2 pre3
```

Duomenyse atsirado trys nauji stulpeliai. Stulpelyje `pre1` kiekvienam respondentui suskaičiuota tikimybė, kad apie romus išreiškė teigiamą požiūrį. Analogiškai stulpelyje `pre2` yra tikimybės, kad požiūris buvo neutralus, o `pre3` – neigiamas. Sukuriame „tuščią“ stulpelį:

```
gen cat = 0
```

Dabar nuosekliai pakeičiame nulius į 1, kai labiausiai tikėtinas teigiamas požiūris. Po to pakeičiame nulius į 2, kai labiausiai tikėtinas neutralus požiūris, ir į 3, kai požiūris neigiamas.

```
replace cat = 1 if pre1>pre2 & pre1 > pre3  
replace cat = 2 if pre2>pre1 & pre2 > pre3  
replace cat = 3 if pre3>pre1 & pre3 > pre2
```

Suteikiame reikšmėms aiškinamuosius komentarus. Įvykdome:

```
label define nopsas 1 "Teigiamas" 2 "Neutralus" 3 "Neigiamas"  
label values cat nopsas
```

Dabar jau galime sudaryti klasifikacinę lentelę. Įvykdome:

```
tab r01_04 cat, row
```

Požiūris į žmones	cat			Total
	Teigiamas	Neutralus	Neigiamas	
Teigiamas	101 74.26	29 21.32	6 4.41	136 100.00
Neutralus	18 4.88	274 74.25	77 20.87	369 100.00
Neigiamas	12 3.35	140 39.11	206 57.54	358 100.00
Total	131 15.18	443 51.33	289 33.49	863 100.00

Matome, kad iš 136 respondentų, kurie pareiškė teigiamą požiūrį į romus, teisingai klasifikuoti 101 (74,26 %). Teisingai buvo klasifikuoti 74,25 % neutralų požiūrį išreiškę respondentai ir 57,54 % – išreiškę neigiamą požiūrį. Palyginkime su pradine nuomonių dažnių lentele:

```
tab r01_04, freq
```

grupės?	Freq.	Percent	Cum.
Teigiamas	136	15.76	15.76
Neutralus	369	42.76	58.52
Neigiamas	358	41.48	100.00
Total	863	100.00	

Klasifikacinės lentelės procentai daug didesni, nei gautume akiai spėliodami. Taigi modelį galima laikyti visai tinkamu.

5.3.5. Kategorinis kintamasis

Kategorinis kintamasis turi būti keičiamas dvireikšmiais pseudokintamaisiais. Tą galima padaryti automatiškai. Ištirsime daugianarės logistinės regresijos modelį, kurį sąlygiškai užrašome: $r01_04 = f(kiti, s11)$. Kintamajame *s11* nurodyta respondento gyvenamoji vieta (1 – Vilnius, 2 – Kaunas, Klaipėda, Šiauliai, Panevėžys, 3 – rajono centras, 4 – kiti miestai, 5 – kaimas).

Daugianarė regresija atliekama įvykdžius:

```
xi:mlogit r01_04 kiti i.s11, base(3)
```

i.s11	_Is11_1-5		(naturally coded; _Is11_1 omitted)			
Iteration 0:	log likelihood = -879.80204					
Iteration 1:	log likelihood = -681.24599					
Iteration 2:	log likelihood = -637.27355					
Iteration 3:	log likelihood = -632.5721					
Iteration 4:	log likelihood = -632.38841					
Iteration 5:	log likelihood = -632.38796					
Multinomial logistic regression			Number of obs		=	863
			LR chi2(10)		=	494.83
			Prob > chi2		=	0.0000
Log likelihood = -632.38796			Pseudo R2		=	0.2812
r01_04	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
Teigiamas						
kiti	-1.326815	.0871201	-15.23	0.000	-1.497567	-1.156063
_Is11_2	.8310298	.4648955	1.79	0.074	-.0801486	1.742208
_Is11_3	1.20512	.4733611	2.55	0.011	.2773497	2.132891
_Is11_4	-.2837328	.959032	-0.30	0.767	-2.163401	1.595935
_Is11_5	.7896133	.4611713	1.71	0.087	-.1142658	1.693492
_cons	10.91784	.8263439	13.21	0.000	9.298235	12.53744
Neutralus						
kiti	-.4934852	.0509341	-9.69	0.000	-.5933143	-.3936562
_Is11_2	.4684803	.2538883	1.85	0.065	-.0291317	.9660923
_Is11_3	.299621	.2555699	1.17	0.241	-.2012868	.8005288
_Is11_4	-1.650373	.9318776	-1.77	0.077	-3.476819	.1760737
_Is11_5	.5188331	.2421728	2.14	0.032	.0441831	.9934831
_cons	5.146229	.5764447	8.93	0.000	4.016418	6.27604
(r01_04==Neigiamas is the base outcome)						

Kategorinis regresorius *s11* buvo pakeistas dvireikšmiais regresoriais, kurie įgyja nulius ir vienetus: *_Izzz_2* = 1, kai *s11* = 2, *_Izzz_3* = 1, kai *s11* = 3, ir t. t. Atvejis *_Izzz_2*=*_Izzz_3*=*_Izzz_4* = *_Izzz_5*=0 atitinka *s11* = 1. Bendroji formulė pirmajam daliniam modeliui atrodo taip:

$$\frac{\hat{P}(\text{Teigiamas})}{\hat{P}(\text{Neigiamas})} = e^{z_1}.$$

Čia $z_1 = 10,92 - 1,33 \text{ kiti} + 0,83 \text{ _Izzz_1} + 1,21 \text{ _Izzz_2} - 0,28 \text{ _Izzz_3} + 0,79 \text{ _Izzz_4}$.

Norėdami gauti lygtį vilniečiams, vietoje visų *_Izzz_j* įstatome nulius. Norėdami gauti lygtį kaimui, įstatome *_Izzz_1* = *_Izzz_2* = *_Izzz_3* = 0, *_Izzz_4* = 1 ir t. t.

5.4. Daugianarė logistinė regresinė analizė su SAS

5.4.1. Duomenys

Failas **ZTLT** . Tyrimas: Lietuvos tolerancijos profiliai, 2003 m. Respondentai atsakė, koks jų požiūris (1 – teigiamas, 2 – neutralus, 3 – neigiamas, 4 – sunku pasakyti) į:

- *r01_01* – juodaodžius,
- *r01_02* – musulmonus,

- *r01_03* – žydus,
- *r01_04* – čigonus (romus),
- *r01_05* – migrantus,
- *r01_06* – pabėgėlius.

Norėsime ištirti, kaip požiūriui į romus turi įtakos požiūris į kitus nelietuvius. Visų pirma pasižiūrime, kiek kokių reikšmių šis kintamasis įgyja. Įvykdome:

```

OPTIONS nofmterr;
data new;
set rgr.ZTLT_s;
run;
PROC FORMAT;
  VALUE r01_04f  1="Teigiamas"
                  2="Neutralus"
                  3="Neigiamas"
                  4="Sunku pasakyti";

  RUN;
proc freq data=new;
format r01_04 r01_04f.;
tables r01_04;
run;

```

r01_04	Frequency	Percent	Cumulative Frequency	Cumulative Percent
Teigiamas	147	14.08	147	14.08
Neutralus	402	38.51	549	52.59
Neigiamas	446	42.72	995	95.31
Sunku pasakyti	49	4.69	1044	100.00

Matome, kad nuomonės neturėjo tik 4,69 % respondentų. Panaši situacija su atsakymais į kitus klausimus. Todėl iš tyrimo pašaliname visus respondentus, neturinčius nuomonės apie svetimtaučius. Sudėdami visus kintamuosius, išskyrus *r01_04*, sukuriame jungtinį kintamąjį *kiti*. Šis kintamasis rodo respondentų priešišumą visiems nelietuviams, išskyrus romus. Kuo didesnė kintamojo *kiti* reikšmė, tuo priešišumas yra didesnis:

```

OPTIONS nofmterr;

data ZtLt;

set rgr.ZTLT_s;

if (r01_01 LE 3) AND (r01_02 LE 3) AND (r01_03 LE 3) AND (r01_04 LE 3) AND (r01_05 LE 3)
AND (r01_06 LE 3) ;

kiti = r01_01+ r01_02 + r01_03+ r01_05+ r01_06;

run;

```

5.4.2. Analizė

Tikrinsime modelį: $r01_04 = f(kiti)^{63}$. Kontroline kategorija pasirenkame reikšmę $r01_04 = 3$ (neigiamą požiūrį). Įvykdome

```

PROC FORMAT;

VALUE r01_04f 1="Teigiamas"
              2="Neutralus"
              3="Neigiamas" ;

RUN;

proc logistic data=ZtLt;
format r01_04 r01_04f.;
class r01_04 (ref = "Neigiamas") ;
model r01_04= kiti / link = glogit rsq;

run;

```

Model Fit Statistics		
Criterion	Intercept Only	Intercept and Covariates
AIC	1763.604	1289.500
SC	1773.125	1308.542
-2 Log L	1759.604	1281.500

⁶³ Modelio tiksli išraiška pateikiama aprašant rezultatus.

R-Square	0.4254	Max-rescaled R-Square	0.4890
----------	--------	-----------------------	--------

Testing Global Null Hypothesis: BETA=0			
Test	Chi-Square	DF	Pr > ChiSq
Likelihood Ratio	478.1038	2	<.0001
Score	397.6471	2	<.0001
Wald	239.7892	2	<.0001

Analysis of Maximum Likelihood Estimates						
Parameter	r01_04	DF	Estimate	Standard Error	Wald Chi-Square	Pr > ChiSq
Intercept	Neutralus	1	5.2855	0.5570	90.0406	<.0001
Intercept	Teigiamas	1	11.3266	0.7826	209.4545	<.0001
kiti	Neutralus	1	-0.4750	0.0498	90.8078	<.0001
kiti	Teigiamas	1	-1.2894	0.0834	239.0620	<.0001

Odds Ratio Estimates				
Effect	r01_04	Point Estimate	95% Wald Confidence Limits	
kiti	Neutralus	0.622	0.564	0.686
kiti	Teigiamas	0.275	0.234	0.324

Modelio tikimo tikėtinumų santykio kriterijaus p reikšmė yra lentelės **Testing Global Null Hypothesis: BETA=0** stulpelyje **Pr > ChiSq**. Darome išvadą, kad modelis duomenims tinka, nes $p = 0,000 < 0,05$. Determinacijos koeficiento reikšmė nėra itin didelė $R^2 = 0,4254$, bet jo vaidmuo nėra itin svarbus (ir jis vis tiek $> 0,20$). Voldo kriterijaus rezultatai rodo, kad visi koeficientai yra statistiškai reikšmingi. Užrašykime pirmąjį dalinį modelį:

$$\frac{\hat{P}(\text{Teigiamas})}{\hat{P}(\text{Neigiamas})} = e^{z_1}.$$

Čia $z_1 = 11,327 - 1,289kiti$.

Regresoriaus *kiti* koeficiento ženklas yra neigiamas. Todėl, didėjant *kiti* reikšmėms (respondentui išreiškiant didesnę priešišumą nelietuviams), didėja tikimybė, kad ir romų atžvilgiu jis nusistatęs neigiamai. Analogiškai galima sudaryti ir pakomentuoti antrąjį modelį:

$$\frac{\hat{P}(\text{Neutralus})}{\hat{P}(\text{Neigiamas})} = e^{z_2}.$$

Čia $z_2 = 5,285 - 0,7498\textit{kiti}$.

Galimybių santykių įverčiai (lentelė **Odds Ratio Estimates**) pateikti kartu su jų pasikliautiniais intervalais. Paimkime pirmąjį dalinį modelį. Galimybių santykis regresoriui *kiti* lygus 0,275 (95 % pasikliautinis intervalas 0,234–0,324). Tai reiškia, kad regresoriui *kiti* padidėjus vienetu, tikimybių santykis $P(\text{Teigiamas}) / P(\text{Neigiamas})$ pasikeis 0,275 karto (paprastiau kalbant, sumažės $1/0,275 = 3,64$ karto):

$$\left(\frac{\hat{P}(\text{Teigiamas})}{\hat{P}(\text{Neigiamas})} \right)_{\text{kai } \textit{kiti} \text{ padidėja vienetu}} = 0,275 \left(\frac{\hat{P}(\text{Teigiamas})}{\hat{P}(\text{Neigiamas})} \right)_{\text{senas}}$$

Analogiškai interpretuojamas ir antrasis galimybių santykis.

Lentelėje **Model Fit Statistics** pateikiami modelio suderinamumo matai (Akaikės indeksas ir kt).

5.4.3. Prognozavimas

Prognozuojant duomenų aibę reikia papildyti nauju įrašu, kuriame prognozuojamo kintamojo reikšmės nėra, o regresoriai reikšmės tokios, kokioms norime atlikti prognozę. Be to, rezultatų masyvas išsaugomas ir tik tada galime išspausdinti prognozę. Tarkime, kad norime padaryti *r01_04* prognozę respondentui, kurio *kiti* = 10. Įvykdome

```
data new;
set ztlt end=eof;
output;
if eof then do;
Call missing( of _all_ );
kiti=10;
output;
end ;
run;
```



```

proc logistic data=new;
format r01_04 r01_04f.;
class r01_04 (ref = "Neigiamas") ;
model r01_04= kiti / link = glogit ;
output out=klasif PREDPROBS=(INDIVIDUAL);
run;
proc sql;
select distinct kiti,IP_Neigiamas,IP_Neutralus,IP_Teigiamas from klasif where kiti=10;
run;

```

kiti	Individual Probability: r01_04=Neigiamas	Individual Probability: r01_04=Neutralus	Individual Probability: r01_04=Teigiamas
10	0.342793	0.585699	0.071509

Jeigu regresorių būtų daugiau, nurodytume daugiau reikšmių (duomenų aibę papildytume daugiau įrašų pagal anksčiau nurodyta taisyklę).

5.4.4. Klasifikacinė lentelė

Tiesiogiai klasifikacinės lentelės gauti su SAS *proc logistic* negalima. Pirmiausia suformuojamas rezultatų masyvas kaip ir prognozavimo atveju ir tik tada spausdinama klasifikacinė lentelė.

Įvykdome:

```

proc logistic data=ZtLt;
format r01_04 r01_04f.;
class r01_04 (ref = "Neigiamas") ;
model r01_04= kiti / link = glogit ;
output out=klasif PREDPROBS=(INDIVIDUAL);
run;
proc freq data=klasif;
tables _FROM_*_INTO_;
run;

```

Frequency
Percent
Row Pct
Col Pct

Table of _FROM_ by _INTO_				
FROM (Formatted Value of the Observed Response)	_INTO_ (Formatted Value of the Predicted Response)			
	Neigiamas	Neutralus	Teigiamas	Total
Neigiamas	206 23.87 57.54 71.28	140 16.22 39.11 31.60	12 1.39 3.35 9.16	358 41.48
Neutralus	77 8.92 20.87 26.64	274 31.75 74.25 61.85	18 2.09 4.88 13.74	369 42.76
Teigiamas	6 0.70 4.41 2.08	29 3.36 21.32 6.55	101 11.70 74.26 77.10	136 15.76
Total	289 33.49	443 51.33	131 15.18	863 100.00

Matome, kad iš 136 respondentų, kurie pareiškė teigiamą požiūrį į romus, teisingai klasifikuoti 101 (74,26 %) . Teisingai buvo klasifikuoti 74,25 % neutralų požiūrį išreiškę respondentai ir 57,54 % – išreiškę neigiamą požiūrį. Palyginkime su pradine nuomonių dažnių lentele:

```
proc freq data=ZtLt;
format r01_04 r01_04f.;
tables r01_04;
run;
```

r01_04	Frequency	Percent	Cumulative Frequency	Cumulative Percent
Teigiamas	136	15.76	136	15.76
Neutralus	369	42.76	505	58.52
Neigiamas	358	41.48	863	100.00

Klasifikacinės lentelės procentai daug didesni nei gautume aklai spėliodami. Taigi modelį galima laikyti visai tinkamu.

5.4.5. Kategorinis kintamasis

Kategorinis kintamasis turi būti keičiamas dvireikšmiais pseudokintamaisiais. Tą galima padaryti automatiškai, aprašant kintamąjį ir jo bazinę (atskaitos) kategoriją *class* sakinyje. Ištirsime daugianarės logistinės regresijos modelį, kurį sąlygiškai galima užrašyti taip: $r01_04 = f(kiti, s11)$. Kintamajame *s11* nurodyta respondento gyvenamoji vieta (1 – Vilnius, 2 – Kaunas, Klaipėda, Šiauliai, Panevėžys, 3 – rajono centras, 4 – kiti miestai, 5 – kaimas).

Daugianarė regresija atliekama įvykdžius:

```
proc logistic data=ZtLt;
format r01_04 r01_04f.;
class r01_04 (ref = "Neigiamas") s11(ref="1") / param = ref;
model r01_04= kiti s11 / link = glogit;
run;
```

Logits modeled use r01_04='Neigiamas' as the reference category.

Class Level Information					
Class	Value	Design Variables			
s11	1	0	0	0	0
	2	1	0	0	0
	3	0	1	0	0
	4	0	0	1	0
	5	0	0	0	1

Model Fit Statistics		
Criterion	Intercept Only	Intercept and Covariates
AIC	1763.604	1288.776
SC	1773.125	1345.901
-2 Log L	1759.604	1264.776

R-Square	0.4364	Max-rescaled R-Square	0.5017
----------	--------	-----------------------	--------

Testing Global Null Hypothesis: BETA=0			
Test	Chi-Square	DF	Pr > ChiSq
Likelihood Ratio	494.8282	10	<.0001
Score	410.8048	10	<.0001
Wald	245.2106	10	<.0001

Analysis of Maximum Likelihood Estimates							
Parameter		r01_04	DF	Estimate	Standard Error	Wald Chi-Square	Pr > ChiSq
Intercept		Neutralus	1	5.1462	0.5764	79.7008	<.0001
Intercept		Teigiamas	1	10.9178	0.8263	174.5619	<.0001
kiti		Neutralus	1	-0.4935	0.0509	93.8708	<.0001
kiti		Teigiamas	1	-1.3268	0.0871	231.9428	<.0001
s11	2	Neutralus	1	0.4685	0.2539	3.4048	0.0650
s11	2	Teigiamas	1	0.8310	0.4649	3.1953	0.0738
s11	3	Neutralus	1	0.2996	0.2556	1.3744	0.2411
s11	3	Teigiamas	1	1.2051	0.4734	6.4813	0.0109
s11	4	Neutralus	1	-1.6504	0.9319	3.1365	0.0766
s11	4	Teigiamas	1	-0.2837	0.9590	0.0875	0.7673
s11	5	Neutralus	1	0.5188	0.2422	4.5899	0.0322
s11	5	Teigiamas	1	0.7896	0.4612	2.9315	0.0869

Odds Ratio Estimates				
Effect	r01_04	Point Estimate	95% Wald Confidence Limits	
kiti	Neutralus	0.610	0.552	0.675
kiti	Teigiamas	0.265	0.224	0.315
s11 2 vs 1	Neutralus	1.598	0.971	2.628
s11 2 vs 1	Teigiamas	2.296	0.923	5.710
s11 3 vs 1	Neutralus	1.349	0.818	2.227
s11 3 vs 1	Teigiamas	3.337	1.320	8.439
s11 4 vs 1	Neutralus	0.192	0.031	1.193
s11 4 vs 1	Teigiamas	0.753	0.115	4.933
s11 5 vs 1	Neutralus	1.680	1.045	2.701
s11 5 vs 1	Teigiamas	2.203	0.892	5.438

Pateiktoje rezultatų išklotinėje matome, kad modelis tinkamas – modelio AIC = 1288,8 yra daug mažesnis už modelio be regresorių AIC = 1763,6, o R-square = 0,436. „**Class Level Information**“ matome, kaip buvo sudaryti pseudokintamieji. Kategorinis regresorius *s11* buvo pakeistas dvireikšmiais regresoriais, kurie įgyja nulių ir vienetų. Bendroji formulė pirmajam daliniam modeliui atrodo taip:

$$\frac{\hat{P}(\text{Teigiamas})}{\hat{P}(\text{Neigiamas})} = e^{z_1}.$$

Čia

$$z_1 = 10,92 - 1,33 \text{ kiti} + 0,83 \text{ S11_2} + 1,21 \text{ s11_3} - 0,28 \text{ s11_4} + 0,79 \text{ s11_5}.$$

Norėdami gauti lygtį vilniečiams, vietoje visų *_s11_j* įstatome nulių. Norėdami gauti lygtį kaimui, įstatome *s11_2 = s11_3 = s11_4 = 0*, *s11_5 = 1* ir t. t., žr. 5.2.4 skyrelį.

5.4.6. SAS programos logistinės regresijos procedūra

Taikant SAS logistinei regresinei analizei yra naudojama **proc logistic** procedūra. Ji tinka tiek dvinarei, tiek daugianarei logistinei regresijai. Šios procedūros sintaksė atrodo taip:

```

PROC LOGISTIC <options> ;
BY variables ;
CLASS variable <(options)><variable <(options)>></ options> ;
CONTRAST 'label' effect values<, effect values,></ options> ;
EFFECT name = effect-type ( variables </ options> ) ;
EFFECTPLOT <plot-type<(plot-definition-options)>></ options> ;
ESTIMATE <'label'> estimate-specification </ options> ;
EXACT <'label'><INTERCEPT><effects></ options> ;
EXACTOPTIONS options ;FREQ variable ;
LSMEANS <model-effects> </ options> ;LSMESTIMATE model-effect lsmestimate-
specification </ options> ;
<label:> MODEL variable <(variable_options)>=<effects></ options> ;
<label:> MODEL events/trials=<effects></ options> ;ODDSRATIO <'label'> variable </
options> ;
OUTPUT <OUT=SAS-data-set><keyword=name <keyword=name>></ option> ;
ROC <'label'> <specification> </ options> ;
ROCCONTRAST <'label'><contrast></ options> ;SCORE <options> ;
SLICE model-effect </ options> ;STORE <OUT=>item-store-name </ LABEL='label'> ;
STRATA effects </ options> ;<label:> TEST equation1 <,equation2,></ option> ;
UNITS <independent1=list1 <independent2=list2 >></ option> ;
WEIGHT variable </ option> ;

```

model yra būtinas **logistic** procedūros sakiny. Šiuo sakiniu aprašomas modelio pavidalas.

CLASS and EFFECT sakiniai (jei apibrėžti) turi būti prieš MODEL sakinį; CONTRAST, EXACT ir ROC sakiniai (jei apibrėžti) turi būti po MODEL sakinio.

Scenarijus :

```

OPTIONS nofmterr;
data new;
set rgr.ZTLT_s;
run;

```

```

PROC FORMAT;
  VALUE r01_04f  1="Teigiamas"
                2="Neutralus"
                3="Neigiamas"
                4="Sunku pasakyti";

  RUN;

proc freq data=new;
format r01_04 r01_04f.;
tables r01_04;
run;

data ZtLt;
set rgr.ZTLT_s;

if (r01_01 LE 3) AND (r01_02 LE 3) AND (r01_03 LE 3) AND (r01_04 LE 3) AND
(r01_05 LE 3) AND (r01_06 LE 3)
kiti = r01_01+ r01_02 + r01_03+ r01_05+ r01_06;

run;

proc logistic data=ZtLt;
format r01_04 r01_04f.;
class r01_04 (ref = "Neigiamas") ;
model r01_04= kiti / link = glogit rsq;
run;

/* klasifikavimas */
proc logistic data=ZtLt;
format r01_04 r01_04f.;
class r01_04 (ref = "Neigiamas") ;
model r01_04= kiti / link = glogit ;
output out=klasif PREDPROBS=(INDIVIDUAL);
run;

proc freq data=klasif;
tables _FROM_*_INTO_;
run;

proc freq data=ZtLt;;

```

```

format r01_04 r01_04f.;
tables r01_04;

run;

/* prognozavimas */
data new;
set ztl end=eof;
output;
if eof then do;
Call missing( of _all_ );
kiti=10;
output;
end ;
run;

proc logistic data=new;
format r01_04 r01_04f.;
class r01_04 (ref = "Neigiamas") ;
model r01_04= kiti / link = glogit ;
output out=klasif PREDPROBS=(INDIVIDUAL);
run;

proc sql;
select distinct kiti,IP_Neigiamas,IP_Neutralus,IP_Teigiamas from klasif where kiti=10;
run;

/* kategoriniai kintamieji */
proc logistic data=ZtLt;
format r01_04 r01_04f.;
class r01_04 (ref = "Neigiamas") s11(ref="1") / param = ref;
model r01_04= kiti s11 / link = glogit rsquare;
run;

```


5.5. Daugianarė logistinė regresinė analizė su R

5.5.1. Duomenys

Failas **ZTLT**. Tyrimas: Lietuvos tolerancijos profiliai, 2003 m. Respondentai atsakė, koks jų požiūris (1 – teigiamas, 2 – neutralus, 3 – neigiamas, 4 – sunku pasakyti) į:

- *r01_01* – juodaodžius,
- *r01_02* – musulmonus,
- *r01_03* – žydus,
- *r01_04* – čigonus (romus),
- *r01_05* – migrantus,
- *r01_06* – pabėgėlius.

Norėsime ištirti, kaip požiūriui į romus turi įtakos požiūris į kitus nelietuvius. Visų pirma pasižiūrime, kiek kokių reikšmių šis kintamasis įgyja. Įvykdome komandą

```
dta<-read.csv2("ZTLT_s.csv",na.strings = "NA",stringsAsFactors=FALSE)

tb<-addmargins(table(dta$r01_04))
names(tb) <-c("Teigiamas","Neutralus","Neigiamas","Sunku pasakyti","suma")
tb
tbl<-prop.table((table(dta$r01_04)))
names(tbl) <-c("Teigiamas","Neutralus","Neigiamas","Sunku pasakyti")
tbl*100
```

```
> tb
  Teigiamas  Neutralus  Neigiamas Sunku pasakyti   suma
      147       402       446        49     1044

> tbl*100
  Teigiamas  Neutralus  Neigiamas  Sunku pasakyti
 14.080460  38.505747  42.720307   4.693487
>
```

Matome, kad nuomonės neturėjo tik 4,69% respondentų. Panaši situacija su atsakymais į kitus klausimus. Todėl iš tyrimo pašaliname visus respondentus, neturinčius nuomonės apie svetimtaučius:

```
ldta<-subset(dta,r01_01<=3 & r01_02 <=3 & r01_03 <=3 & r01_04 <=3 & r01_05 <=3 &
r01_06 <=3)
```

Sudėdami visus kintamuosius, išskyrus *r01_04*, sukuriame jungtinį kintamąjį *kiti*. Šis kintamasis rodo respondentų priešišumą visiems nelietuviams, išskyrus romus. Kuo didesnė kintamojo *kiti* reikšmė, tuo priešišumas yra didesnis:

```
attach(ldta)
ldta$kiti <- r01_01+ r01_02 + r01_03+ r01_05+ r01_06
```

5.5.2. Analizė

Tikrinsime modelį: $r01_04 = f(kiti)$. Kontroline kategorija pasirenkame reikšmę $r01_04 = 3$ (neigiamą požiūrį)⁶⁴. Naudosime R programos funkcijų biblioteką *nnet*. Įvykdome

```
library(nnet)
ldta$r0104 <- relevel(factor(r01_04), ref = 3)
dlrg <- multinom(r0104 ~ kit, data = ldta)
summary(dlrg)
dlrg_null<- multinom(r0104 ~ 1, data = ldta)
rkvadrat<-1-dlrg$deviance/dlrg_null$deviance
rkvadrat
```

```
> summary(dlrg)
Call:
multinom(formula = r0104 ~ kit, data = ldta)

Coefficients:
  (Intercept)    kit
1  11.330040  -1.289727
2   5.286561  -0.475072

Std. Errors:
  (Intercept)    kit
1  0.7828020  0.08341089
2  0.5570912  0.04985089

Residual Deviance: 1281.500
AIC: 1289.500
```

⁶⁴ Modelio tiksli išraiška pateikiama aprašant rezultatus.

```
> rkvadrat  
[1] 0.271711
```

Modelio tikimo tikėtinumų santykio kriterijaus p reikšmė yra stulpelyje **Prob** > **chi2**. Darome išvadą, kad modelis duomenims tinka, nes $p = 0,000 < 0,05$. Pateiktasis (Makfadeno) determinacijos pseudokoeficientas nėra itin didelis $R^2 = 0,271$ ir jo vaidmuo nėra itin svarbus (ir jis vis tiek $> 0,20$). Akaikės indeksas (AIC) 1289,5. Primename, kad tai santykinis suderinamumo matas. Norint juo pasinaudoti, reikėtų paskaičiuoti modelio tik su konstanta AIC. Beje, „nulinį“ modelį panaudojome ir skaičiuodami determinacijos koeficientą. Įvykdome:

```
summary(dlrg_null)
```

Nulinio modelio AIC = 1763,6. Nagrinėjamo modelio AIC daug mažesnė. Tai dar vienas patvirtinimas, kad modelis tinka.

Užrašykime pirmąjį dalinį modelį:

$$\frac{\hat{P}(\text{Teigiamas})}{\hat{P}(\text{Neigiamas})} = e^{z_1}.$$

Čia $z_1 = 11,326 - 1,289\textit{kiti}$ (rezultatų išsklotinė nėra labai informatyvi, nes nespausdinamos priklausomo kintamojo reikšmių etiketės. Primename 1– „teigiamas“, 2– „neutralus“).

Regresoriaus *kiti* koeficiento ženklas yra neigiamas. Todėl, didėjant *kiti* reikšmėms (respondentui išreiškiant didesnę priešišumą nelietuviams), didėja tikimybė, kad ir romų atžvilgiu jis nusistatęs neigiamai. Analogiškai galima sudaryti ir pakomentuoti antrąjį modelį:

$$\frac{\hat{P}(\text{Neutralus})}{\hat{P}(\text{Neigiamas})} = e^{z_2}.$$

Čia $z_2 = 5,285 - 0,7498\textit{kiti}$.

Norėdami gauti galimybių santykius, įvykdome:

```
exp(coef(dlrg))
```

```
> exp(coef(dlrg))
      (Intercept)      kiti
1 83286.3214    0.2753460
2  197.6626    0.6218403
```

Paimkime pirmąjį dalinį modelį. Galimybių santykio įvertis regresoriui *kiti* lygus 0,275. Tai reiškia, kad kintamajam *kiti* padidėjus vienetu, tikimybių santykis $P(\text{Teigiamas}) / P(\text{Neigiamas})$ pasikeis 0,275 karto: (paprasčiau kalbant, sumažės $1/0,275 = 3,64$ karto).

$$\left(\frac{\hat{P}(\text{Teigiamas})}{\hat{P}(\text{Neigiamas})} \right)_{\text{kai } kiti \text{ padidėja vienetu}} = 0,275 \left(\frac{\hat{P}(\text{Teigiamas})}{\hat{P}(\text{Neigiamas})} \right)_{\text{senas}}$$

Analogiškai interpretuojamas ir antrojo galimybių santykio įvertis.

5.5.3. Prognozavimas

Tarkime, kad norime padaryti *r01_04* prognozę respondentui, kurio *kiti* = 10. Įvykdome

```
predict(dlrg, data.frame(kiti= 10), type="probs")
```

```
      3      1      2
0.3427583 0.0715072 0.5857345
>
```

Primename 1– „teigiamas“, 2– „neutralus“, 3– „neigiamas“. Taigi labiausiai tikėtina reikšmė yra „neutralus“.

5.5.4. Klasifikacinė lentelė

Tiesiogiai klasifikacinės lentelės gauti su R negalima. Todėl ją sukursime, įdėję šiek tiek darbo. Įvykdome:

```
pred<-data.frame(fitted(dlrg))
pred$X4<-0
pred$X4[(pred$X1 > pred$X2) & (pred$X1 > pred$X3)]=1
pred$X4[(pred$X2 > pred$X1) & (pred$X2 > pred$X3)]=2
pred$X4[(pred$X3 > pred$X1) & (pred$X3 > pred$X2)]=3
lda$obs <- releval(factor(r01_04), ref =1 )
```

```
tb1<-addmargins(table(ldta$obs,pred$X4))
rownames(tb1) <-c("Teigiamas","Neutralus","Neigiamas","Suma")
colnames(tb1) <-c("Teigiamas","Neutralus","Neigiamas","Suma")
tb1
tb2<-prop.table(table(ldta$obs,pred$X4),margin=1)*100
rownames(tb2) <-c("Teigiamas","Neutralus","Neigiamas")
colnames(tb2) <-c("Teigiamas","Neutralus","Neigiamas")
tb2
```

	Teigiamas	Neutralus	Neigiamas	Suma
Teigiamas	101	29	6	136
Neutralus	18	274	77	369
Neigiamas	12	140	206	358
Suma	131	443	289	863

	Teigiamas	Neutralus	Neigiamas
Teigiamas	74.264706	21.323529	4.411765
Neutralus	4.878049	74.254743	20.867209
Neigiamas	3.351955	39.106145	57.541899

Matome, kad iš 136 respondentų, kurie pareiškė teigiamą požiūrį į romus, teisingai klasifikuoti 101 (74,26 %). Teisingai buvo klasifikuoti 74,25 % neutralų požiūrį išreiškę respondentai ir 57,54 % – išreiškę neigiamą požiūrį. Palyginkime su pradine nuomonių dažnių lentele:

```
tbl<-prop.table((table(ldta$r01_04)))*100
names(tbl) <-c("Teigiamas","Neutralus","Neigiamas")
tbl
```

Teigiamas	Neutralus	Neigiamas
15.75898	42.75782	41.48320

Klasifikacinės lentelės procentai daug didesni, nei gautume aklai spėliodami. Taigi modelį galima laikyti visai tinkamu.

5.5.5. Kategorinis kintamasis

Kategorinis kintamasis turi būti keičiamas dvireikšmiais pseudokintamaisiais. Tai padaroma automatiškai, jei modelio aprašyme kintamasis nurodomas kaip faktorius. Ištersime daugianarės logistinės regresijos modelį, kurį sąlygiškai galima užrašyti taip: $r01_04 = f(kiti, s11)$. Kintamajame

s11 nurodyta respondento gyvenamoji vieta (1 – Vilnius, 2 – Kaunas, Klaipėda, Šiauliai, Panevėžys, 3 – rajono centras, 4 – kiti miestai, 5 – kaimas).

Daugianarė logistinė regresinė analizė atliekama įvykdžius:

```
ldta$r0104 <- relevel(factor(r01_04), ref = 3)
dlrg2 <- multinom(r0104 ~ kiti+as.factor(s11),data=ldta)
summary(dlrg2)
rkvadrat<-1-dlrg2$deviance/dlrg_n$deviance

rkvadrat
```

Call:

multinom(formula = r0104 ~ kiti + as.factor(s11), data = ldta)

Coefficients:

	(Intercept)	kiti	as.factor(s11)2	as.factor(s11)3	as.factor(s11)4
1	10.917683	-1.3268006	0.8310869	1.2051240	-0.2835491
2	5.146177	-0.4934818	0.4685011	0.2996265	-1.6500929
	as.factor(s11)5				
1	0.7896298				
2	0.5188395				

Std. Errors:

	(Intercept)	kiti	as.factor(s11)2	as.factor(s11)3	as.factor(s11)4
1	0.8263378	0.08711956	0.4648950	0.4733613	0.9590402
2	0.5764418	0.05093391	0.2538882	0.2555696	0.9318370
	as.factor(s11)5				
1	0.4611713				
2	0.2421725				

Residual Deviance: 1264.776

AIC: 1288.776

```
> rkvadrat
[1] 0.2812156
```

Kategorinis regresorius *s11* buvo pakeistas dvireikšmiais regresoriais, kurie įgyja nulių ir vienetų: *as.factor(s11)2* = 1, kai *s11* = 2, *as.factor(s11)3* = 1, kai *s11* = 3, ir t. t. Bendroji formulė pirmajam daliniam modeliui atrodo taip:

$$\frac{\hat{P}(\text{Teigiamas})}{\hat{P}(\text{Neigiamas})} = e^{z_1}.$$

Čia

$z_1 = 10,92 - 1,32\text{kiti} + 0,83\text{as.factor}(s11)^2 + 1,21\text{as.factor}(s11)^3 - 0,28\text{as.factor}(s11)^4 + 0,79\text{as.factor}(s11)^5$.

Norėdami gauti lygtį vilniečiams, vietoje visų *as.factor(s11)^j* įstatome nulius. Norėdami gauti lygtį kaimui, įstatome *as.factor(s11)² = as.factor(s11)³ = as.factor(s11)⁴ = 0*, *as.factor(s11)⁵ = 1* ir t. t.

5.5.6. R programos daugianarės logistinės regresijos komandos

R programoje daugianarei logistinei regresinei analizei yra naudojama ***multinom*** funkcija (biblioteka ***nnet***). Komados sintaksė atrodo taip

```
multinom(formula, data, weights, subset, na.action,
          contrasts = NULL, Hess = FALSE, summ = 0, censored = FALSE,
          model = FALSE, ...)
```

Būtinasis parametras **formula** – užrašome modelio išraišką.

Scenarijus:

```
dta<-read.csv2("ZTLT_s.csv",na.strings = "NA",stringsAsFactors=FALSE)
tb<-addmargins(table(dta$r01_04))
names(tb) <-c("Teigiamas", "Neutralus", "Neigiamas", "Sunku pasakyti", "suma")
tb
tbl<-prop.table((table(dta$r01_04)))
names(tbl) <-c("Teigiamas", "Neutralus", "Neigiamas", "Sunku pasakyti")
tbl*100
ldta<-subset(dta,r01_01<=3 & r01_02 <=3 & r01_03 <=3 & r01_04 <=3 & r01_05 <=3 &
r01_06 <=3)
attach(ldta)
ldta$kiti <- r01_01+ r01_02 + r01_03+ r01_05+ r01_06
ldta$r0104 <- relevel(factor(r01_04), ref = 3)
library(nnet)
dlrg <- multinom(r0104 ~ kit, data = ldta)
summary(dlrg)
```

```

# r2, nulinis modelis
dlrg_null <- multinom(r0104 ~ 1, data = ldta)
rkvadrat<-1-dlrg$deviance/dlrg_null$deviance
rkvadrat
summary(dlrg_null)
exp(coef(dlrg)) # odds
predict(dlrg, data.frame(kiti= 10), type="probs") # prognozuojamos trim lygiams, kai k=10
# Klasifikavimo lentelė
pred<-data.frame(fitted(dlrg))
pred$X4<-0
pred$X4[(pred$X1 > pred$X2) & (pred$X1 > pred$X3)]=1
pred$X4[(pred$X2 > pred$X1) & (pred$X2 > pred$X3)]=2
pred$X4[(pred$X3 > pred$X1) & (pred$X3 > pred$X2)]=3
ldta$obs <- relevel(factor(r01_04), ref =1 )
tb1=addmargins(table(ldta$obs,pred$X4))
rownames(tb1) <-c("Teigiamas", "Neutralus", "Neigiamas", "Suma")
colnames(tb1) <-c("Teigiamas", "Neutralus", "Neigiamas", "Suma")
tb1
tb2<-prop.table(table(ldta$obs,pred$X4),margin=1)*100
rownames(tb2) <-c("Teigiamas", "Neutralus", "Neigiamas")
colnames(tb2) <-c("Teigiamas", "Neutralus", "Neigiamas")
tb2
tbl<-prop.table((table(ldta$r01_04)))*100
names(tbl) <-c("Teigiamas", "Neutralus", "Neigiamas")
tbl
# modelis su kategoriniu kintamuoju
ldta$r0104 <- relevel(factor(r01_04), ref = 3)
dlrg2 <- multinom(r0104 ~ kiti+as.factor(s11),data=ldta)
summary(dlrg2)
rkvadrat<-1-dlrg2$deviance/dlrg_null$deviance
rkvadrat

```


Uždaviniai


1. Failas **ZTLT**. Tyrimas: Lietuvos tolerancijos profiliai, 2003 m. Respondentai atsakė, koks jų požiūris (1 – teigiamas, 2 – neutralus, 3 – neigiamas, 4 – sunku pasakyti) į musulmonus (kintamasis $r01_02$). Kintamasis $r02_04$ (koks procentas Lietuvos gyventojų būdami homoseksualūs nekeltų grėsmės visuomenei) yra ranginis, bet rangų daug. Todėl tyrime jį galima traktuoti kaip intervalinį. Atsakymai į klausimą, ar galima pateisinti darbdavį, atsisakiusį priimti į darbą kitos rasės žmogų ($r06_01$) ir homoseksualų žmogų ($r06_07$), koduoti skalėje: 1 – Niekada, 2 – Kartais, 3 – Visada, 4 – sunku pasakyti. Kintamasis $s01$ žymi lytį (1 – vyr., 2 – mot.). Reikia perkoduoti kintamuosius $r06_01$ ir $r06_07$ į *ras* ir *homo* : $1 \rightarrow 1$, $2 \rightarrow 2$, $3 \rightarrow 2$, $4 \rightarrow 3$. Suteikti naujosioms reikšmėms „etiketes“ : 1 – niekada, 2 – kartais / visada, 3 – sunku pasakyti. Vyrams ištirti daugianarės logistinės regresijos modelį: $homo = f(ras, r01_02, r02_04)$.

2. Failai **ESS4LT1**, **ESS4PT**, **ESS4IL**. Kintamieji: *cntry* – šalies kodas, *agea* – amžius, *gnbr* – lytis (1 – vyr., 2 – mot.), *pray* – kaip dažnai meldžiamasi (matuojamas 7 balų skale nuo 1 – kasdien iki 7 – niekada), *hhmb* – pastoviai kartu gyvenančių namų ūkio narių skaičius,


- *stfedu*, *stflife*, *stfeco*, *stfgov*, *stfdem*, *stfhlth* – respondento požiūris į savo šalies švietimo sistemos būklę, savo gyvenimą, ekonominę padėtį, vyriausybę, demokratijos būklę, sveikatos apsaugą (reikšmės nuo 0 – itin bloga, iki 10 – itin gera),
- *trstprl*, *trstlgl*, *trstplc*, *trstplt*, *trstprrt*, *trstep*, *trstun* – pasitikėjimas savo šalies parlamentu, teisine sistema, policija, politikais, partijomis, Europarlamentu, Jungtinėmis Tautomis, (matuojamas 10 balų skale nuo 0 – itin nepasitikiu, iki 9 – itin pasitikiu),

Pritaikius daugianarę logistinę regresiją, ištirti, kokie kintamieji padeda apibūdinti respondentės šalį. Tirti 35–40 metų moteris.

3. Pritaikyti daugianarės logistinės regresijos modelį 6.2 skyrelio problemai. Kuris modelis geriau tinka?



Dvinarė



Daugianarė


Logistinės regresijos

6. RANGINĖ LOGISTINĖ REGRESINĖ ANALIZĖ

Tipinės situacijos, kai taikoma ranginė logistinė regresinė analizė, yra šios:

- Norime įvertinti, kaip respondento požiūris į gyvenimą (nykuma – rutina – smaguma) priklauso nuo jo išsilavinimo, lyties ir turinės padėties.
- Tiriame, kas apibūdina pritarimą vykdomai užsienio politikai (visai nepritariu – labiau nepritariu nei pritariu – labiau pritariu nei nepritariu – pritariu).
- Manome, kad teniso turnyruose laimėta prizinė vieta priklauso nuo vidutinio smūgiuoto kamuoliuko greičio.

Ranginė logistinė regresija dar vadinama daugialyge logistine regresija arba proporcingų galimybių modeliu⁶⁵. Kartais vartojamas trumpesnis terminas – ranginė regresija, praleidžiant žodį „logistinė“. Modelio schema:



Ranginis kintamasis Y vadinamas priklausomu kintamuoju, kintamieji X, Z, W vadinami regresoriais. Ranginė logistinė regresija yra daugianarės logistinės regresijos analogas, kai naudojama informacija apie Y ranginę struktūrą.

6.1. Ranginės logistinės regresijos modelis

6.1.1. Modelio lygtys

Analogiškai daugianarei regresijai ranginė logistinė regresija leidžia įvertinti ranginio priklausomo kintamojo Y reikšmių įgijimo tikimybes. Matematinis modelis aprašomas keliomis lygtimis. Todėl toliau, aprašydami teorinį modelį remsimės pavyzdžiu, kai priklausomas kintamasis Y įgyja 4 rangines reikšmes ($Y = 1, 2, 3, 4$). Visi modeliai sudaromi tam tikrų tikimybių santykiams, pasirenant įvairias vadinamąsias *jungties* funkcijas. Tų funkcijų yra įvairių. Aprašysime

⁶⁵ Angl. *proportional odds*.

populiariausią *logit* funkciją. Tarkime, kad Y priklauso nuo intervalinių arba dvireikšmių regresorių X, Z, W . Sudaromi trys matematiniai modeliai priklausomo kintamojo tikimybių santykių logaritmams (*logit* funkcijoms). Nors visi modeliai sudaromi tikimybių $P(Y \leq i)$ ir $P(Y > i)$ santykiui, tačiau konkreti modelio išraiška priklauso nuo naudojamos statistinės programos. STATA programoje ranginės regresijos modelis atrodo taip:

$$\ln \frac{P(Y > i)}{P(Y \leq i)} = C_i + b_1 X + b_2 Z + b_3 W, \quad i = 1, 2, 3, \quad (1)$$

t. y.

$$\begin{aligned} \ln \frac{P(Y > 1)}{P(Y \leq 1)} &= C_1 + b_1 X + b_2 Z + b_3 W, \quad \ln \frac{P(Y > 2)}{P(Y \leq 2)} = C_2 + b_1 X + b_2 Z + b_3 W, \\ \ln \frac{P(Y > 3)}{P(Y \leq 3)} &= C_3 + b_1 X + b_2 Z + b_3 W. \end{aligned}$$

SPSS ir R programose naudojamas modelis su priešingu konstantos ženklu:

$$\ln \frac{P(Y > i)}{P(Y \leq i)} = -C_i + b_1 X + b_2 Z + b_3 W, \quad i = 1, 2, 3, \quad (2)$$

Atkreipsime dėmesį, kad literatūroje dažniausiai pateikiamas toks (2) modelio užrašas:

$$\ln \frac{P(Y \leq i)}{P(Y > i)} = C_i - b_1 X - b_2 Z - b_3 W, \quad i = 1, 2, 3, \quad (2')$$

SAS programoje ranginės regresijos modelis užrašomas priešingam nei modelyje (1) tikimybių santykiui:

$$\ln \frac{P(Y \leq i)}{P(Y > i)} = C_i + b_1 X + b_2 Z + b_3 W, \quad i = 1, 2, 3, \quad (3)$$

Konstantos ir koeficientai $C_1, C_2, C_3, b_1, b_2, b_3$ nėra žinomi. Jų įverčiai $\hat{C}_1, \hat{C}_2, \hat{C}_3, \hat{b}_1, \hat{b}_2, \hat{b}_3$ gaunami panaudojus imties duomenis. Atkreipiame dėmesį, kad visose lygtyse regresorių koeficientai yra tie patys (pvz., visose lygtyse prie X yra tas b_1), o skiriasi tik konstantos C_1, C_2, C_3 . Modelio parametrų $C_1, C_2, C_3, b_1, b_2, b_3$ (konstantų ir koeficientų) įverčiai naudojami prognozuoti, galimybių santykiams įvertinti ir regresorių įtakai interpretuoti. Modelio koeficiento įverčio ženklo interpretacija priklauso nuo tiriamo modelio.

Tarkime, kad $\hat{b}_1 > 0$.

- Jeigu tiriamo (1) arba (2) modelius, didėjant X didėja tikimybė, kad Y įgis didesnes reikšmes (didėja santykis $P(Y > i)/P(Y \leq i)$).
- Jeigu tiriamo (3) modelį, didėjant X didėja tikimybė, kad Y įgis mažesnes reikšmes (didėja santykis $P(Y \leq i)/P(Y > i)$).

6.1.2. Galimybės ir jų santykis

STATA ir SPSS ranginės regresijos modeliuose galimybė vadinamas tikimybių santykis $P(Y > j)/P(Y \leq j)$. SAS modelyje galimybė vadinamas santykis $P(Y \leq j) / P(Y > j)$.

Galimybė $P(Y \leq j) / P(Y > j)$ parodo, kiek kartų kintamajam Y tikėtinau įgyti reikšmę $Y \leq j$ nei $Y > j$.

Galimybė $P(Y > j) / P(Y \leq j)$ parodo, kiek kartų kintamajam Y tikėtinau įgyti reikšmę $Y > j$ nei $Y \leq j$.

Galimybių santykis parodo, kaip pasikeis galimybė (tikimybių santykis), kai atitinkamas kintamasis padidės vienetu, fiksuojant kitų kintamųjų reikšmes. Galimybių santykis priklauso tik nuo modelio koeficientų. Tarkime, kad nagrinėjame (3) modelį. Tada, X padidėjus vienetu, naujoji galimybė per ankstesnę išsireiškia taip:

$$\left(\frac{P(Y \leq j)}{P(Y > j)} \right)_{\text{nauja}} = e^{b_1} \left(\frac{P(Y \leq j)}{P(Y > j)} \right)_{\text{ankstesnė}}$$

Daugiklis e^{b_1} , kuris ir yra vadinamas galimybių santykiu, yra kiekybinis kintamojo X įtakos modelyje įvertinimas. Jeigu $b_1 > 0$, žinome, kad X didėjant, taip pat didėja tikimybė, kad Y įgis

didesnes reikšmes. Tai kokybinė charakteristika. O kiek padidės ta tikimybė? Atsakyti į šį klausimą neįmanoma, nežinant pačios pradinės tikimybės. Galimybių santykis yra kompromisinis sprendimas – parodo, kiek pasikeis tikimybių santykis. Pavyzdžiui, jeigu $e^{b_1} = 2$, santykis padvigubės. Tai **neriškia**, kad tikimybė $P(Y \leq j)$ padvigubės. Tiesą sakant, šiuo konkrečiu atveju naujoji tikimybė visada padidės mažiau nei dvigubai. Jei senoji tikimybė yra 0,5 (santykis 1 : 1), naujoji bus 2/3 (santykis 2 : 1); jei senoji tikimybė 0,25 (santykis 1 : 3), naujoji 0,40 (santykis 2 : 3) ir pan.

6.1.3. Prognozavimas

Atkreipiame dėmesį į tai, kad $P(Y > i) = 1 - P(Y \leq i)$. Todėl, naudojantis aprašytaisiais modeliais, nesunku rasti $P(Y \leq i)$. O šias tikimybes jau galima panaudoti skaičiuojant $P(Y = i)$. Kadangi Y įgyja tik sveikas reikšmes, nesunku suprasti, kad

$$P(Y = j) = P(Y \leq j) - P(Y \leq j - 1).$$

Pažymėkime dešinę (1), (2) arba (3) modelio lygybės pusę simboliu z_i . Tada

(1) ir (2) modeliams:

$$P(Y > i) = \frac{1}{1 + e^{-z_i}},$$

(3) modeliui:

$$P(Y \leq i) = \frac{1}{1 + e^{-z_i}}.$$

Konkrečioms tikimybių prognozėms naudojame modelius su koeficientų įverčiais.

Pavyzdys. Tiriame (3) modelį. Tarkime, kad, atlikę ranginę logistinę regresiją, gavome tokius koeficientų įverčius: $\hat{C}_1 = 1, \hat{C}_2 = 2, \hat{C}_3 = 4, \hat{b}_1 = 1, \hat{b}_2 = -1, \hat{b}_3 = 2$. Tikimybių įverčius norime gauti respondentui, kuriam $X = 2, Z = 1, W = 0$. Atsižvelgę į (3) modelio dešinę pusę, matome, kad $z_i = C_i + b_1 X + b_2 Z + b_3 W$. Įstatome $X = 2, Z = 1, W = 0$ ir koeficientų įverčius. Gauname

$$z_1 = 1 + 1 \cdot 2 - 1 \cdot 1 + 2 \cdot 0 = 2, \quad z_2 = 2 + 1 \cdot 2 - 1 \cdot 1 + 2 \cdot 0 = 3, \quad z_3 = 5.$$

Prisiminę, kad Y įgyja tik reikšmes 1, 2, 3, 4, apskaičiuojame

$$\hat{P}(Y \leq 1) = \hat{P}(Y = 1) = \frac{1}{1 + e^{-z_1}} = \frac{1}{1 + e^{-2}} = 0,880 \dots;$$

$$\hat{P}(Y \leq 2) = \frac{1}{1 + e^{-z_2}} = \frac{1}{1 + e^{-3}} = 0,952 \dots; \hat{P}(Y \leq 3) = \frac{1}{1 + e^{-5}} = 0,993 \dots$$

Pasinaudoję skyrelio pradžioje pateiktomis formulėmis surandame visus tikimybių įverčius:

$$\hat{P}(Y = 1) = 0,88; \hat{P}(Y = 2) = \hat{P}(Y \leq 2) - \hat{P}(Y = 1) = 0,95 - 0,88 = 0,07;$$

$$\hat{P}(Y = 3) = \hat{P}(Y \leq 3) - \hat{P}(Y \leq 2) = 0,99 - 0,95 = 0,04;$$

$$\hat{P}(Y = 4) = 1 - \hat{P}(Y \leq 3) = 1 - 0,99 = 0,01.$$

Kartais reikalinga šiurkšti prognozė, kurį iš galimų Y atsakymų rinksis respondentas. Prognozė daroma taip: įvertinamos visų galimų Y reikšmių tikimybės. Prognozuojame tą reikšmę, kurios įgijimo tikimybė didžiausia. Pavyzdžio atveju prognozuotume, kad Y įgis 1.

6.1.4. Duomenys

Duomenys turi tenkinti tokius reikalavimus:

- Priklausomas kintamasis Y turi būti ranginis. Kai rangų pakankamai daug (bent 7 arba, kaip sako itin liberalūs statistikai, bent 5), o Y vidurkis visiškai prasmingas, galima bandyti taikyti tiesinės regresijos modelį.
- Regresoriai – intervaliniai, ranginiai arba kategoriniai kintamieji. Nereikalaujama regresorių normalumo. Kategoriniai regresoriai keičiami dvireikšmiaisiais pseudokintamaisiais.
- Duomenyse kažkurių Y reikšmių negali būti labai mažai. Turime turėti informacijos apie įvairių kategorijų respondentus, kad galėtume nustatyti, kas būdinga kiekvienai kategorijai. Iš tikrųjų reikalavimas yra kiek stipresnis: pakankamai (dažniausiai bent 5) reikšmės turi būti kiekvienam kategorinių regresorių ir priklausomo kintamojo Y reikšmių deriniui. Todėl į modelį įtraukdami daug kategorinių regresorių galime susidurti su problemomis.
- Turi būti tenkinama *lygiagrečių tiesių* prielaida. Matematiškai šią prielaidą galime nusakyti kaip reikalavimą, kad modeliuose gali skirtis tik konstantos C_1, C_2, C_3 , o daugikliai b_1, b_2, b_3 visuose modeliuose yra tie patys. Ar tenkinama ši prielaida, tikrinama specialiu chi kvadrato kriterijumi. Lygiagrečių tiesių prielaida – reikalavimas, kad „atstumai“ tarp Y rangų būtų vienodi. Kai yra keli regresoriai, grafiškai lygiagrečių tiesių prielaidą pavaizduoti sudėtinga – ji virsta lygiagrečių hiperplokštumų prielaida.

6.1.5. Modelio tinkamumas

Modelio tinkamumą duomenims rodo:

- a) *Modelio tikėtinumų santykio kriterijus*⁶⁶. Vertinamas bendrasis modelio tikimas duomenims. Gerai duomenims tinkančio modelio $p < 0,05$. Jeigu $p \geq 0,05$, regresijos modelio tinkamumas labai abejotinas.
- b) *Pirsono ir deviacijos kriterijai*. Tai tikėtinumų santykio kriterijaus alternatyvos. Modelis gerai tinka duomenimis, kai Pirsono ir deviacijos kriterijų p reikšmės yra didelės ($p \geq 0,05$). Kai modelyje yra intervalinių regresorių, Pirsono ir deviacijos kriterijų p reikšmės beveik visada yra nepatikimas modelio gerumo indikatorius. Be to, šios charakteristikos jautrios imties didumui. Didelėms imtims p reikšmės gali būti nepagrįstai mažos. Todėl į šias charakteristikas atsižvelgiama toli gražu ne visada.
- c) *Voldo kriterijus*. Šis kriterijus padeda nuspręsti, kurie regresoriai modelyje reikalingi (yra statistiškai reikšmingi, jų $p < 0,05$). Gerame modelyje visi regresoriai yra statistiškai reikšmingi. Paprastai konstantai šio kriterijaus netaikome ir iš modelio nešaliname net ir statistiškai nereikšmingos konstantos.
- d) *Determinacijos (pseudo) koeficientai*. Parodo bendrąjį modelio tikimą. Kuo koeficiento reikšmė didesnė, tuo modelis geriau tinka duomenims. Nelabai gerai, kai $R^2 < 0,20$. Ranginėje logistinėje regresijoje determinacijos koeficientai tik pagalbiniai. Jų yra net keli (Kokso–Snello, Nagelkerkės, Makfadenio). Kurį iš jų naudoti, dažniausiai nusprendžia (sufantazuoja) tyrėjas. Privalu nurodyti tikslų determinacijos koeficiento pavadinimą.
- e) *Tiesių lygiagretumo kriterijus*. Tiesių lygiagretumo prielaida galioja, kai kriterijaus p reikšmė $\geq 0,05$. Geruose modeliuose tiesių lygiagretumo prielaida galioja.
- f) *Y reikšmių įgijimo tikimybių įverčiai ir klasifikacinė lentelė*. Konkretiems stebiniams prognozuojamos Y reikšmės įgijimo tikimybės, pasirenkama ta Y reikšmė, kurios įgijimo tikimybė didžiausia, ir tikrinama, ar spėjimas sutapo su tikrąja Y reikšme. Kuo daugiau sutapčių, tuo modelis geresnis. Ranginėje logistinėje regresijoje ši charakteristika nelaikoma labai svarbia. Kai kurios statistinės programos jos net neskaičiuoja. Vis dėlto, jeigu visos kategorijos vienodai svarbios, kiekvienos jų teisingų atpažinimų procentas neturi būti mažesnis už tos kategorijos duomenų procentą imtyje.

Apibendrinami galime nusakyti, kokie turi būti gero regresijos modelio rodikliai.

⁶⁶ Angl. *likelihood ratio test*.

Gera duomenims tinkamo modelio:

- Tikėtinumų santykio kriterijaus $p < 0,05$.
- Visų regresorių Voldo kriterijaus $p < 0,05$.
- Tiesių lygiagretumo kriterijaus $p \geq 0,05$.
- Klasifikacinėje lentelėje teisingų kiekvienos kategorijos klasifikavimų procentas ne mažesnis už tos kategorijos duomenų procentą imtyje.
- Nelabai didelėms imtims, turinčioms nedaug (arba neturinčioms) intervalinių regresorių, deviacijos kriterijaus ir Pirsono kriterijaus $p \geq 0,05$.

6.1.6. Modelio tyrimas ir tobulinimas

Patikriname visas svarbiausias charakteristikas.

- 1) Jeigu modelio tikėtinumų santykio kriterijaus p reikšmė $\geq 0,05$, **modelis netinkamas**.
- 2) Patikriname, ar visi regresoriai statistiškai reikšmingi (visos Voldo kriterijaus p reikšmės $< 0,05$). Jeigu ne – modelis taisytinas. Konstantos statistinio reikšmingumo netiriame.
- 3) Patikriname, ar tenkinama tiesių lygiagretumo prielaida. Jeigu atitinkama p reikšmė $< 0,05$, reikia papildomos analizės (STATA dažniausiai tenka ieškoti programos papildo *gologit2*, alternatyva – taikyti nominaliąją regresiją).
- 4) Papildomai galima ištirti, ar deviacijos ir Pirsono kriterijų p reikšmės $\geq 0,05$ (taip turi būti geruose nedidelių imčių modeliuose, turinčiuose nedaug intervalinių regresorių), surasti galimybių ir jų santykių įverčius, determinacijos koeficientus ir klasifikacinę lentelę. Jeigu viskas gerai – modelį aprašome, jei ne – tobuliname.

Modelio tobulinimas reiškia regresorių šalinimą arba jų transformaciją. Pašalinus bent vieną regresorių, keičiasi visos modelio charakteristikos: determinacijos koeficientai, visos p reikšmės. Modelis tobulinamas, jeigu:

- 1) *Yra statistiškai nereikšmingas regresorius* Tada šis regresorius pašalinamas iš modelio, ir logistinė regresinė analizė pakartojama be jo.
- 2) *Netenkinama tiesių lygiagretumo prielaida*, dar pažiūrime, ar pati statistikos reikšmė yra nedidelė. Galime gauti mažą p reikšmę vien todėl, kad turime daug duomenų. Tada modelio atmesti kaip netinkamo negalima. Alternatyva – kitokių jungties funkcijų pasirinkimas.

6.1.7. Pastabos apie ranginės regresijos taikymą

- Gali būti ir vienas regresorius.
- Pseudokintamieji aprašomi taip pat kaip ir tiesinėje regresijoje.
- Jeigu turime abejonių dėl ranginės regresijos modelio tinkamumo, visada galima išbandyti daugianarės logistinės regresijos modelį. Atrodytų, kad daugianarės logistinės regresijos modelis yra tikslesnis, ir ranginė logistinė regresija apskritai nebereikalinga. Vis dėlto yra pavyzdžių, kai duomenims ranginės logistinės regresijos modelis tinka, o daugianarės logistinės regresijos modelis – ne.
- Aprašymuose dažnai apsiribojama bendruoju teisingų klasifikavimų procentu. Tai nėra blogai. Tik reikia nepamiršti, kad gerai atpažinti turi visas Y kategorijas.
- Galimos ir kitos jungties funkcijos, ne tik logaritminė. Jas galima taikyti klasifikavimui, bet nebebus teisinga galimybių santykių interpretacija. Be to, terminas *logistinė regresija* tada nevartotinas, reikia kalbėti apie vieną ar kitą ranginės regresijos modelį. Paminėsime kelias jungties funkcijas, kurias galima naudoti, kai svarbus tik teisingas klasifikavimas:

- *Dvigubas logaritmas (log-log)*. Modelis atrodo taip:

$$\ln(-\ln(1 - P(Y > i))) = C_i - b_1 X - b_2 Z - b_3 W.$$

Šią jungties funkciją rekomenduojama naudoti, kai didesnės Y reikšmės labiau tikėtinos nei mažesnės.

- *Neigiamas dvigubas logaritmas (negative log-log)*. Modelis atrodo taip

$$-\ln(-\ln(1 - P(Y > i))) = C_i - b_1 X - b_2 Z - b_3 W.$$

Šią jungties funkciją rekomenduojama naudoti, kai mažesnės Y reikšmės labiau tikėtinos nei didesnės.

- *Atvirkštinis Koši skirstinys (Cauchit)*. Tikimybė $P(Y \leq i)$ išreiškiama per Koši pasiskirstymo funkciją. Modelio lygties nepateiksime, nes ji labai sudėtinga. Užtikriname, kad Koši pasiskirstymo funkcija yra pakankamai sudėtinga, kad praeitų bet koks noras šį modelį skaičiuoti „rankomis“. Koši jungties funkcija rekomenduojama naudoti tada, kai yra daug išskirtinai didelių ir / ar mažų Y reikšmių.

6.1.8. Standartiniai ranginės logistinės regresijos modelių aprašymai

Visada aprašomas galutinis, po visų tobulinimų gautasis modelis. Pateiksime keletą galimų aprašymų fragmentų.

- *Taikytas daugianarės ranginės regresijos modelis. Modelio tikėtinumų santykio kriterijaus statistikos reikšmė $\chi^2=13,27$; o $p < 0,05$. Visi regresoriai buvo statistiškai reikšmingi. Teisingai klasifikuota 70,5 % imties respondentų. Nagelgerkės determinacijos koeficientas lygus 0,49. Kintamajam X padidėjus 1, galimybių ($P(Y > i) / P(Y \leq i)$) santykis padidėja 2,3 karto.*
- *Modelyje paliktas statistiškai nereikšmingas regresorius Z , nes jį pašalinus labai sumažėja teisingai klasifikuotų atvejų procentas...*
- *Kintamajam X padidėjus 1, galimybių ($P(Y \leq i)/P(Y > i)$) santykis sumažėja 2,3 karto...*

6.2. Ranginė logistinė regresinė analizė su SPSS

6.2.1. Duomenys

Kaip atlikti ranginę logistinę regresinę analizę, parodysime, naudodami Lietuvos aukštojo mokslo tyrimo duomenis **LAMS**. Tyrime naudosime tokius kintamuosius:

- $K32$ – asmeninės vidutinės pajamos prieš mėnesį (1 – mažiau kaip 1 000, ..., 9 – daugiau kaip 10 000);
- $K36_1$ – studijų metu įgytų žinių panaudojimo esamame darbe įvertinimas (1 – visiškai nenaudoju, ..., 5 – labai dažnai naudoju, 99 – nestudijavau / negaliu atsakyti);
- $K2$ – aukštoji mokykla;
- $D8$ – miesto (gyvenvietės), kurioje dirba didumas, (1 – iki 2000, ..., 7 – daugiau kaip 500 000, 8 – dirbu ne Lietuvoje);
- $K25$ – pirmojo darbo atitiktis bakalauro studijų kryptčiai (1 – tikrai taip, ..., 4 – tikrai ne, 99 – sunku pasakyti);
- $K11_1$ – bakalauro studijų rezultatų įvertinimas (1 – dažniausiai pažymių vidurkis būdavo vienas iš žemiausių kurse, ..., 5 – dažniausiai pažymių vidurkis būdavo vienas iš pirmiausių kurse, 99 – nestudijavau);
- $K33_1$ – išsilavinimo lygio įtaka, pasiekiant esamą padėtį darbo rinkoje (1 – visai nereikšmingas veiksnys, ..., 5 – labai reikšmingas veiksnys, 99 – nestudijavau).

Norime nustatyti, kaip studijas baigusių respondentų studijų metu gautų žinių naudingumo įvertinimas priklauso nuo respondento pažangumo bei nuomonės apie išsilavinimo įtaką darbo pasiekimams. Tirsime Vilniaus universiteto (VU), Vilniaus Gedimino technikos universiteto (VGTU) ir Lietuvos žemės ūkio akademijos (LŽŪA) absolventus, dirbančius Lietuvoje.

Kadangi verta tirti tik studijavusius žmones ($K36_1 \neq 99$), kurie baigė VU, VGTU ir LŽŪA ($K2 = 13, 7, 11$), dirba Lietuvoje ($D8 \leq 7$) ir supranta, ar darbas atitinka studijų pobūdį ($K25 \neq 99$), su **Select Cases** atrenkame tinkamus respondentus. Sąlyga:


$K36_1 \neq 99 \& K25 \neq 99 \& (K2 = 13 | K2 = 11 | K2 = 7) \& (D8 \leq 7)$.

Reikia iš tyrimo pašalinti kintamųjų $K11_1$, $K33_1$, $K36_1$ reikšmes 99. Tą padarysime jas įvardydami kaip trūkstamas reikšmes⁶⁷. Atidarome **Variable View** langą. Pasirinkę **Missing**, kintamiesiems $K11_1$ ir $K33_1$ paeiliui nurodome, kad 99 yra praleista reikšmė.

Patikriname, ar turime pakankamai daug skirtingų požiūrių į studijų metu gautas žinias. Pritaikę **Frequencies** matome, kad kintamasis $K36_1$ įgyja labai nedaug mažų reikšmių, todėl tikslingiau naudoti mažiau kategorijų turintį ranginį kintamąjį.

K36_1 Studijų metu įgytų profesinių žinių panaudojimo esamame darbe įvertinimas					
		Frequency	Percent	Valid Percent	Cumulative Percent
Valid	1 Visiškai nenaudoju	6	3.6	3.6	3.6
	2	13	7.7	7.7	11.3
	3	34	20.2	20.2	31.5
	4	50	29.8	29.8	61.3
	5 Labai dažnai naudoju	65	38.7	38.7	100.0
Total		168	100.0	100.0	

Naudodami komandą **Recode into Different Variables**, sukuriame naują kintamąjį $Bakna3$, kuris lygus 1, kai $K36_1 = 1, 2$ arba 3 (menkas profesinių žinių naudojimas), $Bakna3 = 2$, kai $K36_1 = 4$ (vidutinis naudojimas), $Bakna3 = 3$, kai $K36_1 = 5$ (labai dažnas naudojimas).



⁶⁷ Angl. *missing values*.


Analogiškai įsitikiname, kad *K32* įgyja labai mažai didelių reikšmių (mažai absolventų gauna labai didelius atlyginimus). Šį kintamąjį taip pat keičiame kintamuoju, turinčiu mažiau kategorijų. Naudodami komandą **Recode into Different Variables**, sukuriame naują kintamąjį *algl2*, kuris visus respondentus padalija į uždirbančius iki 1500 LTL per mėn. (*algl2* = 1) ir uždirbančius daugiau nei 1500 LTL per mėn. (*algl2* = 2). Beje, nežinančių, kiek uždirba (*K32* = 99), į tyrimą neįtraukėme ir perkoduodami šio kodo nenaudojome.

6.2.2. SPSS parinktys ranginei logistinei regresijai


Tirsime modelį, kurį sąlygiškai galima užrašyti taip:

$$Bakna3 = f(algl2, K11_1, K33_1).$$


Atsidarome langelį **Analyze** ir renkamės **Regression → Ordinal**.



Atsidariusiame meniu perkeliame kintamąjį *Bakna3* į laukelį **Dependent**. Kintamuosius *K11_1*, *K33_1* įkeliamė į laukelį **Covariates**. Kintamasis *algl2* yra kategorinis, todėl jį keliame į **Factor(s)**.



Pasirenkame **Output** ir papildomai pažymime **Test of parallel lines** ir **Predicted category** (tam, kad galėtume sudaryti klasifikacinę lentelę). Pasirenkame **Continue** ir **OK**.



6.2.3. Rezultatai

Rezultatų išklotinė prasideda nuo įspėjimo, kad 28,6 % langelių tušti.

Warnings

There are 18 (28.6%) cells (i.e., dependent variable levels by combinations of predictor variable values) with zero frequencies.

Apie kokius langelius čia kalbama? Tai tikrinimas, ar bent kelios *Bakna3* reikšmės yra įgyjamos kiekvienam regresorių reikšmių deriniui (pvz., ar yra bent viena *Bakna3* reikšmė, kai $K11_1 = 1$, $K33_1 = 1$, o $algl2 = 1$). Šis rodiklis gali būti informatyvus, kai regresoriai yra kategoriniai. Tada didelis procentas tuščių langelių rodo, kad vertėtų dalį kategorinių kintamųjų iš modelio arba pašalinti, arba sustambinti jų kategorijas. Kai modelyje yra intervalinių kintamųjų, šis įspėjimas ignoruojamas. Nors regresoriai $K11_1$, $K33_1$ tik labai „pritemptai“ laikytini intervaliniais, šį įspėjimą taip pat ignoruosime. Didelis tuščių langelių procentas taip pat rodo, kad nelabai galima pasitikėti Pirsono ir deviacijos chi kvadrato statistikos p reikšmėmis.

Lentelėje **Case Processing Summary** yra informacijos, kokias reikšmes įgyja modelio kategoriniai kintamieji. Visų pirma įsitikiname, kad pakankamai daug (žr. atitinkamas rekomendacijas daugianarei logistinei regresijai) stebinių atitinka kiekvieną kintamųjų *Bakna3* ir regresorius *algl2* kategoriją. Modelis nebūtų labai logiškas, jeigu būtų informacijos tik apie kelis respondentus, uždirbančius daugiau nei 1500 LTL, beveik nebūtų dažnai studijų žinias darbe taikiusių respondentų ir pan.

Case Processing Summary

		N	Marginal Percentage
Bakna3 Studijų panaudojimas darbe	1.00 menkas naudojimas	51	30.7%
	2.00 vidutinis naudojimas	50	30.1%
	3.00 dažnas naudojimas	65	39.2%
alg12 alga per men.	1.00 iki 1500	52	31.3%
	2.00 virš 1500	114	68.7%
Valid		166	100.0%
Missing		2	
Total		168	

Priklausomo kintamojo *Bakna3* įgyjamų reikšmių procentai naudotini ir tiriant klasifikavimo tikslumą. Pavyzdžiui, visą laiką spėdami, kad studijų panaudojimas darbe yra vidutinis (*Bakna3* = 2), teisingai klasifikuotume 30,1 % atsakymų. Logiška reikalauti, kad pasiūlytas ranginės logistinės regresijos modelis užtikrintų neblogesnę klasifikavimo procentą.

Lentelėje **Model Fitting Information** yra tikėtinumų santykio kriterijaus statistikos reikšmė ir atitinkama *p* reikšmė. Kadangi $p = 0,000... < 0,05$, gavome vieną iš svarbiausių patvirtinimų, kad modelis duomenims tinka.

Model Fitting Information

Model	-2 Log Likelihood	Chi-Square	df	Sig.
Intercept Only	147.472			
Final	82.100	65.372	3	.000

Link function: Logit.

Lentelėje **Goodness-of-Fit** yra Pirsono ir deviacijos statistikų reikšmės ir *p* reikšmės. Kadangi abi $p > 0,05$, gavome dar vieną patvirtinimą, kad modelis duomenims tinka. Primename, kad šios *p* reikšmės svarbios tik tada, kai imtys nedidelės. Taip ir yra tiriamu atveju, nes imtį sudaro tik 166 respondentai (žr. lenteles pirmiau). Determinacijos koeficientai (lentelė **Pseudo R-Square**) nėra itin dideli. Vis dėlto du iš jų yra didesni už 0,20, o ir trečiasis nedaug mažesnis. Taigi ir šie rodikliai nerodo labai blogo modelio tikimo.

Goodness-of-Fit			
	Chi-Square	df	Sig.
Pearson	25.434	37	.925
Deviance	26.579	37	.898

Link function: Logit.

Pseudo R-Square	
Cox and Snell	.326
Nagelkerke	.367
McFadden	.180

Link function: Logit.

Parametrų įverčiai ir jų 95 % pasikliautiniai intervalai yra lentelėje **Parameter Estimates**. Prisimename, kad SPSS tiria (2) modelį „su priešingo ženklo konstanta“:

$$\ln \frac{P(Y > i)}{P(Y \leq i)} = -C_i + b_1 X + b_2 Z + b_3 W.$$

Teigiamas regresoriaus koeficientas rodo, kad, didėjant regresoriaus reikšmėms, labiau tikėtinomis taps ir didesnės *Bakna3* reikšmės. Teigiami regresorių *K11_1* ir *K33_1* koeficientai (1,182 ir 0,979) visiškai atitinka modelio logiką: kuo geriau respondentas(ė) mokėsi bakalauro studijų metu ir kuo svarbesne laikoma išsilavinimo įtaka karjerai, tuo labiau tikėtina, kad jis(ji) palankiau įvertins studijų medžiagos naudojimą darbe. Analogiškai interpretuojamas ir kategorinio kintamojo *algl2* koeficientas. SPSS pakete ši informacija pateikiama ne itin patogiu pavidalu. Manoma, kad *algl2* = 2 yra pagrindinė kategorija (jos koeficiento nėra), ir stebima, kaip viskas keisis, jeigu *algl2* = 1. Matome, kad kai *algl2* = 1, koeficientas yra neigiamas (-1,277). Prisimename, kad neigiamas koeficientas rodo, jog, didėjant kintamojo reikšmėms, labiau tikėtinos taps ir mažesnės *Bakna3* reikšmės. Taigi informacija, jog respondentas(ė) uždirba iki 1500 LTL, padaro labiau tikėtiną tikimybę, kad jis(ji) mažiau naudojasi studijų metu sukauptomis žiniomis.

Parameter Estimates								
							95 % Confidence Interval	
							Lower Bound	Upper Bound
		Estimate	Std. Error	Wald	df	Sig.		
Threshold	[Bakna3 = 1.00]	7.567	1.426	28.177	1	.000	4.773	10.362
	[Bakna3 = 2.00]	9.286	1.490	38.850	1	.000	6.366	12.206
Location	K11_1	1.182	.264	20.098	1	.000	.665	1.698
	K33_1	.979	.205	22.866	1	.000	.578	1.380
	[algl2=1.00]	-1.277	.360	12.565	1	.000	-1.984	-.571
	[algl2=2.00]	0 ^a	.	.	0	.	.	.

Link function: Logit.

a. This parameter is set to zero because it is redundant.

Tikimybėms skaičiuoti naudotina tokia formulė ($i = 1, 2$):

$$\ln \frac{\hat{P}(Bakna3 > i)}{\hat{P}(Bakna3 \leq i)} = 1,18K11_1 + 0,98K33_1 - \begin{cases} 7,57, & \text{jei } i = 1, \\ 9,29, & \text{jei } i = 2, \end{cases} - \begin{cases} 1,28, & \text{jei } algl2 = 1, \\ 0, & \text{jei } algl2 = 2. \end{cases}$$

Beliktų į šią formulę įstatyti konkretaus respondento duomenis.

Lentelėje **Test of Parallel Lines** tikrinama hipotezė, kad regresorių koeficientai yra tie patys visiems tikimybių santykiams (kaip ir pirmiau pateiktoje formulėje – kintant i , keičiasi tik poslinkio konstanta, o daugikliai, kai $K11_1$ ir $K33_1$, nesikeičia). Kadangi $p = 0,566 > 0,05$, ši hipotezė neatmetama.


Test of Parallel Lines ^a				
Model	-2 Log Likelihood	Chi-Square	df	Sig.
Null Hypothesis	82.100			
General	80.070	2.030	3	.566

The null hypothesis states that the location parameters (slope coefficients) are the same across response categories.

Visos pagrindinės modelio charakteristikos rodo gerą modelio tikimą duomenims, vis dėlto rekomenduotina patikrinti, ar modelis tinkamai klasifikuoja respondentus.

6.2.4. Klasifikacinė lentelė

Klasifikacinę lentelę lengviausia gauti pasinaudojus porinių (kryžminių) dažnių lentele. Kiekvienam respondentui esame išsaugoję prognozuojamą kintamojo *Bakna3* kategoriją (tai įvyko tada, kai SPSS parinktyse pažymėjome **Predicted category**. Duomenyse atsirado naujas stulpelis *PRE_1*, kuriame ir pažymėta toji kategorija). Pasirenkame **Analyze** → **Descriptive Statistics** → **Crosstabs**. Kintamąjį *Bakna3* įkeliamė į **Row(s)**, o *PRE_1* į **Column(s)**. Pasirenkame **Cells**.



Atsidariusiame lange papildomai pažymime **Row**. Spaudžiame **Continue** ir **OK**.

Percentages ☒ Row ☐ Column ☐ Total	Residuals ☐ Unstandardized ☐ Standardized ☐ Adjusted standardized
---	---

Gautojoje klasifikacinėje lentelėje matyti, kad teisingai klasifikuota 49 % atvejų, kai *Bakna3* = 1, 36% atvejų, kai *Bakna3* = 2 ir 72 % atvejų, kai *Bakna3* = 3. Ar tenkinamas toks klasifikavimo tikslumas? Visų pirma įsitikiname, kad kiekvienai *Bakna3* kategorijai teisingai klasifikuotų atvejų procentas yra ne mažesnis nei klaidingų klasifikavimų procentas. Be to, įsitikiname, kad, taikant modelį, visada klasifikavimo procentas didesnis, nei gautume akiai spėdami (žr. lentelę **Case Processing Summary**). Pavyzdžiui, visą laiką spėdami, kad *Bakna3* = 2, teisingai klasifikuotume 30,1% atvejų, o taikydami modelį – 36 % atvejų. Nors teisingų klasifikavimų procentai nėra labai dideli, jie yra pakankami, kad manytume modelį esant tinkamą duomenims.

Bakna3 Studiju panaudojimas darbe * PRE_1 Predicted Response Category Crosstabulation

			PRE_1 Predicted Response Category			Total
			1.00	2.00	3.00	
			menkas naudojimas	vidutinis naudojimas	dažnas naudojimas	
Bakna3 Studiju panaudojimas darbe	1.00 menkas	Count	25	17	9	51
	naudojimas	% within Bakna3	49.0%	33.3%	17.6%	100.0%
	2.00 vidutinis	Count	14	18	18	50
	naudojimas	% within Bakna3	28.0%	36.0%	36.0%	100.0%
	3.00 dažnas	Count	2	16	47	65
	naudojimas	% within Bakna3	3.1%	24.6%	72.3%	100.0%
Total		Count	41	51	74	166
		% within Bakna3	24.7%	30.7%	44.6%	100.0%

6.2.5. Rezultatų aprašymas

Pirmiausia aprašome, ką tyrėme, kokius kintamuosius naudojome ir kaip juos perkodavome. Tada kompaktiškai surašome visa tai, ką išsamiai aptarėme ankstesniame skyrelyje. Pateikiame vieną iš daugybės galimų tokio aprašymo variantų.

Duomenų analizei taikėme ranginę logistinę regresiją. Tiesių lygiagretumo prielaida buvo patenkinta ($\chi^2 = 2,03$; $df = 3$; $p = 0,566$). Pakankamai gerą pasirinkto modelio tikimą duomenims rodo tikėtinumų santykio kriterijus ($\chi^2 = 65,372$; $df = 3$; $p = 0,00$) bei Pirsono ($\chi^2 = 25,434$; $df = 37$; $p = 0,925$) ir deviacijos ($\chi^2 = 26,579$; $df = 37$; $p = 0,898$) kriterijai. Nagelkerkės determinacijos koeficientas yra 0,367. Taikant modelį teisingai klasifikuojama 49 % atvejų, kai Bakna3 = 1, 36 % atvejų, kai Bakna3 = 2 ir 72 % atvejų, kai Bakna3 = 3. Modelis su įvertintais parametrais atrodo taip:

$$\ln \frac{\hat{P}(\text{Bakna3} > i)}{\hat{P}(\text{Bakna3} \leq i)} = 1,18K11_1 + 0,98K33_1$$

$$- \begin{cases} 7,57, & \text{jei } i = 1, \\ 9,29, & \text{jei } i = 2, \end{cases} - \begin{cases} 1,28, & \text{jei } algl2 = 1, \\ 0, & \text{jei } algl2 = 2. \end{cases}$$

6.2.6. SPSS komandų sintaksė ranginei logistinei regresinei analizei

Surašysime, kaip atrodo SPSS komandos nagrinėtam ranginės logistinės regresijos modeliui. Jas galima vykdyti sintaksės lange, pasirenkant **Run**.

Kintamųjų atranka:

```
COMPUTE filter_$=(K36_1 ~= 99 & K25 ~= 99 & (K2 = 13 | K2 = 11 | K2 =7) & D8 <= 7).
VARIABLE LABELS filter_$ 'K36_1 ~= 99 & K25 ~= 99 & (K2 = 13 | K2 = 11 | K2 =7) & D8 <=
7 (FILTER)'.
VALUE LABELS filter_$ 0 'Not Selected' 1 'Selected'.
FORMATS filter_$ (f1.0).
FILTER BY filter_$.
EXECUTE.
```

Kintamųjų Bakna3 ir algl2 kūrimas:

```
RECODE K36_1 (4=2) (5=3) (1 thru 3=1) INTO Bakna3.
EXECUTE.
RECODE K32 (1 thru 2=1) (3 thru 9=2) INTO algl2.
EXECUTE.
```

Ranginės logistinės regresijos modelis:


```
PLUM Bakna3 BY algl2 WITH K11_1 K33_1  
/CRITERIA=CIN(95) DELTA(0) LCONVERGE(0) MXITER(100)  
MXSTEP(5) PCONVERGE(1.0E-6) SINGULAR(1.0E-8)  
/LINK=LOGIT  
/PRINT=FIT PARAMETER SUMMARY TPARALLEL  
/SAVE=PREDCAT.
```

Klasifikacinė lentelė:

```
CROSSTABS  
/TABLES=Bakna3 BY PRE_1 /FORMAT=AVALUE TABLES  
/CELLS=COUNT ROW /COUNT ROUND CELL.
```

6.2.7. Ranginė logistinė regresija su kintamųjų sąveika

Į modelį galima įtraukti ne tik pačius kintamuosius, bet ir jų sandaugas. Tada sakoma, kad modelyje yra kintamųjų tarpusavio sąveika (interakcija). Parodysime, kaip tą padaryti naudojantis SPSS programa. Visos parinktys išlieka tokios pat kaip aprašyta 5.2.2 skyrelyje. Papildomai pagrindiniame lange **Ordinal Regression** spaudžiame **Location**. Atsidariusiame lange pažymime **Custom**. Iš pateiktų **Type** parinkčių pasirenkame **Interaction** ir į laukelį **Location model** perkeliame visus regresorius po vieną ir regresorių *K11_1* ir *K33_1* kartu.



Tiriame modelį, kurį sąlygiškai galima užrašyti taip $Bakna3 = f(algl2, K11_1, K33_1, K11_1 * K33_1)$, t. y. visose formulėse prisideda kintamųjų $K11_1 * K33_1$ sandauga. Patikriname, ar naujasis modelis taip pat gerai tinka duomenims kaip ir modelis be interakcijos. Nepateiksime visų rezultatų, tik pažymėsime, kad visos modelio tikimo duomenims charakteristikos pagerėja, tačiau beveik visi kintamieji tapo statistiškai nereikšmingi.

Parameter Estimates								
		Estimate	Std. Error	Wald	df	Sig.	95 % Confidence Interval	
							Lower Bound	Upper Bound
Threshold	[Bakna3 = 1.00]	.561	4.670	.014	1	.904	-8.592	9.714
	[Bakna3 = 2.00]	2.305	4.672	.243	1	.622	-6.852	11.462
Location	[algl2=1.00]	-1.287	.363	12.583	1	.000	-1.999	-.576
	[algl2=2.00]	0 ^a	.	.	0	.	.	.
	K11_1	-.587	1.178	.248	1	.618	-2.896	1.722
	K33_1	-.595	1.045	.325	1	.569	-2.644	1.453
	K11_1 * K33_1	.399	.265	2.272	1	.132	-.120	.917


Link function: Logit.

a. This parameter is set to zero because it is redundant.

Taigi modelį papildžius nereikalinga kintamųjų interakcija, ji ne tik pasidarė statistiškai nereikšminga, bet ir visas modelis tapo visiškai netikęs.

6.2.8. Ranginė regresija su kitomis jungties funkcijomis

Parodysime, kaip ranginės regresijos modelyje pasirinkti kitą jungties funkciją. Pasirinksime ranginės regresijos Koši modelį. Atsidarome langelį **Analyze** ir renkamės **Regression** → **Ordinal**. Spaudžiame **Options**. Pasirenkame **Link** – **Cauchit**.



Spaudžiame **Continue** ir toliau viską darome taip kaip aprašyta 5.2.2 ir 5.2.4 skyreliuose. Nepateiksime visų gautų rezultatų, tik pažymėsime, kad beveik visos modelio tikimo charakteristikos liko nepakitusios, o klasifikacinė lentelė net pagerėjo: teisingai klasifikuota 47,1 % atvejų, kai $Bakna3 = 1$, 44 % atvejų, kai $Bakna3 = 2$, ir 72,3 % atvejų, kai $Bakna3 = 3$. Tiesa, šiam modeliui nebegalima kalbėti apie galimybių santykius. Kažkokių patikimų rekomendacijų, kada

kokią jungties funkciją naudoti, – nėra. Matyt, vienintelė protinga rekomendacija – jeigu neišėjo su logaritmine jungtimi gauti gero modelio, galima išbandyti kitas jungties funkcijas.

6.3. Ranginė logistinė regresinė analizė su STATA

6.3.1. Duomenys

Pasinaudosime su SPSS jau atliktomis **LAMS** failo duomenų transformacijomis. Tirsime Vilniaus universiteto (VU), Vilniaus Gedimino technikos universiteto (VGTU) ir Lietuvos žemės ūkio akademijos (LŽŪA) absolventus, dirbančius Lietuvoje. Kintamieji

- *K11_1* – bakalauro studijų rezultatų įvertinimas (1 – dažniausiai pažymių vidurkis būdavo vienas iš žemiausių kurse, ..., 5 – dažniausiai pažymių vidurkis būdavo vienas iš aukščiausių kurse, 99 – nestudijavau);
- *K33_1* – išsilavinimo lygio įtaka, pasiekiant esamą padėtį darbo rinkoje (1 – visai nereikšmingas veiksnys, ..., 5 – labai reikšmingas veiksnys, 99 – nestudijavau);
- *Bakna3* – profesinių žinių naudojimas (1 – menkas, 2 – vidutinis, 3 – labai dažnas);
- *algl2* – algos lygmuo (1 – iki 1500 LTL per mėn., 2 – daugiau nei 1500 LTL per mėn.).

Reikia iš tyrimo pašalinti kintamųjų *K11_1* ir *K33_1* reikšmes 99. Tą padarome, įvykdę:

```
keep if (K11_1 < 99 & K33_1 < 99)
```

Su išlyga kintamuosius *K11_1* ir *K33_1* galima tarti esant intervaliniams.

6.3.2. Modelio analizė

STATA ranginės regresijos modelyje tiriamas $P(Y > j) / P(Y \leq j)$ tikimybių santykis, todėl teigiamas regresoriaus koeficientas b_i rodo, kad, didėjant regresoriaus reikšmėms, labiau tikėtina taps ir didesnės Y reikšmės. Tirsime modelį, kurį galima užrašyti taip:

$$\ln \frac{P(Bakna3 > i)}{P(Bakna3 \leq i)} = C_i + b_1 K11_1 + b_2 K33_1 + b_3 algl2,$$

Jeigu *algl2* būtų intervalinis kintamasis, atitinkama komanda būtų *ologit Bakna3 algl2 K11_1 K33_1*. Kadangi *algl2* yra kategorinis kintamasis, pasinaudojame automatinio perkodavimo. Reikia prieš *ologit* parašyti *xi:*, o prieš kategorinius kintamuosius *i*. Automatinis perkodavimas vyksta taip: kiekviena kita regresoriaus reikšmė keičiama nauju dvireikšmiu regresoriumi (1 – atitinka tą senąją

reikšmę, o 0 – visas kitas reikšmes). Kai regresorius ir taip dvireikšmis, perkodavę gauname vienintelį jam identišką pseudokintamąjį.

Įvykdome

xi: ologit Bakna3 i.algl2 K11_1 K33_1

i.algl2

_ialgl2_1-2

(naturally coded; _ialgl2_1 omitted)

Iteration 0: log likelihood = -181.13054

Iteration 1: log likelihood = -149.19508

Iteration 2: log likelihood = -148.45194

Iteration 3: log likelihood = -148.44438

Iteration 4: log likelihood = -148.44438

Ordered logistic regression

Number of obs = 166

LR chi2(3) = 65.37

Prob > chi2 = 0.0000

Pseudo R2 = 0.1805

Log likelihood = -148.44438

Bakna3	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
_ialgl2_2	1.277259	.3600362	3.55	0.000	.5716016	1.982917
k11_1	1.18157	.2665309	4.43	0.000	.6591788	1.703961
k33_1	.9790868	.2020289	4.85	0.000	.5831174	1.375056
/cut1	8.84465	1.497767			5.909081	11.78022
/cut2	10.56329	1.569818			7.486499	13.64007

Modelio tikėtinumų santykio kriterijaus statistikos reikšmė 65,37; ir $p = 0,000$ rodo gerą modelio tinkamumą. Pateiktasis (Makfadeno) determinacijos pseudokoeficientas nėra itin didelis $R^2 = 0,18$, bet nedaug skiriasi nuo 0,20. Voldo kriterijai rodo, kad visi regresoriai yra statistiškai reikšmingi.

Kitaip nei SPSS, STATA nespausdina modelio laisvųjų konstantų įverčių, o tik pateikia vadinamuosius *pjūvio taškus*⁶⁸. Tariaama, kad tikrasis *Bakna3* yra tolydus kintamasis ir jo reikšmės nuo 0 iki 8,8 rodo menką žinių naudojimą, nuo 8,8 iki 10,5 – vidutinį, o daugiau kaip 10,5 – didelį naudojimą. Naudos iš tokios interpretacijos nėra daug. Žinoma, modelio konstantoms ir pjūvio taškams teisinga: $C_i = - /cut_i$. Ranginėje logistinėje regresijoje svarbiausia yra regresorių koeficientų įverčiai. Visų kintamųjų koeficientų įverčiai teigiami. Todėl, didėjant *K11_1* (atsakinėjant geriau besimokiusiam respondentui), tikimybė, kad respondentas dažniau naudoja profesines žinias, padidėja. Ši tikimybė didėja ir didėjant *K33_1* (palankiau vertinant išsilavinimo lygio įtaką karjerai). Tikimybė didina ir informacija, kad respondentas uždirba daugiau nei 1500 litų (*algl2 = 2*).

Modelis su įvertintais koeficientais atrodo taip:

⁶⁸ Angl. *cut points*.

$$\ln \frac{\hat{P}(Bakna3 > i)}{\hat{P}(Bakna3 \leq i)} = \begin{cases} -8,84, & \text{jei } i = 1, \\ -10,56, & \text{jei } i = 2, \end{cases} + 1,18K11_1 + 0,98K33_1$$

$$+ \begin{cases} 0, & \text{jei } algl2 = 1, \\ 1,28, & \text{jei } algl2 = 2. \end{cases}$$

Norėdami gauti informaciją apie galimybių santykių įverčius įvykdome

xi: ologit Bakna3 i.algl2 K11 1 K33 1, or

Ordered logistic regression					Number of obs	=	166
					LR chi2(3)	=	65.37
					Prob > chi2	=	0.0000
Log likelihood = -148.44438					Pseudo R2	=	0.1805

Bakna3	Odds Ratio	Std. Err.	z	P> z	[95% Conf. Interval]	
_1alg12_2	3.586797	1.291377	3.55	0.000	1.771101	7.263904
k11_1	3.259487	.8687538	4.43	0.000	1.933204	5.495671
k33_1	2.662024	.5378057	4.85	0.000	1.791615	3.955299
/cut1	8.84465	1.497767			5.909081	11.78022
/cut2	10.56329	1.569818			7.486499	13.64007

Galimybių santykis parodo, kaip pasikeičia tikimybių santykis, kai vienetu didėja tik vieno regresoriaus reikšmė, kitiems regresoriams nesikeičiant. Pavyzdžiui, galimybė, kad respondentas dažniau naudoja profesines žinias, padidėja $\exp\{1,28\}=3,59$ karto, kai žinome, jog jis uždirba daugiau kaip 1500 litų ($alql2 = 2$):

$$\left(\frac{\widehat{\mathbb{P}}(\text{Bakna3} > i)}{\widehat{\mathbb{P}}(\text{Bakna3} \leq i)}\right)_{\text{alg}|2=2} = e^{1,28} \left(\frac{\widehat{\mathbb{P}}(\text{Bakna3} > i)}{\widehat{\mathbb{P}}(\text{Bakna3} \leq i)}\right)_{\text{alg}|2=1}$$

arba

$$\left(\frac{\hat{P}(Bakna3 > i)}{\hat{P}(Bakna3 \leq i)} \right)_{\text{uždirba} \geq 1500} = 3,59 \left(\frac{\hat{P}(Bakna3 > i)}{\hat{P}(Bakna3 \leq i)} \right)_{\text{uždirba iki } 1500}.$$

Analogiškai interpretuojami ir likusių regresorių galimybių santykiai. Alternatyviai galima pasinaudoti SPost programa listcoef.

listcoef, help

Odds of: >m vs <=m

Bakna3	b	z	P> z	e^b	e^bStdX	SDofX
_IaIgl2_2	1.27726	3.548	0.000	3.5868	1.8116	0.4652
K11_1	1.18157	4.433	0.000	3.2595	2.2409	0.6829
K33_1	0.97909	4.846	0.000	2.6620	2.4868	0.9304

b = raw coefficient
 z = z-score for test of b=0
 P>|z| = p-value for z-test
 e^b = exp(b) = factor change in odds for unit increase in x
 e^bStdX = exp(b*SD of x) = change in odds for SD increase in x
 SDofX = standard deviation of x

Šioje lentelėje galimybių santykiai yra stulpelyje **e^b**. Klasikinis (standartinis) galimybių santykis rodo pokyčius, kai regresorius padidėja vienetu. Ne visada toks požiūris yra logiškas – būna regresorių, kuriems vieneto pokytis – labai mažas, būna regresorių, kuriems vieneto pokytis – labai didelis. Todėl lentelėje dar yra informacijos, kaip keisis galimybės, jeigu regresoriaus reikšmė pasikeis per jo standartinę nuokrypį. Toks savitas panormavimas ir matavimo skalės nukenksminimas.

Tikrindami tiesių lygiagretumo prielaidą, įvykdome

brant

Brant Test of Parallel Regression Assumption

Variable	chi2	p>chi2	df
All	1.98	0.577	3
_IaIgl2_2	0.02	0.897	1
K11_1	0.13	0.716	1
K33_1	1.96	0.162	1

A significant test statistic provides evidence that the parallel regression assumption has been violated.

Lentelėje pateikiama informacija, ar lygiagrečių tiesių prielaida tenkinama, kai atsižvelgiama į visus regresorius (**All**) ir į kiekvieną regresorių atskirai. Visos *p* reikšmės surašytos stulpelyje **p > chi2**. Jeigu regresoriui *p* < 0,05, gali būti, kad jis modelyje nereikalingas (reikėtų patikrinti modelį be to regresoriaus). Matome, kad regresorių, kuriems *p* < 0,05, nagrinėjamame modelyje nėra. Neprieštaraujama ir bendrajai tiesių lygiagretumo prielaidai (*p* = 0,557 > 0,05). Darome išvadą, kad modelis yra tinkamas.

Beje, norėdami pamatyti alternatyvius determinacijos koeficientus, Akaikės informacinio kriterijaus reikšmę ir kitus rodiklius, tiesiog įvykdome

```
fitstat
```

Measures of Fit for **ologit** of **Bakna3**

Log-Lik Intercept Only:	-181.131	Log-Lik Full Model:	-148.444
D(161):	296.889	LR(3):	65.372
		Prob > LR:	0.000
McFadden's R2:	0.180	McFadden's Adj R2:	0.153
ML (Cox-Snell) R2:	0.326	Cragg-Uhler(Nagelkerke) R2:	0.367
McKelvey & Zavoina's R2:	0.388		
Variance of y*:	5.380	Variance of error:	3.290
Count R2:	0.542	Adj Count R2:	0.248
AIC:	1.849	AIC*n:	306.889
BIC:	-526.141	BIC':	-50.036
BIC used by Stata:	322.449	AIC used by Stata:	306.889

Matome, kad Nagelkerkės $R^2 = 0,367$ yra gerokai didesnis už Makfadeno R^2 .

6.3.3. Prognozavimas

Prognozuoti patogiausia naudoti `SPost` priedo komandą `prvalue`. Tarkime, kad norime padaryti *Bakna3* prognozę respondentui, kurio *algl2* = 1, *K11_1* = 2, *K33_1* = 5. Įvykdome

```
xi: prvalue, x( i.algl2=1 K11_1=2 K33_1=5)
```

Confidence intervals by delta method

	95% Conf. Interval
Pr(y=menkas_n x): 0.5766	[0.3213, 0.8319]
Pr(y=vidutini x): 0.3071	[0.1488, 0.4653]
Pr(y=dažnas_n x): 0.1164	[0.0038, 0.2289]

<i>_i</i> algl2_2	<i>K11_1</i>	<i>K33_1</i>
x= 1	2	5

Gavome ne tik galimų *Bakna3* reikšmių tikimybes (pavyzdžiui, $P(Bakna3 = 3) = 0,116$), bet ir tų tikimybių pasikliautinius intervalus.

Tarkime norime padaryti prognozę, kai *algl2* = 1, *K11_1* = 2, o *K33_1* lygus savo galimų reikšmių vidurkiui. Įvykdome

```
xi: prvalue, x( i.algl2=1 K11_1=2) rest(mean)
```

Confidence intervals by delta method

```

          95% Conf. Interval
Pr(y=menkas_n|x): 0.7155 [ 0.5052, 0.9258]
Pr(y=vidutini|x): 0.2180 [ 0.0685, 0.3675]
Pr(y=dažnas_n|x): 0.0666 [-0.0022, 0.1353]

      _lalg12_2      k11_1      k33_1
x=      1          2      4.373494

```

Be pačių prognozuojamų tikimybių, gavome informaciją, kad $K33_1$ vidurkis yra 4,37. Galima gauti ir išsamesnę informaciją, kaip keičiasi kiekvienos $Bakna3$ reikšmės tikimybė, keičiantis regresoriui. Imdami vidutines $K11_1$ ir $K33_1$ reikšmes ištirsime šią priklausomybę regresoriui $alg12$. Primename, kad $alg12$ įgyja reikšmę 1, jeigu respondentas uždirba iki 1500 litų per mėnesį. Regresorius $alg12 = 2$, jeigu respondentas uždirba daugiau nei 1500 litų per mėnesį. Įvykdome

xi: prt ab i.alg12

ologit: Predicted probabilities for **Bakna3**

Predicted probability of outcome 1 (menkas_naudojimas)

alg12==2	Prediction
0	0.4539
1	0.1881

Predicted probability of outcome 2 (vidutinis_naudojimas)

alg12==2	Prediction
0	0.3687
1	0.3756

Predicted probability of outcome 3 (dažnas_naudojimas)

alg12==2	Prediction
0	0.1775
1	0.4363

```

      _lalg12_2      k11_1      k33_1
x=      .68674699  4.0180723  4.373494

```

Matome, kad menko profesinių žinių naudojimo tikimybė stipriai sumažėja, kai respondentas uždirba daugiau kaip 1500 litų. Vidutinio žinių naudojimo tikimybė beveik nepasikeičia, o dažno naudojimo tikimybė stipriai padidėja.

6.3.4. Klasifikacinė lentelė

Nors klasifikacinė lentelė beveik niekada ranginės logistinės regresijos aprašuose nepridedama, parodysime, kaip ją gauti. Klasifikacinę lentelę tenka susikurti analogiškai daugianarės regresijos atvejui, žr. 5.3.4 skyrelį. Paėiliui įvykdome komandas:

```
predict pre1 pre2 pre3
gen cat = 0
replace cat = 1 if pre1>pre2 & pre1 > pre3
replace cat = 2 if pre2>pre1 & pre2 > pre3
replace cat = 3 if pre3>pre1 & pre3 > pre2
label define nopsas 1 "Menkai" 2 "Vidutiniškai" 3 "Dažnai"
label values cat nopsas
tab Bakna3 cat, row
```

<i>frequency row percentage</i>				
Studiju panaudojimas darbe	cat			Total
	Menkai	Vidutiniškai	Dažnai	
menkas naudojimas	25 49.02	17 33.33	9 17.65	51 100.00
vidutinis naudojimas	14 28.00	18 36.00	18 36.00	50 100.00
dažnas naudojimas	2 3.08	16 24.62	47 72.31	65 100.00
Total	41 24.70	51 30.72	74 44.58	166 100.00

Matome, kad iš 51 menkai profesines žinias naudojusio respondento teisingai klasifikuoti 25 (49,02 %) . Teisingai buvo klasifikuoti 36 % vidutiniai žinių naudotojai ir 72,31 % – dažni naudotojai. Išskyrus trečią kategoriją, kiti procentai gana maži. Palyginkime su pradine nuomonių dažnių lentele:

```
tab Bakna3, freq
```

. tab Bakna3				
Studiju panaudojimas darbe	Freq.	Percent	Cum.	
menkas naudojimas	51	30.72	30.72	
vidutinis naudojimas	50	30.12	60.84	
dažnas naudojimas	65	39.16	100.00	

Klasifikacinės lentelės procentai didesni, nei gautume akiai spėliodami. Taigi klasifikavimas nėra toks blogas.

6.4. Ranginė logistinė regresinė analizė su SAS

6.4.1. Duomenys

Pasinaudosime su SPSS jau atliktomis **LAMS** failo duomenų transformacijomis. Tirsime Vilniaus universiteto (VU), Vilniaus Gedimino technikos universiteto (VGTU) ir Lietuvos žemės ūkio akademijos (LŽŪA) absolventus, dirbančius Lietuvoje. Kintamieji

- *K11_1* – bakalauro studijų rezultatų įvertinimas (1 – dažniausiai pažymių vidurkis būdavo vienas iš žemiausių kurse, ..., 5 – dažniausiai pažymių vidurkis būdavo vienas iš aukščiausių kurse, 99 – nestudijavau);
- *K33_1* – išsilavinimo lygio įtaka, pasiekiant esamą padėtį darbo rinkoje (1 – visai nereikšmingas veiksnys, ..., 5 – labai reikšmingas veiksnys, 99 – nestudijavau);
- *Bakna3* – profesinių žinių naudojimas (1 – menkas, 2 – vidutinis, 3 – labai dažnas);
- *algl2* – algos lygmuo (1 – iki 1500 LTL per mėn., 2 – daugiau nei 1500 LTL per mėn.).

Pradiniai duomenys saugomi SAS duomenų bibliotekoje **rgr**. Atrenkame reikalingus duomenis įvykdę:

```
OPTIONS nofmterr;  
data LAMS;  
set rgr.LAMS_s;  
keep bakna3 K11_1 K33_1 K36_1 K25 K2 D8;  
if K2 in (7,11,13) AND (D8 le 7);  
if cmiss(of bakna3 K11_1 K33_1 K36_1 K25 K2 D8) then delete;  
run;
```

Su išlyga kintamuosius *K11_1* ir *K33_1* galima tarti esant intervaliniams. Kintamasis *algl2* yra dvireikšmis.

6.4.2. Modelio analizė

Tirsime modelį, kurį sąlygiškai galima užrašyti taip: $Bakna3 = f(algl2, K11_1, K33_1)$. Įvykdome

```
proc logistic data=lams;
    class algl2(ref="2.00") / param=ref ;
    model Bakna3 =algl2 K11_1 K33_1 / rsq;
    oddsratio algl2;
run;
```

Pirmiausia yra informacija apie tai, kokias reikšmes įgyja priklausomas kintamasis, koks naudojamas modelis ir kategorinio kintamojo *algl2* perkodavimo taisyklė. Įsitikiname, kad pakankamai daug (žr. atitinkamas rekomendacijas daugianarei logistinei regresijai) stebinių atitinka kiekvieną kintamojo *Bakna3* kategoriją. Modelis nebūtų logiškas, jeigu tam tikrų priklausomo kintamojo kategorijų dažnių būtų mažai.

Response Profile		
Ordered Value	Bakna3	Total Frequency
1	1.00	51
2	2.00	50
3	3.00	65

Probabilities modeled are cumulated over the lower Ordered Values.

Class Level Information		
Class	Value	Design Variables
algl2	1.00	1
	2.00	0

Priklausomo kintamojo *Bakna3* įgyjamų reikšmių procentai naudotini ir tiriant klasifikavimo tikslumą. Logiška reikalauti, kad pasiūlytas ranginės logistinės regresijos modelis užtikrintų neblogesnę klasifikavimo procentą (žr. skyrelį **Klasifikavimo lentelė**).

Lentelėje **Model Fit Statistics** yra informacinių indeksų reikšmės nagrinėjamam modeliui ir modeliui tik su konstanta (be regresorių). Matome, kad nagrinėjamo modelio indeksai yra mažesni,

tai reiškia, kad regresoriai tikrai turi įtakos priklausomam kintamajam – pasirinktas modelis yra nagrinėtinas. Lentelėje **Testing Global Null Hypothesis: BETA=0** tikėtinumų santykio kriterijaus (kaip ir kitų dviejų kriterijų) p reikšmė $< 0,0001$, tad gavome vieną iš svarbiausių patvirtinimų, jog modelis tinka duomenims.

Model Fit Statistics		
Criterion	Intercept Only	Intercept and Covariates
AIC	366.261	306.889
SC	372.485	322.449
-2 Log L	362.261	296.889

Testing Global Null Hypothesis: BETA=0			
Test	Chi-Square	DF	Pr > ChiSq
Likelihood Ratio	65.3723	3	<.0001
Score	53.2971	3	<.0001
Wald	45.1111	3	<.0001

Determinacijos koeficientai nėra itin dideli. Vis dėlto jie yra didesni už 0,20. Taigi ir šis rodiklis leidžia teigti, kad modelis neblogai tinka.

R-Square	0.3255	Max-rescaled R-Square	0.3669
----------	--------	-----------------------	--------

Dar vienas modelio „kokybės matas“ – klasifikacinė lentelė. Ją aprašysime kitame skyrelyje.

Lentelėje **Score Test for the Proportional Odds Assumption** yra hipotezės, kad regresorių koeficientai yra tie patys visiems tikimybių santykiams, tikrinimo rezultatai (taip kaip pirmiau pateiktoje formulėje – kintant i , keičiasi tik poslinkio konstanta, o daugikliai prie $K11_1$ ir $K33_1$

nesikeičia). Kadangi $p = 0,6116 > 0,05$, ši hipotezė neatmetama. Modelio prielaida patenkinta.

Score Test for the Proportional Odds Assumption		
Chi-Square	DF	Pr > ChiSq
1.8151	3	0.6116

Parametrų įverčiai yra lentelėje **Analysis of Maximum Likelihood Estimates**.

Ranginėje logistinėje regresijoje svarbiausia yra regresorių koeficientai. Modelis su įvertintais koeficientais atrodo taip:

$$\ln \frac{\hat{P}(Bakna3 \leq i)}{\hat{P}(Bakna3 > i)} = -1,182K11_1 - 0,979K33_1 + \begin{cases} 7,567, & \text{jei } i = 1, \\ 9,286, & \text{jei } i = 2, \end{cases} + \begin{cases} 1,277, & \text{jei } algl2 = 1, \\ 0, & \text{jei } algl2 = 2. \end{cases}$$

Neigiami regresorių $K11_1$ ir $K33_1$ koeficientai (-1,182 ir -0,979) reiškia – kuo geriau respondentas(ė) mokėsi bakalauro studijų metu ir kuo svarbesne laikoma išsilavinimo įtaka karjerai, tuo labiau tikėtina, kad jis(ji) palankiau įvertins studijų medžiagos naudojimą darbe. Analogiškai interpretuojamas ir kategorinio kintamojo $algl2$ koeficientas. Manoma, kad $algl2 = 2$ yra pagrindinė kategorija (jos koeficiento nėra), ir stebima, kaip viskas keisis, jeigu $algl2 = 1$. Matome, kad kai $algl2 = 1$, koeficientas yra teigiamas (1,277). Prisimename, kad teigiamas koeficientas rodo, jog didėjant kintamojo reikšmėms, labiau tikėtinos taps ir mažesnės $Bakna3$ reikšmės. Taigi informacija, kad respondentas(ė) uždirba iki 1500 LTL, padaro labiau tikėtiną tikimybę, kad jis(ji) mažiau naudojasi studijų metu sukauptomis žiniomis.

Analysis of Maximum Likelihood Estimates						
Parameter		DF	Estimate	Standard Error	Wald Chi-Square	Pr > ChiSq
Intercept	1.00	1	7.5671	1.4256	28.1752	<.0001
Intercept	2.00	1	9.2857	1.4898	38.8480	<.0001
algl2	1.00	1	1.2773	0.3603	12.5648	0.0004
K11_1		1	-1.1815	0.2636	20.0960	<.0001
K33_1		1	-0.9791	0.2047	22.8657	<.0001

Taigi visos pagrindinės modelio charakteristikos rodo gerą modelio tikimą duomenims.

Lentelėje „**Odds Ratio Estimates and Wald Confidence Intervals**“ yra galimybių santykio įvertis ir pasikliautinasis intervalas regresoriui *algl2* (sakinyje *oddsratio* nurodome regresorius, kuriems norime išspausdinti galimybių santykių įverčius).

Odds Ratio Estimates and Wald Confidence Intervals			
Label	Estimate	95% Confidence Limits	
algl2 1.00 vs 2.00	3.587	1.770	7.268

Galimybių santykis parodo, kaip pasikeičia tikimybių santykis, kai vienetu didėja tik vieno regresoriaus reikšmė, kitiems regresoriams nesikeičiant. Pavyzdžiui, galimybė, kad respondentas dažniau naudoja profesines žinias, padidėja 3,59 karto, kai žinome, jog jis uždirba daugiau kaip 1500 litų (*zalg2* = 1):

$$\left(\frac{\hat{P}(\text{dažniau naudoja})}{\hat{P}(\text{rečiau naudoja})} \right)_{\text{uždirba} > 1500} = 3,59 \left(\frac{\hat{P}(\text{dažniau naudoja})}{\hat{P}(\text{rečiau naudoja})} \right)_{\text{uždirba iki 1500}}$$

Analogiškai interpretuotume ir kitų regresorių galimybių santykius.

6.4.3. Klasifikacinė lentelė

Išspausdinsime klasifikacinę lentelę ir priklausomo kintamojo dažnių lentelę. Įvykdome:

```
proc logistic data=lams ;
    class algl2(ref="2.00") / param=ref ;
    model Bakna3 =algl2 K11_1 K33_1;
    output out=klasif PREDPROBS=(INDIVIDUAL);
run;
proc freq data=klasif;
    tables _FROM_*_INTO_/nocol;
run;
proc freq data=lams;
    tables bakna3;
run;
```


Frequency Row Pct	Table of _FROM_ by _INTO_				
	FROM (Formatted Value of the Observed Response)	_INTO_ (Formatted Value of the Predicted Response)			
		1.00	2.00	3.00	Total
	1.00	25 49.02	17 33.33	9 17.65	51
	2.00	14 28.00	18 36.00	18 36.00	50
	3.00	2 3.08	16 24.62	47 72.31	65
	Total	41	51	74	166

Bakna3				
Bakna3	Frequency	Percent	Cumulative Frequency	Cumulative Percent
1.00	51	30.72	51	30.72
2.00	50	30.12	101	60.84
3.00	65	39.16	166	100.00

Matome, kad iš 51 menkai profesines žinias naudojusio respondento teisingai klasifikuoti 25 (49,02 %) Teisingai buvo klasifikuoti 36 % vidutinių žinių naudotojų ir 72,31 % – dažnų naudotojų. (žiūrime ant įstrižainės procentų reikšmes). Ar patenkinamas toks klasifikavimo tikslumas? Visų pirma įsitikiname, kad kiekvienai *Bakna3* kategorijai teisingai klasifikuotų atvejų procentas yra ne mažesnis nei klaidingų klasifikavimų procentas. Be to, įsitikiname, kad, taikant modelį, visada klasifikavimo procentas didesnis, nei gautume aklai spėdami (žr. *bakna3* dažnių lentelę). Pavyzdžiui, visą laiką spėdami, kad *Bakna3* = 2, teisingai klasifikuotume 30,1 % atvejų, o taikydami modelį – 36 % atvejų. Nors teisingų klasifikavimų procentas nėra labai didelis, jis yra pakankamas, kad manytume modelį esant tinkamą duomenims.

6.4.4. Prognozavimas

Tarkime, kad norime padaryti *Bakna3* prognozę respondentui, kurio *algl2* = 1, *K11_1* = 2, *K33_1* = 5. Įvykdome

```
data new;
set lams end=eof;
output;
if eof then do;
Call missing( of _all_ );
algl2 = 2; K11_1 = 2; K33_1 = 5;
output;
end ;
run;
proc logistic data=new noprint;
    class algl2(ref="2.00") / param=ref ;
    model Bakna3 =algl2 K11_1 K33_1;
output out=klasif PREDPROBS=(INDIVIDUAL);
run;
proc sql;
select distinct IP_1_00,IP_2_00,IP_3_00 from klasif where algl2 = 2 and K11_1 = 2 and
K33_1 = 5;
run;
```

Individual Probability: Bakna3=1.00	Individual Probability: Bakna3=2.00	Individual Probability: Bakna3=3.00
0.576567	0.307068	0.116366

Prognozuotume *Bakna3* = 1. Gavome, kad respondentas, turintis mažą pažymių vidurkį, atsakęs, kad išsilavinimo lygio įtaka pasiekiant esamą padėtį darbo rinkoje yra žymi ir uždirbantis >1500 litų, labiausiai tikėtina atsakytų – profesinių žinių naudojimasis menkas.

Padarę prognozę, kai *algl2* = 1, *K11_1* = 4, *K33_1* = 5 (t. y. prognozė gerai besimokantiems), gautume:

Individual Probability: Bakna3=1.00	Individual Probability: Bakna3=2.00	Individual Probability: Bakna3=3.00
0.113618	0.303238	0.583144

Progyzuotume $Bakna3 = 3$. Matome, kad pažangumas turi įtakos naudojimuisi profesinėmis žiniomis.

6.4.5. Rezultatų aprašymas

Pirmiausia aprašome, ką tyrėme, kokius naudojome kintamuosius ir kaip juos perkodavome. Tada kompaktiškai surašome visa tai, ką išsamiai aptarėme ankstesniame skyrelyje. Pateikiame vieną iš daugybės galimų tokio aprašymo variantų.

Duomenų analizei taikėme ranginę logistinę regresiją. Tiesių lygiagretumo prielaida buvo patenkinta ($\chi^2 = 1,815$; $df = 3$; $p = 0,611$). Pakankamai gerą pasirinkto modelio tikimą duomenims rodo tikėtinumų santykio kriterijus ($\chi^2 = 65,372$; $df = 3$; $p = 0,00$). Determinacijos koeficientas yra 0,3255. Taikant modelį teisingai klasifikuojama 49 % atvejų, kai $Bakna3 = 1$, 36 % atvejų, kai $Bakna3 = 2$, ir 72 % atvejų, kai $Bakna3 = 3$. Modelis su įvertintais parametrais atrodo taip

$$\ln \frac{\hat{P}(Bakna3 \leq i)}{\hat{P}(Bakna3 > i)} = \begin{cases} 7,567, & \text{jei } i = 1, \\ 9,286, & \text{jei } i = 2, \end{cases} - 1,182K11_1 - 0,979K33_1$$

$$+ \begin{cases} 1,277, & \text{jei } algl2 = 1, \\ 0, & \text{jei } algl2 = 2. \end{cases}$$

6.4.6. SAS programos logistinės regresijos procedūra

SAS ranginei regresinei analizei yra naudojama **proc logistic** procedūra. Prisiminkime, kad ji tinka ir dvinarei bei daugianarei logistinei regresijai. Šios procedūros sintaksė atrodo taip:

```
PROC LOGISTIC <options> ;
BY variables ;
CLASS variable <(options)><variable <(options)>></ options> ;
```

```

CONTRAST 'label' effect values<, effect values,></ options> ;
EFFECT name = effect-type ( variables </ options> ) ;
EFFECTPLOT <plot-type<(plot-definition-options)>></ options> ;
ESTIMATE <'label'> estimate-specification </ options> ;
EXACT <'label'><INTERCEPT><effects></ options> ;
EXACTOPTIONS options ;FREQ variable ;
LSMEANS <model-effects> </ options> ;LSMESTIMATE model-effect
lsestimate-specification </ options> ;
<label:> MODEL variable <(variable_options)>=<effects></ options> ;
<label:> MODEL events/trials=<effects></ options> ;ODDSRATIO <'label'>
variable </ options> ;
OUTPUT <OUT=SAS-data-set><keyword=name <keyword=name>></ option> ;
ROC <'label'> <specification> </ options> ;
ROCONTRAST <'label'><contrast></ options> ;SCORE <options> ;
SLICE model-effect </ options> ;STORE <OUT=>item-store-name </
LABEL='label'> ;
STRATA effects </ options> ;<label:> TEST equation1 <,equation2,></ option> ;
UNITS <independent1=list1 <independent2=list2 >></ option> ;
WEIGHT variable </ option> ;

```

Scenarijus :

```

OPTIONS nofmterr;
data LAMS;
set rgr.LAMS_s;
keep bakna3 K11_1 K33_1 K36_1 K25 K2 D8 algl2;
if K2 in (7,11,13) AND (D8 le 7);
if cmiss(of bakna3 K11_1 K33_1 K36_1 K25 K2 D8 algl2) then delete;
run;
proc freq data=lams;
table bakna3;

```

```

run;
proc logistic data=lams;
    class algl2(ref="2.00") / param=ref ;
    model Bakna3 =algl2 K11_1 K33_1 / rsq;
    oddsratio algl2;
run;
/* klasifikavimas */
proc logistic data=lams;
    class algl2(ref="2.00") / param=ref ;
    model Bakna3 =algl2 K11_1 K33_1;
output out=klasif PREDPROBS=(INDIVIDUAL);
run;
proc freq data=klasif;
tables _FROM_*_INTO_ /nocol;
run;
proc freq data=lams;
tables bakna3;
run;
/*=====*/
/* Prognozavimas */
data new;
set lams end=eof;
output;
if eof then do;
    Call missing( of _all_ ) ;
    algl2 = 2; K11_1 = 2; K33_1 = 5;
    output;
end ;
run;
proc logistic data=new noprint;
    class algl2(ref="2.00") / param=ref ;
    model Bakna3 =algl2 K11_1 K33_1;
output out=klasif PREDPROBS=(INDIVIDUAL);

```

```
run;
proc sql;
select distinct IP_1_00,IP_2_00,IP_3_00 from klasif where algl2 = 2 and K11_1 = 2
and K33_1 = 5;
run;
```

6.5. Ranginė logistinė regresinė analizė su R

6.5.1. Duomenys

Pasinaudosime su SPSS jau atliktomis **LAMS** failo duomenų transformacijomis. Tirsime Vilniaus universiteto (VU), Vilniaus Gedimino technikos universiteto (VGTU) ir Lietuvos žemės ūkio akademijos (LŽŪA) absolventus, dirbančius Lietuvoje. Kintamieji

- *K11_1* – bakalauro studijų rezultatų įvertinimas (1 – dažniausiai pažymių vidurkis būdavo vienas iš žemiausių kurse, ..., 5 – dažniausiai pažymių vidurkis būdavo vienas iš aukščiausių kurse, 99 – nestudijavau);
- *K33_1* – išsilavinimo lygio įtaka, pasiekiant esamą padėtį darbo rinkoje (1 – visai nereikšmingas veiksnys, ..., 5 – labai reikšmingas veiksnys, 99 – nestudijavau);
- *Bakna3* – profesinių žinių naudojimas (1 – menkas, 2 – vidutinis, 3 – labai dažnas);
- *algl2* – algos lygmuo (1 – iki 1500 LTL per mėn., 2 – daugiau nei 1500 LTL per mėn.).

Pradiniai duomenys buvo išsaugoti .csv formatu. Išrenkame reikalingą duomenų poaibį įvykdę:

```
dta<-read.csv2("LAMS_s.csv",na.strings = "NA",stringsAsFactors=FALSE)
ldta<-subset(dta, K36_1 < 99 & K25 < 99 & ( (K2 == 13) | (K2 == 11) | (K2 ==7) ) & D8 <=
7,select = c(Bakna3,algl2,K11_1,K33_1))
ldta<-ldta[complete.cases(ldta),]
```

Su išlyga kintamuosius *K11_1* ir *K33_1* galima tarti esant intervalinius. Kintamasis *algl2* yra dvireikšmis.

6.5.2. Modelio analizė

Tirsime modelį, kurį sąlygiškai galima užrašyti taip: $Bakna3 = f(algl2, K11_1, K33_1)$.
Įvykdome

```
ldta$algl2<-relevel(factor(ldta$algl2), ref = 2)
m <- polr(factor(Bakna3) ~algl2+K11_1+K33_1, data = ldta, Hess = TRUE)
summary(m)
m_0 <- polr(factor(Bakna3) ~ 1, data = ldta, Hess = TRUE)
anova(m_0,m)
rkvadrat<-1-m$deviance/m_0$deviance
rkvadrat
summary(m_0)
```

Call:

**polr(formula = factor(Bakna3) ~ algl2 + K11_1 + K33_1, data = ldta,
Hess = TRUE)**

Coefficients:

	Value	Std. Error	t value
algl21	-1.2773	0.3600	-3.548
K11_1	1.1816	0.2665	4.433
K33_1	0.9791	0.2020	4.846

Intercepts:

	Value	Std. Error	t value
1 2	7.5674	1.4145	5.3499
2 3	9.2860	1.4808	6.2711

Residual Deviance: 296.8888

AIC: 306.8888

(2 observations deleted due to missingness)

Likelihood ratio tests of ordinal regression models

Response: factor(Bakna3)

	Model	Resid. df	Resid. Dev	Test	Df	LR stat.	Pr(Chi)
1	1	164	362.2611				
2	algl2 + K11_1 + K33_1	161	296.8888	1 vs 2	3	65.37233	4.174439e-14

```
> rkvadrat  
[1] 0.1804564
```

```
Call:  
polr(formula = factor(Bakna3) ~ 1, data = Idta, Hess = TRUE)  
  
No coefficients  
  
Intercepts:  
      1|2      2|3  
-0.8131066 0.4407332  
  
Residual Deviance: 362.2611  
AIC: 366.2611
```

Modelio tikėtinumų santykio kriterijaus statistikos reikšmė 65,37; o $p < 0,0001$. Viena iš svarbiausių charakteristikų rodo gerą modelio tinkamumą. Pateiktasis (Makfadeno) determinacijos pseudokoefficientas nėra itin didelis $R^2 = 0,180$, bet nedaug skiriasi nuo 0,20. Rezultatų išsklotinėje yra spausdinami informacinių indeksų (AIC) reikšmės nagrinėjamam modeliui $AIC = 306,89$ ir modeliui tik su konstanta (be regresorių) $AIC = 366,26$. Matome, kad nagrinėjamo modelio indeksas yra mažesnis, reiškia, kad regresoriai tikrai turi įtakos priklausomam kintamajam – pasirinktas modelis yra nagrinėtinas.

Rezultatų išsklotinėje taip pat yra parametrų įverčiai. R programoje nagrinėjamas (2) teorijos modelis (modelis su priešingu konstantos ženklu). Modelis su įvertintais koeficientais atrodo taip ($i = 1, 2$):

$$\ln \frac{\hat{P}(Bakna3 > i)}{\hat{P}(Bakna3 \leq i)} = 1,182K11_1 + 0,979K33_1$$
$$-\begin{cases} 7,567, & \text{jei } i = 1, \\ 9,286, & \text{jei } i = 2, \end{cases} - \begin{cases} 1,277, & \text{jei } algl2 = 1, \\ 0, & \text{jei } algl2 = 2. \end{cases}$$

Teigiami regresorių $K11_1$ ir $K33_1$ koeficientai (1,182 ir 0,979) visiškai atitinka modelio logiką: kuo geriau respondentas(ė) mokėsi bakalauro studijų metu ir kuo svarbesne laikoma išsilavinimo įtaka karjerai, tuo labiau tikėtina, kad jis(ji) palankiau įvertins studijų medžiagos naudojimą darbe. Analogiškai interpretuojamas ir kategorinio kintamojo $algl2$ koeficientas. Manoma, kad $algl2 = 2$ yra pagrindinė kategorija (jos koeficiento nėra), ir stebima, kaip viskas keisis, jeigu $algl2 = 1$. Matome, kad kai $algl2 = 1$ (išsklotinėje $algl21$), koeficientas yra neigiamas (-1,277). Prisimename, kad neigiamas koeficientas rodo, jog, didėjant kintamojo reikšmėms, labiau tikėtinos taps ir mažesnės $Bakna3$ reikšmės. Taigi informacija, kad respondentas(ė) uždirba iki

1500 LTL, padaro labiau tikėtiną tikimybę, kad jis(ji) mažiau naudojasi studijų metu sukauptomis žiniomis.

Norėdami gauti informaciją apie galimybių santykius įvykdome

exp(coef(m))		
algl21	K11_1	K33_1
0.278800	3.259487	2.662022

Galimybių santykis parodo, kaip pasikeičia tikimybių santykis, kai vienetu didėja tik vieno regresoriaus reikšmė, kitiems regresoriams nesikeičiant. Pavyzdžiui, galimybė, kad respondentas dažniau naudoja profesines žinias padidėja 0,278 karto (sumažėja $1/0,278 = 3,597$ karto), kai žinome, kad jis uždirba iki 1500 litų

$$\left(\frac{\hat{P}(Bakna3 > i)}{\hat{P}(Bakna3 \leq i)} \right)_{algl2=1} = e^{-1,277} \left(\frac{\hat{P}(Bakna3 > i)}{\hat{P}(Bakna3 \leq i)} \right)_{algl2=2}$$

arba

$$\left(\frac{\hat{P}(\text{dažniau naudoja})}{\hat{P}(\text{rečiau naudoja})} \right)_{\text{uždirba iki 1500}} = 0,2788 \left(\frac{\hat{P}(\text{dažniau naudoja})}{\hat{P}(\text{rečiau naudoja})} \right)_{\text{uždirba} > 1500}$$

arba

$$3,597 \left(\frac{\hat{P}(\text{dažniau naudoja})}{\hat{P}(\text{rečiau naudoja})} \right)_{\text{uždirba iki 1500}} = \left(\frac{\hat{P}(\text{dažniau naudoja})}{\hat{P}(\text{rečiau naudoja})} \right)_{\text{uždirba} > 1500}$$

Analogiškai interpretuojami ir likusių regresorių galimybių santykiai.

6.5.3. Prognozavimas

Tarkime, kad norime padaryti *Bakna3* prognozę respondentui, kurio *alg2* = 2, *K11_1* = 2, *K33_1* = 5. Įvykdome

```
ndat <- data.frame(algl2 = 2, K11_1 = 2, K33_1 = 5)
ndat$algl2 <- as.factor(ndat$algl2)
predict(m, newdata = ndat, type = 'probs')
```

1	2	3
0.5765968	0.3070527	0.1163506

Gavome, kad respondentas, kurio pažymių vidurkis mažas, atsakęs, kad išsilavinimo lygio įtaka, pasiekiant esamą padėtį darbo rinkoje, yra žymi ir uždirbantis >1500 litų, labiausiai tikėtina atsakytų – profesinėmis žiniomis naudojuosi menkai.

Padarę prognozę, kai $algl2 = 2$, $K11_1 = 4$, $K33_1 = 5$ (t. y. prognozė gerai besimokantiems), gautume:

1	2	3
0.1136164	0.3032410	0.5831425

Matome, kad pažangumas turi įtakos naudojimuisi profesinėmis žiniomis.

6.5.4. Klasifikacinė lentelė

Nors klasifikacinė lentelė beveik niekada ranginės logistinės regresijos aprašuose nepridedama, parodysime, kaip ją gauti. Klasifikacinę lentelę tenka susikurti, analogiškai daugianarės regresijos atvejui, žr. 5.3.4 skyrelį. Paeiliui įvykdome komandas:

```
pred <- data.frame(fitted(m))
pred$X4 = 0
pred$X4[(pred$X1 > pred$X2) & (pred$X1 > pred$X3)] = 1
pred$X4[(pred$X2 > pred$X1) & (pred$X2 > pred$X3)] = 2
pred$X4[(pred$X3 > pred$X1) & (pred$X3 > pred$X2)] = 3
addmargins(table(ldta$Bakna3, pred$X4))
prop.table(table(ldta$Bakna3, pred$X4), margin = 1) * 100
prop.table(table(ldta$Bakna3)) * 100
```

```
> addmargins(table(ldta$Bakna3,pred$X4))
```

	1	2	3	Sum
1	25	17	9	51
2	14	18	18	50
3	2	16	47	65
Sum	41	51	74	166

```
> prop.table(table(ldta$Bakna3,pred$X4),margin=1)*100
```

	1	2	3
1	49.019608	33.333333	17.647059
2	28.000000	36.000000	36.000000
3	3.076923	24.615385	72.307692

```
> prop.table(table(ldta$Bakna3))*100
```

	1	2	3
	30.72289	30.12048	39.15663

Matome, kad iš 51 menkai profesines žinias naudojusio respondento teisingai klasifikuoti 25 (49,02 %). Teisingai buvo klasifikuoti 36 % vidutinių žinių naudotojų ir 72,31 % – dažnų naudotojų (žiūrime ant įstrižainės 1 ir 2 lentelių – atitinkamai dažnių ir procentų reikšmės). Ar patenkinamas toks klasifikavimo tikslumas? Visų pirma įsitikiname, kad kiekvienai *Bakna3* kategorijai teisingai klasifikuotų atvejų procentas yra ne mažesnis nei klaidingų klasifikavimų procentas. Be to, įsitikiname, kad taikant modelį visada klasifikavimo procentas didesnis, nei gautume aklaui spėdami. Pavyzdžiui, visą laiką spėdami, kad *Bakna3* = 2, teisingai klasifikuotume 30,1 % atvejų, o taikydami modelį – 36 % atvejų. Nors teisingų klasifikavimų procentas nėra labai didelis, jis yra pakankamas, kad manytume modelį esant tinkamą duomenims.

Klasifikacinės lentelės procentai didesni, nei gautume aklaui spėliodami. Taigi klasifikavimas nėra toks blogas.

6.5.5. R programos ranginės logistinės regresijos komandos

R programoje ranginei regresinei analizei yra naudojama *polr* funkcija (biblioteka *MASS*). Komandos sintaksė atrodo taip

```
polr(formula, data, weights, start, ..., subset, na.action,  
      contrasts = NULL, Hess = FALSE, model = TRUE,  
      method = c("logistic", "probit", "cloglog", "cauchit"))
```

Būtinias parametrus **formula** – užrašome modelio išraišką.

Scenarijus:

```
dta<-read.csv2("LAMS_s.csv",na.strings = "NA",stringsAsFactors=FALSE)  
ldta<-subset(dta, K36_1 < 99 & K25 < 99 & ( (K2 == 13) | (K2 == 11) | (K2 ==7) ) & D8  
  <= 7,select = c(Bakna3,algl2,K11_1,K33_1))  
ldta<-ldta[complete.cases(ldta),]  
ldta$algl2<-relevel(factor(ldta$algl2), ref = 2)  
library(MASS)  
m <- polr(factor(Bakna3) ~algl2+K11_1+K33_1, data = ldta, Hess = TRUE)  
summary(m)  
#  
# tikėtinumų santykio kriterijus  
m_0 <- polr(factor(Bakna3) ~ 1, data = ldta, Hess = TRUE)  
anova(m_0,m)  
#  
# rkvadrat  
#  
m_0 <- polr(factor(Bakna3) ~ 1, data = ldta, Hess = TRUE)  
summary(m_0)  
rkvadrat<-1-m$deviance/m_0$deviance  
rkvadrat  
#  
# galimybių santykiai  
#  
exp(coef(m))  
#  
# prognozavimas
```

```

#
ndat <- data.frame(algl2 = 2, K11_1 = 2 , K33_1 = 5)
ndat$algl2=as.factor(ndat$algl2)
predict(m, newdata = ndat, type = 'probs')
#
ndat <- data.frame(algl2 = 2, K11_1 = 4 , K33_1 = 5)
ndat$algl2<-as.factor(ndat$algl2)
predict(m, newdata = ndat, type = 'probs')
#
# klasifikacine lentele
#
pred<-data.frame(fitted(m))
pred$X4<-0
pred$X4[(pred$X1 > pred$X2) & (pred$X1 > pred$X3)]=1
pred$X4[(pred$X2 > pred$X1) & (pred$X2 > pred$X3)]=2
pred$X4[(pred$X3 > pred$X1) & (pred$X3 > pred$X2)]=3
addmargins(table(ldta$Bakna3,pred$X4))
prop.table(table(ldta$Bakna3,pred$X4),margin=1)*100
prop.table(table(ldta$Bakna3))*100

```

Uždaviniai

1. Failas **ZTLT**: Lietuvos tolerancijos profiliai, 2003 m. Respondentai atsakė, koks jų požiūris į musulmonus (1 – teigiamas, 2 – neutralus, 3 – neigiamas, 4 – sunku pasakyti) (kintamasis *r01_02*) ir į žydus (kintamasis *r01_03*); ar Lietuvoje turi būti toleruojamos kitos nekrikščioniškos religijos (1 – visiškai sutinku, 2 – sutinku, 3 – nesutinku, 4 – visiškai nesutinku, kintamasis *r04_04*). Kintamasis *s01* žymi lytį (1 – vyr., 2 – mot.).

Tyrimui atrinkti vyrus. Įsitikinti, kad kintamieji *r01_02* ir *r01_03* įgyja labai mažai ketvertukų. Atrinkti tik respondentus, kuriems kintamieji *r01_02* ir *r01_03* ≤ 3 . Ištirti modelį $r01_02 = f(r01_03, r04_04)$.


2. Pritaikyti ranginės regresijos modelį problemai, nagrinėtai 5.3 skyrelyje. Kuris modelis geriau tinka?

7. PUASONO REGRESINĖ ANALIZĖ

Dažniausiai Puasono regresijos modeliai taikomi retų įvykių skaičiui modeliuoti. Tipinės situacijos:

- norime ištirti žmogžudysčių skaičiaus per metus priklausomybę nuo miesto gyventojų skaičiaus, vidutinių gyventojų pajamų ir suvartojamo alkoholio kiekio vienam gyventojui;
- aiškinamės, kokie socialiniai ir ekonominiai faktoriai lemia vaikų skaičių šeimoje;
- tiriame, kaip vyrų, nešiojančių skrybėles, skaičius priklauso nuo įvairių regiono kultūrinių ir ekonominių charakteristikų.

Tarkime, kad skaičiuojame kažkokius pakankamai retus įvykius (Puasono modeliai dar vadinami katastrofų modeliais) ir manome, kad tų įvykių skaičius (pažymėkime jį Y) priklauso nuo kitų stebimų kintamųjų. Modelio schema:



Kintamasis Y vadinamas *priklausomu kintamuoju*, kintamieji X , Z , W yra *nepriklausomi kintamieji* arba *regresoriai*. Dažnai intuityviai aišku, kokie įvykiai yra reti – draudžiamųjų įvykių skaičius, telefono skambučių kiekis per valandą ir pan. Formalus požiūris – priklausomas kintamasis nėra normalus. Jeigu Y galima laikyti normaliu, geriau taikyti tiesinę regresiją. Specialus Puasono regresijos atvejis yra įvykių dažnio (įvykių skaičiaus per metus ar per valandą, įvykių skaičiaus tūkstančiui gyventojų ir pan.) modeliavimas.

7.1. Puasono regresijos modelis

7.1.1. Modelio lygtis ir jos taikymas prognozuojant

Matematinis modelis sudaromas ne pačiam priklausomam kintamajam Y , o jo vidurkiui, kurį pažymėsime simboliu μ . Modelis atrodo taip:

$$\mu = e^z,$$
$$z = C + b_1 X + b_2 Z + b_3 W.$$

Naudojant imties duomenis įvertinami modelio koeficientai $\hat{C}, \hat{b}_1, \hat{b}_2, \hat{b}_3$. Jų ženklai padeda suprasti regresorių poveikį Y .

Jeigu koeficientas teigiamas, regresoriui didėjant, vidutinė Y reikšmė didėja.

Jeigu koeficientas neigiamas, regresoriui didėjant, vidutinė Y reikšmė mažėja.

Į *modelio koeficientų eksponentes* (t. y. į skaičių e , pakeltą koeficiento laipsniu) atsižvelgiama, kai norima įvertinti, *kiek kartų* padidės (sumažės) kintamojo Y vidurkis μ , atitinkamam regresoriui padidėjus vienetu. Be pačių modelio koeficientų eksponenčių, dar atsižvelgiama į jų pasikliautinuosius intervalus.

Kai X padidėja vienetu, kintamojo Y vidurkis μ padidėja (sumažėja) e^{β^1} karto.

Vidutinio įvykių skaičiaus prognozavimas konkrečioms X, Z, W reikšmėms atliekamas taip: į formulę

$$z = \hat{C} + \hat{b}_1 X + \hat{b}_2 Z + \hat{b}_3 W$$

įstatome tas X, Z ir W reikšmes, kurioms norime gauti prognozę. Vidurkio μ įvertis gaunamas pagal formulę: $\hat{\mu} = e^z$. Čia $e = 2,718...$

Pavyzdys. Tarkime, pavyzdžiui, kad atlikę Puasono regresiją, gavome įverčius $\hat{C} = -21, \hat{b}_1 = -4, \hat{b}_2 = 3, \hat{b}_3 = 1$ ir norime nustatyti, koks turėtų būti vidutinis Y , kai $X = 0, Z = 7, W = 2$. Nesunkiai apskaičiuojame $z = -21 + 0 + 21 + 2 = 2$. Todėl $\hat{\mu} = 7,3890...$ Nesunku pastebėti, kad prognozuojame vidutinę reikšmę, kuri dažniausiai nėra sveikasis skaičius (ne taip kaip Y reikšmės).

7.1.2. Dažnio modelis

Kartais protingiau modeliuoti ne įvykių skaičių, o jų dažnį. Daugiausia pasaulio genialių vaikų gyvena Kinijoje. Tai dar nereiškia, kad kinai ypač gabūs. Tiesiog Kinijoje daugiausia gyventojų. Todėl daugiausia vaikų, turinčių vystymosi sutrikimų, taip pat gyvena Kinijoje. Matome, kad šiuo atveju prasminga kalbėti ne apie bendrąjį genijų skaičių šalyje, o apie jų (tarkime, $IQ = 300$) skaičių milijonui gyventojų. Tuo atveju naudojamas modifikuotas Puasono regresijos modelis:

$$\frac{\mu}{s} = e^z,$$

$$z = C + b_1 X + b_2 Z + b_3 W.$$

Čia s – normuojantis dažnio kintamasis, kuriam pagal tyrėjo prielaidą turėtų būti proporcingas vidutinis dažnis (įvykių intensyvumas) ir kurio reikšmės kiekvienu atveju yra žinomos. Pavyzdžiui, s gali rodyti, kiek milijonų gyventojų šalyje gyvena. Parametrai C, b_1, b_2, b_3 nėra žinomi. Jų įverčiai $\hat{C}, \hat{b}_1, \hat{b}_2, \hat{b}_3$ gaunami panaudojus imties duomenis. Dažnai naudojamas ekvivalentus modelio užrašas:

$$\mu = e^v, \quad v = \ln(s) + C + b_1 X + b_2 Z + b_3 W.$$

Faktiškai tai tradicinis Puasono regresijos modelis, tik prie regresorių pridedama (logaritmuota ir su vienetu daugiklio) informacija apie populiacijos didumą.

Prognozės norime vienam milijonui gyventojų, vienai stebinių valandai ir pan. Taigi faktiškai norime μ prognozės, kai $s = 1$. Vidutinio įvykių dažnio prognozavimas konkrečioms X, Z, W reikšmėms atliekamas taip:

- į formulę $v = \hat{C} + \hat{b}_1 X + \hat{b}_2 Z + \hat{b}_3 W$ įstatome tas X, Z, W ir reikšmes, kurioms norime gauti prognozę ($\ln 1 = 0$);
- dažnio įvertis gaunamas skaičių e pakėlus v laipsniu: $\hat{\mu} = e^v$.

Pavyzdys. Tarkime, kad skaičiavome, kiek SMS žinučių pasiunčia paaugliai. Žinome, paauglių amžių (X) ir lytį ($Z, Z = 0$ mot., $Z = 1$ vyr.). Be to, paauglius stebėjome skirtingą valandų skaičių (kintamasis s). Šiuo atveju prasminga kalbėti apie vidutinį SMS žinučių skaičių per valandą. Kiekvieno paauglio pasiųstų SMS žinučių skaičių pažymime Y , o Y vidurkį μ . Tarkime, kad turimiems duomenims pritaikę Puasono regresiją, gavome


$$\ln \hat{\mu} = \ln s + 2 + 0,04X + 5Z.$$

Kiek vidutiniškai SMS per valandą pasiunčia 13 metų paauglė? Įstatę į lygtį $s = 1, X = 13, Z = 0$, gauname: $\ln \hat{\mu} = \ln 1 + 2 + 0,04 \cdot 13 + 0 = 2,52$. Prognozuojamas vidutinis SMS per valandą skaičius bus $e^{2,52} = 12,42$.

7.1.3. Duomenys

Duomenys turi tenkinti tokius reikalavimus:

- 1) Stebime kintamąjį Y , kuris turi Puasono skirstinį. Tai reiškia, kad jis įgyja reikšmes 0, 1, 2, ... ir 0 bei 1 įgijimo tikimybės gana didelės. Svarbiausia Puasono kintamojo savybė – jo vidurkis sutampa su dispersija. Primename, kad dispersija apibūdina kintamojo reikšmių išsibarstymą (žr. įvadą). Todėl visada reikia pažiūrėti, ar priklausomo kintamojo Y imties vidurkis nedaug skiriasi nuo dispersijos. Toliau pateikiama Puasono kintamojo dažnių diagrama, kai vidurkis lygus 1. Matome, kad skirstinys yra labai asimetriškas, visai nepanašus į normalųjį ir tiesinei regresijai netinkamas.



- 2) Dalis regresorių gali būti intervaliniai, dalis dvireikšmiai (įgyti reikšmes 0 arba 1) arba kategoriniai (jie keičiami dvireikšmiais pseudokintamaisiais). Modelį lengviau interpretuoti, kai regresoriai intervaliniai.

7.1.4. Modelio tinkamumas

Modelio tinkamumą duomenims parodančių charakteristikų nėra labai daug:

- 1) *Deviacija* yra vadinamas skaitinis rodiklis⁶⁹, kuris parodo, kiek tiriamas modelis skiriasi nuo visiškai duomenis aprašančio (bet labai sudėtingo ir todėl naudoti netinkamo) modelio. Dar reikia atsižvelgti į imties didumą ir regresorių skaičių (juos nusako vadinamieji laisvės laipsniai). Modelis pakankamai geras, jeigu deviacija, padalyta iš savo laisvės laipsnių, nedaug skiriasi nuo vieneto. Intervalas 0,9–1,1 visai priimtinas, reikšmė, mažesnė už 0,7 (didesnė už 1,3), jau rodo blogą modelio tikimą.
- 2) *Pirsono chi kvadrato statistika* yra kiek rečiau taikomas deviacijos analogas. Matuoja, ar modeliu gautųjų vidutinių ir tikrųjų Y reikšmių skirtumai yra maži (statistiškai

⁶⁹ Deviacijos išraiška yra pakankamai sudėtinga. Žr.: V. Čekanavičius, G. Murauskas. „Statistika ir jos taikymai. III“ vadovėlis, p. 59.

nereikšmingi). Gerai, kai taip. Tariau, kad modelis pakankamai geras, jeigu chi kvadrato statistika, padalyta iš savo laisvės laipsnių, nedaug skiriasi nuo vieneto (bent jau patenka į intervalą 0,8–1, 2).

- 3) *Didžiausių tikėtinumų santykio kriterijus*. Parodo, ar modelyje yra su priklausomu kintamuoju susijusių regresorių. Jeigu kriterijaus p reikšmė didesnė už 0,05, regresijos modelio tinkamumas labai abejotinas. Formaliai žiūrint, didelė p reikšmė reiškia, kad bandome Y elgesį prognozuoti pagal su juo visiškai nesusijusius kintamuosius. Pavyzdžiui, vidutinį vaikų skaičių lietuviškoje šeimoje pagal Afrikos dramblių tankį Kenijos savanoje. (Matyt, jie ten žiemojančius gandrų trypa.)
- 4) *Informaciniai indeksai* (informaciniai kriterijai). Tai sąlyginiai rodikliai, leidžiantys „iš akies“ palyginti du modelius. Geresnis tas modelis, kurio informacinis indeksas mažesnis. Bene plačiausiai naudojamas Akaičės informacijos kriterijus AIC.
- 5) *Voldo kriterijai*. Padeda nuspręsti, ar regresorius šalintinas iš modelio. Jeigu p reikšmė $< 0,05$, *regresorius yra statistiškai reikšmingas* ir jį modelyje paliekame. Jeigu $p \geq 0,05$, regresorius yra statistiškai nereikšmingas ir modelyje jis paliekamas tik ypatingais atvejais. Dažniausiai modelio konstanta C paliekama net ir tada, kai ji statistiškai nereikšminga.

7.1.5. Puasono regresinės analizės etapai

Regresinė analizė susideda iš preliminarų kintamųjų tinkamumo tyrimo ir modelio tinkamumo duomenims tikrinimo:

- 1) Patikriname, ar Y turi Puasono skirstinį. Kintamojo Y imties dispersija turi nedaug skirtis (idealiu atveju sutapti) nuo Y imties vidurkio. Galima sugeneruoti Puasono kintamąjį, turintį tą patį vidurkį kaip ir Y , ir vizualiai palyginti abiejų kintamųjų dažnių diagramas.
- 2) Sudarome Puasono regresijos modelį ir patikriname, ar deviacija, padalyta iš savo laisvės laipsnių, nedaug skiriasi nuo vieneto. Alternatyviai galima tikrinti, ar Pirsono chi kvadrato statistikos reikšmė, padalyta iš laisvės laipsnių, nedaug skiriasi nuo vieneto.
- 3) Patikriname, ar didžiausių tikėtinumų santykio kriterijaus p reikšmė $< 0,05$. Jeigu p reikšmė $\geq 0,05$, modelis netinkamas.
- 4) Patikriname, ar visi regresoriai statistiškai reikšmingi (visos Voldo kriterijų $p < 0,05$). Jeigu ne – modelis taisytinas. Konstantai p reikšmės nežiūrime.
- 5) Pažiūrėję į koeficientų eksponentes nustatome, kurie modelio regresoriai įtakingiausi.
- 6) Jeigu viskas gerai – modelį aprašome, jei ne – tobuliname.

Gera duomenims tinkamo modelio:

- Deviacija, padalyta iš laisvės laipsnių, nedaug skiriasi nuo vieneto.
- Tikėtinumų santykio kriterijaus $p < 0,05$.
- Visiems regresoriams Voldo kriterijaus $p < 0,05$.
- Pirsono chi kvadrato statistika, padalyta iš laisvės laipsnių, nedaug skiriasi nuo vieneto.

7.1.6. Modelio tobulinimas

Modelio tobulinimas – kintamųjų šalinimas arba jų transformavimas.

Pašalinus bent vieną regresorių, keičiasi visos p reikšmės

Modelis tobulinamas, jeigu yra problemų:


- *Deviacijos arba Pirsono chi kvadrato statistikos ir jų laisvės laipsnių santykiai* labai skiriasi nuo 1. Dažniausiai tai reiškia, kad parinkome netinkamus regresorius arba kad priklausomas kintamasis visiškai nepanašus į Puasono kintamąjį. Bandome keisti modelį.
- *Kintamojo Y dispersija daug didesnė už jo vidurkį*⁷⁰. Tada geriau naudoti neigiamą binominę regresiją (žr. kitą skyrelį).
- *Per daug nulių*⁷¹. Kintamojo Y grafike nulio dažnis daug didesnis, nei turėtų įgyti Puasono atsitiktinis dydis. Kodėl atsiranda būtent nulių perviršis? Tarkime, tiriame respondentų vaikų skaičių. Nulį vaikų turi ne tik respondentės, kurios nusprendė jų neturėti (vienuolės), bet ir tos, kurios nespėjo jų pagimdyti. Panašių situacijų kyla gana dažnai. Kai nulių yra per daug, standartinė Puasono regresija netinka. Kai kuriuose statistiniuose paketuose numatyta pataisyta Puasono regresinė analizė, tinkama ir tokiai situacijai.
- *Yra statistiškai nereikšmingas regresorius* (jam Voldo kriterijaus p reikšmė didesnė už 0,05). Regresorius pašalinamas iš modelio ir Puasono regresinė analizė pakartojama be jo. Visi rodikliai peržiūrimi iš naujo.

⁷⁰ Angl. *Overdispersion*.

⁷¹ Angl. *Zero – inflated model*.

7.1.7. Pastabos apie Puasono regresijos taikymą

- Primename, kad nors stebime sveikuosius skaičius įgyjantį dydį, prognozuojame vidutinę jo reikšmę. Vidurkis visai neturi būti sveikasis skaičius. Jeigu, taikydami Puasono regresijos prognozę šeimai, kurios abudu tėvai turi bakalauro išsilavinimą, gausime, kad šeimoje bus vidutiniškai 1,7 vaiko, nereiškia, kad šeimoje bus du vaikai, kurių vienas be kojos. Tai tiesiog prognozė, kad bendras visų šeimų, kuriose tėvai turi bakalauro išsilavinimą, vaikų skaičius, padalytas iš tokių šeimų skaičiaus, bus 1,7.
- Reikia nepainioti tikėtinumų santykio chi kvadrato ir Pirsono chi kvadrato statistikų. Pastaroji statistika yra deviacijos analogas ir rodo geresnį modelio tikimą, kai nedaug skiriasi nuo savo laisvės laipsnių skaičiaus. Tikėtinumų santykio chi kvadrato statistika lygina tiriamą modelį su modeliu, neturinčiu jokių regresorių. Ji rodo geresnį modelio tikimą, kai yra *didelė*.
- Puasono kintamasis, turintis didelį vidurkį, nedaug skiriasi nuo normaliojo, o tuo atveju dažnai galima taikyti paprastą tiesinę regresiją. Todėl visada rekomenduojama nusibraižyti Y dažnių diagramą arba histogramą. Jeigu ji ryškiai asimetrinė (a) pav.), jokių kalbų apie tiesinę regresiją negali būti. Jeigu diagrama primena normaliąją kreivę (b) pav.), galima pamąstyti ir apie tiesinės regresijos taikymą.



- Nereikia suabsoliutinti deviacijos ir kitų charakteristikų vaidmens. Nesunku sukurti pavyzdį visai be regresorių ($Y = C$), kai deviacijos ir jos laisvės laipsnių santykis artimas vienetui, o konstanta C statistiškai reikšminga. Modelis turi būti dar ir logiškas.
- Galima dirbtinai transformuoti duomenis, kad jie pasidarytų panašūs į puasoniškus. Tam reikia pritaikyti svorį, lygų deviacijos ir laisvės laipsnių santykiui. Mums toks duomenų keitimas atrodo kiek dirbtinas ir šiame el. vadovėlyje jis nebus nagrinėjamas.

7.1.8. Standartiniai Puasono regresijos modelio aprašymai

Visada aprašomas galutinis, po visų tobulinimų gautas modelis. Pateiksime keletą galimų aprašymų fragmentų.

- *Pritaikytas Puasono regresijos modelis gerai tiko duomenims. Tikėtinumų santykio $\chi^2=13,27$; $p < 0,01$. Deviacijos ir jos laisvės laipsnių santykis 1,08. Visi modelio regresoriai statistiškai reikšmingi. Kintamojo Y vidurkio regresinis modelis atrodo taip: $\ln \hat{\mu} = -2 + 0,46X + 5Z$. Kai X padidėja 1, kintamojo Y vidurkis padidėja 1,58 karto...*
- *Iš modelio buvo pašalintas statistiškai nereikšmingas regresorius X. Galutinis modelis buvo statistiškai reikšmingas. Tikėtinumų santykio $\chi^2=10,02$; $p = 0,023$; deviacijos ir laisvės laipsnių santykis 0,99.*

7.2. Puasono regresinė analizė su SPSS


7.2.1. Duomenys

Kaip atlikti Puasono regresinę analizę parodysime, tirdami 2008 metų Europos Sąjungos socialinio tyrimo Prancūzijos duomenis **ESS4FR**. Tyrime naudosime tokius kintamuosius:

- *agea* – respondento amžius,
- *hhmb* – namų ūkio nuolatinių narių skaičius,
- *imptrad* – svarbu laikytis tradicijų ir papročių (1 – visai kaip aš, ... , 6 – absoliučiai ne taip kaip aš),
- *eduyrs* – prasimokytų metų skaičius,
- *cldcrsv* – paramos vaiko priežiūrai teikimas tėvams, turintiems teisę ją gauti (0 – itin blogas, ... , 10 – labai geras).


Modeliuosime, kiek namų ūkyje yra gyventojų be paties respondento(ės). Regresoriai bus amžius (*agea*) ir požiūris į paramos vaiko priežiūrai prieinamumą (*cldcrsv*). Tirsime stipriai tradicijų besilaikančius ($imptrad \leq 2$) aukštojo mokslo neragavusius ($eduyrs \leq 10$) respondentus(es).

Su komanda **Select Cases** atrenkame reikiamus respondentus. Tai daroma taip: meniu **Select Cases** pažymime **If condition is satisfied** ir spaudžiame klavišą **If**.




Naujajame meniu suformuluojame sąlygą $imptrad \leq 2 \ \& \ eduys \leq 10$. Tada spaudžiame **Continue** ir **OK**.

Dar reikia sukurti priklausomą kintamąjį. Pavadinkime jį *numbhh*. Aišku, kad $numbhh = hhmb-1$. Todėl reikiamą kintamąjį sukuriame **Transform** → **Compute Variable** komanda.




7.2.2. Preliminari analizė

Pirmiausia pasižiūrėsime, ar priklausomas kintamasis *numbhh* panašus į Puasono kintamąjį. Aišku, kad jis įgyja sveikas neneigiamas reikšmes. Taip pat labai tikėtina, kad respondentų iš daugiavaikių šeimų nėra daug. Nusibraižysime dažnių stulpelių grafiką ir apskaičiuosime empirinį vidurkį ir dispersiją. Spaudžiame **Analyze** → **Descriptive Statistics** → **Frequencies**.



Atsivėrusiame meniu perkeliame kintamąjį *numbhh* į langelį **Variable(s)** ir spaudžiame **Statistics**. Atsivėrusiame meniu pažymime **Mean** ir **Variance**. Grįžę į ankstesnįjį meniu spaudžiame **Charts**. Pažymime **Bar chart**. Grįžtame į ankstesnį meniu ir spaudžiame **OK**.




Rezultatų išsklotinėje matyti, kad *numbhh* vidurkis (1,0036) nedaug skiriasi nuo dispersijos (1,482). Vadinas, kad *numbhh* tenkina vieną iš svarbiausių Puasono kintamojo savybių.

Statistics


numbhh		
N	Valid	281
	Missing	0
Mean		1.0036
Variance		1.482

Panašumą į Puasono skirstinį rodo ir dažnių stulpelių diagrama. Skirstinys asimetriškas, turi daug reikšmių kairėje pusėje.




Dažniausiai tyrimuose apsiribojama vidurkio ir dispersijos reikšmėmis bei dažnių grafiku. Parodysime, ką dar galima padaryti preliminarioje kintamųjų analizėje. Norint įsivaizduoti, kaip gali atrodyti Puasono skirstinys su vidurkiu, lygiu vienetui, galima atsitiktinai sugeneruoti atitinkamą Puasono skirstinį ir nubraižyti jo dažnių grafiką. Parodysime, kaip generuojamas Puasono dydis. Spaudžiame **Transform** → **Compute Variable**. Atsidariusiame meniu gali būti likę kintamojo *numbhh* kūrimo pėdsakų. Viską išvalome paspaudę **Reset**. Langelyje **Target**


Variable įrašome naujo kintamojo vardą *Pois1*. Langelyje **Function Group** pasirenkame **Random Numbers**. Langelyje **Functions and Special Variables** pasirenkamas **Rv.Poisson**. Paspaudę  perkeliame šį užrašą į langelį **Numeric Expression**. Perkeltaje išraiškoje dar reikia įrašyti generuojamo dydžio vidurkį (Puasono skirstinio parametą). Kadangi tiriamo *numbhh* vidurkis buvo beveik 1, tai įrašome 1. Spaudžiame **OK**.



Nubraižę gauto kintamojo dažnių grafiką įsitikiname, kad jis gana panašus į kintamojo *numbhh* grafiką.



Kintamojo puasoniškumą galima tikrinti ir **Kolmogorovo–Smirnov** kriterijumi. Tik reikia turėti omenyje, kad šis kriterijus nėra galingas. Todėl dažnai pirmiau aprašytas vertinimas „iš akies“ yra naudingesnis. Vis dėlto parodysime, kaip taikomas Kolmogorovo–Smirnov kriterijus. Spaudžiame **Analyze** → **Nonparametric Tests** → **Legacy Dialogs** → **1-Sample K-S**. Kintamąjį *numbhh* perkeliame į laukelį **Test Variable List**. Pažymime **Poisson** ir **Normal**. Pastarąją parinktį pasirinkome, kad galėtume įsitikinti, jog *numbhh* nėra normalusis kintamasis.



Kintamojo skirstinys statistiškai reikšmingai skiriasi nuo pasirinkto skirstinio, jeigu p reikšmė $< 0,05$. Matome, kad pagal Kolmogorovo–Smirnov kriterijų *numbhh* statistiškai reikšmingai nesiskiria nuo Puasono kintamojo ($p = 0,169$), bet skiriasi nuo normaliojo ($p = 0,000$).

One-Sample Kolmogorov-Smirnov Test		
		numbhh
N		281
Normal	Mean	1.0036
Parameters ^{a,b}	Std. Deviation	1.21743
Most Extreme	Absolute	.302
Differences	Positive	.302
	Negative	-.205
Kolmogorov-Smirnov Z		5.060
Asymp. Sig. (2-tailed)		.000


a. Test distribution is Normal.

One-Sample Kolmogorov-Smirnov Test 2		
		numbhh
N		281
Poisson	Mean	1.0036
Parameter ^{a,b}		
Most Extreme	Absolute	.066
Differences	Positive	.066
	Negative	-.026
Kolmogorov-Smirnov Z		1.111
Asymp. Sig. (2-tailed)		.169


a. Test distribution is Poisson.

7.2.3. SPSS parinktys Puasono regresijos modeliui


Patikrinsime, kaip atrinktiesiems respondentams tinka Puasono regresijos modelis. Primename, kad tikriname modelį, kurį sąlygiškai galima užrašyti $numbhh = f(agea, cldcrsv)$. Spaudžiame **Analyze** → **Generalized Linear Models** → **Generalized Linear Models**.




Atsidariusiame meniu spaudžiame **Type of Model** ir pažymime **Poisson loglinear**.




Paskui spaudžiame **Response** ir perkeliame *numbhh* į laukelį **Dependent Variable**.




Paspaudę **Predictors** abudu kintamuosius *agea* ir *cldcsv* perkeliame į langelį **Covariates**. Jeigu būtų kategorinių kintamųjų, juos keltume į **Factors**.



Pasirinkę **Model**, abudu kintamuosius perkeliame į langą **Model**.



Pasirinkę **Statistics** papildomai pažymime **Include exponential parameter estimates**. Jau pažymėtus langelius paliekame ramybėje. Spaudžiame **OK**.



7.2.4. Rezultatai

Rezultatų išsklotinė prasideda nuo informacijos apie tolydžiuosius kintamuosius. Atkreipiame dėmesį, kad, palyginti su preliminariniu tyrimu, kintamojo *numbhh* vidurkis ir standartinis nuokrypis kiek pasikeitė. Taip atsitiko, nes 27 atrinktieji respondentai neatsakė į *cldcrsv* klausimą, todėl iš tyrimo buvo automatiškai pašalinti. Vis dėlto stebinių liko pakankamai daug – 254.

Continuous Variable Information

		N	Minimum	Maximum	Mean	Std. Deviation
Dependent Variable	Numbhh	254	.00	10.00	1.0472	1.24385
Covariate	agea	254	15	93	63.10	16.153
	cldcrsv	254	0	10	5.26	2.170

Lentelėje **Goodness of Fit** yra surašyta deviacijos reikšmė, Pirsono chi kvadrato statistika ir t. t. Deviacijos ir jos laisvės laipsnių santykis, jei Puasono regresijos modelis tinkamas, turi būti artimas vienetui. Matome, kad šis santykis yra 0,919. Gavome patvirtinimą, kad apskritai modelis tinka duomenims. Liko nustatyti regresorių svarbą. Beje, Pirsono chi kvadrato statistika, padalyta iš savo laisvės laipsnių, taip pat turi būti arti vieneto. Vis dėlto manome, kad ši modelio tikimo charakteristika yra mažiau svarbi nei deviacija. Lentelėje surašytos informacinių kriterijų reikšmės

(AIC, BIC ir pan.) naudojamos keliems modeliams palyginti. Geresnis būtų tas modelis, kurio informacinių kriterijų reikšmės mažesnės.

Goodness of Fit ^b			
	Value	df	Value/df
Deviance	230.635	251	.919
Scaled Deviance	230.635	251	
Pearson Chi-Square	188.314	251	.750
Scaled Pearson Chi-Square	188.314	251	
Log Likelihood ^a	-301.040		
Akaike's Information Criterion (AIC)	608.080		
Finite Sample Corrected AIC (AICC)	608.176		
Bayesian Information Criterion (BIC)	618.692		
Consistent AIC (CAIC)	621.692		

Lentelėje **Omnibus Test** yra tikėtinumų santykio statistika ir jos p reikšmė. Gerai, kai $p < 0,05$, nes tada modelyje yra bent vienas reikalingas (statistiškai reikšmingas) regresorius. Kadangi $p = 0,000...$, galima teigti, kad regresijos modelio tinkamumą patvirtina ir tikėtinumų santykio kriterijus.

Omnibus Test ^a		
Likelihood Ratio Chi-Square	df	Sig.
112.919	2	.000

Lentelėje **Tests of Model Effects** yra informacijos apie Voldo kriterijų. Kadangi visos $p = 0,000 < 0,05$, darome išvadą, kad abudu regresoriai (*agea* ir *cldcrsv*) yra statistiškai reikšmingi ir modelyje reikalingi.

Tests of Model Effects			
Source	Type III		
	Wald Chi-Square	df	Sig.
(Intercept)	41.188	1	.000
agea	105.703	1	.000
cldcrsv	14.395	1	.000

Lentelėje **Parameter Estimates** pasikartoja informacija apie Voldo kriterijų. Taip pat surašyti parametrų įverčiai. Parametrų įverčių ženklai ir **Exp(B)** suteikia informacijos, kaip keisis vidutinis kitų namų ūkio gyventojų skaičius, keičiantis regresoriams *agea* ir *cldcrsv*.

Parameter Estimates										
Parameter	B	Std. Error	95 % Wald Confidence Interval		Hypothesis Test			Exp(B)	95 % Wald Confidence Interval for Exp(B)	
			Lower	Upper	Wald Chi-Square	df	Sig.		Lower	Upper
(Intercept)	1.535	.2392	1.066	2.004	41.188	1	.000	4.642	2.905	7.419
agea	-.035	.0034	-.042	-.028	105.703	1	.000	.966	.959	.972
cldcrsv	.099	.0261	.048	.150	14.395	1	.000	1.104	1.049	1.162
(Scale)	1 ^a									

Regresoriaus *agea* koeficientas $-0,035 < 0$. Tai reiškia, kad, didėjant atsakinėjusio respondento amžiui, vidutinis kitų namų ūkio narių skaičius mažėja. Stulpelyje **Exp(B)** užrašyta reikšmė 0,966 rodo, kad vieneri papildomi respondento amžiaus metai sumažina vidutinį tikėtiną kitų namų ūkio narių skaičių 0,966 **karto** (narių skaičių reikia dauginti iš 0,966). Stulpeliuose **Lower** ir **Upper** nurodyti **Exp(B)** pasikliautiniųjų intervalų rėžiai. Pasikliautinieji intervalai naudojami, norint patikslinti informaciją apie koeficiento įvertį. Pavyzdžiui, pasikliautinasis intervalas regresoriaus *agea* daugiklio eksponentei **Exp(B)** yra [0,959; 0,972] ir interpretuotinas taip: labai tikėtina, kad vieneri papildomi respondento amžiaus metai sumažina tikėtiną kitų namų ūkio narių skaičių nuo 0,959 iki 0,972 karto.

Matematinis modelio užrašas atrodo taip:

$$\hat{\mu} = \exp\{1,535 - 0,035 \text{ agea} + 0,099 \text{ cldcrsv}\}.$$

Čia $\hat{\mu}$ – vidutinis kitų namų ūkio narių skaičius.

Atrodytų viskas modelyje gerai. Vis dėlto, nors abudu regresoriai statistiškai reikšmingi, Voldo statistikos reikšmės (105,7 ir 14,39) skiriasi septynis kartus. Kuo Voldo statistika didesnė, tuo koeficientas statistiškai reikšmingesnis. Todėl ramybės dėlei išbandome Puasono regresiją be regresoriaus *cldcrsv*. Nebepateiksime visų lentelių, tik konstatuosime, kad

- deviacijos ir laisvės laipsnių santykis yra 0,958;
- tikėtinumų santykio kriterijaus $p = 0,000... < 0,05$;
- Voldo kriterijaus $p = 0,000... < 0,05$;
- modelis $\hat{\mu} = \exp\{2,02 - 0,034 \text{ agea}\}$.

Darome išvadą, kad naujasis modelis nėra blogesnis nei pradinis. Parodysime, kaip šį modelį taikyti konkrečioms prognozėms. Tarkime, kad respondentui 50 metų. Kiek dar yra narių jo namų ūkyje? Įstatę kintamųjų reikšmes į pirmiau pateiktą modelio lygtį, gauname

$$\hat{\mu} = \exp\{2,02 - 0,035 \cdot 50\} = \exp\{0,27\} = 1,3...$$

Darome prognozę, kad penkiasdešimtmečių namų ūkiuose, be pačių respondentų, dar turi būti vidutiniškai⁷² 1,3 narys.

7.2.5. SPSS komandų sintaksė Puasono regresinei analizei

Surašysime kaip atrodo SPSS komandos nagrinėtam Puasono regresijos pavyzdžiui. Jas galima vykdyti sintaksės lange pasirenkant **Run**. Duomenų atranka:

```
USE ALL.  
COMPUTE filter_$=(imptrad <= 2 & eduyrs <= 10).  
VARIABLE LABELS filter_$ 'imptrad <= 2 & eduyrs <= 10 (FILTER)'.  
VALUE LABELS filter_$ 0 'Not Selected' 1 'Selected'.  
FORMATS filter_$ (f1.0).  
FILTER BY filter_$.  
EXECUTE.
```

Naujo kintamojo kūrimas, jo vidurkis, dispersija ir dažnių grafikas:

```
COMPUTE numbhh=hmmmb-1.  
EXECUTE.  
FREQUENCIES VARIABLES=numbhh  
  /STATISTICS=VARIANCE MEAN  
  /BARCHART FREQ /ORDER=ANALYSIS.
```

Puasono kintamojo generavimas:

```
COMPUTE Pois1=RV.POISSON(1). EXECUTE.
```

Kolmogorovo – Smirnovo kriterijus:

```
NPAR TESTS  
  /K-S(NORMAL)=numbhh  
  /K-S(POISSON)=numbhh  
  /MISSING ANALYSIS.
```

⁷² Čia visų penkiasdešimtmečių vidurkis! Su vienu gyvena daugiau, su kitais – mažiau žmonių, o ne kiekvienoje šeimoje po invalidą.

Puasono regresijos modelis:


```

GENLIN numbhh WITH agea cldcrsv
/MODEL agea cldcrsv INTERCEPT=YES
DISTRIBUTION=POISSON LINK=LOG
/CRITERIA METHOD=FISHER(1) SCALE=1 COVB=MODEL
MAXITERATIONS=100 MAXSTEPHALVING=5
PCONVERGE=1E-006(ABSOLUTE) SINGULAR=1E-012
ANALYSISTYPE=3(WALD) CILEVEL=95 CITYPE=WALD LIKELIHOOD=FULL
/MISSING CLASSMISSING=EXCLUDE
/PRINT CPS DESCRIPTIVES MODELINFO FIT
SUMMARY SOLUTION (EXPONENTIATED).

```

7.2.6. Kategorinis regresorius

Jeigu į modelį reikia įtraukti kategorinį regresorių (pvz., kintamąjį *ctzntr* – ar yra pilietis), meniu **Generalized Linear Models - Predictors** jį įkeliame į langą **Factors**.



Nepamirštame *ctzntr* perkelti **Model** meniu į **Model** langą. Tolesnis modelio tyrimas parodo, kad regresorius *ctzntr* nėra statistiškai reikšmingas. Vis dėlto parodysime, kaip reikėtų užrašyti modelį su šiuo kintamuoju. Pateikiame lentelės **Parameter Estimates** fragmentą:


Parameter	B	Std. Error	95 % Wald Confidence Interval	
			Lower	Upper
(Intercept)	1.239	.3115	.629	1.850
agea	-.036	.0034	-.043	-.029
[ctzntr=1]	.352	.2319	-.103	.806
[ctzntr=2]	0 ^a	.	.	.
cldcrsv	.104	.0263	.053	.156

Matematinė lygtis atrodys taip:

$$\ln \hat{\mu} = 1,239 - 0,036agea + 0,104cldcrsv + \begin{cases} 0,352, & \text{jei } ctzcntr = 1, \\ 0, & \text{jei } ctzcntr = 2. \end{cases}$$

7.2.7. Puasono regresinė analizė dažniui

Tarkime, kad norime sumodeliuoti skirtingoms šalims AIDS sergamumą, atsižvelgdami į įvairius socialinius ir ekonominius veiksnius. Žinome bendrąjį sergančiųjų AIDS skaičių *aids* ir gyventojų skaičių *pop*. Norime modelio santykiui *aids/pop*. Tada su komanda **Compute Variable** sukuriame kintamąjį *logpop*, lygų *pop* logaritmui. Renkamės visas tas pačias parinktis kaip ir standartinėje Puasono regresijoje (**Dependent Variable** *aids*), tik tai **Predictors** lange į lauką **Offset Variable** įkeliame *logpop*.



Visi rezultatai interpretuojami kaip ir ankstesniu atveju. Tik tai dabar modelis sudarytas dažnio *aids/pop* logaritmui, o ne kintamojo *aids* logaritmui. Beje, lentelėje **Parameter Estimates** atsiranda kintamasis (**Scale**) su koeficientu 1.

7.3. Puasono regresinė analizė su STATA

7.3.1. Duomenys

Pakartosime Puasono regresinę analizę, jau atliktą su SPSS. Tiriame 2008 metų Prancūzijos duomenis **ESS4FR**. Tyrime naudosime tokius kintamuosius: *agea* – respondento amžius, *hhmb* – namų ūkio nuolatinių narių skaičius, *cldcrsv* – paramos vaiko priežiūrai teikimas tėvams, turintiems teisę ją gauti (0 – itin blogas, ..., 10 – labai geras), *imptrad* – svarbu laikytis tradicijų ir papročių (1 – visai kaip aš, ..., 6 – absoliučiai ne taip kaip aš), *eduyrs* – metų, kiek mokytasi, skaičius.

Tirsime stipriai tradicijų besilaikančius (*imptrad* ≤ 2) aukštojo mokslo neragavusius (*eduyrs* ≤ 10) respondentus(es):


```
keep if imptrad <= 2 & eduyrs <= 10
```

Modeliuosime, kiek namų ūkyje yra gyventojų be paties respondento(ės):

```
gen numbhh = hhmmb – 1
```

Pasižiūrėsime, ar priklausomas kintamasis *numbhh* panašus į Puasono kintamąjį. Aišku, kad jis įgyja sveikas neneigiamas reikšmes. Įvykdome: (ės):

```
summarize numbhh, detail
```


```
tab numbhh
```

```
hist numbhh, freq
```

numbhh				
Percentiles		Smallest		
1%	0	0		
5%	0	0		
10%	0	0	Obs	254
25%	0	0	Sum of Wgt.	254
50%	1	Largest	Mean	1.047244
75%	1		Std. Dev.	1.243851
90%	3		Variance	1.547166
95%	3		Skewness	2.45407
99%	5	10	Kurtosis	13.99373

```
. tab numbhh
```

numbhh	Freq.	Percent	Cum.
0	93	36.61	36.61
1	106	41.73	78.35
2	26	10.24	88.58
3	18	7.09	95.67
4	7	2.76	98.43
5	2	0.79	99.21
6	1	0.39	99.61
10	1	0.39	100.00
Total	254	100.00	



Dispersija (1,54) nedaug skiriasi nuo vidurkio (1,04). Vadinasi, kad *numbhh* tenkina vieną iš svarbiausių Puasono kintamojo savybių. Panašumą į Puasono skirstinį rodo ir dažnių stulpelių diagrama. Skirstinys asimetriškas, turi daug reikšmių kairėje pusėje.

7.3.2. Puasono modelio taikymas

Ištirsime modelį, kurį sąlygiškai galima užrašyti taip: $numbhh = f(agea, cldcrsv)$. Primename, kad mes nebandome komentuoti nustatytų ryšių, nes tai – specialisto sociologo duona. (Žinoma, dvi minutes palaužę mažąjį pirštelį, nesunkiai išlaužėme tokią teoriją: respondentas tradicionalistas – kontracepcijos nepripažįsta, o gyvena jau ilgai. Mano, kad valstybės teikiama parama vaikams auginti pakankamai didelė. Tai, ko čia stebėtis, kad septyniolika vaikų.) Įvykdome:

poisson numbhh agea cldcrsv						
Poisson regression			Number of obs = 254			
			LR chi2(2) = 112.92			
			Prob > chi2 = 0.0000			
Log likelihood = -301.04013			Pseudo R2 = 0.1579			
numbhh	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
agea	-.03498	.0034023	-10.28	0.000	-.0416484	-.0283116
cldcrsv	.0988642	.0260573	3.79	0.000	.0477928	.1499355
_cons	1.535153	.2392022	6.42	0.000	1.066326	2.003981

Virš lentelės pateikta tikėtinumų santykio statistikos reikšmė (112,92) ir $p = 0,00$. Kadangi p reikšmė mažesnė už 0,05, gavome vieną iš įrodymų, kad modelis gali tikti. Pačioje lentelėje įrašyti koeficientų įverčiai (su 95 % pasikliautiniais intervalais) ir Voldo kriterijų reikšmės. Regresoriai *agea* ir *cldcrsv* statistškai reikšmingi ($p < 0,05$). Konstantai p reikšmės netikriname.

Matematinis modelio užrašas atrodo taip:

vidutinis kitų namų ūkio narių skaičius = $\exp\{1,535 - 0,035 \text{ agea} - 0,099 \text{ cldcrsv}\}$.

Regresoriaus *agea* koeficientas neigiamas – kuo vyresnis respondentas, tuo iš mažesnio namų ūkio. Taigi iš piršto laužtoji teorija nepasitvirtino.

Norėdami gauti koeficientų įverčių eksponentes, įvykdome :

```
poisson numbhh agea cldcrsv, irr
```

numbhh	IRR	Std. Err.	z	P> z	[95% Conf. Interval]	
agea	.9656247	.0032854	-10.28	0.000	.9592069	.9720854
cldcrsv	1.103916	.0287651	3.79	0.000	1.048953	1.161759

Amžiui padidėjus 1 metais, namų ūkio narių skaičius sumažėja vidutiniškai 0,966 karto.

Kaip galimas bendrojo modelio tikimo indikatorius pateikiamas Makfadeno determinacijos koeficientas $R^2 = 0,1579$, kuris nėra didelis (ir šiuo atveju yra labai nepatikimas). Žinoma, būtų galima su komanda *fitstat* rasti ir kitus pseudokoeficientus (ir paaiškėtų, kad Nagelkerkės $R^2 = 0,35$). Vis dėlto protingesnė alternatyva yra deviacija. Įvykdome :

```
estat gof
```

```
. estat gof

Goodness-of-fit chi2 = 230.6347
Prob > chi2(251)    = 0.8172
```

STATA nepateikia statistikos ir jos laisvės laipsnių santykio, bet pateikia *p* reikšmę. Jeigu *p* reikšmė $\geq 0,05$, tai rodo gerą modelio tikimą. Patys randame deviacijos ir jos laisvės laipsnių santykį (laisvės laipsniai yra 251): $230,6347/251 = 0,9188...$ Šis santykis artimas vienetui ir rodo pakankamai gerą modelio tikimą.

Pabandome modelį be regresoriaus *cldcrsv*. Paeiliui įvykdome komandas

```
poisson numbhh agea
estat gof
```

```
Goodness-of-fit chi2 = 244.7568
Prob > chi2(252)    = 0.6164
```

Matome, kad $p = 0,6164 > 0,05$, o deviacijos ir jos laisvės laipsnių santykis 0,96 net geresnis nei anksčiau. Puikiausiai galima apsieiti modeliu $numbhh = f(agea)$, tik tiriamoji jo vertė abejotina.

7.3.3. Prognozavimas

Pirminiam modeliui parodysime, kaip atlikti vidutinio namų ūkio narių skaičiaus prognozę penkiasdešimtmečiam respondentui. Įvykdome

adjust agea=50 cldcrsv=5, exp	
Dependent variable: numbhh Equation: numbhh Command: poisson Covariates set to value: agea = 50, cldcrsv = 5	
All	exp(xb)
	1.32376
Key: exp(xb) = exp(xb)	

Gavome, kad, be pačių penkiasdešimtmečių, namų ūkiuose vidutiniškai gyvena dar po 1,32 žmogaus.

Beje, galima paprognozuoti ir pačias tikimybes, kad kartu negyvens niekas, gyvens vienas žmogus, gyvens dar du žmonės ir t. t. Įvykdome

prvalue, x(agea = 50 cldcrsv=5)	
Confidence intervals by delta method	
	95% Conf. Interval
Rate:	1.3238 [1.1552, 1.4924]
Pr(y=0 x):	0.2661 [0.2213, 0.3110]
Pr(y=1 x):	0.3523 [0.3378, 0.3668]
Pr(y=2 x):	0.2332 [0.2131, 0.2533]
Pr(y=3 x):	0.1029 [0.0809, 0.1249]
Pr(y=4 x):	0.0341 [0.0224, 0.0457]
Pr(y=5 x):	0.0090 [0.0048, 0.0132]
Pr(y=6 x):	0.0020 [0.0008, 0.0032]
Pr(y=7 x):	0.0004 [0.0001, 0.0006]
Pr(y=8 x):	0.0001 [0.0000, 0.0001]
Pr(y=9 x):	0.0000 [0.0000, 0.0000]
x=	agea cldcrsv
	50 5

Tikimybė, kad kartu negyvens jokių žmonių, – 0,266; vienas – 0,35; du – 0,23. Visos kitos tikimybės daug mažesnės.

7.3.4. Kategorinis regresorius

Jeigu regresorius įgyja tik 0 arba 1, jį galima įtraukti į modelį be jokių pakeitimų. Su STATA programa perkoduojama automatiškai. Reikia prieš komandą *poisson* parašyti *xi:*, o prieš kategorinius kintamuosius *i*. Pagrindinis regresijos modelis sudaromas mažiausiai kategorinio regresoriaus reikšmei. Visoms kitoms reikšmėms sukuriama nauji dvireikšmiai regresoriai (1 – atitinka tą senąją reikšmę, o 0 – visas kitas reikšmes).

Įtraukime į anksčiau nagrinėtą modelį lytį *gndr*.

xi: poisson numbhh agea i.gndr						
Poisson regression				Number of obs	=	254
				LR chi2(2)	=	98.91
				Prob > chi2	=	0.0000
Log likelihood = -308.04404				Pseudo R2	=	0.1383
numbhh	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
agea	-.034575	.0033749	-10.24	0.000	-.0411896	-.0279604
_Igndr_2	.0418111	.1237499	0.34	0.735	-.2007342	.2843565
_cons	2.033162	.1945051	10.45	0.000	1.651939	2.414385

Buvo sukurtas naujas dvireikšmis kintamasis *_Igndr_2*, atitinkantis antrąją *gndr* kategoriją (moteris). Nors jis ir nėra statistiškai reikšmingas, kurį laiką į tai nekreipsime dėmesio, ir pasiaiškinsime, kaip toks modelis traktuojamas. Realiai jis išskaidomas į dalinius modelius kiekvienai kategorinio regresoriaus reikšmei. Užrašome bendrąjį formalų modelį:

$$\hat{\mu} = 2,03 - 0,034 \text{ agea} + 0,042 \text{ _Igndr_2}.$$

Įstatę į jį *_Igndr_2* = 0, gauname modelį vyrams:

$$\hat{\mu} = 2,00 - 0,034 \text{ agea}.$$

Įstatę *_Igndr_2* = 1, gauname modelį moterims:

$$\hat{\mu} = 2,072 - 0,034 \text{ agea}.$$

Analogiškai sudaromi visi daliniai modeliai, kai kategorinis regresorius įgyja daugiau reikšmių.

7.4. Puasono regresinė analizė su SAS

7.4.1. Duomenys

Pakartosime Puasono regresinę analizę, jau atliktą su SPSS. Tiriamo 2008 metų Prancūzijos duomenis **ESS4FR**. Tyrime naudosime tokius kintamuosius: *agea* – respondento amžius, *hhmmb* – namų ūkio nuolatinių narių skaičius, *cldcrsv* – paramos vaiko priežiūrai teikimas tėvams, turintiems teisę ją gauti (0 – itin blogas,..., 10 – labai geras), *imptrad* – svarbu laikytis tradicijų ir papročių (1 – visai kaip aš,..., 6 – absoliučiai ne taip kaip aš), *eduyrs* – metų, kiek mokytasi, skaičius.

Tirsime stipriai tradicijų besilaikančius ($imptrad \leq 2$) aukštojo mokslo neragavusius ($eduyrs \leq 10$) respondentus(es):

```
OPTIONS nofmterr;  
data FR_s;  
set rgr.ESS4FR_s;  
if (imptrad LE 2) AND (eduyrs LE 10) AND (imptrad ne .) AND (eduyrs ne .) AND (cldcrsv ne .);  
numbhh = hhmmb - 1;  
run;
```

Modeliuosime, kiek namų ūkyje yra gyventojų be paties respondento(ės). Tam naudojamas sakiny:


```
Idta$numbhh = Idta$hhmmb - 1
```

Pasižiūrėsime, ar priklausomas kintamasis *numbhh* panašus į Puasono kintamąjį. Aišku, kad jis įgyja sveikas neneigiamas reikšmes. Dar svarbu įvertinti vidurkį, dispersiją ir nubraižyti histogramą. Įvykdome:

```
proc univariate data=FR_S freq;  
var numbhh;  
histogram numbhh;  
run;
```

The MEANS Procedure

Analysis Variable : numbhh numbhh				
N	Mean	Variance	Minimum	Maximum
254	1.0472441	1.5471663	0	10.0000000



Dispersija 1,55 nedaug skiriasi nuo vidurkio 1.05. Vadinasi, *numbhh* tenkina vieną iš svarbiausių Puasono kintamojo savybių. Panašumą į Puasono skirstinį rodo ir dažnių stulpelių diagrama. Skirstinys asimetriškas, turi daug reikšmių kairėje pusėje.

7.4.2. Puasono modelio taikymas

Ištirsime modelį, kurį sąlygiškai galima užrašyti taip: $numbhh = f(agea, cldcrsv)$. Įvykdome:

```
proc genmod data = FR_S;  
  model numbhh = agea cldcrsv / dist=poisson;  
run;
```

Number of Observations Read	254
Number of Observations Used	254

Criteria For Assessing Goodness Of Fit			
Criterion	DF	Value	Value/DF
Deviance	251	230.6347	0.9189
Scaled Deviance	251	230.6347	0.9189
Pearson Chi-Square	251	188.3136	0.7503
Scaled Pearson X2	251	188.3136	0.7503
Log Likelihood		-197.2616	
Full Log Likelihood		-301.0401	
AIC (smaller is better)		608.0803	
AICC (smaller is better)		608.1763	
BIC (smaller is better)		618.6923	

Analysis Of Maximum Likelihood Parameter Estimates							
Parameter	DF	Estimate	Standard Error	Wald 95% Confidence Limits		Wald Chi-Square	Pr > ChiSq
Intercept	1	1.5352	0.2392	1.0663	2.0040	41.19	<.0001
agea	1	-0.0350	0.0034	-0.0416	-0.0283	105.70	<.0001
cldersv	1	0.0989	0.0261	0.0478	0.1499	14.40	0.0001
Scale	0	1.0000	0.0000	1.0000	1.0000		

Note: The scale parameter was held fixed.

Lentelėje **Criteria For Assessing Goodness Of Fit** suderinamumo matai ir statistikos. Tiek deviacijos ir jos laisvės laipsnių santykis, tiek Pirsonos chi kvadrato statistikos santykis yra arti vieneto (atitinkamai 0,9189 ir 0,7503) ir rodo pakankamai gerą modelio tikimą.

Norėdami patikrinti, ar deviacijos ir laisvės laipsnių santykis statistiškai reikšmingai skiriasi nuo 1, galime papildomai įvykdyti:

```
data pvalue;
  df = 251; chisq = 230.6347;
  pvalue = 1 - probchi(chisq, df);
run;
```



```
proc print data = pvalue noobs;
run;
```

df	chisq	pvalue
251	230.635	0.81721

Gavome, kad $p > 0,8172$. Tai dar vienas modelio tinkamumo požymis. Pačioje lentelėje įrašyti koeficientų įverčiai (su 95 % pasikliautiniais intervalais) ir Voldo testų reikšmės. Regresoriai *agea* ir *cldcrsv* statistiškai reikšmingi ($p < 0,05$). Konstantai p reikšmės netikriname.

Matematinis modelio užrašas atrodo taip:

vidutinis kitų namų ūkio narių skaičius = $\exp\{1,535 - 0,035 \text{ agea} - 0,099 \text{ cldcrsv}\}$.

Regresoriaus *agea* koeficientas neigiamas – kuo vyresnis respondentas, tuo iš mažesnio namų ūkio. Taigi iš piršto laužtoji teorija nepasitvirtino.

Norėdami gauti koeficientų įverčių eksponentes, įvykdome :

```
ods output ParameterEstimates = est;
proc plm source = p1;
  show parameters;
run;
data est_exp;
  set est;
  irr = exp(estimate);
  if parameter ^= "Intercept";
run;
proc print data = est_exp;
run;
```

Obs	Parameter	Estimate	StdErr	irr
1	Age of respondent, calculated	-0.03498	0.003402	0.96562
2	Provision of affordable child care services for working parents	0.09886	0.02606	1.10392

Amžiui padidėjus 1 metais, namų ūkio narių skaičius sumažėja vidutiniškai 0,966 karto.

SAS nepateikia statistikos ir jos laisvės laipsnių santykio, bet pateikia p reikšmę. Jeigu p reikšmė $\geq 0,05$, tai rodo gerą modelio tikimą. Randame statistikos ir jos laisvės laipsnių santykį (laisvės laipsniai yra 251): $230,6347/251 = 0,9188...$ Šis santykis artimas vienetui ir rodo pakankamai gerą modelio tikimą.

Pabandome modelį be regresoriaus *cldcrsv*. Paeiliui įvykdome komandas

```
proc genmod data = FR_S;
  model numbhh = agea / dist=poisson;
  store p1; /* modelio issaugojimas */
run;
```

Criteria For Assessing Goodness Of Fit			
Criterion	DF	Value	Value/DF
Deviance	252	244.7568	0.9713
Scaled Deviance	252	244.7568	0.9713
Pearson Chi-Square	252	210.7957	0.8365
Scaled Pearson X2	252	210.7957	0.8365
Log Likelihood		-204.3227	
Full Log Likelihood		-308.1012	
AIC (smaller is better)		620.2024	
AICC (smaller is better)		620.2502	
BIC (smaller is better)		627.2771	

Analysis Of Maximum Likelihood Parameter Estimates							
Parameter	DF	Estimate	Standard Error	Wald 95% Confidence Limits		Wald Chi-Square	Pr > ChiSq
Intercept	1	2.0503	0.1876	1.6826	2.4180	119.45	<.0001
agea	1	-0.0345	0.0034	-0.0411	-0.0279	105.20	<.0001
Scale	0	1.0000	0.0000	1.0000	1.0000		

Note: The scale parameter was held fixed.

Sakinys *store* naudojamas tam, kad sudarytąjį modelį galėtume naudoti tolesnei analizei.

Matome, kad $p = 0,6164 > 0,05$, o Pirsono chi kvadrato statistikos ir jos laisvės laipsnių santykis 0,96 net geresnis nei anksčiau. Puikiausiai galima apsieiti su modeliu, kurį sąlygiškai galima užrašyti taip $numbhh = f(agea)$. Tik jo tiriamoji vertė abejotina.

7.4.3. Prognozavimas

Pirminiam modeliui parodysime kaip atlikti vidutinio namų ūkio narių skaičiaus prognozę penkiasdešimtmečiam respondentui. Įvykdome

```
data arg;
  set fr_s;
  agea =50 ;
  output;
run;
proc plm source=p1;
  score data = arg out=prg /ilink;
run;
proc means data = prg mean;
  class agea;
  var predicted;
run;
```

Analysis Variable : Predicted Predicted Value		
Age of respondent, calculated	N Obs	Mean
50	254	1.3908675

Gavome, kad, be pačių penkiasdešimtmečių, namų ūkiuose vidutiniškai gyvena dar po 1,39 žmogaus.

7.4.4. Kategorinis regresorius

Jeigu regresorius įgyja tik 0 arba 1, jį galima įtraukti į modelį be jokių pakeitimų. SAS programoje kategorinis regresorius perkoduojamas automatiškai, nurodžius jį *class* sakinyje.

Įtraukime į anksčiau nagrinėtą modelį lytį *gndr*.

```
proc genmod data = FR_S;
  class gndr /param=glm;
  model numbhh = agea gndr / dist=poisson;
run;
```

Class Level Information		
Class	Levels	Values
gndr	2	Female Male

Criteria For Assessing Goodness Of Fit			
Criterion	DF	Value	Value/DF
Deviance	251	244.6425	0.9747
Scaled Deviance	251	244.6425	0.9747
Pearson Chi-Square	251	210.3925	0.8382
Scaled Pearson X2	251	210.3925	0.8382
Log Likelihood		-204.2655	
Full Log Likelihood		-308.0440	
AIC (smaller is better)		622.0881	
AICC (smaller is better)		622.1841	
BIC (smaller is better)		632.7001	

Analysis Of Maximum Likelihood Parameter Estimates								
Parameter		DF	Estimate	Standard Error	Wald 95% Confidence Limits		Wald Chi-Square	Pr > ChiSq
Intercept		1	2.0332	0.1945	1.6519	2.4144	109.27	<.0001
agea		1	-0.0346	0.0034	-0.0412	-0.0280	104.96	<.0001
gndr	Female	1	0.0418	0.1237	-0.2007	0.2844	0.11	0.7355
gndr	Male	0	0.0000	0.0000	0.0000	0.0000	.	.
Scale		0	1.0000	0.0000	1.0000	1.0000		

Note: The scale parameter was held fixed.

Kintamasis *gndr* buvo perkoduotas (1 atitinka antrąją *gndr* kategoriją (moteris)). Nors jis ir nėra statistiškai reikšmingas, pasiaiškinsime, kaip toks modelis traktuojamas. Realiai jis išskaidomas į dalinius modelius kiekvienai kategorinio regresoriaus reikšmei. Užrašome bendrąjį formalų modelį:

$$\hat{\mu} = 2,03 - 0,034 \text{ agea} + 0,042 \text{ gndr} .$$

Įstatę į jį $I_{\text{gndr}} = 0$, gauname modelį vyrams:

$$\hat{\mu} = 2,00 - 0,034 \text{ agea} .$$

Istatę $gndr = 1$, gauname modelį moterims:

$$\hat{\mu} = 2,072 - 0,034 \text{ agea.}$$

Analogiškai sudaromi visi daliniai modeliai, kai kategorinis regresorius įgyja daugiau reikšmių.

7.4.5. SAS programos Puasono regresijos procedūra

Taikant SAS programą Puasono regresinei analizei yra naudojama **proc genmod** procedūra. Šios procedūros sintaksė atrodo taip:

```
PROC GENMOD <options> ;
ASSESS | ASSESSMENT VAR=(effect) | LINK </ options> ;
BAYES <options> ;
BY variables ;
CLASS variable <(options)><variable <(options)>> </ options> ;
CONTRAST 'label' contrast-specification </ options> ;
DEVIANCE variable = expression ;
EFFECTPLOT <plot-type <(plot-definition-options)>> </ options> ;
ESTIMATE 'label' effect values <,...effect values> </ options> ;
EXACT <'label'> <INTERCEPT> <effects> </ options> ;
EXACTOPTIONS options ;
FREQ | FREQUENCY variable ;
FWDLINK variable = expression ;
INVLINK variable = expression ;
LSMEANS <model-effects> </ options> ;
LSMESTIMATE model-effect <'label'> values <divisor=> <, ...<'label'> values
<divisor=>> </ options> ;
MODEL response = <effects> </ options> ;
OUTPUT <OUT=SAS-data-set> <keyword=name...keyword=name> ;
Programming statements ;
REPEATED SUBJECT=subject-effect </ options> ;
SLICE model-effect </ options> ;
STORE <OUT=>item-store-name </ LABEL='label'> ;
```

```
STRATA variable <(option)> <variable <(option)>> </ options> ;  
WEIGHT | SCWGT variable ;  
VARIANCE variable = expression ;  
ZEROMODEL <effects > </ options> ;
```

Scenarijus :

```
OPTIONS nofmterr;  
data FR_s;  
set rgr.ESS4FR_s;  
if (imptrad LE 2) AND (eduyrs LE 10) AND (imptrad ne .) AND (eduyrs ne .) AND  
  (cldcsv ne .);  
numbhh = hhmb - 1;  
run;  
#  
# Priklausomo kintamojo charakteristikos  
#  
proc means data = FR_S n mean var min max;  
var numbhh;  
run;  
proc sgplot data = FR_S;  
  histogram numbhh / scale = count showbins;  
run;  
/* koeficientų skaičiavimas */  
proc genmod data = FR_S;  
  model numbhh = agea cldcsv / dist=poisson;  
store p1; /* modelio išsaugojimas */  
run;  
/* chi kvadrat */  
data pvalue;  
df = 251; chisq = 230.6347;  
pvalue = 1 - probchi(chisq, df);
```

```

run;
proc print data = pvalue noobs;
run;
/* eksponentinių koeficientų skaičiavimas */
ods output ParameterEstimates = est;
proc plm source = p1;
  show parameters;
run;
data est_exp;
  set est;
  irr = exp(estimate);
  if parameter ^= "Intercept";
run;
proc print data = est_exp;
run;
/* Supaprastintas modelis */
proc genmod data = FR_S;
  model numbhh = agea / dist=poisson;
store p1; /* modelio išsaugojimas */
run;

/* prognozavimas */

data arg;
  set fr_s;
  agea =50 ;
  output;
run;
proc plm source=p1;
  score data = arg out=prg /ilink;
run;
proc means data = prg mean;
  class agea;

```

```

var predicted;
run;

/* eksperimentas prognozuojant */
data new;
set FR_S end=eof;
output;
if eof then do;
Call missing( of _all_ );
agea=50;
output;
end ;
run;

proc genmod data = new;
model numbhh = agea / dist=poisson;
output out=mmm predicted=pre;
run;

proc sql;
select pre from mmm where agea=50;
run;

/* Modelis su kategoriniu kintamuoju */
proc genmod data = FR_S;
class gndr /param=glm;
model numbhh = agea gndr / dist=poisson;
/*store p1; modelio išsaugojimas */
run;

```


7.5. Puasono regresinė analizė su R

7.5.1. Duomenys

Pakartosime Puasono regresinę analizę, atliktą su SPSS. Tiriamo 2008 metų Prancūzijos duomenis **ESS4FR**. Tyrime naudosime tokius kintamuosius: *agea* – respondento amžius, *hhmmb* – namų ūkio nuolatinių narių skaičius, *cldcrsv* – paramos vaiko priežiūrai teikimas tėvams, turintiems teisę ją gauti (0 – itin blogas,..., 10 – labai geras), *imptrad* – svarbu laikytis tradicijų ir papročių (1 – visai kaip aš,..., 6 – absoliučiai ne taip kaip aš), *eduyrs* – metų, kiek mokytasi, skaičius.

Tirsime stipriai tradicijų besilaikančius ($imptrad \leq 2$) aukštojo mokslo neragavusius ($eduyrs \leq 10$) respondentus(es) (atsakiusius į visus tyrime vartojamus klausimus):

```
dta<-read.csv2("ESS4FR_s.csv",na.strings = "NA",stringsAsFactors=FALSE)
ldta<-subset(dta, imptrad <= 2 & eduyrs <= 10 & imptrad >0)
ldta$cldcrsv<-replace(ldta$cldcrsv,ldta$cldcrsv==88,NA)
ldta <- ldta[complete.cases(ldta), ]
```

Modeliuosime kiek namų ūkyje yra gyventojų be paties respondento(ės):

```
ldta$numbhh <- ldta$hhmmb – 1
```

Pasižiūrėsime, ar priklausomas kintamasis *numbhh* panašus į Puasono kintamąjį. Aišku, kad jis įgyja sveikas neneigiamas reikšmes. Dar svarbu įvertinti vidurkį, dispersiją ir nubraižyti histogramą. Įvykdome: (ės):

```
addmargins(table(ldta$numbhh))
summary(ldta$numbhh)
var(ldta$numbhh)
hist(ldta$numbhh)
```

```
> addmargins(table(Idta$numbhh))
```


0	1	2	3	4	5	6	10	Sum
93	106	26	18	7	2	1	1	254

```
> summary(Idta$numbhh)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.000	0.000	1.000	1.047	1.000	10.000

```
> var(Idta$numbhh)
```

```
[1] 1.547166
```



Dispersija (1,55) nedaug skiriasi nuo vidurkio (1,05). Tai reiškia, kad *numbhh* tenkina vieną išsvarbiausių Puasono kintamojo savybių. Panašumą į Puasono skirstinį rodo ir dažnių stulpelių diagrama. Skirstinys asimetriškas, turi daug reikšmių kairėje pusėje.

7.5.2. Puasono modelio taikymas

Ištirsime modelį, kurį sąlygiškai galima užrašyti taip: $\text{numbhh} = f(\text{agea}, \text{cldcrsv})$. Įvykdome:

```
summary(m1 <- glm(numbhh ~ agea+cldcrsv, family = "poisson", data = ldta))
```

```
Call:
glm(formula = numbhh ~ agea + cldcrsv, family = "poisson", data = ldta)

Deviance Residuals:
    Min       1Q   Median       3Q      Max
-2.54842 -0.97981  0.01375  0.55598  2.55014

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept)  1.535153   0.239202   6.418  1.38e-10 ***
agea        -0.034980   0.003402  -10.281 < 2e-16 ***
cldcrsv      0.098864   0.026057   3.794  0.000148 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 343.55 on 253 degrees of freedom
Residual deviance: 230.63 on 251 degrees of freedom
(27 observations deleted due to missingness)
AIC: 608.08

Number of Fisher Scoring iterations: 5
```

Rezultatų išsklotinėje pirmiausia pateiktos deviacijos charakteristikos, koeficientų įverčiai ir Voldo kriterijų reikšmės. Regresoriai *agea* ir *cldcrsv* statistiškai reikšmingi ($p < 0,05$). Konstantai p reikšmės netikriname.

Pagal nutylėjimą R programa pateikia labai nedaug modelio suderinamumo rodiklių (deviacija ir AIC). R nepateikia deviacijos (**Residual deviance**) ir jos laisvės laipsnių santykio. Patys randame statistikos ir jos laisvės laipsnių santykį (laisvės laipsniai yra 251): $230,6347/251 = 0,9188$... Šis santykis artimas vienetui ir rodo pakankamai gerą modelio tikimą.

Didžiausio tikėtinumo santykio chi kvadrato kriterijaus rezultatus ir pseudo R^2 gauname įvykdę:

```
m1.reduced <- glm(numbhh ~ 1, family = "poisson", data=ldta)
anova(m1.reduced, m1, test="Chisq")
rkvadrat <- 1 - m1$deviance/m1$null.deviance
rkvadrat
```

Analysis of Deviance Table

Model 1: numbhh ~ 1

Model 2: numbhh ~ agea + cldcrsv

	Resid. Df	Resid.Dev	Df	Deviance	Pr(>Chi)
1	253	343.55			
2	251	230.63	2	112.92	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

> rkvadrat

[1] 0.3286785

Didžiausių tikėtinumų santykio chi kvadrato statistikos reikšmė 112,92, o $p = 0,00$. Kadangi p reikšmė mažesnė už 0,05, gavome dar vieną iš įrodymų, kad modelis gali tikti.

Determinacijos koeficientas $R^2 = 0,33$ nėra didelis (ir šiuo atveju yra labai nepatikimas), bet $> 0,2$. Tai dar vienas patvirtinimas, kad modelis nagrinėtinas.

Matematinis modelio užrašas atrodo taip:

vidutinis kitų namų ūkio narių skaičius = $\exp\{1,535 - 0,035 \text{ agea} - 0,099 \text{ cldcrsv}\}$.

Regresoriaus *agea* koeficiento įvertis neigiamas – kuo vyresnis respondentas, tuo iš mažesnio namų ūkio.

Norėdami gauti koeficientų įverčių pasikliautinuosius intervalus bei eksponentes, įvykdome :

```
(est <- cbind(Estimate = coef(m1), confint(m1)))
exp(est)
```

```
> (est <- cbind(Estimate = coef(m1), confint(m1)))
Waiting for profiling to be done...
      Estimate      2.5 %      97.5 %
(Intercept)  1.53515331  1.05658206  1.99454929
agea         -0.03498002 -0.04162771 -0.02828454
cldcrsv       0.09886418  0.04755434  0.14974192
> exp(est)
      Estimate      2.5 %      97.5 %
(Intercept)  4.6420371  2.8765224  7.3488900
agea         0.9656247  0.9592268  0.9721117
cldcrsv      1.1039164  1.0487032  1.1615344
```

Amžiui padidėjus 1 metais, namų ūkio narių skaičius sumažėja vidutiniškai 0,966 karto.

Pabandome modelį be regresoriaus *cldcrsv*. Paeiliui įvykdome komandas

```
ldta<-ldta[!is.na(ldta$cldcrsv),]  
summary(m1 <- glm(numbhh ~ agea, family = "poisson", data = ldta))
```

```
Call:  
glm(formula = numbhh ~ agea, family = "poisson", data = ldta)  
  
Deviance Residuals:  
    Min       1Q   Median       3Q      Max   
-2.56220 -1.02342 -0.01668  0.49116  2.84129  
  
Coefficients:  
            Estimate Std. Error z value Pr(>|z|)      
(Intercept)  2.050314    0.187596   10.93  <2e-16 ***  
agea        -0.034469    0.003361  -10.26  <2e-16 ***  
---  
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1  
  
(Dispersion parameter for poisson family taken to be 1)  
  
Null deviance: 343.55 on 253 degrees of freedom  
Residual deviance: 244.76 on 252 degrees of freedom  
AIC: 620.2  
  
Number of Fisher Scoring iterations: 5
```

Matome, kad sąlyginis tinkamumo matas AIC pasikeitė (buvo 608,1, dabar 620,2) , tačiau Pirsono chi kvadrato statistikos (**Residual deviance**) ir jos laisvės laipsnių santykis $244,76/252=0,971$ net geresnis nei anksčiau. Galima apsieiti su modeliu, kurį sąlygiškai galima užrašyti taip $numbhh = f(agea)$. Tik tiriamoji jo vertė abejotina.

7.5.3. Prognozavimas

Supaprastintam modeliui (vienas regresorius *agea*) parodysime, kaip atlikti visuotinio namų ūkio narių skaičiaus prognozę penkiadešimtmečiam respondentui. Įvykdome

```
predict(m1, data.frame(agea = 50), type = "response")
```

```
> predict(m1, data.frame(agea = 50), type = "response")  
1  
1.386599  
>
```

Gavome, kad, be pačių penkiasdešimtmečių, namų ūkiuose vidutiniškai gyvena dar po 1,387 žmogaus.

7.5.4. Kategorinis regresorius

Jeigu regresorius įgyja tik 0 arba 1, jį galima įtraukti į modelį be jokių pakeitimų. R programoje kategorinis kintamasis perkoduojamas automatiškai, nurodžius regresorių komadoje kaip *factor*. Pagrindinis regresijos modelis sudaromas mažiausiai kategorinio regresoriaus reikšmei. Visoms kitoms reikšmėms sukuriama nauji dvireikšmiai regresoriai (1 – atitinka senąją reikšmę, o 0 – visas kitas reikšmes).

Įtraukime į anksčiau nagrinėtą modelį lytį *gndr*.

```
summary(m1 <- glm(numbhh ~ agea+factor(gndr), family = "poisson", data = ldta))  
# arba  
summary(m1 <- glm(numbhh ~ agea+l(gndr==2), family = "poisson", data = ldta))
```

Call:

```
glm(formula = numbhh ~ agea + l(gndr == 2), family = "poisson",  
    data = ldta)
```

Deviance Residuals:

Min	1Q	Median	3Q	Max
-2.53696	-1.03184	-0.03525	0.51072	2.82115

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	2.033162	0.194505	10.453	<2e-16 ***
agea	-0.034575	0.003375	-10.245	<2e-16 ***
l(gndr == 2)TRUE	0.041811	0.123750	0.338	0.735

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 343.55 on 253 degrees of freedom
Residual deviance: 244.64 on 251 degrees of freedom
AIC: 622.09

Number of Fisher Scoring iterations: 5

Buvo sukurtas naujas dvireikšmis kintamasis $I(gndr == 2)$, (1 – atitinkantis antrąją *gndr* kategoriją (moteris)). Nors jis ir nėra statistiškai reikšmingas, edukaciniu tikslu pasiaiškinsime,

kaip toks modelis traktuojamas. Realiai jis išskaidomas į dalinius modelius kiekvienai kategorinio regresoriaus reikšmei. Užrašome bendrąjį formalų modelį:

$$\hat{\mu} = 2,03 - 0,034 \text{ agea} + 0,042I(\text{gndr} == 2).$$

Įstatę į jį $I(\text{gndr} == 2) = 0$, gauname modelį vyrams:

$$\hat{\mu} = 2,00 - 0,034 \text{ agea}.$$

Įstatę $I(\text{gndr} == 2) = 1$, gauname modelį moterims:

$$\hat{\mu} = 2,072 - 0,034 \text{ agea}.$$

Analogiškai sudaromi visi daliniai modeliai, kai kategorinis regresorius įgyja daugiau reikšmių.

7.5.5. R programos Puasono regresijos komandos

R programoje Puasono regresinei analizei yra naudojama **glm** komanda. Šios komandos sintaksė atrodo taip:

```
glm(formula, family, data, weights, subset, ...)
```

Būtinas parametras **formula** – užrašome modelio išraišką. Komanda **glm** naudojama ne tik Puasono regresijos analizei. Kokia analizė bus atliekama, nulemia parametras *family*. Puasono regresijos atveju jo reikšmė yra **family = "poisson"**.

Scenarijus:

```
dta<-read.csv2("ESS4FR_s.csv",na.strings = "NA",stringsAsFactors=FALSE)
ldta<-subset(dta, imprtrad <= 2 & eduys <= 10 & imprtrad >0)
ldta$cldcrsv<-replace(ldta$cldcrsv,ldta$cldcrsv==88,NA)
ldta <- ldta[complete.cases(ldta), ]
ldta$numbhh <- ldta$hhmmb - 1
#
# Priklausomo kintamojo charakteristikos
#
addmargins(table(ldta$numbhh))
summary(ldta$numbhh)
var(ldta$numbhh)
```

```

hist(ldta$numbhh)

#
# Puasono modelio taikymas
#
summary(m1 <- glm(numbhh ~ agea+cldcrsv, family = "poisson", data = ldta))
#
# suderinamumo tikrinimas
#
m1.reduced <- glm(numbhh ~ 1, family = "poisson", data=ldta)
anova(m1.reduced, m1, test="Chisq")
# pseudo r kvadratas
rkvadrat <- 1 - m1$deviance / m1$null.deviance
rkvadrat
#
# Įverčių pasikliautinieji intervalai ir eksponentės
#
(est <- cbind(Estimate = coef(m1), confint(m1)))
exp(est)
#
# Modelis be cldcrsv
#
ldta <- ldta[!is.na(ldta$cldcrsv),]
summary(m1 <- glm(numbhh ~ agea, family = "poisson", data = ldta))
# prognozavimas (paprasčiausiam modeliui tik su agea)
#
predict(m1, data.frame(agea = 50), type = "response")
#
# modelis su kategoriniu kintamuoju gndr
#
summary(m1 <- glm(numbhh ~ agea + I(gndr == 2), family = "poisson", data = ldta))
#

```


Uždaviniai

1. 2008 metų Europos Sąjungos socialinio tyrimo Izraelio duomenų failas **ESS4IL**. Kintamieji:

- *agea* – respondento amžius,
- *freehms* – gėjai ir lesbietės gali gyventi kaip nori (matuojamas skale nuo 1 – visiškai sutinku, iki 5 – visiškai nesutinku),
- *hhmmb* – namų ūkio nuolatinių narių skaičius,
- *blgetmg* – priklausymas etninėms mažumoms (1 – taip, 2 – ne),
- *gndr* – lytis (1 – vyr., 2 – mot.),
- *imptrad* – svarbu laikytis tradicijų ir papročių (1 – visai kaip aš,..., 6 – absoliučiai ne taip kaip aš),
- *pray* – meldžiamasi (1 – kasdien, 2 – dažniau nei kartą per savaitę, 3 – kartą per savaitę, ..., 7 – niekada).

Pritaikyti Puasono regresijos modelį namų ūkio nuolatinių gyventojų skaičiui (*hhmmb*). Regresoriai amžius (*agea*) ir požiūris į seksualines mažumas (*freehms*). Tiriami labai tradicijų besilaikantys (*imptrad* = 1), religingi (*pray* ≤ 3) vyrai (*gndr* = 1), priklausantys nacionalinei daugumai (*blgtmg* = 2).

2. Ar tiks Puasono regresijos modelis, jeigu ankstesnio uždavinio sąlygoje pakeisime respondentus vyrus moterimis?

~~POISSON~~ REGRESSION


Kai korektorius moka anglų kalbą

8. NEIGIAMA BINOMINĖ REGRESIJA

Tipinės situacijos, kai gali būti taikoma neigiama binominė regresinė analizė, yra šios:

- Norime ištirti, ar praleistų paskaitų skaičius priklauso nuo ankstesnės sesijos statistikos egzamino pažymio.
- Bandome išsiaiškinti, kaip peršalimų skaičius susijęs su maitinimosi įpročiais.
- Modeliuojame loterijos laimėtojų įvairiuose regionuose skaičių, atsižvelgdami į gyventojų skaičių ir parduotų bilietų skaičių.
- Tiriame, nuo kokių draudžiamojo objekto savybių priklauso draudžiamųjų įvykių skaičius.

Modelio schema:



Skaičiuojame kažkokius įvykius ir manome, kad tų įvykių skaičius (pažymėkime jį Y) nėra panašus į normalųjį kintamąjį ir priklauso nuo kitų stebimų kintamųjų X , Z , W . Kintamasis Y vadinamas *priklausomu kintamuoju*, kintamieji X , Z , W – *nepriklausomais kintamaisiais* arba *regresoriais*. Faktiškai tokį pat modelį nagrinėjome Puasono regresijos atveju. Iš tikrųjų neigiama binominė regresija yra Puasono regresijos alternatyva, kai kintamojo Y dispersija daug didesnė už jo vidurkį. Beveik viskas, kas pasakyta apie Puasono regresijos modelį, tinka ir neigiamos binominės regresijos atveju. Modelio pavidalas ir prognozavimas atliekamas visiškai analogiškai. Vis dėlto, kad būtų patogiau naudotis el. vadovėliu, pagrindines idėjas trumpai pakartosime.

8.1. Neigiamos binominės regresijos modelis

8.1.1. Modelio lygtis ir jos taikymas prognozuojant

Matematinis modelis sudaromas ne pačiam priklausomam kintamajam Y , o jo vidurkiui, kurį pažymėsime simboliu μ . Modelis atrodo taip:

$$\mu = e^z,$$
$$z = C + b_1 X + b_2 Z + b_3 W.$$

Naudojant imties duomenis apskaičiuojami koeficientų įverčiai $\hat{C}, \hat{b}_1, \hat{b}_2, \hat{b}_3$. Jų ženklai padeda suprasti regresorių poveikį Y .

Jeigu koeficientas teigiamas, regresoriui didėjant, vidutinė Y reikšmė didėja.

Jeigu koeficientas neigiamas, regresoriui didėjant, vidutinė Y reikšmė mažėja.

Į *modelio koeficientų eksponentes* atsižvelgiama, kai norima įvertinti, kiek kartų padidės (sumažės) kintamojo Y vidurkis μ , atitinkamam regresoriui padidėjus vienetu.

Kai X padidėja vienetu, kintamojo Y vidurkis μ padidėja (sumažėja) e^{β_1} karto.

Vidutinio įvykių skaičiaus prognozavimas konkrečioms X, Z, W reikšmėms atliekamas taip: į formulę $z = \hat{C} + \hat{b}_1 X + \hat{b}_2 Z + \hat{b}_3 W$ įstatome tas X, Z ir W reikšmes, kurioms norime gauti prognozę. Vidurkio μ įvertis gaunamas pagal formulę: $\hat{\mu} = e^z$. Čia $e = 2,718...$ Tarkime, kad konkrečioms X, Z, W reikšmėms apskaičiavome $z = 2$. Tada $\hat{\mu} = e^2 = 7,3890 ...$

Modeliuojant dažnį (įvykių skaičių per laiko vienetą), reikia tarp duomenų turėti tyrimo trukmę rodantį kintamąjį (tarkime s). Pavyzdžiui, pateikiant kiekvieno traumatologijos punkto pacientų skaičiaus (Y) statistiką, dar reikia nurodyti, kelių dienų informaciją pateikiame (kintamasis s). Šiuo atveju naudojamas modifikuotas neigiamos binominės regresijos modelis:

$$\ln(\mu/s) = C + b_1 X + b_2 Z + b_3 W.$$

Parametrai C, b_1, b_2, b_3 nėra žinomi. Jų įverčiai $\hat{C}, \hat{b}_1, \hat{b}_2, \hat{b}_3$ gaunami panaudojus imties duomenis. Prognozavimas niekuo nesiskiria nuo ankstesnio atvejo.

8.1.2. Duomenys

Duomenys turi tenkinti tokius reikalavimus:

- Kintamasis Y turi neigiamą binominį skirstinį. Dispersija didesnė už vidurkį.
- Dalis regresorių gali būti intervaliniai, dalis dvireikšmiai arba kategoriniai (jie keičiami pseudokintamaisiais). Modelį lengviau interpretuoti, kai regresoriai intervaliniai.

8.1.3. Modelio tinkamumas

Modelio tinkamumą duomenims rodo šios charakteristikos:

- a) *Deviacija*. Taria, kad modelis pakankamai geras, jeigu deviacija, padalyta iš savo laisvės laipsnių skaičiaus, nedaug skiriasi nuo vieneto.
- b) *Pirsono chi kvadrato statistika* yra deviacijos analogas. Modelis tuo geresnis, kuo ši statistika mažesnė.
- c) *Tikėtinumų santykio kriterijus*. Parodo, ar modelyje yra bent vienas reikalingas (reikšmingas) regresorius. Jeigu p reikšmė didesnė už 0,05, regresijos modelio tinkamumas labai abejotinas.
- d) *Akaičės informacinis indeksas AIC*. Rodiklis, leidžiantis „iš akies“ palyginti du modelius. Geresnis tas modelis, kurio AIC mažesnis. Primename, kad lyginamųjų modelių parametrų įverčiai turi būti apskaičiuoti naudojant tuos pačius duomenis.
- e) *Voldo kriterijai atskiriems regresoriams*. Jeigu $p < 0,05$, tariame, kad *regresorius yra statistiškai reikšmingas* ir dažniausiai jį modelyje paliekame. Jeigu $p \geq 0,05$, regresorius yra statistiškai nereikšmingas ir modelyje jis paliekamas tik ypatingais atvejais. Dažniausiai modelio konstanta C paliekama net ir tada, kai ji statistiškai nereikšminga.

8.1.4. Neigiamos binominės regresinės analizės etapai

Regresinė analizė susideda iš preliminarų kintamųjų tinkamumo tyrimo ir modelio tinkamumo duomenims tikrinimo. Išsami analizė susideda iš tokių etapų:

- 1) Patikriname, ar Y dispersija didesnė už vidurkį. Jeigu mažesnė, neigiama binominė regresinė analizė netaikytina.
- 2) Sudarome neigiamos binominės regresijos modelį ir patikriname, ar deviacija, padalyta iš savo laisvės laipsnių, nedaug skiriasi nuo vieneto. Alternatyviai galima tikrinti, ar Pirsono statistikos reikšmė, padalyta iš laisvės laipsnių, nedaug skiriasi nuo vieneto.
- 3) Patikriname, ar tikėtinumų santykio kriterijaus $p < 0,05$. Jeigu ne – modelis netinkamas.
- 4) Patikriname, ar visi regresoriai statistiškai reikšmingi (visos Voldo kriterijaus $p < 0,05$). Jeigu ne – modelis taisytinas. Konstantai p reikšmės nežiūrime.
- 5) Jeigu viskas gerai – modelį aprašome, jei ne – tobuliname.

Gera duomenims tinkamo modelio:

- Deviacija (arba Pirsono chi kvadrato statistika), padalyta iš laisvės laipsnių skaičiaus, nedaug skiriasi nuo vieneto.
- Tikėtinumų santykio kriterijaus $p < 0,05$.
- Visų regresorių Voldo kriterijaus $p < 0,05$.

8.1.5. Modelio tobulinimas

Modelio tobulinimas – tai regresorių šalinimas arba jų transformavimas.

Pašalinus bent vieną regresorių, keičiasi visos p reikšmės.

Modelis tobulinamas, jeigu:

- *Deviacijos ir jos laisvės laipsnių skaičiaus santykis* labai skiriasi nuo 1. Dažniausiai tai reiškia arba netinkamus regresorius, arba kad priklausomas kintamasis visiškai nepanašus į neigiamą binominį kintamąjį (pavyzdžiui, jo dispersija mažesnė už vidurkį). Bandome keisti modelį.
- *Yra statistiškai nereikšmingas regresorius* (Voldo kriterijaus p reikšmė didesnė už 0,05). Regresorius pašalinamas iš modelio ir neigiama binominė regresinė analizė pakartojama be šio regresoriaus. Viskas gerai, jeigu deviacija, padalyta iš laisvės laipsnių skaičiaus, liko panaši į 1, o Akaikės informacinis indeksas AIC sumažėjo.
- *Per daug nulių*⁷³. Kintamojo Y grafike nulinio dažnis daug didesnis, nei turėtų įgyti neigiamai binominis atsitiktinis dydis. Kai kuriuose statistiniuose paketuose numatyta pataisyta neigiamai binominė regresinė analizė ir tokiai situacijai.

8.1.6. Pastabos apie modelio taikymą

- Neigiamas binominis skirstinys turi du parametrus $\alpha = \mu^2/(\sigma^2 - \mu)$ ir p . Parametras p yra tam tikra tikimybė ir visada įvertinamas panaudojus imties duomenis. Dažnai statistinėse programose, skirtose neigiamai binominei regresijai, tariama, kad parametras

⁷³ Angl. zero – inflated model.

$\alpha = 1$. Jeigu kintamasis turi neigiamai binominį skirstinį, α gali net labai skirtis nuo 1. Todėl vertėtų parametą α pasirinkti patiems arba įvertinti jį naudojantis duomenimis (abu atvejai aptariami kituose skyreliuose). Beje, Lagranžo daugiklių kriterijumi, kuris realizuotas SPSS, galima patikrinti, ar parametras α nuo pasirinkto skaičiaus skiriasi statistiškai reikšmingai.

- Dar kartą primename, kad nors stebime sveikuosius skaičius įgyjantį dydį, prognozuojame vidutinę reikšmę. Vidurkis visai neturi būti sveikasis skaičius.
- Reikia nepainioti tikėtinumų santykio kriterijaus statistikos su Pirsono statistika (abi jos įvardijamos kaip chi kvadrato statistikos). Pirsono statistika yra deviacijos analogas ir rodo geresnį modelio tikimą, kai jos ir laisvės laipsnių santykis artį 1. Tikėtinumų santykio kriterijus lygina tiriamą modelį su modeliu, neturinčiu jokių regresorių. Modelis geriau tinka duomenims, kai santykio statistika yra *didelė*.
- Nereikia suabsoliutinti deviacijos ir kitų charakteristikų vaidmens. Nesunku sukurti pavyzdį visai be regresorių, kai deviacija maža, o konstanta C statistiškai reikšminga. Modelis turi būti dar ir logiškas.

8.1.7. Standartiniai neigiamos binominės regresijos modelio aprašymai

Visada aprašomas galutinis, po visų tobulinimų gautas modelis. Pateiksime keletą galimų aprašymų fragmentų.

- *Pritaikytas neigiamos binominės regresijos modelis gerai tiko duomenims. Tikėtinumų santykio statistika $\chi^2=12,27$; o $p < 0,05$. Deviacijos ir laisvės laipsnių santykis 1,01. Visi modelio regresoriai statistiškai reikšmingi. Kintamojo Y vidurkio regresinis modelis atrodo taip: $\ln \hat{\mu} = -2 + 0,46X + 5Z$. Kai X padidėja 1, kintamojo prognozuojamas Y vidurkis padidėja 1,58 karto...*
- *Iš modelio buvo pašalintas statistiškai nereikšmingas regresorius X. Galutinis modelis buvo statistiškai reikšmingas, tikėtinumų santykio $\chi^2=10,02$; $p = 0,023$...*

8.2. Neigiama binominė regresinė analizė su SPSS

8.2.1. Duomenys

Kaip atlikti neigiamą binominę regresinę analizę, parodysime tirdami 2008 metų Europos Sąjungos socialinio tyrimo Švedijos duomenis **ESS4SE**. Tyrime naudosime tokius kintamuosius:

- *emplno* – turimų darbuotojų skaičius,
- *emplnof* – tėvo turimų darbuotojų skaičius (1 – neturi, 2 – turi 1–24 darbuotojus, 3 – turi 25 ir daugiau darbuotojų),
- *brwmny* – pasiskolinti pinigų išgyvenimui (1 – labai sunku, ..., 5 – labai lengva),
- *eduyrs* – metų, kiek buvo mokytasi, skaičius.


Modeliuosime *emplno* priklausomybę nuo *emplnof*, *brwmny*, *eduyrs*. Visų pirma įsitikiname, ar visi kintamieji turi pakankamai daug reikšmių. Atsižvelgdami į tai, kad modeliuosime *emplno*, dažnių lentelės tiriamo tik preliminariai **Select Cases** pasirinkę *emplno* ≥ 0 . Ši sąlyga užtikrina, kad gausime informaciją tik apie respondentus, atsakiusius į klausimą apie turimą darbuotojų skaičių. Renkamės **Analyze** → **Descriptive Statistics** → **Frequencies**. Į langą **Variable(s)** įkeliamo kintamuosius *emplno*, *emplnof*, *brwmny*, *eduyrs* ir spaudžiame **O.K.** Visi kintamieji turi pakankamai daug įvairių reikšmių, išskyrus kintamąjį *emplnof*. Yra tik vienas respondentas, kurio tėvo darbuotojų skaičius buvo ne mažesnis už 25.

emplnof Number of employees father had					
		Frequency	Percent	Valid Percent	Cumulative Percent
Valid	1 None	34	19.3	50.7	50.7
	2 1 to 24	32	18.2	47.8	98.5
	3 25 or more	1	.6	1.5	100.0
	Total	67	38.1	100.0	


Pakeisime kintamąjį *emplnof* nauju kintamuoju *emplnof2*, kuris įgis tik dvi reikšmes: 0 – kai respondento tėvas darbuotojų neturėjo ir 1 – kai respondento tėvas turėjo bent vieną darbuotoją. Renkamės **Transform** → **Recode into Different Variables**. Į langą perkeliame kintamąjį *emplnof*. Langelyje **Name** įrašome *emplnof2* ir spaudžiame **Change**. Paspaudę **Old and New Values** nurodome, kad 1 (**old value**) taps 0 (**new value**), o 2 ir 3 taps 1. Pasirenkame **Continue** ir **O.K.**

8.2.2. SPSS parinktys neigiamos binominės regresijos modeliui


Patikrinsime, kaip atrinktiesiems respondentams tinka neigiama binominė regresija. **Analyze** → **Generalized Linear Models** → **Generalized Linear Models**.




Atsidariusiame meniu spaudžiame **Type of Model**. Nors atsidariusiame meniu yra parinktis **Negative binomial with log link**, jos **nesirenkame** (viename iš skyrelių toliau pakomentuota kodėl). Pažymime **Custom**. Parinktyse **Distribution** pasirenkame **Negative binomial**, **Link function** – **Log**, **Parameter** – **Estimate value**.




Spaudžiame **Response** ir perkeliame *emplno* į laukelį **Dependent Variable**.




Paspaudę **Predictors** abudu kintamuosius *eduyrs* ir *brwmny* perkeliame į langelį **Covariates**. Kategorinį kintamąjį *emplnof2* keliame į **Factors**.



Pasirinkę **Model**, visus kintamuosius perkeliame į langą **Model**.



Pasirinkę **Statistics** papildomai pažymime **Include exponential parameter estimates**. Jau pažymėtus langelius paliekame ramybėje. Spaudžiame **OK**.



8.2.3. Rezultatų aptarimas

Rezultatų išsklotinė prasideda nuo informacijos apie kintamuosius. Matome, kad pusės respondentų tėvai darbuotojų neturėjo. Atkreipiame dėmesį, kad *emplno* standartinis nuokrypis (o juo labiau

dispersija) daug didesnis už vidurkį, todėl paprastas Puasono regresijos modelis šiems duomenims netiktų.

Categorical Variable Information

		N	Percent
Factor	emplnof2		
	.00	33	50.0%
	1.00	33	50.0%
	Total	66	100.0%

Continuous Variable Information

		N	Minimum	Maximum	Mean	Std. Deviation
Dependent Variable	emplno Number of employees respondent has/had	66	0	763	14.73	93.831
Covariate	eduys Years of full-time education completed	66	5	23	11.71	3.732
	brwmny Borrow money to make ends meet, difficult or easy	66	1	5	3.68	1.069

Lentelėje **Goodness of Fit** yra surašytos deviacijos reikšmė, Pirsono chi kvadrato statistikos reikšmė ir t. t. Deviacijos ir jos laisvės laipsnių santykis, kai neigiamos binominės regresijos modelis tinkamas, turi būti artimas vienetui. Matome, kad šis santykis yra 0,901. Pirsono chi kvadrato statistika, padalyta iš savo laisvės laipsnių skaičiaus, taip pat turi būti arti vieneto. Šis santykis (0,968) taip pat labai artimas vienetui. Gavome patvirtinimą, kad apskritai modelis tinka duomenims. Informacinių kriterijų reikšmės (AIC, BIC ir kt.) naudojamos keliems modeliams palyginti. Geresnis būtų tas modelis, kurio informacinių kriterijų reikšmės mažesnės.

Goodness of Fit^b

	Value	df	Value/df
Deviance	54.989	61	.901
Scaled Deviance	54.989	61	
Pearson Chi-Square	59.032	61	.968
Scaled Pearson Chi-Square	59.032	61	
Log Likelihood ^a	-133.952		
Akaike's Information Criterion (AIC)	277.905		
Finite Sample Corrected AIC (AICC)	278.905		
Bayesian Information Criterion (BIC)	288.853		
Consistent AIC (CAIC)	293.853		

Lentelėje **Omnibus Test** yra tikėtinumų santykio kriterijaus statistika ir jos p reikšmė. Gerai, kai $p < 0,05$, nes tada modelyje yra bent vienas reikalingas (statistiškai reikšmingas) regresorius. Kadangi $p = 0,000...$, galime teigti, kad neigiamos binominės regresijos modelio tinkamumą patvirtina ir tikėtinumų santykio kriterijus.

Lentelėje **Tests of Model Effects** yra informacija apie Voldo kriterijų. Regresoriai *emplnof2*, *eduyrs*, *brwmny* yra statistiškai reikšmingi (jų p reikšmės $< 0,05$). Konstantai p reikšmės nežiūrima, nes jos iš modelio nežadame šalinti. Taigi visi regresoriai yra statistiškai reikšmingi ir modelyje reikalingi.

Tests of Model Effects			
Source	Type III		
	Wald Chi-Square	df	Sig.
(Intercept)	.151	1	.698
emplnof2	6.298	1	.012
Eduyrs	4.959	1	.026
Brwmny	7.399	1	.007

Omnibus Test ^a		
Likelihood Ratio Chi-Square	df	Sig.
23.777	3	.000

Lentelėje **Parameter Estimates** pasikartoja informacija apie Voldo kriterijų. Taip pat surašyti parametrų įverčiai. Parametrų įverčių ženklai ir **Exp(B)** suteikia informacijos, kaip keisis vidutinis darbuotojų skaičius *emplno* keičiantis regresoriams *emplnof2*, *eduyrs*, *brwmny*.

Parameter Estimates										
Parameter	B	Std. Error	95 % Wald Confidence Interval		Hypothesis Test			Exp(B)	95 % Wald Confidence Interval for Exp(B)	
			Lower	Upper	Wald Chi-Square	df	Sig.		Lower	Upper
(Intercept)	1.590	2.1316	-2.588	5.768	.556	1	.456	4.904	.075	319.831
[emplnof2=.00]	-1.629	.6493	-2.902	-.357	6.298	1	.012	.196	.055	.700
[emplnof2=1.00]	0 ^a	.	.	.	.	.	.	1	.	.
Eduyrs	.286	.1286	.034	.539	4.959	1	.026	1.332	1.035	1.714
Brwmny	-.753	.2768	-1.295	-.210	7.399	1	.007	.471	.274	.810
(Scale)	1 ^b									
(Negative binomial)	5.327	1.2084	3.415	8.310						

Regresoriaus *eduyrs* koeficiento įvertis $0,286 > 0$. Vadinasi, didėjant atsakinėjusio respondento išsilavinimui, prognozuojamas vidutinis turimų darbuotojų skaičius didėja. Stulpelyje **Exp(B)** užrašyta reikšmė 1,332 rodo, kad vieneri papildomi metai, kai respondentas mokėsi, padidina tikėtiną turimų darbuotojų skaičių 1,332 **karto**. Stulpeliuose **Lower** ir **Upper** nurodyti paties koeficiento ir **Exp(B)** pasikliautiniųjų intervalų rėžiai. Analogiškai galima interpretuoti regresoriaus *brwmny* įtaką. Lentelėje yra dvi konstantų reikšmės abiem *emplnof2* reikšmėms. Matome, kai tėvas neturi darbuotojų, tai turi neigiamą įtaką vidutiniam respondento darbuotojų skaičiui, nes modelio konstanta sumažėja per -1.629.

Matematinis modelio užrašas atrodo taip:

$$\ln \hat{\mu} = 1,590 + 0,286 \text{ eduyrs} - 0,753 \text{ brwmny} + \begin{cases} 0, & \text{jei } \text{emplnof2} = 1, \\ -1,629, & \text{jei } \text{emplnof2} = 0. \end{cases}$$

Čia $\hat{\mu}$ – prognozuojamas vidutinis respondento turimų darbuotojų skaičius. Parodysime, kaip šį modelį taikyti konkrečioms prognozėms. Tarkime, kad respondentas mokėsi 10 metų, mano, kad pasiskolinti pinigų labai lengva (*brwmny* = 5), o jo tėvas darbuotojų neturėjo (*emplnof2* = 0). Kiek vidutiniškai tokie respondentai turi darbuotojų? Įstatę regresorių reikšmes į prieš tai pateiktą lygtį gauname

$$\ln \hat{\mu} = 1,590 + 0,286 \cdot 10 - 0,753 \cdot 5 - 1,629 = -0,944.$$

Pačią narių skaičiaus prognozę gauname, pakėlę gautuoju skaičiumi $e = 2,718....$ Todėl

$$\hat{\mu} = e^{-0,944} = 0,389.$$

Darome prognozę, kad menkai išsilavinę optimistai, kurių tėvai darbuotojų neturėjo, ir patys nelabai jų turės (vidutiniškai 0,389 darbuotojo).

8.2.4. Modelio tobulinimas

Iš esmės beveik visi modelio rodikliai yra geri. Vis dėlto kintamojo *emplnof2* koeficiento 95 % pasikliautinis intervalas [0,055; 0,700] yra pakankamai didelis. Jį galima interpretuoti taip: tikėtina, kad respondentų, kurių tėvai neturėjo darbuotojų, vidutinis turimas darbuotojų skaičius sudarys nuo 5 iki 70 procentų darbuotojų skaičiaus tų respondentų, kurių tėvai taip pat turėjo darbuotojų. Toks didelis procentinis intervalas kelia minčių, kad *galbūt* modelį reikėtų patobulinti. Jeigu tirsime tuos pačius respondentus (atsakiusius į klausimą apie tėvo samdomų darbuotojų skaičių), modelis be regresoriaus *emplnof2* taip pat atrodo neblogesnis (ar geresnis – galima pasiginčyti). Kurį modelį rinktis šiuo atveju, turi spręsti tyrėjas.

Goodness of Fit^b

	Value	f	Value/df
Deviance	54.447	2	.878
Scaled Deviance	54.447	2	
Pearson Chi-Square	65.049	2	1.049
Scaled Pearson Chi-Square	65.049	2	
Log Likelihood ^a	-136.542		
Akaike's Information Criterion (AIC)	281.085		
Finite Sample Corrected AIC (AICC)	281.740		
Bayesian Information Criterion (BIC)	289.843		
Consistent AIC (CAIC)	293.843		

Omnibus Test^a

Likelihood Ratio Chi-Square	df	Sig.
18.597	2	.000

Tests of Model Effects

Source	Type III		
	Wald Chi-Square	df	Sig.
(Intercept)	.319	1	.572
eduyrs	10.501	1	.001
brwmny	4.730	1	.030

Parameter Estimates

Parameter	B	Std. Error	95 % Wald Confidence Interval		Hypothesis Test			Exp(B)	95 % Wald Confidence Interval for Exp(B)	
			Lower	Upper	Wald Chi-Square	df	Sig.		Lower	Upper
(Intercept)	-1.223	2.1655	-5.467	3.021	.319	1	.572	.294	.004	20.522
eduyrs	.436	.1345	.172	.699	10.501	1	.001	1.546	1.188	2.013
brwmny	1 ^a -6.619	.2845	-1.176	-.061	4.730	1	.030	.539	.308	.941
(Scale)										
(Negative binomial)	6.091	1.3389	3.959	9.371						

8.2.5. Rezultatų aprašymas

Pirmiausia aprašome, ką tyrėme, kokius naudojome kintamuosius ir kaip juos perkodavome. Tada kompaktiškai surašome visa tai, ką išsamiai aptarėme ankstesniame skyrelyje. Pateikiame vieną iš daugybės galimų tokio aprašymo variantų modeliui su kategoriniu regresoriumi.

Neigiamos binominės regresijos modelis gerai tiko duomenims, tikėtinumų santykio statistika $\chi^2=23,777$, o $p < 0,01$. Deviacijos ir jos laisvės laipsnių santykis yra 0,901. Voldo kriterijus parodė, kad visi modelio regresoriai, išskyrus konstantą, yra statistiškai reikšmingi. Modelio matematinė išraiška

$$\ln \hat{\mu} = 1,590 + 0,286 \text{ eduyrs} - 0,753 \text{ brwmny} + \begin{cases} 0, & \text{jei emplnof2} = 1, \\ -1,629, & \text{jei emplnof2} = 0. \end{cases}$$

rodo, kad prognozuojamas vidutinis turimų darbuotojų skaičius didėja, didėjant respondento išsilavinimui ir esant didesniai pesimizmui, vertinant paskolos galimybes. Didesnį darbuotojų skaičių turi tie respondentai, kurių tėvai taip pat turėjo darbuotojų. Koeficientų eksponenčių analizė parodė, kad vieneriais metais padidėjus respondento metų, kiek jis mokėsi, skaičiui, vidutinis darbuotojų skaičius padidėja 1,332 karto (95 % pasikliautinis intervalas [1,035; 1,714]). Vienu balu didesnis optimizmas, vertinant paskolos galimybes, sumažina galimą respondento turimų darbuotojų skaičių 0,471 karto (95 % pasikliautinis intervalas [0,274; 0,810]). Respondentai, kurių tėvai neturėjo darbuotojų, vidutiniškai turės 0,196 karto mažiau darbuotojų nei tie respondentai, kurių tėvai darbuotojų turėjo. Taigi beveik penkis kartus mažiau. Vis dėlto šio rodiklio 95 % pasikliautinis intervalas [0,055; 0,700] yra pakankamai didelis. Todėl būtų teisingiau konstatuoti, kad tikėtina, jog tokių respondentų turimas darbuotojų skaičius sudarys nuo 5 iki 70 procentų darbuotojų skaičiaus tų respondentų, kurių tėvai taip pat turėjo darbuotojų.

8.2.6. SPSS komandų sintaksė

Surašysime, kaip atrodo SPSS komandos nagrinėtajam regresijos pavyzdžiui. Kintamojo *emplnof2* sukūrimas:

```
RECODE emplnof (1=0) (2 thru 3=1) INTO emplnof2.  
EXECUTE.
```


Neigiamos binominės regresijos sintaksė:

```
GENLIN emplno BY emplnof2 (ORDER=ASCENDING) WITH eduyrs
```

```
brwmny
  /MODEL emplnof2 eduyrs brwmny INTERCEPT=YES
  DISTRIBUTION=NEGBIN(MLE) LINK=LOG
  /CRITERIA METHOD=FISHER(1) SCALE=1 COVB=MODEL
  MAXITERATIONS=100 MAXSTEPHALVING=5
  PCONVERGE=1E-006(ABSOLUTE) SINGULAR=1E-012
  ANALYSISTYPE=3(WALD) CILEVEL=95 CITYPE=WALD
  LIKELIHOOD=FULL
  /MISSING CLASSMISSING=EXCLUDE
  /PRINT CPS DESCRIPTIVES MODELINFO
  FIT SUMMARY SOLUTION (EXPONENTIATED).
```

8.2.7. Neigiama binominė regresinė analizė dažniui

Pateiksime teorinį pavyzdį, parodantį, kas tada keisis tyrime. Tarkime, kad turime informacijos apie respondento patirtų epilepsijos priepuolių skaičių (*epnumb*). Kiekvienas respondentas stebėtas skirtingą laiko tarpą (kintamasis *time*). Aišku, kad šiuo atveju natūraliau modeliuoti priepuolių dažnumą, o ne patį jų skaičių. Komanda **Compute Variable** sukuriame kintamąjį *lotime* lygų *time* logaritmui. Paskui renkamės visas tas pačias parinktis kaip ir standartinėje neigiamoje binominėje regresijoje, tik tai **Predictors** lange į lauką **Offset Variable** įkeliamo *logtime*.



Visi rezultatai interpretuojami kaip ir ankstesniu atveju. Tik tai dabar modelis sudarytas dažnio *epnumb/time* logaritmui, o ne kintamojo *epnumb* logaritmui.

8.2.8. Neigiamos binominės regresinės analizės standartinė opcija SPSS

SPSS parinkčių lange **Type of Model** nurodyta neigiama binominė regresija **Negative binomial with log link**:

Type of Model Response Predictors Model

Choose one of the model types listed below or select a model from the list on the right.

Scale Response

☐ Linear

☐ Gamma with log link

Counts

☐ Poisson loglinear

☒ Negative binomial with log link

Kuo ši parinktis skiriasi nuo pirmiau naudotos? Neigiamas binominis skirstinys turi du parametrus. Juos ir išnaudojome pasistengdami, kad modelio vidurkis ir dispersija sutaptų su modeliuojamojo *emplno* imties vidurkiu ir dispersija. O **Negative binomial with log link** parinktis numato, kad vienas iš skirstinio savybes lemiančių parametrų bus lygus vienetui. Todėl negalima tikėtis, kad modelio dispersija sutaps su *emplno* dispersija. Padarinys – blogas modelio tikimas. Iš tikrųjų, pritaikę nagrinėjamam modeliui **Negative binomial with log link** parinktį, gauname, kad deviacijos ir laisvės laipsnių santykis yra beveik trys (2,980), o Pirsono chi kvadrato statistikos ir laisvės laipsnių santykis yra keturi. Tai rodo labai blogą modelio tikimą duomenims.

Goodness of Fit ^b			
	Value	df	Value/df
Deviance	184.745	62	2.980
Scaled Deviance	184.745	62	
Pearson Chi-Square	248.708	62	4.011

8.3. Neigiama binominė regresinė analizė su STATA

8.3.1. Duomenys

Atliksime tą pačią analizę kaip ir su SPSS programa. Tiriame Švedijos duomenis **ESS4SE**. Modeliuosime *emplno* (turimų darbuotojų skaičius) priklausomybę nuo regresorių

- *brwmny* (ar sunku pasiskolinti pinigų išgyvenimui, 1 – labai sunku, ..., 5 – labai lengva),
- *eduyrs* (prasimokytų metų skaičius),
- *emplnof2* (tėvo turimų darbuotojų skaičius, 0 – neturi, 1 – turi).

SPSS duomenis išsaugojome *dta* formatu. Atidarius failą su STATA dar reikia užtikrinti, kad kodai, kurie SPSS žymėjo praleistas reikšmes, nebūtų traktuojami kaip regresorių reikšmės. Todėl įvykdėme:

```
keep if emplno < 900 & emplnof < 4 & eduyrs < 88 & brwmny < 8
```

Kintamasis *emplnof2* gautas tinkamai perkodavus *emplnof* (recode *emplnof* (1 = 0) (2/3 = 1), gen(*emplnof2*)). Pirmiausia įsitikiname, kad kintamojo *emplno* dispersija daug didesnė už vidurkį. Įvykdome:

```
summarize emplno, detail
```

50%	0		Mean	14.72727
		Largest	Std. Dev.	93.83071
75%	2	24		
90%	15	30	Variance	8804.201
95%	24	42	Skewness	7.859733
99%	763	763	Kurtosis	63.18019

Dispersija yra 8804, o vidurkis tik 14,727. Šiuo atveju Puasono regresija visiškai netinka, o neigiama binominė regresija gali ir tikti.

8.3.2. Modelio parametrų analizė

Regresorius *emplnof2* yra kategorinis. Tą pažymime komandą pradėdami *xi*: komandos pirmiausia ir *i*. prie kategorinio kintamojo:

```
xi: nbreg emplno brwmny eduyrs i.emplnof2
```

Negative binomial regression				Number of obs	=	66
Dispersion = mean				LR chi2(3)	=	23.78
Log likelihood = -133.95237				Prob > chi2	=	0.0000
				Pseudo R2	=	0.0815

emplno	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
brwmny	-.752886	.2767894	-2.72	0.007	-1.295383	-.2103887
eduyrs	.2864844	.1286464	2.23	0.026	.0343422	.5386267
_temp1nof2_1	1.629398	.6492644	2.51	0.012	.3568631	2.901933
_cons	-.0394117	1.910606	-0.02	0.984	-3.784131	3.705307
/lnalpha	1.67284	.2268809			1.228161	2.117518
alpha	5.327274	1.208657			3.414944	8.310486

Likelihood-ratio test of alpha=0: chibar2(01) = 2444.86 Prob>=chibar2 = 0.000

Lentelės viršuje dešinėje yra tikėtinumų santykio kriterijaus statistika ir jos p reikšmė. Kadangi $p = 0,000 < 0,05$, galime teigti, kad tikėtinumų santykio kriterijus patvirtina neigiamos binominės regresijos modelio tinkamumą. Makfadeno pseudo $R^2 = 0,08$ yra mažas ($< 0,20$), bet neigiamai binominei regresijai tai nėra svarbus rodiklis. Aprašant modelio rezultatus, apie R^2 dažniausiai net neužsimenama.

Po lentelė yra informacija apie vieną neigiamos binominės regresijos modelio parametą. Kai šis parametras lygus nuliui, neigiama binominė regresija virsta Puasono regresija. STATA programoje jis žymimas α . Matome, kad $\alpha = 5,327$ ir nuo nulio skiriasi statistiškai reikšmingai (Prob $\geq$ chibar2 yra tikėtinumų santykio testo p reikšmė. Ji lygi $0,000... < 0,05$). Gavome statistiškai reikšmingą patvirtinimą, kad Puasono regresija nagrinėjamam pavyzdžiui netinka.

Pačioje lentelėje pateikta informacija apie Voldo kriterijų. Regresoriai *emplnof2*, *eduyrs*, *brwmny* yra statistiškai reikšmingi (jų p reikšmės $< 0,05$). Konstantai p reikšmės nežiūrimė, nes jos iš modelio nežadame šalinti. Taigi visi regresoriai yra statistiškai reikšmingi ir modelyje reikalingi. Užrašas *_Iemplnof2_1* atitinka kategoriją *emplnof2=1*. Todėl modelį galima užrašyti taip:

$$\text{Vidutinis darbuotojų skaičius} = \exp\{-0,04 - 0,75 \text{ brwmny} + 0,29 \text{ eduyrs} + 1,63 \text{ emplnof2}\}.$$

Regresorių koeficientų įverčių ženklai atitinka logiką: neigiamas *brwmny* koeficientas reiškia, kad respondentas, labiau įsitikinęs lengvai gausiąs paskolą, turi mažiau darbuotojų. Analogiškai darome išvadą, kad daugiau metų prasimokę respondentai turi ir daugiau darbuotojų. Daugiau darbuotojų turi ir žmonės, kurių tėvai jų taip pat turi. Norėdami skaitiškai įvertinti regresorių įtaką, įvykdome:

```
listcoef, help
```

emplno	b	z	P> z	e^b	e^bStdX	SDofX
brwmny	-0.75289	-2.720	0.007	0.4710	0.4471	1.0693
eduyrs	0.28648	2.227	0.026	1.3317	2.9133	3.7325
_Iemplnof2_1	1.62940	2.510	0.012	5.1008	2.2726	0.5038
ln alpha	1.67284					
alpha	5.32727	SE(alpha) = 1.20866				
LR test of alpha=0: 2444.86 Prob>=LRX2 = 0.000						
b = raw coefficient						
z = z-score for test of b=0						
P> z = p-value for z-test						
e^b = exp(b) = factor change in expected count for unit increase in x						
e^bStdX = exp(b*SD of x) = change in expected count for SD increase in x						
SDofX = standard deviation of x						

Lentelėje pakartoti koeficientų įverčiai ir jų eksponentės, t. y. daugikliai, rodantys, kiek kartų padidės (sumažės) modeliuojamo kintamojo vidurkis, regresoriui padidėjus vienetu. Pavyzdžiui, matome, kad respondentai, kurių tėvai turi samdomų darbuotojų, vidutiniškai ir patys jų turi 5,1 karto daugiau, palyginti su respondентаis, kurių tėvai neturi samdomų darbuotojų. Norėdami gauti analogišką informaciją, surašytą procentais, įvykdome:

```
listcoef, help percent
```

emplno	b	z	P> z	%	%StdX	SDofX
brwmny	-0.75289	-2.720	0.007	-52.9	-55.3	1.0693
eduyrs	0.28648	2.227	0.026	33.2	191.3	3.7325
_Iemplnof2_1	1.62940	2.510	0.012	410.1	127.3	0.5038
ln alpha	1.67284	SE(alpha) = 1.20866				
alpha	5.32727					
LR test of alpha=0: 2444.86 Prob>=LRX2 = 0.000						

Iš tikrųjų, jeigu tėvo turimi samdomi darbuotojai padidina galimą vidutinį respondento darbuotojų skaičių 5,1 karto, darbuotojų skaičius padidėja 410 procentų. Tai ir užfiksuota gautojoje lentelėje.

Nors ir visi regresoriai statistiškai reikšmingi, ir modelio tikėtinumų kriterijaus p reikšmė labai maža, dar reiktų pažvelgti į modelio deviaciją. Ją gausime paeiliui įvykdę:

```
local v = e(alpha)
xi: glm emplno brwmny eduyrs i.emplnof2, family(nb `v') nolog
```

```
. xi: glm emplno brwmny eduyrs i.emplnof2, family(nb `v') nolog
i.emplnof2      _Iemplnof2_0-1      (naturally coded; _Iemplnof2_0 omitted)

Generalized linear models              No. of obs      =       66
Optimization      : ML                  Residual df    =       62
                                      Scale parameter =       1
Deviance          =  54.98876078        (1/df) Deviance =  .8869155
Pearson           =  59.03185108        (1/df) Pearson =  .9521266

Variance function: V(u) = u+(5.327273896968735)u^2 [Neg. Binomial]
Link function     : g(u) = ln(u)              [Log]

Log likelihood    = -133.9523705              AIC          =  4.180375
                                      BIC          = -204.7698
```

Ieškomoji modelio deviacija yra 54,988. Deviacija padalyta iš laisvės laipsnių skaičiaus, yra 0,887. Nėra taip toli nuo vieneto. Dar arčiau vieneto yra liekamųjų paklaidų Pirsono chi kvadrato ir laisvės laipsnių santykis 0,952. Darome išvadą, kad neigiamos binominės regresijos modelis duomenims gerai tinka.

Pastaba. Kadangi kintamasis *emplnof2* įgyja tik dvi reikšmes (0 ir 1), jį buvo galima įtraukti nenurodant, kad jis kategorinis. Pvz., vykdyti komandą *nbreg emplno brwmny eduyrs emplnof2*. Rezultatai nesikeičia.

8.4. Neigiama binominė regresinė analizė su SAS

8.4.1. Duomenys

Atliksime tą pačią analizę kaip ir su SPSS programa. Tiriame Švedijos duomenis **ESS4SE**. Modeliuosime *emplno* (turimų darbuotojų skaičius) priklausomybę nuo regresorių

- *brwmny* (ar sunku pasiskolinti pinigų išgyvenimui, 1 – labai sunku, ..., 5 – labai lengva),
- *eduyrs* (metų, kiek mokytasi, skaičius),
- *emplnof2* (tėvo turimų darbuotojų skaičius, 0 – neturi, 1 – turi).

SPSS formatu paruošti duomenys importuoti į SAS rgr biblioteką. Atidarius failą su SAS dar reikia užtikrinti, kad kodai, kurie SPSS žymėjo praleistas reikšmes, nebūtų traktuojami kaip regresorių reikšmės. Be to, kintamąjį *emplnof* perkoduojame į dvireikšmį kintamąjį *emplnof2* (naudojamą tolesnėje analizėje). Todėl įvykdėme:

```
OPTIONS nofmterr;
data Dse;
set rgr.ESS4SE;
if (emplno LT 900) AND (emplnof LT 4) AND (eduyrs LT 88) AND (brwmny LT 8) AND
(emplno ne .) AND (emplnof ne .) AND (eduyrs ne .) AND (brwmny ne .);
emplnof2=.;
IF (emplnof=1) THEN emplnof2 = 0;
ELSE IF ((emplnof=2) OR (emplnof=3)) THEN emplnof2 = 1;
keep emplno emplnof emplnof2 eduyrs brwmny;
run;
```

Pirmiausia įsitikiname, kad kintamojo *emplno* dispersija daug didesnė už vidurkį. Įvykdome:

```
proc univariate;
var emplno;
run;
```

Dispersija lygi 8804, o vidurkis tik 14,727. Šiuo atveju Puasono regresija visiškai netinka, o neigiama binominė regresija gali ir tikti.

8.4.2. Modelio parametrų analizė

Regresorius *emplnof2* yra kategorinis, bet įgyja tik dvi reikšmes (0 ir 1). Jeigu regresorius įgyja tik 0 arba 1, jį galima įtraukti į modelį be jokių pakeitimų. SAS programoje kategorinis regresorius perkoduojamas automatiškai, nurodžius jį *class* sakinyje (pseudokintamųjų skaičius lygus kategorijų skaičiui minus 1). Neigiama binominė regresija atliekama, įvykdant :

```
proc genmod data = dse;
class emplnof2 (ref="0");
model emplno=brwmny eduyrs emplnof2 / link=log dist=negbin;
store p1;
run;
```

Criteria For Assessing Goodness Of Fit			
Criterion	DF	Value	Value/DF
Deviance	62	54.9888	0.8869
Scaled Deviance	62	54.9888	0.8869
Pearson Chi-Square	62	59.0319	0.9521
Scaled Pearson X2	62	59.0319	0.9521
Log Likelihood		4567.1320	
Full Log Likelihood		-133.9524	
AIC (smaller is better)		277.9047	
AICC (smaller is better)		278.9047	
BIC (smaller is better)		288.8530	

Analysis Of Maximum Likelihood Parameter Estimates								
Parameter		DF	Estimate	Standard Error	Wald 95% Confidence Limits		Wald Chi-Square	Pr > ChiSq
Intercept		1	-0.0394	1.9106	-3.7841	3.7053	0.00	0.9835
brwmny		1	-0.7529	0.2768	-1.2954	-0.2104	7.40	0.0065
eduyrs		1	0.2865	0.1286	0.0343	0.5386	4.96	0.0260
emplnof2	1	1	1.6294	0.6493	0.3569	2.9019	6.30	0.0121
emplnof2	0	0	0.0000	0.0000	0.0000	0.0000	.	.
Dispersion		1	5.3273	1.2087	3.4149	8.3105		

Note: The negative binomial dispersion parameter was estimated by maximum likelihood.

Pastaba. Procedūroje sakiny *store p1* yra tam, kad galėtume sudarytą modelį vėliau panaudoti skaitiškai įvertinant regresorių įtaką.

Lentelėje **Criteria For Assessing Goodness Of Fit** pateikiami modelio suderinamumo indeksai. Modelio deviacija yra 54,988. Deviacija, padalyta iš laisvės laipsnių skaičiaus, yra 0,887. Netoli nuo vieneto. Dar arčiau vieneto yra liekamųjų paklaidų Pirsono chi kvadrato statistikos ir jos laisvės laipsnių santykis 0,952. Darome išvadą, kad neigiamos binominės regresijos modelis duomenims gerai tinka.

Lentelės **Analysis of Maximum Likelihood Parameter Estimates** paskutinėje eilutėje yra informacijos apie vieną neigiamos binominės regresijos modelio parametą (SPSS ir STATA jis žymimas **alpha**, R programoje **Theta**). Kai šis parametras lygus nuliui, neigiama binominė regresija virsta Puasono regresija. SAS programoje jis žymimas *dispersion*. Matome, kad *dispersion* = 5,327 ir 95 % pasikliautinis intervalas [3,4149; 8,3105] rodo, kad parametras nuo nulio skiriasi statistiškai reikšmingai. Gavome statistiškai reikšmingą patvirtinimą, kad Puasono regresija nagrinėjamam pavyzdžiui netinka.

Lentelėje **Analysis of Maximum Likelihood Parameter Estimates** taip pat pateikti regresijos parametų įverčiai ir informacija apie Voldo kriterijaus taikymo rezultatus. Regresoriai *emplnof2*, *eduyrs*, *brwmny* yra statistiškai reikšmingi (jų *p* reikšmės < 0,05). Konstantai *p* reikšmės nežiūrime, nes jos iš modelio nežadame šalinti. Taigi visi regresoriai yra statistiškai reikšmingi ir modelyje reikalingi. Modelį galima užrašyti taip:

$$\text{Vidutinis darbuotojų skaičius} = \exp\{-0,04 - 0,75 \text{ brwmny} + 0,29 \text{ eduyrs} + 1,63 \text{ emplnof2}\}.$$

Regresorių koeficientų įverčių ženklai atitinka logiką: neigiamas *brwmny* koeficientas reiškia, kad respondentas, labiau įsitikinęs lengvai gausiąs paskolą, turi mažiau darbuotojų. Analogiškai darome išvadą, kad daugiau metų mokėsi respondentai turi ir daugiau darbuotojų. Daugiau darbuotojų turi ir žmonės, kurių tėvai jų taip pat turi. Norėdami skaitiškai įvertinti regresorių įtaką, įvykdome:

```
ods output ParameterEstimates = est;
proc plm source = p1;
  show parameters;
run;
data est_exp;
  set est;
  expb = exp(estimate);
  if parameter ^= "Intercept";
run;
proc print data = est_exp;
run;
```

Obs	Parameter	emplnof2	Estimate	StdErr	expb
1	Borrow money to make ends meet, difficult or easy	—	-0.7529	0.2768	0.47101
2	Years of full-time education completed	—	0.2865	0.1286	1.33174
3	emplnof2 1	1	1.6294	0.6493	5.10080
4	emplnof2 0	0	0	.	1.00000

Lentelėje pakartoti koeficientų įverčiai ir jų eksponentės (atitinkamai stulpeliai **Estimate** ir **expb**), t. y. daugikliai, rodantys, kiek kartų padidės (sumažės) modeliuojamo kintamojo vidurkis, regresoriui padidėjus vienetu. Pavyzdžiui, matome, kad respondentai, kurių tėvai turi samdomų darbuotojų, vidutiniškai ir patys jų turi 5,1 karto daugiau, palyginti su respondентаis, kurių tėvai neturi samdomų darbuotojų.

8.4.3. Prognozavimas

Prognozavimas niekuo nesiskiria nuo Puasono regresijos atvejo. Parodysime, kaip atlikti vidutinio darbuotojų skaičiaus prognozę respondentui, prasimokusiam 15 metų ir manančiam, kad pinigų

pasiskolinti labai sunku. Be to žinome, kad jo tėvas turi samdomų darbuotojų. Tam pirmiausia duomenų aibę papildome nauju įrašu su atitinkamomis nurodytų regresorių reikšmėmis (kitų kintamųjų reikšmės automatiškai generuojamos kaip praleistos). Įvykdome :

```
data new;  
set dse end=eof;  
output;  
if eof then do;  
Call missing( of _all_ );  
eduyrs=15;  
brwmny = 1;  
emplnof2 = 1;  
output;  
end ;  
run;
```

Tada atliekame neigiamą binominę regresiją, išsaugome duomenis ir prognozuojamas reikšmes ir išspausdiname prognozes TIK naujiems įrašams:

```
proc genmod data = new;  
class emplnof2 (ref="0");  
model emplno=brwmny eduyrs emplnof2 / link=log dist=negbin;  
output out=mmm predicted=pre;  
run;  
proc sql;  
select pre from mmm where eduyrs=15 and brwmny = 1 and emplnof2 = 1;  
run;
```

Predicted Value
169.7567

Gavome, kad tokie respondentai vidutiniškai turėtų 169,75 darbuotojus. Analogiškai galime prognozuoti atsižvelgdami į tėvo darbuotojus: respondentai, kurių tėvai neturi samdomų darbuotojų.

Papildę duomenų aibę dviem įrašais (eduyrs = 15, brwmny = 1, emplnof2 = 0) ir (eduyrs = 15, brwmny = 1, emplnof2 = 1) galime gauti iškart dvi prognozes. Įvykdome:

```
data new;
set dse end=eof;
output;
if eof then do;
Call missing( of _all_ );
eduyrs=15;
brwmny = 1;
emplnof2 = 1;
output;
eduyrs=15;
brwmny = 1;
emplnof2 = 0;
output;
end ;
run;

proc genmod data = new;
class emplnof2 (ref="0");
model emplno=brwmny eduyrs emplnof2 / link=log dist=negbin;
output out=mmm predicted=pre;
run;

proc sql;
select emplnof2,pre from mmm where eduyrs=15 and brwmny = 1 and (emplnof2 = 1 or
emplnof2 = 0);
run;
```

emplnof2	Predicted Value
1	169.7567
0	33.2804

Matome, kad respondentai, kurių tėvai samdomų darbuotojų neturi, vidutiniškai turi 33,28 darbuotojus.

8.4.4. SAS programos neigiamos binominės regresijos procedūra

Taikant SAS programą neigiamai binominei regresinei analizei, kaip ir Puasono regresinei analizei, yra naudojama **proc genmod** procedūra. Šios procedūros sintaksė atrodo taip:

```
PROC GENMOD <options> ;
ASSESS | ASSESSMENT VAR=(effect) | LINK </ options> ;
BAYES <options> ;
BY variables ;
CLASS variable <(options)><variable <(options)>> </ options> ;
CONTRAST 'label' contrast-specification </ options> ;
DEVIANCE variable = expression ;
EFFECTPLOT <plot-type <(plot-definition-options)>> </ options> ;
ESTIMATE 'label' effect values <,...effect values> </ options> ;
EXACT <'label'> <INTERCEPT> <effects> </ options> ;
EXACTOPTIONS options ;
FREQ | FREQUENCY variable ;
FWDLINK variable = expression ;
INVLINK variable = expression ;
LSMEANS <model-effects> </ options> ;
LSMESTIMATE model-effect <'label'> values <divisor=> <, ...<'label'> values <divisor=>>
< / options> ;
MODEL response = <effects > </ options> ;
OUTPUT <OUT=SAS-data-set> <keyword=name...keyword=name> ;
Programming statements ;
REPEATED SUBJECT=subject-effect </ options> ;
SLICE model-effect </ options> ;
STORE <OUT=>item-store-name </ LABEL='label'> ;
STRATA variable <(option)> <variable <(option)>> </ options> ;
WEIGHT | SCWGT variable ;
VARIANCE variable = expression ;
ZEROMODEL <effects > </ options> ;
```

Rgresijos tipas priklauso nuo **dist** parinkties **model** sakinyje. Atlikdami Puasono regresinę analizę nurodome **dist=poisson** (atitinkamai neigiamai binominei regresijai **dist=negbin**).

Scenarijus :

```
OPTIONS nofmterr;
data Dse;
set rgr.ESS4SE;
if (emplno LT 900) AND (emplnof LT 4) AND (eduyrs LT 88) AND (brwmny LT 8)
AND (emplno ne .) AND (emplnof ne .) AND (eduyrs ne .) AND (brwmny ne .);
emplnof2=.;
IF (emplnof=1) THEN emplnof2 = 0;
ELSE IF ((emplnof=2) OR (emplnof=3)) THEN emplnof2 = 1;
keep emplno emplnof emplnof2 eduyrs brwmny;
run;
/* kintamojo emplno vidurkis, dispersija */
proc univariate;
var emplno;
run;
/* Modelis */
proc genmod data = dse;
class emplnof2 (ref="0");
model emplno=brwmny eduyrs emplnof2 / link=log dist=negbin;
store p1;
run;
/* exp koeficientų skaičiavimas */
ods output ParameterEstimates = est;
proc plm source = p1;
show parameters;
run;
data est_exp;
set est;
expb = exp(estimate);
if parameter ^= "Intercept";
```

```

run;
proc print data = est_exp;
run;
ods pdf close;
/* prognozavimas */
data new;
set dse end=eof;
output;
if eof then do;
Call missing( of _all_ );
eduyrs=15;brwmny = 1; emplnof2 = 1;
output;
end ;
run;
proc genmod data = new;
class emplnof2 (ref="0");
model emplno=brwmny eduyrs emplnof2 / link=log dist=negbin;
output out=mmm predicted=pre;
run;
proc sql;
select pre from mmm where eduyrs=15 and brwmny = 1 and emplnof2 = 1;
run;
/* dviems irasams */
data new;
set dse end=eof;
output;
if eof then do;
Call missing( of _all_ );
eduyrs=15;brwmny = 1; emplnof2 = 1;
output;
eduyrs=15;brwmny = 1; emplnof2 = 0;
output;
end ;

```

```

run;
proc genmod data = new;
  class emplnof2 (ref="0");
  model emplno=brwmny eduyrs emplnof2 / link=log dist=negbin;
  output out=mmm predicted=pre;
run;
proc sql;
  select emplnof2,pre from mmm where eduyrs=15 and brwmny = 1 and (emplnof2 = 1 or
  emplnof2 = 0);
run;

```

8.5. Neigiama binominė regresinė analizė su R

8.5.1. Duomenys

Atliksime tą pačią analizę kaip ir su SPSS programa. Tiriamie Švedijos duomenis **ESS4SE**. Modeliuosime *emplno* (turimų darbuotojų skaičius) priklausomybę nuo regresorių

- *brwmny* (ar sunku pasiskolinti pinigų išgyvenimui, 1 – labai sunku, ..., 5 – labai lengva),
- *eduyrs* (metų, kiek buvo mokytasi, skaičius),
- *emplnof2* (tėvo turimų darbuotojų skaičius, 0 – neturi, 1 – turi).

SPSS duomenis išsaugome csv formatu. Atidarius failą su R dar reikia užtikrinti, kad kodai, kurie SPSS žymėjo praleistas reikšmes, nebūtų traktuojami kaip regresorių reikšmės. Todėl įvykdėme:

```

dta<-read.csv2("ESS4SE.csv",na.strings = "NA",stringsAsFactors=FALSE)

library(car)

dta$emplnof2 <- recode(dta$emplnof,"1=0;c(2,3)=1")

ldta<-subset(dta,emplno<900 & emplnof<4 & eduyrs<88 & brwmny<8,
select=c(emplno,brwmny,eduyrs,emplnof2,gndr))

```

Kintamasis *emplnof2* gautas tinkamai perkodavus *emplnof*. Pirmiausia įsitikiname, kad kintamojo *emplno* dispersija daug didesnė už vidurkį. Įvykdome:

```
mean(ldta$emplno,na.rm=T)
```

```
var(ldta$emplno,na.rm=T)
```

```
> mean(ldta$emplno,na.rm=T)
```

```
[1] 14.72727
```

```
> var(ldta$emplno,na.rm=T)
```

```
[1] 8804.201
```

Dispersija yra 8804, o vidurkis tik 14,727. Šiuo atveju Puasono regresija visiškai netinka, o neigiama binominė regresija gali ir tikti.

8.5.2. Modelio parametrų analizė

Regresorius *emplnof2* yra kategorinis, bet įgyja tik dvi reikšmes (0 ir 1). Todėl jokių specialių komandų nereikia. Kategorinis kintamasis automatiškai perkoduojamas į keletą dvireikšmių kintamųjų (pseudokintamųjų skaičius lygus kategorijų skaičiui, minus 1), jei R programoje aprašant modelį nurodomas kaip *factor*. Išsamiai tokį atvejį aprašėme nagrinėdami Puasono regresiją. Neigiama binominė regresija atliekama įvykdant :

```
library(MASS)
```

```
summary(m1 <- glm.nb(emplno~brwmny+eduyrs+emplnof2, data = ldta))
```

```
#arba
```

```
summary(m1 <- glm.nb(emplno~brwmny+eduyrs+as.factor(emplnof2), data = ldta))
```

```
glm.nb(formula = emplno ~ brwmny + eduyrs + emplnof2, data = ldta,  
init.theta = 0.1877132532, link = log)
```

Deviance Residuals:

Min	1Q	Median	3Q	Max
-1.6026	-1.0651	-0.7066	-0.1500	1.5723

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.03945	1.37670	-0.029	0.977138
brwmny	-0.75288	0.28362	-2.655	0.007941 **
eduyrs	0.28649	0.08171	3.506	0.000455 ***
emplnof2	1.62939	0.59996	2.716	0.006611 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for Negative Binomial(0.1877) family taken to be 1)

Null deviance: 86.571 on 65 degrees of freedom

Residual deviance: 54.989 on 62 degrees of freedom

AIC: 277.90

Number of Fisher Scoring iterations: 1

Theta: 0.1877

Std. Err.: 0.0426

2 x log-likelihood: -267.9050

Pagal nutylėjimą R programa pateikia labai nedaug modelio suderinamumo rodiklių (deviacija ir AIC). Modelio suderinamumo matas $AIC = 277,9$ – jis būtų naudingas, jei norėtume palyginti su kitu neigiamos binominės regresijos modeliu (turinčiu mažiau ar daugiau regresorių). Mūsų atveju geresnis modelio suderinamumo indikatorius yra modelio deviacija. Ji yra 54,989. Deviacija, padalyta iš laisvės laipsnių skaičiaus, $54,989/62=0,887$. Nėra toli nuo vieneto. Darome išvadą, kad neigiamos binominės regresijos modelis duomenims tinka pakankamai gerai.

R protokole neigiamos binominės regresijos su dispersija susijęs parametras žymimas **Theta**. SPSS, STATA programose dispersijos parametras yra **alpha**, o SAS **dispersion**. Šių parametų ryšys $\alpha = 1/\text{Theta}$. Pirmiau pateiktam pavyzdžiui turime **alpha=1/0,18877=5,2975**. Kai šis parametras lygus nuliui, neigiama binominė regresija virsta Puasono regresija. Šis koeficientas statistiškai reikšmingai skiriasi nuo 0 (atsižvelgiant, kad *theta* standartinė paklaida 0,043), taigi Puasono regresija netinka nagrinėjamam pavyzdžiui.

Didžiausio tikėtinumo santykio chi kvadrato kriterijaus rezultatus ir pseudo R2 gauname įvykdę:

```
m1.reduced = glm.nb(emplno ~ 1, data=ldta)
anova(m1.reduced, m1, test="Chisq")
# pseudo r square
rkvadrat = 1 - m1$deviance / m1$null.deviance
```

Likelihood ratio tests of Negative Binomial Models

Response: emplno

	Model	theta	Resid. df	2 x log-lik.	Test	df
1	1	0.1090146	65	-291.6817		
2	brwmny + eduyrs + emplnof2	0.1877133	62	-267.9047	1 vs 2	3
	LR stat.	Pr(Chi)				
1						
2	23.77697	2.780654e-05				

> rkvadrat

[1] 0.3648126

Rezultatų išsklotinėje yra tikėtinumų santykio kriterijaus chi kvadrato statistika (23,78) ir p reikšmė. Kadangi $p = 0,000 < 0,05$, galime teigti, kad tikėtinumų santykio kriterijus patvirtina neigiamos binominės regresijos modelio tinkamumą. Pseudo $R^2 = 0,36$ yra nedidelis, bet $> 0,20$. Neigiamai binominei regresijai tai nėra svarbus rodiklis. Aprašant modelio rezultatus, apie R^2 dažniausiai net neužsimenama.

Rezultatų išsklotinėje taip pat pateikta informacija apie regresorių koeficientų įverčius ir Voldo kriterijus. Regresoriai *emplnof2*, *eduyrs*, *brwmny* yra statistiškai reikšmingi (atitinkamų kriterijų p reikšmės $< 0,05$). Konstantai p reikšmės nežiūrime, nes jos iš modelio nežadame šalinti. Taigi visi regresoriai yra statistiškai reikšmingi ir modelyje reikalingi. Modelį galima užrašyti taip:

$$\text{Vidutinis darbuotojų skaičius} = \exp\{-0,04 - 0,75 \text{ brwmny} + 0,29 \text{ eduyrs} + 1,63 \text{ emplnof2}\}.$$

Regresorių koeficientų įverčių ženklai atitinka logiką: neigiamas *brwmny* koeficientas reiškia, kad respondentas, labiau įsitikinęs lengvai gausiąs paskolą, turi mažiau darbuotojų. Analogiškai darome išvadą, kad daugiau metų mokęsi respondentai turi ir daugiau darbuotojų. Daugiau darbuotojų turi ir žmonės, kurių tėvai jų taip pat turi. Norėdami skaitiškai įvertinti regresorių įtaką, įvykdome:

```
(est <- cbind(Estimate = coef(m1), confint(m1)))
exp(est)
```



```
> (est <- cbind(Estimate = coef(m1), confint(m1)))
Waiting for profiling to be done...
      Estimate      2.5 %      97.5 %
(Intercept) -0.03945154 -3.60374529  3.9229231
brwmny      -0.75288351 -1.32884465 -0.2249868
eduyrs       0.28648741  0.04110999  0.5461916
emplnof2     1.62938869  0.29356719  2.8953009
> exp(est)
      Estimate      2.5 %      97.5 %
(Intercept)  0.9613165  0.02722158 50.5479876
brwmny       0.4710064  0.26478300  0.7985268
eduyrs       1.3317414  1.04196671  1.7266646
emplnof2     5.1007556  1.34120329 18.0889440
>
```

Lentelėse pateikti koeficientų įverčiai, pasikliautiniai intervalai ir koeficientų įverčių eksponentės, t. y. daugikliai, rodantys, kiek kartų padidės (sumažės) modeliuojamo kintamojo vidurkis, regresoriui padidėjus vienetu. Pavyzdžiui, matome, kad respondentai, kurių tėvai turi samdomų darbuotojų, vidutiniškai ir patys jų turi 5,1 karto daugiau, palyginti su respondентаis, kurių tėvai neturi samdomų darbuotojų.

8.5.3. Prognozavimas

Prognozavimas niekuo nesiskiria nuo Puasono regresijos atvejo. Parodysime kaip atlikti vidutinio darbuotojų skaičiaus prognozę respondentui, kuris mokėsi 15 metų ir mano, kad pinigų pasiskolinti labai sunku. Be to, žinome, kad jo tėvas turi samdomų darbuotojų. Įvykdome:

```
newdata1 <- data.frame(eduyrs=15,brwmny = 1,emplnof2 = 1)
newdata1$phat <- predict(m1, newdata1, type = "response")
newdata1
```

```
> newdata1
  eduyrs brwmny emplnof2  phat
1   15      1      1 169.7565
```

Gavome, kad tokie respondentai vidutiniškai turėtų 169,76 darbuotojus. Galima prognozę išskaidyti į dvi, atsižvelgiant į tėvo darbuotojus: respondentai, kurių tėvai samdomų darbuotojų neturi vidutiniškai turi 33,28 darbuotojus.

```
newdata1 <- data.frame(eduyrs=15,brwmny = 1,emplnof2 = c(0,1))
```

```
newdata1$phat <- predict(m1, newdata1, type = "response")
newdata1
```

```
> newdata1
  eduyrs brwmny emplnof2  phat
1    15     1      0    33.28065
2    15     1      1   169.75647
```

8.5.4. R programos neigiamos binominės regresijos komandos

Neigiamai binominei regresinei analizei atlikti naudojama **glm.nb** funkcija iš **MASS** funkcijų bibliotekos.

```
glm.nb(formula, family, data, weights, subset, ...)
```

Būtinasis parametras **formula** – užrašome modelio išraišką.

Scenarijus:

```
dta<-read.csv2("ESS4SE.csv",na.strings = "NA",stringsAsFactors=FALSE)
library(car)
dta$emplnof2 <- recode(dta$emplnof,"1=0;c(2,3)=1")
ldta<-subset(dta,emplno < 900 & emplnof < 4 & eduyrs < 88 &brwmny <
8,select=c(emplno,brwmny,eduyrs,emplnof2,gndr)) # 281 stebejimai kaip spss
mean(ldta$emplno,na.rm=T)
var(ldta$emplno,na.rm=T)
# modelis
library(MASS)
summary(m1 <- glm.nb(emplno~brwmny+eduyrs+emplnof2, data = ldta))
#arba
summary(m1 <- glm.nb(emplno~brwmny+eduyrs+as.factor(emplnof2), data =
ldta))
# suderinamumas
m1.reduced <-glm.nb(emplno ~ 1, data=ldta)
```

```

anova(m1.reduced,m1, test="Chisq")
# pseudo r square
rkvadrat<-1-m1$deviance/m1$null.deviance

# koeficientai

(est <- cbind(Estimate = coef(m1), confint(m1)))
exp(est)

# prognozavimas

newdata1 <- data.frame(eduyrs=15,brwmny = 1,emplnof2 = 1)
newdata1$phat <- predict(m1, newdata1, type = "response")
newdata1
newdata1 <- data.frame(eduyrs=15,brwmny = 1,emplnof2 = c(0,1))
newdata1$phat <- predict(m1, newdata1, type = "response")
newdata1

```

Uždaviniai

1. Tiriame 2008 metų Prancūzijos duomenis **ESS4FR**. Tyrime naudosime tokius kintamuosius:

- *agea* – respondento amžius,
- *hhmmb* – namų ūkio nuolatinių narių skaičius,
- *cldcrsv* – paramos vaiko priežiūrai teikimas tėvams, turintiems teisę ją gauti (0 – itin blogas,..., 10 – labai geras),
- *imptrad* – svarbu laikytis tradicijų ir papročių (1 – visai kaip aš,..., 6 – absoliučiai ne taip kaip aš), *eduyrs* – metų, kiek buvo mokytasi, skaičius.

Tirsime stipriai tradicijų besilaikančius ($imptrad \leq 2$) aukštojo mokslo neragavusius ($eduyrs \leq 10$) respondentus. Modeliuosime, kiek namų ūkyje yra gyventojų: $hhmmb = f(cldcrsv, agea)$. Taikysime neigiamą binominę regresiją. Ar rezultatai skiriasi nuo gautųjų, aptartų Puasono regresijai skirtame skyriuje? Kaip atrodys neigiamą binominę regresiją, atlikta su standartinėmis *glm* opcijomis?

2. Tiriame 2008 metų Europos Sąjungos socialinio tyrimo Izraelio duomenis **ESS4IL**. Kintamieji:

- *agea* – respondento amžius,
- *freehms* – gėjai ir lesbietės gali gyventi kaip nori (matuojamas skale nuo 1 – visiškai sutinku, iki 5 – visiškai nesutinku),
- *hhmmb* – namų ūkio nuolatinių narių skaičius,
- *blgetmg* – priklausymas etninėms mažumoms (1 – taip, 2 – ne),
- *gndr* – lytis (1 – vyr., 2 – mot.),
- *imptrad* – svarbu laikytis tradicijų ir papročių (1 – visai kaip aš,..., 6 – absoliučiai ne taip kaip aš),
- *pray* – meldžiamasi (1 – kasdien, 2 – dažniau nei kartą per savaitę, 3 – kartą per savaitę, ..., 7 – niekada).

Pritaikyti neigiamos regresijos modelį namų ūkio nuolatinių gyventojų skaičiui (*hhmmb*). Regresoriai amžius (*agea*) ir požiūris į seksualines mažumas (*freehms*). Tiriame labai tradicijų besilaikantys (*imptrad* = 1), religingi (*pray* ≤ 3) vyrai (*gndr* = 1), priklausantys nacionalinei daugumai (*blgtmg* = 2).



9. MODIFIKUOTI SKAIČIUOJAMIEJI MODELIAI


Modeliuojant kažkokių reiškinių skaičių (neišlaikytų egzaminų skaičių, žemės drebėjimų skaičių, laimėjimų loterijoje skaičių) ir kai duomenys nėra normalūs, dažniausiai taikomos Puasono arba neigiama binominė regresijos. Šiame skyrelyje aptarsime dvi šių regresijos modelių modifikacijas tais atvejais, kai:

- duomenyse per daug nulių;
- duomenyse nėra nulių.

9.1. Perteklinių nulių Puasono regresijos modelis

9.1.1. Modelio paskirtis

Kai modeliuojame retus įvykius, gana dažnai nulių būna daug daugiau, nei tiktų Puasono regresijai. Pavyzdžiui, turimų samdomų darbuotojų skaičiaus Švedijoje dažnių grafikas aiškiai rodo, kad dauguma respondentų neturi samdomų darbuotojų.



Perteklinių nulių Puasono regresijos⁷⁴ (idėjos esmė samprotavimas, kad nulis nuliui nelygus. Galbūt dalis respondentų yra tokie, kad jie iš principo negali turėti samdomų darbuotojų (pavyzdžiui, dirba valstybinėje tarnyboje). Todėl juos reikėtų atskirti nuo galinčių turėti samdomų darbuotojų (pavyzdžiui, užsiimančių privačia veikla) respondentų. Idėjiniu lygmeniu šis reikalavimas nusako, kokiems duomenims skirtas modelis – visi respondentai skirstytini į dvi

⁷⁴ Angl. *zero-inflated Poisson regression*.

grupės: tuos, kuriems kintamojo reikšmė visada nulis, ir tuos, kuriems kintamasis dar gali įgyti ir kitokių reikšmių. Jeigu hareme klausinėjame apie vaikų skaičių, reikia skirti eunuchus nuo žmonių.

Problema ta, kad realiai nežinoma, kurie respondentai kokiai grupei priklauso. Matematiškai tai reiškia, kad bendrasis modelis sudaromas, sujungus dvinarę logistinę regresiją su standartine Puasono regresija. Dvinarė logistinė regresija turi padėti rasti respondentus, kuriems priklausomas kintamasis visada lygus nuliui (nulinukų grupę). Tiems, kurie nepateko į šią grupę, taikomas Puasono regresijos modelis.

Regresoriai, vartojami viename modelyje, gali skirtis nuo kito modelio regresorių.

Kitais žodžiais tariant, visai nebūtina (bet leistina) į abudu modelius įtraukti tuos pačius regresorius. Formaliai kiekvieną modelio tikimybę galime užrašyti kaip tikimybių mišinį:

$$P(Y = 0) = P(\text{priklauso nulinukų grupei}) + P(\text{nepriklauso nulinukų grupei}) \times P(Y = 0, \text{ o respondentas yra iš antrosios grupės}),$$
$$P(Y = k) = P(\text{nepriklauso nulinukų grupei}) \times P(Y = k, \text{ o respondentas yra iš antrosios grupės}).$$

Nustatant modelio tikimą reikia:

- Pažiūrėti į tikėtinumų santykio kriterijaus p reikšmę. Gerų modelių $p < 0,05$.
- Voldo kriterijumi patikrinti, ar visi regresoriai statistiškai reikšmingi Puasono regresijos modelyje, skirtime ne nulinukams. Gerų modelių visų regresorių $p < 0,05$. Konstantai p reikšmės nežiūrima.
- Voldo kriterijumi patikrinti, ar visi regresoriai statistiškai reikšmingi logistiniame modelyje, atskiriančiame nulinukus. Gerų modelių visų regresorių $p < 0,05$. Konstantai p reikšmės nežiūrima.
- Vuongo kriterijumi patikrinti, ar perteklinių nulių Puasono regresijos modelis statistiškai reikšmingai skiriasi nuo paprasto Puasono regresijos modelio. Skiriasi, jeigu $p < 0,05$.

Perteklinių nulių Puasono regresijos nerekomenduojama taikyti labai mažoms imtims ($n < 100$).

9.1.2. Perteklinių nulių Puasono regresija su STATA

Atliksime tą pačią analizę kaip ir nagrinėdami neigiamą binominę regresiją. Tiriame Švedijos duomenis **ESS4SE**. Modeliuojame *emplno* (turimų darbuotojų skaičius) priklausomybę nuo regresorių

- *brwmny* (ar sunku pasiskolinti pinigų išgyvenimui, 1 – labai sunku, ..., 5 – labai lengva),
- *eduyrs* (metų, kiek buvo mokytasi, skaičius),
- *emplnof2* (tėvo turimų darbuotojų skaičius, 0 – neturi, 1 – turi).

Atidarę failą su STATA dar įvykdome: `keep if emplno < 900 & emplnof < 4 & eduyrs < 88 & brwmny < 8`.

Puasono modeliui pasirinksime tokius regresorius: *brwmny*, *eduyrs*, *emplnof2*. Logistiniame modelyje apsiribosime vienu regresoriumi – *emplnof2*. Regresorių parinkimas modeliams remiasi teoriniais samprotavimais ir praktiniais bandymais. Teoriškai bandome išmąstyti, nuo ko priklauso – turės respondentas darbuotojų ar neturės (logistinis modelis) ir nuo ko priklauso darbuotojų skaičius, jeigu respondentas jų turi (Puasono modelis). Praktiniai bandymai reiškia, kad išbandomi keli variantai ir renkamas geriausias. Perteklinių nulių Puasono regresija atliekama įvykdant:

```
zip emplno eduyrs brwmny emplnof2 , inflate( emplnof2) vuong
```

Zero-inflated Poisson regression				Number of obs	=	66
				Nonzero obs	=	30
				Zero obs	=	36
Inflation model = logit				LR chi2(3)	=	3477.94
Log likelihood = -598.8196				Prob > chi2	=	0.0000
	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
emplno						
eduyrs	.1851223	.0190059	9.74	0.000	.1478715	.222373
brwmny	-1.687293	.0484736	-34.81	0.000	-1.7823	-1.592286
emplnof2	4.018727	.1661605	24.19	0.000	3.693058	4.344395
_cons	2.908324	.2662471	10.92	0.000	2.386489	3.430158
inflate						
emplnof2	2.165891	1.013478	2.14	0.033	.1795099	4.152272
_cons	-2.048418	.9481365	-2.16	0.031	-3.906732	-.1901049
Vuong test of zip vs. standard Poisson:				z =	2.12	Pr>z = 0.0169

Tikėtinumų santykio chi kvadrato kriterijaus statistika i 3477,94, o *p* reikšmė (0,000) daug mažesnė už 0,05. Tai rodo gerą modelio bendrąjį tikimą. Pirmoji lentelės dalis skirta Puasono regresijai. Visos interpretacijos išlieka kaip ir Puasono regresijos atveju. Pavyzdžiui, teigiama *emplnof2* regresoriaus koeficiento reikšmė rodo, kad daugiau darbuotojų turi tie respondentai, kurių tėvai taip pat turi samdomų darbuotojų. Matome, kad pagal Voldo kriterijų visi regresoriai

statistiškai reikšmingi. Antroji lentelės dalis (**inflate**) skirta logistiniam modeliui, padedančiam atskirti nulinukus nuo likusiųjų respondentų. Matome, kad regresorius *inflate* yra statistiškai reikšmingas. Lentelės pabaigoje pateikiamas Vuongo kriterijus, palyginantis nagrinėtąjį modelį su paprastu Puasono regresijos modeliu. Kriterijaus p reikšmė $0,0169 < 0,05$. Todėl hipotezę, kad modeliai nesiskiria, atmetame.

Norėdami gauti išsamesnę informaciją apie koeficientų eksponentes ir kitas charakteristikas, galime įvykdyti:

```
listcoef
```

emplno	b	z	P> z	e^b	e^bStdX	SDofX
eduyrs	0.18512	9.740	0.000	1.2034	1.9956	3.7325
brwmny	-1.68729	-34.808	0.000	0.1850	0.1646	1.0693
emplnof2	4.01873	24.186	0.000	55.6302	7.5743	0.5038

b = raw coefficient

Pateikėme tik trumpą rezultatų fragmentą, skirtą ne nulinukų grupei. Visi papildomi metai, kai buvo mokytasi, didina vidutinį turimų darbuotojų skaičių 1,203 karto.

Reikšmės prognozuojamos analogiškai Puasono regresijai. Pavyzdžiui, padarysime prognozes visoms (realiai pirmoms dešimčiai) tikimybių, kai $emplnof2 = 1$. Kitų regresorių reikšmės bus paimtos lygios jų vidurkiui. Įvykdome:

```
prvalue, x(emplnof2 = 1)
```

zip: Predictions for emplno

```
Expected y:          8.4091
Pr(Always0|z):       0.5293
Pr(y=0|x,z):         0.5293
Pr(y=1|x):           0.0000
Pr(y=2|x):           0.0000
Pr(y=3|x):           0.0000
Pr(y=4|x):           0.0000
Pr(y=5|x):           0.0001
Pr(y=6|x):           0.0004
Pr(y=7|x):           0.0009
Pr(y=8|x):           0.0021
Pr(y=9|x):           0.0042
```

x values for count equation

```
      eduyrs      brwmny      emplnof2
x= 11.712121  3.6818182          1
```

z values for binary equation

```
      emplnof2
z=          1
```


Visos tikimybės įvertintos tam atvejui, kai *emplnof2* = 1, *eduyrs* = 11,71 (*eduyrs* vidurkis yra 11,71), *brwmny* = 3,68. Vidutinis tikėtinas darbuotojų skaičius – 8,409. Tikimybė, kad respondentas yra iš nulinukų grupės, – 0,529. Tikimybė, kad respondentas turi aštuonis darbuotojus, – 0,0021 ir t. t.

9.1.3. Perteklinių nulių Puasono regresija su SAS

Atliksime tą pačią analizę kaip ir nagrinėdami neigiamą binominę regresiją. Tiriame Švedijos duomenis **ESS4SE**. Modeliuojame *emplno* (turimų darbuotojų skaičius) priklausomybę nuo regresorių

- *brwmny* (ar sunku pasiskolinti pinigų išgyvenimui, 1 – labai sunku, ..., 5 – labai lengva),
- *eduyrs* (metų, kiek buvo mokytasi, skaičius),
- *emplnof2* (tėvo turimų darbuotojų skaičius, 0 – neturi, 1 – turi).

SPSS formatu paruošti duomenys importuoti į SAS rgr biblioteką. Atidarius failą su SAS dar reikia užtikrinti, kad kodai, kurie SPSS žymėjo praleistas reikšmes, nebūtų traktuojami kaip regresorių reikšmės. Be to, kintamąjį *emplnof* perkoduojame į dvireikšmį kintamąjį *emplnof2* (naudojamą tolesnėje analizėje). Todėl įvykdome:

```
OPTIONS nomfterr;
data Dse;
set rgr.ESS4SE;
if (emplno LT 900) AND (emplnof LT 4) AND (eduyrs LT 88) AND (brwmny LT 8) AND
(emplno ne .) AND (emplnof ne .) AND (eduyrs ne .) AND (brwmny ne .);
emplnof2=.;
IF (emplnof=1) THEN emplnof2 = 0;
ELSE IF ((emplnof=2) OR (emplnof=3)) THEN emplnof2 = 1;
keep emplno emplnof emplnof2 eduyrs brwmny;
run;
```

Puasono modeliui pasirinksimė tokius regresorius: *brwmny*, *eduyrs*, *emplnof2*. Logistiniame modelyje apsiribosime vienu regresoriumi – *emplnof2*. Regresorių parinkimas modeliams remiasi teoriniais samprotavimais ir praktiniais bandymais. Teoriškai bandome išmąstyti, nuo ko priklauso – turės respondentas darbuotojų ar jų neturės (logistinis modelis) ir nuo ko priklauso darbuotojų skaičius, jeigu respondentas jų turi (Puasono modelis). Praktiniai bandymai reiškia, kad išbandomi keli variantai ir renkamas geriausias. Perteklinių nulių Puasono regresija atliekama įvykdant:

```

proc genmod data = dse;
class emplnof2 (ref="0");
model emplno=brwmny eduyrs emplnof2 / link=log dist=zip;
zeromodel emplnof2 /link = logit ;
store p1;
run;

```

Criteria For Assessing Goodness Of Fit			
Criterion	DF	Value	Value/DF
Deviance		1197.6391	
Scaled Deviance		1197.6391	
Pearson Chi-Square	60	2135.1184	35.5853
Scaled Pearson X2	60	2135.1184	35.5853
Log Likelihood		4102.2648	
Full Log Likelihood		-598.8196	
AIC (smaller is better)		1209.6391	
AICC (smaller is better)		1211.0629	
BIC (smaller is better)		1222.7771	

Analysis Of Maximum Likelihood Parameter Estimates								
Parameter		DF	Estimate	Standard Error	Wald 95% Confidence Limits		Wald Chi-Square	Pr > ChiSq
Intercept		1	2.9083	0.2662	2.3865	3.4302	119.32	<.0001
brwmny		1	-1.6873	0.0485	-1.7823	-1.5923	1211.63	<.0001
eduyrs		1	0.1851	0.0190	0.1479	0.2224	94.87	<.0001
emplnof2	1	1	4.0187	0.1662	3.6931	4.3444	584.95	<.0001
emplnof2	0	0	0.0000	0.0000	0.0000	0.0000	.	.
Scale		0	1.0000	0.0000	1.0000	1.0000		

Note: The scale parameter was held fixed.

Analysis Of Maximum Likelihood Zero Inflation Parameter Estimates								
Parameter		DF	Estimate	Standard Error	Wald 95% Confidence Limits		Wald Chi-Square	Pr > ChiSq
Intercept		1	-2.0484	0.9481	-3.9068	-0.1901	4.67	0.0307
emplnof2	1	1	2.1659	1.0135	0.1795	4.1523	4.57	0.0326
emplnof2	0	0	0.0000	0.0000	0.0000	0.0000	.	.

Lentelėje „Criteria For Assessing Goodness Of Fit“ yra suderinamumo matai ir statistikos SAS spausdina keliolika informacinių indeksų (AIC, BIC ir t. t.) ir suderinamumo statistikų. Kuo mažesnis informacinis indeksas, tuo modelis tinkamesnis, tačiau informaciniai indeksai labiau tinka lyginant modelius (tai aptarsime kiek vėliau).

Norint įvertinti, ar modelis tinkamesnis už nulinį (skirtingai nuo STATA programos), reikia papildomų skaičiavimų. Turime nagrinėjamo modelio logtikėtinumo funkcijos (**Full Log Likelihood**) reikšmę. Reikia rasti nulinio modelio logtikėtinumo funkciją, apskaičiuoti chi2 statistikos reikšmę ir rasti p reikšmę. Apskaičiuoti chi2 statistika rankiniu būdu yra paprasta:

$2 * (-598,8196 - (-2337,7890)) = 3479,9388$. Skaičiuodami p reikšmę jau be chi skirstinio reikšmių lentelės neišsiverstume ($df = 3$). Taigi su SAS programa visus skaičiavimus galima atlikti taip:

```
/* Pasirinkto modelio analizė */

proc genmod data = dse;
class emplnof2 (ref="0");
model emplno=brwmny eduyrs emplnof2 / link=log dist=zip;
zeromodel emplnof2 /link = logit ;
ods output Modelfit=fit1;
run;

/* logtikėtinumo f-jos reišmės ištraukimas */

data fit1;
set fit1(where=(criterion="Full Log Likelihood"));
l1=value;
run;

/* nulinio modelio analizė */

proc genmod data= dse;
model emplno= /dist=zip;
zeromodel / link = logit ;
ods output Modelfit=fit2;
RUN;

/* logtikėtinumo f-jos reišmės ištraukimas */

data fit2;
set fit2(where=(criterion="Full Log Likelihood"));
l2=value;
run;
```

```
/* ch2 statistikos ir p-reikšmės skaičiavimas */
```

```
data fit;
merge fit1 fit2;
by criterion;
chi2=2*(l1-l2);
pvalue=1-probchi(chi2,3);
run;
```

```
proc print data=fit;
var l1 l2 chi2 pvalue;
format pvalue pvalue6.4;
run;
```

Obs	l1	l2	chi2	pvalue
1	-598.820	-2337.79	3477.94	<.0001

Toliau pateikiami perteklinės Puasono regresijos koeficientų įverčiai. Visos interpretacijos išlieka kaip ir Puasono regresijos atveju. Pavyzdžiui, teigiama *emplnof2* regresoriaus koeficiento reikšmė rodo, kad daugiau darbuotojų turi tie respondentai, kurių tėvai taip pat turi samdomų darbuotojų. Matome, kad pagal Voldo testą visi regresoriai statistiškai reikšmingi. Antroji lentelės dalis (...**Inflation Parameter Estimates**) yra skirta logistiniam modeliui, padedančiam atskirti nulinukus nuo likusiųjų respondentų. Matome, kad regresorius *emplnof2* yra statistiškai reikšmingas. SAS sistemoje Vuongo kriterijus, lyginantis nagrinėtajį modelį su paprastu Puasono regresijos modeliu, yra tik *macro* kodo pavidalu. Todėl reikia atsisiųsti **young.sas** iš SAS svetainės ir įvykdyti:

```
%include "C:/Users/GM/Documents/workSAS/vuong.sas";
proc genmod data = dse;
class emplnof2 (ref="0");
model emplno=brwmny eduyrs emplnof2 / link=log dist=zip;
zeromodel emplnof2 /link = logit ;
output out=outzinb pred=predzip pzero=p0;
run;
proc genmod data = outzinb order=data;
class emplnof2 (ref="0");
model emplno=brwmny eduyrs emplnof2 /DIST=poi;
output out=out pred=predpoi;
run;
```

```
%vuong(data=out, response=emplno,
      model1=zip, p1=predzip, dist1=zip, scale1=1.00, pzero1=p0,
      model2=poi, p2=predpoi, dist2=poi, scale2=1.00,
      nparm1=4, nparm2=3)
```

Vuong Test

H0: models are equally close to the true model

Ha: one of the models is closer to the true model

Vuong Statistic	Z	Pr> Z	Preferred Model
Unadjusted	2.2196	0.0264	zip
Akaike Adjusted	2.2166	0.0266	zip
Schwarz Adjusted	2.2134	0.0269	zip

Kriterijaus p reikšmė $0,0264 < 0,05$. Todėl hipotezę, kad modeliai nesiskiria, atmetame.

Norėdami gauti išsamesnę informaciją apie koeficientų eksponentes ir kitas charakteristikas, galime įvykdyti:

```
ods output ParameterEstimates = est;
proc plm source = p1;
  show parameters;
run;
data est_exp;
  set est;
  expb = exp(estimate);
  if parameter ^= "Intercept";
run;
proc print data = est_exp;
run;
```

Obs	Parameter	emplnof2	Estimate	StdErr	expb
1	Borrow money to make ends meet, difficult or easy	–	-1.6873	0.04847	0.1850
2	Years of full-time education completed	–	0.1851	0.01901	1.2034
3	emplnof2 1	1	4.0187	0.1662	55.6303
4	emplnof2 0	0	0	.	1.0000

Pateikėme tik trumpą rezultatų fragmentą, skirtą ne nulinukų grupei. Visi papildomi metai, kiek buvo mokytasi, didina vidutinį turimų darbuotojų skaičių 1,203 karto.

Reikšmės prognozuojamos analogiškai Puasono regresijai. Pavyzdžiui, padarysime visų (realiai dešimčiai pirmų) galimų reikšmių tikimybių prognozes, kai *emplnof2* = 1. Kitų regresorių reikšmės bus paimtos lygios jų vidurkiui. Įvykdome

```

data new;
  set dse;
  if emplnof2=1 then emplnof2=0;
  else if (emplnof2=0) then emplnof2=1;
run;
proc countreg data = new method = qn;
class emplnof2;
model emplno=brwmny eduyrs emplnof2 / dist=zip;
zeromodel emplno ~ emplnof2;
output out=predpoi probcount(0 to 10);
run;
data predpoi1;
set predpoi;
if emplnof2=0;
run;
proc means mean data=predpoi1;
var p_0-p_10 eduyrs brwmny;
run;
```

Variable	Label	Mean
P_0	Probability of emplno taking level=0	0.5465285
P_1	Probability of emplno taking level=1	0.0249392
P_2	Probability of emplno taking level=2	0.0247472
P_3	Probability of emplno taking level=3	0.0234781
P_4	Probability of emplno taking level=4	0.0226846
P_5	Probability of emplno taking level=5	0.0216123
P_6	Probability of emplno taking level=6	0.0199436
P_7	Probability of emplno taking level=7	0.0181244
P_8	Probability of emplno taking level=8	0.0166898
P_9	Probability of emplno taking level=9	0.0157978
P_10	Probability of emplno taking level=10	0.0152422
eduyrs	Years of full-time education completed	11.6060606
brwmny	Borrow money to make ends meet, difficult or easy	3.6969697

Visos tikimybės įvertintos tam atvejui, kai $emplnof2 = 1$ ⁷⁵, $eduyrs = 11,6$ ($eduyrs$ vidurkis yra 11,71), $brwmny = 3,69$. Vidutinis tikėtinas darbuotojų skaičius – 8,409. Tikimybė, kad respondentas yra iš nulinukų grupės, 0,54. Tikimybė, kad respondentas turi aštuonis darbuotojus, – 0,017 ir t. t.

9.1.4. Perteklinių nulių Puasono regresija su R

Atliksime tą pačią analizę kaip ir nagrinėdami neigiamą binominę regresiją. Tiriame Švedijos duomenis **ESS4SE**. Modeliuojame *emplno* (turimų darbuotojų skaičius) priklausomybę nuo regresorių

- *brwmny* (ar sunku pasiskolinti pinigų išgyvenimui, 1 – labai sunku, ..., 5 – labai lengva),
- *eduyrs* (metų, kiek buvo mokytasi, skaičius),
- *emplnof2* (tėvo turimų darbuotojų skaičius, 0 – neturi, 1 – turi).
- SPSS duomenis išsaugojome csv formatu. Atidarius failą su R dar reikia užtikrinti, kad kodai, kurie SPSS žymėjo praleistas reikšmes, nebūtų traktuojami kaip regresorių reikšmės. Be to, kintamąjį *emplnof* perkoduojame į *emplnof2*. Todėl įvykdėme:

⁷⁵ Skaičiavimams supaprastinti kintamojo kodai buvo sukeisti vietomis.

```
dta<-read.csv2("ESS4SE.csv",na.strings = "NA",stringsAsFactors=FALSE)
library(car)
dta$emplnof2 <- recode(dta$emplnof,"1=0;c(2,3)=1")
ldta<-subset(dta,emplno<900 & emplnof<4 & eduyrs<88 & brwmny<8,
select=c(emplno,brwmny,eduyrs,emplnof2,gndr))
```

Puasono modeliui pasirinksimė tokius regresorius: *brwmny*, *eduyrs*, *emplnof2*. Logistiniame modelyje apsiribosime vienu regresoriumi – *emplnof2*. Regresorių parinkimas modeliams remiasi teoriniais samprotavimais ir praktiniais bandymais. Teoriškai bandome išmąstyti, nuo ko priklauso – turės respondentas darbuotojų ar jų neturės (logistinis modelis) ir nuo ko priklauso darbuotojų skaičius, jeigu respondentas jų turi (Puasono modelis). Praktiniai bandymai reiškia, kad išbandomi keli variantai, ir renkamas geriausias. Perteklinių nulių Puasono regresija atliekama įvykdant:

```
library(pscl);
summary(m1 <- zeroinfl(emplno~brwmny+eduyrs+factor(emplnof2) | emplnof2, data =
ldta))
# lyginimas su nuliniu modeliu (modelio tinkamumas)
mnull <- update(m1, . ~ 1)
lr=2 * (logLik(m1) - logLik(mnull))
pvalue<-pchisq(2 * (logLik(m1) - logLik(mnull)), df = 3, lower.tail = FALSE)
cat('LR chi2(3)',lr,'\n','Prob>chi2',pvalue,'\n')
# palyginimas su Puasono modeliu
summary(p1 <- glm(emplno~brwmny+eduyrs+factor(emplnof2), family = poisson, data =
ldta))
vuong( m1,p1)
#informacinis indeksas
AIC(m1)
```



```
Call:
zeroinfl(formula = emplno ~ brwmny + eduyrs + factor(emplnof2) | emplnof2,
  data = ldta)
```

Pearson residuals:

```
   Min   1Q Median   3Q   Max
-2.3724 -0.8795 -0.3782  0.8417 24.9176
```

Count model coefficients (poisson with log link):

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	2.90845	0.26624	10.92	<2e-16 ***
brwmny	-1.68731	0.04847	-34.81	<2e-16 ***
eduyrs	0.18511	0.01901	9.74	<2e-16 ***
factor(emplnof2)1	4.01879	0.16616	24.19	<2e-16 ***

Zero-inflation model coefficients (binomial with logit link):

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-2.0483	0.9481	-2.160	0.0307 *
emplnof2	2.1657	1.0134	2.137	0.0326 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Number of iterations in BFGS optimization: 14

Log-likelihood: -598.8 on 6 Df

```
LR chi2(3) 3477.939
Prob>chi2 0
```

Vuong Non-Nested Hypothesis Test-Statistic: 2.202668
(test-statistic is asymptotically distributed $N(0,1)$ under the
null that the models are indistinguishable)
in this case:
model1 > model2, with p-value 0.01380907

```
> AIC(m1)
[1] 1209.639
```

Tikėtinumų santykio kriterijaus statistika **LR chi2(3)** yra 3477,939, o p reikšmė $0,000 < 0,05$. Tai rodo gerą modelio bendrąjį tinkamumą.

Pirmiausia yra pateikiami regresijos koeficientų įverčiai. Visos interpretacijos išlieka kaip ir Puasono regresijos atveju. Pavyzdžiui, teigiama *emplnof2* regresoriaus koeficiento įverčio reikšmė rodo, kad daugiau darbuotojų turi tie respondentai, kurių tėvai taip pat turi samdomų darbuotojų. Matome, kad pagal Voldo kriterijus visi regresoriai statistiškai reikšmingi. Antroji dalis (**zero-inflation model coefficients**) yra skirta logistiniam modeliui, padedančiam atskirti nulinukus nuo

likusiųjų respondentų. Matome, kad regresorius *emplnof* yra statistiškai reikšmingas. Toliau pateikiamas Vuongo kriterijus, palyginantis nagrinėtąjį modelį su paprastu Puasono regresijos modeliu. Testo *p* reikšmė $0,0138 < 0,05$. Todėl hipotezę, kad modeliai nesiskiria, atmetame. Informacinis indeksas AIC yra 1209,64. Kuo šis indeksas mažesnis, tuo geriau. Pats savaime jis nėra labai informatyvus, bet jis pravers, kai lyginsime modelius su skirtingu regresorių skaičiumi tiems patiems duomenims.

Norėdami gauti išsamesnę informaciją apie koeficientų eksponentes ir kitas charakteristikas, galime įvykdyti:

```
(est <- cbind(Estimate = coef(m1), confint(m1)))
exp(est)
```

```
> (est <- cbind(Estimate = coef(m1), confint(m1)))
      Estimate      2.5 %      97.5 %
count_(Intercept)  2.9084470  2.3866216  3.4302723
count_brwmny      -1.6873138 -1.7823214 -1.5923062
count_eduys       0.1851135  0.1478639  0.2223630
count_factor(emplnof2)1 4.0187869  3.6931136  4.3444603
zero_(Intercept)  -2.0482607 -3.9064174 -0.1901040
zero_emplnof2     2.1656525  0.1794182  4.1518867
> exp(est)
      Estimate      2.5 %      97.5 %
count_(Intercept) 18.3283124 10.87668651 30.8850525
count_brwmny      0.1850159  0.16824713  0.2034559
count_eduys       1.2033550  1.15935509  1.2490247
count_factor(emplnof2)1 55.6335782 40.16972344 77.0504438
zero_(Intercept)  0.1289590  0.02011243  0.8268732
zero_emplnof2     8.7202898  1.19652103 63.5537966
>
```

Matome, kad visi papildomi metai, kiek buvo mokytasi, didina vidutinį turimų darbuotojų skaičių 1,203 karto.

Reikšmės prognozuojamos analogiškai Puasono regresijai. Pavyzdžiui, įvykdome:

```
meanedu<-mean(ldta$eduys)
meanbrw<-mean(ldta$brwmny)
newdata1 <- data.frame(eduys=meanedu,brwmny = meanbrw,emplnof2 = 1)
newdata1$phat <- predict(m1, newdata1, type = "response")
newdata1
```

```
> newdata1
      eduyrs    brwmny    emplnof2    phat
1    11.71212    3.681818         1    8.409466
>
```

Tikėtinas darbuotojų skaičius įvertintas tam atvejui, kai $emplnof2 = 1$, $eduyrs = 11,71$ ($eduyrs$ vidurkis yra 11,71), $brwmny = 3.68$. Vidutinis tikėtinas darbuotojų skaičius yra 8,409.

9.2. Perteklinių nulių neigiama binominė regresija

9.2.1. Modelio paskirtis

Viskas, ką galima pasakyti apie perteklinių nulių Puasono regresiją, tinka ir perteklinių nulių neigiamai binominei regresijai. Trumpai priminsime svarbiausius momentus.

- Modeliuojame įvykių skaičių. Duomenys – sveikieji neneigiami skaičiai, juose daug nulių.
- Duomenys (pvz., histograma) visiškai nepanašūs į normaliuosius.
- Spėjama, kad visi respondentai skaidytini į tuos, kuriems priklausomas kintamasis neišvengiamai turi įgyti nulines reikšmes (nulinukų grupė), ir tuos, kuriems nulis yra tik viena iš galimybių.
- Perteklinių nulių neigiamos binominės regresijos modelis – tai dviejų modelių mišinys. Pirmasis iš jų – logistinės regresijos modelis, kuriuo nustatoma respondento priklausomybė nulinukų grupei. Antrasis modelis – neigiamos binominės regresijos modelis, skirtas ne nulinukų grupei.
- Regresoriai, vartojami viename modelyje, gali skirtis nuo kito modelio regresorių.

Nustatant modelio tikimą reikia:

- 1) Pažiūrėti į tikėtinumų santykio chi kvadrato kriterijaus p reikšmę. Gerų modelių $p < 0,05$.
- 2) Voldo kriterijumi patikrinti, ar visi regresoriai statistiškai reikšmingi neigiamos binominės regresijos modelyje, skirtame ne nulinukams. Gerų modelių visų regresorių $p < 0,05$. Konstantai p reikšmės nežiūrime.
- 3) Patikrinti, ar neigiamo binominio skirstinio parametras $alpha$ skiriasi nuo nulio. Skirtumas nuo nulio statistiškai reikšmingas, kai atitinkama p reikšmė $< 0,05$. Jeigu $alpha$ nuo nulio statistiškai reikšmingai nesiskiria, labai tikėtina, kad taikytina Puasono regresija.

- 4) Voldo kriterijumi patikrinti, ar visi regresoriai statistiškai reikšmingi logistiniame modelyje, atskiriančiame nulinukus. Gerų modelių visų regresorių $p < 0,05$. Konstantai p reikšmės nežiūrimė.
- 5) Vuongo kriterijumi patikrinti, ar perteklinių nulių neigiamos binominės regresijos modelis statistiškai reikšmingai skiriasi nuo paprasto neigiamos binominės regresijos modelio. Skiriasi, jeigu $p < 0,05$.

9.2.2. Perteklinių nulių neigiama binominė regresija su STATA

Atliksime tą pačią analizę kaip ir nagrinėdami neigiamą binominę regresiją. Tiriamo Švedijos duomenis **ESS4SE**. Modeliuojame *emplno* (turimų darbuotojų skaičius) priklausomybę nuo regresorių

- *brwmny* (ar sunku pasiskolinti pinigų išgyvenimui, 1 – labai sunku, ..., 5 – labai lengva),
- *edyrs* (metų, kiek buvo mokytasi, skaičius),
- *emplnof2* (tėvo turimų darbuotojų skaičius, 0 – neturi, 1 – turi).

Atidarę failą su STATA dar įvykdome: keep if emplno < 900 & emplnof < 4 & eduyrs < 88 & brwmny < 8.

Neigiamai binominei regresijai imsime tokius regresorius: *brwmny*, *eduyrs*, *emplnof2*. Logistiniame modelyje apsiribosime vienu regresoriumi – *emplnof2*. Ivykdome:

```
zinb emplno eduyrs brwmny emplnof2 , inflate( emplnof2) vuong
```

Zero-inflated negative binomial regression	Number of obs	=	66
	Nonzero obs	=	30
	Zero obs	=	36
Inflation model = logit	LR chi2(3)	=	25.62
Log likelihood = -133.0299	Prob > chi2	=	0.0000

	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
emplno						
eduysr	.2411996	.119541	2.02	0.044	.0069036	.4754956
brwmny	-.8253969	.2681687	-3.08	0.002	-1.350998	-.2997959
emplnof2	2.080372	.6475327	3.21	0.001	.811231	3.349513
_cons	.7150847	1.809166	0.40	0.693	-2.830816	4.260985
inflate						
emplnof2	13.6117	852.2105	0.02	0.987	-1656.69	1683.914
_cons	-14.46382	852.2107	-0.02	0.986	-1684.766	1655.839
/lnalpha	1.310606	.3326411	3.94	0.000	.6586413	1.96257
alpha	3.70842	1.233573			1.932165	7.117599

Vuong test of zinb vs. standard negative binomial: z = **0.61** Pr>z = **0.2710**

Visi rezultatai aprašomi ir interpretuojami analogiškai perteklinių nulių Puasono regresijos modeliui. Statistiškai reikšmingą bendrąjį modelio tikimą rodo maža ($0,000 < 0,05$) tikėtinumų santykio chi kvadrato kriterijaus p reikšmė ($\text{Prob} > \chi^2$). Sprendžiant iš Voldo kriterijų visi regresoriai neigiamos binominės regresijos modelyje yra statistiškai reikšmingi (visos $p < 0,05$, išskyrus konstantos p reikšmę).

Logistinės regresijos modelis blogai atskiria nulinukus nuo likusiųjų, nes regresorius *emplnof2* nėra statistiškai reikšmingas ($p = 0,987 > 0,05$).

Neigiamos binominės regresijos parametras *alpha* = 3,708 statistiškai reikšmingas ($p = 0,00$), todėl tradicinė Puasono regresija šiems duomenims netinka.

Vuongo kriterijaus $p = 0,27 > 0,05$. Negalime atmesti hipotezės, kad perteklinių nulių modelis nesiskiria nuo įprasto neigiamos binominės regresijos modelio.

Galutinė išvada tokia – rezultatai nerodo, kad perteklinių nulių neigiamos binominės regresijos modelis būtų geresnis už standartinį neigiamos binominės regresijos modelį. Tai gana pamokoma išvada – nereikia tikėtis, kad kuo modelis sudėtingesnis, tuo daugiau šansų, jog jis tiks.

Jeigu reikėtų prognozuoti tikimybes, naudotina *prvalue* komanda, analogiška ankstesniems skyreliams.

9.2.3. Perteklinių nulių neigiama binominė regresija su SAS

Atliksime tą pačią analizę kaip ir nagrinėdami neigiamą binominę regresiją. Tiriame Švedijos duomenis **ESS4SE**. Modeliuojame *emplno* (turimų darbuotojų skaičius) priklausomybę nuo regresorių

- *brwmny* (ar sunku pasiskolinti pinigų išgyvenimui, 1 – labai sunku, ..., 5 – labai lengva),
- *edyrs* (metų, kiek buvo mokytasi, skaičius),
- *emplnof2* (tėvo turimų darbuotojų skaičius, 0 – neturi, 1 – turi).

Duomenis paruošiamo taip pat kaip ir perteklinių nulių Puasono regresijos atveju.

```
OPTIONS nofmterr;  
data Dse;  
set rgr.ESS4SE;
```

```

if (emplno LT 900) AND (emplnof LT 4) AND (eduyrs LT 88) AND (brwmny LT 8) AND
(emplno ne .) AND (emplnof ne .) AND (eduyrs ne .) AND (brwmny ne .);
emplnof2=.;
IF (emplnof=1) THEN emplnof2 = 0;
ELSE IF ((emplnof=2) OR (emplnof=3)) THEN emplnof2 = 1;
keep emplno emplnof emplnof2 eduyrs brwmny;
run;

```

Neigiamai binominei regresijai insime tokius regresorius: *brwmny*, *eduyrs*, *emplnof2*.
Logistiniame modelyje apsiribosime vienu regresoriumi – *emplnof2*. Įvykdome:

```

proc genmod data = dse;
class emplnof2 (ref="0");
model emplno=brwmny eduyrs emplnof2 / link=log dist=zinb;
zeromodel emplnof2 ;
store p1;
run;

```

Criteria For Assessing Goodness Of Fit			
Criterion	DF	Value	Value/DF
Deviance		266.0599	
Scaled Deviance		266.0599	
Pearson Chi-Square	60	65.7712	1.0962
Scaled Pearson X2	60	65.7712	1.0962
Log Likelihood		-133.0299	
Full Log Likelihood		-133.0299	
AIC (smaller is better)		280.0599	
AICC (smaller is better)		281.9909	
BIC (smaller is better)		295.3874	

Analysis Of Maximum Likelihood Parameter Estimates								
Parameter		DF	Estimate	Standard Error	Wald 95% Confidence Limits		Wald Chi-Square	Pr > ChiSq
Intercept		1	0.7150	1.8090	-2.8306	4.2605	0.16	0.6927
brwmny		1	-0.8253	0.2681	-1.3509	-0.2998	9.47	0.0021
eduysr		1	0.2412	0.1195	0.0069	0.4755	4.07	0.0436
emplnof2	1	1	2.0803	0.6475	0.8113	3.3493	10.32	0.0013
emplnof2	0	0	0.0000	0.0000	0.0000	0.0000	.	.
Dispersion		1	3.7079	1.2333	1.9321	7.1162		

Note: The negative binomial dispersion parameter was estimated by maximum likelihood.

Analysis Of Maximum Likelihood Zero Inflation Parameter Estimates								
Parameter		DF	Estimate	Standard Error	Wald 95% Confidence Limits		Wald Chi-Square	Pr > ChiSq
Intercept		1	-23.7746	0.8484	-25.4374	-22.1118	785.30	<.0001
emplnof2	1	0	22.9228	0.0000	22.9228	22.9228	.	.
emplnof2	0	0	0.0000	0.0000	0.0000	0.0000	.	.

Visi rezultatai aprašomi ir interpretuojami analogiškai perteklinių nulių Puasono regresijos modeliui. Lentelėje „**Criteria For Assessing Goodness Of Fit**“ suderinamumo matai ir statistikos. SAS spausdina keliolika informacinių indeksų (AIC, BIC ir t. t.) ir suderinamumo statistikų. Kuo mažesnis informacinis indeksas, tuo tinkamesnis modelis. Kaip ir perteklinių nulių Puasono regresijos atveju, norėdami įvertinti modelio tikimą (palyginti su atitinkamu nuliniu modeliu), chi2 statistiką ir p eikšmę turime apskaičiuoti patys. Čia (trumpumo dėlei) nededame procedūrų ir sakinių aprašymo (scenarijai bus skyrelio pabaigoje). Įdedame tik rezultatų lentelę:

Obs	l1	l2	chi2	pvalue
1	-133.030	-145.841	25.6218	<.0001

Sprendžiant iš Voldo kriterijaus, visi regresoriai neigiamos binominės regresijos modelyje yra statistiškai reikšmingi (visos $p < 0,05$, išskyrus konstantos p reikšmę).

Logistinės regresijos modelis blogai atskiria nulinius nuo likusiųjų, nes regresorius *emplnof2* nėra statistiškai reikšmingas ($p = 0,987 > 0,05$). Neigiamos binominės regresijos parametras *dispersion* = 3,708. Jo 95 % pasikliautinis intervalas „neuždengia“ 0, todėl galima

tvirtinti, kad jis statistiškai reikšmingai skiriasi nuo 0. Vadinasi, tradicinė Puasono regresija šiems duomenims netinka.

Kaip jau rašėme, Vuongo kriterijui SAS sistemoje reikia atsisiųsti `vuong.sas` programėlę iš SAS korporacijos svetainės. Tada įvykdome:

```
proc genmod data = dse;
class emplnof2 (ref="0");
model emplno=brwmny eduyrs emplnof2 / link=log dist=zinb;
zeromodel emplnof2 ;
output out=outzinb pred=predzinb pzero=p0;
run;
proc genmod data = outzinb order=data;
class emplnof2 (ref="0");
model emplno=brwmny eduyrs emplnof2 /dist=nb;
output out=out pred=prednb;
run;
%include "C:/workSAS/vuong.sas"; /* nurodoma failo vieta */
%vuong(data=out, response=emplno,
model1=zinb, p1=predzinb, dist1=zinb, scale1=3.7079, pzero1=p0,
model2=nb, p2=prednb, dist2=nb, scale2=5.3273,
nparm1=6, nparm2=4)
```

Pastaba. Scale parametrų reikšmes nurašome iš abiejų regresijų protokolų.

Vuong Test

H0: models are equally close to the true model

Ha: one of the models is closer to the true model

Vuong Statistic	Z	Pr> Z	Preferred Model
Unadjusted	0.6908	0.4897	zinb
Akaike Adjusted	-0.8069	0.4197	nb
Schwarz Adjusted	-2.4467	0.0144	nb

Vuongo testo $p = 0,4897 > 0,05$. Negalime atmesti hipotezės, kad perteklinių nulių modelis nesiskiria nuo įprasto neigiamos binominės regresijos modelio.

Galutinė išvada tokia – rezultatai nerodo, kad perteklinių nulių neigiamos binominės regresijos modelis būtų geresnis už standartinį neigiamos binominės regresijos modelį. Tai gana pamokoma išvada – nereikia tikėtis, kad kuo modelis sudėtingesnis, tuo daugiau šansų, jog jis tiks.

Prognozavimas yra analogiškas ankstesniems skyreliams.

9.2.4. Perteklinių nulių neigiama binominė regresija su R

Atliksime tą pačią analizę kaip ir nagrinėdami neigiamą binominę regresiją. Tiriame Švedijos duomenis **ESS4SE**. Modeliuojame *emplno* (turimų darbuotojų skaičius) priklausomybę nuo regresorių

- *brwmny* (ar sunku pasiskolinti pinigų išgyvenimui, 1 – labai sunku, ..., 5 – labai lengva),
- *eduyrs* (metų, kiek buvo mokytasi, skaičius),
- *emplnof2* (tėvo turimų darbuotojų skaičius, 0 – neturi, 1 – turi).

Įvykdome:

```
dta<-read.csv2("ESS4SE.csv",na.strings = "NA",stringsAsFactors=FALSE)

library(car)

dta$emplnof2 <- recode(dta$emplnof,"1=0;c(2,3)=1")

ldta<-subset(dta,emplno<900 & emplnof<4 & eduyrs<88 & brwmny<8,
select=c(emplno,brwmny,eduyrs,emplnof2,gndr))
```

Perteklinių nulių neigiamai binominei regresijai imsime tokius regresorius: *brwmny*, *eduyrs*, *emplnof2*. Logistiniame modelyje apsiribosime vienu regresoriumi – *emplnof2*. Įvykdome:

```
library(pscl)

summary(m1 <- zeroinfl(emplno~brwmny+eduyrs+factor(emplnof2) | emplnof2, data =
ldta,dist="negbin"))

mnull <- update(m1, . ~ 1)

lr=2 * (logLik(m1) - logLik(mnull))

pvalue=pchisq(2 * (logLik(m1) - logLik(mnull)), df = 3, lower.tail = FALSE)

cat('LR chi2(3)',lr,'\n','Prob>chi2',pvalue,'\n')

# Lyginimas neigiamos binominės regresijos modeliu
```

```
summary(m2 <- glm.nb(emplno~brwmny+eduyrs+factor(emplnof2), data = ldta))
vuong(m1, m2)
AIC(m1)
```

Call:

```
zeroinfl(formula = emplno ~ brwmny + eduyrs + factor(emplnof2) | factor(emplnof2), data = ldta, dist = "negbin")
```

Pearson residuals:

```
Min 1Q Median 3Q Max
-0.5166 -0.4196 -0.4046 -0.1041 4.3582
```

Count model coefficients (negbin with log link):

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	0.7052	1.8092	0.390	0.69668
brwmny	-0.8245	0.2681	-3.075	0.00211 **
eduyrs	0.2417	0.1196	2.021	0.04323 *
factor(emplnof2)1	2.0793	0.6478	3.210	0.00133 **
Log(theta)	-1.3109	0.3327	-3.940	8.15e-05 ***

Zero-inflation model coefficients (binomial with logit link):

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-10.641	126.059	-0.084	0.933
factor(emplnof2)1	9.787	126.057	0.078	0.938

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Theta = 0.2696

Number of iterations in BFGS optimization: 31

Log-likelihood: -133 on 7 Df

```
LR chi2(3) 25.62196
Prob>chi2 1.144361e-05
```

Vuong Non-Nested Hypothesis Test-Statistic: 0.6862813
(test-statistic is asymptotically distributed N(0,1) under the
null that the models are indistinguishable)
in this case:
model1 > model2, with p-value 0.2462679

```
> AIC(m1)
```

```
[1] 280.06>
```

Visi rezultatai aprašomi ir interpretuojami analogiškai perteklinių nulių Puasono regresijos modeliui. Statistiškai reikšmingą bendrąjį modelio tikimą rodo maža tikėtinumų santykio kriterijaus p reikšmė (**Prob>chi2** = 1,1e-05 < 0,05). Sprendžiant iš Voldo kriterijų, visi regresoriai neigiamos binominės regresijos modelyje yra statistiškai reikšmingi (visos p < 0,05, išskyrus konstantos p reikšmę). Informacinis indeksas AIC mažas, tačiau pasikartosime sakydami, kad jis yra informatyvus tik lyginant skirtingus modelius (tiems patiems duomenims).

Logistinės regresijos modelis blogai atskiria nulinukus nuo likusiųjų, nes regresorius *emplnof2* nėra statistiškai reikšmingas ($p = 0,938 > 0,05$). Neigiamos binominės regresijos parametras $\theta = 0,2696$ (primename, kad kitų statistikos programų protokoluose yra $\alpha = 1/\theta = 3,708$) statistiškai reikšmingas ($p = 0,00$). Todėl tradicinė Puasono regresija šiems duomenims netinka.

Vuongo kriterijaus $p = 0,25 > 0,05$. Negalime atmesti hipotezės, kad perteklinių nulių modelis nesiskiria nuo įprasto neigiamos binominės regresijos modelio.

Galutinė išvada tokia – rezultatai nerodo, kad perteklinių nulių neigiamos binominės regresijos modelis būtų geresnis už standartinį neigiamos binominės regresijos modelį. Tai gana pamokoma išvada – nereikia tikėtis, kad kuo modelis sudėtingesnis, tuo daugiau šansų, jog jis tiks.

Prognozuojama analogiškai ankstesniems skyreliams.

9.3. Skaičiuojamų regresijos modelių palyginimas su STATA

Visi skaičiuojamieji regresijos modeliai (Puasono, perteklinių nulių Puasono neigiamos binominės ir perteklinių nulių neigiamos binominės regresijos) turi labai nedaug tikimo duomenims rodiklių. STATA programoje yra numatyta galimybė palyginti skirtingus modelius. Tam skirta komanda *countfit*.

Jau ne kartą modeliavome respondento darbuotojų skaičių (*emplno*), atsižvelgdami į metų, kiek jis mokėsi, skaičių (*eduyrs*), požiūrį į paskolas (*brwmny*, ar sunku pasiskolinti pinigų išgyvenimui, 1 – labai sunku, ..., 5 – labai lengva) ir tėvo turimų darbuotojų skaičių (*emplnof2* (tėvo turimų darbuotojų skaičius, 0 – neturi, 1 – turi). Modelis: $emplno = f(eduyrs, brwmny, brwmny)$.


Kokius modelius norime lyginti, nurodome STATA *countfit* komandoje užrašydami:

- *prn* – Puasono regresijai,
- *nbreg* – neigiamai binominei regresijai,
- *zip* – perteklinių nulių Puasono regresijai,
- *zinb* – perteklinių nulių neigiamai binominei regresijai.

Atitinkamuose skyreliuose įsitikinome, kad šiems duomenims tinka ir perteklinių nulių Puasono regresijos ir neigiamos binominės regresijos modeliai. Palyginsime tuos du modelius:

```
countfit emplno eduyrs brwmny emplnof2 , inflate( emplnof2) zip nbreg
```

Visų pirma aptarsime liekamųjų paklaidų grafikus. Kuo liekamosios paklaidos arčiau nulio (x ašies), tuo modelis geresnis. Matome, kad abudu modeliai šiuo atžvilgiu elgiasi panašiai. Nulius ir vienetus truputį geriau modeliuoja neigiama binominė regresija (NBRM).



Rezultatų išsklotinės pradžioje pateikiama abiejų modelių koeficientų eksponentės ($\exp\{b_j\}$) ir jų t reikšmės. Pavyzdžiui, regresoriaus *eduyrs* toks eksponentinis koeficientas neigiamos binominės regresijos modelyje yra 1,332, o perteklinių nulių Puasono modelyje (ZIP) 1,203. Kai kurie koeficientai skiriasi radikaliai (5,1 ir 55,6). Kai kurios Voldo kriterijaus t reikšmės taip pat skiriasi keletą kartų (-2,72 ir -34,81).

NBRM: Predicted and actual probabilities				
Count	Actual	Predicted	Diff	Pearson
0	0.545	0.572	0.027	0.084
1	0.121	0.095	0.026	0.480
2	0.106	0.051	0.055	3.966
3	0.045	0.034	0.012	0.261
4	0.015	0.025	0.010	0.255
5	0.030	0.020	0.011	0.394
6	0.015	0.016	0.001	0.002
7	0.000	0.013	0.013	0.872
8	0.000	0.011	0.011	0.743
9	0.000	0.010	0.010	0.644
Sum	0.879	0.847	0.176	7.702
ZIP: Predicted and actual probabilities				
Count	Actual	Predicted	Diff	Pearson
0	0.545	0.606	0.061	0.403
1	0.121	0.079	0.042	1.455
2	0.106	0.037	0.069	8.639
3	0.045	0.025	0.021	1.151
4	0.015	0.020	0.005	0.091
5	0.030	0.018	0.012	0.539
6	0.015	0.016	0.001	0.003
7	0.000	0.014	0.014	0.914
8	0.000	0.012	0.012	0.793
9	0.000	0.011	0.011	0.703
Sum	0.879	0.838	0.248	14.691

Dar vienoje lentelėje išrašytos stebimos 0–9 tikimybės (t. y. kurių stebinių dalį sudarė atitinkamos reikšmės) ir prognozuojamos, taikant vieną ir kitą metodus (regresorius, laikant lygius vidutinėms jų reikšmėms). Kuo mažiau skiriasi tikimybės, tuo modelis geresnis. Vis dėlto įžiūrėti tuos skirtumus sudėtinga, todėl jų absoliutūs didumai pateikti stulpelyje **|Diff|**. Stulpelyje **Pearson** išrašyta tų skirtumų indėliai į Pirsono statistikos reikšmę. Atmetant detales, galima pasakyti, kad kuo ši reikšmė didesnė, tuo blogiau tinka. Užmetę akį į paskutinius du stulpelius, nustatome, kad neigiama binominė regresija tinka geriau už perteklinių nulių Puasono regresiją.

Paskutinėje lentelėje pateikiama santrauka apie modelius, atsižvelgiant į informacinius indeksus. Matome, kad neigiama binominė regresija tinka daug geriau nei perteklinių nulių Puasono regresija.

NBRM	BIC=	12.336	AIC=	4.211	Prefer	Over	Evidence
vs ZIP	BIC=	946.260	dif=	-933.924	NBRM	ZIP	Very strong
	AIC=	18.328	dif=	-14.117	NBRM	ZIP	
ZIP	BIC=	946.260	AIC=	18.328	Prefer	Over	Evidence

Pastabos. Kartojant *countfit* komandą su kitais modeliais, komandos gale reikia pridėti *replace*. Priešingu atveju gausime pranešimą apie klaidą. Jeigu nenurodome, kuriuos modelius norime lyginti, palyginami visi keturi modeliai.

Galutinė lyginamosios analizės išvada – neigiamos binominės regresijos modelis tiko duomenims daug geriau nei perteklinių nulių Puasono modelis.

9.4. Benulė Puasono regresija

9.4.1. Modelio paskirtis

Būna, kad kintamasis pagal savo prigimtį negali įgyti nulių, nors visais kitais atžvilgiais labai panašus į Puasono (ir visai nepanašus į normalųjį) kintamąjį. Pavyzdžiui, minimalus praleistų ligoninėje dienų skaičius yra vienetasis. Minimalus namų ūkio narių skaičius – vienas. Puasono regresijos modelyje *visada* tariama, kad gali būti ir nulinės reikšmės ir surandamos jų įgijimo tikimybės. Todėl tokiems duomenims tiesiai taikyti Puasono regresijos modelio negalima. Vienas iš variantų – transformuoti duomenis, pavyzdžiui, atimant vienetą. Būtent taip transformavome namų ūkio narių skaičių į kitų namų ūkio subjektų skaičių ($numbhh = hhmmb - 1$). Alternatyva – benulis Puasono regresijos modelis.

Pastumtasis Puasono modelis (tiksliau Puasono modelis pastumtiems duomenims) skiriasi nuo benulio Puasono modelio. Pastumtojo Puasono modelio atveju, Puasono kintamojo nulinio tikimybė priskiriama vienetui, vienetui priskiriama dvejetui ir t. t. Benulio Puasono modelio idėja yra kitokia, tikimybės laikome sąlyginėmis Puasono tikimybėmis. Maždaug taip – stebime Puasono kintamąjį, tik jis nulių neįgyja. Tikimybė tokiam Puasono dydžiui įgyti reikšmę k yra $P(Y = k)/(1 - e^{-\lambda})$.

Svarbiausia benulio Puasono regresijos modelio bėda – minimalus statistinių suderinamumo rodiklių rinkinys. Labai sunku nuspręsti, ar šis modelis tinka duomenims. Faktiškai apsiribojama:

- Tikėtinumų santykio kriterijumi (gerai, kai $p < 0,05$).
- Voldo kriterijumi patikrinama, ar visi regresoriai statistiškai reikšmingi.
- Palyginti su pastumtuoju Puasono regresijos modeliu, naudojami informaciniai indeksai AIC, BIC.

Analogiškai kaip benulį Puasono regresijos modelį galima iširti ir benulį neigiamos binominės regresijos modelį.

9.4.2. Benulė Puasono regresija su STATA

Pakartosime benulę Puasono regresinę analizę duomenims, kuriems jau taikėme Puasono regresiją. Tiriamo 2008 metų Prancūzijos duomenis **ESS4FR**. Tyrime naudosime tokius kintamuosius: *agea* – respondento amžius, *hhmmb* – namų ūkio nuolatinių narių skaičius, *cldcrsv* – paramos vaiko priežiūrai teikimas tėvams, turintiems teisę ją gauti (0 – itin blogas,..., 10 – labai geras), *imptrad* – svarbu laikytis tradicijų ir papročių (1 – visai kaip aš,..., 6 – absoliučiai ne taip kaip aš), *eduyrs* – metų, kiek buvo mokytasi, skaičius. Tiriamo stipriai tradicijų besilaikančius ($imptrad \leq 2$) aukštojo mokslo neragavusius ($eduyrs \leq 10$) respondentus(es). Su *tab* komanda peržiūrime kintamųjų reikšmes ir išmetame tas, kurios SPSS programoje buvo praleistų reikšmių kodai. Benulė Puasono regresija atliekama taip:

```
ztp hhmmb agea cldcrsv
```

Zero-truncated Poisson regression

Log likelihood = -307.33139

Number of obs = 254
LR chi2(2) = 109.89
Prob > chi2 = 0.0000
Pseudo R2 = 0.1517

	hhmmb	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
	agea	-.0292351	.0031247	-9.36	0.000	-.0353594	-.0231109
	cldcrsv	.0829182	.0238419	3.48	0.001	.036189	.1296475
	_cons	1.737643	.2178941	7.97	0.000	1.310579	2.164708

Tikėtinumų santykio chi kvadrato statistika pakankamai didelė (109,89), $p = 0,00 < 0,05$. Visi regresoriai statistiškai reikšmingi (visiems jiems Voldo kriterijaus $p < 0,05$). Galima su *pvalue* surasti pirmųjų dešimties reikšmių skaičiaus tikimybių prognozes:

```
Prvalue
```

	Uncond	Cond
Rate:	1.39	1.851
Pr(y=0 x):	0.2491	.
Pr(y=1 x):	0.3462	0.4611
Pr(y=2 x):	0.2406	0.3204
Pr(y=3 x):	0.1115	0.1485
Pr(y=4 x):	0.0387	0.0516
Pr(y=5 x):	0.0108	0.0143
Pr(y=6 x):	0.0025	0.0033
Pr(y=7 x):	0.0005	0.0007
Pr(y=8 x):	0.0001	0.0001
Pr(y=9 x):	0.0000	0.0000
agea		cldcrsv
x= 63.102362	5.2637795	

Tikimybės buvo apskaičiuotos vidutinėms regresorių *agea* ir *cldcrsv* reikšmėms. Šios reikšmės parašytos lentelės apačioje (*agea* = 63,1; *cldcrsv* = 5,26). Pateiktos dviejų rūšių tikimybės. Stulpelyje **Uncond** yra tikimybės to Puasono skirstinio, kurį stebime su visomis nulinėmis, o stulpelyje **Cond** yra to paties Puasono kintamojo tikimybės, *kai žinome*, kad nulių imtyje nėra.

Norėdami sužinoti, kuris modelis – benulis ar pastumtasis – geriau tinka duomenims, surandame šio modelio informacinį indeksą AIC. Įvykdome

Fitstat			
BIC:	-775.208	BIC':	-98.820
BIC used by Stata:	631.275	AIC used by Stata:	620.663

Analogišką statistiką surandame Puasono regresijos modeliui su priklausomu kintamuoju *numbhh* = *hhmb* – 1. Gauname:

BIC:	-787.791	BIC':	-101.844
BIC used by Stata:	618.692	AIC used by Stata:	608.080

Matome, kad AIC skiriasi nedaug (AIC = 620,66 ir AIC = 608,08), nors standartinei Puasono regresijai šis rodiklis ir mažesnis. Griežtai kalbant, toks AIC lyginimas skirtingais būdais apskaičiuotiems modeliams nėra iki galo korektiškas. Vis dėlto jis duoda bendrą supratimą apie modelių gerumą. Reikia turėti omenyje, kad nedidelis AIC skirtumas dar neleidžia teigti, kad kažkuris modelis yra geresnis. Koks AIC skirtumas jau yra pakankamai didelis, kad tą galėtume teigti? Šiuo klausimu nėra kažkokios nusistovėjusios bendros nuomonės. Dažnai siūloma svarbiu laikyti AIC skirtumą, viršijantį 10. Bet, žinoma, nėra privaloma. Tarkime, nagrinėjamu atveju skirtumas yra maždaug 12. Dešimtį viršija visai nedaug. Todėl, mūsų nuomone, prioritetas turėtų būti teikiamas įprastai Puasono regresijai (po kintamojo „pastūmimo“, kad įgytų nulį), nes tiesiog šis modelis turi daugiau tinkamumo charakteristikų (pvz., deviaciją). Beje, nebūtina atsižvelgti būtent į AIC. Galima naudoti ir BIC. Kai kurie statistikai labiau vertina būtent šį indeksą. Išvados daromos kaip ir AIC atveju. Matome, kad jos nepasikeičia.

9.4.3. Benulė Puasono regresija su SAS

Pakartosime benulę Puasono regresinę analizę duomenims, kuriems jau taikėme Puasono regresiją. Tiriame 2008 metų Prancūzijos duomenis **ESS4FR**. Tyrime naudosisime tokius kintamuosius: *agea* – respondento amžius, *hhmb* – namų ūkio nuolatinių narių skaičius, *cldcrsv* – paramos vaiko priežiūrai teikimas tėvams, turintiems teisę ją gauti (0 – itin blogas, ..., 10 – labai geras), *imptrad* –

svarbu laikytis tradicijų ir papročių (1 – visai kaip aš,..., 6 – absoliučiai ne taip kaip aš), *eduyrs* – metų, kiek buvo mokytasi, skaičius. Tiriamo stipriai tradicijų besilaikančius (*imptrad* ≤ 2) aukštojo mokslo neragavusius (*eduyrs* ≤ 10) respondentus(es):

```
data Dse;
set rgr.ESS4FR_s;
if (imptrad LE 2) AND (eduyrs LE 10) AND (cldcrsv LT 88) AND (imptrad NE .) AND (eduyrs
NE .) AND (cldcrsv NE .); /* 254 stebejimai */
run;
```

Benulė Puasono regresija atliekama taip:

```
/* Tik SAS 9.3 versija ir pirmiau */
proc fmm data=Dse;
    model hhmmb = agea cldcrsv / dist = truncpoisson;
run;
```

Fit Statistics	
-2 Log Likelihood	614.7
AIC (smaller is better)	620.7
AICC (smaller is better)	620.8
BIC (smaller is better)	631.3
Pearson Statistic	160.3

Parameter Estimates for 'Truncated Poisson' Model				
Effect	Estimate	Standard Error	z Value	Pr > z
Intercept	1.7376	0.2179	7.97	<.0001
agea	-0.02924	0.003125	-9.36	<.0001
cldcrsv	0.08292	0.02384	3.48	0.0005

SAS spausdina keliolika informacinių indeksų (AIC, BIC ir t. t.) ir suderinamumo statistikų. Kuo mažesnis informacinis indeksas, tuo tinkamesnis modelis. Visi regresoriai statistiškai reikšmingi (visiems jiems Voldo testo $p < 0,05$).

Norėdami sužinoti, kuris modelis – benulis ar pastumtasis – geriau tinka duomenims, pakartokime analizę ir palyginkime informacinius indeksus. Įvykdome:

```

OPTIONS nofmterr;
data Dse;
set rgr.ESS4FR_s;
if (imptrad LE 2) AND (eduyrs LE 10) AND (cldcrsv LT 88) AND (imptrad NE .) AND (eduyrs
NE .) AND (cldcrsv NE .);
run;
proc fmm data=Dse;
    model hhmmb = agea cldcrsv / dist = truncpoisson;
run;
data new;
set dse;
numbhh1=hhmmb - 1;
run;
proc genmod data = new;
    model numbhh1 = agea cldcrsv / dist=poisson;
run;

```

The FMM Procedure

Fit Statistics	
-2 Log Likelihood	614.7
AIC (smaller is better)	620.7
AICC (smaller is better)	620.8
BIC (smaller is better)	631.3
Pearson Statistic	160.3

Criteria For Assessing Goodness Of Fit			
Criterion	DF	Value	Value/DF
Deviance	251	230.6347	0.9189
Scaled Deviance	251	230.6347	0.9189
Pearson Chi-Square	251	188.3136	0.7503
Scaled Pearson X2	251	188.3136	0.7503
Log Likelihood		-197.2616	
Full Log Likelihood		-301.0401	
AIC (smaller is better)		608.0803	
AICC (smaller is better)		608.1763	
BIC (smaller is better)		618.6923	

Matome, kad AIC skiriasi nedaug ($AIC = 620,7$ ir $AIC = 608,08$), nors standartinei Puasono regresijai šis rodiklis ir mažesnis. Griežtai kalbant, toks AIC lyginimas skirtingais būdais apskaičiuotiems modeliams nėra iki galo korektiškas. Vis dėlto jis duoda bendrą supratimą apie modelių gerumą. Reikia turėti omenyje, kad nedidelis AIC skirtumas dar neleidžia teigti, jog kažkuris modelis yra geresnis. Koks AIC skirtumas jau yra pakankamai didelis, kad tą galėtume teigti? Šiuo klausimu nėra kažkokios nusistovėjusios bendros nuomonės. Dažnai siūloma svarbiu laikyti AIC skirtumą, viršijantį 10. Bet, žinoma, nėra privaloma. Tarkime, nagrinėjamu atveju skirtumas yra maždaug 12. Dešimtį viršija visai nedaug. Todėl, mūsų nuomone, prioritetas turėtų būti teikiamas įprastai Puasono regresijai (po kintamojo „pastūmimo“, kad įgytų nulį), nes tiesiog šis modelis turi daugiau tinkamumo charakteristikų (pvz., deviaciją). Beje, nebūtina atsižvelgti būtent į AIC. Galima naudoti ir BIC. Kai kurie statistikai labiau vertina būtent šį indeksą. Išvados daromos kaip ir AIC atveju. Matome, kad jos nepasikeičia.

Taikant SAS programą **perteklinių nulių Puasono** regresinei analizei ir **perteklinių nulių neigiamai binominei** regresinei analizei yra naudojama **proc genmod** procedūra. Šios procedūros sintaksė atrodo taip:

```
PROC GENMOD <options> ;
ASSESS | ASSESSMENT VAR=(effect) | LINK </ options> ;
BAYES <options> ;
BY variables ;
CLASS variable <(options)><variable <(options)>> </ options> ;
CONTRAST 'label' contrast-specification </ options> ;
DEVIANCE variable = expression ;
EFFECTPLOT <plot-type <(plot-definition-options)>> </ options> ;
ESTIMATE 'label' effect values <,...effect values> </ options> ;
EXACT <'label'> <INTERCEPT> <effects> </ options> ;
EXACTOPTIONS options ;
FREQ | FREQUENCY variable ;
FWDLINK variable = expression ;
INVLINK variable = expression ;
LSMEANS <model-effects> </ options> ;
LSMESTIMATE model-effect <'label'> values <divisor=> <,...<'label'> values
<divisor=>> </ options> ;
```

```

MODEL response = <effects > </ options> ;
OUTPUT <OUT=SAS-data-set> <keyword=name...keyword=name> ;
Programming statements ;
REPEATED SUBJECT=subject-effect </ options> ;
SLICE model-effect </ options> ;
STORE <OUT=>item-store-name </ LABEL='label'> ;
STRATA variable <(option)> <variable <(option)>> </ options> ;
WEIGHT | SCWGT variable ;
VARIANCE variable = expression ;
ZEROMODEL <effects > </ options> ;

```

Jei norime prognozuoti, tada atitinkamoms analizėms geriau naudoti **proc countreg** procedūrą, kurios sintaksė atrodo taip:

```

PROC COUNTREG options ;
BOUNDS bound1 < , bound2 ...> ;
BY variables ;
CLASS variables ;
FREQ variable ;
INIT initvalue1 < , initvalue2 ...> ;
MODEL dependent variable = regressors / options ;
NLOPTIONS options ;
OUTPUT options ;
RESTRICT restriction1 < , restriction2 ...> ;
WEIGHT variable ;
ZEROMODEL dependent variable zero-inflated regressors / options ;

```

Taikant SAS programą benulei Puasono regresinei analizei, naudojama **proc fmm** procedūra. Šios procedūros sintaksė atrodo taip:

```

PROC FMM <options> ;
BAYES bayes-options ;
BY variables ;
CLASS variables </ TRUNCATE> ;

```

```

FREQ variable ;
ID variables ;
MODEL response<(response-options)> = <effects> </ model-options> ;
MODEL events/trials = <effects> </ model-options> ;
MODEL + <effects> </ model-options> ;
OUTPUT <OUT=SAS-data-set>
<keyword<(keyword-options)> <=name>>...
<keyword<(keyword-options)> <=name>> </ options> ;
PERFORMANCE performance-options ;
PROBMODEL <effects> </ probmodel-options> ;
RESTRICT <'label'> constraint-specification <, ..., constraint-specification>
<operator <value>> </ option> ;
WEIGHT variable ;

```

Scenarijus :

```

/* perteklinių nulių Puasono */
OPTIONS nofmterr;
OPTIONS nofmterr;
data Dse;
set rgr.ESS4SE;
if (emplno LT 900) AND (emplnof LT 4) AND (eduyrs LT 88) AND (brwmny LT 8)
AND (emplno ne .) AND (emplnof ne .) AND (eduyrs ne .) AND (brwmny ne .);
emplnof2=.;
IF (emplnof=1) THEN emplnof2 = 0;
ELSE IF ((emplnof=2) OR (emplnof=3)) THEN emplnof2 = 1;
keep emplno emplnof emplnof2 eduyrs brwmny;
run;
/*=====*/
/* Perteklinių nulių Puasono */
/*=====*/
proc genmod data = dse;
class emplnof2 (ref="0");
model emplno=brwmny eduyrs emplnof2 / link=log dist=zip;

```

```

zeromodel emplnof2 /link = logit ;
store p1;
run;
/* Pasirinkto modelio analizė */
proc genmod data = dse;
class emplnof2 (ref="0");
model emplno=brwmny eduyrs emplnof2 / link=log dist=zip;
zeromodel emplnof2 /link = logit ;
ods output Modelfit=fit1;
run;

/* logtikėtinumo f-jos reišmės ištraukimas */
data fit1;
set fit1(where=(criterion="Full Log Likelihood"));
l1=value;
run;

/* nulinio modelio analizė */
proc genmod data= dse;
model emplno= /dist=zip;
zeromodel / link = logit ;
ods output Modelfit=fit2;
RUN;

/* logtikėtinumo f-jos reišmės ištraukimas */
data fit2;
set fit2(where=(criterion="Full Log Likelihood"));
l2=value;
run;

/* ch2 statistikos ir p reikšmės skaičiavimas */

data fit;

```

```

merge fit1 fit2;
by criterion;
chi2=2*(l1-l2);
pvalue=1-probchi(chi2,3);
run;

proc print data=fit;
var l1 l2 chi2 pvalue;
format pvalue pvalue6.4;
run;

%include "C:/Users/GM/Documents/workSAS/vuong.sas";
proc genmod data = dse;
class emplnof2 (ref="0");
model emplno=brwmny eduyrs emplnof2 / link=log dist=zip;
zeromodel emplnof2 /link = logit ;
output out=outzinb pred=predzip pzero=p0;
run;
proc genmod data = outzinb order=data;
class emplnof2 (ref="0");
model emplno=brwmny eduyrs emplnof2 /DIST=poi;
output out=out pred=predpoi;
run;
%vuong(data=out, response=emplno,
model1=zip, p1=predzip, dist1=zip, scale1=1.00, pzero1=p0,
model2=poi, p2=predpoi, dist2=poi, scale2=1.00,
nparm1=4, nparm2=3)
/* eksponentes */
ods output ParameterEstimates = est;
proc plm source = p1;
show parameters;
run;
data est_exp;
set est;

```



```

    expb = exp(estimate);
data new;
    set dse;
if emplnof2=1 then emplnof2=0;
else if (emplnof2=0) then emplnof2=1;
run;

proc countreg data = new method = qn;
class emplnof2;
    model emplno=brwmny eduyrs emplnof2 / dist=zip;
zeromodel emplno ~ emplnof2;
output out=predpoi probcount(0 to 10);
    run;
data predpoi1;
set predpoi;
if emplnof2=0;
run;
proc means mean data=predpoi1;
    var p_0-p_10 eduyrs brwmny;
run;
/*=====*/
/* Perteklinių nulių NB */
/*=====*/
OPTIONS nofmterr;
data Dse;
set rgr.ESS4SE;
if (emplno LT 900) AND (emplnof LT 4) AND (eduyrs LT 88) AND (brwmny LT 8)
AND (emplno ne .) AND (emplnof ne .) AND (eduyrs ne .) AND (brwmny ne .);
emplnof2=.;
IF (emplnof=1) THEN emplnof2 = 0;
ELSE IF ((emplnof=2) OR (emplnof=3)) THEN emplnof2 = 1;
keep emplno emplnof emplnof2 eduyrs brwmny;
run;
proc genmod data = dse;

```

```

class emplnof2 (ref="0");
  model emplno=brwmny eduyrs emplnof2 / link=log dist=zinb;
zeromodel emplnof2 ;
  output out=outzinb pred=predzinb pzero=p0;
run;

proc genmod data = outzinb order=data;
class emplnof2 (ref="0");
  model emplno=brwmny eduyrs emplnof2 /dist=nb;
  output out=out pred=prednb;
run;

%include "C:/workSAS/vuong.sas"; /* nurodoma failo vieta */
%vuong(data=out, response=emplno,
  model1=zinb, p1=predzinb, dist1=zinb, scale1=3.7079, pzero1=p0,
  model2=nb, p2=prednb, dist2=nb, scale2=5.3273,
  nparm1=6, nparm2=4)
/*=====*/
/* Benule Puasono regresija */
/*=====*/

data Dse;
set rgr.ESS4FR_s;
if (imptrad LE 2) AND (eduyrs LE 10) AND (cldcrsv LT 88) AND (imptrad NE .) AND
(eduyrs NE .) AND (cldcrsv NE .); /* 254 stebejimai */
run;

/* Tik SAS 9.3 versija ir pirmiau */
proc fmm data=Dse;
  model hhmmb = agea cldcrsv / dist = truncpoisson;
run;
OPTIONS nofmterr;
data Dse;
set rgr.ESS4FR_s;
if (imptrad LE 2) AND (eduyrs LE 10) AND (cldcrsv LT 88) AND (imptrad NE .) AND
(eduyrs NE .) AND (cldcrsv NE .);
run;

```

```

proc fmm data=Dse;
    model hhmmb = agea cldcrsv / dist = truncpoisson;
run;
data new;
set dse;
numbhh1=hhmmb - 1;
run;
proc genmod data = new;
    model numbhh1 = agea cldcrsv / dist=poisson;
run;

```

9.4.4. Benulė Puasono regresija su R

Pakartosime benulę Puasono regresinę analizę duomenims, kuriems jau taikėme Puasono regresiją. Tiriame 2008 metų Prancūzijos duomenis **ESS4FR**. Tyrime naudosime tokius kintamuosius: *agea* – respondento amžius, *hhmmb* – namų ūkio nuolatinių narių skaičius, *cldcrsv* – paramos vaiko priežiūrai teikimas tėvams, turintiems teisę ją gauti (0 – itin blogas,..., 10 – labai geras), *imptrad* – svarbu laikytis tradicijų ir papročių (1 – visai kaip aš,..., 6 – absoliučiai ne taip kaip aš), *eduyrs* – metų, kiek buvo mokytasi, skaičius. Tiriame stipriai tradicijų besilaikančius (*imptrad* ≤ 2) aukštojo mokslo neragavusius (*eduyrs* ≤ 10) respondentus(es).

```

dta<-read.csv2("ESS4FR_s.csv",na.strings = "NA",stringsAsFactors=FALSE)
ldta<-subset(dta,imptrad <=2 & eduyrs <= 10 & cldcrsv < 88,
select=c(hhmmb,cldcrsv,agea))

```

Benulė Puasono regresija atliekama taip:

```

library(VGAM)
m1 <- vglm(hhmmb ~ agea+cldcrsv, family = pospoisson(), data = ldta)
summary(m1)

```

Call:
vglm(formula = hhmmb ~ agea + cldcrsv, family = pospoisson(), data = ldta)

Pearson Residuals:

	Min	1Q	Median	3Q	Max
log(lambda)	-1.64	-0.66319	0.023577	0.56161	3.3421

Coefficients:

	Estimate	Std. Error	z value
(Intercept)	1.737643	0.2178941	7.9747
agea	-0.029235	0.0031247	-9.3562
cldcrsv	0.082918	0.0238419	3.4778

Number of linear predictors: 1

Name of linear predictor: log(lambda)

Dispersion Parameter for pospoisson family: 1

Log-likelihood: -307.3314 on 251 degrees of freedom

Number of iterations: 5

Alternatyva

```
library("countreg")

m <- zerotrunc(hhmmb ~ agea+cldcrsv, data = ldta, dist = "poisson")
summary(m)
mnull <- update(m, . ~ 1)
lr<-2 * (logLik(m) - logLik(mnull))
pvalue<-pchisq(2 * (logLik(m) - logLik(mnull)), df = 3, lower.tail = FALSE)
cat('LR chi2(3)',lr,'\n','Prob>chi2',pvalue,'\n')
```

Call:
zerotrunc(formula = hhmmb ~ agea + cldcrsv, data = ldta, dist = "poisson")

Deviance residuals:

	Min	1Q	Median	3Q	Max
	-2.35338	-0.95646	0.02343	0.51481	2.32798

```

Coefficients (truncated poisson with log link):
              Estimate Std. Error z value Pr(>|z|)
(Intercept)  1.737644  0.217820   7.977 1.49e-15 ***
agea        -0.029235  0.003121  -9.367 < 2e-16 ***
cldcrsv      0.082918  0.023842   3.478 0.000505 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Number of iterations in BFGS optimization: 7
Log-likelihood: -307.3 on 3 Df

```

LR chi2(3) 94.31767

Prob>chi2 2.587909e-20

Tikėtinumų santykio kriterijaus statistika pakankamai didelė 94,32, o p reikšmė (**Prob > ch2**) $< 0,05$. Visi regresoriai statistiškai reikšmingi (visiems jiems Voldo kriterijaus $p < 0,05$). Galima teigti, kad modelis tinkamas duomenims.

Apskaičiuosime prognozę esant vidutinėms agea ir cldcrsv reikšmėms:

```

meanagea<-mean(ldta$agea)
meancldcrsv<-mean(ldta$cldcrsv)
newdata1 <- data.frame(agea=meanagea,cldcrsv = meancldcrsv)
newdata1$phat <- predict(m, newdata1, type = "response")
newdata1

```

```
> newdata1
```

```

  agea cldcrsv  phat
1 63.10236 5.26378 1.851049

```

Norėdami sužinoti, kuris modelis – benulis ar pastumtasis – geriau tinka duomenims, surandame šių modelių informacinį indeksą AIC. Įvykdome

```

m <- zerotrunc(hhmmb ~ agea+cldcrsv, data = ldta, dist = "poisson")
summary(m)
AIC(m)
summary(m1 <- glm(hhmmb-1 ~ agea+cldcrsv, family = "poisson", data = ldta))
AIC(m1)

```

```

> AIC(m)      > AIC(m1)
[1] 620.6628   [1] 608.0803

```

Matome, kad AIC skiriasi nedaug ($AIC = 620,66$ ir $AIC = 608,08$), nors standartinei Puasono regresijai šis rodiklis ir mažesnis. Griežtai kalbant, toks AIC lyginimas skirtingais būdais apskaičiuotiems modeliams nėra iki galo korektiškas. Vis dėlto jis duoda bendrą supratimą apie modelių gerumą. Reikia turėti omenyje, kad nedidelis AIC skirtumas dar neleidžia teigti, kad kažkuris modelis yra geresnis. Koks AIC skirtumas jau yra pakankamai didelis, kad tą galėtume teigti? Šiuo klausimu nėra kažkokios nusistovėjusios bendros nuomonės. Dažnai siūloma svarbiu laikyti AIC skirtumą viršijantį 10. Bet, žinoma, nėra privaloma. Tarkime, mūsų nagrinėjamu atveju skirtumas yra maždaug 12. Dešimtį viršija visai nedaug. Todėl, mūsų nuomone, prioritetas turėtų būti teikiamas įprastai Puasono regresijai (po kintamojo „pastūmimo“, kad įgytų nulį), nes tiesiog šis modelis turi daugiau tinkamumo charakteristikų (pvz., deviaciją).

R programos skaičiuojamosios regresijos komandos. Perteklinių nulių Puasono regresijai ir perteklinių nulių neigiamai binominei regresijai yra naudojama *zeroinfl* funkcija iš *pscl* funkcijų bibliotekos. Benulei Puasono regresijai yra naudojama *zerotrunc* funkcija iš *countreg* funkcijų bibliotekos.

Scenarijai:

```
# Perteklinių nulių Puasono regresija
#
dta<-read.csv2("ESS4SE.csv",na.strings = "NA",stringsAsFactors=FALSE)
library(car)
dta$emplnof2 <- recode(dta$emplnof, "1=0;c(2,3)=1")
ldta<-subset(dta,emplno < 900 & emplnof < 4 & eduyrs < 88 &brwmny <
8,select=c(emplno,brwmny,eduyrs,emplnof2,gndr)) # 281 stebejimai kaip spss
mean(ldta$emplno,na.rm=T)
var(ldta$emplno,na.rm=T)
# arba
library(psych)
describe(ldta$empno)
# modelis
library(pscl)
summary(m1 <- zeroinfl(emplno~brwmny+eduyrs+factor(emplnof2) | emplnof2, data =
```

```

ldta))
AIC(m1)
#
# Kad geriau už nulinį modelį (suderinamumas)
#
mnull <- update(m1, . ~ 1)
lr<-2 * (logLik(m1) - logLik(mnull))
pvalue<-pchisq(2 * (logLik(m1) - logLik(mnull)), df = 3, lower.tail = FALSE)
cat('LR chi2(3)',lr,'\n','Prob>chi2',pvalue,'\n')
#
# Palyginimas Puasono modeliui
#
summary(p1 <- glm(emplno~brwmny+eduyrs+factor(emplnof2), family = poisson, data =
ldta))
vuong(p1, m1)
#
# koeficientai
#
(est <- cbind(Estimate = coef(m1), confint(m1)))
exp(est)
#
# prognozavimas
meanedu<-mean(ldta$eduyrs)
meanbrw<-mean(ldta$brwmny)
newdata1 <- data.frame(eduyrs=meanedu,brwmny = meanbrw,emplnof2 = 1)
newdata1$phat <- predict(m1, newdata1, type = "response")
newdata1
#####
# Perteklinių nulių neigiama binominė regresija
#####
library(pscl)
library(car) # reikalingas rekodavimui

```

```

dta<-read.csv2("ESS4SE.csv",na.strings = "NA",stringsAsFactors=FALSE)
dta$emplnof2 <- recode(dta$emplnof, "1=0;c(2,3)=1")
ldta<-subset(dta,emplno < 900 & emplnof < 4 & eduyrs < 88 &brwmny <
8,select=c(emplno,brwmny,eduyrs,emplnof2)) # 281 stebejimai kaip spss
summary(m1 <- zeroinfl(emplno~brwmny+eduyrs+factor(emplnof2) | emplnof2, data =
ldta,dist="negbin"))
AIC(m1)
# Kad geriau už nulinį modelį
mnull <- update(m1, . ~ 1)
lr<-2 * (logLik(m1) - logLik(mnull))
pvalue<-pchisq(2 * (logLik(m1) - logLik(mnull)), df = 3, lower.tail = FALSE)
cat('LR chi2(3)',lr,'\n','Prob>chi2',pvalue,'\n')
#
# Darom neigamą binominę lyginimui
summary(m2 <- glm.nb(emplno~brwmny+eduyrs+factor(emplnof2), data = ldta))
vuong(m1, m2)
#####
# benulė Puasono regresija
#####
dta<-read.csv2("ESS4FR_s.csv",na.strings = "NA",stringsAsFactors=FALSE)
ldta<-subset(dta,imptrad <= 2 & eduyrs <= 10 & cldcrsv < 88
,select=c(hhmmb,cldcrsv,agea))
#
# reikia nustatyti forge repository
install.packages("countreg", repos="http://R-Forge.R-project.org") # reikia R3 versijos
library("countreg")
dta<-read.csv2("ESS4FR_s.csv",na.strings = "NA",stringsAsFactors=FALSE)
ldta<-subset(dta,imptrad <= 2 & eduyrs <= 10 & cldcrsv < 88
,select=c(hhmmb,cldcrsv,agea))
m <- zero trunc(hhmmb ~ agea+cldcrsv, data = ldta, dist = "poisson")
summary(m)
AIC(m)

```



```

# Modelio tinkamumas
mnull <- update(m, . ~ 1)
lr<-2 * (logLik(m) - logLik(mnull))
pvalue<-pchisq(2 * (logLik(m) - logLik(mnull)), df = 3, lower.tail = FALSE)
cat('LR chi2(3)',lr,'\n','Prob>chi2',pvalue,'\n')
# prognozavimas
#
meanagea<-mean(ldta$agea)
meancldcsv<-mean(ldta$cldcsv)
newdata1 <- data.frame(agea=meanagea,cldcsv = meancldcsv)
newdata1$phat <- predict(m, newdata1, type = "response")
newdata1
#
# lyginimas su paprasta Puasono regresija
#
summary(m1 <- glm(hhmb-1 ~ agea+cldcsv, family = "poisson", data = ldta))
AIC(m1)

```

Uždaviniai

1. Visiems Puasono regresijos ir neigiamos binominės regresijos uždaviniams ir pavyzdžiams pritaikyti perteklinių nulių modelius. Palyginti, kurie modeliai geriausiai tinka duomenims.



Biudžeto išlaidos visada būna perteklinių nulių modelis

10. *PROBIT* REGRESIJA

Tokiu visai nelietuvišku terminu vadinama viena dvinarės logistinės regresijos alternatyva. Ją galima taikyti dvejopai: a) tomis situacijomis, kai taikoma ir logistinė regresija, b) specifiniams dozavimo (dažnių) modeliams nagrinėti. Tipiniai šių dviejų situacijų pavyzdžiai:


- Norime išsiaiškinti, ar respondento lytis ir socialinis statusas daro įtaką jo požiūriui į mirties bausmės panaikinimą.
- Tiriamo, kokį finansiniai stimulai turi poveikį respondentų norui tarnauti profesionalioje kariuomenėje. Kokio dydžio turi būti atlyginimas, kad 30 % abiturientų rinktųsi Karo akademiją?

Abi situacijos aptariamos atskirai.

10.1. *Probit* regresijos modelis

10.1.1. Modelio lygtis

Modeliuojamas *dvireikšmis* kintamasis Y priklauso nuo X, Z, W . Modelio schema:



Kintamasis Y vadinamas *priklausomu* (arba *regresuojamu*) kintamuoju, o kintamieji X, Z, W vadinami *nepriklausomais kintamaisiais* arba *regresoriais*. Tradiciškai manoma, kad Y įgyjamos reikšmės yra **kodai** **0** ir **1**. Ką šie kodai reiškia, priklauso nuo konkretaus tyrimo. Matematinis modelis sudaromas ne pačiam priklausomam kintamajam, o jo tikimybei $P(Y = 0)$:

$$P(Y = 0) = \Phi(C + b_1 X + b_2 Z + b_3 W).$$

Čia $\Phi(\cdot)$ – standartinio normaliojo dydžio pasiskirstymo funkcija. Ekvivalentus modelio užrašas

$$\Phi^{-1}(P(Y = 0)) = C + b_1 X + b_2 Z + b_3 W.$$

Čia $\Phi^{-1}(\cdot)$ – atvirkštinė funkcija, kuri dar vadinama *probit* funkcija. Iš čia ir kilo paties modelio pavadinimas. Koeficientų C, b_1, b_2, b_3 reikšmės nėra žinomos. Jų įverčiai $\hat{C}, \hat{b}_1, \hat{b}_2, \hat{b}_3$ gaunami, naudojant imties duomenis. Atsižvelgdami į koeficientų reikšmes nustatysime, kurie regresoriai

svarbesni. Jeigu koeficientas prie kažkurio regresoriaus teigiamas, šiam regresoriui didėjant, tikimybė Y įgyti nulį (o kokią situaciją ta modelio lygybė $Y = 0$ atitinka, turime žinoti iš sąlygos) didėja. Jeigu koeficientas neigiamas, atitinkamam kintamajam didėjant, tikimybė Y įgyti nulį mažėja (didėja tikimybė, kad Y įgis 1).

Jeigu $b_1 > 0$, X didėjant, didėja ir tikimybė $P(Y = 0)$.

Jeigu $b_1 < 0$, X didėjant, didėja ir tikimybė $P(Y = 1)$.

Priešingai dvinarei logistinei regresijai, jokie galimybių santykiai *probit* regresijoje nėra skaičiuojami. Prognozė, kam bus lygi tikimybė $P(Y = 0)$, atliekama tik konkrečioms X , Z , W reikšmėms. Prognozę lengviausia atlikti dviem etapais. Pirmiausia į formulę

$$z = \hat{C} + \hat{b}_1 X + \hat{b}_2 Z + \hat{b}_3 W$$

įstatome tas konkrečias X , Z ir W reikšmes, kurioms reikia prognozės. Tada tikimybių įverčiai apskaičiuojami pagal formules:

$$\hat{P}(Y = 0) = \Phi(z), \quad \hat{P}(Y = 1) = 1 - \Phi(z).$$

Funkcijos $\Phi(z)$ reikšmių lentelės yra kiekviename statistikos vadovėlyje.

Pastaba. Gali būti ir modelis tikimybei $P(Y = 1)$. Tada visose išvadose reikia sukeisti tikimybes $P(Y = 1)$ ir $P(Y = 0)$ vietomis.

10.1.2. Reikalavimai duomenims

Duomenys turi tenkinti tokius reikalavimus:

- Priklausomas kintamasis Y yra dvireikšmis.* Formaliai kalbant, visi kiti kintamieji gali būti arba intervaliniai, arba dvireikšmiai (įgyti reikšmes 0 arba 1). Geriausia, kai dauguma regresorių yra intervaliniai, o dvireikšmių kintamųjų nedaug. Kai kada nurodoma, kad priklausomas kintamasis *savo prigimtimi* turi būti diskretizuotas normalusis kintamasis.
- Duomenyse negali vyrauti viena iš Y reikšmių.* Dažniausiai reikalaujama, kad tarp stebimų Y reikšmių vienetų (nulių) būtų ne mažiau kaip penktadalis.
- Jeigu modelyje yra daug kategorinių kintamųjų, kiekvienam tų kategorijų deriniui turi būti pakankamai daug respondentų.* Minimalus reikalavimas – bent 5 respondentai.
- Regresoriai neturi labai stipriai koreliuoti (neturi būti regresorių multikolinearumo).*

10.1.3. Modelio tinkamumas

Dozavimo modelių tinkamumo charakteristikas aptarsime atskirai. Bendruoju atveju modelio tiinkamumą duomenims parodo tokie rodikliai:

- 1) *Klasifikacinė lentelė*. Konkretiems stebiniams prognozuojama Y reikšmė ir žiūrima, ar spėjimas sutapo su tikrąja Y reikšme. Kuo daugiau sutapčių, tuo modelis geresnis. Kiekvienos kategorijos stebinių turi būti suklasifikuota daugiau, nei gautume atsitiktinai spėdami.
- 2) *Tikėtinumų santykio kriterijus*. Parodo, ar modelyje yra bent vienas reikalingas regresorius. Jeigu statistikos p reikšmė didesnė už 0,05, regresijos modelio tinkamumas labai abejotinas.
- 3) *Voldo kriterijai regresoriams*. Padeda nuspręsti, ar regresorius šalintinas iš modelio. Jeigu konkretaus kriterijaus p reikšmė $< 0,05$, tariame, kad *regresorius yra statistiškai reikšmingas*, ir dažniausiai jį modelyje paliekame. Jeigu p reikšmė $\geq 0,05$, regresorius yra statistiškai nereikšmingas ir modelyje jis paliekamas tik ypatingais atvejais. Dažniausiai modelio konstanta C paliekama net ir tada, kai ji statistiškai nereikšminga.
- 4) *Determinacijos (pseudo) koeficientai*. Rodo bendrąjį modelio tinkamumą duomenims. Kuo koeficiento reikšmė didesnė, tuo modelis geriau tinka duomenims. Ne itin gerai, kai R^2 yra labai mažas ($R^2 < 0,2$). Determinacijos koeficientų yra net keli ir visi jie yra pseudokoeficientai. Galima naudoti bet kurį. Tiesa, privalu nurodyti tikslų determinacijos koeficiento pavadinimą.
- 5) *Kuko matas*. Parodo, ar duomenų imtyje yra išskirčių. Išskirčiai Kuko matas viršija 1. Skaičiuojamas kiekvienam respondentui. Modelis su išskirtimis – nepatikimas.
- 6) *Deviacija*. *Probit* regresijos modelis yra apibendrintojo tiesinio modelio tam tikras atvejis. Kaip ir kitiems tos rūšies modeliams galima patikrinti, ar deviacijos ir jos laisvės laipsnių santykis yra artimas vienetui. Kuo jis artimesnis, tuo modelis geriau tinka. Vis dėlto *probit* regresijos atveju kur kas patikimesnis modelio gerumo rodiklis yra klasifikacinė lentelė ir tikėtinumų santykio kriterijus.

10.1.4. Bendrosios *probit* regresinės analizės etapai

Išsamios modelio analizės etapai:

- 1) Peržiūrima klasifikacinė lentelė. Tikriname, ar kiekvienai Y kategorijai teisingai klasifikuota bent tiek atvejų, kiek gautume atsitiktinai spėdami.
- 2) Patikriname, ar tikėtinumų santykio kriterijaus p reikšmė $< 0,05$. Jeigu ne – modelis netinkamas.

- 3) Voldo kriterijumi patikriname, ar visi regresoriai statistiškai reikšmingi (visos p reikšmės $< 0,05$). Jeigu ne – modelis taisytinas. Konstantai p reikšmės nežiūrime.
- 4) Patikriname, ar modelyje nėra išskirčių (nėra stebinių, kuriems Kuko matas > 1).
- 5) Žiūrime, ar koeficientų ženklai atitinka spėjamą regresorių įtaką (neįtariame multikolinearumo).
- 6) Pasirinktasis determinacijos pseudokoeficientas yra pakankamai didelis ($> 0,20$).
- 7) Jeigu viskas gerai – modelį aprašome, jei ne – tobuliname.

Gera duomenims tinkamo modelio:

- Tikėtinumų santykio kriterijaus $p < 0,05$.
- Visiems regresoriams Voldo kriterijaus $p < 0,05$.
- Koeficientų ženklai atrodo logiški.
- Teisingai klasifikuojama daug atvejų, kai $Y = 1$ ir kai $Y = 0$.
- Visų duomenų Kuko matai ≤ 1 .
- Pasirinktasis determinacijos koeficientas $\geq 0,20$.

10.1.5. Modelio tobulinimas

Modelio tobulinimas – tai regresorių šalinimas arba jų transformavimas. Transformacija (logaritmavimas ir pan.) retai kada padeda, bet pabandyti visada galima. Modelis tobulinamas, jeigu:

- 1) *Yra statistiškai nereikšmingas regresorius* (jam Voldo kriterijaus $p \geq 0,05$). Regresorius pašalinamas iš modelio ir *probit* regresinė analizė pakartojama be jo. Viskas gerai, jeigu klasifikacinėje lentelėje teisingai klasifikuotų atvejų sumažėjo nedaug. Jeigu teisingai klasifikuotų atvejų sumažėja radikaliai, regresorių grąžiname į modelį. Aprašydami tada konstatuosime, kad „regresorius buvo statistiškai nereikšmingas. Vis dėlto jis paliktas modelyje, nes be jo labai sumažėja teisingų klasifikavimų procentas“.
- 2) *Yra multikolinearumo problema*. Modelyje kai kurių koeficientų ženklai neatitinka sveiko proto (teorijos). Tada patikrinama, ar intervaliniai regresoriai stipriai koreliuoja. Jeigu taip – dalį regresorių pašaliname. Kartais (jeigu toks veiksmas prasmingas) stipriai koreliuojančius regresorius keičiame jų vidurkiu.
- 3) *Yra išskirčių*. Kartais išskirtį galima pašalinti (pavyzdžiui, įtarus vedimo klaidą).

10.1.6. Dozavimo modelis

Vienas iš svarbiausių ir neabejotinai populiariausias *probit* regresijos taikymas yra vadinamasis dozavimo (dažnių) modelis. Kada jis taikomas? Lengviausia tai suprasti, aptariant konkretų pavyzdį. Tarkime, kad reikia nuspręsti, kokios koncentracijos chemikalų tirpalą naudoti, naikinant amarus. Eksperimentas vykdomas taip: amarus suskirstome į grupes, kurias apipurškiame skirtingos koncentracijos tirpalu. Žinome, kiek kurioje grupėje buvo amarų ir kokios koncentracijos tirpalu jie buvo apipurkšti. Suskaičiuojame, kiek amarų nugaišo. Norime sužinoti, kaip amaro nugaišimo tikimybė priklauso nuo tirpalo koncentracijos. Be to, dažnai reikia atsakyti į klausimą, kokios koncentracijos tirpalo reikia, jeigu norime išnaikinti 90 % ar 80 % amarų, nes 100 % amarų išnaikinimas gali reikšti, kad drauge išnaikinome visus aplinkinių kaimų gyventojus ir nebėra kam valgyti uogų.

Tradicionio dozavimo modelio žinome:

- kiekvienos grupės respondentų skaičių,
- kiek respondentų kiekvienoje grupėje įgijo norimą būseną,
- kokią dozę gavo kiekvienos grupės respondentai,
- kiek respondentų įgytų norimą būseną be dozės.

Dažniausiai taria, kad be poveikio kintamojo (nulinė dozė) norimos būsenos neįgis nė vienas respondentas. Nenuodytas amaras išgyvens. Kartais taip nėra. Tiriant, kaip finansiniai stimulai veikia norą studijuoti karybą, tai, kad nėra stimulų, dar nereiškia, kad niekas nestudijuos karybos. Gal respondentas visą vaikystę žaidė alaviniais kareivėliais, o dabar norėtų pabandyti pažaisti gyvais.

Dozavimo modeliai turi palyginti nedaug modelio tikimo rodiklių:

- 1) *Pirsono kriterijus*. Jis rodo gerą / blogą bendrąjį modelio tikimą duomenims. Gerai, kai $p \geq 0,05$.
- 2) *Regresorių Z kriterijus*. Tai t–kriterijaus tiesinėje regresijoje ir Voldo kriterijaus logistinėje regresijoje analogas. Regresorius yra statistiškai reikšmingas (modelis geras), kai $p < 0,05$.
- 3) *Duomenų probit grafikas*. *Probit* regresijos modelyje taria, kad regresuojamo kintamojo Y reikšmių $\Phi^{-1}(Y)$ ir regresorių priklausomybė yra tiesinė. Grafike ir atidedamos šios reikšmės. Modelis tuo geresnis, kuo šis grafikas labiau primena tiesę. Jeigu reikia, duomenys transformuojami – logaritmuojami ir pan.

Nors klasikiniuose dozavimo modeliuose yra tik vienas dozuojamas poveikio kintamasis (regresorius), tokių regresorių gali būti ir daugiau.

Gera duomenims tinkamo dozavimo modelio:

- Pirsono chi kvadrato kriterijaus $p \geq 0,05$.
- Visiems regresoriams Z kriterijaus $p < 0,05$.
- Duomenų *probit* grafikas primena tiesę.

10.1.7. Standartiniai *probit* regresijos modelių aprašymai

Visada aprašomas galutinis, po visų tobulinimų gautas modelis. Privaloma aprašyti tikėtinumų santykio kriterijaus rezultatus ir aptarti regresorių statistinius reikšmingumus. Pateiksime keletą galimų aprašymų fragmentų.

- *Probit regresijos modelis tiko, tikėtinumų santykio kriterijaus $\chi^2=130,2$; $p < 0,01$. Visi regresoriai buvo statistiškai reikšmingi. Teisingai klasifikuota 81,3 % imties respondentų. Nagelgerkės determinacijos koeficientas 0,64.*
- *Amarų skaičiaus priklausomybę nuo STPK_3000 koncentracijos purškamame skystyje aprašo probit modelis: $P(\text{amarui amen}) = \Phi(-1,8 + 0,11\text{STPK_3000})$. Pirsono chi kvadrato kriterijaus statistika $\chi^2= 3,2$; o $p = 0,65$. Norint išnaikinti 80 % amarų reikalinga koncentracija $\text{STPK_3000} = 30$. Transformuotų duomenų grafikas primena tiesę...*

10.2. *Probit* regresinė analizė su SPSS

10.2.1. Duomenys

Kaip atlikti standartinę *probit* regresinę analizę, parodysime, tirdami universitetų absolventų integraciją darbo rinkoje, 2009 m. lapkritis – 2010 m. sausis. Failas **LAMS**, kintamieji:

- K2 – aukštoji mokykla
- K33_2 – pasiekiant dabartinę padėtį darbo rinkoje studijų metu įgytos žinios (1 – visai nereikšmingos, ..., 5 – labai reikšmingos),
- K35_1 – esamo darbo atitiktis bakalauro studijų kryptčiai (1 – tikrai taip, 2 – greičiau taip, 3 – greičiau ne, 4 – tikrai ne),

- *K36_1* – studijų metu įgytų profesinių žinių panaudojimas darbe (1 – visiškai nenaudoju, ..., 5 – labai dažnai naudoju),
- *K37_1* – pasitenkinimas esamu darbu (1 – labai nepatenkintas, ..., 5 – labai patenkintas).

Tirsime, kaip Klaipėdos universiteto bakalauro profesinių žinių panaudojimo vertinimas susijęs su požiūriu į žinių svarbą darbo rinkoje ir pasitenkinimu esamu darbu. Papildomai atsižvelgsime į darbo atitiktį studijų kryptį.


Visų pirma pašaliname iš tyrimo respondentus, kurie į klausimus neatsakė (visiems kintamiesiems nurodome, kad *missing value all (99)*). Atsirenkame Klaipėdos universiteto absolventus (*Select cases if K2 = 3*). Su *Frequencies* komanda ištiriame *K36_1* reikšmes:

K36_1 Pirmųjų studijų metu įgytų profesinių žinių panaudojimo darbe įvertinimas					
		Frequency	Percent	Valid Percent	Cumulative Percent
Valid	1 Visiškai nenaudoju	10	2.6	3.1	3.1
	2	22	5.6	6.7	9.8
	3	69	17.6	21.1	30.9
	4	109	27.9	33.3	64.2
	5 Labai dažnai naudoju	117	29.9	35.8	100.0
	Total	327	83.6	100.0	
Missing	99 Nestudijavau / negaliu atsakyti	1	.3		
	System	63	16.1		
	Total	64	16.4		
Total		391	100.0		

Matome, kad labai nedaug respondentų rinkosi reikšmes 1 ir 2. Todėl su komanda *recode* sukuriame naują kintamąjį *Y*, kuris įgyja dvi reikšmes: 0 – jeigu respondantai nedažnai naudoja studijų žiniomis (*K36_1* = 1, 2 arba 3) ir 1 – jeigu respondantai dažnai naudoja studijų žiniomis (*K36_1* = 4 arba 5). Tirsime modelį, kurį sąlygiškai galima užrašyti taip:

$$Y = f(K35_1, K33_2, K37_1).$$


Grafiškai tiriamą modelį galima pavaizduoti taip:




Atlikome pradinę modelio specifikaciją. Dabar patikrinsime, ar parinktasis modelis tinka duomenims.

10.2.2. SPSS parinktys pradiniam regresijos modeliui


Tradicinis *probit* regresijos modelis tiriamas kaip apibendrintasis tiesinis modelis. Atsidarome langelį **Analyze** ir renkamės **Generalized Linear Models** → **Generalized Linear Models**.




Atsidariusiame meniu renkamės langą **Type of Model** ir pažymime **Binary probit**.




Atsidarome langą **Response** ir į laukelį **Dependent Variable** įkeliamo kintamąjį Y.



Atidarome langą **Predictors** ir į **Covariates** įkeliame *K37_1* ir *K33_2* (su tam tikromis išlygomis juos galima laikyti intervaliniais kintamaisiais. Regresorius *K35_1* įgyja tik 4 reikšmes, todėl traktuosime jį kaip kategorinį kintamąjį. Įkeliame *K35_1* į langą **Factors**.



Atidarome langą **Model** ir visus regresorius perkeliame į dešinįjį langą.



Atidarome langą **Save** ir pažymime **Predicted category** ir **Cook's distance**. Šios parinktys leis sudaryti klasifikacinę lentelę ir patikrinti, ar imtyje yra išskirčių.

Type of Model	Response	Predictors	Model	Estimation	Statistics	EM Means	Save	Exp
Save	Item to Save		Variable Name or Root N...					
☐	Predicted value of mean of response		MeanPredicted					
☐	Lower bound of confidence interval for mean of response		CIMeanPredictedLower					
☐	Upper bound of confidence interval for mean of response		CIMeanPredictedUpper					
☒	Predicted category		PredictedValue					
☐	Predicted value of linear predictor		XBPredicted					
☐	Estimated standard error of predicted value of linear predictor		XBStandardError					
☒	Cook's distance		CooksDistance					

10.2.3. Rezultatai

Rezultatų išsklotinė prasideda informacija, kad modelis sudaromas tikimybei $P(Y = 0)$:

Model Information	
Dependent Variable	Y^a
Probability Distribution	Binomial
Link Function	Probit

a. The procedure models .00 as the response, treating 1.00 as the reference category.

Lentelėje **Categorical Variable Information** pateikiama informacija apie kategorinių kintamųjų reikšmes. Primename, kad duomenyse negali dominuoti nė viena iš priklausomo kintamojo kategorijų. Nedažnai ($Y = 0$) studijų žiniomis naudojasi 31,1 % respondentų, dažnai ($Y = 1$) – 68,9 % respondentų. Primename, kad minimalus kiekvienos kategorijos procentas turi būti bent 20 %. Šis reikalavimas patenkintas. Šiuos procentus prisiminsime, kai tirsime klasifikacinę lentelę. Gero modelio turi būti geresni teisingų klasifikavimų procentai.

Regresoriaus $K35_1$ reikšmes verta peržiūrėti tuo pačiu tikslu – jeigu kai kurių reikšmių nedaug, vertėtų regresoriaus kategorijas sustambinti. Matome, kad tokių atsakymų nėra. Regresoriaus nereikia transformuoti.

Categorical Variable Information			N	Percent
Dependent Variable	Y	.00	100	31.1%
		1.00	222	68.9%
		Total	322	100.0%
Factor	K35_1 Esamo darbo atitikimas bakalauro (vientisųjų) studijų kryptiai	1 Tikrai taip	153	47.5 %
		2 Greičiau taip	95	29.5 %
		3 Greičiau ne	36	11.2%
		4 Tikrai ne	38	11.8%
		Total	322	100.0%

Tikėtinumų santykio kriterijaus statistika ir jos p reikšmė yra lentelėje **Omnibus Test**. Matome, $p = 0,00... < 0,05$. Taigi vienas iš svarbiausių rodiklių rodo gerą modelio tikimą duomenims.

Omnibus Test ^a		
Likelihood Ratio		
Chi-Square	df	Sig.
163.847	5	.000

Dependent Variable: Y

Model: (Intercept), K35_1, K37_1, K33_2

Lentelėje **Parameter Estimates** yra modelio koeficientų įverčiai, tų įverčių 95 % pasikliautiniai intervalai ir Voldo kriterijaus statistikos ir p reikšmės. Kategorinis kintamasis **K35_1** buvo pakeistas į keturis pseudokintamuosius. Vienas iš šių pseudokintamųjų, atitinkantis reikšmę $K35_1 = 3$, yra statistiškai nereikšmingas. Vis dėlto dėl vienos tokios reikšmės modelio neverta tobulinti.

Parameter Estimates							
Parameter	B	Std. Error	95 % Wald Confidence Interval		Hypothesis Test		
			Lower	Upper	Wald Chi-Square	df	Sig.
(Intercept)	4.853	.7092	3.463	6.243	46.832	1	.000
[K35_1=1]	-1.577	.3272	-2.218	-.936	23.229	1	.000
[K35_1=2]	-1.018	.3226	-1.650	-.385	9.953	1	.002
[K35_1=3]	-.261	.3722	-.991	.468	.493	1	.482
[K35_1=4]	0 ^a	.	.	.	.	.	.
K37_1	-.273	.1141	-.496	-.049	5.720	1	.017
K33_2	-.780	.1151	-1.005	-.554	45.859	1	.000
(Scale)	1 ^b						

Dependent Variable: Y

Model: (Intercept), K35_1, K37_1, K33_2

a. Set to zero because this parameter is redundant.

b. Fixed at the displayed value.

Gavome keturis modelius, kurie skiriasi tik konstanta. Juos galima užrašyti taip:

$$\hat{P}(Y = 0) = P(\text{Retai naudoja studijų žinias darbe}) = \Phi(z),$$

$$z = 4,85 - 0,273 K37_1 - 0,78 K33_2 + \begin{cases} -1,57, & \text{kai } K35_1 = 1, \\ -1,02, & \text{kai } K35_1 = 2, \\ -0,26, & \text{kai } K35_1 = 3, \\ 0, & \text{kai } K35_1 = 4. \end{cases}$$

Įsitikinsime, kad modelio koeficientų ženklai atitinka sveiko proto reikalavimus. Koeficientas prie $K37_1$ yra neigiamas. Jeigu respondentas renkasi didesnę $K37_1$ reikšmę (yra labiau patenkintas darbu), mažiau tikėtina, kad jis retai naudoja studijų žinias darbe. Analogiškai darome išvadą, kad kuo labiau respondentas suvokia studijų žinių reikšmę, tuo didesnė tikimybė dažnai naudoti tas žinias darbe (mažiau tikėtina, kad tai įvyksta retai). Kuo $K35_1$ įgyja didesnę reikšmę (darbo pobūdis labiau atitinka studijų kryptį), tuo labiau tikėtina, kad žinias darbe naudos dažnai. Trumpai kalbant, respondentai, labiau vertinantys studijų žinias ir labiau patenkinti savo darbu, dažniau studijų žinias naudoja savo darbe. Ir ši tendencija stipresnė tų, kurių darbo pobūdis labiau atitinka studijų kryptį.

Kadangi *probit* regresiją tyrėme kaip apibendrintąjį tiesinį modelį, lentelėje **Goodness of Fit** galima peržiūrėti deviacijos ir laisvės laipsnių santykį. Gerai, kai jis arti vieneto. Matome, kad jis toks ir yra (1,156). Pažymėtina, kad *probit* regresijai svarbesnis rodiklis yra didžiausių tikėtinumų santykio chi kvadrato kriterijaus maža *p* reikšmė (primename, kad ji yra lentelėje **Omnibus Test.**) Jeigu deviacijos ir laisvės laipsnių santykis daug skiriasi nuo vieneto, bet visos kitos charakteristikos (įskaitant klasifikacinę lentelę) geros, modelis laikytinas priimtinu.

Goodness of Fit ^b			
	Value	Df	Value/df
Deviance	49.722	43	1.156
Scaled Deviance	49.722	43	
Pearson Chi-Square	48.218	43	1.121
Scaled Pearson Chi-Square	48.218	43	
Log Likelihood ^a	-47.932		
Akaike's Information Criterion (AIC)	107.865		
Finite Sample Corrected AIC (AICC)	108.131		
Bayesian Information Criterion (BIC)	130.512		
Consistent AIC (CAIC)	136.512		

Norint nustatyti, ar imtyje nėra išskirčių, reikia patikrinti, ar duomenyse (ne rezultatų išsklotinėje) atsiradusio stulpelio *CooksDistance* visos reikšmės mažesnės už vienetą. Panaudojame

komandą **Analyze** → **Descriptive Statistics** → **Descriptives**. Perkeliame *CooksDistance* į **Variable(s)**. Pasirenkame **OK**.

Descriptive Statistics					
	N	Minimum	Maximum	Mean	Std. Deviation
CooksDistance Cook's Distance	322	.000	.039	.00324	.006749
Valid N (listwise)	322				

Matome, kad maksimali Kuko mato reikšmė $0,039 < 1$. Todėl darome išvadą, kad duomenys neturi išskirčių.

Norėdami gauti klasifikacinę lentelę, renkamės **Analyze** → **Descriptive Statistics** → **Crosstabs**. Į **Row(s)** perkeliame *Y*, į **Column(s)** – *PredictedValue*. Pasirenkame **Cells** ir pažymime **Row**. Renkamės **Continue** ir **OK**.

Y * PredictedValue Predicted Category Value Crosstabulation					
			PredictedValue Predicted Category Value		Total
			.00	1.00	
Y	.00	Count	66	34	100
		% within Y	66.0%	34.0%	100.0%
	1.00	Count	17	205	222
		% within Y	7.7%	92.3%	100.0%
Total	Count		83	239	322
	% within Y		25.8%	74.2%	100.0%

Iš 100 respondentų, kurie retai naudojami studijų metu gautomis žiniomis, teisingai klasifikuoti 66 (66 %). Iš 222 respondentų, kurie dažnai naudojami studijų metu gautomis žiniomis, teisingai klasifikuoti 205 (92,3 %). Prisiminę lentelės **Categorical Variable Information** procentus (atitinkamai 31,1 % ir 68,9 %), įsitikiname, kad taikomas modelis tinkamas. Galutinė išvada: *probit* regresijos modelis gerai tinka duomenims.

10.2.4. Prognozavimas

Vieną konkrečią reikšmę galima prognozuoti ir su SPSS. Tarkime, norime ištirti, ką apie studijų naudojimą mąsto respondentai, kuriems $K33_2 = 4$, $K35_1 = 1$, $K37_1 = 4$. Duomenyse įvedame papildomą eilutę: stulpelyje $K33_2$ įrašome 4, stulpelyje $K35_1$ įrašome 1, stulpelyje $K37_1$

įrašome 4, stulpelyje *filter_\$* įrašome 1, kitus stulpelius paliekame tuščius. Jeigu išmestume kitus kintamuosius, paskutinė duomenų eilutė atrodytų taip:

K33_2	K35_1	K37_1	filter_\$	Y	var
4	1	4	1	.	

Vykdydami *probit* analizę lange **Save** pažymime **Predicted value of mean of response**.

Type of Model	Response	Predictors	Model	Estimation	Statistics	EM Means	Save
Save	Item to Save					Variable Name or Role	
☒	Predicted value of mean of response					MeanPredicted	
☐	Lower bound of confidence interval for mean of response					CIMeanPredictedLower	

Duomenyse atsiranda papildomas stulpelis **MeanPredicted**, kuriame įrašytas tikimybės $P(Y = 0) = P(\text{Retai naudoja studijų žinias})$ įvertis. Gavome, kad ši tikimybė 0,175. Taigi labai mažai tikėtina, kad toks respondentas retai naudoja studijų metais įgytomis žiniomis. Daug tikėtiniau (tikimybė lygi $1 - 0,175 = 0,825$), kad jis tomis žiniomis naudoja dažnai.

K33_2	K35_1	K37_1	filter_\$	Y	MeanPredicted	PredictedValue
4	1	4	1	.	.175	1.00

10.2.5. Dozavimo modelio tyrimas


Tarkime, kad dešimt grupių po dešimt savanorių buvo skirtingą laiką agituojami vyksti pakariauti į vieną Afrikos valstybę. Stulpelyje *grupdidumas* nurodyta, kiek kiekvienoje grupėje buvo savanorių, stulpelyje *laikas* – kiek laiko jiems buvo „plaunamos smegenys“, stulpelyje *kiekis* – kiek savanorių agitacijai pasidavė. Šiaip jau siekiama, kad visose grupėse būtų panašus respondentų skaičius. Vis dėlto grupių didumas nebūtinai turi sutapti. Pavyzdžiui, dešimtojoje grupėje buvo 11 respondentų, o likusiose – po dešimt.

	kiekis	grupdidumas	laikas
1	.00	10.00	2.00
2	.00	10.00	.00
3	1.00	10.00	8.00
4	2.00	10.00	14.00
5	4.00	10.00	17.00
6	5.00	10.00	20.00
7	6.00	10.00	22.00
8	7.00	10.00	25.00
9	8.00	10.00	30.00
10	9.00	11.00	36.00

Su *probit* regresija sumodeliuosime *kiekio* priklausomybę nuo *laiko*. Pasirenkame **Analyze** → **Regression** → **Probit**. Į langelį **Response Frequency** įkeliame *kiekis*, į **Total Observed** – *grupdidumas*, į **Covariates** – *laikas*. Spaudžiame **OK**.



Jeigu turėtume kategorinį regresorių (vieną), jį reikėtų įkelti į langelį **Factor**. Jeigu norėtume logaritmuoti duomenis, **Transform** pasirinktume tinkamą transformaciją. Duomenis rekomenduojama logaritmuoti, kai duomenų *probit* grafikas neprimena tiesės. Tarėme, kad visai neagituoti respondentai vykti į Afriką nenorės. Jeigu manytume kitaip, pasirinkę **Options** parinktyje **Natural Response Rate** nurodytume spėjamą neagituotų respondentų skaičių (**Value**) arba nurodytume, kad šis skaičius būtų įvertintas iš imties duomenų (**Calculate from data**).




Norint išsiaiškinti, ar *probit* regresija tiko, rezultatų išsklotinėje reikia surasti lentelę **Chi-Square Tests**. Joje yra Pirsono statistikos reikšmė (2,775) ir jos *p* reikšmė ($p = 0,948$). Matome, kad *p* reikšmė daug didesnė už 0,05. *Probit* regresijos modelio atmesti kaip netinkamo negalima.

Chi-Square Tests				
		Chi-Square	df ^a	Sig.
PROBIT	Pearson Goodness-of-Fit Test	2.775	8	.948 ^b

a. Statistics based on individual cases differ from statistics based on aggregated cases.

b. Since the significance level is greater than .150, no heterogeneity factor is used in the calculation of confidence limits.

Duomenų *probit* grafikas pakankamai tiesinis. Tai taip pat rodo gerą regresijos modelio tikimą. Darome išvadą, kad *probit* modelis tinkamai aprašo duomenis.



Modelio koeficientų įverčiai yra lentelėje **Parameter Estimates**.

Parameter Estimates						
Parameter	Estimate	Std. Error	Z	Sig.	95 % Confidence Interval	
					Lower Bound	Upper Bound
PROBIT ^a laikas	.105	.019	5.496	.000	.067	.142
Intercept	-2.185	.413	-5.286	.000	-2.598	-1.772

a. PROBIT model: PROBIT(p) = Intercept + BX

Modelis atrodo taip:

$$\hat{P}(\text{norės į Afriką}) = \Phi(z), \quad z = -2,185 + 0,105 \times \text{laikas}.$$

Kuo ilgesnė įtikinėjimo trukmė, tuo didesnė tikimybė įtikinti.

Lentelėje **Confidence Limits** yra informacija apie *laiko* kiekį, reikalingą atitinkamam procentui respondentų suagituoti. Pavyzdžiui, jeigu norime suagituoti 15 % respondentų, vidutinis agitavimo laikas yra 10,447 valandos. Greta dar pateikiamas 95 % kintamojo reikšmės intervalas (nuo 3,737 iki 14,237 valandos). Matome, kad pasikliautinis intervalas gana ilgas. Tai nėra labai gerai, nes atsakymas – nuo 3,7 iki 14, 2 valandos – skamba nepraktiškai.

Confidence Limits				
		95 % Confidence Limits for laikas		
	Probability	Estimate	Lower Bound	Upper Bound
PROBIT	.010	-3.158	-16.832	3.597
	.020	-.283	-12.425	5.786
	.030	1.542	-9.640	7.185
	.040	2.914	-7.551	8.244
	.050	4.030	-5.857	9.110
	.060	4.980	-4.419	9.852
	.070	5.813	-3.162	10.506
	.080	6.559	-2.040	11.095
	.090	7.238	-1.023	11.634
	.100	7.862	-.090	12.133

Jeigu būtų kategorinis regresorius, atitinkama procentinė lentelė būtų sudaryta kiekvienai to regresoriaus kategorijai. Pavyzdžiui, jeigu būtume dar grupes skirstę pagal lytį, gautume dvi lenteles – vieną vyrams, kitą moterims. Jeigu modelyje būtų ne vienas intervalinis regresorius, šios lentelės rezultatų išsklotinėje apskritai nebūtų.

Rezultatų išsklotinėje dar pateikiama pagalbinė lentelė **Cell Counts and Residuals**. Joje yra informacijos, kiek kiekvienoje grupėje buvo suagituotų savanorių ir kiek jų turėjo būti pagal modelį. Nedidelės prognozės ir stebinių skirtumų reikšmės skiltyje **Residuals** rodo gerą modelio tikimą duomenims.

Cell Counts and Residuals							
Number		laikas	Number of Subjects	Observed Responses	Expected Responses	Residual	Probability
PROBIT	1	2.000	10	0	.331	-.331	.033
	2	.000	10	0	.213	-.213	.021
	3	8.000	10	1	1.023	-.023	.102
	4	14.000	10	2	2.421	-.421	.242
	5	17.000	10	4	3.390	.610	.339
	6	20.000	10	5	4.480	.520	.448
	7	22.000	10	6	5.235	.765	.523
	8	25.000	10	7	6.343	.657	.634
	9	30.000	10	8	7.931	.069	.793
	10	36.000	11	9	10.089	-1.089	.917

10.2.6. SPSS komandų sintaksė

Surašysime, kaip atrodo SPSS komandos nagrinėjamam pradiniam logistinės regresijos modeliui. Jas galima vykdyti sintaksės lange pasirenkant **Run**.

* Generalized Linear Models.

GENLIN Y (REFERENCE=LAST) BY K35_1 (ORDER=ASCENDING) WITH K37_1 K33_2

/MODEL K35_1 K37_1 K33_2 INTERCEPT=YES

DISTRIBUTION=BINOMIAL LINK=PROBIT

/CRITERIA METHOD=FISHER(1) SCALE=1 COVB=MODEL MAXITERATIONS=100

MAXSTEPHALVING=5

PCONVERGE=1E-006(ABSOLUTE) SINGULAR=1E-012 ANALYSISTYPE=3(WALD)

CILEVEL=95 CITYPE=WALD

LIKELIHOOD=FULL

/MISSING CLASSMISSING=EXCLUDE

/PRINT CPS DESCRIPTIVES MODELINFO FIT SUMMARY SOLUTION

/SAVE PREDVAL COOK.

SPSS sintaksė dozavimo modeliui atrodo taip:

PROBIT kiekis OF grupdidumas WITH laikas

/LOG NONE

/MODEL PROBIT

/PRINT FREQ CI

/CRITERIA P(.15) ITERATE(20) STEPLIMIT(.1).

10.3. *Probit* regresinė analizė su STATA

10.3.1. Duomenys

Pakartosime *probit* analizę, atliktą SPSS programa. Tiriamo universitetų absolventų integraciją darbo rinkoje, 2009 m. lapkritis – 2010 m. sausis. Failas **LAMS**, kintamieji: *K2* – aukštoji mokykla, *K33_2* – pasiekiant dabartinę padėtį darbo rinkoje studijų metu įgytos žinios (1 – visai nereikšmingos, ..., 5 – labai reikšmingos), *K35_1* – esamo darbo atitiktį bakalauro studijų kryptčiai

(1 - tikrai taip, 2 – greičiau taip, 3 – greičiau ne, 4 – tikrai ne), $K37_1$ – pasitenkinimas esamu darbu (1 – labai nepatenkintas, ..., 5 – labai patenkintas) ir Y , kuris įgyja dvi reikšmes: 0 – jeigu respondentai nedažnai naudojami studijų žiniomis ($K36_1 = 1, 2$ arba 3) ir 1 – jeigu respondentai dažnai naudojami studijų žiniomis ($K36_1 = 4$ arba 5). Klaipėdos universiteto bakalaurs tirsime modelį: $Y = f(K35_1, K33_2, K37_1)$.

Visų pirma pašaliname iš tyrimo respondentus, kurie į klausimus neatsakė (keep if $K35_1 < 99$ & $K33_2 < 99$ & $K37_1 < 99$). Atsirenkame Klaipėdos universiteto absolventus (keep if $K2 == 3$).

Pasižiūrime, kokias reikšmes įgyja Y . Įvykdome:

```
tabulate Y, nolabel
```

Y	Freq.	Percent	Cum.
0	100	31.06	31.06
1	222	68.94	100.00
Total	322	100.00	

10.3.2. Modelio tyrimas

Tirsime modelį $Y = f(K35_1, K33_2, K37_1)$. Modelyje yra vienas kategorinis regresorius $K35_1$. Įvykdome komandą:

```
xi: probit Y i.K35_1 K33_2 K37_1
```

```
. xi: probit Y i.K35_1 K33_2 K37_1
i.K35_1      _IK35_1_1-4      (naturally coded; _IK35_1_1 omitted)
```

```
Iteration 0:    log likelihood = -199.4942
Iteration 1:    log likelihood = -124.52213
Iteration 2:    log likelihood = -117.88921
Iteration 3:    log likelihood = -117.57191
Iteration 4:    log likelihood = -117.57071
```

```
Probit regression                                Number of obs   =       322
                                                LR chi2(5)      =      163.85
                                                Prob > chi2     =       0.0000
Log likelihood = -117.57071                    Pseudo R2      =       0.4107
```

Y	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
_IK35_1_2	-.5592151	.2150986	-2.60	0.009	-.9808007	-.1376296
_IK35_1_3	-1.315548	.2857085	-4.60	0.000	-1.875527	-.7555698
_IK35_1_4	-1.576967	.3271906	-4.82	0.000	-2.218249	-.9356852
K33_2	.779756	.1151439	6.77	0.000	.5540781	1.005434
K37_1	.2727866	.1140529	2.39	0.017	.049247	.4963261
_cons	-3.276152	.6937848	-4.72	0.000	-4.635945	-1.916358

Regresorius $K35_1$ buvo kategorinis, įgyjantis keturias reikšmes. Todėl jis modelyje keičiamas trimis dichotominiais regresoriais, kurie įtraukiami į kintamųjų sąrašą. Kintamasis $_IK35_1_2$ atitinka $K35_1 = 2$, $_IK35_1_3$ atitinka $K35_1 = 3$, $_IK35_1_4$ atitinka $K35_1 = 4$.

Tikėtinumų santykio kriterijaus statistika ir p reikšmė pateikiamos lentelės viršuje dešinėje pusėje. Matome, kad statistika yra didelė (lygi 163,85) ir jos p reikšmė 0,000... Faktiškai tai informacija, kad su pasirinktais regresoriais modelis gerai tinka duomenims, nors neaišku, ar visi regresoriai modelyje reikalingi. Kuo kriterijaus statistikos reikšmė didesnė, tuo labiau tikėtina, kad logistinės regresijos modelis tinka. Ji ypač informatyvi, kai turime labai daug duomenų.

Determinacijos pseudokoeficiento reikšmė pakankama (**Pseudo R² = 0.41**) ir gerokai viršija 0,20 – tradicinę determinacijos koeficientams taikomą tinkamumo ribą. STATA pateikia Makfadenio determinacijos pseudokoeficientą.

Lentelėje yra modelio koeficientų įverčiai, tų įverčių 95 % pasikliautinieji intervalai ir Voldo kriterijaus reikšmės.

STATA *probit* regresija sudaroma tikimybei $Y = 1$.

Taigi sudarysime dažno studijų žinių naudojimo darbe modelį. Norėdami gauti reto žinių naudojimo modelį, turėtume tiesiog perkoduoti Y (pakeisti 0 į 1, o 1 – į 0).

Gavome keturis modelius, kurie skiriasi tik konstanta. Juos galima užrašyti taip:

$$\hat{P}(\text{Dažnai naudoja studijų žinias darbe}) = \Phi(z),$$

$$z = -3,28 + 0,27 K37_1 + 0,78 K33_2 + \begin{cases} 0, & \text{kai } K35_1 = 1, \\ -0,56, & \text{kai } K35_1 = 2, \\ -1,32, & \text{kai } K35_1 = 3, \\ -1,58, & \text{kai } K35_1 = 4. \end{cases}$$

Įsitikinsime, kad modelio koeficientų ženklai atitinka sveiko proto reikalavimus. Koeficientas prie $K37_1$ yra teigiamas. Jeigu respondentas renkasi didesnę $K37_1$ reikšmę (yra labiau patenkintas darbu), labiau tikėtina, kad jis dažnai naudoja studijų žinias darbe. Analogiškai darome išvadą, kad kuo labiau respondentas suvokia studijų žinių reikšmę, tuo didesnė tikimybė dažnai naudoti tas žinias darbe.

Norėdami gauti klasifikacinę lentelę, įvykdome komandą:

estat clas

Probit model for Y

Classified	True		Total
	D	~D	
+	205	34	239
-	17	66	83
Total	222	100	322

Classified + if predicted $\Pr(D) \geq .5$
True D defined as $Y \neq 0$

Sensitivity	$\Pr(+ D)$	92.34%
Specificity	$\Pr(- \sim D)$	66.00%
Positive predictive value	$\Pr(D +)$	85.77%
Negative predictive value	$\Pr(\sim D -)$	79.52%
False + rate for true ~D	$\Pr(+ \sim D)$	34.00%
False - rate for true D	$\Pr(- D)$	7.66%
False + rate for classified +	$\Pr(\sim D +)$	14.23%
False - rate for classified -	$\Pr(D -)$	20.48%
Correctly classified		84.16%

D kategorija žymi dažną žinių naudojimą ($Y = 1$). Matome, kad iš 222 tokių respondentų teisingai atpažinti 205. Tai sudaro 92,34 % teisingų klasifikavimų. Analogiškai nustatome, kad iš 100 retai naudojančių studijų žinias respondentų teisingai klasifikuoti 66 (66 %). Bendrasis teisingų klasifikavimų procentas yra 84,16 %. Tai rodo gerą modelio tikimą duomenims.

Galima papildomai pritaikyti *Pirsono chi kvadrato kriterijų*. Jeigu p reikšmė $\geq 0,05$, modelis gerai tinka. Tuo įsitikiname įvykdę :

```
estat gof
```

Probit model for Naudbak, goodness-of-fit test

```

number of observations =      322
number of covariate patterns =    49
      Pearson chi2(43) =    48.22
          Prob > chi2 =    0.2700

```

Norėdami gauti informacinių kriterijų AIC ir BIC reikšmes (jie taikomi, kai lyginami du modeliai. Geresnis tas modelis, kurio AIC ir BIC mažesni). Norėdami gauti klasifikacinę lentelę, įvykdome komandą:

```
fitstat
```

Measures of Fit for **probit** of **Naudbak**

Log-Lik Intercept Only:	-199.494	Log-Lik Full Model:	-117.571
D(316):	235.141	LR(5):	163.847
		Prob > LR:	0.000
McFadden's R2:	0.411	McFadden's Adj R2:	0.381
ML (Cox-Snell) R2:	0.399	Cragg-Uhler(Nagelkerke) R2:	0.561
McKelvey & Zavoina's R2:	0.600	Efron's R2:	0.457
Variance of y*:	2.501	Variance of error:	1.000
Count R2:	0.842	Adj Count R2:	0.490
AIC:	0.768	AIC*n:	247.141
BIC:	-1589.617	BIC':	-134.974
BIC used by Stata:	269.789	AIC used by Stata:	247.141

Matome, kad ir visi pseudodeterminacijos koeficientai rodo pakankamai gerą modelio tikimą duomenims.

10.3.3. Reikšmių prognozavimas

Tarkime, kad norime prognozuoti Y , žinodami, kad jam(jai) $K33_2 = 4$, $K37_1 = 4$, $K35_1 = 2$. Tą galima padaryti, įvykdžius komandą:

```
adjust K33_2 = 4 K37_1=4 _IK35_1_2=1 _IK35_1_3=0 _IK35_1_4=0, pr
```

All	pr
	.646097

Key: pr = Probability

Tikimybė, kad respondentas dažnai naudoja studijų metu įgytas žinias, yra 0,516.

10.4. *Probit* regresinė analizė su SAS

10.4.1. Duomenys

Pakartosime *probit* analizę, jau atliktą SPSS programa. Tiriame universitetų absolventų integraciją darbo rinkoje, 2009 m. lapkritis – 2010 m. sausis. Failas **LAMS**, kintamieji: $K2$ – aukštoji mokykla, $K33_2$ – pasiekiant dabartinę padėtį darbo rinkoje studijų metu įgytos žinios (1 – visai nereikšmingos, ..., 5 – labai reikšmingos), $K35_1$ – esamo darbo atitiktį bakalauro studijų kryptiai

(1 – tikrai taip, 2 – greičiau taip, 3 – greičiau ne, 4 – tikrai ne), $K37_1$ – pasitenkinimas esamu darbu (1 – labai nepatenkintas , ..., 5 – labai patenkintas) ir Y , kuris įgyja dvi reikšmes: 0 – jeigu respondentai nedažnai naudojami studijų žiniomis ($K36_1 = 1, 2$ arba 3) ir 1 – jeigu respondentai dažnai naudojami studijų žiniomis ($K36_1 = 4$ arba 5). Klaipėdos universiteto bakalaurs tirsime modelį, kurį sąlygiškai galima užrašyti taip:

$$Y = f(K35_1, K33_2, K37_1).$$

Visų pirma pašaliname iš tyrimo respondentus, kurie į klausimus neatsakė (keep if $K35_1 < 99$ & $K33_2 < 99$ & $K37_1 < 99$). Atsirenkame Klaipėdos universiteto absolventus (keep if $K2 == 3$).

Pasižiūrime, kokias reikšmes įgyja Y . Įvykdome:

```
OPTIONS nofmterr;
data LAMS;
set rgr.LAMS_s;
if (K2 eq 3) AND (K35_1 lt 99) AND (K33_2 lt 99) AND (K37_1 lt 99);
run;
proc freq data=lams;
table Y;
run;
```

Y				
Y	Frequency	Percent	Cumulative Frequency	Cumulative Percent
0.00	101	30.89	101	30.89
1.00	226	69.11	327	100.00
Frequency Missing = 64				

10.4.2. Modelio tyrimas

Tirsime modelį, kurį sąlygiškai galima užrašyti taip: $Y = f(K35_1, K33_2, K37_1)$. Modelyje yra vienas kategorinis regresorius $K35_1$. Įvykdome:


```
proc logistic data=lams descending;
  class K35_1 (ref="1" param=ref) ;
  model Y=K35_1 K33_2 K37_1 /link=probit rsq;
run;
```

Number of Observations Read	391
Number of Observations Used	322

Response Profile		
Ordered Value	Y	Total Frequency
1	1.00	222
2	0.00	100

Probability modeled is Y='1.00'.

Class Level Information				
Class	Value	Design Variables		
K35_1	1	0	0	0
	2	1	0	0
	3	0	1	0
	4	0	0	1

Model Fit Statistics		
Criterion	Intercept Only	Intercept and Covariates
AIC	400.988	247.141
SC	404.763	269.789
-2 Log L	398.988	235.141

Testing Global Null Hypothesis: BETA=0			
Test	Chi-Square	DF	Pr > ChiSq
Likelihood Ratio	163.8470	5	<.0001
Score	144.4070	5	<.0001
Wald	102.0011	5	<.0001

R-Square	0.3988	Max-rescaled R-Square	0.5614
----------	--------	-----------------------	--------

Analysis of Maximum Likelihood Estimates						
Parameter		DF	Estimate	Standard Error	Wald Chi-Square	Pr > ChiSq
Intercept		1	-3.2760	0.6835	22.9704	<.0001
K35_1	2	1	-0.5592	0.2156	6.7281	0.0095
K35_1	3	1	-1.3156	0.2862	21.1358	<.0001
K35_1	4	1	-1.5770	0.3276	23.1665	<.0001
K33_2		1	0.7797	0.1146	46.2563	<.0001
K37_1		1	0.2728	0.1140	5.7279	0.0167

Regresorius *K35_1* buvo kategorinis, įgyja keturias reikšmes. Todėl jis modelyje keičiamas trimis dichotominiais regresoriais, kurie įtraukiami į kintamųjų sąrašą. Lentelėje **Class Level Information** yra informacijos, kaip modelyje perkoduojamas kategorinis regresorius. Kintamasis *K35_1_2* atitinka *K35_1* = 2, *K35_1_3* atitinka *K35_1* = 3, *K35_1_4* atitinka *K35_1* = 4.

Lentelėje **Model Fit Statistics** pateikiami suderinamumo informaciniai kriterijai. Matome, kad pasirinkto modelio visi informaciniai indeksai yra mažesni nei modelio be regresorių (tik su konstanta). Pavyzdžiui, AIC yra 247,14 (be regresorių 400,99). Determinacijos pseudokoeficiento reikšmė skaičiuojama tik nurodžius parinktį *rsq*. Ji nėra didelė (**R-Square = 0.3988**), bet *probit* regresijai šis rodiklis įvairiomis programomis skaičiuojamas skirtingai, todėl vertinamas prieštarigai ir nėra „lemiamas“ vertinant modelio kokybę. Juolab kad vis tiek viršija 0,20 – tradicinę determinacijos koeficientams taikomą tinkamumo ribą.

Lentelės **Testing Global Null Hypothesis** ir **Analysis of Maximum Likelihood Estimates** yra numatytosios. Tikėtinumų santykio Chi kvadrato kriterijaus statistika ir *p* reikšmė pateikiamos lentelės **Testing Global Null Hypothesis** viršuje dešinėje pusėje. Matome, kad chi kvadrato statistikos reikšmė yra didelė (163,85). Be to, kriterijaus *p* reikšmė < 0,0001. Faktiškai tai informacija, kad su pasirinktais regresoriais modelis tinka duomenims, nors neaišku, ar visi regresoriai modelyje reikalingi. Kuo chi kvadrato reikšmė didesnė, tuo labiau tikėtina, kad *probit* regresijos modelis tinka. Ji ypač informatyvi, kai turime labai daug duomenų.

Lentelėje **Analysis of Maximum Likelihood Estimates** yra modelio koeficientų įverčiai, tų įverčių 95 % pasikliautiniai intervalai ir Voldo kriterijaus reikšmės. Išklotinėje nurodyta, kad *probit* regresija sudaroma tikimybei $Y = 1$. Sudarysime dažno studijų žinių naudojimo darbe

modelį. Norėdami gauti reto žinių naudojimo modelį, turėtume tiesiog perkoduoti Y (pakeisti 0 į 1, o 1 – į 0).

Gavome keturis modelius, kurie skiriasi tik konstanta. Juos galima užrašyti taip:

$$\hat{P}(\text{Dažnai naudoja studijų žinias darbe}) = \Phi(z),$$

$$z = -3,28 + 0,27 K37_1 + 0,78 K33_2 + \begin{cases} -0,56, \text{ kai } K35_1 = 2, \\ -1,32, \text{ kai } K35_1 = 3, \\ -1,58, \text{ kai } K35_1 = 4. \end{cases}$$

Įsitikinsime, kad modelio koeficientų ženklai atitinka sveiko proto reikalavimus. Koeficientas prie $K37_1$ yra teigiamas. Jeigu respondentas renkasi didesnę $K37_1$ reikšmę (yra labiau patenkintas darbu), labiau tikėtina, kad jis dažnai naudoja studijų žinias darbe. Analogiškai darome išvadą, kad kuo labiau respondentas suvokia studijų žinių reikšmę, tuo didesnė tikimybė dažnai naudoti tas žinias darbe.

Norėdami gauti klasifikacinę lentelę, *model* sakinyje turime nurodyti papildomas dvi parinktis *ctable* ir *pprob*. Įvykdome:

```
proc logistic data=lams descending;
  class K35_1 (ref="1" param=ref) ;
  model Y=K35_1 K33_2 K37_1 /link=probit ctable pprob=0.5;
run;
```

Classification Table									
Prob Level	Correct		Incorrect		Percentages				
	Event	Non-Event	Event	Non-Event	Correct	Sensitivity	Specificity	False POS	False NEG
0.500	205	66	34	17	84.2	92.3	66.0	14.2	20.5

Event kategorija žymi dažną žinių naudojimą ($Y = 1$). Matome, kad iš 222 tokių respondentų teisingai atpažinti 205. Tai sudaro 92,3 % (**Sensitivity**) teisingų klasifikavimų. Analogiškai nustatome, kad iš 100 retai naudojančių studijų žinias respondentų teisingai klasifikuoti 66 (66 %) (**non-Event, Specifity**). Bendrasis teisingų klasifikavimų procentas yra 84,2 % (**Correct**). Tai rodo gerą modelio tikimą duomenims.

10.4.3. Reikšmių prognozavimas

Tarkime, kad norime prognozuoti Y , žinodami, kad jam(jai) $K33_2 = 4$, $K37_1 = 4$, $K35_1 = 2$. Tą padaryti galima, įvykdžius:

```
Data new;  
xbeta== -3.2760 - 0.5592*1 + 0.7797*4 + 0.2728*4;  
a=probnorm(xbeta);  
run;  
proc print data=new;  
run;
```

Obs	xbeta	a
1	0.3748	0.64610

Tikimybė, kad respondentas dažnai naudoja studijų metu įgytas žinias, 0,516.

Taikant SAS programą **probit regresinei analizei**, kaip ir logistinei regresinei analizei, yra naudojama **proc logistic** procedūra. Šios procedūros sintaksė atrodo taip:

```
PROC LOGISTIC <options> ;  
BY variables ;  
CLASS variable <(options)><variable <(options)>></ options> ;  
CONTRAST 'label' effect values<, effect values,></ options> ;  
EFFECT name = effect-type ( variables </ options> ) ;  
EFFECTPLOT <plot-type<(plot-definition-options)>></ options> ;  
ESTIMATE <'label'> estimate-specification </ options> ;  
EXACT <'label'><INTERCEPT><effects></ options> ;  
EXACTOPTIONS options ;FREQ variable ;  
LSMEANS <model-effects> </ options> ;LSMESTIMATE model-effect lsmestimate-  
specification </ options> ;  
<label:> MODEL variable <(variable_options)>=<effects></ options> ;  
<label:> MODEL events/trials=<effects></ options> ;ODDSRATIO <'label'> variable </  
options> ;
```

```

OUTPUT <OUT=SAS-data-set><keyword=name <keyword=name>></ option> ;
ROC <'label'> <specification> </ options> ;
ROCCONTRAST <'label'><contrast></ options> ;SCORE <options> ;
SLICE model-effect </ options> ;STORE <OUT=>item-store-name </ LABEL='label'> ;
STRATA effects </ options> ;<label:> TEST equation1 <,equation2,></ option> ;
UNITS <independent1=list1 <independent2=list2 >></ option> ;

WEIGHT variable </ option> ;

```

model yra būtinas **logistic** procedūros sakiny. Šiuo sakiniu aprašomas modelio pavidalas.

CLASS and EFFECT sakiniai (jei apibrėžti) turi būti prieš MODEL sakinį; CONTRAST, EXACT ir ROC sakiniai (jei apibrėžti) turi būti po MODEL sakinio.

Scenarijus :

```

OPTIONS nofmterr;
data LAMS;
set rgr.LAMS_s;
if (K2 eq 3) AND (K35_1 lt 99) AND (K33_2 lt 99) AND (K37_1 lt 99);
run;
proc freq data=lams;
table Y;
run;
proc logistic data=lams descending;
class K35_1 (ref="1" param=ref) ;
model Y=K35_1 K33_2 K37_1 /link=probit rsq ctable pprob=0.5;
run;
Data new;
xbeta== -3.2760-0.5592*1+0.7797*4+0.2728*4;
a=probnorm(xbeta);
run;
proc print data=new;
run;

```

10.5. *Probit* regresinė analizė su R

10.5.1. Duomenys

Pakartosime *probit* analizę, atliktą SPSS programa. Tiriamieji universitetų absolventų integraciją darbo rinkoje, 2009 m. lapkritis – 2010 m. sausis. Failas **LAMS**, kintamieji: *K2* – aukštoji mokykla, *K33_2* – pasiekiant dabartinę padėtį darbo rinkoje studijų metu įgytos žinios (1 – visai nereikšmingos, ..., 5 – labai reikšmingos), *K35_1* – esamo darbo atitiktį bakalauro studijų kryptčiai (1 – tikrai taip, 2 – greičiau taip, 3 – greičiau ne, 4 – tikrai ne), *K37_1* – pasitenkinimas esamu darbu (1 – labai nepatenkintas, ..., 5 – labai patenkintas) ir *Y*, kuris įgyja dvi reikšmes: 0 – jeigu respondentai nedažnai naudojami studijų žiniomis (*K36_1* = 1, 2 arba 3) ir 1 – jeigu respondentai dažnai naudojami studijų žiniomis (*K36_1* = 4 arba 5). Klaipėdos universiteto bakalauroams tirsime modelį: $Y = f(K35_1, K33_2, K37_1)$.

Visų pirma pašaliname iš tyrimo respondentus, kurie į klausimus neatsakė, ir pasirinkime Klaipėdos universiteto absolventus:

```
dta=read.csv2("LAMS_s.csv",na.strings = "NA",stringsAsFactors=FALSE)
ldta=subset(dta, K35_1 <99 & K33_2 <99 & K37_1 < 99 & (K2 == 3),select =
c(Y,K35_1,K33_2,K37_1))
```

Pasižiūrime, kokias reikšmes įgyja *Y*. Įvykdome

```
addmargins(table(ldta$Y))
```

```
> addmargins(table(ldta$Y))
```

0	1	Sum
100	222	322

10.5.2. Modelio tyrimas

Tirsime modelį, kurį sąlygiškai galima užrašyti taip: $Y = f(K35_1, K33_2, K37_1)$. Modelyje yra vienas kategorinis regresorius *K35_1*. Įvykdome komandą:

```

mprobit <- glm(Y~factor(K35_1)+K33_2+K37_1, family = binomial(link =
"probit"),data=ldta)

summary(mprobit)

confint(mprobit)

mprobit.reduced <-glm(Y~1, family=binomial(link = "probit"),data=ldta)

anova(mprobit.reduced,mprobit, test="Chisq")

rkvadrat<-1-mprobit$deviance/mprobit$null.deviance

rkvadrat

```

Call:

```
glm(formula = Y ~ factor(K35_1) + K33_2 + K37_1, family = binomial(link = "probit"),
    data = ldta)
```

Deviance Residuals:

Min	1Q	Median	3Q	Max
-2.7391	-0.3034	0.2975	0.5149	2.0482

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-3.2761	0.6835	-4.793	1.64e-06 ***
factor(K35_1)2	-0.5592	0.2156	-2.594	0.00949 **
factor(K35_1)3	-1.3155	0.2862	-4.597	4.28e-06 ***
factor(K35_1)4	-1.5770	0.3276	-4.813	1.49e-06 ***
K33_2	0.7798	0.1146	6.801	1.04e-11 ***
K37_1	0.2728	0.1140	2.393	0.01669 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 398.99 on 321 degrees of freedom
Residual deviance: 235.14 on 316 degrees of freedom
(1 observation deleted due to missingness)
AIC: 247.14

Number of Fisher Scoring iterations: 6

	2.5 %	97.5 %
(Intercept)	-4.67079701	-1.9477301
factor(K35_1)2	-0.98463744	-0.1399093
factor(K35_1)3	-1.88277915	-0.7612282
factor(K35_1)4	-2.23516228	-0.9495893
K33_2	0.55969376	1.0114142
K37_1	0.04876121	0.4965738

```
> anova(mprobit.reduced,mprobit, test="Chisq")
Analysis of Deviance Table

Model 1: Y ~ 1
Model 2: Y ~ factor(K35_1) + K33_2 + K37_1
```

	Resid. Df	Resid. Dev	Df	Deviance	P(> Chi)
1	321	398.99			
2	316	235.14	5	163.85	< 2.2e-16 ***

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
> rkvadrat
[1] 0.410656
>
```

Regresorius *K35_1* buvo kategorinis, įgyja keturias reikšmes. Todėl jis modelyje keičiamas trimis dichotominiais regresoriais, kurie įtraukiami į kintamųjų sąrašą. Kintamasis *factor(K35_1)_2* atitinka *K35_1 = 2*, *factor(K35_1)_3* atitinka *K35_1 = 3*, *factor(K35_1)_4* atitinka *K35_1 = 4*.

Didžiausio tikėtinumo santykio chi kvadrato kriterijaus statistika ir *p* reikšmė pateikiamos lentelėje **Analysis of Deviance Table**. Matome, kad chi kvadrato statistka yra didelė (163,85), o *p* reikšmė 0,000...< 0,05. Faktiškai tai informacija, kad su pasirinktais regresoriais modelis gerai tinka duomenims, nors neaišku, ar visi regresoriai modelyje reikalingi. Kuo chi kvadrato reikšmė didesnė, tuo labiau tikėtina, kad logistinės regresijos modelis tinka. Ji ypač informatyvi, kai turima labai daug duomenų. Tada net ir statistiškai reikšminga, bet maža chi kvadrato reikšmė kelia įtarimų dėl modelio gerumo.

Determinacijos pseudokoeficiento reikšmė pakankama (**rkvadrat = 0.4107**) ir gerokai viršija 0,20 – tradicinę determinacijos koeficientams taikomą tinkamumo ribą.

Be to, rezultatų lentelėje yra informacinio kriterijaus AIC reikšmė (**AIC: 247.14**). Ji būtų taikoma, kai lygintume du *probit* modelius su skirtingu regresorių skaičiumi. Geresnis tas modelis, kurio AIC mažesnė.

R *probit* regresija sudaroma tikimybei $Y = 1$.

Taigi sudarysime dažno studijų žinių naudojimo darbe modelį.

Gavome keturis modelius, kurie skiriasi tik konstanta. Juos galime užrašyti taip:

$$\hat{P}(\text{Dažnai naudoja studijų žinias darbe}) = \Phi(z),$$

$$z = -3,28 + 0,27 K37_1 + 0,78 K33_2 + \begin{cases} 0, & \text{kai } K35_1 = 1, \\ -0,56, & \text{kai } K35_1 = 2, \\ -1,32, & \text{kai } K35_1 = 3, \\ -1,58, & \text{kai } K35_1 = 4. \end{cases}$$

Įsitikinsime, kad modelio koeficientų ženklai atitinka sveiko proto reikalavimus. Koeficientas prie $K37_1$ yra teigiamas. Jeigu respondentas renkasi didesnę $K37_1$ reikšmę (yra labiau patenkintas darbu), labiau tikėtina, kad jis dažnai naudoja studijų žinias darbe. Analogiškai darome išvadą, kad kuo labiau respondentas suvokia studijų žinių reikšmę, tuo didesnė tikimybė dažnai naudoti tas žinias darbe.

Norėdami gauti klasifikacinę lentelę, pasinaudosime funkcijų biblioteka **car**.

(iš **car** bibliotekos pasinaudosime tik *recode* funkcija). Įvykdome:

```
library(car)
Predict <- recode(mprobit$fitted.values, 'lo:.499999=0 ; .5:hi=1; ', as.factor.result=FALSE)
addmargins(table(Idta$Y[!is.na(Idta$Y)],Predict))
prop.table(table(Idta$Y[!is.na(Idta$Y)],Predict),1)
```

Predict			
	0	1	Sum
0	66	34	100
1	17	205	222
Sum	83	239	322

Predict		
	0	1
0	66.000000	34.000000
1	7.657658	92.342342

Matome, kad iš 222 tokių respondentų teisingai atpažinti 205. Tai sudaro 92,34 % teisingų klasifikavimų (lentelių „1“ eilutė ir „1“ stulpelis). Analogiškai nustatome, kad iš 100 retai naudojančių studijų žinias respondentų teisingai klasifikuoti 66 (66 %) (lentelių „0“ eilutė ir „0“

stulpelis). Bendrasis teisingų klasifikavimų procentas yra 84,16 % $((205 + 66)/(222 + 100)) \cdot 100$. Tai rodo gerą modelio tikimą duomenims.

10.5.3. Reikšmių prognozavimas

Tarkime, kad norime prognozuoti Y , žinodami, kad jam(jai) $K33_2 = 4$, $K37_1 = 4$, $K35_1 = 2$. Tą padaryti galima, įvykdžius komandą:

```
predict(mprobit, data.frame(K33_2 = 4, K37_1 = 4, K35_1 = 2), type="response")
```

```
> predict(mprobit, data.frame(K33_2 = 4, K37_1 = 4, K35_1 = 2), type="response")
1
0.6460968
```

10.5.4. R programos *probit* regresijos komanda

```
glm(formula, family, data, weights, subset, ...)
```

Būtinas parametras **formula** – užrašome modelio išraišką.

glm naudojama ne tik *probit* regresinei analizei (prisiminkime dvinarės logistinės regresijos analizės aprašymą). Kokia analizė bus atliekama, nulemia parametras *family*. *Probit* regresijos atveju jo reikšmė yra ***binomial(link = "probit")***, t. y. ***family=binomial(link = "probit")***.

Scenarijai:

```
dta<-read.csv2("LAMS_s.csv",na.strings = "NA",stringsAsFactors=FALSE)
ldta<-subset(dta, K35_1 <99 & K33_2 <99 & K37_1 < 99 & (K2 == 3),select =
c(Y,K35_1,K33_2,K37_1))
addmargins(table(ldta$Y))
mprobit <- glm(Y~factor(K35_1)+K33_2+K37_1, family = binomial(link =
"probit"),data=ldta)
summary(mprobit)
#pasikliautiniai intervalai
confint(mprobit)
#
```

```

mprobit.reduced <- glm(Y~1, family=binomial(link = "probit"), data=ldta)
anova(mprobit.reduced, mprobit, test="Chisq")
# pseudo r square
rkvadrat <- 1 - mprobit$deviance / mprobit$null.deviance
rkvadrat
logLik(mprobit)
# klasifikavimo lentelė
library(car) # recode komandai panaudoti
Predict <- recode(mprobit$fitted.values, 'lo:.499999=0 ; .5:hi=1; ; ',
as.factor.result=FALSE)
addmargins(table(ldta$Y[!is.na(ldta$Y)], Predict))
# eilučių procentai
prop.table(table(ldta$Y[!is.na(ldta$Y)], Predict), 1) * 100
# reikšmių prognozavimas
predict(mprobit, data.frame(K33_2 = 4, K37_1 = 4, K35_1 = 2), type="response")
predict(mprobit, data.frame(K33_2 = 4, K37_1 = 4, K35_1 = factor(1:4)),
type="response")


```

Uždaviniai

1. Naudojant *probit* regresiją išspręsti dvinarės logistinės regresijos skyrelio uždavinius. Palyginti gautų modelių klasifikacines lenteles su logistinės regresijos klasifikacinėmis lentelėmis.
2. Sudaryti ir ištirti dozavimo modelį. Tirtas dviejų rūšių bičių atsparumas augalų cheminiam užterštumui. Kiekvienos rūšies bitės buvo apipurkštos skirtingos koncentracijos Mechiko smogo koncentratu. Fiksuota, kiek apipurkštų bičių neišgyveno nė pusvalandžio.

Kiekis	Iš kiek	Koncentracija	Grupė
0	20	2	1
0	20	0	1
1	20	7	1
2	20	13	1

4	20	16	1
5	20	19	1
6	20	21	1
7	20	24	1
8	20	27	1
10	20	29	1
2	20	2	2
0	20	0	2
3	20	7	2
5	20	13	2
7	20	16	2
7	20	19	2
9	20	21	2
10	20	24	2
12	20	27	2
13	20	30	2




Kaip pasirinkti tinkamą regresijos modelį.

Literatūra

1. Čekanavičius V., Murauskas G. Statistika ir jos taikymai. I. Vilnius: TEV, 2000.
2. Čekanavičius V., Murauskas G. Statistika ir jos taikymai. II. Vilnius: TEV, 2002.
3. Agresti A. Categorical data analysis (sec. edition). Wiley, 2002.
4. Chatterjee S., Hadi A. S. Regression analysis by Example (fourth edition). Wiley, 2006.
5. Field A. Discovering statistics using SPSS (and sex, drugs and rock'n'roll), (sec. edition). Sage, 2005.
6. Hosmer J D., Lemeshow S. Applied logistic regression, (sec. edition). Wiley, 2000.
7. IBM SPSS Regression 19, SPSS Inc, 2010.
8. Kleinbaum D. G., Klein M. Logistic Regression. A Self-Learning Text. Springer-Verlag, 2002.
9. Kutner M., Nachtsheim Ch. J., Neter J., Li W. Applied Linear Statistical Models (fifth edition). McGraw- Hill, 2005.
10. Long S., Freese J. Regression Models for Categorical Dependent Variables Using Stata, (sec. edition). Stata Press, 2006.
11. Tabachnick B. G., Fidell L. S. Using Multivariate Statistics (fifth edition). Pearson, 2007.
12. Tarling R. Statistical Modelling for Social Researchers. Principles and practice. Routledge, 2009.
13. Ryan T. P., Modern regression methods. Wiley, 1997.

Naudingas tinklalapis:

- <http://www.ats.ucla.edu/stat/>



Vydas Čekanavičius, Gediminas Murauskas

Taikomoji regresinė analizė socialiniuose tyrimuose. – Vilnius: Vilniaus universitetas, 2014. – 561 p.

ISBN 978-609-459-300-0

Šio el. vadovėlio tikslas – padėti įgyti praktinių regresinio modeliavimo ir analizės įgūdžių. Siekiama, kad tie įgūdžiai iš tikrųjų būtų praktiniai. Pagrindinių teorinių idėjų atpasakojimai pateikiami itin supaprastinti, o kaip atlikti analizę SPSS, STATA, SAS ir R programomis aprašyta labai detalai. Sąmoningai vengta patarimų „pasidaryk pats“. Vadovėlis skirtas tiesinei ir netiesinei, dvinarei ir daugianarei logistinėms, ranginei, medianos, Puasono, neigiamai binominei ir *probit* regresijoms.

Vydas Čekanavičius, Gediminas Murauskas

TAIKOMOJI REGRESINĖ ANALIZĖ SOCIALINIUIOSE TYRIMUOSE

Viršelis, maketas

Vydas Čekanavičius, Gediminas Murauskas

Išleido Vilniaus universitetas

Universiteto g. 3 LT-01513 Vilnius

$$Y = C + \beta_1 X + \beta_2 Z + e$$

Y - varanopso svoris

X - mėsa

Z - ne mėsa

e - liekamoji paklaida

