


Vydas Čekanavičius
Gediminas Murauskas

2

STATISTIKA IR JOS TAIKYMAI



TEV

VILNIUS 2011

UDK 311(075.8)
Če82

Lietuvos Respublikos švietimo ir mokslo ministerijos Aukštųjų mokyklų bendrųjų vadovėlių leidybos komisijos rekomenduota 2000 06 19 Nr. 05A-35

Šio vadovėlio autoriams 2003 metais paskirta Lietuvos Respublikos švietimo ir mokslo ministerijos pirmoji premija.

Darbo vadovas *Elmundas Žalys*

Redaktorė *Zita Manstavičienė*

Programinė įranga: *Tadeuš Šeibak*

Kompiuterinė grafika: *Edita Tatarinavičiūtė, Daiva Sniečkutė*

Maketuotoja *Aldona Žalienė*

Gamybos vadovas *Algimantas Paškevičius*

Korektorė *Birutė Laurinskienė*

ISBN 9955-491-16-7

© Leidykla TEV, Vilnius, 2002

© Vydas Čekanavičius, 2002

© Gediminas Murauskas, 2002

© Dail. Edita Tatarinavičiūtė, 2002

TURINYS

Pratarmė	5
Žymenys	6
1. Neparametriniai kriterijai	7
1.1. Parametrinių ir neparametrinių kriterijų skirtumai	7
1.2. Imties atsitiktinumo tikrinimas. Serijų kriterijus	12
1.3. Vilkoksono ženklų kriterijus priklausomoms imtims	15
1.4. Mano–Vitnio–Vilkoksono rangų sumų kriterijus nepriklausomoms imtims	20
1.5. Voldo–Volfovico kriterijus nepriklausomoms imtims	25
1.6. Kruskalo–Voliso ranginis kriterijus nepriklausomoms imtims	28
1.7. Frydmano kriterijus priklausomoms imtims	30
1.8. Ranginių kintamųjų ryšio matai	33
Uždaviniai	42
2. Vienfaktorinė dispersinė analizė	45
2.1. Dispersinė analizė ir t kriterijus	46
2.2. Struktūrinis ANOVA modelis	48
2.3. Dispersinės analizės prielaidos	49
2.4. Kriterijaus apie vidurkių lygybę sudarymas	51
2.5. Vienfaktorinės dispersinės analizės taikymas	54
2.6. <i>Post hoc</i> kriterijai	57
2.7. Aprioriniai kriterijai	64
2.8. Vidurkių trendas	66
2.9. Kintamųjų priklausomybės matai	70
2.10. Hipotezės apie dispersijų lygybę tikrinimas	75
Uždaviniai	77
3. Dvifaktorinė dispersinė analizė	81
3.1. Skirtumai nuo vienfaktorinės dispersinės analizės	82
3.2. Struktūrinis modelis	83
3.3. Stebėjimo duomenų struktūra	85
3.4. Dvifaktorinės dispersinės analizės taikymas	87
3.5. <i>Post hoc</i> kriterijai	92
3.6. Kintamųjų priklausomybės matai	94
3.7. Hipotezė apie vidurkių lygybę fiksavus vieną iš faktorių	96
3.8. Atsitiktiniai ir mišrieji modeliai	98
Uždaviniai	99
4. Blokuotųjų duomenų dispersinė analizė	101
4.1. Blokuotieji duomenys	101
4.2. Blokuotųjų duomenų vienfaktorinės dispersinės analizės modelis ir prielaidos	102
4.3. Stebėjimo duomenų struktūra	104
4.4. Kriterijaus taikymas	105
4.5. Blokuotųjų duomenų ANOVA <i>post hoc</i> kriterijai	109
4.6. Koeficientas η^2	110
4.7. Blokuotųjų duomenų dvifaktorinės dispersinės analizės modelis	111
Uždaviniai	119
5. Tiesinė regresija	123
5.1. Tiesinė regresija ir koreliacija	124
5.2. Tiesinės regresijos modelis	127
5.3. Regresijos tiesė	129
5.4. Liekamųjų paklaidų analizė	131
5.5. Determinacijos koeficientas	136

5.6. Regresinės analizės statistinės išvados	138
5.7. Prognozavimas regresinėje analizėje	143
Uždaviniai	147
6. Daugialypė regresija	151
6.1. Daugialypės regresijos modelis	152
6.2. Regresijos funkcija	153
6.3. Liekamosios paklaidos	155
6.4. Statistinės išvados apie modelio koeficientus	158
6.5. Kintamųjų įtakos priklausomybės matai	163
6.6. Multikolinearumas	168
6.7. Pseudokintamieji	171
6.8. Dviejų regresijos modelių koeficientų lygybė	174
6.9. Modelio parinkimas	175
Uždaviniai	179
7. Logistinė regresija	181
7.1. Logistinės regresijos modelis	181
7.2. Prognozavimas	183
7.3. Klasifikavimas	185
7.4. Statistinės išvados	188
Uždaviniai	192
8. Klasterinė analizė	195
8.1. Klasterinės analizės etapai ir tikslai	195
8.2. Objektų panašumo matai	197
8.3. Klasterinės analizės metodų klasifikacija	202
8.4. Jungimo metodai	203
8.5. k -vidurkių metodas	210
Uždaviniai	213
9. Diskriminantinė analizė	215
9.1. Diskriminantinės analizės tikslai ir etapai	215
9.2. Diskriminantinės analizės modelis	216
9.3. Diskriminavimas	218
9.4. Kanoninės funkcijos	221
9.5. Klasifikavimas	227
9.6. Klasifikavimas, kai populiaciją sudaro dvi grupės	228
9.7. Klasifikavimas, kai grupių daugiau nei dvi	230
9.8. Klasifikavimo patikimumas	233
Uždaviniai	235
10. Faktorinė analizė	237
10.1. Faktorinė analizės tikslai ir etapai	237
10.2. Matematinis modelis	240
10.3. Duomenų tikimas faktorinei analizei	242
10.4. Faktorių išskyrimas	244
10.5. Faktorių sukimas ir interpretavimas	251
10.6. Faktorių reikšmių skaičiavimas	253
Uždaviniai	254
Priedas	257
Vartojamų terminų anglų-lietuvių kalbų žodynėlis	269
Dalykinė rodyklė	270
Statistinių metodų schema	271
Literatūra	272

PRATARMĖ

Šiuolaikinė statistika – tai mokslas apie informacijos rinkimą, sisteminimą, analizavimą ir interpretavimą. Ši knyga yra vadovėlio „Statistika ir jos taikymai. I“ tęsinys ir skirta visiems savo tyrimams taikantiems statistinę analizę: ekonomistams, sociologams, biologams, psichologams, medikams, edukologams ir kt. Manome, kad naudingų žinių joje ras ir matematikai. Didžioji dalis knygos skirta daugiamatės statistikos metodams – dispersinei, regresinei, klasterinei, diskriminantinei ir faktorinei analizėms. Čia nagrinėjami ir nparametriniai metodai, kurie taikomi, kai duomenys ranginiai ir jų nedaug.

Tinkamai surinkus duomenis, minėtais metodais galima įvertinti skirtingų preparatų poveikį ligonio savijautai; nustatyti, kaip ūkio rentabilumas priklauso nuo naudmenų ploto; ištirti, ar vaikų intelekto koeficientui turi įtakos tėvų išsilavinimas; įvertinti nesveikos mitybos bei rūkymo ryšį su rizika susirgti vėžiu; sugrupuoti regionus pagal jų ekonominių rodiklių panašumus; išskirti tiesiogiai neišmatuojamus faktorius ir pan.

Naudotis šia knyga užtenka kuklių matematikos žinių. Pateikdami daug matematinių formulių, viso labo siekėme palengvinti skaitytojui kelią nuo pradinių duomenų iki statistinių išvadų. Tam turėtų pasitarnauti ir gausūs pavyzdžiai. Kai kurių pavyzdžių duomenys yra realių tyrimų, kai kurių – specialiai sukurti siekiant atskleisti metodo taikymo niuansus. Kai kuriems pavyzdžiams spręsti naudotasi SPSS paketu.

Šios knygos sudarymo principai tokie pat, kaip ir pirmosios. Po pratarinės pateikti dažniausiai vartojami žymenys. Temos dėstomos atskirais skyriais, kurie baigiasi uždavimais. Lietuviški statistikos (ypač daugiamatės) terminai tik kuriami, todėl, siekdami išvengti nesusipratimų, vadovėlio pabaigoje pateikėme vartojamų terminų anglų-lietuvių kalbų žodynėlį.

Rekomenduojame skaitytojams retkarčiais užmesti akį į mūsų tinklalapį www.ts.vu.lt. Be kita ko, jame rasite ir pastebėtų pirmosios knygos netikslumų atitaisymus.

Nuoširdžiai dėkojame visiems savo kolegoms už jų geranoriškumą aptariant įvairias statistinių metodų taikymo problemas. Ypač dėkingi V. Kazakevičiui, V. Bagdonavičiui ir E. Žaliui, kruopščiai perskaičiusiems knygos rankraštį ir pateikusiems vertingų pastabų. Už sutvarkytą rankraščio kalbą dėkojame redaktorei Z. Manstavičienei, o už šaunius piešinius – dailininkei E. Tatarinavičiūtei.

Vydas Čekanavičius, Gediminas Murauskas

Žymenys¹

n	imties didumas
$\overline{X}$	imties vidurkis (statistika)
$\bar{x}$	imties vidurkis
s^2, s_x^2	imties dispersija
s, s_x	standartinis nuokrypis
$P(A)$	įvykio A tikimybė
$P(A B)$	įvykio A sąlyginė tikimybė
$X, Y, Z, \dots$	kintamieji
EX	kintamojo X vidurkis
DX	kintamojo X dispersija
$X \sim \mathcal{P}(\lambda)$	kintamojo X skirstinys yra Puasono
$X \sim \mathcal{B}(n, p)$	kintamojo X skirstinys yra binominis
$X \sim \mathcal{N}(\mu, \sigma^2)$	kintamojo X skirstinys yra normalusis
z_α	standartinio normaliojo skirstinio α lygmens kritinė reikšmė
$\chi_\alpha^2(n)$	χ^2 skirstinio su n laisvės laipsnių α lygmens kritinė reikšmė
$t_\alpha(n)$	Stjudento skirstinio su n laisvės laipsnių α lygmens kritinė reikšmė
ϱ, ϱ_{XY}	koreliacijos koeficientas
r, r_{xy}	koreliacijos koeficientas (realizacija)
α	reikšmingumo lygmuo
W	kritinė sritis
SST	visa kvadratų suma
SSW	vidinė kvadratų suma
SSB	grupių kvadratų suma
MSB	grupių kvadratų sumos vidurkis
MSW	vidinės kvadratų sumos vidurkis
TSD	Tjūkio kriterijaus kritinė reikšmė
BSD	Bonferonio kriterijaus kritinė reikšmė
$y, \bar{y}(x), \dots$	įvėčiai

¹ Rečiau pasitaikančioms charakteristikoms vartojami tarptautiniai žymenys.


1. NEPARAMETRINIAI KRITERIJAI



Kiekviena problema turi vieną sprendimą, kuris yra paprastas, gražus ir neteisingas.

H. L. Menkenas

Pshichologas Eugenijus Linksmaitis perskaitė knygą „Statistika ir jos taikymai. I“ ir nutarė aprašytus metodus pritaikyti savo tyrimams. Norėdamas ištirti, kurie psichologijos studentai – „pelėdos“ ar „vyturiai“ mokosi geriau, jis apklausė 17 atsitiktinai parinktų studentų. Pašėkėjo, kad 9 iš jų yra „vyturiai“, 8 – „pelėdos“. Sužinojęs apklaustų studentų sesijos pažymių vidurkius ir pritaikęs t kriterijų dviem nepriklausomoms imtims, jis padarė išvadą, kad geriau sekasi „vyturiams“. Ir čia jį apniko abejonės. Duomenų mažai, patikrinti, ar jie pasiskirstę pagal normalųjį dėsnį, nėra kaip. Tad ar galima taikyti t kriterijų šiam uždaviniui spręsti? Kreipėsi į autorius. O šie atsakė – negalima. Kodėl? Atsakymą rasite šiame skyriuje.



1.1. Parametrinių ir neparametrinių kriterijų skirtumai

1.1.1. Parametrinių kriterijų trūkumai ir pranašumai

Parametrinės hipotezės – tai hipotezės apie kintamųjų skirstinių parametų (vidurkio, dispersijos ir pan.) reikšmes. Prisiminkime, kokias sąlygas turi tenkinti stebimi kintamieji. Dauguma parametrinių hipotezių tikrinimo kriterijų gali būti taikomi tik tada, kai kintamieji yra normalieji¹. Praktiškai ši sąlyga ne visada tenkinama. Be to, mažoms imtims šios sąlygos patikrinti neįmanoma. Normalusis kintamasis yra simetrinis, o realiai stebimų kintamųjų skirstiniai dažnai yra asimetriniai. Kartais įvairios duomenų transformacijos ($\ln X$, $\sqrt{X}$ ir pan.) panaikina asimetriją ir pagerina parametrinių kriterijų taikymo rezultatus, bet, deja, ne visada.

Laimei, yra gausi grupė kriterijų, kuriuos taikant nėra reikalaujama, kad stebimasis kintamasis būtų normalusis. Šie kriterijai vadinami *nepriklausomais nuo skirstinio*, arba

¹ Tai yra pasiskirstę pagal normalųjį (Gauso) dėsnį. Normalumo sąlyga – reikalavimas, kad kintamojo skirstinys būtų normalusis.

neparametriniais, kriterijais. Jie nėra skirti hipotezėms apie populiacijų parametrų reikšmes tikrinti. Beje, pirmojoje knygoje jau susipažinome su keliais neparametriniais (χ^2 ir Maknemaro) kriterijais.

Visi šiame skyriuje aprašyti kriterijai (išskyrus serijų kriterijų) taikomi tik tada, kai stebimi kintamieji yra tolydūs. Duomenys gali būti gauti naudojantis *santykių, intervalų arba rangų* skalėmis. (Beje, kaip teigia kai kurie statistikai, parametriniams kriterijams būtina, kad stebimi kintamieji būtų matuojami bent jau pagal intervalų skalę.) Neparametriniai kriterijai galingiausi, kai stebimų kintamųjų skirstiniai skiriasi tik padėties parametru (vidurkiu, mediana).

Neparametriniai kriterijai turi dar vieną teigiamą savybę – jie gali būti taikomi mažoms imtims. Šiame skyriuje mažų imčių tikslūs kriterijus skirsime nuo didelių imčių asimptotinių (apytikslų) kriterijų. Pats imties mažumas – santykinis dydis. Imtis yra pakankamai didelė ir jai galima taikyti asimptotinį kriterijų, jei tikslaus kriterijaus statistikos skirstinio kvantiliai praktiškai nesiskiria nuo aproksimuojančiojo skirstinio kvantilių, t. y. kvantilių skirtumas yra mažesnis kaip 0,001 ar pan. (žiūrint, kokio tikslumo tyrėjui pakanka). Šiame vadovėlyje nenagrinėjama, kaip įvertinti tiksliai ir asimptotiniams kriterijams naudojamų statistikų skirtumą. Jei remiantis knygos pabaigoje esančiomis statistikos lentelėmis galima tiksliai apskaičiuoti reikiamas neparametrinių kriterijų tikimybes (ar rasti kritines sritis), tai imtį laikysime maža. Priešingu atveju taikysime asimptotinį didelių imčių kriterijų.

Kaip matome, neparametriniai kriterijai turi pranašumą prieš parametrinius – jiems taikyti užtenka kur kas kuklesnių sąlygų. Kita vertus, jeigu stebimi normalieji kintamieji, o imtys didelės, tai geriau taikyti parametrinius kriterijus, nes jie galingesni. Taigi parametriniai ir neparametriniai kriterijai papildo vieni kitus. Reziumuodami galime teigti, kad:

1. Jeigu tam pačiam uždaviniui spręsti tinka ir parametrinis, ir neparametrinis kriterijus, geriau taikyti parametrinį kriterijų.
2. Jei sprendžiamam uždaviniui reikia normalumo prielaidos, o ji negalioja, tai geriau taikyti neparametrinį kriterijų.
3. Taikant neparametrinius kriterijus taip pat reikia atsižvelgti į tam tikras sąlygas.

1.1.2. Vienpusės ir dvipusės neparametrinių hipotezių alternatyvos

Taikant parametrines hipotezes, visi reikalavimai buvo formuluojami parametrams, todėl nekildavo jokių problemų rašant vienpuses bei dvipuses alternatyvas. Pavyzdžiui, $H_1: \mu_1 \neq \mu_2$ reiškė, kad vidurkiai nelygūs, o $H_1: \mu_1 > \mu_2$, kad pirmo kintamojo vidurkis didesnis už antrojo vidurkį. Neparametrinių hipotezių atveju dažniausiai lyginami skirstiniai.

Tarkime, norime palyginti dviejų kintamųjų X ir Y skirstinius (pavyzdžiui, studentų ir studenčių rūkymo intensyvumą). Dvipusės alternatyvos statistinė hipotezė atrodo taip:

$$\begin{cases} H_0: X \text{ ir } Y \text{ skirstiniai nesiskiria,} \\ H_1: X \text{ ir } Y \text{ skirstiniai skiriasi.} \end{cases} \quad (1)$$

Kitaip tariant, studentų ir studenčių rūkymo intensyvumas nesiskiria (H_0) arba skiriasi (H_1).

Šiame skyriuje nagrinėjami kriterijai, kuriems visiškai pakanka kintamųjų X ir Y tolydumo. Kriterijaus gerumą charakterizuoja tikimybė atmesti H_0 , kai ji klaidinga, t. y. kriterijaus galia (žr. [1], 3.3.2 skyrių). Kuo kriterijus galingesnis, tuo jis geresnis. Beveik visi šio skyriaus kriterijai galingiausi, kai alternatyva „skirstiniai skiriasi“ suprantama, kad jie skiriasi tik postūmio parametru, t. y. X turi tokį pat skirstinį kaip ir $Y + a$; čia a nelygus nuliui skaičius.



Tai, kad X turi tokį pat skirstinį kaip $Y + a$, nereiškia, kad $X = Y + a$. Kintamieji X ir Y nepriklausomi, taigi X gali įgyti įvairias reikšmes nepriklausomai nuo to, kokias įgyja Y . Tačiau tikimybė, kad X įgis reikšmę, mažesnę už t , yra lygi tikimybei, kad $Y + a$ įgis reikšmę, mažesnę už t , t. y. X ir $Y + a$ „valdo“ toks pats atsitiktinumas.

Šiame skyriuje kriterijaus pakankamą galingumą garantuojančios sąlygos pateikiamos kaip sąlygos, kurias turi tenkinti duomenys.


Patikslinsime, kaip suprantamos neparametrinių hipotezių vienpusės ir dvipusės alternatyvos. Matematiškai vienpusių alternatyvų statistines hipotezes rašysime taip:

$$\begin{cases} H_0: P(X > t) = P(Y > t) & \text{kiekvienam } t, \\ H_1: P(X > t) > P(Y > t) & \text{kiekvienam } t, \end{cases} \quad (2)$$

ir

$$\begin{cases} H_0: P(X > t) = P(Y > t) & \text{kiekvienam } t, \\ H_1: P(X > t) < P(Y > t) & \text{kiekvienam } t. \end{cases} \quad (3)$$

Nesunku suvokti, kad $P(X > t) = P(Y > t)$ tėra tik matematinis sakinio „skirstiniai nesiskiria“ užrašas. Kaip suprasti vienpusę alternatyvą $P(X > t) > P(Y > t)$? Jos žodinė formulė yra tokia: kintamasis X „linkęs“ įgyti didesnes reikšmes už Y , jo skirstinys „koncentruotas“ dešiniau Y skirstinio. Kartais dar sakoma, kad X *tikimybiškai didesnis* už Y . Analogiškai formuluojama ir kita vienpusė alternatyva. Vienpusių alternatyvų esmė lengviau suprantama pažvelgus į 1.1 paveikslą.



Dvipusę alternatyvą „skirstiniai skiriasi“ suprantame kaip teiginį, kad X skirstinys „koncentruotas“ arba dešiniau, arba kairiau Y skirstinio, t. y. kaip abiejų vienpusių alternatyvų junginį:

$$\begin{cases} H_0: P(X > t) = P(Y > t) & \text{kiekvienam } t, \\ H_1: P(X > t) > P(Y > t) & \text{arba } P(X > t) < P(Y > t) \text{ kiekvienam } t. \end{cases} \quad (4)$$

Žinoma, nors toks užrašas matematiškai ir teisingas, jis nėra itin patogus vartoti. Todėl, užuot naudojęsi juo, dažnai taikysime (1) formuluotę.



Jeigu X skirstinys yra toks pat kaip $Y + a$, tai alternatyva „skirstiniai skiriasi“ ekvivalenti teiginiui $a \neq 0$; alternatyva „ X 'linkęs' įgyti didesnes reikšmes už Y “ ekvivalenti teiginiui $a > 0$; alternatyva „ X 'linkęs' įgyti mažesnes reikšmes už Y “ ekvivalenti teiginiui $a < 0$.

1.1.3. Neparametrinių kriterijų sudarymo principai

Kaip neparametriniai kriterijai taikomi mažoms imtims? Pateiksime paprasčiausią tokių kriterijų sudarymo ir taikymo pavyzdį, iš kurio turėtų paaiškėti šio skyriaus kriterijų sudarymo logika.

1.1 pavyzdys. Stebime tolydžių kintamųjų porą (X, Y) . Norime patikrinti hipotezę, kad X ir Y skirstiniai yra vienodi. Tarkime, reikšmingumo lygmuo $\alpha = 0,1$. Duomenys pateikti 1.1 lentelėje.

1.1 lentelė

X	15	18	11	12
Y	6	13	4	9

Sprendimas. Tarkime, kad X ir Y skirstiniai yra vienodi. Tada vienodai galimai X gali viršyti Y , ir atvirkščiai, t. y. $P(X < Y) = P(X > Y) = 1/2$. Iš 1.1 lentelės matyti, kad $x_1 > y_1$, $x_2 > y_2$, $x_3 > y_3$, $x_4 > y_4$. Imtį sudaro nepriklausomos poros, todėl tikimybė, kad visus keturis kartus X stebėjimai viršys Y stebėjimus, yra lygi $(1/2)^4 = 1/16 = 0,0625$. Mes apskaičiavome, kiek tikėtina, kad keturis kartus stebint vienodus skirstinius turinčių kintamųjų porą (X, Y) pirmoji koordinatė viršys antrąją, t. y. ne ką kitą kaip p -reikšmę (žr. [1], 3.3.2 skyrelį). Palyginti su reikšmingumo lygmeniu $\alpha = 0,1$, apskaičiuotoji tikimybė yra maža ($0,0625 < 0,1$). Taigi mažai tikėtina, kad X ir Y skirstiniai sutampa. Todėl hipotezę H_0 apie skirstinių vienodumą atmetame.

Atkreipiame dėmesį, kad taikant tikslus kriterijus nesinaudojama papildomomis sąlygomis. Be to, jie netinkami didelėms imtims, nes skaičiavimų apimtys yra milžiniškos.

Didelėms imtims taikomi asimptotiniai kriterijai. Šioje knygoje mažoms imtims taikomi tikslūs kriterijai, o didelėms imtims naudojama normalioji arba χ^2 aproksimacija.

1.1.4. Duomenų rangavimas

Ne viename aprašomų šiame skyriuje kriterijų pavadinime yra žodis *ranginis*. Priežastis – daugelio čia aptariamų kriterijų viena iš sudėtinių dalių yra *duomenų rangavimas*. Kas tai yra?

Panagrinėkime tokį pavyzdį. Žinome 8-ių atsitiktinai parinktų žmonių mėnesio pajamas: 610, 560, 680, 1710, 990, 2700, 650, 640 Lt. Sudarykime variacinę eilutę ir priskirkime duomenų reikšmėms vietas (mažiausia reikšmė – pirma vieta, didžiausia reikšmė – aštunta ir t. t.). Toks vietų priskyrimas vadinamas duomenų rangavimu, o vietos – duomenų rangais. Surangavę nagrinėjamus duomenis, gauname 1.2 lentelę.

1.2 lentelė. Duomenys ir jų rangai

Duomenys	610	560	680	1710	990	2700	650	640
Eilės Nr.	1	2	3	4	5	6	7	8
Rangas	2	1	5	7	6	8	4	3

Kaip atliekamas duomenų rangavimas, kai joje yra pasikartojančių reikšmių? Tarkime, duomenys yra tokie: 610, 560, 680, 1710, 990, 660, 660, 660. Matome, kad sutampančios duomenų reikšmės „dalijasi“ 3–5 vietomis (yra variacinės eilutės 3–5 vietose). Šioms reikšmėms priskiriamas vidutinis „užimamų“ vietų rangas: $(3 + 4 + 5)/3 = 4$. Taigi po rangavimo turėsime tokią lentelę:

1.3 lentelė. Rangavimas, kai yra vienodų reikšmių


Duomenys	610	560	680	1710	990	660	660	660
Eilės Nr.	1	2	3	4	5	6	7	8
Rangas	2	1	6	8	7	4	4	4

Nesunku suprasti, kad rangų suma S lygi duomenų eilės numerių sumai, t. y.

$$S = 1 + 2 + 3 + \dots + n = \frac{n(n+1)}{2}.$$



1722 metais Petras I surangavo visą Rusiją. Kiekvienas rangas atitiko karinį laipsnį.



Matavimų pagal rangų skalę nereikėtų painioti su pačiais rangais. Pavyzdžiui, studento Petraičio matematikos egzamino įvertinimas 4 akademiniėje grupėje yra blogiausias; čia įvertinimas pagal rangų skalę lygus 4 balams, įvertinimo rangas lygus 1.

Kartais rangai atsiranda natūraliai. Tarkime, dailiojo čiuožimo arbitras kiekvienai porai skiria vietą – pirmą, antrą ir t. t. Taigi visus dalyvius jis suranguoja.

Pastaba. Apskritai kalbant, šiame skyriuje aptariami kriterijai yra taikomi, kai matuojami tolydūs kintamieji. Tada pasikartojančių reikšmių tikimybė yra lygi 0. Tačiau jei matuojama pagal rangų skalę, tokių reikšmių gali pasitaikyti. Reikšmės, kurioms priskiriami vienodi rangai, vadinamos *susietosiomis* reikšmėmis. Kai susietų reikšmių yra daug, taikomos specialios statistikų pataisos. Vengdami detalizavimo, šiame skyriuje situacijų, kai yra susietų reikšmių, smulkiai nenagrinėsime. Beje, jei susietų reikšmių yra mažai, skaičiavimams jų galima nenaudoti (t. y. susieti stebėjimai iš duomenų pašalinami).

1.2. Imties atsitiktinumo tikrinimas. Serijų kriterijus

Šioje knygoje duomenys laikomi atsitiktinės imties realizacijomis. Ar turint imties realizaciją galima patikrinti imties atsitiktinumą? Pasirodo, galima. Serijų kriterijus – neparametrinis kriterijus imties atsitiktinumui tikrinti. Jis pagrįstas duomenų rinkimo *eiliškumu* (t. y. žinojimu, po kurio duomens kuris kitas duomuo buvo gautas), todėl jį taikyti galima tik tada, kai tokį duomenų eiliškumą galima nustatyti. Apdorojant sociologinius duomenis, duomenų rinkimo eiliškumas paprastai nežinomas, tuo tarpu gamyboje matuojant detales jis nesunkiai nustatomas.

Tarkime, kaimo šviesuolis Ambraziejus 20 metų fiksavo gerų ir blogų metų kaitą. Duomenys yra tokie: *GGGGGGGGGGBBBBBBBBBBB*. Taigi 10 kartų iš eilės buvo geri metai, o 10 – blogi. Jeigu geri metai blogus keistų atsitiktinai, tai tokia seka būtų mažai tikėtina. Jau greičiau ji patvirtina liaudies išmintį, kad „kai seka si, tai sekasi“ ir „bėda viena nevaikšto“. O dabar tarkime, kad buvo tokia metų seka: *GBGBGBGBGBGBGBGBGBGBGB*. Vargu ar ji atsitiktinė.

Serijų kriterijus remiasi serijos (posekio) sąvoka.

Serija yra seka tų pačių simbolių, prieš kuriuos ir po kurių yra skirtingi simboliai.

Kai visi simboliai vienodi, turime vieną seriją. Aprašytose situacijose pirmu atveju yra dvi serijos, antruoju – dvidešimt.

Skirsime mažų imčių ir didelių imčių serijų kriterijus.

1.2.1. Mažų imčių atvejis ($n_1 \leq 20$, $n_2 \leq 20$)

1 *Duomenys.* Kintamojo X stebėjimus $x_1, x_2, \dots, x_n$ pertvarkome į dvireikšmius duomenis taip: stebėjimą keičiame 1 (sėkmė) arba 0 (nesėkmė) priklausomai nuo to, ar stebėjimas ne mažesnis, ar mažesnis už pasirinktą skaičių (dažniausiai už empirinį vidurkį, medianą arba modą). Pavyzdžiui, duomenys 10; 20; 30; 40 po pakeitimo, kai pasirinktasis skaičius yra vidurkis, atrodo taip: 0; 0; 1; 1. Jei kintamasis yra kategorinis, tai jis į dvireikšmį pertvarkomas keičiant kategorijų kodus (kaip, nusprendžia pats tyrėjas, tai jau ne statistiko problema). Tarkime, po pertvarkymo imtyje yra n_1 vienetų ir n_2 nulių.

2 Statistinė hipotezė:

$$\begin{cases} H_0: \text{imtis atsitiktinė,} \\ H_1: \text{imtis neatsitiktinė.} \end{cases} \quad (5)$$

3 Kriterijaus statistika. Randame serijų skaičių r . Jis ir yra kriterijaus statistika.

4 Sprendimo priėmimo taisyklė. Tegul reikšmingumo lygmuo lygus α^1 . Iš 9 ir 10 lentelių randame n_1 ir n_2 atitinkančius skaičius. Hipotezė H_0 atmetama, jeigu r ne didesnis už mažesnį iš rastųjų skaičių (iš 9 lentelės) arba ne mažesnis už didesnį skaičių (iš 10 lentelės). Priešingu atveju (jeigu r pakliūna tarp abiejų skaičių) imtį laikome atsitiktine.



Patikrinti hipotezę galime ir be lentelių. Žinodami imties didumą n , pirmojo ir antrojo tipo narių skaičius n_1 ir n_2 ($n = n_1 + n_2$) bei serijų skaičių r , galime apskaičiuoti tikimybę įvykio, kad atsitiktinės imties serijų skaičius yra ne mažesnis (ne didesnis) už r . Jei ši tikimybė, palyginti su α , maža, darome išvadą, kad imtis nėra atsitiktinė. Taigi elgiamės taip, kaip ir aptarėme pirmajame skyrelyje.

1.2 pavyzdys. Didelės firmos 24 paskutinių paskyrimų į atsakingus postus eilė atrodo taip: $V M V V V V M V V V M M M M V M M V V V M M M M$; čia V – vyras, M – moteris. Reikia patikrinti imties atsitiktinumą (t. y. ar pretendento į aukštą postą lytis neturėjo įtakos vadovybės sprendimams).

Sprendimas. Tarkime, reikšmingumo lygmuo $\alpha = 0,05$. Apskaičiuojame $r = 10$, $n_1 = 12$, $n_2 = 12$. Pažiūrėję į 9 ir 10 lenteles, matome, kad hipotezę apie atsitiktinumą turėsime atmesti, jei $r \leq 7$ arba $r \geq 19$ (t. y. statistikos r kritinė sritį sudaro intervalai $[0, 7]$ ir $[19, 24]$).

Kadangi $7 < r < 19$, hipotezės apie imties atsitiktinumą atmesti negalime. Taigi negalime teigti, kad šioje firmoje skiriant į atsakingus postus yra lyčių diskriminacija.

1.2.2. Didelių imčių atvejais ($n_1 > 20$, $n_2 > 20$)

1 Duomenys. Tarkime, turime kintamojo X stebėjimus $x_1, x_2, \dots, x_n$. Kaip ir mažų imčių atveju, kiekvieną stebėjimą pakeičiame 1 (sėkmė) arba 0 (nesėkmė) priklausomai nuo to, ar stebėjimas didesnis, ar mažesnis už pasirinktą skaičių. Tarkime, po pakeitimo imtyje yra n_1 vienetų ir n_2 nulių.

2 Statistinė hipotezė:

$$\begin{cases} H_0: \text{imtis atsitiktinė,} \\ H_1: \text{imtis neatsitiktinė.} \end{cases} \quad (6)$$

3 Kriterijaus statistika. Randame serijų skaičių r . Didelių atsitiktinių imčių serijų skaičiaus skirstinys r aproksimuojamas normaliuoju skirstiniu, kurio vidurkis ir standartinis nuokrypis yra atitinkamai:

$$\mu = \frac{2n_1n_2}{n_1 + n_2} + 1, \quad \sigma_r = \sqrt{\frac{2n_1n_2(2n_1n_2 - n_1 - n_2)}{(n_1 + n_2)^2(n_1 + n_2 - 1)}}.$$

¹ Knygoje pateikiamos lentelės tik atveju $\alpha = 0,05$.

Apskaičiuojame

$$Z = \frac{r - \mu}{\sigma_r}.$$

- 4** *Sprendimo priėmimo taisyklė.* Tegul reikšmingumo lygmuo lygus α . Hipotezė H_0 atmetama, jeigu $|Z| > z_{\alpha/2}$; čia $z_{\alpha/2}$ yra standartinio normaliojo skirstinio $\alpha/2$ lygmens kritinė reikšmė. Priešingu atveju H_0 neatmetama.

1.3 pavyzdys. Degalinėje yra A-92 (A) ir A-95 (B) oktaninio skaičiaus benzino. Vieną dieną 50 mašinų benzino A ir B prisipylė tokia tvarka: AABAABABBAABBBABBABBABBABBABBABBABBAABBBBAABABABAAAABA.

Ar galima teigti, kad benzino rūšies pasirinkimas yra atsitiktinis (t. y. paros metas neturi įtakos benzino rūšies pasirinkimui)?

Sprendimas. Tarkime, reikšmingumo lygmuo $\alpha = 0,05$. Apskaičiuojame $n_1 = 24$, $n_2 = 26$, $r = 31$,

$$\mu = \frac{31}{24 + 26} + 1 = 25,96, \quad \sigma_r = \sqrt{\frac{2 \cdot 26 \cdot 24(2 \cdot 24 \cdot 26 - 24 - 26)}{(24 + 26)^2(24 + 26 - 1)}} = 3,49.$$

$$Z = \frac{31 - \mu}{\sigma_r} = 1,44.$$

Kadangi $Z = 1,44 < 1,96 = z_{0,025}$, hipotezės apie imties atsitiktinumą atmesti negalima.

Kriterijaus taikymas naudojantis SPSS paketu. Taikydami serijų kriterijų, turime nurodyti, su kokia reikšme stebėjimus lyginti. Mažesni už šią reikšmę stebėjimai keičiami 0, didesni arba lygūs jai keičiami 1. Kaip ir kitais atvejais, nulinė hipotezė atmetama, jeigu atitinkama p -reikšmė mažesnė už reikšmingumo lygmenį.

Tegul reikšmingumo lygmuo yra α , o p -reikšmė lygi p . Tuomet darome išvadą, kad:

stebėjimų seka atsitiktinė, jeigu $p \geq \alpha$;
stebėjimų seka neatsitiktinė, jeigu $p < \alpha$.

SPSS rezultatai 1.3 pavyzdžio atveju pateikti 1.2 paveiksle. Lentelėje pateikiama: a) skaičius, kurio atžvilgiu duomenys buvo pertvarkyti į dvireikšmius (Test Value = 1); b) nulių (Cases < Test Value) skaičius $n_1 = 24$ ir vienetų (Cases $\geq$ Test Value) skaičius $n_2 = 26$; c) serijų skaičius (Number of Runs) $r = 31$; d) statistikos Z realizacija 1,443 ir e) p -reikšmė (Asymp. Sig. (2-tailed)), lygi 0,149. Kadangi $p = 0,149 > 0,05$, tai H_0 atmesti nėra pagrindo.

RUNS TEST	
	BENZINAS
Test Value	1
Cases < Test Value	24
Cases $\geq$ Test Value	26
Total Cases	50
Number Of Runs	31
Z	1,443
Asymp. Sig. (2-tailed)	,149

1.2 pav.

Labai dažnai imties atsitiktinumo kriterijus taikomas kokybės kontrolės uždaviniams, norint nustatyti, ar nuokrypia nuo normos yra atsitiktiniai, ar ne.

1.3. Vilkoksono ženklų kriterijus priklausomoms imtims

Ar vyrų ir žmonių šeimoje pajamos yra vienodos; ar studentai geriau išlaiko rudens nei pavasario sesijos egzaminus; ar individualių įmonių šių metų pelnas toks pat kaip ir praeitų; ar knygoms skaityti skiriama daugiau laiko, nei žiūrėti TV? Tokiems ir panašiams uždaviniams spręsti naudojamas porinis Stjudento kriterijus (Stjudento kriterijus priklausomoms imtims), kurį aprašėme pirmojoje knygoje. Prisiminkime prielaidas, būtinas taikant šį kriterijų. Stebima tolydžių normaliai pasiskirsčiusių kintamųjų pora (X, Y) . Duomenis sudaro matavimų poros, t. y. turime dvi priklausomas normalių populiacijų imtis.

O jei normalumo sąlyga netenkinama arba jos patikrinti negalima (pavyzdžiui, duomenų mažai)? Tada taikomas Vilkoksono¹ ženklų kriterijus priklausomoms imtims. Jis yra Stjudento porinio kriterijaus neparametrinis analogas.

Atkreipiame dėmesį, kad Vilkoksono kriterijus galingiausias, kai kintamųjų skirstiniai skiriasi tik postūmio parametru, t. y. X skirstinys sutampa su $Y + a$ skirstiniu. Būtent tokiems duomenims jį ir rekomenduojame taikyti.

1.3.1. Mažų imčių atvejis ($n \leq 25$)

1 *Duomenys.* Stebime tolydžių kintamųjų porą (X, Y) . Duomenys $(x_1, y_1), \dots, (x_n, y_n)$ gauti matavimams naudojant santykių, intervalų arba rangų skalę.

2 *Statistinė hipotezė:*

$$\begin{cases} H_0: \text{kintamųjų skirstiniai vienodi,} \\ H_1: \text{kintamųjų skirstiniai nėra vienodi.} \end{cases}$$

3 *Kriterijaus statistika.* Apskaičiuojame kiekvienos poros duomenų skirtumą $d_i = x_i - y_i$, $i = 1, \dots, n$. Jeigu $d_i = 0$ (t. y. $x_i = y_i$), tai šios d_i reikšmės tolesniems skaičiavimams nebenaudojame, o imties didumą laikome lygiu nenulinių d_i reikšmių skaičiui. Randame visų d_i absoliučiuosius didumus $|d_i|$ ir juos ranguojame. Rangas, atitinkantis neigiamą d_i reikšmę, vadinamas neigiamuoju, rangas, atitinkantis teigiamą d_i reikšmę, vadinamas teigiamuoju rangų. Apskaičiuojame teigiamų T^+ ir neigiamų T^- rangų sumas. Kriterijaus statistika pasirenkame T^+ .

4 *Sprendimo priėmimo taisyklė.* Tarkime, reikšmingumo lygmuo yra α . T^+ palyginame su 8 lentelės kritine reikšme, atitinkančia: a) imties didumą n , b) reikšmingumo lygmenį α , c) alternatyvos tipą (dvipusę alternatyvą). Jei statistikos reikšmė mažesnė už kritinę reikšmę, hipotezę apie skirstinių vienodumą atmetame.

Pastaba. Kadangi $T^- + T^+ = n(n + 1)/2$, tai sprendimą galime priimti pagal bet kurią iš statistikų T^+ ar T^- . Taigi Vilkoksono kriterijų galima performuluoti ir tuo atveju, kai statistika yra T^- .

¹ Frank Wilcoxon (1892–1965) – amerikiečių statistikas.

Alternatyvos gali būti ir vienusės: $H_1: P(X > t) > P(Y > t)$ arba $P(X > t) < P(Y > t)$ (žr. 1.1 skyrelį). Svarbu išsiaiškinti, kokia turi būti pasirinktoji statistika esant teisingai alternatyvai H_1 – „didelė“ ar „maža“. Tada lieka nustatyti, ar apskaičiuotoji statistikos reikšmė iš tikrųjų tokia didelė (maža), kad imties atsitiktinumu to jau nelabai bepaaiškinsi. Tai daroma taip:

- Iš 8 lentelės randamos reikšmingumo lygmenį α atitinkančios vienusės alternatyvos kritinės reikšmės.
- Nustatome, kuri iš statistikų – T^+ ar T^- turi būti maža, kai H_1 teisinga.
- Alternatyvą H_1 priimame, kai apskaičiuotoji statistikos reikšmė yra mažesnė už kritinę reikšmę; priešingu atveju paliekame nulinę hipotezę H_0 .

Pavyzdžiui, jeigu alternatyva yra $H_1: P(X > t) > P(Y > t)$ (X „linkęs“ viršyti Y), tai X rangai turi dažnai viršyti Y rangus. Todėl nulinę hipotezę H_0 galime atmesti (pripažinti, kad X iš tikrųjų „didesnis“ už Y), jeigu T^- yra mažesnė už reikšmingumo lygmenį α atitinkančią vienusės alternatyvos kritinę reikšmę, rastą iš 8 lentelės.

Analogiškai alternatyva $P(X > t) < P(Y > t)$ priimama, jei T^+ mažesnė už α atitinkančią vienusės alternatyvos kritinę reikšmę, rastą iš 8 lentelės.

1.4 pavyzdys. Tirti naujų migdomųjų vaistų efektyvumą kariuomenėje atsitiktinai buvo paskirti 8 „savariniai“. Pirmą naktį jie gavo migdomųjų, antrąją – placebo¹. Laikas (min.), per kurį jie užmigo, pateiktas 1.4 lentelėje. Ar šie vaistai tinkami vartoti? (Reikšmingumo lygmuo $\alpha = 0,025$.)

1.4 lentelė. Užmigimo greitis

I imtis (vaistai)	12	9	11	21	20	22	18	11
II imtis (placebo)	21	16	8	36	28	20	28	23
d_i	-9	-7	3	-15	-8	2	-10	-12
$ d_i $	9	7	3	15	8	2	10	12
Rangas	5	3	2	8	4	1	6	7

Sprendimas. Statistinė hipotezė:

$$\begin{cases} H_0: \text{vaistai užmigimo greičiui neturi įtakos,} \\ H_1: \text{vaistai padeda greičiau užmigti.} \end{cases}$$

Atkreipiame dėmesį, kad alternatyva yra vienusė – mes nurodėme, ko tikimės iš vaistų. Jie turi padėti greičiau užmigti. Taigi užmigimo su vaistais trukmės turi būti apskritai mažesnės nei be vaistų (t.y. galime tikėtis, kad T^+ bus mažas). Surašome $|d_i|$, $i = 1, \dots, 8$, didėjimo tvarka ir suranguojame. Apskaičiuojame $T^+ = 1 + 2 = 3$, $T^- = 5 + 3 + 8 + 4 + 6 + 7 = 33$.

Patikriname rangų sumą $T^+ + T^- = 8 \cdot 9/2 = 36$. Gautą T^+ reikšmę lyginame su 8 lentelės kritine reikšme, atitinkančia imties didumą $n = 8$, reikšmingumo lygmenį $\alpha = 0,025$ bei vienusės alternatyvos atvejį, t.y. su 4. Kadangi $T^+ = 3 < 4$, gauname, kad nulinę hipotezę reikia atmesti – vaistai padeda greičiau užmigti.

¹ Lot. *placebas* – neveiklus preparatas, skiriamas naujų vaistų kontrolės arba ligonių įtaigos tikslais.



Pastebėsime, kad patikrinti, ar hipotezė teisinga, ar ne, galima ir be lentelių. Mažoms imtims galima tiksliai apskaičiuoti tikimybę įvykio, kad T^+ įgis ne didesnę reikšmę kaip 3 (esant prielaidai, kad H_0 teisinga!), t. y. statistikos p -reikšmę. Priminsime p -reikšmės taikymo logiką. Jeigu p -reikšmė nėra maža (ne mažesnė už α), tai samprotausime taip: visai tikėtina, kad galiojant H_0 nagrinėjamoji statistika įgis reikšmę, ne didesnę kaip 3 (taigi čia joks stebuklas), todėl H_0 neatmesime. Jeigu p -reikšmė pasirodys mažesnė nei α , tai samprotausime taip: mažai tikėtina, kad galiojant H_0 statistika įgis reikšmę, ne didesnę kaip 3 (bet taip ėmė ir atsitiko), todėl hipotezę H_0 atmesime. Taigi H_0 atmesime, jeigu apskaičiuotoji tikimybė bus mažesnė už α .

Kiekviena rangų eilutė vienodai galima. Mus domina, ar konkretus rangas atitinka teigiamą skirtumą, ar neigiamą. Galime sudaryti 2^8 skirtingų rangų eilučių (primename, kad tariame, jog vieno rangų nėra). Kiek yra situacijų, kad T^+ reikšmė būtų ne didesnė kaip 3? Tokių variantų yra penki: visai nėra teigiamų skirtumų (tada $T^+ = 0$); yra vienintelis, mažiausią modulį turintis teigiamas skirtumas (tada $T^+ = 1$); yra vienas teigiamas skirtumas, turintis antrą pagal mažumą modulį (tada $T^+ = 2$); yra vienas modulių trečias pagal didumą skirtumas (tada $T^+ = 3$); yra du mažiausius modulius turintys teigiami skirtumai (tada $T^+ = 1 + 2 = 3$).

Taigi galima tiksliai apskaičiuoti „teisingos“ hipotezės atmetimo tikimybę:

$$P(T^+ \leq 3 | H_0) = \frac{\text{variantų skaičius, kai } T^+ \leq 3}{2^8} = \frac{5}{2^8} = 0,019.$$

Jei p -reikšmė mažesnė už reikšmingumo lygmenį, tai hipotezė H_0 atmetama. Kadangi $0,019 < 0,025$, tai H_0 atmetame ir dar kartą įsitikiname, kad vaistai padeda greičiau užmigti.

1.3.2. Didelių imčių atvejis ($n > 25$)

1 Duomenys. Stebime tolydžių kintamųjų porą (X, Y) . Duomenys $(x_1, y_1), \dots, (x_n, y_n)$ gauti matavimams naudojant santykių, intervalų arba rangų skalę.

2 Statistinė hipotezė:

$$\begin{cases} H_0: \text{kintamųjų skirstiniai vienodi,} \\ H_1: \text{kintamųjų skirstiniai nėra vienodi.} \end{cases}$$

3 Kriterijaus statistika. Apskaičiuojame:

$$\mu = \frac{n(n+1)}{4}, \quad \sigma = \sqrt{\frac{n(n+1)(2n+1)}{24}}, \quad Z = \frac{T^+ - \mu}{\sigma}.$$

1.5 lentelė. H_0 : X ir Y skirstiniai lygūs

Alternatyva H_1	H_0 atmetama, jeigu	H_0 neatmetama, jeigu
$P(X > t) > P(Y > t)$ arba $P(X > t) < P(Y > t)$	$ Z > z_{\alpha/2}$	$ Z \leq z_{\alpha/2}$
$P(X > t) > P(Y > t)$	$Z > z_{\alpha}$	$Z \leq z_{\alpha}$
$P(X > t) < P(Y > t)$	$Z < -z_{\alpha}$	$Z \geq -z_{\alpha}$

4 *Sprendimo priėmimo taisyklė.* Tarkime, reikšmingumo lygmuo lygus α . Jei $|Z| > z_{\alpha/2}$, hipotezę H_0 atmetame (skirstiniai skiriasi); čia $z_{\alpha/2}$ yra standartinio normaliojo skirstinio $\alpha/2$ lygmens kritinė reikšmė. Priešingu atveju nulinės hipotezės neatmetame.

Pastaba. Alternatyvos gali būti ir vienpusės: $H_1: P(X > t) > P(Y > t)$ arba $P(X > t) < P(Y > t)$. Sprendimo priėmimo taisyklės vienusių alternatyvų atveju pateiktos 1.5 lentelėje.



Irodysime, kad jei hipotezė H_0 teisinga, tai $Z \approx \mathcal{N}(0, 1)$. Iš tiesų $T^+ = \sum_{j=1}^n jW_j$; čia W_j yra $|d|_{(j)}$ rangas:

$$W_j = \begin{cases} 1, & \text{jei } |d|_{(j)} \text{ atitinka teigiamą stebėjimą,} \\ 0, & \text{jei } |d|_{(j)} \text{ atitinka neigiamą stebėjimą.} \end{cases}$$

Yra žinoma, jei hipotezė H_0 teisinga, tai $W_1, W_2, \dots, W_n$ yra nepriklausomi, vienodai pasiskirstę, dvireikšmiai atsitiktiniai dydžiai: $P(W_j = 0) = P(W_j = 1) = 1/2$. Tuomet statistikos T^+ vidurkis ir dispersija atitinkamai yra:

$$\begin{aligned} \mathbf{E}T^+ &= \mathbf{E} \sum_{j=1}^n jW_j = \sum_{j=1}^n j\mathbf{E}W_j = \sum_{j=1}^n \frac{(n+1)}{2} \cdot \frac{1}{2} = \frac{n(n+1)}{4}, \\ \mathbf{D}T^+ &= \mathbf{D} \sum_{j=1}^n jW_j = \sum_{j=1}^n j^2\mathbf{D}W_j = \sum_{j=1}^n j^2 \frac{1}{4} = \frac{n(n+1)(2n+1)}{24}. \end{aligned}$$

Pasinaudojus centrine ribine teorema, galima teigti, kad dideliems n (pvz., $n > 25$)

$$Z = \frac{T^+ - \mathbf{E}T^+}{\sqrt{\mathbf{D}T^+}} \approx \mathcal{N}(0, 1).$$

1.5 pavyzdys. Ar tikrai moterų ir vyrų plaukų kirpimo kainos skiriasi (nekalbame apie papildomas paslaugas – dažymą, cheminį šukavimą ir pan.)? Atsitiktinai parinkus 25 kirpyklas, kuriose kerpami tiek vyrai, tiek moterys, gauti rezultatai pateikti 1.6 lentelėje. Tarkime, reikšmingumo lygmuo $\alpha = 0,05$.

Sprendimas. Tarkime, (X, Y) yra moterų ir vyrų kirpimo kainų pora. Atrodytų, kad turime dvi nepriklausomas imtis – vyrų ir moterų, tačiau taip nėra. Vienijantis veiksnys yra kirpykla. Mus domina, ar kirpyklos vienodai brangiai įkainoja vyrų ir moterų kirpimą. Toks duomenų struktūrinimas abi imtis leidžia traktuoti kaip priklausomas.

1.6 lentelė. Kirpyklų duomenys

Moterų kirpimas	Vyrų kirpimas	d_i	$ d_i $	Rangas	Moterų kirpimas	Vyrų kirpimas	d_i	$ d_i $	Rangas
30	32,8	-2,8	2,8	14	16,5	14	2,5	2,5	13
18,1	20	-1,9	1,9	10	21	18	3	3	15
10	11,4	-1,4	1,4	8	30	26,5	3,5	3,5	16
8	8,3	-0,3	0,3	2	27	23	4	4	17
18,2	18	0,2	0,2	1	30	25,5	4,5	4,5	18
15,4	15	0,4	0,4	3	12	7	5	5	19
19,9	19	0,9	0,9	4	40	34	6	6	20
20	19	1	1	5	20	11	9	9	21
20	18,8	1,2	1,2	6	20	10	10	10	22
14,8	13,5	1,3	1,3	7	27	16	11	11	23
14,6	13	1,6	1,6	9	35	23	12	12	24
15	13	2	2	11	35	22	13	13	25
20	17,8	2,2	2,2	12					

Formuluojame statistinę hipotezę:

$$\begin{cases} H_0: \text{kintamųjų skirstiniai vienodi,} \\ H_1: \text{kintamųjų skirstiniai nėra vienodi.} \end{cases}$$

Apskaičiuojame $Z = -3,46$. Kadangi $|Z| > 1,96 = z_{0,025}$, tai hipotezę H_0 atmetame. Moterų ir vyrų kirpimo kaina nevienoda.

Vilkoksono kriterijaus taikymas naudojantis SPSS paketu. SPSS paketu tikrinama tik dvipusė alternatyva (H_1 : skirstiniai skiriasi).

Tegul reikšmingumo lygmuo yra α , o p -reikšmė lygi p . Tuomet darome išvadą, kad:
 skirstiniai skiriasi, jeigu $p < \alpha$;
 skirstiniai nesiskiria, jeigu $p \geq \alpha$.

SPSS rezultatai 1.5 pavyzdžio atveju pateikti 1.3 paveiksle. Eilutėje Negative Ranks pažymėta, kiek buvo kirpyklų, kuriose moterų kirpimo kaina viršijo vyrų kirpimo kainą ($N = 21$); šias kirpyklas atitinkančių rangų suma (Sum of Ranks = 291); vidutinis rangas (Mean Rank = $291/21 = 13,86$). Analogiška informacija pateikta apie kirpyklas, kuriose vyrų kirpimo kaina viršijo moterų kirpimo kainą. Antroje lentelėje yra statistikos Z reikšmė ($-3,458$) bei p -reikšmė (Asymp. Sig. (2-tailed) = 0,001). Kadangi $0,001 < 0,05$ (mažiau už reikšmingumo lygmenį), dar kartą įsitikiname, kad nulinę hipotezę H_0 reikia atmesti. Taigi vyrų ir moterų kirpimo kainos statistiškai reikšmingai skiriasi.

RANKS					TEST STATISTICS ^a	
		N	Mean Rank	Sum of Ranks		VK-MK
VK	Negative Ranks	21 ^a	13,86	291,00	Z	-3,458 ^b
MK	Positive Ranks	4 ^b	8,50	34,00	Asymp. Sig. (2-tailed)	,001
	Ties	0 ^c				
	Total	25				

^{a.} VK < MK
^{b.} VK > MK
^{c.} MK = VK

^{a.} Wilcoxon Signed Ranks Test.
^{b.} Based on positive ranks.

1.3 pav. Vilkoksono kriterijaus SPSS rezultatai



Vilkoksono kriterijumi galima tikrinti ir hipotezę, kad X skirstinys toks pat kaip aY (t.y. skiriasi normuojančiu, o ne postūmio parametru). Tuomet naudojama kitokia rangavimo sistema (žr. [2]).

1.3.3. Vilkoksono kriterijus vienai imčiai

Istoriškai Vilkoksono kriterijus buvo pasiūlytas kiek kitokiems uždaviniais spręsti.

Stebimas tolydus kintamasis X . Duomenys yra $x_1, x_2, \dots, x_n$. Norima patikrinti statistinę hipotezę

$$\begin{cases} H_0: X \text{ mediana lygi } m_0, \\ H_1: \text{mediana nelygi } m_0. \end{cases}$$

Pažymėję $d_i = x_i - m_0$, kriterijų ir uždavinio sprendimo taisyklę lengvai modifikuojame naudodamiesi dviejų kintamųjų atveju. Iš tikrųjų, jeigu H_0 teisinga, tai vienodai tikėtina, kad $d_i > 0$ arba $d_i < 0$ (abiejų įvykių tikimybės lygios $1/2$), todėl T^+ skirstinys yra toks pat kaip ir dviejų priklausomų imčių atveju.

1.6 pavyzdys. Firma „Kukaboro“ tvirtina, kad jos pateiktos naujos rūšies cigaretėse vidutiniškai yra tik 17 miligramų dervų. Atsitiktinai patikrinus 24 cigaretes, užfiksuoti tokie dervų kiekiai: 16,9; 16,6; 17,3; 17,5; 17,0; 17,2; 16,1; 16,4; 17,3; 15,9; 17,7; 18,3; 15,6; 16,8; 17,1; 17,2; 16,4; 18,1; 17,4; 16,7; 16,9; 16,0; 16,5; 17,8. Ar šie duomenys neprieštarauja firmos teiginiui? (Reikšmingumo lygmuo $\alpha = 0,05$.)

Sprendimas. Pažymėkime X dervų cigaretėse kiekį.

Formuluojame statistinę hipotezę

$$\begin{cases} H_0: Md = 17, \\ H_1: Md \neq 17. \end{cases}$$

Apskaičiuojame $d_i = x_i - 17$ bei $|d_i|$, $i = 1, \dots, 24$, ir modulius suranguojame (žr. 1.7 lentelę).

1.7 lentelė. Vilkoksono kriterijus vienai imčiai

Duomenys	16,9	16,6	17,3	17,5	17,0	17,2	16,1	16,4	17,3	15,9	17,7	18,3
$d_i = x_i - 17$	-0,1	-0,4	0,3	0,5	0	0,2	-0,9	-0,6	0,3	-1,1	0,7	1,3
$ d_i $	0,1	0,4	0,3	0,5	–	0,2	0,9	0,6	0,3	1,1	0,7	1,3
Rangas	2	10,5	8	12,5	–	5	18	14,5	8	20,5	16	22

Duomenys	15,6	16,8	17,1	17,2	16,4	18,1	17,4	16,7	16,9	16,0	16,5	17,8
$d_i = x_i - 17$	-1,4	-0,2	0,1	0,2	-0,6	1,1	0,4	-0,3	-0,1	-1	-0,5	0,8
$ d_i $	1,4	0,2	0,1	0,2	0,6	1,1	0,4	0,3	0,1	1	0,5	0,8
Rangas	23	5	2	5	14,5	20,5	10,5	8	2	19	12,5	17

Kadangi vienas stebėjimas sutapo su spėjama mediana, tai atitinkamą duomenį ignoruojame ir toliau laikome $n = 23$. Apskaičiuojame $z = -0,341$. Kadangi $|z| < z_{0,025}$, hipotezę H_0 atmesti nėra pagrindo. Duomenys neprieštarauja firmos teiginiui.



Rūkymas – pagrindinė statistikos priežastis.

1.4. Mano–Vitnio–Vilkoksono rangų sumų kriterijus nepriklausomoms imtims

Pirmoje knygoje aprašėme Stjudento kriterijų dviem nepriklausomoms imtims. Primename, kad šis kriterijus gali būti taikomas, kai reikia išsiaiškinti: ar moterų ekonomisčių vidutinis atlyginimas yra toks pat kaip ir vyrų ekonomistų; ar kauniečiai ir vilniečiai vidutiniškai vienodai sugaišta laiko vykdami į darbą; ar 3 mėnesių kūdikių mergaičių svoris toks pat kaip ir kūdikių berniukų ir pan.

Atlyginimas, laikas, svoris – tolydieji kintamieji. Tačiau Stjudento kriterijų galima taikyti tik tada, kai kintamieji normalieji. Pavyzdžiui, turėtume patikrinti prielaidą, kad kintamojo – atlyginimo ekonomisčių ir ekonomistų populiacijose skirstinys yra normalusis. Normalumo sąlyga ne visada tenkinama, be to, jei imtys mažos, šios sąlygos patikrinti neįmanoma.

Mano–Vitnio–Vilkoksono kriterijus yra Stjudento kriterijaus dviem nepriklausomoms imtims neparametrinis analogas. Kaip ir praeito skyrelio, šis kriterijus galingiausias, kai

kintamųjų skirstiniai skiriasi tik postūmio parametru, t. y. X skirstinys sutampa su $Y + a$ skirstiniu. Būtent tokiems duomenims jį ir rekomenduojame taikyti.



Penktajame praeito šimtmečio dešimtmetyje dviejų nepriklausomų imčių skirstinių lygybei tikrinti buvo pasiūlyti du ranginiai kriterijai. Pirmąjį pasiūlė Vilkoksonas, antrąjį – Manas ir Vitnis. Kadangi abu kriterijai yra ekvivalentūs, mes į pavadinimą įtraukėme visų trijų autorių pavardes. Kriterijus, kurį dėstome šiame skyrelyje, atitinka Mano–Vitnio¹ pasiūlytąjį.

1.4.1. Mažų imčių atvejis ($n_1 \leq 20$, $n_2 \leq 20$)

1 *Duomenys.* Dviejų tolydžiųjų nepriklausomų kintamųjų X ir Y stebėjimai yra $x_1, x_2, \dots, x_{n_1}$ ir $y_1, y_2, \dots, y_{n_2}$. Duomenys gauti matavimams naudojant santykių, intervalų arba rangų matavimų skalę.

2 *Statistinė hipotezė:*

$$\begin{cases} H_0: \text{kintamųjų skirstiniai vienodi,} \\ H_1: \text{kintamųjų skirstiniai nėra vienodi.} \end{cases}$$

3 *Kriterijaus statistika.*

1. Dvi imtis sujungiame į vieną išdėstydami jų narius didėjimo tvarka nuo mažiausio iki didžiausio stebėjimo (sudarome bendrą variacinę eilutę).
2. Eilutės nariams priskiriame rangus.
3. Apskaičiuojame statistikas:

$$U_1 = n_1 n_2 + \frac{n_1(n_1 + 1)}{2} - R_1, \quad U_2 = n_1 n_2 + \frac{n_2(n_2 + 1)}{2} - R_2;$$

čia R_1 ir R_2 – rangų, priskirtų atitinkamai pirmosios ir antrosios imčių nariams, suma.

4 *Sprendimo priėmimo taisyklė.* Tarkime, reikšmingumo lygmuo yra α . Iš 5 arba 6 lentelių randame n_1 ir n_2 atitinkančias *dvipusio kriterijaus* kritines reikšmes. Jeigu U_1 ne mažesnis už *didesniąją reikšmę* arba U_1 ne didesnis už *mažesniąją reikšmę*, tai nulinė hipotezė H_0 atmetama (skirstiniai skiriasi). Priešingu atveju H_0 neatmetama.

Pastaba. Kadangi $U_2 = n_1 n_2 - U_1$, tai kriterijų galima performuluoti ir statistikai U_2 .

Kai H_0 teisinga, mažoms imtims galima tiksliai apskaičiuoti tikimybę įvykio, kad U_1 įgis reikšmes, ne didesnes kaip gautoji konkrečioms imtims (t. y. p -reikšmę). Dvipusės alternatyvos atveju esant gautai p -reikšmei, mažesnei kaip $\alpha/2$, hipotezė H_0 reiktų atmesti.

Statistika U_1 parodo, kiek pirmos imties narių yra kairiau už kiekvieną antros imties narį.

Panagrinėkime tokį pavyzdį:

1 imtis: 9, 11, 15.

2 imtis: 6, 8, 10, 13.

¹ Henry B. Mann, D. R. Whitney – amerikiečių statistikai.

Variacinė eilutė	6	8	9	10	11	13	15
Imtis	2	2	1	2	1	2	1
Rangas	1	2	3	4	5	6	7

Paskaičiuokime, kiek jungtinėje variacinėje eilutėje pirmos imties narių yra kairiau už kiekvieną antrosios narį. Už 6 ir 8 mažesnių pirmos imties narių nėra, už 10 mažesnis vienas narys (9), už 13 mažesni du (9, 11). Taigi statistika $U_1 = 0 + 0 + 1 + 2 = 3$. Skaičiuodami statistikos reikšmę pagal formulę, gautume tą patį rezultatą:

$$U_1 = 3 \cdot 4 + \frac{3 \cdot 4}{2} - 15 = 3.$$

Beje, $U_1 = 0$ reikštų, kad visi pirmos imties nariai mažesni už antrosios, o $U_1 = 12$ reikštų, kad visi pirmos imties nariai didesni už antrosios narius. Taigi „didelės“ ir „mažos“ statistikos reikšmės kelia abejonių, ar stebimų kintamųjų skirstiniai vienodi.

1.7 pavyzdys. Muitininkas Apolinaras Smalsutis nutarė ištirti, ar dviejų maršrutų „Gauručiai–Baisučiai“ ir „Pūkučiai–Baisučiai“ traukiniai vėluoja vienodai. Lūkuriuodamas Baisučių stotelėje, jis surinko tokius duomenis apie pavėluotas minutes: maršrutu „Gauručiai–Baisučiai“ – 37; 1; 26; 23; 41; 8; 39, o maršrutu „Pūkučiai–Baisučiai“ – 46; 42; 53; 44; 30. (Reikšmingumo lygmuo $\alpha = 0,05$.)

Variacinė eilutė	1	8	23	26	30	37	39	41	42	44	46	53
Imtis	1	1	1	1	2	1	1	1	2	2	2	2
Rangas	1	2	3	4	5	6	7	8	9	10	11	12

Sprendimas. Tarkime, X yra pirmojo maršruto traukinių vėlavimo laikas, Y – antrojo maršruto traukinių vėlavimo laikas.

Formuluojame statistinę hipotezę:

$$\begin{cases} H_0: X \text{ ir } Y \text{ skirstiniai vienodi,} \\ H_1: X \text{ ir } Y \text{ skirstiniai nėra vienodi.} \end{cases}$$

Apskaičiuojame pirmos ir antros imčių rangų sumas:

$$R_1 = 1 + 2 + 3 + 4 + 6 + 7 + 8 = 31, \quad R_2 = 5 + 9 + 10 + 11 + 12 = 47.$$

Beje,

$$R_1 + R_2 = 1 + 2 + \dots + (n_1 + n_2) = \frac{(n_1 + n_2)(n_1 + n_2 + 1)}{2} = \frac{(7 + 5)(7 + 5 + 1)}{2} = 78.$$

Randame

$$U_1 = 7 \cdot 5 + \frac{7 \cdot 8}{2} - 31 = 32, \quad U_2 = 7 \cdot 5 + \frac{5 \cdot 6}{2} - 47 = 3.$$

Lyginame $U_1 = 32$ su 6 lentelės kritinėmis reikšmėmis (5, 30). Kadangi $32 > 30$, nulinę hipotezę atmetame. Taigi traukiniai vėluoja nevienodai.



Pakankamai mažos ar pakankamai didelės R_1 ar R_2 reikšmės kelia abejonių, ar hipotezė H_0 teisinga. Iš tikrųjų, jei hipotezė H_0 teisinga, tai R_2 skirstinys yra simetrinis, kurio vidurkis lygus $n_2(n_1 + n_2 + 1)/2 = 32,5$. Statistikos R_2 reikšmė yra 47. Kokia tikimybė, kad, esant teisingai hipotezei, R_2 gali įgyti reikšmes, ne mažesnes kaip 47? Jei hipotezė H_0 teisinga, tai penki antrosios imties nariai su vienoda tikimybe gali išsidėstyti bet kuriose jungtinės variacinės eilutės vietose, t. y. vienodai galimi $\binom{12}{5}$ variantai. O kiek yra variantų, kai R_2 yra ne mažesnė kaip 47. Pateikiame 12 galimų antrosios imties narių rangų sumų:

$$12 + 11 + 10 + 9 + 8 = 50, \quad 12 + 11 + 10 + 9 + 7 = 49, \quad 12 + 11 + 10 + 9 + 6 = 48,$$

$$12 + 11 + 10 + 8 + 7 = 48, \quad 12 + 11 + 10 + 9 + 5 = 47,$$

$$12 + 11 + 10 + 8 + 6 = 47, \quad 12 + 11 + 9 + 8 + 7 = 47.$$

$$P(R_2 \geq 47 | H_0) = \frac{\text{variantų skaič.}}{\binom{12}{5}} = 7/792 = 0,009.$$

Atsižvelgdami į tai, kad R_2 skirstinys simetrinis, o alternatyva dvipusė, apskaičiuojame teisingos hipotezės atmetimo tikimybę (p -reikšmę) $P = 2 \cdot 0,009 = 0,018$ ir hipotezę apie skirstinių lygybę atmetame. Panašu, kad Gauručių gyventojams pasisekė.

Alternatyvos gali būti ir vienosios – $H_1: P(X > t) > P(Y > t)$ arba $P(X > t) < P(Y > t)$ (žr. 1.1 skyrelį). Suformuluosime sprendimo taisykles. Tegul alternatyva yra $H_1: P(X > t) > P(Y > t)$ (X „linkęs“ viršyti Y). Jei alternatyva teisinga, tai X rangai dažnai didesni už Y rangus. Todėl R_1 būtų „didelis“, o U_1 – „mažas“. Belieka įsitikinti, ar apskaičiuota U_1 reikšmė pakankamai maža, kad alternatyvą H_1 būtų galima priimti. Taigi nulinę hipotezę H_0 reikia atmeti (pripažinti, kad X iš tikrųjų „didesnis“ už Y), jeigu U_1 reikšmė yra mažesnė už reikšmingumo lygmenį α atitinkančią mažesniąją vienosios alternatyvos kritinę reikšmę, rastą iš 5 arba 6 lentelių.

Analogiškai alternatyva $P(X > t) < P(Y > t)$ priimama, jei U_1 yra didesnė už α atitinkančią didesniąją vienosios alternatyvos kritinę reikšmę iš 5 arba 6 lentelių.

Pastaba. Primename, kad ta pati kritinių reikšmių lentelė tinka dvipusei $\alpha/2$ reikšmingumo lygmens alternatyvai ir vienosiai α reikšmingumo lygmens alternatyvai. Pavyzdžiui, 6 lentelė tinka, kai pasirinkę $\alpha = 0,05$ tikriname dvipusę arba esant $\alpha = 0,025$ tikriname vienosę alternatyvą.

1.4.2. Didelių imčių atvejis ($n_1 > 20, n_2 > 20$)

1 *Duomenys.* Tarkime, dviejų nepriklausomų tolydžių kintamųjų X ir Y stebėjimai yra $x_1, x_2, \dots, x_{n1}$ ir $y_1, y_2, \dots, y_{n2}$. Duomenys gauti matavimams naudojant santykių, intervalų arba rangų skalę.

2 *Statistinė hipotezė:*

$$\begin{cases} H_0: \text{kintamųjų skirstiniai yra vienodi,} \\ H_1: \text{kintamųjų skirstiniai nėra vienodi.} \end{cases}$$

3 *Kriterijaus statistika.* Apskaičiuojame statistiką

$$Z = \frac{U_1 - \mu}{\sigma}; \quad \text{čia} \quad \mu = \frac{n_1 n_2}{2}, \quad \sigma = \sqrt{\frac{n_1 n_2 (n_1 + n_2 + 1)}{12}}.$$

4 *Sprendimo priėmimo taisyklė.* Tarkime, reikšmingumo lygmuo yra α . Jei $|Z| > z_{\alpha/2}$, tai hipotezę H_0 atmetame (skirstiniai skiriasi); čia $z_{\alpha/2}$ yra standartinio normaliojo skirstinio $\alpha/2$ lygmens kritinė reikšmė. Priešingu atveju H_0 neatmetame.

Sprendimo priėmimo taisyklės vienosios alternatyvų atveju pateikiamos 1.8 lentelėje.

1.8 lentelė. H_0 : X ir Y skirstiniai lygūs

Alternatyva H_1	H_0 atmetama, jeigu	H_0 neatmetama, jeigu
$P(X > t) > P(Y > t)$ arba $P(X > t) < P(Y > t)$	$ Z > z_{\alpha/2}$	$ Z \leq z_{\alpha/2}$
$P(X > t) > P(Y > t)$	$Z < -z_{\alpha}$	$Z > z_{\alpha}$
$P(X > t) < P(Y > t)$	$Z > z_{\alpha}$	$Z \leq z_{\alpha}$



Jei hipotezė teisinga, tai tenkinama tokia lygybė:

$$P(r_i = j) = \frac{1}{n_1 + n_2}, \quad i = 1, \dots, n_1, \quad j = 1, \dots, n_1 + n_2;$$

čia r_i – pirmosios imties i -ojo stebėjimo rangas. Todėl

$$\mathbf{E}r_i = \sum_{j=1}^{n_1+n_2} \frac{j}{n_1 + n_2} = \frac{(n_1 + n_2 + 1)}{2}, \quad i = 1, \dots, n_1.$$

Tada

$$\mathbf{E}R_1 = \sum_{i=1}^{n_1} \mathbf{E}r_i = \frac{n_1(n_1 + n_2 + 1)}{2}.$$

Panašiai

$$\mathbf{E}R_2 = \frac{n_2(n_1 + n_2 + 1)}{2}, \quad \mathbf{D}R_1 = \mathbf{D}R_2 = \frac{n_1 n_2 (n_1 + n_2 + 1)}{12},$$

$$\mathbf{E}U_1 = n_1 n_2 + \frac{n_1(n_1 + n_2)}{2} - \mathbf{E}R_1 = n_1 n_2 + \frac{n_1(n_1 + n_2)}{2} - \frac{n_1(n_1 + n_2 + 1)}{2} = \frac{n_1 n_2}{2},$$

$$\mathbf{D}U_1 = \mathbf{D}R_1, \quad \mathcal{Z} = \frac{U_1 - \mathbf{E}U_1}{\sqrt{\mathbf{D}U_1}} \approx \mathcal{N}(0, 1).$$

1.8 pavyzdys. Daug metų vienoje aukštojoje mokykloje anglų kalbos pratybos vyksta rytais ir vakarais. Atsitiktinai parinktų 22 studentų, lankiusių anglų kalbos pratybas ryte, ir 25 studentų, lankiusių anglų kalbos pratybas vakare, vertinimų vidurkiai yra 1.9 lentelėje. Ar paros laikas turėjo įtakos mokymosi rezultatams? ($\alpha = 0,05$.)

Sprendimas. Tarkime, X yra rytinės grupės vertinimai, Y – vakarinės grupės vertinimai. Statistinė hipotezė:

$$\begin{cases} H_0: X \text{ ir } Y \text{ skirstiniai vienodi,} \\ H_1: X \text{ ir } Y \text{ skirstiniai nevienodi.} \end{cases}$$

1.9 lentelė. Mokymosi rezultatai

Rytinė grupė	7,20	6,80	8,25	9,05	9,40	9,65	6,15	5,83	5,92	6,00	5,23	7,50	5,20
Vakarinė grupė	7,10	6,70	8,30	8,90	9,35	9,60	6,50	6,20	5,90	6,05	5,00	7,80	6,60
Rytinė grupė	7,73	7,82	7,95	8,05	8,09	9,91	9,10	8,13	8,18				
Vakarinė grupė	7,75	8,00	9,22	9,00	8,30	7,70	5,10	7,60	5,50	5,65	6,10	6,90	

Apskaičiuojame $Z = -0,94$. Kadangi $|Z| = 0,94 < 1,96 = z_{0,025}$, hipotezės atmesti nėra pagrindo. Paros laikas mokymuisi įtakos neturėjo.

Mano–Vitnio–Vilkoksono kriterijaus taikymas naudojantis SPSS paketu. Aptarsime, kaip atrodo ką tik nagrinėto pavyzdžio SPSS rezultatai. SPSS paketu pateikiama kiekvienos grupės rangų suma Sum of Ranks (pvz., pirmos grupės rangų suma yra 572), duomenų skaičius (22) bei vidutinis rangas Mean Rank. Pirmos grupės vidutinis rangas yra $572/22 = 26$, antrosios – 22,24. Ką parodo vidutiniai rangai? Iš jų matyti, kurioje grupėje buvo daugiau didesnių reikšmių. Mūsų atveju daugiau didesnių reikšmių buvo pirmoje grupėje (rytinėje grupėje užfiksuoti geresni rezultatai). Antroji lentelė *Test Statistics* skirta atsakymui į klausimą, ar grupių skirtumai statistiškai reikšmingi. Be $U = \min(U_1, U_2)$ statistikos, dar pateikiamos Vilkoksono $W = \min(R_1, R_2)$ statistika, Z statistika ir jos p -reikšmė Asymp. Sig. (2-tailed) (0,348).

RANKS					TEST STATISTICS ^a	
	GRUPĖ	N	Mean Rank	Sum of Ranks		ĮVERTIN
ĮVERTIN	Rytinė	22	26,00	572,00	Mann-Whitney U	231,000
	Vakarinė	25	22,24	556,00	Wilcoxon W	556,000
	Total	47			Z	-,938
					Asymp. Sig. (2-tailed)	,348

^a. Grouping Variable: GRUPĖ

1.4 pav. SPSS rezultatai

Tegul reikšmingumo lygmuo lygus α , o p -reikšmė yra p . Tuomet darome išvadą, kad:
skirstiniai skiriasi, jeigu $p < \alpha$;
skirstiniai nesiskiria, jeigu $p \geq \alpha$.

Kadangi p -reikšmė $0,348 > 0,05 = \alpha$, tai nulinės hipotezės H_0 atmesti nėra pagrindo. Dar kartą įsitikiname, kad rytinės ir vakarinės grupių rezultatai statistiškai reikšmingai nesiskiria.

1.5. Voldo–Volfovico kriterijus nepriklausomoms imtims

Voldo–Volfovico¹ kriterijus yra serijų kriterijaus modifikacija dviem imtims ir taikomas tiems patiems uždaviniams spręsti kaip ir Mano–Vitnio–Vilkoksono kriterijus. Todėl šiame skyrelyje nagrinėsime ankstesniojo skyrelio pavyzdžius.

Pastaba. Voldo–Volfovico kriterijus naudojamas tik su dvipuse alternatyva! Iš tikrųjų, jeigu X „linkęs“ įgyti didesnes reikšmes už Y , tai serijų skaičius r yra mažas. Tačiau r yra mažas ir tuomet, kai X „linkęs“ įgyti mažesnes reikšmes už Y . Todėl pagal mažą r reikšmę negalime nustatyti, su kuria situacija susidūrėme.

¹ Abraham Wald (1902–1950), Jacob Wolfowitz (1910–1981) – amerikiečių statistikai.

1.5.1. Mažų imčių atvejis ($n_1 \leq 20, n_2 \leq 20$)

1 *Duomenys.* Tarkime, dviejų tolydžių nepriklausomų kintamųjų X ir Y stebėjimai yra $x_1, x_2, \dots, x_{n_1}$ ir $y_1, y_2, \dots, y_{n_2}$. Duomenys gauti matavimams naudojant santykių, intervalų arba rangų skalę.

2 *Statistinė hipotezė:*

$$\begin{cases} H_0: \text{kintamųjų skirstiniai vienodi,} \\ H_1: \text{kintamųjų skirstiniai nėra vienodi.} \end{cases}$$

3 *Kriterijaus statistika.* Stebėjimus sujungiame išdėstydami jų narius didėjimo tvarka nuo mažiausio iki didžiausio (t. y. sudarome jungtinę variacinę eilutę). Kriterijaus statistika yra serijų skaičius r . Šiuo atveju serija yra tos pačios imties narių seka (prieš kurią ir po kurios yra kitos imties nariai).

4 *Sprendimo priėmimo taisyklė.* Tarkime, reikšmingumo lygmuo yra α . Iš priedo 9 lentelės randame kritinę reikšmę, atitinkančią n_1 ir n_2 . Jeigu r ne didesnė už rastąją iš lentelės reikšmę, tai nulinę hipotezę H_0 atmetame (darome išvadą, kad skirstiniai skiriasi). Priešingu atveju H_0 neatmetame.

1.9 pavyzdys. Išspręskime 1.7 pavyzdžio uždavinį Voldo–Volfovico metodu.

Sprendimas. Tarkime, X yra pirmojo maršruto traukinių vėlavimo laikas, Y – antrojo maršruto traukinių vėlavimo laikas.

Statistinė hipotezė:

$$\begin{cases} H_0: X \text{ ir } Y \text{ skirstiniai vienodi,} \\ H_1: X \text{ ir } Y \text{ skirstiniai nevienodi.} \end{cases}$$

Apskaičiuojame 1.7 pavyzdžio lentelės antroje eilutėje serijų skaičių: $r = 4$.

Statistikos r kritinė sritis, kai $n_1 = 6, n_2 = 3$, o $\alpha = 0,05$, nusakoma reikšme 2. Kadangi $r \geq 2$, tai nulinės hipotezės H_0 atmesti negalime.

Beje, jeigu reikšmingumo lygmuo būtų 0,10, tai nulinę hipotezę H_0 reiktų atmesti.

Pastaba. Įsitikinome, kad taikant Voldo–Volfovico ir Mano–Vitnio–Vilkoksono kriterijus galima gauti visiškai priešingas išvadas (palyginkime 1.7 ir 1.9 pavyzdžius). Kada kurių kriterijų naudoti? Jeigu lyginamieji skirstiniai skiriasi sklaidos bei formos charakteristikomis, tai tinkamesnis (galingesnis) yra Voldo–Volfovico kriterijus. Jeigu skirstinių sklaida bei forma maždaug vienoda, o skiriasi skirstinių medianos (idealiu atveju vienas skirstinys gautas „pastūmus“ kitą), tai labiau taikytinas Mano–Vitnio–Vilkoksono kriterijus.

Laikydami H_0 teisinga, mažoms imtims galime tiksliai apskaičiuoti tikimybę įvykio, kad r įgis reikšmę, ne didesnę nei gautoji (t. y. p -reikšmę). Dvipusės alternatyvos atveju, jei gautoji p -reikšmė mažesnė už $\alpha/2$, hipotezę H_0 reiktų atmesti.

1.5.2. Didelių imčių atvejis ($n_1 > 20, n_2 > 20$)

1 *Duomenys.* Tarkime, dviejų nepriklausomų tolydžių kintamųjų X ir Y imtys yra $x_1, x_2, \dots, x_{n_1}$ ir $y_1, y_2, \dots, y_{n_2}$. Duomenys gauti matavimams naudojant santykių, intervalų arba rangų skalę.

2 Statistinė hipotezė:

$$\begin{cases} H_0: \text{kintamųjų skirstiniai yra vienodi,} \\ H_1: \text{kintamųjų skirstiniai nėra vienodi.} \end{cases}$$

3 Kriterijaus statistika. Apskaičiuojame

$$Z = \frac{r - \mu_r}{\sigma_r};$$

čia

$$\mu = \frac{2n_1n_2}{n_1 + n_2} + 1, \quad \sigma_r = \sqrt{\frac{2n_1n_2(2n_1n_2 - n_1 - n_2)}{(n_1 + n_2)^2(n_1 + n_2 - 1)}}.$$

4 Sprendimo priėmimo taisyklė. Tarkime, reikšmingumo lygmuo yra α . Jei $|Z| > z_{\alpha/2}$, tai hipotezę H_0 atmetame (skirstiniai skiriasi). Priešingu atveju H_0 neatmetame; čia $z_{\alpha/2}$ yra standartinio normaliojo skirstinio $\alpha/2$ lygmens kritinė reikšmė.

Pastaba. Jei $(n_1 + n_2)$ reikšmė nėra labai didelė, tai kriterijaus statistika skaičiuojama su vadinamąja tolydumo pataisa

$$Z = \frac{|r - \mu_r| - 0,5}{\sigma_r}.$$

1.10 pavyzdys. Išspręskime 1.8 pavyzdžio uždavinį.

Sprendimas. Tarkime, X yra rytinės, Y – vakarinės grupės vertinimai.

Statistinė hipotezė:

$$\begin{cases} H_0: X \text{ ir } Y \text{ skirstiniai vienodi,} \\ H_1: X \text{ ir } Y \text{ skirstiniai nevienodi.} \end{cases}$$

Apskaičiuojame $\mu = 24,4$, $\sigma = 3,37$, $Z = 0,03$ (su tolydumo pataisa). Kadangi $|Z| < 1,96 = z_{0,025}$, hipotezės atmeti nėra pagrindo. Paros laikas mokymuisi įtakos neturėjo.

Voldo–Volfovico kriterijaus taikymas naudojantis SPSS paketu. Patikrinsime hipotezę apie rytinių ir vakarinių kursų efektyvumą Voldo–Volfovico metodu. SPSS rezultatai 1.8

FREQUENCIES			TEST STATISTICS ^{a,b}				
GRUPĖ		N			Number of Runs	Z	Asymp. Sig. (1-tailed)
IVERTIN	Rytinė	22	IVERTIN	Exact Number of Runs	25	,000	,500
	Vakarinė	25					
	Total	47					

^{a.} Wald-Wolfowitz Test.

^{b.} Grouping variable: GRUPĖ

1.5 pav. Voldo–Volfovico kriterijaus SPSS rezultatai

1.5 pav. Voldo–Volfovico kriterijaus SPSS rezultatai

pavyzdžio atveju pateikti 1.5 paveiksle. Pirmoje lentelėje nurodyta, kiek buvo imtyse elementų, antroje – kiek buvo serijų (24), statistikos Z reikšmė (0,000) ir p -reikšmė (0,500).

Tegul reikšmingumo lygmuo yra α , o p -reikšmė lygi p . Tuomet darome išvadą, kad:
 skirstiniai skiriasi, jeigu $p < \alpha$;
 skirstiniai nesiskiria, jeigu $p \geq \alpha$.

Tarkime, reikšmingumo lygmuo $\alpha = 0,05$. Kadangi $0,5 > 0,05$, tai dar kartą įsitikiname, kad rytinės ir vakarinės grupių rezultatų skirtumas statistiškai nereikšmingas.

1.6. Kruskalo–Voliso ranginis kriterijus nepriklausomoms imtims

Anksčiau aprašytas Mano–Vitnio–Vilkoksono kriterijus taikomas *dviem* nepriklausomoms imtims. Dažnai reikia palyginti trijų ir daugiau populiacijų skirstinius. Pavyzdžiui, norint nuspręsti: ar kaimo, rajonų centrų ir didžiųjų miestų gyventojai būstui išlaikyti išleidžia vienodą sumą pinigų; ar šešių skirtingų veislių rugiai vienodai derlingi; ar keturių skirtingų gydymo būdų reabilitacijos laikas toks pat ir pan. Kruskalo–Voliso¹ kriterijus skirtas hipotezei apie dviejų ar daugiau populiacijų skirstinių lygybę tikrinti.

Suformuluosime nagrinėjamo uždavinio sprendimo etapus.

1 *Duomenys.* Nepriklausomų tolydžiųjų kintamųjų $X, Y, Z, \dots$ stebėjimai yra $(x_1, x_2, x_3, \dots, x_{n1}), (y_1, y_2, \dots, y_{n2}), (z_1, z_2, \dots, z_{n3}), \dots$. Duomenys gauti matavimams naudojant santykių, intervalų arba rangų skalę.

2 *Statistinė hipotezė:*

$$\begin{cases} H_0: \text{kintamųjų skirstiniai yra vienodi,} \\ H_1: \text{kintamųjų skirstiniai nėra vienodi.} \end{cases}$$

3 *Kriterijaus statistika.*

1. Sudarome jungtinę variacinę eilutę.
2. Ranguojame duomenis.
3. Skaičiuojame statistiką

$$H = \frac{12}{n(n+1)} \cdot \sum_{j=1}^k \frac{R_j^2}{n_j} - 3 \cdot (n+1);$$

čia k – kintamųjų skaičius, n_j – j -ojo kintamojo stebėjimų skaičius ($n = n_1 + n_2 + \dots + n_k$), R_j^2 – j -osios imties rangų sumos kvadratas. Jei hipotezė H_0 teisinga, tai statistika H apytiksliai pasiskirsčiusi pagal χ^2 dėsnį su $(k-1)$ laisvės laipsnių, t. y. $H \approx \chi^2(k-1)$.

¹ William Henry Kruskal – amerikiečių statistikas; W. Allen Wallis (1912–1998) – amerikiečių ekonomistas ir statistikas.

- 4** *Sprendimo priėmimo taisyklė.* Tarkime, reikšmingumo lygmuo yra α . Jei $H > \chi_{0,05}^2(k-1)$, hipotezę apie skirstinių lygybę atmetame. Priešingu atveju H_0 neatmetame.



Statistika H įvertina, kiek vidutiniai kiekvienos imties rangai (R_j/n_j) „vidutiniškai“ skiriasi nuo jungtinės imties vidutinio rango $(\bar{R} = (n+1)/2)$. Iš tiesų

$$\begin{aligned} H &= \frac{12}{n(n+1)} \sum_{j=1}^k n_j \left(\frac{R_j}{n_j} - \bar{R} \right)^2 = \frac{12}{n(n+1)} \left(\sum_{j=1}^k \frac{R_j^2}{n_j} - 2 \cdot \bar{R} \sum_{j=1}^k R_j + \sum_{j=1}^k n_j (\bar{R})^2 \right) \\ &= \frac{12}{n(n+1)} \left(\sum_{j=1}^k \frac{R_j^2}{n_j} - 2 \cdot \bar{R} \cdot \frac{n(n+1)}{2} + n \cdot (\bar{R})^2 \right) \\ &= \frac{12}{n(n+1)} \left(\sum_{j=1}^k R_j^2 - 2 \cdot n \cdot (\bar{R})^2 + n \cdot (\bar{R})^2 \right) = \frac{12}{n(n+1)} \left(\sum_{j=1}^k \frac{R_j^2}{n_j} - n(\bar{R})^2 \right) \\ &= \frac{12}{n(n+1)} \left(\sum_{j=1}^k \frac{R_j^2}{n_j} - n \left(\frac{n+1}{2} \right)^2 \right) = \frac{12}{n(n+1)} \sum_{j=1}^k \frac{R_j^2}{n_j} - 3(n+1). \end{aligned}$$

1.11 pavyzdys. Trijose gamyklose buvo testuoti kineskopai. Pirmoje gamykloje atsitiktinai parinkta 10, antroje – 12, trečioje – 11 kineskopų. Jų darbo trukmė (mėnesiais iki pirmo gedimo) surašyta 1.10 lentelėje. Ar galima tvirtinti, kad visose trijose gamyklose gaminamų kineskopų darbo trukmė yra vienoda? (Reikšmingumo lygmuo $\alpha = 0,05$.)

1.10 lentelė. Kineskopų duomenys

I gamyklos kineskopai	41	70	26	89	62	54	46	77	34	51		
II gamyklos kineskopai	30	69	42	60	44	74	32	47	45	37	52	81
III gamyklos kineskopai	23	35	29	38	21	53	31	25	36	50	61	

Sprendimas. Statistinė hipotezė:

$$\begin{cases} H_0: \text{visų gamyklų kineskopų gedimo tikimybės vienodos,} \\ H_1: \text{kineskopų gedimo tikimybės skiriasi.} \end{cases}$$

Sudarome vieną jungtinę variacinę eilutę ir duomenis ranguojame. Pasižymime, kuriai imčiai duomuo priklauso.

1.11 lentelė. Kruskalo–Voliso kriterijaus taikymas

Stebėjimas	21	23	25	26	29	30	31	32	34	35	36
Rangas	1	2	3	4	5	6	7	8	9	10	11
Gamykla	3	3	3	1	3	2	3	2	1	3	3
Stebėjimas	37	38	41	42	44	45	46	47	50	51	52
Rangas	12	13	14	15	16	17	18	19	20	21	22
Gamykla	2	3	1	2	2	2	1	2	3	1	2
Stebėjimas	53	54	60	61	62	69	70	74	77	81	89
Rangas	23	24	25	26	27	28	29	30	31	32	33
Gamykla	3	1	2	3	1	2	1	2	1	2	1

Apskaičiuojame: $n_1 = 10$, $n_2 = 12$, $n_3 = 11$, $R_1 = 210$, $R_2 = 230$, $R_3 = 121$, $H = 6,549$. Kadangi $H = 6,549 > \chi_{0,95}^2(2) = 5,991$, tai H_0 hipotezę atmetame. Kineskopų tarnavimo laikas trijose gamyklose nėra vienodas.

Kruskalo–Voliso kriterijaus taikymas naudojantis SPSS paketu. Aptarsime 1.11 pavyzdžio sprendimą SPSS paketu. Gauti rezultatai pateikti 1.6 paveiksle.

RANKS				TEST STATISTICS ^{a,b}	
GRUPĖ		N	Mean Rank		KINESKOP
KINESKOP	I gamykla	10	21,00	Chi-Square	6,549
	II gamykla	12	19,17	df	2
	III gamykla	11	11,00	Asymp. Sig.	,038
	Total	33			

^{a.} Kruskal Wallis Test.
^{b.} Grouping variable: GRUPĖ

1.6 pav. Kruskalo–Voliso kriterijaus SPSS rezultatai

Lentelėje *Test Statistics* pateikiama statistikos reikšmė Chi-Square (6,549), laisvės laipsniai df (2) ir *p*-reikšmė Asymp. Sig. (0,038).

Tegul reikšmingumo lygmuo yra α , o *p*-reikšmė lygi *p*. Tuomet:

skirstiniai skiriasi, jeigu $p < \alpha$;
 skirstiniai nesiskiria, jeigu $p \geq \alpha$.

Kadangi *p*-reikšmė lygi $0,038 < 0,05$, tai skirstiniai skiriasi. Ką galime pasakyti apie pačius skirstinius, t. y. kurie skirstiniai „linkę“ būti didesni už kitus? Informaciją apie tai sužinome iš pirmosios lentelės vidutinių rangų stulpelio Mean Rank. Vidutinis rangas yra R_j/n_j , t. y. imties elementų rangų suma, padalyta iš imties didumo. Pirmosios imties $R_1 = 210$ (žr. 1.12 pavyzdį), o $n_1 = 10$, todėl jos vidutinis rangas lygus 21. Kuo jis didesnis, tuo labiau atitinkamas kintamasis „linkęs“ įgyti didesnes, palyginti su kitais kintamaisiais, reikšmes. Matome, kad didžiausias vidutinis rangas yra pirmos gamyklos kineskopų tarnavimo laiko (21), o mažiausias – trečiosios (11). Antrosios gamyklos produkcija tarnavimo laiku artimesnė pirmajai gamyklai (vidutinis rangas lygus 19,17). Taikant kriterijų, gautas statistiškai reikšmingas gamyklų skirtumas, todėl galime teigti, kad pirmosios gamyklos produkcija tarnavimo laiku statistiškai reikšmingai skiriasi nuo trečiosios gamyklos, nes būtent šių dviejų imčių vidutinių rangų skirtumas didžiausias. Deja, Kruskalo–Voliso kriterijus neparodo, kurie kiti skirstiniai skiriasi, todėl vidutinių rangų peržiūra lieka bene vienintelė priemonė bandant išsiaiškinti galimus skirstinių skirtumus.

1.7. Frydmano kriterijus priklausomoms imtims

Frydmano¹ kriterijus skirtas hipotezei apie *k* kintamųjų ($k \geq 3$) skirstinių lygybę tikrinti, kai imtys yra priklausomos. Frydmano kriterijaus taikymo pavyzdžiai lengviau suprantami prisiminus priklausomų imčių sąvoką (žr. [1], p. 179). Paprasčiausias priklausomų imčių atvejis yra tų pačių objektų pakartotiniai matavimai. Tačiau duomenis gali sieti ir kitokia informacija. Tarkime, norime patikrinti hipotezę, kad:

- Studentų IQ kyla artėjant prie išsvajoto diplomo. Atsitiktinai parinkę 100 studentų, testuojame juos 1-ame, 2-ame, 3-ame ir 4-ame kursuose. Turime keturias susijusias imtis, nes keturis kartus matavome tuos pačius žmones. Duomenys užrašomi taip:

¹ Milton Friedman (1912) – amerikiečių ekonomistas, 1976 metų Nobelio premijos laureatas.

$(x_{1j}, x_{2j}, x_{3j}, x_{4j})$, $j = 1, \dots, 100$; čia $(x_{1j}, x_{2j}, x_{3j}, x_{4j})$ – 1-o, 2-o, ... kursų j -ojo studento IQ.

- A, B, C, D universitetų absolventų pradiniai atlyginimai nesiskiria (universitetai vienodo lygio). Suprantama, kad didelę įtaką pradinio atlyginimo sumai daro įgyta specialybė (dėl paprastumo sakysime – baigtas fakultetas). Vadinasi, sužinoję aptariamų universitetų tam tikro skaičiaus absolventų pradinius atlyginimus, duomenis grupuojame atsižvelgdami į baigtą fakultetą. Kruskalo–Voliso kriterijus netinka, nes fakultetai skiriasi. Frydmano kriterijus šiam pavyzdžiui taikomas skyrelio pabaigoje. Aptarsime šio kriterijaus taikymo etapus.

1.12 lentelė. Frydmano kriterijaus duomenys

X	Y	Z	...
x_1	y_1	z_1	...
x_2	y_2	z_2	...
x_3	y_3	z_3	...
...	...	...	...
x_n	y_n	z_n	...

1 *Duomenys.* Tolydžių kintamųjų rinkinio $(X, Y, Z, \dots)$ stebėjimai yra $(x_i, y_i, z_i, \dots)$, $i = 1, \dots, n$ (žr. 1.12 lentelę). Duomenys gauti matavimams naudojant santykių, intervalų arba rangų skalę.

2 *Statistinė hipotezė:*

$$\begin{cases} H_0: \text{kintamųjų skirstiniai vienodi,} \\ H_1: \text{kintamųjų skirstiniai nėra vienodi.} \end{cases}$$

3 *Kriterijaus statistika.* Kiekvieną kintamųjų rinkinio stebėjimą (eilutę) ranguojame atskirai, t. y. iš pradžių $x_1, y_1, z_1, \dots$, po to $x_2, y_2, z_2, \dots$ ir t. t. Kiekvieno stebėjimo rangų suma yra $1 + 2 + \dots + k = k(k+1)/2$. Vidutinis rangas lygus $(k+1)/2$. Sudedame visus x -ams tekusius rangus. Gautą sumą pažymime R_1 . Analogiškai skaičiuojame y -ams tekusių rangų sumą R_2 ir t. t.

Randame

$$S = \frac{12}{nk(k+1)} \sum_{j=1}^k R_j^2 - 3n(k+1).$$

4 *Sprendimo priėmimo taisyklė.* Tarkime, reikšmingumo lygmuo yra α . Hipotezę apie skirstinių lygybę atmetame, kai $S > \chi_\alpha^2(k-1)$; čia $\chi_\alpha^2(k-1)$ yra χ^2 skirstinio su $(k-1)$ laisvės laipsnių α lygmens kritinė reikšmė. Priešingu atveju H_0 neatmetame.



Pastebėsime, kad $\sum_{j=1}^k R_j = nk(k+1)/2$. Pažymime j -ojo stulpelio vidutinį rangą $\bar{R}_j = R_j/n$. Rinkinio stebėjimo vidutinis rangas yra $(\bar{R}_1 + \bar{R}_2 + \dots + \bar{R}_k)/k = (k+1)/2$. Tada

$$S = \frac{12n}{k(k+1)} \sum_{j=1}^k \left(\bar{R}_j - \frac{k+1}{2} \right)^2 = \frac{12n}{k(k+1)} \left(\sum_{j=1}^k \bar{R}_j^2 - \frac{2(k+1)}{2} \cdot \sum_{j=1}^k \bar{R}_j + \frac{k(k+1)^2}{4} \right)$$

$$\begin{aligned}
&= \frac{12n}{k(k+1)} \left(\sum_{j=1}^k \overline{R}_j^2 - \frac{2k(k+1)^2}{4} + \frac{k(k+1)^2}{4} \right) \\
&= \frac{12n}{k(k+1)} \cdot \sum_{j=1}^k \overline{R}_j^2 - 3n(k+1) = \frac{12}{nk(k+1)} \sum_{j=1}^k R_j^2 - 3n(k+1).
\end{aligned}$$

Normuojantis daugiklis sumoje S yra reikalingas tam, kad gautume žinomą skirstinį. Kai hipotezė H_0 teisinga, $S \approx \chi^2(k-1)$.

1.12 pavyzdys. Tikrinama, ar 4 universitetų (A, B, C, D) absolventų pradinis atlyginimas skiriasi. Atsitiktinai pasirinkta po 100 absolventų, baigusių A, B, C, D universitetų Matematikos, Fizikos, Filologijos, Komunikacijos ir Ekonomikos fakultetus. Apskaičiavus atskirų fakultetų atlyginimų vidurkių, gauti duomenys pateikti 1.13 lentelėje. Reikšmingumo lygmuo $\alpha = 0,05$.

1.13 lentelė. Absolventų atlyginimai. Duomenys ir rangai

Fakultetas	Universitetas			
	A	B	C	D
Matematikos	1286 (3)	1299 (4)	1281 (2)	1275 (1)
Fizikos	1269 (1)	1284 (2)	1291 (4)	1285 (3)
Filologijos	1220 (3)	1185 (2)	1159 (1)	1231 (4)
Komunikacijos	1180 (3)	1156 (1)	1163 (2)	1193 (4)
Ekonomikos	1213 (4)	1185 (2)	1161 (1)	1210 (3)
R_j	$R_1 = 14$	$R_2 = 11$	$R_3 = 10$	$R_4 = 15$

Sprendimas. Apskaičiuojame

$$S = \frac{12}{5 \cdot 4 \cdot 5} (14^2 + 11^2 + 10^2 + 15^2) - 3 \cdot 5 \cdot 5 = 2,04, \quad \chi_{0,05}^2(3) = 7,815.$$

Kadangi $2,04 < 7,815$, mes negalime teigti, kad pasirinktų universitetų absolventų pradiniai atlyginimai skiriasi.

Frydmano kriterijaus taikymas naudojantis SPSS paketu. Šiuo paketu gauti 1.12 pavyzdžio rezultatai parodyti 1.7 paveiksle. Pirmojoje lentelėje yra vidutiniai rangai R_j (juos apibrėžėme anksčiau). Antrojoje lentelėje pateikta statistikos reikšmė Chi-Square (2,040); laisvės laipsniai df (3) ir p -reikšmė Asymp. Sig. (0,564).

Tegul reikšmingumo lygmuo yra α , o p -reikšmė lygi p . Tuomet:
skirstiniai skiriasi, jeigu $p < \alpha$;
skirstiniai nesiskiria, jeigu $p \geq \alpha$.

RANKS		TEST STATISTICS ^a	
	Mean Rank	N	5
		Chi-Square	2,040
		df	3
		Asymp. Sig.	,564
A	2,80	^a . Friedman Test.	
B	2,20		
C	2,00		
D	3,00		

1.7 pav. Frydmano kriterijaus SPSS rezultatai

Mūsų nagrinėjamu atveju p -reikšmė $0,546 > 0,05$, todėl dar kartą įsitikiname, jog statistiškai reikšmingo absolventų atlyginimų skirtumo nėra.

1.8. Ranginių kintamųjų ryšio matai

Pirmoje knygoje aprašėme kintamųjų, matuojamų pagal pavadinimų skalę, ryšio matus. Šiame skyrelyje aprašysime kintamųjų, matuojamų pagal rangų skalę (ranginių kintamųjų), ryšio matus.

Tarkime, stebime tolydžiųjų kintamųjų porą (X, Y) . Duomenis sudaro stebėjimų poros (x_i, y_i) , $i = 1, \dots, n$. Visos šio skyrelio charakteristikos skaičiuojamos naudojant rangus, o ne duomenų reikšmes. Taigi iš pradžių duomenys ranguojami.

Kiekvienos imties duomenys ranguojami *atskirai*: R_{xi} yra x_i rangas, R_{yj} – y_j rangas.

Jeigu jau patys pradiniai duomenys ranguoti, tai parengiamasis kiekvieno ryšio mato (ar su juo susijusio kriterijaus) skaičiavimo etapas tiesiog atpuola.

Ranginiai duomenys gali atsirasti ir tiesiogiai. Pavyzdžiui, Spirmenas¹ tyrė gabumų muzikai ir matematikai ryšį. Klasės auklėtoja buvo paprašyta pateikti du mokinių sąrašus, kuriuose vaikai surašyti pagal jų gabumus muzikai ir matematikai. Kiekvieno vaiko eilės numeriai sąrašuose ir yra jo gabumų rangai.

Aptarsime pagrindinius ranginių kintamųjų ryšio matus.

1.8.1. Spirmeno ranginės koreliacijos koeficientas

Tarkime, tolydžiųjų kintamųjų poros (X, Y) stebėjimai yra $(x_1, y_1), \dots, (x_n, y_n)$. Galime apskaičiuoti Pirsono tiesinės koreliacijos koeficientą – kintamųjų tiesinės priklausomybės matą. Tačiau jei kintamųjų normalumo prielaida nėra tenkinama arba duomenų mažai (< 20 stebėjimų), šia charakteristika naudotis negalima. Tuo atveju skaičiuojamas Spirmeno koreliacijos koeficientas. Po rangavimo duomenis sudaro poros $(R_{x1}, R_{y1}), \dots, (R_{xn}, R_{yn})$.

Spirmeno koreliacijos koeficientas

$$r_s = \frac{\sum_{i=1}^n \left(R_{xi} - \frac{n+1}{2} \right) \left(R_{yi} - \frac{n+1}{2} \right)}{\sqrt{\sum_{i=1}^n \left(R_{xi} - \frac{n+1}{2} \right)^2} \sqrt{\sum_{i=1}^n \left(R_{yi} - \frac{n+1}{2} \right)^2}}. \quad (7)$$

Čia R_{xi} yra x_i rangas, o R_{yi} – y_i rangas.

Spirmeno koreliacijos koeficientas yra ne kas kita kaip Pirsono koreliacijos koeficientas, apskaičiuotas ne pačioms kintamųjų reikšmėms, o jų rangams. Jis matuoja tiesinę kintamųjų priklausomybę. Analogiška ir interpretacija – kuo koeficientas absoliučiau didesnis, tuo priklausomybė stipresnė. Teigiamas koreliacijos koeficientas rodo tiesioginę kintamųjų priklausomybę (didesnės X reikšmės atitinka didesnės Y reikšmės), neigiamas – atvirkštinę (didesnės X reikšmės atitinka mažesnės Y reikšmės).

¹ Charles Edvard Spearman (1863–1945) – anglų psichologas ir statistikas.

1.13 pavyzdys. Ar autoavarijų metu sužeistųjų bei žuvusiųjų skaičius priklauso nuo autoavarijų skaičiaus? Atrodytų, atsakymas labai paprastas – priklauso. Tačiau juk automobiliai vis saugesni, keliai vis geresni, kelių policija atidesnė. Turėdami 1990–1999 metų duomenis apie avarijas Lietuvos keliuose, įvertinkime šių dydžių priklausomybę. Duomenys pateikti 1.14 lentelėje.

1.14 lentelė. Autoavarijos ir jų rezultatai

Metai	1990	1991	1992	1993	1994	1995	1996	1997	1998	1999
Avarijos (X)	5135	6067	4049	4319	3902	4144	4579	5319	6445	6356
Žuvusieji (Y)	933	1093	779	893	765	672	667	725	829	748
Sužeistieji (Z)	5491	6638	4251	4555	4146	4508	5223	6198	7669	7696
Avarių rangai	6	8	2	4	1	3	5	7	10	9
Žuvusiųjų rangai	9	10	6	8	5	2	1	3	7	4
Sužeistųjų rangai	6	8	2	4	1	3	5	7	9	10

Duomenis suranguojame. Kadangi $n = 10$, tai $(n + 1)/2 = 5,5$. Apskaičiuojame avarių ir žuvusiųjų skaičiaus Spirmeno koreliacijos koeficientą. Pagal (7) formulę gauname

$$r_s(x, y) = \frac{\sum_{i=1}^{10} (R_{xi} - 5,5)(R_{yi} - 5,5)}{\sqrt{\sum_{i=1}^{10} (R_{xi} - 5,5)^2} \sqrt{\sum_{i=1}^{10} (R_{yi} - 5,5)^2}} = 0,224. \quad (8)$$

Matome, kad koreliacija nėra didelė. Avarių ir sužeistųjų skaičiaus koreliacija

$$r_s(x, z) = \frac{\sum_{i=1}^{10} (R_{xi} - 5,5)(R_{zi} - 5,5)}{\sqrt{\sum_{i=1}^{10} (R_{xi} - 5,5)^2} \sqrt{\sum_{i=1}^{10} (R_{zi} - 5,5)^2}} = 0,988, \quad (9)$$

t. y. labai stipri.

Jeigu visi R_{xi} skirtingi (t. y. tarp x_i nebuvo vienodų reikšmių) ir visi R_{yi} skirtingi, tai Spirmeno koreliacijos koeficientą patogiau skaičiuoti pagal formulę

$$r_s = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n^3 - n}, \quad (10)$$

čia $d_i = R_{xi} - R_{yi}$.



Įrodysime, kad (7) ir (10) formulės ekvivalenčios. Dėl paprastumo tarkime, kad duomenys išdėstyti taip, jog X sudaro variacinę eilutę, t. y. $R_{xi} = i$. Tuomet

$$\begin{aligned} \sum_{i=1}^n \left(i - \frac{n+1}{2} \right)^2 &= \sum_{i=1}^n i^2 - 2 \cdot \frac{n(n+1)}{2} \cdot \frac{(n+1)}{2} + \frac{n(n+1)^2}{4} \\ &= \frac{n(n+1)(2n+1)}{6} - \frac{n(n+1)^2}{4} = \frac{2n(n+1)(2n+1) - 3n(n+1)^2}{12} \\ &= \frac{n(n+1)(4n+2-3n-3)}{12} = \frac{n(n^2-1)}{12}. \end{aligned}$$

Analogiškai

$$\sum_{i=1}^n \left(R_{yi} - \frac{n+1}{2} \right)^2 = \frac{n(n^2-1)}{12}.$$

Tada

$$r_s = \frac{12}{n(n^2-1)} \cdot \sum_{i=1}^n \left(i - \frac{n+1}{2} \right) \left(R_{yi} - \frac{n+1}{2} \right) = \frac{12}{n(n^2-1)} \cdot \sum_{i=1}^n \left(i - \frac{n+1}{2} \right) R_{yi}. \quad (11)$$

Kita vertus,

$$\begin{aligned} \sum_{i=1}^n (i - R_{yi})^2 &= \sum_{i=1}^n \left(i - \frac{n+1}{2} + \frac{n+1}{2} - R_{yi} \right)^2 \\ &= \sum_{i=1}^n \left(\left(i - \frac{n+1}{2} \right)^2 + 2 \left(i - \frac{n+1}{2} \right) \left(\frac{n+1}{2} - R_{yi} \right) + \left(\frac{n+1}{2} - R_{yi} \right)^2 \right) \\ &= 2 \sum_{i=1}^n \left(i - \frac{n+1}{2} \right)^2 - 2 \sum_{i=1}^n \left(i - \frac{n+1}{2} \right) R_{yi} = \frac{n(n^2-1)}{6} - 2 \sum_{i=1}^n \left(i - \frac{n+1}{2} \right) R_{yi}. \end{aligned}$$

Taigi

$$\sum_{i=1}^n \left(i - \frac{n+1}{2} \right) R_{yi} = \frac{n(n^2-1)}{12} - \frac{1}{2} \sum_{i=1}^n (i - R_{yi})^2. \quad (12)$$

Istatę (12) į (11), gauname

$$r_s = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n^3 - n}.$$

Žinome, kuo r_s absoliučiuoju didumu arčiau vieneto, tuo koreliacija stipresnė. Tačiau kaip nustatyti, ar koreliacija *statistiškai* reikšminga? Taigi vėl susidūrėme su įprasta statistikos problema – išmatuoti galime tik empirinį (imties) Spirmeno koreliacijos koeficientą r_s , o išvadą norime padaryti apie nežinomą populiacijos kintamųjų koreliaciją.

Atsakymą į klausimą, ar du populiacijos kintamieji priklausomi, gauname patikrinę atitinkamą hipotezę.

1 *Duomenys.* Porinė imtis $((x_1, y_1), \dots, (x_n, y_n))$ gauta matuojant pagal rangų skalę tolydžių kintamųjų porą (X, Y) .

2 *Statistinė hipotezė:*

$$\begin{cases} H_0: X \text{ ir } Y \text{ nekoreliuoja,} \\ H_1: X \text{ ir } Y \text{ koreliuoja.} \end{cases}$$

Nulinė hipotezė H_0 reiškia, kad r_s statistiškai reikšmingai nesiskiria nuo nulio (koreliacija nėra statistiškai reikšminga), alternatyva H_1 – skiriasi (koreliacija yra statistiškai reikšminga, kintamieji priklausomi).

3 *Kriterijaus statistika.* Apskaičiuojame

$$T = r_s \sqrt{\frac{n-2}{1-r_s^2}};$$

čia r_s – imties Spirmeno koeficientas, skaičiuojamas pagal (7) arba (9) formulę.

- 4 *Sprendimo priėmimo taisyklė.* Tegul reikšmingumo lygmuo yra α . Hipotezė H_0 atmetama (taigi X ir Y priklausomi), jeigu $|T| > t_{\alpha/2}(n-2)$; čia $t_{\alpha/2}$ yra Stjudento skirstinio su $(n-2)$ laisvės laipsnių $\alpha/2$ lygmens kritinė reikšmė. Hipotezė H_0 neatmetama, jeigu $|T| \leq t_{\alpha/2}(n-2)$.

1.14 pavyzdys. Patikrinkime, ar 1.13 pavyzdyje gautos koreliacijos statistiškai reikšmingos. Tarkime, reikšmingumo lygmuo $\alpha = 0,05$. Kadangi $r_s(x, y) = 0,224$, $r_s(x, z) = 0,988$, tai

$$T_{xy} = 0,224 \sqrt{\frac{8}{1 - 0,224^2}} = 0,65, \quad T_{xz} = 18,09.$$

Kadangi $T_{x,y} = 0,65 < 2,3 = t_{0,025}(8)$, tai pirmuoju atveju H_0 atmesti nėra pagrindo. Nėra stiprios tiesinės avarių ir žuvusiųjų skaičiaus priklausomybės. Kadangi $T_{xz} = 18,09 > 2,3 = t_{0,025}(8)$, tai antruoju atveju H_0 atmetame. Darome išvadą, kad avarių ir sužeistųjų skaičiaus priklausomybė statistiškai reikšminga.

Pastaba. Spirmeno koreliacijos koeficientą galima taikyti ir imties atsitiktinumui tikrinti. Tuomet duomenis sudaro $(x_1, 1), (x_2, 2), \dots, (x_n, n)$. Imtį $x_1, \dots, x_n$ laikome atsitiktine, jeigu priklausomybės nerandame (nulinės hipotezės H_0 neatmetame).

Spirmeno koreliacijos koeficientas naudojantis SPSS paketu. SPSS paketas leidžia patikrinti hipotezę, kad ranginių kintamųjų Spirmeno koreliacijos koeficientas nelygus nuliui. Pateikiamas empirinis koreliacijos koeficientas r_s ir kriterijaus p -reikšmė.

Jeigu tikrinant hipotezę apie Spirmeno koreliacijos koeficientą p -reikšmė lygi p , o reikšmingumo lygmuo lygus α , tai darome išvadą, kad:

kintamieji koreliuoja, kai $p < \alpha$,
kintamieji nekoreliuoja, kai $p \geq \alpha$.

Tarkime, 1.14 pavyzdžio problemą sprendžiame SPSS paketu. Gauti rezultatai pateikti 1.8 paveiksle. Matome, kad autoavarių ir žuvusiųjų skaičiaus koreliaciją ($r_s(xy) = 0,224$) atitinkanti p -reikšmė (0,533) yra didesnė už 0,05. Taigi dar kartą įsitikinome, kad šie du dydžiai nekoreliuoja. Tuo tarpu avarių ir sužeistųjų skaičiaus koreliaciją ($r_s(xz) = 0,988$) atitinkanti p -reikšmė (0,00) yra mažesnė ne tik už 0,05, bet ir už 0,01. Taigi šie du

CORRELATIONS					
			AUTV	SUŽ	ŽUV
Spearman's rho	Correlation Coefficient	AUTV	1,000	,988**	,224
		SUŽ	,988**	1,000	,188
		ŽUV	,224	,188	1,000
	Sig. (2-tailed)	AUTV	,	,000	,533
		SUŽ	,000	,	,603
		ŽUV	,533	,603	,
N		AUTV	10	10	10
		SUŽ	10	10	10
		ŽUV	10	10	10

** Correlation is significant at the .01 level (2-tailed).

1.8 pav. SPSS Spirmeno kriterijaus rezultatai

dydžiai statistiškai reikšmingai koreliuoja ne tik esant reikšmingumo lygmeniui $\alpha = 0,05$, bet ir $\alpha = 0,01$. Koreliacija teigiama, taigi priklausomybė tiesioginė. Beje, statistiškai reikšmingi koreliacijos koeficientai „papuosti“ žvaigždutėmis.

1.8.2. Kendalo ranginės koreliacijos koeficientas

Kendalo¹ koeficientas, kaip ir Spirmeno, naudojamas ranginių kintamųjų ryšio stiprumui įvertinti.

Kendalo koeficientas

$$\tau = \frac{S}{n(n-1)/2}. \quad (13)$$

Čia S yra suderintų ir nesuderintų porų skaičiaus skirtumas, n – imties didumas.

Kas yra suderintos ir nesuderintos poros? Dvi duomenų poros (x_i, y_i) ir (x_j, y_j) ($i \neq j$) yra suderintos, jei $(x_i > x_j \text{ ir } y_i > y_j)$ arba $(x_i < x_j \text{ ir } y_i < y_j)$. Poros nesuderintos, jei $(x_i > x_j \text{ ir } y_i < y_j)$ arba $(x_i < x_j \text{ ir } y_i > y_j)$. Iš viso suderintų ir nesuderintų porų yra $n(n-1)/2$. (Primename, kad nagrinėjame situacijas, kai duomenys nesusiję.) Taigi $\tau = 1$, jei visos poros suderintos, ir $\tau = -1$, jei visos poros nesuderintos.

Panagrinėkime tokį pavyzdį. Tarkime, du ekspertai vertina keturis Sausučių aplinkkelio projektus (projektai A, B, C, D). Kiekvienas ekspertas išrikiuoja projektus pagal priimtinumą (taigi projektams natūraliai suteikia rangus). Duomenys pateikti 1.15 lentelėje. Ar galima sakyti, kad ekspertų vertinimai panašūs?

Išrūšiavę duomenis pagal I eksperto įvertinimus, gauname 1.16 lentelę.

1.15 lentelė. Ekspertų nuomonė

	A	B	C	D
I ekspertas	3	4	2	1
II ekspertas	3	1	4	2

1.16 lentelė. Sutvarkyti duomenys

	D	C	A	B
I ekspertas	1	2	3	4
II ekspertas	2	4	3	1


Turėdami išrūšiuotą lentelę, nesunkiai randame suderintas ir nesuderintas poras. Norėdami išvengti pasikartojimų, kiekvieną vertinimų porą lyginame tik su poromis iš dešinės. Projekto D vertinimų pora (1, 2) yra suderinta su C ir A vertinimų poromis ir nesuderinta su B vertinimų pora. Projekto C vertinimų pora (2, 4) yra nesuderinta su A ir su B vertinimų poromis. Projekto A įvertinimų pora nesuderinta su B pora.

Randame visų suderintų ir nesuderintų porų skaičiaus skirtumą $S = 2 - 4 = -2$. Įstatę šią reikšmę į (13) formulę, gauname

$$\tau = \frac{-2}{4 \cdot 3/2} = -0,33.$$

Taigi koreliacija nėra labai didelė. Kendalo koreliacijos koeficiento ženklas interpretuojamas kaip ir Spirmeno bei Pirsono koeficientų ženklas, t. y. teigiamas koeficientas žymi tiesioginę priklausomybę, neigiamas – atvirkštinę. Apskaičiuotasis koeficientas yra

¹ Morice George Kendall (1907–1983) – anglų statistikas.



neigiamas. Kuo vienam ekspertui labiau patiko projektas, tuo kitam jis atrodė nepatrauklesnis. Tačiau dar nenustatėme, ar ši koreliacija yra *statistiškai* reikšminga.

Kendalo koeficientą galima skaičiuoti ir pasitelkus grafinę iliustraciją (jungiant atkarpomis ranginių duomenų taškus, žr. 1.9 pav.).

$$\tau = 1 - \frac{2c}{\frac{n(n-1)}{2}};$$

čia n – imties didumas, c – atkarpų susikirtimo skaičius, $n(n-1)/2$ – maksimalus atkarpų susikirtimų skaičius. Paveiksle pateiktos situacijos, kai $\tau = +1; 0; -1$.

Kaip ir Spirmeno koeficiento atveju, galima apskaičiuoti ne tik patį Kendalo koeficientą, bet ir patikrinti, ar gauta ranginė koreliacija statistiškai reikšminga. Kendalo ranginės koreliacijos reikšmingumas patikrinamas taip.

1 *Duomenys.* Porinė imtis $((x_1, y_1), \dots, (x_n, y_n))$ gauta matuojant pagal rangų skalę tolydžiųjų kintamųjų porą (X, Y) .

2 *Statistinė hipotezė:*

$$\begin{cases} H_0: X \text{ ir } Y \text{ nekoreliuoja,} \\ H_1: X \text{ ir } Y \text{ koreliuoja.} \end{cases}$$

Nulinė hipotezė H_0 reiškia, kad τ statistiškai reikšmingai nesiskiria nuo nulio (koreliacija nėra statistiškai reikšminga), alternatyva H_1 – skiriasi (koreliacija yra statistiškai reikšminga, kintamieji priklausomi).

3 *Kriterijaus statistika.* Apskaičiuojame

$$Z = \frac{\tau}{\sqrt{\frac{2(2n+5)}{9n(n-1)}}};$$

čia τ – Kendalo koeficiento realizacija, skaičiuojama pagal (13) formulę.

- 4 *Sprendimo priėmimo taisyklė.* Jei H_0 teisinga, tai $Z \approx \mathcal{N}(0, 1)$. Tegul reikšmingumo lygmuo yra α . Hipotezė H_0 atmetama (t.y. X ir Y priklausomi), jeigu $|Z| > z_{\alpha/2}$; čia $z_{\alpha/2}$ yra standartinio normaliojo skirstinio $\alpha/2$ lygmens kritinė reikšmė. Hipotezė H_0 neatmetama, jeigu $|Z| \geq z_{\alpha/2}$.

1.15 pavyzdys. Tarkime, norime išspręsti 1.13 pavyzdžio problemą apie autoavarijų ir žuvusiųjų skaičiaus priklausomybę. Tegul reikšmingumo lygmuo $\alpha = 0,05$.

Iš 1.14 lentelės persirašome rangus, išdėstydami juos pagal autoavarijas:

Avarių rangai	1	2	3	4	5	6	7	8	9	10
Žuvusiųjų rangai	5	6	2	8	1	9	3	10	4	7

Apskaičiuojame $S = 26 - 18 = 8$, $\tau = 8/45$, $Z = 0,715$. Kadangi $|Z| < 1,96 = z_{0,025}$, tai statistiškai reikšmingos autoavarijų ir jose žuvusiųjų skaičiaus priklausomybės nenustatėme.

Kendalo ir Spirmeno koeficientus skaičiuojame, kai norime įvertinti ranginių kintamųjų ryšio stiprumą. Šiuos koeficientus skaičiuojant, remiamasi tomis pačiomis prielaidomis, gauti rezultatai vienodai reikšmingi, o skiriasi tik koeficientų skaitinės reikšmės. Galioja toks sąryšis: $-1 \leq 3 \cdot \tau - 2 \cdot r_s \leq 1$.

Kendalo koreliacijos koeficientas naudojantis SPSS paketu. SPSS paketas leidžia patikrinti hipotezę, kad ranginių kintamųjų Kendalo koreliacijos koeficientas nelygus nuliui. Pateikiamas empirinis koreliacijos koeficientas τ ir kriterijaus p -reikšmė. Visą informaciją analogiška Spirmeno koreliacijos koeficientui.

Jeigu tikrinant hipotezę apie Kendalo koreliacijos koeficientą p -reikšmė lygi p , o reikšmingumo lygmuo yra α , tai darome išvadą, kad:

kintamieji koreliuoja, kai $p < \alpha$,
kintamieji nekoreliuoja, kai $p \geq \alpha$.

Sprendžiant 1.13 pavyzdžio problemą SPSS paketu, gauti rezultatai pateikti 1.10 paveiksle. Matome, kad autoavarijų ir žuvusiųjų skaičiaus koreliaciją ($\tau_{xy} = 0,20$) atitinkanti p -reikšmė (0,421) yra didesnė kaip 0,05. Dar kartą įsitikinome, kad šie du dydžiai nekoreliuoja. Tuo tarpu avarių ir sužeistųjų skaičiaus koreliaciją ($\tau_{xz} = 0,956$) atitinkanti

CORRELATIONS					
			AUTV	SUŽ	ŽUV
Kendall's tau_b	Correlation	AUTV	1,000	,956**	,200
	Coefficient	SUŽ	,956**	1,000	,156
		ŽUV	,200	,156	1,000
	Sig. (2-tailed)	AUTV	,	,000	,421
		SUŽ	,000	,	,531
		ŽUV	,421	,531	,
N		AUTV	10	10	10
		SUŽ	10	10	10
		ŽUV	10	10	10

** Correlation is significant at the .01 level (2-tailed).

1.10 pav. SPSS Kendalo kriterijaus rezultatai

p -reikšmė (0,00) yra mažesnė kaip 0,05. Taigi šie du dydžiai statistiškai reikšmingai koreliuoja. Koreliacija teigiama, todėl priklausomybė tiesioginė. Statistiškai reikšmingi koreliacijos koeficientai pažymėti žvaigždutėmis.

1.8.3. Kendalo konkordacijos koeficientas W

Tarkime, kad yra daugiau kaip 2 ranginiai kintamieji. Atrodytų, kad norint įvertinti šių kintamųjų priklausomybę, pakaktų rasti kintamųjų porų koreliacijos koeficientą (pavyzdžiui, Kendalo), o po to gautas reikšmes suvidurkinti. Tačiau net ir esant palyginti nedideliame kiekiui kintamųjų, koreliacijos koeficientą tektų daug kartų skaičiuoti. Pavyzdžiui, jei būtų 6 kintamieji, tai tektų $\binom{6}{2} = 15$ kartų skaičiuoti koreliacijos koeficientus. Išėitis – konkordacijos koeficientas.

Stebime k tolydžių kintamųjų $X_1, X_2, \dots, X_k$. Duomenys yra $(x_{1j}, x_{2j}, \dots, x_{kj})$, $j = 1, \dots, n$; čia x_{ij} yra i -ojo kintamojo j -oji reikšmė (gauta matavimams naudojant santykių, intervalų arba rangų skalę), n – imties didumas. Suranguojame kiekvieno kintamojo reikšmes ir apskaičiuojame $\tilde{R}_j$, $j = 1, \dots, n$, – j -ojo rinkinio rangų sumą (t. y. $\tilde{R}_1 = R_{x_{11}} + R_{x_{21}} + \dots + R_{x_{k1}}$ ir t. t.). Tada konkordacijos koeficientas apibrėžiamas taip:

$$W = \frac{12\tilde{S}}{k^2(n^3 - n)};$$

čia

$$\tilde{S} = \sum_{j=1}^n \left(\tilde{R}_j - \frac{\tilde{R}_1 + \tilde{R}_2 + \dots + \tilde{R}_n}{n} \right)^2 = \sum_{j=1}^n \left(\tilde{R}_j - \frac{k(n+1)}{2} \right)^2. \quad (14)$$

Konkordacijos koeficiento reikšmių aibė yra $[0, 1]$. Kuo didesnis W , tuo stipresnė kintamųjų koreliacija.

1.16 pavyzdys. Tarkime, 3 ekspertai X, Y, Z vertina 6 kandidatus (a, b, c, d, e, f), ar jie tinkami eiti direktoriaus pareigas. Aukštesnis balas rodo palankesnę vertinimą. Gauti rezultatai pateikti 1.17 lentelėje. Ar ekspertų vertinimai yra priklausomi?

1.17 lentelė. Ekspertų nuomonės

Kandidatas	Ekspertas		
	X	Y	Z
a	10	10	5
b	4	6	8
c	8	5	9
d	9	7	6
e	6	9	7
f	7	8	10

Pirmiausia duomenis suranguojame ir surašome į 1.18 lentelę. Apskaičiuojame:

$$\begin{aligned} \frac{\sum_{j=1}^6 \tilde{R}_j}{6} &= 10,5; & \tilde{S} &= (8 - 10,5)^2 + (14 - 10,5)^2 + (11 - 10,5)^2 \\ & & &+ (11 - 10,5)^2 + (11 - 10,5)^2 + (8 - 10,5)^2 = 25,5; \\ W &= \frac{12 \cdot 25,5}{3^2(6^3 - 6)} = 0,16. \end{aligned}$$

Kadangi W arti nulis, galime teigti, kad ekspertų vertinimai labai skiriasi.

1.18 lentelė. Ekspertų nuomonių rangai

Kandidatas	Ekspertas			$\tilde{R}_i$
	X	Y	Z	
a	1	1	6	8
b	6	5	3	14
c	3	6	2	11
d	2	4	5	11
e	5	2	4	11
f	4	3	1	8

Kokia konkordacijos koeficiento skaičiavimo logika? $\tilde{S}$ parodo, ar ekspertų vertinimai labai skiriasi nuo bendrojo vidutinio vertinimo. Normuojantis daugiklis parenkamas taip, kad konkordacijos koeficientas būtų lygus vienetui, kai ekspertų vertinimai visiškai sutampa. Tada $\tilde{R}_j = jk$, $j = 1, \dots, n$, o

$$\sum_{j=1}^n \left(\tilde{R}_j - \frac{\sum_{j=1}^n \tilde{R}_j}{n} \right)^2 = \frac{1}{12} k^2 (n^3 - n).$$

Galima apskaičiuoti ne tik patį konkordacijos koeficientą, bet ir patikrinti, ar jis statistiškai reikšmingai skiriasi nuo nulio.

1 *Duomenys.* Stebime k tolydžių kintamųjų $X_1, X_2, \dots, X_k$. Duomenys yra $(x_{1j}, x_{2j}, \dots, x_{kj})$, $j = 1, \dots, n$; čia x_{ij} – i -ojo kintamojo j -oji reikšmė (gauta matavimams naudojant santykių, intervalų arba rangų skalę), n – imties didumas.

2 *Statistinė hipotezė:*

$$\begin{cases} H_0: & \text{konkordacijos koeficientas lygus } 0, \\ H_1: & \text{konkordacijos koeficientas nelygus } 0. \end{cases}$$

3 *Kriterijaus statistika.* Pagal (14) formulę apskaičiuojame $\tilde{S}$.

4 *Sprendimo priėmimo taisyklė.* Tegul reikšmingumo lygmuo yra α . Hipotezė H_0 atmetama (t. y. matuojamų kintamųjų priklausomybė yra, konkordacijos koeficientas statistiškai reikšmingai skiriasi nuo 0), jeigu $\tilde{S}$ ne mažesnė už n ir k atitinkančią kritinę reikšmę iš 7 lentelės. Priešingu atveju hipotezė H_0 neatmetama.

1.17 pavyzdys. Tarkime, norime patikrinti, ar ekspertų nuomonės apie kandidatus koreliuoja. Tegul reikšmingumo lygmuo $\alpha = 0,05$. Jau buvome radę $\tilde{S} = 25,5$. Iš 7 lentelės randame $k = 3$ ir $n = 6$ atitinkančią $\tilde{S}$ kritinę reikšmę 103,9. Kadangi $25,5 < 103,9$, tai nulinės hipotezės H_0 atmesti negalima. Duomenys neleidžia teigti, kad ekspertų nuomonės koreliuoja.

Konkordacijos koeficiento skaičiavimas naudojantis SPSS paketu. SPSS paketas leidžia patikrinti hipotezę apie konkordacijos koeficiento lygybę nuliui. Konkordacija sta-

tistiškai reikšminga, jeigu atitinkama p -reikšmė (ją galima rasti stulpelyje *Sig.*) yra mažesnė už pasirinktąjį reikšmingumo lygmenį α . Beje, $k(n-1)W$ yra ne kas kita kaip Frydmano χ^2 statistikos reikšmė (turinti asimptotinį χ^2 skirstinį su $n-1$ laisvės laipsnių), kai skaičiuojama, ar visi 6 kandidatai įvertinti vienodai (t. y. taikant Frydmano kriterijų 6 priklausomoms imtims po tris stebėjimus, žr. 1.19 lentelę).

1.19 lentelė. Ekspertų nuomonės

Ekspertas	Kandidatas					
	<i>a</i>	<i>b</i>	<i>c</i>	<i>d</i>	<i>e</i>	<i>f</i>
<i>X</i>	10	4	8	9	6	7
<i>Y</i>	10	6	5	7	9	8
<i>Z</i>	5	8	9	6	7	10



Duomenų rangavimas	Kruskalo–Voliso kriterijus	Spirmeno koreliacijos koeficientas
Frydmano kriterijus	Mano–Vitnio–Vilkoksono kriterijus	Suderintosios poros
Kendalo koreliacijos koeficientas	Nesuderintosios poros	Susietosios reikšmės
Konkordacijos koeficientas	Serių kriterijus	Voldo–Volfovico kriterijus

UŽDAVINIAI

1. Studentai laikė statistikos egzaminą žodžiu. Išlaikė 22, neišlaikė 8. Egzamino rezultatai: *TTTTTNTTTNTTTTTTTNNNNNTTTT*; čia *T* – išlaikė, *N* – neišlaikė. Ar atsakinėjimo tvarka turi įtakos rezultatui (kai dėstytojas pradeda „mėtyti“, tai įsijaučia ir sunkiai liaujasi)? Tarkime, reikšmingumo lygmuo $\alpha = 0,05$.
2. Norima patikrinti, ar tam tikri pratimai mažina sistolinį¹ kraujo spaudimą. Atsitiktinai parinktų 15 žmonių spaudimas buvo matuotas prieš darant pratimus ir po to. Duomenys pateikti 1.20 lentelėje. Ar pratimai efektyvūs ($\alpha = 0,01$)?

1.20 lentelė. Kraujospūdis

Asmuo	Prieš	Po	Asmuo	Prieš	Po
<i>a</i>	164	162	<i>i</i>	138	139
<i>b</i>	146	144	<i>j</i>	130	124
<i>c</i>	148	146	<i>k</i>	175	170
<i>d</i>	154	156	<i>l</i>	146	147
<i>e</i>	143	145	<i>m</i>	160	157
<i>f</i>	160	159	<i>n</i>	160	140
<i>g</i>	150	145	<i>o</i>	153	148
<i>h</i>	148	150			

¹ Gr. *systolē* – susitraukimas, suspaudimas.

3. Besiruošdamas jubiliejui, verslininkas Apolonijus Drinkūnas atliko eksperimentą. Prisipirkęs pigių ir brangių šventinių žvakučių, jis fiksavo laiką, per kurį žvakutės sudega. Ar ponas Apolonijus teisingai nutaręs, kad žvakučių degimo laikas nesiskiria ir jubiliejui tiks pigiosios žvakutės? Duomenys pateikti 1.21 lentelėje ($\alpha = 0,05$).

1.21 lentelė. Žvakutės

Pigios	25	27	23	28	22	20	
Brangios	31	26	30	24	29	21	33



4. Gamtininkas R. Žvirblėnas tyrė musių pasiskirstymą trijose arealuose: žolynuose, krūmynuose ir virtuvėse. Duomenys pateikti 1.22 lentelėje (vidutinis musių skaičius 1 m^3). Ar tirtuose arealuose musių pasiskirstymas vienodas ($\alpha = 0,05$)?

1.22 lentelė. Musių tankis

Žolynas	14,0	12,1	9,6	8,2
Krūmynas	8,4	5,1	7,3	6,6
Virtuvė	6,9	5,3	5,8	4,1

5. Tarkime, kad mažmeninės prekybos firma nori pasirinkti spausdintuvų tiekėją. Ši firma gavo iš 3 tiekėjų informaciją apie 12 spausdintuvų kainas (Lt), kurias pateiktos 1.23 lentelėje. Ar tiekėjų siūlomos spausdintuvų kainos skiriasi ($\alpha = 0,05$)?

1.23 lentelė. Spausdintuvų kainos

Spausdintuvas	I tiekėjas	II tiekėjas	III tiekėjas
1	660	673	658
2	790	799	785
3	590	580	599
4	950	945	960
5	1290	1280	1295
6	1550	1500	1499
7	1980	1950	1970
8	2300	2295	2310
9	2500	2480	2490
10	2190	2199	2210
11	5590	5500	5550
12	6000	6100	6090

6. Penki nepriklausomi ekspertai balais vertino 3 rūšių alų. Duomenys pateikti 1.24 lentelėje. Ar visų rūšių alus yra vienodai geras ($\alpha = 0,05$)?

1.24 lentelė. Alaus kokybė

Ekspertas	Alaus rūšis		
	A	B	C
Pirmas	10	7	8
Antras	5	2	4
Trečias	6	8	6
Ketvirtas	3	4	6
Penktas	9	8	10

7. Kavos rūšių Atuvos rinkoje dalys (procentais) ir reklamos išlaidos pateiktos 1.25 lentelėje. Apskaičiuokite Spirmeno koreliacijos koeficientą. Ar kintamieji yra priklausomi ($\alpha = 0,05$)?

1.25 lentelė

Rūšis	<i>A</i>	<i>B</i>	<i>C</i>	<i>D</i>	<i>E</i>	<i>F</i>	Kita
Rinkos dalis (%)	15,7	3,9	10,6	9,6	12,3	26,2	21,7
Reklamos išlaidos (tūkst. eurų)	7,6	3,5	6,1	6,8	8,3	10,1	7,1

8. Naudodamiesi 6 uždavinio duomenimis, raskite konkordacijos koeficientą W . Ar jis statistiškai reikšmingai skiriasi nuo 0 ($\alpha = 0,05$)?

2. VIENFAKTORINĖ DISPERSINĖ ANALIZĖ



Kam kalbėti trumpai ir aiškiai, jeigu galima sudėtingai ir nuostabiai.

Trumpai: vienfaktorinė dispersinė analizė yra Stjudento kriterijaus apibendrinimas keletui nepriklausomų imčių. Įsivaizduokime, kad Vilniaus, Rygos ir Talino sociologai tiria, kiek laiko studentai būna „internautais“, t. y. kiek minučių per savaitę jie naudojami internetu. Tarkime, kad, tyrimą dosniai finansavus Bilui Geitsui, sociologams pavyko apklausti *visus* trijų miestų studentus. Tuomet visiškai tiksliai galima nustatyti, kurios sostinės studentai daugiausia laiko praleidžia prie interneto. Tačiau toks tyrimas labai brangiai kainuoja. Kur kas pigiau būtų apklausti tik *dalį* visų studentų. Apklausai studentus parinkus visiškai atsitiktinai, tektų spręsti klasikinę statistikos problemą – pagal imtis nuspręsti apie pačias populiacijas. Minimo pavyzdžio atveju lyginame trijų miestų studentų vidutinį praleistą prie interneto laiką. Panašūs uždaviniai iškyla, kai:

- autobusų parko direkcija susirūpina skirtingų rūšių padangų vidutine sudilimo trukme;
- sociologas nori sužinoti, ar mokytojų, medikų ir policininkų vidutiniškai per metus suvartojamas alkoholio kiekis skiriasi;
- medikas domisi, kuri terapija garantuoja trumpiausią pooperacinę reabilitaciją;
- mokesčių inspekcija smalsauja, ar gydymo įstaigos daro mažiau buhalterinės apskaitos klaidų nei transporto arba prekybinės firmos ir pan.

Visais minėtais atvejais statistikui tektų lyginti kelių ar net keliolikos imčių vidurkius ir taikyti specialų statistinį tyrimo metodą – vienfaktorinę dispersinę analizę. Vienfaktorinei dispersinei analizei žymėti plačiai vartojama santrumpa ANOVA¹.

Vienfaktorinė dispersinė analizė naudojama tada, kai populiacijas vieną nuo kitos tyrėjas skiria tik pagal *vieną* požymį. Atvejai, kai atsižvelgiama į daugiau požymių, nagrinėjami trečiame skyriuje.

Kategorinis kintamasis (populiacijos požymis), pagal kurį skiriame populiacijas viena nuo kitos, vadinamas *nepriklausomuoju* kintamuoju, arba *faktoriumi*. Tiriant padangų dilimą, nepriklausomas kintamasis yra padangų rūšis; gėrimo įpročius – respondento profesija; pooperacinę reabilitaciją – terapijos rūšis; buhalterinę apskaitą – firmos veiklos pobūdis. Norėdami trumpai įvardyti, *ką* visose populiacijose matuojame, vartosime *priklausomojo* kintamojo sąvoką. Tiriant padangas, priklausomas kintamasis yra padangos sudilimo laikas; gėrimo įpročius – kiekvieno respondento per metus išgeriamas alkoholio kiekis; terapijas – pooperacinės reabilitacijos trukmė; buhalterinę apskaitą – padarytų klaidų skaičius.

Dispersinės analizės tikslas – nuspręsti, ar priklausomo kintamojo, išmatuoto skirtingose populiacijose, vidurkiai skiriasi.

¹ ANOVA – ang. *ANalysis Of VAriance*.

Dažniausiai naudojami du vienfaktorinės dispersinės analizės modeliai – *fiksuotasis* ir *atsitiktinis*. Remiantis fiksuotu modeliu, lyginami *visų* turimų imčių vidurkiai. Taikant atsitiktinį modelį, priklausomas kintamasis matuojamas daugelyje populiacijų, o vidurkiams lyginti atsitiktinai parenkama tik dalis imčių. Pavyzdžiui, atšiaurumo svetimtaučiams indeksą pamatavus Vokietijoje, Italijoje bei Prancūzijoje ir visas šias valstybes lyginant, taikomas fiksuotasis ANOVA modelis. Apklausą atlikus visose Europos valstybėse ir lyginimui atsitiktinai parinkus tik tris iš jų, naudojamas atsitiktinis ANOVA modelis. Šiame skyriuje kalbama tik apie fiksuotąjį vienfaktorinės analizės modelį.

Be dispersinės analizės, šiame skyriuje aptariamos ir kitos, glaudžiai su ja susijusios, temos: trendų analizė, daugkartiniai lyginimai ir pan.

2.1. Dispersinė analizė ir t kriterijus

Taikydami ANOVA, lyginame kelių nepriklausomų imčių vidurkius. Analogiškoje dviejų imčių situacijoje naudojome Stjudento t kriterijų. Atrodytų, kad šio kriterijaus turėtų pakakti ir tuomet, kai imčių daugiau nei dvi.



Kai vienintelis turimas įrankis yra plaktukas, kiekviena problema pradeda atrodyti panaši į vinį.

A. Maslou

Tarkime, norime palyginti dešimties profesijų atstovus ir nustatyti, kurie iš jų daugiau sia keikiasi¹. Sudarę dešimt imčių, apskaičiuojame kiekvieno respondento keiksmų per mėnesį skaičių. Galime sudaryti visas įmanomas imčių poras ir kiekvienai porai taikyti Stjudento kriterijų. Lyginame pirmos profesijos atstovus su antrosios, trečiosios su ketvirtosios ir t. t. Tačiau taip daryti *nerekomenduojama*. Kodėl? Akivaizdu, kad daugkartinis Stjudento kriterijaus taikymas – darbui imlus procesas. Tačiau tai tik menkas nepatogumas, jeigu skaičiuojama kompiuteriu. Pagrindinė problema – padidėjusi pirmosios rūšies klaidos tikimybė.

Primename, kad taikydami statistinius kriterijus pagal imtį sprendžiame apie visą populiaciją (žr. [1], 3.2 skyrių). Tiriame tik po kelis kiekvienos profesijos atstovus, o sprendžiame apie *visus* toms profesijoms priklausančius. Geriausiu atveju mūsų išvada yra tik *labai tikėtina*. Apsirikti galime dvejopai – įžiūrėdami, kad vidutiniškai skirtingų profesijų atstovai keikiasi nevienodai, nors taip nėra (I rūšies klaida), arba tų skirtumų nerasdami, nors jie iš tikrųjų yra (II rūšies klaida). Kiekvieną statistinį kriterijų galima „suderinti“ taip, kad jį taikant pirmosios rūšies klaida neviršytų iš anksto pasirinkto fiksuoto skaičiaus α (vadinamojo *reikšmingumo lygmens*). Taip garantuojame, kad bent jau teisingą nulinę hipotezę atmesime ne per dažnai. Pavyzdžiui, pasirinkę reikšmingumo lygmenį $\alpha = 0,05$ ir tokį kriterijų taikydami daug kartų, maždaug 95% atvejų teisingos nulinės hipotezės neatmesime.



Statistiko gyvenimo tikslas – klysti penkiais atvejais iš šimto.

¹ Juk ne veltui liaudis sako: „Keikiasi kaip šiaučius“.

Tarkime, Stjudento t kriterijus „suderintas“ taip, kad $\alpha = 0,05$. Lyginame pirmą imtį su antrąja. Tikimybė neteisingai nuspręsti, kad pačių populiacijų vidurkiai skiriasi (padaryti I rūšies klaidą), lygi 0,05. Lyginame pirmą imtį su trečiąja. Tikimybė padaryti pirmosios rūšies klaidą lygi 0,05. Atrodytų, viskas gerai. Tačiau, kokia tikimybė šį procesą tęsiant *bent vieną kartą* padaryti pirmosios rūšies klaidą? Ši tikimybė dar vadinama *eksperimento reikšmingumo lygmeniu* ir žymima α_E .

Tarkime, statistinei problemai išspręsti reikia keletą kartų taikyti statistinius kriterijus. Eksperimento reikšmingumo lygmuo α_E yra tikimybė bent kartą padaryti pirmosios rūšies klaidą. Vienfaktorinėje dispersinėje analizėje α_E – tai tikimybė bent vieną kartą nuspręsti, kad lyginamų populiacijų vidurkiai nelygūs, nors iš tikrųjų jie nesiskiria.

Rasime eksperimento reikšmingumo lygmenį, kai t kriterijus taikomas daug kartų. Prisiminę tikimybių teoriją, pereiname prie priešingo įvykio

$$\alpha_E = P(\text{bent viena I rūšies klaida}) = 1 - P(\text{nė vienos I rūšies klaidos}).$$

Tikimybė, kad lygindami dvi imtis *nepadarysime* pirmosios rūšies klaidos, lygi $1 - \alpha$. Tarkime, lyginame C imčių porų. Tuomet

$$\alpha_E \approx 1 - (1 - \alpha)^C. \quad (1)$$

Tiksli lygybė galiotų, jeigu visi įvykiai būtų nepriklausomi (pvz., kiekviena imtis būtų lyginama tik vieną kartą). Turint k imčių ir *visas* jas lyginant poromis, $C = k(k - 1)/2$ (žr. [1], II dalį). Minėto pavyzdžio apie profesijų keiksmingumą imčių yra 10. Įstatę $\alpha = 0,05$ į (1) lygtį, gauname

$$\alpha_E \approx 1 - (1 - 0,05)^{45} \approx 0,90. \quad (2)$$

Taigi, sprendžiant problemą t kriterijumi, tikimybė *bent kartą* klaidingai paskelbti apie dviejų profesijų skirtumą išauga iki 0,90 vietoje norimos 0,05.

Toks drastiškas pirmosios rūšies klaidos tikimybės šuolis nuo 5% iki 90% paskatino naujų kriterijų paiešką. Vienfaktorinę dispersinę analizę XX amžiaus pirmoje pusėje pasiūlė R. A. Fišeris. Šis metodas leidžia atsakyti į klausimą, ar iš kelių nepriklausomų imčių bent dviejų vidurkiai statistiškai reikšmingai skiriasi esant fiksuotam eksperimento reikšmingumo lygmeniui $\alpha_E = \alpha$.

Nors šiame skyriuje vienfaktorinė dispersinė analizė taikoma lyginti trims ir daugiau imčių, ji tinka ir dviem imtims. Pastaruoju atveju ANOVA rezultatai sutampa su Stjudento kriterijaus dviem nepriklausomoms imtims rezultatais.



Nesutariama, ar bučiamasis ilgina, ar trumpina žmogaus gyvenimą. Europiečiai linkę manyti, kad ilgina (degina kalorijas). Kinai 1992 metais paskelbė straipsnį, įrodantį, kad bučiamasis trumpina gyvenimą (didina kraujo spaudimą). Pasibučiuokite 175 200 kartų ir prarasite metus gyvenimo. Kol kas niekas nesiėmė šių teiginių patikrinti empiriškai.

2.2. Struktūrinis ANOVA modelis

Tarkime, turime k nepriklausomų populiacijų. Priklausomas kintamasis, matuojamas i -ojoje populiacijoje, vadinamas populiacijos kintamuoju. Populiacijų kintamuosius pažymime $X_1, X_2, \dots, X_k$. Iš kiekvienos populiacijos parenkama paprastoji atsitiktinė imtis: $X_{i1}, X_{i2}, \dots, X_{in_i}$; čia $i = 1, 2, \dots, k$ – populiacijos numeris, o n_i – i -osios imties didumas. ANOVA duomenys pateikiami 2.1 lentelė.

2.1 lentelė. ANOVA duomenys

X_1	X_2	X_3	...	X_k
X_{11}	X_{21}	X_{31}	...	X_{k1}
X_{12}	X_{22}	X_{32}	...	X_{k2}
X_{13}	X_{23}	X_{33}	...	X_{k3}
...	...	...	...	...
X_{1n_1}	X_{2n_2}	X_{3n_3}	...	X_{kn_k}


Struktūrinis ANOVA modelis i -osios imties j -ajam stebėjimui X_{ij} užrašomas taip:

$$X_{ij} = \mu_i + e_{ij} = \mu + \tau_i + e_{ij}; \quad (3)$$


čia $\mu_i = \mathbf{E}X_i = \mathbf{E}X_{ij}$ yra i -osios populiacijos kintamojo vidurkis; e_{ij} – atsitiktinė paklaida; μ – bendrasis visų populiacijų vidurkis; $\tau_i = \mu_i - \mu$ yra i -osios populiacijos vidurkio ir bendrojo vidurkio skirtumas (kartais τ_i dar vadinamas i -osios populiacijos *efektu*). Modelis nusako, kokią potencialią reikšmę gali įgyti i -osios imties j -asis elementas, todėl (3) formulėje X_{ij} yra atsitiktinis dydis. Beje, μ , μ_i , τ_i yra skaičiai, o e_{ij} – atsitiktinis dydis.



Struktūrinis ANOVA (3) modelis tik nusako duomenų sandarą, t. y. kokios komponentės jį sudaro. Mes nežinome nei μ , nei μ_i tikrųjų reikšmių. Atsitiktinis dydis e_{ij} irgi priklauso nuo nežinomos dispersijos. Sąlygos, kurias turi tenkinti e_{ij} , yra ne kas kita, kaip reikalavimai, leidžiantys taikyti vienfaktorinę dispersinę analizę.



Struktūriniu ANOVA (3) modeliu matematiškai užrašoma gana paprasta idėja. Tarkime, lyginame suaugusių lietuvių, japonų bei pigmėjų ūgius. Nepriklausomas faktorius – tautybė, priklausomas – ūgis. Kintamasis X_1 žymi lietuvių ūgį, X_2 – japonų, o X_3 –



pigmėjo. Tuomet (3) modelyje μ atitinka vidutinį visų trijų populiacijų žmonių ūgį; μ_1 – vidutinį lietuvių ūgį (μ_2 ir μ_3 – atitinkamai vidutinius japonų ir pigmėjų ūgius); τ_1 – vidutinio lietuvių ūgio ir bendrojo ūgių vidurkio skirtumą (kiek lietuvių ūgio vidurkis didesnis už bendrąjį trijų populiacijų ūgio vidurkį); e_{1j} – dydis, rodantis, kiek j -asis lietuvių imties respondentas skiriasi nuo vidutinio lietuvio. Galima matavimo realizacija pateikta 2.1 paveiksle. Žinoma, paklaida e_{ij} ir τ_i taip pat gali įgyti ir neigiamas reikšmes.

ANOVA šiuo atveju padeda nustatyti, ar įvairių tautybių vidutiniai vyrų ūgiai skiriasi.



Skiriasi ne tik rasių ūgiai, bet ir plaukuotumas. Suaugę azijiečiai vidutiniškai ant galvos turi 120 000 plaukų, juodieji Karibų gyventojai – 110 000. Europos blondinės vidutiniškai turi 140 000, o rudaplaukės – tik 108 000 plaukų.

2.3. Dispersinės analizės prielaidos

Taikydami ANOVA, tiriamo k populiacijų. Pirmoje populiacijoje stebime kintamąjį X_1 , antroje – $X_2, \dots$, k -ojoje – X_k . Ko reikia, kad būtų galima taikyti vienfaktorinę dispersinę analizę?

ANOVA modelio prielaidos:


- 1) kintamieji pasiskirstę pagal normalųjį dėsnį;
- 2) kintamųjų dispersijos lygios;
- 3) kintamieji nepriklausomi.

Šie reikalavimai susiję su struktūrinio ANOVA modelio sandara. Būtent jais remiantis sudaromas pats kriterijus vidurkių lygybei tikrinti. Vienfaktorinė dispersinė analizė yra ganėtinai atspari nedideliems ir net vidutiniams nuokrypiams nuo pirmųjų dviejų prielaidų, tačiau tik tada, kai imčių didumai panašūs. Kiekvieną reikalavimą aptarsime atskirai.

1

Kintamųjų normalumas. Teorinis modelis reikalauja, kad visi duomenys būtų gauti stebint normaliuosius kintamuosius, kitaip sakant, kad $X_1, X_2, \dots, X_k$ būtų normaliai pasiskirstę (žr. 2.2 pav.).

ANOVA yra pakankamai atspari normalumo prielaidos pažeidimams – ypač kai imčių didumai mažai skiriasi. Labai dažnai ANOVA taikoma net ir tuo atveju, kai kintamieji matuojami pagal rangų skalę. Svarbu tik, kad kintamojo vidurkis turėtų prasmę ir skirtingų




rangų nebūtų per mažai. Pavyzdžiui, egzamino pažymys yra ranginis kintamasis (nuo 1 – labai blogai iki 10 – puiku), bet visiems aišku, kas tai yra sesijos pažymių vidurkis. Nėra griežtų taisyklių, reglamentuojančių minimalų įgyjamų rangų skaičių. Dauguma mano, kad turi būti bent 7 skirtingi rangai. Tuo tarpu kai kurie autoriai siūlo ANOVA naudoti 5 skirtingų rangų skalei.

2 *Dispersijų lygybė.* Teorinis modelis reikalauja, kad visų populiacijų kintamųjų dispersijos būtų lygios: $\mathbf{DX}_1 = \mathbf{DX}_2 = \dots = \mathbf{DX}_k = \sigma^2$.

Iš pirmųjų dviejų reikalavimų išplaukia, kad $X_1 \sim \mathcal{N}(\mu_1, \sigma^2)$, $X_2 \sim \mathcal{N}(\mu_2, \sigma^2)$, ..., $X_k \sim \mathcal{N}(\mu_k, \sigma^2)$. Taigi kintamieji $X_1, \dots, X_k$ turi visiškai identišką formą tankius, kurie gali skirtis tik padėties parametrais (vidurkiais). Skirtingai nuo Stjudento kriterijaus, ANOVA nelygių dispersijų atveju modifikacijų neturi. Yra keletas kriterijų dispersijų lygybei patikrinti. Du iš jų pateikiami 2.10 skyrelyje.

Ar galima ANOVA taikyti, kai ne visų populiacijų dispersijos lygios? Tai labai priklauso nuo imčių didumo. Jeigu didesnė imtis yra iš populiacijos, kurios dispersija didesnė, kriterijus tampa per daug konservatyvus – apskaičiuotoji p -reikšmė yra didesnė nei tikroji. Todėl rečiau, nei turėtų būti, pripažįstamas populiacijų vidurkių skirtumas, didėja antrosios rūšies klaidos tikimybė ir mažėja kriterijaus galia. Jeigu iš populiacijos, kurios dispersija didesnė, parinkta maža imtis, kriterijus tampa per daug liberalus – apskaičiuotoji p -reikšmė yra mažesnė nei tikroji. Todėl dažniau skelbiamas populiacijų vidurkių skirtumas, nors iš tikrųjų jo ir nėra; didėja pirmosios rūšies klaidos tikimybė. Kuo mažiau skiriasi imčių didumai, tuo mažiau ANOVA jautri populiacijų dispersijų skirtumams.



Žinoma, net ir vienodo didumo imčių dispersijos negali *per daug* skirtis. Vertinant dispersijų lygybę „iš akies“, reikalaujama, kad didžiausioji iš *imčių* dispersijų būtų didesnė už mažiausiąją ne daugiau kaip tris kartus.

3 *Kintamųjų nepriklausomumas.* Visi populiacijų kintamieji $X_1, X_2, \dots, X_k$ yra nepriklausomi (visos e_{ij} (3) formulėje – nepriklausomos). Šios prielaidos pažeidimas gali turėti didelės įtakos ANOVA rezultatams, todėl taikydami vienfaktorinę dispersinę analizę turime būti tikri, kad duomenys gauti stebint nepriklausomus populiacijų kintamuosius. Priklausomiems kintamiesiems taikoma blokuotųjų duomenų dispersinė analizė (žr. 4 skyrių).

Taikant vienfaktorinę dispersinę analizę, labai svarbu, kad visų imčių didumai skirtųsi kuo mažiau. Kuo vienesnės imčių didumai, tuo ANOVA atsparesnė kintamųjų normalumo bei lygių dispersijų reikalavimų pažeidimams.

Žinoma, vienfaktorinės dispersinės analizės rezultatai tiesiogiai priklauso ir nuo pačių imčių didumų. Jeigu kiekvienoje imtyje stebėjimų labai daug, tai net ir nedideli imčių vidurkių skirtumai laikomi statistiškai reikšmingais. Primename, kad sąvokos „statistiškai reikšmingas skirtumas“ ir „tyrimui reikšmingas skirtumas“ yra netapačios (žr. [1], 3.3.3 skyrelį).

2.4. Kriterijaus apie vidurkių lygybę sudarymas

Sakykime, kad populiacijose stebimi nepriklausomi kintamieji $X_1 \sim \mathcal{N}(\mu_1, \sigma^2)$, $X_2 \sim \mathcal{N}(\mu_2, \sigma^2)$, $\dots$, $X_k \sim \mathcal{N}(\mu_k, \sigma^2)$. Nulinė vienfaktorinės dispersinės analizės hipotezė teigia, kad visi populiacijų kintamųjų vidurkiai lygūs, t. y. $H_0: \mu_1 = \mu_2 = \dots = \mu_k$. Ar jie lygūs, nuspręsimė lygindami imčių vidurkius $\bar{X}_1, \bar{X}_2, \dots, \bar{X}_k$.



Patys imčių vidurkiai beveik visuomet skiriasi. Tačiau kartais tie skirtumai yra dideli (statistiškai reikšmingi) ir mes teigiame, kad skiriasi ir pačių populiacijų vidurkiai, nes tai labai tikėtina. Kartais imčių vidurkių skirtumai yra maži (statistiškai nereikšmingi), galintys atsirasti dėl atsitiktinumo sudarant imtis. Tada nefiksuojame populiacijų vidurkių skirtumo.


Tačiau vien pačių imčių vidurkių nepakanka, dar reikia žinoti ir dispersijos didumą. Iš tikrųjų tuos pačius imčių vidurkius gali atitikti ir situacija, kai visų kintamųjų tankis yra toks pat, o dispersija didelė; ir situacija, kai visų kintamųjų tankiai skirtingi, o dispersijos mažos. Kai dispersija σ^2 didelė, didelė ir duomenų sklaida, kuri ir lemia nemažus skirtingų *imčių* vidurkių skirtumus, nors iš tikrųjų visų *kintamųjų* vidurkis tas pats (žr. 2.4 pav., a)). Kai σ^2 maža, duomenys koncentruoti apie vidurkius, todėl imčių vidurkių skirtumai atskleidžia tikrųjų kintamųjų vidurkių skirtumus (žr. 2.4 pav., b)).

Vienfaktorinė dispersinė analizė grindžiama dviejų dispersijos σ^2 įverčių palyginimu (nuo to kilo ir kriterijaus pavadinimas). Aptarsime šią idėją išsamiau.

Panagrinėkime 2.1 lentelę. Tarkime, kad visų imčių didumų suma lygi $N = n_1 + n_2 + \dots + n_k$. Tegul bendrasis visų imčių vidurkis yra $\bar{X}$ (t. y. *visi* duomenys sudėti ir padalyti iš N), o $\bar{X}_i$ yra i -osios imties vidurkis. Imkime pirmosios imties pirmąjį elementą X_{11} . Jo ir bendrojo vidurkio skirtumą galime išskaidyti į dvi komponentes:

$$X_{11} - \bar{X} = (X_{11} - \bar{X}_1) + (\bar{X}_1 - \bar{X}). \quad (4)$$

Palyginę šią formulę su (3), matome, kad (4) sandara visiškai analogiška struktūriniam vienfaktorinės dispersinės analizės modeliui. Iš tikrųjų $\bar{X}$ atitinka μ ; $X_{11} - \bar{X}_1$ atitinka e_{11} , o $\bar{X}_1 - \bar{X}$ atitinka τ_1 .



Pakelkime abi (4) lygybės puses kvadratu:

$$(X_{11} - \bar{X})^2 = (X_{11} - \bar{X}_1)^2 + (\bar{X}_1 - \bar{X})^2 + 2(X_{11} - \bar{X}_1)(\bar{X}_1 - \bar{X}). \quad (5)$$

Analogiškai išreiškę visų pirmosios imties elementų ir bendrojo vidurkio skirtumus bei gautus rezultatus sudėję, gauname:

$$\begin{aligned} & (X_{11} - \bar{X})^2 + (X_{12} - \bar{X})^2 + \dots + (X_{1n_1} - \bar{X})^2 \\ &= (X_{11} - \bar{X}_1)^2 + \dots + (X_{1n_1} - \bar{X}_1)^2 + n_1(\bar{X}_1 - \bar{X})^2 + 2(\bar{X}_1 - \bar{X}) \\ & \quad \times ((X_{11} - \bar{X}_1) + (X_{12} - \bar{X}_1) + \dots + (X_{1n_1} - \bar{X}_1)). \end{aligned} \quad (6)$$

Nesunku patikrinti, kad paskutinis (6) lygybės dėmuo lygus nuliui. Taigi

$$\sum_{j=1}^{n_1} (X_{1j} - \bar{X})^2 = \sum_{j=1}^{n_1} (X_{1j} - \bar{X}_1)^2 + n_1(\bar{X}_1 - \bar{X})^2. \quad (7)$$

Analogiškai susitvarkę su kitomis imtimis ir rezultatus susumavę, gauname

$$SST = SSW + SSB; \quad (8)$$


čia

$$\begin{aligned} SST &= \sum_{i=1}^k \sum_{j=1}^{n_i} (X_{ij} - \bar{X})^2, & SSW &= \sum_{i=1}^k \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2, \\ SSB &= \sum_{i=1}^k n_i (\bar{X}_i - \bar{X})^2. \end{aligned} \quad (9)$$



Didelė grupių kvadratų sumos reikšmė, palyginti su vidine kvadratų suma, rodo, kad imčių vidurkiai reikšmingai skiriasi. Tuo grindžiamas ir pats kriterijus. Kaip matysime, čia naudojama statistika F išreiškiama normuotų SSB ir SSW santykiu. Beje, tarptautiniu mastu vartojami žymenys SSB , SSW ir SST yra atitinkamai angliškų terminų – „sum of squares between“, „sum of squares within“, „sum of squares total“ – santrumpos.

Kiekvienas (8) lygybės dėmuo turi savo pavadinimą. *SST* apima visų duomenų ir bendrojo vidurkio skirtumus ir vadinama *visa kvadratų suma*. Matome, kad ji skyla į dvi komponentes. Pirmoji komponentė *SSW* įvertina kiekvienos imties duomenų sklaidą (apie imties vidurkį) ir vadinama *vidinė kvadratų suma*. Antroji komponentė *SSB* įvertina imčių vidurkių ir bendrojo vidurkio skirtumus ir vadinama *grupių kvadratų suma*. Grafiškai (8) lygybė pavaizduota 2.5 paveiksle.



Pasinaudosime (8) skaidiniu ir sudarysime du nežinomos dispersijos σ^2 įverčius. Tarkime, kad visų populiacijų vidurkiai lygūs: $\mu_1 = \mu_2 = \dots = \mu$. Tuomet:

$$\mathbf{ESSW} = (N - k)\sigma^2, \quad \mathbf{ESST} = (N - 1)\sigma^2,$$

$$\mathbf{ESSB} = \mathbf{ESST} - \mathbf{ESSW} = (N - 1)\sigma^2 - (N - k)\sigma^2 = (k - 1)\sigma^2.$$

Sunormavę kvadratų sumas, gauname du dispersijos įverčius:

$$MSW = \frac{SSW}{N - k} = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2 + \dots + (n_k - 1)S_k^2}{n_1 + n_2 + \dots + n_k - k}, \quad (10)$$

$$MSB = \frac{SSB}{k - 1} = \frac{n_1(\bar{X}_1 - \bar{X})^2 + \dots + n_k(\bar{X}_k - \bar{X})^2}{k - 1}; \quad (11)$$

čia S_i^2 yra i -osios imties dispersija.

Galima įsitikinti, kad bendruoju atveju

$$\mathbf{EMSW} = \sigma^2, \quad \mathbf{EMSB} = \sigma^2 + \frac{\sum_1^k n_i(\mu_i - \mu)^2}{k - 1}; \quad (12)$$

čia μ yra bendrojo visų populiacijų vidurkio analogas, t. y.

$$\mu = \mathbf{E}\bar{X} = \frac{n_1\mu_1 + n_2\mu_2 + \dots + n_k\mu_k}{N}.$$

Matome, kad MSW yra nepaslinktasis (vidinis) dispersijos įvertis, tuo tarpu MSB yra nepaslinktasis dispersijos įvertis tik tuo atveju, jeigu visų kintamųjų vidurkiai sutampa. ANOVA hipotezei tikrinti naudojama statistika

$$F = \frac{MSB}{MSW}. \quad (13)$$

2.2 lentelė. ANOVA rezultatai

	Kvadratų suma	Laisvės laipsniai	Dispersijos įverčiai	Statistika
Grupių	SSB	$k - 1$	MSB	F
Vidinė	SSW	$N - k$	MSW	
Visa	SST	$N - 1$		

Jei F reikšmė didelė, tai tikėtina, kad vidurkiai skiriasi, jei artima vienetui – ne. Tikslus kriterijus formuluojamas 2.5 skyrelyje.

Jeigu nulinė ANOVA hipotezė teisinga (visų populiacijų vidurkiai lygūs), tai F turi Fišerio skirstinį su $(k - 1)$ ir $(N - k)$ laisvės laipsnių. Remiantis šiuo faktu, kiekvienam reikšmingumo lygmeniui sudaromos kritinės sritys. ANOVA rezultatai paprastai pateikiami 2.2 lentele.

Dydžius SSB ir SSW patogiau skaičiuoti pagal tokias formules:

$$T_i = X_{i1} + X_{i2} + \dots + X_{in_i}, \quad T = X_{11} + \dots + X_{kn_k} = T_1 + \dots + T_k, \quad (14)$$

$$N = n_1 + n_2 + \dots + n_k, \quad SST = \sum_{i=1}^k \sum_{j=1}^{n_i} X_{ij}^2 - \frac{T^2}{N}, \quad (15)$$

$$SSB = \sum_{i=1}^k \frac{T_i^2}{n_i} - \frac{T^2}{N}, \quad SSW = \sum_{i=1}^k \sum_{j=1}^{n_i} X_{ij}^2 - \sum_{i=1}^k \frac{T_i^2}{n_i}. \quad (16)$$

2.5. Vienfaktorinės dispersinės analizės taikymas

Ankstesniame skyrelyje išdėstyta teorija leidžia suformuluoti tokias ANOVA taikymo taisykles.

1 *Duomenys.* Turime k imčių $(x_{11}, x_{12}, \dots, x_{1n_1}), (x_{21}, x_{22}, \dots, x_{2n_2}), \dots, (x_{k1}, x_{k2}, \dots, x_{kn_k})$, gautų matuojant nepriklausomus normaliuosius atsitiktinius dydžius $X_1 \sim \mathcal{N}(\mu_1, \sigma^2)$, $X_2 \sim \mathcal{N}(\mu_2, \sigma^2)$, $\dots$, $X_k \sim \mathcal{N}(\mu_k, \sigma^2)$ pagal intervalų skalę. Nei vidurkių $\mu_1, \dots, \mu_k$, nei dispersijos σ^2 nežinome.

2 *Statistinė hipotezė:*

$$\begin{cases} H_0: \mu_1 = \mu_2 = \dots = \mu_k, \\ H_1: \text{bent du vidurkiai skiriasi.} \end{cases} \quad (17)$$

3 *Kriterijaus statistika.* Skaičiuojama F pagal (13) formulę.

4 *Sprendimo priėmimo taisyklė.* Tegul reikšmingumo lygmuo lygus α . Hipotezė H_0 atmetama (taigi bent du vidurkiai statistiškai reikšmingai skiriasi), jeigu $F > F_\alpha(k - 1, N - k)$; čia $N = n_1 + \dots + n_k$, $F_\alpha(k - 1, N - k)$ yra Fišerio skirstinio su $k - 1$ ir $N - k$ laisvės laipsnių α lygmens kritinė reikšmė. Hipotezė H_0 neatmetama, jeigu $F \leq F_\alpha(k - 1, N - k)$.

2.1 pavyzdys. Gamykloje yra keturių rūšių staklės. Žinoma, kiek mėnesių praėjo nuo kiekvienų staklių darbo pradžios iki pirmojo gedimo. Ar duomenys leidžia teigti, kad ne visų rūšių staklės genda vienodai greitai? (Reikšmingumo lygmuo $\alpha = 0,05$.) Duomenys pateikti 2.3 lentelėje.

2.3 lentelė. Staklių gedimai

Staklių rūšis	A	B	C	D	
Laikas iki pirmojo gedimo (mėn.)	36,0 30,2 33,3 35,1 33,9	35,0 36,0 34,5 33,9	35,0 30,6 33,7 37,1	36,5 30,3 30,0 33,6 36,5	
n_i	5	4	4	5	$N = 18$
T_i	167,5	139,4	136,4	166,9	$T = 610,2$
$\bar{x}_i$	33,50	34,85	34,10	33,48	$\bar{x} = 33,85$
$\sum x_{ij}^2$	5631,35	4860,46	4673,46	5611,55	$\sum x_{ij}^2 = 20776,82$

Tegul μ_i yra vidutinis laikas iki i -osios rūšies staklių pirmojo gedimo. (Mes nežinome μ_i ! Žinome tik apytikslės šių vidurkių reikšmes – imčių vidurkius $\bar{x}_i$.) Nagrinėjamo pavyzdžio statistinės hipotezės formuluotė sutampa su (17). Atkreipiame dėmesį, kad žodžiais šią hipotezę galima suformuluoti taip:

$$\begin{cases} H_0: \text{visų rūšių staklių vidutiniai laikai iki pirmojo gedimo nesiskiria,} \\ H_1: \text{bent dviejų rūšių staklių vidutiniai laikai iki gedimo skiriasi.} \end{cases}$$

Pagal (14)–(16) formules randame:

$$T_1 = 36 + \dots + 33,9 = 167,5, \quad \dots, \quad T = 167,5 + \dots + 166,9 = 610,2,$$

$$N = 5 + 4 + 4 + 5 = 18, \quad T_1^2/5 + T_2^2/4 + T_3^2/4 + T_4^2/5 = 20691,70,$$

$$\sum_{i=1}^4 \sum_{j=1}^{n_i} x_{ij}^2 = 36^2 + 30,2^2 + \dots + 36,5^2 = 5631,35 + \dots + 5611,55 = 20776,82,$$

$$SSB = 20691,70 - 20685,78 = 5,92, \quad SSW = 20776,82 - 20691,70 = 85,12,$$

$$SST = 91,04, \quad k - 1 = 4 - 1 = 3, \quad N - k = 18 - 4 = 14.$$

Taigi

$$MSB = SSB/(k - 1) = 5,92/3 = 1,97, \quad MSW = SSW/(N - k) = 85,12/14 = 6,08,$$

$$F = MSB/MSW = 1,97/6,08 = 0,32.$$

Gauti rezultatai pateikti 2.4 lentelėje įprastu ANOVA pavidalu.

2.4 lentelė. Staklių gedimo ANOVA rezultatai

	Kvadratų suma	Laisvės laipsniai	Dispersijos įverčiai	Statistika
Grupių	5,92	3	1,97	0,32
Vidinė	85,12	14	6,08	
Visa	91,04	17		


Kadangi $F = 0,32 < 3,34 = F_{0,05}(3,14)$ (žr. priedo 4 lentelę), tai atmesti nulinės hipotezės negalima. Turimi duomenys neleidžia teigti, kad įvairių rūšių staklių vidutiniai laikai iki pirmo gedimo skiriasi.

2.2 pavyzdys. Vienos firmos savininkai trijuose vienodai našiai dirbančiuose cechuose atliko eksperimentą. Pirmame ceche visą mėnesį buvo dirbama skambant klasikinei muzikai, trečiajame visą mėnesį skambėjo

populiarioji muzika, o antrajame ceche muzikinio fono nebuvo (kontrolinė grupė). Kiek produkcijos vienetų pagamino kiekvienas darbuotojas, pateikta 2.5 lentelėje.

2.5 lentelė. Muzika ir darbo našumas

Klasikinė	Tyla	Populiarioji
760	691	723
722	653	747
695	681	771
742	676	765
705	645	755
763	692	732
752	654	751
721	681	772
740	679	766
760	647	755



Pirmo cecho darbuotojų vidutinis našumas $\bar{x}_1 = 736$ produkcijos vienetai; antrojo $\bar{x}_2 = 669,9$; trečiojo $\bar{x}_3 = 754,7$. Ar šie vidurkiai statistiškai reikšmingai skiriasi, ar tuos skirtumus galima paaiškinti atsitiktinumu? Tikruosius vidutinius darbo našumus, esant skirtingiems muzikiniams fonams, pažymėję μ_1 , μ_2 ir μ_3 , galime suformuluoti statistinę hipotezę:

$$\begin{cases} H_0: \mu_1 = \mu_2 = \mu_3, \\ H_1: \text{bent du vidurkiai skiriasi.} \end{cases}$$

Rezultatai, gauti pritaikius (14) ir skyriaus (15) formules, surašyti 2.6 lentelėje.

2.6 lentelė. Muzikinio fono ANOVA rezultatai

	Kvadratų suma	Laisvės laipsniai	Dispersijos įverčiai	Statistika
Grupių	39016,47	2	19508,23	49,61
Vidinė	10617	27	393,22	
Visa	49633,47	17		

Kadangi $F = 49 > 5,49 = F_{0,01}(2,27)$, tai, esant reikšmingumo lygmeniui $\alpha = 0,01$, nulinę hipotezę atmetame. Vidutiniai darbo našumai statistiškai reikšmingai skiriasi. (Juo labiau hipotezę atmestume, pasirinkę $\alpha = 0,05$.) Darome išvadą, kad muzikinis fonas turėjo įtakos darbo našumui.

ANOVA realizuota daugelyje statistinių paketų. Tradiciškai juose pateikiama ne tik rezultatų lentelė, bet ir p -reikšmė.

Kaip priimti sprendimą pagal p -reikšmę, kai ANOVA statistinė hipotezė yra

$H_0: \mu_1 = \mu_2 = \dots = \mu_k$ su alternatyva $H_1: \text{bent du vidurkiai skiriasi?}$

Tegul reikšmingumo lygmuo lygus α . Tuomet:

H_0 atmetama (ne visi vidurkiai lygūs), jeigu $p < \alpha$,

H_0 neatmetama (vidurkių skirtumo nerasta), jeigu $p \geq \alpha$.

2.3 pavyzdys. Valdininkas apklausė 28 vienos privačios ligoninės ligonius, norėdamas sužinoti jų nuomonę apie slaugos kokybę. Didesnis balas žymi palankesnę nuomonę. Atsižvelgiant į ligonių būklę, visi jie suskirstyti į keturias grupes (pirma grupė – sunkiausiai sergantys, ketvirtoji – lengviausiai). Ar galima teigti, kad požiūris į slaugos kokybę ir ligonio būklė yra susiję dalykai? (Reikšmingumo lygmuo $\alpha = 0,01$.) Duomenys pateikti 2.7 lentelėje.

SPSS paketu gauta ANOVA rezultatų lentelė parodyta 2.6 paveiksle. Ši lentelė turi dar vieną grafą, kurioje pateikiama F statistikos p -reikšmė. Ji mažesnė už 0,01, todėl hipotezę apie vidurkių lygybę atmetame. Skirtingos būklės ligonių vidutiniai slaugos vertinimai skiriasi. Kitais žodžiais tariant, slaugos kokybės vertinimai ir ligonių būklė yra tarpusavyje susiję.

2.7 lentelė. Slauga ir ligo bio būklė

Grupė	1	2	3	4
Nuomonė	78	75	71	63
	81	77	69	61
	79	73	62	67
	80	69	69	65
	74	78	68	67
	81	74	71	64
	80	75	70	63

ANOVA						
		Sum of Squares	df	Mean Square	F	Sig.
Nuomonė	Between Groups	878,667	3	292,667	40,170	.000
	Within Groups	174,857	24	7,286		
	Total	1052,857	27			

2.6 pav. 2.3 pavyzdžio SPSS rezultatai

2.6. Post hoc kriterijai



2.6.1. Daugkartiniai lyginimai

ANOVA atsako į klausimą, ar yra statistiškai reikšmingai besiskiriančių imčių vidurkių, bet nenurodo, kurių imčių vidurkiai statistiškai reikšmingai skiriasi. Kažin ar darbdavius tenkins tik statistinė išvada, kad muzikinis fonas daro įtaką darbo našumui (žr. 2.2 pavyzdį). O kokia ta įtaka? Geriau klasikinė muzika, ar geriau tylą? Taigi reikia kriterijų, leidžiančių nustatyti, kurių imčių vidurkiai statistiškai reikšmingai skiriasi. Tokie kriterijai vadinami *daugkartinųjų lyginimų* kriterijais.

Į ką reikia ypač atkreipti dėmesį, taikant daugkartinųjų lyginimų kriterijus? Į tai, kad statistiškai nereikšmingas imčių vidurkių skirtumas netapatus įrodymui, kad atitinkamų populiacijų vidurkiai lygūs. Matematikoje, jeigu $a = b$, $b = c$, tai negali būti $a \neq c$. Čia lyginoje pačius skaičius a , b , c ir išvadas darėme būtent apie juos. Tuo tarpu lygindami imčių vidurkius $\bar{x}_1$, $\bar{x}_2$ ir $\bar{x}_3$, išvadas darome apie nežinomus populiacijų vidurkius μ_1 , μ_2 ir μ_3 . Todėl visiškai įmanoma tokia situacija: $\bar{x}_1$ statistiškai reikšmingai skiriasi nuo $\bar{x}_3$, bet $\bar{x}_2$ statistiškai reikšmingai nesiskiria nei nuo $\bar{x}_1$, nei nuo $\bar{x}_3$. Vadinasi, jau galime teigti radę labai tikėtiną μ_1 ir μ_3 skirtumą, tačiau apie μ_2 dar negalime padaryti jokių tikėtinų išvadų – reali gali būti bet kuri iš 2.7 paveiksle pavaizduotų situacijų.

Daugkartiniai lyginimai skirstomi į iš anksto planuotus (*apriorinius*) kriterijus ir *post hoc* (*aposteriorinius*) kriterijus (žr. 2.8 pav.). Svarbiausias šių dviejų kriterijų grupių skirtumas – laikas, kada sprendžiama, kurias imtis tarpusavyje lyginti. Jeigu sprendžiame *prieš* vienfaktorinę dispersinę analizę, turime apriorinius, iš anksto planuotus lyginimus; jeigu *po to*, kai jau žinomi ANOVA rezultatai, turime aposteriorinius, *post hoc* lyginimus.


Ką lemia lyginamų imčių parinkimo laikas? Atsitiktinumo laipsnį. Žinome, kad visos statistinės išvados daromos tik su tam tikra tikimybe. Visuomet pasiliekiama teisė suklysti



(pasirenkamas reikšmingumo lygmuo fiksuoja pirmosios rūšies klaidos tikimybę). Susipažinę su ANOVA rezultatais, gauname papildomos informacijos. Atsitiktinumo laipsnis sumažėja, ir pirmosios rūšies klaidos tikimybė padidėja. Todėl tenka koreguoti taikomų kriterijų reikšmingumo lygmenis.

Tie patys kriterijai (tik su skirtingais reikšmingumo lygmenimis) gali būti taikomi ir kaip aprioriniai, ir kaip *post hoc* lyginimai. Tačiau labai sumažinus reikšmingumo lygmenį, krenta kriterijaus galia (tampa labai tikėtina priimti klaidingą nulinę hipotezę). Todėl tradiciškai konkretūs kriterijai siejami su kuria nors viena iš dviejų grupių. Šiame skyrelyje aptarsime *post hoc* kriterijus tuo atveju, kai poromis lyginami *visų* imčių vidurkiai.

Yra daug skirtingų *post hoc* kriterijų (vien SPSS jų pateikta per dešimt). Kiekvienas turi pranašumų ir trūkumų. Tai bloga naujiena statistikui, nes kiekvieną kartą jis atsiduria savotiškoje Buridano asilo¹ padėtyje, tik „šieno kaugių“ daugiau nei dvi. Žinoma, galima taikyti visus *post hoc* kriterijus. Tačiau tada kiltų problema, ką daryti, kai kriterijų išvados skiriasi. Iš šios padėties nėra geros išeities. Paprastai tyrimuose apsiribojama keliais pagrindiniais *post hoc* kriterijais, kuriuos šiame skyrelyje ir pateiksime. Pažymėtina, kad



Post hoc: pagal tai, ką stebime, bandome atpažinti tikrai besiskiriančius.

¹ Žymus XIV a. prancūzų asilas. Ne statistikas. Būtų problemą sprendęs šieno *intimis*, nebūtų nugaišęs badu.

dauguma jų skirti atvejui, kai visų k imčių didumai lygūs ($n_1 = n_2 = \dots = n_k = n$). Kai imčių didumai skiriasi, vietoje n naudojamas harmoninis vidurkis $\bar{n}$:


$$\bar{n} = \frac{k}{1/n_1 + 1/n_2 + \dots + 1/n_k}.$$

Itin nemaloni, bet realiai pasitaikanti situacija būna, kai ANOVA rodo, kad yra statistiškai reikšmingų vidurkių skirtumų, o *post hoc* kriterijai jų neranda. Taip atsitinka todėl, kad ANOVA ir *post hoc* kriterijai remiasi skirtingomis statistikomis.

2.6.2. Fišerio LSD kriterijus

Fišerio *mažiausiai reikšmingo skirtumo* LSD¹ kriterijus siūlo visas imčių poras lyginti naudojant t kriterijų (žr. [1], III dalį, 4.1 skyrelį). Taip daryti reikia tik *po to*, kai ANOVA parodo, kad vidurkiai statistiškai reikšmingai skiriasi.

LSD kriterijus – labiausiai liberalus *post hoc* kriterijus, t. y. jis dažniausiai randa statistiškai reikšmingus vidurkių skirtumus.



R. A. Fišerio dėka LSD statistikai gavo keliasdešimt metų anksčiau, nei T. Lyras savuoju LSD „pradžiugino“ likusį pasaulį. Beje, mūsų LSD truputį mažiau pavojingas.

2.6.3. Bonferonio kriterijus

Kaip įrodė Bonferonis², jeigu $0 \leq \alpha < 1$, $C > 0$, tai $1 - (1 - \alpha)^C \leq C\alpha$. Todėl eksperimento reikšmingumo lygmuo α_E (t. y. tikimybė lyginant *visas* įmanomas poras nors kartą *neteisingai* nustatyti statistiškai reikšmingą dviejų imčių vidurkių skirtumą) neviršija $k(k - 1)\alpha/2$; čia k yra imčių skaičius, o α – reikšmingumo lygmuo lyginant *vieną* porą imčių (žr. 2.1 skyrelį). Bonferonio kriterijus skamba taip: pasirenkamas eksperimento reikšmingumo lygmuo α_E ir visos imčių poros lyginamos taikant Stjudento kriterijų, esant reikšmingumo lygmeniui $\alpha = \alpha_E/C$; čia $C = k(k - 1)/2$. Pavyzdžiui, jeigu imčių yra trys, o pasirenkame $\alpha_E = 0,05$, tai lygindami bet kokių dviejų imčių vidurkius, taikysime t kriterijų su $\alpha = 0,05 \cdot 2/6 = 0,0166$.

¹ LSD – ang. *Least Significant Difference*.

² Carlo Emilio Bonferroni (1892–1960) – italų ekonomistas.

Bonferonio kriterijų galima taikyti ir naudojantis ANOVA lentele. Paprastai tai daroma taip: lyginant i -ąją imtį su j -ąja, apskaičiuojamas dydis

$$BSD_{ij} = t_{\alpha/2}(N - k) \sqrt{MSW \left(\frac{1}{n_i} + \frac{1}{n_j} \right)};$$

čia $N = n_1 + n_2 + \dots + n_k$, k – bendrasis imčių skaičius, $\alpha = 2\alpha_E/(k(k-1))$, α_E – pasirinktas eksperimento reikšmingumo lygmuo, $t_{\alpha/2}(N - k)$ – Stjudento skirstinio su $(N - k)$ laisvės laipsnių $\alpha/2$ lygmens kritinė reikšmė, MSW yra imties dispersijos įvertis (žr. 2.4 skyrelį), pateikiamas ANOVA rezultatų lentelėje.

Vidurkiai $\bar{x}_i$ ir $\bar{x}_j$ statistiškai reikšmingai *skiriasi*, jeigu $|\bar{x}_i - \bar{x}_j| > BSD_{ij}$.

Jeigu visų imčių didumai vienodi, tai $BSD_{ij} = BSD$, t. y. visiems lyginimams naudojame tą patį dydį.

2.4 pavyzdys. Prisiminkime 2.2 pavyzdį apie muzikinio fono įtaką darbo našumui. Turime $\bar{x}_1 = 736$ (klasikinė muzika), $\bar{x}_2 = 669,9$ (tyla) ir $\bar{x}_3 = 754,7$ (pop muzika). Be to, $N = 30$, $MSW = 393,22$, $k = 3$. Tarkime, kad eksperimento reikšmingumo lygmuo $\alpha_E = 0,05$. Tuomet $\alpha = 0,05 \cdot 2/3 \cdot 2 = 0,0166$, $BSD = t_{0,0166}(27) \sqrt{2 \cdot 393,22/10} = 19,5$. Tada $|\bar{x}_1 - \bar{x}_2| = 66,1 > BSD$, $|\bar{x}_2 - \bar{x}_3| = 83 > BSD$, $|\bar{x}_1 - \bar{x}_3| = 17,7 < BSD$. Taigi antrojo cecho vidutinis darbo našumas statistiškai reikšmingai skiriasi nuo abiejų likusiųjų cechų vidutinių darbo našumų, tačiau pirmojo ir trečiojo cechų darbo našumų skirtumas statistiškai nereikšmingas. Turime pagrindo manyti, kad muzikinis fonas padidina darbo našumą, tačiau dar negalime teigti, kad pop muzika darbo našumą didina labiau už klasikinę muziką.

Taikant Bonferonio kriterijų, susiduriame su sunkumais, kai reikia rasti tinkamą Stjudento skirstinio kritinę reikšmę (lentelėse paprastai pateikiamos tik 0,05 ir 0,01 lygmenų kritinės reikšmės). Šios problemos pavyksta išvengti, kai naudojamas statistinis paketas. Paprastai tuo atveju pateikiamos kriterijaus p -reikšmės.

MULTIPLE COMPARISONS						
Dependent Variable: PRODUKCIJA						
Bonferroni						
(I) FONAS	(J) FONAS	Mean Difference (I-J)	Std. Error	Sig.	95% Confidence Interval	
					Lower Bound	Upper Bound
1,00 Klasika	2,00 Tyla	66,1000*	8,868	,000	43,4644	88,7356
	3,00 Populiarioji	-17,7000	8,868	,168	-40,3356	4,9356
2,00 Tyla	1,00 Klasika	-66,1000*	8,868	,000	-88,7356	-43,4644
	3,00 Populiarioji	-83,8000*	8,868	,000	-106,4356	-61,1644
3,00 Populiarioji	1,00 Klasika	17,7000	8,868	,168	-4,9356	40,3356
	2,00 Tyla	83,8000*	8,868	,000	61,1644	106,4356

* The mean difference is significant at the .05 level.

2.9 pav. Bonferonio testo SPSS rezultatai

Jeigu p -reikšmė yra mažesnė už α , tai vidurkiai statistiškai reikšmingai *skiriasi*.
Priešingu atveju – statistiškai reikšmingo skirtumo nėra.

SPSS paketo lentelėse statistiškai reikšmingi vidurkių skirtumai pažymimi žvaigždutėmis. Nagrinėto 2.4 pavyzdžio Bonferonio *post hoc* kriterijaus SPSS rezultatai pateikti 2.9 paveiksle. Atkreipiame dėmesį, kad p -reikšmės yra stulpelyje *Sig.*, žvaigždutėmis pažymėti pačių vidurkių skirtumai. Lentelės apačioje nurodytas eksperimento reikšmingumo lygmuo yra 0,05.

Kai imčių daug, Bonferonio kriterijus tampa nebeefektyvus, nes labai sumažėja α . Beveik niekuomet nefiksuojamas statistiškai reikšmingas vidurkių skirtumas, nors tikrieji populiacijų vidurkiai ir skiriasi (t. y. labai išauga antrosios rūšies klaidos tikimybė). Todėl Bonferonio kriterijus netaikytinas, kai imčių yra daug.

2.6.4. Tjūkio HSD kriterijus

Dž. Tjukis¹ pasiūlė *ganėtinai statistiškai reikšmingo skirtumo* (HSD²) kriterijų. Šis kriterijus grindžiamas vadinamąja studentizuoto atstumo Q statistika, kurios kvantiliams sudaromos specialios lentelės (žr. priedo 11 lentelę). Tarkime, kad visų imčių didumai vienodi: $n_1 = n_2 = \dots = n_k = n$. Norėdami palyginti i -osios ir j -osios imčių vidurkius, apskaičiuojame

$$Q(i, j) = \frac{\bar{x}_i - \bar{x}_j}{\sqrt{MSW/n}}. \quad (18)$$

Vidurkiai $\bar{x}_i$ ir $\bar{x}_j$ statistiškai reikšmingai *skiriasi*, jeigu $|Q(i, j)| > Q_\alpha(nk - k, k)$; čia α yra pasirinktasis reikšmingumo lygmuo (jis sutampa su eksperimento reikšmingumo lygmeniu), o $Q_\alpha(nk - k, k) - Q$ statistikos α lygmens kritinė reikšmė, rasta iš priedo 11 lentelės.

Neretai Tjūkio kriterijus užrašomas analogiškai Bonferonio kriterijui.

Vidurkiai $\bar{x}_i$ ir $\bar{x}_j$ statistiškai reikšmingai *skiriasi*, jeigu $|\bar{x}_i - \bar{x}_j| > TSD$; čia

$$TSD = \sqrt{\frac{MSW}{n}} Q_\alpha(nk - k, k).$$

2.5 pavyzdys. Trims tobulinimosi kursų klausytojų grupėms *tas pats* pranešėjas skaitė paskaitą apie rūkymo naudą³. Pirmai grupei pranešėjas buvo pristatytas kaip doktorantas Liudas Poškus, antrajai – kaip docentas Liudvikas Poškevičius, trečiajai – kaip Harvardo profesorius Ludas Poskus ir kalbėjo su akcentu. Kiekvienas klausytojas balais (iki 100) vertino pranešimą. Duomenys pateikti 2.8 lentelėje. Ar pranešėjo pristatymas turėjo įtakos vertinimams?

2.8 lentelė. Pranešimo vertinimai

1 grupė	60	65	63	70	76	68	59	64	62	69	75	67
2 grupė	72	76	74	75	70	83	71	75	73	74	69	82
3 grupė	86	76	83	77	72	86	85	75	82	76	71	85

¹ John Wilder Tukey (1915–2000) – JAV statistikas.

² HSD – ang. *Honestly Significant Difference*.

³ Ne rūkančiam, žinoma.

2.9 lentelė. Klausytojų vertinimų ANOVA rezultatai

	Kvadratų suma	Laisvės laipsniai	Dispersijos įverčiai	Statistika
Grupių	1032	2	516	19,59
Vidinė	869	33	26,33	
Visa	1901	35		

Tarkime, $\alpha = 0,05$. Iš 2.9 lentelės nustatome, kad yra statistiškai reikšmingai besiskiriančių vidurkių. Iš tikrųjų $F = 19,59 > 3,2 = F_{0,05}(2,33)$. Be to, $n = 12$, $k = 3$, $MSW = 26,33$.

Apskaičiuojame $\bar{x}_1 = 79,5$; $\bar{x}_2 = 74,5$; $\bar{x}_3 = 66,5$; $Q(2, 3) = 5,40$; $Q(1, 3) = 8,77$; $Q(1, 2) = 3,37$. Iš priedo 11 lentelės randame $Q_{0,05}(33, 3)$. Dabar jau nesunku pastebėti, kad trečiosios grupės vertinimai statistiškai reikšmingai skiriasi nuo kitų dviejų grupių. Tuo tarpu statistiškai reikšmingo pirmosios ir antrosios grupių skirtumo nerasta. „Užsienietiškas“ palankiau nuteikė klausytojus. Rezultatai pateikiami 2.10 lentelėje. Dėl aiškumo statistiškai reikšmingus skirtumus pažymėjome žvaigždute.

2.10 lentelė. Vertinimų Tjūkio HSD rezultatai

Grupė	3	2	1
$\bar{x}_i$	66,5	74,5	79,5
$\bar{x}_j - \bar{x}_3$		8	13
$\bar{x}_j - \bar{x}_2$			5
$Q(j, 3)$		5,40*	8,77*
$Q(j, 2)$			3,37
$Q_{0,05}(33, 3) = 3,49$			

SPSS programų pakete Tjūkio HSD kriterijaus rezultatai pateikiami analogiškai Bonferonio kriterijui. Be to, Tjūkio kriterijumi sudaromos imčių homogeniškumo grupės, t. y. tiesiog kita forma užrašoma, kurių grupių vidurkiai skiriasi (žr. 2.10 pav.). Beje, jeigu imčių didumai skiriasi (naudojame harmoninį imčių vidurkių didumą), homogeniškumo grupių ir HSD kriterijaus rezultatai gali skirtis. Taip atsitinka todėl, kad taikant Tjūkio kriterijų homogeniškumo grupėms sudaryti harmoninis vidurkis skaičiuojamas ne iš visų imčių didumų, o tik iš tų imčių, kurios lyginamos.

Tjūkio kriterijus – vienas dažniausiai taikomų *post hoc* kriterijų. Jis yra gera alternatyva Bonferonio kriterijui, kai imčių daug. Pažymėtina, kad HSD kriterijus yra labai konservatyvus, t. y. labiausiai nelinkęs atmesti nulinės hipotezės (vidurkių skirtumus pripažinti statistiškai reikšmingais).

2.6.5. Stjudento–Njumen–Keulso kriterijus

Stjudento–Njumen–Keulso (SNK) kriterijus skiriasi nuo Tjūkio HSD kriterijaus tik tuo, kad reikia atsižvelgti į skaičių imčių, kurių vidurkiai yra tarp $\bar{x}_i$ ir $\bar{x}_j$. Visos grupės išrikiuojamos pagal vidurkių didumą. Toliau viskas skaičiuojama kaip ir HSD kriterijui. Tačiau $Q(i, j)$ lyginamas ne su viena visiems bendra q statistikos kritine reikšme, o su $Q_\alpha(nk - k, m)$ kritine reikšme; čia m yra skaičius, vienetu didesnis už skaičių imčių, kurių vidurkiai yra tarp $\bar{x}_i$ ir $\bar{x}_j$ (mažesni už vieną iš jų ir didesni už kitą). Vidurkiai statistiškai reikšmingai skiriasi, jeigu $Q(i, j) > Q_\alpha(nk - k, m)$.

Dėl paprastumo tarkime, kad $\bar{x}_1 < \bar{x}_2 < \dots < \bar{x}_k$. Tuomet vidurkiai $\bar{x}_i$ ir $\bar{x}_j$ statistiškai reikšmingai skiriasi, jeigu $Q(i, j) > Q_\alpha(nk - k, |j - i| + 1)$.

2.6 pavyzdys. Šiuo atveju $Q(2, 3) = 5,40$ lyginamas su $Q_{0,05}(33, 2) = 2,8$; $Q(1, 3) = 8,77$ lyginamas su $Q_{0,05}(33, 3) = 3,49$; $Q(1, 2) = 3,37$ – su $Q_{0,05}(33, 2) = 2,8$.

2.11 lentelė. Vertinimų SNK kriterijaus rezultatai

Grupė	3	2	1
$\bar{x}_i$	66,5	74,5	79,5
$\bar{x}_j - \bar{x}_3$		8	13
$\bar{x}_j - \bar{x}_2$			5
$Q(j, 3)$		5,40*	8,77*
$Q(j, 2)$			3,37*
$Q_{0,05}(33, m)$		2,8	3,49
			2,8

Įsitikiname, kad visų grupių vidurkiai statistiškai reikšmingai skiriasi.

SPSS pateikia SNK kriterijų kaip homogeniškų imčių grupių išskyrimo priemonę. Nagrinėto 2.5 pavyzdžio duomenų SPSS rezultatai pateikti 2.10 paveiksle. Kai imtys nelygios, taikant SNK kriterijų vietoje n reikia imti harmoninį imčių didumų vidurkį.

SNK yra konservatyvesnis už Bonferonio kriterijų, bet ne toks konservatyvus kaip Tjukio kriterijus. Antra vertus, taikant SNK, kaip ir LSD, statistiškai reikšmingi imčių vidurkių skirtumai dažnai randami net tada, kai tikrieji populiacijų vidurkiai nesiskiria. Todėl dauguma statistikų į SNK kriterijų žiūri gana skeptiškai. Kai kas siūlo jį naudoti tik tuo atveju, kai yra trys imtys.

Daugelis kitų *post hoc* kriterijų grindžiami mūsų aptartaisiais. Pavyzdžiui, *Duno* kriterijus yra atskiras Bonferonio kriterijaus variantas su tikslesniu pirmosios rūšies klaidos įverčiu; *Duneto* kriterijus atitinka Bonferonio kriterijų, kai visos imtys lyginamos su viena kontroline imtimi; *Rajeno* kriterijus – tam tikra SNK modifikacija, sumažinanti pirmosios rūšies ir padidinanti antrosios rūšies klaidos tikimybes; *Tjukio WSD* kriterijus lyginimams siūlo imti Tjukio ir SNK kritinių reikšmių vidurkius.

VERTINIMAS					
	GRUPĖ	N	Subset for alpha = .05		
			1	2	3
Student-Newman-Keuls ^a	1,00	12	66,5000		
	2,00	12		74,5000	
	3,00	12			79,5000
	Sig.		1,000	1,000	1,000
Tukey HSD ^a	1,00	12	66,5000		
	2,00	12		74,5000	
	3,00	12		79,5000	
	Sig.		1,000	,058	

^a. Means for groups in homogeneous are displayed.
Uses Harmonic Mean Sample Size = 12,000.

2.10 pav. Tjukio ir SNK SPSS rezultatai

2.7. Aprioriniai kriterijai

Kaip minėjome praeito skyrelio pradžioje, daugumą kriterijų galima naudoti ir kaip *post hoc* ir kaip apriorinius daugkartinius lyginimus. Užtenka parinkti kitokius reikšmingumo lygmenis. Tarkime, kad turime k imčių, o pasirinktasis eksperimento reikšmingumo lygmuo $\alpha_E = 0,05$. Stjudento kriterijumi poromis lygindami visas įmanomas imtis, tokių lyginimų gautume $7 \cdot 6/2 = 21$. Bonferonio pataisa reikalauja kiekvieną kartą t kriterijų taikyti esant $\alpha = \alpha_E/21 = 0,00238$. Toks mažas reikšmingumo lygmuo labai padidina antrosios rūšies klaidos tikimybę. Tai tipiškas Bonferonio *post hoc* kriterijaus taikymo pavyzdys. Dabar tarkime, kad *prieš* vykdydami ANOVA nutarėme palyginti tik pirmą imtį su trečiąja bei antrąją su penktąja. Lyginimų skaičius $C = 2$. Todėl šiuo atveju galima dukart taikyti t kriterijų, kai $\alpha = \alpha_E/2 = 0,025$. Tai tipiškas Bonferonio apriorinio kriterijaus pavyzdys. Pažymėtina, kad apriorinius kriterijus galima taikyti ir *vietoje* dispersinės analizės.

Tradiciškai aprioriniams priskiriami kriterijai, taikomi hipotezėms apie tiesines populiacijų vidurkių daugdaras (kontrastus) tikrinti. Toliau visų imčių didumus laikysime vienodais.

Tiesiniu populiacijų vidurkių *kontrastu* vadinama suma

$$C_1\mu_1 + C_2\mu_2 + \dots + C_k\mu_k.$$

Koeficientai C_i tenkina lygybę $C_1 + C_2 + \dots + C_k = 0$.

Pavyzdžiui, $\mu_1 + \mu_2 - 2\mu_3$ yra kontrastas, o $\mu_1 + \mu_2 - \mu_3$ ne. Kontrasto koeficientus (t. y. konkrečius skaičius $C_1, \dots, C_k$) pasirenkame patys. Akivaizdu, kad imdami tik du nenulinius koeficientus 1 ir -1 , gauname hipotezę apie dviejų vidurkių lygybę. Tačiau kontrastai leidžia atskirti vieną nuo kitos ir kelias populiacijų grupes, pavyzdžiui, $(\mu_1 + \mu_2 + \mu_3)/3$ palyginti su $(\mu_4 + \mu_5)/2$.

Užrašysime, kaip tikrinti hipotezę apie kontrasto reikšmę.

1 *Duomenys.* Turime k imčių $(x_{11}, x_{12}, \dots, x_{1n}), (x_{21}, x_{22}, \dots, x_{2n}), \dots, (x_{k1}, x_{k2}, \dots, x_{kn})$, kurios gautos matuojant nepriklausomus normaliuosius atsitiktinius dydžius $X_1 \sim \mathcal{N}(\mu_1, \sigma^2), X_2 \sim \mathcal{N}(\mu_2, \sigma^2), \dots, X_k \sim \mathcal{N}(\mu_k, \sigma^2)$ pagal intervalų skalę.

2 *Statistinė hipotezė:*

$$\begin{cases} H_0: C_1\mu_1 + C_2\mu_2 + \dots + C_k\mu_k = 0, \\ H_1: C_1\mu_1 + C_2\mu_2 + \dots + C_k\mu_k \neq 0; \end{cases} \quad (19)$$

čia C_i yra iš anksto pasirinkti skaičiai, tenkinantys lygybę $C_1 + C_2 + \dots + C_k = 0$.

3 *Kriterijaus statistika.* Apskaičiuojame

$$F = \frac{(C_1\bar{x}_1 + C_2\bar{x}_2 + \dots + C_k\bar{x}_k)^2}{MSW(C_1^2/n + C_2^2/n + \dots + C_k^2/n)}; \quad (20)$$

čia MSW yra vidinis dispersijos įvertis (žr. 2.4 skyrelį). Jį galima rasti iš ANOVA rezultatų lentelės.

- 4** *Sprendimo priėmimo taisyklė.* Tegul reikšmingumo lygmuo lygus α . Hipotezė H_0 atmetama (taigi kontrastas statistiškai reikšmingai skiriasi nuo nulio), jeigu $F > F_\alpha(1, N - k)$; čia $N = nk$, $F_\alpha(1, N - k)$ yra Fišerio skirstinio su 1 ir $(N - k)$ laisvės laipsnių α lygmens kritinė reikšmė. Hipotezė H_0 neatmetama, jeigu $F \leq F_\alpha(1, N - k)$.

2.7 pavyzdys. Prisiminkime 2.2 pavyzdį apie muzikinį foną ir darbo našumą. Tarkime, mus domina *vienintelis* klausimas: ar vidutinis darbo našumas skambant klasikinei muzikai lygus likusiųjų cechų vidutinių darbo našumų vidurkiui. Reikšmingumo lygmuo $\alpha = 0,05$. Mus domina, ar $\mu_1 = (\mu_2 + \mu_3)/2$. Patogiau šią problemą užrašyti taip:

$$\begin{cases} H_0: 2\mu_1 - \mu_2 - \mu_3 = 0, \\ H_1: 2\mu_1 - \mu_2 - \mu_3 \neq 0. \end{cases}$$

Nesunku matyti, kad $2\mu_1 - \mu_2 - \mu_3$ yra kontrastas ($2 - 1 - 1 = 0$). Jau buvo apskaičiuota $MSW = 393,22$, $k = 3$, $n_1 = n_2 = n_3 = 10$, $\bar{x}_1 = 736$, $\bar{x}_2 = 669,9$, $\bar{x}_3 = 754,7$. Randame

$$F = \frac{(2 \cdot 736 - 669,9 - 754,7)^2}{393,22(0,4 + 0,1 + 0,1)} = 9,52.$$

Iš priedo 4 lentelės randame $F_{0,05}(1,27) = 4,21$. Kadangi $F = 9,52 > 4,21$, tai hipotezę H_0 atmetame. Duomenys mūsų spėjimo nepatvirtino.

Ką daryti, jeigu iš anksto suplanuojame tikrinti hipotezes apie kelis kontrastus? Tuo atveju fiksuojame pasirinktąjį eksperimento reikšmingumo lygmenį (tikimybę bent vieną nulinę hipotezę atmeti neteisingai), o kiekvienos hipotezės reikšmingumo lygmeniui α taikome Bonferonio pataisą (t. y. $\alpha = \alpha_E / C$; čia C yra tikrinamųjų hipotezių skaičius). Pavyzdžiui, pasirinkę $\alpha_E = 0,05$ ir tikrindami tris hipotezes apie kontrastus, kiekvienai hipotezei turėtume imti $\alpha = 0,05/3 = 0,0166$.

Ar negalima Bonferonio pataisos išvengti? Yra tiesinių kontrastų grupė, kuriai imama $\alpha = \alpha_E$. Tai – ortogonalieji kontrastai.

Du tiesiniai kontrastai $C_{11}\mu_1 + C_{12}\mu_2 + \dots + C_{1k}\mu_k$ ir $C_{21}\mu_1 + C_{22}\mu_2 + \dots + C_{2k}\mu_k$ vadinami *ortogonaliais*, jeigu $C_{11}C_{21} + C_{12}C_{22} + \dots + C_{1k}C_{2k} = 0$.

Pavyzdžiui, kontrastai $\mu_1 - \mu_3$ ir $\mu_1 - 2\mu_2 + \mu_3$ ortogonalūs ($1 \cdot 1 + 0 \cdot (-2) + (-1) \cdot 1 = 0$). Tuo tarpu kontrastai $\mu_1 - \mu_3$ ir $2\mu_1 - \mu_2 - \mu_3$ neortogonalūs ($1 \cdot 2 + 0 \cdot (-1) + (-1) \cdot (-1) = 3$).

Galima sudaryti įvairias ortogonalųjų kontrastų sistemas, tačiau kiekvienoje iš jų gali būti ne daugiau kaip $(k - 1)$ kontrastų.

Turint k imčių, su jų vidurkiais galima sudaryti ne daugiau kaip $(k - 1)$ skirtingų ortogonalųjų kontrastų.

Pateiksime dvi skirtingų ortogonalųjų kontrastų sistemas, leidžiančias patikrinti skirtingas hipotezes:

C_{i1}	C_{i2}	C_{i3}	C_{i1}	C_{i2}	C_{i3}
-1	0	1	2	-1	-1
1	-2	1	0	-1	1



Kentaurams iškilo rimta problema. Neaišku, kuri trąša labiausiai didina vidutinį žolės derlingumą (beje, nors kentaurai ir nenusistatė prieš rūkymą, jie žolę valgo). Išgirdę apie žmonijos laimėjimus statistikoje, kentaurai kreipėsi į artimiausią universitetą. Statistikos profesorius duomenis ištyrė remdamasis ANOVA. Aha! Paaiškėjo, kad yra statistiškai reikšmingai besiskiriančių vidurkių (reikšmingumo lygmuo $\alpha = 0,05$). Kentaurai labai apsidžiaugė. Profesorius tuojau pažadėjo Tjukio kriterijumi rasti visus ganėtinai skirtingus vidurkius. Deja. HSD nenustatė nė vieno statistiškai reikšmingo skirtumo (reikšmingumo lygmuo $\alpha = 0,05$).

Sugluminti kentaurai kreipėsi į Statistikos departamentą. Departamento darbuotojas juos nuramino, kad šiais laikais profesoriai pernelyg konservatyvūs. Pažadėjo liberaliuoju LSD kriterijumi rasti tiek skirtingų vidurkių, kiek tik reikia. Tačiau LSD kriterijus taip pat nenustatė reikšmingai besiskiriančių vidurkių (reikšmingumo lygmuo $\alpha = 0,05$).

Išgyvendami gilią depresiją, kentaurai griebėsi paskutinio šiaudo – doktorantų statistikos guru, garsėjančio gebėjimais įrodyti viską, ko tik paprašo. Už nedidelį mokestį guru, remdamasis SPSS, pabūrė ir sušuko: „Gavau statistiškai reikšmingą skirtumą (reikšmingumo lygmuo $\alpha = 0,05$)!“ Apimti ekstazės, kentaurai paklausė: „Kokį skirtumą?“

VIENA TREČIOJI PIRMOJO, ANTROJO IR KETVIRTOJO VIDURKIŲ SUMOS STATISTIŠKAI REIKŠMINGAI SKIRIASI NUO PUSĖS ANTROJO IR KETVIRTOJO VIDURKIŲ SUMOS!

Niekada, niekada, niekada daugiau kentaurai nesikreips pagalbos į statistikus.

Kuo ortogonalieji kontrastai pranašesni už kitus? Matematiškai įrodoma, kad $SSB = SSB_1 + SSB_2 + \dots + SSB_{k-1}$; čia SSB yra imčių skirtumus nurodanti ANOVA komponentė – grupių kvadratų suma (žr. 2.4 skyrelį), o SSB_i yra i -ojo kontrasto duomenų kvadratų suma, gaunama i -ojo kontrasto statistiką F iš (20) formulės padauginus iš MSW . Trumpai tariant, ortogonalieji kontrastai naudoja skirtingą informaciją apie imčių skirtumus.



Beje, kai kurie statistikai net ir ortogonaliesiems kontrastams siūlo taikyti Bonferonio pataisą. Savo nuomonę jie grindžia tuo, kad visų hipotezių statistikose figūruoja tas pats dydis MSW , todėl šios statistikos priklausomos.

Su Bonferonio pataisa aprašytąjį kriterijų galima naudoti ir kaip *post hoc* kriterijų. Tuo atveju jis vadinamas Šefė¹ kriterijumi.


Hipotezes apie kontrastus galima tikrinti ir tuo atveju, kai imčių didumai skiriasi. Tada pats kontrastas apibūdinamas kitaip: jo koeficientai turi tenkinti lygybę $n_1C_1 + n_2C_2 + \dots + n_kC_k = 0$. Tikrinant hipotezę, (20) formulėje vietoje n reikia imti n_i , o $N = n_1 + \dots + n_k$. Kontrastų ortogonalumas suprantamas taip: $n_1C_{11}C_{21} + n_2C_{12}C_{22} + \dots + n_kC_{1k}C_{2k} = 0$.

2.8. Vidurkių trendas

Tarkime, kad nepriklausomo faktoriaus reikšmės rodo skirtingą vaistų dozę, treniruotumo laipsnį, streso lygį, bandomojo gaminio apkrovos stiprumą, užduoties atlikimo trukmę ar pan. Kitais žodžiais tariant, nepriklausomasis kintamasis (faktorius), pagal kurį skiriame populiacijas, yra ne šiaip kategorinis, bet gautas iš intervalinio kintamojo. Tyrėją gali dominti populiacijose stebimo kintamojo vidurkių kitimo tendencija, t. y. *vidurkių trendas*. Trendus lengviausia suprasti nubraižius atitinkamą laužtę.

Tarkime, firmos vadovai domisi atlyginimo įtaka darbo našumui. Eksperimento metu keturių iki tol vienodai dirbusių firmų padalinių darbuotojams buvo pakeltos algos – atitinkamai 100, 200, 300 ir 400 litų. Firmos vadovus domina algų didinimo įtaka vidutiniam

¹ Henry Scheffe (1907–1977) – amerikiečių statistikas.



vieno dirbančiojo pagaminamos produkcijos kiekiui. Jie tikisi, kad didėjant priedui, vidutinis vieno darbuotojo pagaminamos produkcijos kiekis tiesiškai didės (žr. 2.11 pav., a)).

Bandant nustatyti vidurkių tendą, svarbu, kad padalinio numeris būtų proporcingas atlyginimo priedui: pirmas padalinys gavo mažiausius atlyginimo priedus, o ketvirtasis – didžiausius.

Mus domina produkcijos didėjimo tendencija kylant algoms. Įvertinti tendą galima tik gerai suplanavus eksperimentą. Pavyzdžiui, tyrėjas gali manyti, kad vidutinis našumas tiesiškai didės *dvigubinant* atlyginimo priedą, t. y. padaliniams atitinkamai pridėjus po 100, 200, 400 ir 800 Lt. Kaip sudarant imtis dozuoti išorinį poveikį, reikia nuspręsti prieš atliekant eksperimentą. Tai – tyrėjo problema (jis gali remtis ankstesne patirtimi, kolegų nuomone, sveiku protu, intuicija, pranašingu sapnu ir pan.).

Galima kalbėti ne tik apie tiesinius trendus. Tarkime, firmos vadovai spėja, kad didėjant atlyginimo priedui vidutinis darbo našumas nors ir kils, bet netiesiškai. Paskaičiavę kiekvieno darbuotojo vidutinį darbo našumą, randame, kad jis iš pradžių didėja, tačiau tik iki tam tikros ribos, o po to pradeda mažėti, t. y. vidutinis darbuotojo darbo našumas sudaro *kvadratinį* tendą (žr. 2.11 pav., b)).

Trendo pavadinimas nurodo, kokią kreivę jo grafikas primena: tiesinio – tiesę ($y = ax + b$), kvadratinio – parabolę ($y = ax^2 + bx + c$) ir pan. Dažniausiai tikrinamos hipotezės apie tiesinį arba kvadratinį tendą. Tik šiais dviem atvejais ir apsiribosime.

Ar imčių duomenys neprieštarauja hipotezei apie populiacijų vidurkių trendus, nustatoma patikrinus hipotezes apie specialiai sudarytus ortogonaliosius kontrastus (žr. 2.6 skyrelį). Kokius kontrastų koeficientus parinkti, priklauso nuo imčių skaičiaus. Keletas tiesiniam ir kvadratiniam trendams skirtų ortogonalųjų kontrastų koeficientų reikšmių, kai visų imčių didumai vienodi, pateikta 2.12 lentelėje.

Suformuluosime taisyklės hipotezei apie tiesinį vidurkių tendą tikrinti.

1 *Duomenys.* Turime k imčių $(x_{11}, x_{12}, \dots, x_{1n}), (x_{21}, x_{22}, \dots, x_{2n}), \dots, (x_{k1}, x_{k2}, \dots, x_{kn})$, kurios gautos matuojant nepriklausomus normaliuosius atsitiktinius dydžius $X_1 \sim \mathcal{N}(\mu_1, \sigma^2), X_2 \sim \mathcal{N}(\mu_2, \sigma^2), \dots, X_k \sim \mathcal{N}(\mu_k, \sigma^2)$ pagal intervalų skalę.

2.12 lentelė. Kontrastų koeficientai trendams

Imčių skaičius	$k = 3$			$k = 4$				$k = 5$					$k = 6$						
Trendas	C_1	C_2	C_3	C_1	C_2	C_3	C_4	C_1	C_2	C_3	C_4	C_5	C_1	C_2	C_3	C_4	C_5	C_6	
Tiesinis	-1	0	1	-3	-1	1	3	-2	-1	0	1	2	-5	-3	-1	1	3	5	
Kvadratinis		1	-2	1	1	-1	-1	1	2	-1	-2	-1	2	5	-1	-4	-4	-1	5

2 Statistinė hipotezė:

$$\begin{cases} H_0: & \text{vidurkiai } \mu_1, \mu_2, \dots, \mu_k \text{ nesudaro tiesinio trendo,} \\ H_1: & \text{vidurkiai } \mu_1, \mu_2, \dots, \mu_k \text{ sudaro tiesinį trendą.} \end{cases} \quad (21)$$

3 Kriterijaus statistika. Apskaičiuojame

$$F = \frac{(C_1\bar{x}_1 + C_2\bar{x}_2 + \dots + C_k\bar{x}_k)^2}{MSW(C_1^2/n + C_2^2/n + \dots + C_k^2/n)}; \quad (22)$$

čia MSW yra vidinis dispersijos įvertis (žr. 2.4 skyrelį), skaičiai C_i yra tiesinį trendą atitinkančio kontrasto reikšmės (kai imčių yra ne daugiau kaip šešios, reikšmės galima imti iš 2.12 lentelės).

4 Sprendimo priėmimo taisyklė. Tegul reikšmingumo lygmuo lygus α . Hipotezė H_0 atmetama (taigi vidurkiai sudaro tiesinį trendą), jeigu $F > F_\alpha(1, N - k)$; čia $N = nk$, $F_\alpha(1, N - k)$ yra Fišerio skirstinio su 1 ir $(N - k)$ laisvės laipsnių α lygmens kritinė reikšmė. Hipotezė H_0 neatmetama (vidurkiai nesudaro tiesinio trendo), jeigu $F \leq F_\alpha(1, N - k)$.

2.8 pavyzdys. Matuojamas laikas, reikalingas specialiai vairavimo užduočiai atlikti. Tirtos keturios pradedančiųjų vairuotojų grupės. Pirmos grupės vairuotojai prieš užduotį nervus ramino vienu bokalu alaus, antrosios – dviem, trečiosios – trimis, ketvirtosios – keturiais bokalais. Duomenys pateikti 2.13 lentelėje. Reikia patikrinti hipotezę, ar vidutinis užduoties atlikimo laikas *tiesiškai* didėja didėjant išgertų bokalų skaičiui (reikšmingumo lygmuo $\alpha = 0,01$). ANOVA rezultatai pateikti 2.14 lentelėje.

2.13 lentelė. Alus ir vairavimas

Grupė	1	2	3	4
Laikas	7,4	9,2	11,0	12,0
	8,8	10,0	12,1	10,9
	6,3	8,4	11,3	13,8
	8,4	10,1	10,7	13,1
	9,4	11,1	11,4	11,8
	8,3	10,2	10,2	12,3
	8,0	10,8	9,8	12,5
	9,1	9,9	10,9	12,4

2.14 lentelė. Vairavimo laiko ANOVA rezultatai

	Kvadratų suma	Laisvės laipsniai	Dispersijos įverčiai	Statistika
Grupių	72,39	3	24,13	32,38
Vidinė	20,83	28	0,74	
Visa	93,25	31		


Patikrinkime hipotezę apie tiesinį vidurkių trendą:

$$\begin{cases} H_0: & \text{vidurkiai nesudaro tiesinio trendo,} \\ H_1: & \text{vidurkiai sudaro tiesinį trendą.} \end{cases}$$

Apskaičiuojame: $\bar{x}_1 = 8,21$, $\bar{x}_2 = 9,96$, $\bar{x}_3 = 10,92$, $\bar{x}_4 = 12,35$, $MSW = 0,745$. Iš 2.12 lentelės pasirenkame koeficientus: $C_1 = -3$, $C_2 = -1$, $C_3 = 1$, $C_4 = 3$. Statistikos reikšmė

$$F = \frac{(-3 \cdot 8,21 - 9,96 + 10,92 + 3 \cdot 12,35)^2}{0,74(9 + 1 + 1 + 9)/8} = 96,7.$$

Kadangi $F = 96,7 > 7,63 = F_{0,01}(1,28)$, tai H_0 atmetame. Gavome statistiškai reikšmingą patvirtinimą, kad bokalų skaičiui didėjant laiko užduočiai atlikti vidurkiai didėja tiesiškai. Primename, kad tikrinome hipotezę apie *populiacijų* vidurkių elgesį (t. y. kaip elgtųsi visi pradedantys vairuotojai, išgėrę kelis bokalus



alaus). Kadangi populiacijų vidurkių nežinome, jiems trendo nubraižyti negalime. Tačiau žinome imčių vidurkius, kurie yra nežinomų populiacijų vidurkių apytikslės reikšmės. Jiems galime nubraižyti laužtę, kuri neblogai iliustruoja spėjamą populiacijų vidurkių tendą (žr. 2.12 pav.)

Kaip ir kitais ortogonalųjų kontrastų atvejais, iškart galima tikrinti kelias hipotezes: ir apie tiesinį vidurkių tendą, ir apie kvadratinį, ir t. t. Tik reikalaujama, kad imčių būtų bent viena daugiau nei tendą atitinkančio daugianario didžiausias laipsnis. Pavyzdžiui: turint tris imtis galima tikrinti hipotezę apie tiesinį populiacijų vidurkių tendą; keturias – apie tiesinį ir kvadratinį tendus; penkias – apie tiesinį, kvadratinį ir kubinį tendus. Ką daryti, jeigu vidurkiams tinka keli trendai? Sprendžia pats tyrėjas. Dažniausiai pasirenkamas mažesnės eilės trendas. Pavyzdžiui, iš kvadratinio ir tiesinio tendų imamas tiesinis.

Trendų analizę galima atlikti ir SPSS paketu. Tuo atveju gaunama išplėstinė ANOVA lentelė. Informacija apie tendus išdėstyta iškart po eilutės, skirtos grupių skirtumams.

Trendas *tinka*, jei atitinkamo kontrasto p -reikšmė (ją galima rasti stulpelyje Sig.) *mažesnė* už pasirinktąjį reikšmingumo lygmenį. Priešingu atveju neturime statistiškai reikšmingo patvirtinimo, kad trendas *tinka*.


2.9 pavyzdys. Keturių grupių studentus matematikos dėstytojas pradžiugino netikėta naujiena apie pusvalandžio kontrolinį. Pirmos grupės studentai kontrolinį rašė iškart, antrosios – po pusvalandžio, trečiosios – po valandos, o ketvirtosios – po pusantros valandos. Buvo suskaičiuota, kiek uždavinių kiekvienas studentas išsprendė. Dėstytojas mano, kad truputis įtampos turėtų mobilizuoti studentus, o daug – slopinti. Tarkime, $\alpha = 0,05$. Duomenys apie studentų rezultatus pateikti 2.15 lentelėje. Išplėstinė ANOVA lentelė yra 2.13 paveiksle. Matome, kad tiesinis trendas netinka, nes atitinkama p -reikšmė (eilutės Linear Term Contrast stulpelyje Sig.) yra ne mažesnė kaip 0,05. Tuo tarpu kvadratinis trendas tinka, nes p -reikšmė (eilutės Quadratic Term Contrast stulpelyje Sig.) mažesnė kaip 0,05. Imčių vidurkius sujungę atkarpomis, gauname gana gerą spėjamo kvadratinio populiacijų vidurkių trendo vaizdą (žr. 2.14 pav.). Jis liudija, kad dėstytojas buvo teisus.

2.15 lentelė. Studentų kontrolinio rezultatai

Grupė	Laikas												
1	16	15	13	12	15	16	17	18	15	16	16	15	17
2	23	22	20	24	25	23	22	24	25	22	23	20	19
3	25	27	26	26	28	24	25	26	23	24	22	21	24
4	15	14	13	12	18	15	16	12	14	19	20	12	15

ANOVA					Sum of Squares	df	Mean Square	F	Sig.
REZULTATAS	Between Groups	(Combined)			939,288	3	313,096	73,228	,000
		Linear Term	Contrast		,465	1	,465	,109	,743
			Deviation		938,823	2	469,412	109,787	,000
		Quadratic Term	Contrast		905,558	1	905,558	211,795	,000
			Deviation		33,265	1	33,265	7,780	,008
	Within Groups				205,231	48	4,276		
	Total				1144,519	51			

2.13 pav. Kontrolinio rezultatų ANOVA lentelė



2.14 pav. Imčių vidurkių trendas

Jeigu imčių didumai skiriasi, SPSS yra realizuoti du hipotezės apie trendus tikrinimo variantai. Vienas jų kiekvieno respondento indėlį laiko vienodai svarbiu (išplėstinėje ANOVA lentelėje atsiranda eilutė *Weighted*), kitas vienodai svarbiu laiko kiekvienos imties indėlį (eilutė *Unweighted*). Kurį variantą pasirinkti, lemia tyrėjo nuomonė. Jei jis mano, kad visų grupių (imčių) indėlis turi būti vertinamas kaip vienodai svarbus (nepriklausomai nuo to, kiek buvo imties duomenų), jam derėtų taikyti antrąjį metodą (*Unweighted*). Jei jis mano, kad visų duomenų indėliai vienodai svarbūs analizei (tada didesnės imtys turės ir didesnės įtakos išvadoms), jam derėtų naudoti pirmąjį metodą (*Weighted*). Beje, (22) formulė atitinka būtent šį metodą.

2.9. Kintamųjų priklausomybės matai

Taikant vienfaktorinę dispersinę analizę, dažnai kyla klausimas, kokią įtaką faktorius daro priklausomojo kintamojo reikšmėms. Pavyzdžiui: kaip valstybinio egzamino rezultatas priklauso nuo mokinio baigtos mokyklos; kaip detalės ilgaamžiškumas priklauso nuo ją gaminusios firmos ir pan. Naudojama keletas vienfaktorinės dispersinės analizės kintamųjų priklausomybės matų. Visi jie skaitiškai lygina duomenų skirtumus pačiose imtyse su imčių skirtumais. Aptarsime svarbiausius matus.

2.9.1. Koeficientas η^2

Prisiminkime struktūrinį ANOVA modelį (žr. 2.4 skyrelį). Visą kvadratų sumą išskaidėme į dvi komponentes:

$$SST = SSB + SSW;$$

čia SSB įvertina imčių vidurkių ir bendrojo vidurkio skirtumus (grupių kvadratų suma), o SSW – imties duomenų skirtumus (vidinė kvadratų suma). Kuo SSB didesnė, tuo ir imčių vidurkių skirtumai didesni. Tačiau pati SSB populiacijos įtakai matuoti netinka, nes priklauso nuo skalės, kuria duomenys matuoti. Pavyzdžiui, ilgus matuodami ne metrais, o centimetrais, gauname 10 000 kartų didesnę SSB reikšmę. Todėl naudojamas santykinis matas – koeficientas η^2 .

$$\eta^2 = \frac{SSB}{SST} = \frac{SSB}{SSB + SSW}. \quad (23)$$

SSB ir SST galima rasti iš ANOVA rezultatų lentelės. Aišku, kad $0 \leq \eta^2 \leq 1$. Jeigu $\eta^2 = 0$, tai $SSB = 0$. Kitaip sakant, visų imčių vidurkiai lygūs, o visą rezultatų įvairovę galima paaiškinti individualiais respondentų skirtumais (viską lemia SSW). Jeigu $\eta^2 = 1$, tai $SSW = 0$. Šiuo atveju kiekviena imtis visiškai homogeniška (visi jos elementais vienodi), o skiriasi tik pačių imčių vidurkiai. Kuo η^2 didesnis, tuo mažiau imčių elementai skiriasi tarpusavyje, palyginti su imčių skirtumais. Sakoma, kad η^2 parodo, *kurią dalį duomenų sklaidos lemia populiacijų skirtumai*. Neretai naudojama procentinė η^2 interpretacija.

2.10 pavyzdys. Prisiminkime 2.2 pavyzdį apie muzikinio fono įtaką darbo našumui. Kadangi $SSB = 39016,47$, $SST = 49633,47$, tai $\eta^2 = 0,786$. Todėl galima sakyti, kad 78,6% respondentų pagaminamos produkcijos kiekio skirtumų lėmė skirtingi muzikiniai fonai, o 21,4% – individualūs gamintojų skirtumai.

Nors koeficientą η^2 patogiau skaičiuoti naudojantis ANOVA lentele, jo nebūtina sieti su vienfaktorine dispersine analize. Šį koeficientą galima skaičiuoti visada, kai prireikia įvertinti kategorinio faktoriaus (mokyklos, profesijos, firmos, valstybės, dėstytojo, ligoninės ir pan.) įtaką priklausomam intervaliniam kintamajam (testo rezultatams, produkcijos gausai, IQ, pažymiui, gijimo laikui ir pan.) Kalbant ANOVA terminais, η^2 parodo, koks procentas priklausomo kintamojo reikšmių sklaidos paaiškinamas nepriklausomo kintamojo įgyjamomis reikšmėmis.

Be paties koeficiento η^2 , dar naudojamas *netiesinis koreliacijos koeficientas* η .

$$\eta = \sqrt{\eta^2} = \sqrt{\frac{SSB}{SST}}. \quad (24)$$

2.11 pavyzdys. Muzikinio fono ir darbo našumo priklausomybės $\eta = 0,887$. Pavyzdžio apie ligos sunkumą ir slaugos kokybę (žr. 2.3 pvz.) $\eta = 0,913$, $\eta^2 = 0,834$.

Sakoma, kad η parodo, kaip stipriai priklausomo kintamojo reikšmė priklauso nuo to, kokią reikšmę įgijo kategorinis imties požymis (nepriklausomas kintamasis). Šis koeficientas kartais naudojamas ir netiesinei dviejų *intervalinių* kintamųjų priklausomybei


matuoti. Tuo atveju pasirenkama, kurį kintamąjį laikyti nepriklausomu ir jį kategorizuoti (paliekama 6–12 kategorijų). Tada η skaičiuojamas, kaip įprasta.

Koeficiento η didumas interpretuojamas analogiškai Pirsono arba Spirmeno koreliacijos koeficientams. Tačiau yra ir keli esminiai skirtumai:

- 1) koeficientas η visada neneigiamas;
- 2) nepriklausomojo kintamojo reikšmės pernumeravus (pavyzdžiui, antrą grupę pavadinus trečiaja, o trečiąją – antrąja, žr. 2.15 pav.), koeficiento η reikšmė nesikeičia;
- 3) koeficientas η yra griežtai asimetriškas ta prasme, kad iškart nurodoma, jog tiriama kategorinio kintamojo įtaka intervaliniam kintamajam. Žinoma, net ir didelis η dar neįrodo *priežastingumo*. Sąvokos „nepriklausomas kintamasis“ ir „priklausomas kintamasis“ tėra ANOVA terminai, atspindintys tyrėjo *spėjimą* apie galimą priežastingumo kryptį.

Tai, kas paskyta apie η , tinka ir η^2 . Kaip ir visi statistiniai koeficientai, η^2 tuo tiksliau nurodo kintamųjų priklausomybę, kuo imtys yra didesnės.

SPSS paketu apskaičiuoti 2.9 pavyzdžio koeficientai η^2 ir η pateikti 2.16 paveiksle.



MEASURES OF ASSOCIATION		
	Eta	Eta Squared
REZULTATAS*STRESAS	,906	,821

2.16 pav. 2.9 pavyzdžio koeficientai η^2 ir η



Viena iš teorijų teigia, kad asmenybės formavimuisi įtaką daro ir gimimo šeimoje eilė. Gimus antrajam vaikui, pirmagimiai iš „karaliukų“ tampa eiliniaisiais. Todėl jie ilgisi ankstesnės tvarkos ir linkę į konservatyvumą. Antrieji vaikai, būdami mažesni, konkuruoja su pirmagimiais. Todėl jie revoliucingesni ir labiau linkę į riziką. Įvairūs tyrimai iš dalies šią teoriją patvirtino ir iš dalies paneigė. Pavyzdžiui, iš antrojo pasaulinio karo pasižymėjusių lakūnų (asu, numušusių ne mažiau kaip penkis priešų lėktuvus) daugiau buvo nepirmagimių. Tačiau kitas tyrimas parodė, kad blogo mokymosi padarinių, galinčių turėti įtakos karjerai, antrieji vaikai bijojo labiau nei pirmagimiai. Dr. M. Steinbergas tyrė vaikų gebėjimą skaityti. Visi vaikai pagal gimimo eilę buvo suskirstyti į keturias grupes. Remiantis teorija, išeity, kad kuo daugiau vaikų, tuo mažiau laiko vienam vaikui gali skirti tėvai. Šiuo atžvilgiu pirmagimiai pranašesni už kitus vaikus ir turėtų geriau skaityti. Tyrimas parodė, kad vidutiniai skirtingų grupių skaitymo gebėjimai statistiškai reikšmingai skiriasi. Tačiau pabandžius nustatyti, kokią įtaką tam turi grupė (t. y. gimimo eilė), gauta: $SSB = 3041,676$, $SST = 56009$ ir $\eta^2 = 0,054$. Taigi tik truputį daugiau kaip pusę procento rezultatų sklaidos lemia gimimo eilė.

2.9.2. Koeficientas ω^2

Tarkime, kad visų imčių didumai lygūs, t. y. $n_1 = n_2 = \dots = n_k = n$. Koeficientas ω^2 yra tam tikrų dispersijų įverčių realizacijų santykis. Kokių dispersijų, lengviausia suvokti iš i -osios imties j -ojo elemento struktūrinio ANOVA modelio (žr. 2.2 skyrelį):

$$X_{ij} = \mu + (\mu_i - \mu) + e_{ij} = \mu + \tau_i + e_{ij}; \quad (25)$$

čia $e_{ij} \sim \mathcal{N}(0, \sigma^2)$. Nei dispersija σ^2 , nei μ_i nežinomi. Individualius respondentų skirtumus atskleidžia σ^2 . Populiacijų įtaka matyti iš vidurkių μ_i (arba τ_i) skirtumų. Kaip šiuos skirtumus skaitiškai įvertinti? Paprasčiausias įvertis yra

$$\sigma_\tau^2 = \frac{1}{k} \sum_{i=1}^k (\mu_i - \mu)^2 = \frac{1}{k} \sum_{i=1}^k \tau_i^2. \quad (26)$$

Kuo σ_τ^2 didesnė, tuo labiau populiacijų vidurkiai tarpusavyje skiriasi. Natūralus santykinis tokių skirtumų matas būtų

$$\frac{\sigma_\tau^2}{\sigma^2 + \sigma_\tau^2}, \quad (27)$$

t. y. vidurkių dispersijos ir populiacijų dispersijos bei vidurkių dispersijos sumos santykis. Nors ši formuluoė gremėzdiška, principinė idėja analogiška η^2 apibrėžimui: vidurkių sklaidos matas lyginamas su bendruoju duomenų sklaidos matu. Kaip įvertinti σ^2 ? Iš (12) formulių išplaukia:

$$EMSW = \sigma^2, \quad EMSB = \sigma^2 + \frac{nk}{k-1} \sigma_\tau^2. \quad (28)$$

Todėl galima naudotis tokiais įverčiais:

$$\hat{\sigma}^2 = MSW, \quad \hat{\sigma}_\tau^2 = \frac{k-1}{nk} (MSB - MSW).$$

Istatę juos į (27) formulę, gauname

$$\frac{\hat{\sigma}_\tau^2}{\hat{\sigma}^2 + \hat{\sigma}_\tau^2} = \frac{SSB - (k-1)MSW}{SSB + SSW + MSW} = \frac{SSB - (k-1)MSW}{SST + MSW}.$$

Nors šią formulę išvedėme visas imtis laikydami vienodo didumo, ji taikoma ir kai imčių didumai skiriasi. Gautasis koeficientas vadinamas ω^2 (omega kvadratu).

$$\omega^2 = \frac{SSB - (k-1)MSW}{SST + MSW}.$$

Kaip apskaičiuoti SST , SSB ir MSW reikšmes, nurodyta 2.4 skyrelyje. Jas galima rasti ir iš ANOVA rezultatų lentelės.

Sakoma, kad koeficientas ω^2 parodo, kokią dalį bendrosios priklausomojo kintamojo dispersijos paaiškina populiacijų vidurkių skirtumai. Kuo ω^2 didesnis, tuo kiekvienos imties elementai vienodesni ir tuo labiau duomenų skirtumus lemia priklausymas konkrečiai populiacijai.

2.12 pavyzdys. Prisiminkime 2.2 pavyzdį apie muzikinį foną ir darbo našumą. Tuomet

$$\omega^2 = \frac{39016,47 - 2 \cdot 393,22}{49633,47 + 393,22} = 0,776.$$

Nagrinėto 2.3 pavyzdžio apie slaugos kokybę ir pacientų ligos sunkumą

$$\omega^2 = \frac{878 - 3 \cdot 7,286}{1052,857 + 7,286} = 0,807.$$

Manoma, kad ω^2 yra tikslesnis priklausomybės matas už η^2 . Be to (tą liudija ir mūsų nagrinėti pavyzdžiai), dažniausiai $\omega^2 \leq \eta^2$. Šiuo metu ω^2 yra populiariausias ANOVA kintamųjų priklausomybės matas. Nėra griežto susitarimo, kokią ω^2 reikšmę laikyti didele. Dažniausiai siūloma ω^2 laikyti pakankamai didele, jeigu $\omega^2 > 0,15$.

2.9.3. Koreliacijos koeficientas ICC

Tarkime, kad imčių didumai vienodi ($n_i = n$). Tegul populiacijos ANOVA tyrimui atsitiktinai parenkamos iš didesnės populiacijų aibės, t. y. nagrinėjame ne fiksuotą, o atsitiktinį ANOVA modelį. Tuomet vidurkiai $\mu_1, \mu_2, \dots, \mu_k$ tėra tam tikra galimų vidurkių imtis ir, užuot taikius (26) formulę, reikia naudotis tokiu dispersijos įverčiu (žr. [1], I dalį):

$$\sigma_\tau^2 = \frac{1}{k-1} \sum_{i=1}^k (\mu_i - \mu)^2. \quad (29)$$

Koeficiento ω^2 analogas šiam atsitiktiniam ANOVA modeliui vadinamas (kvadratinio) koreliacijos koeficientu ICC^1 . Rasime jį. Iš (12) formulių išplaukia, kad:

$$EMSW = \sigma^2, \quad EMSB = \sigma^2 + n\sigma_\tau^2. \quad (30)$$

Todėl dispersijų įverčiai yra:

$$\hat{\sigma}^2 = MSW, \quad \hat{\sigma}_\tau^2 = (MSB - MSW)/n.$$

Istatę juos į (27) formulę, gauname ICC išraišką:

$$ICC = \frac{(MSB - MSW)/n}{MSW + (MSB - MSW)/n} = \frac{MSB - MSW}{MSB + (n-1)MSW} = \frac{F-1}{F + (n-1)}.$$

Visus šiuos dydžius galima apskaičiuoti pagal 2.4 skyrelio formules. ICC dar sutrumpintai žymimas ρ . Jeigu imčių didumai skiriasi, šio koreliacijos koeficiento išraiškoje, užuot naudojus n , imamas imčių didumų harmoninis vidurkis $\bar{n}$.

$$ICC = \frac{MSB - MSW}{MSB + (\bar{n} - 1)MSW} = \frac{F - 1}{F + (\bar{n} - 1)}.$$

Kaip apskaičiuoti MSB , MSW ir F reikšmes, nurodyta 2.4 skyrelyje. Jas galima rasti ir iš ANOVA rezultatų lentelės; $\bar{n} = k/(1/n_1 + \dots + 1/n_k)$.

ICC interpretuojamas kaip ir koeficientai η^2 , ω^2 . Kuo ICC didesnis, tuo kiekvienos imties duomenys panašesni ir tuo labiau duomenų skirtumus lemia priklausymas konkrečiai populiacijai.

2.13 pavyzdys. Prisiminkime 2.2 pavyzdį apie muzikinį foną ir darbo našumą. Tuomet

$$ICC = \frac{49,61 - 1}{49,61 + 2} = 0,94.$$

Kito 2.3 pavyzdžio apie slaugos kokybę ir pacientų ligos sunkumą

$$ICC = \frac{40,17 - 1}{40,17 + 3} = 0,90.$$

ICC gali būti ir neigiamas (jei $F < 1$). Minimali reikšmė $ICC = -1/(n-1)$ rodo, kad visose imtyse duomenų įvairovė didžiausia (imtyys labai heterogeniškos).

¹ ICC – ang. *Intraclass Correlation Coefficient*.

2.9.4. Kurį koeficientą taikyti?

Realiesiems taikymams nėra didelio skirtumo, kuriuo koeficientu naudotis, nes jų reikšmės mažai skiriasi. Iš tikrųjų 2.2 pavyzdžio $\eta^2 = 0,887$, $\omega^2 = 0,77$, $ICC = 0,94$, o 2.3 pavyzdžio $\eta^2 = 0,834$, $\omega^2 = 0,807$, $ICC = 0,90$. Kur kas svarbiau, kad imtys būtų pakankamai didelės, o imčių didumai kuo mažiau skirtingi.

2.10. Hipotezės apie dispersijų lygybę tikrinimas

Aptardami ANOVA prielaidas, nurodėme, kad populiacijų dispersijos turi būti lygios. Pateiksime du kriterijus hipotezei apie dispersijų lygybę tikrinti.

2.10.1. Bartleto kriterijus

Bartleto¹ kriterijus yra pakankamai galingas tik tuo atveju, kai stebimi kintamieji yra normalieji.

1 *Duomenys.* Turime k imčių $(x_{11}, x_{12}, \dots, x_{1n_1}), (x_{21}, x_{22}, \dots, x_{2n_2}), \dots, (x_{k1}, x_{k2}, \dots, x_{kn_k})$, kurios gautos matuojant nepriklausomus normaliuosius atsitiktinius dydžius $X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2), X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2), \dots, X_k \sim \mathcal{N}(\mu_k, \sigma_k^2)$ pagal intervalų skalę.

2 *Statistinė hipotezė:*

$$\begin{cases} H_0: \sigma_1^2 = \sigma_2^2 = \dots = \sigma_k^2, \\ H_1: \text{ bent dvi dispersijos nelygios.} \end{cases}$$

3 *Kriterijaus statistika.* Apskaičiuojame

$$T = \frac{(N - k) \ln s_p^2 - \sum_{i=1}^k (n_i - 1) \ln s_i^2}{1 + \Delta};$$

čia

$$\Delta = \frac{1}{3(k-1)} \sum_{i=1}^k \left(\frac{1}{n_i - 1} - \frac{1}{N - k} \right), \quad s_p^2 = \frac{1}{N - k} \sum_{i=1}^k (n_i - 1) s_i^2,$$

$N = n_1 + n_2 + \dots + n_k$, s_i^2 yra i -osios imties dispersija.

4 *Sprendimo priėmimo taisyklė.* Tegul reikšmingumo lygmuo lygus α . Hipotezė H_0 atmetama (taigi bent dvi dispersijos statistiškai reikšmingai skiriasi), jeigu $T > \chi_\alpha^2(k-1)$; čia $\chi_\alpha^2(k-1)$ yra χ^2 skirstinio su $(k-1)$ laisvės laipsnių α lygmens kritinė reikšmė. Hipotezė H_0 neatmetama, jeigu $T \leq \chi_\alpha^2(k-1)$.

¹ Maurice S. Bartlett (1910) – anglų statistikas.

2.14 pavyzdys. Prisiminkime 2.2 pavyzdį apie muzikinio fono poveikį darbo našumui. Tegul $\alpha = 0,05$. Visi imčių didumai vienodi, t. y. $n_i = 10$, $k = 3$, $N = 30$. Randame:

$$s_1^2 = 583,56, \quad s_2^2 = 331,43, \quad s_3^2 = 264,68,$$

$$\ln s_1^2 = 6,37, \quad \ln s_2^2 = 5,80, \quad \ln s_3^2 = 5,58,$$

$$s_p^2 = \frac{9}{27}(583,56 + 331,43 + 264,68) = 393,223, \quad \ln s_p^2 = 5,97,$$

$$\Delta = \frac{1}{3 \cdot 2} \left(\frac{3}{9} - \frac{3}{27} \right) = \frac{1}{27}, \quad T = \frac{27 \cdot 5,97 - 9(6,37 + 5,80 + 5,58)}{1 + 1/27} = 1,388.$$

Kadangi $T = 1,388 < 5,99 = \chi_{0,05}^2(2)$, hipotezės apie dispersijų lygybę atmesti nėra pagrindo.

2.10.2. Livyno kriterijus

Livyno¹ kriterijus yra alternatyva Barleto kriterijui. Jis ne toks jautrus normalumo prielaidos pažeidimams.

1 *Duomenys.* Turime k imčių $(x_{11}, x_{12}, \dots, x_{1n_1}), (x_{21}, x_{22}, \dots, x_{2n_2}), \dots, (x_{k1}, x_{k2}, \dots, x_{kn_k})$, kurios gautos matuojant nepriklausomus normaliuosius atsitiktinius dydžius $X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2), X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2), \dots, X_k \sim \mathcal{N}(\mu_k, \sigma_k^2)$ pagal intervalų skalę.

2 *Statistinė hipotezė:*

$$\begin{cases} H_0: \sigma_1^2 = \sigma_2^2 = \dots = \sigma_k^2, \\ H_1: \text{ bent dvi dispersijos nelygios.} \end{cases}$$

3 *Kriterijaus statistika.* Apskaičiuojame

$$W = \frac{(N - k) \sum_{i=1}^k n_i (\bar{z}_i - \bar{z})^2}{(k - 1) \sum_{i=1}^k \sum_{j=1}^{n_i} (z_{ij} - \bar{z}_i)^2};$$

čia $\bar{z} = (z_{11} + z_{12} + \dots + z_{kn_k})/N$, $\bar{z}_i = (z_{i1} + z_{i2} + \dots + z_{in_i})/n_i$, $N = n_1 + n_2 + \dots + n_k$, o $z_{ij} = |x_{ij} - \bar{x}_i|$, $\bar{x}_i = (x_{i1} + \dots + x_{in_i})/n_i$.

4 *Sprendimo priėmimo taisyklė.* Tegul reikšmingumo lygmuo lygus α . Hipotezė H_0 atmetama (taigi bent dvi dispersijos statistiškai reikšmingai skiriasi), jeigu $W > F_\alpha(k - 1, N - k)$; čia $F_\alpha(k - 1, N - k)$ yra Fišerio skirstinio su $(k - 1)$ ir $(N - k)$ laisvės laipsnių α lygmens kritinė reikšmė. Hipotezė H_0 neatmetama, jeigu $W \leq F_\alpha(k - 1, N - k)$.

¹ Howard Levene – amerikiečių statistikas.

2.15 pavyzdys. Prisiminkime 2.2 pavyzdį apie muzikinio fono poveikį darbo našumui. Tegul $\alpha = 0,05$. Visi imčių didumai vienodi, t. y. $n_i = 10$, $k = 3$, $N = 30$. Randame $\bar{x}_1 = 736$; $\bar{x}_2 = 669,9$; $\bar{x}_3 = 753,7$; $\bar{z}_1 = 20,2$; $\bar{z}_2 = 16,12$; $\bar{z}_3 = 12,36$; $\bar{z} = 16,2267$; $W = 1,722$.

Kadangi $W = 1,722 < 3,35 = F_{0,05}(2, 27)$, hipotezės apie dispersijų lygybę atmeti nėra pagrindo.

Yra Livyno kriterijaus variantas medianoms. Užtenka imti $z_{ij} = |x_{ij} - Md_i|$; čia Md_i yra i -osios imties mediana.

SPSS taiko Livyno kriterijų dispersijų lygybei tikrinti kaip papildomą ANOVA opciją. Kaip visada, naudojant SPSS, patogiau išvadas daryti remiantis p -reikšmėmis (stulpelis Sig.). Jeigu p -reikšmė mažesnė už pasirinktąjį reikšmingumo lygmenį α , tai hipotezę H_0 apie dispersijų lygybę atmetame (ne visos dispersijos lygios). Neturime pagrindo teigti, kad dispersijos skiriasi, jeigu p -reikšmė yra ne mažesnė kaip α .

2.16 pavyzdys. Prisiminkime 2.8 pavyzdį apie išgertų alaus bokalų skaičiaus įtaką vairavimo testo rezultatams. Tarkime, reikšmingumo lygmuo $\alpha = 0,05$. Livyno kriterijaus rezultatai pateikti 2.17 paveiksle. Matome, kad p -reikšmė lygi $0,897 > 0,05$, todėl nėra pagrindo laikyti dispersijas skirtingomis.

TEST OF HOMOGENEITY OF VARIANCES			
REZULTATAS			
Levene Statistic	df1	df2	Sig.
,199	3	28	,897

2.17 pav. Livyno kriterijaus SPSS rezultatai



ANOVA	Livyno kriterijus	vidinė kvadratų suma
apriorinis kriterijus	LSD kriterijus	vidurkių trendas
aposteriorinis kriterijus	nepriklausomas faktorius	vienfaktorinė dispersinė analizė
Bartleto kriterijus	ortogonalusis kontrastas	
Bonferonio kriterijus	<i>post hoc</i> testai	visa kvadratų suma
eksperimento reikšmingumo lygmuo	priklausomas kintamasis	η^2
gruپیų kvadratų suma	SNK kriterijus	ω^2
	Tjukio HSD kriterijus	

UŽDAVINIAI

- Užpildykite ANOVA lentelę. Kiek buvo imčių? Ar imčių vidurkiai skiriasi statistiškai reikšmingai ($\alpha = 0,05$)?

	Kvadratų suma	Laisvės laipsniai	Dispersijos įverčiai	Statistika
Grupių	1466	4		
Vidinė		61		
Visa	1723			

2. Norėdamas rasti optimalų darbo režimą, firmos prezidentas trijuose vienodo našumo padaliniuose (kiekviename dirba po 6 darbuotojus) išbandė skirtingas 48 valandų darbo savaites: 5 dienų, 4 dienų ir 3,5 dienos. Eksperimentas vyko vienus metus. Pateikta lentelė, kiek per vieną savaitę vidutiniškai kiekvienas darbuotojas pagamino detalių. Ar kuris nors savaitės darbo režimas davė statistiškai reikšmingai daugiau naudos nei likusieji? (Reikšmingumo lygmuo $\alpha = 0,01$.)

5 dienos	4 dienos	3,5 dienos
360	340	371
302	350	365
333	306	303
351	337	300
329	371	336
340	365	365

3. Norėdamas išsiaiškinti, kaip pateiktas tekstas geriau įsimenamas, vyriausybės atstovas spaudai tą pačią ilgą ir nuobodžią instrukciją (kaip pildyti būsimos darbo veiklos ataskaitą) išsiuntinėjo grupei pavaldinių. Dalis pavaldinių instrukciją gavo nepakeistą, dalis papildytą smagiais piešiniais, o dalis – papildytą ir piešiniais, ir pajuokavimais. Po mėnesio buvo įvertinta pažymiu (iki 50 balų), kaip kiekvienas pavaldinys įsiminė instrukciją. Koks pateikimo būdas buvo efektyviausias? ($\alpha = 0,05$.)

Instrukcija	Pažymys									
Vien tekstas	32	31	30	29	28	31	32	33	34	35
Su piešiniais	40	35	37	36	35	34	33	35	37	36
Su piešiniais ir pajuokavimais	40	39	38	35	34	38	33	37	36	37

4. Maisto kokybės kontrolieriai 10 dienų nustatinėjo keturiose parduotuvėse gaminamo faršo „Taurus“ riebalų procentą. Ar galima teigti, kad skirtingų parduotuvių gaminiuose jis iš esmės skiriasi? ($\alpha = 0,05$.)

Parduotuvė	Riebalų procentas farše									
1	20	25	23	24	25	26	27	25	23	24
2	28	29	30	31	32	29	28	27	26	25
3	20	22	21	25	26	22	27	23	24	23
4	30	29	26	28	26	30	31	32	29	28

5. Kurios turi daugiau plaukų: blondinės, rudaplaukės ar raudonplaukės? Rašantis disertaciją biologas ištyrė po penkiolika (nedažytų!) grožio konkurso dalyvių. Lentelėje pateikti plaukų skaičiai. Reikšmingumo lygmuo $\alpha = 0,05$.

	Plaukų skaičius (tūkst.)														
Blondinės	140	136	139	100	127	152	143	126	127	138	146	142	141	121	143
Rudaplaukės	108	111	112	120	122	101	130	115	114	109	107	116	114	117	106
Raudonplaukės	90	100	120	87	93	95	86	101	102	94	86	87	96	90	100

6. Baldus gaminanti firma tiria, kaip potencialūs pirkėjai vertina (pagal 100 balų skalę) biuro baldų komplektą. Penkioms skirtingoms pirkėjų grupėms buvo pasakytos penkios skirtingos komplekto kainos (kainų skirtumai 1000, 2000, 3000, 4000 Lt). Manoma, kad kainai didėjant iš pradžių nuomonė turėtų gerėti (brangus – vadinasi, geras), o po to – blogėti (tiek nevertas). Patikrinkite, ar duomenys neprieštarauja šiai hipotezei ($\alpha = 0,05$).

Grupė		Vertinimai													
1	76	75	73	72	75	76	77	78	75	76	76	75	77	76	
2	83	82	80	84	85	83	82	84	85	82	83	80	79	83	
3	87	86	88	89	86	88	85	86	87	84	85	82	87	85	
4	85	87	86	86	88	84	85	86	83	84	82	81	84	84	
5	75	74	73	72	78	75	76	72	74	79	80	72	75	78	

7. Ar remiantis 2.5 pavyzdžio duomenimis galima teigti, kad nuomonių vidurkiai sudaro didėjančią tiesinį trendą? ($\alpha = 0,05$.)
8. Kultūros savitumų tyrinėtojas skaičiavo, kiek gestų per dviejų valandų pranešimą padarė skirtingų šalių pranešėjai. Ar galima teigti, kad vidutinis kilikiečių gestikuliavimo lygis yra lygus nubų ir ilyrų vidutinių gestikuliavimo lygių vidurkiui? ($\alpha = 0,05$.)

Šalis	Gestų skaičius														
Nubija	41	37	40	36	28	38	44	27	28	39	41	39	42	35	44
Ilyrija	9	5	12	6	7	11	6	3	5	6	12	5	9	4	5
Kilikija	19	21	15	21	23	27	31	16	15	14	19	17	15	28	27

9. Remdamiesi Bartleto ir Livyno kriterijais, įsitikinkite, kad 2–8 uždavinių visų grupių dispersijos lygios. Reikšmingumo lygmuo $\alpha = 0,05$.
10. Apskaičiuokite 5 ir 8 uždaviniuose koeficientus η^2 ir ω^2 . Ką galima pasakyti apie tautybės įtaką rezultatams?

3. DVIFAKTORINĖ DISPERSINĖ ANALIZĖ



Statistika, kaip ir sapnai, yra norų išsipildymo forma.
Ž. Bodrilaras

Tiriant naują labai slaptą psichotropinį preparatą, visi tiriamieji buvo suskirstyti į du srautus po tris grupes. Pirmo srauto grupės gavo vienos rūšies preparato (*K*), antrojo – kitos (*L*). Prieš suleidžiant preparatą, abiejų srautų pirmosios grupės badavo vieną, antrosios – dvi, o trečiosios – tris savaites. Apskaičiuota, kiek laiko buvo pernelyg atviri ir save kompromituojančius faktus pasakojo preparato gavę tiriamieji. Ar preparatai vienodai gerai „atrisa liežuvius“? Ar preparatai labiau veikia išsekusį organizmą? Ar preparatų poveikio skirtumas ryškesnis ilgiau badavus? Į tokius ir panašius klausimus atsako dvifaktorinė dispersinė analizė.

Dvifaktorinės ir vienfaktorinės dispersinių analizių duomenų struktūros labai panašios. Tik dvifaktorinėje dispersinėje analizėje populiacijos skiriamos atsižvelgiant į *du faktorius* (nepriklausomus kintamuosius). Slaptajame tyrime buvo atsižvelgta ir į preparato rūšį, ir į badavimo trukmę. Kaip ir anksčiau, matuojamasis intervalinis kintamasis (plepėjimo trukmė) vadinamas *priklausomuoju kintamuoju*.



*Kaip ir vienfaktorinei, dvifaktorinei dispersinei analizei žymėti vartojama santrumpa ANOVA. Tik paprastai prirašoma, kad yra du faktoriai. Dažnai nurodomas faktorių įgyjamų reikšmių skaičius. Tyrime dvi preparato rūšys (*K* ir *L*) ir tris badavimo lygius (1, 2 ir 3 savaitės). Todėl šiuo atveju galima sakyti, kad buvo taikyta 2×3 ANOVA.*

Pagrindinis dvifaktorinės analizės tikslas – nustatyti, ar priklausomo intervalinio kintamojo vidurkiai skirtingose populiacijose skiriasi. Iš pradžių tiriamos populiacijos, kurių skirtumus nusako pirmojo faktoriaus reikšmės, po to populiacijos, kurių skirtumus nusako antrojo faktoriaus reikšmės. Panašių tikslų siekime taikydami vienfaktorinę dispersinę analizę. Dvifaktorinė dispersinė analizė turi dar vieną tikslą – nustatyti nepriklausomų faktorių tarpusavio sąveiką. Aptartoj pavyzdžio pirmasis faktorius yra preparato rūšis. Pagal jį tiriamieji skirstomi į gavusiuosius preparato *K* arba preparato *L*. Pagal antrąjį faktorių (badavimo trukmę) visi tiriamieji skirstomi į 1, 2 arba 3 savaites badavusius. Mus domina ne tik tai, ar vidutinė šių populiacijų pernelyg didelio šnekumo trukmė yra skirtinga, bet ir galima preparato rūšies ir badavimo trukmės tarpusavio sąveika, dėl kurios ypač padidėja šnekumas.

Dvifaktorinės analizės prireikia, kai:

- skirtingų kursų ir specialybių studentai pažymiu vertina universiteto paskaitų kokybę ir norima nustatyti, ar šie vertinimai priklauso nuo respondento kurso, specialybės bei jų tarpusavio sąveikos;
- tiriamas trijų rūšių valiklių efektyvumas valant riebalų, vyno, purvo arba rašalo dėmes;
- aiškinamasi kambario didumo ir aplinkos triukšmo įtaka tiriamojo dirglumui ir pan.

Daugiausia šiame skyriuje kalbama apie *pastovųjį* dispersinės analizės modelį, t. y. atvejį, kai uždaviniui spręsti naudojamos *visos* turimos imtys. Atsitiktiniai ir mišrieji modeliai aptariami 3.8 skyrelyje.

3.1. Skirtumai nuo vienfaktorinės dispersinės analizės

Tarkime, norime įvertinti preparatų K ir L poveikio skirtumą. Tai standartinis vienfaktorinės dispersinės analizės uždavinys. Tačiau turime papildomos informacijos – žinome, kiek laiko kiekvienas tiriamasis badavo. Taigi galime atsižvelgti ir į dėl to atsiradusius rezultatų skirtumus. Vienas iš dvifaktorinės analizės privalumų – galimybė efektyviau panaudoti turimą informaciją ir padidinti kriterijaus galią.


Kitas privalumas – galimybė įvertinti nepriklausomų faktorių tarpusavio sąveiką. Pavyzdžiui, gali paaiškėti, kad preparatas K labiausiai paveikė dvi savaites badavusiuosius, o preparatas L – tris. Kitaip sakant, kiekvienam preparatui sava dieta.



Kaip skelbia liaudies išmintis: „Gali visą vakarą gurkšnoti alų ir nepasigerti, gali po truputį gerti degtinę ir nepasigerti, bet šiukštu nemaišyk!“ Statistikas šiuo atveju pasakytų, kad alaus ir degtinės tarpusavio sąveika itin stipri.

Naudojami keli ekvivalentūs faktorių tarpusavio sąveikos apibrėžimai ir visi jie gremėzdiski ir nelengvai suvokiami. Pateiksime vieną iš jų. Tarkime, pagal pirmą faktorių sudarome a populiacijų (pirmasis faktorius įgyja a skirtingų reikšmių). Pagal antrąjį faktorių kiekviena iš tų populiacijų suskirstoma į b mažesnių populiacijų (antrasis faktorius įgyja b skirtingų reikšmių). Taigi po skirstymo turime $a \times b$ skirtingų populiacijų. Išmatuojame intervalinio (priklausomo) kintamojo populiacijų vidurkius. Parenkame b populiacijų, kurios skiriasi tik pagal antrąjį faktorių, o pirmasis faktorius jose fiksuotas ir įgyja tą pačią (tarkime, pirmąją) reikšmę. Apskaičiuojame visus atrinktųjų populiacijų vidurkių skirtumus. Po to atrenkame b populiacijų, kuriose pirmasis faktorius įgyja antrąją reikšmę. Vėl skaičiuojame visų atrinktųjų populiacijų vidurkių skirtumus. Patikriname, ar gautieji skirtumai tokie patys kaip ankstesnės populiacijų grupės. Procesą tęsiame toliau. Jei keičiantis pirmojo faktoriaus reikšmei populiacijų vidurkių skirtumai nesikeičia, tai sakome, kad tarpusavio sąveikos nėra. Priešingu atveju sakome, kad tarpusavio sąveika yra. Pažymėsime, kad skirtingi populiacijų vidurkiai dar negarantuoja faktorių tarpusavio sąveikos. Faktorių tarpusavio sąveika yra tada, kai skirtingoms faktorių reikšmėms nustatomi nevienodi vidurkių skirtumai.

Į tokį apibrėžimą reikia įsigilinti. Pabandysime šį procesą palengvinti, pastebėję, kad faktorių tarpusavio sąveiką gerai atskleidžia vidurkių trendai. Prisiminkime ankstesnįjį pavyzdį. Turime du nepriklausomus faktorius – preparato rūšį (K arba L) ir badavimo trukmę (1, 2 arba 3 savaitių). Tame pačiame grafike atidėkime vieną, dvi ir tris savaites badavusių bandomųjų vidutinį laiką, kai veikiant preparatui K ir preparatui L jie buvo pernelyg atviri. Įvairūs galimi trendų grafikai pateikti 3.1 paveiksle. Atveju a) preparatų K ir L poveikis nesiskiria (trendų grafikai sutampa) ir matyti tik badavimo įtaka. Čia faktorių tarpusavio sąveikos nėra. Atvejais b) ir c) preparatas K yra efektyvesnis už preparatą L , tačiau vidutinių laikų skirtumai vienodi ir vieną, ir dvi, ir tris savaites badavusiųjų. Faktorių tarpusavio sąveikos nėra. Atveju d) preparatas K labiausiai paveikė mažiausiai badavusius, o preparatas L – daugiausiai. Faktorių tarpusavio sąveika yra. Atveju e) abu preparatai labiausiai paveikė tris savaites badavusiuosius, tačiau, preparato L poveikio didėjimas radikalesnis nei preparato K . Faktorių tarpusavio sąveika yra. Atveju f) tarpusavio sąveika taip pat yra, nes vidutinis dvi savaites badavusių laikas skiriasi nuo tris savaites badavusių laiko.



Praktiškai galime teigti, kad faktorių tarpusavio sąveikos nėra, jeigu atitinkami trendų grafikai sutampa arba yra identiškos formos ir skiriasi tik postūmiu (vienas grafikas yra aukščiau nei kitas). Visais kitais atvejais tarpusavio sąveika yra.



Kartais nedidelis netikslumas sutaupo toną paaiškinimų.

Saki

3.2. Struktūrinis modelis

Tarkime, pagal du nepriklausomus faktorius A ir B skiriame $a \times b$ nepriklausomų populiacijų. Populiaciją, kurioje faktorius A įgyja reikšmę i , o faktorius B – reikšmę j , žymėsime (i, j) . Pavyzdžiui, $(1, 3)$ reiškia populiaciją, kurioje $A = 1$, o $B = 3$.

Kiekvienoje populiacijoje matuojame tą patį priklausomą intervalinį kintamąjį X . Susiedami šį kintamąjį su konkrečia populiacija (i, j) , gauname populiacijos kintamąjį X_{ij} . Pavyzdžiui, buvo matuojamas visų tiriamųjų laikas X , t. y. kiek jie buvo pernelyg atviri. Vieną savaitę badavusių ir preparatą K vartojusių laikas yra X_{11} , tris savaites badavusių ir K vartojusių – X_{31} ir pan.

Matuodami kintamąjį X_{ij} , sudarome atsitiktinę imtį $X_{ij1}, X_{ij2}, \dots, X_{ijn}, i = 1, \dots, a, j = 1, \dots, b$. Visų imčių didumai lygūs n . Duomenys pateikti 3.1 lentelėje.

3.1 lentelė. Dvifaktorinės ANOVA duomenys

A	B				Vidurkis
	1	2	...	b	
1	X_{111}	X_{121}	...	X_{1b1}	$\bar{X}_{1.}$
	X_{112}	X_{122}	...	X_{1b2}	
	...	...	...	...	
	X_{11n}	X_{12n}	...	X_{1bn}	
2	X_{211}	X_{221}	...	X_{2b1}	$\bar{X}_{2.}$
	X_{212}	X_{222}	...	X_{2b2}	
	...	...	...	...	
	X_{21n}	X_{22n}	...	X_{2bn}	
...	...	...	...	...	...
a	X_{a11}	X_{a21}	...	X_{ab1}	$\bar{X}_{a.}$
	X_{a12}	X_{a22}	...	X_{ab2}	
	...	...	...	...	
	X_{a1n}	X_{a2n}	...	X_{abn}	
Vidurkis	$\bar{X}_{.1}$	$\bar{X}_{.2}$	...	$\bar{X}_{.b}$	

Struktūrinis (i, j) imties k -ojo stebėjimo X_{ijk} ANOVA modelis užrašomas taip:

$$X_{ijk} = \mu_{ij} + e_{ijk} = \mu + (\mu_{ij} - \mu) + e_{ijk} = \mu + \tau_i. + \tau_{.j} + \tau_{ij} + e_{ijk}; \quad (1)$$

čia $\mu_{ij} = \mathbf{E}X_{ij}$ yra (i, j) -osios populiacijos kintamojo vidurkis; e_{ijk} – atsitiktinė paklaida; μ – bendrasis vidurkis (X vidurkis); $\tau_i.$ – faktoriaus A įtaka (indėlis); $\tau_{.j}$ – faktoriaus B įtaka (indėlis); τ_{ij} – faktorių A ir B tarpusavio sąveikos įtaka (indėlis).

Galime užrašyti tokias bendrojo vidurkio, i -osios eilutės, j -ojo stulpelio vidurkių ir $\tau_i.$, $\tau_{.j}$, τ_{ij} išraiškas:

$$\mu = \frac{\sum_{i=1}^a \sum_{j=1}^b \mu_{ij}}{ab}, \quad \mu_{i.} = \frac{\sum_{j=1}^b \mu_{ij}}{b}, \quad \mu_{.j} = \frac{\sum_{i=1}^a \mu_{ij}}{a}, \quad (2)$$

$$\tau_i. = \mu_{i.} - \mu, \quad \tau_{.j} = \mu_{.j} - \mu, \quad \tau_{ij} = (\mu_{ij} - \mu) - (\mu_{i.} - \mu) - (\mu_{.j} - \mu). \quad (3)$$

Nesunku įsitikinti, kad:

$$\sum_{i=1}^a \tau_i. = 0, \quad \sum_{j=1}^b \tau_{.j} = 0, \quad \sum_{i=1}^a \tau_{ij} = \sum_{j=1}^b \tau_{ij} = 0. \quad (4)$$

Minėto psichotropinio preparato tyrimo μ yra bendras vidutinis (teorinis) visų preparato gavusiųjų laikas, per kurį jie buvo pernelyg atviri; $\tau_i.$ rodo preparato rūšies įtaką laikui (kiek skiriasi skirtingus preparatus gavusiųjų vidutinės plepėjimo trukmės); $\tau_{.j}$ – badavimo įtaką (kiek skiriasi vidutiniai savaitę, dvi ar tris badavusių laikai); τ_{ij} – badavimo ir preparato rūšies tarpusavio sąveikos įtaką laikui; e_{ijk} – individualią tiriamojo reakciją į preparatą.

Kaip ir vienfaktorinėje dispersinėje analizėje, reikalaujama, kad visi e_{ijk} būtų normalieji, nepriklausomi, vienodai pasiskirstę atsitiktiniai dydžiai, turintys nulinius vidurkius

ir tą pačią nežinomą dispersiją, t. y. $e_{ijk} \sim \mathcal{N}(0, \sigma^2)$. Šį reikalavimą galima užrašyti ir taip:

Dvifaktoris ANOVA modelio prielaidos:

- 1) kintamųjų X_{ij} normalumas;
- 2) kintamųjų X_{ij} dispersijų lygybė, $\mathbf{D}X_{ij} = \sigma^2$;
- 3) kintamųjų X_{ij} nepriklausomumas.

Dvifaktoris dispersinė analizė yra gana atspari saikingiems prielaidų pažeidimams. Praktiškai viskas, kas pasakyta apie vienfaktoris analizės prielaidas, galioja ir dvifaktoris dispersinei analizei.

3.3. Stebėjimo duomenų struktūra

Tarkime, kad tenkinamos visos ankstesniojo skyrelio prielaidos. Duomenys pateikti 3.1 lentelė. Apibrėšime μ , μ_i , μ_j ir μ_{ij} empirinius analogus. Žymėsime: X_{ijk} – k -ąjį (i, j) imties elementą; $\bar{X}_i$ – i -osios eilutės vidurkį; $\bar{X}_j$ – j -ojo stulpelio vidurkį; $\bar{X}_{ij}$ – (i, j) populiacijos kintamojo vidurkį; $N = nab$ – bendrąjį visų stebėjimų skaičių.

$$\bar{X}_{.j} = \frac{\sum_{i=1}^a \sum_{k=1}^n X_{ijk}}{na} = \frac{\sum_{i=1}^a \bar{X}_{ij}}{a}, \quad \bar{X}_{i.} = \frac{\sum_{j=1}^b \sum_{k=1}^n X_{ijk}}{nb} = \frac{\sum_{j=1}^b \bar{X}_{ij}}{b}, \quad (5)$$

$$\bar{X}_{ij} = \frac{\sum_{k=1}^n X_{ijk}}{n}, \quad \bar{X} = \frac{\sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^n X_{ijk}}{nab} = \frac{\sum_{i=1}^a \bar{X}_{i.}}{a} = \frac{\sum_{j=1}^b \bar{X}_{.j}}{b}. \quad (6)$$

Užrašysime (1) formulės empirinį analogą:

$$X_{ijk} - \bar{X} = (\bar{X}_{i.} - \bar{X}) + (\bar{X}_{.j} - \bar{X}) + (X_{ijk} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X}). \quad (7)$$

Pakėlę (7) lygybės abi puses kvadratu, sudėję pagal visus elementus ir suprastinę panašiuosius narius, gauname formulę¹

$$SST = SSFA + SSFB + SSAB + SSE. \quad (8)$$

Čia

$$SST = \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^n (X_{ijk} - \bar{X})^2, \quad (9)$$

$$SSFA = nb \sum_{i=1}^a (\bar{X}_{i.} - \bar{X})^2, \quad SSFB = na \sum_{j=1}^b (\bar{X}_{.j} - \bar{X})^2, \quad (10)$$

$$SSAB = n \sum_{i=1}^a \sum_{j=1}^b (\bar{X}_{ij} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X})^2, \quad SSE = \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^n (X_{ijk} - \bar{X}_{ij})^2. \quad (11)$$

Kiekvienas (8) lygybės dėmuo turi savo pavadinimą. SST apima visų duomenų skirtumus nuo bendrojo vidurkio ir vadinama *visa kvadratų suma*. Matome, kad ji skyla į keturias

¹ Čia vartojami traptautiniai žymenys.

komponentes. Pirmoji komponentė $SSFA$ įvertina faktoriaus A įtaką ir vadinama *faktoriaus A kvadratų suma*. Analogiškai $SSFB$ yra *faktoriaus B kvadratų suma*, $SSAB$ – *kvadratų suma faktorių A ir B tarpusavio sąveikai*, SSE – *paklaidos kvadratų suma*.



Palyginę šio ir 2.4 skyrelių (8) lygybes, matome, kad SSE atitinka vienfaktorinės ANOVA komponentę SSW . Duomenų skirtumų šaltiniai šiuo atveju yra trys, todėl vietoje SSB turime $SSFA + SSFB + SSAB$.

Kiekviena (8) formulės komponentė atskleidžia skirtingų veiksnių įtaką duomenims. Jeigu $SSFA$ nedaug skiriasi nuo SSE , galima manyti, kad faktoriaus A įtaka kintamųjų X_{ij} reikšmėms statistiškai nereikšminga. Tuo ir grindžiamas atitinkamas statistinis kriterijus. Analogiškai sudaromi ir kiti kriterijai. Tik juose naudojami ne SSE ir panašūs dydžiai, bet nežinomos dispersijos σ^2 įverčiai. Apibrėšime juos:

$$MSFA = \frac{SSFA}{a-1}, \quad MSFB = \frac{SSFB}{b-1}, \quad (12)$$

$$MSAB = \frac{SSAB}{(a-1)(b-1)}, \quad MSE = \frac{SSE}{ab(n-1)}. \quad (13)$$

Galima įsitikinti, kad:


$$EMSFA = \sigma^2 + \frac{nb \sum_{i=1}^a (\mu_{i.} - \mu)^2}{a-1}, \quad EMSFB = \sigma^2 + \frac{na \sum_{j=1}^b (\mu_{.j} - \mu)^2}{b-1}, \quad (14)$$

$$EMSAB = \sigma^2 + \frac{n \sum_{i=1}^a \sum_{j=1}^b (\mu_{ij} - \mu)^2}{(a-1)(b-1)}, \quad EMSE = \sigma^2. \quad (15)$$

Matome, kad $EMSFA$ yra nepaslinktasis σ^2 įvertis tik tada, kai nėra A faktoriaus įtakos, t. y. visų populiacijų suskirstytų pagal faktorių A kintamųjų vidurkiai lygūs ($\mu_{1.} = \mu_{2.} = \dots = \mu_{a.}$). Todėl, jeigu $MSFA/MSE$ daug viršija vienetą, ne visus vidurkius laikome lygiais. Įvertinti, ką tai reiškia *viršija daug*, padeda tinkamai parinkta kritinė reikšmė.

Skaičiuoti patogiau pagal tokias formules:

$$SST = \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^n X_{ijk}^2 - \frac{T^2}{nab}, \quad T = \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^n X_{ijk}, \quad (16)$$



$$SSFA = \frac{\sum_{i=1}^a T_{i.}^2}{bn} - \frac{T^2}{nab}, \quad SSFB = \frac{\sum_{j=1}^b T_{.j}^2}{an} - \frac{T^2}{nab}, \quad (17)$$

$$T_{i.} = \sum_{j=1}^b \sum_{k=1}^n X_{ijk}, \quad T_{.j} = \sum_{i=1}^a \sum_{k=1}^n X_{ijk}, \quad T_{ij} = \sum_{k=1}^n X_{ijk}, \quad (18)$$

$$SSAB = \frac{\sum_{i=1}^a \sum_{j=1}^b T_{ij}^2}{n} - \frac{T^2}{nab} - SSFA - SSFB, \\ SSE = SST - SSFA - SSFB - SSAB. \quad (19)$$



Jeigu pamatęs formulę nežinau, ką ji reiškia, – ji nieko negali manęs išmokyti. Jeigu aš jau žinau jos prasmę – ką gi iš jos išmokstu tada?

Šv. Augustinas

Šioje knygoje pateikėme formules, taikomas tik vienodo didumo imtims. Kai taip nėra, formulėse naudojamas harmoninis imčių didumų vidurkis. Dvifaktoris analizės modelį galima užrašyti ir tada, kai imčių didumai skiriasi, tačiau tuo atveju jis tampa labai gremėzdiškas. Šis modelis realizuotas statistiniuose paketuose.

3.4. Dvifaktoris dispersinės analizės taikymas

Atkreipiame dėmesį, kad dvifaktoris dispersinė analizė leidžia formuluoti tris statistines hipotezes: apie faktoriaus A įtaką, apie faktoriaus B įtaką ir apie faktorių A ir B tarpusavio sąveiką.

1 *Duomenys.* Turime $a \times b$ imčių po n elementų, gautų intervalų skalėje matuojant nepriklausomus vienodai pasiskirsčiusius kintamuosius $X_{ij} \sim \mathcal{N}(\mu_{ij}, \sigma^2)$, $i = 1, \dots, a$, $j = 1, \dots, b$. Nei vidurkiai μ_{ij} , nei dispersija σ^2 nežinomi. Duomenys pateikti 3.1 lentelė.

2 *Statistinės hipotezės.* Galima tikrinti šias statistines hipotezes:

$$\begin{cases} H_0: \mu_{1.} = \mu_{2.} = \dots = \mu_{a.}, \\ H_1: \text{bent du vidurkiai skiriasi.} \end{cases} \quad (\text{A})$$

Nulinė hipotezė H_0 reiškia, kad faktoriaus A įtakos nėra. Nulinę hipotezę galima užrašyti ir taip $H_0: \tau_{i.} = 0$, $i = 1, \dots, a$; čia $\tau_{i.}$ apibrėžta (3) lygybe.

$$\begin{cases} H_0: \mu_{.1} = \mu_{.2} = \dots = \mu_{.b}, \\ H_1: \text{bent du vidurkiai skiriasi.} \end{cases} \quad (\text{B})$$

Nulinė hipotezė H_0 reiškia, kad faktoriaus B įtakos nėra. Nulinę hipotezę galima užrašyti ir taip $H_0: \tau_{.j} = 0$, $j = 1, \dots, b$.

$$\begin{cases} H_0: \mu_{ij} - \mu_{i.} - \mu_{.j} + \mu = 0, \\ H_1: \mu_{ij} - \mu_{i.} - \mu_{.j} + \mu \neq 0. \end{cases} \quad (\text{A} \times \text{B})$$

Nulinė hipotezė H_0 reiškia, kad faktorių A ir B tarpusavio sąveikos nėra, H_1 – kad tarpusavio sąveika yra. Nulinę hipotezę galima užrašyti ir taip $H_0: \tau_{ij} = 0$, $i = 1, \dots, a$, $j = 1, \dots, b$.

3 *Kriterijų statistikos.* Pasinaudoję ankstesniojo skyrelio formulėmis, randame:

$$F_A = \frac{MSFA}{MSE}, \quad F_B = \frac{MSFB}{MSE}, \quad F_{AB} = \frac{MSAB}{MSE}. \quad (20)$$

Kai teisingos atitinkamos nulinės hipotezės, F_A turi Fišerio skirstinį su $(a - 1)$ ir $ab(n - 1)$ laisvės laipsnių; F_B turi Fišerio skirstinį su $(b - 1)$ ir $ab(n - 1)$ laisvės laipsnių; F_{AB} turi Fišerio skirstinį su $(a - 1)(b - 1)$ ir $ab(n - 1)$ laisvės laipsnių.

4 *Sprendimų priėmimo taisyklės.* Tegul reikšmingumo lygmuo lygus α . Uždavinio (A) hipotezė H_0 atmetama (bent dviejų pagal faktoriaus A reikšmes suskirstytų populiacijų kintamųjų vidurkiai statistiškai reikšmingai skiriasi, faktoriaus A įtaka yra), jeigu $F_A > F_\alpha(a - 1, ab(n - 1))$; čia $F_\alpha(a - 1, ab(n - 1))$ yra Fišerio skirstinio su $a - 1$ ir $ab(n - 1)$ laisvės laipsnių α lygmens kritinė reikšmė. Hipotezė H_0 neatmetama, jeigu $F_A \leq F_\alpha(a - 1, ab(n - 1))$.

Uždavinio (B) hipotezė H_0 atmetama (bent dviejų pagal faktoriaus B reikšmes suskirstytų populiacijų kintamųjų vidurkiai statistiškai reikšmingai skiriasi, faktoriaus B įtaka yra), jeigu $F_B > F_\alpha(b - 1, ab(n - 1))$. Hipotezė H_0 neatmetama, jeigu $F_B \leq F_\alpha(b - 1, ab(n - 1))$.

Uždavinio (A×B) hipotezė H_0 atmetama (faktorių A ir B tarpusavio sąveika yra), jeigu $F_{AB} > F_\alpha((a - 1)(b - 1), ab(n - 1))$. Hipotezė H_0 neatmetama (tarpusavio sąveikos nėra), jeigu $F_{AB} \leq F_\alpha((a - 1)(b - 1), ab(n - 1))$.

Dvifaktoriinės dispersinės analizės rezultatai paprastai pateikiami 3.2 lentelė.

3.2 lentelė. Dvifaktoriinės ANOVA rezultatai

	Kvadratų suma	Laisvės laipsniai	Dispersijos įverčiai	Statistika
Faktorius A	$SSFA$	$a - 1$	$MSFA$	F_A
Faktorius B	$SSFB$	$b - 1$	$MSFB$	F_B
Sąveika $A \times B$	$SSAB$	$(a - 1)(b - 1)$	$MSAB$	F_{AB}
Paklaida	SSE	$ab(n - 1)$	MSE	
Visa	SST	$abn - 1$		

3.1 pavyzdys. Sociologas tyrė gando įtikinamumo priklausomybę nuo gando skelbėjo lyties ir pareigų. Trisdešimt šešiose firmose buvo užfiksuota, koks procentas eilinių darbuotojų patikėjo gandu. Gandonešiai skyrėsi užimamomis pareigomis (eiliniai, skyrių viršininkai, direktoriaus pavaduotojai). Be to, pusė gandonešių buvo vyrai, o pusė – moterys. Duomenys pateikti 3.3 lentelėje. Ar vyrais ir moterimis vienodai tikima? Ar gando įtikinamumas priklauso nuo pareigų? Ar visų pareigybių vyrų ir moterų skelbiamų gandų įtikinamumo skirtumai vienodi? Tarkime, kad reikšmingumo lygmuo $\alpha = 0,05$.

3.3 lentelė. Gando įtikinamumas

Lytis	Pareigos						$T_{i.}$
	Eilinis		Skyriaus viršininkas		Direktoriaus pavaduotojas		
Vyr.	25	24	28	27	35	29	$T_{1.} = 512$
	26	23	31	29	30	32	
	25	25	30	30	31	32	
	$(T_{11} = 148)$		$(T_{12} = 175)$		$(T_{13} = 189)$		
Mot.	20	19	28	26	29	28	$T_{2.} = 460$
	18	20	27	28	33	30	
	17	19	27	27	30	34	
	$(T_{21} = 113)$		$(T_{22} = 163)$		$(T_{23} = 184)$		
$T_{.j}$	$T_{.1} = 261$		$T_{.2} = 338$		$T_{.3} = 373$		$T = 972$

Sprendimas. Pirmąjį klausimą galime performuluoti taip: ar vidutiniškai vienodai patikėta gandonešiais vyrais ir moterimis, t. y.

$$\begin{cases} H_0: \mu_{1.} = \mu_{2.}, \\ H_1: \mu_{1.} \neq \mu_{2.}. \end{cases} \quad (21)$$

Problema apie pareigų ir gando įtikinamumo priklausomybę užrašome taip:

$$\begin{cases} H_0: \mu_{.1} = \mu_{.2} = \mu_{.3}, \\ H_1: \text{bent du vidurkiai skiriasi.} \end{cases} \quad (22)$$

Skirtingų pareigybių moterų ir vyrų skelbiamų gandų įtikinamumo skirtumai rodo pareigų ir lyties tarpusavio sąveiką, t. y.

$$\begin{cases} H_0: \mu_{ij} - \mu_{i.} - \mu_{.j} + \mu = 0, & i = 1, 2; j = 1, 2, 3. \\ H_1: \mu_{ij} - \mu_{i.} - \mu_{.j} + \mu \neq 0, & \text{bent viena porai } i, j. \end{cases} \quad (23)$$

Turime du faktorius: lytį (A) ir pareigas (B). Tada $a = 2$, $b = 3$, $n = 6$. Norėdami patikrinti (21), (22) ir (23) hipotezes, apskaičiuojame:


$$\begin{aligned} SSFA &= \frac{512^2}{18} - \frac{972^2}{36} = 75,111, & SSFB &= \frac{261^2 + 338^2 + 373^2}{12} - \frac{972^2}{36} = 547,167, \\ SSAB &= 41,056, & SSE &= 74,667, & SST &= 738, \\ F_A &= 30,179, & F_B &= 109,922, & F_{AB} &= 8,248. \end{aligned} \quad (24)$$

Rezultatus surašome į 3.4 lentelę.

Iš priedo 4 lentelės randame $F_{0,05}(1, 30) = 4,171$, $F_{0,05}(2, 30) = 3,316$. Kadangi $F_A > 4,171$, $F_B > 3,316$, $F_{AB} > 3,316$, tai visos nulinės hipotezės H_0 atmetamos. Taigi gando įtikinamumas priklauso ir nuo sakančiojo lyties, ir nuo pareigų. Ką šiuo atveju reiškia lyties ir pareigų tarpusavio sąveika? Atidėkime vidurkių trendus, kaip parodyta 3.3 paveiksle.

3.4 lentelė. Dvifaktorinės ANOVA rezultatai

	Kvadratų suma	Laisvės laipsniai	Dispersijos įverčiai	Statistika
Lytis (A)	75,111	1	75,111	30,179
Pareigos (B)	547,167	2	273,583	109,922
Lytis $\times$ Pareigos	41,056	2	20,528	8,248
Paklaida	74,667	30	2,489	
Visa	738	35		



Iš brėžinio matyti, kad visada labiau tikima, kai gandą sako vyras. Be to, daugiau tikima aukštesnes pareigas užimančiaisiais. Tačiau skirtumai tarp vyrų ir moterų didžiausi, kai gandonešiai yra eiliniai, ir beveik išnyksta tarp direktorių pavaduotojų. Pastarasis vyrų ir moterų skirtumo mažėjimas, kintant pareigoms, žymi lyties ir pareigų tarpusavio sąveiką.

Dvifaktorisės dispersinės analizės taikymas naudojantis SPSS paketu. SPSS paketu galima patikrinti visas tris statistines hipotezes. Pateikiamas ANOVA 3.2 lentelės analogas. Tikslai prisideda stulpelis, kuriame nurodytos statistikų p -reikšmės. Kiekvienai statistinei hipotezei galioja ta pati sprendimo taisyklė.

Tegul reikšmingumo lygmuo lygus α , o p -reikšmė yra p . Tuomet nulinę hipotezę H_0 atmetame, jeigu $p < \alpha$;
priimame, jeigu $p \geq \alpha$.


Žinoma, reikia prisiminti, ką kokia nulinė hipotezė reiškia. Pavyzdžiui, tegul $\alpha = 0,05$. Jeigu faktorių A atitinkanti p -reikšmė $p < 0,05$, tai imtyse, sudarytose pagal A reikšmes, kintamųjų vidurkiai statistiškai reikšmingai skiriasi. Jeigu p -reikšmė ne mažesnė kaip $0,05$ – nesiskiria. Analogiškai sprendžiame apie faktorių B . Jeigu atitinkanti faktorių A ir B tarpusavio sąveiką p -reikšmė $p < 0,05$, tai tariame, kad faktorių tarpusavio sąveika yra. Priešingu atveju – nėra.

SPSS pakete dvifaktorisė dispersinė analizė pateikiama kaip atskiras vadinamojo *bendrojo tiesinio modelio* atvejis, todėl rezultatų lentelėje nurodyti atsakymai ir į kai kuriuos kitus statistinių hipotezių klausimus, pavyzdžiui, ar bendrasis visų imčių vidurkis statistiškai reikšmingai skiriasi nuo nulio. Išsamiau SPSS rezultatus aptarsime nagrinėdami 3.2 pavyzdį.

3.2 pavyzdys. Suvenyrais prekiaujanti firma tyrė skulptūrėlės „vanapaganas – trolio draugas“ paklausos priklausomybę nuo gaminio dydžio ir reklamos. Buvo gaminamos dviejų dydžių (bet vienodos kainos) skulptūrėlės – mažos ir didelės. Kiekviename suvenyrų kioske buvo prekiaujama tik vienos rūšies gaminiu. Be to, pusė visų kioskų buvo rajonuose, kuriuose gaminiai plačiai reklamuojami, o pusė – visai be reklamos. Duomenys apie vidutinį per dieną kioske parduotų suvenyrų skaičių pateikti 3.5 lentelėje. Reikia atsakyti, ar skirtingo didumo suvenyrai vienodai paklausūs? Ar reklama padidino paklausą? Ar reklama didelių ir mažų suvenyrų paklausą paveikė skirtingai? Tarkime, kad reikšmingumo lygmuo $\alpha = 0,05$.

3.5 lentelė. Suvenyrų paklausa

Didumas	Reklama										
	Yra						Nėra				
Maži	11	13	12	9	10	12	14	6	4	5	9
Dideli	9	11	8	7	5	12	11	1	0	4	5



Sprendimas. SPSS rezultatas pateiktas 3.4 paveiksle. Corrected Model yra visa kvadratų suma be paklaidos (t. y. $\text{Corrected Model} = SSFA + SSFB + SSAB$), Intercept atitinka statistinę hipotezę (kuri anksčiau nebuvo aptarta) apie bendrojo vidurkio lygybę nuliui. Kadangi visuose kioskuose buvo parduota nemažai suvenyrų, mums ši hipotezė neaktuali. Eilutės REKLAMA, DIDUMAS ir REKLAMA*DIDUMAS atitinka 3.2 lentelės eilutes ir duoda atsakymą apie reklamos įtaką, apie didumo įtaką ir apie reklamos ir didumo tarpusavio sąveiką. Šias hipotezes atitinkančios p -reikšmės pateiktos stulpelyje Sig. Eilutė Error atitinka paklaidos eilutę, Corrected Total – visą kvadratų sumą iš 3.2 lentelės. Total – tai SST su pridėta Intercept suma.

DESCRIPTIVE STATISTICS

Dependent Variable: KIEKIS


REKLAMA	DIDUMAS	Mean	Std. Deviation	N
1,00 Yra	1,00 Mažas	11,5714	1,7182	7
	2,00 Didelis	9,0000	2,5166	7
	Total	10,2857	2,4629	14
2,00 Nėra	1,00 Mažas	5,4286	1,9024	7
	2,00 Didelis	3,4286	2,2254	7
	Total	4,4286	2,2434	14
Total	1,00 Mažas	8,5000	3,6321	14
	2,00 Didelis	6,2143	3,6832	14
	Total	7,3571	3,7733	28

TESTS OF BETWEEN-SUBJECTS EFFECTS

Dependent Variable: KIEKIS

Source	Type III Sum of Squares	df	Mean Square	F	Sig.	Eta Squared
Corrected Model	277,286 ^a	3	92,429	20,704	,000	,721
Intercept	1515,517	1	1515,517	339,488	,000	,934
REKLAMA	240,143	1	240,143	53,792	,000	,691
DIDUMAS	36,571	1	36,571	8,192	,009	,254
REKLAMA*DIDUMAS	,571	1	,571	,128	,724	,005
Error	107,143	24	4,464			
Total	1900,000	28				
Corrected Total	384,429	27				

^a. R Squared = ,721 (Adjusted R Squared = ,686).**3.4 pav.** Dvifaktoriinės analizės SPSS rezultatai



Rezultatus lengviau interpretuoti iš 3.5 paveikslo, kur pateikti atskiri vidurkiai (t. y. $\bar{X}_1$, $\bar{X}_2$, $\bar{X}_{.1}$ ir $\bar{X}_{.2}$) bei vidurkių tendrų grafikas.

Atsakymą į klausimą, ar dideli ir maži suvenyrai vienodai paklausūs, randame eilutėje DIDUMAS. Kadangi atitinkama p -reikšmė yra $0,009 < 0,05$, tai darome išvadą, kad didelių ir mažų skulptūrėlių parduodama nevienodai (atitinkami vidurkiai statistiškai reikšmingai skiriasi). Iš 3.5 paveikslo matyti, kad paklausesni maži suvenyrai (vidutiniškai parduodama 8,5 mažų ir 6,284 didelių suvenyrų).

Atsakymą į klausimą, ar reklama padidina paklausą, randame eilutėje REKLAMA. Kadangi atitinkama p -reikšmė yra $0,000 < 0,05$, tai darome išvadą, kad vidutinis parduodamų reklamuojamų suvenyrų kiekis statistiškai reikšmingai skiriasi nuo vidutinio be reklamos parduodamų suvenyrų kiekio. Daugiau suvenyrų parduodama, kai reklama yra (vidutiniškai 10,286), nei kai jos nėra (vidutiniškai 4,429).

Ar reklama didelių ir mažų suvenyrų paklausą veikia skirtingai? Atsakymą į šį klausimą randame ištyrę reklamos ir gaminio didumo tarpusavio sąveiką. Kadangi atitinkama p -reikšmė yra $0,724 > 0,05$, tai darome išvadą, kad tarpusavio sąveikos nėra. Reklama vidutiniškai vienodai padidino ir mažų, ir didelių suvenyrų paklausą (žr. 3.5 pav. vidurkių tendrų grafiką).

Pažymėsime, kad SPSS pakete realizuota ir trifaktorinė analizė. Tuo atveju atsiranda daugiau tarpusavio sąveikų ir jas sunkiau interpretuoti.

3.5. Post hoc kriterijai

Nustatę, kad ne visų imčių vidurkiai lygūs, norime sužinoti, *kurių* imčių vidurkiai statistiškai reikšmingai skiriasi. Kaip ir vienfaktorinės dispersinės analizės atveju, tą padaryti padės *post hoc* kriterijai. Užrašysime, kaip taikyti Tjukio kriterijų, kai norima nustatyti, kurios iš skiriamų pagal požymį B populiacijų kintamieji turi nevienodus vidurkius.

1

Duomenys. Turime $a \times b$ imčių po n elementų, gautų intervalų skalėje matuojant nepriklausomus vienodai pasiskirsčiusius kintamuosius $X_{ij} \sim \mathcal{N}(\mu_{ij}, \sigma^2)$, $i = 1, \dots, a$, $j = 1, \dots, b$. Nei vidurkiai μ_{ij} , nei dispersija σ^2 nežinomi. Duomenys pateikti 3.1 lentelė. Remiantis dvifaktorine dispersine analize, nustatyta, kad tarp $\bar{X}_{.1}, \bar{X}_{.2}, \dots, \bar{X}_{.b}$ yra statistiškai reikšmingai besiskiriančių.

- 2** *Statistinės hipotezės.* Lyginame visas pagal faktorių B sudarytas imtis. Statistinės hipotezės atrodo taip:

$$\begin{cases} H_0: \mu_{\cdot k} = \mu_{\cdot j}, \\ H_1: \mu_{\cdot k} \neq \mu_{\cdot j}; \end{cases}$$

čia $k, j = 1, \dots, b, k \neq j$. Nulinė hipotezė H_0 reiškia, kad atitinkamų populiacijų kintamųjų vidurkiai nesiskiria.

- 3** *Kriterijaus statistikos.* Apskaičiuojame

$$T_B(k, j) = \frac{|\bar{X}_{\cdot k} - \bar{X}_{\cdot j}|}{\sqrt{MSE/(na)}}.$$

- 4** *Sprendimo priėmimo taisyklė.* Tegul reikšmingumo lygmuo lygus α . Nulinė hipotezė H_0 atmetama (lyginamieji vidurkiai statistiškai reikšmingai skiriasi), jeigu $T_B(k, j) > Q_\alpha(ab(n-1), b)$; čia $Q_\alpha(ab(n-1), b)$ yra Q -statistikos α lygmens kritinė reikšmė iš priedo 10 lentelės. Hipotezė H_0 neatmetama, jeigu $T_B \leq Q_\alpha(ab(n-1), b)$.

Analogiškai lyginami imčių, besiskiriančių pagal požymį A , vidurkiai. Tik hipotezei $H_0: \mu_i = \mu_l$ ir alternatyvai $H_1: \mu_i \neq \mu_l$ tikrinti naudojama statistika

$$T_A(i, l) = \frac{|\bar{X}_i - \bar{X}_l|}{\sqrt{MSE/(nb)}}.$$

Vidurkiai statistiškai reikšmingai skiriasi, jei $T_A(i, l) > Q_\alpha(ab(n-1), a)$.

Pastaba. *Post hoc* kriterijai taikomi tik tuomet, kai imčių yra ne mažiau kaip trys.

3.3 pavyzdys. Nustatysime, ar visų pareigybių gandonešiai vienodai įtikinamai skleidžia gandas. Tegul reikšmingumo lygmuo $\alpha = 0,05$. Randame: $MSE = 2,49$, $a = 2$, $b = 3$, $n = 6$, $\bar{X}_{\cdot 1} = 21,75$, $\bar{X}_{\cdot 2} = 28,17$, $\bar{X}_{\cdot 3} = 31,08$. Apskaičiuojame:

$$T_B(1, 2) = \frac{21,75 - 28,17}{\sqrt{2,49/12}} = 14,09, \quad T_B(1, 3) = 20,48, \quad T_B(2, 3) = 6,38.$$

Iš priedo 10 lentelės randame $Q_{0,05}(30, 3) = 3,49$. Kadangi visi T_B didesni už 3,49, tai visi vidurkiai statistiškai reikšmingai skiriasi. Vadinas, turintys skirtingas pareigas nevienodai įtikinamai skleidžia gandas.

Post hoc kriterijų taikymas naudojantis SPSS paketu. SPSS pakete yra keletas *post hoc* kriterijų, pateikiamų taip pat kaip ir vienfaktorinės dispersinės analizės atveju. Tjokio kriterijaus rezultatai 3.3 pavyzdžio atveju pateikti 3.6 paveiksle.

Vidurkiai statistiškai reikšmingai skiriasi, kai atitinkama p -reikšmė mažesnė už pasirinktąjį reikšmingumo lygmenį.

Statistiškai reikšmingi vidurkių skirtumai (kai $\alpha = 0,05$) pažymėti simboliu *. Beje, hipotezei apie vidurkių lygybę tikrinti galima naudoti ir pateikiamus pasikliautinuosius intervalus. Jeigu $\alpha = 0,05$ ir 0 nepatenka į pasikliautinąjį intervalą, sakome, kad vidurkiai skiriasi.

MULTIPLE COMPARISONS				
Dependent Variable: VAR00003 Tukey HSD				
(I) PAREIGOS	(J) PAREIGOS	Mean Difference (I-J)	Std. Error	Sig.
1,00 Eilinis	2,00 Vidurinė grandis	-6,4167*	,6441	,000
	3,00 Viršininkas	-9,3333*	,6441	,000
2,00 Vidurinė grandis	1,00 Eilinis	6,4167*	,6441	,000
	3,00 Viršininkas	-2,9167*	,6441	,000
3,00 Viršininkas	12,00 Eilinis	9,3333*	,6441	,000
	2,00 Viršininkas	2,9167*	,6441	,000

*. Based on observed means.

3.6 pav. Dvifaktoriinės ANOVA Tjukio kriterijus

3.6. Kintamųjų priklausomybės matai

Dvifaktoriinėje dispersinėje analizėje faktorių įtaka stebimajam kintamajam matuojama panašiai kaip ir vienfaktoriinėje ANOVA. Analogiška ir visų koeficientų interpretacija – kuo didesnis koeficientas, tuo didesnė atitinkamo faktoriaus įtaka matavimo rezultatui.

3.6.1. Koeficientas η^2

Jis skaičiuojamas ir interpretuojamas kaip ir 2.9 skyrelyje. Duomenų skirtumų, atsirandančių dėl faktoriaus (ar faktorių sąveikos) įtakos, kvadratų suma lyginama su visa kvadratų suma:

$$\eta_A^2 = \frac{SSFA}{SST}, \quad \eta_B^2 = \frac{SSFB}{SST}, \quad \eta_{AB}^2 = \frac{SSAB}{SST}. \quad (25)$$

3.4 pavyzdys. Raskime 3.1 pavyzdžio koeficientus:

$$\eta_A^2 = \frac{75,11}{738} = 0,10, \quad \eta_B^2 = \frac{547,16}{738} = 0,74, \quad \eta_{AB}^2 = \frac{41,05}{738} = 0,056.$$

Matome, kad, *palyginti su visomis įmanomomis įtakomis*, gando įtikinamumui gana didelę įtaką daro pareigos ir mažai įtakos turi lytis bei lyties ir pareigų tarpusavio sąveika.

3.6.2. Dalinis koeficientas $\tilde{\eta}^2$

Koeficientas η^2 leidžia palyginti visų faktorių įtaką gautiems rezultatams. Tačiau kartais mus domina kiekvieno faktoriaus įtaka, palyginti su atsitiktiniais „triukšmais“. Tuo atveju naudojamas *dalinis* η^2 (žymėsime jį $\tilde{\eta}^2$). Koeficientas $\tilde{\eta}^2$ lygina duomenų skirtumus, atsiradusius dėl faktoriaus įtakos, su skirtumais, kuriuos paaiškina atsitiktinė paklaida. Taigi koeficientas $\tilde{\eta}^2$ yra sąlyginis. Kuo jis didesnis, tuo faktoriaus įtaka rezultatams didesnė, *palyginti su skirtumais, atsirandančiais dėl imties atsitiktinumo*. Koeficientą $\tilde{\eta}^2$ skaičiuojame taip:

$$\tilde{\eta}_A^2 = \frac{SSFA}{SSFA + SSE}, \quad \tilde{\eta}_B^2 = \frac{SSFB}{SSFB + SSE}, \quad \tilde{\eta}_{AB}^2 = \frac{SSAB}{SSAB + SSE}. \quad (26)$$

3.5 pavyzdys. Raskime 3.1 pavyzdžio dalinius η^2 koeficientus:

$$\tilde{\eta}_A^2 = \frac{75,11}{75,11 + 74,66} = 0,50, \quad \tilde{\eta}_B^2 = \frac{547,16}{547,16 + 74,66} = 0,88, \quad \tilde{\eta}_{AB}^2 = \frac{41,05}{41,05 + 74,66} = 0,355.$$

Matome, kad, *palyginti su atsitiktine paklaida SSE*, gando įtikinamumui gana didelę įtaką daro pareigos, vidutinę – lytis; lyties ir pareigų tarpusavio sąveika silpna.

Koeficientas $\tilde{\eta}^2$ skaičiuojamas ir SPSS paketu (žr. 3.4 pav., grafą Eta Squared).

3.6.3. Koeficientas ω^2

Šis koeficientas rodo su faktoriumi susijusios matuojamojo kintamojo dispersijos ir bendrosios dispersijos santykį. Visa, kas pasakyta 2.9 skyrelyje apie ω^2 , tinka ir šiuo atveju. Faktorių dispersijų įverčius pažymėkime $\hat{\sigma}_A^2$, $\hat{\sigma}_B^2$, $\hat{\sigma}_{AB}^2$, $\hat{\sigma}_E^2$ ir $\hat{\sigma}_T^2 = \hat{\sigma}_A^2 + \hat{\sigma}_B^2 + \hat{\sigma}_{AB}^2 + \hat{\sigma}_E^2$. Tuomet $\omega_A^2 = \hat{\sigma}_A^2 / \hat{\sigma}_T^2$ ir t. t. Reikiamus dispersijų įverčius gauname iš (14) ir (15) formulių (primename, kad nagrinėjame pastovųjį modelį). Tada

$$MSFA = \hat{\sigma}_E^2 + \frac{nab}{a-1} \hat{\sigma}_A^2, \quad MSFB = \hat{\sigma}_E^2 + \frac{nab}{b-1} \hat{\sigma}_B^2,$$

$$MSAB = \hat{\sigma}_E^2 + \frac{nab}{(a-1)(b-1)} \hat{\sigma}_{AB}^2, \quad MSE = \hat{\sigma}_E^2.$$

Pasinaudoję šiomis formulėmis, nesunkiai gauname koeficientų ω^2 išraiškas:

$$\omega_A^2 = \frac{SSFA - MSE(a-1)}{SST + MSE}, \quad \omega_B^2 = \frac{SSFB - MSE(b-1)}{SST + MSE}, \quad (27)$$

$$\omega_{AB}^2 = \frac{SSAB - MSE(a-1)(b-1)}{SST + MSE}. \quad (28)$$

3.6 pavyzdys. Raskime 3.1 pavyzdžio ω^2 koeficientus:

$$\omega_A^2 = \frac{75,11 - 2,49}{738 + 2,49} = 0,09, \quad \omega_B^2 = \frac{547,16 - 2 \cdot 2,49}{738 + 2,49} = 0,73, \quad \omega_{AB}^2 = 0,05.$$

Palyginti su η^2 , koeficientas ω^2 mažesnis: $\omega^2 \leq \eta^2$.

3.6.4. Koreliacijos koeficientas ICC

Tarkime, kad stebimas atsitiktinis dvifaktorišės dispersinės analizės modelis (žr. 3.8 skyrelį). Tuomet

$$ICC_A = \frac{\hat{\sigma}_A^2}{\hat{\sigma}_T^2}, \quad ICC_B = \frac{\hat{\sigma}_B^2}{\hat{\sigma}_T^2}, \quad ICC_{AB} = \frac{\hat{\sigma}_{AB}^2}{\hat{\sigma}_T^2}; \quad (29)$$

čia

$$\begin{aligned} \hat{\sigma}_A^2 &= \frac{MSFA - MSAB}{nb}, & \hat{\sigma}_B^2 &= \frac{MSFB - MSAB}{na}, \\ \hat{\sigma}_{AB}^2 &= \frac{MSAB - MSE}{n}, & \hat{\sigma}_E^2 &= MSE, & \hat{\sigma}_T^2 &= \hat{\sigma}_A^2 + \hat{\sigma}_B^2 + \hat{\sigma}_{AB}^2 + \hat{\sigma}_E^2. \end{aligned}$$

3.7 pavyzdys. Raskime 3.1 pavyzdžio ICC koeficientus:

$$ICC_A = \frac{3,03}{29,607} = 0,10, \quad ICC_B = \frac{21,087}{29,607} = 0,71, \quad ICC_{AB} = \frac{3}{29,607}.$$

Matome, kad visi koeficientai η^2 , ω^2 , ICC tarpusavyje skiriasi visai nedaug.



Kai kurie autoriai siūlo naudoti dalinius ICC koeficientus (pažymėkime juos $\widetilde{ICC}$), kurie sudaromi panašiai kaip 2.9 skyrelyje:

$$\widetilde{ICC}_A = \frac{MSFA - MSE}{MSFA + (a - 1)MSE}, \quad \widetilde{ICC}_B = \frac{MSFB - MSE}{MSFB + (b - 1)MSE},$$

$$\widetilde{ICC}_{AB} = \frac{MSAB - MSE}{MSFA + (a - 1)(b - 1)MSE}.$$

Daliniai koreliacijos koeficientai panašūs į η^2 koeficientus ir interpretuojami analogiškai. Apskaičiuojame 3.1 pavyzdžio dalinius ICC:


$$\widetilde{ICC}_A = 0,94, \quad \widetilde{ICC}_B = 0,97, \quad \widetilde{ICC}_{AB} = 0,71.$$

3.7. Hipotezė apie vidurkių lygybę fiksavus vieną iš faktorių

Tarkime, kad viena grupė žmonių per TV žiūrėjo futbolo varžybas, o kita – laidą „Manikiūro paslaptys“. Kiekvienas žiūrovas pagal įdomumą laidą vertino balais (iki 20). Mus domina, ar abi laidos buvo vienodai populiarios? Ar vyrų ir moterų vertinimai skiriasi? Ar yra laidos ir žiūrėjo lyties tarpusavio sąveika? Tarkime, kad visi vyrai vienodai teigiamai įvertino futbolą ir neigiamai – laidą apie manikiūrą, o moterys taip pat kategoriškai pasielgė priešingai (vertinimų vidurkių trendai pavaizduoti 3.7 pav.).

Dvifaktorinė analizė mums pateikia netikėtas išvadas: ir vyrai, ir moterys žiūrėtas laidas vertino vidutiniškai vienodai; ir futbolą, ir manikiūras buvo vidutiniškai vienodai populiarius; yra laidos ir žiūrėjo lyties tarpusavio sąveika. Taip atsitiko todėl, kad kiek vyrai teigiamai vertino futbolą, tiek moterys jį vertino neigiamai, ir skaičiuojant vidurkius šie priešingi vertinimai vienas kitą kompensavo. Akivaizdu, kad minėtoje situacijoje tiksliau būtų iš pradžių ištirti vyrų ir moterų vertinimų skirtumus žiūrint futbolą, o po to – žiūrint laidą apie manikiūrą. Taigi reikia įvertinti lyčių (grupei, sudarytų pagal faktorių A), fiksavus laidą (faktoriaus B reikšmę), skirtumus.

Suformuluosime taisyklę, kaip patikrinti hipotezę apie atitinkamų vidurkių lygybę fiksavus B reikšmę.



1 *Duomenys.* Dvifaktorisės dispersinės analizės duomenys aprašyti 3.1 lentelė. Tarkime, kad faktoriaus B reikšmė fiksuota ir lygi j (t. y. lyginame tik j -ojo stulpelio imčių vidurkius).

2 *Statistinė hipotezė:*

$$\begin{cases} H_0: \mu_{1j} = \mu_{2j} = \dots = \mu_{aj}, \\ H_1: \text{bent du vidurkiai skiriasi.} \end{cases}$$

3 *Kriterijaus statistika.* Pasinaudoję 3.3 skyrelio formulėmis, randame

$$\begin{aligned} SSFA_j &= \frac{T_{1j}^2 + T_{2j}^2 + \dots + T_{aj}^2}{n} - \frac{T_{\cdot j}^2}{na}, \\ MSFA_j &= \frac{SSFA_j}{a-1}, \quad F_{Aj} = \frac{MSFA_j}{MSE}. \end{aligned} \quad (30)$$

4 *Sprendimo priėmimo taisyklė.* Tegul reikšmingumo lygmuo lygus α . Nulinė hipotezė H_0 atmetama (bent dviejų pagal faktoriaus A reikšmes suskirstytų populiacijų, kurioms $B = j$, kintamųjų vidurkiai statistiškai reikšmingai skiriasi), jeigu $F_{Aj} > F_\alpha(a-1, ab(n-1))$; čia $F_\alpha(a-1, ab(n-1))$ yra Fišerio skirstinio su $(a-1)$ ir $ab(n-1)$ laisvės laipsnių α lygmens kritinė reikšmė. Hipotezė H_0 neatmetama, jeigu $F_A \leq F_\alpha(a-1, ab(n-1))$.

Analogiškai tikrinama hipotezė apie vidurkių lygybę, kai fiksuota faktoriaus A reikšmė. Tarkime, $A = i$. Tuomet nulinė hipotezė $H_0: \mu_{i1} = \dots = \mu_{ib}$ atmetama, jeigu $F_{iB} > F_\alpha(b-1, ab(n-1))$; čia

$$F_{iB} = \frac{MSFB_i}{MSE}, \quad MSB_i = \frac{SSFB_i}{b-1}, \quad SSFB_i = \frac{T_{i1}^2 + T_{i2}^2 + \dots + T_{ib}^2}{n} - \frac{T_{i\cdot}^2}{nb}.$$

3.7 pavyzdys. Raskime 3.1 pavyzdžio skirtingas pareigas turinčių moterų skleidžiamų gandų įtaigumo skirtumus (t. y. $A = 2$). Statistinė hipotezė:

$$\begin{cases} H_0: \mu_{21} = \mu_{22} = \mu_{23}, \\ H_1: \text{bent du vidurkiai skiriasi.} \end{cases}$$

Pasinaudoję 3.1 pavyzdžio rezultatais, randame:

$$SSFB_2 = \frac{T_{21}^2 + T_{22}^2 + \dots + T_{23}^2}{6} - \frac{T_{2\cdot}^2}{18} = \frac{113^2 + 163^2 + 184^2}{6} = 443,44,$$

$$MSB_2 = 221,72, \quad F_{2B} = \frac{221,72}{2,489} = 89,08.$$

Kadangi $F_{2B} > 3,316 = F_{0,05}(2,30)$, tai nulinę hipotezę H_0 atmetame. Moterų skleidžiamų gandų įtaigumas priklauso nuo skleidžios užimamų pareigų.

3.8. Atsitiktiniai ir mišrieji modeliai

Iki šiol aptarėme pastovų ANOVA modelį, t. y. atvejį, kai naudojamos visos turimos imtys. Tačiau tyrimui imtys gali būti atsitiktinai parenkamos iš didesnės imčių aibės. Dvifaktorisinė dispersinė analizė imtys skiriamos pagal du požymius (faktorius A ir B). Jeigu tyrimui imama dalis (atsitiktinai parinktų) pagal požymį A besiskiriančių imčių ir dalis (atsitiktinai parinktų) pagal požymį B besiskiriančių imčių, gaunamas atsitiktinis modelis. Jeigu imtyse atspindėtos visos požymio A reikšmės (A fiksuotas) ir tik dalis B reikšmių, turime mišrųjį modelį. Mišrusis modelis yra ir tada, kai A reikšmės atsitiktinės, o B fiksuotos. Geriau šiuos modelius suprasime panagrinėję pavyzdį. Tarkime, tirdami vidutines respondentų išlaidas maistui Rytų Europos valstybėse, atsižvelgėme į respondento tautybę (faktorius A) ir profesiją (faktorius B). Tirdami visų tautybių ir visų profesijų atstovus, gausime pastovųjį modelį (A ir B fiksuoti). Jeigu tyrimui atsitiktinai parinksime keletą tautybių ir keletą profesijų, modelis bus atsitiktinis (A ir B atsitiktiniai). Jeigu tirsime visas tautybes, tačiau profesijas pasirinksime atsitiktinai, modelis bus mišrusis (A fiksuotas, B atsitiktinis). Jeigu tautybes parinksime atsitiktinai, o profesijas – ne, tai modelis bus mišrusis (A atsitiktinis, B fiksuotas).

Kiekvienam modeliui tikrinamos tos pačios 3.4 skyrelio hipotezės – (A), (B) ir ($A \times B$). Tačiau naudojamos skirtingos statistikos (žr. 3.6 lentelę).

Kada nulinė hipotezė atmetama? Nulinė hipotezė atmetama, kai $F > F_\alpha(s, v)$; čia $F_\alpha(s, v)$ yra Fišerio skirstinio su s ir v laisvės laipsnių α lygmens kritinė reikšmė, čia α yra pasirinktasis reikšmingumo lygmuo, s yra F formulės skaitiklio laisvės laipsnių skaičius, v yra F formulės vardiklio laisvės laipsnių skaičius (turima omenyje formulės iš 3.6 lentelės).

Kaip rasti s ir v ? Tarkime, tyrimui naudojami duomenys aprašyti 3.1 lentele. Tuomet $MSFA$, $MSFB$, $MSAB$ ir MSE turi atitinkamai $a - 1$, $b - 1$, $(a - 1)(b - 1)$ ir $ab(n - 1)$ laisvės laipsnių.

Pavyzdžiui, norėdami patikrinti atsitiktinio modelio hipotezę, kad pagal faktorių skiriamų A populiacijų kintamųjų vidurkiai skiriasi (hipotezė (A)), turėtume apskaičiuoti $F = MSFA/MSAB$. Vidurkius laikome skirtingais, jeigu $F > F_\alpha(a - 1, (a - 1)(b - 1))$.

3.6 lentelė. Dvifaktorisinės ANOVA statistikos

Statistinė hipotezė	Modelis			
	Pastovusis A ir B fiksuoti	Atsitiktinis A ir B atsitiktiniai	Mišrusis A fiksuotas, B atsitiktinis	Mišrusis A atsitiktinis, B fiksuotas
(A)	$F = \frac{MSFA}{MSE}$	$F = \frac{MSFA}{MSAB}$	$F = \frac{MSFA}{MSE}$	$F = \frac{MSFA}{MSAB}$
(B)	$F = \frac{MSFB}{MSE}$	$F = \frac{MSFB}{MSAB}$	$F = \frac{MSFB}{MSAB}$	$F = \frac{MSFB}{MSE}$
(A $\times$ B)	$F = \frac{MSAB}{MSE}$	$F = \frac{MSAB}{MSE}$	$F = \frac{MSAB}{MSE}$	$F = \frac{MSAB}{MSE}$



atsitiktinis modelis
dalinis η^2

faktorių tarpusavio sąveika
koeficientas ω^2

koeficientas η^2
mišrusis modelis

UŽDAVINIAI

1. Sąvoka „brangus“ neretai asocijuojasi su sąvoka „geras“. Penkiasdešimt keturi tiriamieji buvo suskirstyti į tris grupes: valstiečius, verslininkus ir inteligentus. Kiekvienam tiriamajam buvo parodytas *tas pats* abstraktus paveikslas. Kartu buvo pasakoma viena iš trijų tariamų paveikslų kainų: maža, vidutinė arba didelė. Tiriamasis turėjo balais (iki 100) įvertinti paveikslą. Ar skirtingų profesijų atstovai vienodai vertina abstraktųjį meną? Ar paveikslų kaina turi įtakos vertinimams? Ar kainos didėjimas vienodai paveikė visų profesijų atstovų nuomonę? Reikšmingumo lygmuo $\alpha = 0,05$, duomenys yra 3.7 lentelėje.

3.7 lentelė. Paveikslų vertinimai

Grupė	Kaina											
	Maža						Vidutinė					
Valstiečiai	52	50	48	51	53	52	55	63	52	64	59	62
Verslininkai	47	45	45	44	46	43	65	56	66	57	69	60
Inteligentai	56	60	58	61	57	62	70	75	71	74	72	75
	73	73	69	76	72	70						

2. Chemijos laboratorija išbandė tris valiklius. Kiekvienu iš jų buvo valomos keturių rūšių dėmės (purvo, riebalų, vyno, rašalo). Stebėta, per kiek sekundžių dėmė išnyksta. Bandymas buvo pakartotas keturis kartus. Ką galima pasakyti apie valiklių efektyvumą? Reikšmingumo lygmuo $\alpha = 0,1$. Duomenys pateikti 3.8 lentelėje.

3.8 lentelė

Valiklis	Dėmės rūšis											
	Purvo				Riebalų				Vyno			
I	12	10	9	11	13	13	14	14	18	18	19	17
II	12	11	10	12	14	15	14	15	18	17	17	16
III	8	9	9	10	16	13	15	14	17	18	18	19
	25	26	17	25	20	21	22	22	24	23	23	25

3. Norėdamas nustatyti, ar įvairių kursų studentų požiūris į dėstytojus skiriasi, sociologas įvairių specialybių studentų paprašė įvertinti (parašyti pažymį) paskutinės sesijos egzaminatorių objektyvumą. Ar visų kursų studentai vienodai vertina dėstytojų objektyvumą? Ar visų specialybių studentai vienodai vertina dėstytojų objektyvumą? Ar skirtingų kursų studentų požiūrio į dėstytojus skirtumams turi įtakos specialybė? Tarkime, reikšmingumo lygmuo $\alpha = 0,05$. Duomenys pateikti 3.9 lentelėje.

3.9 lentelė

Fakultetas	Kursas											
	Pirmas				Antras				Trečias			
Filologijos	1	1	2	5	4	3	4	3	7	6	5	8
	1	2	3	2	3	5	4	4	6	7	4	5
Matematikos	3	5	4	2	7	6	7	7	8	8	10	9
	1	2	3	1	7	6	7	6	7	8	8	9
Ekonomikos	3	2	5	6	4	6	7	5	7	6	7	6
	1	4	2	1	5	5	4	6	6	6	7	8
	8	8	7	9	8	8	7	9	8	8	7	9

4. Dvidešimt reguliariai alų geriančių ir dvidešimt retkarčiais išgeriančių studentų dalyvavo eksperimente. Specialiu prietaisu buvo matuojamas jų reakcijos greitis (sekundėmis). Prieš eksperimentą studentams buvo papasakota apie biržietiško alaus gamybos subtilybes (pabrėžiant jo stiprumą) ir pasakyta, kad reklamos tikslais firma „Biržapilis“ studentus nemokamai vaišina alumi. Po to 20 studentų buvo pasiūlyta po didelį bokalą stipraus biržietiško alaus, kiti gavo to paties skonio ir kvapo bealkoholinio pakaitalo. Studentų reakcijos greičio matavimo rezultatai pateikti 3.10 lentelėje. Ar alus lėtina reakciją? Ar reguliariai išgeriantys yra lėtesnės reakcijos? Ką alus paveikė stipriau – reguliarius ar neregulius gėrėjus? Tarkime, reikšmingumo lygmuo $\alpha = 0,05$.

3.10 lentelė. Alus ir reakcijos greitis

	Reguliarūs gėrėjai										Nereguliarūs gėrėjai									
Gavo alaus	17	18	18	19	17	20	18	19	19	20	13	15	14	14	12	16	14	14	12	13
Gavo pakaitalo	13	15	16	14	15	16	15	14	16	15	15	14	16	13	12	13	13	14	12	13

5. Norėdami ištirti dviejų rūšių trąšų efektyvumą, agronomai jomis patyrė po penkis trijų skirtingų dirvožemių sklypelius. Gauti kviečių derliai (centneriais) pateikti 3.11 lentelėje. Ar trąšos vienodai efektyvios? Ar visi dirvožemiai vienodai derlingi? Ar kurios nors trąšos pasirodė itin tinkamos konkrečiam dirvožemiui? Reikšmingumo lygmuo $\alpha = 0,05$.

3.11 lentelė. Trąšos ir derlingumas

Trąša	Dirvožemis														
	A					B					C				
I	32	34	33	32	33	26	30	28	29	30	20	23	22	21	23
II	35	39	36	37	38	33	30	32	31	32	24	27	25	26	24

4. BLOKUOTŲJŲ DUOMENŲ DISPERSINĖ ANALIZĖ



Manipuliavimas statistikos formulėmis negali būti žinojimo, ką darome, pakaitalas.

H. M. Blalokas

Prieš pradėdama naujų sportinių batelių gamybą, firma „Septynmylis“ nutarė išbandyti tris naujus modelius. Kaip greitai avint naujuosius batelius galima nubėgti 1 km, padės nustatyti grupė atsitiktinai parinktų bėgikų. Kaip suplanuoti eksperimentą ir analizuoti duomenis? Galima bėgikus suskirstyti į tris grupes skirtingų modelių batams bandyti. Tuomet lyginant bėgimo laikus galima naudotis vienfaktorine dispersine analize. Tačiau bėgikai skiriasi vienas nuo kito. Geras bėgikas ir su netikusiais bateliais gali bėgti greičiau nei blogas geras. Todėl natūraliau būtų, jei kiekvienas bėgikas išbandytų visų trijų modelių batelius. Taip suplanuotas eksperimentas leidžia iš tyrimo pašalinti individualius bėgikų skirtumus. Šiame skyriuje išsiaiškinsime, kaip modifikuoti dispersinės analizės modelį, kad jis tiktų ir tokiai situacijai.

4.1. Blokuotieji duomenys

Blokuotųjų duomenų dispersinė analizė yra Stjudento kriterijaus priklausomoms imtims apibendrinimas didesniai imčių skaičiui. Neparametrinis šios analizės analogas yra Frydmano kriterijus. Porinio Stjudento kriterijaus atveju duomenis sudaro stebėjimų poros $(x_1, y_2), (x_2, y_2), \dots, (x_n, y_n)$. Apibendrinami tarkime, kad duomenis sudaro b -mačiai stebėjimų vektoriai (vadinamieji *duomenų blokai*): $(x_{11}, x_{12}, \dots, x_{1b}), (x_{21}, x_{22}, \dots, x_{2b}), \dots, (x_{n1}, x_{n2}, \dots, x_{nb})$.

Blokuotieji duomenys dažniausiai atsiranda tokiose situacijose, kai tų pačių objektų tiriamą požymį matuojame keletą kartų. Pavyzdžiui:

- matuojame ligonio kraujospūdį prieš gydymą, iškart po gydymo, po pusmečio ir po metų;
- stebime, kaip kinta studento IQ pereinant iš vieno kurso į kitą;
- dvidešimt kompiuterinių žaidimų ekspertų balais vertina tris naujus žaidimus;
- tie patys tiriamieji bando keturias stabdžių sistemas (fiksuojuame stabdymo laiką) ir pan.

Duomenų bloką sudaro visi vieno tiriamojo požymių matavimai. Blokų gaunama tiek, kiek ir tiriamųjų. Pavyzdžiui, surinkę ekspertų nuomones apie žaidimus, gauname dvidešimt blokų.

Tiriamieji matuojami skirtingomis sąlygomis. Pavyzdžiui: prieš gydymą ir po gydymo; bandant vienus stabdžius, bandant kitus stabdžius ir pan. Skiriamos dvi situacijos – kai matavimo sąlygos keičiasi pagal griežtai nustatytą tvarką ir kai sąlygų keitimo tvarką galima parinkti. Matuodami kraujospūdį, neturime jokios galimybės sukeisti matavimų tvarkos – matuojame kraujospūdį iki gydymo ir po jo. Tuo tarpu, kai bandomos stabdžių sistemos, vieni bandymus gali pradėti nuo vienos sistemos, o kiti nuo kitos.

Šiame skyriuje tarsime, kad sąlygų keitimo tvarka subalansuota, t. y. vieni tyrimą pradeda vienomis sąlygomis, kiti – kitomis. Numatytos visos įmanomos sąlygų keitimo

tvarkos, o koks tiriamasis ir kokia tvarka turi keisti sąlygas, nusprendžiama atsitiktinai. Pavyzdžiui, sudarome visas žaidimų keitimo tvarkas (žaidimas A , po to B , C ; B , po to A , C ; C , A , B ir t. t.). Atsitiktinai suskirstome tiriamuosius į panašaus didumo grupes. Pirmoji grupė žaidžia A , po to B ir C , antroji – B , A , C ir t. t. Gautų duomenų struktūra vadinama *randomizuotąja* blokine. Kodėl duomenys randomizuojami? Taip išvengiama situacijos, kai sąlygų keitimo tvarka daro įtaką galutiniams rezultatams. Pavyzdžiui, žaidimas „Skerdyklė“, žaidžiamas paskutinis, gali gauti žemesnį įvertinimą vien todėl, kad žaidėjas jau būna persisotinęs virtualių šaudymų, sprogdinimų ir kraujo klanų. Jei visi žaidimai sužaisti paskutiniai vienodą skaičių kartų, dėl žaidimo tvarkos atsiradę vertinimų skirtumai vienas kitą kompensuoja.

Blokuotųjų duomenų dispersinė analizė tinka ne vien pakartotiniams matavimams. Svarbu tik, kad bloką sudarančius duomenis vienyty kokia nors bendra informacija. Pavyzdžiui, taikant Stjudento porinį kriterijų (žr. [1], 3.4.6 pavyzdį) duomenų blokai (kavinių pirmadienio pelnas, antradienio pelnas ir t. t.) atsirado dėl to, kad skirtingomis savaitės dienomis kavinės lankomos nevienodai. Šios knygos 1 skyriaus 1.5 pavyzdyje blokai yra kirpyklos, 1.12 pavyzdyje – baigti fakultetai.

4.2. Blokuotųjų duomenų vienfaktorinės dispersinės analizės modelis ir prielaidos



Visi modeliai neteisingi, kai kurie iš jų naudingi.

Dž. Boksas

Tarkime, tą patį intervalinį kintamąjį matuojame skirtingomis sąlygomis. Kintamąjį, pamatuotą pirmomis sąlygomis, žymėsime X_1 , antrosiomis – X_2 ir t. t. Kartais dėl trumpumo tiesiog sakysime, kad kiekvieną iš b kintamųjų $X_1, \dots, X_b$ pamatavome n kartų. Gautas imtys surašytos 4.1 lentelės stulpeliuose. Blokuotųjų duomenų struktūra pateikta 4.1 paveiksle. Vienas blokas (eilutė) nepriklauso nuo kito. Pavyzdžiui, $(X_{11}, X_{12}, \dots, X_{1b})$ nepriklauso nuo $(X_{21}, X_{22}, \dots, X_{2b})$.


Struktūrinis dispersinės analizės modelis j -osios imties i -ajam stebėjimui X_{ij} (i -ojo tiriamojo rezultatu, esant j -osioms sąlygoms) užrašomas taip:

$$X_{ij} = \mu + \tau_j + \pi_i + e_{ij}; \quad (1)$$

čia μ yra bendrasis visų kintamųjų vidurkis, t. y. $\mu = (\mu_1 + \dots + \mu_b)/b$, $\mu_j = \mathbf{E}X_j$; $\tau_j = \mu_j - \mu$ atskleidžia j -ųjų sąlygų įtaką rezultatui; π_i parodo i -ojo tiriamojo (bloko) įtaką; e_{ij} – atsitiktinė paklaida.

4.1 lentelė. Blokuotieji duomenys

X_1	X_2	X_3	...	X_b
X_{11}	X_{12}	X_{13}	...	X_{1b}
X_{21}	X_{22}	X_{23}	...	X_{2b}
X_{31}	X_{32}	X_{33}	...	X_{3b}
...	...	...	...	...
X_{n1}	X_{n2}	X_{n3}	...	X_{nb}



Lygindami (1) formulę su vienfaktorinės ANOVA modeliu (žr. 2.8 skyrelį), matome, kad (1) lygybėje atsižvelgta į papildomą informaciją – blokų įtaką.

Prisiminkime praėjusiame skyrelyje minėtus kompiuterinių žaidimų ekspertų vertinimus. Duomenis sudaro trys stulpeliai (vienas stulpelis vienam žaidimui) ir dvidešimt eilučių-blokų (viena eilutė vienam ekspertui). Kiekvieno eksperto vertinimus lemia bendras vidutinis visų ekspertų požiūris į žaidimus (μ), pačių ekspertų skirtumai (pvz., vieni ekspertai gali būti labai griežti, kiti geranoriški – visa tai atskleidžia dydis π_i), žaidimų skirtumai (τ_j) ir liekamoji atsitiktinė paklaida e_{ij} .



Nesunku patikrinti, kad (1) formulė atitinka dvifaktorinės dispersinės analizės be tarpusavio sąveikos modelį. Blokuotųjų duomenų dispersinė analizė sutampa su dvifaktoria ANOVA, kai kiekviena imtis sudaryta tik iš vieno stebėjimo.

Blokuotųjų duomenų ANOVA prielaidos daug kuo panašios į vienfaktorinės dispersinės analizės prielaidas, aprašytas 2.3 skyrelyje.

Blokuotųjų duomenų modelio prielaidos:

- 1) kintamieji X_j normalieji;
- 2) kintamųjų X_j dispersijos lygios;
- 3) kintamųjų skirtumų $X_j - X_i$ ir $X_k - X_l$ dispersijos lygios ($i \neq j, k \neq l$).

Pirmosios dvi prielaidos buvo jau ne kartą aptartos (žr., pvz., 2.3 skyrelį), pakomentuosime tik trečiąją prielaidą. Mus domina sąlygų skirtumai. Todėl lyginame rezultatų, gautų vienomis ir kitomis sąlygomis, *skirtumus*. Trečioji prielaida reikalauja, kad visi šie skirtumai turėtų tą pačią dispersiją. Tarkime, vertindamas žaidimus, pirmasis ekspertas pirmąjį, antrąjį ir trečiąjį žaidimus įvertino atitinkamai 15, 13 ir 18 balų. Tegul antrojo eksperto vertinimai yra 5, 3 ir 8 balai. Aišku, kad pirmasis ekspertas daug geranoriškesnis už antrąjį. Tačiau mus domina, ką galima pasakyti apie pačius žaidimus. Matome, kad abu ekspertai pirmąjį žaidimą įvertino 2 balais palankiau už antrąjį ir 3 balais blogiau nei trečiąjį, t. y. vertinimų *skirtumai* visiškai identiški. Šie vertinimų skirtumai leidžia spėti, kad geriausias buvo trečiasis žaidimas, o prasčiausias – antrasis. Išvadas darome pagal rezultatų skirtumus. Norėdami įvertinti galimą imčių atsitiktinumą, reikalaujame, kad minėtų skirtumų dispersijos būtų vienodos.

Antroji ir trečioji sąlygos dar vadinamos sferiškumo prielaidomis. Matematiškai antrąją ir trečiąją prielaidas galima suformuluoti taip:



Sudarome visų įmanomų X_j ir X_k kovariacijų matricą. Antroji prielaida reikalauja, kad visi pagrindinės įstrižinės elementai būtų lygūs (šių įstrižainę sudaro X_j dispersijos). Trečioji prielaida reikalauja, kad visi likusieji elementai (visos X_j ir X_k , $j \neq k$, koreliacijos) būtų lygūs, bet nebūtinai sutaptų su įstrižinės elementais.

Yra keletas kriterijų, pagal kuriuos tikrinamas kovariacijų matricos sferiškumas.

Analizės rezultatai ganėtinai jautrūs trečiosios prielaidos pažeidimui. Jeigu trečioji prielaida netenkinama, naudojamos specialios pataisos. Išsamiau šią problemą panagrinėsime kalbėdami apie SPSS rezultatus.

4.3. Stebėjimo duomenų struktūra

Šiame skyrelyje aptarsime, kaip sudaromas kriterijus skirtingų imčių vidurkiams palyginti. Kaip ir nepriklausomų imčių atveju, kriterijaus statistika grindžiama dispersijų įverčių santykiu.

Iš pradžių paanalizuosime duomenų skirtumų struktūrą. Tarkime, tenkinamos visos ankstesniajame skyrelyje suformuluotos prielaidos, o duomenys pateikti 4.1 lentelė.

Žymėsime: X_{ij} – i -ąją j -osios imties elementą; $\bar{X}_{i.}$ – i -osios eilutės vidurkį; $\bar{X}_{.j}$ – j -ojo stulpelio (j -osios imties) vidurkį; $\bar{X}$ – bendrąjį vidurkį; n – eilučių (blokų) skaičių; b – stulpelių (imčių) skaičius. Tada:

$$\bar{X}_{.j} = \frac{\sum_{i=1}^n X_{ij}}{n}, \quad \bar{X}_{i.} = \frac{\sum_{j=1}^b X_{ij}}{b}, \quad \bar{X} = \frac{\sum_{i=1}^n \sum_{j=1}^b X_{ij}}{nb}. \quad (2)$$

Užrašysime (1) formulės empirinį analogą:

$$X_{ij} - \bar{X} = (\bar{X}_{i.} - \bar{X}) + (\bar{X}_{.j} - \bar{X}) + (X_{ij} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X}). \quad (3)$$

Pakėlę (3) formulės abi puses kvadratu, sudėję pagal visus elementus ir suprastinę panašiuosius narius, gauname:

$$SST = SSBL + SSSTR + SSE. \quad (4)$$

Čia


$$SST = \sum_{i=1}^n \sum_{j=1}^b (X_{ij} - \bar{X})^2, \quad SSBL = b \sum_{i=1}^n (\bar{X}_{i.} - \bar{X})^2, \quad (5)$$

$$SSSTR = n \sum_{j=1}^b (\bar{X}_{.j} - \bar{X})^2, \quad SSE = SST - SSSTR - SSBL. \quad (6)$$

Kiekvienas (4) lygybės dėmuo turi savo pavadinimą. SST , apimantis visų duomenų ir bendrojo vidurkio skirtumus, vadinamas *visa kvadratų suma*. Matome, kad ši suma skyla į tris komponentes. Pirmoji komponentė $SSBL$ įvertina blokų (tiriamųjų) įtaką ir vadinama *blokų kvadratų suma*. Analogiškai $SSSTR$ yra eksperimento *sąlygų kvadratų suma*, SSE – *paklaidos kvadratų suma*. Trumpai tariant, sumą, kuri įvertina visų duomenų sklaidą, išskaidėme į sudėtinės dalis: sklaidas, kurioms įtakos turi atitinkamai imčių vidurkių skirtumai, blokinė struktūra ir atsitiktinumas (žr. 4.2 pav.).



Palyginę (4) ir 2 skyriaus (8) formules, matome, kad $SSSTR$ atitinka vienfaktorinės ANOVA komponentę SSB . Tuo tarpu vietoje bendrosios paklaidos SSW turime dviejų komponentių $SSBL$ ir SSE sumą. Taigi, atsižvelgdami į blokinę struktūrą, sumažiname atsitiktinę paklaidą. Tai leidžia padidinti naudojamo kriterijaus galią.



4.2 lentelė

	Kvadratų suma	Laisvės laipsniai	Dispersijos įverčiai	Statistika
Sąlygų	$SSTR$	$b - 1$	$MSTR$	F
Blokų	$SSBL$	$n - 1$	$MSBL$	
Paklaidos	SSE	$(b-1)(n-1)$	MSE	
Visa	SST	$bn - 1$		

Blokuotųjų duomenų dispersinė analizė grindžiama dviejų dispersijos įverčių palyginimu. Vienas įvertis gaunamas sunormavus SSE , kitas – $SSTR$. Tegul

$$MSE = \frac{SSE}{(b-1)(n-1)}, \quad MSTR = \frac{SSTR}{b-1}; \quad (7)$$

Be to, skaičiuojami

$$MSBL = \frac{SSBL}{n-1}, \quad F = \frac{MSTR}{MSE}. \quad (8)$$

Jeigu nulinė ANOVA hipotezė teisinga (visų b populiacijų vidurkiai lygūs), tai F turi Fišerio skirstinį su $b-1$ ir $(b-1)(n-1)$ laisvės laipsnių. Remiantis šiuo faktu, kiekvienam reikšmingumo lygmeniui sudaromos kritinės sritys. Rezultatai paprastai pateikiami 4.2 lentelė.

Skaičiuoti patogiau pagal tokias formules:

$$SST = \sum_{i=1}^n \sum_{j=1}^b X_{ij}^2 - \frac{T^2}{nb}, \quad T = \sum_{i=1}^n \sum_{j=1}^b X_{ij}, \quad (9)$$

$$SSBL = \frac{\sum_{i=1}^n T_{i\cdot}^2}{b} - \frac{T^2}{nb}, \quad SSTR = \frac{\sum_{j=1}^b T_{\cdot j}^2}{n} - \frac{T^2}{nb}, \quad (10)$$

$$T_{i\cdot} = \sum_{j=1}^b X_{ij}, \quad T_{\cdot j} = \sum_{i=1}^n X_{ij}, \quad SSE = SST - SSTR - SSBL. \quad (11)$$

Kaip matyti iš (9)–(11) formulių, T yra visų duomenų suma, $T_{i\cdot}$ – i -osios eilutės duomenų suma, o $T_{\cdot j}$ – j -ojo stulpelio duomenų suma, n – eilučių skaičius, b – stulpelių skaičius. Kaip tikrinama hipotezė apie vidurkių lygybę, parodysime kitame skyrelyje.

4.4. Kriterijaus taikymas



Biologas daug kartų plaukė į jūrą ir tyrė tinklu sugautus gyvius. Daugkartinių pakartotinių matavimų rezultatai leido padaryti tokią išvadą: visi jūros gyventojai turi plaukmenis ir yra ne mažesni kaip 1 cm.

Ankstesniame skyrelyje išdėstyta teorija leidžia suformuluoti tokias blokuotųjų duomenų tyrimo taisykles.

1 *Duomenys.* Turime b imčių, gautų matuojant pagal intervalų skalę priklausomus normaliuosius, tenkinančius sferiškumo sąlygą, kintamuosius $X_1 \sim \mathcal{N}(\mu_1, \sigma^2)$, $X_2 \sim \mathcal{N}(\mu_2, \sigma^2), \dots, X_b \sim \mathcal{N}(\mu_b, \sigma^2)$. Nei vidurkiai $\mu_1, \dots, \mu_b$, nei dispersijos σ^2 , nei kovariacijos $\text{cov}(X_i, X_j)$ nežinomos. Gautųjų duomenų struktūra yra blokinė, aprašyta 4.2 skyrelyje ir pateikta 4.1 lentelė.

2 *Statistinė hipotezė:*

$$\begin{cases} H_0: \mu_1 = \mu_2 = \dots = \mu_b, \\ H_1: \text{bent du vidurkiai skiriasi.} \end{cases} \quad (12)$$

3 *Kriterijaus statistika.* Apskaičiuojame F pagal (8) formulę.

4 *Sprendimo priėmimo taisyklė.* Tegul reikšmingumo lygmuo lygus α . Hipotezė H_0 atmetama (bent du vidurkiai statistiškai reikšmingai skiriasi, jeigu $F > F_\alpha(b-1, (b-1)(n-1))$; čia $F_\alpha(b-1, (b-1)(n-1))$ yra Fišerio skirstinio su $b-1$ ir $(b-1)(n-1)$ laisvės laipsnių α lygmens kritinė reikšmė. Hipotezė H_0 neatmetama (sakome, kad vidurkių skirtumo nėra), jeigu $F \leq F_\alpha(b-1, (b-1)(n-1))$.

4.1 pavyzdys. Septyni ekspertai vertino lietuvišką, japonišką ir amerikietišką mažo galingumo traktorių (atsižvelgė į valdymo patogumą, kainą, eksploatacijos brangumą ir pan.) Ar duomenys, pateikti 4.3 lentelėje, leidžia teigti, kad ne visi traktoriai vienodai geri? Reikšmingumo lygmuo $\alpha = 0,05$. Tegul $\mu_j, j = 1, 2, 3$, yra vidutiniai traktorių vertinimo balai (žinome tik apytiksles šių vidurkių reikšmes – imčių vidurkių $\bar{x}_j$.) Nagrinėjamojo pavyzdžio statistinės hipotezės formuluotė sutampa su (12). Žodžiais ją galima nusakyti taip:

$$\begin{cases} H_0: \text{visų traktorių vidutiniai vertinimai nesiskiria,} \\ H_1: \text{bent dviejų traktorių vertinimai skiriasi.} \end{cases}$$

Pagal (7)–(11) formules apskaičiuojame:

$$SST = 6220 - \frac{344^2}{21} = 584,95, \quad SSTR = \frac{90^2 + 129^2 + 125^2}{7} - \frac{344^2}{21} = 131,52,$$

$$SSBL = \frac{54^2 + \dots + 55^2}{3} - \frac{344^2}{21} = 192,95, \quad SSE = 584,95 - 131,52 - 192,95 = 260,48.$$

4.3 lentelė. Traktorių vertinimai

Ekspertai	Traktoriai			T_i
	Lietuviškas	Japoniškas	Amerikietiškas	
a	16	20	18	54
b	20	22	21	63
c	10	20	15	45
d	5	15	25	45
e	10	10	12	32
f	19	17	14	50
g	10	25	20	55
T_i	90	129	125	$T = 344$
$\bar{x}_i$	12,86	18,43	17,86	$\bar{x} = 16,38$
$\sum x_{ij}^2$	1342	2523	2355	$\sum x_{ij}^2 = 6220$

Taigi

$$MSTR = \frac{131,52}{2} = 65,76, \quad MSE = \frac{260,48}{12} = 21,71,$$

$$MSBL = \frac{192,95}{6} = 32,16, \quad F = \frac{131,52}{21,71} = 3,03.$$

Gauti rezultatai dispersinei analizei įprastu pavidalu pateikti 4.4 lentelėje.

4.4 lentelė. Traktorių vertinimų rezultatai

	Kvadratų suma	Laisvės laipsniai	Dispersijos įverčiai	Statistika
Sąlygų	131,52	2	65,76	3,03
Blokų	192,95	6	32,16	
Paklaidos	260,48	12	21,71	
Visa	584,95	20		

Kadangi $F = 3,03 < 3,88 = F_{0,05}(2,12)$, tai nėra pagrindo nulinės hipotezės atmesti. Turimi duomenys neleidžia teigti, kad traktoriai vertinami skirtingai.

Pastaba. Jeigu $b = 2$ (lyginame tik dvi imtis), tai blokuotųjų duomenų ANOVA ekvivalenti Stjudento poriniam kriterijui. Statistika F lygi Stjudento t statistikos kvadratai. *Blokuotųjų duomenų vienfaktorinė dispersinė analizė naudojantis SPSS paketu.* Atliekant dispersinę analizę, sprendimas priimamas pagal pateikiamą p -reikšmę.

Tikrinama hipotezė

$$\begin{cases} H_0: \mu_1 = \mu_2 = \dots = \mu_k, \\ H_1: \text{ bent du vidurkiai skiriasi.} \end{cases}$$

Kaip priimti sprendimą atsižvelgiant į p -reikšmę?

Tegul reikšmingumo lygmuo lygus α . Tuomet:

H_0 atmetama, jeigu $p < \alpha$.

H_0 neatmetama, jeigu $p \geq \alpha$.

Pastaba. Pažymėtina, kad SPSS paketu papildomai tikrinama sferiškumo hipotezė (žr. 4.2 skyrelį). Jeigu ši hipotezė atmetama (atitinkama p -reikšmė mažesnė už reikšmingumo lygmenį), tai atsakymo apie vidurkių lygybę reikia ieškoti žiūrint į pataisyta kriterijų atitinkančią p -reikšmę. Dažniausiai SPSS paketu pateikiamas truputį lakoniškesnis 4.2 lentelės variantas, kuriame apsiribojama sumų $SSTR$ ir SSE eilutėmis, tačiau kartu pateikiami net keli atsakymai, kai sferiškumo prielaida netenkinama.

4.2 pavyzdys. Tarkime, kad dvidešimties kompiuterinių žaidimų ekspertų nuomonė apie tris naujus žaidimus pateikta 4.5 lentelėje. Ar visi trys žaidimai buvo įvertinti vienodai gerai? Nulinė hipotezė H_0 : visų trijų žaidimų vidutiniai vertinimai vienodi. Alternatyva H_1 : ne visų žaidimų vidutiniai vertinimai vienodi. Tegul reikšmingumo lygmuo $\alpha = 0,05$.

SPSS paketo rezultatai pateikti 4.3 paveiksle. Pirmoje a) lentelėje yra visų trijų žaidimų vidurkiai (15,3; 12,10 ir 15,0) ir standartiniai nuokrypiai. Matome, kad imčių vidurkiai skiriasi. Tačiau ar šis skirtumas statistiškai reikšmingas? Antroje b) lentelėje Močlio¹ kriterijumi tikrinama sferiškumo prielaida (apie ją žr. 4.2 skyrelį). Kadangi p -reikšmė (ji yra stulpelyje Sig.) lygi 0,29, t. y. didesnė už reikšmingumo lygmenį 0,05, tai galima teigti, kad sferiškumo prielaida tenkinama. Priešingu atveju reiktų naudotis pataisomis. Trečioje c) lentelėje pateikti sąlygų eilutės Žaidimas 4 variantai ir paklaidos eilutės Error (Žaidimas) 4 variantai.

¹ John William Mauchly (1907–1980) – amerikiečių fizikas, vadovavęs IBM.

DESCRIPTIVE STATISTICS

	Mean	Std. Deviation	N
ŽAID1	15,3000	4,1562	20
ŽAID2	12,1000	3,9457	20
ŽAID3	15,0000	4,1675	20

a)

MAUCHLY'S TEST OF SPHERICITY

Measure: MEASURE_1

Within Subjects Effect	Mauchly's W	Approx. Chi-Square	df	Sig.	Epsilon		
					Greenhouse-Geisser	Huynh-Feldt	Lower-bound
ŽAIDIMAS	,872	2,474	2	,290	,886	,971	,500

b)


TEST OF WITHIN-SUBJECTS EFFECTS

Measure: MEASURE_1

Source		Type III Sum of Squares	df	Mean Square	F	Sig.
ŽAIDIMAS	Sphericity Assumed	124,933	2	62,467	24,795	,000
	Greenhouse-Geisser	124,933	1,772	70,488	24,795	,000
	Huynh-Feldt	124,933	1,942	64,348	24,795	,000
	Lower-bound	124,933	1,000	124,933	24,795	,000
Error (ŽAIDIMAS)	Sphericity Assumed	95,733	38	2,519		
	Greenhouse-Geisser	95,733	33,676	2,843		
	Huynh-Feldt	95,733	36,889	2,595		
	Lower-bound	95,733	19,000	5,039		

c)

Estimate Marginal Means of MEASURE_1



d)

4.3 pav. Blokuotųjų duomenų vienfaktorinės dispersinės analizės SPSS rezultatai

4.5 lentelė. Ekspertų vertinimai

Ekspertas	Žaidimas			Ekspertas	Žaidimas		
	1	2	3		1	2	3
I	15	13	10	XI	17	10	16
II	8	6	11	XII	19	15	18
III	20	18	20	XIII	16	16	19
IV	17	12	17	XIV	8	6	9
V	11	7	8	XV	19	12	20
VI	15	11	17	XVI	14	13	12
VII	19	18	17	XVII	18	15	19
VIII	16	10	13	XVIII	6	5	7
IX	18	14	18	XIX	17	15	17
X	20	16	18	XX	13	10	14

Viršutinės eilutės Sphericity Assumed atitinka mūsų nagrinėjamą atvejį, kai sferiškumo prielaida tenkinama. Randame atitinkamą statistikos reikšmę $F = 24,795$ ir p -reikšmę stulpelyje Sig. $p = 0,00$. Kadangi p -reikšmė mažesnė už reikšmingumo lygmenį $\alpha = 0,05$, tai nulinė hipotezė H_0 apie vidurkių lygybę atmetama. Ne visi žaidimai buvo vienodai gerai įvertinti.

Ką reiktų daryti, jeigu sferiškumo hipotezė būtų nepasitvirtinusi? Tuo atveju reiktų naudotis viena iš trijų SPSS siūlomų pataisų: Grynhauso–Geiserio, Hjuino–Feldto¹ arba apatinio režio. Jų p -reikšmės taip pat pateiktos c) lentelėje.

Kartu 4.3 paveiksle, d) pateikiamas SPSS paketu gautas vertinimų vidurkių tendrų grafikas. Matome, kad blogiausiai buvo įvertintas antrasis žaidimas.

4.5. Blokuotųjų duomenų ANOVA *post hoc* kriterijai

Kaip ir kitais dispersinės analizės atvejais, nustatyti, *kurių* imčių vidurkiai statistiškai reikšmingai skiriasi, padeda *post hoc* kriterijai. Užrašysime, kaip taikyti Tjukio kriterijų.

1 *Duomenys.* Turime b imčių po n elementų, gautų pagal intervalų skalę matuojant priklausomus, sferiškumo sąlygą tenkinančius kintamuosius $X_j \sim \mathcal{N}(\mu_j, \sigma^2)$, $j = 1, \dots, b$. Nei vidurkiai μ_j , nei dispersija σ^2 nežinomi. Duomenys pateikti 4.1 lentelė. Dispersinė analizė parodė, kad tarp $\bar{X}_{.1}, \bar{X}_{.2}, \dots, \bar{X}_{.b}$ yra statistiškai reikšmingai besiskiriančių.

2 *Statistinės hipotezės.* Poromis lyginame visas imtis. Statistinės hipotezės atrodo taip:

$$\begin{cases} H_0: \mu_k = \mu_j, \\ H_1: \mu_k \neq \mu_j; \end{cases}$$

čia $k, j = 1, \dots, b, k \neq j$. Nulinė hipotezė H_0 reiškia, kad atitinkamų populiacijų kintamųjų vidurkiai nesiskiria.

3 *Kriterijaus statistikos.* Apskaičiuojame

$$T(k, j) = \frac{|\bar{X}_k - \bar{X}_j|}{\sqrt{MSE/(n)}}.$$

¹ S. W. Greenhouse, S. Geisser, H. Huynh, L. S. Feldt – amerikiečių statistikai.

- 4** *Sprendimo priėmimo taisyklė.* Tegul reikšmingumo lygmuo lygus α . Nulinė hipotezė H_0 atmetama (lyginamieji vidurkiai statistiškai reikšmingai skiriasi), jeigu $T(k, j) > Q_\alpha((b-1)(n-1), b)$; čia $Q_\alpha((b-1)(n-1), b)$ yra Q -statistikos α lygmens kritinė reikšmė iš priedo 11 lentelės. Hipotezė H_0 neatmetama, jeigu $T_B \leq Q_\alpha((b-1)(n-1), b)$.

Pastaba. *Post hoc* kriterijai taikomi tik tuomet, kai imčių yra ne mažiau kaip trys.

4.3 pavyzdys. Nustatykime, ar 4.2 pavyzdžio visų žaidimų įvertinimai skiriasi. Tegul reikšmingumo lygmuo $\alpha = 0,05$. Žinome, kad $\bar{X}_1 = 15,3$, $\bar{X}_2 = 12,1$, $\bar{X}_3 = 15,0$, $MSE = 2,519$, $n = 20$ (žr. 4.3 pav., a). Todėl

$$T(1, 2) = 9,02, \quad T(1, 3) = 0,845, \quad T(2, 3) = 8,17. \quad (13)$$

Kadangi $Q_{0,05}(38, 3) = 3,4$, tai vidutinis antrojo žaidimo įvertinimas skiriasi nuo pirmojo ir trečiojo žaidimų vidutinių įvertinimų. Tuo tarpu tarp vidutinių pirmojo ir trečiojo žaidimų įvertinimų statistiškai reikšmingo skirtumo nėra.

Post hoc kriterijų taikymas naudojantis SPSS paketu. SPSS pakete yra keletas *post hoc* kriterijų, kurie pateikiami taip pat kaip vienfaktorinės dispersinės analizės atveju. Nagrinėto 4.2 pavyzdžio Bonferonio kriterijaus rezultatai pateikti 4.4 paveiksle.

PAIRWISE COMPARISONS						
Measure: MEASURE_1						
(I) ŽAIDIMAS (J) ŽAIDIMAS		Mean Difference (I-J)	Std. Error	Sig. ^a	95% Confidence Interval	
					Lower Bound	Upper Bound
1	2	3,200*	,445	,000	2,032	4,368
	3	,3000	,465	1,000	-,921	1,521
2	1	-3,200*	,445	,000	-4,368	-2,032
	3	-2,900*	,584	,000	-4,434	-1,366
3	1	-,300	,465	1,000	-1,521	,921
	2	2,900*	,584	,000	1,366	4,434

Based on estimated marginal means.
 *. The mean difference is significant at the ,05 level.
 a. Adjustment for multiple comparisons: Bonferroni.

4.4 pav. Bonferonio kriterijus

Vidurkiai statistiškai reikšmingai skiriasi, kai atitinkama p -reikšmė mažesnė už pasirinktąjį reikšmingumo lygmenį.

Statistiškai reikšmingi vidurkių skirtumai (kai $\alpha = 0,05$) pažymėti simboliu *. Matome, kad ir Bonferonio kriterijus leidžia teigti, kad antrojo žaidimo įvertinimų vidurkis skiriasi nuo abiejų kitų įvertinimų vidurkių. Tuo tarpu vidutinių pirmojo ir trečiojo žaidimų įvertinimų skirtumas statistiškai nereikšmingas.

4.6. Koeficientas η^2

Į klausimą, kaip matuojamo kintamojo reikšmė priklauso nuo to, kokiomis sąlygomis buvo matuojama, padeda atsakyti koeficientas η^2 . Jis interpretuojamas analogiškai vienfakto-

rinės ANOVA atvejui, t. y. kuo didesnis koeficientas, tuo didesnė sąlygų įtaka matavimo rezultatui. Koeficientą η^2 skaičiuojame taip:

$$\eta^2 = \frac{SSTR}{SSTR + SSE}. \quad (14)$$

4.4 pavyzdys. Raskime 4.2 pavyzdžio η^2 koeficientą. Kadangi $SSTR = 124,933$, $SSE = 95,733$, tai

$$\eta^2 = \frac{124,933}{124,933 + 95,733} = 0,566.$$

Matome, kad, *palyginti su atsitiktine paklaida SSE*, įvertinimui gana didelę įtaką daro žaidimo rūšis.

Koeficientas η^2 skaičiuojamas ir SPSS paketu.

4.7. Blokuotųjų duomenų dvifaktorisės dispersinės analizės modelis



Epidemiologijoje statistiniai modeliai kartais suprantami neteisingai. Statistiniai modeliai niekada neatitinka duomenų. Klausimas, ar modelis teisingas, nesvarbus. Aktualesnis klausimas būtų, ar galima gauti teisingą mokslinę išvadą, tarus, kad tiriamasis procesas elgiasi pagal konkretų statistinį modelį.

S. Zegeris, *Amer. J. Epidemiology*, 1991

Blokuotųjų duomenų struktūra gali būti daug sudėtingesnė nei aptartoji ankstesniuose skyreliuose.

Išsamiau panagrinėsime tik vieną dažnai pasitaikančią situaciją, primenančią dvifaktorisę ANOVA. Beje, statistiniais paketais galima ištirti ir daug sudėtingesnės struktūros duomenis.

4.7.1. Duomenų struktūra

Tarkime, turime a nepriklausomų grupių po n tiriamųjų. Kiekvienas tiriamasis buvo pakartotinai matuotas (testuotas, apklaustas) po b kartų vis kitomis sąlygomis. Mus domina

4.6 lentelė. Priklausomų imčių duomenys

A	B			
	1	2	...	b
1	X_{111}	X_{121}	...	X_{1b1}
	X_{112}	X_{122}	...	X_{1b2}
	...	...	...	...
	X_{11n}	X_{12n}	...	X_{1bn}
2	X_{211}	X_{221}	...	X_{2b1}
	X_{212}	X_{222}	...	X_{2b2}
	...	...	...	...
	X_{21n}	X_{22n}	...	X_{2bn}
...	...	...	...	...
a	X_{a11}	X_{a21}	...	X_{ab1}
	X_{a12}	X_{a22}	...	X_{ab2}
	...	...	...	...
	X_{a1n}	X_{a2n}	...	X_{abn}

ne tik matavimo sąlygų įtaka rezultatui, bet ir tai, ar skirtingų grupių rezultatai skiriasi, be to, ar yra priklausymo konkrečiai grupei ir tyrimo sąlygų tarpusavio sąveika (pvz., ar matuojant antrą kartą kurios nors grupės tiriamųjų rezultatų pokytis didesnis nei kitos grupės). Kaip matome, situacija labai primena dvifaktoriinę dispersinę analizę, tačiau ne visi kintamieji nepriklausomi. Kiekvieno tiriamojo duomenys sudaro duomenų bloką (taigi blokų yra tiek, kiek ir tiriamųjų – $a \times n$). Blokai nepriklausomi, tačiau duomenys bloko viduje gauti matuojant priklausomus kintamuosius. Tarkime, kad duomenys pateikti 4.6 lentelė. Tuomet visos eilutės (duomenų blokai) yra nepriklausomos, o stulpeliai – priklausomi. Skirtingai nuo vienfaktoriinės blokuotųjų duomenų analizės, čia yra ne viena duomenų blokų grupė, o a grupių, suskirstytų pagal požymį A .

Pavyzdžiui, minėtą blokuotųjų duomenų struktūrą gauname:

- Tirdami efektyvumą dviejų metodų, taikytų aukštą kraujospūdį turintiems ligoniams gydyti. Kiekvieno ligonio pakartotiniai kraujospūdžio matavimai sudaro duomenų bloką. Pagal taikytą metodą duomenų blokai skiriami į dvi grupes.
- Tirdami studentų matematikų ir humanitarų IQ kitimą pereinant iš kurso į kursą ir norėdami nustatyti jų skirtumus. Kiekvieno tiriamojo IQ duomenys sudaro rezultatų bloką. Pagal studijų pobūdį tiriamieji skiriami į dvi grupes.
- Žaidimų vertintojus pagal amžių suskirstę į paauglius, jaunuolius bei vyresnius ir bandydami nustatyti, kuris žaidimas labiausiai atitinka paauglių mentalitetą.
- Stabdžių bandytojus suskirstę į autobusų vairuotojus, taksi vairuotojus ir vairuotojus mėgėjus.

Aptarsime, kokias sąlygas turi tenkinti duomenys. Duomenų priklausomybę jau aptarėme anksčiau. Kaip visuomet tariame, kad to, kq kiekvienam tiriamajam matuojame (kraujospūdžio, IQ, stabdymo laiko ir pan.), skirstinys yra normalusis, t. y. tenkinama normalumo prielaida. Kiti reikalavimai formuluojami kintamųjų dispersijoms. Reikalaujama, kad visų a nepriklausomų duomenų grupių dispersijos būtų lygios. Kiekvienai iš šių grupių turi galioti sferiškumo prielaida. Be to, reikalaujama, kad visų grupių apskaičiuotos stulpelių kovariacijų matricos sutaptų. Matome, kad duomenims keliami gana griežti reikalavimai, tačiau, kaip ir kitais dispersinės analizės atvejais, galimi nedideli nukrypimai.

4.7.2. Blokuotųjų duomenų dvifaktoriinės dispersinės analizės taikymas

Kaip ir nepriklausomų duomenų dvifaktoriinės dispersinės analizės atveju, suformuluosime tris statistines hipotezes: apie grupės (faktoriaus A) įtaką rezultatams, apie sąlygų (faktoriaus B) įtaką ir apie faktorių A ir B tarpusavio sąveikos poveikį.

1 *Duomenys.* Jie yra 4.7.1 skyrelyje aprašytos blokinės struktūros ir pateikti 4.6 lentelė. Visos anksčiau minėtos prielaidos tenkinamos.

2 *Statistinės hipotezės.* Galima tikrinti šias statistines hipotezes:

$$\begin{cases} H_0: \mu_{1.} = \mu_{2.} = \dots = \mu_{a.}, \\ H_1: \text{ bent du vidurkiai skiriasi.} \end{cases} \quad (A)$$

Nulinė hipotezė H_0 teigia, kad visų grupių vidutiniai matavimų rezultatai vienodi.

$$\begin{cases} H_0: \mu_{.1} = \mu_{.2} = \dots = \mu_{.b}, \\ H_1: \text{bent du vidurkiai skiriasi.} \end{cases} \quad (\text{B})$$

Nulinė hipotezė H_0 reiškia, kad visomis sąlygomis pakartotinai matuojant vidutiniai matavimų rezultatai nesiskiria.

$$\begin{cases} H_0: A \text{ ir } B \text{ tarpusavio sąveikos nėra,} \\ H_1: A \text{ ir } B \text{ tarpusavio sąveika yra.} \end{cases} \quad (A \times B)$$

3 *Kriterijų statistikos.* Visiškai analogiškai dvifaktoringei dispersinei analizei pasinaudoję 3 skyriaus (16)–(19) formulėmis, randame SST , $SSFA$, $SSFB$ ir $SSAB$. Kaip ir vienfaktorinės analizės atveju, randame blokų kvadratų sumą. Ją patogiausia skaičiuoti pagal tokią formulę:

$$SSBL = \frac{\sum_{i=1}^a \sum_{k=1}^n \left(\sum_{j=1}^b X_{ijk} \right)^2}{b} - \frac{T^2}{nab}.$$

Sąlygas ir paklaidas atitinkančias sumas skaičiuojame pagal tokias formules:

$$SSTR = SST - SSBL, \quad SSAE = SSBL - SSFA,$$

$$SSBE = SSTR - SSFB - SSAB.$$

Su kiekviena kvadratų suma siejamas tam tikras skaičius (paprastai lygus sumuojamų narių skaičiui atėmus vieneta), vadinamas laisvės laipsniu. Padaliję kvadratų sumas iš atitinkamų laisvės laipsnių, gauname suvidurkintas kvadratų sumas:

$$MSFA = \frac{SSFA}{a-1}, \quad MSFB = \frac{SSFB}{b-1}, \quad MSAB = \frac{SSAB}{(a-1)(b-1)}, \quad (15)$$

$$MSAE = \frac{SSAE}{a(n-1)}, \quad MSBE = \frac{SSBE}{a(n-1)(b-1)}. \quad (16)$$

Hipotezėms tikrinti naudosimės tokiomis statistikomis:

$$F_A = \frac{MSFA}{MSAE}, \quad F_B = \frac{MSFB}{MSBE}, \quad F_{AB} = \frac{MSAB}{MSBE}. \quad (17)$$

Kai teisingos atitinkamos nulinės hipotezės, F_A , F_B ir F_{AB} skirstiniai yra Fišerio.

4 *Sprendimų priėmimo taisyklės.* Tegul reikšmingumo lygmuo lygus α . Uždavinio (A) hipotezė H_0 atmetama (bent dviejų grupių vidurkiai statistiškai reikšmingai skiriasi, faktoriaus A įtaka yra), jeigu $F_A > F_\alpha(a-1, a(n-1))$; čia $F_\alpha(a-1, a(n-1))$ yra Fišerio skirstinio su $a-1$ ir $a(n-1)$ laisvės laipsnių α lygmens kritinė reikšmė. Hipotezė H_0 neatmetama, jeigu $F_A \leq F_\alpha(a-1, a(n-1))$.

Uždavinio (B) hipotezė H_0 atmetama (bent dviem sąlygomis matuotų rezultatų vidurkiai statistiškai reikšmingai skiriasi, faktoriaus B įtaka yra), jeigu $F_B > F_\alpha(b-1, a(n-1)(b-1))$. Hipotezė H_0 neatmetama, jeigu $F_B \leq F_\alpha(b-1, a(n-1)(b-1))$. Uždavinio ($A \times B$) hipotezė H_0 atmetama (faktorių A ir B tarpusavio sąveika yra), jeigu $F_{AB} > F_\alpha((a-1)(b-1), a(n-1)(b-1))$. Hipotezė H_0 neatmetama (tarpusavio sąveikos nėra), jeigu $F_{AB} \leq F_\alpha((a-1)(b-1), a(n-1)(b-1))$.

Dvifaktorisės dispersinės analizės rezultatai paprastai pateikiami 4.7 lentelė.

4.7 lentelė. Struktūrinių duomenų dvifaktorisės ANOVA rezultatai

	Kvadratų suma	Laisvės laipsniai	Dispersijos įverčiai	Statistika
Blokų	$SSBL$	$an - 1$		
Faktoriaus A	$SSFA$	$a - 1$	$MSFA$	F_A
A paklaidos	$SSAE$	$a(n - 1)$	$MSAE$	
Sąlygų	$SSTR$	$an(b - 1)$		
Faktoriaus B	$SSFB$	$b - 1$	$MSFB$	F_B
Sąveika $A \times B$	$SSAB$	$(a - 1)(b - 1)$	$MSAB$	F_{AB}
B paklaidos	$SSBE$	$a(n - 1)(b - 1)$	$MSBE$	
Visa	SST	$abn - 1$		

Pastaba. Formules (15)–(17) pateikėme tik tuo atveju, kai visose grupėse tiriamųjų buvo po lygiai (n). Statistiniuose paketuose numatytas ir nevienodo didumo grupių dispersinės analizės atvejis.

Pastebėsime, kad tiriamieji gali būti ir prekių didumai, automobilių rūšys ir pan. Sąlygos gali reikšti skirtingus gaminius, skirtingą matavimo laiką ir kt.

4.5 pavyzdys. Norėdama nustebinti NATO ekspertus, vienos šalies gynybos ministerija nusprendė paruošti lankininkų būrį. Vienas iš reikalavimų šio dalinio kariams yra mokėti šaudyti iš lanko naktį. Po apmokymo į taikinius iš lankų šaudė trijų grupių kariai. Kiekvienos grupės karius apmokė skirtingi seržantai. Kiekvienas karys išbandė indėniškąjį (I), mongoliškąjį (M) ir patbulintąjį (su optiniu naktinio matymo taikikliu, P) lankus. Surinkti taškai pateikti 4.8 lentelėje. Ar galima teigti, kad skirtingų grupių karių taiklumas skiriasi? Ar galima teigti, kad ne iš visų lankų vienodai gerai pataikoma? Ką dar galima pasakyti apie seržantų darbą? Tegul reikšmingumo lygmuo $\alpha = 0,05$.

Turime tris grupes (A) ir tris lankus (B). Patikrinsime hipotezes apie grupių, lankų ir jų tarpusavio sąveikos skirtumus. Apskaičiuojame:

$$SSFA = \frac{589^2 + 573^2 + 501^2}{18} - \frac{1663^2}{54} = 244,15, \quad SSFB = \frac{523^2 + 512^2 + 628^2}{18} - \frac{1663^2}{54} = 455,59,$$

$$SST = (33^2 + \dots + 35^2) - \frac{1663^2}{54} = 850,76,$$

$$SSAB = \frac{190^2 + \dots + 207^2}{6} - \frac{1663^2}{54} - SSFA - SSFB = 92,85,$$

$$SSBL = \frac{98^2 + \dots + 85^2}{3} - \frac{1663^2}{54} = 259,43, \quad SSTR = 850,76 - 259,43 = 591,33,$$

$$SSAE = 259,43 - 244,15 = 15,28, \quad SSBE = 591,33 - 455,59 - 92,85 = 42,89,$$

$$MSFA = \frac{244,15}{2} = 122,075, \quad MSFB = \frac{455,59}{2} = 227,795, \quad MSAB = \frac{92,85}{4} = 23,21,$$

$$MSAE = \frac{15,28}{15} = 1,028, \quad MSBE = \frac{42,89}{30} = 1,43,$$

4.8 lentelė. Šaudymo iš lanko rezultatai

Grupė	Lankas			Suma	T_i
	I	M	P		
1	33	30	35	98	$T_1 = 589$
	32	31	34	97	
	33	32	35	100	
	32	30	36	98	
	33	31	36	100	
	27	32	37	96	
	$(T_{11} = 190)$	$(T_{12} = 186)$	$(T_{13} = 213)$		
2	31	31	35	97	$T_2 = 573$
	36	32	34	96	
	29	30	35	94	
	31	31	34	96	
	31	30	35	96	
	30	29	35	94	
	$(T_{21} = 182)$	$(T_{22} = 183)$	$(T_{23} = 208)$		
3	25	24	34	83	$T_3 = 501$
	24	23	33	80	
	26	24	36	86	
	25	25	35	85	
	25	23	34	82	
	26	24	35	85	
	$(T_{31} = 151)$	$(T_{32} = 143)$	$(T_{33} = 207)$		
$T_{.j}$	$T_{.1} = 523$	$T_{.2} = 512$	$T_{.3} = 628$		$T = 1663$

$$F_A = \frac{122,075}{1,028} = 119,92, \quad F_B = \frac{227,795}{1,43} = 159,297, \quad F_{AB} = \frac{23,21}{1,43} = 16,23.$$

Rezultatus surašome į 4.9 lentelę.

4.9 lentelė. Šaudymo iš lanko rezultatų ANOVA lentelė

	Kvadratų suma	Laisvės laipsniai	Dispersijos įverčiai	Statistika
Blokų	259,43	17		
Grupės A	244,15	2	122,075	119,92
A paklaidos	15,28	15	1,028	
Sąlygų	591,33	36		
Lanko B	455,59	2	227,795	159,297
Sąveikos $A \times B$	92,85	4	23,21	16,23
B paklaidos	42,89	30	1,43	
Visa	850,76	53		

Kadangi $F_A > 3,68 = F_{0,05}(2,15)$, tai grupių pataikymų vidurkiai statistiškai reikšmingai skiriasi. Ne visos grupės vienodai gerai šaudė.

Kadangi $F_B > 3,32 = F_{0,05}(2,30)$, tai matome, kad šaudant skirtingais lankais, taiklumas statistiškai reikšmingai skiriasi.

Kadangi $F_{AB} > 2,69 = F_{0,05}(4,30)$, tai darome išvadą, kad faktorių tarpusavio sąveika yra – keičiant lankus, grupių taiklumas kito nevienodai.

Žinoma, dar reiktų atsakyti į klausimus, kuri grupė šaudė geriausiai, kaip kito grupių taiklumas ir pan. Tam reiktų *post hoc* kriterijų. Čia jų neapibrėšime. Pažymėsime, kad jie yra statistiniuose paketuose ir interpretuojami visiškai analogiškai ankstesniems atvejams.

Kiekvieno požymio daroma įtaka matyti iš koeficientų η^2 . Jie apibrėžiami taip:

$$\eta_A^2 = \frac{SSFA}{SSFA + SSAE}, \quad \eta_B^2 = \frac{SSFB}{SSFB + SSBE}, \quad \eta_{AB}^2 = \frac{SSAB}{SSAB + SSBE}.$$

MAUCHLY'S TEST OF SPHERICITY

Measure: MEASURE_1

Within Subjects Effect	Mauchly's W	Approx. Chi-Square	df	Sig.	Epsilon		
					Greenhouse-Geisser	Huynh-Feldt	Lower-bound
LANKAS	,752	3,986	2	,136	,801	1,000	,500

TEST OF WITHIN-SUBJECTS EFFECTS

Measure: MEASURE_1

Source		Type III Sum of Squares	df	Mean Square	F	Sig.	Eta Squared
LANKAS	Sphericity Assumed	455,593	2	227,796	159,339	,000	,914
	Greenhouse-Geisser	455,593	1,603	284,232	159,339	,000	,914
	Huynh-Feldt	455,593	2,000	227,796	159,339	,000	,914
	Lower-bound	455,593	1,000	455,593	159,339	,000	,914
LANKAS* GRUPE	Sphericity Assumed	92,852	4	23,213	16,237	,000	,684
	Greenhouse-Geisser	92,852	3,206	28,964	16,237	,000	,684
	Huynh-Feldt	92,852	4,000	23,213	16,237	,000	,684
	Lower-bound	92,852	2,000	46,426	16,237	,000	,684
Error (LANKAS)	Sphericity Assumed	42,889	30	1,430			
	Greenhouse-Geisser	42,889	24,043	1,784			
	Huynh-Feldt	42,889	30,000	1,430			
	Lower-bound	42,889	15,000	2,859			

TEST OF BETWEEN-SUBJECTS EFFECTS

Measure: MEASURE_1

Transformed Variable: Average

Source	Type III Sum of Squares	df	Mean Square	F	Sig.	Eta Squared
Intercept	51214,241	1	51214,241	50283,073	,000	1,000
GRUPE	244,148	2	122,074	122,074	,000	,941
Error	15,278	15	1,019	1,019		

ESTIMATES

Measure: MEASURE_1

LANKAS	Mean	Std. Error	95 % Confidence Interval	
			Lower Bound	Upper Bound
1	29,056	,352	28,305	29,806
2	28,444	,214	27,989	28,900
3	34,889	,214	34,433	35,344

4.5 pav. SPSS paketu gauti 4.5 pavyzdžio rezultatai

4.6 pavyzdys. Apskaičiuokime 4.5 pavyzdžio koeficientus η^2 :

$$\eta_A^2 = \frac{244,15}{244,15 + 15,28} = 0,94, \quad \eta_B^2 = \frac{455,59}{455,59 + 42,89} = 0,91, \quad \eta_{AB}^2 = \frac{92,85}{92,85 + 42,89} = 0,68.$$

Matome, kad, palyginti su paklaidomis, visų faktorių įtaka labai stipri.

SPSS paketu galima patikrinti visas anksčiau suformuluotas hipotezes. Sprendimai priimami pagal p -reikšmes. Kiekvienai statistinei hipotezei galioja ta pati taisyklė.

PAIRWISE COMPARISONS

Measure: MEASURE_1

(I) LANKAS	(J) LANKAS	Mean Difference (I-J)	Std. Error	Sig. ^a	95% Confidence Interval	
					Lower Bound	Upper Bound
1	2	,611	,437	,546	-,565	1,788
	3	-5,833*	,453	,000	-7,055	-4,612
2	1	,611	,437	,546	-1,788	,565
	3	-6,444*	,283	,000	-7,208	-5,681
3	1	5,833*	,453	,000	4,612	7,055
	2	6,444*	,283	,000	5,681	7,208

Based on estimated marginal means.

*. The mean difference is significant at the ,05 level.

^a. Adjustment for multiple comparisons: Bonferroni.

ESTIMATES

Measure: MEASURE_1

GRUPĖ	Mean	Std. Error	95 % Confidence Interval	
			Lower Bound	Upper Bound
1	32,722	,238	32,215	33,229
2	31,833	,238	31,326	32,340
3	27,833	,238	27,326	28,340

PAIRWISE COMPARISONS

Measure: MEASURE_1


(I) GRUPĖ	(J) GRUPĖ	Mean Difference (I-J)	Std. Error	Sig. ^a	95% Confidence Interval	
					Lower Bound	Upper Bound
1	2	,889	,336	,055	-1,730E-02	1,795
	3	4,889*	,336	,000	3,983	5,795
2	1	-,889	,336	,055	-1,795	1,730E-02
	3	4,000*	,336	,000	3,094	4,906
3	1	-4,889*	,336	,000	-5,795	-3,983
	2	-4,000*	,336	,000	-4,906	-3,094

Based on estimated marginal means.

*. The mean difference is significant at the ,05 level.

^a. Adjustment for multiple comparisons: Bonferroni.**4.6 pav.** SPSS paketu gauti 4.5 pavyzdžio *post hoc* rezultataiTegul reikšmingumo lygmuo lygus α , o p -reikšmė yra p .Tuomet nulinę hipotezę H_0 atmetame, jeigu $p < \alpha$;priimame, jeigu $p \geq \alpha$.

Žinoma, reikia prisiminti, ką kokia nulinė hipotezė reiškia. Pavyzdžiui, tegul $\alpha = 0,05$. Jeigu grupės faktorių A atitinkanti p -reikšmė $p < 0,05$, tai grupių vidurkiai statistiškai reikšmingai *skiriasi*. Jeigu sąlygų faktorių B atitinkanti p -reikšmė $p < 0,05$, tai skirtingomis sąlygomis gautų rezultatų vidurkiai statistiškai reikšmingai *skiriasi*. Jeigu



p -reikšmė, atitinkanti faktorių A ir B tarpusavio sąveiką, $p < 0,05$, tai nusprendžiame, kad faktorių tarpusavio sąveika yra. Priešingu atveju – nėra.

SPSS pakete yra realizuoti ir *post hoc* kriterijai. Jie interpretuojami kaip ir ankstesniuose skyriuose, t. y. dviejų grupių (arba sąlygų) rezultatų vidurkiai statistiškai reikšmingai skiriasi, jeigu atitinkama p -reikšmė yra mažesnė už pasirinktą reikšmingumo lygmenį α . SPSS paketu skaičiuojami ir koeficientai η^2 bei tikrinama sferiškumo prielaida. Kaip ir anksčiau, jeigu sferiškumo prielaida netenkinama, reikia naudotis viena iš trijų siūlomų pataisų.

4.7 pavyzdys. SPSS paketu atlikime 4.5 pavyzdžio blokuotųjų duomenų dvifaktoriinę dispersinę analizę. Reikšmingumo lygmuo $\alpha = 0,05$.

Iš 4.5 paveikslą lentelių randame atsakymus į pagrindines hipotezes. Močlio kriterijaus p -reikšmė yra $0,136 > 0,05$, todėl sferiškumo prielaidą galime laikyti tenkinama ir atsakymų ieškoti antros lentelės eilutės Sphericity Assumed. Randame atitinkamas p -reikšmes (abi lygios 0,00) ir įsitikiname ($0,00 < 0,05$), kad šaudant skirtingais lankais buvo pasiekti statistiškai reikšmingai besiskiriantys rezultatai. Be to, yra grupės numerio (seržanto, ruošusio karių) ir lanko rūšies tarpusavio sąveika. Beje, koeficientai η^2 pateikiami

paskutiniame stulpelyje Eta Squared (0,914 ir 0,684). Trečioje lentelėje pateiktas atsakymas į klausimą, ar skirtingų grupių taiklumai skiriasi. Kadangi atitinkama p -reikšmė (0,00) mažesnė už pasirinktąjį reikšmingumo lygmenį $\alpha = 0,05$, tai gavome patvirtinimą, kad grupių taiklumai statistiškai reikšmingai skiriasi.

Ketvirtoje lentelėje pateikti vidutiniai pataikymo iš skirtingų lankų rezultatai (29,056, 28,444 ir 34,889) ir Bonferonio kriterijus, kuris parodo, kad šaudant iš pirmojo (indėniško) ir trečiojo (patobulinto) lankų bei antrojo (mongoliško) ir trečiojo (patobulinto) lankų yra statistiškai reikšmingas rezultatų skirtumas, tačiau vidutiniai taiklumai, šaudant pirmuoju (indėnišku) ir antruoju (mongolišku) lankais statistiškai reikšmingai nesiskiria. Taigi jau turime pagrindo manyti, kad šaudant patobulintu lanku vidutinis taiklumas yra didžiausias (34,889 pataikymų). Vizualiai tuo galime įsitikinti, pažvelgę į vidurkių tendų grafiką (4.7 pav., a)). Analogiškai įsitikiname, kad pirmosios ir antrosios grupių vidutiniai taiklumai statistiškai reikšmingai nesiskiria, tačiau nuo abiejų pirmųjų grupių statistiškai reikšmingai skiriasi trečiosios grupės pataikymų vidurkis. Pastebime (žr. 4.6 pav. grupių pataikymo vidurkius ir 4.7 pav., b)), kad trečioji grupė šaudė prasčiausiai.

Be minėtų vidurkių tendų, 4.7 paveiksle, c) pateikti kiekvienos grupės vidutinius pataikymus vaizduojantys trendai. Iš jų matyti, kokia yra faktorių tarpusavio sąveika. Visų grupių kariai geriausiai (ir beveik vienodai gerai) šaudė trečiuoju (patobulintu) lanku. Tačiau pirmos dvi grupės neblogai šaudė ir kitais dviem lankais, o trečioji pasirodė daug prasčiau. Taigi trečiajai grupei vadovavęs seržantas savo šaulius paruošė prasčiausiai.



blokuotųjų duomenų
struktūra

randomizuoti blokai
sferiškumo prielaida

UŽDAVINIAI

1. Pakartokite 1 skyriaus 1.12 pavyzdžio tyrimą taikydami blokuotųjų duomenų dispersinę analizę. Reikšmingumo lygmuo $\alpha = 0,05$.
2. Prekybos centro vadybininkas ieško tinkamos vietos indų plovikliui „Laumė“. Ploviklis po savaitę buvo laikomas viršutinėje, vidurinėje ir apatinėje lentynose. Užfiksuota, kiek ploviklio indelių parduota. Eksperimente dalyvavo septynios parduotuvės, kuriose lentynų keitimo tvarka buvo randomizuota. Ar galima teigti, kad parduodamų ploviklių skaičius priklauso nuo to, kurioje lentynoje jie laikomi? Duomenys pateikti 4.10 lentelėje. Reikšmingumo lygmuo $\alpha = 0,10$.

4.10 lentelė. Parduota ploviklių

Parduotuvė	Lentyna		
	Viršutinė	Vidurinė	Apatinė
Pirma	10	12	8
Antra	5	6	4
Trečia	16	18	15
Ketvirta	30	38	25
Penkta	19	19	17
Šešta	29	30	24
Septinta	39	41	36

3. Psichologė domina, ar politiko svoris ir jo populiarumas yra tarpusavyje susiję. Ji žino svorius aštuonių politikų, kai jie buvo populiarūs, kai buvo vertinami pakančiai ir kai buvo nemėgstami. Duomenys pateikti 4.11 lentelėje. Išspręskite psichologę kamuojančią problemą. Reikšmingumo lygmuo $\alpha = 0,05$. Primename, kad nustatyta priklausomybė dar nepaaiškina priežastingumo. Kuo dar būtų galima paaiškinti svorių skirtumus?

4.11 lentelė. Politikų svoriai

Politikas	Populiarumas		
	Populiarus	Pakenčiamas	Nemėgstamas
<i>a</i>	75	85	95
<i>b</i>	68	64	70
<i>c</i>	83	86	94
<i>d</i>	66	67	73
<i>e</i>	58	57	60
<i>f</i>	79	86	90
<i>g</i>	62	72	76
<i>h</i>	82	83	90

4. Eksperimento metu buvo skaičiuota, kiek važiavimo klaidų padaro kiekvienas ką tik teises gavęs vairuotojas, važiuodamas kiekviena keturių skirtingų modelių mašina. Duomenys pateikti 4.12 lentelėje. Ar visų modelių mašinomis važiuojama vienodai sėkmingai? Reikšmingumo lygmuo $\alpha = 0,05$.

4.12 lentelė. Važiavimo klaidos

Vairuotojas	Mašinos modelis			
	<i>A</i>	<i>B</i>	<i>O</i>	<i>W</i>
<i>a</i>	13	10	15	17
<i>b</i>	12	11	14	15
<i>c</i>	13	12	15	17
<i>d</i>	20	20	26	28
<i>e</i>	13	11	16	10
<i>f</i>	17	22	27	26
<i>g</i>	21	21	25	27
<i>h</i>	16	12	14	16
<i>i</i>	19	20	25	24
<i>j</i>	21	21	24	26

5. Sesijos metu studentai laikė keturis egzaminus (kalbos, politologijos, matematikos ir logikos). Duomenys pateikti 4.13 lentelėje. Ar visi egzaminai išlaikyti vienodai gerai? Ar studentai ir studentės egzaminus išlaikė vienodai gerai? Ar kuris nors egzaminas itin patiko studentėms? Reikšmingumo lygmuo $\alpha = 0,05$.

4.13 lentelė. Sesijos rezultatai

Lytis	Egzaminas			
	Kalbos	Politologijos	Matematikos	Logikos
Vyr.	9	10	9	7
	7	8	7	5
	5	8	7	6
	7	8	6	3
	7	9	6	5
	9	8	7	6
Mot.	6	5	5	2
	8	8	7	6
	9	10	8	8
	10	10	10	9
	10	9	8	6
	8	9	5	4

6. Keturių skirtingų firmų baterijos bandomos trijų rūšių ausinukais. Skaičiuojama, kiek laiko dirbo kiekvienas ausinukas. Kiekvienu ausinuku bandomos visų keturių firmų baterijos. Duomenys pateikti 4.14 lentelėje. Ar skirtingos rūšies ausinukų veikimo laikas skiriasi? Ar skirtingų firmų gaminamos baterijos skiriasi? Ar yra rūšis ausinukų, itin suderintų su konkrečia baterija? Reikšmingumo lygmuo $\alpha = 0,05$.

4.14 lentelė. Ausinukų veikimo laikas

Ausinuko rūšis	Baterijos modelis			
	<i>a</i>	<i>b</i>	<i>c</i>	<i>d</i>
I	9	10	11	7
	12	11	14	8
	13	12	15	10
	9	8	10	8
	12	11	10	7
	14	12	13	10
II	16	15	13	12
	16	16	14	10
	19	15	15	14
	14	16	14	12
	13	10	11	9
	16	17	15	11
III	8	7	7	6
	10	10	10	9
	11	12	13	9
	14	11	10	10
	17	10	11	9
	16	15	15	11

5. TIESINĖ REGRESIJA



Visiškai neįmanoma, kad matematinė formulė leistų sužinoti ateitį, o manantys kitaip, matyt, patikėtų ir burtais.

B. de Žiuvenelis

Kamščiatraukius gaminančios firmos prezidentas mano, kad gaunamos pajamos tiesiogiai priklauso nuo TV reklamai skiriamų lėšų. Surinkus duomenis, paaiškėjo, kad šių dviejų kintamųjų koreliacija statistiškai reikšminga. Tačiau firmos prezidentui tokios informacijos nepakanka. Jis bent apytiksliai norėtų žinoti, *kiek* papildomų pajamų gaus, padidinęs reklamos išlaidas tūkstančiu litų. Be to, kiek lėšų reiktų skirti reklamai, kad pelnas būtų didžiausias. Trumpai tariant, reikia modelio, apibrėžiančio pajamų ir reklamos išlaidų priklausomybę. Modelio, kuris ne tik padėtų įvertinti abiejų kintamųjų priklausomybės stiprumą, bet ir leidžiančio *prognozuoti* galimas pajamas.

Kokios problemos kyla renkantis tinkamą modelį? Gerai žinome determinuotą kintamųjų priklausomybę, kai pagal vieno kintamojo reikšmę vienareikšmiškai nustatome, kam lygus kitas kintamasis. Pavyzdžiui, determinuota priklausomybė sieja kintamuosius x ir y lygtyje $y = 2x + 3$. Jeigu $x = 2$, tai visuomet gauname $y = 2 \cdot 2 + 3 = 7$. Tačiau determinuotos pajamų ir reklamos išlaidų priklausomybės nėra. Kodėl? Reklama paveikia tik dalį ją mačiusių potencialių pirkėjų. Be to, reklamos poveikiui įtakos gali turėti ir tai, ar, pavyzdžiui, prieš ją rodytas krepšinio varžybas nacionalinė rinktinė laimėjo, ar ne. Todėl du kartus išleidus reklamai vienodą pinigų sumą, pajamos padidėja nebūtinai vienodai. Taigi stebimas kintamasis – pajamos yra atsitiktinis dydis ir galima gauti tik gana tikėtinas jo reikšmių prognozes.

Regresijos modelis – statistinis modelis, leidžiantis vieno kintamojo reikšmės prognozuoti pagal kito kintamojo reikšmės. Statistiniai metodai, skirti regresijos modeliui sudaryti, patikrinti, ar jis tinkamas, ir taikyti prognozėms, turi bendrą pavadinimą – *regresinė analizė*.




Šnekamojoje kalboje žodis „regresija“ kelia neigiamas asociacijas (regresas – grįžimas į žemesnį būvį). Statistikoje – tai viso labo terminas, apibūdinantis specialius matematinius modelius. Šį terminą 1885 metais pirmąkart pavartojo anglų genetikas F. Galtonas (1822–1911). Tyrinėdamas vaikų ir tėvų ūgių priklausomybę, jis teigė, kad vaikų ūgiai regresuoja link populiacijos vidurkio.

Regresinės analizės metodai dažnai taikomi praktiniams tyrimams. Kai JAV prezidento rinkimuose kilo teisminių ginčų dėl Floridos rinkėjų balsų perskaiciavimo, vienas svarbiausių argumentų buvo tai, kad gautieji balsavimo rezultatai pernelyg skyrėsi nuo regresijos modelio prognozės.

Pirmiausias pasirenkamas regresijos modelio tipas – nusprendžiama, kokia priklausomybė kintamuosius sieja. Šiame skyriuje nagrinėjamas *tiesinės* regresijos modelis, t. y. vienas kintamasis nuo kito priklauso tiesiškai. Pasirinkus modelį reikia:

- 1) įvertinti nežinomus modelio parametrus;
- 2) patikrinti, ar parinktasis modelis suderinamas su duomenimis;
- 3) išmokyti regresijos modelį taikyti prognozėms.



Tiesinė regresija

Šiame skyriuje kalbėsime tik apie paprastąją tiesinę regresiją, t. y. nagrinėsime atvejį, kai prognozuojamas intervalinis kintamasis tiesiškai priklauso nuo *vieno* intervalinio kintamojo. Sudėtingesni regresijos modeliai aprašyti šeštajame skyriuje.

5.1. Tiesinė regresija ir koreliacija

Prognozės ir pranašystės visada buvo viena iš žmonijos silpnybių. Kasandra, Delfų orakulas, Nostradamas, horoskopininkai pranašavo be jokios statistikos. Tuo tarpu modernesnė pranašai savo prognozes būtinai sustiprina nuorodomis į statistinius duomenis. Tiesa, rezultatai nebūtinai nuo to pagerėja – kažin, ar skelbdamas pūvančio kapitalizmo mirtį Leninas turėjo omenyje, kad ta mirtis tęsis šimtmečius.

Leninas rėmėsi statistika „iš akies“ („mes matome...“). Kad prognozės nebūtų gautos iš akies, bendraujant su žvaigždėmis ar ano pasaulio atstovais, griežčiau nusakysime, apie kokias prognozes regresinėje analizėje kalbama. Visos minėtos prognozės (pranašystės) buvo kokybinės. Regresinėje analizėje visos prognozės yra kiekybinės – visada sprendžiama problema, kaip vieno kintamojo *skaitinės* reikšmės priklauso nuo kito kintamojo skaitinių reikšmių. Pranašystės dažniausiai būna kategoriškos: per dešimt metų pagal ekonomikos išsivystymą pavysime Švediją, 1997 rugpjūtį į Baltiją bumbtels kometa, po rinkimų atlyginimai ir pensijos ženkliai išaugs – t. y. bus taip ir ne kitaip. Tiesinėje regresijoje susiduriame su atsitiktiniais dydžiais, todėl jokia prognozė nėra šimtaprocentinė – prognozuojamos reikšmės tėra gana tikėtinės.

Šiame skyriuje tirsime, kaip kintamojo Y reikšmės priklauso nuo X reikšmių. Pavyzdžiui, toks poreikis iškyla, kai reikia:

- numatyti tokius keleivių vežimo įkainius, kad taksi firma gautų didžiausią pelną;
- nustatyti svorio ir ūgio priklausomybę;
- įrodyti tam tikros medžiagos kancerogeninį poveikį;
- atsakyti į klausimą, ar IQ lemia sesijos pažymių vidurkį;
- ištirti, kaip didinama vaisto dozė veikia kraujospūdį;
- nusakyti išlaidų ir pajamų priklausomybę;
- nustatyti nusikaltimų skaičiaus ir gyventojų tankumo priklausomybę;
- patikrinti, ar oro temperatūra turi įtakos parduodamų ledų porcijų kiekiui;
- ištirti, ar naujas paranoidinės šizofrenijos diagnostinis testas leidžia numatyti gydytojų konsiliumo nustatomą ligos sunkumo balą ir pan.


Iki šiol dviejų intervalinių kintamųjų tiesinei priklausomybei įvertinti naudojamos koreliacijos koeficientu.

Kokios informacijos suteikia koreliacijos koeficientas? Prisiminkime [1] knygos III dalies 1.5 ir 3.8 skyrelius. Koreliacijos koeficientas parodo, ar matuojamų kintamųjų tiesinė priklausomybė stipri. Be to, galima patikrinti, ar koreliacija statistiškai reikšminga. Jeigu tokios informacijos gana, regresija nereikalinga.

Tačiau dažnai tokios informacijos per mažai. Skyriaus pradžioje pateiktajame pavyzdyje kalbėjome apie kamščiatraukius gaminančios firmos gaunamų pajamų ir išlaidų reklamai ryšį. Tarkime, kad jų koreliacija lygi 0,9, t. y. rodo didelę tiesinę tiesioginę priklausomybę. Pažvelkime į 5.1 paveiksle pateiktas dvi galimas duomenų aibes. Situacija a) atskleidžia tiesinę priklausomybę, kai kiekvienas reklamai skirtas litas duoda keletą litų papildomų pajamų (reklama atsiperka). Situacija b) – tiesinė priklausomybė, kai kiekvienas reklamai skirtas litas duoda mažiau nei litą papildomų pajamų (reklama kainuoja brangiau nei atneša naudos). Abiem atvejais koreliacijos koeficientas tas pats. Taigi šiuo atveju koreliacijos koeficiento reikšmė nesuteikia visos reikiamos informacijos.

Kintamųjų koreliacija (arba jos analogas) skaičiuojama ir regresinėje analizėje (žr. 5.5 skyrelį). Vis dėlto svarbiausias tiesinės regresinės analizės privalumas yra tai, kad parenkama kintamuosius siejanti funkcija (sudaromas modelis). Apytikslė kintamojo Y priklausomybė nuo X aprašoma lygtimi $y = bx + c$. Šia lygtimi galima naudotis prognozuojant Y reikšmes. Be to, parametras b parodo, keliais vienetais pasikeičia prognozuojama y reikšmė (pvz., keliais litais padidėja pajamos) vienetu padidėjus x reikšmei (vienu litu padidėjus reklamos išlaidoms). Žinoma, tokia lygtis tik apytiksliai atitinka tikrąją, kintamuosius X ir Y siejančią priklausomybę. Tikslus tikimybinių tiesinės regresijos modelis pateikiamas kitame skyrelyje.


Koreliacija yra simetriška: X koreliuoja su Y taip pat stipriai, kaip ir Y su X . Tuo tarpu regresiniai modeliai kintamųjų atžvilgiu asimetriški. Pasirinkdami regresijos modelį, kartu nusprendžiame, kuris kintamasis bus prognozuojamas. Nuo to priklauso, kaip bus skaičiuojami nežinomų modelio parametrų įverčiai. Todėl Y ir X priklausomybę įvertinanti lygtis skiriasi nuo X ir Y priklausomybės lygties.



Kintamasis, kurio reikšmės norima prognozuoti, vadinamas *priklausomuoju* kintamuoju.

Kintamasis, pagal kurio reikšmės norima prognozuoti priklausomo kintamojo reikšmės, vadinamas *nepriklausomuoju* kintamuoju.

Maksimizuojant taksi firmos pelną, nepriklausomas kintamasis yra vieno nuvažiuoto kilometro kaina, o priklausomas – taksi gautos pajamos. Tiriant kancerogeninį medžiagos poveikį, nepriklausomas kintamasis yra medžiagos kiekis aplinkoje, o priklausomas – toje aplinkoje dirbusiųjų vėžinių susirgimų skaičius. Matuojant išlaidų ir pajamų priklausomybę, nepriklausomas kintamasis yra pajamos, priklausomas – išlaidos. Tiriant nusikaltamumą, nepriklausomas kintamasis yra gyventojų tankumas, priklausomas – tame rajone įvykdytų nusikaltimų skaičius. Diagnozuojant šizofreniją, nepriklausomas kintamasis yra naujojo testo reikšmė, priklausomas – konsiliumo nustatytas ligos sunkumas.



Vienpusė ir dvipusė priklausomybės

Regresijos modelio kintamuosius gali sieti *vienpusė* arba *dvipusė* priklausomybė. Pavyzdžiui, vienpusė yra dienos temperatūros ir suvartoto ledų kiekio priklausomybė. Mes galime spėti, kad prekyba ledais pagyvėja karštesnėmis dienomis, bet neprotinga būtų manyti, kad pardavus daugiau ledų porcijų dienos temperatūra pakils. Šiuo atveju priklausomas ir nepriklausomas kintamamieji akivaizdūs. Dvipusė priklausomybė gali sieti matematikos ir kalbos testų rezultatus. Šiuo atveju galime domėtis, kaip matematikos testo rezultatai priklauso nuo kalbos testo rezultatų, ir atvirkščiai. Dvipusės priklausomybės atveju, kurį laikyti priklausomu kintamuoju, lemia tiriama problema.

Nei vienas, nei dvipusė regresijos modelio kintamųjų priklausomybė dar nereiškia jų *priežastinio* ryšio. Tiesioginis priežastinis yra kancerogeninės medžiagos koncentracijos ir vėžinių susirgimų skaičiaus ryšys. Didesnė kancerogeninės medžiagos darbo aplinkoje koncentracija yra didesnio vėžinių susirgimų skaičiaus priežastis. Tačiau negalima būtų teigti, kad didesnė šizofrenijos diagnostinio testo reikšmė yra didesnio konsiliumo parašyto balo *priežastis*. Šiuo atveju kintamuosius sieja *netiesioginis* ryšys. Ir testo rezultatas, ir konsiliumo parašytas balas tik atskleidžia ligonio psichinę būklę. Kokie ryšiai sieja kintamuosius, nustatoma remiantis papildoma informacija, pavyzdžiui, specialiai suplanuoto eksperimento rezultatais.



Teorija netiki niekas, išskyrus jos kūrėją. Eksperimento rezultatais tiki visi, išskyrus jo atlikėją.

Kokias sąlygas turi tenkinti kintamieji ir kaip nustatyti, ar tiesinė regresija tinka, aptarsime kituose skyreliuose.

5.2. Tiesinės regresijos modelis

Bendriausias tiesinis tikimybinių modelis, siejantis intervalinius kintamuosius Y ir X , atrodo taip:

$$Y = a + bX + e. \quad (1)$$

Šioje lygtyje a, b yra nežinomos konstantos, o e – atsitiktinė paklaida. Kaip atsiranda atsitiktinė paklaida? Dažnai atsitiktinė paklaida – tai matavimo paklaida. Atsitiktinę paklaidą gali lemti ir individualūs respondentų skirtumai, pavyzdžiui, individuali organizmo reakcija į kraujospūdį mažinančius vaistus. Regresijos modelyje pabrėžiama Y priklausomybė nuo X . Bet Y gali priklausyti ir nuo kitų neįvardytų kintamųjų. Jų įtaka matyti iš atsitiktinės paklaidos. Pavyzdžiui, išlaidų didumui gali turėti įtakos ne tik pajamos, bet ir respondentų išsilavinimas ar gyvenamasis rajonas.

Dažnai mus domina, kokias reikšmes gali įgyti Y , esant fiksuotoms (neatsitiktinėms) X reikšmėms. Užrašysime (1) modelio analogą tuo atveju, kai X įgyja reikšmę x_i :


$$Y_i = a + bx_i + e_i. \quad (2)$$

Šiame modelyje x_i yra neatsitiktinė fiksuota reikšmė, o e_i – atsitiktinė paklaida (atsitiktinis dydis). Būtent (2) modelis toliau ir nagrinėjamas šiame skyriuje. Norime dar kartą pabrėžti, kad rinkdamiesi regresijos modelį, tik pasirenkame priklausomybės *tipą* su nežinomais koeficientais a ir b . Tikrindami, ar modelis tinka, kartu randame ir šių koeficientų įverčius.

Modelio lygtis parodo, kodėl esant tai pačiai reikšmei x_i galima gauti skirtingas Y_i realizacijas y_i . Galimos realizacijos priklauso nuo atsitiktinės paklaidos elgesio. Regresijos modelio prielaidos – tai reikalavimai, kuriuos turi tenkinti paklaidos e_i . Suformuluosime jas.

Tiesinės regresijos prielaidos:

- 1) e_i normaliai pasiskirstę atsitiktiniai dydžiai;
- 2) visų e_i vidurkiai lygūs nuliui, t. y. $Ee_i = 0$;
- 3) visų e_i dispersijos lygios, t. y. $De_i = \sigma^2$;
- 4) visi e_i nepriklausomi.



Trumpai visas keturias prielaidas galima užrašyti taip: $e_i \sim \mathcal{N}(0, \sigma^2)$; čia e_i yra nepriklausomi atsitiktiniai dydžiai. Beje, dispersija σ^2 nežinoma.

Aptarsime išplaukiančias iš prielaidų regresijos modelio savybes.

1 *Paklaidų normalumas.* Kadangi e_i yra normalieji atsitiktiniai dydžiai, tai su kiekviena fiksuota x_i reikšme kintamieji Y_i irgi yra normalieji atsitiktiniai dydžiai. Regresinės analizės rezultatai nedaug keičiasi ir tuo atveju, kai kintamųjų skirstiniai truputį skiriasi nuo normaliųjų. Praktiškai regresija taikoma net ir tuomet, kai kintamieji įgyja ne mažiau kaip 7 skirtingas rangines reikšmes.

2 *Vidurkių lygybė nuliui.* Atsižvelgę į tai, kad (2) modelyje x_i fiksuoti, apskaičiuokime kintamojo Y_i vidurkį:

$$\mathbf{E}Y_i = a + bx_i. \quad (3)$$

Kintamųjų Y ir X sąryšį aprašo stochastinė lygtis. Tuo tarpu priklausomo kintamojo vidurkis su x_i susietas determinuota tiesine lygtimi. Parametrai a ir b nežinomi. Pakeitus parametrus jų įverčiais, (3) lygybės analogas taikomas Y reikšmėms prognozuoti.

3 *Dispersijų lygybė.* Ši prielaida dar vadinama *homoskedastiškumo* reikalavimu. Kai ji netenkinama, sakoma, kad duomenys *heteroskedastiški*. Regresinis modelis jautrus šios prielaidos pažeidimams. Skirtingos dispersijos gali iš esmės iškreipti prognozę. Homoskedastiškumas yra reikalavimas, kad su kiekvienu fiksuotu x_i galimų Y_i reikšmių sklaida būtų vienoda (žr. 5.2 pav., a)). Atkreipiame dėmesį, kad patys Y_i reikšmių vidurkiai kinta tiesiškai, o vienoda tik reikšmių *sklaida* apie vidurkius. Būdingas heteroskedastiškumo atvejis, kai didėjant x sklaida didėja, pavaizduotas 5.2 paveiksle, b).

4 *Paklaidų nepriklausomumas.* Nepriklausomos paklaidos reiškia, kad ir visi Y_i nepriklausomi. Iš šio reikalavimo išplaukia, pavyzdžiui, kad Y_i nepriklauso nuo Y_{i-1} . Tarkime, kad x_i yra to paties kintamojo matavimai skirtingais laiko momentais.

Tuomet iš paklaidų nepriklausomumo išplaukia, kad priklausomojo kintamojo reikšmė Y_i , įgyta i -uoju laiko momentu, nepriklauso nuo reikšmės Y_{i-1} , įgytos prieš tai, $(i-1)$ -uoju laiko momentu. Toks reikalavimas ne visada pagrįstas. Tada tiesinės regresijos modelis netaikytinas ir reikia naudotis autoregresija.

5.3. Regresijos tiesė



Nubraižęs regresijos tiesės grafiką, dėstytojas pamatė galiniame suole snaudžiantį studentą. „Gerbiamas Juozai, pasakykite, prognozuojamoji y reikšmė bus didesnė už 100 ar mažesnė.“ Išgirdęs savo vardą, studentas pašoko ir suriko: „Taip!“. „Kas taip? Pasakykite, didesnė už 100 ar mažesnė.“ „Didesnė už 100 ar mažesnė?“ „Taip!“ „Aš taip iškart ir sakiau.“

Visur šiame skyriuje tarsime, kad duomenis sudaro intervalinių kintamųjų poriniai stebėjimai $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$. Atkreipiame dėmesį, kad tarp $x_1, \dots, x_n$ gali būti ir sutampančių reikšmių, be to, jei $x_i = x_j$, tai dar nebūtinai $y_i = y_j$, t. y. vienodas x reikšmės nebūtinai atitiks vienodos y reikšmės.

Mūsų tikslas – parametrų a ir b įverčius $\hat{a}$ ir $\hat{b}$ parinkti taip, kad funkcijos $\hat{y}(x) = \hat{a} + \hat{b}x$ reikšmės taškuose x_i kiek galima mažiau skirtųsi nuo y_i . Gautoji funkcija bus naudojama priklausomojo kintamojo reikšmėms prognozuoti.


Kiekvieną x_i atitinka jo porinis stebėjimas y_i ir funkcijos $\hat{y}(x_i) = \hat{a} + \hat{b}x_i$ reikšmė. Geriausiai tinkanti funkcija yra tokia, kurios skirtumai $\hat{e}_i = y_i - \hat{y}(x_i)$, $i = 1, 2, \dots, n$, mažiausi (žr. 5.3 pav., a)).

Įverčiai $\hat{a}$ ir $\hat{b}$ randami minimizuojant

$$SSE = \sum_{i=1}^n (y_i - a - bx_i)^2. \quad (4)$$

Sumą SSE minimizuoja

$$\hat{b} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n x_i y_i - (\sum_{i=1}^n x_i \sum_{i=1}^n y_i)/n}{\sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2/n}; \quad (5)$$



$$\hat{a} = \bar{y} - \hat{b}\bar{x}; \quad (6)$$

čia $\bar{y} = \sum_{i=1}^n y_i/n$, $\bar{x} = \sum_{i=1}^n x_i/n$. Aprašytasis funkcijos $\hat{y}(x)$ parametų parinkimo metodas vadinamas *mažiausiųjų kvadratų metodu*. Šiuo metodu gauti įverčiai yra nepaslinktieji ir turi mažiausias dispersijas.

Lygtis $\hat{y}(x) = \hat{a} + \hat{b}x$, kurios koeficientai $\hat{a}$, $\hat{b}$ apibrėžti (5) ir (6) lygybėmis, vadinama *regresijos tiesės lygtimi*.
 $\hat{e}_i = y_i - \hat{y}(x_i) = y_i - (\hat{a} + \hat{b}x_i)$ vadinama *i-ąja liekamąja paklaida*, $i = 1, 2, \dots, n$.

5.1 pavyzdys. Žinoma kurortinio miestelio kelių vasaros dienų vidutinė dienos temperatūra ir vietos restorane suvalgytų ledų kiekis. Duomenys pateikti 5.1 lentelėje. Raskite regresijos tiesės lygtį. Kiek ledų (kg) tikėtina suvalgyti per dieną, kurios vidutinė temperatūra 27,5°C?

5.1 lentelė. Ledų pardavimas

Temperatūra	25	26	24	26	24	26	22	23	27	20	20	22
Ledai (kg)	116	120	115	119	115	118	111	113	121	108	109	110
Temperatūra	28	22	23	23	28	24	26	29	25	25	25	24
Ledai (kg)	122	113	113	114	123	116	119	125	118	119	117	116

Mūsų nagrinėjamo pavyzdžio nepriklausomas kintamasis X yra temperatūra, o priklausomas kintamasis Y – suvalgytų ledų kiekis. Randame:

$$\sum_{i=1}^{24} x_i = 25 + \dots + 24 = 587, \quad \sum_{i=1}^{24} y_i = 116 + \dots + 116 = 2790,$$

$$\sum_{i=1}^{24} x_i y_i = 25 \cdot 116 + \dots + 24 \cdot 116 = 68474, \quad \sum_{i=1}^{24} x_i^2 = 25^2 + \dots + 24^2 = 14485,$$

$$\hat{b} = 1,84, \quad \hat{a} = 71,28.$$

Taigi regresijos tiesės lygtis yra

$$\hat{y}(x) = 71,28 + 1,84x. \quad (7)$$

Prognozuojamas ledų kiekis $\hat{y}(27,5) = 71,28 + 1,84 \cdot 27,5 = 121,88$ kg.

Ankstesniame skyrelyje apibrėžėme teorinį regresijos modelį. Pastebėsime, kad $\hat{a}$, $\hat{b}$, $\hat{e}_i$ yra nežinomų parametų a , b ir paklaidos e_i įverčiai. Iš tikrųjų (žr. (6) ir $\hat{e}_i$ apibrėžimą):

$$\bar{y} = \hat{a} + \hat{b}\bar{x}, \quad y_i = \hat{a} + \hat{b}x_i + \hat{e}_i. \quad (8)$$



Dažnai ieškoma ne tik regresijos tiesės, bet ir standartizuotųjų reikšmių regresijos tiesės. Stebėjimai (x_i, y_i) keičiami z -reikšmėmis (z_{xi}, z_{yi}) , $i = 1, \dots, n$, ir mažiausiųjų kvadratų metodu nustatomi tiesės $z_{yi} = \alpha + \beta \cdot z_{xi}$ koeficientai; čia $z_{xi} = (x_i - \bar{x})/s_x$, $z_{yi} = (y_i - \bar{y})/s_y$, o s_x , s_y yra standartiniai nuokrypiai. Standartizuotoji regresijos tiesė dažniau naudojama daugialypėje regresijoje, nes pagal jos koeficientus galima nuspręsti, koks kintamasis daro didesnę įtaką prognozei. Paprastosios tiesinės regresijos atveju koeficientas β sutampa su pradinųjų duomenų (x_i, y_i) koreliacija.

Tarkime, regresijos modelio kintamuosius sieja dvipusė priklausomybė. Tuomet galima rasti tų pačių duomenų $(x_1, y_1), \dots, (x_n, y_n)$ regresijos tiesę $x(y) = c + dy$. Ši lygtis apibrėžia vadinamąją *atvirkštinę regresijos tiesę*.

Nagrinėjant neatsitiktinę (determinuotą) priklausomybę $y = a + bx$, lengva rasti $x = -a/b + y/b$. Tačiau regresinėje analizėje susiduriama su atsitiktinėmis paklaidomis. Todėl iš regresijos tiesės lygties $y = \hat{a} + \hat{b}x$ išreiškus $x = -\hat{a}/\hat{b} + y/\hat{b}$, bendruoju atveju atvirkštinės regresijos tiesės lygties *negaunama*. Tai paaiškinama tuo, kad mažiausiųjų kvadratų metodas šiuo atveju minimizuoja kitus paklaidų įverčius (žr. 5.3 pav., b)). Nekreipdami dėmesio į tai, kad ledų kiekio ir temperatūros atvirkštinė regresijos tiesė nėra itin prasminga, ir jos vis dėlto ieškodami, gauname $x(y) = -36,52 + 0,52y$. Tuo tarpu iš (7) išsireiškę x , gauname $x(y) = -39,95 + 0,54y$.

Jei regresijos modelis tinka, tai regresijos tiesės lygtis yra empirinis (3) lygybės analogas. Tačiau kaip patikrinti, ar duomenys iš tikro tenkina tiesinės regresijos modelį?

Svarbiausios priežastys, dėl kurių tiesinė regresija gali netikti:

- 1) kintamųjų priklausomybė nėra tiesinė;
- 2) stebėjimai heteroskedastiški;
- 3) paklaidų skirstiniai nėra normalieji;
- 4) paklaidos priklausomos;
- 5) duomenyse yra išskirčių.

Į visa tai reikia atsižvelgti. Norint nuspręsti, ar regresijos modelis tinka, reikės grafinės duomenų analizės, determinacijos koeficiento ir statistinės hipotezės apie nepriklausomo kintamojo daugiklį. Su tuo susipažinsime 5.4, 5.5 ir 5.6 skyreliuose. Norime pabrėžti, kad kurio nors vieno iš jų *negalima* suabsoliutinti.

5.4. Liekamųjų paklaidų analizė


Šiame skyrelyje susipažinsime su liekamųjų paklaidų analize. Primename, kad porinio stebėjimo (x_i, y_i) liekamąją paklaidą vadiname $\hat{e}_i = y_i - \hat{y}(x_i) = y_i - (\hat{a} + \hat{b}x_i)$; čia koeficientai $\hat{a}$ ir $\hat{b}$ skaičiuojami pagal (5) ir (6) formules. Taigi $\hat{e}_i$ parodo, kiek stebėtoji y_i reikšmė skiriasi nuo reikšmės, kurią gautume prognozuodami pagal regresijos tiesę. Jeigu visi $\hat{e}_i = 0$, tai prognozuojami $\hat{y}(x_i)$ sutampa su stebimais y_i . Ir atvirkščiai, kuo $\hat{e}_i$ daugiau skiriasi nuo 0, tuo labiau prognozuojama reikšmė skiriasi nuo stebimosios.

Aptarsime tik paprasčiausius paklaidų įverčių analizės atvejus, daug kuo primenančius vertinimus iš akies. Vis dėlto net pradinė duomenų peržiūra gali atskleisti nemažai informacijos apie kintamųjų priklausomybę.

5.4.1. Išskirtys

Net ir vienas, labai nuo kitų besiskiriantis porinis stebėjimas (x_j, y_j) gali radikaliai pakeisti regresijos tiesės lygties parametrų įverčius. Tarkime, kad 5.1 pavyzdžio duomenys yra papildyti: dieną, kai temperatūra siekė 36°C, suvalgyta 90 kg ledų. Kaip šiuo atveju atrodo poriniai stebėjimai ir regresijos tiesės grafikas, matome 5.4 paveiksle, a). Nors visi, išskyrus *vieną*, stebėjimai rodo, kad kylant temperatūrai ledų suvartojama daugiau, regresijos tiesė yra mažėjanti. Kažin, ar tokia regresijos tiesė tinka prognozėms. Dabar tarkime, kad duomenys papildyti ne stebėjimu (36, 90), bet stebėjimu (20, 140). Regresijos tiesė (žr. 5.4 pav., b)) yra nuožulnesnė, nei matytųsi iš kitų duomenų. Abiem atvejais viena pridėtojo porinio stebėjimo koordinatė labai išsiskiria iš kitų duomenų. Tokie besiskiriantys nuo kitų duomenų poriniai stebėjimai vadinami *išskirtimis*¹. Išskirtys – tai

¹ Čia kalbame apie porinių stebėjimų išskirtis. Neporinės išskirtys aptartos [1] knygos I dalies 6 skyrelyje.



savotiški įtartinai taškai. Išskirtis *nebūtinai* iš esmės pakeičia parametrų įverčius. Paveiksle 5.4, c) išskirtis (36, 138) atitinka tą pačią kintamųjų priklausomybę, kurią galima nustatyti ir iš likusių duomenų. Duomenų su šia išskirtimi regresijos tiesė praktiškai nesiskiria nuo duomenų be išskirties.

Taigi reikia išmokti rasti duomenų išskirtis ir po to išsiaiškinti, ką su tomis išskirtimis daryti. Iš pradžių aptarsime, kaip sprendžiama antroji problema.


Tyrėjas didesnę dėmesį turėtų skirti toms išskirtims, kurios labai keičia likusiųjų duomenų regresijos tiesės lygties koeficientus. Ar išskirtis „kenksminga“, paprasčiausia nustatyti skaičiuojant regresijos tiesės lygtį su išskirtimi ir be jos. Palyginkime keturias regresijos tiesės lygtis – 5.1 pavyzdžio 5.1 lentelės duomenų (x atitinka temperatūrą, y – suvalgytą ledų kiekį, žr. 5.5 pav., a)); ir 5.1 lentelės duomenų, papildytų stebėjimais (36, 90), (20, 140) arba (36, 138) (jų regresijos tiesės pavaizduotos 5.4 pav.):

$$\hat{y}_1(x) = 71,28 + 1,84x, \quad \hat{y}_2(x) = 120,62 - 0,22x,$$

$$\hat{y}_3(x) = 95,14 + 0,91x, \quad \hat{y}_4(x) = 70,73 + 1,86x.$$

Įsitikiname, kad tik išskirtis (36, 138) beveik nepakeičia 5.1 pavyzdžio regresijos tiesės lygties koeficientų įverčių.

Ką daryti, suradus parametrų įverčius keičiančias išskirtis? Dažniausiai rekomenduojama patikrinti, ar duomenyse nėra klaidos. Pavyzdžiui, gali paaiškėti, kad turėjo būti ne (36, 90), o (36, 130). Kartais stebėjimas atskleidžia visiškai nebūdingą situaciją. Pavyzdžiui, gali būti, kad toje vietovėje 36°C temperatūra pasitaiko kartą per šimtą metų. Išskirtis gali atsirasti ir dėl stipraus kokio nors pašalinio kintamojo poveikio. Pavyzdžiui, gali paaiškėti, kad didelį suvalgytų ledų kiekį išskirtyje (20, 140) lėmė ne tiek temperatūra, kiek vykusį desertų degustavimo šventė. Minėtais atvejais išskirtis iš duomenų galima pašalinti. Dažnai apie išskirtį jokios informacijos neturime. Tad neišsiaiškinus, kaip



atsirado duomenų išskirtis, jos negalima šalinti. Tuomet rekomenduojama duomenis papildyti naujais stebėjimais ir tyrimą kartoti. Nepamirškime, kad regresijos modeliai tinka ne visiems duomenims. Gali tiesiog paaiškėti, kad tiesinės regresijos modelis neatitinka stebimų kintamųjų elgesio.

Minėtuose pavyzdžiuose išskirtys buvo lengvai pastebimos. Tačiau kaip jas rasti bendruoju atveju?

Taikomi keli alternatyvūs išskirčių nustatymo metodai. Vieni iš jų svarbiausia laiko itin didelę (itin mažą) nepriklausomo kintamojo reikšmę, t. y. pagal x_j didumą sprendžiama, ar stebėjimą laikyti išskirtimi, ar ne; kiti svarbiausiu laiko $\hat{e}_j$ didumą, parodantį, kaip toli stebėjimas nutolęs nuo regresijos tiesės. Šioje knygoje susipažinsime su trimis metodais, kai išskirtis nustatoma pagal: a) stebėjimo įtakos indeksą; b) standartizuotąją liekaną; c) Kuko matą.

Stebėjimo įtakos indeksas įvertina tik pirmosios koordinatės (nepriklausomojo kintamojo) reikšmę (ar toli nuo $\bar{x}$ yra x_j). Stebėjimo (x_j, y_j) įtakos indeksas

$$h_j = \frac{1}{n} + \frac{(x_j - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{1}{n} + \frac{(x_j - \bar{x})^2}{\sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2/n}; \quad (9)$$

čia n – porinės imties didumas, $\bar{x} = \sum_{i=1}^n x_i/n$.

Kuo regresijos tiesės lygties koeficientai labiau priklauso nuo stebėjimo, tuo stebėjimo įtakos indeksas didesnis. Pateiksime vieną taisyklę, kaip iš akies pagal h_i rasti išskirtis.

$$\text{Stebėjimą } (x_j, y_j) \text{ laikome išskirtimi, jei } h_j > 4/n. \quad (10)$$

Pastaba. Kai kurie autoriai siūlo mažiau konservatyvią taisyklę: išskirtimi laikyti stebėjimą, kurio $h_j > 6/n$.



Beje, (10) sąlyga ekvivalenti reikalavimui $|x_j - \bar{x}| > (3(1 - 1/n))^{1/2} s_x$; čia s_x yra imties $(x_1, x_2, \dots, x_n)$ standartinis nuokrypis.

5.2 pavyzdys. Pagal (10) taisyklę raskime 5.1 pavyzdžio 5.1 lentelės duomenų išskirtis. Kadangi $n = 24$, tai h_j lyginame su $4/24 = 0,166$. Primename, kad nagrinėjamuoju atveju x – temperatūra. Apskaičiuojame: $\bar{x} = 24,46$, $\sum x_i^2 = 14485$, $\sum x_i = 587$. Taigi $h_1 = (25 - 24,46)^2 / (14485 - 587^2/24) = 0,0023$, $h_2 = 0,0185$ ir t. t. Peržiūrėję visus h_j , įsitikiname, kad išskirčių nėra.

5.3 pavyzdys. Pagal (10) taisyklę raskime išskirtis 5.1 lentelės duomenų, papildytų stebėjimais (36, 90), (20, 140) ir (36, 138), pavaizduotais 5.4 paveiksle atitinkamai a), b) ir c). Visais atvejais $n = 25$, todėl h_j lyginame su $4/25 = 0,16$. Apskaičiavę visus h_j ir palyginę su 0,16, įsitikiname, kad pirmu atveju (36, 90) yra vienintelė išskirtis ($h_{25} = 0,48$), antruoju – išskirčių nėra, trečiuoju (36, 138) yra vienintelė išskirtis ($h_{25} = 0,48$).

Matome, kad stebėjimo įtakos indeksas nepadėjo rasti tikrai kenksmingos išskirties (20, 140).

Standartizuotosios liekanos yra liekamųjų paklaidų $\hat{e}_i$ z -reikšmės. Primename, kad z -reikšmė gaunama iš duomens atėmus imties vidurkį ir padalijus iš standartinio nuokrypio

(žr. [1] knygos I dalies 6 skyrelį). Beje, visų $\hat{e}_i$, $i = 1, \dots, n$, aritmetinis vidurkis lygus nuliui. Standartizuotoji liekana

$$SR_i = \frac{\hat{e}_i}{\sqrt{MSE(1 - h_i)}}; \quad (11)$$

čia $\hat{e}_i$ yra i -ojo stebėjimo liekamoji paklaida, h_i – stebėjimo įtakos indeksas, $i = 1, \dots, n$, n – imties didumas, $MSE = SSE/(n - 2)$, o SSE apibrėžta (4) lygybe.

Kaip ir aprašomojoje statistikoje, išskirtimi galima laikyti reikšmę, kuri nuo imties vidurkio nutolusi per du arba tris standartinius nuokrypius. Standartizuotųjų liekanų imties vidurkis lygus nuliui, o imties dispersija – vienetui.

$$\text{Stebėjimą } (x_i, y_i) \text{ laikome išskirtimi, jei } |SR_i| > 3. \quad (12)$$

5.4 pavyzdys. Pagal (12) taisyklę raskime išskirtis 5.1 lentelės duomenų ir tų pačių duomenų, papildytų stebėjimais (36, 90), (20, 140) ir (36, 138), pavaizduotais 5.4 paveiksle atitinkamai a), b) ir c). Stebėjimas (36, 90) yra išskirtis ($SR_{25} = -3,29$), stebėjimas (20, 140) – taip pat išskirtis ($SR_{25} = 4,34$), stebėjimas (36, 138) nėra išskirtis ir 5.1 lentelės duomenys išskirčių neturi.

Standartizuotųjų liekanų metodas padėjo rasti abi kenksmingas išskirtis.

*Kuko*¹ matas (atstumo statistika) atsižvelgia ir į standartizuotąją liekaną ir į stebėjimo įtakos indeksą. Kuko matas

$$D_i = \frac{(SR_i)^2 h_i}{2(1 - h_i)}. \quad (13)$$

Kaip matyti iš šios formulės, Kuko matas didelis tada, kai didelis stebėjimo įtakos indeksas arba didelė standartizuotoji liekana.

$$\text{Stebėjimą } (x_i, y_i) \text{ laikome išskirtimi, jei } D_i > F_{0,5}(2, n - 2). \quad (14)$$

Čia $F_{0,5}(2, n - 2)$ yra Fišerio skirstinio su 2 ir $(n - 2)$ laisvės laipsnių 0,5 lygmens kritinė reikšmė.

Fišerio skirstinio 0,5 lygmens kritinės reikšmės galima rasti iš priedo 12 lentelės. Neturint lentelių gana gera taisyklė iš akies išskirtimi laikyti stebėjimą, kurio $D_i > 1$.

5.5 pavyzdys. Pagal (14) taisyklę raskime išskirtis 5.1 lentelės duomenų ir tų pačių duomenų, papildytų stebėjimais (36, 90), (20, 140) ir (36, 138), pavaizduotais 5.4 paveiksle atitinkamai a), b) ir c). Iš 12 lentelės randame $F_{0,5}(2, 22) \approx F_{0,5}(2, 23) \approx 0,71$.

Stebėjimas (36, 90) yra išskirtis ($D_{25} = 12,27$), stebėjimas (20, 140) – taip pat išskirtis ($D_{25} = 2,22$), o stebėjimas (36, 138) nėra išskirtis ir 5.1 lentelės duomenys išskirčių neturi.

Taigi gavome tokius pat rezultatus kaip ir standartizuotųjų liekanų metodu. Žinoma, bendruoju atveju šie metodai nėra identiški. Kuko matas ir kitos charakteristikos skaičiuojamos daugeliu statistinių paketų.

¹ R. D. Cook – amerikiečių statistikas.

5.4.2. Liekamųjų paklaidų grafikai

Nors rinkdamasis *tiesinės* regresijos modelį tyrėjas spėja, kad kintamųjų priklausomybė yra *tiesinė*, nepakenktų pažvelgti į duomenų sklaidos grafiką. Norime pabrėžti, kad sprendžiant apie pasirinktojo regresinės analizės modelio tinkamumą grafinės duomenų analizės *nepakanka*. Tai tik vienas iš modelio tikimo tikrinimo etapų.


5.6 pavyzdys. Tarkime, psichologas matavo įvairaus amžiaus paauglių savęs sureikšminimo indeksą (*SASURI*). Duomenys pateikti 5.2 lentelėje.

5.2 lentelė. Savęs sureikšminimas

Amžius (x)	10	10	10,5	11	11,5	12	12	12	12,5	13	13	14	14	14,5
SaSurI (y)	20	18	21	38	35	50	54	47	48	61	64	70	68	73

Amžius (x)	14,5	15	15	16	16	16,5	16,5	17	17,5	18	18,5	19	19
SaSurI (y)	66	60	58	54	50	52	55	40	43	39	35	34	36

Šių duomenų regresijos tiesė pateikta 5.5 paveiksle, b). Akivaizdu, kad tiesinė regresija netinka. Ir ne todėl, kad yra išskirčių, bet todėl, kad kintamųjų priklausomybė nėra tiesinė. Palyginimui 5.5 paveiksle, a) pateikta 5.1 pavyzdžio (5.1 lentelės) duomenų regresijos tiesė.





5.5 pav. 5.1 ir 5.6 pavyzdžių regresijos tiesės

Grafinė prielaidų diagnostikai paprastai naudojami ne porinių stebėjimų grafikai, o liekamųjų paklaidų arba standartizuotųjų liekanų grafikai. Jeigu regresijos modelis tinka, visi $\hat{e}_i$ turėtų būti nelabai dideli ir daugmaž vienodai išsibarstę apie tiesę $y = 0$. Nagrinėto 5.1 pavyzdžio porinių stebėjimų $(x_i, \hat{e}_i)$, $i = 1, \dots, n$, diagrama pateikta 5.6 paveiksle, a). Dar kartą gauname patvirtinimą, kad šiems duomenims tiesinės regresijos modelis tinka. Analogišką informaciją suteikia ir standartizuotųjų liekanų (y_i, SR_i) sklaidos diagrama (žr. 5.6 pav., b)). Atkreipiame dėmesį, kad paprastai braižoma ne (x_i, SR_i) , o (y_i, SR_i) diagrama. Paveiksle 5.6, c) nubraižyta 5.6 pavyzdžio duomenų standartizuotųjų liekanų diagrama. Matome, kad stebėjimai nėra atsitiktinai išsibarstę.

Primename, kad iš sklaidos diagramų galima spręsti ir apie stebėjimų heteroskedastiškumą.

Stebėjimų normalumą grafiškai galima įvertinti nusibraižius standartizuotųjų liekanų histogramas. Nagrinėtų 5.1 ir 5.5 pavyzdžių standartizuotųjų liekanų histogramos pateiktos 5.7 paveiksle, atitinkamai a) ir b). Matome, kad *SASURI* liekanų histograma (5.7 pav., b)) su normaliąja kreive suderinta blogiau.



Duomenų ir standartizuotųjų liekanų grafikus galima nubraižyti naudojantis daugeliu statistikos paketų. Šio skyrelio 5.4–5.7 paveikslai nubraižyti naudojantis SPSS paketu.

Aptarėme, kaip vizualiai patikrinti, ar nepažeistos regresijos modelio prielaidos. Tačiau ką daryti, jeigu nusprendžiame, kad pažeistos? Paprastai rekomenduojama: 1) rinktis netiesinį modelį arba 2) transformuoti kintamuosius. Išsamiau šiuos dalykus aptarsime 5.6 skyrelyje.

5.5. Determinacijos koeficientas


Nepriklausomo ir priklausomo kintamųjų priklausomybės stiprumą dispersinėje analizėje vertiname η^2 koeficientu (žr. 2.9 skyrelį). Susipažinsime su šio koeficiento tiesinėje regresijoje analogu. Primename, kad dispersinėje analizėje nepriklausomas kintamasis yra kategorinis, o priklausomas – intervalinis. Regresinėje analizėje abu kintamieji yra intervaliniai. Kaip ir ankstesniuose skyreliuose, tarsime, kad duomenis sudaro intervalinių kintamųjų poriniai stebėjimai: $(x_1, y_1), \dots, (x_n, y_n)$.

Kaip matyti iš (5) ir (7) lygybių, žinant tik $\bar{x}$ prognozuojama Y reikšmė būtų $\bar{y}$. Kiekvieną y_i ir $\bar{y}$ skirtumą galima išskaidyti į dvi sudėtinės dalis:

$$y_i - \bar{y} = (y_i - \hat{y}(x_i)) + (\hat{y}(x_i) - \bar{y}) = \hat{e}_i + (\hat{y}(x_i) - \bar{y}). \quad (14)$$

Pakėlę abi (14) lygybės puses kvadratu, susumavę ir sutraukę panašiuosius narius, gauname tokią lygybę:

$$SST = SSR + SSE; \quad (15)$$



čia

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2, \quad SSR = \sum_{i=1}^n (\hat{y}(x_i) - \bar{y})^2, \quad SSE = \sum_{i=1}^n \hat{e}_i^2. \quad (16)$$

Suma SST vadinama *visa kvadratų suma*, SSR – *regresijos kvadratų suma*, o SSE – *liekamųjų paklaidų kvadratų suma*. Beje, SSE mes jau buvome apibrėžę (4) lygybe. Lengviausia šių sumų vaidmenį suvokti pažvelgus į 5.8 paveikslą. SST įvertina, kaip $y_1, \dots, y_n$ reikšmės išsibarsčiusios apie tiesę $y = \bar{y}$. SSE įvertina, kaip $y_1, \dots, y_n$ reikšmės išsibarsčiusios apie regresijos tiesę $\hat{y}(x) = \hat{a} + \hat{b}x$. SSR – tai kvadratų suma, rodanti, kiek regresijos tiesė $\hat{y}(x)$ skiriasi nuo tiesės $y = \bar{y}$.

Santykis SSR/SST vadinamas *determinacijos koeficientu*.

$$\text{Determinacijos koeficientas } r^2 = \frac{SSR}{SST}.$$

Determinacijos koeficientą galima interpretuoti taip:

$$r^2 = \frac{\text{Variacijos dalis, kurią paaiškina regresijos modelis}}{\text{Visa variacija}}.$$

Tarkime, kad duomenys idealiai atitinka regresijos tiesės lygtį $\hat{y}(x) = \hat{a} + \hat{b}x$, t. y. grafiko visos y_i reikšmės patenka ant regresijos tiesės. Tuo atveju $SSE = 0$, $SSR = SST$ ir $SSR/SST = 1$. Dabar tarkime, kad regresijos tiesės lygtis visiškai netinkama prognozei, t. y. $SSR = 0$. Tuomet $SSR/SST = 0$.

5.7 pavyzdys. Apskaičiuokime 5.1 pavyzdžio determinacijos koeficientą. Nesunkiai įsitikiname, kad $SSR = 432,5$, $SST = 448,5$, $r^2 = 0,964$. Taigi galime sakyti, kad regresijos modelis paaiškina 96,4% variacijos.

Determinacijos koeficientas glaudžiai susijęs su Pirsono koreliacijos koeficientu.

Paprastosios tiesinės regresijos atveju determinacijos koeficientas r^2 sutampa su empirinio Pirsono koreliacijos koeficiento kvadratu.

Atkreipiame dėmesį, kad taip yra tik paprastosios tiesinės regresijos (vieno nepriklausomo kintamojo) atveju. Tada r yra Pirsono koreliacijos koeficiento absoliutusias didumas.

Koreliacijos koeficiento ženklas parenkamas taip: jeigu $\hat{b} > 0$, koeficientas teigiamas; jeigu $\hat{b} < 0$ – neigiamas.

Determinacijos koeficientas plačiai naudojamas kaip regresijos modelio tinkamumo indikatorius.

Norime atkreipti dėmesį, kad:

- 1) Didesnis determinacijos koeficientas reiškia, kad stebėjimai yra labiau koncentruoti apie mažiausiųjų kvadratų metodu gautą tiesę. Remiantis *vien* tik determinacijos koeficientu, dar negalima pasakyti, ar tiesinės regresijos modelis turimiems duomenims tinka.
- 2) Praktiškai taikant regresinę analizę, dažniausiai reikalaujama, kad $r^2 \geq 0,25$. Jeigu $r^2 < 0,25$, labai abejotina, ar tiesinės regresijos modelis tinka.

Kartais (ypač daugialypėje regresijoje, žr. 6 skyrių) naudojamas *pataisytasis* (ang. *adjusted*) *determinacijos koeficientas* r_{adj}^2 , atsižvelgiantis ir į imties didumą, ir į nepriklausomų kintamųjų skaičių. Paprastajame tiesinės regresijos modelyje yra tik vienas nepriklausomas kintamasis, todėl koeficientai r^2 ir r_{adj}^2 skiriasi labai nedaug. Juos sieja toks ryšys:

$$r_{adj}^2 = 1 - (1 - r^2) \frac{n - 1}{n - 2}. \quad (17)$$

Abu koeficientus galima apskaičiuoti SPSS paketu. Jei r^2 mažas, tai r_{adj}^2 gali įgyti ir neigiamas reikšmes.

5.8 pavyzdys. Apskaičiuokime 5.6 pavyzdžio determinacijos koeficientą. SPSS rezultatai pateikti 5.9 paveiksle. Matyti, kad $r = 0,154$, $r^2 = 0,024$, $r_{adj}^2 = -0,015$. Taigi determinacijos koeficientas rodo, kad *tiesinės* regresijos modelis duomenims nelabai tinka.

MODEL SUMMARY				
Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	,154 ^a	,024	-,015	15,3163
^a . Predictors: (Constant), X				

5.9 pav. SPSS paketu gautas determinacijos koeficientas

5.6. Regresinės analizės statistinės išvados



Išvada padaroma tada, kai nusibosta mąstyti.

Ankstesniuose skyreliuose apsiribojome aprašomajai statistikai būdingais vertinimais iš akies. Kai kurie iš jų skirti regresijos modelio prielaidoms patikrinti. Atkreipiame dėmesį, kad užrašydami regresijos modelį jokių reikalavimų koeficientams a , b nekėlėme (žr.

5.2 skyrelį). Be to, nereikalavome, kad paklaidų dispersija σ^2 būtų maža. Žodžiu, regresijos modelio prielaidose kalbama apie paklaidų elgesį, o ne apie modelio tikimą prognozėms. Gali atsitikti taip, kad paklaidos yra normaliai pasiskirsčiusios ir nepriklausomos, ir homoskedastiškos, o nepriklausomas kintamasis priklausomam kintamajam jokios įtakos neturi, nes jo koeficientas modelyje lygus nuliui, t. y. turėsime modelį $Y_i = a + 0 \cdot x_i + e_i$. Todėl dar reikia įvertinti regresijos modelio koeficientų elgesį.

5.6.1. Parametrų pasikliautiniai intervalai

Tarkime, kad visos (2) modelio prielaidos galioja. Modelyje yra du nežinomi koeficientai a , b ir nežinoma dispersija σ^2 . Visų jų įverčiai jau rasti anksčiau: $\hat{a}$, $\hat{b}$ ir MSE . Primename, kad $MSE = SSE/(n - 2)$.

Galima apskaičiuoti parametrų a ir b pasikliautinius intervalus.



Pirmoje šio vadovėlio knygoje esame aptarę, kuo statistika skiriasi nuo jos realizacijos. Spręsdami problemą, kokias reikšmes gali įgyti $\hat{a}$, $\hat{b}$, MSE , turėsime jų apibrėžimuose stebėjimus y_i pakeisti atsitiktiniais dydžiais Y_i , nusakytais (2) modeliu. Tuomet $\hat{a}$, $\hat{b}$, MSE virs atsitiktiniais dydžiais. Remiantis modelio prielaidomis, įrodyta, kad tada $\hat{a}$ ir $\hat{b}$ skirstiniai yra normalieji. Be to,

$$E\hat{a} = a, \quad D\hat{a} = \sigma^2 \left(\frac{1}{n} + \frac{(\bar{x})^2}{(n-1)s_x^2} \right), \quad E\hat{b} = b, \quad D\hat{b} = \frac{\sigma^2}{(n-1)s_x^2}, \quad (18)$$

$$\text{cov}(\hat{a}, \hat{b}) = -\frac{\sigma^2 \bar{x}}{(n-1)s_x^2}; \quad \text{čia } (n-1)s_x^2 = \sum_1^n x_i^2 - \left(\sum_1^n x_i \right)^2 / n. \quad (19)$$

Taigi s_x^2 yra empirinė $x_1, \dots, x_n$ dispersija.

Pakeitę (18) ir (19) formulėse nežinomą dispersiją σ^2 jos įverčiu MSE , gauname $\hat{a}$, $\hat{b}$ dispersijų įverčius:

$$s_a^2 = MSE \left(\frac{1}{n} + \frac{(\bar{x})^2}{(n-1)s_x^2} \right), \quad s_b^2 = \frac{MSE}{(n-1)s_x^2}. \quad (20)$$

Statistikos $(\hat{a} - a)/s_a$, $(\hat{b} - b)/s_b$ turi Stjudento skirstinius su $(n - 2)$ laisvės laipsnių. Be to, SSE/σ^2 turi χ^2 skirstinį su $(n - 2)$ laisvės laipsnių. Koeficientų a , b ir dispersijos σ^2 pasikliautiniai intervalai skaičiuojami pagal formules:

$$\hat{a} \pm s_a t_{(1-Q)/2}(n-2), \quad \hat{b} \pm s_b t_{(1-Q)/2}(n-2), \quad (21)$$

$$\left(\frac{SSE}{\chi_{(1-Q)/2}^2(n-2)}; \frac{SSE}{\chi_{(1+Q)/2}^2(n-2)} \right); \quad (22)$$

čia Q yra pasiklivimo lygmuo, $t_{(1-Q)/2}(n-2)$ – Stjudento skirstinio su $(n - 2)$ laisvės laipsnių $(1 - Q)/2$ lygmens kritinė reikšmė, $\chi_{(1+Q)/2}^2(n-2)$ yra χ^2 skirstinio su $(n - 2)$ laisvės laipsnių $(1 + Q)/2$ lygmens kritinė reikšmė. Visas kritines reikšmes galima rasti iš knygos pabaigoje pateikiamų lentelių. Atkreipiame dėmesį, kad formulėse yra s_a , s_b , o ne s_a^2 , s_b^2 . Žinoma, įstatydami į (21)–(22) konkrečius stebėjimus, gauname konkretius pasikliautinių intervalų realizacijas.

Dažniausiai ieškoma 95% pasikliautinių intervalų (t. y. $Q = 0,95$). Kaip juos skaičiuoti, nurodyta 5.3 lentelėje.

5.3 lentelė. 95% pasikliautiniai intervalai

Parametras	Pasikliautinojo intervalo režiai	
	Apatinis	Viršutinis
a	$\hat{a} - s_a t_{0,025}(n-2)$	$\hat{a} + s_a t_{0,025}(n-2)$
b	$\hat{a} - s_b t_{0,025}(n-2)$	$\hat{a} + s_b t_{0,025}(n-2)$
σ^2	$SSE/\chi_{0,025}^2(n-2)$	$SSE/\chi_{0,975}^2(n-2)$

5.9 pavyzdys. Apskaičiuokime 5.1 pavyzdžio koeficientų ir dispersijos 95% pasikliautinius intervalus. Jau buvome gavę, kad regresijos tiesės lygtis, siejanti temperatūrą (x) ir suvalgytų ledų kiekį (y), yra $\hat{y}(x) = 71,28 + 1,84x$. Be to, $SSE = 15,99$, $\bar{x} = 24,458$, $MSE = 0,727$, $s_b = 0,075$. Iš lentelių nustatome $t_{0,025}(22) = 2,069$, $\chi_{0,025}^2(22) = 36,781$, $\chi_{0,975}^2(n-2) = 10,982$. Pagal 5.3 lentelę randame pasikliautinius intervalus: dispersijos – (0,435; 1,456), temperatūros daugiklio – (1,68; 1,99), konstantos – (67,44; 75,12).

5.6.2. Hipotezė apie koeficiento b lygybę nuliui



Didžioji mokslo tragedija – nuostabios hipotezės mirtis nuo bjauraus fakto.

T. H. Haksliis

Žinodami koeficientų įverčių skirstinius, galime tikrinti statistines hipotezes apie pačių koeficientų reikšmes. Statistinė hipotezė $H_0: a = 0$ aktuali tik tuo atveju, kai svarbu įsitikinti, ar regresijos tiesė kerta koordinačių susikirtimo tašką (0, 0). Taip būna retai. Todėl šios hipotezės plačiau neaptarsime, tik pažymėsime, kad ji tikrinama visiškai analogiškai hipotezei apie b reikšmę ir naudojama statistika $(\hat{a} - a)/s_a$.

Mus labiausiai domina, ar koeficientas b nelygus nuliui, nes tuo atveju regresijos modelis virsta $Y_i = a + e_i$, t. y. Y_i nepriklauso nuo x_i . Užrašysime, kaip patikrinti hipotezę apie koeficiento b lygybę nuliui.

1 *Duomenys.* Turime porinius stebėjimus $(x_1, y_1), \dots, (x_n, y_n)$. Visos tiesinės regresijos prielaidos galioja.

2 *Statistinė hipotezė:*

$$\begin{cases} H_0: b = 0, \\ H_1: b \neq 0. \end{cases} \quad (23)$$

3 *Kriterijaus statistika.* Apskaičiuojame statistiką $T = \hat{b}/s_b$.

4 *Sprendimo priėmimo taisyklė.* Tegul reikšmingumo lygmuo lygus α . Hipotezė H_0 atmetama, jeigu $|T| > t_{\alpha/2}(n-2)$; čia $t_{\alpha/2}(n-2)$ yra Stjudento skirstinio su $(n-2)$ laisvės laipsnių $\alpha/2$ lygmens kritinė reikšmė. Hipotezė H_0 neatmetama, jeigu $|T| \leq t_{\alpha/2}(n-2)$.

Trumpai tariant, jei nulinės hipotezės H_0 neatmetame, tai reiškia, kad Y nelabai priklauso nuo x , t. y. regresijos tiesė prognozėms daryti netinka, o atmesta nulinė hipotezė – kad tinka. Tačiau nereikia šio kriterijaus suabsoliutinti. Iš bendrosios hipotezių tikrinimo teorijos (žr. [1] knygą) žinome, kad pagal statistinius kriterijus priimamiems sprendimams didelę įtaką daro imties didumas. Todėl H_0 galima neatmesti tik todėl, kad imtyje per mažai stebėjimų, arba atmesti tik todėl, kad imtis labai didelė. Kita vertus, jeigu net labai didelei imčiai nulinė hipotezė atmetama, tai jau yra rimtas argumentas, kad regresijos modelis prognozėms tinka.

5.10 pavyzdys. Patikrinkime hipotezę apie 5.1 pavyzdžio 5.1 lentelės duomenų koeficiento b lygybę nuliui. Reikšmingumo lygmuo $\alpha = 0,05$.

Jau esame apskaičiavę koeficientą $\hat{b} = 1,84$ ir kai kurias kvadratų sumas. Randame $SSE = 15,99$, $MSE = 0,727$, $s_b^2 = 0,727/(14485 - 587^2/24) = 0,0057$, $s_b = 0,075$. Taigi $T = 1,84/0,075 = 24,4$. Iš priedo 2 lentelės randame $t_{0,025}(22) = 2,074$. Kadangi $T > 2,074$, tai nulinę hipotezę $H_0: b = 0$ atmetame. Galime teigti, kad regresijos modelyje koeficientas b nelygus nuliui, t. y. prognozuojant suvalgytų ledų kiekį temperatūra yra svarbi.

5.11 pavyzdys. Patikrinkime hipotezę apie 5.6 pavyzdžio 5.2 lentelės duomenų koeficiento b lygybę nuliui. Reikšmingumo lygmuo $\alpha = 0,10$.

Atlikę nesudėtingus skaičiavimus, randame $T = 0,78$. Kadangi $t_{0,05}(25) = 1,7$, tai nulinės hipotezės H_0 neatmetame. Neturime statistiškai patikimo įrodymo, kad regresijos modelyje koeficientas b nelygus nuliui. Taigi dar kartą gavome patvirtinimą, kad abejotina, jog savęs sureikšminimas nuo amžiaus priklauso tiesiškai.

Statistinio kriterijaus naudojama statistika T su determinacijos koeficientu r^2 yra susijusi tokia priklausomybe:

$$r^2 = \frac{T^2}{T^2 + (n - 2)}. \quad (24)$$



Regresijos modelio tinkamumą galima tikrinti naudojantis ir vienfaktorine dispersine analize. Paprastosios regresijos atveju (kai yra tik vienas nepriklausomas kintamasis) tikrinamoji hipotezė sutampa su (23) formule, o apskaičiuotoji dispersinės analizės statistika išreiškiama taip: $F = SSR/MSE = T^2$. Sutampa ir pagal abu kriterijus daromos statistinės išvados. Esant daugia-lypei regresijai, minėti kriterijai nesutampa ir bus aptariami atskirai.

Naudojantis SPSS paketu, taip pat galima skaičiuoti koeficientų pasikliautuosius intervalus ir tikrinti hipotezes apie koeficientų lygybę nuliui. Nagrinėtame 1 skyriaus 1.14 pavyzdyje buvo tirta avarijose sužeistų žmonių ir avarijų skaičiaus priklausomybė. Tarę, kad nepriklausomas kintamasis yra avarijų skaičius, o priklausomas – sužeistųjų skaičius, užrašysime regresijos tiesės lygtį ir įvertinsime jos parametrus. SPSS paketu gauti rezultatai pateikti 5.10 paveiksle. Pirmame stulpelyje įvardyti kintamieji: Constant (atitinka modelio parametą a), AVARIJOS (atitinka modelio kintamąjį x). Antrame stulpelyje (B) pateikiami koeficientai $\hat{a}$, $\hat{b}$. Kadangi priklausomas kintamasis yra SUŽEISTI (atitinka modelio kintamąjį y), tai regresijos lygtis yra

$$SUŽEISTI = 1,361 \cdot AVARIJOS - 1212,225. \quad (25)$$

Pastaba. Kalbėdami apie regresijos modelį, priklausomą kintamąjį žymėjome Y , o nepriklausomą – X . Konkrečiuose uždaviniuose šie kintamieji turi savo pavadinimus (pvz., SUŽEISTI, AVARIJOS).

COEFFICIENTS ^a							
Model	Unstandardized Coefficients		Standardized Coefficients	t	Sig.	95% Confidence Interval	
	B	Std. Error	Beta			Lower Bound	Upper Bound
1 (Constant)	-1212,225	398,110		-3,045	,016	2,032	4,368
AVARIJOS	1,361	,078	,987	17,497	,000	-,921	1,521

^a. Dependent Variable: SUŽEISTI

5.10 pav. SPSS paketu gauta regresijos koeficientų lentelė

Stulpelyje Std. Error užrašytos $s_a = 398,110$ ir $s_b = 0,078$ reikšmės. Stulpelyje Beta pateiktas standartizuotų duomenų regresijos tiesės lygties koeficientas (žr. komentarą 5.3 skyrelyje). Nagrinėjamu paprastosios tiesinės regresijos atveju šis koeficientas sutampa su avarių ir sužeistųjų skaičiaus koreliacijos koeficientu (0,987).

Stulpeliuose t ir Sig. pateikiamos hipotezių $H_0: a = 0$ ir $H_0: b = 0$ statistikos bei p -reikšmės.

Nulinė hipotezė H_0 atmetama (koeficientas statistiškai reikšmingai skiriasi nuo 0), jeigu p -reikšmė $p < \alpha$, čia α yra pasirinktasis reikšmingumo lygmuo.

Pirmoji statistinė hipotezė $H_0: a = 0$ šiuo atveju neaktuali. Antroji statistinė hipotezė $H_0: b = 0$ aptarta anksčiau ir parodo, ar sužeistųjų skaičius priklauso nuo avarių skaičiaus. Tarkime, kad pasirinkome reikšmingumo lygmenį 0,05. Kadangi 5.10 paveiksle pateiktoji p -reikšmė lygi $0,00 < 0,05$, tai nulinė hipotezė H_0 atmetama – prognozuojant sužeistųjų skaičių avarių skaičius svarbus ir regresijos modelyje reikalingas.

Paskutiniuose dviejuose stulpeliuose pateikti koeficientų a ir b 95% pasikliautinųjų intervalų režiai. Pavyzdžiui, koeficiento b pasikliautinis intervalas yra $(-0,921; 1,521)$.

5.6.3. Durbino–Vatsonio kriterijus

Kartais prognozės liekamosios paklaidos būna priklausomos. Pavyzdžiui, akcijų kursas kinta nevisiškai atsitiktinai. Vieną dieną nusistovėjęs akcijų kursas 200 Lt, kitą dieną pradeda mažėti ar didėti nuo 200 Lt. Regresijos modeliai su koreliuojančiomis liekanomis nagrinėjami laiko eilučių teorijoje. Durbino–Vatsonio¹ kriterijus plačiai taikomas laiko eilučių teorijoje, kai norima nustatyti, ar yra vadinamasis autoregresijos modelis. Tuo tarpu mus domina, ar autoregresijos nėra. Suformuluosime šį kriterijų.

1 Prielaida. Regresijos modelio paklaidas sieja ryšys

$$e_i = \rho e_{i-1} + z_i; \quad (26)$$

čia $z_i \sim \mathcal{N}(0, \sigma^2)$ ir $z_1, z_2, \dots$ yra nepriklausomi atsitiktiniai dydžiai. Paklaidos e_i nekoreliuoja, jeigu $\rho = 0$. Patikrinsime šią hipotezę.

¹ J. Durbin, G. S. Watson – amerikiečių statistikai.

2 Statistinė hipotezė:


$$\begin{cases} H_0: \rho = 0, \\ H_1: \rho \neq 0. \end{cases}$$

3 Kriterijaus statistika. Apskaičiuojame statistiką

$$d = \frac{\sum_{i=2}^n (\hat{e}_i - \hat{e}_{i-1})^2}{\sum_{i=1}^n \hat{e}_i^2}. \quad (27)$$

4 Sprendimo priėmimo taisyklė. Tegul reikšmingumo lygmuo lygus 0,05. Iš 13 lentelės randame atitinkamas d_L ir d_U reikšmes. Hipotezė H_0 atmetama (taigi autokoreliacija yra), jeigu $d < d_L$ arba $d > 4 - d_L$. Hipotezė H_0 neatmetama (liekanų autokoreliacija statistiškai nereikšminga), jeigu $d_U < d < 4 - d_U$. Jokių statistinių išvadų negalima padaryti, kai $d_L \leq d \leq d_U$ arba $4 - d_U \leq d \leq 4 - d_L$. Grafiškai sprendimo taisyklė pavaizduota 5.11 paveiksle.

Pastaba. Durbino–Vatsono statistika d kinta nuo 0 iki 4. Kuo d arčiau 2, tuo mažiau tikėtina, kad autokoreliacija yra. Durbino–Vatsono statistika yra viena iš SPSS paketo regresinės analizės opcijų.



5.12 pavyzdys. Apskaičiuokime 5.1 pavyzdžio Durbino–Vatsono statistiką. Nesunkiai įsitikiname, kad $d = 1,99$, t. y. labai arti 2. Iš lentelės randame $d_L = 1,16$ ir $d_U = 1,33$. Kadangi $4 - d_U = 2,67$, tai $d_U < d < 4 - d_U$, t. y. neturime pagrindo manyti, kad liekanos koreliuoja.

5.7. Prognozavimas regresinėje analizėje



Londono gyventojų skaičius negali viršyti milijono, nes statistika rodo, kad tuomet miestas paprasčiausiai uždus nuo į karietas kinkomų arklių mėšlo.

(XVIII a. pabaigos mokslinis tyrimas)

Trečiajame skyrelyje nurodėme, kad priklausomo kintamojo reikšmės prognozuojamos pagal regresijos tiesę. Aptarsime, kokie reikalavimai keliami prognozėms ir kaip jas galima patikslinti.

5.7.1. Reikšmių prognozavimas

Prognozuojama naudojantis regresijos lygtimi $\hat{y}(x) = \hat{a} + \hat{b}x$, kurios koeficientai nusakyti (5) ir (6) lygybėmis. Pavyzdžiui, 5.1 pavyzdyje nagrinėdami temperatūrą ir suvalgytų

ledų kiekį siejančią priklausomybę gavome lygtį

$$LEDAI = 71,28 + 1,84 \cdot TEMPERAT. \quad (28)$$

Taip pat buvo pateikta prognozė dienos, kurios vidutinė temperatūra $27,5^\circ\text{C}$.

Aptarsime, ką reiškia prognozuoti pagal regresijos tiesės lygtį. Prisiminkime (2) modelį. Tarkime, kad prognozę norime padaryti konkrečiai fiksuotai nepriklausomo kintamojo reikšmei x . Iš (2) modelio išplaukia, kad tada priklausomas kintamasis

$$Y = a + bx + e; \quad (29)$$

čia $e \sim \mathcal{N}(0, \sigma^2)$ yra atsitiktinė paklaida. Vadinasi, su fiksuotomis x reikšmėmis Y gali įgyti įvairias reikšmes, nes joms įtakos turi ir atsitiktinė paklaida. Todėl nelabai tikėtina, kad pasiseks *tiksliai* atspėti tikrąją būsimąją Y reikšmę. Ką tuomet prognozuojame?

Kadangi e skirstinys yra normalusis, tai normaliai pasiskirstęs ir kintamasis Y . Normaliojo kintamojo tankis didžiausią reikšmę įgyja vidurkio taške. Todėl geriausia, ką galima padaryti, tai prognozuoti Y reikšmę, kiek galima artimesnę visų galimų (fiksuotam x) kintamojo Y reikšmių vidurkiui. Taip ir darome: $\hat{a}$ yra a , o $\hat{b}$ yra b įverčiai, todėl akivaizdu, kad regresijos tiesė $\hat{y}(x) = \hat{a} + \hat{b}x$ yra lygties $EY = a + bx$ (kurioje jau nėra atsitiktinių dydžių, tik nežinomi daugikliai) analogas.

Taigi taikydami $\hat{y}(x)$ prognozei, siekiame, kad prognozuojamoji reikšmė būtų kiek galima artimesnė, esant tam tikram fiksuotam x , galimų y_i reikšmių vidurkiui.

Prisiminkime 1.14 pavyzdį apie sužeistųjų ir avarių skaičiaus priklausomybę. Šiuos kintamuosius sieja (25) regresijos tiesės lygtis. Per metus, kai įvyks 5000 avarių, prognozuojame $1,361 \cdot 5000 - 1212,225 = 5592,775$ sužeistųjų.

Atkreipiame dėmesį, kad norėdami prognozuoti vidutinę Y reikšmę, esant fiksuotam x , naudotumėmės ta pačia regresijos tiesės lygtimi ir gautume tą pačią prognozę.



– Įdomiai apie tai samprotauja Vinvudas Ridas, – tęsė Holmsas. – Jis teigia: individas yra neatspėjama mįslė, o žmonių visuma – matematinė tikrybė. Pavyzdžiui, niekad iš anksto nepasakysi, kaip pasielgs konkretus žmogus, bet gali tiksliai nusakyti, ką darys dauguma žmonių tam tikromis aplinkybėmis. Individai skiriasi, bet procentinis santykis lieka pastovus. Tai byloja statistika.

A. Konanas Doilis. Keturių ženklas

Viena iš būdingiausių bet kokio prognozavimo klaidų yra bandymas pernelyg tolimą ateitį spėti remiantis dabarties prielaidomis. Norėdami jų išvengti, griežčiau apibrėšime, kokioms x reikšmėms galima prognozuoti Y reikšmes.

Regresinėje analizėje prognozės daromos tik toms x reikšmėms, kurios patenka į duomenų intervalą, t. y. tik tada, kai $\min(x_1, \dots, x_n) \leq x \leq \max(x_1, \dots, x_n)$.

Prisiminkime 5.1 pavyzdį. Duomenys ir 5.5 paveikslo, a) grafikas leidžia manyti, kad (28) formulė daugmaž teisingai parodo vidutinio ledų kiekio ir temperatūros priklausomybę, kai temperatūra kinta nuo 13 iki 34°C . Geriausiu atveju galime įtarti, kad panaši priklausomybė išliks, kai temperatūra bus truputį žemesnė už 13 arba truputį aukštesnė už 34°C . Tačiau mes negalime (28) lygties taikyti ledų suvartojimo prognozei, kai temperatūra yra 0 arba 43°C .

Nesunku pastebėti, kad $\hat{y}(0) = \hat{a}$. Tarkime, kad x yra dirbtas laikas, o Y – pagaminta produkcija. Jeigu $\hat{a} > 0$, tai gautume, kad niekas nedirbo, o produkcija vis tiek

pagaminta. Todėl kyla pagunda reikalauti, kad $\hat{a} = 0$. Tačiau toks reikalavimas pagrįstas tik tuomet, jeigu $x = 0$ pateko į duomenų x sritį. Kai $\hat{a} > 0$, tiesė gali gerai aprašyti kintamųjų elgesį tiriamajame intervale, o kituose intervaluose kintamuosius gali sieti visai kita priklausomybė.

5.7.2. Prognozės intervalas

Esant fiksuotam x , galima prognozuoti galimų Y reikšmių *intervalą*. Faktiškai reikia mokėti sudaryti skirtumo $Y - \hat{y}(x)$ prognozės intervalą. Fiksuokime nepriklausomojo kintamojo reikšmę x . Tegul

$$SY = MSE \left(1 + \frac{1}{n} + \frac{(x - \bar{x})^2}{(n-1)s_x^2} \right); \quad (30)$$

čia s_x^2 yra empirinė $x_1, \dots, x_n$ dispersija (žr. (19) formulę).



Nesunku įsitikinti, kad SY yra $Y - \hat{y}(x)$ dispersijos įvertis. Iš tikrųjų, jeigu atsižvelgtume į Y , $\hat{a}$ ir $\hat{b}$ kitimą, tai iš (18), (19) išplauktų


$$\begin{aligned} \mathbf{D}(Y - \hat{y}(x)) &= \mathbf{D}(a - \hat{a}) + x^2 \mathbf{D}(b - \hat{b}) + 2x \text{cov}(a - \hat{a}, b - \hat{b}) + \mathbf{D}e \\ &= \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{(n-1)s_x^2} \right) + \sigma^2 \frac{x^2}{(n-1)s_x^2} - 2x\sigma^2 \frac{\bar{x}}{(n-1)s_x^2} + \sigma^2 \\ &= \sigma^2 \left(1 + \frac{1}{n} + \frac{(x - \bar{x})^2}{(n-1)s_x^2} \right). \end{aligned} \quad (31)$$

Belieka nežinomą dispersiją σ^2 pakeisti jos įverčiu $MSE = SSE/(n-2)$.

Yra žinoma, kad $(Y - \hat{y}(x))/\sqrt{SY}$ turi Stjudento skirstinį su $(n-2)$ laisvės laipsnių. Todėl Q pasiklovimo lygmens $y(x)$ pasikliautinasis intervalas yra $\hat{y}(x) \pm t_{(1-Q)/2}(n-2)\sqrt{SY}$; čia $t_{(1-Q)/2}(n-2)$ yra Stjudento kriterijaus su $(n-2)$ laisvės laipsnių $(1-Q)/2$ lygmens kritinė reikšmė. Kaip ir 5.7.1 skyrelyje, reikalaujama, kad x būtų iš duomenų intervalo, t. y. $\min(x_1, \dots, x_n) \leq x \leq \max(x_1, \dots, x_n)$. Dažniausiai skaičiuojamas 95% prognozės intervalas.

Kintamojo Y , esant fiksuotam x , 95% prognozės intervalas yra

$$[\hat{y}(x) - \sqrt{SY}t_{0,025}(n-2); \hat{y}(x) + \sqrt{SY}t_{0,025}(n-2)].$$



Akivaizdu, kad prognozės intervalo plotis priklauso ne tik nuo imties didumo, bet ir nuo x reikšmės. Kuo x arčiau $\bar{x}$, tuo prognozės intervalas siauresnis (žr. 5.12 pav.).

5.13 pavyzdys. Apskaičiuokime 5.1 pavyzdžio suvalgomų ledų kiekio, esant 27,5°C temperatūrai, 95% prognozės intervalą. Jau buvome radę $\hat{y}(27,5) = 121,88$ kg. Iš priedo 2 lentelės randame $t_{0,025}(22) = 2,074$. Be to, $\bar{x} = 24,46$, $22s_x^2 = 127,96$, $MSE = 0,727$. Todėl nesunkiai įsitikiname, kad ieškomasis prognozės intervalas yra (120,01; 123,75). Taigi su 95% pasiklovimu galime prognozuoti, kad dieną, kai vidutinė temperatūra 27,5°C, reikės nuo 120,01 iki 123,75 kg ledų.

5.7.3. Vidutinės prognozuojamos reikšmės pasikliautinis intervalas

Tegul x yra fiksuota reikšmė iš prognozavimui tinkamo reikšmių intervalo. Esame minėję, kad ta pati regresijos tiesės lygtis $\hat{y}(x) = \hat{a} + \hat{b}x$ yra naudojama ir konkrečiai reikšmei $Y = a + bx + e$ ir vidutinei reikšmei $EY = a + bx$ prognozuoti. Kuo skiriasi šios dvi prognozės? Jeigu mus domina, kiek ledų bus suvalgyta per dieną, kurios vidutinė temperatūra yra 27,5°C, tai kalbame apie konkrečios reikšmės prognozę. Jeigu norime įvertinti, kiek vidutiniškai ledų bus suvalgyta dienomis, kurių vidutinė temperatūra yra 27,5°C, tai kalbame apie vidutinės reikšmės (vidurkio) prognozę. Vieną dieną gali būti suvalgoma daugiau ledų, kitą – mažiau, o mus domina vidurkis.

Nors pačios prognozuojamosios reikšmės abiem atvejais sutampa, jų pasikliautinieji intervalai skiriasi. Vidurkio pasikliautinis intervalas yra siauresnis. Statistikos $EY - \hat{y}(x)$ dispersijos įvertis yra

$$SEY = MSE \left(\frac{1}{n} + \frac{(x - \bar{x})^2}{(n-1)s_x^2} \right). \quad (32)$$



Nesunku įsitikinti, kad SEY nuo SY skiriasi tik dar vienu dėmeniu (MSE). Taip yra todėl, kad

$$\mathbf{D}(EY - \hat{y}(x)) = \mathbf{D}(a - \hat{a}) + x^2 \mathbf{D}(b - \hat{b}) + 2xcov(a - \hat{a}, b - \hat{b}),$$

t. y. sumoje nebelieka $\mathbf{D}e = \sigma^2$.

Yra žinoma, kad $(EY - \hat{y}(x))/\sqrt{SEY}$ turi Stjudento skirstinį su $(n-2)$ laisvės laipsnių. Todėl Q pasiklovimo lygmens $y(x)$ pasikliautinis intervalas yra $\hat{y}(x) \pm t_{(1-Q)/2}(n-2)\sqrt{SEY}$; čia $t_{(1-Q)/2}(n-2)$ yra Stjudento kriterijaus su $(n-2)$ laisvės laipsnių $(1-Q)/2$ lygmens kritinė reikšmė.

Dažniausiai skaičiuojamas 95% prognozės intervalas.

$$EY, \text{ esant fiksuotam } x, 95\% \text{ prognozės intervalas yra} \\ [\hat{y}(x) - \sqrt{SEY}t_{0,025}(n-2); \hat{y}(x) + \sqrt{SEY}t_{0,025}(n-2)].$$

5.14 pavyzdys. Apskaičiuokime 5.1 pavyzdžio vidutinio suvalgomų ledų kiekio, esant 27,5°C temperatūrai, 95% pasikliautinąjį intervalą. Jau radome $\hat{y}(27,5) = 121,88$ kg ir $t_{0,025}(22) = 2,074$. Todėl nesunkiai įsitikiname, kad ieškomasis pasikliautinis intervalas yra (121,59; 122,17). Taigi su 95% pasiklovimu galime prognozuoti, kad vidutiniškai per dieną, kurios vidutinė temperatūra yra 27,5°C, reikia nuo 121,59 iki 122,17 kg ledų.

Vidurkio pasikliautinis intervalas visada trumpesnis už prognozės intervalą.



atvirkštinė regresijos tiesė	išskirtis	mažiausiųjų kvadratų
determinacijos koeficientas	įtakos indeksas	metodas
Durbino–Vatsono kriterijus	Kuko matas	prognozės intervalas
heteroskedastiškumas	liekamoji paklaida	regresijos tiesė
homoskedastiškumas		standartizuotoji liekana

UŽDAVINIAI

1. Tegul X yra nepriklausomas kintamasis. Sudarykite ir ištirkite tiesinės regresijos modelius tais atvejais, kai priklausomas kintamasis yra Y , Z arba U . Reikšmingumo lygmuo $\alpha = 0,05$.


5.4 lentelė

x	y	z	u
6	−361	690	47,6
7	−327	526	61,8
8	−292	387	77,4
9	−258	724	53,2
10	−223	186	74,5
11	−189	123	93,1
12	−154	86	85,4
13	−119	74	88,3
14	−85	87	113,4
15	374	126	80,8
16	−16	190	104,6

2. Visuomeninis centras „Madam“ kreipėsi į vyriausybę su prašymu visus valdininkus priversti lankyti jų centro organizuojamus džentelmeniškumo kursus. Kursų naudą pagrindė duomenimis, pateiktais 5.5 lentelėje. Joje užfiksuota, kiek kartų kiekvienas vyras kursuose treniravosi būti džentelmenu (x) ir kiek po to per mėnesį savo žmonai viešai pasakė komplimentų (skaičiavo uošvė). Ištirkite, ar tinka tiesinės regresijos modelis, ir padarykite prognozę, kiek komplimentų pasakys vyras, treniravęsis 267 kartus. Sudarykite 95% prognozės ir vidurkio pasikliautinąjį intervalus.

5.5 lentelė. Džentelmenų treniruotės

Treniruotės	254	230	254	300	320	364	312	264	274	226	274	234	274	306	234	252
Komplimentai	124	108	85	152	140	198	182	125	130	95	171	102	115	109	115	134
Treniruotės	340	364	324	368	286	318	216	350	216	358	222	374	222	230	360	336
Komplimentai	213	155	188	204	85	148	106	155	73	179	118	159	79	74	180	126



3. Autoremonta dirbtuvių šeimininkas mąsto, ar nereiktų pakelti senų automobilių remonto kainos. Jis žymėjosi automobilio amžių (metais) ir remonto trukmę (valandomis). Visi gedimai buvo mechaniniai. Duomenys pateikti 5.6 lentelėje. Patikrinkite, ar tinka tiesinės regresijos modelis. Reikšmingumo lygmuo $\alpha = 0,05$.

5.6 lentelė. Gedimai ir taisymo trukmė

Amžius	1	2	6	8	3	2	11	15	8	4	6	12	9	10	3	4
Trukmė	2,5	3	9,5	11	4	2,5	15	20,5	10,5	5,5	9	16,5	12,5	13,5	4,5	5,5

4. Paplūdimio gelbėtojų tarnyba visą mėnesį fiksavo vandens temperatūrą ir maksimalų besimaudančiųjų skaičių (atsižvelgdama į jį, planuoja, kiek reikia budinčių gelbėtojų). Duomenys pateikti 5.7 lentelėje. (Vieną dieną paplūdimyje vyko sveikuolių fiesta.) Patikrinkite, ar tinka regresijos modelis. Reikšmingumo lygmuo $\alpha = 0,05$. Ką galima pasakyti apie regresijos modelį, pašalinus išskirtį?

5.7 lentelė. Vanduo ir mauduoliai

Vandens temp.	17	18	16	18	16	18	14	15	19	12	12	14
Mauduoliai	79	83	78	82	78	81	74	76	84	71	72	73
Vandens temp.	20	14	15	15	20	16	18	21	17	17	16	12
Mauduoliai	85	76	76	77	86	79	82	88	81	82	79	120

5. Medicinos fakulteto studentas tyrė kraujo spaudimo ir insulto rizikos balo priklausomybę. Kokį rizikos balą galima prognozuoti pacientui, kurio kraujo spaudimas yra 180? Sudarykite 95% prognozės intervalą.

5.8 lentelė. Kraujo spaudimas ir insulto rizika

Spaudimas	150	162	155	173	195	188	155	120	136	100	150
Rizika	27	40	28	60	43	55	33	43	49	30	37
Spaudimas	170	135	200	199	118	165	126	118	203	149	121
Rizika	51	31	62	30	40	30	45	26	52	27	30

6. Buvo tiriama, kaip greitai žmonės suranda tekste nurodytą specialų simbolį. Spėjama, kad paieškos trukmės ir numerio eilutės, kurioje paslėptas simbolis, priklausomybė yra tiesinė. Sudarykite paieškos trukmės, kai simbolis yra 20 eilutėje, 90% prognozės intervalą.

5.9 lentelė. Simbolio paieška

Eilutė	8	11	15	18	19	21	23	24	25	29	32	35	36	39	40	41
Trukmė	7	8	8	6	10	15	13	14	16	17	19	21	23	26	27	29

7. Lietuvos banko duomenys (mln. Lt) apie terminuotus ir taupomuosius indėlius šalies bankuose (kintamasis *TIND*) bei indėlius užsienio valiuta (kintamasis *UIND*) 1999–2001 m. pateikti 5.10 lentelėje. Ar taikant tiesinės regresijos modelį ir žinant

TIND reikšmės galima prognozuoti indėlių užsienio valiuta atsargas? Apskaičiuokite Durbino–Vatsono statistiką.

5.10 lentelė

Metai, mėnuo	<i>TIND</i>	<i>UIND</i>
2001 10	1 697	4 198
2001 09	1 703	4 187
2001 08	1 639	4 164
2001 07	1 565	4 087
2001 06	1 549	3 915
2001 05	1 526	3 923
2001 04	1 475	3 844
2001 03	1 468	3 846
2001 02	1 422	3 746
2001 01	1 333	3 705
2000 12	1 228	3 555
2000 11	1 279	3 436
2000 10	1 235	3 381
2000 09	1 274	3 259
2000 08	1 211	3 200
2000 07	1 203	3 053
2000 06	1 192	3 026
2000 05	1 176	2 986
2000 04	1 089	2 905
2000 03	1 080	2 862
2000 02	1 069	2 830
2000 01	1 006	2 766
1999 12	972	2 725
1999 11	936	2 718
1999 10	1 010	2 661
1999 09	1 035	2 565
1999 08	1 068	2 552
1999 07	1 062	2 473
1999 06	1 052	2 305
1999 05	1 041	2 195
1999 04	945	2 090
1999 03	915	2 023
1999 02	876	2 048
1999 01	833	2 040

6. DAUGIALYPĖ REGRESIJA



Yra dviejų rūšių prognozuotojai: tie, kurie ateities nežino, ir tie, kurie nežino, kad nežino.

Dž. K. Galbraitas

Žinodama, kurie iš studentų bus geri gyvybės draudimo specialistai, draudimo kompanija galėtų su jais sudaryti išankstines sutartis. Tarkime, buvo tirti keliasdešimties studentų *IQ*, nustatyti jų matematikos ir ekonomikos dalykų pažymių vidurkiai, įvertinti darbo kompiuteriu įgūdžiai. Be to, studentai buvo stebėti ir po studijų baigimo. Praėjus metams nuo darbo draudimo kompanijose pradžios, taškais (iki 100) buvo įvertintas kiekvieno iš jų profesionalumas.

Norint tarp studentų nustatyti būsimus gerus specialistus, reiktų prognozuoti jų profesionalumo balą. Tam taikoma daugialypė (daugelio kintamųjų) regresija. Daugialypė regresinė analizė daug kuo panaši į paprastąją: panašiai skaičiuojamas determinacijos koeficientas, ieškoma išskirčių, analizuojamos liekamosios paklaidos, daromos prognozės. Tačiau kyla ir naujų problemų: ar prognozuojant visi nepriklausomi kintamieji būtini; kurie iš jų prognozėms svarbiausi; ar negalima būtų atsižvelgti į papildomą kokybinę informaciją. Pavyzdžiui, gali paaiškėti, kad profesionalumas visai nepriklauso nuo darbo kompiuteriu įgūdžių, tuo tarpu matematikos ir ekonomikos disciplinų pažymių vidurkiai stipriai koreliuoja, o tai kenkia prognozių stabilumui ir pan. Pabrėžiame, kad net ir gerai su duomenimis suderintas daugialypės regresijos modelis konkrečiu atveju tikslios prognozės negarantuoja. Gali būti, kad geras specialistas studijuodamas tiesiog tinginiavo arba prastas specialistas studijuodamas per egzaminus sumaniai nusirašinėjo. Abiem atvejais tikrasis profesionalumo balas gali labai skirtis nuo regresijos prognozės. Vis dėlto sudarant išankstinę sutartį, rizika įsigyti prastą specialistą bus mažesnė į prognozę atsižvelgus.



Prieš keliolika metų Lietuvos matematikų draugijos konferencijoje buvo perskaitytas pranešimas apie naują tarybinės edukologijos laimėjimą. Pranešėjas įrodinėjo, kad geriausiai būsimų matematikos mokytojų kvalifikaciją leidžia prognozuoti valstybinio „mokslinio komunizmo“ egzamino pažymys (...ir su statistika nepasiginčysi!). Matematikai šią naujieną sutiko skeptiškai. Paaiškėjo, kad pranešėjas gana savotiškai supranta matematikos mokytojo kvalifikaciją – išvadas padarė sužinojęs, ką apie naująją (pusmetį teišdirbusį!) mokytoją mano tos mokyklos direktorius.



Pavyzdžiui, daugialypės regresijos prireikia, kai:

- norima nustatyti, kaip buto kaina priklauso nuo jo ploto ir nuo namo senumo;
- reikia atsakyti į klausimą, ar užsiregistravusio darbo biržoje bedarbio pasiūlymų laukimo trukmė priklauso nuo jo amžiaus, išsilavinimo, šeimos narių skaičiaus bei ankstesnio atlyginimo;
- tiriama, kaip antikvarinių indų aukciono kaina priklauso nuo jų senumo bei aukciono dalyvių skaičiaus;
- tiriama, kaip per sezoną laimėtų krepšinio varžybų skaičius priklauso nuo metimų pataikymo procento, nuo vidutinio blokuotų bei per rungtynes perimtų kamuolių skaičiaus;
- nustatinėjama, ar po egzamino bendrasis dirglumo indeksas priklauso nuo gauto pažymio, sistolinio ir diastolinio kraujo spaudimo ir pan.

Kaip ir paprastosios regresijos atveju, iš anksto nusprendžiame, kurio intervalinio kintamojo reikšmės prognozuosime (t. y. kuris kintamasis yra *priklausomas*) ir pagal kuriuos kintamuosius prognozuosime (t. y. kurie kintamieji yra *nepriklausomi*). Išskyrus specialųjį atvejį (žr. 6.7 skyrelį), visi kintamieji yra intervaliniai.

Šiame skyriuje nagrinėjame *tiesinę* daugialypę regresiją, t. y. atvejį, kai vienas intervalinis kintamasis nuo keleto (nepriklausomų) intervalinių kintamųjų priklauso tiesiškai. Keletas pastabų apie netiesinius modelius pateikta 6.10 skyrelyje.

6.1. Daugialypės regresijos modelis

Daugialypės regresijos modelis yra 5 skyriaus (2) modelio apibendrinimas, kai nepriklausomų intervalinių kintamųjų yra daugiau nei vienas. Tarkime, kad Y yra priklausomas kintamasis, kurio i -ąją reikšmę Y_i norime prognozuoti esant fiksuotoms (neatsitiktinėms) nepriklausomų kintamųjų reikšmėms $X_1 = x_{1i}, \dots, X_k = x_{ki}$. Tuomet tiesinės daugialypės regresijos modelis yra

$$Y_i = a + b_1x_{1i} + b_2x_{2i} + \dots + b_kx_{ki} + e_i; \quad (1)$$

čia e_i yra atsitiktinė paklaida (atsitiktinis dydis). Modelio koeficientai $a, b_1, b_2, \dots, b_k$ nežinomi. Tikrindami, ar modelis tinka, kartu randame ir šių koeficientų įverčius.

Regresijos modelio prielaidos išlieka tos pačios kaip ir paprastosios regresijos. Pakartosime jas.

Tiesinės daugialypės regresijos prielaidos:

- 1) e_i normaliai pasiskirstę atsitiktiniai dydžiai;
- 2) visų e_i vidurkiai lygūs nuliui, t. y. $Ee_i = 0$;
- 3) visų e_i dispersijos lygios nežinomam skaičiui σ^2 ;
- 4) visi e_i nepriklausomi.

Viskas, kas 5.2 skyrelyje pasakyta apie šias prielaidas, galioja ir daugialypės regresijos atveju. Pavyzdžiui, iš prielaidų išplaukia, kad Y_i yra normalusis atsitiktinis dydis, o jo vidurkį ir nepriklausomų kintamųjų fiksuotas reikšmės sieja determinuota priklausomybė

$$EY_i = a + b_1x_{1i} + b_2x_{2i} + \dots + b_kx_{ki}. \quad (2)$$

Be minėtųjų modelio prielaidų, dar reikalaujama, kad vienas nepriklausomas kintamasis nebūtų likusiųjų tiesinė daugdara. Pavyzdžiui, tegul $k = 2$ ir kintamuosius sieja determinuota tiesinė priklausomybė $x_{1i} = 3 - 2x_{2i}$. Tuomet mažiausiųjų kvadratų metodu negalima gauti nežinomų modelio parametrų įverčių. Iš tiesų, iš (1) modelio išplaukia, kad

$$Y_i = (a + 3b_1) + (b_2 - 2b_1)x_{2i}. \quad (3)$$

Remdamiesi 5 skyriuje išdėstytais metodais, galime įvertinti koeficientų sumas $a + 3b_1$ ir $b_2 - 2b_1$, bet ne pačius koeficientus a , b_1 , b_2 .

Net ir stipri nepriklausomų kintamųjų koreliacija (kai koreliacijos koeficientas absoliučioju didumu artimas vienetui) neigiamai veikia prognozių stabilumą. Tai vadinamoji *multikolinearumo* problema. Išsamiau multikolinearumo problema aptarta 6.6 skyrelyje.

6.2. Regresijos funkcija



Garsios prognozės:

1895 metai. *Sunkesni už orą skraidymo aparatai negalimi.*

1897 metai. *Radijas neturi ateities.*

1900 metai. *Ateityje bus įrodyta, kad rentgeno spinduliai – apgavystė.*

1943 metai. *Pasauliui reikia ne daugiau kaip penkių kompiuterių.*

1977 metai. *Nėra jokios priežasties manyti, kad kas nors norės turėti kompiuterį namuose.*

Vienas iš regresijos tikslų – priklausomojo kintamojo reikšmių prognozavimas. Aptarsime, kaip tai daroma daugialypėje regresijoje. Tarsime, kad visur šiame skyriuje duomenis sudaro intervalinių kintamųjų rinkinio stebėjimai $(x_{11}, x_{21}, \dots, x_{k1}, y_1)$, $(x_{12}, x_{22}, \dots, x_{k2}, y_2)$, $\dots$, $(x_{1n}, x_{2n}, \dots, x_{kn}, y_n)$.

Kaip ir paprastosios regresijos atveju (žr. 5.3 skyrelį), mūsų tikslas – rasti parametrų a , $b_1, \dots, b_k$ tokius įverčius $\hat{a}$ ir $\hat{b}_1, \dots, \hat{b}_k$, kad funkcijos

$$\hat{y}(\vec{x}) = \hat{y}(x_1, x_2, \dots, x_k) = \hat{a} + \hat{b}_1 x_1 + \hat{b}_2 x_2 + \dots + \hat{b}_k x_k \quad (4)$$

reikšmės taškuose $(x_{1i}, x_{2i}, \dots, x_{ki})$ kiek galima mažiau skitūsi nuo y_i , t. y. visi skirtumai (*liekamosios paklaidos*)

$$\hat{e}_i = y_i - \hat{y}(\vec{x}_i) = y_i - (\hat{a} + \hat{b}_1 x_{1i} + \hat{b}_2 x_{2i} + \dots + \hat{b}_k x_{ki}), \quad (5)$$

$i = 1, 2, \dots, n$, būtų kiek galima mažesni.

Tokie parametrai randami mažiausiųjų kvadratų metodu, t. y. parenkami taip, kad liekamųjų paklaidų kvadratų suma $SSE = \sum_1^n \hat{e}_i^2$ būtų mažiausia.

Tarkime, kad mažiausiųjų kvadratų metodu radome SSE minimizuojančius parametrų įverčius $\hat{a}$, $\hat{b}_1, \dots, \hat{b}_k$. Tuomet $\hat{y}(\vec{x}) = \hat{a} + \hat{b}_1 x_1 + \hat{b}_2 x_2 + \dots + \hat{b}_k x_k$ vadinama *regresijos funkcija*.

Norint gauti prognozuojamą Y reikšmę, užtenka į $\hat{y}(\vec{x})$ įstatyti $x_1, x_2, \dots, x_k$ reikšmes. Žinoma, kaip ir paprastosios regresijos atveju, reikia atsiminti, kad prognozė daroma tik tokioms reikšmėms, kurios patenka į duomenų aprėptą sritį, t. y. x_1 turi būti iš intervalo $(\min_i x_{1i}, \max_i x_{1i})$ ir t. t.



Paprastosios regresijos atveju, kai yra tik vienas nepriklausomas kintamasis, regresijos funkcija apibrėžia tiesę. Panašiai yra ir daugialypėje regresijoje. Pavyzdžiui, kai yra du nepriklausomi kintamieji, tai $\hat{y}(\vec{x})$ apibrėžia plokštumą. Pati plokštumą parenkama taip, kad būtų kiek galima arčiau trimatės erdvės taškų $(x_{11}, x_{21}, y_1), \dots, (x_{1n}, x_{2n}, y_n)$. Kai nepriklausomų kintamųjų yra k , tai $\hat{y}(\vec{x})$ nusako $(k-1)$ -matę hiperplokštumą.

Bendruoju atveju ieškant regresijos funkcijos mažiausiųjų kvadratų metodu, reikia: a) apskaičiuoti $(k+1)$ dalinę SSE išvestinę pagal nežinomus parametrus, b) visas gautas išvestines prilyginti nuliui ir c) gautąją $(k+1)$ lygčių sistemą išspręsti. Būtent sprendžiant lygčių sistemą ir prireikia modelio prielaidose aptartojo reikalavimo, kad x_j nebūtų tiesiškai priklausomi. Praktiškai kiekviena statistinė kompiuterinė programa pateikia mažiausiųjų kvadratų metodu gautus parametrų įverčius, todėl formules užrašysime tik dviejų nepriklausomų kintamųjų atveju:

$$\hat{y}(\vec{x}) = \hat{y}(x_1, x_2) = \hat{a} + \hat{b}_1 x_1 + \hat{b}_2 x_2;$$

čia

$$\hat{b}_1 = \frac{U_{22}U_{1y} - U_{12}U_{2y}}{U_{11}U_{22} - U_{12}^2}, \quad \hat{b}_2 = \frac{U_{11}U_{2y} - U_{12}U_{1y}}{U_{11}U_{22} - U_{12}^2}, \quad (6)$$

$$\hat{a} = \bar{y} - \hat{b}_1 \bar{x}_1 - \hat{b}_2 \bar{x}_2, \quad (7)$$

$$U_{11} = \sum_{i=1}^n x_{1i}^2 - n\bar{x}_1^2, \quad U_{12} = \sum_{i=1}^n x_{1i}x_{2i} - n\bar{x}_1\bar{x}_2, \quad U_{22} = \sum_{i=1}^n x_{2i}^2 - n\bar{x}_2^2, \quad (8)$$

$$U_{1y} = \sum_{i=1}^n x_{1i}y_i - n\bar{x}_1\bar{y}, \quad U_{2y} = \sum_{i=1}^n x_{2i}y_i - n\bar{x}_2\bar{y}. \quad (9)$$

Nesunku įsitikinti, kad $U_{11} = (n-1)s_1^2$; čia $s_1^2 = \sum_{i=1}^n (x_{1i} - \bar{x}_1)^2 / (n-1)$ yra x_1 empirinė dispersija. Analogiškai empirinėmis dispersijomis arba kovariacijomis išreiškiami ir U_{12} , U_{22} , U_{1y} ir U_{2y} .

6.1 pavyzdys. Žinome, kiek lėšų įvairiuose Europos regionuose buvo išleista keptuvės „Vorskla“ reklamai TV bei laikraščiuose, ir koks gautas pelnas (tūkst. eurų). Duomenys pateikti 6.1 lentelėje. Raskite regresijos funkciją. Kokį pelną tikėtina gauti, išleidus TV reklamai 7, o reklamai laikraščiuose 5 tūkstančius eurų?

6.1 lentelė

TV (x_1)	8,5	8,0	8,5	7,5	6,7	7,7	5,8	7,5	8,4	7,9	8,4	7,4	6,6	7,6	5,7	7,4
Laikraščiai (x_2)	6,0	1,0	5,0	1,9	4,9	3,0	4,0	4,1	7,0	1,0	4,2	2,2	4,2	3,1	4,0	5,1
Pelnas (y)	93,0	61,0	80,0	66,5	72,0	77,5	66,5	72,0	95,1	62,1	84,1	67,7	73,1	78,6	67,6	73,1

Pagal (6)–(9) formules randame parametrų įverčius: $\hat{b}_1 = 5,23$; $\hat{b}_2 = 4,45$; $\hat{a} = 17,94$. Regresijos funkcija

$$\hat{y}(x_1, x_2) = 17,94 + 5,23x_1 + 4,55x_2. \quad (10)$$

Prognozuojamos pajamos, kai $x_1 = 7$, $x_2 = 5$, yra $\hat{y}(7, 5) = 17,94 + 5,23 \cdot 7 + 4,55 \cdot 5 = 76,8$ tūkst. eurų.

Atkreipiame dėmesį, kad prognozuojame vidutinį pelną, kurį galima tikėtis gauti išleidus 7 tūkstančius eurų TV reklamai ir 5 tūkstančius eurų reklamai laikraščiuose.

Koeficientas $\hat{b}_j$ parodo, kiek padidėja (sumažėja) $\hat{y}(\vec{x})$ reikšmė vienu vienetu padidėjus x_j , kai likusieji $x_1, \dots, x_{j-1}, x_{j+1}, \dots, x_k$ yra fiksuoti. Pavyzdžiui, esant fiksuotoms

išlaidoms TV reklamai, kiekvienas papildomai reklamai laikraščiuose išleistas tūkstantis eurų atneš 4,45 tūkstančius eurų pelno.

SPSS rezultatų protokole regresijos koeficientai pateikiami specialia lentele.

6.2 pavyzdys. Žinome judėjimo „Į Vakarus“ 22 vadybininkų algas (Lt), IQ ir ankstesnę analogiško darbo patirtį (mėn.). Duomenys pateikti 6.2 lentelėje. Reikia rasti regresijos funkciją.

6.2 lentelė

Alga (y)	5000	2000	4000	2500	3000	3500	2500	3000	5100	2100	4100
IQ (x ₁)	149	159	154	113	144	112	114	113	111	114	112
Patirtis (x ₂)	49	21	39	26	29	36	25	31	50	22	40
Alga (y)	2600	3100	3600	2600	3100	2000	4100	2600	3200	3500	2600
IQ (x ₁)	113	114	112	114	149	114	113	113	114	111	114
Patirtis (x ₂)	27	30	35	27	32	23	40	26	29	35	28

SPSS paketu gauta regresijos koeficientų lentelė pateikta 6.1 paveiksle. Pirmojoje skiltyje nurodyti patys kintamieji, o skiltyje Unstandardized Coefficients, B pateikti įverčiai $\hat{b}_i$. Todėl regresijos funkcija yra

$$ALGA = -318,712 + 0,294 \cdot IQ + 108,608 \cdot PATIRTIS.$$

Likusias lentelės skiltis aptarsime kituose skyreliuose.

COEFFICIENTS ^a										
Model	Unstandardized Coefficients		Standardized Coefficients	t	Sig.	Correlations			Collinearity Statistics	
	B	Std. Error	Beta			Zero-order	Partial	Part	Tolerance	VIF
1 (Constant)	-318,712	215,179		-1,4815	,155					
IQ	,294	1,603	,006	,183	,857	,091	,042	,006	,993	1,007
PATIRTIS	108,608	3,320	,991	32,715	,000	,991	,991	,987	,993	1,007

^a. Dependent Variable: ALGA

6.1 pav. Judėjimo „Į Vakarus“ SPSS koeficientų lentelė

6.3. Liekamosios paklaidos

Praėjusiame skyrelyje nagrinėjome, kaip randama ir taikoma regresijos prognozės funkcija, tačiau nekalbėjome apie prognozių tikslumą. Paprasčiausias būdas įvertinti prognozių tikslumą – tai pasižiūrėti, ar stebimos priklausomojo kintamojo reikšmės labai skiriasi nuo tų, kurias gautume prognozei naudodami regresijos funkciją $\hat{y}(\vec{x})$. Trumpai šią liekamųjų paklaidų analizę ir aptarsime.

Liekamosios paklaidos padeda nustatyti išskirtis bei pagal jų grafikus iš akies įvertinti, ar modelis tinka.

Liekamoji stebėjimo $(x_{1i}, x_{2i}, \dots, x_{ki}, y_i)$ paklaida apibrėžiama (5) lygybe (į ją reikia įstatyti parametru $\hat{a}, \hat{b}_1, \dots, \hat{b}_k$ įverčius). Kuo didesnė liekamoji paklaida $\hat{e}_i$, tuo labiau prognozuojamoji reikšmė $\hat{y}(\vec{x}_i)$ skiriasi nuo stebimosios reikšmės y_i .

Regresijos funkcija gali priklausyti nuo duomenų išskirčių (žr. 5.4 skyrelį). Kaip ir vieno nepriklausomo kintamojo atveju, išskirtys nustatomos atsižvelgus į: a) stebėjimo įtakos indeksą (h_i); b) standartizuotąją liekaną (SR_i); c) Kuko matą (D_i). Tačiau daugialypėje regresijoje minėtas charakteristikas skaičiuoti yra daug sudėtingiau. Laimei, viską galima apskaičiuoti statistiniais paketais. Todėl apsiribosime tik pačiomis taisyklėmis. Standartizuotajai liekanai galioja ta pati 5.4 skyrelio taisyklė, t.y. stebėjimas ($x_{1i}, x_{2i}, \dots, x_{ki}, y_i$) laikomas išskirtimi, jeigu $|SR_i| > 3$. Tuo tarpu nustatant išskirtį pagal stebėjimo įtakos indeksą arba Kuko atstumą, atsižvelgiama į nepriklausomų kintamųjų skaičių (k).

Pagal stebėjimo įtakos indekso h_i reikšmę išskirtis nustatoma taip:

Stebėjimą ($x_{1i}, x_{2i}, \dots, x_{ki}, y_i$) laikome išskirtimi, jei $h_i > 2(k+1)/n$.

Pastaba. Kai kurie autoriai siūlo išskirtimi laikyti stebėjimą, jei $h_j > 3(k+1)/n$.

6.3 pavyzdys. Pagal stebėjimo įtakos indeksus raskime 6.1 pavyzdžio išskirtis. SPSS paketu apskaičiuoti kiekvieno stebėjimo įtakos indeksai h_i , standartizuotosios liekanos SR_i ir Kuko atstumai D_i pateikti atitinkamai 6.2 paveikslu stulpeliuose *lev_1*, *zre_1* ir *coo_1*. Kadangi $n = 16$, tai stebėjimų įtakos indeksus lyginame su $6/16 = 0,375$. Peržiūrėję visus h_i , įsitikiname, kad išskirčių nėra. Beje, nė viena iš standartizuotųjų liekanų absoliučiuoju didumu neviršija 3.


	tv	laikr	pajamos	zre_1	coo_1	lev_1
1	8,50	6,00	93,00	,82567	,10073	,18711
2	8,00	1,00	61,00	-,90323	,14819	,21890
3	8,50	5,00	80,00	-1,26039	,13903	,11508
4	7,50	1,90	66,50	,10621	,00076	,08471
5	6,70	4,90	72,00	-,78070	,04216	,08746
6	7,70	3,00	77,50	1,33708	,05890	,02060
7	5,80	4,00	66,50	,01732	,00006	,24606
8	7,50	4,10	72,00	-,94356	,02195	,00220
9	8,40	7,00	95,10	,37995	,04090	,29185
10	7,90	1,00	62,10	-,50560	,04344	,20847
11	8,40	4,20	84,10	,73956	,03363	,07478
12	7,40	2,20	67,70	,20202	,00215	,05922
13	6,60	4,20	73,10	,37816	,00863	,07283
14	7,60	3,10	78,60	1,62597	,07827	,01335
15	5,70	4,00	67,60	,41495	,04440	,27602
16	7,40	5,10	73,10	-1,63339	,11502	,04136

6.2 pav.


Pagal Kuko atstumą išskirtis nustatoma taip:

Stebėjimą ($x_{1i}, x_{2i}, \dots, x_{ki}, y_i$) laikome išskirtimi, jei $D_i > F_{0,5}(k+1, n-k-1)$.


Čia $F_{0,5}(k+1, n-k-1)$ yra Fišerio skirstinio su $(k+1)$ ir $(n-k-1)$ laisvės laipsnių 0,5 lygmens kritinė reikšmė.



a)



b)



c)

6.3 pav. 6.1 pavyzdžio liekanų sklaidos diagramos

Neturint kritinių reikšmių lentelės, galima taikyti grubesnę taisyklę iš akies ir išskirtimi laikyti stebėjimus, kurių $D_i > 1$.

6.4 pavyzdys. Pagal Kuko atstumą raskime 6.1 pavyzdžio išskirtis. Kadangi $n = 16$, $k = 2$ ir $F_{0,5}(3, 12) = 0,835$, tai peržiūrėję 6.2 paveikso stulpelį $\circ\circ\circ_1$ įsitikiname, kad išskirčių nėra.

Ar regresijos modelis duomenims tinka, iš akies galima įvertinti ir pagal liekamųjų paklaidų grafikus. Tačiau, kai kintamųjų yra keli, neįmanoma nubraižyti $(x_{1i}, \dots, x_{ki}, y_i)$ reikšmių grafiko (jis yra k -matis). Todėl braižomas (y_i, SR_i) reikšmių grafikas. Regresijos funkcija stebėjimų elgesį tuo geriau aprašo, kuo šios reikšmės vienodžiau išsibarsčiusios apie x ašį (žr. 5.6 pav., b)). Vis dėlto daugialypėje regresijoje vien tik standartizuotųjų liekanų grafiko nepakanka, nes jame neatsiskleidžia individuali kiekvieno nepriklausomo kintamojo svarba.

Norėdami pamatyti, kaip Y priklauso nuo X_j , turime pašalinti galimą likusiųjų kintamųjų įtaką. Tai daroma taip:

- Sudaromas regresijos modelis, kur Y priklauso nuo $X_1, \dots, X_{j-1}, X_{j+1}, \dots, X_k$. Randamos liekamosios paklaidos $\hat{e}_i(y, j)$.
- Sudaromas regresijos modelis, kur X_j priklauso nuo $X_1, \dots, X_{j-1}, X_{j+1}, \dots, X_k$. Randamos liekamosios paklaidos $\hat{e}_i(x, j)$.
- Nubraižomas $(\hat{e}_i(x, j), \hat{e}_i(y, j))$ reikšmių grafikas. Kuo priklausomybė artimesnė tiesinei, tuo geriau X_j tinka pasirinktajam regresijos modeliui.

6.5 pavyzdys. Prisiminkime 6.1 pavyzdį. Paveiksle 6.3 nubraižyta: a) standartizuotųjų liekanų reikšmių grafikas (y_i, SR_i) ; b) pelno ir reklamos laikraščiuose priklausomybės, eliminavus TV reklamos įtaką, t. y. $(\hat{e}_i(x, 1), \hat{e}_i(y, 1))$ reikšmių, grafikas; c) $(\hat{e}_i(x, 2), \hat{e}_i(y, 2))$ reikšmių grafikas. Kaip matyti, pajamų priklausomybė nuo reklamos laikraščiuose išlaidų yra stipresnė nei nuo TV reklamos išlaidų.

6.6 pavyzdys. Grįžkime prie 6.2 pavyzdžio. Paveiksle 6.4 pateikti: a) $(\hat{e}_j(x, 1), \hat{e}_j(y, 1))$ ir b) $(\hat{e}_j(x, 2), \hat{e}_j(y, 2))$ reikšmių grafikai. Akivaizdu, kad algos ir patirties priklausomybė yra tiesinė, tuo tarpu ar algos ir IQ priklausomybė yra tiesinė, labai abejotina.

6.4. Statistinės išvados apie modelio koeficientus




Ilgokai buvo manyta, kad elektra galės pakeisti garą. Ši prielaida buvo paneigta ir teoriškai, ir bandymais. Jei mums pavyks išradėjus atitraukti nuo panašių chimeriškų sumanymų, tikrai padarysime jiems paslaugą.

L. Figuje (1819–1894)

Šiame skyriuje nagrinėjamas regresijos modelis, kuriame y_i nepriklauso nuo y_{i-1} , t. y. atvejis, kai liekamosios paklaidos nepriklausomos. Ar liekamųjų paklaidų autokoreliacijos nėra, galima patikrinti Durbino–Vatsono kriterijumi. Šio kriterijaus taikymas niekuo nesiskiria nuo aprašytojo 5.6 skyrelyje.

Regresijos prognozės yra tuo tikslesnės, kuo geriau pasirinktasis modelis atskleidžia tikrąjį kintamųjų priklausomybę. Norėdami įsitikinti, ar tikrai Y priklauso nuo visų nepriklausomų kintamųjų, tikriname statistines hipotezes apie galimas regresijos funkcijos



koeficientų $b_1, \dots, b_k$ reikšmes. Jei koks nors koeficientas b_j statistiškai reikšmingai nesiskiria nuo nulio, galima spėti, kad prognozės nedaug tepriklauso nuo kintamojo X_j reikšmių, nes tuomet sandauga $b_j X_j$ yra maža. Būtent nuo šios sandaugos priklauso Y . Statistinėms išvadoms apie koeficientus gauti taikomi F ir Stjudento kriterijai. Juos išsamiau ir aptarsime.

6.4.1. Regresijos ANOVA

Jeigu visi koeficientai b_j lygūs nuliui, tai akivaizdu, kad (1) regresijos modelis prognozėms visiškai netinka. Taikydami F kriterijų, gauname vieną iš dviejų išvadų: 1) visi koeficientai $b_j = 0$, t. y. (1) regresijos modelis su duomenimis nesuderintas; 2) bent vienas koeficientas $b_j \neq 0$, t. y. (1) regresijos modelis bent jau iš dalies prognozėms tinka.

Vis dėlto F kriterijus dar neleidžia nuspręsti, nuo kurių modelio kintamųjų X_j labiau priklauso prognozuojamos Y reikšmės.

F kriterijus remiasi ta pačia idėja kaip ir vienfaktorinė dispersinė analizė (žr. 2 skyrių), todėl dažnai vadinamas *regresijos ANOVA*. Visų pirma y_i reikšmių skirtumų kvadratus išskaidome į sudėtinės dalis:

$$SST = SSR + SSE; \quad (11)$$

čia

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2, \quad SSR = \sum_{i=1}^n (\hat{y}(\vec{x}_i) - \bar{y})^2, \quad SSE = \sum_{i=1}^n \hat{e}_i^2. \quad (12)$$

Kaip ir 5 skyriuje, SST vadinama *visa kvadratų suma*, SSR – *regresijos kvadratų suma*, o SSE – *liekamųjų paklaidų kvadratų suma*. Galima sakyti, kad SSR yra kvadratų suma, paaiškinama regresijos modeliu.

Tarkime, kad prognozuojamasis Y nuo kintamųjų $X_1, \dots, X_k$ nepriklauso. Vadinasi, (1) modelio visi koeficientai $b_j = 0$, o liekamosios paklaidos didelės, be to, didelė ir suma SSE .

Dabar tarkime, kad pasirinktasis (1) regresijos modelis puikiai aprašo tikrąją kintamųjų priklausomybę. Tada stebimų duomenų suma SSR yra didelė, o suma SSE – maža. Taigi didelė suma SSE rodo, kad regresijos modelis blogai aprašo kintamųjų elgesį ($\hat{y}(\vec{x})$ negalima naudoti prognozėms), o maža – gerai (tai svarus, bet *nepakankamas* argumentas, kad $\hat{y}(\vec{x})$ būtų galima naudoti prognozėms).

Kaip nuspręsti, kada suma SSE yra didelė? SSE didumas yra reliatyvi sąvoka (jis priklauso nuo nežinomos dispersijos σ^2), todėl apie SSE didumą sprendžiame lygindami jį su SSR didumu. Kad galėtume patikrinti atitinkamą statistinę hipotezę, sumos SSR ir SSE normuojamos. Tegul

$$MSE = \frac{SSE}{n - k - 1}. \quad (13)$$

Prisiminkime regresijos modelio prielaidas: visos paklaidos turi tą pačią (nežinomą) dispersiją σ^2 . Dydis MSE yra šios dispersijos įvertis. Įrodyta, kad

$$MSR = \frac{SSR}{k} \quad (14)$$

taip pat yra σ^2 įvertis, kai visi (1) modelio koeficientai $b_j = 0$. F kriterijaus statistika yra MSR/MSE . Jei šis santykis didelis (daug didesnis už 1), tai normuotoji suma MSE , palyginti su MSR , yra maža. Tada maža ir liekamųjų paklaidų suma SSE – regresijos modelis neblogai aprašo kintamųjų elgesį. Ir priešingai, mažas santykis MSR/MSE rodo, kad suma SSE didelė – pasirinktasis regresijos modelis kintamųjų elgesio neatskleidžia.

Suformuluosime F kriterijaus taikymo taisykles.

1 *Statistinė hipotezė:*

$$\begin{cases} H_0: b_1 = b_2 = \dots = b_k = 0, \\ H_1: \text{ bent vienas } b_j \neq 0. \end{cases} \quad (15)$$

2 *Kriterijaus statistika.* Apskaičiuojame $F = MSR/MSE$.

3 *Sprendimo priėmimo taisyklė.* Tegul reikšmingumo lygmuo lygus α . Hipotezė H_0 atmetama (taigi bent vienas $b_j \neq 0$), jeigu $F > F_\alpha(k, n-k-1)$; čia $F_\alpha(k, n-k-1)$ yra Fišerio skirstinio su k ir $(n-k-1)$ laisvės laipsnių α lygmens kritinė reikšmė. Hipotezė H_0 neatmetama, jeigu $F \leq F_\alpha(k, n-k-1)$.

Pastaba. Trumpai galima pasakyti, kad jei nulinė hipotezė H_0 neatmetama, tai regresijos modelis netinka. Tuo tarpu atmesta nulinė hipotezė tėra tik vienas iš daugelio indikatorių, pagal kuriuos sprendžiama, ar pasirinktasis regresijos modelis tinka.

6.7 pavyzdys. Patikrinkime hipotezę, kad 6.1 pavyzdžio regresijos funkcijos bent vienas daugiklis nenulinis, t. y.

$$\begin{cases} H_0: b_1 = b_2 = 0, \\ H_1: \text{bent vienas } b_j \neq 0. \end{cases}$$

Tegul reikšmingumo lygmuo $\alpha = 0,05$. Apskaičiuojame $n = 16$; $k = 2$; $SSR = 1270,69$; $SSE = 218,15$; $SST = 1488,83$; $MSR = 635,34$; $MSE = 16,78$; $F = 37,86$. Kadangi $F > 3,8 = F_{0,05}(2,13)$, tai nulinę hipotezę H_0 atmetame ir darome išvadą, kad bent vienas iš koeficientų b_1, b_2 nelygus nuliui.

Paprastai F kriterijaus rezultatai pateikiami 6.3 ANOVA lentele. Tokia pat rezultatų lentelė gaunama ir skaičiuojant SPSS paketą. Tikslai yra papildoma grafa p -reikšmei.

6.3 lentelė. Regresijos ANOVA rezultatai

	Kvadratų suma	Laisvės laipsniai	Dispersijos įverčiai	Statistika
Regresijos	SSR	k	MSR	$F = MSR/MSE$
Paklaidų	SSE	$n-k-1$	MSE	
Visa	SST	$n-1$		

Hipotezė H_0 atmetama, kai p -reikšmė $p < \alpha$. Priešingu atveju hipotezė H_0 neatmetama (regresijos modelis netinka).

6.8 pavyzdys. Patikrinsime hipotezę H_0 , kad 6.2 pavyzdžio regresijos funkcijos abu daugikliai b_1 ir b_2 lygūs nuliui. Tegul reikšmingumo lygmuo $\alpha = 0,01$. SPSS paketą gauti F kriterijaus rezultatai pateikti 6.5 paveiksle. Įsitikiname, kad p -reikšmė lygi 0,00. Taigi nulinę hipotezę H_0 atmetame ir darome išvadą, kad bent vienas iš daugiklių b_1, b_2 nelygus nuliui.

ANOVA ^b						
Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	15766088	2	7883043,896	539,645	,000 ^a
	Residual	277548,572	19	14607,820		
	Total	16043636	21			

^a. Predictors: (Constant), PATIRTIS, IQ
^b. Dependent Variable: ALGA

6.5 pav. SPSS gauta regresijos ANOVA lentelė

6.4.2. Stjudento kriterijus

F kriterijus leidžia nustatyti, ar tarp visų koeficientų $b_1, \dots, b_k$ yra nenulinių, tuo tarpu Stjudento kriterijus atsako į klausimą, ar konkretus koeficientas $b_j \neq 0$. Norime pabrėžti, kad Stjudento kriterijus tėra tik vienas iš regresijos modelio tinkamumo duomenims tikrinimo etapų. Jeigu paaiškėja, kad visi $b_j \neq 0$, tai labai tikėtina, jog kintamojo Y reikšmėms prognozuoti reikia visų kintamųjų X_j . Vis dėlto galutinai tuo įsitikinti galime tik atsižvelgę į kitus rodiklius: imties didumą, liekamąsias paklaidas, determinacijos koeficientą ir ypač į kintamųjų multikolinearumą (žr. 6.5 skyrelį). Jei hipotezė, kad $b_j = 0$, neatmetama, tai prognozuojamos Y reikšmės nuo X_j mažai priklauso. Ar prognozuojant kintamasis X_j reikalingas, nusprendžiame atsižvelgę ir į daugelį kitų faktorių. Pavyzdžiui, gali paaiškėti, kad kintamojo X_j nelabai reikia prognozuojant Y reikšmes, kai modelyje yra kintamasis X_l , bet jei prognozuojant X_l reikšmes neatsižvelgiama, tai X_j prognozėms tiesiog būtinas. Plačiau kintamųjų parinkimo problemas aptarsime 6.9 skyrelyje.

Stjudento kriterijus remiasi tuo, kad skirtumas $(\hat{b}_j - b_j)$, padalytas iš $\hat{b}_j$ standartinio nuokrypio įverčio, turi Stjudento skirstinį su $(n - k - 1)$ laisvės laipsnių. Aprašysime, kaip taikomas Stjudento kriterijus hipotezei $b_j = 0$ tikrinti.

1 *Statistinė hipotezė:*

$$\begin{cases} H_0: b_j = 0, \\ H_1: b_j \neq 0. \end{cases}$$

2 *Kriterijaus statistika.* Apskaičiuojame regresijos modelio, kuriame X_j yra priklausomas kintamasis, o $X_1, \dots, X_{j-1}, X_{j+1}, \dots, X_n$ – nepriklausomi kintamieji, liekamųjų paklaidų kvadratų sumą. Pažymėkime ją SSE_j . Kriterijaus statistika yra

$$t = \frac{\hat{b}_j}{\sqrt{MSE/SSE_j}}.$$

3 *Sprendimo priėmimo taisyklė.* Tegul reikšmingumo lygmuo lygus α . Hipotezė H_0 atmetama (taigi $b_j \neq 0$), jeigu $|t| > t_{\alpha/2}(n - k - 1)$; čia $t_{\alpha/2}(n - k - 1)$ yra Stjudento skirstinio su $(n - k - 1)$ laisvės laipsnių $\alpha/2$ lygmens kritinė reikšmė. Hipotezė H_0 neatmetama, jeigu $|t| \leq t_{\alpha/2}(n - k - 1)$.

Dviejų nepriklausomų kintamųjų atveju t galima skaičiuoti pagal tokią formulę:

$$t = \hat{b}_j \sqrt{\frac{(n-1)s_j^2(1-r_{12}^2)}{MSE}};$$

čia r_{12} yra empirinė X_1 ir X_2 koreliacija, s_j^2 – empirinė X_j dispersija, $j = 1, 2$. Žinoma, t reikia lyginti su $t_{\alpha/2}(n - 3)$.

6.9 pavyzdys. Patikrinkime hipotezes, kad 6.1 pavyzdyje abu koeficientai nenuliniai, t. y.

$$\begin{cases} H_0: b_1 = 0, \\ H_1: b_1 \neq 0, \end{cases} \quad \text{ir} \quad \begin{cases} H_0: b_2 = 0, \\ H_1: b_2 \neq 0. \end{cases}$$

Tegul reikšmingumo lygmuo $\alpha = 0,05$. Apskaičiuojame $n = 16$; $k = 2$; $MSE = 16,78$; $\hat{b}_1 = 5,23$, $\hat{b}_2 = 4,45$, $s_1^2 = 1,20$, $s_2^2 = 0,63$, $r_{12} = 0,088$. Taigi pirmosios hipotezės $t = 4,4$, o antrosios $t = 7,1$. Kadangi $t_{0,025}(13) = 2,16$, tai abiem atvejais nulinę hipotezę H_0 atmetame ir darome išvadą, kad abu koeficientai b_1 ir b_2 nelygūs nuliui.

Naudojantis SPSS paketu, taip pat galima patikrinti hipotezes apie koeficientų lygybę nuliui. Nagrinėto 6.2 pavyzdžio SPSS apskaičiuotų koeficientų lentelė pateikta 6.1 paveiksle.

Stulpelyje Std. Error užrašyti koeficientų $\hat{a}$, $\hat{b}_1$ ir $\hat{b}_2$ įverčių standartiniai nuokrypiai. Stulpeliuose t ir Sig. pateikiamos hipotezių H_0 : $a = 0$, H_0 : $b_1 = 0$ ir H_0 : $b_2 = 0$ statistikos bei p -reikšmės. Tarkime, reikšmingumo lygmuo yra α .

Nulinė hipotezė H_0 atmetama, jeigu p -reikšmė $p < \alpha$ (koeficientas nelygus nuliui).

Tarkime, kad pasirinkome reikšmingumo lygmenį $\alpha = 0,05$. Ką galime pasakyti apie b_1 (daugiklio prie IQ) reikšmę? Kadangi 6.1 paveiksle pateiktoji p -reikšmė $0,857 > 0,05$, tai nulinė hipotezė H_0 : $b_1 = 0$ neatmetama, galima įtarti, kad nuo kintamojo IQ alga nepriklauso. Analogiškai įsitikiname, kad galime laikyti $b_2 \neq 0$, nes p -reikšmė $0,000 < 0,05$.

Taigi gavome dar vieną patvirtinimą (žr. taip pat 6.6 pvz.), kad prognozuojant vadybininkų algą svarbi patirtis ir (ko gero) nesvarbus IQ. Galutinį sprendimą priimsime 6.9 skyrelyje.



PREAMBULĖ. Ekonomistai labai dažnai taiko regresiją ir kitus statistinius metodus, tik visa tai vadinama ekonometrija.

PASAKOJIMAS. Penki statistikai važiuoja traukiniu. Į vagoną įlipa penki pažįstami ekonomistai. Draugiškai besišnekučiuojant, paaiškėja, kad ekonomistai važiuoja su bilietais, o visi statistikai turi vieną bendrą bilietą. „Kodėl jūs taip padarėte?“ – stebisi ekonomistai. „Juk kontrolierius jus išlaipins iš traukinio!“.

Prasideda bilietų patikrinimas. Visi statistikai nuskuba į artimiausią tualetą ir užsirakina. Kontrolierius patikrina ekonomistų bilietus ir pastebi, kad tualetas užrakintas. Jis pabeldžia į duris: „Prašau bilietą!“. Statistikai iškiša bilietą pro durų apačią. Kontrolierius jį patikrina ir grąžina atgal. Kontrolieriui nuėjus, statistikai grįžta į savo vietas. Ekonomistų susižavėjimas beribis. „Tai neįtikėtina! protinga,“ – pareiškia vienas ekonomistas.

Po kelių savaičių statistikai ir ekonomistai vėl susitinka traukinyje. „Mes padarėme kaip ir jūs – nusipirkome vieną bilietą penkiems“ – giriasi ekonomistai. „Iš tikro? O mes šį kartą važiuojame be bilietų!“ Ekonomistai pritrenkti. „To jau per daug. Jūs būtinai išsodins iš traukinio.“

Pastebėję kontrolierių, ekonomistai nuskuba į artimiausią tualetą ir užsirakina. Statistikai nuseka iš paskos. Vienas statistikas pabeldžia į duris ir pareikalauja bilieto. Ekonomistai iškiša bilietą pro durų apačią. Statistikai čiumpa bilietą ir užsidaro kitame tualete. Kontrolierius prieina prie tualetu su ekonomistais. „Prašau bilietą!“. Tyla. „Prašau bilietą!“. Ekonomistai pripažįsta savo pralaimėjimą, išeina iš tualetu ir išlaipinami artimiausioje stotelėje.

MORALAS. Statistikų metodus galima taikyti tik žinant, kokia teorija jie remiasi.

6.5. Kintamųjų įtakos priklausomybės matai

Norėdami taikyti tiesinę regresiją, turime įvertinti, kokią įtaką priklausomojo kintamojo elgesiui daro nepriklausomi kintamieji. Taip pat reiktų išsiaiškinti, kurie nepriklausomi kintamieji šia prasme svarbesni.

Taikydami F arba Stjudento kriterijus, nustatome, ar koeficientai b_j statistiškai reikšmingai skiriasi nuo nulio, ir pagal tai sprendžiame, ar prognozuojamosios reikšmės priklauso nuo X_j . Vis dėlto statistiniai kriterijai neduoda atsakymo į klausimą, ar nustatytoji

priklausomybė stipri. Nedidelius, bet statistiškai reikšmingus koeficientų skirtumus nuo nulio galima gauti vien todėl, kad duomenys gauti iš labai daug stebėjimų (tokia daugelio statistinių kriterijų matematinė prigimtis). Be to, net ir turėdami kelis Stjudento kriterijumi neišbrokuotus kintamuosius, dar negalime nustatyti, kurie iš jų prognozei svarbesni.

6.5.1. Standartizuotieji koeficientai

Prisiminkime regresijos funkciją

$$\hat{y}(\vec{x}) = \hat{a} + \hat{b}_1 x_1 + \hat{b}_2 x_2 + \dots + \hat{b}_k x_k.$$

Tarkime, kad kintamuosius X_j norime tarpusavyje palyginti ir nustatyti jų santykinę svarbą prognozuojant Y reikšmes. Lygindami koeficientus $\hat{b}_1, \dots, \hat{b}_k$, to dar nepadarysime, nes $\hat{b}_j$ didumas labai priklauso ir nuo X_j matavimo vienetų ir nuo duomenų sklaidos. Todėl, norėdami gauti tarpusavyje palyginamus daugiklius, randame *standartizuotąją* regresijos funkciją, t. y. regresijos funkciją skaičiuojame visų kintamųjų z -reikšmėmis. Stebėjimai $(x_{1i}, x_{2i}, \dots, x_{ki}, y_i)$ keičiami z -reikšmėmis $(z_{1i}, z_{2i}, \dots, z_{ki}, z_{yi})$, $i = 1, \dots, n$; čia $z_{ji} = (x_{ji} - \bar{x}_j)/s_j$, $z_{yi} = (y_i - \bar{y})/s_y$, s_j yra X_j empirinis standartinis nuokrypis, o s_y yra Y empirinis standartinis nuokrypis. Šioms reikšmėms randami regresijos modelio

$$z_y = \alpha + \beta_1 z_1 + \beta_2 z_2 + \dots + \beta_k z_k + e \quad (16)$$

koeficientų $\alpha, \beta_1, \dots, \beta_k$ įverčiai $\hat{\alpha}, \hat{\beta}_1, \dots, \hat{\beta}_k$. Standartizuotosios ir nestandartizuotosios regresijos funkcijų koeficientus sieja priklausomybė $\hat{b}_j s_j = \beta_j s_y$. Dviejų kintamųjų standartizuotos funkcijos koeficientus galima išreikšti kintamųjų koreliacijomis:

$$\hat{\beta}_1 = \frac{r_{1y} - r_{2y} r_{12}}{1 - r_{12}^2}, \quad \hat{\beta}_2 = \frac{r_{2y} - r_{1y} r_{12}}{1 - r_{12}^2}; \quad (16)$$

čia r_{12} žymi empirines X_1 ir X_2 , o r_{1y} – X_1 ir Y koreliacijas.

Standartizuotieji koeficientai β_j naudojami iš akies nustatant santykinę nepriklausomų kintamųjų įtaką prognozuojamajam Y . Absoliučiuoju didumu didesnis $\hat{\beta}_j$ rodo didesnę Y priklausomybę nuo X_j .

6.10 pavyzdys. Apskaičiuokime standartizuotus 6.1 pavyzdžio modelio koeficientus. Standartizuotas išlaidų TV reklamai koeficientas $\hat{\beta}_1 = 0,47$, o reklamos laikraščiuose koeficientas $\hat{\beta}_2 = 0,76$. Taigi standartizuotieji koeficientai rodo, kad pajamos labiau priklauso nuo išlaidų reklamai laikraščiuose nei nuo TV reklamai. Tuo tarpu $\hat{b}_1 = 5,23 > 4,55 = \hat{b}_2$, t. y. regresijos funkcijos koeficientas didesnis TV reklamos išlaidoms.

SPSS paketu apskaičiuotos koeficientų $\hat{\beta}_i$ reikšmės pateikiamos koeficientų lentelės (žr. 6.1 pav.) grafoje Standardized Coefficients, Beta.

6.11 pavyzdys. Raskime standartizuotus 6.2 pavyzdžio modelio koeficientus. Iš 6.1 paveikslą lentelės randame $\beta_{IQ} = 0,006$, o $\beta_{PATIRTIS} = 0,99$. Taigi alga labiau priklauso nuo patirties nei nuo IQ. Panašią išvadą jau buvome padarę nagrinėdami 6.3 pavyzdžio liekamųjų paklaidų grafikus.

6.5.2. Determinacijos koeficientas

Regresinėje analizėje skaitiškai vertinant nepriklausomų kintamųjų įtaką Y įgyjamoms reikšmėms, skaičiuojamas determinacijos koeficientas, koreguotasis determinacijos koeficientas ir daugialypės koreliacijos koeficientas.

Daugialypės regresijos determinacijos koeficientas apibrėžiamas kaip ir vieno kintamojo atveju. Santykis

$$r^2 = \frac{SSR}{SST}$$

vadinamas *determinacijos koeficientu*. Primename, kad kvadratų sumos SST ir SSR apibrėžtos 6.4 skyrelyje.

Determinacijos koeficientas $r^2 \leq 1$. Šiek tiek nusižengdami tikslumui, galime sakyti, kad kuo r^2 reikšmė didesnė, tuo daugiau informacijos apie Y reikšmes glūdi kintamuosiuose $X_1, \dots, X_j$. Taigi tuo geriau tinka ir pasirinktasis regresijos modelis.

Vis dėlto reikia turėti omenyje, kad, jei kintamųjų skaičius k nedaug skiriasi nuo stebėjimų skaičiaus n , tai vien todėl determinacijos koeficientas r^2 yra arti vieneto. Todėl į r^2 rekomenduojama atsižvelgti tik tada, kai k daug mažesnis už n .

Kitais atvejais skaičiuojamas *koreguotasis determinacijos koeficientas* r_{adj}^2 . Jį skaičiuojant, atsižvelgiama ir į imties didumą, ir į nepriklausomų kintamųjų skaičių.

Koreguotasis determinacijos koeficientas

$$r_{adj}^2 = 1 - \frac{n-1}{n-k-1}(1-r^2).$$

Atkreipiame dėmesį, kad mažiems r^2 koreguotasis determinacijos koeficientas gali įgyti ir neigiamas reikšmes.

Koreguotojo determinacijos koeficiento r_{adj}^2 interpretacija lieka ta pati: kuo jis didesnis, tuo geriau Y reikšmes aprašo regresijos modelyje esančių nepriklausomų kintamųjų elgesys.

Kvadratinė šaknis iš determinacijos koeficiento vadinama *daugialypės koreliacijos koeficientu*.

MODEL SUMMARY

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	,924 ^a	,853	,831	4,0964

^a. Predictors: (Constant), LAIKR, TV

MODEL SUMMARY

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	,991 ^a	,983	,981	120,8628

^a. Predictors: (Constant), PATIRTIS, IQ

6.6 pav. Determinacijos ir daugialypės koreliacijos koeficientai

Daugialypės koreliacijos koeficientas $r = \sqrt{r^2}$.

Daugialypės koreliacijos koeficientas parodo, kaip stipriai prognozuojamas kintamasis priklauso nuo *visų* nepriklausomų kintamųjų. Žinoma, kalbame apie tiesinę priklausomybę, aprašytą (1) modeliu. Norime pabrėžti, kad didelis daugialypės koreliacijos koeficientas dar nereiškia, kad prognozuojant *visi* nepriklausomi kintamieji yra svarbūs ir naudingi. Gali būti, kad r yra didelis, nors Y priklauso tik nuo X_1 , o kiti kintamieji jokios įtakos Y elgesiui neturi.

6.12 pavyzdys. SPSS paketu apskaičiuoti 6.1 ir 6.2 pavyzdžių daugialypės koreliacijos, determinacijos ir koreguotasis determinacijos koeficientai pateikti 6.6 paveiksle. Abiem atvejais r dideli, ir 6.2 pavyzdžio atveju visiškai nematyti jau anksčiau nustatytos abejotinos algos priklausomybės nuo IQ .

6.5.3. Dalinės koreliacijos koeficientas

Daugialypės koreliacijos koeficientas yra Y priklausomybės nuo visų kintamųjų $X_1, X_2, \dots, X_k$ kartu, bet ne nuo kiekvieno X_j atskirai, matas. *Dalinė koreliacija* atskleidžia Y priklausomybę nuo vieno kintamojo, *kai eliminuojama likusių kintamųjų įtaka*. Analizuojant dalines koreliacijas, galima susidaryti nuomonę apie tai, kokius kintamuosius regresijos modelyje vertėtų palikti, kad prognozės būtų tikslesnės.

Tiesinę Y ir X_j priklausomybę matuoja koreliacijos koeficientas r_{yj} , tačiau jis gali būti didelis vien todėl, kad abu kintamieji Y ir X_j priklauso nuo kokių nors kitų kintamųjų (žr., pvz., 5.1 skyrelį). Dalinės koreliacijos koeficientas šių kintamųjų įtakos neatskleidžia. Kaip ir visi koreliacijos koeficientai, jis nenusako priežastinės priklausomybės. Priežastinė priklausomybė paprastai nustatoma remiantis tiriamos srities teorinėmis žiniomis arba (ir) specialiai parengtu eksperimentu, o dalinė koreliacija tėra pagalbinis instrumentas.

Kintamieji, į kurių įtaką skaičiuojant dalinę koreliaciją atsižvelgta, vadinami *kontroliuojamaisiais* kintamaisiais. Kontroliuojamų kintamųjų skaičius vadinamas *dalinės koreliacijos eile*. Pirmosios eilės dalinės koreliacijos gaunamos, kai yra vienas kontroliuojamas kintamasis, antrosios – kai du ir t. t. Pavyzdžiui, $r_{y1.2}$ yra pirmosios eilės dalinė Y ir X_1 koreliacija, kai kontroliuojamas kintamasis X_2 ; $r_{y2.134}$ – trečiosios eilės dalinė Y ir X_2 koreliacija, kai kontroliuojami kintamieji X_1, X_3 ir X_4 , ir pan. Daugialypėje regresijoje dažniausiai skaičiuojamos $(k - 1)$ -osios eilės dalinės Y ir X_j koreliacijos, kai kontroliuojami visi likę nepriklausomi kintamieji.

Dalinė Y ir X_j koreliacija skaičiuojama taip:

- a) apskaičiuojamos visos liekamosios paklaidos regresijos modelio, kuriame Y priklauso nuo visų kontroliuojamųjų kintamųjų (bet ne nuo X_j);
- b) apskaičiuojamos visos liekamosios paklaidos regresijos modelio, kuriame X_j priklauso nuo visų kontroliuojamųjų kintamųjų;
- c) skaičiuojama gautųjų liekamųjų paklaidų empirinė koreliacija.

Nesunku suprasti, kad 6.3 skyrelyje kalbėdami apie $(\hat{e}_i(x, j), \hat{e}_i(y, j))$ grafiką iš tikrųjų turėjome omenyje dalinės koreliacijos $r_{y \cdot j \cdot 12 \dots j-1, j+1 \dots k}$ vertinimą iš akies.

Dviejų kintamųjų atveju dalines koreliacijas galima išreikšti empirinėmis koreliacijomis:

$$r_{y1.2} = \frac{r_{y1} - r_{y2}r_{12}}{\sqrt{(1 - r_{y2}^2)(1 - r_{12}^2)}}, \quad r_{y2.1} = \frac{r_{y2} - r_{y1}r_{12}}{\sqrt{(1 - r_{y1}^2)(1 - r_{12}^2)}}. \quad (17)$$

6.13 pavyzdys. Raskime 6.1 pavyzdžio dalines koreliacijas. Primename, kad Y yra gautasis pelnas, X_1 – išlaidos TV reklamai, X_2 – išlaidos reklamai laikraščiuose. Apskaičiuojame empirines koreliacijas: $r_{y1} = 0,535$; $r_{y2} = 0,797$; $r_{12} = 0,088$. Pagal (17) formules randame $r_{y1.2} = 0,77$, $r_{y2.1} = 0,89$.

Palyginę gautus dalinės koreliacijos koeficientus $r_{y1.2}$ ir $r_{y2.1}$ su koreliacijos koeficientais r_{y1} ir r_{y2} , matome, kad daliniai koreliacijos koeficientai didesni. Taigi šio pavyzdžio kintamieji vienas kitą veikia slopinamai. Tačiau taip yra ne visada – dalinės koreliacijos koeficientai gali būti ir mažesni už empirinės koreliacijos koeficientus.

Dalinės koreliacijos koeficientus galima apskaičiuoti daugeliu statistinių paketų. Pagnagrinėkime vieną pavyzdį.

6.14 pavyzdys. „Piratinių“ muzikos bei žaidimų kompaktinių plokštelių prekybos bosas susidomėjo statistika. Jo nurodymu iš įvairių miestų surinkti duomenys apie gautą pelną (Y , tūkst. Lt), sumokėtas už nelegalią prekybą baudas (X_1 , tūkst. Lt), konfiskuotų kompaktinių plokštelių skaičių (X_2), parduotų plokštelių skaičių (X_3 , tūkst. vienetų) ir produkciją pardavinėjusių kioskų skaičių (X_4). Duomenys pateikti 6.4 lentelėje. Išplėstinė SPSS koeficientų lentelė parodyta 6.7 paveiksle.

6.4 lentelė. Prekyba kompaktinėmis plokštelėmis

Pelnas (y)	95	37	77	47	57	67	47	57	99	39	79	49	59	69	49	59
Baudos (x_1)	3	4	3	5	6,6	4,6	8,4	5	3,2	4,2	3,2	5,2	6,8	4,8	8,6	5,2
Konfisk (x_2)	260	380	250	480	620	450	800	450	310	360	260	490	660	440	850	510
Parduota (x_3)	7,11	6,57	6,92	6,70	6,90	6,90	6,90	6,83	7,15	6,61	6,95	6,75	6,93	6,93	6,92	6,90
Kioskai (x_4)	145	134	143	137	138	141	140	139	146	135	142	138	142	141	137	141

COEFFICIENTS^a

Model	Unstandardized Coefficients		Standardized Coefficients	t	Sig.	Correlations			Collinearity Statistics	
	B	Std. Error	Beta			Zero-order	Partial	Part	Tolerance	VIF
1 (Constant)	−590,240	19,688		−29,979	,000					
BAUDOS	−4,878	2,550	−,469	−1,913	,082	−,550	−,500	−,044	,009	115,8
KONFISK	−,002	,025	−,024	−,100	,922	−,536	−,030	−,002	,009	114,2
PARDUOTA	102,220	8,487	,863	12,044	,000	,873	,964	,274	,101	9,905
KIOSKAI	−,178	,418	−,033	−,426	,679	,929	−,127	−,010	,089	11,259

^a. Dependent Variable: PELNAS

6.7 pav. 6.14 pavyzdžio SPSS koeficientų lentelė

Regresijos funkcija yra

$$PELNAS = -590,24 - 4,878 \cdot BAUDOS + 0,002 \cdot KONFISK + 102,22 \cdot PARDUOTA - 0,178 \cdot KIOSKAI. \quad (18)$$

Žiūri bosas į šią funkciją ir nieko nesupranta: daugiklis prie konfiskuotos produkcijos teigiamas, o prie kioskų skaičiaus – neigiamas. Išeitų, kad kuo daugiau konfiskuota plokštelių, tuo pelnas didesnis, o kuo daugiau

kioskų produkciją pardavinėja, tuo pelnas mažesnis. Visiška ekonominė nesąmonė! Bosas daro išvadą, kad statistika yra ne mokslas, o kvailių išsigalvojimai.



Pabandykime reabilituoti statistiką. Grafoje *Correlations*, *Zero-order* pateiktos empirinės koreliacijos r_{y1} , r_{y2} , r_{y3} ir r_{y4} . Matome, kad jos visos absoliučioju didumu pakankamai didelės. Tuo tarpu grafoje *Partial* pateiktos dalinės koreliacijos $r_{y1.234}$, $r_{y2.134}$, $r_{y3.124}$ ir $r_{y4.123}$. Pastebime, kad $|r_{y2.134}| = 0,03$ daug mažesnis už $|r_{y2}| = 0,536$, o $r_{y4.123} = 0,127$ daug mažesnis už $r_{y4} = 0,929$. Taigi nepriklausomi kintamieji stipriai tarpusavyje koreliuoja ir, įtraukti į bendrą regresijos modelį, vienas kitą veikia. Dėl šios tarpusavio koreliacijos ir atsirado „ne tie“ daugiklių ženklai. Reikėtų pasirinkti paprastesnį modelį. Prie šio pavyzdžio dar grįšime 6.6 skyrelyje, o 6.9 skyrelyje pateiksime, kaip šią problemą spręsti.


Beje, visas nepriklausomųjų kintamųjų reikšmės pasirinkę lygias nuliui, gauname $-590,24$ tūkst. litų pelno (t. y. $590,24$ tūkst. nuostolio), bet tai dar neleidžia teigti, kad prognozės funkcija netikusi – taip atsitiko todėl, kad nulinės kintamųjų reikšmės jau patenka už reikšmių, kurioms galima daryti prognozes, aibės ribų.

Dalines koreliacijas galima skaičiuoti ir atskirai nuo daugialypės regresijos modelio. Be to, galima patikrinti hipotezę, ar gautoji dalinė koreliacija statistiškai reikšminga. Tokią galimybę suteikia dauguma statistinių paketų (iš jų ir SPSS). Išvada daroma taip pat, kaip ir tikrinant hipotezę apie Pirsono arba Spirmeno koreliaciją – koreliacija statistiškai reikšminga, jeigu p -reikšmė mažesnė už pasirinktąjį reikšmingumo lygmenį.

Be dalinių korelacių, kartais skaičiuojamos ir *pusdalinės koreliacijos*, kai kontroliuojamųjų kintamųjų įtaką pašalinama tik vienam iš kintamųjų. Pavyzdžiui, $r_{y(1.2)}$ žymi $\hat{e}_i(x, j)$ ir y_i , $i = 1, \dots, n$, t. y. Y ir X_1 koreliaciją, kai pašalinta X_2 įtaka kintamajam X_1 . Pusedalinės 6.14 pavyzdžio koreliacijos $r_{y(1.234)}$, $r_{y(2.134)}$, $r_{y(3.124)}$ ir $r_{y(4.123)}$ pateiktos 6.7 paveiksle, grafoje *Part*.

6.6. Multikolinearumas

Daugialypės regresijos modelis tinkamiausias prognozuoti tada, kai visi nepriklausomi kintamieji $X_1, \dots, X_k$ tarpusavyje nekoreliuoja, o priklausomybė sieja tik juos ir Y (žr. 6.8 pav., a)). Kai tarp kintamųjų $X_1, \dots, X_k$ yra stipriai koreliuojančių (žr. 6.8 pav., b)), susiduriame su vadinamąja *multikolinearumo* problema.





Multikolinearumo sąvoką pirmasis 1934 metais savo monografijoje pavartojo norvegų ekonomistas Ragnaras Friskas (Ragnar Frisch).

Kuo blogas nepriklausomų kintamųjų multikolinearumas? Viena vertus, negalima gerai atskirti koreliuojančių kintamųjų įtakos prognozuojamai reikšmei. Dėl multikolinearumo gali atsirasti „ne tas“ daugiklio ženklas (prisiminkime 6.14 pavyzdį). Vis dėlto didžiausia multikolinearumo žala yra regresijos funkcijos koeficientų nestabilumas – keli papildomi stebėjimai gali juos labai pakeisti, o tada nebeaišku, kuria funkcija naudotis prognozuojant.

6.15 pavyzdys. Tarkime, kad žinome dviejų parengiamųjų biologijos žinių testų bei per baigiamąjį egzaminą gautus taškus. Duomenys pateikti 6.5 lentelėje. Pagal parengiamųjų testų rezultatus norime prognozuoti egzamino taškų skaičių. SPSS paketu gauti koeficientų lentelės rezultatai pateikti 6.9 paveiksle.

Randame regresijos funkciją

$$EGZAM = -23,43 + 2,85 \cdot TEST1 + 7,599 \cdot TEST2. \quad (19)$$

Atlikę liekamųjų paklaidų analizę, įsitikintume, kad tarp stebėjimų išskirčių nėra. Atrodytų, kad duomenys regresinei analizei tinka. Tačiau pašalinę iš duomenų paskutinius du stebėjimus ir iš naujo apskaičiavę regresijos funkcijos koeficientus, gauname

$$EGZAM = -28,489 + 4,089 \cdot TEST1 + 6,765 \cdot TEST2. \quad (20)$$

Taigi regresijos funkcijos koeficientai labai pasikeitė. Nebeaišku, kada prognozė tikslesnė – naudojantis (19) ar (20) funkcija.

6.5 lentelė

I testas (x_1)	13,3	13,3	13,4	13,7	13,9	14,2	14,4	14,5	14,7	14,7	15,0	15,4	15,8
II testas (x_2)	13,8	14,1	14,6	14,9	15,3	15,6	15,6	15,6	15,4	15,5	15,7	16,1	16,3
Egzaminas (y)	120	123	124	130	134	136	136	134	133	136	139	143	149
I testas (x_1)	15,9	16,1	16,3	16,4	16,7	16,7	16,7	16,8	16,9	17,0	17,0	17,1	17,3
II testas (x_2)	17,2	17,7	18,1	18,2	18,6	18,8	19,1	19,1	19,5	19,0	19,3	19,1	19,3
Egzaminas (y)	154	160	162	163	164	163	167	169	170	174	172	169	171
I testas (x_1)	17,5	17,9	18,2	18,5	18,7	18,8	18,8	18,8	19,0	18,0	19,3	19,6	20,0
II testas (x_2)	20,0	20,2	20,6	21,3	21,1	21,3	21,5	22,0	22,1	20,0	22,0	21,8	22,0
Egzaminas (y)	174	179	184	190	191	193	195	200	205	178	200	201	195

COEFFICIENTS^a

Model	Unstandardized Coefficients		Standardized Coefficients	t	Sig.	Correlations			Collinearity Statistics	
	B	Std. Error				Zero-order	Partial	Part	Tolerance	VIF
1 (Constant)	-23,430	4,999		-4,687	,000					
TEST1	2,850	1,320	,218	2,159	,038	,987	,339	,035	,026	37,873
TEST2	7,599	,983	,780	7,727	,000	,995	,790	,127	,026	37,873

^a. Dependent Variable: EGZAM

6.9 pav. 6.15 pavyzdžio SPSS rezultatai

Atrodytų, kuo daugiau informacijos regresijos funkcijoje panaudosime, tuo tikslesnės bus prognozės. Tačiau pasirodo, kad regresijos funkcijos koeficientai labai nestabilūs. Pažiūrėkime, kaip atrodo regresijos funkcija, kai egzaminu taškus prognozuojame pagal antrojo testo rezultatus. Taip pat pateikiame regresijos funkciją, kai iš duomenų pašalinti paskutiniai du stebėjimai:

$$EGZAM = -14,744 + 9,695 \cdot TEST2, \quad EGZAM = -14,576 + 9,684 \cdot TEST2.$$

Koeficientų reikšmės beveik nepasikeitė!

Regresijos (19) funkcijos koeficientų nestabilumas paaiškinamas kintamųjų multikolinearumu. Kaip nustatoma, ar vektoriai multikolinearūs? Dažniausiai skaičiuojamas *dispersijos mažėjimo daugiklis* VIF^1 . Tarkime, kad r_j^2 yra regresijos modelio, kuriame X_j yra priklausomas kintamasis, o $X_1, \dots, X_{j-1}, X_{j+1}, \dots, X_n$ – nepriklausomi kintamieji, determinacijos koeficientas.

$$\text{Kintamojo } X_j \text{ dispersijos mažėjimo daugiklis } VIF = \frac{1}{1 - r_j^2}.$$

Paprastai VIF interpretuojamas kaip $\hat{b}_j$ dispersijos santykis su ta dispersija, kurią $\hat{b}_j$ turėtų, jeigu X_j nekoreliuotų su likusiais X . Visuotinai priimta taisyklė iš akies skamba taip:

$$\text{Kintamasis yra „perdaug multikolinearus“, jeigu } VIF > 4.$$

„Perdaug multikolinearus“ reiškia, kad regresijos modelyje palikus šį kintamąjį ir kintamuosius su kuriais jis koreliuoja, gali kilti prognozių stabilumo problemų. Mūsų atveju abiejų kintamųjų $TEST1$ ir $TEST2$ daugiklis $VIF = 37,873 > 4$ (žr. 6.9 pav.), taigi kintamieji yra perdaug multikolinearūs. Peržiūrėję VIF 6.7 paveiksle, įsitikiname, kad ir 6.14 pavyzdyje užfiksuotas kintamųjų multikolinearumas.

Kaip matyti iš 6.7 ir 6.9 paveikslų, multikolinearumas nesusijęs su Studento kriterijaus išvadomis. Be to, akivaizdu, kad žiūrint į $X_1, X_2, \dots, X_k$ ir Y koreliacijas jį ne visada galima pastebėti. Net ir dalinės koreliacijos neviseiškai išryškina kintamųjų multikolinearumą. Nesunku įsitikinti, kad ir determinacijos koeficientai, ir F kriterijaus išvados nepadedą pastebėti multikolinearumo. Todėl, atliekant regresinę analizę, rekomenduojama peržiūrėti ir VIF koeficientus. Beje, kartais skaičiuojama vadinamoji *tolerancija*, t. y. $1/VIF$ (SPSS paketas pateikia abu koeficientus, žr. 6.9 pav.). Žinoma, nesunku performuluoti multikolinearumo nustatymo iš akies taisyklę ir tolerancijai: multikolinearumą galima įtarti, kai tolerancija mažesnė kaip 0,25. Stebėti VIF ir tolerancijos didumus yra ne vienintelis metodas multikolinearumui nustatyti, bet bene pats paprasčiausias ir populiariausias.

Ką daryti nustatčius multikolinearumą? Vieningos nuomonės šiuo klausimu nėra. Dažnai siūloma padidinti imtį. Kita paplitusi rekomendacija – atsisakyti dalies kintamųjų arba vietoje kelių kintamųjų imti jų tiesinę daugdarą. Tačiau šie veiksmai turi būti pagrįsti tiriamo dalyko teorija. Pavyzdžiui, aišku, kad dviejų biologijos testų rezultatus pakeitę tų rezultatų vidurkiu, daug informacijos neprarasime, o multikolinearumo išvengsime.

¹ VIF – ang. *Variance Inflation Factor*.

Prisiminkime 6.14 pavyzdį. Ką galime patarti bosui? Aišku, kad parduodama „piratinė“ produkcija ir ją pardavinėjantys kioskai yra susiję dalykai, todėl regresijos modelyje galima būtų vieno iš šių kintamųjų atsisakyti. Be to, konfiskuota produkcija ir baudos didumas – taip pat tarpusavyje susiję. Iš šių kintamųjų modelyje galima būtų palikti tik vieną. Bosą, žinomą, domina, *kuriuos* kintamuosius palikti. Į šį klausimą atsakysime 6.9 skyrelyje (nekantraujantys gali pasižiūrėti jau dabar).

Kiti multikolinearumo mažinimo metodai pakankamai sudėtingi, ir dažnai atsiranda sunkumų bandant „sutvarkytą“ funkciją taikyti prognozėms. Pavyzdžiui, siūloma kintamuosius keisti pagrindinėmis komponentėmis (žr. 10 skyrių) arba įvesti papildomą priklausomo kintamojo daugiklį, parinkus jį taip, kad įverčių dispersijos būtų kuo mažesnės. Tokių metodų šioje knygoje neaptarsime.

6.7. Pseudokintamieji




Geriau jau būsiu apytikriai teišus nei tikrai neteišus.

Dž. M. Keinsas

Iki šiol nagrinėjome atvejį, kai visi nepriklausomi kintamieji kiekybiniai. Tačiau kartais tenka atsižvelgti ir į kokybinę informaciją. Tarkime, kad reikia nustatyti buto ploto ir kainos priklausomybę. Atskirai ištyrę kiekvieną iš dviejų rajonų, nustatėme, kad priklausomybė daugmaž vienoda, tačiau vidutiniškai už to paties ploto butą I rajone reikia mokėti 5000 eurų daugiau nei II rajone (žr. 6.10 pav.). Jeigu rajonus nagrinėtume kartu, tai regresijos tiesės būtų visiškai kitokia ir prognozės nebūtų tokios tikslios (žr. 6.10 pav. brūkšninę liniją). Pseudokintamųjų naudojimas – tai būdas į nepriklausomų kintamųjų aibę įtraukti kategorinį kintamąjį. Pasirinkdami pseudokintamųjų reikšmes, gautume kiekvieną kategoriją atitinkančią regresijos funkciją.

Ar verta vargti? Ar ne paprasčiau būtų apsiriboti vienu rajonu, atlikti jo duomenų regresinę analizę, o po to imtis antrojo rajono? Jei mes manome, kad skirtinguose rajonuose kintamųjų priklausomybę nusako visiškai skirtingos funkcijos (su skirtingais nepriklausomų kintamųjų daugikliais, regresijos tiesės nelygiagrečios), tai rajonus reikia nagrinėti



atskirai. Tuo tarpu, jeigu manome, kad ploto ir kainos priklausomybė iš esmės ta pati ir tik atsiranda papildoma pastovi priemoka už rajoną (regresijos tiesės lygiagrečios), tai dažniausiai patartina naudoti pseudokintamuosius. Kodėl? Primename, kad visose regresinės analizės statistinėse išvadose naudojamas nežinomos paklaidos dispersijos įvertis. Pseudokintamieji leidžia atsižvelgti į visus stebėjimus, todėl dispersijos įvertis tikslesnis (taigi tikslesnės ir statistinės išvados apie nepriklausomus kintamuosius).

Dažniausiai į regresijos modelį įtraukiami kategoriniai kintamieji yra lytis, gyvenamoji vieta, išsilavinimas, metų laikas, politinės pažiūros, tautybė ir pan. Kategorinis kintamasis į regresijos modelį įtraukiamas ne tiesiogiai, o pakeičiant jį vienu arba keliais dvireikšmiais *pseudokintamaisiais*. Trumpai aptarsime pseudokintamųjų sudarymo principus. Tarkime, kad kategorinis kintamasis įgyja dvi reikšmes (pvz., I rajonas, II rajonas). Tuomet regresijos modelis papildomas vienu dvireikšmiu pseudokintamuoju $\tilde{x}_1$:

$$\tilde{x}_1 = \begin{cases} 1, & \text{I rajono butai,} \\ 0, & \text{II rajono butai.} \end{cases} \quad (21)$$

Mažiausiųjų kvadratų metodu apskaičiuojami regresijos funkcijos koeficientai. Tarkime, kad

$$KAINA = \hat{a} + \hat{b}_1 \cdot PLOTAS + \tilde{b}_1 \tilde{x}_1. \quad (22)$$

Įstatę $\tilde{x}_1 = 0$, gauname II rajono butų regresijos tiesės lygtį: $KAINA = \hat{a} + \hat{b}_1 \cdot PLOTAS$, o įstatę $\tilde{x}_1 = 1$, I rajono butų: $KAINA = (\hat{a} + \tilde{b}_1) + \hat{b}_1 \cdot PLOTAS$. Matome, kad $\tilde{b}_1$ yra ne kas kita kaip regresijos tiesių skirtumas (nagrinėtame pavyzdyje jis buvo lygus 5000 eurų).

Kai kategorinis kintamasis turi $m > 2$ kategorijų, jis keičiamas $(m - 1)$ pseudokintamuoju. Visi pseudokintamieji gali įgyti tik dvi reikšmes: 1 arba 0. Vieną iš kategorijų atitinka visų pseudokintamųjų nulinės reikšmės. Kiekvieną iš likusių kategorijų atitinka visų pseudokintamųjų nulinės reikšmės, išskyrus vieną kintamąjį, kuris įgyja reikšmę 1. Pavyzdžiui, tarkime, kad prognozuodami buto kainą norime atsižvelgti į namo rūšį (blokinis, plytinis, monolitinis). Tuomet reikia dviejų pseudokintamųjų:

$$\tilde{x}_1 = \begin{cases} 1, & \text{blokinis,} \\ 0, & \text{neblokinis,} \end{cases} \quad \tilde{x}_2 = \begin{cases} 1, & \text{plytinis,} \\ 0, & \text{neplytinis.} \end{cases}$$

Kai $\tilde{x}_1 = \tilde{x}_2 = 0$, namas monolitinis; kai $\tilde{x}_1 = 1, \tilde{x}_2 = 0$, namas blokinis; kai $\tilde{x}_1 = 0, \tilde{x}_2 = 1$, namas plytinis.

Žinoma, galima įtraukti ir kelis kategorinius kintamuosius. Pavyzdžiui, rajoną, namo rūšį, balkonų skaičių. Kiekvieną kategorinį kintamąjį pseudokintamaisiais keičiame atskirai.

Pasirinkus modelyje per didelį kategorinių kintamųjų skaičių, būtų sunku interpretuoti gautus rezultatus. Be to, patiems pseudokintamiesiems netaikomos statistinės išvados, o analizuojant liekamąsias paklaidas atsiranda problemų. Turint pakankamai daug kiekvieno kategorinio kintamojo stebėjimų, reikėtų gerai pagalvoti, ar verta pseudokintamuosius naudoti, nes jie gerokai apsunkina regresinės analizės taikymą.



Be pateiktojo, naudojami ir kiti pseudokintamųjų kodavimo būdai. Pavyzdžiui, kontrastinis kodavimas – vienoms kategorijoms priskiriami teigiami skaičiai, kitoms – neigiami (skaičių suma lygi nuliui) ir pan.

SPSS regresijos koeficientų lentelėje pseudokintamieji iš kitų nepriklausomų kintamųjų neišskiriami. Pagal žinomas taisykles sudaroma regresijos funkcija. Į ją įrašius pseudokintamųjų reikšmes, randamos regresijos funkcijos, atitinkančios kiekvieno kategorinio kintamojo duomenis.

6.16 pavyzdys. Ar žinant automobilio variklio arklio jėgų skaičių (AJ) galima numatyti, kiek kilometrų jis nuvažiuos, turėdamas 10 l degalų? Automobiliai gaminti JAV, Europoje arba Azijoje. Regioną, kuriame gamintas automobilis, užkoduojame dviem pseudokintamaisiais:

$$DUM_1 = \begin{cases} 1, & \text{JAV,} \\ 0, & \text{kitur,} \end{cases} \quad DUM_2 = \begin{cases} 1, & \text{Europa,} \\ 0, & \text{kitur.} \end{cases}$$

Kai $DUM_1 = DUM_2 = 0$, tai automobilis pagamintas Azijoje. SPSS paketu gauta koeficientų lentelė pateikta 6.11 paveiksle. Iš jos matyti, kad regresijos funkcija

$$KM = 171,348 - 0,553 \cdot AJ - 21,49 \cdot DUM_1 - 11,347 \cdot DUM_2.$$

Parinkę pseudokintamųjų reikšmes, randame regresijos funkcijas automobilių, pagamintų JAV: $KM = 149,858 - 0,553 \cdot AJ$; Europoje: $KM = 160 - 0,553 \cdot AJ$ ir Azijoje: $KM = 171,348 - 0,553 \cdot AJ$.

COEFFICIENTS ^a					
Model		Unstandardized Coefficients		Standardized Coefficients	Sig.
		B	Std. Error	Beta	
1	(Constant)	171,348	3,223		,000
	AJ	-,553	,030	-,649	,000
	DUM_1	-21,490	2,773	-,320	,000
	DUM_2	-11,347	3,222	-,132	,000

^a. Dependent Variable: KM

6.11 pav.

Iki šiol kalbėjome apie atvejį, kai pseudokintamieji tik papildė nepriklausomų intervalinių kintamųjų aibę. O kas atsitinka, jeigu visi nepriklausomi kintamieji yra pseudokintamieji? Pasirodo, kad tuo atveju regresijos rezultatai tie patys kaip ir vienfaktorinės dispersinės analizės, o F kriterijaus lentelė sutampa su atitinkama ANOVA lentele. Tarkime, kad norime patikrinti, ar trijų grupių vidutiniai reakcijos laikai nesiskiria. Duomenys su pseudokintamaisiais parodyti 6.12 paveiksle. Atkreipiame dėmesį, kad vieną grupę atitinka abiejų pseudokintamųjų nulinės reikšmės.

Y	$\tilde{X}_1$	$\tilde{X}_2$
y_1	0	0
y_2	0	0
...	...	...
y_m	1	0
y_{m+1}	1	0
...	...	...
y_s	0	1
y_{s+1}	0	1

6.12 pav.

6.8. Dviejų regresijos modelių koeficientų lygybė



Regresinė duomenų analizė leido ekonomistams numatyti 7 iš paskutinių 5 krizių.

Tarkime, kad turime dvi imtis, gautas matuojant tuos pačius kintamuosius. Norime išsiaiškinti, ar abiem imtims tinka tas pats kintamųjų priklausomybę nusakantis tiesinės regresijos modelis. Pavyzdžiui, toks poreikis iškyla, kai įtariame, kad TV reklamos įtaka pardavimui JAV yra kitokia nei Lietuvoje; arba kai norime nustatyti, ar požiūrio į savo sveikatos būklę priklausomybė nuo amžiaus ir pajamų dabar kitokia nei prieš dešimtmetį.

Pabandykime tiksliau suformuluoti, kokius regresijos modelius lyginame. Tarkime, kad Y ir $X_1, \dots, X_k$ priklausomybę aprašo du modeliai

$$Y_i = a + b_1 x_{1i} + b_2 x_{2i} + \dots + b_k x_{ki} + e_i \quad (\text{I imties}),$$

$$Y_i = a' + b'_1 x_{1i} + b'_2 x_{2i} + \dots + b'_k x_{ki} + e'_i \quad (\text{II imties}).$$

Atsitiktines paklaidas e_j ir e'_j laikome normaliai pasiskirsčiusiomis ir turinčiomis vienodas dispersijas.

Kadangi visi nepriklausomi kintamieji tie patys, tai faktiškai gali skirtis tik jų daugikliai. Suformuluosime Čou¹ kriterijų hipotezei apie daugiklių lygybę tikrinti.

1 Statistinė hipotezė:

$$\begin{cases} H_0: b_1 = b'_1, b_2 = b'_2, \dots, b_k = b'_k, a = a', \\ H_1: \text{bent viena lygybė neteisinga.} \end{cases} \quad (23)$$

2 Kriterijaus statistika. Apskaičiuojame I imties duomenų liekamųjų paklaidų kvadratų sumą SSE_1 , II imties duomenų liekamųjų paklaidų kvadratų sumą SSE_2 ir abiejų imčių duomenų liekamųjų paklaidų kvadratų sumą SSE .

$$F = \frac{(SSE - SSE_1 - SSE_2)/(k + 1)}{(SSE_1 + SSE_2)/(n_1 + n_2 - 2k - 2)}; \quad (24)$$

čia n_1 yra I imties didumas, n_2 – II imties didumas, k – nepriklausomų kintamųjų skaičius.

3 Sprendimo priėmimo taisyklė. Tegul reikšmingumo lygmuo lygus α . Hipotezė H_0 atmetama (taigi modeliai skiriasi), jeigu $F > F_\alpha(k + 1, n_1 + n_2 - 2k - 2)$; čia $F_\alpha(k + 1, n_1 + n_2 - 2k - 2)$ yra Fišerio skirstinio su $(k + 1)$ ir $(n_1 + n_2 - 2k - 2)$ laisvės laipsnių α lygmens kritinė reikšmė. Hipotezė H_0 neatmetama (galima teigti, kad regresijos modeliai vienodi), jeigu $F \leq F_\alpha(k + 1, n_1 + n_2 - 2k - 2)$.

¹ G. C. Chow – kinų statistikas.

6.17 pavyzdys. Tarkime, kad iš 14 Azijos regionų gavome duomenis apie keptuvės „Vorskla“ išlaidas TV reklamai bei reklamai laikraščiuose ir gautą pelną (žr. 6.6 lentelę). Ar pelno ir išlaidų TV bei laikraščių reklamoms priklausomybę Europoje (žr. 6.1 pvz.) ir Azijoje aprašo skirtingi regresijos modeliai? Tarkime, reikšmingumo lygmuo $\alpha = 0,01$.

6.6 lentelė

TV (x_1)	8,5	7,9	8,4	7,0	6,6	7,5	5,8	7,4	8,2	7,8	8,4	7,4	6,5	7,0
Laikr (x_2)	6,0	1,3	5,2	2,0	4,8	3,2	4,1	4,2	7,3	1,1	4,0	2,2	4,5	2,9
Pelnas (y)	89,3	63,2	88,5	64,2	74,2	71,5	66,7	74,0	94,2	64,3	80,4	67,1	72,3	68,1

Pelno ir reklamos išlaidų priklausomybę Europoje jau nustatėme 6.1 pavyzdyje: $PELNAS = 17,94 + 5,23 \cdot TV + 4,55 \cdot LAIKR$. Be to, jau buvome apskaičiavę $SSE_1 = 218,15$, $n_1 = 16$. Analogiškai randame 6.6 lentelės duomenų regresijos funkciją: $PELNAS = 15,88 + 5,47 \cdot TV + 4,64 \cdot LAIKR$. Be to, $SSE_2 = 16,15$, $n_2 = 14$. Jungtinę regresijos funkciją yra $PELNAS = 16,95 + 5,37 \cdot TV + 4,55 \cdot LAIKR$. Be to, $SSE = 235,26$.

Kadangi yra du nepriklausomi kintamieji ($k = 2$), tai pagal (24) skaičiuojame $F = 0,03$. Iš lentelių randame $F_{0,01}(3,24) = 4,71$. Kadangi $F < 4,71$, tai nulinės hipotezės atmesti negalima – manome, kad ir Europoje, ir Azijoje pelno ir išlaidų reklamoms TV ir laikraščiuose priklausomybę aprašo tas pats modelis.

6.9. Modelio parinkimas



Geriausias būdas pataikyti į taikinį – taikinį pasirinkti po šūvio.

Jeigu (koreguotas) determinacijos koeficientas pakankamai didelis, F ir Stjudento kriterijai atmeta hipotezes apie koeficientų lygybę nuliui, nėra multikolinearumo, o liekamųjų paklaidų grafikai patvirtina tiesinę kintamųjų priklausomybę, tai pasirinktasis regresijos modelis atskleidžia tikruosius kintamųjų ryšius ir prognozėms tinka. Taip atsitiko 6.1 pavyzdžio atveju.

Vis dėlto ką daryti, kai tikrinant modelio tinkamumą paaiškėja, kad ne viskas gerai? Modelis gali netikti, jei:

- atsižvelgta ne į visus reikalingus nepriklausomus kintamuosius,
- ne visų kintamųjų reikia,
- kintamųjų priklausomybė nėra tiesinė.

Pirmoji problema susijusi su tyrimo specifika ir šioje knygoje nenagrinėjama. Kitas dvi aptarsime išsamiau.

6.9.1. Kintamųjų redukcija

Kintamųjų redukcija – tai dalies nepriklausomų kintamųjų pašalinimas iš modelio. Kada to prireikia? Didelis nepriklausomų kintamųjų skaičius gali prognozes pabloginti, jei jie multikolinearūs. Tą pastebėjome nagrinėdami 6.14 pavyzdį.

Pradėsime nuo paties paprasčiausio šalinimų kintamųjų radimo būdo. Tarkime, Stjudento kriterijus parodė, kad hipotezės $b_j = 0$ atmesti negalima. Tuomet pašalinkime iš modelio X_j . Jeigu naujasis modelis gerai aprašo duomenų struktūrą, jį ir pasirenkame. Kintamąjį pašalinus, iškart keičiasi determinacijos koeficiento reikšmė – todėl paprastai stebime, ar jį per daug nesumažėjo.

6.18 pavyzdys. Prisiminkime 6.2 pavyzdžio judėjimo „Į Vakarus“ vadybininkų algas (Lt). Visa ligšiolinė analizė rodė, kad jų alga nepriklauso nuo IQ , tačiau ją galima visai neblogai prognozuoti žinant vadybininko patirtį. Sudarykime regresijos modelį, kuriame alga priklauso tik nuo patirties. Determinacijos koeficientas pašalinus IQ nepasikeičia: $r^2 = 0,98$. Stjudento kriterijus ir liekamųjų paklaidų analizė irgi rodo modelio tinkamumą prognozėms. Todėl darome išvadą, kad prognozuojant vadybininko algą IQ nereikalingas, o užtenka žinoti jo patirtį. Beje, pašalinus iš modelio patirtį matuojantį kintamąjį, determinacijos koeficientas katastrofiškai sumažėja iki $r^2 = 0,004$.

Toks kintamųjų šalinimas (įtraukimas) stebint determinacijos koeficiento reikšmę gana paplitęs. Įprasta kintamąjį palikti, jei jį pašalinus drastiškai mažėja determinacijos koeficientas, *net jei* Stjudento kriterijus rodo, kad $b_j = 0$.

Pateikta procedūra nesunkiai realizuojama, jei yra tik vienas koeficientas, kuriam Stjudento kriterijus hipotezės $b_j = 0$ neatmeta. Jeigu tokių koeficientų yra daugiau, tai nebūtinai visus juos atitinkančius kintamuosius iš modelio reikia pašalinti. Prisiminkime 6.14 pavyzdį. Kaip matyti iš 6.7 paveikslėlio, net trijų kintamųjų ($KIOSKAI$, $KONFISK$ ir $BAUDOS$) p -reikšmės didesnės kaip 0,05. Tačiau išbandę regresijos modelius su visais įmanomais nepriklausomų kintamųjų rinkiniais, įsitikiname, kad geriausiai tinka modeliai: $PELNAS = -288,5 + 54,54 \cdot PARDUOTA - 0,025 \cdot KONFISK$ ($r^2 = 0,987$) ir $PELNAS = -283,9 + 54 \cdot PARDUOTA - 2,64 \cdot BAUDOS$ ($r^2 = 0,990$). Bosas gali pasirinkti bet kurį iš šių modelių.

Kad nereiktų perrinkinėti visų įmanomų regresijos modelių, galima iškart patikrinti hipotezę apie kelių koeficientų b_j lygybę nuliui, t. y. keletą Stjudento kriterijų pakeisti ANOVA. Tam reikia žinoti, ar pradinio regresijos modelio ir modelio be keleto nepriklausomų kintamųjų liekamųjų paklaidų kvadratų sumos skiriasi.

Dėl paprastumo tikrinsime hipotezę apie (1) modelio pirmųjų m koeficientų lygybę nuliui.

1 *Statistinė hipotezė:*

$$\begin{cases} H_0: b_1 = b_2 = \dots = b_m = 0, \\ H_1: \text{ bent vienas } b_j \neq 0. \end{cases} \quad (25)$$

2 *Kriterijaus statistika.* Apskaičiuojame modelio su visais k nepriklausomais kintamaisiais liekamųjų paklaidų kvadratų sumas SSE ir MSE . Apskaičiuojame modelio be kintamųjų, atitinkančių nulinės hipotezės H_0 koeficientus, liekamųjų paklaidų kvadratų sumą SSE_r . Randame

$$F = \frac{(SSE_r - SSE)/(k - m)}{MSE}. \quad (26)$$

3 *Sprendimo priėmimo taisyklė.* Tegul reikšmingumo lygmuo lygus α . Hipotezė H_0 atmetama (taigi ne visi pasirinktieji koeficientai lygūs nuliui), jeigu $F > F_\alpha(k - m, n - k - 1)$; čia $F_\alpha(k - m, n - k - 1)$ yra Fišerio skirstinio su $(k - m)$ ir $(n - k - 1)$ laisvės laipsnių α lygmens kritinė reikšmė. Hipotezė H_0 neatmetama (galima teigti, kad visi pasirinktieji koeficientai lygūs nuliui), jeigu $F \leq F_\alpha(k - m, n - k - 1)$.

Norime atkreipti dėmesį į vieną pateikto kriterijaus interpretavimo niuansą. Jeigu nulinės hipotezės H_0 neatmetame, tai tereiškia, kad papildomai į modelį įtraukti kintamieji

$X_1, \dots, X_m$ nepagerins prognozės tikslumo, palyginti su *jau anksčiau į modelį įtrauktais* kintamaisiais $X_{m+1}, \dots, X_k$. Turint du stipriai koreliuojančius kintamuosius ir *bet kurią* iš jų pašalinus, prognozių tikslumas daug nenukentės. Kurį kintamąjį palikti modelyje, sprendžia tyrėjas.

6.19 pavyzdys. Patikrinkime, ar 6.14 pavyzdyje galima apsieiti be kintamųjų *KONFISK* (X_2) ir *KIOSKAI* (X_4). Tegul reikšmingumo lygmuo $\alpha = 0,05$. Statistinė hipotezė

$$\begin{cases} H_0: b_2 = b_4 = 0, \\ H_1: \text{ bent vienas iš } b_j \neq 0, j = 2, 4. \end{cases}$$

Randame modelio su visais 4 kintamaisiais $SSE = 13,53$ ir $MSE = 1,23$. Sudarę modelį, kuriame pilnas priklauso tik nuo gautų baudų ir parduotos produkcijos, randame $SSE_r = 15,22$. Kadangi $n = 16$, $m = 2$, tai $F = 0,69 < 3,98 = F_{0,05}(2,11)$. Taigi nulinės hipotezės atmeti nėra pagrindo. Darome išvadą, kad iš modelio pašalinus konfiskuotų plokštelių skaičių bei kioskų skaičių prognozių tikslumas statistiškai reikšmingai nesumažėja.

Nesunku patikrinti, kad hipotezė $H_0: b_1 = b_2 = b_4 = 0$ atmetama, nes tuo atveju $SSE_r = 339,37$, $F = 132,4 > 4,84 = F_{0,05}(1,11)$, taigi (priešingai, nei būtų galima spėti pagal Stjudento kriterijų) visų trijų kintamųjų – baudų, konfiskuotos produkcijos ir kioskų skaičiaus – iš modelio šalinti neverta.

Šiame skyriuje nagrinėjome tik tokią tiesinę regresiją, kai visi modelio kintamieji buvo pasirinkti iš karto. Kartais naudojama *žingsninė* regresija, kuri grindžiama idėja, labai panašia į aprašytą kriterijų – kintamieji į modelį įtraukiami po vieną, vis stebint, kiek sumažėja liekamųjų paklaidų kvadratų suma SSE . Šioje knygoje žingsninė regresija nenagrinėjama.

6.9.2. Kintamųjų transformacijos



Jei nesugebi daryti taip, kaip reikia, išmok džiaugtis darydamas taip, kaip sugebi.

E. Brilliant

Ankstesniame skyrelyje pažymėjome, kad ne visuomet kintamuosius sieja tiesinė priklausomybė. Tuomet reikia rinktis kito tipo modelį arba kintamuosius transformuoti, tačiau norime atkreipti dėmesį, kad tai ne visada pavyksta.

Gali būti, kad nagrinėjamiems kintamiesiems
joks regresijos modelis netinka.

Pastaruoju atveju patarimai negelbės.

Transformuoti kintamuosius siūloma tada, kai pačių kintamųjų priklausomybė yra netiesinė, tačiau jų transformacijų priklausomybė – tiesinė. Pavyzdžiui, ekonomistas gali spėti, jog naudingumo funkciją (U) su kapitalo (K) bei darbo (L) resursais sieja tokia priklausomybė:

$$U = AK^\alpha L^\beta. \quad (27)$$

Koeficientai A , α , β nežinomi ir juos reikia įvertinti. Tokiai priklausomybei sudaryti regresijos modelį ganėtinai sudėtinga. Tačiau išlogaritmavę (27), gauname tiesinę kintamųjų priklausomybę

$$\ln U = \ln A + \alpha \ln K + \beta \ln L. \quad (28)$$

Suradę naujus kintamuosius $Y = \ln U$, $X_1 = \ln K$ ir $X_2 = \ln L$, galėsime tirti tiesinės regresijos modelį $Y = \ln A + \alpha X_1 + \beta X_2$.




Teoriniai modeliai $\ln U_i = \ln A + \alpha \ln K_i + \beta \ln L_i + e_i$ ir $U_i = A(K_i)^\alpha (L_i)^\beta + e_i$, čia e_i žymi atsitiktinę paklaidą, skiriasi iš esmės. Todėl, transformuodami kintamuosius, kartu pasirenkame ir kitą priklausomybės teorinį modelį.

Panašiai sprendžiama problema, kai į modelį reikia įtraukti X_1^2 arba $X_1 X_2$ (pastarasis narys vadinamas kintamųjų X_1 ir X_2 tarpusavio sąveika). Tuomet skaičiuojame naujus kintamuosius, pavyzdžiui, $X_{12} = X_1 X_2$, kuriuos įtraukiame į tiesinį modelį. Tačiau taip elgtis siūloma tik tada, jei nekyla multikolinearumo problemos.

6.20 pavyzdys. Prisiminkime 5.6 pavyzdį apie įvairaus amžiaus paauglių savęs sureikšminimo indeksą (SASURI). Penktajame skyriuje įsitikinome, kad regresijos tiesė $SASURI = a + b_1 \cdot AMŽIUS$ šio pavyzdžio duomenims nesuderinta ir prognozėms netinka. Tarkime, kad norime patikrinti, ar funkcija $SASURI = a + b_1 \cdot AMŽIUS + b_2 \cdot (AMŽIUS)^2$ prognozėms tinka. Apskaičiuojame $z_i = (AMŽIUS)^2$ ir atliekame tiesinės regresijos analizę. Gauname regresijos funkciją: $SASURI = -355,13 + 56,74 \cdot AMŽIUS - 1,93 \cdot z = -355,13 + 56,74 \cdot AMŽIUS - 1,93 \cdot (AMŽIUS)^2$. Vis dėlto ši funkcija nėra labai naudinga prognozėms, nes VIF rodo, kad tarp kintamųjų $AMŽIUS$ ir $(AMŽIUS)^2$ yra stipri koreliacija.

Kartais kintamųjų negalima transformuoti taip, kad tiesinė regresija tiktų. Tuo atveju galima taikyti *netiesinę* regresiją. Dažniausiai tokių modelių parametrai parenkami skaičiuojant iteracijas. Plačiau netiesinės regresijos nenagrinėsime, atkreipiame dėmesį, kad dauguma šiame skyriuje apžvelgtų regresinės analizės metodų jai netinka.

Netiesinė regresija realizuota daugelyje programinių paketų. SPSS paketu gauti 5.6 pavyzdžio duomenų (1), tiesinės regresijos (2), kvadratinės regresijos (3), kurios koeficientus radome 6.20 pavyzdyje, ir eksponentinės (4) regresijos $y = ae^{bx}$ grafikai pateikti 6.13 paveiksle. Matome, kad geriausiai tinka kvadratinė regresija. Beje, SPSS rezultatų protokole netiesinės regresijos koeficientų lentelė nedaug skiriasi nuo tiesinės regresijos koeficientų lentelės.





Čou kriterijus	koreguotasis determinacijos	pusdalinė koreliacija
dalinė koreliacija	koeficientas	regresijos ANOVA
dispersijos mažėjimo	multikolinearumas	regresijos funkcija
daugiklis	netiesiniai modeliai	standartizuotieji koeficientai
	pseudokintamieji	

UŽDAVINIAI

1. Policijos komisaras pastebėjo, kad po kiekvienos stambesnės privatizacijos kai kurie valdininkai gauna iš *nežinomos tetos* dovanų (palikimus). Duomenys apie dovanų vertę (tūkst. dolerių), privatizuotų objektų kainą (mln. eurų) ir konkurse dalyvavusių firmų skaičių pateikti 6.7 lentelėje. Kokią tetos dovaną prognozuotumėte valdininkui, jei objektas privatizuotas už 90 mln. eurų, o konkurse dalyvavo 10 firmų? Ar šiems duomenims tinka tiesinės regresijos modelis?

6.7 lentelė

Vertė (x_1)	88	83	88	78	70	80	61	78	87	82	87	77	69	79	60	77
Firmos (x_2)	24	4	20	8	20	12	16	16	28	4	17	9	17	12	16	20
Dovana (y)	106,5	74,5	93,5	80	85,5	91	80	85,5	108,6	75,6	97,6	81,2	86,6	92,1	81,1	86,6

2. Sporto apžvalgininkas tiria, kaip krepšinio komandos laimėtų rungtynių procentas (Y), priklauso nuo komandos biudžeto (X_1 , mln. eurų), vidutinio per rungtynes pelnyto taškų skaičiaus (X_2) ir tritaškių pataikymo procento (X_3). Duomenys apie 16 krepšinio komandų pateikti 6.8 lentelėje. Ar tiesinės regresijos modelis tinka? Ar visi kintamieji jame reikalingi?

6.8 lentelė

Pergalės (y)	91	33	73	43	53	63	43	53	95	35	75	45	55	65	45	55
Biudžetas (x_1)	6	7	6,1	8	9,6	7,6	11,4	8	6,2	7,2	6,2	8,2	9,8	7,8	11,6	8,2
Taškai (x_2)	85	74	83	77	78	81	80	79	86	75	82	78	82	81	77	81
Tritaškiai (x_3)	51,1	45,7	49,2	47	49	49	49	48,3	51,5	46,1	49,5	47,5	49,3	49,3	49,2	49

3. Įvaizdžio kūrimo firmoje „Pigmalionas“ surinkti duomenys apie darbuotojų amžių, gaunamą metinę algą (tūkst. Lt), lytį (1 – mot., 2 – vyr.) ir per metus praleistas darbo dienas pateikti 6.9 lentelėje. Ar galima praleistų dienų skaičių prognozuoti pagal likusius kintamuosius? Padarykite prognozę, kiek per metus praleis dienų vyras ir kiek moteris (amžius – 28 metai, alga – 3 tūkst. Lt).

6.9 lentelė

Amžius	31	26	30	27	29	29	28	28	32	26	26	27	30	31	32	28
Alga	2,5	3,5	2,5	4,5	6,1	4,1	7,9	4,5	2,7	3,7	2,7	4,7	6,3	4,3	8,1	4,7
Lytis	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1
Dienos	10	4	8	5	6	7	5	6	11	4	8	5	6	7	5	6
Amžius	31	28	30	26	32	35	27	22	33	24	26	27	36	23	25	30
Alga	2,7	3,5	3	2	5	4,2	6	5	2,7	3,3	2,5	4,1	5,8	4,6	7	5
Lytis	2	2	2	2	2	2	2	2	2	2	2	2	2	2	2	2
Dienos	13	10	12	9	11	15	8	6	12	0	11	8	13	7	6	10

4. Psichologas mano, kad TV apžvalgininko politinių pažiūrų ir pateikiamos medžiagos interpretacijos priklausomybė yra net ir tada, kai apžvalgininkas stengiasi išlikti objektyvus. Pagal specialų klausimyną buvo įvertintos kiekvieno iš 28 žurnalistų politinės pažiūros (–50 – kairiosios, 0 – neutralios, 50 – dešinėsios). Po to kiekvieno žurnalistą pristatytą tarptautinių įvykių apžvalgą vertino nepriklausomų Vakarų Europos ekspertų grupė. Už kiekvieną šališkumo apraišką ekspertai skyrė baudos balus. Gauti rezultatai pateikti 6.10 lentelėje. Ar teisingas psichologas? Ar priklausomybė tiesinė?

6.10 lentelė

Pažiūros (x)	–47	–43	–47	–37	–32	–26	–27	–22	–27	–17	–16	–6	–2	–7
Baudos balai (y)	55	54	57	37	40	25	28	26	28	23	18	17	15	17
Pažiūros (x)	–1	3	4	13	18	14	19	23	28	33	43	44	38	40
Baudos balai (y)	18	15	17	21	23	25	20	30	32	36	41	42	40	42

7. LOGISTINĖ REGRESIJA



Išgėrę šių vaistų, pagis visi, išskyrus tuos, kuriems vaistai nepadės ir kurie mirs. Taigi akivaizdu, kad vaistai nepadeda tik nepagydomais atvejais.

Galenas

Pradėjo žmogui darbe akyse temti, naktimis košmarai sapnuotis, nuo cepelinų pykinti, nuo krepšinio žiūrėjimo odą berti ir pan. – žodžiu, susirgo. Kreipėsi į gydytojus, o šie tik tyrimus daro, tik vaistus leidžia ir vis ramina, kad viskas tiesiog normalu. Na, gal šiek tiek per mažai geležies kraujyje (padidinsime), gal kiek per daug eozinofilų (sumažinsime) ir dviejų protinių dantų trūksta (implantuosime). Gydosi žmogus, visi rodikliai gerėja, o saviąauta – ne. Ir panašu, kad numirs sveikas kaip ridikas.

Pažvelgę į šią truputį utiruotą situaciją statistiko akimis, matome, kad būtų gerai pagal tyrimų rezultatus išmokti prognozuoti *kategorinio* kintamojo reikšmių (pagis – nepagis) tikimybes. Pavyzdžiui, panašūs uždaviniai kyla, kai:

- pagal paciento svorį ir kraujo parametrus norime sužinoti, kiek tikėtina pacientui susirgti diabetu;
- tiriamo, ar pagal testų rezultatus galima nuspėti, kad kompiuteriui prireiks garantinio remonto;
- aiškinamasi, ar žinant rinkėjo pajamas, amžių bei išsilavinimą galima įvertinti tikimybę, kad jis balsuos už kairiųjų kandidatą į prezidentus;
- siekiama nustatyti, ar pagal agresyvumą bei plepumą galima atskirti vyrą nuo moters ir pan.

Visais šiais atvejais priklausomi kategoriniai kintamieji yra dvireikšmiai. Jų reikšmių tikimybėms prognozuoti galima taikyti *logistinę regresiją*. Ką daryti, kai kategorijų daugiau nei dvi, nagrinėjama 9 skyriuje.

Kategorinio kintamojo reikšmių prognozavimas tam tikra prasme yra klasifikavimo uždavinys. Pavyzdžiui, pagal paciento svorį ir kraujo parametrus įvertinęs diabeto susirgimo tikimybę, gydytojas paskiria (arba nepaskiria) vaistus, t. y. pacientas nejučia klasifikuojamas arba į rizikos grupę (tikimybė susirgti didelė), arba į sveikuolių grupę (tikimybė susirgti maža). Kaip logistinė regresija taikoma klasifikavimo uždaviniams, aprašyta 7.3 skyrelyje.


7.1. Logistinės regresijos modelis

Visur šiame skyriuje tarsime, kad kategorinis kintamasis įgyja dvi reikšmes: 1 ir 0. Bet kokį dvireikšmį kintamąjį galima taip perkoduoti.

Esant fiksuotoms (neatsitiktinėms) nepriklausomų kintamųjų reikšmėms $X_1 = x_{1i}, \dots, X_k = x_{ki}$, tiesinės daugialypės regresijos modelis atrodo taip:

$$Y_i = a + b_1 x_{1i} + b_2 x_{2i} + \dots + b_k x_{ki} + e_i; \quad (1)$$

čia Y_i yra atsitiktinis dydis, galintis įgyti 0 arba 1 su tikimybėmis $P(Y_i = 1) = p_i$, $P(Y_i = 0) = 1 - p_i$, o e_i yra atsitiktinė paklaida. Iš pradžių išsiaiškinsime, kodėl dvireikšmiui kintamajam prognozuoti netinka tiesinė regresija.



Kodėl prognozėms negalima taikyti (1) modelio regresijos funkcijos? Visų pirma netenkinamos tiesinės regresijos prielaidos. Iš tikrųjų Y_i įgyja tik dvi reikšmes. Todėl e_i taip pat gali įgyti tik dvi reikšmes (netenkinama *normalumo* prielaida). Žinome, kad tiesinėje regresijoje prognozuojamas priklausomo kintamojo vidurkis. Kadangi $EY_i = p_i$, tai prognozuotume tikimybę, su kuria Y_i įgyja reikšmę 1. Bet dešinioji (1) lygybės pusė gali įgyti ir neigiamas reikšmes, taip pat reikšmes, didesnes už vieną. Tai prieštarauja tikimybės apibrėžimui.

Taikomas sudėtingesnis tikimybės p_i priklausomybės nuo $x_{1i}, \dots, x_{ki}$ modelis. Logistinės regresijos modelis yra

$$p_i = \frac{\exp\{z(\vec{x}_i)\}}{1 + \exp\{z(\vec{x}_i)\}}, \quad z(\vec{x}_i) = a + b_1x_{1i} + b_2x_{2i} + \dots + b_kx_{ki}. \quad (2)$$

Tarkime, kad yra tik vienas nepriklausomas kintamasis X . Tada abiejų modelių skirtumus galima pavaizduoti grafiškai (žr. 7.1 pav.). Akivaizdu, kad p_i gali įgyti reikšmes tik iš intervalo $(0, 1)$.

Iš (2) lygties išreiškiame:

$$\frac{p_i}{1 - p_i} = \exp\{a + b_1x_{1i} + b_2x_{2i} + \dots + b_kx_{ki}\} = \exp\{z(\vec{x}_i)\}, \quad (3)$$

$$\ln \frac{p_i}{1 - p_i} = a + b_1x_{1i} + b_2x_{2i} + \dots + b_kx_{ki} = z(\vec{x}_i). \quad (4)$$

Ką rodo santykis $p_i/(1 - p_i)$? Jis tiesiog vaizdžiau perteikia informaciją apie p_i didumą.

Pavyzdžiui, jeigu $p_i = 0,25$, tai $p_i/(1 - p_i) = 1/3$, t. y. galime sakyti, kad galimybė Y_i įgyti reikšmę 1, o ne 0, vertintina kaip 1 ir 3 santykis. Tai labai primena bukmekerių vartojamus terminus – jie nesako, kad tikimybė Prancūzijos rinktinei laimėti 2002 metų pasaulio futbolo čempionatą yra 0,7. Bukmekeriai sako, kad rinktinės galimybė laimėti vertinama kaip 7 ir 3 santykis, ir būtent tokiu santykiu priimamos statomos pinigų sumos.

Tikimybių santykis $p_i/(1 - p_i)$ vadinamas *galimybe* (galimybės įvertinimu) įvykti įvykiui $Y_i = 1$.

Įvykio $Y = 1$ galimybė įvykti yra didesnė už 1 tada ir tik tada, kai $P(Y = 1) > P(Y = 0)$.

Pavyzdžiui, galimybė 0,8 (t. y. 8 : 10) reiškia, kad tikėtiniau, jog $Y = 0$, o ne $Y = 1$. Tuo tarpu galimybė 3,5 (t. y. 35 : 10) rodo, kad daug tikėtiniau, jog $Y = 1$, nei $Y = 0$.

Galimybės logaritmas $z(\vec{x}_i) = \ln(p_i/(1 - p_i))$ nuo kintamųjų reikšmių $x_{1i}, \dots, x_{ki}$ priklauso tiesiškai (žr. (4)). Be to (priešingai nei p_i), jis gali įgyti reikšmes iš intervalo $(-\infty, +\infty)$. Todėl šiuo atveju taikant (1) modelį nekyla problemos, kad prognozuojamoji reikšmė nepateks į leistinų reikšmių intervalą. Kai $z(\vec{x}_i)$ įgyja labai mažas reikšmes, tai p_i artimas nuliui. Kai $z(\vec{x}_i)$ įgyja dideles reikšmes, tai p_i artimas vienetui. Kai $z(\vec{x}_i) = 0$, tai $p_i = 0,5$.

Logistinė regresija tinka galiojant gana bendroms prielaidoms: kintamieji $X_1, \dots, X_k$ nebūtinai turi būti normalieji; nereikalaujama normaliai pasiskirsčiusių paklaidų, nekalbama apie priklausomo kintamojo homoskedastiškumą. Antra vertus, (2) modelis gali prognozavimui netikti dėl kintamųjų multikolinearumo arba dėl sudėtingesnės kintamųjų tarpusavio priklausomybės.

Taikant tas pačias, kaip ir daugialypėje regresijoje, kodavimo taisykles, į modelį galima įtraukti pseudokintamuosius.

7.2. Prognozavimas



Sulaukęs senatvės, žmogus miršta.

Mao

Tarkime, duomenis sudaro stebėjimai $(y_i, x_{1i}, x_{2i}, \dots, x_{ki})$, $i = 1, 2, \dots, n$; čia y_i yra arba 0, arba 1, o $x_{1i}, x_{2i}, \dots$ – intervalinių kintamųjų arba pseudokintamųjų reikšmės. Kaip ir tiesinės regresijos atveju, parametrų $a, b_1, \dots, b_k$ įverčius $\hat{a}, \hat{b}_1, \dots, \hat{b}_k$ reikia parinkti taip, kad (2) modelis su turimais duomenimis būtų kuo geriau suderintas. Tam taikomas ne mažiausiųjų kvadratų, o didžiausiojo tikėtino metodo. Kiekvienam stebėjimui pagal (2) formulę skaičiuojama tikimybė p_i . Parametrų įverčiai $\hat{a}$ ir $\hat{b}_1, \dots, \hat{b}_k$ parenkami taip, kad tikėtino funkcija

$$L = \prod_{i: y_i=1} p_i \prod_{i: y_i=0} (1 - p_i) \quad (5)$$

būtų maksimali. Čia

$$p_i = \frac{\exp\{\hat{z}(\vec{x}_i)\}}{1 + \exp\{\hat{z}(\vec{x}_i)\}}, \quad \hat{z}(\vec{x}_i) = \hat{a} + \hat{b}_1 x_{1i} + \hat{b}_2 x_{2i} + \dots + \hat{b}_k x_{ki}. \quad (6)$$

Parametrų įverčių skaičiavimas – iteracinis procesas, t. y. pasirenkamos pradinės jų reikšmės ir, taikant tam tikrą skaičiavimo metodą, keičiamos tol, kol stabilizuojasi.

Didžiausiojo tikėtino metodo realizuotas daugelyje statistinių paketų. Šioje knygoje naudosimės logistinės regresijos koeficientais, apskaičiuotais SPSS paketu.

Gauti koeficientai $\hat{a}, \hat{b}_1, \dots, \hat{b}_k$ naudojami $\hat{z}(\vec{x})$ skaičiuoti. Be to, pagal (6) formulę visada galima rasti tikimybę, kad $Y = 1$, įvertį.

Tikimybės $P(Y = 1)$ įvertis, kai nepriklausomų kintamųjų reikšmių $x_1, x_2, \dots, x_k$ vektorius yra $\vec{x} = (x_1, x_2, \dots, x_k)$, skaičiuojamas pagal formulę $\hat{P}(Y = 1 | \vec{x}) = \exp \{\hat{z}(\vec{x})\} / (1 + \exp \{\hat{z}(\vec{x})\})$; čia $\hat{z}(\vec{x}) = \hat{a} + \hat{b}_1 x_1 + \hat{b}_2 x_2 + \dots + \hat{b}_k x_k$.

Žinoma, tikimybės įvertis skaičiuojamas tik tokioms x reikšmėms, kurios patenka į duomenų aibės intervalą, pavyzdžiui, x_1 turi būti iš intervalo $[\min x_{1i}, \max x_{1i}]$ ir pan.

7.1 pavyzdys. Turime 24 studentų įskaitos rezultatų duomenis. Priklausomas kintamasis $Y = 1$, jeigu studentas gavo įskaitą, ir $Y = 0$, jeigu negavo. Kiek valandų praktinių užsiėmimų dirbo kiekvienas studentas, rodo kintamasis $PRAT$. Ar studentas prieš pat sesiją ko nors klausė dėstytojo, rodo kintamasis $KALB$ (1 – klausė, 0 – neklausė). Duomenys pateikti 7.1 lentelėje. Įvertinsime tikimybę, kad išlaikys įskaitą studentas, kuris pratybose dirbo lygiai 20 valandų ir spėjo į save atkreipti dėstytojo dėmesį ($KALB = 1$).

7.1 lentelė. Įskaita

Įskaita (y)	0	0	0	0	0	0	0	0	0	0	0	1
Kalb (x_1)	0	0	0	0	0	1	1	1	1	1	1	0
Prat (x_2)	19	17	13	15	19	21	17	18	23	15	13	26

Įskaita (y)	1	1	1	1	1	1	1	1	1	1	1	1
Kalb (x_1)	0	0	1	1	1	1	1	1	1	0	0	0
Prat (x_2)	30	19	22	21	24	28	30	27	21	24	20	16

Kintamasis $KALB$ yra pseudokintamasis, kintamasis $PRAT$ – intervalinis kintamasis. SPSS paketu apskaičiuojami koeficientai $\hat{a}$, $\hat{b}_1$ ir $\hat{b}_2$ (žr. 7.2 pav., grafą B).

VARIABLES IN THE EQUATION						
		B	S.E	Wald	df	Sig.
Step	KALB(1)	1,459	1,376	1,125	1	,289
1 ^a	PRAT	,590	,264	4,978	1	,026
	Constant	-12,371	5,663	4,772	1	,029

^a. Variable(s) entered on step 1: KALB, PRAT

7.2 pav. SPSS paketu gauta 7.1 pavyzdžio koeficientų lentelė

Pagal tas pačias, kaip ir tiesinėje regresijoje, taisyklės užrašome z formulę:

$$z = -12,371 + 1,459 \cdot KALB + 0,590 \cdot PRAT.$$

Kai $KALB = 1$, o $PRAT = 20$, tai $z = 0,888$. Pagal (2) formulę nustatome, kad

$$\hat{P}(\text{įskaita išlaikyta} | (20, 1)) = \exp \{0,888\} / (1 + \exp \{0,888\}) = 0,71.$$

Kaip interpretuojamos koeficientų $\hat{b}_j$ reikšmės? Tiriant intervalinius kintamuosius, $\hat{b}_j$ parodo, kiek padidėja (sumažėja) $\hat{z}(\vec{x})$ reikšmė, kai x_j padidėja vienu vienetu, o likusieji $x_1, \dots, x_{j-1}, x_{j+1}, \dots, x_k$ yra fiksuoti. Pseudokintamųjų atveju skirtingoms b_j reikšmėms gaunamos skirtingos galimybės logaritmo formulės. Tačiau galimybės logaritmo pokyčius sunku interpretuoti. Todėl paprastai skaičiuojamas vadinamasis *galimybių*

santykis $\exp\{\hat{b}_j\}$, kuris parodo, kaip kinta Y galimybė įgyti reikšmę 1. Prisiminkime 7.1 pavyzdį. Atkreipusių į save dėmesį studentų galimybė gauti įskaitą yra

$$\left(\frac{\hat{P}(Y = 1|PRAT)}{1 - \hat{P}(Y = 1|PRAT)} \right)_{KALB=1} = \exp\{-12,371 + 1,459 + 0,59 \cdot PRAT\}.$$

Tuo tarpu likusiųjų galimybė yra

$$\left(\frac{\hat{P}(Y = 1|PRAT)}{1 - \hat{P}(Y = 1|PRAT)} \right)_{KALB=0} = \exp\{-12,371 + 0 + 0,59 \cdot PRAT\}.$$

Galimybių santykis

$$\left(\frac{\hat{P}(Y = 1|PRAT)}{1 - \hat{P}(Y = 1|PRAT)} \right)_{KALB=1} : \left(\frac{\hat{P}(Y = 1|PRAT)}{1 - \hat{P}(Y = 1|PRAT)} \right)_{KALB=0} = \exp\{1,459\} = 4,302.$$

Taigi galime sakyti, kad studentas, paskutiniuose užsiėmimuose atkreipęs į save dėstytojo dėmesį, padidino savo galimybę gauti įskaitą 4,302 karto. SPSS paketu apskaičiuoti koeficientai $\exp\{b_j\}$ pateikti 7.2 paveiksle, stulpelyje $\text{Exp}(B)$. Analogiškai interpretuojami ir intervalinių kintamųjų galimybių santykiai. Pavyzdžiui, viena papildoma praktinių užsiėmimų valanda padidina galimybę išlaikyti įskaitą 1,803 karto.

Tarkime, kalbame apie 7.1 pavyzdžio studentą ($KALB = 1$, $PRAT = 20$). Jo $\hat{P}(Y = 1|20, 1) = 0,71$, o galimybė išlaikyti įskaitą yra $0,71/(1 - 0,71) = 2,45$ (t. y. galimybė vertintina santykiu $2,45 : 1$). Jeigu jis praktiniuose užsiėmimuose būtų dirbęs 21 valandą, jo galimybė padidėtų iki $2,45 \cdot 1,803 = 4,4$. Kita vertus, jeigu jis būtų į save neatkreipęs dėstytojo dėmesio, jo galimybė gauti įskaitą sumažėtų iki $2,45/4,302 = 0,56$, t. y. taptų labiau tikėtina, kad įskaitos jis negaus.

7.3. Klasifikavimas

Aprašysime, kaip logistinė regresija taikoma klasifikavimui. Žinodami $P(Y = 1 | \vec{x})$ įvertį, galime nesunkiai nusakyti taisyklę Y reikšmei prognozuoti.

Jeigu $\hat{P}(Y = 1 | \vec{x}) > 0,5$, tai prognozuojame, kad Y reikšmė yra 1.

Jeigu $\hat{P}(Y = 1 | \vec{x}) < 0,5$, tai prognozuojame, kad Y reikšmė yra 0.

Čia nenumatytas atvejis, kai $\hat{P}(Y = 1 | \vec{x}) = 0,5$. Realiai taikymuose ši situacija beveik nepasitaiko. Vis dėlto, jeigu tikimybės įvertis lygus 0,5 (t. y. vienodai tikėtina, kad $Y = 1$ ir $Y = 0$), sprendimą apie Y reikšmę galima priimti metant monetą. Jeigu atsivers herbas, laikysime $Y = 1$.



Galima pasirinkti ir kitokią Y prognozavimo taisyklę. Pavyzdžiui, tarti, kad $Y = 1$, kai $\hat{P}(Y = 1 | \vec{x}) > 0,7$, ir pan. Vis dėlto dažniausiai tikimybė lyginama su 0,5. Tokio lyginimo idėja labai paprasta – prognozuojame tą Y reikšmę, kuri labiau tikėtina. Šiame skyriuje kitų prognozavimo taisyklių nenagrinėsime.

Jeigu mus domina tik Y reikšmės prognozė, visai nebūtina skaičiuoti $P(Y = 1 | \vec{x})$ įverčio. Iš tikrųjų $\hat{P}(Y = 1 | \vec{x}) > 0,5$ tada ir tik tada, kai $\hat{z}(\vec{x}) > 0$. Todėl Y reikšmėms prognozuoti patogiau taikyti tokią taisyklę:

I formulę $\hat{z}(\vec{x}) = \hat{a} + \hat{b}_1x_1 + \hat{b}_2x_2 + \dots + \hat{b}_kx_k$ įstatomos $x_1, x_2, \dots, x_k$ reikšmės.

Jeigu $\hat{z}(\vec{x}) > 0$, tai prognozuojama, kad $Y = 1$.

Jeigu $\hat{z}(\vec{x}) < 0$, tai prognozuojama, kad $Y = 0$.

Jei $\hat{z}(\vec{x}) = 0$, tai rekomenduojama sprendimą priimti metant monetą.

7.2 pavyzdys. Nagrinėto 7.1 pavyzdžio $\hat{P}(Y = 1|(20, 1)) = 0,71 > 0,5$, todėl prognozuojame, kad Y įgis reikšmę 1, t. y. studentas įskaitą gaus. Nesunku įsitikinti, kad $\hat{z} = 0,888 > 0$.

Logistinėje regresijoje prognozuojame tikimybes ir pagal jas sprendžiame, kad $Y = 1$ arba $Y = 0$ (suklystame arba nesuklystame). Todėl logistinėje regresijoje prasmingiau kalbėti ne apie liekamąsias paklaidas, o apie teisingų prognozių procentą. Duomenis sudaro stebėjimai $(y_i, x_{1i}, x_{2i}, \dots, x_{ki})$, $i = 1, 2, \dots, n$, ir žinomos y_i reikšmės, todėl galima patikrinti, ar dažnai jos sutampa su reikšmėmis, kurias remdamiesi logistine regresija prognozuotume. Tikrinant, ar logistinė regresija prognozėms tinka, šis žingsnis būtinas.

Jeigu duomenų, iš kurių gauti parametrai įverčiai $\hat{a}$ ir $\hat{b}_j$, prognozės netikslios, tai logistinės regresijos taikyti negalima, net jei kiti rodikliai bei statistinės išvados rodytų, kad ji tinkama.

Duomenų y_i reikšmės ir prognozuotinos y_i reikšmės pateikiamos vadinamąja klasifikacine lentele. Nagrinėto 7.1 pavyzdžio duomenų klasifikacinė lentelė parodyta 7.3 paveiksle.

Iš 11 įskaitą negavusių studentų taikant logistinę regresiją teisingai klasifikuoti 7, o neteisingai 4, tai sudaro 63,6% teisingų prognozių. Iš gavusiųjų įskaitą teisingai klasifi-

CLASSIFICATION TABLE ^a				
Observed		Predicted		
		ĮSKAITA		Percentage Correct
		Negavo	Gavo	
Step 1 ĮSKAITA	Negavo	7	4	63,6
	Gavo	1	12	92,3
Overall Percentage				79,2

^a. The cut value is ,500.

7.3 pav. SPSS paketu gauta 7.1 pavyzdžio klasifikacinė lentelė

CLASSIFICATION TABLE ^a				
Observed		Predicted		
		Status		Percentage Correct
		Vyr.	Mot.	
Step 1 Status	Vyr.	1054	1	99,9
	Mot.	65	1	1,5
Overall Percentage				94,1

^a. The cut value is ,500.

7.4 pav. Lyties atpažinimo SPSS klasifikacinė lentelė

didesnė už 0,5 – gavę įskaitą (g). Jie surašyti apačioje. Virš x ašies atidėtos duomenų $\hat{P}(Y = 1 | \bar{x})$ reikšmės ir pažymėta, ar respondentas iš tikrųjų gavo įskaitą, ar ne. Kuo daugiau simbolių „n“ yra į kairę nuo 0,5 ir kuo daugiau „g“ į dešinę nuo 0,5, tuo geriau prognozės sutapo su turimais stebėjimais. Pažymėtina, kad vieną stebėjimą atitinka net keturi simboliai. (Kiek stebėjimų turi atitikti vienas simbolis, SPSS nustato automatiškai.)

7.4. Statistinės išvados



100 000 lemingų negali klysti.

Kaip ir daugialypėje regresijoje, mus domina, ar visi į modelį įtraukti nepriklausomi kintamieji prognozavimui svarbūs. Aišku, jeigu prognozuojama tikimybė nuo kintamojo x_j nepriklauso, tai (2) modelio parametras $b_j = 0$. Todėl klausimas apie prognozės priklausomybę nuo nepriklausomų kintamųjų ekvivalentus klausimui apie parametru $b_1, \dots, b_k$ lygį nuliui. Tai ir aptarsime.

7.4.1. Modelio χ^2 suderinamumo kriterijus

Jeigu visi koeficientai b_j lygūs nuliui, tai akivaizdu, kad (2) logistinės regresijos modelis visiškai netinka prognozėms daryti. χ^2 suderinamumo kriterijus yra regresijos ANOVA analogas (žr. 6.4.1 skyrelį).

Tarkime, didžiausiojo tikėtino metodo parinkome parametrus $\hat{a}, \hat{b}_1, \dots, \hat{b}_k$, įstatėme juos į didžiausiojo tikėtino funkciją L (ją apibrėžėme 7.2 skyrelyje) ir radome L maksimumą. Pažymėkime jį simboliu $L(\hat{a}, \hat{b})$.

Tarkime, kad pasirinkome logistinės regresijos modelį, kur visi $b_j = 0$, t. y. $z_i = a$. Didžiausiojo tikėtino funkcijos maksimumą šiuo atveju pažymėkime $L(\tilde{a}, 0)$.

χ^2 kriterijus remiasi tuo, kad $L(\hat{a}, \hat{b})$ mažai skiriasi nuo $L(\tilde{a}, 0)$, jei visi koeficientai $b_j = 0$.

1 Statistinė hipotezė:

$$\begin{cases} H_0: b_1 = b_2 = \dots = b_k = 0, \\ H_1: \text{bent vienas } b_j \neq 0. \end{cases} \quad (7)$$

2 Kriterijaus statistika. Apskaičiuojame

$$\chi^2 = -2 \ln L(\tilde{a}, 0) + 2 \ln L(\hat{a}, \hat{b}).$$

3 Sprendimo priėmimo taisyklė. Tegul reikšmingumo lygmuo lygus α . Hipotezė H_0 atmetama (taigi bent vienas $b_j \neq 0$), jeigu $\chi^2 > \chi^2_{\alpha}(k)$; čia $\chi^2_{\alpha}(k)$ yra χ^2 skirstinio su k laisvės laipsnių α lygmens kritinė reikšmė. Hipotezė H_0 neatmetama, jeigu $\chi^2 \leq \chi^2_{\alpha}(k)$. Pagal p -reikšmę sprendžiama taip: jeigu $p < \alpha$, tai H_0 atmetama. Jeigu $p \geq \alpha$, tai H_0 neatmetama. Taigi neatmesta nulinė hipotezė H_0 rodo, kad logistinės regresijos modelis netinka. Atmesta nulinė hipotezė H_0 rodo, kad bent vienas nepriklausomas kintamasis modelyje reikalingas.

7.3 pavyzdys. Patikrinkime hipotezę, kad 7.1 pavyzdžio bent vienas koeficientas b_1 arba b_2 nenulinis. Tegul reikšmingumo lygmuo $\alpha = 0,05$. SPSS paketu gauta χ^2 reikšmė (14,503) ir p -reikšmė (0,001) pateiktos 7.6 paveiksle. Kadangi $0,001 < 0,05$, tai nulinę hipotezę H_0 atmetame. Darome išvadą, kad bent vieno kintamojo modelyje reikia.

OMNIBUS TEST OF MODEL COEFFICIENTS				
		Chi-square	df	Sig.
Step 1	KALB(1)	14,503	2	,001
	PRAT	14,503	2	,001
	Constant	14,503	2	,001

7.6 pav. SPSS paketu gauta χ^2 kriterijaus reikšmė

7.4.2. Voldo kriterijus

Voldo kriterijus yra Stjudento kriterijaus tiesinėje regresijoje analogas, t. y. jis atsako į klausimą, ar konkretus koeficientas $b_j \neq 0$. Voldo statistika $W = (\hat{b}_j/SE_j)^2$; čia SE_j yra $\hat{b}_j$ standartinio nuokrypio įvertis. Voldo statistika turi χ^2 skirstinį su 1 laisvės laipsniu. Ją patogiausia skaičiuoti statistiniu paketu. Suformuluosime, kaip naudotis Voldo kriterijumi, žinant statistikos p -reikšmę.

1 Statistinė hipotezė:

$$\begin{cases} H_0: b_j = 0, \\ H_1: b_j \neq 0. \end{cases}$$

2 Sprendimo priėmimo taisyklė. Tegul reikšmingumo lygmuo lygus α . Hipotezė H_0 atmetama (taigi $b_j \neq 0$), jeigu p -reikšmė $p < \alpha$. Hipotezė H_0 neatmetama, jeigu $p \geq \alpha$.

7.4 pavyzdys. Prisiminkime 7.1 pavyzdį. Kadangi kintamasis *KALB* dvireikšmis (pseudokintamasis), tai Voldo kriterijų taikome tik koeficientui b_2 (t. y. kintamojo *PRAT* daugikliui). Voldo statistikos reikšmė (4,978) ir p -reikšmė (0,026) pateiktos 7.2 paveiksle. Kadangi $0,026 < 0,05$, tai gauname statistiškai reikšmingą patvirtinimą, jog tikimybė gauti įskaitą priklauso nuo kintamojo *PRAT* reikšmės. Beje, SE_j nurodyta stulpelyje S. E.

VARIABLES IN THE EQUATION						
		B	S. E	Wald	df	Sig.
Step 1 ^a	MES	,349	,133	6,886	1	,009
	EMOC	-,444	,187	5,614	1	,018
	KITI	,066	,092	,508	1	,476
	Constant	-20,014	7,428	7,260	1	,007

^a. Variable(s) entered on step 1: MES, EMOC, KITI

7.7 pav.

7.5 pavyzdys. Škotų sociologas įvertino keliasdešimties lietuvių ir estų emocionalumą (*EMOC*), požiūrį į savo valstybę (*MES*) ir į kaimynines šalis (*KITI*). Tarkime, kad reikšmingumo lygmuo $\alpha = 0,05$. Iš pateiktos 7.7 paveiksle koeficientų lentelės matyti, kad kintamieji *MES* ir *EMOC* padeda atskirti lietuvių nuo esto (p -reikšmės $0,009 < 0,05$ ir $0,018 < 0,05$), tuo tarpu kintamojo *KITI* Voldo statistikos p -reikšmė $0,476 > 0,05$, todėl šio kintamojo nauda prognozuojant respondento tautybę abejotina.

Ką daryti, kai Voldo kriterijaus p -reikšmė ne mažesnė už reikšmingumo lygmenį α ? Tuomet reiktų išbandyti logistinės regresijos modelį be įtartino kintamojo ir pažiūrėti, kaip pasikeičia koeficientų reikšmės bei klasifikacinė lentelė. Iš 7.5 pavyzdžio pašalinus kintamąjį *KITI*, klasifikavimo tikslumas praktiškai nepasikeičia (nuo 83,3% sumažėja iki 82,7%), tačiau Voldo kriterijus abiem likusiems kintamiesiems statistiškai reikšmingas.

7.4.3. Hosmerio–Lemešou kriterijus

D. V. Hosmeris¹ ir S. Lemešou² χ^2 suderinamumo kriterijui pasiūlė alternatyvą. Jos esmė ta, kad visų stebėjimų prognozuojamųjų tikimybių $\hat{p}_i = \hat{P}(Y = 1 | \vec{x}_i)$ variacinė eilutė padalijama į keletą grupių. Kiekvienos grupės tikimybės sudedamos. Gautosios sumos traktuojamos kaip skaičiai, rodantys, kiek kartų kiekvienoje grupėje y_i turėtų įgyti reikšmę 1, jeigu (2) modelis būtų suderintas su duomenimis. Taip pat sudedamos kiekvienos grupės stebėjimų y_i reikšmės. Gautosios sumos rodo, kiek kartų kiekvienoje grupėje y_i įgijo reikšmę 1. Šių dydžių skirtumą aprašo χ^2 skirstinys su $(k - 2)$ laisvės laipsnių; čia k – grupių skaičius. Tuo ir pagrįstas Hosmerio–Lemešou kriterijus.

HOSMER AND LEMESHOW TEST

Step	Chi-square	df	Sig.
1	2,730	7	,909

CONTINGENCY TABLE FOR HOSMER AND LEMESHOW TEST

		TAUT = ,00 lietuviai		TAUT = 1,00 estai		Total
		Observed	Expected	Observed	Expected	
Step 1	1	8	7,980	0	,020	8
	2	8	7,911	0	,089	8
	3	7	7,357	1	,643	8
	4	5	5,160	3	2,840	8
	5	3	3,435	5	4,565	8
	6	3	2,153	5	5,847	8
	7	1	1,518	7	6,482	8
	8	2	1,007	6	6,993	8
	9	0	,479	11	10,521	11

7.8 pav. 7.5 pavyzdžio Hosmerio–Lemešou testo rezultatai

^{1,2} David W. Hosmer, Stanley Lemeshow – amerikiečių statistikai.

Tegul reikšmingumo lygmuo lygus α . Kai Hosmerio–Lemešou statistikos p -reikšmė $p \geq \alpha$, gauname patvirtinimą, kad logistinės regresijos modelis su duomenimis suderintas.

Taikant Hosmerio–Lemešou kriterijų 7.5 pavyzdyje tautybei pagal kintamuosius *MES* ir *EMOC* prognozuoti gauti rezultatai pateikti 7.8 paveiksle. Tarkime, kad reikšmingumo lygmuo $\alpha = 0,05$. Matome, kad p -reikšmė $0,909 > 0,05$, t. y. kriterijus patvirtina, jog logistinės regresijos modelis gana gerai suderintas su duomenimis. Antroje 7.8 paveikslo lentelėje nurodyta, kiek iš tikrųjų 0 ir 1 buvo kiekvienoje iš 9 grupių ir kiek jų turėjo būti prognozei taikant logistinę regresiją. Pavyzdžiui, trečioje grupėje buvo 8 stebėjimai. Vieno iš jų y_i reikšmė lygi vienetui. Tuo tarpu visų šiuos stebėjimus atitinkančių tikimybių $\hat{p}_i$ suma lygi 0,643. Nulių buvo septyni, o visų tikimybių $1 - \hat{p}_i$ suma lygi $7,357 = 8 - 0,643$.

Panašų gautume ir 7.1 pavyzdžio rezultata. Vis dėlto Hosmerio–Lemešou kriterijų paprastai rekomenduojama taikyti, kai stebėjimų yra pakankamai daug (kad į kiekvieną grupę pakliūtų bent 5 stebėjimai), todėl šis kriterijus 7.1 pavyzdžiui nelabai taikytinas.

7.4.4. Determinacijos koeficientai

Kai tiesinėje regresinėje analizėje norima skaitiškai įvertinti, ar nepriklausomų kintamųjų ir Y priklausomybė yra didelė, skaičiuojamas determinacijos koeficientas r^2 . Logistinėje regresijoje yra net keletas determinacijos koeficiento analogų. Susipažinsime su kai kuriais iš jų. Visiems koeficientams galioja ta pati taisyklė: kuo koeficientas didesnis, tuo geriau logistinė regresija suderinta su duomenimis. Patys koeficientai tarpusavyje dažniausiai nepalyginami, nes skiriasi jų apibrėžimai.

Makfadeno¹ pseudodeterminacijos koeficientas r^2 apibrėžiamas taip:

$$r_M^2 = 1 - \frac{-2 \ln L(\hat{a}, \hat{b})}{-2 \ln L(\tilde{a}, 0)} = 1 - \frac{\ln L(\hat{a}, \hat{b})}{\ln L(\tilde{a}, 0)}. \quad (8)$$

Primename, kad $L(\hat{a}, \hat{b})$ ir $L(\tilde{a}, 0)$ apibrėžti skyrelio pradžioje.

7.6 pavyzdys. Apskaičiuokime 7.1 pavyzdžio Makfadeno koeficientą r_M^2 . SPSS paketas pateikia $-2 \ln L(\hat{a}, \hat{b}) = 18,601$. Be to, χ^2 suderinamumo kriterijaus statistika yra 14,503. Kadangi ši statistika lygi $-2 \ln L(\tilde{a}, 0) + 2 \ln L(\hat{a}, \hat{b})$ (žr. 7.4.1 skyrelį), tai lengvai randame $-2 \ln L(\tilde{a}, 0) = 33,104$. Taigi koeficientas $r_M^2 = 1 - 18,601/33,104 = 0,438$.

Dažnai taikomas Kokso–Snelo² pseudodeterminacijos koeficientas

$$r_{CS}^2 = 1 - \left(\frac{L(\tilde{a}, 0)}{L(\hat{a}, \hat{b})} \right)^{2/n}; \quad (9)$$

čia n – stebėjimų skaičius.

¹ D. McFadden – amerikiečių statistikas.

² David R. Cox, E. J. Snell – anglų statistikai.

MODEL SUMMARY			
Step	-2 Log likelihood	Cox & Snell R Square	Nagelkerke R Square
1	18,601	,454	,606

7.9 pav.

7.7 pavyzdys. Apskaičiuokime 7.1 pavyzdžio Kokso–Snello pseudodeterminacijos koeficientą. Jau 7.6 pavyzdyje buvome gavę reikšmes $-2 \ln L(\hat{a}, \hat{b})$ ir $-2 \ln L(\tilde{a}, 0)$. Kadangi $n = 24$, tai $r_{CS}^2 = 0,45$. Matome, kad abu koeficientai skiriasi nedaug.

Kokso–Snello pseudodeterminacijos koeficientas mažesnis už vienetą. Nagelkerkė¹ pasiūlė naudoti normuotąjį Kokso–Snello koeficientą

$$r_N^2 = \frac{r_{CS}^2}{\max r_{CS}^2} = \frac{r_{CS}^2}{1 - (L(\tilde{a}, 0))^{2/n}}. \quad (10)$$

Nesunku įsitikinti, kad 7.1 pavyzdžio Nagelkerkės pseudodeterminacijos koeficientas $r_N^2 = 0,60$. SPSS paketu gauti Kokso–Snello ir Nagelkerkės pseudodeterminacijos koeficientai parodyti 7.9 paveiksle.



galimybė	Kokso–Snello r_{CS}^2	pseudodeterminacijos
galimybių santykis	Makfadeno r_M^2	koeficientai
Hosmerio–Lemešou testas	Negelkerkės r_N^2	Voldo kriterijus

UŽDAVINIAI

1. Edukologas tiria žargono vartojimą sąlygojančius veiksnius. Po smagaus humoro vakaro, kurio metu visi leipo juokais, sociologas apklausė 22 žiūrovus. Kai kurie iš jų pasakė, kad prisijuokė, kiti pasidžiaugė, kad prisizvengė. Žiūrovo linksmumas (kintamasis $Y = 0$ – žvengia, $Y = 1$ – juokiasi), amžius ir lytis (0 – vyr., 1 – mot.) pateikta 7.2 lentelėje. Remdamiesi logistine regresija, nustatykite, ar galima pagal amžių atskirti besijuokiančius žiūrovus nuo žvengiančiųjų. Lytį panaudoti kaip pseudokintamąjį.

7.2 lentelė

Linksmumas (y)	1	0	1	0	0	1	1	1	1	1	0
Lytis (x_1)	1	1	1	1	1	1	1	1	1	1	0
Amžius (x_2)	64	56	40	24	24	40	56	64	40	40	32

Linksmumas (y)	1	1	0	0	0	0	1	0	0	1	0
Lytis (x_1)	0	0	0	0	0	0	0	0	0	0	0
Amžius (x_2)	56	24	16	32	16	24	32	24	16	56	24

¹ N. J. D. Nagelkerke – olandų statistikas.

2. Ar galima pagal pajamas (*PAJAMOS*) ir darbo prestižiškumo indeksą (*PRESTG*) atpažinti, kad respondentas aukštąjį išsilavinimą turi (*MOKSL* = 1) arba neturi (*MOKSL* = 0)? Duomenys pateikti 7.3 lentelėje.

7.3 lentelė

Pajamos	3670	1923	3067	3811	3494	2012	1637	1265	2722	4050	1501	3340	3193
Prestg	60	65	70	105	70	55	55	35	105	135	50	65	60
Moksl	1	0	1	1	1	0	0	0	0	1	0	1	1

Pajamos	3125	4050	3458	2219	3781	2736	2568	3408	3298	3043	3536	3780	3798
Prestg	95	115	95	95	90	85	135	110	60	95	80	94	78
Moksl	0	1	0	0	1	0	0	0	1	1	1	1	1

3. Gimdymo namuose surinkti duomenys (žr. 7.4 lentelę) apie gimdyvių amžių, svorį (kg), rūkymą (1 – rūko, 0 – nerūko), hipertoniją (1 – serga, 0 – neserga) ir naujagimio svorį (g). Naujagimis sveria nepakankamai, jeigu jo svoris nesiekia 2500 g. Įvertinkite tikimybę, kad būsimoji motina, kuri rūko, serga hipertonija ir sveria 85 kg, pagimdys nepakankamo svorio naujagimį. Kokį naujagimio svorį prognozuotumėte taikydami tiesinę regresiją?

7.4 lentelė

Motinos amžius	Rūkymas	Hipertonija	Naujagimio svoris (g)	Motinos svoris (kg)
24	0	0	1703	64,0
21	1	1	1792	82,5
21	0	0	1930	100,0
19	0	0	2084	51,0
24	0	0	2102	69,0
17	1	0	2227	55,0
18	0	0	2284	74,0
15	0	0	2383	57,5
17	0	0	2440	60,0
20	0	0	2452	52,5
14	1	0	2468	50,5
14	0	0	2497	50,0
21	1	1	2497	65,0
33	0	0	2553	77,5
32	0	0	2837	60,5
28	0	0	2879	83,5
29	0	0	2922	75,0
26	1	0	2922	84,0
17	0	0	2922	56,5
35	1	0	2950	60,5
33	1	0	3035	54,5
21	1	0	3044	92,5
19	0	0	3064	94,5
21	0	0	3064	80,0
19	0	0	3177	57,5
28	0	0	3236	70,0
16	1	0	3376	67,5
22	0	0	3462	65,5
32	0	0	3475	85,0
19	0	0	3574	52,5
24	0	0	3730	55,0
25	0	4	3985	60,0


8. KLASTERINĖ ANALIZĖ



Jeigu eksperimento rezultatą suprasti prireikia statistiko pagalbos, tai turėtumėte geriau suplanuoti eksperimentą.

E. Rezerfordas

Vyksta firmos „Doodoo ir Co“ prezidento gimtadienis. Po pirmųjų užkandžių prie švediškojo vaišių stalo stebime įprastą vaizdą – visi svečiai susiskirsto į didesnes ar mažesnes grupeles. Grupeles pavadinę klasteriais, galime teigti, kad įvyko natūrali klasterizacija. Matyti, kad: a) klasteriai nebūtinai vienodo didumo, b) į klasterį svečiai pateko pagal tam tikrus panašumus (bendrus interesus, pažintį, giminystę, abipuses simpatijas ir pan.), c) vieno klasterio svečiai panašesni tarpusavyje nei skirtingų klasterių. Kasdienėje ir mokslinėje veikloje klasterizavimas (grupavimas) vyksta nuolat. Šiame skyriuje aprašomas objektų skirstymo į klasterius uždavinys ir jo sprendimo metodai.



8.1. Klasterinės analizės etapai ir tikslai

Taikydami klasterinę analizę¹, nustatome objektų panašumą ir suskirstome juos į klasterius. Tikslaus klasterio apibrėžimo nėra, tačiau norėtume pabrėžti, kad nereikėtų tapatinti dviejų terminų – „grupė“ ir „klasteris“. Klasteris – *panašių* objektų grupė. Ką reiškia objektų panašumas, aptariama 8.2 skyrelyje. Klasterinės analizės tikslas – suskirstyti objektus taip, kad skirtumai klasterių viduje būtų kuo mažesni, o tarp klasterių – kuo didesni.

Patebėsime, kad skirstydami objektus į klasterius dažniausiai nežinome, kiek klasterių tiriamoje populiacijoje realiai egzistuoja (ir ar išvis egzistuoja). Todėl tam tikra prasme klasterinė analizė yra egzistuojančių struktūrų paieška. Žmonių noras grupuoti yra visapimantis – grupuojamos valstybės, augalai, gyvūnai, mašinos, muzikos kryptys ir pan. Klasterinės analizės metodai leidžia šį procesą padaryti objektyvesnį. Konkretaus metodo parinkimas, rezultatų interpretacija priklauso tik nuo tyrėjo.

¹ Terminą „klasteris“ 1939 metais pirmasis pavartojo R. Trajonas (R. Tryon). Klasterinė analizė kartais dar vadinama taksonomine analize.



Biologijoje kartais porūšių skirtumai būna ne ką mažesni nei rūšių. Todėl klasifikuojant vabzdžius, žuvis ir pan. tarp mokslininkų netyla diskusijos dėl rūšių ir porūšių skaičiaus bei sudėties.

Klasterizuodami turime pereiti 5 etapus:

- 1 Pasirinkti klasterizuojamus objektus.
- 2 Nuspręsti, pagal kokius požymius klasterizuosime.
- 3 Pasirinkti kiekybinį matą, kuriuo matuosime objektų panašumą.
- 4 Vienu ar kitu metodu suskirstyti objektus į klasterius.
- 5 Peržiūrėti gautus rezultatus.

Klasterizuojamų objektų ir klasterizavimo požymių parinkimą diktuoja konkretaus tyrimo tikslai bei uždaviniai. Tai – ne statistiko reikalas. Ekonomistas siekia išskirstyti valstybes pagal jų ekonominius bei demografinius rodiklius; psichologas visus tiriamuosius nori suskirstyti į klasterius pagal jų intelektą, savitvardą bei temperamentą; medikas tiriamus ligonius klasifikuoja pagal įvairius organizmo funkcinis parametrus ir pan. Visais atvejais skirstymas į klasterius prasideda tada, kai jau turime objektų aibę ir kiekvieną objektą aprašančių *skaitinių* rodiklių aibę. Toliau svarbu parinkti kiekybinio panašumo matą – jų yra ne vienas. Nuo pasirinkto mato priklauso klasterizacijos rezultatai. Išsamiau galimi matai (bei jų pasirinkimo taisyklės) aptariami 8.2 skyrelyje. Turėdami kiekybinį panašumo matą, galime pasakyti, kurios objektų poros panašesnės. Klasterizacijos metodas leidžia nustatyti principus, pagal kuriuos sudaromi klasteriai, ir atsakyti į klausimą, ką reiškia klasterių panašumas. Suskirstę objektus į klasterius, dar turime patikrinti, ar gauti rezultatai neprieštarauja sveikam protui.

Yra keletas dalykų, kuriuos reikia turėti omenyje taikant klasterinės analizės metodus:

- 1) Klasterinėje analizėje yra daug euristinių, neturinčių teorinio pagrindimo, metodų. Viena iš problemų – dažnai nėra aišku, ar klasterizuojamų objektų aibė yra populiacija, ar populiacijos dalis (imtis). Taigi kyla sunkumų vertinant imties reprezentatyvumą, rezultatų statistinį reikšmingumą ir pan.
- 2) Klasterinės analizės metodai buvo konstruojami įvairioms sritims, todėl juose yra nemažai specifiskumų.
- 3) Tiems patiems duomenims taikydami skirtingus klasterinės analizės metodus, galime gauti skirtingus rezultatus.

Šiame skyriuje X, Y, Z žymėsime tiriamuosius objektus (respondentus, javų rūšis, akcines bendroves ir pan.); $(x_1, x_2, \dots, x_m)$, $(y_1, y_2, \dots, y_m)$ – atitinkamai objektų X ir Y pasirinktų m požymių reikšmių vektorius ir pan.

8.2. Objektų panašumo matai



Šiuo metu yra šimtas devyniasdešimt trys beždžionių rūšys. Šimtas devyniasdešimt dviejų rūšių beždžionės plaukuotos.

D. Morisas

Petriukas panašus į savo tėtį, naujasis firmos „Milimili“ mašinos modelis primena firmos „Tootoo“ modelį, grupės „Clap trept“ dainos yra regi stilčiau, UAB „Auksiukai“ priklauso vidutinio dydžio įmonių grupei, visi Linksmičių šeimos nariai yra sangvinikai ir pan. Tai-gi gyvenime dažnai pastebime, kad objektai panašūs. Panašumas – subjektyvus dalykas. Statistikoje kiek lengviau, nes klasterizuojame atsižvelgdami į skaičius (panašumo matų reikšmes). Tačiau ir čia labai daug priklauso nuo matuojamų požymių tipo (ar požymis tolydus, ar diskretus, ar dvireikšmis), nuo matavimų skalės ir nuo pasirinkto panašumo mato.

Dažniausiai naudojami panašumo matai:

- 1) metriniai atstumo matai,
- 2) koreliacijos koeficientai,
- 3) asociatyvumo koeficientai.

8.2.1. Metriniai atstumo matai

Metriniai atstumo matai naudojami tada, kai objektus charakterizuojantys požymiai matuojami pagal intervalų arba santykių skalę. Šiuos matus tiksliau būtų vadinti skirtingumo matais – kuo didesnė reikšmė, tuo objektai mažiau panašūs. Daugelis metrinio atstumo matų yra metrikos. Kas yra metrika ir kodėl svarbu, kad metrinis atstumo matas būtų metrika? Metrika – tai skaitinė neneigiama dviejų objektų X ir Y funkcija $d(X, Y)$, tenkinanti sąlygas:

- 1) simetriškumo: $d(X, Y) = d(Y, X)$;
- 2) trikampio nelygybės: $d(X, Y) \leq d(X, Z) + d(Y, Z)$;
- 3) netapačių objektų atskiriamumo: jei $X \neq Y$, tai $d(X, Y) \neq 0$;
- 4) tapačių objektų neatskiriamumo: jei $d(X, Y) = 0$, tai X ir Y identiški.

Išvardytų sąlygų natūralumas yra suprantamas. Pailiustruosime tai remdamiesi Euklido atstumo kvadratu – vienu iš metrinio atstumo matų.

Euklido atstumas objektams X ir Y apibrėžiamas taip:

$$d(X, Y) = \|X - Y\| = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \dots + (x_m - y_m)^2}.$$

Tarkime, X , Y ir Z yra trys VU studentai, kurių amžius ir ūgis atitinkamai yra (21, 180), (22, 178), (23, 179). Visų studentų ūgis ir amžius skirtingas. Tada $\|X - Y\|^2 = 5$, $\|X - Z\|^2 = 5$, $\|Y - Z\|^2 = 2$ – visi atstumai tarp objektų nelygūs nuliui (3 savybė). Akivaizdu, kad $\|X - Y\|^2 = \|Y - X\|^2 = 5$ (1 savybė), o $\|X - Y\|^2 = 5 \leq \|X - Z\|^2 + \|Y - Z\|^2 = 7$ (2 savybė). Atskirai reikia aptarti 4 savybę (tapačių objektų neatskiriamumo). Tarkime, dviejų studentų X ir Y ūgis ir amžius vienodi. Tada $d(X, Y) = 0$. Tapačios yra studentų tiriamų požymių reikšmės, tačiau ne patys studentai!

8.1 lentelė

Atstumas	$d(X, Y)$ formulė
Euklido	$\ X - Y\ = \sqrt{\sum_{i=1}^m (x_i - y_i)^2}$
Euklido atstumo kvadratas	$\ X - Y\ ^2 = \sum_{i=1}^m (x_i - y_i)^2$
Minkovskio	$\left(\sum_{i=1}^m x_i - y_i ^l \right)^{1/l}, \quad l > 0$
Manheteno (blokinis)	$\sum_{i=1}^m x_i - y_i $
Čebyšovo	$\max_i x_i - y_i $
Vektorių kampo kosinusas	$\sum_{i=1}^m (x_i y_i) \left(\sum_{i=1}^m x_i^2 \sum_{i=1}^m y_i^2 \right)^{-1/2}$
Mahalanobio atstumo kvadratas	$(x - y)' V^{-1} (x - y),$ V – požymių reikšmių vektorių kovariacinė matrica


Dažniausiai naudojami atstumai pateikti 8.1 lentelėje.

Manheteno atstumas yra atskiras Minkovskio¹ atstumo atvejis, kai $l = 1$. Mato pavadinimas aiškinamas labai paprastai – kelias iš taško A į tašką B Niujorke (ir ne tik jame) panašus į pavaizduotąjį 8.1 paveiksle.

Vektorių kampo kosinusui negalioja metrikos trikampio nelygybė!

Skaičiuojant Čebyšovo atstumą, naudojama tik dalis turimos informacijos apie objektus. Kada tai yra pateisinama? Tarkime, grupei keliautojų atliekamas suderinamumo testas. Norima sudaryti klasterius, į kuriuos patektų panašių charakterių (matuojamų požymių) žmonės, t. y. visi jų skirtumai nebūtų ryškūs. Tinkamiausias šiuo atveju yra panašumo matas – Čebyšovo atstumas.

Kai kovariacinė matrica yra vienetinė, Mahalanobio² atstumas sutampa su Euklido atstumo kvadratu.



¹ H. Minkowski (1864–1909) – vokiečių matematikas.

² Prasanta Chandra Mahalanobis (1893–1972) – indų matematikas.

Vienas iš metrinių atstumo matų trūkumų – nevienoda skirtingai matuojamų požymių įtaka. Kintamieji, kurių sklaidos charakteristikos įgyja dideles reikšmes, gali nustelbti mažai įvairuojančių kintamųjų įtaką. Tarkime, turime du vektorius (1; 800) ir (0,2; 200). Atstumas tarp jų yra $\sqrt{(0,8^2 + 600^2)} = 600,0007$. Atstumą faktiškai lemia antroji vektorių koordinatė. Vienas iš būdų šio trūkumo išvengti – užuot naudojus pačius kintamuosius, imti jų standartizuotąsias reikšmes (z -reikšmes).

8.2.2. Koreliacijos koeficientai

Žinome, kad koreliacijos koeficientai naudojami kaip kintamųjų panašumo matai. Kartais jais remiantis vertinamas objektų panašumas. Jei duomenys yra kiekybiniai, objektų panašumui įvertinti galima taikyti tiesinės koreliacijos koeficientą. Jis skaičiuojamas taip:

$$r_{XY} = \frac{\sum_{i=1}^m (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^m (x_i - \bar{x})^2 \sum_{i=1}^m (y_i - \bar{y})^2}}; \quad (1)$$

čia x_i yra X objekto i -ojo požymio reikšmė, y_j – Y objekto j -ojo požymio reikšmė, m – matuojamų požymių skaičius.

Kokie yra (1) mato privalumai ir trūkumai? Panagrinėkime tokį pavyzdį. Tarkime, du respondentai buvo paprašyti įvertinti 5 muzikos stilius (klasiką, džiazą, repą, populiariąją, roką) pagal 5 balų skalę (1 – labai nemėgsta, 2 – nemėgsta, 3 – nei taip, nei ne, 4 – mėgsta, 5 – labai mėgsta). Atsakymai pateikti 8.2 lentelėje.

Iš atsakymų matyti, kad I respondentas mėgsta klasikinę muziką ir džiazą, antrasis – repą ir roką. Skirtingi skonieniai, ar ne? Apskaičiuojame koreliacijos koeficientą $r_{XY} = -0,491$. Gavome rezultatą, kurio ir buvo galima tikėtis – priklausomybė atvirkštinė. Dabar tarkime, kad II respondento atsakymų vektorius yra toks: $Y1 = (2, 4, 5, 3, 5)$. Šiuo atveju, koreliacijos koeficientas $r_{XY1} = -0,491$. Koeficiento reikšmė nepasikeitė, nors pasikeitė *visi* antrojo respondento atsakymai!


Kiti koreliacijos koeficiento, kaip panašumo mato, trūkumai:

- 1) Jis neturi aiškos statistikinės prasmės (pvz., jei $r_{XY} = -0,491$, tai ar galima sakyti, kad objektai *labai* skiriasi?).
- 2) Jis nejautrus kintamųjų reikšmių išsibarstymui ir poslinkiui (pavyzdyje $Y1 = Y + 1$).
- 3) Jei vieno iš objektų kintamųjų reikšmių vektorius susideda iš vienodų reikšmių (pvz., vieno iš respondentų atsakymų vektorius yra (5, 5, 5, 5, 5)), r skaičiuoti negalima.
- 4) Jis nėra metrika.

Kaip koreliacijos koeficiento privalumą reiktų paminėti jo jautrumą kintamųjų reikšmių *profilio* formai (profilis – tai objekto kintamųjų reikšmių laužtės grafikas). Aptarto pavyzdžio X ir Y vektorių profiliai pavaizduoti 8.2 paveiksle.

8.2 lentelė. Muzikos stilių vertinimas

	Klasika	Džiazas	Repas	Populiarioji	Rokas
I respondentas (X)	4	5	1	3	3
II respondentas (Y)	1	3	4	2	4
$Y1$	2	4	5	3	5



Koreliacijos koeficientą geriausia naudoti, kai objektų požymiai matuojami pagal santykių arba intervalų skalę.

8.2.3. Asociatyvumo koeficientai

Anksčiau aprašyti panašumo matai taikomi tik kiekybiniais duomenimis. Šiame skyrelyje aprašomi objektų panašumo matai, kai matuojami požymiai yra kokybiniai. Tokie panašumo koeficientai vadinami *asociatyvumo* koeficientais.

Iš pradžių tarkime, kad matuojami požymiai yra dvireikšmiai: 1 (taip – sėkmė), 0 (ne – nesėkmė). Tada matuojant dviejų objektų X ir Y m požymių gautą duomenų aibę galima užrašyti 8.3 dažnių lentele.

8.3 lentelė

$X \setminus Y$	1	0	Σ
1	a	b	$a + b$
0	c	d	$c + d$
Σ	$a + c$	$b + d$	$m = a + b + c + d$

Aišku, kad objektai yra tuo panašesni, kuo daugiau sutampančių koordinačių turi vektoriai X ir Y (t. y. kuo daugiau yra porų $(1, 1)$ arba $(0, 0)$). Tuo ir grindžiami panašumo matai dvireikšmių duomenų atveju. Beje, poros $(1, 1)$ ir $(0, 0)$ yra nelygiavertės. Tarkime, matuojamas požymis – lotynų kalbos mokėjimas (1 – moka, 0 – nemoka). Kalbos nemokėjimas vargu ar gali būti panašumo indikatoriumi, visai kas kita, jei du respondentai moka lotynų kalbą. Keletas dažniausiai naudojamų panašumo matų pateikiama 8.4 lentelėje.

Visi dvireikšmių vektorių panašumo matai (išskyrus Julo ir formos koeficientus) įgyja tik neneigiamas reikšmes. Kuo didesnė koeficiento reikšmė, tuo panašesni objektai (skirtingai nuo atstumo matų!). Dažniausiai koeficientai skiriasi pagal tai, ar atsižvelgiama į porų $(0, 0)$ skaičių.

Bendruoju atveju, kai matuojami kokybiniai požymiai (t. y. naudojama pavadinimų ar rangų matavimų skalė), dažniausiai taikomas asociatyvumo koeficientas

$$d(X, Y) = \#(x_i \neq y_i) / m; \quad (2)$$

čia $\#(x_i \neq y_i)$ – nesutampančių požymių reikšmių skaičius.

8.4 lentelė. Dvireikšmių vektorių panašumo matai

Atstumas	$d(X, Y)$ formulė
Euklido	$\ X - Y\ = \sqrt{b + c}$
Euklido atstumo kvadratas	$\ X - Y\ ^2 = b + c$
Paprasčiausias suderinamumo	$(a + d)/m$
Kauliuko	$2a/(2a + b + c)$
Žakardo	$a/(a + b + c)$
Struktūrų skirtumo	bc/m^2
Didumų skirtumo	$(b - c)^2/m^2$
Formos koeficientas	$(m(b + c) - (b - c)^2)/m^2$
Lenso ir Viljamso	$(b + c)/(2a + b + c)$
Sklandos	$(b + c)/(4m)$
Julo koeficientas	$(ad - bc)/(ad + bc)$

Aprašėme panašumo matus, kai matuojami lyginamųjų objektų kiekybiniai arba kokybiniai požymiai. Tačiau labai dažnai dalis matuojamųjų požymių yra kiekybiniai, o dalis kokybiniai. Ką daryti tokiu atveju? Panagrinėkime tokį pavyzdį. Turime trijų moksleivių duomenis:

Moksleivis	Ūgis (cm)	Akių spalva	Plaukai
A	175	Ruda (kodas 1)	Šviesūs (kodas 1)
B	185	Mėlyna (kodas 2)	Tamsūs (kodas 2)
C	180	Žalia (kodas 3)	Šviesūs (kodas 1)

Vienas požymis yra santykių skalės kintamasis, kiti – kategoriniai kintamieji. Standartizuokime pirmo kintamojo reikšmes, t. y. pakeiskime jas z -reikšmėmis. Ūgio vidurkis $\bar{u} = 180$, o standartinis nuokrypis $s = 5$, todėl $z_1 = (x_1 - \bar{u})/s = (175 - 180)/5 = -1$, $z_2 = 1$, $z_3 = 0$. Standartizuotų duomenų matrica atrodo taip:

Moksleivis	Ūgis	Akių spalva	Plaukai
A	-1	Ruda (kodas 1)	Šviesūs (kodas 1)
B	1	Mėlyna (kodas 2)	Tamsūs (kodas 2)
C	0	Žalia (kodas 3)	Šviesūs (kodas 1)

Apskaičiuojame Euklido atstumo kvadratus $\|A - B\|^2 = 6$, $\|A - C\|^2 = 5$, $\|B - C\|^2 = 3$. Gavome, kad panašiausi yra B ir C moksleiviai, nors turėtų būti A ir C (bent jau plaukų spalva vienoda). Taigi naudojant atstumų matus, kai dalis kintamųjų yra kategoriniai, galima gauti neteisingus rezultatus (kategorinių kintamųjų kodavimas


daro įtaką rezultatams!). Vienas iš būdų, kaip tokiu atveju įvertinti objektų panašumą, – duomenis transformuoti į kategorinius. Aišku, tuo atveju prarandama informacijos, tačiau išvengiama anksčiau aprašytų problemų. Mūsų aptariamo pavyzdžio paskutinės lentelės duomenis galima interpretuoti kaip kategorinius (pirmojo kintamojo 1 – aukštas, 0 – vidutinis, –1 – žemas) ir panašumui įvertinti taikyti (2) formulę:

$$d(A, B) = d(B, C) = 1, \quad d(B, C) = 2/3.$$

Taigi iš tikrųjų B ir C moksleiviai panašiausi.

8.3. Klasterinės analizės metodų klasifikacija

Klasterių sudarymo metodų yra daug. Jie skiriami pagal tai, kaip parenkami panašumo matai, atstumo tarp klasterių nustatymo kriterijai bei kokia skirstymo į klasterius strategija. Pagrindines klasterinės analizės metodų klases galima pavaizduoti schema, parodyta 8.3 paveiksle.



Skiriamos dvi pagrindinės klasterinės analizės metodų klasės – hierarchiniai ir nehierarchiniai metodai. Hierarchinių metodų rezultatai nusako klasterių tarpusavio hierarchiją, t. y. visi objektai laikomi vienu dideliu klasteriu, kurį sudaro mažesni klasteriai, šiuos savo ruožtu dar mažesni ir t. t. Taikydami hierarchinius metodus, nustatome bendrą visų klasterių tarpusavio priklausomybių struktūrą ir tik po to sprendžiame, koks klasterių skaičius optimalus. Hierarchiniai metodai skirstomi į jungimo ir skaidymo metodus. Jungimo metodai smulkius klasterius jungia vis į stambesnius, kol galų gale lieka vienas. Skaidymo metodai yra loginė jungimo metodų priešingybė. Vienintelis klasteris nuosekliai skaidomas į dalis.

Nehierarchiniai metodai paprastai taikomi tada, kai iš anksto žinomas (pasirenkamas) klasterių skaičius ir norima tirti objektus klasterizuoti.

Šiame skyriuje aprašysime vieną hierarchinių metodų klasę – jungimo metodus bei vieną dažniausiai naudojamų nehierarchinių metodų – k -vidurkių metodą. Manome, kad jų pakaks pagrindiniams klasterinės analizės metodų sudarymo bei naudojimosi principams suprasti.



Ne vienus metus yra skaičiuojamas tarptautinis žmonių kentėjimo indeksas, atsižvelgiantis į žmonių išsilavinimą, vartojamą maistą, geriamo vandens kokybę ir pan. 1992 metais pagal šį indeksą suskirsčius valstybes į grupes (klasterius), paaiškėjo, kad didžiausias šis indeksas Sudane, Haityje, Afganistane, Somalyje ir Mozambike, mažiausias – Danijoje, Olandijoje, Belgijoje, Šveicarijoje ir Kanadoje.

8.4. Jungimo metodai




Bukerio dėsnis: Net nedidelė praktika atstoja didelę teoriją.

Hierarchinių jungimo metodų strategiją (bendrąją klasterizavimo schemą) galima apibrėžti taip:

- 1** Turime N klasterių po 1 objektą ir $N \times N$ simetrinę atstumų matricą $(d_{ij})_{i,j}$.
- 2** Pagal atstumų matricą nustatome du klasterius, tarp kurių atstumas yra mažiausias (kurie yra panašiausi). Tarkime, kad tai klasteriai U ir V .
- 3** Sujungiamo klasterius U ir V . Naują klasterį pavadiname (UV) . Tada atstumų matricą pakeičiame taip:
 - a) išbraukiame stulpelius ir eilutes, atitinkančius klasterius U ir V ,
 - b) pridedame eilutę ir stulpelį su atstumais tarp (UV) ir likusiųjų klasterių.
- 4** Kartojame 2 ir 3 žingsnius $(N - 1)$ kartų. Procesą baigiame, kai visi objektai yra viename klasteryje.

Šio proceso schema vaizduojama grafiku, vadinamu *dendrograma*. Tyrėjas pats sprendžia (dažniausiai žiūrėdamas į dendrogramą bei klasterizavimo eigos schemą), kuriuo etapu objektų paskirstymas į klasterius yra optimalus¹.



¹ Kartais optimalus klasterių skaičius randamas matematiškai – parenkamas vadinamasis *skaidymo kokybės funkcionalas* ir žiūrima, kuriuo hierarchinės klasterizacijos etapu jis minimalus. Skaidymo kokybės funkcionalo pavyzdys gali būti objektų atstumų iki klasterių centrų sumos.

Vienoje dendrogramos ašyje (žr. 8.4 pav.) atidedami objektų numeriai, kitoje – atstumai. Objektus jungianti laužtė (jos aukštis!) parodo, kada objektai sujungti į klasterius ir koks atstumas tarp jų.


Viena iš klasterizavimo metodų sudedamųjų dalių – panašių klasterių jungimas. Kaip nustatomi panašūs klasteriai? Kas yra atstumas tarp klasterių?

8.4.1. Klasterių panašumo matai ir jungimo metodai

Tarkime, turime du klasterius U ir V . Atstumas $d(X_i, Y_j)$ tarp $X_i \in U$ ir $Y_j \in V$ matuojamas vienu iš 8.1 ir 8.4 lentelėse apibrėžtų matų. Dažniausiai naudojami atstumai $d(U, V)$ tarp dviejų klasterių U ir V pateikti 8.5 lentelėje.

8.5 lentelė. Klasterių panašumo matai

Atstumas	$d(U, V)$ formulė
Vienetinės jungties (artimiausio kaimyno)	$d(U, V) = \min_{X_i \in U, Y_j \in V} d(X_i, Y_j),$ X_i – i -asis U objektas, Y_j – j -asis V objektas
Pilnosios jungties (tolimiausio kaimyno)	$d(U, V) = \max_{X_i \in U, Y_j \in V} d(X_i, Y_j),$
Vidutinės jungties	$d(U, V) = \sum_{X_i \in U} \sum_{Y_j \in V} d(X_i, Y_j) / (n_U n_V),$ n_U, n_V – klasterių objektų skaičius
Centrų	$d(U, V) = d(\bar{U}, \bar{V}),$ $\bar{U}, \bar{V}$ – klasterius sudarančių objektų požymių vektorių vidurkiai
Vordo	$d(U, V) = \ \bar{U} - \bar{V}\ ^2 / (1/n_U + 1/n_V)$



Kaip gali būti skaičiuojami atstumai tarp klasterių, parodyta 8.5 paveiksle.

Jungimo metodas, kai atstumas tarp klasterių yra vienetinės jungties, vadinamas vienetinės jungties metodu ir pan.

Rašėme, kad kiekvienu klasterizavimo etapu jungiami panašiausi klasteriai, t. y. tarp kurių atstumas yra mažiausias. Kurį metodą reikia pasirinkti sprendžiant konkretų uždavinį? Kas slypi už atstumų tarp klasterių skaičiavimo formulių įvairovės?

Panagrinėkime tokį pavyzdį.

8.1 pavyzdys. Žinome 5 automobilių galingumą (arklio jėgomis) ir kiek jie sunaudoja benzino 100 km. Duomenys pateikti 8.6 lentelėje. Šiuos automobilius norima suskirstyti į klasterius. Automobilių skirtumams įvertinti taikome Euklido atstumo kvadratą.

8.6 lentelė. Automobiliai

	Automobilis	Galingumas	Degalai
1	Vreno	95	8
2	Saudi	92	8
3	Ituzu	95	10
4	Delicija	94	6
5	Mopel	93	5

Išspręskime šį uždavinį vienetinės jungties metodu. Apskaičiuojame atstumų matricą: $d(Vreno, Saudi) = (95 - 92)^2 + (8 - 8)^2 = 9$ ir t. t.

	1	2	3	4	5
1	0	9	4	5	13
2	9	0	13	8	10
3	4	13	0	17	29
4	5	8	17	0	2
5	13	10	29	2	0

Randame mažiausiai besiskiriančius automobilius $\min(d_{ik}) = d_{45} = 2$. Objektai 4 ir 5 jungiami į klasterį (45). Norėdami procesą tęsti, turime apskaičiuoti atstumus tarp (45) ir likusių klasterių 1, 3, 4: $d_{(45)1} = \min(d_{41}, d_{51}) = \min(5, 13) = 5$; $d_{(45)2} = \min(d_{42}, d_{52}) = \min(8, 10) = 8$; $d_{(45)3} = \min(d_{43}, d_{53}) = \min(17, 29) = 17$.

Pastaba. Atstumai tarp klasterių apibrėžiami arba tiesiogiai, arba naudojantis kombinatorine formule. Tai formulė, naudojama atstumų matricai perskaičiuoti po kiekvieno klasterizavimo procedūros žingsnio (sujungus klasterius). Tiesioginės formulės pateiktos 8.5 lentelėje. Pavyzdžiuose naudojama kombinatorinė formulė, nes pagal ją patogiau skaičiuoti. Mūsų atveju 3-iu bendrojo algoritmo žingsniu atstumas tarp klasterio (UV) ir bet kokio kito klasterio W skaičiuojamas pagal tokią vienetinio atstumo kombinatorinę formulę: $d_{(UV)W} = \min(d_{UW}, d_{VW})$. Be abejo, atstumo reikšmė, gauta naudojantis tiesiogine ar kombinatorine formule, yra ta pati.

Taigi nauja atstumų matrica yra

	1	2	3	(45)
1	0	9	4	5
2	9	0	13	8
3	4	13	0	17
(45)	5	8	17	0

Mažiausias atstumas yra $d_{13} = 4$. Todėl toliau jungiame 1-ąjį klasterį su 3-uoju. Tada $d_{(13)2} = \min(d_{12}, d_{32}) = \min(9, 13) = 9$; $d_{(13)(45)} = \min(d_{1(45)}, d_{3(45)}) = \min(5, 17) = 5$.

Atstumų matrica tampa tokia:

	(13)	2	(45)
(13)	0	9	5
2	9	0	8
(45)	5	8	0

Mažiausias atstumas $d_{(13)(45)} = 5$, todėl jungiame klasterius (13) ir (45). Naująjį klasterį pažymime (1345). Liko du klasteriai (1345) ir 2. Atstumas tarp jų $d_{(1345)2} = \min(d_{(13)2}, d_{(45)2}) = \min(9, 8) = 8$.

Galutinė atstumų matrica atrodo taip:

	(1345)	2
(1345)	0	8
2	8	0

Galų gale sujungiame klasterius (1345) ir (2).

8.2 pavyzdys. Išspėskime 8.1 pavyzdžio uždavinį Vordo¹ metodu. Visų pirma sudarome objektų atstumų matricą. Kodėl negalime pasinaudoti 8.1 pavyzdžio atstumų matrica? Vienetinės jungties metodo pradinė objektų atstumų matrica nepriklauso nuo to, ar pavienius objektus interpretuojame kaip klasterius, ar ne. Vordo metodo atveju yra kitaip. Atstumas tarp objektų *Vreno* ir *Saudi* yra $d(Vreno, Saudi) = (95 - 92)^2 + (8 - 8)^2 = 9$. Tarkime, kad yra du klasteriai – (*Vreno*) ir (*Saudi*), turintys po vieną objektą. Tada atstumas tarp šių klasterių yra $d((Vreno), (Saudi)) = ((95 - 92)^2 + (8 - 8)^2)/2 = 4,5$. Taigi Vordo atstumų matrica tarp objektų klasterių atrodo taip:

	(1)	(2)	(3)	(4)	(5)
(1)	0	4,5	2	2,5	6,5
(2)	4,5	0	6,5	4	5
(3)	2	6,5	0	8,5	14,5
(4)	2,5	4	8,5	0	1
(5)	6,5	5	14,5	1	0

Randame mažiausiai besiskiriančius klasterius $\min(d_{ik}) = d_{45} = 1$. Objektai (4) ir (5) jungiami į klasterį (45). Norėdami procesą tęsti, turime apskaičiuoti atstumus tarp (45) ir likusių klasterių 1, 3, 4. Klasterio (45) centras $\overline{(45)}$ nustatomas suvidurkinus visų klasterių sudarančių objektų koordinatas: $\overline{(45)} = ((94 + 93)/2; (6 + 5)/2) = (93,5; 5,5)$. Todėl $d_{(45)(1)} = \|\overline{(45)} - \overline{(1)}\|^2/(1 + 1/2) = ((93,5 - 95)^2 + (5,5 - 8)^2) \cdot 2/3 = 5,67$; $d_{(45)(2)} = \|\overline{(45)} - \overline{(2)}\|^2/(1/2 + 1) = 5,67$; $d_{(45)(3)} = 14,33$.

Taigi nauja atstumų matrica yra

	(1)	(2)	(3)	(45)
(1)	0	4,5	2	5,67
(2)	4,5	0	6,5	5,67
(3)	2	6,5	0	14,33
(45)	5,67	5,67	14,33	0

Mažiausias atstumas $d_{(1)(3)} = 2$. Toliau jungiame 1-ąjį klasterį su 3-uoju. Tada $d_{(13)(2)} = \|\overline{(13)} - \overline{(2)}\|^2/(1 + 1/2) = 6,67$; $d_{(13)(45)} = \|\overline{(13)} - \overline{(45)}\|^2/(1/2 + 1/2) = 14,5$.

¹ J. H. Ward – amerikiečių statistikas.

Atstumų matrica tampa tokia:


	(13)	(2)	(45)
(13)	0	6,67	14,5
(2)	6,67	0	5,67
(45)	14,5	5,67	0

Mažiausias atstumas $d_{(2)(45)} = 5,67$, todėl sujungiame klasterius (2) ir (45). Naująjį klasterį pažymime (245). Liko du klasteriai (13) ir (245). Atstumas tarp jų $d_{(13)(245)} = \|\overline{(13)} - \overline{(245)}\|^2 / (1/2 + 1/3) = 13,35$. Galutinė atstumų matrica atrodo taip:

	(13)	(245)
(13)	0	13,35
(245)	13,35	0

Galų gale sujungiame klasterius (13) ir (245).

Panagrinėkime abiejų pavyzdžių klasterizavimo dendrogramas (žr. 8.6 pav.). Jos skiriasi, nes nevienoda klasterių jungimo strategija (tai matyti iš klasterių atstumų formulų). Vienetinės jungties metodu jungiami klasteriai, turintys artimiausius kaimynus. Taikant Vordo metodą, imama klasterių pora ir apskaičiuojama požymių vektorių nuokrypių nuo jungtinio klasterio centro kvadratų suma. Tas pats daroma su kita klasterių pora ir t. t. Jungiami tie klasteriai, kuriuos sujungus nuokrypių suma mažiausia. Beje,



pritaikius 8.1 pavyzdžiui vidutinės jungties metodą, gaunama ta pati dendrograma kaip ir Vordo metodu. Vidutinės jungties atstumas skaičiuojamas naudojantis *visa* informacija apie klasterius – tuo jis pranašesnis už vienietinės ir pilnosios jungties atstumus. Pritaikę objektų klasterizavimui keletą metodų, galime tikėtis patikimesnių rezultatų.

Kuris metodas yra geriausias? Kokie yra metodų trūkumai? Deja, vienareikšmiško atsakymo į šiuos klausimus nėra. Klasterius apibūdina keliolika charakteristikų: požymių vektorių sklaida nuo klasterio centro, forma ir pan. Neturint išankstinės informacijos apie nagrinėjamų duomenų struktūras, gautus rezultatus lyginti sunku. Todėl pranašumai ir trūkumai – santykinis dalykas. Viena aišku, objektų klasterizavimui *rekomenduojama* taikyti keletą klasterizavimo metodų.



Tikslumo taisyklė: Sprendžiant uždavinius, visados pravartu žinoti atsakymą.

Paminėsime kai kurias taikomų metodų savybes. Centrų metodu klasterizavimo eigoje atstumai tarp klasterių dažnai mažėja, nors iš tiesų jungiami vis mažiau ir mažiau panašūs klasteriai (vargu ar tai pranašumas). Pastebėta, kad taikant Vordo metodą gaunama daug mažų klasterių. Vordo metodo rezultatams labai didelę įtaką daro objektai su požymių išskirtimis. Apie išskirčių įtaką klasterizavimo rezultatams verta tarti keletą žodžių. Sakykime, norime klasterizuoti šalis pagal jų gyventojų skaičių ir plotą. Tiek Kinija (gyventojų skaičiumi), tiek Rusija (plotu) aiškiai išsiskiria iš kitų šalių (neminint šalių nykštukų). Klasterizuodami šalis be dviejų minėtų ir su jomis, gauname visiškai skirtingas klasterizavimo eigos schemas. Todėl prieš atliekant klasterizavimą pageidautina pašalinti išskirtis (kaip jas nustatyti, rašėme [1] knygos I dalyje).

8.4.2. Hierarchinių metodų taikymas naudojantis SPSS paketu

Socialiniai bei ekonominiai 10-ties apskričių 1999 metų rodikliai pateikti 8.7 lentelėje¹. Kokius apskričių klasterius galima sudaryti pagal šiuos rodiklius?

Čia a_1 – gyventojų aprūpinimas gyvenamuoju plotu (kiek vienam gyventojui vidutiškai tenka naudingo ploto (m^2)); a_2 – bendrasis vidaus produktas (BVP) vienam gyventojui (tūkst. Lt); a_3 – materialinės investicijos (tūkst. Lt); a_4 – nusikaltamumas (kiek

8.7 lentelė. Apskritys

Apskritis	a_1	a_2	a_3	a_4	a_5	a_6	a_7
Alytaus	22,5	9,3	260433	122	24,5	171585	–1,3
Kauno	22,9	11,1	1052822	209	27,3	792675	–0,6
Klaipėdos	19,6	12,5	690000	247	28,7	850725	–0,2
Marijampolės	19,8	7,7	146914	164	24,1	20806	–0,6
Panevėžio	22,9	9,8	396002	210	23,9	334743	–1,8
Šiaulių	21,1	8,8	296607	189	24,3	147408	–1,1
Tauragės	21,6	7,0	35921	156	22,4	17674	–1,3
Telšių	21,1	10,0	503425	171	24,4	115108	–0,8
Utenos	24,5	10,3	268631	140	23,5	91212	–3,9
Vilniaus	20,6	15,8	2502666	236	26,9	3959258	–1,0

¹ Statistikos departamento prie Lietuvos Respublikos Vyriausybės duomenys.

PROXIMITY MATRIX

Case	Squared Euclidean Distance									
	1:Alytaus	2:Kauno	3:Klaipėdo	4:Marjamp	5:Panevėži	6:Šiaulių	7:Tauragės	8:Telšių	9:Utenos	10:Vilniaus
1:Alytaus		7,445	19,855	4,906	4,975	3,575	3,009	5,312	6,861	17,490
2:Kauno	7,445		6,385	9,747	4,236	4,945	11,597	5,921	15,105	6,311
3:Klaipėdo	19,855	6,385		13,351	14,267	10,681	22,503	10,842	33,964	3,488
4:Marjamp	4,906	9,747	13,351		6,998	1,456	2,564	2,925	18,184	15,868
5: Panevėži	4,975	4,236	14,267	6,998		2,161	4,440	6,905	7,052	11,094
6:Šiaulių	3,575	4,945	10,681	1,456	2,161		2,228	2,859	12,123	10,926
7:Tauragės	3,009	11,597	22,503	2,564	4,440	2,228		5,675	10,301	21,784
8:Telšių	5,312	5,921	10,842	2,925	6,905	2,859	5,675		20,583	11,744
9:Utenos	6,861	15,105	33,964	18,184	7,052	12,123	10,301	20,583		25,361
10:Vilniaus	17,490	6,311	3,488	15,868	11,094	10,926	21,784	11,744	25,361	

This is a dissimilarity matrix.


AGGLOMERATION SCHEDULE

Stage	Cluster Combined		Coefficients	Stage Cluster First Appears		Next Stage
	Cluster 1	Cluster 2		Cluster 1	Cluster 2	
1	4	6	1,456	0	0	2
2	4	7	2,396	1	0	4
3	3	10	3,448	0	0	9
4	4	8	3,819	2	0	5
5	1	4	4,200	0	4	7
6	2	5	4,236	0	0	7
7	1	2	6,513	5	6	8
8	1	9	12,887	7	0	9
9	1	3	15,777	8	3	0

VERTICAL ICICLE

Number of clusters	Case																		
	10:Vilniaus		3:Klaipėdo		9:Utenos		5:Panevėži		2:Kauno		8:Telšių		7:Tauragės		6:Šiaulių		4:Marjamp		1:Alytaus
1	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X
2	X	X	X		X	X	X	X	X	X	X	X	X	X	X	X	X	X	X
3	X	X	X		X	X	X	X	X	X	X	X	X	X	X	X	X	X	X
4	X	X	X		X		X	X	X	X	X	X	X	X	X	X	X	X	X
5	X	X	X		X		X		X	X	X	X	X	X	X	X	X	X	X
6	X	X	X		X		X		X	X	X	X	X	X	X	X	X	X	X
7	X	X	X		X		X		X	X	X	X	X	X	X	X	X	X	X
8	X		X		X		X		X	X	X	X	X	X	X	X	X	X	X
9	X		X		X		X		X		X		X	X	X	X	X		X

Dendrogram using Average Linkage (Between Groups)



8.7 pav. SPSS rezultatai taikant hierarchinius metodus

užregistruota nusikaltimų, tenkančių 10 000 gyventojų); a_5 – gyventojų aprūpinimas telefonais butuose (100 gyventojų); a_6 – tiesioginės užsienio investicijos (tūkst. Lt, sausio 1 d. duomenys); a_7 – natūralus gyventojų prieaugis (1000 gyventojų).

Klasterizuosime pagal požymius a_1 , a_2 , a_4 , a_5 ir a_6 . Standartizavę kintamuosius, t. y. stebėjimus pakeitę z -reikšmėmis, taikysime vidutinės jungties metodą.

Apskričių klasterizavimo problemos sprendimas SPSS paketu pateiktas 8.7 paveiksle.

Lentelėje *Proximity Matrix* yra Euklido atstumų kvadratų matrica. Klasterizavimo eigos schema nurodyta lentelėje *Agglomeration Schedule*. Kaip interpretuojami lentelės duomenys? Stulpelyje *Stage* nurodoma klasterizavimo žingsniai (10 apskričių – 9 žingsniai!). Stulpeliuose *Cluster Combined* nurodoma, kokie klasteriai kuriuo žingsniu buvo jungiami, o stulpelyje *Coefficients* pateikiama atstumo tarp jungiamų klasterių reikšmė. Pavyzdžiui, 4-u žingsniu buvo jungiami 4 ir 8 klasteriai, tarp kurių atstumas lygus 3,819. Kas sudaro 4 ir 8 klasterius? Tai išsiaiškinti galima pažiūrėjus į antrąją lentelės dalį (stulpelius *Stage Cluster First Appears* ir *Next Stage*). Ketvirtoje šių stulpelių eilutėje yra skaičiai 2, 0 ir 5. Vadinasi: a) 4 klasteris jau buvo jungiamas 2-u žingsniu (su klasteriu 7); panašiai nustatome, kad jis buvo jungiamas su 6 klasteriu 1-u žingsniu (žr. 1 eilutę); b) 8 klasteris anksčiau nebuvo jungiamas; c) sujungtas klasteris bus vėl jungiamas 5-u žingsniu. Išvada – po 4-o žingsnio į vieną klasterį pateko 4, 8, 7, 6 apskritys (tiksliau (4, 6, 7) apskričių klasteris buvo sujungtas su 8 apskritimi); 5-u žingsniu šios apskritys vėl klasterizuojamos. Taigi klasterių eigos schema yra savotiškas dendrogramos pakaitalas. Lentelę *Vertical Icicle* galima interpretuoti kaip dendrogramos negatyvą, t. y. schemą, pagal kurią buvo jungiami klasteriai (nenurodant atstumų). Beje, lentelė išties panaši į varveklis¹. Dendrogramos reikšmę aptarėme anksčiau. Tik pažymėsime, kad atstumų ašis projektuojama į intervalą (0, 25). Dėl skalės grubumo dendrogramoje sunku atskirti panašaus didumo atstumus tarp klasterių – nesimato, kurie klasteriai sujungti anksčiau.

8.5. k -vidurkių metodas



Lengva meluoti remiantis statistika, bet dar lengviau nesiremiant.

F. Mosteleris

Vienas iš hierarchinių klasterinės analizės metodų trūkumų – skaičiavimams naudojama atstumų matrica. Pavyzdžiui, jei yra 300 objektų, kuriuos norima suskirstyti į klasterius, atstumų matricai apskaičiuoti bei jos elementams išsaugoti reikia daug resursų. Tad dideliems (> 300) objektų masyvams klasterizuoti dažnai naudojami nehierarchiniai klasterizavimo metodai. Čia aprašysime vieną iš jų – k -vidurkių metodą.

Pateiksime paprasčiausią šio metodo variantą. Klasterizavimo procedūrą sudaro trys žingsniai:

- 1** Objektai suskirstomi į k pradinių klasterių.

¹ Angl. *icicle* – varveklis.

2 Paeiliui apskaičiuojamas kiekvieno objekto atstumas iki klasterių centrų (atstumas paprastai skaičiuojamas naudojantis Euklido metrika arba jos kvadratu). Objektas skiriamas į artimiausią klasterį. Klasterių centrai perskaičiuojami.

3 2 žingsnis kartojamas tol, kol perskirstymų daugiau nėra.

8.3 pavyzdys. Tarkime, 4 atsitiktinai parinkti piliečiai buvo paprašyti įvertinti savo materialinę padėtį ir šalies ekonominę situaciją skalėje nuo -5 (labai bloga) iki $+5$ (labai gera). Duomenys pateikti 8.8 lentelėje.

8.8 lentelė

Respondentas	Materialinė padėtis (X)	Šalies situacija (Y)
A	5	3
B	-1	1
C	0	-3
D	-2	-1

Mūsų tikslas suskirstyti šiuos respondentus į $k = 2$ klasterius (optimistus ir pesimistus) taip, kad vieno klasterio respondentai būtų vienas kitam artimesni nei skirtingų klasterių.

Iš pradžių laisvai suskirstome respondentus į du klasterius (tarkime, (AB) ir (CD)) ir apskaičiuojame šių klasterių centrus. Po pradinio etapo gauname 8.9 lentelę.

8.9 lentelė

Klasteris	Centras X	Centras Y
(AB)	$(5 + (-1))/2 = 2$	$(3 + 1)/2 = 2$
(CD)	$(0 + (-2))/2 = -1$	$((-3) + (-1))/2 = -2$

8.10 lentelė

Klasteris	Centras X	Centras Y
(A)	5	3
(BCD)	-1	-1

1. *Pirmoji iteracija (žingsnis).* Apskaičiuojame respondentų atsakymų vektorių atstumus nuo klasterių centrų ir priskiriame respondentus artimiausiam klasteriui. Po to klasterių centrai perskaičiuojami (tarkime, kad panašumo matas – Euklido atstumo kvadratas). $\|A - \overline{(AB)}\|^2 = (5 - 2)^2 + (3 - 2)^2 = 10$; $\|A - \overline{(CD)}\|^2 = (5 + 1)^2 + (3 + 2)^2 = 61$; $\|B - \overline{(AB)}\|^2 = 10$; $\|B - \overline{(CD)}\|^2 = 9$; $\|C - \overline{(AB)}\|^2 = 41$; $\|C - \overline{(CD)}\|^2 = 2$; $\|D - \overline{(AB)}\|^2 = 25$; $\|D - \overline{(CD)}\|^2 = 2$.

B respondentas yra artimesnis klasteriui (CD) nei (AB) , todėl jį priskiriame klasteriui (CD) . Kartu turime naujus klasterius (A) ir (BCD) . Jų centrai nurodyti 8.10 lentelėje.

2. *Antroji iteracija.* Skaičiuojame respondentų atsakymų vektorių atstumus nuo klasterių centrų:

$\|A - \overline{(A)}\|^2 = 0$; $\|A - \overline{(BCD)}\|^2 = (5 + 1)^2 + (3 + 1)^2 = 52$; $\|B - \overline{(A)}\|^2 = 40$; $\|B - \overline{(BCD)}\|^2 = 8$; $\|C - \overline{(A)}\|^2 = 61$; $\|C - \overline{(BCD)}\|^2 = 5$; $\|D - \overline{(A)}\|^2 = 65$; $\|D - \overline{(BCD)}\|^2 = 1$.

Visi respondentai vietose – kiekvieno atsakymų vektoriaus atstumas iki „savo“ klasterio centro yra mažiausias.

Taigi nustatėme vieną optimistą (respondentas A) ir 3 pesimistus (respondentai B , C ir D).

k-vidurkių metodo taikymas naudojantis SPSS paketu. Apskritys (duomenys 8.7 lentelėje) skirstomos į 3 klasterius. Šios problemos sprendimo SPSS paketu taikant k -vidurkių metodą rezultatai pateikti 8.8 paveiksle. Lentelėje *Initial Cluster Centers* yra pasirinktieji pradiniai klasterių centrai¹. Lentelėje *Iteration History* parodyta, kaip keičiasi klasterių centrai po kiekvieno klasterinės procedūros žingsnio (iteracijos). Lentelėje *Cluster Mem-*

¹ Klasterių centrais pasirenkami arba automatiškai parenkami labiausiai besiskiriančių objektų (apskričių) požymių vektoriai.

INITIAL CLUSTER CENTERS				ITERATION HISTORY ^a			
	Cluster			Iteration	Change in Cluster Centers		
	1	2	3		1	2	3
Butai mieste	22,50	21,10	19,60	1	9,176	5,868	5,847
BVP	9,30	8,80	12,50	2	8,437	5,465	,000
Nusik.	122,00	189,00	247,00	3	,000	,000	,000
Tel.	24,50	24,30	28,70				
Nat. pr.	-1,30	-1,10	-,20				

^a. convergence achieved due to no or small distance change. The maximum distance by which any center has changed is ,000. The current iteration is 3. The minimum distance between initial centers is 58,310.

INITIAL CLUSTER CENTERS				FINAL CLUSTER CENTERS			
Case Number	APSKRITI	Cluster	Distance		Cluster		
					1	2	3
1	Alytaus	1	17,395	Butai mieste	22,87	21,56	20,10
2	Kauno	2	20,660	BVP	8,87	9,48	14,15
3	Klaipėdo	3	5,847	Nusik.	139,33	188,60	241,50
4	Marijamp	2	24,737	Tel.	23,47	24,80	27,80
5	Panevėži	2	21,493	Nat. pr.	-2,17	-,66	-,60
6	Šiaulių	2	1,130				
7	Tauragės	1	16,875				
8	Telšių	2	17,679				
9	Utenos	1	2,859				
10	Vilniaus	3	5,847				

DISTANCES BETWEEN FINAL CLUSTER CENTERS				NUMBER OF CASES IN EACH CLUSTER	
Cluster	1	2	3	Cluster	
1		49,329	102,444	1	3,000
2	49,329		53,210	2	5,000
3	102,444	53,210		3	2,000

Valid	10,000
Missing	,000

8.8 pav. SPSS rezultatai taikant *k*-vidurkių metodą

bership pateikta, į kokius klasterius baigus klasterizavimą pateko apskritys, ir nurodyti jų atstumai nuo atitinkamų klasterių centrų. Taigi į 1-ą klasterį pateko Alytaus, Tauragės ir Utenos, į 2-ą – Kauno, Marijampolės, Panevėžio ir Šiaulių, Telšių, į 3-ą Klaipėdos ir Vilniaus apskritys. Lentelėje *Final Cluster Centers* yra klasterizavimo pabaigoje gautų klasterių centrai. Matome, kad pirmąjį klasterį sudaro apskritys, kur nusikalstamumas mažas, aprūpinimas gyvenamuoju plotu geras bei santykiškai menki kiti rodikliai, o į trečiąjį klasterį patenkančiose Vilniaus ir Klaipėdos apskrityse yra didelis nusikalstamumas, blogas aprūpinimas gyvenamuoju plotu, tačiau geri likusieji rodikliai. Lentelėje *Distances Between Final Cluster Centers* pateikiamas atstumas tarp gautų klasterių centrų. Lentelėje *Number of Cases in Each Cluster* išspausdintas kiekvieną klasterį sudarančių apskričių skaičius.

Vienas iš *k*-vidurkių metodų trūkumų – klasterių skaičių reikia nustatyti iš anksto. Yra keletas argumentų, prieštaraujančių išankstiniam klasterių skaičiaus nustatymui:

- 1) Pasirinktieji klasterių centrai yra iš vieno klasterio ir gauti klasteriai mažai skiriasi.

- 2) Net jei iš tiesų žinoma, kad objektų populiacijoje yra k klasterių, tiriamoje objektų imtyje gali nepasitaikyti atstovų iš k -ojo klasterio.
- 3) Objektas, kurio požymių reikšmių vektorius yra iš išskirčių, gali sudaryti atskirą klasterį.
- 4) Klasterinės analizės tikslas – egzistuojančių struktūrų paieška, tačiau, nurodant pradinį klasterių skaičių, struktūra yra primetama.



asociatyvumo koeficientai	klasteris	nehierarchiniai metodai
dendrograma	klasterizavimo eigos schema	panašumo matas
hierarchiniai metodai	k -vidurkių metodas	profilis
jungimo metodai	metrika	


UŽDAVINIAI

1. Vordo metodu suklasterizuokite apskritis (žr. 8.7 lentelę). Ar rezultatai skiriasi nuo gautųjų pilnosios jungties metodu?
2. Tarkime, turime 4 objektų atstumų matricą

	(1)	(2)	(3)	(4)
(1)	0	2	12	6
(2)	2	0	3	4
(3)	12	3	0	5
(4)	6	4	5	0

Klasterizuokite šiuos objektus taikydami: a) vienetinės, b) pilnosios ir c) vidutinės jungties metodus. Nubraižykite dendrogramas ir palyginkite rezultatus.

3. Paveiksle 8.9 pateikta dendrograma. Kiek klasterių sudaro objektai?



4. Standartizavę požymius, k -vidurkių metodu suskirstykite apskritis į tris klasterius. Ar rezultatai skiriasi nuo pateiktųjų tekste?

5. Turime 4 alaus bendrovių akcijų kainų koreliacijos matricą

	(1)	(2)	(3)	(4)
(1)	1	0,51	0,39	-0,24
(2)	0,51	1	0,72	0,10
(3)	0,39	0,72	1	-0,44
(4)	-0,24	0,10	-0,44	1

Suskirstykite bendroves į du klasterius.

6. Kazanova visas damas klasterizuoja pagal krūtinės ir klubų matmenis. Vienetinės jungties metodu pakartokite Kazanovos klasterizavimą.

8.11 lentelė. Damos

Dama	Krūtinė	Klubai
Rima	100	106
Irma	96	106
Mania	99	108
Ninel	98	104
Odeta	97	103
Pamela	94	111
Sigurn	100	102




9. DISKRIMINANTINĖ ANALIZĖ



Diskriminuoti – tai pastebėti detales, kurios vieną žmogų ar daiktą daro, jei tik tai įmanoma, dar atgrasesnį nei kitas.

A. Byrsas

Pradedantis gydytojas Aiskaudutis sulaukė pirmojo paciento. Kraujo tyrimai yra. Šlapimo tyrimai yra. Daug visokių tyrimų yra paciento byloje. Trūksta tik diagnozės. Širdies nepakankamumas? Neurozė? O gal?.. Taip... Na... Hm?.. Laimei, į kabinetą užsuko docentas Sveikatauskas. Žvilgtelėjo į paciento bylą ir iškart konstatavo: „Priešinfarktinė būklė!“. Išnešus apalpusį pacientą, docentas su pavydu žvelgiančiam jaunesniajam kolegai tarstelėjo: „Savo disertacijoje nemažai vietos skyriau klasifikavimo uždavinių sprendimui diskriminantinės analizės metodais“. Štai taip! Matyt, ne tik pradedantiems gydytojams bus įdomu sužinoti, ką reikia diskriminuoti moksliai.



9.1. Diskriminantinės analizės tikslai ir etapai

Diskriminantinėje analizėje pagal intervalinių kintamųjų reikšmes sprendžiama apie objekto priklausomybę vienai iš keleto grupių. Pavyzdžiui, diskriminantinės analizės gali prireikti, kai:

- remdamasis simptomais, gydytojas sprendžia, kokia liga pacientas serga;
- sociologas tiria, nuo ko priklauso rinkėjų balsavimo prioritetai;
- edukologas aiškina, ar abiturientas stos į aukštąją mokyklą, ar ne;
- archeologas pagal išlikusių kaulų matmenis nori nustatyti palaikų lytį;
- bankas, prieš suteikdamas paskolą privatiems asmenims, suskirsto juos į patikimus, sąlygiškai patikimus ir nepatikimus;
- kalbininkas bando nustatyti, Sofija Pšibiliauskienė ar Marija Lastauskienė parašė konkretų Lazdynų Pelėdos kūrinį ir pan.

Visais atvejais tenka spręsti atskiriamumo (toliau vartosime tradicinį tarptautinį terminą *diskriminavimo*¹) ir (arba) klasifikavimo uždavinius.



Diskriminuoti 1938 metais statistikams pasiūlė R. Fišeris. Nuo tada statistikai yra nuoseklūs tiriamųjų grupių diskriminuotojai.

¹ Taigi diskriminavimas statistikoje yra viso labo atskiriamumo sinonimas.

Diskriminavimo tikslas – nustatyti požymius, padedančius atskirti tiriamų objektų grupes bei įvertinti diskriminavimo kokybę. Taigi diskriminavimas susijęs su priklausomybės struktūros analize. Klasifikavimo tikslas – remiantis požymių matavimais, objektus priskirti vienai iš grupių bei įvertinti klasifikavimo patikimumą. Konkreti prognozė – klasifikavimo uždavinio dalis. Pavyzdžiui, aprašydamas abiturientų prioritetus, edukologas pirmiausia atrenka požymius, lemiančius vienokį ar kitokį abituriento pasirinkimą, ir įvertina jų svarbą – t. y. sprendžia diskriminavimo uždavinį. Jeigu edukologas prognozuos konkrečių abiturientų pasirinkimus – jis spręs klasifikavimo uždavinį.

Taigi diskriminantinė analizė siekia dviejų tikslų: pirma – įvertinti grupių diskriminavimo galimybę, antra – rasti tam tikra prasme optimalias klasifikavimo taisykles.

Diskriminantinės analizės nereikia painioti su klasterine analize – skirtingai nei klassterinėje analizėje, čia iš anksto yra žinomas grupių skaičius, be to, yra „mokymo imtis“, t. y. informacija apie dalies tiriamų objektų požymių reikšmes ir priklausomybę vienai ar kitai grupei.

Diskriminantinės analizės etapai:

- 1** Nustatoma, kurie kintamieji tinka tiriamų objektų diskriminavimui. Pašalinami kintamieji, nepadedantys nustatyti grupių skirtumų.
- 2** Ieškoma diskriminavimo prižasčių. Įvertinama diskriminavimo kokybė.
- 3** Parenkamas labiausiai tinkamas klasifikuoti būdas. Sudaromos klasifikavimo taisyklės (konstruojamos klasifikavimo funkcijos).
- 4** Įvertinamas klasifikavimo patikimumas. Sudaromos klasifikavimo lentelės. Skaičiuojami klaidingos klasifikacijos tikimybių įverčiai.

Iš pradžių aptarsime diskriminantinės analizės taikymo sąlygas.

9.2. Diskriminantinės analizės modelis

Tarkime, kad matuojame kiekvieno objekto p intervalinių (vadinamųjų *diskriminavimo*) kintamųjų $(X_1, X_2, \dots, X_p)$. Žinome, kad objektų populiaciją sudaro g grupių. Imties duomenis sudaro stebėjimai (x_{ijk}) , $i = 1, \dots, p$, $j = 1, \dots, g$, $k = 1, \dots, n_j$; čia (x_{ijk}) yra i -ojo kintamojo k -asis stebėjimas j -oje grupėje, n_j – stebėjimų skaičius j -oje grupėje, $n = n_1 + n_2 + \dots + n_g$ – imties didumas (žr. 9.1 lentelę). Pavyzdžiui, x_{121} yra kintamojo X_1 pirmasis stebėjimas antrojoje grupėje.

Diskriminantinės analizės prielaidos:

- 1) Grupių skaičius g yra baigtinis.
- 2) Grupės yra nepriklausomos ir neturi bendrų objektų, t. y. objektas vienu metu negali priklausyti kelioms grupėms.
- 3) Diskriminavimo kintamieji $X_i \sim \mathcal{N}(\mu, \sigma^2)$ ir matuojami pagal intervalų skalę.
- 4) Nė vienas diskriminavimo kintamasis negali būti kitų kintamųjų tiesinė daugara.
- 5) Diskriminavimo kintamųjų kovariacijų matricos grupėse lygios.

Pageidautina, kad grupių didumai labai nesiskirtų.

9.1 lentelė. Diskriminantinės analizės duomenys

Grupė	Diskriminavimo kintamieji			
	X_1	X_2	$\dots$	X_p
1	x_{111}	x_{211}	$\dots$	x_{p11}
	x_{112}	x_{212}	$\dots$	x_{p12}
	$\dots$	$\dots$	$\dots$	$\dots$
	x_{11n_1}	x_{21n_1}	$\dots$	x_{p1n_1}
2	x_{121}	x_{221}	$\dots$	x_{p21}
	x_{122}	x_{222}	$\dots$	x_{p22}
	$\dots$	$\dots$	$\dots$	$\dots$
	x_{12n_2}	x_{22n_2}	$\dots$	x_{p2n_2}
$\dots$	$\dots$	$\dots$	$\dots$	$\dots$
g	x_{1g1}	x_{2g1}	$\dots$	x_{pg1}
	x_{1g2}	x_{2g2}	$\dots$	x_{pg2}
	$\dots$	$\dots$	$\dots$	$\dots$
	x_{1gn_g}	x_{2gn_g}	$\dots$	x_{pgn_g}

Dauguma diskriminantinės analizės metodų gana stabilūs ir nedideli nuokrypiai nuo minėtų reikalavimų yra leistini. Pavyzdžiui, kartais diskriminantinė analizė taikoma ir ranginiams kintamiesiems, tačiau tuo atveju kategorijų skaičius turi būti ne mažesnis kaip 5.

Kai normalumo sąlyga netenkinama, geriausia alternatyva diskriminantinei analizei yra logistinė regresija.

Kovariacijų matricų lygybei tikrinti naudojamas Bokso¹ M kriterijus. Nulinė hipotezė teigia, kad grupių kovariacijų matricos nesiskiria. Bokso kriterijus patvirtina, kad duomenys diskriminantinei analizei tinka, kai p -reikšmė $p \geq \alpha$; čia α – pasirinktas reikšmingumo lygmuo.

9.1 pavyzdys. Prisiminkime logistinės regresijos uždavinį apie galimybę pagal pajamas (*PAJAMOS*) ir darbo prestižumo indeksą (*PRESTG*) atpažinti, ar respondentas turi aukštąjį išsilavinimą (*MOKSL* = 1), ar ne (*MOKSL* = 0) (žr. 7 skyriaus 2 uždavinį). Duomenys pateikti 7.3 lentelėje. Bokso kriterijaus taikymo šiam uždaviniui SPSS rezultatai yra 9.1 paveiksle.

TEST RESULTS		
Box's M		7,710
F	Approx.	2,336
	df1	3
	df2	867926,8
	Sig.	,072

9.1 pav. Bokso statistika

Tarkime, kad pasirinkome reikšmingumo lygmenį $\alpha = 0,05$. Lentelėje *Test Results* grafoje Sig. randame Bokso statistikos p -reikšmę. Kadangi $0,072 > 0,05$, nulinės hipotezės apie kovariacijų matricų lygybę neatmetame. Taigi vieną iš svarbiausių diskriminantinės analizės reikalavimų 7.3 lentelės duomenys tenkina.

¹ George Edward Pelham Box – amerikiečių statistikas.

Apie duomenų tinkamumą diskriminantinei analizei negalima spręsti vien pagal Bokso kriterijų. Jei duomenų aibė neturi daug išskirčių, tai diskriminantinė analizė stabili net tada, kai kovariacijų matricos nehomogeniškos. Jei stebėjimų labai daug, tai net maži kovariacijų matricių skirtumai taikant Bokso kriterijų pripažįstami statistiškai reikšmingais.

9.3. Diskriminavimas



Jeigu tikėsite, kad diskriminavimas egzistuoja, jis egzistuos.

A. D'Anželo


Iš pradžių aptarsime grupių diskriminavimą. Tarkime, kad objekto priklausomybę tam tikrai grupei norime atpažinti pagal vieno intervalinio kintamojo reikšmes. Tai įmanoma tik tada, kai skirtingose grupėse šio kintamojo reikšmės bent šiek tiek skiriasi. Paprastai tikrinama, ar kintamojo vidurkiai skirtingose grupėse yra skirtingi. Faktiškai problema išsprendžiama pritaikius vienfaktorinę dispersinę analizę. Dabar tarkime, kad grupes diskriminuoti reikia pagal keletą kintamųjų. Tada tenka lyginti kintamųjų reikšmių vidurkių vektorius, o tai kur kas sudėtingiau. Vidurkių vektorių lygybei tikrinti skirta daugiamatė dispersinė analizė (MANOVA). Daugiamačiai statistikos metodai glaudžiai susiję ir neretai diskriminantinė analizė pateikiama kaip daugiamatės dispersinės analizės dalis. Vis dėlto diskriminantinę analizę patogiau nagrinėti atskirai.

Diskriminantinės analizės metodiką XX amžiaus ketvirtąjį dešimtmetį sukūrė R. Fišeris, H. Hotellingas¹ ir P. Mahalanobis. R. Fišeris pasiūlė metodą, leidžiantį grupių atskyrimui naudoti kintamųjų rinkinio tiesinę daugdarą. H. Hotellingas sukūrė kriterijų (Hotelingo T^2 kriterijų) vidurkių vektorių lygybei tikrinti. P. Mahalanobis pasiūlė matą atstumui tarp vektorių su koreliuotomis koordinatėmis matuoti.

Visa ši metodika atsispindi šiuolaikinėje diskriminantinėje analizėje (vadinamojoje *kanoninėje* diskriminantinėje analizėje). Atstumas tarp dviejų imčių vidurkių skaičiuojamas naudojant Mahalanobio matą. Ar šis atstumas statistiškai reikšmingai skiriasi nuo nulio, tikrinama Hotelingo ir panašiais kriterijais. Objektams klasifikuoti į grupes konstruojamos Fišerio arba panašios klasifikavimo funkcijos.

Pradėkime nuo kiekvieno atskirai paimto kintamojo diskriminavimo galimybių įvertinimo. Pabandysime grafiškai paaiškinti, ką reiškia, kad kintamasis gerai diskriminuoja grupes. Tarkime, pagal du intervalinius kintamuosius X_1 ir X_2 reikia nustatyti, kuriai iš dviejų grupių objektas priklauso. Duomenis galima pavaizduoti kaip plokštumos taškus, kurių koordinatės atitinka kintamųjų reikšmes (žr. 9.2 pav.). Dėl vaizdumo pirmosios grupės stebėjimus pažymėjome taškais, o antrosios – rombais. Kintamasis gerai diskriminuoja grupes, jeigu paėmus visų taškų projekcijas į jį atitinkančią ašį gaunamos mažai besikertančios aibės. Pavyzdžiui, 9.2 paveiksle, a) kintamasis X_1 gerai diskriminuoja grupes, o X_2 blogai. Jeigu skirtingas grupes atitinkantys taškai nesuformuoja atskirų „debesėlių“, tai kintamieji diskriminavimui netinka. Tačiau pavieniai kintamieji gali būti prasti diskriminatoriai net ir tuo atveju, kai skirtingų grupių stebėjimai suformuoja visiškai atskirus

¹ Harold Hotelling (1895–1973) – amerikiečių statistikas.



„debesėlius“ (žr. 9.2 pav., b)). Ateityje matysime, kad šiuo atveju diskriminavimui galima panaudoti kintamųjų tiesinę daugdarą.

Kurie diskriminavimo kintamieji statistiškai patikimai skiriasi grupėse, o kurie – ne, galima nustatyti pasinaudojus vienfaktorine dispersine analize. Jei kintamojo vidurkio reikšmės skirtingose grupėse nesiskiria, tai lyg ir nėra prasmės šio kintamojo traukti į diskriminantinę analizę. Tačiau toks kintamasis gali būti svarbus tiesinei kintamųjų daugdarai, todėl vienfaktorinė dispersinė analizė tepadeda nustatyti „įtartinus“ kintamuosius.

Pati vienfaktorinė dispersinė analizė atliekama visiškai analogiškai kaip 2 skyriuje aprašyta ANOVA. Iš tikrųjų užtenka 9.1 lentelėje ignoruoti visus kintamuosius, išskyrus X_i , kad gautume tipiską ANOVA duomenų struktūrą. Vis dėlto aprašysime smulkiau, kaip nustatomos kintamojo diskriminavimo galimybės.

Pažymėkime i -ojo kintamojo empirinį vidurkį j -oje grupėje ir bendrąjį i -ojo kintamojo empirinį vidurkį simboliais

$$\bar{x}_{ij} = \left(\sum_{k=1}^{n_j} x_{ijk} \right) / n_j \quad \text{ir} \quad \bar{x}_i = \left(\sum_{j=1}^g \sum_{k=1}^{n_j} x_{ijk} \right) / n. \quad (1)$$

Tegul

$$w_{il} = \sum_{j=1}^g \sum_{k=1}^{n_j} (x_{ijk} - \bar{x}_{ij})(x_{ljk} - \bar{x}_{lj}), \quad t_{il} = \sum_{j=1}^g \sum_{k=1}^{n_j} (x_{ijk} - \bar{x}_i)(x_{ljk} - \bar{x}_l). \quad (2)$$

Matrica $W = (w_{il})$, $i, l = 1, \dots, p$, vadinama empirine nuokrypių grupių viduje sandaugų matrica arba *vidinių nuokrypių* matrica. Matrica $T = (t_{il})$, $i, l = 1, \dots, p$, vadinama empirine pilnaja nuokrypių sandaugų matrica, arba *pilnaja nuokrypių* matrica. Matrica $B = T - W$ vadinama empirine grupių nuokrypių sandaugų matrica, arba *grupių nuokrypių* matrica.

Kaip sužinoti, ar kintamasis X_i statistiškai reikšmingai diskriminuoja grupes? Tikrinama tokia statistinė hipotezė:

$$\begin{cases} H_0: \mu_{i1} = \mu_{i2} = \dots = \mu_{ig}, \\ H_1: \mu_{ik} \neq \mu_{il} \text{ bent vienai porai } (k \neq l); \end{cases}$$

čia $k, l = 1, \dots, g$.

Skaičiuojama statistika

$$F_i = \frac{(t_{ii} - w_{ii})(n - g)}{w_{ii}}.$$

Jei $F_i > F_{\alpha/2}(g - 1, n - g)$, tai nulinė hipotezė H_0 atmetama. Išvada – kintamasis *diskriminuoja* grupes. Priešingu atveju H_0 neatmetama – kintamasis grupių nediskriminuoja. Čia $F_{\alpha/2}(g - 1, n - g)$ yra Fišerio skirstinio su $(g - 1)$ ir $(n - g)$ laisvės laipsnių $\alpha/2$ lygmens kritinė reikšmė.

Pasirinkę kriterijaus p -reikšmę, sprendimą priimame analogiškai ankstesniems kriterijams. Tegul pasirinktasis reikšmingumo lygmuo lygus α , o p -reikšmė lygi p .

Kintamasis statistiškai reikšmingai diskriminuoja grupes, jeigu $p < \alpha$.

Paprastai ne tik tikrinama, ar kintamasis X_i yra geras grupių diskriminatorius, bet ir apskaičiuojama viena iš diskriminavimo charakteristikų – Vilks¹ Λ statistika (ji dar vadinama *U statistika*). Kintamojo X_i Vilks¹ Λ statistika apskaičiuojama pagal formulę

$$\Lambda_i = \frac{w_{ii}}{t_{ii}}. \quad (4)$$

Šios statistikos reikšmių kitimo sritis yra intervalas $[0; 1]$. Reikšmė 1 reiškia, kad stebimo kintamojo vidurkiai grupėse nesiskiria (tiksliau – i -ojo kintamojo vidinių nuokrypių suma nesiskiria nuo pilnosios nuokrypių sumos). Taigi, kuo šios statistikos reikšmė *mažesnė*, tuo kintamasis *geriau* diskriminuoja grupes.

9.2 pavyzdys. Įvertinkime 9.1 pavyzdžio požymių *PAJAMOS* ir *PRESTG* diskriminavimo galią. Tegul reikšmingumo lygmuo $\alpha = 0,05$. SPSS paketu gauti rezultatai parodyti 9.3 paveiksle, a).

TESTS OF EQUALITY OF GROUP MEANS					
	Wilks' Lambda	F	df1	df2	Sig.
PAJAMOS	,452	29,110	1	24	,000
PRESTG	,998	,055	1	24	,817

a)

TESTS OF EQUALITY OF GROUP MEANS					
	Wilks' Lambda	F	df1	df2	Sig.
TURTAS	,039	406,803	2	33	,000
DRAUD	,572	12,364	2	33	,000
PAŽYM	,311	36,491	2	33	,000

b)

9.3 pav. Vilks¹ Λ statistika

¹ Samuel Stanley Wilks (1906–1964) – amerikiečių matematikas.

Lentelėje *Tests of Equality of Group Means* pateikiama Vilksio Λ , F statistika bei hipotezių apie atskirų kintamųjų vidurkių lygybę grupėse tikrinimo rezultatai. Atitinkamos p -reikšmės yra stulpelyje *Sig.* Matome, kad kintamasis *PRESTG* nediskriminuoja grupių (jo p -reikšmė didesnė už 0,05), o kintamasis *PAJAMOS* – diskriminuoja.

9.3 pavyzdys. Visus paskolą gavusius studentus bankas, atsižvelgdamas į „jų patikimumą“, skirsto į tris kategorijas (kintamasis *KATEGOR*): nepatikimus klientus (1), patikimus (2) ir iš dalies patikimus (3) klientus. Bankas nori nustatyti, ar pagal sesijos pažymių vidurkį (*PAŽYM*), tėvų turtą (*TURTAS*, tūkst. Lt) ir sumą, kuria studentas apdraudė savo gyvybę (*DRAUD*, tūkst. Lt), galima nustatyti, kuriai kategorijai priklauso studentas. Informacija apie 36 paskolą paėmusius studentus pateikta 9.2 lentelėje. Šiems duomenims Vilksio Λ ir atitinkamos p -reikšmės yra 9.3 paveiksle, b). Tarkime, kad pasirinktume reikšmingumo lygmenį $\alpha = 0,05$. Matome, kad visų testų rezultatai statistiškai reikšmingi. Vis dėlto Vilksio Λ reikšmės kintamiesiems *DRAUD* ir *PAŽYM* pakankamai didelės (0,572 ir 0,311), taigi jų įtaka atskiriant grupes gali būti gana silpna. Kita vertus, kintamojo *TURTAS* Vilksio $\Lambda = 0,039$ labai maža, todėl tikėtina, kad šis kintamasis turi gerą diskriminavimo savybių.

9.2 lentelė. Banko klientų duomenys


Kategor	1	1	1	1	2	1	2	1	2	3	2	2	2	1	2	1	2	1
Pažym	6,5	6,1	6,6	6,5	7,3	6,9	7,9	7,0	7,5	7,3	8,7	7,7	7,4	5,9	8,7	6,5	9,2	6,4
Turtas	69	45	99	69	291	75	315	69	285	219	351	309	291	63	345	57	351	75
Draud	49	44	46	44	35	42	39	50	30	35	44	42	38	38	40	40	38	39

Kategor	3	3	3	1	1	2	1	2	1	1	2	1	2	1	2	3	3	3
Pažym	7,7	7,6	7,2	6,6	6,7	7,8	6,1	8,2	6,3	7,3	7,7	6,1	7,8	6,7	7,2	7,6	7,8	7,2
Turtas	309	267	231	75	75	345	69	297	69	57	273	69	321	75	285	303	267	237
Draud	37	36	36	46	43	41	42	38	38	48	36	40	42	42	33	35	36	36

9.4. Kanoninės funkcijos

Kaip diskriminuojant kintamųjų grupes iškart atsižvelgti į visus kintamuosius? Paprasčiausias būdas – paimti jų tiesinę daugdarą. Kyla klausimas – ar kintamųjų tiesinė daugdara diskriminavimui gali tikti geriau nei patys kintamieji? Tuo nesunku įsitikinti, dar kartą pažvelgus į 9.4 paveikslą (pakartotą 9.2 pav., b) situaciją). Matyti, kad nors kiekvienas kintamasis atskirai prastai diskriminuoja grupes, jų tiesinė daugdara tam puikiausiai tinka. (Taškų projekcijos į naująją ašį sudaro nesikertančias aibes.)

Tinkamai parinkus koeficientus l_j^i , galima gauti net kelias diskriminavimui tinkamas tiesines daugdaras $Y_i = l_1^i X_1 + l_2^i X_2 + \dots + l_p^i X_p + C_i$. Šios daugdaros vadinamos



kanoninėmis diskriminantinėmis funkcijomis, arba kanoniniais kintamaisiais. Toliau dėl trumpumo šias funkcijas vadinsime kanoninėmis funkcijomis. Jos ne tik pagerina grupių diskriminavimą, bet ir:

- a) padeda įvertinti kiekybinį kiekvieno stebimo kintamojo indėlį diskriminuojant grupes;
- b) palengvina interpretavimą priežasčių, dėl kurių atsiranda grupių skirtumai;
- c) gali būti naudojamos ir klasifikavimui;
- d) grupių duomenų vaizdavimas kanoninių funkcijų erdvėje leidžia suvokti populiaciją sudarančių grupių skirtumus ir ryšius bei aptikti išskirtis.

9.4.1. Kanoninių funkcijų sudarymas

Kaip sudaromos kanoninės funkcijos? Nusakysime pagrindinę idėją, kaip parenkami kanoninių funkcijų koeficientai. Kiekvienam p kintamųjų stebėjimų vektoriui $(x_{1jk}, x_{2jk}, \dots, x_{pjk})$ tiesinė daugdara (kanoninė funkcija) $l_1 x_{1jk} + \dots + l_p x_{pjk}$ priskiria vieną reikšmę. Taigi vietoje n vektorių duomenis sudaro n skaičių (kanoninės funkcijos reikšmių). Mūsų tikslas – koeficientus l_i parinkti taip, kad vidurkiai grupėse kuo labiau skirtųsi. Iš vienfaktorinės dispersinės analizės (žr. 2 skyrių) žinome, kad grupių vidurkių skirtumą atskleidžia grupių kvadratų sumos ir vidinės kvadratų sumos santykis. Todėl pirmosios kanoninės funkcijos koeficientai parenkami taip, kad šis santykis būtų maksimalus.

Vis dėlto gali būti ne viena panašias savybes turinti funkcija. Todėl ieškoma ir kitų kanoninių funkcijų. Antros kanoninės funkcijos koeficientai parenkami analogiškai pirmajai, tik su papildoma sąlyga, kad antros funkcijos reikšmės nekoreliuotų su pirmosios reikšmėmis. Analogiškai trečia funkcija turi nekoreliuoti su pirmosiomis dviem ir t.t. Maksimalus tokiu būdu gaunamas kanoninių funkcijų skaičius lygus mažesniajam iš diskriminavimo kintamųjų skaičiaus ir grupių skaičiaus be vieno, t.y. kanoninių funkcijų skaičius lygus $\min(g - 1, p)$.

Matematiškai kanoninių funkcijų daugiklių ieškojimas susiveda į grupių kvadratų sumos ir vidinės kvadratų sumos santykio $\vec{l}'B\vec{l}/\vec{l}'W\vec{l}$ maksimizavimą; čia $\vec{l} = (l_1, l_2, \dots, l_p)$, $\vec{l}'$ žymi transponuotą vektorių, o matricos B ir W apibrėžtos 9.3 skyrelyje. Skaičiuojant antrąją funkciją, dar reikia atsižvelgti į reikalavimą, kad ji nekoreliuotų su pirmąja, todėl problemos sprendimas tampa pakankamai sudėtingas.

Įrodyta, kad kanoninių funkcijų koeficientai yra matricų sandaugos $W^{-1}B$ tikriniai vektoriai. Tarkime, kad matricos $W^{-1}B$ tikrinės reikšmės yra $\lambda_1 \geq \lambda_2 \geq \lambda_3 \geq \dots$ (žr. p. 247). Pirmosios kanoninės funkcijos koeficientų aibė – tai didžiausią tikrinę reikšmę λ_1 atitinkantis tikrinis vektorius; antrosios – λ_2 tikrinę reikšmę atitinkantis tikrinis vektorius ir t.t. Taigi kanoninių funkcijų bus tiek pat, kiek ir tikrinių vektorių.

Taip gauname kanonines funkcijas, kurių koeficientai yra nestandartizuoti:

$$Y_i = l_1^i X_1 + l_2^i X_2 + \dots + l_p^i X_p + C_i, \quad i = 1, \dots, \min(g - 1, p). \quad (5)$$

Laisvasis kanoninės funkcijos narys (konstanta C_i) parenkamas taip, kad duomenų kanoninės funkcijos reikšmių empirinis vidurkis būtų lygus nuliui.

9.4 pavyzdys. SPSS paketu apskaičiuotų 9.3 pavyzdžio duomenų kanoninių funkcijų rezultatai pateikti 9.5 paveiksle.

CANONICAL DISCRIMINANT FUNCTION COEFFICIENTS		
	Function	
	1	2
TURTAS	,048	,008
DRAUD	-,147	,294
PAŽYM	-,347	-,299
(Constant)	-,945	-11,127

Unstandardized coefficients.

9.5 pav. Kanoninės funkcijos

Matome, kad šiuo atveju yra dvi kanoninės funkcijos:

$$f_1(TURTAS, DRAUD, PAŽYM) = 0,048 \cdot TURTAS + (-0,147) \cdot DRAUD + (-0,347) \cdot PAŽYM - 0,945, \quad (6)$$

$$f_2(TURTAS, DRAUD, PAŽYM) = 0,008 \cdot TURTAS + 0,294 \cdot DRAUD + (-0,299) \cdot PAŽYM - 11,127. \quad (7)$$

Pirmojo respondento (žr. 9.2 lentelę) kanoninių funkcijų reikšmės yra:

$$f_1(69, 41, 6,5) = 0,048 \cdot 69 + (-0,147) \cdot 41 + (-0,347) \cdot 6,5 - 0,945 = -5,91,$$

$$f_2(69, 41, 6,5) = 0,008 \cdot 69 + 0,294 \cdot 41 + (-0,299) \cdot 6,5 - 11,127 = -0,46.$$

Kanoninių funkcijų reikšmės galima apskaičiuoti kiekvienam stebėjimų vektoriui. Gautos reikšmės naudojamos kanoninių funkcijų diskriminavimo savybėms įvertinti.

9.4.2. Kanoninių funkcijų diskriminavimo savybės

Skyrelio pradžioje pateiktame 9.4 paveiksle nurodėme situaciją, kai kanoninė funkcija išsiskiria geromis diskriminavimo savybėmis. Dabar aptarsime metodus šioms savybėms įvertinti. Nereikia tikėtis, kad *kiekviena* kanoninė funkcija gerai diskriminuos kintamųjų grupes. Maža to, visiškai įmanoma situacija, kai jokia kanoninė funkcija negarantuos grupių atskyrimo. Diskriminantinė analizė nėra panacėja ir ne visada tinka.

Kaip įvertinti, kurios kanoninės funkcijos turi pakankamai geras diskriminavimo savybes? Nėra vieno tokio rodiklio. Dažniausiai tenka atsižvelgti į kelis požymius. Tyrimą gerokai palengvina tai, kad visada geriausiai diskriminuoja pirmoji kanoninė funkcija, po jos – antroji ir t. t.

Beveik visi rodikliai susiję su minėtomis $W^{-1}B$ tikrinėmis reikšmėmis $\lambda_1, \lambda_2, \dots$. Pirmoje 9.6 paveikslo lentelėje (*Eigenvalues*) pateiktos 9.3 pavyzdžio tikrinės reikšmės. Matome, kad pirmąją kanoninę funkciją atitinkanti tikrinė reikšmė ($\lambda_1 = 33,751$) yra daug didesnė už antrąją ($\lambda_2 = 0,129$). Santykis $\lambda_1/(\lambda_1 + \lambda_2) = 0,996$ interpretuojamas taip: iš visos, *abiem kanoninėmis funkcijomis paaiškinamos* kintamųjų dispersijos 99,6% tenka pirmajai kanoninei funkcijai (žr. stulpelį % of Variance). Analogiškai nustatoma, kad antroji kanoninė funkcija paaiškina tik 0,4% dispersijos. Taigi gauname gana akivaizdų įrodymą, kad pirmoji kanoninė funkcija daug svarbesnė už antrąją. Vis dėlto šio rodiklio nereikia suabsoliutinti – jis yra *santykinis*. Palyginti su antrąja kanonine funkcija, pirmoji

SUMMARY OF CANONICAL DISCRIMINANT FUNCTIONS				
EIGENVALUES				
Function	Eigenvalue	% of Variance	Cumulative %	Canonical Correlation
1	33,751 ^a	99,6	99,6	,986
2	,129 ^a	,4	100,0	,338

^a. First 2 canonical discriminant functions were used in the analysis.

WILKS' LAMBDA				
Test of Function(s)	Wilks' Lambda	Chi-square	df	Sig.
1 through 2	,025	117,414	6	,000
2	,886	3,871	2	,144

9.6 pav. Tikrinės reikšmės

yra svarbesnė, tačiau tai dar nereiškia, kad bent viena iš jų turi gerų diskriminavimo savybių. Jeigu $g = 2$ (yra tik dvi grupės), tai iš viso yra tik viena kanoninė funkcija, kuri lyginama pati su savimi ir, be abejo, paaiškina 100% dispersijos. Paskutiniame stulpelyje Canonical Correlation pateikti dydžiai $\sqrt{1/(1 + \lambda_1)} = \sqrt{1/34,751} = 0,986$ ir $\sqrt{1/(1 + \lambda_2)} = 0,338$. Pagal (6) formulę apskaičiuojame visų stebėjimų vektorių pirmosios kanoninės funkcijos reikšmes. Kadangi žinome, kokiai grupei kokiam reikšmė priklauso, remdamiesi vienfaktorine dispersine analize galime palyginti grupių vidurkius ir apskaičiuoti koeficientą η , kuris šiuo atveju ir yra kanoninės koreliacijos koeficientas. (Primename, kad η^2 – grupių dispersijos ir bendrosios dispersijos santykis.) Taigi kanoninė koreliacija yra diskriminavimo galios matas (reikšmių sritis yra nuo 0 iki 1). Kuo koeficientas arčiau vienetą, tuo diskriminavimas geresnis.

Antroji 9.6 paveikslą lentelė (*Wilks' Lambda*) skirta įvertinti, ar kanoninių funkcijų reikšmių vidurkiai skirtingose grupėse *statistiškai reikšmingai* skiriasi. Jeigu vidurkiai skiriasi, tai grupių diskriminavimas įmanomas.

Pirmiausia tikrinama, ar galima grupes atskirti naudojantis abiem funkcijomis (grafos Test of Function(s) eilutė 1 through 2. Skaitinė charakteristika, parodanti, kaip gerai galima atskirti grupes, yra Vilksio Λ , tačiau kanoninėms funkcijoms ji skaičiuojama kiek kitaip nei kintamiesiems. *Abiejų* kanoninių funkcijų aibės Vilksio Λ skaičiuojama pagal formulę

$$\Lambda_{1,2} = \frac{1}{(1 + \lambda_1)(1 + \lambda_2)};$$

čia λ_i yra su kanoninėmis funkcijomis susijusios tikrinės reikšmės. Vilksio Λ gali įgyti reikšmes nuo 0 iki 1. Kuo Λ mažesnė, tuo funkcijų diskriminavimo galia didesnė. Matome, kad kartu paimtų abiejų kanoninių funkcijų diskriminavimo galia pakankamai didelė (Vilksio $\Lambda_{1,2} = 0,025$).


Vilksio Λ naudojama tikrinant statistinę hipotezę apie kanoninių funkcijų reikšmių vidurkių lygybę grupėse. Tam taikoma statistika $\chi^2 = -(n - (p + g)/2 - 1) \ln \Lambda$, turinti χ^2 skirstinį. Statistikos reikšmė (117,414) ir laisvės laipsnių skaičius (6) pateikti grafose Chi-square ir df. Kriterijaus p -reikšmė (0,000) yra stulpelyje Sig.

Grupių vidurkiai statistiškai reikšmingai skiriasi (tiramųjų kanoninių funkcijų aibės diskriminavimo savybės statistiškai reikšmingos), kai p -reikšmė yra mažesnė už pasirinktą reikšmingumo lygmenį α .

Tarkime, kad reikšmingumo lygmuo $\alpha = 0,05$. Kadangi $0,000 < 0,05$, tai nulinę hipotezę atmetame ir turime pagrindo manyti, jog naudojant *abi* kanonines funkcijas diskriminavimas įmanomas.

Jei Vilksio Λ statistiškai reikšminga, tai nebūtinai atitinkamos kanoninės funkcijos gerai diskriminuoja. Vilksio Λ tik naudojama hipotezei apie grupių vidurkių lygybę tikrinti. Statistiškai reikšmingi gali būti net maži vidurkių skirtumai, tačiau, tai nereiškia gero diskriminavimo. Kita vertus, aišku, kad diskriminavimas neįmanomas, jei vidurkiai ir kovariacijų matricos grupėse nesiskiria.

Apskaičiavus visų kanoninių funkcijų aibės Vilksio Λ , skaičiuojama visų kanoninių funkcijų aibės be pirmosios funkcijos Vilksio Λ . Faktiškai tai reiškia, kad mes bandome įvertinti, kiek diskriminavimo potencialo turi visos likusios kanoninės funkcijos. Visa, kas pasakyta apie Λ didumą bei hipotezės tikrinimą, tinka ir šiuo atveju. Po to pašalinama antroji kanoninė funkcija ir procesas tęsiamas. Kadangi mūsų nagrinėjamu atveju yra dvi kanoninės funkcijos, tai pirmąją pašalinus lieka tik antroji. Jos Vilksio $\Lambda = 0,886$ (didelis



skaičius), o p -reikšmė lygi $0,144 > 0,05$. Taigi matome, kad antroji kanoninė funkcija diskriminavimui nelabai tinka.

Taigi 9.3 pavyzdžio ir Vilkso Λ , ir Vilkso kriterijaus p -reikšmės rodo, kad diskriminuojant pirmoji kanoninė funkcija svarbi, o antroji – ne.

Dviejų kanoninių funkcijų diskriminavimo savybes palyginti ir įvertinti galima ir vizualiai, braižant grafiką. Kadangi svarbiausios yra pirmoji ir antroji kanoninės funkcijos, jos dažniausiai ir naudojamos. Kiekvienam stebėjimui apskaičiuojamos šių kanoninių funkcijų reikšmės (žr. 9.4.1 skyrelį). Dabar kiekvieną stebėjimą charakterizuoja skaičių pora. Vienoje koordinatės ašyje atidėję pirmosios kanoninės funkcijos reikšmę, o antroje – antrosios, pačių funkcijų diskriminavimo savybes galėsime įvertinti pagal reikšmių projekcijas, kaip tai darėme aptardami 9.2 paveikslą. Nagrinėto 9.3 pavyzdžio kanoninių funkcijų grafikas pateiktas 9.7 paveiksle, a). Aiškiai matyti, kad pirmoji kanoninė funkcija iš tikrųjų gerai tinka diskriminuoti, tuo tarpu antroji – ne. Tai dar kartą patvirtina ankstesnes išvadas. Beje, brėžinyje pažymėti ir grupių *centrai*, t. y. kanoninių funkcijų reikšmės, įgyjamos kiekvienos grupės stebėjimų *vidurkių* vektoriuose. Centrų koordinatės pateiktos 9.7 paveikslo, b) lentelėje. Pavyzdžiui, antrosios grupės stebėjimų centro kanoninių funkcijų grafike koordinatės yra (5,608; 0,298).

9.4.3. Koeficientų palyginimas

Jau aptarėme, kaip nustatyti, kurios kanoninės funkcijos turi geras diskriminavimo savybes. Kiekviena kanoninė funkcija yra diskriminavimo kintamųjų tiesinė daugdara, todėl natūralu įvertinti kiekvieno kintamojo įtaką jai. Tam naudojamos *standartizuotosios*, t. y. apskaičiuotos stebėjimų z -reikšmėms, kanoninės funkcijos. Standartizuotųjų kanoninių funkcijų koeficientai (skirtingai nuo nestandartizuotųjų) nepriklauso nuo to, kokiais vienetais pateikti kintamųjų matavimai. Jų vaidmuo analogiškas β_i koeficientų tiesinėje regresijoje vaidmeniui. Šie koeficientai padeda įvertinti kiekvieno kintamojo indėlį į kanoninės funkcijos didumą. Pažymėtina, kad standartizuotųjų kanoninių funkcijų koeficientai rodo kintamojo svarbą, kai jau pašalinta jo priklausomybė nuo kitų kintamųjų (tuo primena dalinius koreliacijos koeficientus). Koeficiento ženklas tik parodo, kokios „krypties“ yra kintamojo poveikis. Jei koeficientas teigiamas, tai kintamajam didėjant funkcijos reikšmė didėja, jei neigiamas – mažėja. Koeficiento svarbą lemia jo absoliutusias didumas. Iš 9.8 paveiksle, a) pateiktų 9.3 pavyzdžio standartizuotosios funkcijos koeficientų matome, kad pirmajai kanoninei funkcijai didžiausią įtaką daro *TURTAS* (1,139), tuo tarpu kitų kintamųjų koeficientai absoliučioju didumu daug mažesni. Antrajai kanoninei funkcijai svarbiausias yra kintamasis *DRAUD*.

STANDARDIZED CANONICAL DISCRIMINANT FUNCTION COEFFICIENTS			STRUCTURE MATRIX		
	Function			Function	
	1	2		1	2
TURTAS	1,139	,197	TURTAS	,854*	,498
DRAUD	-,493	,984	DRAUD	-,136	,987*
PAŽYM	-,158	-,136	PAŽYM	,254	-,514*

a) b)

9.8 pav. Standartizuotosios kanoninės funkcijos

*. Largest absolute correlation.

Atskirų kintamųjų ir standartizuotųjų kanoninių funkcijų koreliacijos koeficientai vadinami *struktūriniais* koeficientais. Struktūrinio koeficiento didumas – kitas kintamųjų ir kanoninių funkcijų priklausomybės matas. Šių koeficientų vaidmuo panašus į faktorių svorių faktorinėje analizėje (žr. 10 skyrių). Kartais struktūriniai koeficientai leidžia įvardyti kiekvieną iš kanoninių funkcijų. Struktūriniai koeficientai 9.3 pavyzdžio atveju pateikti 9.8 paveiksle, b). Matome, kad pirmoji standartizuotoji kanoninė funkcija stipriausiai koreliuoja su kintamuoju *TURTAS*; antroji – su kintamaisiais *DRAUD* ir *PAŽYM*.

Prisiminkime, kad ankstesnė analizė parodė, jog diskriminuojant svarbiausia yra pirmoji kanoninė funkcija. Dabar įsitikinome, kad šiai funkcijai didžiausią įtaką daro kintamasis *TURTAS*. Gauti rezultatai patvirtina jau anksčiau (pagal Vilkso Δ , žr. 9.3 pav., b)) padarytą išvadą, kad šis kintamasis išsiskiria geriausiomis diskriminavimo savybėmis.

9.5. Klasifikavimas



*Tikiuosi, kad išgudrėsit su laiku.
Tiktai išmokit viską redukuot
Ir tinkamai klasifikuot, drauguži.
Mefistofelis¹*

Antrasis diskriminantinės analizės uždavinys – klasifikavimas. Archeologas klasifikuoja naujus radinius, medikas – ligonius, bankas – klientus ir pan. Visais atvejais yra „mokymo imtis“ – anksčiau surinkti duomenys, kuriais remiantis sudaromos klasifikavimo taisyklės. Vienas iš joms keliamų sudarymo kriterijų reikalavimų – minimizuoti klaidingo klasifikavimo tikimybes. Tačiau yra dar vienas klasifikavimo aspektas – skirtingi klaidingo klasifikavimo padariniai. Iš tiesų turbūt mažiau pavojinga diagnozuoti plaučių uždegimą, jei jo nėra, nei nediagnozuoti, kai jis yra. Taigi sudarant klasifikavimo procedūras, į šį aspektą taip pat reikia atsižvelgti. Dažniausiai tai daroma įvedant specialius minimizuojamų tikimybių daugiklius – vadinamąsias klaidingo klasifikavimo kainas. Dėl paprastumo toliau klaidingo klasifikavimo kainas laikysime vienodomis.

Klasifikavimo procedūros priklauso ir nuo apriorinės informacijos. Pavyzdžiui, iš anksto gali būti žinoma, kad 80% tam tikrų simptomų turinčių pacientų serga liga A, o 20% – liga B. Aišku, kad tuomet labiau tikėtina, kad ir naujas tų simptomų turintis ligonis serga liga A.



Senovės kinai visus gyvūnus klasifikavo į: a) priklausančius imperatoriui; b) skleidžiančius malonų aromatą; c) dresiruotus; d) žindančius paršelius; e) sirenas; f) keistus; g) valkataujančius šunis; h) nesuskaičiuojamus; i) iš tolo primenančius muses; j) likusius.

Pastebėsime, kad klasifikavimo procedūrų kokybė įvertinama pagal turimą „mokymo imtį“. Aišku, kad naujų stebėjimų klasifikavimo rezultatai gali būti prastesni, nei tikimasi – visada lengviau spėti žinant rezultatą! Todėl, gavus naujų duomenų, patartina klasifikavimo procedūras patikslinti. Be to, reikia aiškiai skirti „mokymo imties“ klasifikavimą (naudojamą siekiant įvertinti klasifikavimo taisyklių kokybę) nuo naujų objektų klasifikavimo (pagal konkrečius stebėjimus naujo objekto priskyrimo vienai iš grupių).

¹ J. V. Gėtė, *Faustas*.

Yra įvairių klasifikavimo procedūrų. Klasifikavimui galima naudoti ir kanonines funkcijas, ir specialias klasifikavimo funkcijas (kurių apibrėžimą pateiksime vėliau), ir tikimybinės procedūras. Kai galioja diskriminantinės analizės prielaidos, dažnai visos jos yra ekvivalentišios.

Yra keletas sąvokų bei principų, kurie vienaip ar kitaip naudojami klasifikavimo procedūroms. Pagrindinė sąvoka – *grupės centras*, t. y. grupės stebėjimų vidurkių vektorius (nepainioti su grupių centrais kanoninių funkcijų erdvėje, žr., pvz., 9.7 pav., b)). Priesiminkime 9.3 pavyzdį. Kad būtų patogiau, centrų koordinatas rašysime kaip vektorių (*DRAUD*, *PAŽYM*, *TURTAS*). Nepatikimų klientų centras yra (42,68; 6,51; 69,37), patikimų – (38,15; 7,93; 312,23), sąlygiškai patikimų klientų – (35,85; 7,48; 261,86).

Pagrindinė klasifikavimo idėja – objektas priskiriamas tai grupei, nuo kurios centro nutolęs mažiausiai. Atstumo matas – Mahalanobio atstumas.

Pradėkime nuo klasifikavimo, kai populiaciją sudaro dvi grupės. Manome, kad tai padės lengviau suprasti klasifikavimo principus.

9.6. Klasifikavimas, kai populiaciją sudaro dvi grupės



Našta gali būti lengva ir gali būti sunki.

Mao

Populiaciją sudaro dvi grupės G_1 ir G_2 . Tarkime, turime diskriminavimo kintamųjų rinkinio $\vec{X} = (X_1, X_2, \dots, X_p)$ stebėjimų populiacijoje duomenų matricą (t. y. pradinę kintamųjų atranka naudojant Vilkso statistiką ir dispersinės analizės metodus jau atlikta). Iš pradžių tarkime, kad kintamųjų rinkinys $\vec{X} = (X_1, X_2, \dots, X_p)$ grupėse G_1 ir G_2 pasiskirstęs normaliai su žinomais parametrais. Be to, kovariacijų matricas grupėse laikysime vienodomis. Taigi žinomi vidurkiai $\vec{\mu}_i = (\mu_1, \mu_2, \dots, \mu_p)$, $i = 1, 2$, ir kovariacijų matricos $\Sigma_1 = \Sigma_2 = \Sigma = (\sigma_{ij}^2)$, $i = 1, \dots, p$, $j = 1, \dots, p$.


Klasifikavimo uždavinį galima suformuluoti taip: stebėjimų vektorių $\vec{x}$ atitinkantį objektą turime priskirti vienai iš grupių G_1 arba G_2 . Reikia sudaryti taisykles, pagal kurias objektai klasifikuojami į klases.

Klasifikuodami objektus, galime padaryti dviejų tipų klaidas: 1) priskirti objektą grupei G_1 , nors iš tiesų jis priklauso grupei G_2 ; 2) priskirti objektą grupei G_2 , nors iš tiesų jis priklauso grupei G_1 .

$P(G_1|G_2)$ – tikimybė priskirti objektą grupei G_1 , nors jis priklauso grupei G_2 ;
 $P(G_2|G_1)$ – tikimybė priskirti objektą grupei G_2 , nors jis priklauso grupei G_1 ;
 $P(\vec{x}|G_i)$ – tikimybė, kad gausime $\vec{x}$ stebėjimą, kai objektas priklauso grupei G_i ;
 $P(G_i|\vec{x})$ – tikimybė, kad objektas priklauso G_i , kai jo stebėjimų vektorius yra $\vec{x}$.

Tikimybės $P(G_1|G_2)$ ir $P(G_2|G_1)$ vadinamos *klaidingo klasifikavimo* tikimybėmis, o $P(G_1|\vec{x})$ ir $P(G_2|\vec{x})$ – *aposteriorinėmis*. Tikimybės $P(\vec{x}|G_1)$ ir $P(\vec{x}|G_2)$ vadinamos *sąlyginėmis* tikimybėmis.

Pažymėkime q_i *apriorinę* tikimybę, kad atsitiktinai parinktas iš populiacijos objektas priklauso grupei G_i , $i = 1, 2$. Aišku, kad $q_1 + q_2 = 1$.



Klasifikavimo taisyklės parenkamos taip, kad klaidingo klasifikavimo tikimybių suma $q_1 P(G_2|G_1) + q_2 P(G_1|G_2)$ būtų minimali.

Grafiškai aprašyta situacija, kai $p = 1$, pavaizduota 9.9 paveiksle.

Naudojantis *Bajeso klasifikavimo procedūra*, objektas priskiriamas tai grupei, kurios aposteriorinė tikimybė didžiausia, o jei tikimybės lygios, objektas atitenka pirmajai grupei. Vadinasi, objektas, kurio stebėjimo vektorius yra $\vec{x}$, priskiriamas grupei G_1 , jei $P(G_1|\vec{x}) \geq P(G_2|\vec{x})$. Priešingu atveju objektas priskiriamas grupei G_2 .

Pagal Bajeso teoremą bet kokiam $\vec{X}$ skirstiniui yra teisinga lygybė

$$P(G_i|\vec{x}) = \frac{q_i P(\vec{x}|G_i)}{q_1 P(\vec{x}|G_1) + q_2 P(\vec{x}|G_2)}. \quad (8)$$

Jei $\vec{X}$ skirstiniai grupėse yra tolydieji, tai galima užrašyti tokią lygybę:

$$P(G_i|\vec{x}) = \frac{q_i f_i(\vec{x})}{q_1 f_1(\vec{x}) + q_2 f_2(\vec{x})}; \quad (9)$$

čia $f_i(\vec{x})$, $i = 1, 2$, – kintamųjų vektoriaus $\vec{X}$ i -ojoje grupėje tankio funkcija.

Atsižvelgę į (9) formulę, klasifikavimo taisyklės galima suformuluoti taip: objektas, kurio stebėjimo vektorius yra $\vec{x}$, priskiriamas grupei G_1 , jei $(q_1 f_1(\vec{x})) / (q_2 f_2(\vec{x})) \geq 1$, arba grupei G_2 , jei $(q_1 f_1(\vec{x})) / (q_2 f_2(\vec{x})) < 1$. Įrodyta, kad tokia klasifikavimo procedūra minimizuoja klaidingo klasifikavimo tikimybių sumą $q_1 P(G_2|G_1) + q_2 P(G_1|G_2)$.

Dėl paprastumo toliau laikysime $q_1 = q_2 = 1/2$. Daugiamačio normaliojo skirstinio tankis

$$f_i(\vec{x}) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (\vec{x} - \vec{\mu}_i)' \Sigma^{-1} (\vec{x} - \vec{\mu}_i) \right\}; \quad (10)$$

čia $\vec{\mu}_i$ yra kanoninės funkcijos i -ojoje grupėje vidurkis, o Σ^{-1} – atvirkštinė diskriminavimo kintamųjų kovariacijų matrica. Pastebėsime, kad Mahalanobio atstumo kvadratą tarp grupių galima užrašyti taip:

$$\Delta^2 = (\vec{\mu}_1 - \vec{\mu}_2)' \Sigma^{-1} (\vec{\mu}_1 - \vec{\mu}_2).$$

Todėl aposteriorinių tikimybių formules galime perrašyti

$$P(G_i|\vec{x}) = \frac{f_i(\vec{x})}{f_1(\vec{x}) + f_2(\vec{x})} = \frac{\exp\{-0,5\Delta_i^2\}}{\exp\{-0,5\Delta_1^2\} + \exp\{-0,5\Delta_2^2\}}; \quad (11)$$

Tarkime, $D(i)$ yra objekto stebėjimų vektoriaus Mahalanobio atstumas nuo i -osios grupės centro. Tikimybės, kad objektas priklauso i -ajai grupei, įvertis apskaičiuojamas pagal formulę

$$\widehat{P}(G_i|\vec{x}) = R(i)/(R(1) + R(2) + \dots + R(g));$$

čia $R(i) = \exp\{-0,5 * D^2(i)\}$. Ši formulė taikoma, kai apriorinės tikimybės lygios. Objektas priskiriamas tai grupei, kuriai apskaičiuotoji tikimybė yra didžiausia.



Labiausiai paplitęs kūno formų klasifikavimas, kurį pasiūlė amerikiečių psichologas V. H. Šeldonas. 1935 metais jis išskyrė tris pagrindinius kūno formų tipus: endomorfinį, mezomorfinį ir ektomorfinį. Bet žmonės labai sunkiai tokius žodžius įsimindavo, todėl 1942 metais Šeldonas pasiūlė naujus pavadinimus: storas, vidutinis, plonas. Amerikoje šie pavadinimai ir prigijo.

Kaip jau rašėme, klasifikuoti galima ir pagal kanoninių funkcijų reikšmes. Tarkime, objekto stebėjimų vektorius yra $\vec{x}$. Klasifikavimo procedūra yra tokia:

- 1** Apskaičiuojame šio vektoriaus kanoninių funkcijų reikšmes (pažymėkime jas $y_1(\vec{x}), y_2(\vec{x}), \dots, y_s(\vec{x})$; čia $s = \min(g - 1, p)$ – kanoninių funkcijų skaičius).
- 2** Apskaičiuojame kanoninių funkcijų grupių centruose reikšmes. Pažymėkime jas $y_1(c_1), y_2(c_1), \dots, y_s(c_1), y_1(c_2), \dots, y_s(c_k)$.
- 3** Apskaičiuojame

$$d_i = \sum_{j=1}^s (y_j(\vec{x}) - y_j(c_i))^2, \quad i = 1, \dots, k.$$

- 4** Objektas priskiriamas tai grupei, kurios d_i didžiausias.

Aprašytoji procedūra yra ekvivalenti Bajeso klasifikavimo procedūrai.



Mokslinis klasifikavimo metodas subjekto profesijai atpažinti – kiekvienas subjektas siunčiamas į Afriką medžioti dramblių ir jam taikoma tokia klasifikavimo taisyklė:

- a) *Jei subjektas apsiriboja įrodymu, kad dramblių aibė netuščia ir egzistuoja vienintelis (tik neaišku koks) optimalus jų gaudymo metodas, tai jis – matematikas.*
- b) *Jei subjektas n kartų pagavęs pirmą pakliuvusį padarą pavadina jį drambliu, jis – statistikas.*
- c) *Jei subjektas dramblio negaudo, bet pažada drambliui gerai sumokėti, kad pastarasis pats save pagautų, jis – ekonomistas.*
- d) *Jei subjektas sudaro veiksmų algoritmą (skersai išilgai lakstyti po Afriką ir gaudyti, kas po ranka paklius; pagavus lyginti su drambliu; liautis, kai lyginimas sėkmingas), jis – programuotojas.*
- e) *Jei subjektas vietoj dramblio gaudo triušius, dažo juos pilkai ir pardavinėja kaip personalinius mini dramblius, tai jis – kompiuterių pardavėjas.*

Praktiškai klasifikuoti naujus objektus patogiau naudojantis vadinamosiomis *klasifikavimo funkcijomis*. Šio metodo esmė tokia: kiekvienai grupei sudaroma klasifikavimo funkcija, ir objektas priskiriamas tai grupei, kurios klasifikavimo funkcija, objektą atitinkančiam stebėjimui, įgyja didžiausią reikšmę.

Kaip sudaromos klasifikavimo funkcijos? Dėl paprastumo tarkime, kad stebimų kinamųjų rinkinys pasiskirstęs pagal normalųjį dėsnį, kurio parametrai žinomi.

Kai grupių daugiau nei dvi, aposteriorinių tikimybių išraiškos yra

$$P(G_i|\vec{x}) = \frac{\exp\{\delta_i\}}{\sum_{k=1}^g \exp\{\delta_k\}}; \quad (12)$$

čia

$$\delta_i = (\vec{\mu}_i' \Sigma^{-1}) \vec{x} - \frac{1}{2} \vec{\mu}_i' \Sigma^{-1} \vec{\mu}_i, \quad i = 1, \dots, g.$$

Aišku, kad aposteriorinė tikimybė didžiausia, kai δ_i didžiausia. Taigi klasifikavimo procedūrą galima suformuluoti taip: objektas priskiriamas grupei G_i , jei δ_i , palyginti su kitomis δ_j , $j \neq i$, įgyja didžiausią reikšmę.

Pažymėję $\vec{b}_i = \Sigma^{-1} \vec{\mu}_i$ ir $b_{i0} = -\frac{1}{2} \vec{\mu}_i' \Sigma^{-1} \vec{\mu}_i$, $i = 1, \dots, g$, gauname labiau įprastą užrašą

$$\delta_i = b_{i1}x_1 + \dots + b_{ig}x_g + b_{i0}.$$

Jei stebimų kintamųjų vektoriaus skirstinio parametrai nežinomi, tai išraiškose parametrai keičiami į empirinius analogus.

Funkcijos δ_i , $i = 1, \dots, p$, vadinamos Fišerio *klasifikavimo funkcijomis*. Jas pateikia daugelis statistinių paketų.

Grįžkime prie 9.3 pavyzdžio nagrinėjimo. Į banką dėl paskolos gavimo kreipėsi studentas, kurio duomenų vektorius $\vec{x} = (350, 40, 8)$, t. y. jo tėvų turtas – 350 tūkst. Lt, draudimo suma – 40 tūkst. Lt, pažymių vidurkis – 8 balai. Ar galima sakyti, kad tai patikimas klientas? SPSS paketu apskaičiuoti klasifikavimo funkcijų koeficientai pateikti 9.11 paveiksle.

Lentelėje pateikiami trijų grupių klasifikavimo funkcijų koeficientai. Mūsų studento klasifikavimo funkcijų reikšmės yra:

$$f_1(\vec{x}) = 34,56 \cdot 8 + 2,37 \cdot 40 - 0,40 \cdot 350 - 150,40 = 80,88;$$

$$f_2(\vec{x}) = 30,40 \cdot 8 + 0,71 \cdot 40 + 0,16 \cdot 350 - 161,06 = 166,54;$$

$$f_3(\vec{x}) = 31,35 \cdot 8 + 0,71 \cdot 40 + 0,07 \cdot 350 - 139,85 = 163,85.$$

Matome, kad šį studentą galima būtų priskirti patikimų klientų grupei (didžiausia yra f_2 reikšmė – priskiriame studentą antrai kategorijai).


Kanoninių funkcijų reikšmių sklaidos grafikas, kuriame nurodytos grupių sričių ribos, parodytas 9.12 paveiksle. Kokia šio grafiko esmė? Studento duomenų vektorių atitinkantis kanoninių funkcijų reikšmių vektorius lygus (7; 1) (grafike pažymėtas ●). Šis taškas patenka į 2-os grupės teritoriją, t. y. studentas turėtų būti priskirtas prie patikimų klientų grupės.

Bet ar galima gautaisiais rezultatais tikėti? Apie tai – kitame skyrelyje.

CLASSIFICATION FUNCTION COEFFICIENTS			
	KATEGOR		
	1	2	3
TURTAS	-,40	,16	6,60E-02
DRAUD	2,37	,71	,71
PAŽYM	34,56	30,39	31,35
(Constant)	-150,40	-161,05	-139,84

Fisher's linear discriminant functions.

9.11 pav. Klasifikavimo funkcijos



9.8. Klasifikavimo patikimumas

Klasifikavimo kokybę nusako klasifikavimo lentelė bei klaidingo klasifikavimo tikimybių didumas. Klaidingo klasifikavimo tikimybių įverčiai apskaičiuojami naudojantis Lachenbruch'o procedūra. Čia pateiksime šios procedūros aprašymą dviejų grupių atveju:

- 1** Pradedama nuo pirmosios grupės stebėjimų. Praleidžiamas vienas iš stebėjimų ir likusių $(n_1 - 1) + n_2$ stebėjimų pagrindu sudaroma kanoninė funkcija.
- 2** Naudojantis sudaryta kanonine funkcija, praleistas stebėjimas yra klasifikuojamas.
- 3** Pirmas ir antras žingsniai kartojami tol, kol visi pirmosios grupės stebėjimai suklasifikuojami. Tegul $n_{1M}^{(H)}$ – neteisingai suklasifikuotų pirmosios grupės stebėjimų skaičius.
- 4** 1–3 žingsniai kartojami su antrosios grupės stebėjimais. Tegul $n_{2M}^{(H)}$ – neteisingai suklasifikuotų antrosios grupės stebėjimų skaičius.

5 Tada tikimybių $P(G_1|G_2)$ ir $P(G_2|G_1)$ įverčiai yra:

$$\hat{P}(G_1|G_2) = \frac{n_{1M}^{(H)}}{n_1}, \quad \hat{P}(G_2|G_1) = \frac{n_{2M}^{(H)}}{n_2}.$$

Dažnai yra svarbu ne tiek *priskirti* tiriamą objektą vienai ar kitai grupei (žinant, kad klaidos neišvengiamos), kiek *įvertinti* tikimybes, kad jis priklauso vienai ar kitai grupei. Todėl *aposteriorinių tikimybių* įverčiai suteikia labai svarbios informacijos apie tiriamus objektus. Daug ko apie tiriamus objektus pasako ir sąlyginių tikimybių reikšmės.

Panagrinėkime toliau 9.3 pavyzdžio SPSS paketo sprendimo protokolą.

CASEWISE STATISTICS											
Case Number	Actual Group	Highest Group				Second Highest Group				Discriminant Scores	
		Pre-dicted Group	P(D>d G=g)		P(G=g D=d)	Squared Mahalanobis Distance to Centroid	Group	P(G=g D=d)	Squared Mahalanobis Distance to Centroid	Function 1	Function 2
			p	df							
1	1	1	,860	2	1,000	,301	3	,000	92,788	-5,937	-,448
2	1	1	,456	2	1,000	1,570	3	,000	123,791	-7,387	,355
3	1	1	,328	2	1,000	2,228	3	,000	84,019	-5,274	1,240
4	1	1	,908	2	1,000	,192	3	,000	102,636	-6,379	,433
5	2	2	,623	2	,686	,945	3	,314	2,509	5,276	-,616
6	1	1	,937	2	1,000	,129	3	,000	92,920	-5,937	-,225
7	2	2	,961	2	,931	,079	3	,069	5,274	5,626	,579
8	1	1	,061	2	1,000	5,598	3	,000	131,169	-7,435	2,048
9	2	3**	,045	2	,501	6,208	2	,499	6,219	5,656	-2,195
10	3	3	,153	2	,998	3,753	2	,002	16,507	1,836	-1,211

** Misclassified case.

9.13 pav. Klasifikavimo lentelės

Lentelėje (žr. 9.13 pav.) spausdinami kiekvieno stebėjimų vektoriaus klasifikavimo rezultatai: tikroji grupė, grupė, kuriai buvo priskirtas atitinkamas studentas, aposteriorinės tikimybės, sąlyginės tikimybės, Mahalanobio atstumas iki grupės centro ir kanoninių funkcijų reikšmės. Pavyzdžiui, 1-as studentas, kurio duomenų vektorius yra (69; 41; 6,5) yra iš 1-os grupės (žr. stulpelį Actual group), t. y. bankas jį jau yra įtraukęs į juoduosius sąrašus. Taikant klasifikavimo taisykles, jis klasifikuotas taip pat į 1-ą grupę (bingo! žr. stulpelį Predicted Group). Aposteriorinė tikimybė, kad jis priklauso 1-ai grupei, lygi 1 (oho, jokių abejonių! žr. stulpelį $P(G = g|D = d)$). Sąlyginės tikimybės įvertis (kokios dalies nepatikimųjų duomenys panašūs) pateikiamas stulpelyje $P(D > d|G = g)$ ir yra lygus 0,860. Mahalanobio atstumas iki 1-os grupės centro pateikiamas stulpelyje Squared Mahalanobis Distance to Centroid. Stulpelių rinkinyje Second Highest Group pateikiama informacija apie studento galimybes būti įtrauktam į 3-ą grupę (deja, galimybės nulinės). Stulpeliuose Function 1 ir Function 2 pateikiamos stebėjimų vektorių kanoninių funkcijų reikšmės.

Lentelėje *Classification Results* (žr. 9.14 pav.) pateikiami „mokymo imties“, t. y. banko turimų duomenų klasifikavimo, rezultatai. Matome, kad 88,9% anksčiau paskolas gavusių studentų klasifikuota teisingai. Tačiau, jei 1-os grupės studentai klasifikuoti 100% tikslumu, tai 3-os grupės tik 71,4% tikslumu (5 iš 7). Ar šie rezultatai geresni už paprasčiausią atsitiktinį klasifikavimą? Nepamirškime, kad apriorinės tikimybės laikomos lygiomis. Atsitiktinai klasifikuodami objektus (mūsų atveju – studentus), galime tikėtis 33% tikslumo kiekvienai grupei. Taigi 3-ai grupei priklausančių objektų klasifikavimas yra pakankamai geras.

CLASSIFICATION RESULTS ^{b,c}						
KATEGOR			Predicted Group Membership			Total
			1	2	3	
Original	Count	1	16	0	0	16
		2	0	11	2	13
		3	0	2	5	7
	%	1	100,0	,0	,0	100,0
		2	,0	84,6	15,4	100,0
		3	,0	28,6	71,4	100,0
Cross-validated ^a	Count	1	16	0	0	16
		2	0	10	3	13
		3	0	2	5	7
	%	1	100,0	,0	,0	100,0
		2	,0	76,9	23,1	100,0
		3	,0	28,6	71,4	100,0

^a. Cross validation is done only for those cases in the analysis. In cross validation, each case is classified by the functions derived from all cases other than that case.

^b. 88,9% of original grouped cases correctly classified.

^c. 86,1% of cross-validated grouped cases correctly classified.

9.14 pav. Klasifikavimo lentelės

Eilutėje Cross-validated pateikiami klasifikavimo rezultatai naudojantis Lachenbruch procedūra. Jei šie rezultatai būtų daug prastesni už ankstesnius, tai reikštų, kad yra diskriminavimo kintamųjų perteklius. Matome, kad 9.3 pavyzdžio patikimų studentų atpažinimas suprastėjo palyginti nedaug – nuo 84,6% iki 76,9%. Todėl darome išvadą, kad bankas gali gana patikimai atpažinti, ar studentas bus tinkamas klientas.



grupių centrai	klasifikavimo funkcija	struktūrinis koeficientas
kanoninė funkcija	standartizuotasis koeficientas	Vilkso Λ

UŽDAVINIAI

1. Psichologas nori nustatyti, ar galima pagal trijų testų rezultatus atskirti lietuvių nuo latvio ir esto. Pirmasis testas „Jūra“ atspindėjo savęs, kaip jūrų valstybės atstovo, suvokimą. Antrasis testas „Sportas“ skirtas sporto fanatizmui išmatuoti. Trečiasis „Kaimynai“ – respondentų nuomonei apie likusias Baltijos tautas. Rezultatai pateikti 9.3 lentelėje (grafoje „Tautybė“ lietuviai pažymėti 1, latviai – 2, estai – 3). Ar pagal testo rezultatus galima nustatyti respondento tautybę?

9.3 lentelė. Baltijos tautų duomenys

Tautybė	1	1	1	1	2	1	2	1	2	3	2	2	2	1	2	1	2	1	1
1 testas	27	19	37	27	101	29	109	27	99	77	101	25	119	23	121	29	121	107	105
2 testas	83	86	88	86	77	84	81	92	72	77	86	84	80	83	82	82	80	81	82
3 testas	61	57	62	61	69	65	75	66	71	69	83	73	70	55	83	61	88	60	59

Tautybė	3	3	3	1	1	2	1	2	1	1	2	1	2	1	2	3	3	3	3
1 testas	107	93	81	29	29	119	27	103	27	23	95	27	111	29	99	105	93	83	81
2 testas	79	78	78	88	85	83	84	80	80	90	78	82	84	84	75	77	78	78	79
3 testas	73	72	68	62	63	74	57	78	59	69	73	57	74	63	68	72	74	68	70

2. Lentelėje pateikti 2001 metų II ketvirčio 15 Lietuvos įmonių finansiniai rodikliai.

Pavadinimas	X_1	X_2	X_3	X_4	X_5	X_6
1 Naftos terminalas	2,95	3,66	220,35	36,87	0,01	77,96
2 Invalda	8,57	8,67	38,82	23,27	0,22	86,35
3 Klaipėdos nafta	3,52	6,54	14,69	35,08	0,24	1,17
4 Stumbras	9,64	10,37	14,62	35,99	0,66	13,37
5 Utenos trikotažas	19,02	22,82	12,10	26,77	1,57	5,62
6 Ekranas	12,97	20,21	11,59	25,98	1,12	1,83
7 Klaipėdos baldai	18,79	27,99	10,84	31,46	1,73	2,21
8 Lietuvos energija	5,49	7,89	10,02	13,02	0,55	2,39
9 Alita	4,10	5,04	6,83	31,82	0,60	4,36
10 Vilniaus Vingis	6,41	9,24	4,45	20,62	1,44	2,29
11 Pieno žvaigždės	10,19	15,28	4,33	19,24	2,35	2,01
12 Žemaitijos pienas	6,30	11,07	4,19	18,19	1,50	1,32
13 Kalnapilis	2,31	2,80	4,12	37,55	0,56	5,04
14 Snaigė	5,97	12,30	3,85	11,81	1,55	1,26
15 Grafobal Vilnius	4,59	10,35	2,98	25,86	1,54	0,81
16 Sanitas	1,31	1,52	2,89	28,17	0,46	23,28
17 Šiaulių stumbras	2,74	4,45	2,71	20,70	1,01	1,62
18 Lietuvos dujos	1,46	3,30	2,35	12,66	0,62	0,82

Čia:

X_1 – turto grąža;

X_2 – nuosavo kapitalo pelningumas;

X_3 – grynojo pelno marža;

X_4 – bendrojo pelno marža;

X_5 – turto apyvartumas;

X_6 – bendrasis mokumas.

Pasinaudoję pirmųjų 15 įmonių duomenimis, klasterinės analizės metodais sudarykite 3 įmonių grupes. Po to suklasifikuokite 16, 17, 18 įmones.

10. FAKTORINĖ ANALIZĖ



Netikėk tuo, ką teigia statistika, tol, kol kruopščiai neapgalvojai, ko ji neteigia.

V. V. Vatas

Surinko doktorantas (psichologas, sociologas, edukologas, medikas) daug daug duomenų. Ir taip tiria, ir kitaip. Ir vienokius statistinius metodus taiko, ir kitokius. Rezultatų gausybė, o kolegos vis tiek gąsdina, kad be faktorinės analizės „bus šakės“ – neapsigins. Doktorantas visai nenori, kad jam taip atsitiktų, todėl puola ieškoti statistiko. Suradęs prašo padaryti faktorinę analizę. „Mielai“ – sako statistikas. – „O jūs žinote, kas tai yra?“. To, tiesą sakant, doktorantas nežino, bet puikiai žino, kad be faktorinės jam gynime bus... „Mmm“, – sako statistikas. – „Gal iš pradžių aš jums truputėlį apie faktorinę analizę papasakosiu.“

Tai, ką trumpai apie faktorinę analizę (šiukštu, nepainiokite su vienfaktorine *dispersine* analize) galėtų papasakoti statistikas, ir rasite šiame skyriuje. Ko gero, doktorantams praverstų paskaityti šį skyrių *prieš* kreipiantis į statistiką.


10.1. Faktorinė analizės tikslai ir etapai



Kad suprastume Viešpaties mintis, turime studijuoti statistiką, nes tai yra Jo tikslų matas.

F. Naitingel

Išsivaizduokime marionečių teatrą. Tarkime, mūsų užduotis – charakterizuoti lėlininkus. Pačių lėlininkų nematome ir net nežinome, kiek jų yra, o stebime tik jų valdomas lėles. Nustatę, mūsų nuomone, vieno lėlininko valdomas lėles, sprendžiame, ką iš jų elgesio galima pasakyti apie patį lėlininką (nervingas ar ramus, tikęs ar netikęs aktorius ir pan.).



Panašių situacijų dažnai pasitaiko ir statistiniuose tyrimuose. Pavyzdžiui, stebime, kaip respondentai sprendžia uždavinius, pasirenka paveikslėlių seką, komponuoja kubelius, aiškina žodžius ir pan., o manome, kad visi atsakymai priklauso nuo tam tikrų

betarpiškai neišmatuojamų faktorių, pavyzdžiui, respondento kūrybiškumo, matematinių gabumų, erdvinės vaizduotės ir pan. Faktorinė analizė turi padėti šiuos faktorius nustatyti.

Griežčiau faktorinės analizės idėją galima nusakyti taip: atsižvelgdami į tarpusavio koreliacijas, stebimus kintamuosius suskirstome į grupes. Manome, kad kiekvienos grupės kintamuosius vienija koks nors tiesiogiai nestebimas (latentinis) faktorius. Koks tas faktorius, sprendžiame patys nagrinėdami grupes sudarančius kintamuosius.

Kartais tyrėjas kintamuosius sugrupuoja ir latentinius faktorius įvardija *prieš* pradėdamas tyrimą. Pavyzdžiui, psichologas E. Linksmaitis sudaro klausimyną žmogaus lyderio savybėms matuoti, o klausimyne yra dvi dalys: viena – dalykiniams gebėjimams nustatyti ir kita – bendravimo gebėjimams įvertinti. Dalykiniai gebėjimai, bendravimo gebėjimai – tai du betarpiškai neišmatuojami faktoriai, kuriuos E. Linksmaitis įvardijo prieš tyrimą. Remdamasis sveiku protu ar psichologijos teorija (o greičiausiai ir vienu, ir kitu), prieš tyrimą jis pats nusprendžia, kokie klausimai šiuos faktorius turėtų atskleisti. Faktorinė analizė šiuo atveju psichologo pasirinkimą gali tik patvirtinti arba nepatvirtinti. Tai vadinamoji *patvirtinančioji* faktorinė analizė. Ji šioje knygoje nenagrinėjama.

Šiame skyriuje mes aprašysime *tiriančiosios* faktorinės analizės metodus. Dėl paprastumo toliau žodį *tiriančioji* praleisime. Prieš taikydami šią faktorinę analizę, nežinome, nei kiek bus faktorių, nei kokie kintamieji sudarys juos paaiškinančias grupes. Tarkime, norima sužinoti politikų reitingą. Respondentai rašo pažymius keliolikai politikų. Kai kurių pažiūrų respondentas geriau vertina kairiuosius politikus, dešiniųjų – dešiniuosius ir pan. Aišku, kad vertinimai koreliuoja (gerai įvertinęs politiką L, blogai įvertins politiką B ir gerai politiką K). Faktorinėje analizėje pagal respondentų vertinimų koreliacijas politikai suskirstomi į kelias grupes. Tada sprendžiama, kas (koks faktorius) galėtų vienyti konkrečios grupės politikus. Kadangi visų politikų veikla žinoma, tai faktoriui pavadinimą suteikia *pats tyrėjas*, išanalizavęs grupės sudėtį. Pavyzdžiui, ištyręs vienos politikų grupės sudėtį, jis gali nuspręsti, kad visus vienija pažiūrų kairumas (faktorius – kairumas). Tačiau galbūt į grupę pakliūs tokie politikai, kad akivaizdus grupę vienijantis faktorius bus polinkis kandidatuoti į prezidentus arba aktyvus feminizmo idėjų rėmimas.

Aišku, kad faktorių pavadinimai labai priklauso ir nuo paties tyrėjo išsilavinimo – tai, ką vienas įvardys kaip objekto – visumos suvokimą, kitas pavadins percepcine organizacija.

Ko siekiame taikydami faktorinę analizę? Sociologinių apklausų, medicininių tyrimų, psichologinių testų ir pan. rezultatai – dešimčių ir šimtų požymių matavimų aibės. Faktorinė analizė padeda didelio skaičiaus kintamųjų tarpusavio koreliacijas paaiškinti tam tikrų bendrųjų faktorių įtaka. Nuo kintamųjų pereidami prie faktorių kondensuojame informaciją, padarome ją labiau aprėpiamą. Būtent dėl to faktorinė analizė dažnai taikoma kartu su kitais daugiamatės statistikos metodais (pavyzdžiui, latentinių faktorių reikšmių įverčiai gali būti naudojami kaip pradinių duomenų pakaitalas klasterinėje ar regresinėje analizėje).

Kita vertus, dažnai susiduriame su sąvokomis, kurios neturi kiekybinio mato. Kas yra kūrybiškumas, meilė, altruizmas, lyderiavimas? Skirtingai nei svorio, temperatūros, kraujo spaudimo, šių dydžių negalima betarpiškai išmatuoti. Šias sąvokas galime įsivaizduoti kaip atitinkamas požymių grupes „vienijančias konstrukcijas“ – bendruosius faktorius. Faktorinė analizė taikoma jiems tirti.

Faktorinės analizės tikslas – minimaliai prarandant informacijos pakeisti stebimą reiškinį charakterizuojančių požymių aibę kelių faktorių rinkiniu.



Terminą „faktorinė analizė“ pirmasis 1931 metais savo darbe pavartojo L. L. Terstounas (L. L. Thurstone, 1887–1955). Tačiau pačią faktorinės analizės idėją pirmasis iškėlė Č. Spirmanas 1904 metų straipsnyje „Bendrosios žinios apie objektyvius sprendimus ir matavimus“.

Natūralu, kad faktoriaus galima ieškoti grupuojant ne tik požymius (kintamuosius, klausimus), bet ir objektus (respondentus). Pirmuoju atveju turime vadinamąją R duomenų analizę, antruoju – Q analizę. Q analizė labai artima klasterinei analizei (žr. 8 skyrių). Praktiškai daugiausia taikoma R analizė – ji šiame skyriuje ir aptariama.

Faktorinė analizė – gana sudėtinga ir prieštaringa daugiamatės statistinės analizės dalis, nes:

- a) ne visada latentiniai faktoriai realiai egzistuoja ir ne visada patikimai pagal turimus duomenis juos galima išskirti;
- b) tiems patiems duomenims taikydami skirtingus faktorinės analizės metodus, gauname keletą galimų faktorių rinkinių;
- c) išskirtieji faktoriai ne visada lengvai interpretuojami.

Tipinė faktorinė analizė „pasufleruoja“ atsakymus į tokius klausimus:

- 1) kiek latentinių faktorių paaiškina tiriamų kintamųjų priklausomybės struktūra;
- 2) kokie tie faktoriai;
- 3) kaip gerai faktoriai paaiškina duomenis.

Faktorių skaičių, faktorinės analizės metodą ir faktorių pavadinimus pasirenka pats tyrėjas, todėl ir sakome, kad faktorinė analizė atsakymus tik „pasufleruoja“. Taigi faktorinė analizė visada suteikia galimybes diskutuoti, ir statistikas siūlomų interpretacijų negali nuginčyti – tai paliekama tiriamosios srities specialistams¹. Tačiau statistikas gali nustatyti, ar duomenims iš viso taikytina faktorinė analizė.

Faktorinės analizės etapai:

- 1** Patikrinimas, ar duomenys faktorinei analizei tinka.
- 2** Faktorių išskyrimas – faktorių skaičiaus nustatymas bei faktorių skaičiavimo metodo parinkimas.
- 3** Faktorių sukimas ir interpretavimas.
- 4** Faktorių reikšmių įverčių skaičiavimas.

Kiekvieną iš šių etapų aprašysime išsamiau. Norėdami geriau suprasti faktorinės analizės metodo parinkimo ypatybes, iš pradžių aptarsime faktorinės analizės matematinį modelį.

¹ Atlikta faktorinė analizė doktoranto gali ir neišgelbėti, jei jis gautus faktorius pavadins kitaip, nei oponentai tikisi.

10.2. Matematinis modelis



Modeliai yra skirti naudoti, o ne tam, kad jais tikėtume.

H. Teilas

Tarkime, stebime k kintamųjų $X_1, X_2, \dots, X_k$. Modelis grindžiamas prielaida, kad kiekvieno kintamojo X_i elgesį sąlygoja m bendrųjų latentinių faktorių $F_1, F_2, \dots, F_m$ ir specifinis (charakteringasis) latentinis faktorius e_i . Bendrųjų faktorių yra *mažiau* nei kintamųjų, t. y. $m < k$. Tegul kintamasis X_i nuo faktorių priklauso tiesiškai. Matematinio modelio išraiška yra tokia:

$$X_1 = \lambda_{11}F_1 + \lambda_{12}F_2 + \dots + \lambda_{1m}F_m + e_1 = \sum_{j=1}^m \lambda_{1j}F_j + e_1,$$

$$X_2 = \lambda_{21}F_1 + \lambda_{22}F_2 + \dots + \lambda_{2m}F_m + e_2 = \sum_{j=1}^m \lambda_{2j}F_j + e_2,$$

.....

$$X_k = \lambda_{k1}F_1 + \lambda_{k2}F_2 + \dots + \lambda_{km}F_m + e_k = \sum_{j=1}^m \lambda_{kj}F_j + e_k.$$

Daugikliai λ_{ij} vadinami *faktorių svoriais*.

Išoriškai faktorinės analizės modelis labai primena tiesinę regresiją – žinodami F_i ir λ_{ij} reikšmes, galėtume apytiksliai prognozuoti X_i reikšmes. Tačiau faktorinės analizės uždavinys yra atvirkštinis – žinome tik X_i reikšmes, o norime išsiaiškinti, ką galima pasakyti apie bendruosius faktorius F_i .

Faktorinės analizės modelio prielaidos:

- a) stebimi kintamieji pasiskirstę pagal normalųjį dėsnį, t. y. $X_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$;
- b) bendrieji faktoriai F_j nekoreliuoti ir $\mathbf{D}F_j = 1$;
- c) charakteringieji faktoriai e_i nekoreliuoti ir $\mathbf{D}e_i = \tau_i$;
- d) faktoriai F_j ir e_i nekoreliuoti, čia $i = 1, \dots, k$, $j = 1, \dots, m$.

Panagrinėkime šio modelio savybes. Atsižvelgus į prielaidas, stebimų kintamųjų dispersijas ir kovariacijas galima užrašyti taip:

$$\text{cov}(X_i, X_j) = \lambda_{i1}\lambda_{j1} + \dots + \lambda_{im}\lambda_{jm}, \quad i \neq j,$$

$$\mathbf{D}X_i = \sigma_i^2 = \lambda_{i1}^2 + \dots + \lambda_{im}^2 + \tau_i = h_i^2 + \tau_i, \quad i = 1, \dots, k;$$

$$\text{cov}(X_i, F_j) = \lambda_{ij}, \quad i = 1, \dots, k; \quad j = 1, \dots, m.$$

Dydis $h_i^2 = \sum_{j=1}^m \lambda_{ij}^2$ vadinamas kintamojo X_i *bendrumu*, o dydis τ_i – *specifiškumu* (specifine dispersija).

Matome, kad faktorinės analizės modelyje kiekvieno pradinio kintamojo X_i dispersija skaidoma į dvi dalis – dispersiją, kurią sąlygoja latentiniai bendrieji faktoriai $F_1, \dots, F_m$

(bendrumą h_i^2), ir dispersiją, kurią lemia bendraisiais faktoriais nepaaiškinama paties kintamojo variacija (specifiškumas τ_i).

Matrica, kurios elementai a_{ij} yra $\text{cov}(X_i, X_j)$, $i \neq j$, o pagrindinėje įstrižainėje yra bendrumai h_i^2 , vadinama *redukuotąja* kovariacijų matrica.

Redukuotosios ir pradinės kovariacijų matricų skirtingumas yra indikatorius, rodantis, ar pakankamas bendrųjų faktorių skaičius (m parinkimo problema) ir ar korektiškas skaičiavimo metodas. Iš tiesų redukuotoji matrica rodo, ar bendrieji faktoriai gerai atskleidžia pradinių kintamųjų priklausomybės struktūrą (t.y. kiek tikroji priklausomybės struktūra gali būti atgaminta naudojantis tik bendraisiais faktoriais ir kiek informacijos apie pradinius kintamuosius prarandame). Kuo didesnis h_i^2 , palyginti su σ_i^2 , tuo daugiau informacijos apie kintamąjį išsaugome nuo pradinių kintamųjų pereidami prie bendrųjų faktorių. Jeigu visi specifiniai faktoriai $e_i = 0$, tai redukuotoji kovariacijų matrica sutampa su pradine ir bendrieji faktoriai F_i išsaugo visą informaciją apie kintamuosius X_i .


Matematinė faktorinės analizės užduotis yra rasti:


- faktorių svorių λ_{ij} bei specifinių dispersijų τ_i , $i = 1, \dots, k$, $j = 1, \dots, m$, įverčius;
- kiekvieno kintamųjų X_i stebėjimų rinkinio latentinių bendrųjų faktorių $F_1, \dots, F_m$ reikšmių įverčius.

Svorių įverčių reikia patiems faktoriams įvardyti (žr. 10.5 skyrelį).

Bendroji faktorinės analizės metodų klasifikacija pateikta 10.1 paveiksle.

Nepaisant didelės faktorinės analizės metodų įvairovės, galima išskirti bendrąjį skaičiavimo algoritmą. Tarkime, turime pradinių duomenų matricą $\mathcal{X}$. Iš pradžių randame kovariacijų matricą $\mathcal{S}$ arba koreliacinę matricą $\mathcal{R}$. Dėl paprastumo duomenis rekomenduojama standartizuoti (naudoti z -reikšmes, t.y. $z_{ij} = (x_{ij} - \bar{x}_j)/s_j$) ir skaičiavimams naudoti koreliacijų matricą (standartizuotų duomenų kovariacijos ir koreliacijos sutampa!). Standartizuotų duomenų $\sigma_i^2 = 1$, todėl itin palengvėja h_i^2 įverčio interpretacija. Po to skaičiuojama redukuota koreliacijų (kovariacijų) matrica. Tada randami faktorių svorių





įverčiai. Paskutiniai du etapai – faktorių svorių matricos sukimas ir faktorių reikšmių įverčių skaičiavimas. Algoritmo schema pateikta 10.2 paveiksle.

Būtent faktorinės analizės metodams ir rezultatų interpretavimui skiriami tolesni skyriai. Šiame skyriuje išsamiau aprašysime tik pagrindinių komponentių metodą. Griežtai matematiškai kalbant, pagrindinių komponentių metodas nėra faktorinės analizės dalis. Tačiau šį metodą suvokus, kur kas lengviau suprasti faktorinę analizę. Šiuo metu faktorinėje analizėje bendrieji faktoriai dažniausiai nustatomi naudojantis pagrindinių komponentių analize.

10.3. Duomenų tikimas faktorinei analizei



Statistikas – tai žmogus, išsiskiriantis neįtikėtinais gabumais pateikti be galo daug įvairių skaičių, gautų remiantis miglotomis prielaidomis, grįstomis abejotiniais įrodymais, naudojant nereprezentatyvią imtį, siekiant vienintelio tikslo – susukti galvas ir taip jau nieko nebesuprantantiems žmonėms, kurie niekada nestudijavo statistikos.

Taikydami faktorinę analizę, ieškome stebimų kintamųjų panašumų. Suprantama, jei kintamieji nekoreliuoti, tai ir panašumų nėra. Todėl nekoreliuotiems kintamiesiems faktorinė analizė neturi prasmės. Taigi visų pirma turime įsitikinti, ar stebimi kintamieji tarpusavyje koreliuoja.

Pradiniai faktorinės analizės duomenys – stebėjimų koreliacijų (arba kovariacijų) matrica. Iš jos pavidalo matyti, kurie kintamieji yra nepriklausomi nuo likusiųjų. Šie kintamieji negrupuojami, t. y. faktiškai sudaro atskirus faktorius. Todėl juos iš faktorinės analizės pradinių kintamųjų sąrašo verta pašalinti.

Ar iš viso tarp stebimų kintamųjų yra statistiškai reikšmingai koreliuojančių, padeda nustatyti Bartleto sferiškumo kriterijus. Juo naudojantis, tikrinama hipotezė, kad koreliacijų matrica yra vienetinė, t. y. visi stebimi kintamieji yra nekoreliuoti. Vadinasi, jei turimiems duomenims hipotezė priimama, faktorinė analizė neturi prasmės.

Jeigu taikant Bartleto sferiškumo kriterijų p -reikšmė $p \geq \alpha$, tai turimiems duomenims faktorinė analizė netaikytina; čia α – pasirinktas reikšmingumo lygmuo.

Ar kintamieji (kartu ir duomenys) tinka faktorinei analizei, įvertina Kaizerio–Mejerio–Olkinio¹ (KMO) matas. Šis matas – empirinių koreliacijos koeficientų didumų ir dalinių koreliacijos koeficientų didumų palyginamasis indeksas. Jis skaičiuojamas pagal formulę

$$KMO = \frac{\sum \sum_{i \neq j} r_{ij}}{\sum \sum_{i \neq j} r_{ij} + \sum \sum_{i \neq j} \tilde{r}_{ij}}; \quad (1)$$

čia r_{ij} – kintamųjų X_i ir X_j koreliacijos koeficientas; $\tilde{r}_{ij}$ – X_i ir X_j dalinės koreliacijos koeficientas. Jei KMO mato reikšmė maža, tai nagrinėjamų kintamųjų faktorinė analizė nerezultatyvi. Iš tiesų maža KMO mato reikšmė rodo, kad kintamųjų porų koreliacija nėra paaiškinama kitais kintamaisiais.

Naudojama tokia KMO reikšmių gradacija iš akies: $0,9 < KMO$ – faktorinė analizė puikiai tinka; $0,8 < KMO \leq 0,9$ – gerai tinka; $0,7 < KMO \leq 0,8$ – tinka patenkinamai; $0,6 < KMO \leq 0,7$ – tinka pakenčiamai; $0,5 < KMO \leq 0,6$ – tinka blogai; $KMO < 0,5$ – faktorinė analizė nepriimtina.

Kiekvieno kintamojo stebėjimų tinkamumo matą galima apskaičiuoti pagal formulę

$$MSA_i = \frac{\sum_{j \neq i} r_{ij}}{\sum_{j \neq i} r_{ij} + \sum_{j \neq i} \tilde{r}_{ij}}. \quad (2)$$

Kintamuosius, kuriems MSA_i reikšmėms mažos, verta iš faktorinės analizės pašalinti.

10.1 pavyzdys. Reklamos agentūra, norėdama sužinoti, kokioms naujojo produkto „Auksinė žuvelė“ charakteristikoms pirkėjas teikia pirmenybę, atliko tyrimą. 50 pirkėjų pagal 7 balų skalę turėjo įvertinti tokias charakteristikas: skonį (SKN), aromatą (ARM), energetinę vertę (ENV), gerą kainą (KAI), tinkamumą užkandai ($UŽK$). Duomenų koreliacijų matrica pateikta 10.1 lentelėje. Kokie bendrieji faktoriai lemia pirkėjų pasirinkimą?

Iš pradžių patikrinkime, ar faktorinei analizei duomenys tinka. SPSS paketu gauta KMO reikšmė bei Bartleto sferiškumo kriterijaus rezultatai parodyti 10.3 paveiksle. Tarkime, kad pasirinkome reikšmingumo lygmenį $\alpha = 0,05$. Bartleto sferiškumo kriterijaus p -reikšmė $p < 0,05$, t. y. kintamieji nėra nepriklausomi. Kadangi ir $KMO = 0,606$ – duomenų aibė pakenčiamai tinka faktorinei analizei. Atsakymą į klausimą, kokie bendrieji faktoriai lemia pirkėjų pasirinkimą, pateiksime tolesniuose skyreliuose.

10.1 lentelė

	Skn	Arm	Env	Kai	Užk
Skn	1	0,46	0,14	0,07	0,18
Arm	0,46	1	0,12	0,19	0,16
Env	0,14	0,12	1	0,25	0,44
Kai	0,07	0,19	0,25	1	0,39
Užk	0,18	0,16	0,44	0,39	1

¹ H. F. Kaiser, D. Meyer, I. Olkin – amerikiečių statistikai.

KMO AND BARTLETT'S TEST		
Kaiser-Meyer-Olkin Measure of Sampling Adequacy		,606
Bartlett's Test of Sphericity	Approx. Chi-Square	32,438
	df	10
	Sig.	,000

10.3 pav. 10.1 pavyzdžio KMO matas ir Bartleto kriterijus

10.4. Faktorių išskyrimas



Dydis, kurio negalima tiesiogiai stebėti ir kuris nieko nepaaiškina, mums neįdomus.

A. Ejeris

Čia aprašysime vieną iš dažniausiai naudojamų faktorių išskyrimo metodų, kai normuojamos pagrindinės komponentės. Šis metodas grindžiamas *pagrindinių komponentių analize*. Tikimės, kad detalesnis vieno metodo aprašymas leis geriau suvokti visos faktorinės analizės esmę. Visur toliau duomenis laikysime tinkamais faktorinei analizei.

Kokia yra pagrindinių komponentių analizės esmė ir kaip ši analizė susijusi su faktorių išskyrimu?

Tarkime, turime k kintamųjų $X_1, X_2, \dots, X_k$. Daugelio kintamųjų tarpusavio priklausomybė vadinama *priklausomybės struktūra* ir gali būti išmatuota (įvertinta) jų koreliacijomis arba kovariacijomis bei dispersijomis.

Taikant pagrindinių komponentių analizę, randamos tarpusavyje nekoreliuojančios kintamųjų $X_1, \dots, X_k$ tiesinės daugdaros $Y_1, Y_2, \dots, Y_k$. Šios tiesinės daugdaros vadinamos pagrindinėmis komponentėmis. Vaizdžiai kalbant, jos turi tiek pat informacijos apie kintamuosius, kiek ir pradiniai duomenys. Kartais kintamųjų $X_1, X_2, \dots, X_k$ priklausomybės struktūrai gerai aprašyti užtenka *dalis* pagrindinių komponentių. Sunormavus jas siūloma laikyti nežinomais bendraisiais faktoriais.



Pageidautina, kad pradinių kintamųjų bendrasis skirstinys būtų daugiamatis normalusis. Tuo atveju normaliųjų kintamųjų tiesinės daugdaros taip pat turi normalųjį skirstinį ir apibrėžiamos vidurkiais ir dispersijomis. Jei visi vidurkiai būtų lygūs nuliui, tai bendroji kovariacijų matrica visiškai identifikuotų kintamųjų $X_1, \dots, X_k$ skirstinį.

Pagrindinių komponentių analizės uždavinį suformuluosime tiksliau. Pagrindinių komponentių analizės esmė – ieškomos pradinių kintamųjų tiesinės daugdaros

$$Y_1 = \sum_{j=1}^k \alpha_{1j} X_j, \quad \dots, \quad Y_k = \sum_{j=1}^k \alpha_{kj} X_j,$$

tenkinančios sąlygas:

- 1) $\text{cov}(Y_i, Y_j) = 0, \quad i, j = 1, \dots, k, i \neq j,$
- 2) $\mathbf{D}Y_1 \geq \mathbf{D}Y_2 \geq \dots \geq \mathbf{D}Y_k,$

$$3) \quad \sum_{i=1}^k \mathbf{D}Y_i = \sum_{i=1}^k \mathbf{D}X_i.$$

Iš formulių matyti, kad kintamieji $Y_1, Y_2, \dots, Y_k$ nekoreliuoti ir išdėstyti dispersijų mažėjimo tvarka. Be to, jų dispersijų suma lygi pradinių kintamųjų dispersijų sumai. Pažymėkime šią sumą simboliu D .

Pastaba. Jeigu analizei naudotume standartizuotąsias kintamųjų reikšmes (z -reikšmes), tai visos dispersijos būtų vienetinės, t. y. $\mathbf{D}X_i = 1$, o bendroji dispersijų suma sutaptų su kintamųjų skaičiumi, t. y. būtų $D = k$. Būtent standartizuotųjų reikšmių pagrindinių komponentių analizė realizuota daugelyje programinių paketų.

Matome, kad pagrindinių komponentių paieška – tai koeficientų α_{ij} , $i, j = 1, \dots, k$, ieškojimas. Trumpas pagrindinių komponentių išskyrimo algoritmas yra toks.

Tarkime, $Y_1 = \alpha_{11}X_1 + \dots + \alpha_{1k}X_k$. Iš pradžių ieškoma $\alpha_{11}, \dots, \alpha_{1k}$, maksimizuojančių

$$\mathbf{D}Y_1 = \sum_{i=1}^k \sum_{j=1}^k \alpha_{1i} \alpha_{1j} \sigma_{ij}^2,$$

su sąlyga, kad $\sum_{j=1}^k \alpha_{1j}^2 = 1$ (šios sąlygos reikia, kad gautume vienintelį sprendinį); čia $\sigma_{ij}^2 = \text{cov}(X_i, X_j)$. Taikant matricų algebros operacijas, galima įrodyti, kad šio uždavinio sprendinys $\alpha_1 = (\alpha_{11}, \dots, \alpha_{1k})$ yra pradinių kintamųjų kovariacijų matricos S *tikrinis vektorius* ir atitinka maksimalią matricos S *tikrinę reikšmę*. Ši tikrinė reikšmė lygi $\mathbf{D}Y_1$. Taip gauta tiesinė daugdara $Y_1 = \alpha_{11}X_1 + \dots + \alpha_{1k}X_k$ vadinama kintamųjų $X_1, \dots, X_k$ pirmąja *pagrindine komponente*. Ji paaiškina $100 \cdot \mathbf{D}Y_1 / D$ procentų bendrosios dispersijos. Analogiškai apskaičiuojama $Y_2 = \alpha_{21}X_1 + \dots + \alpha_{2k}X_k$ – antroji *pagrindinė komponentė*, paaiškinanti $100 \cdot \mathbf{D}Y_2 / D$ procentų bendrosios dispersijos, ir t. t.

Jei pradinių kintamųjų vidurkiai bei kovariacijos nežinomos, pagrindinėms komponentėms skaičiuoti naudojamos atitinkamos empirinės charakteristikos. Tuo atveju sprendinį žymėsime $a_{i1}, a_{i2}, \dots, a_{ik}$.

Bendroji kintamųjų dispersija suteikia informacijos apie jų reikšmių sklaidą. Vaizdžiai tariant, kuo daugiau bendrosios kintamųjų dispersijos paaiškina pagrindinė komponentė, tuo daugiau informacijos apie kintamųjų elgesį joje išlieka. Galima sakyti, kad paaiškintas bendrosios dispersijos procentas lemia pagrindinės komponentės svarbą. Pavyzdžiui, jei komponentė paaiškina 95% bendrosios dispersijos, ji yra labai svarbi ir dažniausiai interpretuojama taip: vietoje (daugelio) pradinių kintamųjų $X_1, \dots, X_k$ palikdami šią (vieną) pagrindinę komponentę, išlaikysime 95% informacijos apie pradinių kintamųjų elgesį (įgyjamų reikšmių sklaidą). Visos pagrindinės komponentės paaiškina visą bendrąją kintamųjų dispersiją (žr. 3 savybę). Pagrindinių komponentių yra tiek, kiek ir pradinių kintamųjų (po k), tačiau jų svarba skirtinga (žr. 2 savybę). Pirmosios m komponentių $Y_1, \dots, Y_m$ paaiškina didžiąją dalį bendrosios dispersijos, t. y. glaustai ir gana tiksliai aprašo pradinių kintamųjų priklausomybės struktūrą, todėl gali būti panaudotos bendriesiems faktoriams skaičiuoti.

Pagrindines komponentes sudaro pradinių kintamųjų tiesinės daugdaros, taigi jų interpretacija dažniausiai skiriasi nuo pradinių kintamųjų interpretacijos. Kaip interpretuoti pagrindines komponentes? Kas yra kovariacijų matricos tikrinės reikšmės ir tikriniai vektoriai? Kokia jų prasmė? Visa tai pabandysime paaiškinti pavyzdžiu.



10.2 pavyzdys. Tarkime, turime 10-ties tos pačios rūšies žuvų ilgio ir pločio matavimus. Duomenys pateikti 10.2 lentelėje ir 10.4 paveiksle. Mūsų tikslas – „koncentruotai“ užrašyti duomenų priklausomybės struktūrą.

10.2 lentelė. Žuvų matmenys

Ilgis	8,8	12,1	14	10,2	15	10	11	16	4,3	10,5
Plotis	2,5	3	3,5	4	5	4,5	2	5,5	1	1,5

Atlikime tokią grafiko transformaciją (ji nekeičia duomenų priklausomybės struktūros): ašis perstumkime taip, kad koordinatų pradžios taškas sutaptų su x (ilgio) ir y (pločio) vidurkiais, po to ašis sukime taip, kad viena iš jų atskleistų didžiausią duomenų variacijos dalį. Laikykime ją *pirmąja komponente* (žr. 10.5 pav., a) ir b)).

Kas yra pirmoji komponentė? Nesunku suprasti, kad tai žuvies didumas. Taigi pagrindinė ašis – didumas. Paprasčiausiu atveju $DIDUMAS = ILGIS + PLOTIS$, t. y. pirmoji komponentė yra stebimų kintamųjų, kurių svoriai vienodi, tiesinė daugdara. Tačiau vieną iš šių kintamųjų galime padaryti svarbesnį. Tarkime, kad sprendžiant apie didumą ilgis svarbesnis nei plotis. Šiuo atveju skirtingą įtaką galima fiksuoti naudojantis svoriais. Pavyzdžiui, tarti, kad $DIDUMAS = 0,75 \cdot ILGIS + 0,25 \cdot PLOTIS$. Sakykime, kad ilgis ir plotis yra standartizuoti (vidurkiai 0, dispersijos 1). Tada galime padaryti išvadą, kad didumui ilgis yra tris kartus svarbesnis už plotį. Jei abu koeficientai būtų lygūs 0,5, jų svarba didumui būtų vienoda. Jei kintamieji yra nestandartizuoti, tai jų įtaką didumui įvertinti kur kas sunkiau – koeficientų reikšmės priklauso nuo ilgio ir



pločio matavimų skalių. Dabar dėl patogumo perbraižykime grafiką taip, kad x ašis būtų horizontali (žr. 10.5 pav., c)). Ką galima pasakyti apie y ašį (antrąją pagrindinę komponentę)? Pagrindinis kriterijus – ji turi atskleisti kiek galima daugiau liekamosios dispersijos (t. y. bendrosios dispersijos, kurios nepaaiškina pirmoji pagrindinė komponentė). Tačiau tuo pat metu turi būti ortogonalai pirmajai ašiai (pagrindinės komponentės turi nekoreliuoti). Dvimačiu atveju tai gana paprastas uždavinys.

Norėdami įvardyti antrąją komponentę, turime nuspręsti, kuo, be didumo, dar skiriasi piešinio žuvis? Matyt, natūralus atsakymas būtų – forma. Taigi antroji ašis (komponentė) parodo žuvies formą.

Nors pagrindinių komponentių (ašių) interpretacija pasikeitė (ilgi ir plotį pakeitė didumas ir forma), naujoji koordinatų sistema žuvis aprašo taip pat tiksliai kaip ankstesnioji. Tai atitiktų anksčiau minėtą teiginį, kad *visoje* pagrindinių komponentių aibėje išlieka visa pradinė informacija apie kintamuosius.

Norėdami išskirti bendruosius faktorius, turėtume pasirinkti tik dalį pagrindinių komponentių ir jas specialiai normuoti (normavimą aptarsime vėliau). Atsisakydami antrosios ašies (komponentės), prarastume informaciją apie formą. Tiriamos žuvis yra panašios formos, todėl informacijos prarasime ištis nedaug. Mūsų atveju galime redukuoti (sumažinti) požymių erdvę nuo dviejų (ilgis ir plotis) iki vieno (didumas), nedaug praradami informacijos apie tiriamas žuvis. Kaip netrukus pamatysime, prarandamą informaciją galima įvertinti kiekybiškai.

Nagrinėdami pavyzdį, grafiką transformavome iš akies. Pasitelkus duomenų koreliacijų matricą, galima matematiškai tiksliai nustatyti naujųjų ašių padėtį ir kryptis.

Bet iš pradžių aptarkime tikrinių reikšmių ir tikrinių vektorių sąvokas.

Tikrinių reikšmių ir tikrinių vektorių skaičiavimas yra matricų algebros operacijos; jos daugiamatėje statistinėje analizėje labai svarbios.

Sakome, kad kvadratinė matrica $\mathcal{V}$ turi tikrinę reikšmę λ , atitinkančią tikrinį vektorių $\vec{\alpha} \neq 0$, jeigu $\mathcal{V}\vec{\alpha} = \lambda\vec{\alpha}$.

Paprastai dar papildomai reikalaujama, kad tikrinio vektoriaus koordinatų kvadratų suma būtų lygi 1, t. y. $\sum_1^k \alpha_j^2 = 1$. Šios sąlygos reikia tam, kad tikrinę reikšmę atitiktų *vienintelis* tikrinis vektorius.


Apskaičiavę nagrinėto 10.2 pavyzdžio duomenų koreliacijų matricą, gauname

$$\mathcal{R} = \begin{pmatrix} 1 & 0,75 \\ 0,75 & 1 \end{pmatrix}.$$

Kvadratinų simetrinių matricų (koreliacijų ir kovariacijų matricos yra simetrinės) tikrinių reikšmių skaičius yra lygus matricos eilučių skaičiui. Nagrinėjamos matricos tikrinės reikšmės yra 1,75 ir 0,25, o atitinkami tikriniai vektoriai yra $(-0,707; 0,707)$ ir $(0,707; 0,707)$ (trijų ženklų po kablelio tikslumu).

Šie visi dydžiai grafiškai pavaizduoti 10.6 paveiksle, a). Koreliacijų matricos eilutės yra dviejų taškų a ir b koordinatės. Tikriniai vektoriai nustato elipsės, einančios per taškus a ir b , ašių kryptis, tikrinės reikšmės – ašių ilgius. Įvairių koreliacijos matricų brėžiniai parodyti 10.6 paveiksle, b) ir c).

Kokias išvadas „sufleruoja“ grafikai? Matome, kuo kintamieji (dvimatė koreliacijų matrica atitinka dviejų kintamųjų koreliaciją) stipriau koreliuoti, tuo didžioji elipsės ašis ilgesnė, o mažoji – trumpesnė. Ilgesnė ašis atitinka svarbesnę komponentę. Riba pasiekama, kai koreliacija lygi 1. Tuo atveju didžiosios ašies ilgis lygus 2, o mažosios – lygus 0, t. y. elipsė virsta atkarpa. Pagrindinių komponentių terminais, vienetinė koreliacija reikštų, kad visą informaciją apie pradinis kintamuosius suteikia pirmoji pagrindinė komponentė. Taigi 10.6 paveikslas leidžia vizualiai įvertinti pagrindinių komponentių svarbą ir pradinės informacijos kiekį, kurį prarastume atsisakydami antrosios komponentės.



Panagrinėkime 10.6 paveikslo a) grafiką. Prisiminkime, kad koreliacijų matricos tikrinių vektorių koordinatės yra pagrindinių komponentių koeficientai, o tikrinės reikšmės – komponentių dispersijos. Taigi iš grafiko galime padaryti tokią išvadą: pirmoji 10.2 pavyzdžio duomenų grafiko ašis (pirmoji pagrindinė komponentė – didumas) paaiškina (išsaugo) $(1,75/2) \cdot 100\% = 87,5\%$ bendrosios kintamųjų dispersijos, t. y. atsisakydami formos komponentės prarastume 12,5% informacijos apie kintamųjų įgyjamų reikšmių sklaidą.



Pateiksime detalesnę pagrindinių komponentių paieškos aprašymą. Dėl paprastumo tarkime, kad $\mathbf{E}X_j = 0$, $j = 1, \dots, k$ (nesunku taip kintamuosius centruoti). Tegul $Y_1 = \sum_{i=1}^k \alpha_{1i} X_i = \vec{\alpha}'_1 X$. Tada

$$\mathbf{D}Y_1 = \mathbf{E}Y_1^2 = \sum_{i=1}^k \sum_{j=1}^k \alpha_{1i} \alpha_{1j} \mathbf{E}X_i X_j = \vec{\alpha}'_1 \mathbf{S} \vec{\alpha}_1.$$

Vektorius $\vec{\alpha}_1$ parenkamas taip, kad dispersija $\mathbf{D}Y_1$ būtų maksimali, kai $\sum_{i=1}^k \alpha_{1i}^2 = \vec{\alpha}'_1 \vec{\alpha}_1 = 1$.

Ši optimizavimo uždavinį su apribojimais sprendžiame Lagranžo daugiklių metodu. Ieškomas vektorius $\vec{\alpha}_1$ maksimizuoja Lagranžo funkciją $\vec{\alpha}'_1 \mathbf{S} \vec{\alpha}_1 - \lambda_1 (\vec{\alpha}'_1 \vec{\alpha}_1 - 1)$; čia λ_1 yra Lagranžo daugiklis. Tegul I žymi vienetinę matricą. Tada λ_1 turi būti toks, kad matricos $(\mathbf{S} - \lambda_1 I)$ determinantas būtų lygus nuliui, t. y. λ_1 būtų $\mathbf{S}$ tikrinė reikšmė. Ją atitinkantis tikrinis vektorius randamas iš lygties $\mathbf{S} \vec{\alpha}_1 = \lambda_1 \vec{\alpha}_1$. Šios lygties kairiąją pusę padauginę iš transponuoto vektoriaus $\vec{\alpha}'_1$, išitikiname, kad $\lambda_1 = \vec{\alpha}'_1 \mathbf{S} \vec{\alpha}_1 = \mathbf{D}Y_1$, t. y. λ_1 yra didžiausioji tikrinė reikšmė.

Ieškant antrosios pagrindinės komponentės $Y_2 = \alpha_{21} X_1 + \dots + \alpha_{2k} X_k$, reikia atsižvelgti į dvi sąlygas – vektorius $\vec{\alpha}_2$ turi būti normuotas ir ortogonalus vektoriui $\vec{\alpha}_1$, t. y. $\vec{\alpha}'_1 \vec{\alpha}_2 = 0$. Taigi ieškome $\vec{\alpha}_2$, tenkinančio nurodytas sąlygas ir maksimizuojančio $\mathbf{D}Y_2$. Šį uždavinį taip pat galima spręsti Lagranžo daugiklių metodu. Procesas tęsiamas tol, kol randamos visos pagrindinės komponentės.

Grįžkime prie faktorių išskyrimo uždavinio. Įrodyta, kad pradiniai kintamieji pagrindinėmis komponentėmis išreiškiami taip:

$$X_i = \sum_{j=1}^k \alpha_{ji} Y_j, \quad i = 1, \dots, k. \quad (3)$$

Šia išraiška pasinaudojama išskiriant bendruosius faktorius.

Tarkime, k normaliai pasiskirsčiusių kintamųjų stebėjimai yra $(x_{1j}, x_{2j}, \dots, x_{kj})$, $j = 1, \dots, m$.

Aprašysime, kaip naudojantis koreliacijų matrica (galima naudotis ir kovariacijų matrica) apskaičiuoti faktorių svorių λ_{ij} , bendrumų h_i^2 ir specifiškumų τ_i įverčius $\hat{\lambda}_{ij}$, $\hat{h}_i^2$ ir $\hat{\tau}_i$ ($i = 1, \dots, k$, $j = 1, \dots, m$) bei kaip rasti pačius bendruosius faktorius F_j .

Iš pradžių apskaičiuojami k pagrindinių komponentių įverčiai

$$\hat{Y}_i = \sum_{j=1}^k a_{ij} X_j, \quad i = 1, \dots, k; \quad (4)$$

čia a_{ij} yra koeficientų α_{ij} empiriniai įverčiai. Priminsime, kad pagrindinės komponentės tarpusavyje nekoreliuoja, o i -osios komponentės dispersijos $\mathbf{D}Y_i$ įvertis $s^2(\hat{Y}_i)$ lygus i -ajai pagal dydį koreliacijų matricos tikrinei reikšmei, kurios atitinkamas tikrinis vektorius yra $\vec{a}_i = (a_{i1}, a_{i2}, \dots, a_{ik})'$, $i = 1, \dots, k$. Latentiniais bendraisiais faktoriais laikomos m pirmųjų pagrindinių komponentių, normuotų standartiniais nuokrypiais, t. y.

$$\hat{F}_j = \frac{\hat{Y}_j}{\sqrt{s^2(\hat{Y}_j)}}. \quad (5)$$

Turėdami pagrindines komponentes, randame ir pačius faktorius. Aišku, kad faktorių svorių įverčiai yra

$$\hat{\lambda}_{ij} = a_{ji} \sqrt{s^2(\hat{Y}_j)}, \quad i = 1, \dots, k, \quad j = 1, \dots, m. \quad (6)$$

Specifinių faktorių įverčiai išreiškiami tokia lygybe:

$$\hat{e}_i = \sum_{j=m+1}^k a_{ji} \hat{Y}_j, \quad i = 1, \dots, k. \quad (7)$$

Taigi gauname tokį įvertį:

$$\hat{X}_i = \sum_{j=1}^m \hat{\lambda}_{ij} \hat{F}_j + \hat{e}_i, \quad i = 1, \dots, k; \quad (8)$$

čia visi bendrieji faktoriai F_j turi vienetines dispersijas ir tarpusavyje nekoreliuoja. Be to, jie nekoreliuoja ir su specifiniais faktoriais. Tačiau pastebėkime, kad

$$\widehat{\text{cov}}(\hat{e}_i, \hat{e}_j) = \sum_{j=m+1}^k a_{ji} a_{jk} s^2(\hat{Y}_j), \quad i, k = 1, \dots, k, \quad i \neq k. \quad (9)$$

Specifinių faktorių kovariacijos nebūtinai lygios nuliui, todėl pažeidžiamos prielaidos. Vadinasi, minėtu faktorių išskyrimo metodu negauname visas modelio prielaidas tenkinančio sprendinio.

Kintamųjų X_i , $i = 1, \dots, k$, bendrumų ir specifiškumų įverčiai skaičiuojami pagal formules:

$$\hat{h}_i^2 = \sum_{j=1}^m \hat{\lambda}_{ji}^2 = \sum_{j=1}^m a_{ji}^2 s^2(\hat{Y}_j), \quad \hat{\tau}_i = \sum_{j=m+1}^k a_{ji}^2 s^2(\hat{Y}_j). \quad (10)$$

Atkreipsime dėmesį, kad anksčiau aprašytame faktorių išskyrimo algoritme faktorių skaičius yra laikomas žinomu. Kaip tyrėjas pasirenka faktorių skaičių m ? Viena vertus, kartais jis gali būti spėjamas iš anksto (pavyzdžiui, grupuodami politikus, iš anksto spėjame, kad bus kairieji, dešinieji ir centristai). Jeigu taip nėra, tai m rekomenduojama parinkti lygų ne mažesnių už vienetą koreliacijos matricos tikrinių reikšmių skaičiui. Kodėl? Prisiminkime, kad standartizuotų kintamųjų dispersijų suma lygi kintamųjų skaičiui, t. y. $\sum_1^k \mathbf{D}X_i = k$. Koreliacijų matricos tikrinės reikšmės atitinka pagrindinių komponentų dispersijas, kurių suma taip pat lygi k . Jei tikrinė reikšmė didesnė už 1, tai atitinkamos komponentės indėlis į bendrąją duomenų variaciją didesnis nei vidutinis.

Kartais faktorių skaičius parenkamas taip, kad būtų paaiškinta ne mažiau kaip iš anksto pasirinktas procentas bendrosios kintamųjų dispersijos (pavyzdžiui, ne mažiau kaip 75% visos dispersijos).

Grįžkime prie 10.1 pavyzdžio. SPSS paketu gautas pagrindinių faktorių išskyrimo rezultatų fragmentas pateiktas 10.7 paveiksle. Iš lentelės *Total Variance Explained* matyti, kad dvi pirmosios komponentės paaiškina 63,74% bendrosios dispersijos. Taigi pirmoji išvada – pirkėjų pasirinkimą lemia du bendrieji faktoriai. Lentelėje *Communalities* surašyti pradinių kintamųjų bendrumai – pradinių kintamųjų variacijų dalys sąlygojamos (paaiškinamos) bendrųjų faktorių. Paprastai sakoma, kad atrinktose pagrindinėse komponentėse išliko pakankamai daug informacijos apie kintamąjį, jeigu jo bendrumas ne mažesnis kaip 0,20. Lentelėje *Component Matrix* pateikti apskaičiuotieji faktorių svoriai ($\hat{\lambda}_{ij}$). Naudojantis šia lentele, identifikuoti bendruosius faktorius nėra paprasta. Ką daryti? Apie tai kitame skyrelyje.

TOTAL VARIANCE EXPLAINED						
Component	Extraction Sums of Squared Loadings			Rotation Sums of Squared Loadings		
	Total	% of Variance	Cumulative %	Total	% of Variance	Cumulative %
1	1,971	39,414	39,414	1,722	34,439	34,439
2	1,216	24,328	63,742	1,465	29,303	63,742

Extraction Method: Principal Component Analysis.

COMMUNALITIES	
	Extraction
SKN	,737
ARM	,724
ENV	,554
KAI	,494
UŽK	,678

Extraction Method: Principal Component Analysis.

COMPONENT MATRIX ^a		
	Component	
	1	2
SKN	,549	,660
ARM	,581	,622
ENV	,643	-,375
KAI	,614	-,341
UŽK	,736	-,370

Extraction Method: Principal Component Analysis.
^a. 2 components extracted.

10.7 pav.

Norime pabrėžti, kad pateikėme tik vieną iš paprasčiausių bendrųjų faktorių išskyrimo metodų. Jų yra daug. Pavyzdžiui, gana dažnai taikomas *pagrindinių faktorių* metodas. Čia faktorių svoriams ir kitiems dydžiams skaičiuoti naudojama redukuotoji koreliacijų matrica, kuri gaunama pagrindinių komponentų analizės metodu. Vis dėlto visus faktorinės analizės metodus vienija tai, kad vienu ar kitu būdu nustatomi faktorių svoriai (žinoma, konkrečios jų reikšmės priklauso nuo pasirinktojo metodo, bendrumai ir specifiškumai, kurie interpretuojami taip kaip šiame skyrelyje). Kokį konkretų analizės metodą pasirinkti, sprendžia tyrėjas.

10.5. Faktorių sukimas ir interpretavimas



Faktų nėra, yra tik jų interpretacijos.

F. Nyčė

Faktorių matrica aprašo faktorių ir atskirų kintamųjų priklausomybę. Kaip nustatyti, kokie kintamieji nusako faktorių F_j ? Šios problemos sprendimo idėja gana paprasta – jeigu faktorinės analizės modelyje λ_{ij} yra mažas skaičius, tai kintamasis X_i su faktoriumi F_j nesusijęs. Praktiškai peržiūrime kiekvieno faktoriaus svorių įverčius $\hat{\lambda}_{ij}$. Populiariausia taisyklė iš akies – svorio įvertį $\hat{\lambda}_{ij}$ laikyti pakankamai dideliu, jeigu $|\hat{\lambda}_{ij}| \geq 0,4$.

Faktorius F_j laikomas susijusiu su tais kintamaisiais $X_1, \dots, X_k$, kuriems svorių įverčiai $\hat{\lambda}_{1j}, \dots, \hat{\lambda}_{kj}$ absoliučiuoju didumu ne mažesni kaip 0,4.

Kintamieji, kurių svoriai teigiami ir kurių neigiami, yra vienodai svarbūs. Teigiamas svoris rodo, kad kintamasis su faktoriumi koreliuoja teigiamai (neigiamas svoris – neigiamai), ir tai neretai palengvina faktoriaus interpretaciją.

Pažvelgę į 10.7 paveikslą, matome, kad pirmasis faktorius F_1 susijęs su *visais* kintamaisiais. Antrasis – su kintamaisiais *SKN* ir *ARM*. Tačiau kaip įvardyti šiuos faktorius? Juk vienas iš faktorinės analizės tikslų – rasti bendruosius faktorius, kuriuos galima interpretuoti.

Naudojantis pradine faktorių svorių matrica, „prasminius“ faktorius gana sunku identifikuoti. Taip atsitinka todėl, kad dažniausiai vyrauja pirmasis faktorius, be to, net keliu to paties kintamojo faktorių svoriai gali viršyti 0,4, t. y. tas pats kintamasis gali būti susijęs su keliais faktoriais (taip yra mūsų atveju). Ką tada daryti?

Grįžkime prie faktorinės analizės modelio. Šis modelis sprendinio vienareikšmiškai nenusako. Galima sudaryti tiesines *gautų* faktorių daugdaras, kurios tarpusavyje neko-reliuotos ir turi vienetines dispersijas (t. y. tenkina modelį!). Naujųjų faktorių rinkinių nustatymo procedūra vadinama *ortogonalioja pradinių faktorių transformacija*, arba *ortogonalioju sukimu*.

Modelio „vieninareikšmiškumą“ galima lengvai suprasti užrašius jį matriciniu pavidalu:




$$X = LF + E, \quad X = L(TT')F + E, \quad X = (LT)(T'F) + E, \quad X = L^*F^* + E;$$

čia T yra ortogonalioji matrica, L^* , F^* – naujieji svoriai ir faktoriai.

Faktorių sukimas (rotacija) – tai faktorių matricos transformavimas suteikiant jai lengviau interpretuojamą pavidalą.

Sukimo tikslas – suprastinti faktorių svorių matricos struktūrą, t. y. siekiama, kad *tik* kelių kintamųjų visų faktorių svoriai būtų nenuliniai. Tai palengvina faktorių interpretuoti. Be to, siekiama, kad kiekvienas kintamasis turėtų tik kelis nenulinius faktorių svorius (idealu, jei vieną). Tada lengviau faktorių diferencijuoti – atskirti juos tarpusavyje.

Terminas „faktorių sukimas“ atsirado dėl aiškos geometrinės šios procedūros interpretacijos. Tarkime, yra du faktoriai F_1 ir F_2 . Tuomet juos galime išivaizduoti kaip plokštumos Dekarto koordinačių ašis, o kintamuosius $X_1, \dots, X_k$ atvaizduoti plokštumos taškais, kurių koordinatės yra $(\lambda_{11}, \lambda_{12}), \dots, (\lambda_{k1}, \lambda_{k2})$ (žr. 10.8 pav., a)). Faktoriai paaiškina tuos kintamuosius, kurių „taškai“ yra arčiau faktorių atitinkančios ašies. Geriausiai faktorių paaiškina tą kintamąjį, kurio „taškas“ patenka ant pačios faktoriaus ašies. Pasukdami koordinačių ašis, galime sumažinti kintamųjų, kurių „taškai“ arti abiejų ašių, skaičių (žr. 10.8 pav., b)). Tai atitinka minėtąjį *ortogonalųjį* sukimą. Geometrinė sukimo interpretacija išlieka ir kai faktorių daugiau nei du (tam užtenka išivaizduoti m -matę Dekarto koordinačių sistemą). Populiariausias iš ortogonalųjų sukimų – VARIMAX.




Sukimas nekeičia sprendinio savybių, t. y. bendrumai ir bendrosios dispersijos paaiškinimo procentas nesikeičia. Tačiau kiekvieno faktoriaus indėlis kitoks – kokį procentą bendrosios dispersijos paaiškina konkretus faktorius. Paprastai po sukimo keičiasi ir pačių faktorių interpretacija. Yra daug sukimo metodų. Mes neapstarinėsime techninių šių metodų detalių, tik pastebėsime, kad skirtingi metodai identifikuoja skirtingus faktorius. Be to, atkreipiame dėmesį, kad matematinė faktorių sukimo procedūra remiasi iteraciniais skaičiavimais, todėl faktorius pasukti *ne visada* pavyksta.



Beje, koordinačių ašis galima ne tik sukti, bet ir suglausti, t. y. nuo ortogonaliosios Dekarto koordinačių sistemos pereiti prie neortogonaliosios (žr. 10.8 pav., c)). Tai vadinamieji neortogonalieji sukimai. Po neortogonaliojo sukimo naujieji bendrieji faktoriai jau koreliuoti, t. y. ne visos pradinio faktorių savybės išlieka.

Kaip interpretuojami faktoriai? Panagrinėkime 10.1 uždavinio sprendimo paskutinę SPSS rezultatų protokolo dalį (žr. 10.9 pav.). Lentelėje *Rotated Component Matrix* yra dviejų bendrųjų faktorių svoriai po sukimo. Matome, kad pirmasis faktorius koreliuoja



(prisiminkime, kad svoriai kartu yra ir koreliacijos su atitinkamais lentelėje nurodytais kintamaisiais!) su kintamaisiais *ENV*, *KAI* ir *UŽK*, o antrasis – su *SKN* ir *ARM*. Kaip dabar galima būtų įvardyti bendruosius faktorius? Subjektyvumo negalima išvengti. Bet drįstume pasiūlyti tokius pavadinimus: F_1 – „maistingumas“, F_2 – „skanumas“.

10.6. Faktorių reikšmių skaičiavimas



Teoriškai praktikos ir teorijos skirtumo nėra, praktiškai – yra.
Č. Reidas

Kaip apskaičiuoti faktorių reikšmių įverčius? Pavyzdžiui, vertinant studentų išsilavinimą išskirti du bendrieji faktoriai: intelektas ir erudicija. Remiantis testo rezultatais, reikia įvertinti faktorių reikšmes, kad galima būtų aprašyti konkretaus studento gebėjimus.

Faktorių įverčių reikšmių skaičiavimą komplikuoja tai, kad nežinomųjų skaičius F_i ir λ_{ij} didesnis nei žinomųjų X_j skaičius. Faktorių reikšmių įverčiams skaičiuoti standartinio metodo nėra. Jei bendrieji faktoriai išskirti taikant pagrindinių komponentių metodą, tai faktorių reikšmių įverčiai skaičiuojami naudojantis mažiausiųjų kvadratų procedūra. Tuo atveju gaunamos tokios formulės:

$$\hat{F}_j = \frac{\hat{Y}_j}{\sqrt{\lambda_j}};$$

čia $\hat{Y}_j$ – j -osios pagrindinės komponentės įvertis, λ_j – jo tikrinė reikšmė.

Kitas būdas – regresinės analizės technika. Tarkime, faktoriai yra priklausomi kintamieji, o pradiniai kintamieji X_i – nepriklausomi. Tada galima užrašyti tokią lygtį:

$$\hat{F}_j = \sum_{i=1}^k b_{ij} z_i, \quad j = 1, \dots, m;$$

čia $\hat{F}_j$ yra j -ojo faktoriaus reikšmė, z_i – i -ojo kintamojo standartizuota reikšmė (t. y. $z_i = (x_i - \bar{x}_i)/s_i$), b_{ij} – regresijos koeficientų įverčiai (dar vadinami faktorių reikšmių koeficientais).

Praktiškai plačiai taikomas ir toks paprastas metodas: jeigu visi su faktoriumi susiję kintamieji matuoti pagal tą pačią intervalų skalę ir visų jų svoriai yra to paties ženklo, tai faktoriaus reikšmė laikomas šių kintamųjų reikšmių vidurkis.



bendrumai	<i>KMO</i> matas	tikrinė reikšmė
Bartleto sferiškumo testas	pagrindinė komponentė	tikrinis vektorius
faktorių svoriai	redukuotoji matrica	
faktorių sukimas	specifiškumas	

UŽDAVINIAI

1. Tarkime, trijų kintamųjų koreliacijų matrica yra

$$\mathcal{R} = \begin{pmatrix} 1 & 0,63 & 0,45 \\ 0,63 & 1 & 0,35 \\ 0,45 & 0,35 & 1 \end{pmatrix}.$$

- a) Sudarykite faktorinės analizės modelį, kai $m = 1$.
- b) Taikydami pagrindinių komponentių analizę, apskaičiuokite faktorių svorių matricą.

Kokie kintamieji daro didžiausią įtaką įvardijant bendrąjį faktorių? Kokią dalį bendrosios dispersijos paaiškina bendrasis faktorius?

2. Tarkime, turime standartizuotų duomenų aibę. Atlikus faktorinę analizę, gauta tokia dviejų bendrųjų faktorių svorių matrica:

F_1	F_2
0,7	0,3
0,8	0,0
0,7	0,0
0,8	0,6
0,6	0,5
0,5	0,0
0,6	0,4
0,7	0,6

Koks yra kiekvieno iš šių faktorių indėlis į bendrąją dispersiją?

3. 500 automobilių mėgėjų buvo paprašyti įvertinti 12 jiems gerai žinomų modelių. (Klausimas: „Ar norėtume įsigyti šį automobilį?“ Vertinimai: 0 – visiškai nenorėčiau, 100 – labai norėčiau). Faktorinės analizės rezultatai pateikti 10.10 paveiksle. Kuri iš rezultatų interpretacijų atrodo priimtiniausia:
 - a) automobilių mėgėjai pirmenybę teikia prabangiems automobiliams;
 - b) vieni mėgėjai pirmenybę teikia sportiniams automobiliams, kiti – prabangiems automobiliams;
 - c) vieni automobilių mėgėjai pirmenybę teikia sportiniams automobiliams, antri – prabangiems automobiliams, o tretieji – svarbiausia saugumas ir patikimumas.

ROTATED COMPONENT MATRIX ^a				
	Component			
	1	2	3	4
PORCHE	-7,087E-02	-3,806E-02	-3,806E-02	-9,123E-02
FERRARI	7,414E-03	-,185	-,185	-2,159E-02
VOLKSWAGEN	3,068E-02	,121	,121	,952
BMW 328I	,186	-,205	-,205	3,572E-02
VOLVO	-,158	,817	,817	-3,173E-02
FIAT	-,947	-1,020E-02	-1,020E-02	3,870E-03
AUDI	,854	,235	,235	-,308
LEXUS	,907	,259	,259	-,156
OPEL	-,247	-,825	-,825	-,176
KIA	-,870	,121	,121	-,271
MERCEDES BENZ	,940	-9,107E-02	-9,107E-02	,131
ROLLS-ROYCE	,944	-7,446E-02	-7,446E-02	,112

Extraction Method: Principal Component Analysis.
 Rotation Method: Varimax with Kaiser Normalization.
^a Rotation converged in 5 iterations.

10.10 pav.

4. Prižiūrimi psichologo pradinių klasių mokiniai sprendė uždavinius (išspręstų uždavinių skaičius – kintamasis *ARIT*); demonstravo erudiciją (kintamasis *INF*); pagal spalvas komponavo kubelius (*KK*); iš dalių surinkinėjo objektus (*OS*); vertino objektų panašumą (*PAN*); išdėstydamo paveikslukus nuoseklia seka (*PI*); užbaigdamo paveikslą (*PU*); bandė įsiminti ir iš kito galo pakartoti skaičių seką (*SE*); ieškojo piešinyje simbolių (*SP*); ir demonstravo žodyno turtingumą (*ŽOD*). Šių kintamųjų koreliacijų matrica pateikta 10.11 paveiksle. Išskirkite keturis faktorius ir pateikite jų interpretaciją.

CORRELATION MATRIX										
	INF	ARIT	PAN	SE	ŽOD	SP	PU	OS	PI	KK
VIDUR	10,83	8,62	10,55	13,30	12,71	7,05	10,87	8,67	13,17	9,39
STD	3,56	3,14	3,19	3,64	3,23	2,98	2,94	2,60	12,92	3,13
N	28,00	28,00	28,00	28,00	28,00	28,00	28,00	28,00	28,00	28,00
INF	1,00	,51	,54	,36	,50	,25	,42	,19	-,16	,32
ARIT	,51	1,00	,48	,44	,21	,45	,33	,06	,02	,27
PAN	,54	,48	1,00	,27	,44	,43	,21	,38	-,23	,21
SE	,36	,44	,27	1,00	,40	,46	,30	-,08	-,19	,20
ŽOD	,50	,21	,44	,40	1,00	,14	,59	,13	-,22	,28
SP	,25	,45	,43	,46	,14	1,00	,15	,17	,05	,23
PU	,42	,33	,21	,30	,59	,15	1,00	,09	,19	,07
OS	,19	,06	,38	-,08	,13	,17	,09	1,00	-,04	,50
PI	-,16	,02	-,23	-,19	-,22	,59	,19	-,04	1,00	-,22
KK	,32	,27	,21	,20	,28	,23	,07	,50	-,22	1,00

10.11 pav.

PRIEDAS

1 lentelė. Normaliojo skirstinio $\mathcal{N}(0, 1)$ kritinės reikšmės z_α

α	z_α	α	z_α	α	z_α	α	z_α	α	z_α	α	z_α
0,50	0,000	0,37	0,331	0,24	0,706	0,11	1,226	0,025	1,959	0,012	2,257
0,49	0,025	0,36	0,358	0,23	0,738	0,10	1,281	0,024	1,977	0,011	2,290
0,48	0,050	0,35	0,385	0,22	0,772	0,09	1,340	0,023	1,995	0,010	2,326
0,47	0,075	0,34	0,412	0,21	0,806	0,08	1,405	0,022	2,014	0,009	2,365
0,46	0,100	0,33	0,439	0,20	0,841	0,07	1,475	0,021	2,033	0,008	2,408
0,45	0,125	0,32	0,467	0,19	0,877	0,06	1,554	0,020	2,053	0,007	2,457
0,44	0,150	0,31	0,495	0,18	0,915	0,05	1,644	0,019	2,074	0,006	2,512
0,43	0,176	0,30	0,524	0,17	0,954	0,04	1,750	0,018	2,096	0,005	2,575
0,42	0,201	0,29	0,553	0,16	0,994	0,03	1,880	0,017	2,120	0,004	2,652
0,41	0,227	0,28	0,582	0,15	1,036	0,029	1,895	0,016	2,144	0,003	2,747
0,40	0,253	0,27	0,612	0,14	1,080	0,028	1,911	0,015	2,170	0,002	2,878
0,39	0,279	0,26	0,643	0,13	1,126	0,027	1,926	0,014	2,197	0,001	3,090
0,38	0,305	0,25	0,674	0,12	1,174	0,026	1,943	0,013	2,226		

2 lentelė. Studento t skirstinio α lygmens kritinės reikšmės $t_{\alpha}(n)$

$n \backslash \alpha$	0,40	0,10	0,05	0,025	0,01	0,005
1	0,325	3,078	6,314	12,706	31,821	63,657
2	0,289	1,886	2,920	4,303	6,965	9,925
3	0,277	1,638	2,353	3,182	4,541	5,841
4	0,271	1,533	2,132	2,776	3,747	4,604
5	0,267	1,476	2,015	2,571	3,365	4,032
6	0,265	1,440	1,943	2,447	3,143	3,707
7	0,263	1,415	1,895	2,365	2,998	3,499
8	0,262	1,397	1,860	2,306	2,896	3,355
9	0,261	1,383	1,833	2,262	2,821	3,250
10	0,260	1,372	1,812	2,228	2,764	3,169
11	0,260	1,363	1,796	2,201	2,718	3,106
12	0,259	1,356	1,782	2,179	2,681	3,055
13	0,259	1,350	1,771	2,160	2,650	3,012
14	0,258	1,345	1,761	2,145	2,624	2,977
15	0,258	1,341	1,753	2,131	2,602	2,947
16	0,258	1,337	1,746	2,120	2,583	2,921
17	0,257	1,333	1,740	2,110	2,567	2,898
18	0,257	1,330	1,734	2,101	2,552	2,878
19	0,257	1,328	1,729	2,093	2,539	2,861
20	0,257	1,325	1,725	2,086	2,528	2,845
21	0,257	1,323	1,721	2,080	2,518	2,831
22	0,256	1,321	1,717	2,074	2,508	2,819
23	0,256	1,319	1,714	2,069	2,500	2,807
24	0,256	1,318	1,711	2,064	2,492	2,797
25	0,256	1,316	1,708	2,060	2,485	2,787
26	0,256	1,315	1,706	2,056	2,479	2,779
27	0,256	1,314	1,703	2,052	2,473	2,771
28	0,256	1,313	1,701	2,048	2,467	2,763
29	0,256	1,311	1,699	2,045	2,462	2,756
30	0,256	1,310	1,697	2,042	2,457	2,750
40	0,255	1,303	1,684	2,021	2,423	2,704
60	0,254	1,296	1,671	2,000	2,390	2,660
120	0,254	1,289	1,658	1,980	2,358	2,617
∞	0,253	1,282	1,645	1,960	2,326	2,576

3 lentelė. χ^2 skirstinio α lygmens kritinės reikšmės $\chi^2_{\alpha}(n)$

$n \backslash \alpha$	0,9995	0,999	0,995	0,99	0,975	0,95	0,90
1	0	0	0,00003	0,00015	0,00098	0,00393	0,0158
2	0,00100	0,00200	0,0100	0,0201	0,0506	0,103	0,211
3	0,0153	0,0243	0,0717	0,115	0,216	0,352	0,584
4	0,0639	0,0908	0,207	0,297	0,484	0,711	1,064
5	0,158	0,210	0,412	0,554	0,831	1,145	1,610
6	0,299	0,381	0,676	0,872	1,237	1,635	2,204
7	0,485	0,598	0,989	1,239	1,690	2,167	2,833
8	0,710	0,857	1,344	1,646	2,180	2,733	3,490
9	0,972	1,153	1,735	2,088	2,700	3,325	4,168
10	1,265	1,479	2,156	2,558	3,247	3,940	4,865
11	1,587	1,834	2,603	3,053	3,816	4,575	5,578
12	1,934	2,214	3,074	3,571	4,404	5,226	6,304
13	2,305	2,617	3,565	4,107	5,009	5,892	7,042
14	2,697	3,041	4,075	4,660	5,629	6,571	7,790
15	3,108	3,483	4,601	5,229	6,262	7,261	8,547
16	3,536	3,942	5,142	5,812	6,908	7,962	9,312
17	3,980	4,416	5,697	6,408	7,564	8,672	10,085
18	4,439	4,905	6,265	7,015	8,231	9,390	10,865
19	4,912	5,407	6,844	7,633	8,907	10,117	11,651
20	5,398	5,921	7,434	8,260	9,591	10,851	12,443
21	5,896	6,447	8,034	8,897	10,283	11,591	13,240
22	6,404	6,983	8,643	9,542	10,982	12,338	14,041
23	6,924	7,529	9,160	10,196	11,688	13,091	14,848
24	7,453	8,085	9,886	10,856	12,401	13,848	15,659
25	7,991	8,649	10,520	11,524	13,120	14,611	16,473
26	8,538	9,222	11,160	12,198	13,844	15,379	17,292
27	9,093	9,803	11,808	12,879	14,573	16,151	18,114
28	9,656	10,391	12,461	13,565	15,308	16,928	18,939
29	10,227	10,986	13,121	14,256	16,047	17,708	19,768
30	10,804	11,588	13,787	14,953	16,791	18,493	20,599
31	11,389	12,196	14,458	15,655	17,539	19,281	21,434
32	11,979	12,811	15,134	16,362	18,291	20,072	22,271
33	12,576	13,431	15,815	17,073	19,047	20,867	23,110
34	13,179	14,057	16,501	17,789	19,806	21,664	23,952
35	13,788	14,688	17,192	18,509	20,569	22,465	24,797
36	14,401	15,324	17,887	19,233	21,336	23,269	25,643
37	15,020	15,965	18,586	19,960	22,106	24,075	26,492
38	15,644	16,611	19,289	20,691	22,878	24,884	27,343
39	16,273	17,262	19,996	21,426	23,654	25,695	28,196
40	16,906	17,916	20,707	22,164	24,433	26,509	29,051
50	23,461	24,674	27,991	29,707	32,357	34,764	37,689
60	30,340	31,738	35,535	37,485	40,482	43,188	46,459
80	44,791	46,520	51,172	53,540	57,153	60,391	64,278
100	59,896	61,918	67,328	70,065	74,222	77,929	82,358

3 lentelės tęsinys

0,10	0,05	0,025	0,01	0,005	0,001	0,0005	$\alpha \backslash n$
2,706	3,841	5,024	6,635	7,879	10,828	12,116	1
4,605	5,991	7,378	9,210	10,597	13,816	15,202	2
6,251	7,815	9,348	11,345	12,838	16,266	17,730	3
7,779	9,488	11,143	13,277	14,860	18,467	19,997	4
9,236	11,070	12,832	15,086	16,750	20,515	22,105	5
10,345	12,592	14,449	16,812	18,548	22,458	24,103	6
12,017	14,067	16,013	18,475	20,278	24,322	26,018	7
13,362	15,507	17,535	20,090	21,955	26,125	27,868	8
14,684	16,919	19,023	21,666	23,589	27,877	29,666	9
15,987	18,307	20,483	23,209	25,188	29,588	31,420	10
17,275	19,675	21,920	24,725	26,757	31,264	33,136	11
18,549	21,026	23,336	26,217	28,300	32,909	34,821	12
19,812	22,362	24,736	27,688	29,819	34,528	36,478	13
21,064	23,685	26,119	29,141	31,319	36,123	38,109	14
22,307	24,996	27,488	30,578	32,801	37,697	39,719	15
23,542	26,296	28,845	32,000	34,267	39,252	41,308	16
24,769	27,587	30,191	33,409	35,718	40,790	42,879	17
25,989	28,869	31,526	34,805	37,156	42,312	44,434	18
27,204	30,144	32,852	36,191	38,582	43,820	45,973	19
28,412	31,410	34,170	37,566	39,997	45,315	47,498	20
29,615	32,671	35,479	38,932	41,401	46,797	49,010	21
30,813	33,924	36,781	40,289	42,796	48,268	50,511	22
32,007	35,172	38,076	41,638	44,181	49,728	52,000	23
33,196	36,415	39,364	42,980	45,558	51,179	53,479	24
34,382	37,652	40,646	44,314	46,928	52,620	54,947	25
35,563	38,885	41,923	45,642	48,290	54,052	56,407	26
36,741	40,113	43,194	46,963	49,645	55,476	57,858	27
37,916	41,337	44,461	48,278	50,993	56,892	59,300	28
39,087	42,557	45,722	49,588	52,336	58,301	60,735	29
40,256	43,773	46,979	50,892	53,672	59,703	62,162	30
41,422	44,985	48,232	52,191	55,003	61,098	63,582	31
42,585	46,194	49,480	53,486	56,328	62,487	64,995	32
43,745	47,400	50,725	54,776	57,648	63,870	66,402	33
44,903	48,602	51,966	56,061	58,964	65,247	67,803	34
46,059	49,802	53,203	57,342	60,275	66,619	69,199	35
47,212	50,998	54,437	58,619	61,581	67,985	70,588	36
48,363	52,192	55,668	59,892	62,882	69,346	71,972	37
49,513	53,384	56,895	61,162	64,181	70,703	73,351	38
50,660	54,572	58,120	62,428	65,476	72,055	74,725	39
51,805	55,758	59,342	63,691	66,766	73,402	76,095	40
63,167	67,505	71,420	76,154	79,490	86,661	89,561	50
74,397	79,082	83,298	88,379	91,952	99,607	102,695	60
96,578	101,879	106,629	112,329	116,321	124,839	128,261	80
118,498	124,342	129,561	135,807	140,169	149,449	153,167	100

4 lentelė. Fišerio skirstinio $\alpha = 0,05$ lygmens kritinės reikšmės $F_{\alpha}(m, n)$

$n \backslash m$	1	2	3	4	5	6	8	10	12	15	20	40
1	161,45	199,50	215,71	224,58	230,16	233,99	238,88	241,88	243,91	245,95	248,01	251,14
2	18,513	19,000	19,164	19,247	19,296	19,330	19,371	19,396	19,413	19,429	19,446	19,471
3	10,128	9,5521	9,2766	9,1172	9,0135	8,9406	8,8452	8,7855	8,7446	8,7029	8,6602	8,5944
4	7,7086	6,9443	6,5914	6,3883	6,2560	6,1631	6,0410	5,9644	5,9117	5,8578	5,8025	5,7170
5	6,6079	5,7861	5,4095	5,1922	5,0503	4,9503	4,8183	4,7351	4,6777	4,6188	4,5581	4,4638
6	5,9874	5,1433	4,7571	4,5337	4,3874	4,2839	4,1468	4,0600	3,9999	3,9381	3,8742	3,7743
7	5,5914	4,7374	4,3468	4,1203	3,9715	3,8660	3,7257	3,6365	3,5747	3,5108	3,4445	3,3404
8	5,3177	4,4590	4,0662	3,8378	3,6875	3,5806	3,4381	3,3472	3,2840	3,2184	3,1503	3,0428
9	5,1174	4,2565	3,8626	3,6331	3,4817	3,3738	3,2296	3,1373	3,0729	3,0061	2,9365	2,8259
10	4,9646	4,1028	3,7083	3,4780	3,3258	3,2172	3,0717	2,9782	2,9130	2,8450	2,7740	2,6609
11	4,8443	3,9823	3,5874	3,3567	3,2039	3,0946	2,9480	2,8536	2,7876	2,7186	2,6464	2,5309
12	4,7472	3,8853	3,4903	3,2592	3,1059	2,9961	2,8486	2,7534	2,6866	2,6169	2,5436	2,4259
13	4,6672	3,8056	3,4105	3,1791	3,0254	2,9153	2,7669	2,6710	2,6037	2,5331	2,4589	2,3392
14	4,6001	3,7389	3,3439	3,1122	2,9582	2,8477	2,6987	2,6021	2,5342	2,4630	2,3879	2,2664
15	4,5431	3,6823	3,2874	3,0556	2,9013	2,7905	2,6408	2,5437	2,4753	2,4035	2,3275	2,2043
16	4,4940	3,6337	3,2389	3,0069	2,8524	2,7413	2,5911	2,4935	2,4247	2,3522	2,2756	2,1507
17	4,4513	3,5915	3,1968	2,9647	2,8100	2,6987	2,5480	2,4499	2,3807	2,3077	2,2304	2,1040
18	4,4139	3,5546	3,1599	2,9277	2,7729	2,6613	2,5102	2,4117	2,3421	2,2686	2,1906	2,0629
19	4,3808	3,5219	3,1274	2,8951	2,7401	2,6283	2,4768	2,3779	2,3080	2,2341	2,1555	2,0264
20	4,3513	3,4928	3,0984	2,8661	2,7109	2,5990	2,4471	2,3479	2,2776	2,2033	2,1242	1,9938
21	4,3248	3,4668	3,0725	2,8401	2,6848	2,5727	2,4205	2,3210	2,2504	2,1757	2,0960	1,9645
22	4,3009	3,4434	3,0491	2,8167	2,6613	2,5491	2,3965	2,2967	2,2258	2,1508	2,0707	1,9380
23	4,2793	3,4221	3,0280	2,7955	2,6400	2,5277	2,3748	2,2747	2,2036	2,1282	2,0476	1,9139
24	4,2597	3,4028	3,0088	2,7763	2,6207	2,5082	2,3551	2,2547	2,1834	2,1077	2,0267	1,8920
25	4,2417	3,3852	2,9912	2,7587	2,6030	2,4904	2,3371	2,2365	2,1649	2,0889	2,0075	1,8718
26	4,2252	3,3690	2,9751	2,7426	2,5868	2,4741	2,3205	2,2197	2,1479	2,0716	1,9898	1,8533
27	4,2100	3,3541	2,9604	2,7278	2,5719	2,4591	2,3053	2,2043	2,1323	2,0558	1,9736	1,8361
28	4,1960	3,3404	2,9467	2,7141	2,5581	2,4453	2,2782	2,1900	2,1179	2,0411	1,9586	1,8203
29	4,1830	3,3277	2,9340	2,7014	2,5454	2,4324	2,2782	2,1768	2,1045	2,0275	1,9446	1,8055
30	4,1709	3,3158	2,9223	2,6896	2,5336	2,4205	2,2662	2,1646	2,0921	2,0148	1,9317	1,7918
40	4,0848	3,2317	2,8387	2,6060	2,4495	2,3359	2,1802	2,0772	2,0035	1,9245	1,8389	1,6928
60	4,0012	3,1504	2,7581	2,5252	2,3683	2,2540	2,0970	1,9926	1,9174	1,8364	1,7480	1,5943
120	3,9201	3,0718	2,6802	2,4472	2,2900	2,1750	2,0164	1,9105	1,8337	1,7505	1,6587	1,4952
∞	3,8415	2,9957	2,6049	2,3719	2,2141	2,0986	1,9384	1,8307	1,7522	1,6664	1,5705	1,3940

5 lentelė. Mano–Vitnio–Vilkoksono kriterijaus $\alpha = 0,05$ vienaspusės ir $\alpha = 0,10$ dvipusės alternatyvų kritinės reikšmės

$n_2 \backslash n_1$	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
1	–	–	–	–	–	–	–	–	–	–	–	–	–	–	–	–	–	–	0	0
																			19	20
2	–	–	–	–	0	0	0	1	1	1	1	2	2	2	3	3	3	4	4	4
					10	12	14	15	17	19	21	22	24	26	27	29	31	32	34	36
3	–	–	0	0	1	2	2	3	3	4	5	5	6	7	7	8	9	9	10	11
			9	12	14	16	19	21	24	26	28	31	33	35	38	40	42	45	47	49
4	–	–	0	1	2	3	4	5	6	7	8	9	10	11	12	14	15	16	17	18
			12	15	18	21	24	27	30	33	36	39	42	45	48	50	53	56	59	62
5	–	0	1	2	4	5	6	8	9	11	12	13	15	16	18	19	20	22	23	25
		10	14	18	21	25	29	32	36	39	43	47	50	54	57	61	65	68	72	75
6	–	0	2	3	5	7	8	10	12	14	16	17	19	21	23	25	26	28	30	32
		12	16	21	25	29	34	38	42	46	50	55	59	63	67	71	76	80	84	88
7	–	0	2	4	6	8	11	13	15	17	19	21	24	26	28	30	33	35	37	39
		14	19	24	29	34	38	43	48	53	58	63	67	72	77	82	86	91	96	101
8	–	1	3	5	8	10	13	15	18	20	23	26	28	31	33	36	39	41	44	47
		15	21	27	32	38	43	49	54	60	65	70	76	81	87	92	97	103	108	113
9	–	1	3	6	9	12	15	18	21	24	27	30	33	36	39	42	45	48	51	54
		17	24	30	36	42	48	54	60	66	72	78	84	90	96	102	108	114	120	126
10	–	1	4	7	11	14	17	20	24	27	31	34	37	41	44	48	51	55	58	62
		19	26	33	39	46	53	60	66	73	79	86	93	99	106	112	119	125	132	138
11	–	1	5	8	12	16	19	23	27	31	34	38	42	46	50	54	57	61	65	69
		21	28	36	43	50	58	65	72	79	87	94	101	108	115	122	130	137	144	151
12	–	2	5	9	13	17	21	26	30	34	38	42	47	51	55	60	64	68	72	77
		22	31	39	47	55	63	70	78	86	94	102	109	117	125	132	140	148	156	163
13	–	2	6	10	15	19	24	28	33	37	42	47	51	56	61	65	70	75	80	84
		24	33	42	50	59	67	76	84	93	101	109	118	126	134	143	151	159	167	176
14	–	2	7	11	16	21	26	31	36	41	46	51	56	61	66	71	77	82	87	92
		26	35	45	54	63	72	81	90	99	108	117	126	135	144	153	161	170	179	188
15	–	3	7	12	18	23	28	33	39	44	50	55	61	66	72	77	83	88	94	100
		27	38	48	57	67	77	87	96	106	115	125	134	144	153	163	172	182	191	200
16	–	3	8	14	19	25	30	36	42	48	54	60	65	71	77	83	89	95	101	107
		29	40	50	61	71	82	92	102	112	122	132	143	153	163	173	183	193	203	213
17	–	3	9	15	20	26	33	39	45	51	57	64	70	77	83	89	96	102	109	115
		31	42	53	65	76	86	97	108	119	130	140	151	161	172	183	193	204	214	225
18	–	4	9	16	22	28	35	41	48	55	61	68	75	82	88	95	102	109	116	123
		32	45	56	68	80	91	103	114	123	137	148	159	170	182	193	204	215	226	237
19	0	4	10	17	23	30	37	44	51	58	65	72	80	87	94	101	109	116	123	130
	19	34	47	59	72	84	96	108	120	132	144	156	167	179	191	203	214	226	238	250
20	0	4	11	18	25	32	39	47	54	62	69	77	84	92	100	107	115	123	130	138
	20	36	49	62	75	88	101	113	126	138	151	163	176	188	200	213	225	237	250	262

6 lentelė. Mano–Vitnio–Vilkoksono kriterijaus $\alpha = 0,025$ vienosios ir $\alpha = 0,05$ dvipusės alternatyvų kritinės reikšmės

$n_2 \backslash n_1$	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
1	–	–	–	–	–	–	–	–	–	–	–	–	–	–	–	–	–	–	–	–
2	–	–	–	–	–	–	–	0	0	0	0	1	1	1	1	1	2	2	2	2
3	–	–	–	–	0	1	1	2	2	3	3	4	4	5	5	6	6	7	7	8
4	–	–	–	0	1	2	3	4	4	5	6	7	8	9	10	11	11	12	13	13
5	–	–	0	1	2	3	5	6	7	8	9	11	12	13	14	15	17	18	19	20
6	–	–	1	2	3	5	6	8	10	11	13	14	16	17	19	21	22	24	25	27
7	–	–	1	3	5	6	8	10	12	14	16	18	20	22	24	26	28	30	32	34
8	–	0	2	4	6	8	10	13	15	17	19	22	24	26	29	31	34	36	38	41
9	–	0	2	4	7	10	12	15	17	20	23	26	28	31	34	37	39	42	45	48
10	–	0	3	5	8	11	14	17	20	23	26	29	33	36	39	42	45	48	52	55
11	–	0	3	6	9	13	16	19	23	26	30	33	37	40	44	47	51	55	58	62
12	–	1	4	7	11	14	18	22	26	29	33	37	41	45	49	53	57	61	65	69
13	–	1	4	8	12	16	20	24	28	33	37	41	45	50	54	59	63	67	72	76
14	–	1	5	9	13	17	22	26	31	36	40	45	50	55	59	64	67	74	78	83
15	–	1	5	10	14	19	24	29	34	39	44	49	54	59	64	70	75	80	85	90
16	–	1	6	11	15	21	26	31	37	42	47	53	59	64	70	75	81	86	92	98
17	–	2	6	11	17	22	28	34	39	45	51	57	63	67	75	81	87	93	99	105
18	–	2	7	12	18	24	30	36	42	48	55	61	67	74	80	86	93	99	106	112
19	–	2	7	13	19	25	32	38	45	52	58	65	72	78	85	92	99	106	113	119
20	–	2	8	13	20	27	34	41	48	55	62	69	76	83	90	98	105	112	119	127
		38	52	67	80	93	106	119	132	145	158	171	184	197	210	222	235	248	261	273

7 lentelė. Kendalo konkordacijos koeficiento kritinės reikšmės

k	n					Papildomos reikšmės, kai $n = 3$	
	3	4	5	6	7	k	s
Reikšmingumo lygmuo $\alpha = 0,05$							
3			64,4	103,9	157,3	9	54,0
4		49,5	88,4	143,3	217,0	12	71,9
5		62,6	112,3	182,4	276,2	14	83,8
6		75,7	136,1	221,4	335,2	16	95,8
8	48,1	101,7	183,7	299,0	453,1	18	107,7
10	60,0	127,8	231,2	376,7	571,0		
15	89,8	192,9	349,8	570,5	864,9		
20	119,7	258,0	468,5	764,4	1158,7		
Reikšmingumo lygmuo $\alpha = 0,01$							
3			75,6	122,8	185,6	9	75,9
4		61,4	109,3	176,2	265,0	12	103,5
5		80,5	142,8	229,4	343,8	14	121,9
6		99,5	176,1	282,4	422,6	16	140,2
8	66,8	137,4	242,7	388,3	579,9	18	158,6
10	85,1	175,3	309,1	494,0	737,0		
15	131,0	269,8	475,2	758,2	1129,5		
20	177,0	364,2	641,2	1022,2	1521,9		

8 lentelė. Vilkoksono kriterijaus kritinės reikšmės

n	Vienpusės alternatyvos reikšmingumo lygmuo α		
	0,025	0,01	0,005
	Dvipusės alternatyvos reikšmingumo lygmuo α		
	0,05	0,02	0,01
6	0	–	–
7	2	0	–
8	4	2	0
9	6	3	2
10	8	5	3
11	11	7	5
12	14	10	7
13	17	13	10
14	21	16	13
15	25	20	16
16	30	24	20
17	35	28	23
18	40	33	28
19	46	38	32
20	52	43	38
21	59	49	43
22	66	56	49
23	73	62	55
24	81	69	61
25	89	77	68

9 lentelė. Serijų kriterijaus $\alpha = 0,05$ lygmens apatinės kritinės reikšmės

$n_1 \backslash n_2$	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
2											2	2	2	2	2	2	2	2	2
3					2	2	2	2	2	2	2	2	2	3	3	3	3	3	3
4				2	2	2	3	3	3	3	3	3	3	3	4	4	4	4	4
5			2	2	3	3	3	3	3	4	4	4	4	4	4	4	5	5	5
6		2	2	3	3	3	3	4	4	4	4	5	5	5	5	5	5	6	6
7		2	2	3	3	3	4	4	5	5	5	5	5	6	6	6	6	6	6
8		2	3	3	3	4	4	5	5	5	6	6	6	6	6	7	7	7	7
9		2	3	3	4	4	5	5	5	6	6	6	7	7	7	7	8	8	8
10		2	3	3	4	5	5	5	6	6	7	7	7	7	8	8	8	8	9
11		2	3	4	4	5	5	6	6	7	7	7	8	8	8	9	9	9	9
12	2	2	3	4	4	5	6	6	7	7	7	8	8	8	9	9	9	10	10
13	2	2	3	4	5	5	6	6	7	7	8	8	9	9	9	10	10	10	10
14	2	2	3	4	5	5	6	7	7	8	8	9	9	9	10	10	10	11	11
15	2	3	3	4	5	6	6	7	7	8	8	9	9	10	10	11	11	11	12
16	2	3	4	4	5	6	6	7	8	8	9	9	10	10	11	11	11	12	12
17	2	3	4	4	5	6	7	7	8	9	9	10	10	11	11	11	12	12	13
18	2	3	4	5	5	6	7	8	8	9	9	10	10	11	11	12	12	13	13
19	2	3	4	5	6	6	7	8	8	9	10	10	11	11	12	12	13	13	13
20	2	3	4	5	6	6	7	8	9	9	10	10	11	12	12	13	13	13	14

10 lentelė. Serijų kriterijaus $\alpha = 0,05$ lygmens viršutinės kritinės reikšmės

$n_1 \backslash n_2$	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
2																			
3																			
4				9	9														
5		9	10	10	11	11													
6		9	10	11	12	12	13	13	13	13									
7			11	12	13	13	14	14	14	14	15	15	15						
8			11	12	13	14	14	15	15	16	16	16	16	16	16	17	17	17	17
9				13	14	14	15	16	16	16	17	17	17	18	18	18	18	18	18
10				13	14	15	16	16	17	17	18	18	18	18	19	19	19	20	20
11				13	14	15	16	17	17	18	19	19	19	19	20	20	20	21	21
12				13	14	16	16	17	18	19	19	20	20	20	21	21	21	22	22
13					15	16	17	18	19	19	20	20	21	21	22	22	23	23	23
14					15	16	17	18	19	20	20	21	22	22	23	23	23	24	24
15					15	16	18	18	19	20	21	22	22	23	23	24	24	25	25
16						17	18	19	20	21	21	22	23	23	24	25	25	25	25
17						17	18	19	20	21	22	23	23	24	25	25	26	26	26
18						17	18	19	20	21	22	23	24	25	25	26	26	27	27
19						17	18	20	21	22	23	23	24	25	26	26	27	27	27
20						17	18	20	21	22	23	24	25	25	26	27	27	27	28

11 lentelė. Q statistikos kritinės reikšmės

i	j										
	α	2	3	4	5	6	7	8	9	10	11
5	0,05	3,64	4,60	5,22	5,67	6,03	6,33	6,58	6,80	6,99	7,17
	0,01	5,70	6,98	7,80	8,42	8,91	9,32	9,67	9,97	10,24	10,48
6	0,05	3,46	4,34	4,90	5,30	5,63	5,90	6,12	6,32	6,49	6,65
	0,01	5,24	6,33	7,03	7,56	7,97	8,32	8,61	8,87	9,10	9,30
7	0,05	3,34	4,16	4,68	5,06	5,36	5,61	5,82	6,00	6,16	6,30
	0,01	4,95	5,92	6,54	7,01	7,37	7,68	7,94	8,17	8,37	8,55
8	0,05	3,26	4,04	4,53	4,89	5,17	5,40	5,60	5,77	5,92	6,05
	0,01	4,75	5,64	6,20	6,62	6,96	7,24	7,47	7,68	7,86	8,03
9	0,05	3,20	3,95	4,41	4,76	5,02	5,24	5,43	5,59	5,74	5,87
	0,01	4,60	5,43	5,96	6,35	6,66	6,91	7,13	7,33	7,49	7,65
10	0,05	3,15	3,88	4,33	4,65	4,91	5,12	5,30	5,46	5,60	5,72
	0,01	4,48	5,27	5,77	6,14	6,43	6,67	6,87	7,05	7,21	7,36
11	0,05	3,11	3,82	4,26	4,57	4,82	5,03	5,20	5,35	5,49	5,61
	0,01	4,39	5,15	5,62	5,97	6,25	6,48	6,67	6,84	6,99	7,13
12	0,05	3,08	3,77	4,20	4,51	4,75	4,95	5,12	5,27	5,39	5,51
	0,01	4,32	5,05	5,50	5,84	6,10	6,32	6,51	6,67	6,81	6,94
13	0,05	3,06	3,73	4,15	4,45	4,69	4,88	5,05	5,19	5,32	5,43
	0,01	4,26	4,96	5,40	5,73	5,98	6,19	6,37	6,53	6,67	6,79
14	0,05	3,03	3,70	4,11	4,41	4,64	4,83	4,99	5,13	5,25	5,36
	0,01	4,21	4,89	5,32	5,63	5,88	6,08	6,26	6,41	6,54	6,66
15	0,05	3,01	3,67	4,08	4,37	4,59	4,78	4,94	5,08	5,20	5,31
	0,01	4,17	4,84	5,25	5,56	5,80	5,99	6,16	6,31	6,44	6,55
16	0,05	3,00	3,65	4,05	4,33	4,56	4,74	4,90	5,03	5,15	5,26
	0,01	4,13	4,79	5,19	5,49	5,72	5,92	6,08	6,22	6,35	6,46
17	0,05	2,98	3,63	4,02	4,30	4,52	4,70	4,86	4,99	5,11	5,21
	0,01	4,10	4,74	5,14	5,43	5,66	5,85	6,01	6,15	6,27	6,38
18	0,05	2,97	3,61	4,00	4,28	4,49	4,67	4,82	4,96	5,07	5,17
	0,01	4,07	4,70	5,09	5,38	5,60	5,79	5,94	6,08	6,20	6,31
19	0,05	2,96	3,59	3,98	4,25	4,47	4,65	4,79	4,92	5,04	5,14
	0,01	4,05	4,67	5,05	5,33	5,55	5,73	5,89	6,02	6,14	6,25
20	0,05	2,95	3,58	3,96	4,23	4,45	4,62	4,77	4,90	5,01	5,11
	0,01	4,02	4,64	5,02	5,29	5,51	5,69	5,84	5,97	6,09	6,19
24	0,05	2,92	3,53	3,90	4,17	4,37	4,54	4,68	4,81	4,92	5,01
	0,01	3,96	4,55	4,91	5,17	5,37	5,54	5,69	5,81	5,92	6,02
30	0,05	2,89	3,49	3,85	4,10	4,30	4,46	4,60	4,72	4,82	4,92
	0,01	3,89	4,45	4,80	5,05	5,24	5,40	5,54	5,65	5,76	5,85
40	0,05	2,86	3,44	3,79	4,04	4,23	4,39	4,52	4,63	4,73	4,82
	0,01	3,82	4,37	4,70	4,93	5,11	5,26	5,39	5,50	5,60	5,69
60	0,05	2,83	3,40	3,74	3,98	4,16	4,31	4,44	4,55	4,65	4,73
	0,01	3,76	4,28	4,59	4,82	4,99	5,13	5,25	5,36	5,45	5,53
120	0,05	2,80	3,36	3,68	3,92	4,10	4,24	4,36	4,47	4,56	4,64
	0,01	3,70	4,20	4,50	4,71	4,87	5,01	5,12	5,21	5,30	5,37
∞	0,05	2,77	3,31	3,63	3,86	4,03	4,17	4,29	4,39	4,47	4,55
	0,01	3,64	4,12	4,40	4,60	4,76	4,88	4,99	5,08	5,16	5,23

12 lentelė. Kuko statistikos kritinės reikšmės

Vardiklis	$\alpha = 0,50$											
	Skaitiklis											
	2	3	4	5	6	7	8	9	10	12	15	20
10	0,743	0,845	0,899	0,932	0,954	0,971	0,983	0,992	1,00	1,01	1,02	1,03
11	0,739	0,840	0,893	0,926	0,948	0,964	0,977	0,986	0,994	1,01	1,02	1,03
12	0,735	0,835	0,888	0,921	0,943	0,959	0,972	0,981	0,989	1,00	1,01	1,02
15	0,726	0,826	0,878	0,911	0,933	0,949	0,960	0,970	0,977	0,989	1,00	1,01
20	0,718	0,816	0,868	0,900	0,922	0,938	0,950	0,959	0,966	0,977	0,989	1,00
24	0,714	0,812	0,863	0,895	0,917	0,932	0,944	0,953	0,961	0,972	0,983	0,994
30	0,709	0,807	0,858	0,890	0,912	0,927	0,939	0,948	0,955	0,966	0,978	0,989
40	0,705	0,802	0,854	0,885	0,907	0,922	0,934	0,943	0,950	0,961	0,972	0,983
60	0,701	0,798	0,849	0,880	0,901	0,917	0,928	0,937	0,945	0,956	0,967	0,978
120	0,697	0,793	0,844	0,875	0,896	0,912	0,923	0,932	0,939	0,950	0,961	0,972
∞	0,693	0,789	0,839	0,870	0,891	0,907	0,918	0,927	0,934	0,945	0,956	0,967

13 lentelė. Durbino–Votsono kriterijaus $\alpha = 0,05$ lygmens kritinės reikšmės

$n \backslash k$	2		3		4		5	
	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U
15	0,95	1,23	0,83	1,40	0,71	1,61	0,59	1,84
16	0,98	1,24	0,86	1,40	0,75	1,59	0,64	1,80
17	1,01	1,25	0,90	1,40	0,79	1,58	0,68	1,77
18	1,03	1,26	0,93	1,40	0,82	1,56	0,72	1,74
19	1,06	1,28	0,96	1,41	0,86	1,55	0,76	1,72
20	1,08	1,28	0,99	1,41	0,89	1,55	0,79	1,70
21	1,10	1,30	1,01	1,41	0,92	1,54	0,83	1,69
22	1,12	1,31	1,04	1,42	0,95	1,54	0,86	1,68
23	1,14	1,32	1,06	1,42	0,97	1,54	0,89	1,67
24	1,16	1,33	1,08	1,43	1,00	1,54	0,91	1,66
25	1,18	1,34	1,10	1,43	1,02	1,54	0,94	1,65
26	1,19	1,35	1,12	1,44	1,04	1,54	0,96	1,65
27	1,21	1,36	1,13	1,44	1,06	1,54	0,99	1,64
28	1,22	1,37	1,15	1,45	1,08	1,54	1,01	1,64
29	1,24	1,38	1,17	1,45	1,10	1,54	1,03	1,63
30	1,25	1,38	1,18	1,46	1,12	1,54	1,05	1,63
31	1,26	1,39	1,20	1,47	1,13	1,55	1,07	1,63
32	1,27	1,40	1,21	1,47	1,15	1,55	1,08	1,63
33	1,28	1,41	1,22	1,48	1,16	1,55	1,10	1,63
34	1,29	1,41	1,24	1,48	1,17	1,55	1,12	1,63
35	1,30	1,42	1,25	1,48	1,19	1,55	1,13	1,63
36	1,31	1,43	1,26	1,49	1,20	1,56	1,15	1,63
37	1,32	1,43	1,27	1,49	1,21	1,56	1,16	1,62
38	1,33	1,44	1,28	1,50	1,23	1,56	1,17	1,62
39	1,34	1,44	1,29	1,50	1,24	1,56	1,19	1,63
40	1,35	1,45	1,30	1,51	1,25	1,57	1,20	1,63
45	1,39	1,48	1,34	1,53	1,30	1,58	1,25	1,63
50	1,42	1,50	1,38	1,54	1,34	1,59	1,30	1,64
55	1,45	1,52	1,41	1,56	1,37	1,60	1,33	1,64
60	1,47	1,54	1,44	1,57	1,40	1,61	1,37	1,65
65	1,49	1,55	1,46	1,59	1,43	1,62	1,40	1,66
70	1,51	1,57	1,48	1,60	1,45	1,63	1,42	1,66
75	1,53	1,58	1,50	1,61	1,47	1,64	1,45	1,67
80	1,54	1,59	1,52	1,62	1,49	1,65	1,47	1,67
85	1,56	1,60	1,53	1,63	1,51	1,65	1,49	1,68
90	1,57	1,61	1,55	1,64	1,53	1,66	1,50	1,69
95	1,58	1,62	1,56	1,65	1,54	1,67	1,52	1,69
100	1,59	1,63	1,57	1,65	1,55	1,67	1,53	1,70

Vartojamų terminų anglų-lietuvių kalbų žodynėlis

adjusted coefficient of determination – pataisytas determinacijos koeficientas
agglomeration methods – jungimo metodai
association coefficients – asociatyvumo koeficientai
block design – blokinė struktūra
canonical correlation – kanoninė koreliacija
classification function – klasifikavimo funkcija
cluster – klasteris
clusterization schedule – klasterizavimo eigos schema
coefficient of determination – determinacijos koeficientas
communality – bendrumas
complete linkage distance – pilnosios jungties (tolimiausio kaimyno) atstumas
Concordance coefficient – konkordacijos koeficientas
dendogram – dendograma
dependent variable – priklausomasis kintamasis
discrimination – atskiriamumas, diskriminavimas
distribution free tests – nepriklausantys nuo skirstinio testai
dummy variables – pseudokintamieji
eigenvalue – tikrinė reikšmė
experimentwise level of significance – eksperimento reikšmingumo lygmuo
factor extraction – faktorių išskyrimas
factor loadings – faktorių svoriai
factor rotation – faktorių sukimas
factor score – faktorių reikšmių įverčiai
heteroscedasticity – heteroskedastiškumas
hierarchical clustering methods – hierarchiniai klas-terizavimo metodai
homoscedasticity – homoskedastiškumas
interaction of factors – faktorių tarpusavio sąveika
k-means method – *k*-vidurkių metodas
least squares method – mažiausiųjų kvadratų meto-das
leverage – įtakos indeksas
linkage methods – jungimo metodai
matched pairs – suderintosios poros
metric – metrika

mixed model – mišrusis modelis
multicollinearity – multikolinearumas
nonlinear models – netiesiniai modeliai
oblique (nonorthogonal) rotation – neortogonalusis sukimas
odds – galimybė
odds ratio – galimybių santykis
oneway analysis of variance – vienfaktorinė disper-sinė analizė
orthogonal contrast – ortogonalusis kontrastas
outlier – išskirtis
part (semipartial) correlation – pusdalinė korelia-cija
partial correlation – dalinė koreliacija
partial η^2 – dalinis η^2
prediction interval – prognozės intervalas
principal components – pagrindinės komponentės
profile – profilis
randomized blocks – randomizuoti blokai
ranking – rangavimas
reduced correlation matrix – redukuotoji koreliacijų matrica
regression line – regresijos tiesė
residual – liekamoji paklaida
runs test – serijų kriterijus
second regression line – atvirkštinė regresijos tiesė
similarity measures – panašumo matai
single linkage distance – vienetinės jungties (arti-miausiojo kaimyno) atstumas
sphericity assumption – sferiškumo prielaida
standardized coefficients – standartizuotieji koefi-cientai
standardized residual – standartizuotoji liekana
sum of squares between – grupių kvadratų suma
sum of squares within – vidinė kvadratų suma
ties – susietosios reikšmės
total sum of squares – visa kvadratų suma
trend – trendas
two-way ANOVA – dvifaktorinė ANOVA
variance inflation factor – dispersijos mažėjimo dau-giklis

Dalykinė rodyklė

- bendrumas 240
- dendrograma 203
- diskriminavimas 215
- dispersinė analizė
 - vienfaktorinė 45
 - dvifaktorinė 81
 - blokuotųjų duomenų 101
- dispersijos sumažėjimo daugiklis 170
- eksperimento reikšmingumo lygmuo 47
- faktorių išskyrimas 244
- faktorių reikšmių įverčiai 253
- faktorių sukimas 251
- faktorių svoriai 240
- faktorių tarpusavio sąveika 82
- funkcija
 - kanoninė 221
 - klasifikavimo 231
 - regresijos 129
- galimybė 182
- galimybių santykis 184
- heteroskedastiškumas 128
- hierarchiniai klasterizavimo metodai 203
- homoskedastiškumas 128
- išskirtis 131
- įtakos indeksas 133
- kintamasis
 - nepriklausomas 126
 - priklausomas 126
 - populiacijos 48
- klasteris 195
- klasterizavimo eigos schema 203, 210
- koeficientas
 - asociatyvumo 200
 - determinacijos 136
 - Kendalo koreliacijos 37
 - konkordacijos 40
 - Spirmeno koreliacijos 33
- koreliacija
 - dalinė 166
 - kanoninė 224
 - pusdalinė 168
- kriterijus
 - Bartleto 75
 - Bonferonio 59
 - Čou 174
 - Durbino–Vatsono 142
 - Frydmano 30
 - Hosmerio–Lemešou 190
 - Kruskalo–Voliso 28
 - Livyno 76
 - Mano–Vitnio–Vilkoksono 20
 - nepriklausantis nuo skirstinio 7
 - post hoc* 57
 - serijų 12
 - Tjukio 61
 - Vilkoksono 15
 - Voldo 189
 - Voldo–Volfovico 25
- Kuko matas 134
- kvadratų suma
 - grupių 53
 - vidinė 53
 - visa 53
- liekamoji paklaida 130
- Makfadeno r^2 191
- metodas
 - jungimo 202
 - k -vidurkių 210
 - mažiausiųjų kvadratų 130
- metrika 197
- multikolinearumas 168
- ortogonalusis kontrastas 64, 65
- panašumo matai 197
- pagrindinė komponentė 245
- profilis 199
- prognozės intervalas 145
- pseudokintamasis 172
- randomizuoti blokai 101, 102
- rangavimas 10
- redukuotoji koreliacijų matrica 241
- sukimas
 - neortogonalus 252
 - ortogonalus 251
- standartizuotoji liekana 133
- susietosios reikšmės 12
- tiesė
 - atvirkštinė regresijos 130
 - regresijos 129
- tikrinė reikšmė 245
- trendas 66

Statistinių metodų schema

Problema	Duomenys (kintamieji)		
	Normalieji	Ranginiai	Nominalieji
Dviejų nepriklausomų imčių lyginimas	Stjudento t kriterijus	Mano–Vitnio–Vilkoksono kriterijus	Proporcijų lygybė
Dviejų priklausomų imčių lyginimas	Porinis Stjudento t kriterijus	Vilkoksono kriterijus	Maknemaro kriterijus
Trijų ir daugiau nepriklausomų imčių lyginimas	ANOVA	Kruskalo–Voliso kriterijus	Chi kvadratu nepriklausomumo kriterijus
Trijų ir daugiau priklausomų imčių lyginimas	Blokuotųjų duomenų ANOVA	Frydmano kriterijus	
Dviejų kintamųjų priklausomybės vertinimas	Pirsono koreliacija	Spirmeno koreliacija	
Kintamojo reikšmių prognozavimas pagal kito kintamojo reikšmes	Tiesinė regresija		
Kintamojo reikšmių prognozavimas pagal kitų kintamųjų reikšmes	Daugialypė regresija		
Objektų grupavimas pagal kintamųjų reikšmes	Klasterinė analizė		
Grupių atskiriamumas ir patekimo į jas prognozavimas	Diskriminantinė analizė Logistinė regresija		Logistinė regresija
Kintamųjų grupavimas pagal jų koreliacijas	Faktorinė analizė		

Literatūra

1. Čekanavičius V., Murauskas G. *Statistika ir jos taikymai*. I. Vilnius: TEV, 2000, 240 p.
2. Kruopis J. *Matematinė statistika*. Vilnius: Mokslo, 1993, 416 p.
3. Affifi A., Clark V. A. *Computer-Aided Multivariate Analysis*. 3rd edn. London: Chapman and Hall, 1996.
4. Berenson M. L., Levine D. M. *Basic Business Statistics: Concepts and Applications*. 7th edn. Prentice Hall, 1999, 1114 p.
5. Everit B. S. *Cluster Analysis*. Wiley, 1993.
6. Gorsuch R. L. *Factor Analysis*. Hillsdale, NJ: Erlbaum, 1983.
7. Johnson R. A., Wichern D. W. *Applied Multivariate Statistical Analysis*. 4th edn. Prentice Hall, 1998.
8. Klecka, W. R. *Discriminant Analysis*. Beverly Hills: Sage Publications, 1980.